JLENS · QWEN3-32B 作者记忆 · 进度汇报

模型在哪一层“知道”一篇论文的作者

截至 2026-11-04，Stage 1–13 全部完成（答辩定稿，git tag defense-2026-11）。数字均可在实验记录 v26 和方法手册中追到出处文件。

2026-11-06 合并更新：本页与讲稿版《给老师的进度汇报》合并为一个当前版本（加入了讲稿版的“自查中发现并修正的问题”表和“下一步”）；答辩后的结果见下方更新框。讲稿版不再单独更新。

2026-11-06 更新：答辩后的重做计划（批次 1 结果，用户已确认措辞）

以下数字都来自看结果前写定规则的重做项目（补充 9–14），复现已发表数字是每一项的硬检查。本页其余内容保持原样，后来被更新的说法在原处加了橙色标注，原数字未改。

- **X1–X4 改为全部作者（批次 1 第 1 项，已完成，硬检查 PASS）：**X1–X4 改为给全部作者打分（全部名字 token），并按作者排位分层。结论都不变：X1 仍与任务无关，L48 有一点小而确实的任务依赖（作者 − 年份 +0.024 [0.019, 0.030]）；X3 改写标题保留约 90% 的作者偏好，target 与 control 一样；X4 从 L8 起可解码出作者，各作者排位相同，认得出的论文方向上更高，但按预注册在测试集上不显著（L8 +0.023 [−0.001, +0.048]，v42_paper_vs_team.md §3）；但只靠标题文字的基线不弱于 Qwen，仍不能排除标题文字的解释。X2 用全部作者重新拟合作者子空间后，搬动量从 0.016 升到 0.032（完整替换的约 7%），但子空间本身仍几乎解码不出作者（留出 $R^2 \leqslant 0.009$），H3 仍证据不足。（381_stage13/reports/b1_xall_report.md：X1 节（测试集，作者 − 年份，团队聚类 bootstrap 2,000 次）；X3 behaviour 表（测试集 552 篇，恢复比 0.897 [0.868, 0.926]）；X4 节（L8，全部作者 +0.048 [0.039, 0.058]；Recognition 表）；X2 verdict 表（L48 R_auth）；New S_auth 表（authall_r2 ⩽ 0.009）；Hard check 表）
- **E4b 减 5 个假标题（实际每篇可用假标题个数见正文）（批次 1 第 4 项，已完成）：**E4b 逐个假标题排除版（偏离 D1，保留 4,654 篇，每篇平均约 1.5 个可用假标题，0–4 个；预注册版只减 false_0、1,395 篇时 L40 姓首 token 为 +0.071）：L40 姓首 token +0.076 [0.068, 0.083]，姓 − 首字母 +0.033 [0.023, 0.042]，逐个排除版（4,654 篇）第一个 token +0.066；原 E4b（1,395 篇）+0.061；置换对照首字母仍 +0.018，其余 ≈ 0；硬检查 E4b L40 +0.0609 PASS。标题位置 probe 的 target − control（同一引用档内）有三个版本：① 预注册版（只减 false_0；false_0 是唯一检查过标题复用的假标题，干净的单一对照；名 1,706、姓 1,395、首字母 1,590 篇）：名的第一个 token L24 +0.051 [0.007, 0.095]、L40 +0.049 [0.005, 0.095]、L48 +0.073 [0.027, 0.122]；姓 L24 −0.002 [−0.037, +0.036]、L40 +0.012 [−0.026,

+0.048]、L48 +0.016 [−0.025, +0.056]；首字母 L24 +0.033 [0.005, 0.059]、L40 +0.031 [−0.001, +0.062]、L48 +0.056 [0.025, 0.089]（与补充 9 已发表值相同，e4b_alltok.md）。② 逐个排除版（事后偏离 D1；每篇平均约 1.5 个可用假标题；名 3,046、姓 4,654、首字母 4,812 篇）：名 L24 +0.037 [0.012, 0.062]、L40 +0.048 [0.021, 0.076]、L48 +0.051 [0.023, 0.081]；姓 L24 +0.019 [0.001, 0.038]、L40 +0.030 [0.013, 0.048]、L48 +0.042 [0.025, 0.060]；首字母 L24 +0.026 [0.012, 0.040]、L40 +0.014 [−0.002, +0.030]、L48 +0.031 [0.014, 0.048]。③ "5 个假标题平均"版（仅敏感性参考：论文同①，只按 false_0 剔除，false_1..4 中约 79% 本应剔除，含泄漏；名 1,706、姓 1,395、首字母 1,590 篇）：名 L40 +0.047 [0.012, 0.081]；姓 L40 +0.024 [−0.006, +0.052]、L48 +0.031 [0.001, 0.059]；首字母 L40 +0.021 [−0.002, +0.043]。结论：预注册版中名的第一个 token 在 L24–L48 为正，姓在 L24–L48 不显著（L40 +0.012 [−0.026, +0.048]）；事后的逐个排除版中姓从 L24 起为正（L40 +0.030 [0.013, 0.048]）。名的信号在三版中一致；姓的证据弱，只来自事后版本。首字母在个别层为正、模式不一致（未做多层校正），不作结论

（381_stage13/summary_b1_e4b5/perdonor_by_run_layer.csv（version = V0 / Vpd / V5x0，列 tc / tc_lo / tc_hi；引用档内 target − control，团队整群 bootstrap 2,000 次 95% CI）；381_stage13/reports/e4b_alltok.md；b1_e4b5_report.md）。

- **X7 五个假标题（批次 1 第 2 项，已完成）：** X7 补做了另外 4 个假标题，按 5 个平均判定，target、control 和全部论文都满足预注册判据（S(L52) 分别为 +0.022、+0.042、+0.028，均 ≤ 0.05）；原来对照组只用 false_0 时为 0.051，属于单个假标题的波动。（381_stage13/reports/b1_x7f_report.md（target 593 / control 593 / 全部 1,186 篇，团队聚类 95% CI））
- **C-3b（补充 13，只作敏感性分析，含泄漏，不作结论）：** 5 个假标题版本不剔除标题复用：硬检查 PASS；L40 姓的第一个 token +0.077 [0.071, 0.084]，首字母 +0.034 [0.029, 0.039]，姓 − 首字母 +0.043 [0.035, 0.051]（6,841 篇）；target − control 的区间几乎处处在 0 以上，与 C-3 一样。（381_stage13/reports/c13_C3b.md（Primary contrasts at L40 表 V5x0_noexcl 列））
- **P1 / P2 用 5 个假标题（批次 1 第 3 项）：还在运行**，194 个计算单元已完成 187 个，结果尚未出来；结果经用户确认后补入。（g391_b1p12f 作业链（14_groups/b1_p12f_gpu_v2.sbatch））
- **答辩后已完成、以前写“没做 / 暂停”的项目：** X2 只替换子空间（补充 6，2026-11-05）：按预注册判据 H2 不支持、H3 通过，但作者子空间几乎解码不出作者，H3 证据仍不足；全部名字 token 的标题位置 probe（补充 9）：L40 姓的第一个 token +0.071 [0.058, 0.085]；X5 跨问法检索曲线：没有一层高于 L4；M5 能用已有数据回答的部分；CPU 项 C-1 到 C-5（Stage 7.1 加标题对照、Stage 8 CPU 代理、不剔除标题复用的敏感性、M1 换 4 个假标题、Stage 10 附加分析补齐全部已存层）。

（381_stage13/reports/x2_report.md；e4b_alltok.md 第 5 节；x5_retrieval.md；m5_report.md；c13_C1.md–c13_C5.md）

- **批次 2（补充 11、12）：**代码、tiny 测试和硬检查的单元测试都已完成，批次 1 结束后由编排作业自动开始（含 Stage 9 Fit B 与 holdout、F1 对半拆分、名字位置 probe 等）；与预注册的出入记在出入记录 D12-1 到 D12-3（2-1、2-2 较省但含原始提示逐位复现重拟合的硬检查；2-11 重建标签、论文内 AUROC、两个基线、对照组只作描述），2-7 的来源改用不含年份的 X4 提示。**批次 3（补充 14）：**3-1 Stage 10 补 L41–L47、L49，3-2 补 L0–L23：代码已就绪，第二批之后开始；3-3 Stage 7.1B 快路径：已停止（偏离 D14-1）：3-3 停止：只有 7 篇论文同时有旧逐前缀结果和快路径结果，不足以确认两者在 ±0.02 内等效（输出层 target−control 差值之差 +0.0059，按论文 Welch 95% CI [−0.0207, +0.0324]；论文级 bootstrap [−0.0005, +0.0181]，因每组仅 3–4 篇偏窄，不作判据）。差异来源为 bf16 舍入随前向长度变化；长度跨档比例 target 28%、control 15%。Stage 10 全程使用快路径，组间口径一致，一致性检查按 0.25 容差（351_stage10.py 第 919 行）通过率 99.81%。决定过程：原判据（≥ 99% 名次完全一致）未通过（79.8%）→ 用户指出事后判据的设计缺陷 → 在看到论文级结果之前写定并锁定修正判据 → 按修正判据（Welch 区间）仍未通过 → 停止；3-4、3-5（Stage 8 按 W 的 GPU 重算）不做。

  （381_stage13/config/prereg_addendum11.json、prereg_addendum12.json、prereg_addendum12_deviations.json、prereg_addendum14.json；381_stage13/reports/b2_groupA_handoff.md）

研究问题。Qwen3-32B 常常在开放回答里写不出一篇论文的作者，却能在多选题里认出真作者名单。那么作者信息在网络的哪一层形成、经过哪些位置、能被哪种读出工具看到？

> **一句话结论：读得早，说得晚。**论文信息从 L24 起在标题位置逐渐形成，在 L44–L52 进入名字位置（部分经由标题之后的 token）；但作者名字要到 L57–L61 才在名字位置被 lens 读出。“认得出”与“认不出”的论文只在最后几层拉开差距。中间层能读出论文的属性和标题的意思，但没有证明它表示的是“这一篇论文”本身。

怎么系统地做

研究分四条论证线，每条线先在小样本上建立信号、逐一排除替代解释，再在全部论文上复核和干预：

论证线	要回答的问题	小样本（Stage 1–9，20–200 篇）	全量（Stage 10–13，9,108 篇）
A 这篇论文?	信号是否针对这篇论文，而不是名字本身好猜	5、7.2、7.3、8	10 标题特异信号；11 名字先验、probe 对照；13 X3
B 读出工具	不同读出工具各能看到什么	3、7.4、8、9	10 三种 Jacobian lens 与 logit lens；11 线性 probe；12 作者提示 lens；13 M2、X4
C 哪一层	信号何时出现、何时被使用	4、7.2、7.3、8	10 细层 L50–61；11 替换与阻断；12 P1/P2；13 X5–X7
D 哪个 token	名字和提示的哪一部分带有信号	6、7.1	10 名字格式与 token 角色；11 标题之后的 token

每一步用的控制

- **对照组：**“认得出”（target，4,621 篇）与“认不出”（control，2,220 篇）只在多选识别上不同；比较都在同一引用档内做。只用两组都没写对作者的论文（R0）复核，结论不变（输出处 `+0.199 [0.188, 0.212]`）。
- **标题特异信号：**真标题减去 5 个按领域和长度匹配的假标题的平均，另设“无标题”条件估计名字先验。
- **因果干预：**把真标题运行的表示替换进假标题运行（替换），或从某层起阻断对标题的注意力（阻断）；Stage 13 用另外 4 个假标题重做（X6、X7）。
- **预注册：**Stage 13 的判定规则在看数据前写定（prereg.json + 补充 1–5，均有 sha256）；所有层都报告，不挑层；调参集选、测试集确认。
- **统计：**区间以按作者团队整群重抽的 bootstrap 为主（同名作者的论文并为一组），probe 按团队分折，分折已存档并核对与原始运行一致。
- **文本基线：**用 BERT、TF-IDF、句子向量模型 all-mpnet 检查“只看标题文字能否得到同样结果”。
- **工程自检：**每个 GPU 作业前先在微型随机模型上跑通全流程，再跑一个真实分片；作业内做复现核对（如 X4 按 token 重算与原分数 4,712 个值逐位相同；P2 钩子的完全替换检查逐位恢复）。

主要发现

1 **真标题有帮助，而且针对这篇论文。**

小样本：L56 真标题比错误标题高 +9.3 pp（Pilot50），在 200 篇新论文上 +5.18 pp [+2.93，+7.48]（Stage 8 冻结设计）。全量：标题特异信号在 L62 约 0.44；名字先验只占目标−对照差的约 0.35（约三分之一），在姓的第一个 token 上约为 0。

2 **“认得出”的优势是真的，但只在最后几层出现。**

引用档内的目标−对照差：中间层约为 0，输出处 +0.21。写对了部分作者的论文（R1）最强，但时间点相同。标题特异信号随引用数单调上升（ρ = 0.451）。

3 **论文信息从 L24 起在标题位置逐渐形成，在 L44–L52 进入名字位置。**

替换标题之后的 token：L48 恢复 0.82，L52 恢复 0.995（5 个假标题平均，各假标题之间相差不超过 0.02）。从 L52 起阻断对标题的注意力，论文特有损失只剩 0.029（control 组 0.051，略高于 0.05 的预注册界线，到 L54–56 降为 0）〔2026-11-06 已更新：X7 按 5 个假标题平均，control +0.042，已满足判据；见页首更新框〕。只替换名字位置在 L52 恢复 0.85，只替换 “:” 最多 0.17。注意力在 L48 把标题带进来（0.23），MLP 在 L52–56 接手（0.18、0.22）。

4 **读出工具在中间层读不到“这篇论文的作者”。**

名字位置上，logit lens 和三种 Jacobian lens 在 L24–L48 的标题特异信号约为 0，Jacobian lens 多读出的只是“名字形状”；在作者提示上重新拟合的 lens（Stage 12 F2）也要到 L62 才区分目标组。标题位置的线性 probe 能读出少量论文特有信号（L24 +0.050、L40 +0.061、L56 +0.075，换成随机论文的作者后约为 0；E4b，target + control 1,395 篇，训练折标准化），但它只给名字第一个 token 打分，而这多半是首字母。〔2026-11-06 已更新：补充 9 给全部名字 token 打分，L40 姓的第一个 token +0.071；逐个假标题排除版（4,654 篇，每篇约 1.5 个可用假标题）+0.076；见页首更新框〕

5 **中间层在标题位置表示论文的属性，在 “:” 位置表示任务。**

标题最后一个 token 上，probe 读出发表年份 R^2 从 0.38（L16）升到 0.56，引用数到 0.53，领域准确率约 0.70–0.72，“是否认得出”AUROC 0.62–0.67。换问法的对照（M3）显示标题位置的表示不随问法改变，但从不高于 L4（只有文字的层），所以不能说明超出文字；“:” 位置按问题重新组织。跨问法替换（X1）效果与问法无关。

6 **改写标题：中间层表示了意思，但分不出是否“认出了论文”。**

改写后的标题在 L28–L40 比用词相近的另一篇论文更接近原标题（最高 L36 +0.16，超出 L4 文字水平），按预注册判据判为“存在论文身份信号”。事后加的检验把解读降级：只懂语义、不认识作者的句子向量模型在用词匹配的子集上也有相当的优势；中间层优势和行为恢复（约 90%）在 target 与 control 之间没有差别。两者都报告，并记为与预注册的出入。

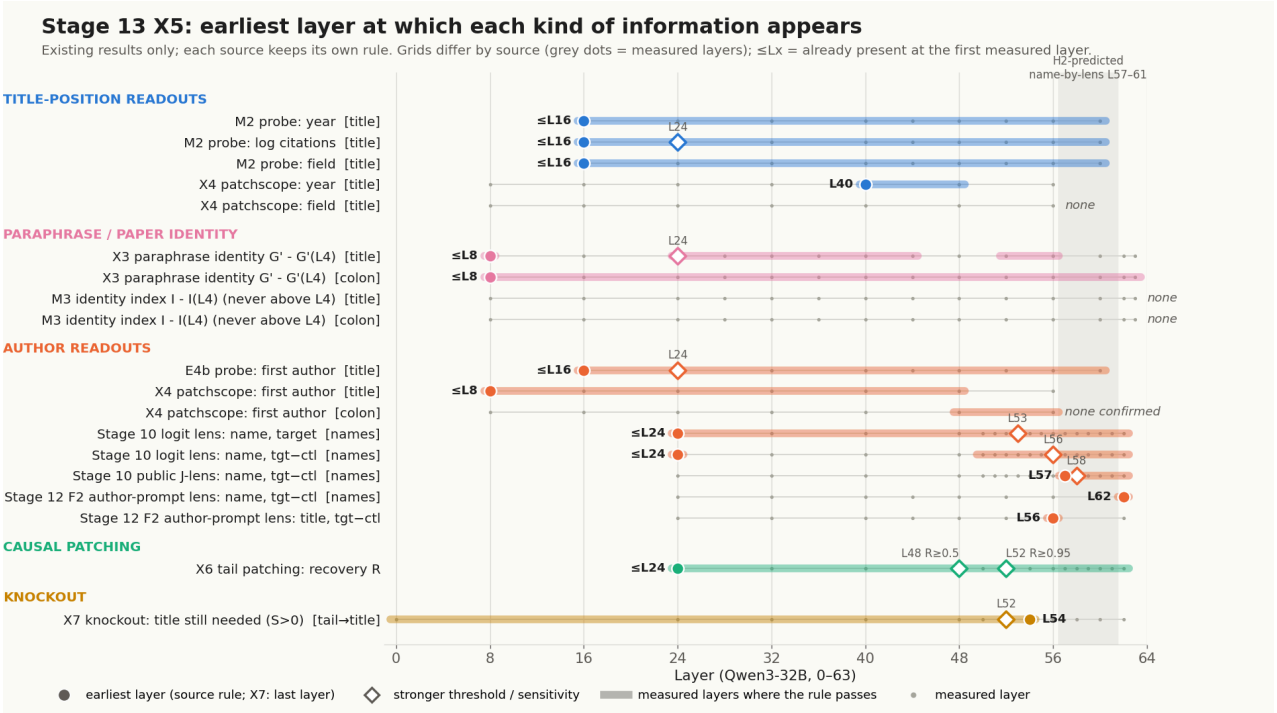
7 **从论文自己的标题状态，L8 就能解码出第一作者，但可能来自标题文字。**

X4 把标题状态注入中性提示：第一作者 L8 起可解码（+0.046 [0.035, 0.059]，主要在姓上），年份到 L40 才弱弱地出现，领域读不出，与“论文身份先于作者”的预测方向相反。在名的首 token 上，纯文本基线（BERT）不弱于 Qwen，所以不能排除文字解释。

8 **名字内部：信号在姓上，首字母几乎不带信号。**

73% 的作者名以首字母开头，此时信号几乎都在后面的姓上（目标−对照 +0.253，首字母本身 +0.048）；完整的名本身也带信号。

层序汇总（X5，只用已有结果）



圆点为按各来源规则最早出现的层，菱形为更严的阈值，灰带为预注册中 H2 预测“lens 读出名字”的 L57–61。图中标签为英文（集群上没有中文字体）。

三个假设的现状

假设	现状	依据
H1 中间层主要表示任务 / 格式	在 “:” 和名字位置成立	“:” 和名字位置承载任务；标题位置承载论文属性和超出用词的意思，没有证明是论文身份
H2 中间层表示“是哪一篇论文”	部分支持，未确立	支持：M2 读得出论文属性，X1 替换与问法无关。不支持或分不开：M3 不高于 L4；X3 分不开语义与论文身份；X4 顺序与预测相反
H3 作者信息已在，只是不在词表方向	证据不足	X4 文本基线不弱于 Qwen；只替换子空间的因果检验（X2）没有做〔2026-11-06 已更新：X2 已于 2026-11-05 完成，H3 仍证据不足；见页首更新框〕

各阶段完成情况

阶段	状态	说明
Stage 1–6、7.2、7.3、8	完成	Stage 8 冻结主终点复现 +2.33 / +2.41 pp；Holm 校正后只有 L62 显著；无出处的区间已从原始数据重算
Stage 7.1	部分	7.1B 停在 1,166 / 15,519，内容由 Stage 10 覆盖
Stage 9	部分	Fit A 完成；Fit B 停在 66/100，答辩前不补（lens 拟合稳定性只有一份证据）〔2026-11-06 已更新：Fit B 与 holdout 列入批次 2，代码已就绪，自动开始；见页首更新框〕
Stage 10、11	完成	全量逐层读出；替换与阻断
Stage 12	完成	单位置替换、注意力与 MLP 分开替换（钩子显式检查通过）、名字先验、作者提示 lens
Stage 13	完成	M1–M3、X1、X3–X7 完成；M4 由 Stage 12 完成；M5 并入 X4；X2 暂停未做〔2026-11-06 已更新：X2 已完成；M5 的 CPU 部分已完成；X1–X4 已改为全部作者重做；见页首更新框〕

复核中发现并改正的问题

- E4b“只用假标题训练、信号反而更强”来自泄漏（同一借出标题同时在训练和测试里）；按团队分折并剔除标题复用后，信号与普通 probe 相当。标准化改为只在训练折内拟合；

两种标准化差别最大 0.0007，无结论翻转

- M3 自动判定原来按绝对阈值写成“支持”，不符合补充 2；按规则重判为不支持。
- 团队分折在支持 AVX-512 的节点上会不同；核对后所有原始运行与存档一致（点估计差 0），现统一读存档。
- X4 首次逐 token 自检对不上，原因是批大小不同造成的 bf16 舍入；按原批大小重算后逐位一致。
- Stage 8：分析计划在 10-18 14:29 写定锁定（主终点为 7 层积分），同日 21:14 的 PROTOCOL 改为 L56，两者都早于 8C 打分；改动人和理由待查（U28）；git 中没有改动记录。

自查中发现并修正的问题（汇总表，来自讲稿版进度汇报第七节）

问题	影响	处理
假标题被重复借用，同一标题出现在训练和测试	M2 的假标题结果虚高	作废
probe 没按作者团队分折	结果可能偏高	全部改为按团队分折重跑，结论不变
一个标题既当真标题又当假标题	probe 结论可能虚高	剔除后重跑（剩 1,863 篇），信号仍在；“只用假标题训练信号更强”一说撤回
置信区间按论文独立重抽	区间偏窄	改为团队整群 bootstrap，点估计不变
Stage 11 替换范围包含名字位置	“信息存在标题后 token 上”的解释不对	Stage 12 拆开后改为“进入名字位置”
替换只用一个假标题、阻断可能搞乱模型	时间点可能偶然	X6、X7 补做，结论成立〔2026-11-06 已更新：X7 已按 5 个假标题平均重判，三组都成立；见页首更新框〕
Stage 8 分析计划在 10-18 14:29 写定锁定（主终点为 7 层积分），同日 21:14 的 PROTOCOL 改为 L56，两者都早于 8C 打分；改动人和理由待查（U28）	可能“挑了有利终点”	补报原定主终点（仍显著）、Holm、逐对剔除

问题	影响	处理
M3 自动判定没按预注册规则	H2 被过度支持	按补充 2 重判为不支持
X4 文本基线代码错误、阳性对照失败	H3 被过度支持	修正后结论反转为“不能排除文字解释”
几个区间和数字找不到计算文件	无法复现	从原始数据重算替换，数值都在原范围内

出处：讲稿版进度汇报（https://claude.ai/artifact/8XcY8CRpz3AAjfDE4n6V6e）第七节；各条的详细记录与出处文件见方法手册附录 G4（V01–V62）和实验室过程汇总（https://claude.ai/artifact/TmqEtZg3gHTz7p7vCkaiB4）第 6 节。本表各行没有逐行列出结果文件。

局限

- 只用了一个模型（Qwen3-32B，bf16）。
- Stage 7.1B 的终端读出只完成 1,166 / 15,519 个上下文（7.5%）；用 Stage 10 快路径补完的尝试（补充 14 第 3-3 项）因无法确认与旧逐前缀结果等效而停止，7.1B 的估计量不报告。（偏离 D14-1）
- Stage 8 RQ2 在 L56 的结论没有用原统计量复核（偏离 D13-1）。
- 所有结论是教师强制打分下模型对正确作者的偏好，不是自由生成的过程。
- “认得出 / 认不出”的标签来自组里的标注包，生成标签的代码（elm）不在集群上。
- lens 的拟合稳定性只有 Stage 9 Fit A 一份证据；作者提示 lens 没做对半拟合。〔2026-11-06 已更新：Fit B 与 F1 对半拆分都列入批次 2；见页首更新框〕
- X5 预注册的“跨问法检索”曲线没有计算；X2（只替换子空间）没有做。〔2026-11-06 已更新：X5 检索曲线与 X2 都已在答辩后完成；见页首更新框〕

需要确认的问题

请组长确认

- 两次标注运行的 run.json 与 elm 代码版本；多选题是否关闭 thinking、答案位置在哪里。
- panel.py 的名字切分规则；多选干扰团队的抽取规则（年份与人数容差、是否排除共同作者、随机种子）；“et al.” 截断规则；Stage 1 标注运行的配置。

需要我自己补的记录

- Stage 8 主终点从 7 层积分改为 L56 的决定与依据（影响唯一的确认性检验）。
- Exp 1–7 编号来源文档；7.1B 是否有意停止；public lens 的模型与语料版本（需问 Neuronpedia）；Stage 10 冻结版本与运行版本之间的改动。

待确认与下一步（来自讲稿版进度汇报第九节）

待确认：

- 向组长确认 6 项标签流程细节（elm 代码和运行记录、多选题 thinking 设置、名字切分规则、干扰团队抽法、et al. 截断规则、运行配置）。
- Stage 8 主终点改动的来由，正在查当时的会话记录。

可能的下一步（希望听取老师意见）：

1. 换一个模型复现主要结果，检验“读得早、说得晚”是否普遍。
2. 在模型自由生成时检验，看内部信号能否预测它最终写对还是写错。
3. 设计新的实验区分“认出论文”和“懂得标题意思”，比如用模型不可能见过的虚构论文作对照。
4. 补完 Fit B，加固读出工具的稳定性证据。〔2026-11-06 已更新：Fit B 与 holdout 已列入批次 2（补充 12 第 2-1 项），代码已就绪，批次 1 结束后自动开始；见页首更新框〕

“可能的下一步”是建议，没有数据支撑，不是结论。

材料

以下页面都需要登录并获得共享权限才能打开。

实验记录 v26：〔2026-11-06 已更新：当前为第 29 版（本地已备，待发布）；见页首更新框〕claude.ai/artifact/QB335qoaBWvSdFyfvc2bSe

方法手册（每个数字附出处）：claude.ai/artifact/W7r7xVte3eaNcbo8D8cybo

合并 PPT v16：〔2026-11-06 已更新：当前为 v20（本地已备，待发布）；见页首更新框〕claude.ai/artifact/XcgK4YF2dYQxudWfhk8MsD

PDF 与 pptx 下载：claude.ai/artifact/5Tdt1mQa8xnPiqQEKvjzta

代码与结果：GitHub ZhiQ1/jlens-authorship-recall，tag `defense-2026-11`