方法补遗：方法空白与矛盾逐条回答

回答对象：上一轮对讲稿、交接文档和 PPT v16 的审读清单。标准：现有资料能否把实验重跑出来。2026-11-05 编写。

依据与限制。所有答案取自方法手册定稿（Stage 1–13 方法手册，2026-11-03），辅以实验记录 v26、讲稿在线版和 PPT v16（含 pptx 备注）。“出处”一栏照抄手册给出的脚本路径、行号、结果文件、作业号和 commit；**本补遗没有登录集群逐一核对这些出处**。手册里写“未知/需确认”或根本没有写的，这里写“未知”，并注明该问谁。没有用记忆补任何数字。

路径缩写沿用手册：`R10` = /scratch/zhang.zhiqi2/jlens/351_stage10/，`R11` = …/361_stage11/，`R12` = …/371_stage12/，`R13` = …/381_stage13/，`C10`–`C13` = ~/jlens_work/10_stage10/ … 13_stage13/。git 仓库 = /scratch/zhang.zhiqi2/jlens-authorship-recall_update。

2026-11-06 / 11-08 更新：答辩后的重做计划（批次 1 全部结果、批次 2 的 C / D 组补全、报告第 30 版的前提和局限，用户已确认措辞）

以下数字都来自看结果前写定规则的重做项目（补充 9–14），复现已发表数字是每一项的硬检查。本页其余内容保持原样，后来被更新的说法在原处加了橙色标注，原数字未改。

- **X1–X4 改为全部作者（批次 1 第 1 项，已完成，硬检查 PASS）：** X1–X4 改为给全部作者打分（全部名字 token），并按作者排位分层。结论都不变：X1 仍与任务无关，L48 有一点小而确实的任务依赖（作者 − 年份 +0.024 [0.019, 0.030]）；X3 改写标题保留约 90% 的作者偏好，target 与 control 一样；X4 从 L8 起可解码出作者，各作者排位相同，认得出的论文方向上更高，但按预注册在测试集上不显著（L8 +0.023 [−0.001, +0.048]，v42_paper_vs_team.md §3）；但只靠标题文字的基线不弱于 Qwen，仍不能排除标题文字的解释，这一差别不再作为 H2 的证据（只看标题文字的 BERT 基线 +0.088 不弱于 Qwen L8 +0.018）。X2 用全部作者重新拟合作者子空间后，搬动量从 0.016 升到 0.032（完整替换的约 7%），但子空间本身仍几乎解码不出作者（留出 $R^2 \leqslant 0.009$），H3 仍证据不足。（381_stage13/reports/b1_xall_report.md：X1 节（测试集，作者 − 年份，团队聚类 bootstrap 2,000 次）；X3 behaviour 表（测试集 552 篇，恢复比 0.897 [0.868, 0.926]）；X4 节（L8，全部作者 +0.048 [0.039, 0.058]；Recognition 表）；X2 verdict 表（L48 R_auth）；New S_auth 表（authall_r2 ⩽ 0.009）；Hard check 表）
- **E4b 减 5 个假标题（实际每篇可用假标题个数见正文）（批次 1 第 4 项，已完成）：** E4b 逐个假标题排除版（偏离 D1，保留 4,654 篇，每篇平均约 1.5 个可用假标题，0–4 个；预注册版只减 false_0、1,395 篇时 L40 姓首 token 为 +0.071）：L40 姓首 token +0.076 [0.068, 0.083]，姓 − 首字母 +0.033 [0.023, 0.042]，逐个排除版（4,654 篇）第一个 token +0.066；原 E4b（1,395 篇）+0.061；置换对照首字母仍 +0.018，其余 ≈ 0；硬检查 E4b L40 +0.0609 PASS。标题位置 probe 的 target − control（同一引用档内）有三个版本：① 预注册版（只减 false_0；false_0 是唯一检查过标题复用的假标题，干净的单一对照；名 1,706、姓 1,395、首字母 1,590 篇）：名的第一个 token L24 +0.051 [0.007, 0.095]、L40 +0.049 [0.005, 0.095]、L48 +0.073 [0.027, 0.122]；姓 L24 −0.002 [−0.037, +0.036]、L40 +0.012 [−0.026, +0.048]、L48 +0.016 [−0.025, +0.056]；首字母 L24 +0.033 [0.005, 0.059]、L40 +0.031 [−0.001, +0.062]、L48 +0.056 [0.025, 0.089]（与补充 9 已发表值相同，e4b_alltok.md）。② 逐个排除版（事后偏离 D1；每篇平均约 1.5 个可用假标题；名 3,046、姓 4,654、首字母 4,812 篇）：名 L24 +0.037 [0.012, 0.062]、L40 +0.048 [0.021, 0.076]、L48 +0.051 [0.023, 0.081]；姓 L24 +0.019 [0.001, 0.038]、L40 +0.030 [0.013, 0.048]、L48 +0.042 [0.025, 0.060]；首字母 L24 +0.026 [0.012, 0.040]、L40 +0.014 [−0.002, +0.030]、L48 +0.031 [0.014, 0.048]。③ "5 个假标题平均"版（仅敏感性参考：论文同①，只按 false_0 剔除，false_1..4 中约 79% 本应剔除，含泄漏；名 1,706、姓 1,395、首字母 1,590 篇）：名 L40 +0.047 [0.012, 0.081]；姓 L40 +0.024 [−0.006, +0.052]、L48 +0.031 [0.001, 0.059]；首字母 L40 +0.021 [−0.002, +0.043]。结论：预注册版中名的第一个 token 在 L24–L48 为正，姓在 L24–L48 不显著（L40 +0.012 [−0.026, +0.048]）；事后的逐个排除版中姓从 L24 起为正（L40 +0.030 [0.013, 0.048]）。名的信号在三版中一致；姓的证据弱，只来自事后版本。首字母在个别层为正、模式不一致（未做多层校正），不作结论（381_stage13/summary_b1_e4b5/perdonor_by_run_layer.csv（version = V0 / Vpd / V5x0，列 tc / tc_lo / tc_hi；引用档内 target − control，团队整群 bootstrap 2,000 次 95% CI）；381_stage13/reports/e4b_alltok.md；b1_e4b5_report.md）。

- **X7 五个假标题（批次 1 第 2 项，已完成）：**X7 补做了另外 4 个假标题，按 5 个平均判定，target、control 和全部论文都满足预注册判据（S(L52) 分别为 +0.022、+0.042、+0.028，均 ≤ 0.05）；原来对照组只用 false_0 时为 0.051，属于单个假标题的波动。（381_stage13/reports/b1_x7f_report.md（target 593 / control 593 / 全部 1,186 篇，团队聚类 95% CI））
- **C-3b（补充 13，只作敏感性分析，含泄漏，不作结论）：**5 个假标题版本不剔除标题复用：硬检查 PASS；L40 姓的第一个 token +0.077 [0.071, 0.084]，首字母 +0.034 [0.029, 0.039]，姓 − 首字母 +0.043 [0.035, 0.051]（6,841 篇）；target − control 的区间几乎处处在 0 以上，与 C-3 一样。（381_stage13/reports/c13_C3b.md（Primary contrasts at L40 表 V5x0_noexcl 列））
- **P1 / P2 用 5 个假标题（批次 1 第 3 项，已完成，硬检查 PASS）：**按补充 10 第 27 行，5 个假标题平均为主结果，原 false_0 版并列。两版所有“5 个假标题平均 − false_0”的区间都含 0，已发表结论不变：论文信息在 L44–L52 汇集到名字位置，注意力在 L48 读入，MLP 在 L52–L56 接手。5 个假标题平均（括号内为 false_0）：P1 全部位置 L48 +0.821 [0.807, 0.835]（0.825）、L52 +0.995 [0.990, 1.001]（0.996）；P1 只换名字位置 L52 +0.841 [0.827, 0.856]（0.847）；P2 注意力 L48 +0.237 [0.229, 0.246]（0.231）；P2 MLP L52 +0.181 [0.174, 0.188]（0.178）、L56 +0.226 [0.217, 0.236]（0.224）（补充 10 第 3 项，Stage 11 样本 1,186 篇，团队整群 bootstrap 2,000 次 95% CI；391_groups/reports/b1_p12f_report.md P1 / P2 表；summary_b1_p12f/p12f_mean5.csv）。p9 位置（标题的右引号；只有共享尾长为 9 的论文，平均每篇约 3 个可用假标题）：各假标题 694–711 篇，集合不同，未加权（summary_b1_p12f/p12f_per_title.csv，item = p9：false_0 708、false_1 694、false_2 711、false_3 707、false_4 710 篇）。“:” 位置的分子 B/A：5 个假标题版 0.72–0.87，false_0 版 0.78–0.99；B 的比例高只因分母约为 A 的一半（P1 只替换 “:”，未写出作者，A 557 / B 586 篇：5 个假标题版 L44 0.72、L48 0.87，分母 B/A 0.51（b1_p12f_report.md “B - A” 表）；false_0 版 L44 0.78、L48 0.99（391_groups/summary_rerun/p1_p2_num_den_B_minus_A.csv））。硬检查：false_0 臂复现已发表值（最大差 2.2e-16），PASS。
- **C / D 组补全 E1 / E2（批次 2 第 2-6 项，补充 11 B，已完成）：**C 组未写出作者 462 篇，同一引用档内与 A 相比（6 个引用档，C 258 篇、A 323 篇）：E1 恢复比例 L48 −0.037 [−0.080, +0.009]，L52 +0.007 [−0.009, +0.024]；L56 −0.007 [−0.014, −0.001]，个别层差异极小，不作解释；E2 阻断损失 L32–L52 区间都含 0。C 的真假标题差距更大：分母 C 0.559 [0.529, 0.590]、A 0.407 [0.386, 0.430]，同档内 C − A +0.075 [+0.024, +0.130]。也就是说，C 的信号更大，但时间点与 A 相同。D（33 篇）按补充 11 只作描述，D − B、C − D 也只作描述（补充 11 B；未写出作者；团队整群 bootstrap 2,000 次 95% CI；391_groups/reports/b2_cd_report.md Numerator / denominator 表与 Contrasts 表；硬检查：重跑 Stage 11 第 0 号分片，差 0.0（容差 0.005），PASS）。前提：同一引用档内只用到 C 462 篇中的 258 篇；分子、分母都只用 false_0；比例差主要反映分母不同（分母效应）。
- **2026-11-08（报告第 30 版）补充的前提：**Stage 8 的结论（真标题让模型更偏好真实第一作者 RQ1；A 组强于 B 组 RQ2）较稳，但有三个前提：① W 只给第一作者名字的第一个 token 打分，在 Stage 8 的 200 篇里有 129 篇（64.5%）这个 token 只是首字母（audit_20261105/part_A_stage4_9.md 第 10 行）；② 偏离 D13-1：按补充 13 C-2 的规则，全部作者 CPU 代理只在 L56 的 RQ2 上与已发表结论不一致（+0.064 [−0.032, +0.163]，区间含 0），触发了按原 W 在 GPU 上重算，用户 2026-11-06 决定不做；在锁定计划的 7 层积分终点上（近似，Stage 10 没有 L16）代理 RQ2 为 +0.046 [+0.007, +0.088]（L16 = 0）或 +0.049 [+0.005, +0.094]（L16 = L24），同向、区间不含 0

（381_stage13/reports/c13_C2.md；381_stage13/c13_C2_followup/c2_followup_proxy.csv）；③ U28：L56 在锁定计划里是探索性次终点，10-18 21:14 的 PROTOCOL.md 把它改为主终点，改动者和依据仍未查清。X4 中认得出的论文第一作者 D 更高（测试集不显著）这一差别不再作为 H2 的证据（只看标题文字的 BERT 基线 +0.088 不弱于 Qwen L8 +0.018）。

- **2026-11-08（报告第 30 版）补充的局限：**层不完整：Stage 10 在 L24–L40 每 8 层取一层（没有 L25–L31、L33–L39），没有补层计划（补充 14 只补 L41–L47、L49 和 L0–L23，都在排队）。主要结论的起始层都不在缺口里；落在缺口里的只有三条描述：X4 年份最早可读出层 L40（前一个测量层是 L32，真实起点在 L33–L40 之间）、Stage 10 真标题下 Jacobian lens 从 L40 起明显好于 logit lens（跳变在 L33–L40 的哪一层不知道）、X4 第一作者峰值 L40（真实峰值可能在 L33–L47）。“L24–L48 约为 0”在缺口层没有测过（~/jlens_work/conclusions_v30_checks.md A1）；一致性容差事后放宽，而且用到了：Stage 10 一致性检查的容差在看到结果后从 0.25 放宽到 0.5（用户 2026-10-25 批准）。主轮 25 个（读出 × 层）组合的最大差 0.367，只有按 0.5 才通过；全部名次 < 42 完全一致，名次不一致使 log10(1/名次) 最多变 0.070。原定 0.25 时，Stage 10 主轮一致性检查（12 个上下文、52 个 token 位置）的 25 个 lens × 层组合中有 10 个超出 0.25，最大差 0.367（351_stage10/reports/parity_before_tol05_amendment.json）；3-3 在 7 篇论文的 23,280 行上按 0.25 计 99.81% 在容差内。这一量级与 3-3 查明的 bf16 舍入随前向长度变化（最大约 0.46）一致，但容差是在看到数据后放宽到 0.5 的，属于事后修改。保留在事后改动清单里（351_stage10/reports/parity.json tolerance_amendment；parity_before_tol05_amendment.json；conclusions_v30_checks.md A2）；干预只用了 1,186 篇：E1、E1t、E2、E2n、P1、P2、F2、X6、X7 只用 9,108 篇中的 1,186 篇（target 593 + control 593，每档每组最多 60 篇，10 档），作为局限，不重做（361_stage11/summary/E1_recovery.csv n_papers）；分母效应：恢复比例 = 分子 ÷ 真假标题差距，组间比较受分母影响：C 0.559 对 A 0.407（C / D 组补全）；“:” 位置分子 B/A 5 个假标题版 0.72–0.87、false_0 版 0.78–0.99；B 组比例偏高只因分母约为 A 的一半。C / D 组补全与 P1 / P2 五个假标题的结论都以此为前提；只用 false_0、没有补做计划：M5 B 部分（真标题对 false_0 的标题 / “:” 位置 probe）和 E4b 的 X1 对照流程只用 false_0，没有计划；M2 的假标题运行也只用 false_0，改用 5 个假标题只需 CPU（残差已在盘上，约 3 小时），是否做待定（conclusions_v30_checks.md A3）；数字核对只覆盖已登记的部分：已登记 680 个结论数字、4,307 处全部一致（第 29 版 h 的核对）；第 30 版新放回或新增的数字已登记进严格核对（claims_defs_v9，结果见核对表）；另约 1,024 个结论性数字未登记（2026-11-07 计数）（351_stage10/reports/numcheck/claims/out_20261108_140102/）。
- **答辩后已完成、以前写“没做 / 暂停”的项目：**X2 只替换子空间（补充 6，2026-11-05）：按预注册判据 H2 不支持、H3 通过，但作者子空间几乎解码不出作者，H3 证据仍不足；全部名字 token 的标题位置 probe（补充 9）：L40 姓的第一个 token +0.071 [0.058, 0.085]；X5 跨问法检索曲线：没有一层高于 L4；M5 能用已有数据回答的部分；CPU 项 C-1 到 C-5（Stage 7.1 加标题对照、Stage 8 CPU 代理、不剔除标题复用的敏感性、M1 换 4 个假标题、Stage 10 附加分析补齐全部已存层）。（381_stage13/reports/x2_report.md；e4b_alltok.md 第 5 节；x5_retrieval.md；m5_report.md；c13_C1.md–c13_C5.md）
- **批次 2（补充 11、12）：**批次 1 结束后已由编排作业开始运行：C / D 组补全 E1 / E2（2-6）已完成；2-11 模型自生成名字的首名复现率 0.880 < 0.90，按预注册停止，改为 2-11b（补充 15，已锁

> 定），只跑第 0 个分片，排队中；名字位置 probe 等其余各项进行中，没有可报告的结果（含 Stage 9 Fit B 与 holdout、F1 对半拆分、名字位置 probe 等）；与预注册的出入记在出入记录 D12-1 到 D12-3（2-1、2-2 较省但含原始提示逐位复现重拟合的硬检查；2-11 重建标签、论文内 AUROC、两个基线、对照组只作描述），2-7 的来源改用不含年份的 X4 提示。**批次 3（补充 14）：** 3-1 Stage 10 补 L41–L47、L49，3-2 补 L0–L23：编排作业已提交，第二批全部结束后自动开始（进行中）；3-3 Stage 7.1B 快路径：已停止（偏离 D14-1）：3-3 停止：只有 7 篇论文同时有旧逐前缀结果和快路径结果，不足以确认两者在 ±0.02 内等效（输出层 target−control 差值之差 +0.0059，按论文 Welch 95% CI [−0.0207, +0.0324]；论文级 bootstrap [−0.0005, +0.0181]，因每组仅 3–4 篇偏窄，不作判据）。差异来源为 bf16 舍入随前向长度变化；长度跨档比例 target 28%、control 15%。Stage 10 全程使用快路径，组间口径一致，一致性检查按 0.25 容差（351_stage10.py 第 919 行）通过率 99.81%。决定过程：原判据（≥ 99% 名次完全一致）未通过（79.8%）→ 用户指出事后判据的设计缺陷 → 在看到论文级结果之前写定并锁定修正判据 → 按修正判据（Welch 区间）仍未通过 → 停止；3-4、3-5（Stage 8 按 W 的 GPU 重算）不做。
>
> （381_stage13/config/prereg_addendum11.json、prereg_addendum12.json、prereg_addendum12_deviations.json、prereg_addendum14.json；381_stage13/reports/b2_groupA_handoff.md）

1. 五个矛盾
2. 代码与环境
3. 提示原文
4. 总表：样本 × 层 × 读出 × 打分 × 区间 × 种子
5. 共同空白逐条回答
6. 逐个实验的空白
7. 早期 Stage 3–9
8. 需要别人回答的清单
9. 本次修改记录

一、五个矛盾

a. Stage 10 是单独打分还是连写

单独打分。核实与手册 G5.3 一致。

- Stage 10 起每位作者单独接在 “Authors:” 之后打分，作者之间互不为上下文；input_ids = prompt_ids + name_ids[:-1]，名字第 j 个 token 在位置 len(prompt)−1+j 被预测。出处：`C10/351_stage10.py` 文档串第 3–5 行，:118–122，:562–563；`R10/config/protocol.json` context、input_ids
- 连写只在两处：Stage 11 E3 作者链（`chain_ids()`，`C11/361_stage11.py:187–188, 286–305`）和 Stage 12 N1 选项连写（`C12/371_stage12.py:190–206`）。另外 Stage 12 F1 的 lens 拟合文本也是“提示 + 逗号连接的真名单”（`371_stage12.py:50–57`），但那是拟合文本，不是打分。
- PPT 第 6 页（Names: encode(prompt) + encode(" " + author)）、第 8 页（提示后只接 “S. Bree” 一位作者）、第 38 页（chain = “Authors: A1, A2, …” instead of each author alone）三处与此**一致，不需**

要改。

- 矛盾出在讲稿 PDF 旧版第 0.1 节（提示写成 “Authors: {作者1}, {作者2}, …”）。讲稿在线版已改为 “单独打分是默认”，此次无需再改。

b. 两个 “25.5%”

两个不同的数，碰巧相同。

出现位置	含义	数值	出处
PPT 第 5 页（Caveat）、第 49 页（Label noise）	标注包自检：0–2 引用档在收紧规则（4/4 且真选项平均概率 ⩾ 0.5）下的通过率；计划上限 10%，未通过。普通规则下为 38.6%	25.5%	`labels_20261015/…/label_README.md:8–9`；`rules.yaml` floor_bin = 0-2、floor_max_pass_rate = 0.1；手册 G3.5、Stage 1 §1.1
讲稿实验 1	Stage 12 N1：删去标题时，真名单在 4 个多选选项（作者链打分）中得分最高的论文比例；机会水平 0.25	0.255 [0.246, 0.264]，n = 8,894（R0/R1）	`R12/summary/N1_prior_mc.csv`；`R12/reports/stage12_report.md` §N1；脚本 `C12/stage12_analyze.py:84–98`

两处说法各自正确，引用时应写全口径，避免读者以为是同一个数。

c. Stage 8 的 +2.41 pp 与 +4.98 pp

数值	终点	比较	在计划中的地位	出处
+2.41 pp [+0.91, +4.00]，61/100 对为正	J-Lens 7 层积分（L16…L62 平均）的标题优势 TA	100 对匹配 A − B，配对 bootstrap B = 10,000	哈希锁定的 `351_stage8/config/analysis_plan.json`（2026-10-18 14:29，sha256 7ff662e0…）定为主组检验	8D supplement `08_stage8/351_stage8D_supplement.py`，种子 3518502，commit 3a4f605（已合入 main a4c1f0a）；2026-10-30 重算一致：`351_stage8/recompute_2026-10-30/s8_endpoints.csv`，作业 11500770
+4.98 pp [+0.32, +9.91]，55 正 / 45 负	J-Lens L56 单层的标题优势	同一 100 对，配对 bootstrap B = 10,000	计划中为次要；同日 21:14 写的 `08_stage8/351_stage8_PROTOCOL.md` 改定为主，8D 按它报告	`08_stage8/351_stage8D.py:242–270`，种子 3518401+2 = 3518403；`351_stage8/stage8D/summary/primary_questions.csv`

- 关系：同一批 100 对、同一种胜率 W、同一种 TA，只差终点层。积分终点约为 L56 的一半。两个文件都早于 8B 冻结（21:25）和 8C 打分（21:47 起）。
- 逐对剔除：积分 A − B 100/100 次区间不含 0；L56 A − B 无变号，但 14/100 次区间跨 0。Holm（7 个逐层 A − B，J-Lens）只有 L62 通过（p_{Holm} 0.029），L56 为 0.19。两者都是冻结计划列出、但原代码没有实现，2026-10-30 事后补算；p 值公式与检验族划分是我们的选择。出处：`351_stage8/recompute_2026-10-30/s8_holm.csv`、`s8_lopo_summary.csv`；手册 Stage 8 §8D
- W 的定义：金标准首 token 对 100 个错误作者首 token 的胜率，**并列记 0.5**（`351_stage8D.py:51–54`）。讲稿漏了 “并列记 0.5”，已补。
- 主终点由谁、因何从积分改为 L56：**未知**，git 无改动记录（U28，需你本人查笔记本上的会话记录）。

d. X3 近邻 D 的实际选取规则与 66 篇子集

- **规则（补充 5 写定后实际使用）**：同领域、不是同一篇、与原论文作者没有共同姓氏；在这些候选中取 jaccard2（与原标题的词重合）**不低于改写版、且最接近改写版**的一篇；**如果没有任何候选的词重合 ≥ 改写版，就取词重合最高的那一篇**。D 在 para_run 之前预先算好存表。出处：`C13/381_stage13.py:292–304, 315`；`R13/config/x3_lexical_neighbour_j2.csv`（sha256 a1c91c87…ff69，脚本 `C13/stage13_x3_neighbour_j2.py`）；`R13/config/prereg_addendum5.json` “word_overlap”
- 为什么中位数是 0.15 对 0.61：同领域其他论文与原标题 jaccard2 > 0.3 的只有 2.4%，而改写版有 87.7% > 0.3。所以绝大多数论文走了“取最高”的后备分支。写定前已知只有 5.9% 的主分析对能匹配上。
- **66 篇子集** = 主分析 1,110 对中 D 的 jaccard2 ≥ 改写版的那些对（列 d_matched；敏感性集 55 对）。它不是另行抽样，而是规则真正满足的子集。这 66 对的改写本身用词变化很大（jaccard2 中位数 0.143）。出处：`R13/reports/x3_groupsplit.md` “Why only 66 primary pairs have a matched D”；`R13/reports/x3_report.md`
- 讲稿写“在用词真正匹配的 66 篇上，all-mpnet 1.40 对 Qwen 1.90”：这两个比值算在 66 篇中的 **test 部分 37 篇**上，不是 66 篇。已改讲稿。出处：`R13/reports/x3_textbase_recovery.md` 比值表 primary/d_matched/test 行

e. 细层范围

不是 L40–L62 全算。

- 主轮（4 把读出 + 模型输出）：L24、32、40、48、56、62，外加 L63。
- 扩展轮（只有 public J-lens 和 logit lens，7 个标题条件全部）：L50–L55、L57–L61，后来补算。出处：`C10/351_stage10.py:43` DEFAULT_LAYERS；`R10/logs/pool/job_s10p_ext_true_11363851.log` 头行；扩展 parity 作业 11338000，扩展分析作业 11378377
- 所以 L40–L62 之间实际有的层是 L40、L48、L50–L62；**L41–L47 和 L49 没有算**。〔2026-11-06 已更新：批次 3 第 3-1 项补算 L41–L47、L49（6,841 篇，logit 与 public），编排作业已提交，第二批全部结束后自动开始；见页首更新框〕self100、fitA 只有主轮层。
- PPT 备注第 36 页（“细层 L50 到 L61 是后来补算的”）基本正确，L56 来自主轮。讲稿实验 5 已改。

二、代码与环境

主脚本、commit 与运行硬件

实验	主脚本	git commit / 脚本版本	硬件与加载
Stage 1 分组映射	`~/jlens_work/00_cohort/351_prepare_all.py`（标签本身由组长 elm 生成）	e2c7156	CPU；标注运行的硬件**未知**（问组长，U10）

Stage 3 lens 验证	`01_public_lens_validation/351_validate_public_lens_offload_fixed.py`、`02_self_lens_validation/351_self_jlens_validation.py`、`351_self_gold_false.py`、`351_self_jlens_split_half.py`；self100 拟合 `home_project/05_fit_jlens_prelim_100.py`	e2c7156	A100，29 块在 GPU、35 块在 CPU；self100 拟合最后一段在 H200（作业 11180979）
Stage 4	`04_stage4/351_stage4_readout.py`、`351_stage4_audit.py`	e2c7156	29 + 35 offload
Stage 5	`05_stage5/351_stage5.py`	e2c7156	29 + 35
Stage 6	`06_stage6/351_stage6.py`	e2c7156	29 + 35
Stage 7.1 / 7.1B	`07_1_stage7_1/351_stage7.py` / `351_stage7_1B_terminal.py`	7.1：e2c7156；7.1B **不在 git**	7.1 CPU；7.1B 29 + 35
Stage 7.2 / 7.3 / 7.4	`07_2_stage7_2/351_stage7_2.py`、`351_stage7_2_score.py`；`07_3_stage7_3/351_stage7_3.py`、`351_stage7_3_score.py`；`07_4_stage7_4/351_stage7_4.py`	e2c7156	7.2/7.3 打分 29 + 35；7.4 CPU
Stage 8	`08_stage8/351_stage8.py`、`351_stage8B.py`、`351_stage8C.py`、`351_stage8D.py`、`351_stage8D_supplement.py`；事后补算 `08_stage8/recompute_2026-10-30/stage8_frozen_plan_recompute.py`	e2c7156；supplement 3a4f605（合入 a4c1f0a）；补算脚本的 commit **未知**	8C 29 + 35；8D CPU；补算作业 11500770
Stage 9	`09_stage9/351_stage9.py`、`stage9_a_repair.py`（及 /scratch 下的 stage9_runner.py 等）	**不在 git**；351_stage9.py sha256 1e2900ef…3878	device_map='auto'；A100-40GB（第一段）与 A100-80GB
Stage 10	`C10/351_stage10.py`（GPU 入口 `351_stage10_fix1.py`）；`stage10_extra*.py`	b4b76ed；运行版 sha 9107c80b…（冻结 manifest 记录的 847e7dde… 找不到，U34）	整模型在 GPU，禁止 offload；A100-SXM4-80GB
Stage 11	`C11/361_stage11.py`、`stage11_analyze.py`、`stage11_cpu_realcheck.py`	全部 raw 由 f8adb8d9… = c86112f 产生；当前文件 = 13ae7ec（计算函数相同）	同 Stage 10
Stage 12	`C12/371_stage12.py`、`stage12_analyze.py`、`stage12_cpu.py`、`stage12_p2_hookcheck.py`	冻结 13ae7ec；P1 修复 95dd94d；GPU 守卫 d569682；F2 排除 663ac1c；完成 fb8be6f	408 个单元全部单张 A100-80GB

Stage 13	`C13/381_stage13.py`（GPU）；分析脚本 `stage13_cpu.py`、`stage13_m2b.py`、`stage13_m2c.py`、`stage13_m3_analyze.py`、`stage13_x1x4_analyze.py`、`stage13_x3_analyze.py`、`stage13_x6_analyze.py`、`stage13_x7_analyze.py`、`stage13_e4b_group.py` 等	GPU 输出 script_sha256 = a7b01a8f… = fb8be6f；para_run 时改为 4e0f4849…（只改 D 来源），该版本的 commit **未知**；group_folds cf7106d；E4b 复核 0dde4de；X6/X7 6d667ab	A100-80GB（M3 task 单元部分为 2 张）

软件版本

项	已记录	未记录
transformers	当前 conda 环境 5.19.0（手册编写时 import 读出）；public lens 拟合时 5.17	各 Stage 运行时的版本**没有写进输出**（手册 G1.1）。Stage 10 起的代码依赖 5.x（hf_device_map 缺失修复），但具体小版本**未知**
torch	Stage 13 输出 meta：2.11.0+cu128；public lens 拟合：2.11	Stage 10–12 的 meta 存了 torch 版本，但手册没有摘出数值：**未知**，需你从 `R10/raw/*/shard_*.npz` meta.env 读出（`351_stage10.py:543`）
CUDA	只有 torch 构建标签 +cu128（Stage 13）	驱动版本、cuDNN：**未知**
numpy	1.26.4（团队折排序审计时确认）	—
jlens	~/projects/jacobian-lens，git 581d398，只加了 `_stage10_compat.py`（镜像 commit b4b76ed）	—
Stage 1–9	—	运行时版本全部**未记录**

注意力实现与 E2 掩码

- **E2、E2n、X7**：sdpa（`R11/logs/realcheck_11396804.log` “attn sdpa”）。传入显式 mask 时 sdpa 走 is_causal=False、不走 GQA 快路径，与不加 mask 的前向不是同一内核，所以基线用同批 l = 64（走同一 mask 路径但什么都不挡）。
- **其他所有实验**：注意力实现**没有记录**。不能按 transformers 默认值推断。需你在集群上读一次 `model.config._attn_implementation`，或查各 Stage 的日志。
- **E2 掩码的加法**：对每个 decoder layer 注册 `register_forward_pre_hook(..., with_kwargs=True)`，把 `kwargs['attention_mask']` 换成形状 [B, 1, T, T] 的加性张量：允许处 0，禁止处 `torch.finfo(bf16).min`（不是 −inf）；第二维为 1，所以对所有头生效。允许集合 = 因果下三角且不在阻断块内。阻断块 = query 从 max(标题位置)+1 到序列末尾，key = 全部标题 token；标题前缀仍可被看，标题 token 之间的注意不动。batch 第 i 份在 layer ≥ KO_LAYERS[i] 时用阻断 mask，否则用普通因果显式 mask。出处：`C11/361_stage11.py:210–216, 254–270`（ko_mask），:258–260，:262–269
- E2n 只把 query 起点改为 “:”（`query_from=len(pt)−1`，`361_stage11.py:329–340`）。

三、提示原文（逐字）

“\n” 表示换行。除标注两项和判断器外，都是裸文本、不套 chat 模板、不加 BOS（Qwen3 tokenizer 的 bos_token 为 None）。出处：手册 G3.1、G3.4、G4.1。

作者问法（Stage 3–12 的读出提示）

```
Who are the authors of the paper titled "{title}" ({year})?
Authors:
```

之后接 encode(" " + 作者名)，每位作者单独一个上下文。出处 `C10/351_stage10.py:29`；Stage 4–8 各脚本相同。问法的选择过程未记录，未系统比较其他问法（U11，用户已决定照此写明）。

删标题条件（Stage 10 delete、Stage 12 N1-delete）

```
Who are the authors of the paper ({year})?
Authors:
```

出处 `C10/351_stage10.py:244`。假标题 false_0…4：同作者问法，{title} 换成供体论文标题，{year} 保留本篇年份（`351_stage10.py:323–325`）。

标注：开放回答（chat 模板，system + user，thinking 关，贪心，max_new_tokens 96）

```
[system] You are a knowledgeable assistant. Answer factually and concisely. When asked for authors,
return a semicolon separated list of full names only, with no additional text.
[user] Who are the authors of the paper titled '{title}' which was published in {year}? Return a
semicolon separated list of author names only.
```

出处 `labels_20261015/…/step1_README.md` “Open question”；与 dua 代码包 `src/dua/probing/stages/stage1_generate.py:164–171, 252–284` 逐字相同。elm 实际运行的设置由此推断（elm 源码不在集群）。

标注：多选题（chat 模板，一条 user 消息）

```
You are an academic assistant. Your task is to identify the correct author list for an academic paper.
You will be given a paper title, its publication year, and four candidate author lists labelled A, B, C,
and D. Exactly one is correct.
- Respond with a single letter: A, B, C, or D.
- Do not add any explanation, notes, or extra content.
Here are some examples:
Question: Which of the following is the author list of the paper titled 'Why men are at higher risk for
hepatocellular carcinoma?' which was published in 2012?
A: V. Keng, D. Largaespada, A. Villanueva
B: M. Sherman, J. Bruix, A. Forner
C: J. Llovet, S. Ricci, V. Mazzaferro
D: H. El-Serag, K. Rudolph, A. Marrero
Answer: A
```

```
Question: Which of the following is the author list of the paper titled 'Research as an influence on
teaching' which was published in 1984?
A: J. Centra
B: K. R. Jolls
C: P. Ramsden
D: M. Prosser
Answer: B
Now, answer the following question:
Question: Which of the following is the author list of the paper titled '{title}' which was published in
{year}?
A: {option shown as A}
B: {option shown as B}
C: {option shown as C}
D: {option shown as D}
Answer:
```

出处 `step1_README.md` “Kind team, order 0 -- one user message”。4 种顺序 [[0,1,3,2],[1,2,0,3],[2,3,1,0],[3,0,2,1]]；P(X) = p("X") + p(" X")，不重新归一化。thinking 设置与答案位置**未知**（问组长，U03）。

Stage 12 N2 纯名字先验

```
The following is the name of a researcher.
Name:
```

之后接 " " + 作者名。出处 `C12/371_stage12.py:38, 213–221`。

Stage 13 M3 三种问法（不含年份；标题前都是 9 个 token）

```
authors: Who are the authors of the paper titled "{t}"?
Authors:
year:    In what year was the research paper titled "{t}" published?
Year:
field:   In what research field is the paper titled "{t}"?
Field:
```

出处 `C13/381_stage13.py:48–50`。同文件第 4–6 行文档串里还留着旧写法（“In which year was the paper titled …”），以代码 TASKS 为准（commit 43c8f0c 改）。**X1 的“问年份 / 问领域”就是这里的 year、field 两条**；X1、X3 para_run、X4 的“作者问法”也是这里的 authors 一条，不是 Stage 10 的含年份问法。

Stage 13 X3 改写生成（裸文本，贪心，max_new_tokens 60，pad = eos）

```
Rewrite the title of a research paper using different words while keeping exactly the same meaning. Do
not add any information.
Original title: {t}
Rewritten title:
```

出处 `C13/381_stage13.py:125–126, 276–286`。生成模型就是 Qwen3-32B 本身；解码后只取第一行、去首尾空白和引号。注意：任务说明里称 para_gen 用了 chat 模板，与代码不符，以代码为准。

Stage 13 X4 Patchscope 目标提示

```
year:   Paper: X
The paper was published in the year
author: Paper: X
The first author of the paper is
field:  Paper: X
Research field:
```

占位符是 "X" 这个 token，三条里都在位置 2。出处 `C13/381_stage13.py:123–124, 243–247`。

Stage 13 Qwen 判断器（chat 模板，thinking 关；最终没有使用）

```
Do these two research paper titles have exactly the same meaning?
Rules: any added, removed or changed specific information counts as a change. A technical term replaced
by a near-synonym that does not keep its precise technical sense (for example "generation" of a group
replaced by "creation") counts as a change. Only rewording that keeps every fact and every technical
term's precise meaning counts as the same meaning.
Title A: {a}
Title B: {b}
Answer with Yes or No.
```

出处 `C13/stage13_gpu_followup.py:25–29`。判断器 v1、v2 都未达标，按补充 5 不用。

四、总表

“团队 bootstrap” = 按作者团队整群重抽；“论文 bootstrap” = 档 × 组内按论文重抽。Stage 10–12 发表的表仍是论文级区间，团队版另见 `R13/reports/cluster_ci.md`。

实验	样本	层	读出	打分 token	区间方法	种子
1 分组（Stage 1）	9,108 → 四组 6,841（A 4,110 / B 2,186 / C 511 / D 34）	—	—	—	—	干扰团队抽取种子**未知**（U06）
2 全队列读出（Stage 10）	9,108 篇、33,811 个作者上下文、149,999 个 token；组间比较 10 档内 target 3,734 / control 2,182	L24、32、40、48、56、62 + L63	logit、public、self100、fitA、final	全部名字 token（token 加权 mean_nlr）	论文 bootstrap B = 2,000	analyze 3510；analyze-title 3511
3 信号拆分	同上	final	final	全部 token；另报 surname_first 等角色	论文 bootstrap B = 2,000	3712（`stage12_cpu.py`）

4 独立复现（Stage 8）	200 篇 / 100 对 A–B（只用 R0）	L16⋯L62（7 层）+ L63	J-Lens（public）、Vanilla、Final	金标准首 token vs 100 个错误作者首 token 的胜率 W	RQ1 论文、RQ2 配对 bootstrap，B = 10,000	8A 3518001；8B 3518201；8D 3518401(+1/+2/+3)；supplement 3518501/2；补算 20261031 起
5 细层	同 2	L50–55、L57–61（主轮 L48、56、62 作锚点）	logit、public	全部 token	论文 bootstrap B = 2,000	3511
6 读出工具比较	同 2	主轮 6 层	4 种 lens	全部 token	论文 bootstrap	3512（`stage10_extra.py`）
7 E1 替换	1,186 篇（593 + 593），19,077 个 token	24, 32, 40, 48, 50, 52, 54, 56, 57–63	final	全部名字 token	配对论文 bootstrap（比值），B = 2,000	抽样 11；bootstrap 3611
7′ E1t	1,186	8, 16, 24, 32, 40, 44, 48, 52, 56, 60, 62, 63	final	全部名字 token	同上	3611
8 E2 / E2n 阻断	1,186	起始层 0, 24, 32, 40, 48, 50, 52, 54, 56, 58, 60, 62, 64（基线）	final	全部名字 token	同上	3611
9 X6	1,186（false_1⋯4 各 24 shard）	同 E1	final	全部名字 token	团队 bootstrap B = 2,000，5 个假标题共用抽样	13
9′ X7	1,186	同 E2	final	全部名字 token	团队 bootstrap B = 2,000	17
10 P1 单位置替换	1,186（4,307 个上下文，19,077 个 token；p9 有效 10,566）	32, 40, 44, 48, 50, 52, 56	final	有效 token，另按角色拆	论文 bootstrap B = 2,000	3713
11 P2 部件替换	1,186	8, 16, 24, 28, 32, 36, 40, 44, 48, 52, 56	final	全部名字 token	论文 bootstrap B = 2,000	3713
12 E4b probe（复核版）	训练 9,108；保留 1,863（target 896、control 499、excluded 433、guard 35）；组间用 1,395	16, 24, 32, 40, 44, 48, 52, 56, 60	ridge probe → final norm → 4,314 个名字 token	每位作者第一个名字 token	档内论文 bootstrap B = 2,000	团队折 seed 13；原版折 11
13 X5 层序	沿用各来源	沿用各来源	—	—	沿用各来源（混用）	—

14 M1	9,108，149,999 个 token	public、logit 细层 L24–62；self100、fitA 6 层；final	4 种 lens + final	每个名字第一个 token；另报全部 token	无区间	—
15 M2	9,108（recognised 只用 6,841）	标题位置 16, 24, 32, 40, 44, 48, 52, 56, 60；“:” 同 9 层 + L63	ridge probe	论文属性（不是名字）	原版论文 bootstrap 200 次；补算团队 bootstrap 2,000 次	折 13；200 次 rng 3813；团队版 20261030
15′ M2b / M2c	9,108	TF-IDF；BERT 13 个隐藏层	Ridge	同 M2	无区间（M2b）	同 M2 折
16 M3	9,108 × 3 问法	4, 8, 16, 24, 28, 32, 36, 40, 44, 48, 52, 56, 60, 62, 63	ridge（T）、余弦（I）	年份、引用、领域	团队 bootstrap B = 2,000	折 13；bootstrap 31
17 X1	1,178 对（tune 596 / test 582）	4, 8, 16, 24, 32, 40, 48	final	第一作者全部名字 token	团队 bootstrap B = 2,000	配对 1313；tune/test 1314；bootstrap 101
18 X3	主分析 1,110（test 552），敏感性 1,012；d_matched 66 / 55（test 37）	4, 8, 16, 24, 28, 32, 36, 40, 44, 48, 52, 56, 60, 62, 63	残差余弦；final 行为	第一作者名字 token 平均	团队 bootstrap B = 2,000	分析 311–333；groupsplit 411
19 X4	1,178 对	8, 16, 24, 32, 40, 48, 56	final	答案 token 平均（作者 = 第一作者全部名字 token）	团队 bootstrap B = 2,000	202；recognition 303+l；角色拆分 47
E3 作者链	9,108 篇、33,811 个作者 × 7 条件（504 单元）	final + logit、public 于 40, 48, 52, 56, 58, 60, 62	同左	全部名字 token（逗号不打分）	论文 bootstrap B = 2,000	3611
N1 / N2	N1 8,894；N2 9,108	final	final	N1 选项链 mean_nlr；N2 全部 token	论文 bootstrap B = 2,000（N2 组均值无区间）	3713
F1 / F2	F1 拟合 40 篇（不在 1,186 内）；F2 1,186 去掉 3 篇同名	24, 32, 40, 44, 48, 52, 56, 62	作者提示 lens	全部名字 token	论文 bootstrap	F1 抽样 12；分析 3713

种子出处：手册 B3 “Bootstrap：单位、次数、种子（逐脚本）”表及各实验节。

五、共同空白逐条回答

上次标的空白	答案	出处
★ 删标题提示长什么样	整段 “titled "…"” 删去，只留年份（见第三部分）	`351_stage10.py:244`
★ 名字怎么切 token、角色怎么定	authors 列按 “;” 切开、strip；每位作者 tok(" " + 名字, add_special_tokens=False)。最后一个词 = 姓；PARTICLES 表内 = 前缀；匹配 `^[^\W\d_]\.?$` = 首字母；其余 = 名；纯标点 token = punct；每词第一个 token 为 _first，其余 _cont	手册 G5.2；`351_stage10.py:80–101, 118–131`
被打分作者有无上限、et al.	全部作者；名字 > 32 token 或上下文 > 512 token 才排除，实际排除 0 位。Stage 10 用元数据作者列表，不涉及 et al.；et al. 只出现在多选题的选项显示里	`351_stage10.py:31–32`；`R10/config/manifest.json` n_excluded_authors 0
上下文超过 512 怎么办	超过即排除该作者，实际 0 位	同上
★ 引用档边界与引用字段	13 个指数档 0-2 ⋯ 4097+，两端都含；只用 Semantic Scholar citationCount（2025-09 快照），不回退到 OAG	dua 代码包 `config/config.yaml:44–59`、`src/dua/bins.py:12–20`；`stratified.py:24–36`
团队并查集里的全名规范化	NFKD → ASCII → 小写 → 非字母变空格 → 切词；≥ 2 个词才连边；同一 paper_id 合并，共享任一全名即合并	`C13/stage13_cpu.py:80–109`
各处随机种子	见总表	手册 B3
R2 与 excluded 在分析里怎么处理	Stage 10 读入全部 9,108 篇；组间比较只用 target、control（合计 6,841），guard 214 与 excluded 2,053 只作描述；“全部论文”曲线包含它们	`351_stage10.py:104–118`；`R10/config/analysis_plan.json` grouping
★ 假标题四档阈值	strict：|Δ年份| ⩽ 5、|Δ作者数| ⩽ 1、|Δ标题 token| ⩽ max(1, 20%)、|Δ档| ⩽ 1；medium：5、round(0.25n)、25%、1；loose：8、round(0.34n)、30%、1；nearest：只保留三条硬排除。前三档每个供体上限 5 次，nearest 7 次	`351_stage10.py:245–247` TIERS；`R10/config/conditions_manifest.json` matching.tiers
代价公式里的 n、长度	都是目标论文 i 的作者数、标题 token 数（Qwen tokenizer 计数）；引用档用 13 档序号	`351_stage10.py:264–266, 281`
Jaccard 分词	ASCII 化小写后，长度 ⩾ 4 的字母词	`351_stage10.py:248, 269, 277–280`
同代价怎么打破平局	每篇的 5 个供体按 (档序, cost, donor_paper_id) 排序，k = 0⋯4 即 false_0⋯4	`351_stage10.py:282–307`
self100、fitA 的拟合文本	self100：`fitting_corpus/wikitext103_qwen32b_1000.jsonl` 索引 0–99（seed 42 蓄水池抽 128 token 片段）；fitA：`351_stage9` 冻结的 fit_A 100 条 + 1 条替补；public：557 段已按 Neuronpedia fit_lens.py 复原	手册 B2；`home_project/05_prepare_jlens_corpus.py`；`351_stage9.py:40–58`
Jacobian 跨文本怎么平均	每条提示的 J_l 等权平均（与长度无关）；有效位置 [16, seq_len−1)；seq_len ⩽ 17 的提示被跳过；存 fp16	`jlens/fitting.py:42, 340–366`；`lens.py:52–65`
Stage 10 头条数字用哪种读出	“L62 target +0.56 / control +0.24” 是 jlens_public 的两组各自平均；final 为 +0.481 / +0.200	`R10/summary_title/A_group_layer.csv`

Stage 10 团队整群区间	点估计不变；具体区间数值手册没有摘出：**未知**，需你查 `R13/reports/cluster_ci.md`（作业 11443686、11443696）	手册 10-1、10-4 状态栏

六、逐个实验的空白

实验 1：分组（Stage 1）

- 问题原文：见第三部分。
- NameMatcher：行为上等于 dua NameMatcher 的 L4 阈值（姓 + 名首字母）；逐级 L1 原串 → L2 Unicode 折叠 → L3 去标点 → L3.5 姓 + 完整名 → L4 姓 + 首字母，姓前缀可去掉，按真作者顺序贪心一对一。用它重算 (m, h, u) 与标注包 9,095/9,108 一致。dua `src/dua/evaluate/matcher.py`；U05 已解决
- 写出名字多于真作者时：h = 写出的名字数 − m，u = 真作者数 − m（9,108 篇恒成立）。
- 多选题 thinking 设置：**未知**（组长，U03）。干扰团队抽法：**未知**（组长，U06）。数据上 100% 同领域、94.8% 作者数相同、93.1% 同档，年份差中位数 3 年、最大 192 年（不是硬约束）。
- 4 种顺序：[[0,1,3,2],[1,2,0,3],[2,3,1,0],[3,0,2,1]]，所有论文相同。
- 6,841 与 9,108：Stage 4–8 从 6,841 篇四组里抽；Stage 10–13 读入全部 9,108 篇，组间只比 6,841 篇。

实验 2–3：Stage 10 读出与拆分

均已在第五部分回答。拆分的置信区间：档内论文 bootstrap B = 2,000，种子 3712（`C12/stage12_cpu.py`，作业 11413574）。

实验 4：Stage 8

- 200 篇怎么抽：排除 Pilot50；在 (field, citation_bin) 格内按 sha256("3518001|…") 的确定性哈希顺序排；格内贪心最近邻配对（代价 10|Δ年份| + 3|Δ作者数|，作者名单不相交）；按引用段配额 low 25 / mid 50 / high 25 对。这是哈希排序，不是随机抽样。`351_stage8.py:26–61`
- 100 个错误作者：排除目标论文全部真作者；50 个匹配（预分级：同领域同 token 数 / 只同领域 / 只同 token 数 / 其余，再按 |Δ年份|、|Δtoken 数|、哈希排序），50 个按哈希顺序取的"随机"作者。`351_stage8B.py:298–345`
- 20 个错误标题：不同来源论文、不共享作者；tier 0 同领域同档、1 同领域、2 其他；按 (tier, |Δ年份|, |Δ标题 token|, 哈希) 取 20；提示保留目标年份。`351_stage8B.py:505–540`
- W 打分的是哪位作者：手册 8B 写"每篇 1 金标准"，没有明写是第一作者；7.2 明写是第一作者。**部分未知**，需你查 `351_stage8B.py` 的金标准选取行。
- Holm 检验族：事后补算时按冻结计划写的"7 个逐层 A − B（J-Lens）"划分；p 值公式（由 bootstrap 反推的双侧 p，B = 100,000）是我们的选择。

- 冻结计划原文件：`351_stage8/config/analysis_plan.json`（sha256 7ff662e0…）与 `08_stage8/351_stage8_PROTOCOL.md`（sha256 3a3a3d65…）都在集群上。

实验 5–6：细层与读出工具比较

- 细层范围见矛盾 e。
- “前 10 命中率”的单位：手册只写“每层每指标的读出均值”，PPT 轴标签写 % of tokens。按 token 还是按论文：**手册未明写**，需你查 `C10/stage10_extra.py:159–176`。
- 多出的 spec 的组间差：每种 lens 的 (spec_lens − spec_logit) 做档内 target − control，论文 bootstrap。

实验 7：E1 替换

- 复制的张量：`model.layers[l]` forward hook 的输出，即第 l 个 decoder block 输出的残差流；不是注意力输出、不是 MLP 输出、不是 KV。`361_stage11.py:203–209`
- 尾段对齐公式：tail_prompt = min(common_suffix(真 ids, 假 ids), len(真) − 1 − max(真标题位置), len(假) − 1 − max(假标题位置))；< 3 报错。每个作者上下文替换 tail = tail_prompt + len(name) − 1 个位置，从末尾对齐：`h[e, -tail:] = acts_true[l][-tail:]`。样本中 tail_prompt 为 9（708 篇）或 8（478 篇）。`361_stage11.py:97–100, 123–125`；`R11/config/sample.parquet`
- 抽样档：两组都 ⩾ 30 篇的 10 档，每档每组 min(60, n_t, n_c)，`default_rng(11)`；9 档各 120 篇，513-1024 档 106 篇。
- 打分：全部名字 token，先在论文内平均再跨论文；比值为均值之比。
- L48 的值：all 0.825 [0.807, 0.842]。讲稿“约 0.82”、PPT 备注“83%”都是它的四舍五入。

实验 8：E2 阻断

- 标题 token 的范围：与 'titled "' 之后、最后一个 '" (' 之前的字符区间有重叠的所有 token；标题以 “.” 结尾时 '."' 合成一个 token，算标题 token（被挡的 key）。
- 标题 token 之间互相注意：不挡。标题前缀仍可被看。
- 阻断到 L63（含）。

实验 9：X6、X7

- X6 的复现分片：单元 ('xf_patch', 'false_0', 0) 与 `R11/raw/patch/shard_000.npz` 比较，516 行 × 15 层逐个名次相同。
- X7 样本：就是 Stage 11 的 1,186 篇。补充：control 的 S(L52) = 0.051 超阈值 0.001，判定 DOES NOT HOLD（边界）；target 0.018、all 0.029 成立。〔2026-11-06 已更新：X7 按 5 个假标题平均，三组都成立（control +0.042）；见页首更新框〕

实验 10：P1

- 角色规则：G5.2（见第五部分）。样本：1,186 篇。
- 首字母靠 “:” 恢复：L48 0.502、L52 0.917（2026-10-30 用 raw 重算，U38）。讲稿原写 0.90，来自没有保存脚本的预览值，已改为 0.92。

实验 11：P2

- 替换范围：**整段对齐尾部 + 全部名字输入位置**（与 P1 的 all 相同），不是只换名字位置；组件输出在加回残差之前替换。讲稿已改。`371_stage12.py:150–151, 161–174`
- hook 检查（U40）：`C12/stage12_p2_hookcheck.py`，在合并作业 11513313 跑真实分片 0：full_true 与 r62c63_true 恢复 1、logit 差 0、残差逐位相等；hook 30,888 / 30,888 次各触发一次；唯一 WARN 为批大小舍入。`R12/reports/p2_hookcheck.md`

实验 12：E4b probe

- W 在哪个条件上训练：真标题运行（X = 真标题运行、标题最后一个 token 的残差；Y = 同一运行 “:” 处 L63 残差，未经 final norm）。测试时同一 W 分别输入真标题和 false_0 的残差。`stage11_analyze.py:150–202`
- “只用假标题训练”对照（PPT 第 18 页绿色柱）：训练输入与目标都换成 false_0 运行，测试仍用测试论文自己的作者。复核后 L24 / L40 / L56 = 0.050 / 0.057 / 0.074，与普通 probe（0.050 / 0.066 / 0.080）持平或略低；原来“更强”的说法来自泄漏，已撤回。`stage12_cpu.py:118–148`；`R13/reports/e4b_split_compare.md`
- 标准化：**原版 μ、σ 用全部 9,108 篇（含测试折）**，不是只用训练折。2026-10-30 改为只在训练折内拟合后重算（作业 11500917）：E4b（target + control 1,395 篇）为 L40 0.061、L56 0.075；两种标准化差别最大 0.0007，0.066 / 0.080 是 X1 对照流程全部 1,863 篇的数字，差别来自论文集合，不是标准化，target − control 差 ⩽ 0.0015，没有“区间是否含 0”的翻转；L44 下界变为 +0.000（边界）。手册建议正文采用新值。讲稿已改。`R13/reports/e4b_trainstd_compare.md`
- 1,863 ≠ 896 + 499：另外 468 篇是 excluded 433 + guard 35。E4b 的信号和组间比较都用 target + control 的 1,395 篇；1,863 篇是剔除标题复用后的全部论文（X1 对照流程用）。
- α 怎么选：只在第 1 折（k = 0）用该折留出集的 MSE 在 {0.1, 1, 10} 中选，每层单独选，之后 5 折沿用；结果都是 1.0。
- 4,314 个 token：队列内所有作者第 1 个 token ∪ 所有姓的第一个 token；gold 只用每位作者的第 1 个 token。〔2026-11-06 已更新：补充 9 扩展到全部名字 token，批次 1 第 4 项改为减 5 个假标题平均；见页首更新框〕

实验 13：X5

每行的判定规则逐条写在手册 X5 节“各来源的通过条件”，脚本 `C13/stage13_x5_layer_order.py:71–85`（最早层、持续起点）、:283–294（X7）。

实验 14：M1

- 读出：public、self100、fitA 三把 Jacobian lens 和 logit lens，加 final；样本是 Stage 10 已存的全部逐 token 读出。
- 位置：“名字首 token”指每个名字第一个 token 作为目标时的读出，即在 “:” 位置预测出的分布。
- “第一名会变”：M1b = mean[top1(true) ≠ top1(false_0)]。
- **更正**：logit lens 在 L62 的 0.867 是“像名字的 token”（name-like）所占的比例，不是“正确名字”的比例。讲稿已改。正确名字的比例：public L52 0.001、L62 0.019。

实验 15：M2、M2b、M2c

- 9 层：16, 24, 32, 40, 44, 48, 52, 56, 60。样本 9,108（recognised 只在 6,841 篇上）。
- 去年份：先用 5 年一箱的年份 one-hot 做 ridge，拿残差。
- AUROC 合并：各引用数箱（两类都 ⩾ 10 篇）内 AUROC 按箱大小加权平均。打乱标签：同一折、按层固定种子打乱 Y 一次。
- TF-IDF：ngram (1,2)、min_df 2、sublinear_tf，Ridge α = 1.0。BERT：bert-base-uncased，13 个隐藏状态，按 attention_mask 均值池化（含 [CLS]/[SEP]），max_length 96，取最好一层（year 最好是 L12）。
- 区间：原报告论文 bootstrap 200 次；2026-10-30 补算团队整群 2,000 次，0 个翻转（作业 11503585）。

实验 16：M3

- 问法原文与 9 token 对齐：见第三部分；freeze 时逐模板断言前缀都是 9 个 token。
- 迁移比 T 的成绩：year、log citations 用 R^2，field 用准确率；6 个有序问法对的比值再平均。
- 区间：团队 bootstrap 2,000 次，种子 31。

实验 17：X1

- 标题长度不同怎么对位：搭档 B（同领域、作者问法下标题 token 数相同、无共同姓氏）和随机 C（任意领域、标题长度相同、与 A、B 都无共同姓氏）在构造时就要求长度相同；不同则跳过。
  `381_stage13.py:143–178, 216–220`
- 调参集的作用：补充 2 把规则改为“全曲线、不选层”，tune 与 test 都报告，test 为确认性。
- 打分：第一作者全部名字 token。相对距离 = $\| x_a - x_b \| \,/\, \| x_a \|$（换问法），对照 $\| x_a - x_a^{perm} \| \,/\, \| x_a \|$（换论文，置换 seed 5）。

实验 18：X3

- 改写：Qwen3-32B 本身，提示见第三部分，贪心。
- 搭档 B：pairs.parquet 的 partner（同 X1）。B 进入次要指标 G = cos(原, 改写) − cos(原, B)，主指标是 G′（对 D）。

- NLI：cross-encoder/nli-deberta-v3-large，两个方向 argmax 都是 entailment 才通过；batch 16，max_length 256。
- 人工标注：A、B 两组各 20 条，标签存 `R13/logs/para_review_sample20_labels.csv`、`para_review_sample20_b_labels.csv`。
- 停用词与去后缀：sklearn ENGLISH_STOP_WORDS；后缀按序试 ically, ation, ities, ness, ment, ical, ally, ing, ity, ies, ive, al, ed, es, ic, ly, s（词长需 > 后缀长 + 2）。`C13/stage13_para_nli.py:15–26`
- D 规则与 66 篇子集：见矛盾 d。
- all-mpnet：mean 池化（模型自身池化），最大层 L12 / 句向量。1.40 与 1.90 是无量纲比值 $\max_l(G'(l) - G'(\text{基线层})) \div G'(\text{基线层})$。

实验 19：X4

- 目标提示、注入位置：见第三部分；在同一层把 " X" 位置的 block 输出换成源状态，batch = 7 一次注入 7 层。
- 打分 s：答案每个 token 的 log10(1/rank) 平均。
- 文本基线 1（kNN）：阳性对照失败，结论不成立。文本基线 2（监督 LR）：given_first 阳性对照通过、surname_first 未通过。阳性对照 = 留出 log10 p 是否高于频率先验。

E3 作者链（上一轮追问）

- 前面的作者用**真名**（标注包作者顺序），名字之间插入逗号 token（id 11）；逗号不打分。
- 假标题条件：7 个 Stage 10 条件全部以连写方式各跑一次，每个条件后面接的都是同一组真作者；spec 在连写和单独两种口径下各自算 true − mean(false_0..4)。所以合作者在假标题运行里同样存在，“标题作用变小”与这一构造有关。
- 4+：第 4 位及以后合并，每篇论文 × 位置 × 条件先求均值。target − control 用档内合并。
- 更正 PPT 备注第 46 页：target 第 4 位及以后作者的标题特异信号从单独 0.421 降到连写 0.260，不是“0.45 → 0.26”。`R11/summary/E3_chain.csv`

七、早期 Stage 3–9

判断：手册已逐个子实验写出材料、脚本、种子、步骤和公式，Stage 1–8 的代码和结果都在 commit e2c7156。按“可重跑”标准，大部分子实验有足够信息；缺口如下。

Stage	能否重跑	还缺什么
2 协议	**可以**	没有独立目录和脚本，协议分散在 Stage 4/5/6 的 config 里
3 lens 验证（Exp 1–7）	**可以**	Exp 编号的来源文档 `Validation_Record_351_Completeness_Checked.docx` 不在集群（U21，你本人）；public lens 拟合时的模型与 wikitext revision 未记录（U14，问 Neuronpedia）；split-half 相对差的分母未逐行核对

4 Benchmark20	**可以**	seed 3514，`random.Random(f"3514:{组}:{档}")`；无缺口
5 交叉对照	**可以**	Pilot50 用 sha256(“35150” + id) 哈希排序；无缺口
6 完整名 JMRR	**可以**	种子 35161+、35162+；无缺口
7.1	**可以**	种子 35171；无缺口
7.1B	**不能（未完成）**	只跑到 1,166 / 15,519，没有分析；不在 git；是否有意放弃待你确认（U23）
7.2	**可以**	种子 35172；已发布区间由 2026-10-30 重算替代
7.3	**基本可以**	tier 2 函数未逐行核对；报告中 “L56 +0.113、L32 −0.032 [−0.058, −0.006]” 未逐行核对
7.4	**可以**	种子 741，B = 20,000
8A–8D	**可以**	主终点改动的决定人与依据（U28，你本人）
8E	**只能按重算版**	原 8E 脚本找不到；2026-10-30 已从 8C 原始 logits 独立重算，点估计与报告相同（作业 11500770）
9 Fit A	**可以**	不在 git，代码与结果在 /scratch
9 Fit B / 9B / 9C	**未完成**	Fit B 停在 66/100（作业 11289356 时限到达，检查点可续跑）；9B、9C 没有代码〔2026-11-06 已更新：Fit B 续跑与 holdout 列入批次 2（补充 12 第 2-1 项），2026-11-08 已在运行，尚无结果；见页首更新框〕
全部 Stage 1–9	—	都在交互式 bash 会话里手动运行，作业号多数可按时间对应，约 15 个无法追溯（U20）；运行时软件版本未记录

八、需要别人回答的清单

只有组长能答

1. U01：两次标注运行的 run.json、elm 代码版本、open_results_noise.jsonl。
2. U03：多选题是否关闭 thinking；答案位置是否在空 <think></think> 块之后。
3. U04：开放回答剥离名字用的 `metrics/panel.py` 原文。（我们打分用的名字切分见手册 G5.2，不需要问。）
4. U06：多选干扰团队的抽取规则原文、bin_window / over_cap / et_al_mismatch 的含义、是否排除共同作者、随机种子。
5. U07：选项显示的截断规则（恰为 8 人是否截断、et al. 的确切写法）。
6. U10：标注运行的加载方式、batch、GPU 与时长。

需要你本人确认或在集群上查

1. U28：Stage 8 主终点从 7 层积分改为 L56 的决定人与依据。
2. U21：Stage 3 Exp 编号来源文档。

3. U23：7.1B 是否有意放弃。
4. U34：Stage 10 冻结版 847e7dde 与运行版 9107c80b 之间改了什么（或问 Stage 10 原作者）。
5. 各 Stage 运行时的 transformers / torch / CUDA 版本，以及 E2 以外实验的注意力实现。
6. Stage 10 团队整群区间的具体数值（`R13/reports/cluster_ci.md`）。
7. Stage 8 金标准是哪位作者（`351_stage8B.py`）；“前 10 命中率”按 token 还是按论文（`stage10_extra.py:159–176`）。
8. 手册内部不一致：B3 表写 M1/M2 的 bootstrap 为 1,000 次，M2 节写 200 次；需对照 `stage13_cpu.py` 第 26 行与第 142–146 行。

问 Neuronpedia

1. U14：public lens 拟合时的 Qwen3-32B 与 wikitext revision。

九、本次修改记录

讲稿（逐个实验讲解稿，在线版）

1. 0.5：“每个供体最多借出 5 次” → “strict/medium/loose 三档最多 5 次，nearest 档最多 7 次”。
2. 实验 4：W 的定义补“并列记 0.5”；统计一行注明 Holm 与逐对剔除是 2026-10-30 事后补算；结果补上 L56 终点 +4.98 pp 与积分终点 +2.41 pp 的关系。
3. 实验 5：“L40–L62 每一层都算” → 主轮 L40、48、56、62 + 扩展轮 L50–55、L57–61；L41–47、L49 未算。
4. 实验 10：首字母靠 “:” 恢复 L52 0.90 → 0.92（重算值 0.917）。
5. 实验 11：替换范围由“名字位置”改为“整段对齐尾部 + 全部名字位置”。
6. 实验 12：标准化说明改为“原版用全部论文，训练折重算后 L40 0.061、L56 0.075”。
7. 实验 14：“logit lens L62 占 87%” → “logit lens L62 第一名有 87% 是像名字的 token（不一定正确）”。
8. 实验 18：D 的规则补后备分支；“66 篇上 1.40 对 1.90” → “66 篇中 test 的 37 篇上”。

PPT v16（网页版）

1. 第 12 页：L56 标题优势区间 [4.7, 13.9] → [4.8, 14.0]（2026-10-30 重算值 [4.77, 14.00]；原区间不在 7.3 输出中）。
2. 第 14 页：RQ 表注明 L56，加一行“RQ2 A−B，7 层积分（冻结主终点）+2.41 pp [+0.91, +4.00]”；图注说明是 PROTOCOL.md 的 L56 估计。
3. 第 15 页：“Scripts not yet archived: not a completed experiment” → 原脚本缺失、已从原始 logits 重算、点估计相同、仍属事后分析。

4. 第 34 页：7.2 七层积分区间上限 +0.228 → +0.229（重算值）。

未改，需另行处理

- PPT 备注第 46 页 “0.45 → 0.26” 应为 “0.421 → 0.260（第 4 位及以后）”：备注只在 pptx 与“带讲稿”PDF 里，网页版没有备注，这次没有改。
- 浅色页（Stage 10–13）是整张图片，图上文字无法在网页里直接改；本次核对没有发现图上数字错误。
- 方法手册：只在 B3 表的 M1/M2 一行加了“待核”注释，没有改数字。