Stage 1–11 实验报告

大模型在哪一层"记住"论文作者

本报告合并原 Stage 1–9 报告（小样本：20 → 50 → 200 篇）与 Stage 10–11 报告（全量 9,108 篇），并加入跨阶段的 R0/R1 分层分析。之后的新实验都只更新本报告和 Stage 1–11 合并 PPT。

目录

总览：四条论证线与主要结论

第一部分 · Stage 1–9：小样本阶段（建立信号、排除替代解释）

Stage 1 分组 · 3 lens · 4 · 5 · 6 · 7 · 8 · 9 · 综合 · 待核实 · 附录

第二部分 · Stage 10–11：全量阶段（定位与干预）

§ 1 摘要 · § 3 数据与分组 · § 4 方法 · § 6 结果 · § 7 结论 · § 8 局限

第三部分 · 跨阶段：R0/R1 分层分析与两阶段对照

第四部分 · Stage 12 正式结果；Stage 13：中间层到底表示什么（计划与进展）

Stage 12 结果（P1、P2、N1、N2、F2） · X6 结果 · X7 结果 · M3、X1、X4 结果 · X3 结果 · Stage 13 计划

总览：一个问题，四条论证线

研究问题：Qwen3-32B 写不全一篇论文的作者、却能在多选题里认出真名单时，论文的作者信息在网络的哪一层形成、经过哪些位置、能被哪种读出工具看到。Stage 1–9 在 20–200 篇论文上建立信号并逐一排除替代解释；Stage 10–11 在全部 9,108 篇论文上逐层定位，并用替换和阻断做干预。

线	问题	Stage 1–9	Stage 10–11
A 这篇论文?	信号是否针对这篇论文，而不是名字好猜	5、7.2、7.3、8	10 标题特异信号；11 名字先验、probe 对照；R0/R1 分层
B 读出工具	每种读出能看到什么	3、7.4、8、9	10 三种 Jacobian lens 与 logit lens；11 线性 probe
C 哪一层	信号何时出现、何时被使用	4、7.2、7.3、8（L56）	10 细层 L50–61；11 替换与阻断
D 哪个 token	名字或提示词的哪一部分带有信号	6、7.1	10 名字格式与 token 角色；11 标题后 token 与作者链

主要结论

1. **真标题有帮助，而且是针对这篇论文的。**小样本：L56 真标题比错误标题高 +9.3 pp（Pilot50），200 篇新论文上 +5.2 pp。全量：真标题减 5 个匹配假标题的"标题特异信号"在 L62 约 0.44；

名字先验只占目标–对照差的约 1/3，在姓的第一个 token 上约为 0。

2. **“认得出”组的优势是真的，但只出现在最后几层。**小样本的 A–B 不确定（依赖少数几对）。全量在引用档内比较：中间层约为 0，输出处 +0.21；两组都只用 R0 时 +0.20，结论不变（第三部分）。
3. **读得早，说得晚。**替换实验：把真标题运行中标题之后的 token 换进假标题运行，L48 已恢复 83%，L52 起 100%；从 L52 起阻断对标题的注意力已没有影响。标题信息在 L24–50 被读取，到 L57–61 才在名字位置被 lens 读出。
4. **Jacobian lens 没有显示额外的论文信息。**小样本中 J-Lens 相对 Vanilla 没有增量；全量中它在中间层多读出的是“名字形状”，不区分论文，也不偏向目标组。
5. **第一个 token 与名字其余部分的差别由名字格式解释**：首字母开头时，姓落在后续 token 上；完整名开头时名本身就带信号。
6. **写对了部分作者的 R1 论文最强，但时间点相同**：同样只在最后几层领先，中间层没有提前（第三部分）。

小样本与全量对照

发现	Stage 1–9（20–200 篇）	Stage 10–11（9,108 篇）	判断
真标题有帮助	Pilot +9.3 pp，新 200 篇 +5.2 pp	L62 标题特异信号约 0.44	**确认**
认得出 > 认不出	不确定，依赖少数几对	输出 +0.21，中间层约 0	**确认，但只在最后几层**
同一口径（只用 R0）	A vs B（都是 R0）	A vs B：输出 +0.199 [0.187, 0.212]，各层形状与合并口径相同	**两阶段可比，结论不变**
关键层	L56	L56 开始，L57–61 上升最快；标题在 L24–50 被读取	**细化**
J-Lens vs Vanilla	无增量	中间层多读出名字形状，不读出论文身份	**一致**
第一个 token vs 后续	差异在后续 token	由首字母 / 完整名两种格式解释	**解释**
引用数	低–高不确定	随引用单调上升，ρ = 0.45	**解决**
lens 稳定性	一次 split-half；Stage 9 只完成 Fit A	三种 Jacobian lens 结论一致	**仍需核实**

分组怎么对应Stage 1–9 的 A/B/C/D 与 Stage 10–11 的 target/control 来自同一个标注包：target = A + C（4,621），control = B + D（2,220）。A = 认得出・R0（4,110），B = 认不出・R0（2,186），C = 认得出・R1（511），D = 认不出・R1（34）。R0 = 开放回答一个真作者都没写对；R1 = 写对了一部分但 HR2 > 0.5。

第一部分

Stage 1–9：小样本阶段

原 Stage 1–9 报告全文（记录日期 2026-10-18 至 10-21）。“与 Stage 10–11 的对照”一节已移到第三部分并更新。

摘要

研究问题：当 Qwen3-32B 能在多选题里认出一篇论文的作者名单、却在开放回答中写不出任何作者时，模型内部是否存在可读出的作者信号，这个信号是否真的与“这篇论文”有关。

Stage 1–3 建立队列、固定模型与提示词，并验证 Jacobian lens（J-Lens）；Stage 4 首次逐层读出作者；Stage 5–7 逐一排除“名字本身好猜”“只在给出前缀后才好”“只赢一个错误名字”等替代解释；Stage 8 在 200 篇全新论文上做冻结设计的独立验证；Stage 9 检验 lens 是否依赖拟合数据。

主要结论：

- **真标题有帮助，且可复现。**Pilot50 中 L56 真标题比 20 个错误标题平均高 +9.3 个百分点（35/50 篇为正）；在 200 篇新论文上为 +5.18 pp [+2.93, +7.48]。
- **“认得出”组是否更强尚不能确定。**Pilot 的 A−B 区间均跨 0；Stage 8 为 +4.98 pp [+0.32, +9.91]，但去掉最大的 10 对后降为 −0.39 pp。
- **J-Lens 相比 Vanilla 没有显示额外价值**：Stage 7.4 为 +0.002 [−0.008, +0.012]，Stage 8 为 −1.38 pp [−3.48, +0.68]。
- **A−B 差异集中在名字的后续 token**（+0.021），第一个 token 几乎为 0，原因当时未解释。
- Stage 9 最终只完成了 Fit A（Stage 10 使用的 fitA 即此）；Fit B 和 holdout 稳定性比较没有做，lens 的拟合稳定性尚未检验。

所有 Stage 1–7 结果均为同一 Pilot50 上的探索性分析，L56 曾被反复查看；只有 Stage 8 是预先冻结的独立检验。

阅读指南：Stage 怎么分

Stage 按研究问题划分；同一问题下的不同实验是子阶段（如 7.1、8A）；prepare、audit、resume、repair 等工程步骤不单列。档案中没有单独的 Stage 0，lens 验证实验（Exp 1–7）归入 Stage 3。

阶段	Stage	作用
建立测量	1–4	定义论文、标签、提示词和读出指标，先看能否观察到作者信号
排除替代解释	5–8	逐步检查名字先验、token 位置、错误标题、样本选择，并用独立样本验证
检验工具	3、9	检验 lens 的拟合可靠性与可比性

全文的分析按四条论证线组织，每个 Stage 标题旁标出所属的线：

线	问题	相关 Stage
A 这篇论文?	信号是否针对这篇论文，而非名字好猜	5、7.2、7.3、8 RQ1–RQ2
B 读出工具	J-Lens 是否优于 Vanilla，是否稳定	3、7.4、8 J–V、9
C 哪一层	信号在第几层出现	4、7.2、7.3、8（L56）
D 哪个 token	第一个 token 还是名字其余部分	6、7.1

字母 A/B 在档案中有三种用法：行为分组 A/B（本报告默认含义）、历史 split-half 的 A/B 两半、Stage 9 的 Fit A/Fit B。三者无关。

Stage 1 队列与行为标签

来源

2026-10-15 标注包共 9,108 篇论文，每个 paper_id 对应论文元数据、作者列表、模型开放回答、多选识别结果、HR2 和 group_tight。分析队列为冻结的 6,841 篇（351_prepare_all.py 保留 group_tight = target/control 且 HR2 > 0.5 的论文），其余 2,267 篇 guard/中间情况排除。HR2 直接取自标注包，未重新计算。

分组

组	识别 / 开放回答	全队列	Pilot50
A	识别通过 / R0（没写对任何作者）	4,110	20
B	识别失败 / R0	2,186	20
C	识别通过 / R1（部分作者匹配）	511	7
D	识别失败 / R1	34	3
合计		6,841	50

与 Stage 10–11 分组的对应关系：Stage 10–11 的 target/control 就是把 R0 和 R1 合并后的识别分组。

	认得出（target）	认不出（control）
R0：一个作者都没写对	A = 4,110	B = 2,186
R1：写对一部分（HR2 > 0.5）	C = 511	D = 34
合计	**target = A + C = 4,621**	**control = B + D = 2,220**

Stage 1–9 比较的是 A vs B，Stage 10–11 比较的是 (A+C) vs (B+D)。多出来的 R1 论文几乎全在 target 一侧（C 511 篇，D 仅 34 篇）。

> **R0/R1 分层的结果（第三部分）**
>
> 在全量数据上只比 A vs B（都是 R0），输出处的目标−对照标题特异差为 +0.199 [0.187, 0.212]，合并口径为 +0.207，各层形状相同；C 比 A 强（+0.11），但同样只在最后几层领先。两阶段的分组口径因此可以直接对照。详见第三部分

识别通过 = 4 种选项顺序全对且真选项平均概率 ⩾ 0.5；失败 = 0–1 次对。A 与 B 都没有写对任何作者，只在“能否认出名单”上不同，所以 A–B 对比的是“认得但说不出”。

Pilot50 构造

- 强制纳入 Stage 4 的 20 篇（A8/B8/C3/D1；这 20 篇是 Stage 4 用种子 3514 在"组 × 引用档"内打乱后轮流抽取的），再新增 30 篇（A12/B12/C4/D2）。新增的 30 篇**不是随机抽样**：每组其余论文按 sha256("35150" + paper_id) 排序，按这个确定性的哈希顺序依次选取，并在同领域、同引用档内配对。
- 20 对 A/B 在完全相同的领域和引用档内匹配，先最大化配对数，再最小化 |Δ年份| + 2×|Δ作者数|。C/D 仅作描述。
- 匹配平衡：平均年份差 1.65（最大 4），作者数差 1.15（最大 7）；年份 SMD +0.016，作者数 SMD +0.287。同领域同档不等于其他协变量完全平衡。
- Pilot50 未覆盖 257–512、2049–4096、4097+ 引用档；4097+ 档在全队列中没有 B、D 组论文。

> **标签局限**
>
> 0–2 引用档的识别通过率为 38.6%（普通）/ 25.5%（严格），高于预设的 ⩽10% 下限，说明低引用档的“通过”可能部分来自猜测。严格通过不能直接解释为模型存储了事实；低引用也不等于训练中没见过。

Stage 2 模型、提示词与打分协议

参数	设定
模型	Qwen/Qwen3-32B，BF16，评估模式；revision 9216db5781bf21249d130ec9da846c4624c16137；64 层，隐藏维度 5,120
读出层	L16、24、32、40、48、56、62（从 0 计），目标层 L63
读出方式	Public-557 J-Lens；Vanilla（use_jacobian=False，即 logit lens）；模型真实输出
位置 / 长度	最后一个输入位置；打分上下文上限 512
名字切词	encode(prompt) + encode(" " + author, add_special_tokens=False)
硬件	29 层放 GPU，35 层放 CPU；embedding、最终归一化和输出层在 GPU
生成	不生成，只做前向和 teacher forcing

提示词（保留换行）：

```
Who are the authors of the paper titled "{title}" ({year})?
Authors:
```

- **名次**：r = 1 + 词表中 logit 严格大于正确 token 的个数；并列取最好名次。倒数名次 1/r 越大越好。
- **JMRR**：论文-层得分 = 对作者平均（对 token 平均 1/r）；积分 JMRR = 7 个源层的平均，L63 作为参照不计入。
- **两种任务**：第一个 token 得分问“仅凭论文提示能否开始这个名字”；后续 token 得分问“给出正确开头后能否接下去”。
- **实现检查**：强制使用指定 token ID 并核对两条读出路径一致；J-Lens 与 Vanilla 的最终 logit 差超过 0.1 即拒绝。这是实现保护，不是效应阈值。

Stage 3 B 读出工具 J-Lens 搭建与验证（Exp 1–7）

比较两个 lens：Neuronpedia 公开的 Public-557（557 条 WikiText-103 提示词拟合，覆盖 L0–L62）和自己拟合的 Self-100（100 条提示词，6 个层）。共享 6 个层 L24–L62，L16 不参与配对比较。

Exp 1 数值检查

两者矩阵都可加载、有限、形状 5,120×5,120（63/63、6/6 通过）。Frobenius 范数相近（如 L48：Public 106.07 vs Self-100 105.16，float64 精确值；原记录的 105.8 / 104.9 用 float32 求和，系统性偏低约 0.25%，2026-10-30 重算），但范数相近不代表方向一致或事实正确。

Exp 2、4 读出保真度

问题：如果最终模型偏好 token X，中间层的读出能否近似最终分布？在 20 条通用提示和 20 条论文提示上比较 KL(P_final ‖ P_readout)。

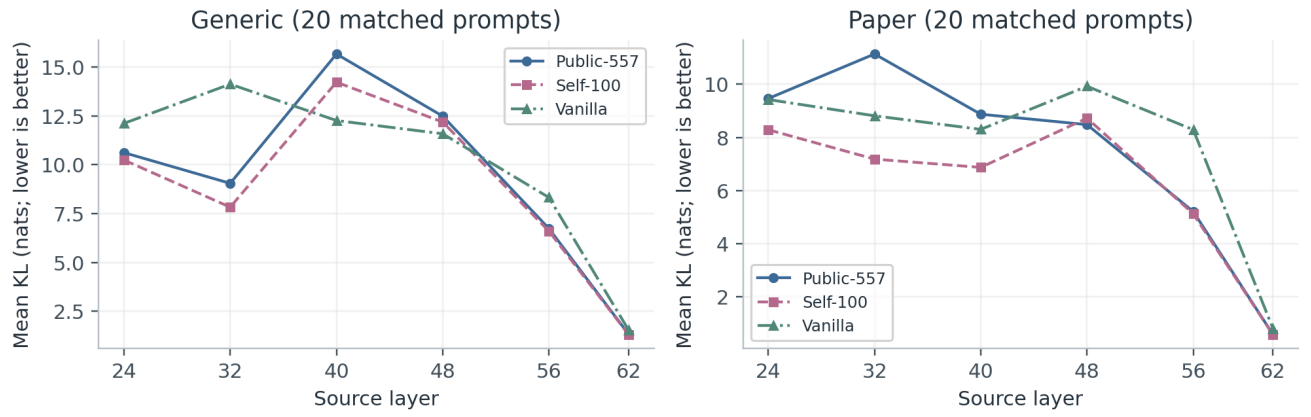


图 3.1 两个 lens 与 Vanilla 的 KL（越低越好），20 条通用提示（左）与 20 条论文提示（右）

层	通用 Self−Public KL [95% CI]	论文 Public / Self / Vanilla KL	论文 Top-10 重合 Public / Self / Vanilla
L24	−0.379 [−1.129, +0.520]	9.460 / 8.286 / 9.422	0 / 0 / 0
L32	−1.221 [−1.954, −0.488]	11.135 / 7.180 / 8.810	0 / 0 / 0
L40	−1.443 [−2.264, −0.629]	8.869 / 6.869 / 8.299	0 / 0 / 0
L48	−0.301 [−0.543, −0.052]	8.479 / 8.722 / 9.922	0 / 0 / 0
L56	−0.134 [−0.383, +0.123]	5.207 / 5.124 / 8.286	0.040 / 0.045 / 0.005
L62	−0.018 [−0.041, +0.005]	0.584 / 0.578 / 0.808	0.345 / 0.355 / 0.720

Self-100 在 6/6 个通用层、5/6 个论文层 KL 更低，但在论文 L62，KL 优于 Vanilla 的同时 Top-10 重合远低于 Vanilla。**分布保真度和排名保真度不能互换。**

Exp 3 金标准 vs 错误作者（20 篇）

层	Self 首 token 胜率	Public 首 token	Self 全名胜率	Public 全名
L24	70%	70%	70%	65%
L32	55%	60%	55%	55%
L40	40%	50%	55%	45%
L48	55%	45%	70%	70%
L56	75%	75%	55%	50%
L62	50%	45%	55%	55%

两个 lens 互不占优；L48 都是 14/20 全名胜出。全名 teacher forcing 给了名字前缀，不是自由回忆。

Exp 5 泄漏审计

Self-100 用冻结的 1,000 条 WikiText 语料前 100 条；与 40 条评估提示 0 次完全匹配、0 次 8 词重叠。Public-557 只能确认处理过索引 0–556，原始文本和拟合时的模型版本无法恢复，所以无法对 Public 作“无泄漏”结论。

Exp 6 拟合协议与源码

两份 fitting.py 的 519 行 diff 显示估计公式一致（有效位置 cotangent、源位置梯度平均、逐提示累加后除以 n_done）。不同之处：训练数据、层覆盖（63 vs 6）、dim_batch（64 vs 8，只影响反向批处理）、停止方式（Public 在 557 条时人工停止，最后相对变化 0.006215，未达 0.002 阈值）。结论：公式可比，完整拟合条件只部分可比，557 与 100 的差别不能归因于提示数量。

Exp 7 Self-100 split-half（历史 50 + 50）

把 Self-100 按偶数 / 奇数索引拆成两半各 50 条分别拟合（A 用时 1,971 s，B 1,504 s）。

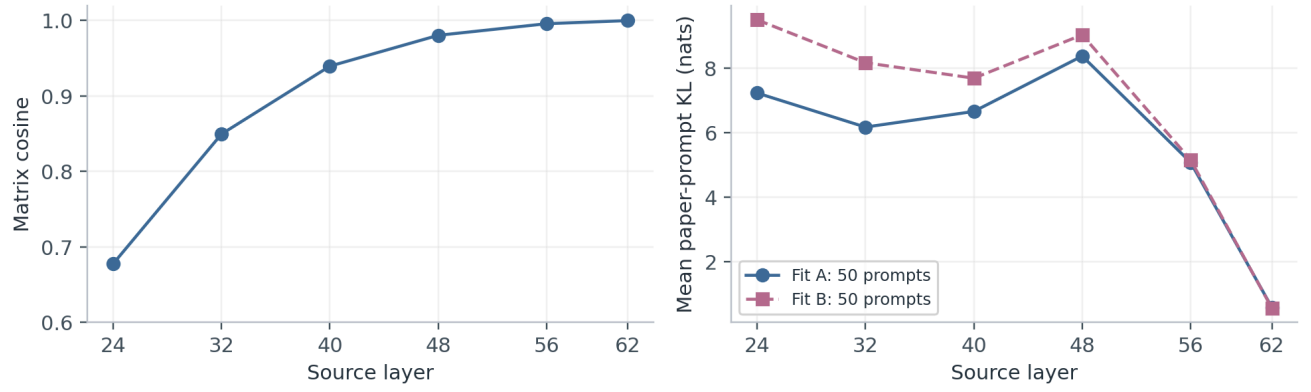


图 3.2 历史 split-half：矩阵余弦（左）与论文提示 KL（右）

矩阵余弦从 L24 的 0.678 升到 L62 的 0.9998，相对 Frobenius 差从 0.807 降到 0.018。论文 L48 上 A 的 KL 更好（8.38 vs 9.04），B 的 final-top1 倒数名次更高。后层一致可能只是因为离 L63 近；只有一次拆分，无法估计不同拆分之间的变异。

> **Stage 3 结论**
>
> 两个 lens 都能用；估计公式一致；但没有哪个 lens 在作者任务上明显更好，也不能用 KL 代替作者排名。

Stage 4 C 哪一层 作者读出基准

20 篇论文、93 位作者（A8 / B8 / C3 / D1），平均 90.68 秒/篇，GPU 峰值约 29.5 GiB（历史报告值）。本档案从 Stage 6 中标记为 stage4_verified_reuse 的记录恢复了全部 20 篇和 93 个作者实例。

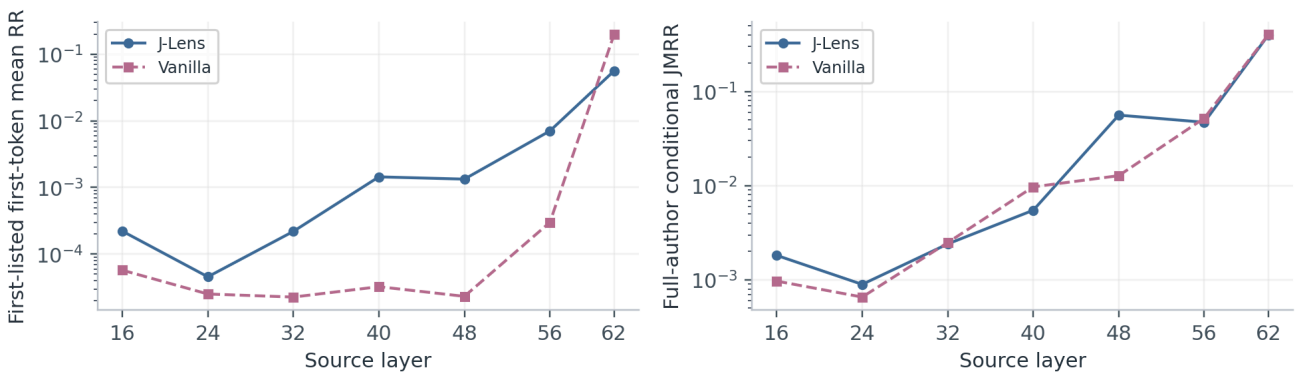


图 4.1 逐层读出：第一作者首 token 平均倒数名次（左）与条件全名 JMRR（右），对数坐标

层	首 token RR：J-Lens	首 token RR：Vanilla	条件全名：J-Lens	条件全名：Vanilla
L16	0.000221	0.000057	0.001819	0.000970
L24	0.000046	0.000025	0.000895	0.000656
L32	0.000219	0.000023	0.002404	0.002487
L40	0.001442	0.000032	0.005481	0.009703
L48	0.001333	0.000023	0.056041	0.012760
L56	0.007040	0.000300	0.047070	0.052046
L62	0.055923	0.196579	0.397721	0.401723

单篇论文主导

L56 第一作者 J-Lens 平均 RR = 0.00704，中位数仅 0.00092；一篇论文贡献了总和的 71.03%，去掉后平均降为 0.00215。相对 Vanilla 的大幅提升本身不足以说明作者信息普遍可读。这直接促成了后续所有对照设计。

Stage 5 A 这篇论文? **交叉标题–作者对照**

设计

50 篇冻结论文。每篇论文 P（第一作者 G）配一篇来源论文 Q（作者 F），F 与替换标题都来自同一篇 Q。Q 须与 P 同领域、同引用档，作者团队按姓名字符串不相交，第一个名字成分也不同；依次最小化年份差、标题长度差、名字长度差，再用种子哈希（35150）。50 对中没有出现 G 与 F 首 token 相同的情况。

- M(上下文) = G 首 token logit − F 首 token logit
- 交叉对比 T = M(P 的标题) − M(Q 的标题)。如果只是 G 本身更好猜，T 会抵消为 0。
- A–B 在同样 20 对上计算；积分终点为 7 个源层平均。bootstrap 2,000 次。

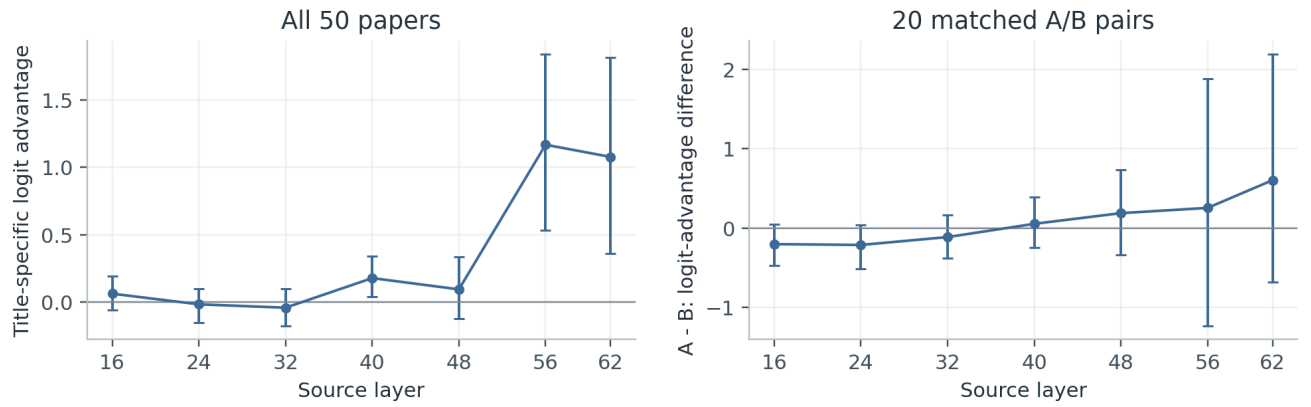


图 5.1 J-Lens 交叉对比：全部 50 篇（左）与 20 对 A–B（右）

结果

全部 50 篇：L56 +1.167 [+0.533, +1.838]，L62 +1.077 [+0.363, +1.816]。匹配 A–B 积分：+0.081 [−0.427, +0.648]。

> **结论**
>
> 标题在后几层确实改变了两个名字的相对偏好；但 A 是否比 B 受益更多不能确定。单一错误名字和单一替换标题的参照太窄，所以有了 7.2（扩到 100 个错误作者）和 7.3（扩到 20 个错误标题）。

Stage 6 D 哪个 token 完整作者名的条件 JMRR

50 篇全部完成：复用 Stage 4 的 20 篇（核对 schema、提示词、作者和 token 名次后），新算 30 篇。每位作者单独打分：对名字 [G_1, G_2, G_3]，在提示后给 G_1 打分，再在提示 + G_1 后给 G_2 打分，依此类推。上下文上限 512，名字上限 32 token（超长拒绝而非截断）。共 227 个作者实例、972 个 token 实例、14,580 行（15 种读出 × 层），最长名字 10 token。

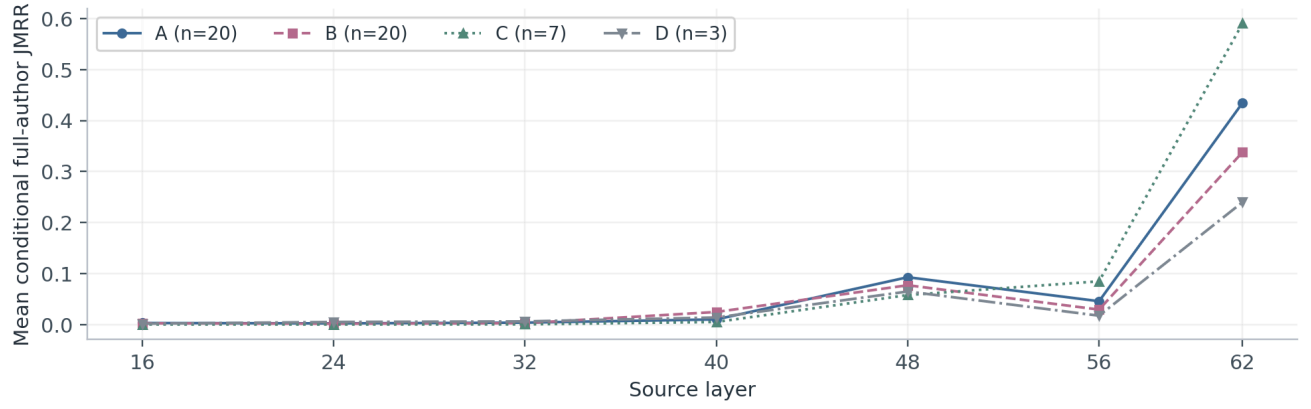


图 6.1 条件全名 JMRR 逐层轨迹，按组平均（A=20, B=20, C=7, D=3）

组	n	7 层积分 J-Lens JMRR	95% CI
A	20	0.084931	[0.075009, 0.095752]
B	20	0.068310	[0.056929, 0.079632]
C	7	0.105820	[0.079544, 0.137856]
D	3	0.050166	[0.032803, 0.082428]

L62 A−B = +0.0966 [+0.0282, +0.1630]；Vanilla 也为正 +0.0907 [+0.0161, +0.1676]。条件全名的正差不代表模型能无前缀地回忆出作者，因此 7.1 把第一个 token 和后续 token 拆开。

Stage 7 排除替代解释（7.1–7.4）

Stage 7 不是重复实验，而是在同一 Pilot50 上逐步检查 Stage 4–6 的信号究竟来自什么。

7.1 D 哪个 token 第一个 token vs 后续 token

只用 CPU 重新分解 Stage 6 数据，不重跑模型。作者等权，后续 token 只对有后续 token 的作者平均（单 token 作者不补 0），配对 bootstrap 10,000 次（种子 35171）。750 个历史聚合值与 Stage 6 完全一致（最大差 1.1×10^{-16}）。

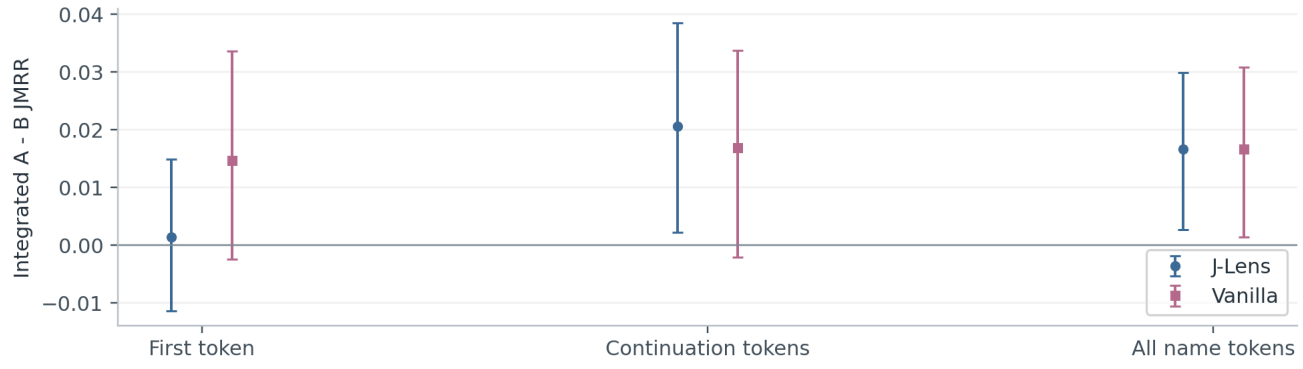


图 7.1 按 token 位置的 7 层积分 A−B JMRR

终点	A−B（7 层积分）	95% CI	L62 A−B	L62 正向对数
第一个 token	+0.001366	[−0.011430, +0.014861]	+0.014112	12/20
后续 token	+0.020644	[+0.002232, +0.038503]	+0.121454	15/20
全部 token	+0.016620	[+0.002640, +0.029887]	+0.096579	17/20

补充：只看第一作者是否代表整个团队？同样 50 篇上，第一作者首 token RR 与全部作者首 token RR 的相关为 L40 r=0.69、L56 r=0.72、L62 r=0.77，部分相关是结构性的（第一作者包含在全部作者里）。

> **结论**

A–B 差异主要在给出正确前缀之后的后续 token 上；第一个 token 不确定。这不能证明无提示的作者回忆。当时未能解释为什么后续 token 才有差异。

7.2 A 这篇论文? 金标准 vs 100 个错误作者

每篇冻结第一作者 + 50 个匹配错误作者 + 50 个随机错误作者（来自 6,841 篇，种子 35172）。匹配分级：tier 0 同领域、同 token 数、年份差 ≤2；tier 1 年份差 ≤5；tier 2 任意年份；tier 3 只同 token 数。实际匹配数 2,159 / 182 / 135 / 24。指标为金标准胜率：金标准 logit 更高记 1、相等 0.5、更低 0，对所有错误作者平均。共 75,000 行配对记录（50 × 100 × 15）。

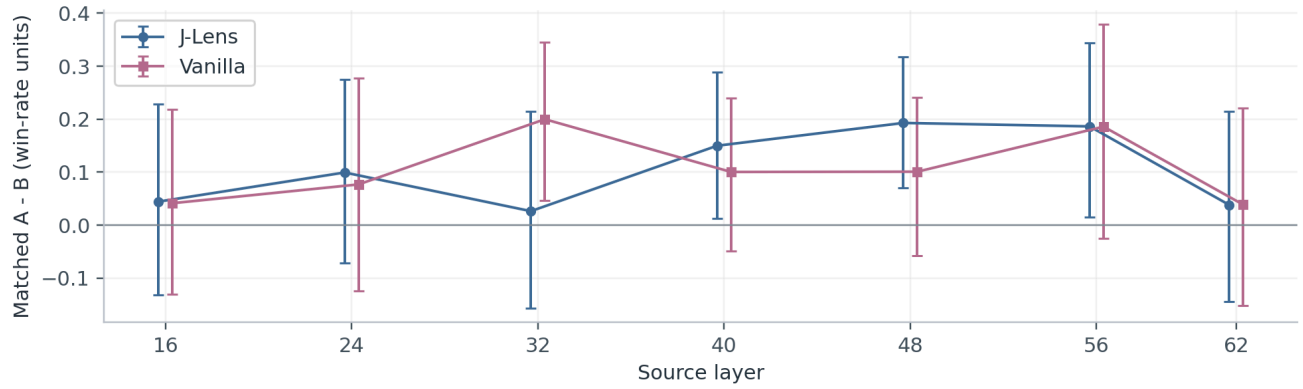


图 7.2 原标题下首 token 金标准胜率的匹配 A–B（100 个错误作者），配对 bootstrap 10,000 次

- J-Lens A–B：L40 +0.150 [+0.013, +0.289]，L48 +0.193 [+0.071, +0.318]，L56 +0.187 [+0.015, +0.345]，L62 +0.038（跨 0）。
- 7 层积分（合并池，20 对）：J-Lens +0.105 [−0.012, +0.229]，Vanilla +0.106 [−0.006, +0.216]（配对 bootstrap 20,000 次，种子 20261031 / 20261032；原区间无出处文件，2026-10-30 按逐对数据重算）。
- 5,000 个错误作者中 156 个与金标准首 token 相同，记为平局；100 个错误名字平均只有 45.76 个不同的首 token。
- 24 个 tier-3 放宽全部出现在同一篇 A 论文中，去掉这一对后，7.3 匹配池 7 层积分 A–B 为 +0.023 [−0.017, +0.068]（19 对，配对 bootstrap 10,000 次，种子 20261037；2026-10-30 重算）。

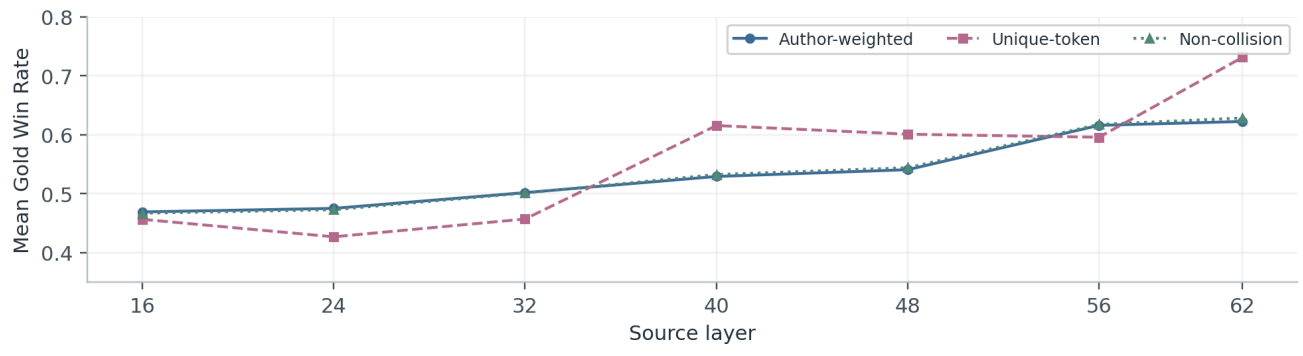


图 7.3 不同候选加权方式的敏感性（作者加权为主终点）

7.3 A 这篇论文? 打乱标题参照

每篇冻结 20 个仅按元数据选出的替代标题（种子 35173），使用 7.2 完全相同的候选、年份、提示格式和 15 种读出，只换标题，共 1,000 个上下文。选题分级：tier 0 同领域同档、年份差 ≤2、标题 token 差 ≤5（334 个）；tier 1 放宽到 ≤5/≤10（487）；tier 2 放宽引用档（179）。平均年份差 1.85，标题 token 差 4.36，同领域 100%，同档 82.1%。

标题优势 = W(真标题) − 20 个替代标题的平均 W。

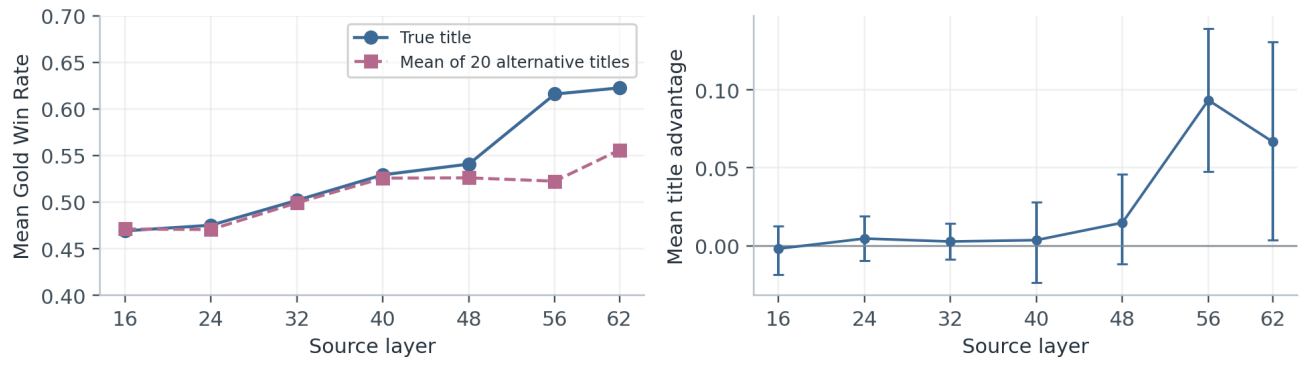


图 7.4 全部 50 篇：真标题与替代标题的胜率（左）及论文内标题优势（右）

层	真标题胜率	参照均值	真 − 参照	正向篇数
L16	0.469	0.471	−0.002	26/50
L24	0.475	0.471	+0.005	26/50
L32	0.502	0.499	+0.003	23/50
L40	0.529	0.526	+0.004	29/50
L48	0.541	0.526	+0.015	27/50
L56	0.616	0.523	**+0.093**	35/50
L62	0.623	0.556	+0.067	32/50

- L56 标题优势 +9.34 pp [+4.77, +14.00]（论文 bootstrap 20,000 次，种子 20261046；原区间无出处文件，2026-10-30 重算），留一篇论文后均值 +8.64 到 +9.99。Vanilla L56 +10.6 pp，最终输出 +7.2 pp：标题效应不是 J-Lens 独有。
- 匹配 A−B 积分：J-Lens +0.0177 [−0.0211, +0.0626]，Vanilla +0.0315 [−0.0090, +0.0757]，均跨 0。L56 +0.113（跨 0），L32 −0.032 [−0.058, −0.006]。

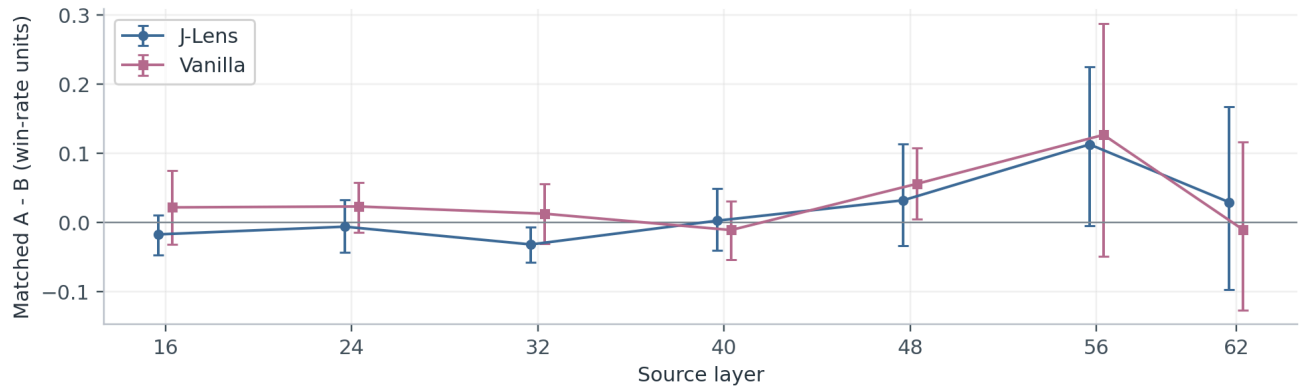


图 7.5 扣除 20 标题参照后的 A–B 胜率对比

稳健性

- **来源作者重叠**：199/1,000 个替代标题的来源论文作者在错误作者池中。去掉后，7 层积分标题优势从 +0.0262 变为 +0.0283。
- **候选加权**：作者加权、唯一 token、去平局三种方式下，合并标题优势为 +0.026 到 +0.032（分别为 +0.026 / +0.032 / +0.027）；J-Lens 与 Vanilla 各 3 个 A–B 区间，共 6 个，全部跨 0（2026-10-30 重算，见 351_stage7_3/recompute_2026-10-30/）。
- **低引用**：0–2 引用档 6 篇（A2/B2/C1/D1），L56 平均优势 +0.224，5/6 为正，但 0/6 的加一尾概率 ≤0.05（20 个参照下最小可能值为 1/21 ≈ 0.048）。6 篇不能确立总体下限。

> **7.3 结论**
>
> “真标题是否有帮助”和“对 A 是否更有帮助”是两个不同问题：前者在 L56 有较强的描述性证据，后者没有确立。

7.4 B 读出工具 跨阶段审计

只读连接 Stage 5–7.3 的冻结输出，bootstrap 20,000 次（种子 741）。

诊断	估计	不确定性 / 样本
Stage 5 与 7.3 在 L56 的一致性	Pearson r = 0.445；Spearman ρ = 0.471	n = 50，符号一致 32/50
J-Lens − Vanilla 积分标题优势	+0.00221	[−0.00753, +0.01241]，中位数 −0.0019，24/50 为正
该增量的匹配 A–B	−0.01387	[−0.03320, +0.00358]，20 对

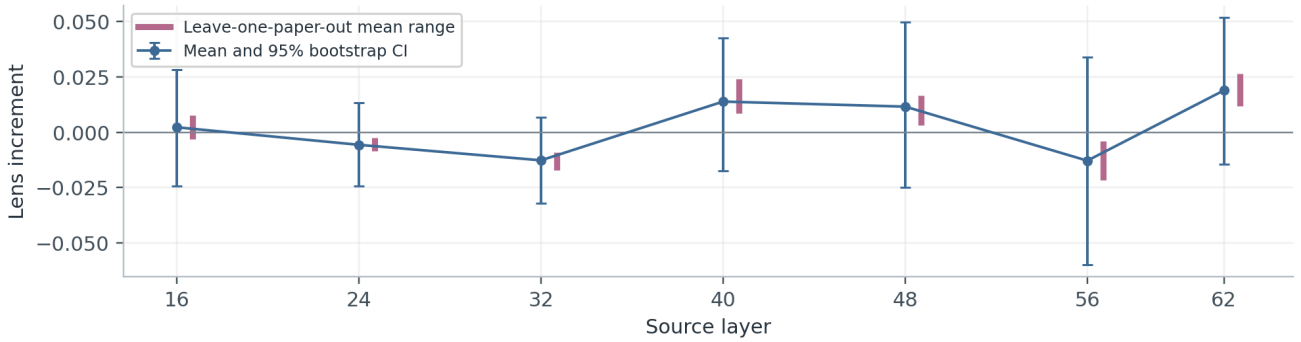


图 7.6 J-Lens 减 Vanilla 的逐层标题优势；粉色为留一法均值范围

留一法均值范围 −0.000046 到 +0.003494：去掉一篇论文就可能翻转符号。

Stage 7 总结

所有发现都是探索性的：L56 和 Pilot50 在早期阶段被反复查看；论文-配对 bootstrap 未校正共享作者、候选池和替代标题来源之间的依赖。证据支持做独立目标论文检验和拟合可靠性检验，但不支持把高 JMRR 或某层峰值解释为存储的事实知识。

Stage 8 A 这篇论文? 独立验证：200 篇新论文

动机：Pilot50 L56 合并标题优势 +9.34 pp，但匹配 A–B 不确定，且来自反复探索。Stage 8 在评分前冻结新论文和全部对照。

问题	冻结比较	单位
RQ1	L56 J-Lens：真标题 − 20 个错误标题平均	200 篇
RQ2	L56 优势(A) − 优势(B)	100 对
RQ3	L56 低引用 − 高引用	匹配引用层
对照	L56 J-Lens − Vanilla	200 篇

8A 队列冻结

从 6,841 篇中排除 Pilot50，在完全相同的领域和引用档内匹配 A/B（配对代价 10|Δ年份| + 3|Δ作者数|）。选取**不是随机抽样**：所有候选对按（代价，sha256 哈希）排序，在低 / 中 / 高三段内按配额依次选取（贪心，确定性顺序，种子 3518001 只用于哈希）。100 对 = 200 篇：低引用（0–2）25 对、中（3–128）50 对、高（129+）25 对。脚本 ~/351_stage8.py（SHA-256 5dce8e48…），日志 STAGE8 FREEZE SUCCESS 与 STAGE 8 VERIFIED。

协议变更（待确认）

> 哈希锁定的分析计划（analysis_plan.json，2026-10-18 14:29）规定：主终点是 7 层积分的论文级标题优势和积分 A–B，L56 是"探索性的次终点"，7 个单层比较做 Holm 校正，逐对剔除列为敏感性分析。当天 21:14 的 PROTOCOL.md 改成以 L56 为主终点；这份文件是从聊天窗口粘贴生成的，改动由谁、依据什么做出，尚待确认。两种终点的结果都在下方并列报告。

8B 候选与错误标题

每篇：第一作者金标准 + 50 个匹配错误作者 + 50 个"随机池"错误作者 + 20 个匹配错误标题。"随机池"并不是随机抽样，而是把非匹配的候选按 sha256 哈希排序后取前 50 个（确定性顺序）。共 20,200 条候选记录、4,000 条错误标题记录。

评分前检查	结果
匹配错误作者 tier 0	9,905 / 10,000（99.05%）
错误标题同领域同档	4,000 / 4,000（100%）
金标准–错误作者首 token 相同	673
错误标题来源作者在错误池中	760 / 4,000（19.0%）
标题 token 长度差	均值 7.37，中位数 5，最大 57
错误标题年份差	均值 2.33，中位数 2，最大 20

8C GPU 评分

7 个 J-Lens + 7 个 Vanilla + 真实 L63 = 15 种模式；每篇 21 个上下文使用同一组首 token 候选 ID，不打后续 token。4,200/4,200 个上下文、63,000 个上下文-模式组合全部完成。

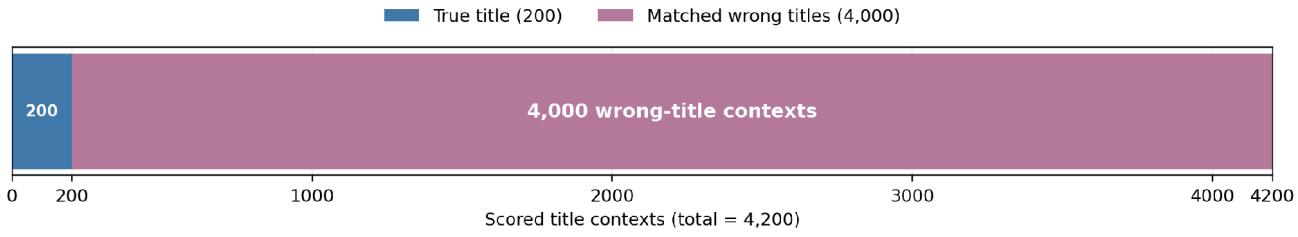


图 8.1 4,200 个冻结标题上下文的构成（上下文不等于独立论文）

8D 主要结果

10,000 次 bootstrap，种子 3518401；单位为百分点。

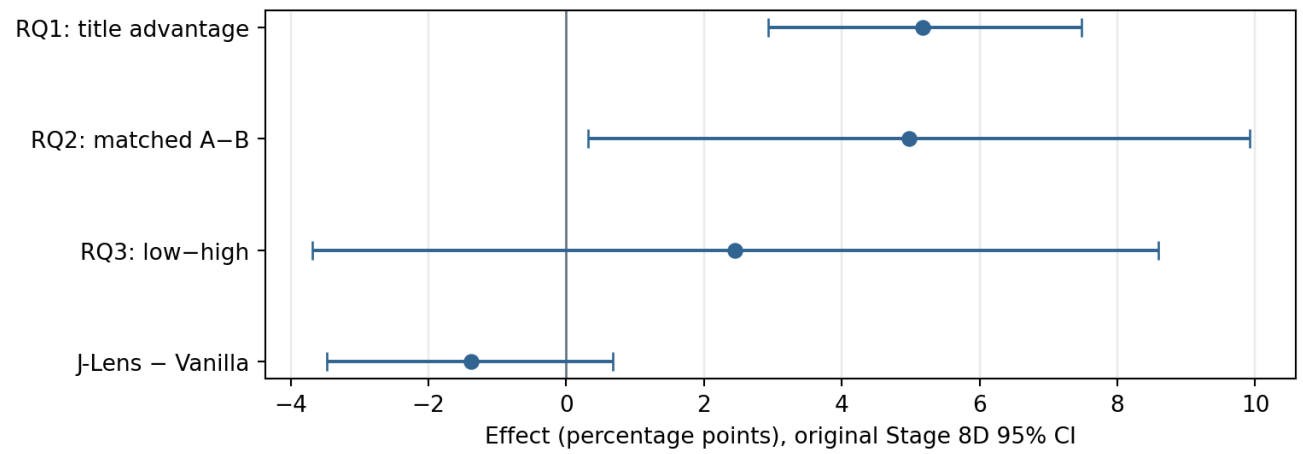


图 8.2 Stage 8D 冻结估计与 95% CI

指标	估计	95% CI	解读
RQ1 L56 标题优势	+5.18 pp	[+2.93, +7.48]	200 篇上为正
RQ2 匹配 A−B	+4.98 pp	[+0.32, +9.91]	均值为正，下界接近 0
RQ3 低 − 高引用	+2.45 pp	[−3.69, +8.60]	不确定
J-Lens − Vanilla	−1.38 pp	[−3.48, +0.68]	没有 J-Lens 优势

引用段	论文数	L56 优势	95% CI
低	50	+6.83 pp	[+2.55, +11.59]
中	100	+4.75 pp	[+1.94, +7.66]
高	50	+4.38 pp	[−1.07, +9.99]

RQ2 的分布与影响

100 对中 55 正 45 负，中位数 +4.41 pp；最有影响的一对 S8P094 约 +84.4 pp。

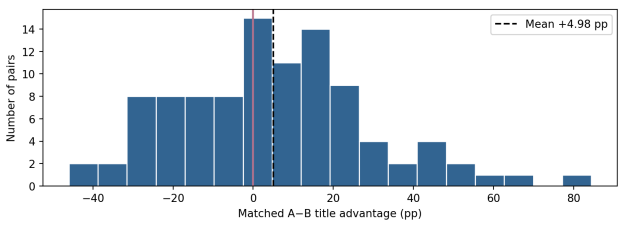


图 8.3 100 对的 L56 A−B 差

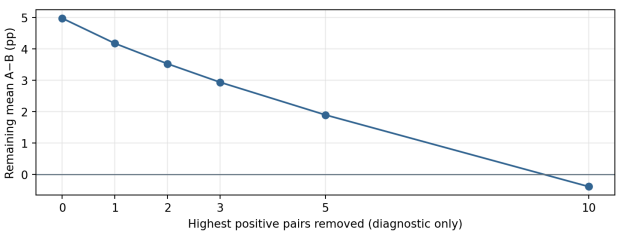


图 8.4 去掉最大正向对后的剩余均值（事后诊断）

去掉最大正向对数	剩余 A−B 均值
0	+4.98
1	+4.18
2	+3.53

去掉最大正向对数	剩余 A–B 均值
3	+2.94
5	+1.90
10	−0.39

敏感性（200 篇合并）：去平局 +5.32 pp，去来源重叠 +5.15 pp，短标题 +4.82 pp。配对重算（配对 bootstrap 10,000 次；原区间无出处文件，2026-10-30 重算）：去平局 +5.03 [+0.23, +9.95]，去来源重叠 +4.53 [−0.15, +9.53]，标题差 ≤10 +4.79 [−0.24, +9.83]（99 对）。

8E 事后审计（2026-10-30 已在 Explorer 上从原始 logits 重算）

原 8E 脚本没有找到。下表是从原始 logits 和冻结的候选首 token 完整重算的值：点估计与原表逐位一致，区间差异在 bootstrap 抽样误差之内。（重算脚本与结果：~/jlens_work/08_stage8/recompute_2026-10-30/、351_stage8/recompute_2026-10-30/，2026-10-30）

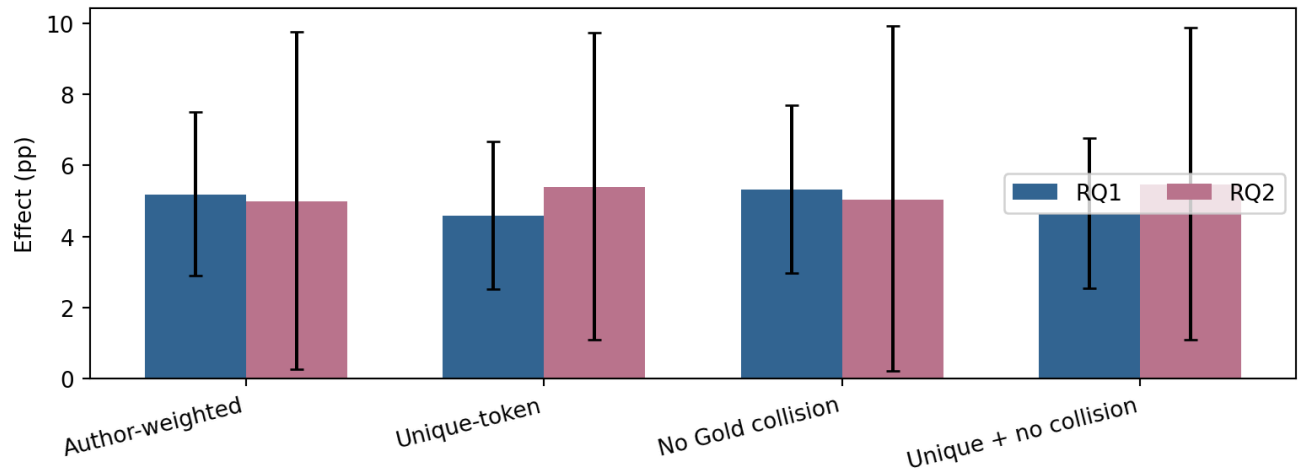


图 8.5 四种 token 终点下的 RQ1 / RQ2

终点	RQ1 [95% CI]	RQ2 [95% CI]
冻结的作者加权	+5.18 [2.91, 7.44]	+4.98 [0.34, 9.81]
唯一 token	+4.58 [2.52, 6.68]	+5.40 [1.19, 9.70]
去金标准平局	+5.32 [3.07, 7.72]	+5.03 [0.27, 9.98]
唯一 token + 去平局	+4.64 [2.53, 6.73]	+5.46 [1.19, 9.84]

错误标题与真标题的 token 长度差：论文固定效应斜率 +0.12 pp/token [+0.015, +0.240]（论文聚类 bootstrap 10,000 次，种子 20261132，2026-10-30 重算），只是关联，可能代表措辞、主题等其他差异。

> **Stage 8 结论**

按哈希锁定的冻结计划：主终点 7 层积分标题优势 +2.33 pp [+1.50, +3.19]，主组检验积分 A−B +2.41 pp [+0.91, +4.00]（bootstrap 双侧 p = 0.002）。逐对剔除 100 次后，积分 A−B 在 +2.14 到 +2.61 之间，区间全部不含 0；L56 A−B 在 +4.18 到 +5.50 之间、不变号，但 14 / 100 次的区间跨 0。计划规定的 7 个单层 A−B 经 Holm 校正后只有 L62 显著（p_Holm = 0.029），L48、L56 不再显著（0.17、0.19）。p 值公式和检验族的划分计划没有写明，按 bootstrap 双侧 p 计算，详见方法手册。（重算脚本与结果：~/jlens_work/08_stage8/recompute_2026-10-30/、351_stage8/recompute_2026-10-30/，2026-10-30）
RQ1：正确标题提升金标准作者首 token 判别，在 200 篇新论文上复现，换加权方式仍为正。RQ2：A 组优势在去重后仍为正，但对少数正向对高度敏感，稳健性未确立。RQ3：低引用段内为正，低−高差异不确定。L56 J-Lens 不优于 Vanilla。这些都不是完整作者名或自发回忆的证据。

Stage 9 B 读出工具 FullFit：lens 是否依赖拟合数据

项目	历史 split-half（3.5.1）	Stage 9 FullFit
训练集	Self-100 拆成 50 + 50	两套不重叠的 100 + 100
Holdout	20 通用 + 20 论文	独立 100 条 WikiText
源层	6 层	7 层（加 L16）
目的	检查现有 Self lens 的可重复性	在拟合和测试数据都独立时检验稳定性与泛化
档案中的状态	A/B 拟合与读出比较完成	Fit A 4/100，Fit B 0/100，holdout 未评估；后续只完成 Fit A（100 条），Fit B 与 holdout 未做

数据准备

Salesforce/wikitext，wikitext-103-raw-v1，train。规范化空白，去掉章节标题行和 100–1,200 字符以外的段落，按规范化文本 SHA-256 去重，按哈希排序后用种子 3519001 打乱，冻结互不重叠的 Fit A100、Fit B100、Holdout100。哈希不重叠不保证来源文档独立，也不能证明与 Public-557 的拟合文本不重叠。

拟合配置

参数	取值
模型	Qwen3-32B，固定 revision，BF16
源层 / 目标	L16/24/32/40/48/56/62 → L63
dim_batch / max_seq_len / skip_first	1 / 128 / 16
有效位置	16 … seq_len−2，n_valid = seq_len − 17

参数	取值
检查点	每条提示保存一次；device_map=auto
累加器	逐提示有效位置 Jacobian，提示等权累加 / n_done，FP32（7 个矩阵约 700 MiB）
完成标准	n_done = next_idx = 100；7 个矩阵有限；层集合、配置、哈希一致；保存的 lens 重新加载后与检查点均值比较（相对误差 ≤0.01）

运行时间与进度

单条提示 7 层基准：Jacobian 320 s，总时间 350.72 s，CPU 内存峰值约 62.06 GiB。正式 Fit A 第一批 4 条平均 323.75 s/条，max_d_mean 0.674 → 0.578 → 0.474（下降但不能说明收敛）。剩余 96 条线性外推约 8.6 计算小时，不含排队。

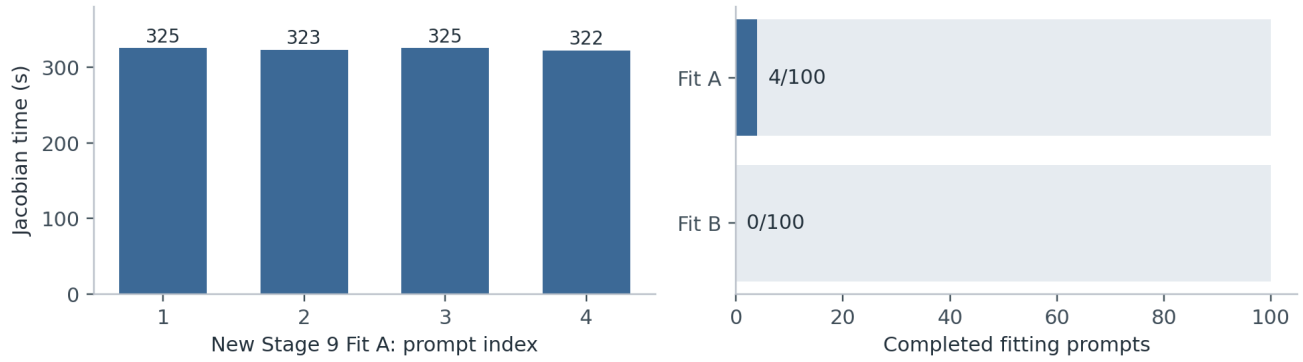


图 9.1 档案记录时的正式 Fit A 进度

最终状态

Stage 9 只完成了 Fit A，即 Stage 10 中的 fitA lens。Fit B 没有拟合，holdout 上的 A/B 稳定性比较也没有做，因此不能声称“lens 结果不依赖拟合样本”。Stage 10 中三种 Jacobian lens 结论一致，只是间接的支持。

综合：四条线各走到了哪里

线	已支持	未确立
A 这篇论文?	真标题优于错误标题：Pilot50 L56 +9.3 pp；200 篇新论文 +5.2 pp	A 组受益多于 B 组（Pilot 区间跨 0；Stage 8 依赖少数对）
B 读出工具	两个 lens 可用、通过数值检查、估计公式一致	J-Lens 相对 Vanilla 的优势（7.4、8 均无）；拟合稳定性（Stage 9 只拟合了 Fit A）
C 哪一层	信号集中在后层，L56 在 7.2、7.3、8 中突出	知识在哪一层形成；L56 是反复查看后选定的
D 哪个 token	A–B 差异在后续 token 上	原因：首字母、姓，还是 teacher forcing?

这一阶段的证据大多基于第一作者、第一个 token、20–200 篇论文。下一步需要全部作者、全部 token、全部论文，这就是 Stage 10。

待核实事项

1. Stage 9：Fit B 未拟合，holdout 稳定性比较未做；如需检验 lens 稳定性，需补做，且打分位置、token 范围、bootstrap 方案和接受标准应在评估前冻结。
2. Stage 8A：主终点从 7 层积分改为 L56 的日期和确认记录。
3. Stage 8：RQ1–RQ3 的多重比较校正。
4. Stage 8E：外部审计脚本、种子、逐篇/逐对 CSV 和回归 bootstrap 结果需要集中归档。
5. Public-557：拟合文本与模型版本无法恢复，独立性无法确立。
6. 名字先验的进一步控制：姓首 token、首字母、标点分类分析，中性标题，提示改写（Stage 10–11 已部分完成）。
7. 依赖结构：共享作者、候选池、替代标题来源之间的依赖尚未用聚类或依赖感知的方法处理。

附录

A. Bootstrap 设置

Stage	次数 / 重抽单位	种子约定
5	2,000；论文或匹配对	35150 起，按层与模式偏移
6	2,000；论文或匹配对	35161 / 35162 起
7.1	10,000；匹配对	35171 起
7.2	10,000；匹配对	351720 + n_pairs + len(mode) + len(pool)
7.3	10,000；匹配对	35173
7.4	20,000；论文或匹配对	741
8D	10,000	3518401

除 Stage 5 用排序后的顺序统计量外，均取 2.5% / 97.5% 百分位。所有区间为名义值，未校正多重比较；token、作者和层都不是独立的重抽单位。

B. 固定标识

对象	SHA-256 / 版本
Qwen3-32B revision	9216db5781bf21249d130ec9da846c4624c16137

对象	SHA-256 / 版本
Public-557 lens	0af5ccf2e1c251bedc202607a7ca214f3b9f60980bab73d67a3d0b887db213d8
Self-100 lens（历史）	268aba15f3377fff4dfa553cc67b782c23148f0aa7a7b7de3c34b6534d8d40e3
1,000 条 WikiText 语料（历史）	1af8dbff1b6e5b9f5bdd55b31d2d7bfadf28c8ab256a47e69d45db6b5ebc0b06
Stage 9 拆分 manifest	951f5ad361dd543f96267a08e3783dadfa70fc1f69d3182191a6902aac3e850c
Stage 9 Fit A 4/100 检查点	e08080cf52f74123ccb5b478bc6d0c105992d18faa881c437b1cf1856e95793d
Stage 8A manifest	7e4b878e9ee037fe822cc42821218459ff48b203cd026de6995a79ca13486f55
Stage 8B manifest	b3c8c5a7e98523c668408884a8e91bac0dba5bcccc560b05a0a94b90133a5309

C. 代码与结果文件

Stage	代码 / 结果
1	351_prepare_all.py；Section_3_5_1_Research_Handoff_2026-10-17.md；zhiqi_qwen3-32b_labels_2026-10-15.zip
3	351_self100_validation_results.tar.gz；351_provenance_audit_results.tar.gz；351_jlens_fitting_diff.txt；Validation_Record_351_Completeness_Checked.docx
5	351_stage5_crossed_v2.zip；351_stage5.py；full_6841_manifest.csv；pilot50_v1.csv；pilot50_ab_pairs.csv
6	351_stage6.tar.gz；351_stage6.py；raw/token_layer_scores.csv
7.1	351_stage7_1_results.zip；summary/layer_and_integrated_effects.csv
7.2	351_stage7_2_full.tar.gz；351_stage7_2_score.py；candidate_audit.md；matched_ab_bootstrap.csv
7.3	351_stage7_3_full.tar.gz；pilot50_shuffled_titles.csv；shuffled_firsttoken_scores.jsonl
7.4	351_stage7_4_results.zip；351_stage7_4.py；cross_stage_correlations.csv；jlens_increment_bootstrap.csv
8	~/351_stage8.py；scripts/351_stage8B.py、351_stage8C.py、351_stage8D.py；raw/stage8C_context_scores.jsonl；stage8D/summary/*.csv
9	351_stage9.py；351_stage9_README.md；stage9_fullfit.py；终端记录 20261018-195325

第二部分

Stage 10–11：全量阶段

原 Stage 10–11 双语报告全文（2026-10-27）。6.12 节标签改为 Stage 11，与 PPT 一致。

§1 摘要 *Summary*

本实验用 9,108 篇论文，逐层读出 Qwen3-32B 内部对作者名字的预测，看模型在哪一层开始"拿着"某篇论文的作者。我们比较了两组论文：一组是模型写不全作者（R0/R1：一个都没写对，或只写对少数）、但在多选题里能认出正确作者名单的"目标组"（target），另一组是既写不全出也认不出的"对照组"（control）。为了区分"认识这篇论文"和"名字本身好猜"，每篇论文还换成 5 个匹配好的假标题和删掉标题再测一遍。

> Using 9,108 papers, we read out Qwen3-32B's internal predictions of author-name tokens layer by layer to find where the model starts to hold a specific paper's authors. We compare a target group (the model cannot write the author list, R0/R1: none or only a few right, but recognises the true author list in a multiple-choice test) with a control group (neither writes nor recognises them). To separate knowing the paper from names that are simply easy to guess, every paper is also scored with 5 matched false titles and with the title deleted.

主要结论：针对具体论文的作者信息只在最后几层才读得出来。L24 到 L48 层，真标题相对假标题的优势（下称"标题特异信号"）几乎为 0；从 L50 前后开始逐层积累，L57–L61 上升最快，L61–L62 和最终输出最强。目标组比对照组多出的部分也集中在 L62/L63（在引用数分档内比较，**+0.21 到 +0.23**，95% 置信区间都在 0 以上），而且几乎全部是标题特异的，不能用名字好猜来解释。在名字位置用 lens 读，中间层没有看到"提前拿着作者"的迹象（标题位置的 probe 结果见下一段和 §6.11）。

> Main result: paper-specific author information becomes readable only in the last layers. From L24 to L48 the advantage of the true title over false titles (the title-specific signal) is close to zero; it builds up layer by layer from about L50, rises fastest over L57–L61, and is strongest at L61–L62 and the model output. The extra signal of the target group over the control group is likewise concentrated at L62/L63 (within citation bins, **+0.21 to +0.23**, all 95% CIs above zero) and is almost entirely title-specific, so it is not explained by easy-to-guess names. Read with a lens at the name positions, there is no sign of the authors being held earlier in the middle layers (for the probe at the title position see the next paragraphs and §6.11).

补充分析（不需要新的 GPU 计算）进一步表明：标题特异信号在名字里的位置取决于名字格式，首字母开头时几乎都在后续 token（含姓）上（目标−对照 +0.253，首字母本身 +0.048），完整名开头时名和后续 token 各带一份相当的信号（+0.174 与 +0.202）；引用数越高，标题特异信号越强（Spearman ρ = 0.45）；三种 Jacobian lens 在中间层只比 logit lens 多读出很少的论文信息（+0.01 到 +0.03），而且这部分信息不偏向目标组。

> Follow-up analyses (no new GPU runs) show further that where the title-specific signal sits within a name depends on its format: for initial-first names it is almost all on the later tokens, which include the surname (target − control +0.253 versus +0.048 on the initial), while for given-name-first names the given name and the later tokens carry comparable shares (+0.174 and +0.202); that it grows with citation count (Spearman ρ = 0.45); and that the three Jacobian lenses read only slightly more paper information than the logit lens in middle layers (+0.01 to +0.03), information that does not favour the target group.

干预实验（Stage 11，§6.11）进一步确定了时间：把真标题运行中"标题之后的 token"的表示替换进假标题运行，L48 已恢复 83%，L52 起恢复 100%；从 L52 起屏蔽对标题的注意力已没有影响。也就是说，论文信息从 L24 起在标题位置逐渐形成，在 L44–L52 汇集到名字位置（只换名字位置 L52 恢复 0.85，只换标题之后的单个 token 最多 0.17）；L52 之后不再需要标题（control 组到 L54–56），这一时间对 5 个假标题都成立。只是要到 L56–62 才变成 lens 能读出的形式。标题最后一个 token 上，线性 probe 从 L24 起就能读出少量这篇论文特有的作者信息（+0.05 到 +0.08），目标组更高（+0.04 到 +0.08） 已复核 （已按作者团队分折、并剔除 probe 训练时见过同一标题的论文后复核，见第四部分）。一句话概括：**读得早，说得晚**。

> Interventions (Stage 11, §6.11) fix the timing: copying the hidden states of the tokens after the title from the true-title run into the false-title run recovers 83% at L48 and 100% from L52, and blocking attention to the title from L52 on has no effect. The paper information forms gradually at the title position from L24 on and is gathered at the name positions in L44–L52 (name positions alone recover 0.85 at L52; any single post-title token at most 0.17); the title is no longer needed after L52 (L54–56 for control), the same for all 5 false titles. It only becomes lens-readable in L56–62. At the last title token a linear probe already reads a small amount of paper-specific author information from L24 on (+0.05 to +0.08), more for target papers (target − control +0.04 to +0.08; re-checked with team folds and title reuse removed). In one line: **read early, spoken late**.

§2 研究问题 *Question*

此前的标注实验发现，Qwen3-32B 对大约一半的论文"写不全作者、但认得出作者名单"。本阶段要回答的是：这种"认得"在网络内部是什么时候形成的？如果模型在中间层就已经把作者信息算出来、只是没能输出，那么用 lens 读中间层时，目标组应该比对照组更容易读出正确的名字；如果信息只在最后几层才组装出来，差异就只会出现在输出附近。

> An earlier labelling run found that for roughly half of the papers Qwen3-32B cannot write the author list yet recognises the true author list. This stage asks when that recognition forms inside the network. If the model already computes the author information in middle layers and only fails to emit it, a lens applied to those layers should read the correct name more easily for target papers than for control papers. If the information is assembled only in the last layers, the difference should appear only near the output.

§3 数据 *Data*

论文集合来自 2026-10-15 的 Qwen3-32B 标注包（`paper_labels_with_papers.csv`），共 9,108 篇，覆盖 8 个领域（医学 1,230、生物 1,179、计算机 1,174、心理学 1,154、化学 1,134、数学 1,088、物理 1,082、材料 1,067）。发表年份 1817–2020（中位数 2006），引用数 0–63,901（中位数 50.5），按引用数分成 13 档（0-2, 3-4, 5-8 ⋯ 2049-4096, 4097+）。每篇论文平均 3.7 位作者（1–20 位）。

> The paper set is the 2026-10-15 Qwen3-32B label package (`paper_labels_with_papers.csv`): 9,108 papers across 8 fields (medicine 1,230, biology 1,179, computer science 1,174, psychology 1,154, chemistry 1,134, mathematics 1,088, physics 1,082, materials science 1,067). Publication years span 1817–2020 (median 2006), citations 0–63,901 (median 50.5), grouped into 13 citation bins (0-2, 3-4, 5-8 ... 2049-4096, 4097+). Papers have 3.7 authors on average (1–20).

3.1 论文从哪来 *Where the papers come from*

论文集合沿用 *Dreaming Up Authors* 研究构建的评测集，我们没有重新抽样。原研究从 Microsoft Open Academic Graph（OAG v2）中随机抽取 9,999,863 条记录，用 Semantic Scholar API 补全引用数、规范化的作者名和领域（截至 2025 年 9 月），再做质量过滤：只保留期刊和会议论文；去掉没有作者或作者超过 20 位的记录（保留 1–20 位；代码中 MAX_AUTHORS = 20，只去掉 > 20 位；此前写成“≥ 20”有误，2026-10-30 据 Dreaming Up Authors 代码包核对）；只留 FastText 判为英文且置信度 ≥ 0.8 的论文；去掉机构名、单 token 名字和格式错误的作者；要求 OAG 和 Semantic Scholar 的标题与第一作者姓一致。过滤后剩 1,921,209 篇（约 19.2%）。

> The paper set is the evaluation set built by the *Dreaming Up Authors* study; we did not resample it. That study drew 9,999,863 random records from the Microsoft Open Academic Graph (OAG v2), added citation counts, canonical author names and fields from the Semantic Scholar API (as of September 2025), and filtered them: journal and conference papers only; no records with zero or more than 20 authors (1–20 kept; MAX_AUTHORS = 20 drops only > 20; the earlier "≥ 20" was wrong, checked against the Dreaming Up Authors code package on 2026-10-30); English only (FastText confidence ≥ 0.8); institutional, single-token and malformed author names removed; OAG and Semantic Scholar must agree on the title and the first author's surname. 1,921,209 papers (about 19.2%) remained.

8 个领域是在初始集合中随机抽 100,000 篇、按出现频率选出的，合计约占整理后数据的 76.95%。引用数分成 13 个指数间隔的档，每个"领域 × 引用档"最多抽 100 篇，理论上限 10,400 篇；部分高引用档不足 100 篇，最终 9,108 篇。

> The 8 fields were chosen by their frequency in a random sample of 100,000 papers from the initial collection; together they cover about 76.95% of the curated data. Citations were split into 13 exponentially spaced bins and up to 100 papers were drawn per field × bin stratum (at most 10,400); some high-citation strata had fewer than 100 eligible papers, giving 9,108.

3.2 分组是怎么定的 *How the groups are defined*

分组沿用标注包的 `group_tight`：先让模型开放回答"这篇论文的作者是谁"，再给 4 个候选作者名单（真名单 + 同领域、相近年份和引用档的 3 个真实团队）按 4 种顺序做多选。能写出作者的是 guard（R2）；写不全（R0/R1）、但 4 次全对且真选项平均概率 ≥ 0.5 的是 target；写不全且最多对 1 次的是 control；其余为 excluded。

> Groups follow the package's `group_tight` label. The model first answers openly "who wrote this paper", then picks among 4 candidate author lists (the true list plus 3 real teams from papers of the same field, similar year and citation bin) in 4 orders. Papers whose authors it can write are guard (R2); papers it cannot fully write (R0/R1) but gets right in all 4 orders with mean true-option probability ≥ 0.5 are target; papers it cannot fully write and gets right at most once are control; the rest are excluded.

操作细节。标注由组长的标注流程在同一个 Qwen3-32B（本地 bf16 权重、A100-80GB）上生成，我们直接使用，没有改动。

① 开放回答：系统提示 `You are a knowledgeable assistant. Answer factually and concisely. When asked for authors, return a semicolon separated list of full names only, with no additional text.`，用户问题 `Who are the authors of the paper titled '{title}' which was published in {year}? Return a semicolon separated list of author names only.`，套模型的对话模板，**贪心解码**。生成长度上限和是否关闭 thinking 模式记录在标注运行的 `run.json` 里，标注包没有附带，待向组长确认。

② R0/R1/R2 由**确定性规则**判定，不经人工或模型：用模糊姓名匹配（考虑姓、名的首字母、顺序、缩写和特殊字符）数出匹配 M、编造 H、遗漏 U，算 HR2 = (H+U)/(M+H+U)。HR2 ⩽ 0.5 为 R2（基本写对）；HR2 > 0.5 时，M = 0 为 R0，M > 0 为 R1。所以 HR2 > 0.5 并不代表一个作者都没写对。
③ 多选题：3 个干扰项是另外 3 篇论文的真实作者团队，要求同领域、团队人数相近、同引用档、年份相近；带两道示例题的提示词，要求只答一个字母。4 种顺序（ABDC、BCAD、CDBA、DACB）各问一次，每次在答案位置取下一个 token 的分布，"A"与" A"的概率相加得到每个字母的概率，**不做重新归一化**（4 个字母概率之和平均为 1.00，没有一次低于 0.5）。"真选项平均概率"= 真选项字母概率在 4 种顺序上的平均。
④ 标注包自带的检查：214 篇 R2 论文 98.1% 通过多选；另抽 500 篇换一批干扰项重测，通过与否的一致率 83.6%（kappa 0.63）。

> **Operational details.** The labels were produced by the group lead's labelling pipeline on the same Qwen3-32B (local bf16 weights, A100-80GB); we use them unchanged.
> (1) Open answer: system prompt `You are a knowledgeable assistant. …return a semicolon separated list of full names only…`, user question `Who are the authors of the paper titled '{title}' which was published in {year}? Return a semicolon separated list of author names only.`, inside the chat template, **greedy decoding**. The maximum generation length and the thinking-mode setting are recorded in the labelling run's `run.json`, which is not in the package; to be confirmed with the group lead.
> (2) R0/R1/R2 come from a **deterministic rule**, not a human or a model: fuzzy name matching (surname, initials, order, abbreviations, special characters) counts matched M, hallucinated H and unretrieved U, and HR2 = (H+U)/(M+H+U). HR2 ≤ 0.5 is R2 (mostly right); with HR2 > 0.5, M = 0 is R0 and M > 0 is R1. So HR2 > 0.5 does not mean no author was right.
> (3) Multiple choice: the 3 distractors are the real author teams of 3 other papers of the same field, similar team size, the same citation bin and a similar year; a prompt with two worked examples asks for a single letter. Each of 4 orders (ABDC, BCAD, CDBA, DACB) is asked once; at the answer position the next-token probabilities of "A" and " A" (etc.) are summed per letter, **without renormalisation** (the four letters sum to 1.00 on average and never below 0.5). "Mean true-option probability" = the true letter's probability averaged over the 4 orders.
> (4) Package checks: 98.1% of the 214 R2 papers pass the multiple choice; on 500 papers re-asked with a second draw of distractors the pass label agrees 83.6% of the time (kappa 0.63).

与 Stage 4–8 的关系：那几个阶段用的是 A/B/C/D 四组（A = 认出・R0 4,110；B = 未认出・R0 2,186；C = 认出・R1 511；D = 未认出・R1 34）。从 Stage 10 起改用 `group_tight`：target/control 把 R0 和 R1 合在一起，并使用收紧的通过规则。

> Relation to Stages 4–8: those stages used groups A/B/C/D (A = recognised·R0 4,110; B = not recognised·R0 2,186; C = recognised·R1 511; D = not recognised·R1 34). From Stage 10 on we use `group_tight`: target/control pool R0 and R1 and use the tightened pass rule.

R0/R1 分层（第三部分）。两组都只保留 R0（即 A vs B）时，输出处标题特异的目标−对照差为 +0.199 [0.187, 0.212]（合并口径 +0.207），各层形状不变；R1 目标论文（C）比 R0（A）多 +0.11，同样只在最后几层；R1 论文内部，模型写对的作者比没写对的高 +0.20，也只在 L54 之后出现。详见第三部分

> R0/R1 split (Part III): with R0 papers only (A vs B) the output title-specific target − control gap is +0.199 [0.187, 0.212] (pooled +0.207) with the same layer profile; R1 targets (C) exceed R0 targets (A) by +0.11, also only in the last layers; inside R1 papers the authors the model wrote correctly exceed the missed ones by +0.20, again only after L54.

组 Group	论文数 Papers	定义 Definitio
target 目标组	4,621	写不全（R0/R1）· 4/4 认出 / cannot write the list (R0/R1) · recognises 4/4
control 对照组	2,220	写不全（R0/R1）· 认不出 (≤1/4) / cannot write the list (R0/R1) · does not recognis
guard 能写出	214	开放回答基本正确 (R2) / writes the authors
excluded 排除	2,053	介于两者之间 / in between

3.3 打分单元 *Scoring units*

每位作者单独作为一个打分单元，共 33,811 个作者上下文、149,999 个名字 token。每个 token 标了角色：姓的第一个 token 33,810 个、姓的后续 token 39,995 个、首字母 28,382 个、标点 28,701 个、名的第一个 token 9,431 个、名的后续 token 9,357 个、姓氏前缀 323 个。

> Each author is scored as a separate unit: 33,811 author contexts and 149,999 name tokens. Every token carries a role: surname-first 33,810, surname-continuation 39,995, initial 28,382, punctuation 28,701, given-name-first 9,431, given-name-continuation 9,357, particle 323.

§4 方法 *Method*

4.1 输入与打分 *Input and scoring*

模型为 Qwen/Qwen3-32B（revision `9216db57`），bf16，单张 A100-80GB。提示词为 `Who are the authors of the paper titled "{title}" ({year})?\nAuthors:`，后面接一位作者的名字。用教师强制（teacher forcing）：在每个名字 token 之前的位置，看模型给正确 token 排第几名。

> The model is Qwen/Qwen3-32B (revision `9216db57`) in bf16 on one A100-80GB. The prompt is `Who are the authors of the paper titled "{title}" ({year})?\nAuthors:` followed by one author's name. With teacher forcing, at the position before each name token we record the rank of the correct token.

主指标是 log10(1/名次)：排第 1 为 0，排第 10 为 −1，词表最差约 −5.18。每篇论文对所有名字 token 取平均，再在组内对论文平均；组间比较只用平均值，不用总和（各组作者数不同）。

> The main metric is log10(1/rank): rank 1 gives 0, rank 10 gives −1, the worst possible is about −5.18. It is averaged over a paper's name tokens and then over papers within a group; groups are compared by means only, never sums, because author counts differ between groups.

4.2 读出方式与层 *Readouts and layers*

在第 24、32、40、48、56、62 层的残差流上用 4 种方式读出，另加模型真实输出（L63）：

> The residual stream at layers 24, 32, 40, 48, 56 and 62 is read out in four ways, plus the model's actual output (L63):

- **logit lens**：直接接最终归一化和输出层。
  final norm + unembedding applied directly.
- **jlens_public**：公开的 Jacobian lens（Neuronpedia；Salesforce/wikitext-103-raw-v1 训练集 557 条提示词，max_seq_len 128，覆盖全部层）。

public Jacobian lens from Neuronpedia (557 prompts of the Salesforce/wikitext-103-raw-v1 train split, max_seq_len 128, all layers).

- **jlens_self100**：自己拟合的 Jacobian lens：冻结的 WikiText-103 语料 `fitting_corpus/wikitext103_qwen32b_1000.jsonl` 的第 0–99 条；源层 L24/32/40/48/56/62，目标层 L63；max_seq_len 128，skip_first 16，dim_batch 8。
  our own Jacobian lens: items 0–99 of the frozen WikiText-103 corpus `fitting_corpus/wikitext103_qwen32b_1000.jsonl`; source layers L24/32/40/48/56/62, target L63; max_seq_len 128, skip_first 16, dim_batch 8.
- **jlens_fitA**：Stage 9 的 Fit A lens：WikiText-103 训练集冻结切分为 Fit A / Fit B / 留出各 100 条（规范化后 sha256 去重，彼此不重叠，不含任何实验论文）；源层 L16/24/32/40/48/56/62，目标层 L63；max_seq_len 128，skip_first 16，dim_batch 1，每条存一次检查点。
  the Stage 9 Fit A lens: a frozen split of the WikiText-103 train set into Fit A / Fit B / holdout of 100 prompts each (sha256-deduplicated after normalisation, disjoint, no experimental papers); source layers L16/24/32/40/48/56/62, target L63; max_seq_len 128, skip_first 16, dim_batch 1, a checkpoint after every prompt.
- **final**：模型真实下一个 token 的输出（L63）。
  the model's real next-token output (L63).

Jacobian lens 先把第 l 层的残差用该层的 Jacobian 矩阵变换到最后一层的空间，再接输出层，比 logit lens 更能读出中间层的信息。

> A Jacobian lens first transports the layer-l residual into the last layer's space with that layer's Jacobian matrix and then applies the unembedding, which reads middle-layer information better than the logit lens.

拟合怎么做。拟合不改动模型参数：对每条通用文本提示词，在 skip_first 之后的每个位置计算源层到 L63 的 Jacobian，在所有成功处理的提示词上取平均，得到每层一个 5120×5120 的变换矩阵。**Stage 9 的"修复"是什么：**原始 Fit A 运行中，`jlens.fit` 跳过了 100 条冻结提示词中的 1 条（检查点记录 next_idx 比 n_done 多 1），只有 99 条有效。修复脚本 `stage9_a_repair.py` 保留原检查点和原 100 条，只追加 1 条经核验、恰好 128 token 的 WikiText-103 替补，最终 101 条候选中 100 条有效（状态 `VERIFIED_100_VALID_OF_101_CANDIDATES`），并加了层配置、检查点兼容性、有效条数、矩阵形状、存取一致性等校验。它修的是"有效提示词不足 100 条"，没有改动 Jacobian 的估计方法，也不说明原估计有数值错误。Fit B 只完成了 66/100，未使用。

> **How the fit works.** Fitting does not change any model parameter: for each generic-text prompt the Jacobian from the source layer to L63 is computed at every position after skip_first and averaged over all successfully processed prompts, giving one 5120×5120 map per layer. **What the Stage 9 "repair" was:** in the original Fit A run, `jlens.fit` skipped 1 of the 100 frozen prompts (the checkpoint's next_idx was one ahead of n_done), leaving 99 valid. The repair script `stage9_a_repair.py` kept the original checkpoint and the original 100 prompts and appended exactly one vetted 128-token WikiText-103 replacement, giving 100 valid of 101 candidates (status `VERIFIED_100_VALID_OF_101_CANDIDATES`), plus checks of the layer set, checkpoint compatibility, valid-prompt count, matrix shapes and save/reload. It fixed the shortfall of valid prompts; it did not change the Jacobian estimator and does not imply a numerical error in it. Fit B reached only 66/100 and is not used.

4.3 标题条件 *Title conditions*

每篇论文测 7 种提示：真标题（true）；5 个假标题（false_0–false_4，借用同领域其他论文的标题，年份保持不变）；删掉标题（delete：`Who are the authors of the paper ({year})?`）。假标题按年份、作者数、标题长度和引用档的差距做最小代价匹配，排除共享姓氏或标题过于相似的论文。匹配分 4 级：strict 35,898 个、medium 1,638 个、loose 2,565 个、nearest 5,439 个。

> Each paper is scored under 7 prompts: the true title; 5 false titles (false_0–false_4, titles of other papers in the same field, year kept); and the title deleted (`Who are the authors of the paper ({year})?`). False titles are matched by minimum-cost assignment on year, author count, title length and citation-bin distance, excluding donors with a shared surname or a too-similar title. Matches fall into 4 tiers: strict 35,898, medium 1,638, loose 2,565, nearest 5,439.

由此得到三种对比（同一组 token，配对比较）：**标题特异** = 真标题 − 5 个假标题的平均，衡量"认识这篇论文"；**总效应** = 真标题 − 删掉标题；**主题效应** = 假标题平均 − 删掉标题，衡量任何相近标题都能带来的帮助。

> This gives three paired contrasts on the same tokens: **title-specific** = true − mean of the 5 false titles, measuring knowledge of this particular paper; **total** = true − deleted; **topic** = mean false − deleted, the help any similar title gives.

4.4 统计 *Statistics*

目标组与对照组只在同一引用档内比较（两组都至少 30 篇的档），按 $n_t \cdot n_c/(n_t+n_c)$ 加权合并，因为引用数和分组高度相关（0-2 档目标组占 25%，4097+ 档占 99%）。置信区间用档内、组内重抽论文的 bootstrap（2,000 次）。敏感性分析去掉 0-4 两个低引用档（这两档的"认出"接近随机偏好的 25%）。

> Target and control are compared only within citation bins (bins with at least 30 papers in both groups), pooled with weights $n_t \cdot n_c/(n_t+n_c)$, because citations and group are strongly confounded (target share 25% in bin 0-2, 99% in 4097+). Confidence intervals come from a bootstrap of papers within bin and group (2,000 draws). A sensitivity analysis drops the two lowest bins 0-4, where recognition is close to the 25% rate of a fixed preference.

§5 计算与质量控制 *Computation and checks*

论文分成 72 个 shard（每个 128 篇）。主轮共 7 个条件 × 72 个 shard × 25 组"读出 × 层"，输出 12,600 个文件，全部完成。计算在 Explorer 集群的 A100-80GB 上进行，主轮实际约 7 GPU 小时，最多 4 张卡并行；每个 shard 约 46 秒。所有输入（论文集合、token 表、提示词、lens 文件）在运行前冻结并做 sha256 校验。

> Papers are split into 72 shards of 128. The main round is 7 conditions × 72 shards × 25 readout-layer pairs, 12,600 output files, all complete. It ran on A100-80GB GPUs of the Explorer cluster, about 7 GPU-hours with up to 4 GPUs in parallel, about 46 s per shard. All inputs (paper set, token table, prompts, lens files) were frozen and sha256-checked before the run.

一致性检查（parity）。快速路径（整段一次前向）和参考路径（每个前缀单独前向）在 12 个样本、52 个位置上比较。两者数学上等价，差异只来自 bf16 累加顺序：最大 $|\Delta\text{logit}|$ 为 0.16–0.37，最大差出现在不经过

lens 的最终输出（0.367），排名前 41 位在所有位置完全一致。原定容差 0.25，看到结果后放宽到 0.5，这是事后调整，已记录在分析计划中。

> **Parity check.** The fast path (one forward pass over the sequence) was compared with a reference (a separate forward pass per prefix) on 12 sampled contexts and 52 positions. The two are mathematically identical; differences come only from bf16 accumulation order. Max |Δlogit| was 0.16–0.37, the largest on the final output, which involves no lens code (0.367), and ranks 1–41 matched exactly at every position. The pre-set tolerance of 0.25 was raised to 0.5 after seeing these results; this post-hoc change is recorded in the analysis plan.

与 Stage 6 交叉核对。972 个重叠 token 的 token id 100% 一致，对数概率差的中位数为 3×10^{-6} 到 7×10^{-5}，排名完全相同的比例为 77–95%，其余差异同样来自 bf16 舍入。

> **Cross-check with Stage 6.** On 972 overlapping tokens the token ids match 100%, the median log-probability difference is 3×10^{-6} to 7×10^{-5}, and 77–95% of ranks are identical; the remaining differences are again bf16 rounding.

§6 结果 *Results*

6.1 逐层读出水平（真标题） *Readout level by layer, true title* Stage 10

所有读出方式都随层数加深而变好。logit lens 在 L48 之前几乎读不出名字（约 −4.4 到 −4.6，相当于排在几万名），L56 到 −3.5，L62 跳到约 −1.0。Jacobian lens 从 L40 起明显好于 logit lens（约 −3.0），说明中间层已经有与名字相关的信息，但这并不区分具体论文（见 6.3）。

> Every readout improves with depth. The logit lens barely reads the name before L48 (about −4.4 to −4.6, i.e. ranks in the tens of thousands), reaches −3.5 at L56 and jumps to about −1.0 at L62. The Jacobian lenses beat the logit lens from L40 on (about −3.0), so middle layers already carry name-related information, but that information is not specific to the paper (see 6.3).

读出 Readout · 组 Group	L24	L32	L40	L48	L56	L62	L63
jlens_public · target	−4.41	−4.24	−3.29	−3.04	−3.30	−1.00	
jlens_public · control	−4.40	−4.21	−3.28	−2.82	−3.06	−1.26	
logit · target	−4.59	−4.51	−4.38	−4.43	−3.52	−0.93	
logit · control	−4.58	−4.50	−4.37	−4.41	−3.51	−1.21	
final · target							−0.71
final · control							−1.00
final · guard							−0.33

平均 log10(1/名次)，未按引用档调整；95% 置信区间宽度约 ±0.01–0.03。 *Mean log10(1/rank), not adjusted for citation bin; 95% CIs are about ±0.01–0.03.*

> **代码 Code**：`~/jlens_work/10_stage10/351_stage10.py analyze`（经 `351_stage10_fix1.py`、`stage10_analyze.sbatch MODE=main`）

> **结果 Results**：`/scratch/zhang.zhiqi2/jlens/351_stage10/summary/A_group_layer.csv` • `summary/A_group_bin_layer.csv` • `figures/A_mean_nlr_by_group.png` • `reports/stage10_report.md`

6.2 目标组 – 对照组（真标题，引用档内） *Target – control within citation bin, true title* Stage 10

在同一引用档内比较，目标组的优势只出现在最后：最终输出 **+0.247** [0.230, 0.265]，各种读出在 L62 为 +0.225 到 +0.247。中间层反而是负的：Jacobian lens 在 L48 为 −0.10 到 −0.15、L56 为 −0.09 到 −0.11，置信区间都在 0 以下；logit lens 在 L48 之前约为 0。

> Within citation bins the target advantage appears only at the end: final output **+0.247** [0.230, 0.265], and +0.225 to +0.247 for every readout at L62. Middle layers are negative: the Jacobian lenses give −0.10 to −0.15 at L48 and −0.09 to −0.11 at L56, with CIs below zero; the logit lens is about zero up to L48.

Readout	L24	L32	L40	L48	L56	L62	L63
jlens_public	−0.028	−0.037	−0.049	−0.133	−0.107	**+0.225**	
jlens_self100	−0.036	−0.051	−0.048	−0.153	−0.110	**+0.226**	
jlens_fitA	−0.019	−0.032	−0.039	−0.096	−0.094	**+0.226**	
logit	+0.002	−0.002	+0.002	−0.011	**+0.035**	**+0.247**	
final							**+0.247**

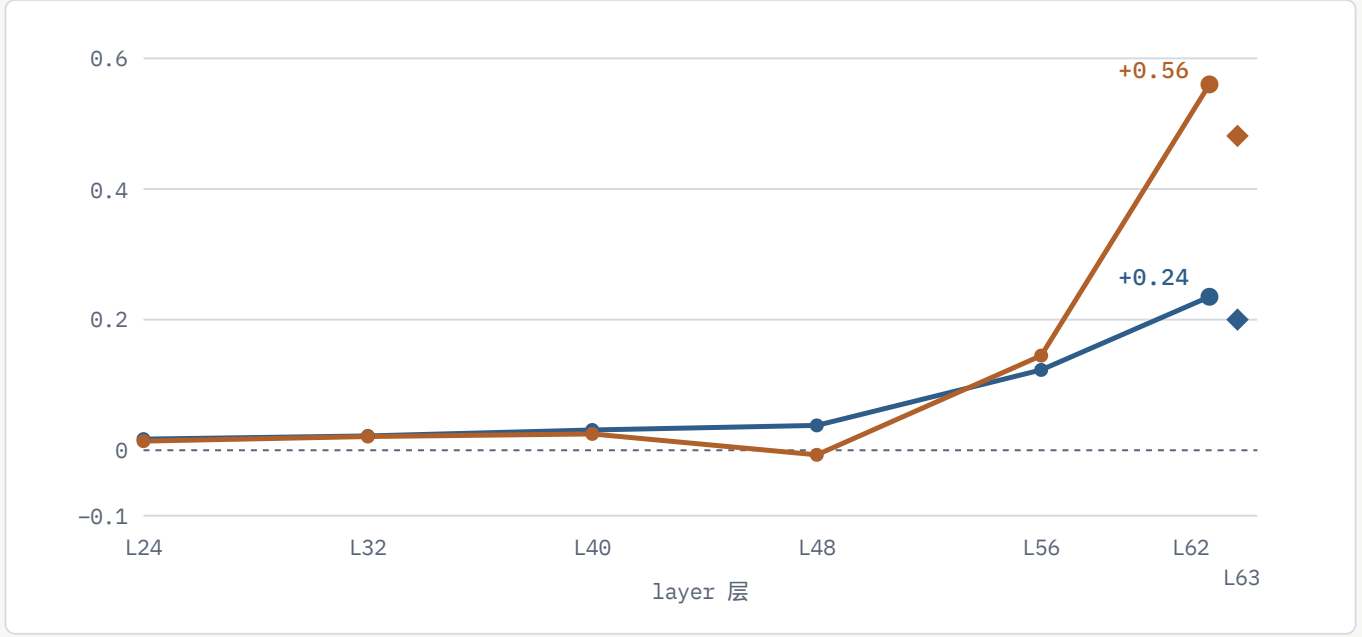
着色项的 95% 置信区间不含 0。 *Coloured cells have 95% CIs that exclude zero.*

> **代码 Code**：`~/jlens_work/10_stage10/351_stage10.py analyze`
> **结果 Results**：`/scratch/zhang.zhiqi2/jlens/351_stage10/summary/B_target_vs_control_within_bin.csv` • `summary/B_sens_*.csv` • `figures/B_target_minus_control.png`

6.3 标题特异信号 *Title-specific signal* Stage 10

把真标题和 5 个假标题对比后，名字本身好不好猜的影响就被抵消了。结果很清楚：L24–L48 层，两组的标题特异信号都不超过 0.05；L56 开始上升（+0.10 到 +0.18）；L62 达到最大，目标组 +0.48 到 +0.58，对照组 +0.20 到 +0.25。对照组也有一定的标题特异信号，说明"认不出名单"的论文模型也并非完全不认识。

> Contrasting the true title with 5 false titles cancels out how guessable a name is. The picture is clear: at L24–L48 the title-specific signal is at most 0.05 in both groups; it rises at L56 (+0.10 to +0.18) and peaks at L62, +0.48 to +0.58 for target and +0.20 to +0.25 for control. The control group also shows some title-specific signal, so papers whose author list the model fails to pick are not entirely unknown to it.



target 目标组　control 对照组

线：jlens_public L24–L62 · 菱形：最终输出 L63 / line: jlens_public, diamond: final output

标题特异信号 = 真标题 − 5 个假标题平均，单位 log10(1/名次)。 *Title-specific signal = true − mean of 5 false titles, in log10(1/rank).*

> **代码 Code**：`~/jlens_work/10_stage10/351_stage10.py analyze-title`（stage10_analyze.sbatch MODE=title）
> **结果 Results**：`/scratch/zhang.zhiqi2/jlens/351_stage10/summary_title/A_group_layer.csv` · `summary_title/paper_title_contrasts.parquet` · `figures/title_*_by_group.png` · `reports/stage10_title_summary.md`

6.4 目标组 − 对照组的标题特异差异 *Target − control difference in the title-specific signal* Stage 10

这是本实验最关键的比较。L24–L40 约为 0；L48 Jacobian lens 略负（−0.04 到 −0.05）；L56 约为 0（logit lens +0.065）；L62/L63 为 **+0.21 到 +0.23**。6.2 中目标组在输出处的优势（+0.22 到 +0.25）几乎全部由标题特异部分构成。去掉 0-4 低引用档后结果不变（L62/L63 为 +0.21 到 +0.24）。

> This is the key comparison. It is about zero at L24–L40, slightly negative for the Jacobian lenses at L48 (−0.04 to −0.05), about zero at L56 (logit lens +0.065), and **+0.21 to +0.23** at L62/L63. The target advantage at the output in 6.2 (+0.22 to +0.25) is therefore almost entirely title-specific. Dropping citation bins 0-4 does not change this (+0.21 to +0.24 at L62/L63).

Readout	L24	L32	L40	L48	L56	L62	L63
jlens_public	−0.002	+0.001	+0.002	−0.044 [−0.057, −0.030]	+0.007	**+0.230** **[0.215, 0.245]**	
jlens_self100	−0.004	+0.001	−0.002	−0.054 [−0.069, −0.040]	+0.003	**+0.231** **[0.215, 0.246]**	
jlens_fitA	−0.003	+0.005	+0.009	−0.037 [−0.049, −0.025]	+0.009	**+0.228** **[0.213, 0.243]**	
logit	**+0.007**	+0.005	+0.003	+0.004	**+0.065** **[0.050, 0.080]**	**+0.229** **[0.213, 0.245]**	
final							**+0.207** **[0.196, 0.220]**

着色项的 95% 置信区间不含 0。 *Coloured cells have 95% CIs that exclude zero.*

> **代码 Code**：`~/jlens_work/10_stage10/351_stage10.py analyze-title`
> **结果 Results**：`/scratch/zhang.zhiqi2/jlens/351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv`
> • `summary_title/B_sens_drop_low_bins.csv`

6.5 阴性对照与 token 角色 *Negative control and token roles* Stage 10

标点 token（名字里的点和空格）不应该依赖论文标题。它们的标题特异信号在所有层都接近 0（最大 0.014），说明对比方法本身不会凭空产生信号。信号主要落在姓的第一个 token 上（L62 为 +0.80 到 +0.88），名的第一个 token 次之，首字母最少。

> Punctuation tokens (the dots and spaces in names) should not depend on the title. Their title-specific signal is near zero at every layer (at most 0.014), so the contrast does not create signal by itself. The signal sits mostly on the first surname token (+0.80 to +0.88 at L62), less on the first given-name token, and least on initials.

> **代码 Code**：`~/jlens_work/10_stage10/351_stage10.py analyze-title`
> **结果 Results**：`/scratch/zhang.zhiqi2/jlens/351_stage10/summary_title/negative_control_by_role.csv`

6.6 与多选题成绩的等级关系 *Graded relation with the multiple-choice score* Stage 10

不分组、直接按多选题答对次数（0–4）看最终输出（在引用档内中心化）：答对 0 次 −0.137、1 次 −0.122、2 次 −0.047、3 次 −0.018、4 次 +0.076，单调上升，档内 Spearman ρ = 0.27（$p < 0.001$）。多选题"认得"越稳，输出时越容易说出作者。

> Without grouping, by the number of correct multiple-choice orders (0–4), the final output (centred within citation bin) rises monotonically: −0.137, −0.122, −0.047, −0.018, +0.076, with a within-bin Spearman ρ of 0.27 ($p < 0.001$). The more consistently the model recognises the author list, the more easily it produces the authors at the output.

> **代码 Code**：`~/jlens_work/10_stage10/351_stage10.py analyze-title`
> **结果 Results**：`/scratch/zhang.zhiqi2/jlens/351_stage10/summary_title/C_graded_mc_team_a.csv`

6.7 第一个 token 与后续 token *First token vs later tokens* Stage 10

每位作者的名字被切成若干 token（平均 4.4 个）。这里把第 1 个 token 和后续 token 分开统计。要注意，在教师强制下，后续 token 前面已经给出了正确的前缀（例如名字的前半部分），所以它们本来就更容易猜，这是预期内的，不能直接解读成"模型更认识姓"。

> Each author name is split into several tokens (4.4 on average). Here the first token is analysed separately from the later tokens. Under teacher forcing the later tokens already have the correct prefix in front of them (for example the first part of the name), so they are easier to guess by construction; this is expected and does not by itself mean the model knows surnames better.

结果要按名字格式分开看（下表）。73% 的作者以首字母开头（如 "S. Bree"），26% 以完整的名开头（如 "Yan Zhao"），其余不到 1%。**首字母开头**时，第 1 个 token（首字母）的标题特异信号很小（输出处 +0.112 [0.104, 0.120]），目标−对照只有 +0.048 [0.028, 0.069]；信号几乎都在后续 token 上（+0.447 [0.440, 0.454]，目标−对照 **+0.253** [0.237, 0.269]）。**完整名开头**时，第 1 个 token（名）本身就带有很强的标题特异信号（+0.358 [0.342, 0.374]，目标−对照 **+0.174** [0.136, 0.213]），和后续 token 相当（+0.396 [0.385, 0.409]，目标−对照 +0.202 [0.173, 0.232]）。所以"信号是否主要由第 1 个 token 决定"取决于格式：首字母几乎不带信号，完整的名则和姓一样带信号。L56 层完整名的第 1 个 token 已经有 +0.25 左右的标题特异信号，目标−对照为 +0.065 到 +0.120，而首字母在 L56 的目标−对照为负。

> The result has to be read by name format (table below). 73% of authors start with an initial (e.g. "S. Bree"), 26% with a full given name (e.g. "Yan Zhao"), and under 1% with something else. **For initial-first names**, the first token (the initial) carries little title-specific signal (+0.112 [0.104, 0.120] at the output) and a target − control difference of only +0.048 [0.028, 0.069]; nearly all the signal is on the later tokens (+0.447 [0.440, 0.454], target − control **+0.253** [0.237, 0.269]). **For given-name-first names**, the first token (the given name) itself carries a strong title-specific signal (+0.358 [0.342, 0.374], target − control **+0.174** [0.136, 0.213]), comparable to the later tokens (+0.396 [0.385, 0.409], target − control +0.202 [0.173, 0.232]). Whether the signal is mainly decided by the first token therefore depends on the format: an initial carries almost none, while a full given name carries as much as the surname. At L56 the first token of a full given name already shows about +0.25 title-specific signal with a target − control difference of +0.065 to +0.120, whereas for initials the L56 target − control difference is negative.

与 6.5 的关系。6.5 说信号主要在"姓的第一个 token"上，这里说第 1 个 token 的信号取决于格式，两者并不矛盾。在首字母和完整名两种格式里，姓都不是名字的第 1 个 token（我们核对过：姓的第一个 token 出现在第 1 个位置的比例为 0%），它总是"后续 token"的一部分。6.5 按 token 的角色分类（首字母、名、姓……），这里按 token 在名字里的位置分类，两种分法互相印证：首字母信号最少（6.5 中输出处 +0.13），所以首字母开头的名字第 1 个 token 信号小；名的信号中等（+0.36），所以完整名开头的名字第 1 个 token 信号明显；姓的第一个 token 信号最多（+0.69），它落在后续 token 里，所以两种格式的后续 token 信号都大。

> **Relation to 6.5.** Section 6.5 says the signal sits mostly on the first surname token; here the first token's signal depends on the format. These do not conflict. In both formats the surname is never the first token of the name (checked: 0% of first-surname tokens are at position 1); it is always among the later tokens. Section 6.5 classifies tokens by role (initial, given name, surname ...), this section by position in the name, and the two agree: initials carry the least signal (+0.13 at the output in 6.5), so the first token of an initial-first name carries little; given names carry a medium amount (+0.36), so the first token of a given-name-first name carries a clear signal; the first surname token carries the most (+0.69) and is among the later tokens, so later tokens carry a large signal in both formats.

位置 · 读出 Position · readout	log10(1/名次)	标题特异 Title-specific	目标−对照（标题特异）Target-control
首字母开头 initial (24,739 位作者)			
第 1 个 token · jlens_public L56	-3.443 [-3.456, -3.430]	**+0.024** **[+0.016, +0.033]**	-0.074 [-0.097, -0.051]
第 1 个 token · logit L56	-3.954 [-3.967, -3.941]	**+0.047** **[+0.037, +0.057]**	-0.056 [-0.086, -0.025]

位置 · 读出 Position · readout	log10(1/名次)	标题特异 Title-specific	目标−对照（标题特异）Target−control
第 1 个 token · jlens_public L62	-1.706 [-1.718, -1.693]	**+0.112** **[+0.102, +0.123]**	+0.019 [-0.008, +0.047]
第 1 个 token · logit L62	-1.077 [-1.087, -1.066]	**+0.126** **[+0.117, +0.137]**	**+0.029** **[+0.003, +0.054]**
第 1 个 token · final L63	-0.946 [-0.955, -0.937]	**+0.112** **[+0.104, +0.120]**	**+0.048** **[+0.028, +0.069]**
后续 token · jlens_public L56	-3.196 [-3.209, -3.182]	**+0.182** **[+0.173, +0.192]**	+0.023 [-0.002, +0.050]
后续 token · logit L56	-3.523 [-3.534, -3.512]	**+0.188** **[+0.181, +0.195]**	**+0.095** **[+0.077, +0.113]**
后续 token · jlens_public L62	-0.845 [-0.853, -0.837]	**+0.534** **[+0.525, +0.542]**	**+0.292** **[+0.272, +0.311]**
后续 token · logit L62	-0.928 [-0.937, -0.919]	**+0.555** **[+0.545, +0.564]**	**+0.279** **[+0.258, +0.300]**
后续 token · final L63	-0.689 [-0.696, -0.681]	**+0.447** **[+0.440, +0.454]**	**+0.253** **[+0.237, +0.269]**
完整名开头 given name (8,876 位作者)			
第 1 个 token · jlens_public L56	-2.708 [-2.733, -2.684]	**+0.259** **[+0.242, +0.275]**	**+0.065** **[+0.022, +0.107]**
第 1 个 token · logit L56	-4.005 [-4.026, -3.981]	**+0.253** **[+0.235, +0.270]**	**+0.120** **[+0.072, +0.168]**
第 1 个 token · jlens_public L62	-2.063 [-2.084, -2.042]	**+0.404** **[+0.385, +0.422]**	**+0.189** **[+0.146, +0.238]**
第 1 个 token · logit L62	-2.188 [-2.212, -2.161]	**+0.421** **[+0.401, +0.442]**	**+0.187** **[+0.142, +0.234]**
第 1 个 token · final L63	-2.022 [-2.046, -1.999]	**+0.358** **[+0.342, +0.374]**	**+0.174** **[+0.136, +0.213]**
后续 token · jlens_public L56	-3.064 [-3.089, -3.040]	**+0.132** **[+0.121, +0.142]**	+0.005 [-0.023, +0.034]
后续 token · logit L56	-2.970 [-2.994, -2.946]	**+0.137** **[+0.128, +0.145]**	**+0.049** **[+0.025, +0.073]**
后续 token · jlens_public L62	-1.056 [-1.075, -1.036]	**+0.441** **[+0.427, +0.456]**	**+0.211** **[+0.179, +0.246]**
后续 token · logit L62	-1.027 [-1.047, -1.006]	**+0.472** **[+0.457, +0.488]**	**+0.230** **[+0.192, +0.267]**
后续 token · final L63	-0.803 [-0.820, -0.785]	**+0.396** **[+0.385, +0.409]**	**+0.202** **[+0.173, +0.232]**

按作者名字第 1 个 token 的角色分格式；每篇论文对该格式、该位置的 token 取平均（有该格式作者的论文：首字母 8,275 篇，完整名 4,157 篇）；目标−对照为引用档内比较。着色项 95% 置信区间不含 0。 *Format is the role of the first token of the author string; each paper is averaged over its tokens of that format and position (papers with such authors: initial 8,275, given name 4,157); target − control within citation bin. Coloured cells have 95% CIs excluding zero.*

知道第一个 token 之后，后面是否容易很多？按第 1 个 token 是否排进前 10 把作者分开，比较后续 token 的表现（真标题）。差别很小：在输出处，第 1 个 token 进前 10 时后续 token 为 −0.740，没进时为 −0.780，差 +0.041 [0.029, 0.052]，后续 token 进前 10 的比例为 69.5% 对 67.5%。L62 的 logit lens 和 Jacobian lens 也只差 +0.05 到 +0.07。中间层第 1 个 token 几乎从不进前 10（L56 只有 0.2%–1.2%），无法做这个比较。

> **Once the first token is known, are the later tokens much easier?** Authors were split by whether the first token ranks in the top 10, and the later tokens compared (true title). The difference is small: at the output, later tokens score −0.740 when the first token is in the top 10 and −0.780 when it is not, a difference of +0.041 [0.029, 0.052]; later tokens reach the top 10 in 69.5% versus 67.5% of cases. At L62 the logit and Jacobian lenses differ by only +0.05 to +0.07. In middle layers the first token almost never reaches the top 10 (0.2%–1.2% at L56), so the comparison cannot be made there.

读出 Readout	第 1 个 token 进前 10 的比例	后续 token · 进前 10	后续 token · 未进	差值 Difference	后续
jlens_public L62	14.3%	-0.895	-0.946	+0.051 [+0.033, +0.069]	
logit L62	38.0%	-0.957	-1.029	+0.072 [+0.057, +0.086]	
final L63	43.6%	-0.740	-0.780	+0.041 [+0.029, +0.052]	

知道名（first name）之后，整个名字是否更容易？按"名字第一个词"整体是否进前 10 来分时，取决于名字格式。名是完整写出的（如 "Yan Zhao"），名进前 10 时，姓明显更容易：输出处 +0.222 [0.165, 0.275]，L62 logit lens +0.322 [0.253, 0.388]。名只是首字母的（如 "S. Bree"），首字母进前 10 对姓几乎没有帮助（输出处 −0.009 [−0.031, +0.013]）。两种格式混在一起时整体差值反而是负的（输出处 −0.113），原因是首字母很容易进前 10（54%），而它后面的姓本来就更难；这是格式比例造成的，分开看后不存在。

> **Once the given name is known, is the whole name easier?** When the split is by whether the whole first word is in the top 10, the answer depends on the name format. For names with a full given name (e.g. "Yan Zhao"), a top-10 given name makes the surname clearly easier: +0.222 [0.165, 0.275] at the output and +0.322 [0.253, 0.388] for the logit lens at L62. For names that start with an initial (e.g. "S. Bree"), a top-10 initial barely helps the surname (−0.009 [−0.031, +0.013] at the output). Pooling both formats gives a negative difference (−0.113 at the output) because initials reach the top 10 easily (54%) and the surnames after them are harder; this comes from the format mix and disappears when the formats are separated.

名字格式 · 读出 Format · readout	作者数 Authors	第一个词进前 10	后续词 · 进前 10	后续词 · 未进	差值 D
首字母 initial · final L63	24,739	54.4%	-1.148	-1.139	[-0.
完整名 given name · final L63	8,876	7.6%	-0.609	-0.831	[+0.1
首字母 initial · logit L62	24,739	45.0%	-1.385	-1.351	[-0
完整名 given name · logit L62	8,876	6.9%	-0.736	-1.058	[+0.2

名字格式 · 读出 Format · readout	作者数 Authors	第一个词进前 10	后续词 · 进前 10	后续词 · 未进	差值 D
首字母 initial · jlens_public L62	24,739	15.5%	-1.335	-1.368	[+0.0(
完整名 given name · jlens_public L62	8,876	7.5%	-0.881	-1.042	[+0.1(

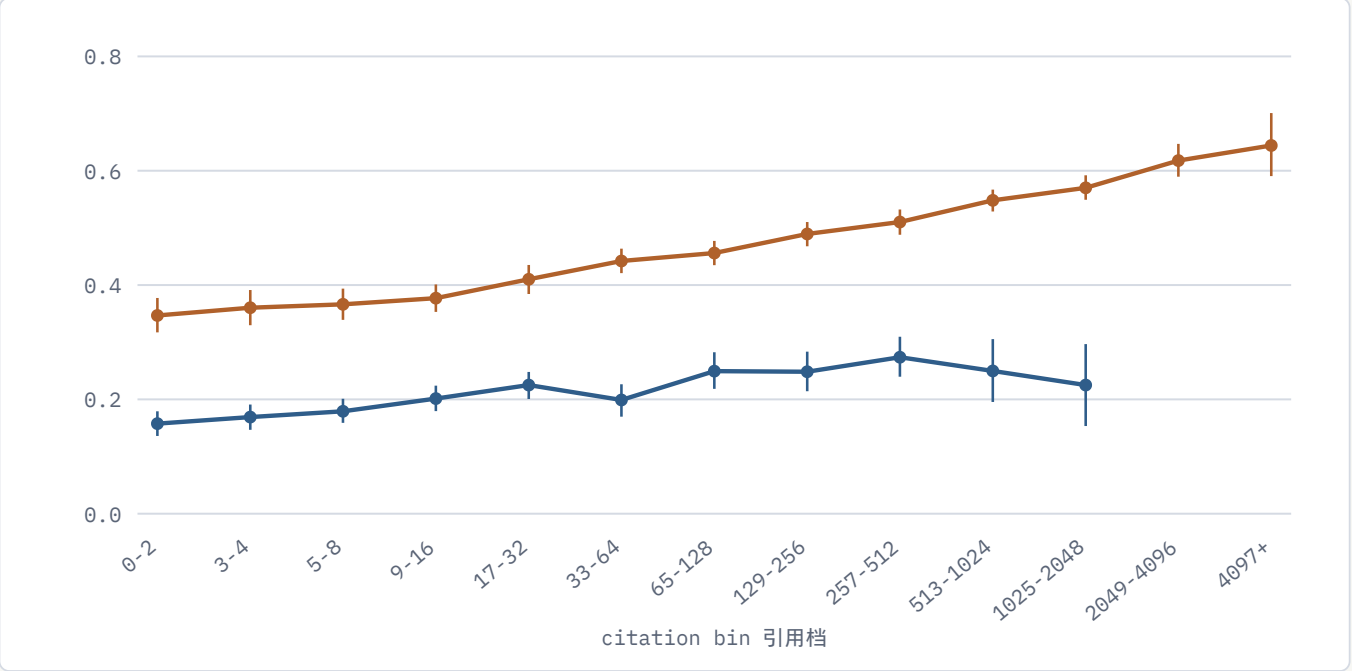
真标题；置信区间为按论文聚类的 bootstrap。 *True title; CIs from a bootstrap clustered by paper.*

> **代码 Code**：`~/jlens_work/10_stage10/stage10_extra.py`（X1）、`stage10_extra_format.py`、`stage10_extra_cond_role.py`
> **结果 Results**：`/scratch/zhang.zhiqi2/jlens/351_stage10/summary_extra/X1_*.csv`

6.8 引用数的影响 *Effect of citation count* Stage 10

按 13 个引用档分别计算最终输出的读出水平和标题特异信号。目标组的标题特异信号从 0-2 档的 +0.347 [0.317, 0.377] 单调升到 4097+ 档的 **+0.644** [0.591, 0.701]；对照组从 +0.158 [0.136, 0.179] 升到 257-512 档的 +0.274 [0.240, 0.309] 左右，高引用档对照组论文很少，区间变宽。在每一个引用档内，目标组都高于对照组。

> The output readout level and title-specific signal were computed in each of the 13 citation bins. The target group's title-specific signal rises monotonically from +0.347 [0.317, 0.377] in bin 0-2 to **+0.644** [0.591, 0.701] in bin 4097+; the control group's rises from +0.158 [0.136, 0.179] to about +0.274 [0.240, 0.309] in bin 257-512, with wide intervals in high bins where control papers are few. In every bin the target group is above the control group.



竖线为 95% 置信区间；少于 10 篇的档不画 / bars are 95% CIs; bins with fewer than 10 papers omitted

最终输出（L63）的标题特异信号，按引用档。 *Title-specific signal at the model output (L63) by citation bin.*

引用档 Bin	n 目标 / 对照	水平 · 目标	水平 · 对照	标题特异 · 目标	标题特异 · 对照
0-2	200 / 352	-0.825 [-0.869, -0.781]	-1.060 [-1.098, -1.021]	+0.347 [+0.317, +0.377]	+0.158 [+0.136, +0.179]
3-4	207 / 355	-0.811 [-0.851, -0.772]	-1.024 [-1.064, -0.986]	+0.360 [+0.330, +0.391]	+0.169 [+0.147, +0.191]
5-8	237 / 332	-0.752 [-0.788, -0.719]	-0.984 [-1.017, -0.950]	+0.366 [+0.339, +0.394]	+0.179 [+0.159, +0.201]
9-16	288 / 275	-0.750 [-0.781, -0.718]	-0.993 [-1.028, -0.958]	+0.377 [+0.353, +0.401]	+0.202 [+0.179, +0.224]
17-32	327 / 234	-0.792 [-0.828, -0.755]	-0.975 [-1.016, -0.937]	+0.410 [+0.384, +0.435]	+0.225 [+0.201, +0.248]
33-64	401 / 185	-0.732 [-0.759, -0.705]	-1.032 [-1.078, -0.984]	+0.442 [+0.421, +0.463]	+0.199 [+0.170, +0.227]
65-128	441 / 165	-0.718 [-0.742, -0.694]	-1.010 [-1.069, -0.955]	+0.456 [+0.435, +0.477]	+0.249 [+0.218, +0.282]
129-256	497 / 126	-0.695 [-0.720, -0.669]	-0.977 [-1.031, -0.921]	+0.489 [+0.468, +0.510]	+0.248 [+0.214, +0.283]
257-512	533 / 105	-0.688 [-0.713, -0.665]	-0.953 [-1.009, -0.900]	+0.510 [+0.488, +0.532]	+0.274 [+0.240, +0.309]
513-1024	603 / 53	-0.664 [-0.686, -0.642]	-0.917 [-1.000, -0.839]	+0.548 [+0.529, +0.567]	+0.250 [+0.196, +0.305]
1025-2048	539 / 29	-0.648 [-0.670, -0.625]	-0.912 [-1.075, -0.776]	+0.570 [+0.549, +0.592]	+0.225 [+0.154, +0.297]
2049-4096	264 / 9	-0.614 [-0.648, -0.582]	—	+0.618 [+0.589, +0.647]	—
4097+	84 / 0	-0.630 [-0.688, -0.568]	—	+0.644 [+0.591, +0.701]	—

Spearman 相关（论文指标对 log10(引用数+1)）：全部论文中，最终输出的标题特异信号 ρ = 0.451 [0.433, 0.467]，读出水平 ρ = 0.317 [0.297, 0.336]。在组内，标题特异信号仍然明显（目标组 0.328、对照组 0.187），读出水平的相关则弱很多（目标组 0.181、对照组 0.084）。L62 的 logit lens 和 Jacobian lens 结果相同。回答：是的，引用越低，模型越不认识论文，表现越差；这主要体现在标题特异信号上，名字本身的可猜程度随引用数变化不大。

> Spearman correlations (paper metric against log10(citations + 1)): across all papers, ρ = 0.451 [0.433, 0.467] for the output's title-specific signal and ρ = 0.317 [0.297, 0.336] for the readout level. Within groups the title-specific correlation remains clear (target 0.328, control 0.187), while the level correlation is much weaker (target 0.181, control 0.084). The logit and Jacobian lenses at L62 give the same picture. Answer: yes, the lower the citation count, the less the model knows the paper and the worse it does; this shows mainly in the title-specific signal, while how guessable the names are changes little with citations.

读出 · 组 Readout · group	n	ρ 水平 level	ρ 标题特异 title-specific
final L63 · all	9,108	**+0.317** [+0.297, +0.336]	**+0.451** [+0.433, +0.467]

读出 · 组 Readout · group	n	ρ 水平 level	ρ 标题特异 title-specific
final L63 · target	4,621	+0.181 [+0.153, +0.209]	+0.328 [+0.301, +0.354]
final L63 · control	2,220	+0.084 [+0.040, +0.126]	+0.187 [+0.145, +0.229]
logit L62 · all	9,108	+0.209 [+0.188, +0.229]	+0.440 [+0.422, +0.456]
logit L62 · target	4,621	+0.062 [+0.032, +0.092]	+0.327 [+0.301, +0.353]
logit L62 · control	2,220	+0.053 [+0.006, +0.092]	+0.205 [+0.165, +0.246]
jlens_public L62 · all	9,108	+0.216 [+0.195, +0.235]	+0.441 [+0.424, +0.457]
jlens_public L62 · target	4,621	+0.085 [+0.056, +0.113]	+0.324 [+0.299, +0.350]
jlens_public L62 · control	2,220	+0.051 [+0.009, +0.095]	+0.196 [+0.155, +0.237]

> **代码 Code**：~/jlens_work/10_stage10/stage10_extra.py（X2）；~/jlens_work/10_stage10/351_stage10.py analyze-title
> **结果 Results**：/scratch/zhang.zhiqi2/jlens/351_stage10/summary_extra/X2_by_bin.csv · summary_extra/X2_spearman.csv · summary_title/E_citation_within_group.csv

6.9 三种 Jacobian lens 与 logit lens 的比较 *Three Jacobian lenses vs the logit lens* Stage 10

对同一批论文、同一批 token 逐层配对比较。读出水平上，fitA 在 L24、L32、L48、L56 最好（L48 为 −2.69，logit lens 为 −4.42），L40 是 self100 略好，public 居中；到 L62 反而是 logit lens 最好（−1.02 对 −1.05 到 −1.09）。前 10 命中率上，L48 的 Jacobian lens 为 15%–18%，logit lens 只有 1.1%；L62 则 logit lens 最高（59.3% 对 53.6%–54.6%）。

> All comparisons are paired on the same papers and tokens. On readout level, fitA is best at L24, L32, L48 and L56 (−2.69 at L48 versus −4.42 for the logit lens), self100 is slightly better at L40, and public lies in between; at L62 the logit lens is best (−1.02 versus −1.05 to −1.09). On top-10 hit rate, the Jacobian lenses reach 15%–18% at L48 versus 1.1% for the logit lens; at L62 the logit lens is highest (59.3% versus 53.6%–54.6%).

指标 · 读出 Metric · readout	L24	L32	L40	L48	L56	L62
log10(1/名次) · jlens_public	-4.405	-4.224	-3.283	-2.950	-3.178	-1.085
log10(1/名次) · jlens_self100	-4.318	-4.137	**-3.016**	-3.037	-3.095	-1.086
log10(1/名次) · jlens_fitA	**-3.776**	**-3.723**	-3.065	**-2.689**	**-3.032**	-1.052
log10(1/名次) · logit	-4.581	-4.504	-4.376	-4.418	-3.496	**-1.021**
前 10 命中率 · jlens_public	0.4%	0.4%	3.5%	16.2%	7.1%	53.6%
前 10 命中率 · jlens_self100	0.4%	0.6%	**6.9%**	14.7%	**8.2%**	53.6%

指标 · 读出 Metric · readout	L24	L32	L40	L48	L56	L62
前 10 命中率 · jlens_fitA	**1.0%**	**1.0%**	2.3%	**18.3%**	7.9%	54.6%
前 10 命中率 · logit	0.6%	0.8%	1.2%	1.1%	8.1%	**59.3%**
标题特异信号 · jlens_public	+0.016	**+0.024**	+0.032	**+0.014**	+0.149	+0.442
标题特异信号 · jlens_self100	+0.014	+0.023	+0.029	+0.010	+0.147	+0.444
标题特异信号 · jlens_fitA	**+0.017**	+0.024	**+0.034**	+0.012	+0.152	+0.436
标题特异信号 · logit	+0.003	+0.007	+0.004	+0.003	**+0.158**	**+0.463**

全部论文的平均值，加粗为该层最好的读出；均值的置信区间宽度均小于 ±0.01（见下表的配对差值）。 *Means over all papers; bold marks the best readout at each layer. CIs of the means are narrower than ±0.01; see the paired differences below.*

Jacobian lens − logit lens	L24	L32	L40	L48	
log10(1/名次) · jlens_public − logit	**+0.176** [+0.170, +0.182]	**+0.280** [+0.274, +0.287]	**+1.093** [+1.082, +1.104]	**+1.467** [+1.456, +1.479]	[+0.311
log10(1/名次) · jlens_self100 − logit	**+0.263** [+0.257, +0.269]	**+0.367** [+0.359, +0.374]	**+1.361** [+1.349, +1.372]	**+1.380** [+1.369, +1.391]	[+0.393
log10(1/名次) · jlens_fitA − logit	**+0.805** [+0.797, +0.813]	**+0.781** [+0.773, +0.789]	**+1.312** [+1.301, +1.322]	**+1.728** [+1.717, +1.740]	[+0.456
前 10 命中率 · jlens_public − logit	-0.002 [-0.002, -0.001]	-0.004 [-0.005, -0.004]	**+0.023** [+0.021, +0.024]	**+0.150** [+0.148, +0.153]	[-0.0
前 10 命中率 · jlens_self100 − logit	-0.002 [-0.002, -0.001]	-0.002 [-0.003, -0.002]	**+0.057** [+0.055, +0.059]	**+0.136** [+0.134, +0.138]	[-0.00
前 10 命中率 · jlens_fitA − logit	**+0.004** [+0.003, +0.005]	**+0.002** [+0.001, +0.003]	**+0.011** [+0.010, +0.012]	**+0.172** [+0.170, +0.174]	[-0.00
标题特异信号 · jlens_public − logit	**+0.014** [+0.012, +0.016]	**+0.017** [+0.014, +0.021]	**+0.028** [+0.022, +0.034]	**+0.011** [+0.006, +0.016]	[-0.0
标题特异信号 · jlens_self100 − logit	**+0.012** [+0.009, +0.014]	**+0.016** [+0.012, +0.020]	**+0.025** [+0.020, +0.030]	**+0.007** [+0.001, +0.012]	[-0.0
标题特异信号 · jlens_fitA − logit	**+0.015** [+0.012, +0.018]	**+0.017** [+0.013, +0.021]	**+0.030** [+0.026, +0.035]	**+0.009** [+0.005, +0.014]	[-0.01

Jacobian lens 之间 Between lenses	L24	L32	L40	L48
log10(1/名次) · jlens_fitA − jlens_public	**+0.629** [+0.624, +0.633]	**+0.501** [+0.497, +0.505]	**+0.218** [+0.215, +0.221]	**+0.261** [+0.259, +0.263]
log10(1/名次) · jlens_fitA − jlens_self100	**+0.542** [+0.538, +0.546]	**+0.414** [+0.411, +0.418]	-0.049 [-0.053, -0.045]	**+0.348** [+0.345, +0.351]
log10(1/名次) · jlens_public − jlens_self100	-0.087 [-0.089, -0.084]	-0.086 [-0.088, -0.084]	-0.267 [-0.270, -0.265]	**+0.087** [+0.086, +0.088]
标题特异信号 · jlens_fitA − jlens_public	+0.001 [-0.001, +0.002]	-0.000 [-0.002, +0.002]	**+0.002** [+0.000, +0.005]	-0.001 [-0.003, +0.000]
标题特异信号 · jlens_fitA − jlens_self100	**+0.003** [+0.001, +0.005]	+0.001 [-0.001, +0.003]	**+0.005** [+0.003, +0.008]	**+0.003** [+0.001, +0.005]

Jacobian lens 之间 Between lenses	L24	L32	L40	L48
标题特异信号 · jlens_public − jlens_self100	**+0.002** **[+0.001, +0.003]**	+0.001 [-0.000, +0.003]	**+0.003** **[+0.001, +0.004]**	**+0.004** **[+0.003, +0.005]**

有没有哪种 lens 能在中间层读出 logit lens 读不出的、针对具体论文的信息？有一点，但很少，而且不区分目标组和对照组。L24–L48 层，三种 Jacobian lens 的标题特异信号都比 logit lens 高 +0.007 到 +0.030（置信区间都在 0 以上），而 L62 的标题特异信号约为 0.44，差了一个数量级以上。再看这部分额外信息是否偏向目标组：把"lens − logit"的标题特异信号做目标−对照比较，L24–L40 约为 0，L48 和 L56 为负（−0.04 到 −0.06），L62 约为 0。也就是说，Jacobian lens 在中间层多读出的那点论文信息，对照组反而略多，不支持"目标组的作者在中间层已经形成"。

> **Does any lens read paper-specific information in middle layers that the logit lens misses?** A little, but very little, and it does not separate target from control. At L24–L48 all three Jacobian lenses show +0.007 to +0.030 more title-specific signal than the logit lens (CIs above zero), against about 0.44 at L62, more than an order of magnitude larger. Comparing the extra lens signal (lens − logit) between target and control gives about zero at L24–L40, negative values at L48 and L56 (−0.04 to −0.06), and about zero at L62. The small extra paper information the Jacobian lenses read in middle layers is, if anything, slightly larger for control papers, which does not support target authors already being formed in middle layers.

目标−对照：标题特异(lens) − 标题特异(logit)	L24	L32	L40	L48	L5
jlens_public − logit	-0.009 [-0.015, -0.002]	-0.004 [-0.013, +0.005]	-0.001 [-0.018, +0.015]	-0.047 [-0.062, -0.033]	-0.05 [-0.075, -0.04
jlens_self100 − logit	-0.010 [-0.017, -0.004]	-0.004 [-0.015, +0.007]	-0.005 [-0.019, +0.010]	-0.058 [-0.073, -0.043]	-0.06 [-0.080, -0.04
jlens_fitA − logit	-0.010 [-0.017, -0.002]	-0.000 [-0.012, +0.012]	+0.006 [-0.007, +0.018]	-0.041 [-0.053, -0.028]	-0.05 [-0.072, -0.03

引用档内的目标−对照差；着色项 95% 置信区间不含 0。 *Target − control within citation bin; coloured cells have 95% CIs excluding zero.*

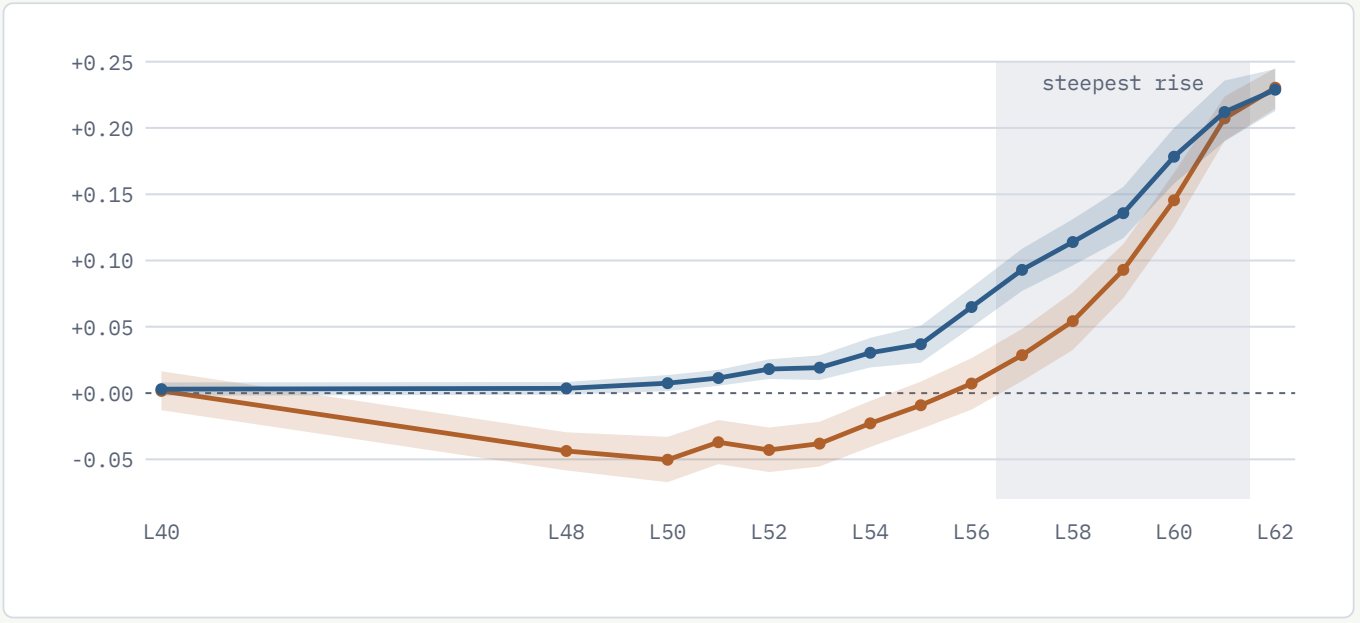
> **代码 Code**：`~/jlens_work/10_stage10/stage10_extra.py`（X3）
> **结果 Results**：`/scratch/zhang.zhiqi2/jlens/351_stage10/summary_extra/X3_means.csv` · `summary_extra/X3_pairwise.csv` · `summary_extra/X3_tc_spec_vs_logit.csv`

6.10 细层：L48–L62 *Fine layers: L48–L62* Stage 10

扩展计算补齐了 L50–L55 和 L57–L61（public Jacobian lens 和 logit lens，7 个标题条件全部），用来确定目标组的优势具体从哪一层开始。结果显示它不是在 L62 突然出现的，而是从 L50 前后开始逐层积累。logit lens 的目标−对照标题特异差在 L48 约为 0，L50 为 +0.007 [0.001, 0.014]，之后逐层上升：L52 +0.018、L54 +0.030、L56 +0.065、L58 +0.114、L60 +0.178、L62 +0.229，上升最快的是 L57–L61。public Jacobian lens 在 L48–L54 为负（−0.02 到 −0.05），L55–L56 约为 0，L57 起转正（+0.029 [0.009, 0.048]），到 L61 为 +0.207。

> The extension filled in L50–L55 and L57–L61 (public Jacobian lens and logit lens, all 7 title conditions) to locate where the target advantage starts. It does not appear suddenly at L62; it accumulates layer by

> layer from about L50. For the logit lens, the target − control title-specific difference is about 0 at L48 and +0.007 [0.001, 0.014] at L50, then rises steadily: L52 +0.018, L54 +0.030, L56 +0.065, L58 +0.114, L60 +0.178, L62 +0.229, rising fastest over L57–L61. For the public Jacobian lens it is negative at L48–L54 (−0.02 to −0.05), about 0 at L55–L56, positive from L57 (+0.029 [0.009, 0.048]), and +0.207 at L61.



logit lens　jlens_public　阴影为 95% 置信区间；灰底为 L57–L61 / shading: 95% CI; grey band: L57–L61

目标−对照的标题特异信号，引用档内比较，L40–L62。 *Target − control title-specific signal within citation bin, L40–L62.*

两组自己的标题特异信号也是逐层增长的（logit lens）：目标组从 L50 的 +0.022 涨到 L61 的 +0.596，对照组从 +0.020 涨到 +0.282，两组在 L52 之后明显分开。两组的标题特异信号都在 L61 达到最高，L62 略有回落（目标组 +0.583，对照组 +0.252）。只看真标题时，logit lens 的目标−对照在 L55 之前约为 0、L56 起转正；public lens 到 L58 仍为负、L60 起转正，比标题特异差晚 2–3 层，因为中间层的 Jacobian lens 读出的名字信息对照组略多（见 6.9）。

> Each group's own title-specific signal also grows layer by layer (logit lens): target from +0.022 at L50 to +0.596 at L61, control from +0.020 to +0.282, with the groups clearly separating after L52. Both peak at L61 and dip slightly at L62 (target +0.583, control +0.252). With the true title alone, the logit lens's target − control difference is about 0 before L55 and positive from L56; for the public lens it is still negative at L58 and positive from L60, 2–3 layers later than the title-specific difference, because the middle-layer Jacobian readout favours control papers slightly (see 6.9).

指标 · 读出 Metric · readout	L48	L50	L51	L52	
标题特异 · target · logit	+0.005	+0.022	+0.027	+0.041	
标题特异 · control · logit	+0.002	+0.020	+0.021	+0.027	
目标−对照（标题特异）· logit	+0.004 [-0.001, +0.008]	**+0.007 [+0.001, +0.014]**	**+0.011 [+0.005, +0.018]**	**+0.018 [+0.011, +0.026]**	**[+0.010,**
目标−对照（真标题）· logit	-0.011 [-0.027, +0.005]	-0.021 [-0.040, -0.002]	-0.012 [-0.031, +0.008]	-0.015 [-0.039, +0.009]	[-0.045
标题特异 · target · jlens_public	-0.007	+0.018	+0.020	+0.023	
标题特异 · control · jlens_public	+0.038	+0.072	+0.065	+0.070	

指标 · 读出 Metric · readout	L48	L50	L51	L52	
目标−对照（标题特异）· jlens_public	-0.044 [-0.058, -0.030]	-0.050 [-0.067, -0.033]	-0.037 [-0.054, -0.020]	-0.043 [-0.060, -0.026]	[-0.055
目标−对照（真标题）· jlens_public	-0.133 [-0.160, -0.107]	-0.187 [-0.215, -0.159]	-0.178 [-0.204, -0.151]	-0.176 [-0.203, -0.149]	[-0.191

着色项 95% 置信区间不含 0。L56 和 L62 的数值来自主轮，其余层来自扩展计算。 *Coloured cells have 95% CIs excluding zero. L56 and L62 come from the main round, the other layers from the extension.*

> **代码 Code**：`~/jlens_work/10_stage10/351_stage10_fix1.py` + `stage10_ext_wait / ext_parity / ext_worker / ext_analyze.sbatch`
> **结果 Results**：`/scratch/zhang.zhiqi2/jlens/351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv`（L50–61 行）· `snapshot_main_round/`（扩展前的分析）

6.11 Stage 11：干预实验——标题信息在哪几层被读取、搬到哪里 *Stage 11: interventions — when the title is read and where it goes* Stage 11

前面的结果都是"读出来"的相关性。Stage 11 直接动手干预模型内部，来确定信息形成的时间和路径。样本是 593 篇目标组和 593 篇对照组论文，在引用档内配平；标题位置读出和作者连写两项用全部 9,108 篇论文。干预后都看模型最终输出里正确名字 token 的名次，用"真标题与假标题差距中恢复（或损失）了多少比例"来衡量。

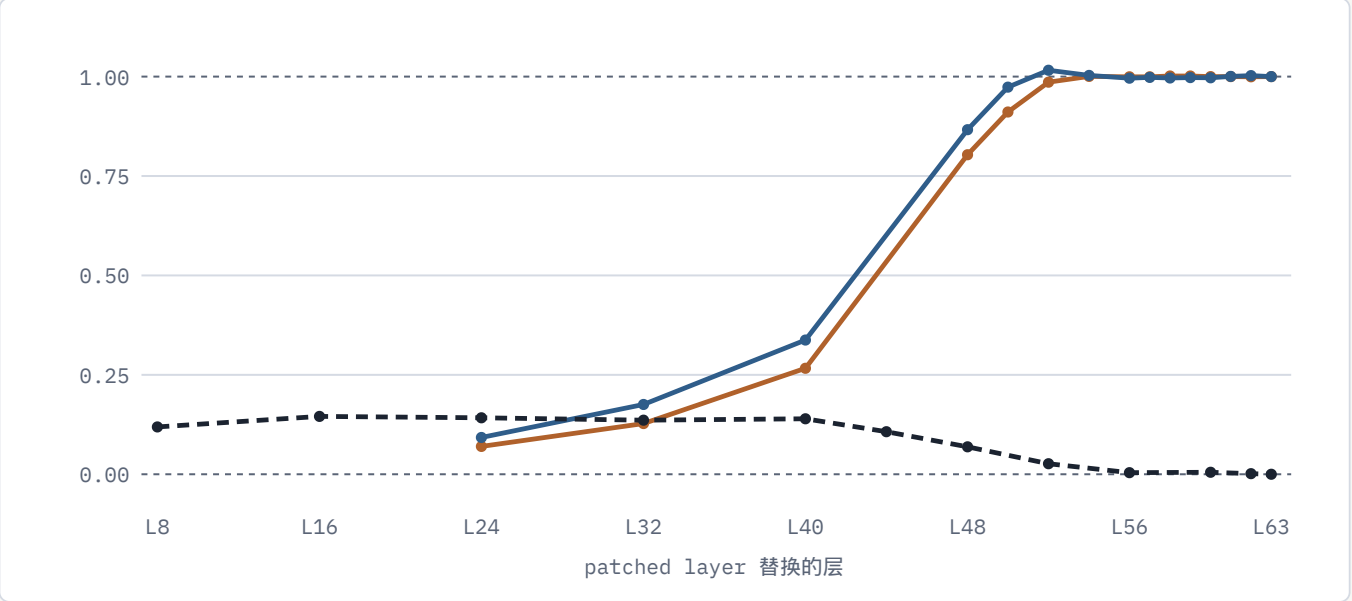
> The results above are correlational readouts. Stage 11 intervenes inside the model to fix when and where the information forms. The sample is 593 target and 593 control papers, balanced within citation bins; the title-position readout and the author chain use all 9,108 papers. Every intervention is scored at the model output, as the share of the true-title vs false-title gap that is recovered (or lost).

设计细节。① 抽样：只用目标组和对照组都至少 30 篇的引用档（与 §4.4 相同的 10 档），每档每组随机抽 $\min(60, n_t, n_c)$ 篇（种子 11），共 593 + 593 篇，每 50 篇一个 shard。② 替换只用 false_0 这一个假标题（匹配代价最小的一个），没有对 5 个假标题取平均。③ 阻断（knockout）在注意力打分上加掩码，对**所有注意力头**生效：从第 l 层到最后一层，标题之后的每个位置都不能注意标题 token；l = 64 表示什么都不挡、只走同一套显式掩码路径，作为基线。E2n 只挡 ":" 和名字位置。

> **Design details.** (1) Sampling: only citation bins with at least 30 target and 30 control papers (the same 10 bins as §4.4); per bin and group $\min(60, n_t, n_c)$ random papers (seed 11), 593 + 593 in total, 50 papers per shard. (2) Patching uses a single false title, false_0 (the lowest-cost match), not the mean of the 5. (3) Knockout adds a mask to the attention scores of **all attention heads**: from layer l to the last layer, no position after the title may attend to the title tokens; l = 64 blocks nothing but uses the same explicit-mask path, as the baseline. E2n blocks only ":" and the name positions.

替换（activation patching）。同一篇论文分别用真标题和匹配的假标题（false_0）跑一遍，在第 l 层把真标题运行里"标题之后的那几个 token"（右引号、年份、"Authors:"、名字）的表示复制进假标题运行。恢复比例在 L24 只有 0.07–0.09，L40 为 0.27–0.34，L48 为 0.80–0.87，**L52 起达到 1.00**。也就是说，到 L52 时，输出所需要的论文信息已经全部在标题之后的这几个位置上了。只替换标题的最后一个 token 时，恢复比例只有约 0.12（L8–L40），到 L56 降为 0：标题最后一个 token 本身携带的信息很少。

> **Activation patching.** Each paper is run with its true title and with its matched false title (false_0). At layer l, the hidden states of the tokens after the title (closing quote, year, "Authors:", the name) are copied from the true run into the false run. Recovery is 0.07–0.09 at L24, 0.27–0.34 at L40, 0.80–0.87 at L48, and **1.00 from L52**: by L52 everything the output needs about the paper already sits in those positions. Patching only the last title token recovers about 0.12 (L8–L40) and nothing from L56, so that token carries little on its own.



标题之后的 token · target　标题之后的 token · control

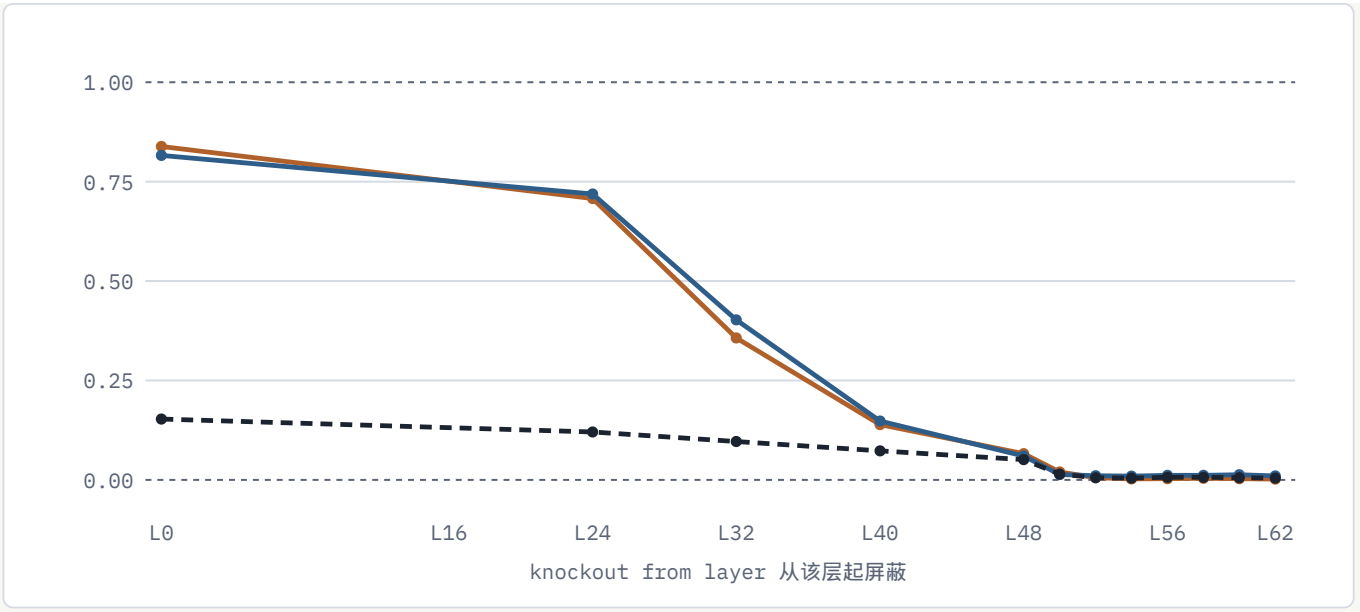
虚线：只替换标题最后一个 token / dashed: last title token only

替换后恢复的比例（真标题−假标题差距的份额）。 *Share of the true − false gap recovered by patching at each layer.*

替换 Patching	L24	L32	L40	L48	L50	
E1 tail patch · target	**+0.070** [+0.060, +0.080]	**+0.128** [+0.115, +0.141]	**+0.267** [+0.247, +0.287]	**+0.803** [+0.784, +0.824]	**+0.911** [+0.895, +0.928]	[+
E1 tail patch · control	**+0.092** [+0.074, +0.111]	**+0.176** [+0.151, +0.200]	**+0.337** [+0.307, +0.374]	**+0.866** [+0.835, +0.903]	**+0.974** [+0.950, +1.000]	[+
E1t last title token · all	**+0.142** [+0.126, +0.159]	**+0.136** [+0.121, +0.152]	**+0.139** [+0.125, +0.155]	**+0.069** [+0.061, +0.077]	—	[+

注意力阻断（knockout）。从第 l 层开始到最后一层，禁止标题之后的所有位置注意标题 token（真标题）。从 L0 开始阻断，损失真假差距的 0.82–0.84；从 L32 开始损失 0.36–0.40；从 L40 开始 0.14–0.15；从 L48 开始约 0.06；**从 L52 开始约为 0**。所以模型主要在 L24–L48 从标题读取论文信息，L50 之后就不再需要标题。如果只阻断 ":" 和名字两个位置，最多只损失 0.15，到 L52 也降为 0：信息主要不是由标题直接传给名字，而是先经过标题之后的那几个 token。

> **Attention knockout.** From layer l to the last layer, every position after the title is blocked from attending to the title tokens (true title). Starting at L0 removes 0.82–0.84 of the gap, at L32 0.36–0.40, at L40 0.14–0.15, at L48 about 0.06, and **from L52 about 0**. The model reads the paper from the title mainly in L24–L48 and no longer needs it after L50. Blocking only ":" and the name positions removes at most 0.15, also 0 by L52: the information does not go straight from the title to the names, it goes through the tokens right after the title.



阻断所有后续位置 · target　阻断所有后续位置 · control　虚线：只阻断 ":" 和名字 / dashed: ":" + names only

从该层起阻断后损失的比例。 *Share of the true − false gap lost when attention to the title is blocked from each layer on.*

阻断 Knockout（起始层）	L0	L24	L32	L40	L48
E2 all later tokens · target	+0.839 [+0.808, +0.872]	+0.708 [+0.679, +0.736]	+0.357 [+0.332, +0.384]	+0.139 [+0.121, +0.158]	+0.066 [+0.051, +0.080]
E2 all later tokens · control	+0.816 [+0.751, +0.885]	+0.719 [+0.664, +0.775]	+0.402 [+0.359, +0.448]	+0.148 [+0.117, +0.181]	+0.060 [+0.033, +0.090]
E2n ":" + names only · all	+0.153 [+0.136, +0.172]	+0.120 [+0.104, +0.136]	+0.097 [+0.082, +0.112]	+0.073 [+0.059, +0.086]	+0.051 [+0.040, +0.062]

标题位置能不能读出作者。在标题最后一个 token 上用 lens 读，标题特异信号只有约 0.01–0.03，而且中间层目标组和对照组没有差别：lens 在标题位置几乎读不出作者。换成线性 probe（5 折 ridge 回归，把标题位置的表示映射到模型在 ":" 处 L63 的表示）能读出一些。**说明：**probe 只给每位作者名字的**第一个 token** 打分，73% 的作者名以首字母开头，所以多数时候打分的是首字母；标题特异信号只减 **false_0** 这一个假标题，不是 5 个假标题的平均。按作者团队分折、并剔除 probe 训练时见过同一标题的论文后复核（剩 1,863 篇，其中目标 896、对照 499） 已复核 ：L24 约 +0.05，L40 约 +0.06，L56 约 +0.08（+0.050 / +0.061 / +0.075）；目标组比对照组高 +0.03 到 +0.08（L24–L60，置信区间在 0 以上，L44 下界 +0.000 在边界上）。这是 2026-10-30 改为**只在训练折内拟合标准化**后的数字：原来的标准化用了全部论文（含测试折，`stage10_extra_r0r1.py:244`）；改后最大变化 0.0075，正则化强度不变，没有任何区间从“不含 0”变成“含 0”（`381_stage13/reports/e4b_trainstd_compare.md`，作业 11500917）。原来按论文分折、未剔除时为 L16 约 +0.04、L52–56 约 +0.08，目标组高 +0.02 到 +0.04（下表），复核后结论不变。对照检验（§6.12）表明，这部分信号是这篇论文特有的，不是题目与名字的泛泛关联。

> **Can the author be read at the title position?** Lenses at the last title token give only about 0.01–0.03 title-specific signal, with no target − control difference in middle layers, so the lenses can hardly read the author there. A linear probe (5-fold ridge from the title-position state to the model's own L63 ":" state) reads a little more: re-checked with team folds and title reuse removed, about +0.05 at L24, +0.06 at L40 and +0.08 at L56 (+0.050 / +0.061 / +0.075), with target above control by +0.03 to +0.08 (CIs above zero; the L44 lower bound is +0.000). These use standardisation fitted on the training folds only (2026-10-30); the original standardised over all papers including the test fold. Largest change 0.0075, no CI

changes whether it contains 0. Note: the probe scores only the **first token** of each author's name (73% of names start with an initial, so usually the initial), and the title-specific signal subtracts only **false_0**, not the mean of 5 false titles. Controls (§6.12) show the signal is specific to the paper, not a generic topic → name association.

标题最后一个 token 上的标题特异信号	L16	L24	L32	L40	
logit lens · target	-0.005 [-0.014, +0.004]	+0.002 [-0.006, +0.010]	-0.001 [-0.008, +0.006]	**+0.007** **[+0.001, +0.013]**	**+** **[+0.004, +**
public J-lens · target	+0.012 [-0.010, +0.035]	+0.002 [-0.014, +0.019]	+0.008 [-0.009, +0.026]	**+0.026** **[+0.006, +0.046]**	+ [-0.006, -
probe · target	**+0.043** **[+0.036, +0.050]**	**+0.047** **[+0.041, +0.054]**	**+0.057** **[+0.050, +0.064]**	**+0.066** **[+0.059, +0.074]**	**+** **[+0.061, +**
probe · control	**+0.035** **[+0.024, +0.046]**	**+0.037** **[+0.026, +0.047]**	**+0.037** **[+0.025, +0.048]**	**+0.048** **[+0.036, +0.060]**	**+** **[+0.041, +**
probe · target − control	**+0.019** **[+0.005, +0.033]**	**+0.024** **[+0.009, +0.039]**	**+0.035** **[+0.021, +0.050]**	**+0.032** **[+0.016, +0.047]**	**+** **[+0.017, +**

作者连写。把全部作者写成 "Authors: A1, A2, …" 连在一起打分，并和逐个单独打分逐 token 配对比较。前面的作者在上下文里时，后面的作者明显更好猜：目标组 +0.17 到 +0.23，对照组 +0.12 到 +0.18。但标题特异信号随之变小，例如目标组第 4 位起的作者从 0.42 降到 0.26，因为合作者本身已经指明了是哪篇论文。在引用档内，目标组仍高于对照组 +0.11 到 +0.15。

Author chain. All authors are scored in one sequence, "Authors: A1, A2, ...", and paired token by token with the isolated scores. With the earlier authors in context, later authors become clearly easier: +0.17 to +0.23 for target, +0.12 to +0.18 for control. The title-specific signal shrinks accordingly (target authors 4+: 0.42 → 0.26), because the co-authors already identify the paper. Within citation bins, target still exceeds control by +0.11 to +0.15.

作者位置 · 组	连写带来的提升（真标题）gain	标题特异 · 单独	标题特异 · 连写
1 · target	+0.000 [-0.000, +0.000]	**+0.531** **[+0.520, +0.541]**	**+0.531** **[+0.521, +0.541]**
1 · control	+0.000 [-0.000, +0.001]	**+0.202** **[+0.191, +0.212]**	**+0.202** **[+0.191, +0.212]**
1 · 目标−对照 target − control		**+0.222** **[+0.206, +0.238]**	**+0.222** **[+0.207, +0.238]**
2 · target	**+0.173** **[+0.163, +0.183]**	**+0.454** **[+0.443, +0.463]**	**+0.405** **[+0.395, +0.415]**
2 · control	**+0.118** **[+0.106, +0.131]**	**+0.203** **[+0.191, +0.214]**	**+0.156** **[+0.144, +0.167]**
2 · 目标−对照 target − control		**+0.194** **[+0.176, +0.210]**	**+0.151** **[+0.134, +0.167]**
3 · target	**+0.229** **[+0.218, +0.241]**	**+0.421** **[+0.409, +0.432]**	**+0.331** **[+0.319, +0.342]**
3 · control	**+0.164** **[+0.148, +0.179]**	**+0.195** **[+0.182, +0.209]**	**+0.125** **[+0.114, +0.136]**

作者位置 · 组	连写带来的提升（真标题）gain	标题特异 · 单独	标题特异 · 连写
3 · 目标−对照 target − control		+0.179 [+0.159, +0.199]	+0.124 [+0.106, +0.141]
4+ · target	+0.234 [+0.223, +0.245]	+0.421 [+0.409, +0.431]	+0.260 [+0.250, +0.270]
4+ · control	+0.183 [+0.166, +0.201]	+0.202 [+0.188, +0.217]	+0.106 [+0.094, +0.118]
4+ · 目标−对照 target − control		+0.169 [+0.147, +0.189]	+0.114 [+0.097, +0.130]

小结。论文特有的信息从 L24 起在标题位置逐渐形成，在 L44–L52 汇集到名字位置（注意力在 L48 读入，MLP 在 L52–56 接手），比它在名字位置变得可读（L56–62）早了约 5–10 层；标题最后一个 token 上已有可被线性 probe 读出、属于这篇论文的作者信息，但不是现有 lens 能读的形式。目标组和对照组的时间点完全相同，目标组只是信号更强（真假差距 0.42 对 0.21）。GPU 自检里有两项一致性核对略低于阈值（GPU 批量计算的 bf16 舍入），不影响以上结果：L63 的替换恰好恢复 1（标题之后的位置）和 0（标题最后一个 token）。

> **Summary.** The paper-specific information forms gradually at the title position from L24 on and is gathered at the name positions in L44–L52 (attention reads it in at L48, MLPs take over at L52–56), about five to ten layers before it becomes readable at the name positions (L56–62); the last title token already carries paper-specific author information that a linear probe can decode, but not in a form the current lenses can read. Target and control share the same timing; target simply carries a stronger signal (true − false gap 0.42 vs 0.21). Two agreement checks in the GPU smoke test fell slightly below threshold because of bf16 rounding in batched GPU runs; they do not affect these results, as patching at L63 recovers exactly 1 (tokens after the title) and 0 (last title token).

> **代码 Code**：`~/jlens_work/11_stage11/361_stage11.py`（work 单元 patch / knockout / patch_title / knockout_name / titlepos / chain）、`stage11_analyze.py`
> **结果 Results**：`/scratch/zhang.zhiqi2/jlens/361_stage11/summary/E1*.csv, E2*.csv, E3_chain.csv, E4_*.csv` • `reports/stage11_report.md` • `config/protocol.json, protocol_amendment_1.json, sample.parquet`

6.12 名字先验（name prior）有多大？以及标题位置 probe 的对照检验 *How large is the name prior? And controls for the title-position probe* Stage 11 · CPU

拆解方法。同一批名字 token 在三种条件下打分：不给标题（只剩"名字本身好不好猜"，即名字先验）、给匹配的假标题、给真标题。三者之差分别是"主题"（假标题 − 不给标题）和"论文特有"（真标题 − 假标题）。下面是模型最终输出上的结果，单位 log10(1/名次)。

> **Decomposition.** The same name tokens are scored with no title (only how guessable the name is: the name prior), with matched false titles, and with the true title. The differences are "topic" (false − no title) and "paper-specific" (true − false). Values below are at the model output, in log10(1/rank).

token 类型 · 组	不给标题（先验）	假标题	真标题	论文特有
全部 token all tokens · target	-1.061	-1.189	-0.708	+0.481
全部 token all tokens · control	-1.150	-1.203	-1.004	+0.200

token 类型 · 组	不给标题（先验）	假标题	真标题	论文特有
姓的第一个 token surname 1st · target	-2.164	-2.302	-1.380	+0.921
姓的第一个 token surname 1st · control	-2.169	-2.208	-1.917	+0.291
姓的其余 surname rest · target	-0.812	-0.960	-0.242	+0.718
姓的其余 surname rest · control	-0.890	-0.943	-0.607	+0.336
名的第一个 token given 1st · target	-2.235	-2.417	-2.005	+0.412
名的第一个 token given 1st · control	-2.246	-2.324	-2.089	+0.236
首字母 initial · target	-0.871	-1.070	-0.924	+0.146
首字母 initial · control	-0.884	-1.004	-0.923	+0.081
标点 punctuation · target	-0.020	-0.032	-0.029	+0.003
标点 punctuation · control	-0.038	-0.048	-0.041	+0.007

名字先验很大，但集中在好猜的 token 上。不给标题时，正确名字平均已排在第 12 名左右（−1.09），因为标点、姓的后半段在给定前缀后本来就好猜。真标题让平均名次再好约 2.4 倍。真正需要"认识这篇论文"的是姓的第一个 token：目标组从约第 146 名提高到约第 24 名。首字母几乎只靠先验。

> **The name prior is large, but concentrated on easy tokens.** With no title the correct name already ranks about 12th on average (−1.09), because punctuation and the rest of a surname are easy once the prefix is given. The true title improves the average rank by about 2.4×. What really needs knowledge of the paper is the first surname token: for target papers from about rank 146 to rank 24. Initials depend almost only on the prior.

目标 − 对照（引用档内）	先验	主题	论文特有	真标题
全部 token all tokens	**+0.087** **[+0.070, +0.103]**	-0.047 [-0.055, -0.038]	**+0.207** **[+0.195, +0.220]**	**+0.247** **[+0.229, +0.265]**
姓的第一个 token surname 1st	+0.022 [-0.019, +0.063]	-0.055 [-0.072, -0.038]	**+0.423** **[+0.393, +0.454]**	**+0.391** **[+0.345, +0.435]**
姓的其余 surname rest	**+0.063** **[+0.028, +0.096]**	-0.076 [-0.094, -0.058]	**+0.279** **[+0.254, +0.305]**	**+0.266** **[+0.236, +0.296]**
名的第一个 token given 1st	+0.036 [-0.021, +0.090]	-0.060 [-0.086, -0.035]	**+0.180** **[+0.141, +0.220]**	**+0.156** **[+0.096, +0.217]**
首字母 initial	+0.010 [-0.011, +0.031]	-0.028 [-0.045, -0.012]	**+0.052** **[+0.033, +0.070]**	**+0.033** **[+0.010, +0.057]**

目标组和对照组的差距里有多少是先验？全部 token 上，真标题下的差距 +0.247 可以拆成：先验 +0.087（目标组的名字即使不给标题也略好猜），主题 −0.047（假标题把一部分拉回），论文特有 +0.207。所以以"不给标题"为基线时，先验约占差距的三分之一；以假标题为基线（本报告的标题特异信号）时，差距主要是论文特有的。在姓的第一个 token 上，先验差距约为 0（+0.022，区间跨过 0），论文特有 +0.42。

> **How much of the target − control gap is prior?** Over all tokens, the true-title gap of +0.247 splits into prior +0.087 (target names are a bit easier to guess even without a title), topic −0.047 (false titles take part of it back), and paper-specific +0.207. Against a no-title baseline the prior is about a third of the

> gap; against false titles (this report's title-specific signal) the gap is mainly paper-specific. On the first surname token the prior gap is about 0 (+0.022, CI includes 0) and the paper-specific part is +0.42.

先验会不会就是"认得出名单"的原因? 在写不全作者的论文里（R0/R1），按引用档中心化后，先验与多选题答对次数的 Spearman 相关只有 +0.085 [+0.063, +0.106]，而论文特有部分是 +0.329 [+0.312, +0.346]。所以"认出名单"主要不是名字好猜造成的。名字常见程度（姓在全部作者中的出现次数）与先验呈负相关（ρ = -0.215），目标组的姓反而略不常见：语料里常见的姓并不更容易被猜中，先验更可能来自名字的字面规律（前缀、拼写）而不是常见度。

> **Does the prior explain recognition?** Among papers whose author list the model cannot write (R0/R1), centred within citation bins, the Spearman correlation of the prior with multiple-choice orders right is only +0.085 [+0.063, +0.106], against +0.329 [+0.312, +0.346] for the paper-specific part, so recognition is mostly not driven by easy names. Name commonness (how often the surname appears among all cohort authors) correlates negatively with the prior (ρ = -0.215), and target surnames are slightly less common: common surnames are not easier to guess here, so the prior seems to come from the form of the name (prefix, spelling) more than from frequency.

标题位置 probe 的对照检验。 §6.11 中线性 probe 能在标题最后一个 token 上读出少量信号，当时担心它学到的只是"这类题目常配这类名字"。现在做了三个对照：把评分用的正确作者换成随机另一篇论文的作者、换成同领域另一篇论文的作者，信号都降为 0；只用假标题数据训练 probe，得到相近的信号 已复核（原表中“更强”来自泄漏：同一个借出标题同时出现在训练和测试里；按作者团队分折并剔除标题复用后，只用假标题训练为 L24 +0.050、L40 +0.057、L56 +0.074，与普通 probe 的 +0.050、+0.066、+0.080 相当或略低，见第四部分）。因此这部分信号是这篇论文特有的：两种置换对照在复核后仍约为 0，标题最后一个 token 上从 L24 起就有可被线性读出的、属于这篇论文的作者信息（目标组更多），只是现有 lens 读不出来。

> **Controls for the title-position probe.** §6.11 found a small probe signal at the last title token, with the concern that it might only be "this kind of title goes with these kinds of names". Three controls: scoring against the authors of a random other paper, or of a random paper in the same field, drops the signal to 0; training the probe only on false-title pairs makes it stronger. The signal is therefore specific to the paper: from L24 the last title token carries linearly decodable author information about this paper (more for target papers), which the current lenses cannot read.

层 · 对照	标题特异信号
L24 · 原 probe / probe (as in Stage 11)	[+0.
L24 · 答案换成随机另一篇论文的作者 / gold = random other paper	[-
L24 · 答案换成同领域另一篇论文的作者 / gold = random paper of the same field	[-
L24 · 只用假标题数据训练 probe / probe trained on FALSE-title pairs （未剔除泄漏，已被复核结果取代）	[+0.
L40 · 原 probe / probe (as in Stage 11)	[+0.
L40 · 答案换成随机另一篇论文的作者 / gold = random other paper	[-

层 · 对照	标题特异信号
L40 · 答案换成同领域另一篇论文的作者 / gold = random paper of the same field	[-
L40 · 只用假标题数据训练 probe / probe trained on FALSE-title pairs （未剔除泄漏，已被复核结果取代）	[+0.
L56 · 原 probe / probe (as in Stage 11)	[+0.
L56 · 答案换成随机另一篇论文的作者 / gold = random other paper	[-
L56 · 答案换成同领域另一篇论文的作者 / gold = random paper of the same field	[-
L56 · 只用假标题数据训练 probe / probe trained on FALSE-title pairs （未剔除泄漏，已被复核结果取代）	[+0.

> **代码 Code**：`~/jlens_work/12_stage12/stage12_cpu.py`
> **结果 Results**：`/scratch/zhang.zhiqi2/jlens/371_stage12/summary_cpu/A_*.csv, B_prior_vs_recognition.csv, C_surname_commonness.csv, X1_probe_controls.csv` • `reports/stage12_cpu_report.md`

6.13 只用 R0 论文的敏感性分析 *Sensitivity analysis with R0 papers only* Stage 10 + Stage 11 · CPU

target/control 把 R0（一个作者都没写对）和 R1（写对少数、HR2 > 0.5）合在一起。R1 在目标组有 511 篇（11%），在对照组只有 34 篇（1.5%），所以目标组的优势可能部分来自"本来就能写出部分作者"的论文。这里两组都只保留 R0（目标 4,110、对照 2,186；引用档内可比较的为 3,423 / 2,151），用同一套引用档内加权和 bootstrap 重算。**结论不变**：输出处标题特异的目标−对照差从 +0.207 变为 **+0.199 [0.188, 0.212]**（约小 4%），L62 各读出 +0.22；L24–L48 仍约为 0 或略负；去掉 0-4 低档后为 +0.204。只看真标题（不减假标题）也只从 +0.247 变为 +0.239。

> Target/control pool R0 (no true author written) and R1 (a few right, HR2 > 0.5). R1 makes up 511 targets (11%) but only 34 controls (1.5%), so part of the target advantage could come from papers whose authors the model can partly write. Here both groups keep R0 papers only (target 4,110, control 2,186; 3,423 / 2,151 in comparable bins), with the same within-bin weights and bootstrap. **The conclusions do not change**: the title-specific target − control difference at the output goes from +0.207 to **+0.199 [0.188, 0.212]** (about 4% smaller), +0.22 at L62 for every readout; L24–L48 stay about zero or slightly negative; +0.204 without bins 0-4. On the true title alone (no false-title subtraction) it goes from +0.247 to +0.239.

标题特异 目标−对照 Title-specific target − control	L24	L48	L56	L60	
logit · R0+R1	+0.007	+0.004	+0.065	+0.178	
logit · 只用 R0 / R0 only	+0.007	+0.003	**+0.063** [0.048, 0.078]	**+0.170** [0.149, 0.191]	[0.20
jlens_public · 只用 R0 / R0 only	−0.001	−0.039 [−0.053, −0.025]	+0.009	**+0.138** [0.117, 0.160]	[0.20
final · R0+R1					

标题特异 目标−对照 Title-specific target − control	L24	L48	L56	L60

final · 只用 R0 / R0 only

R1 论文确实更强：在目标组内部、引用档内比较，R1 比 R0 的输出标题特异信号高 **+0.110 [0.086, 0.135]**；但它们只占目标组 11%，对组间差的影响约 0.01。Stage 11 样本里 R1 只有 41 篇（目标 36、对照 5），只用 R0 后替换和阻断曲线几乎不变：替换恢复 L40 0.28 / 0.34（目标 / 对照）、L48 0.81 / 0.87、**L52 起 0.99–1.00**；从 L0 阻断损失 0.84 / 0.81，从 L52 起约 0。时间点仍然两组相同。

> R1 papers are indeed stronger: within target and within bins, their output title-specific signal is **+0.110 [0.086, 0.135]** above R0, but they are only 11% of the target group, so they move the group difference by about 0.01. The Stage 11 sample has only 41 R1 papers (36 target, 5 control); with R0 only the patching and knockout curves are almost unchanged: recovery 0.28 / 0.34 (target / control) at L40, 0.81 / 0.87 at L48, **0.99–1.00 from L52**; knockout from L0 loses 0.84 / 0.81, about 0 from L52. The timing is still the same in both groups.

> **代码 Code**：`~/jlens_work/10_stage10/stage10_extra_r0.py`（复用冻结的 `351_stage10.py stratified_diff` 和 `stage11_analyze.py`）
> **结果 Results**：`/scratch/zhang.zhiqi2/jlens/351_stage10/summary_r0/*.csv` · `/scratch/zhang.zhiqi2/jlens/361_stage11/summary_r0/*.csv` · `/scratch/zhang.zhiqi2/jlens/351_stage10/reports/r0_sensitivity.md`

§7 结论 *Conclusions*

1. Qwen3-32B 对具体论文作者的知识在网络中形成得很晚，而且是逐层积累的：目标−对照的标题特异差从 L50 前后开始出现，在 L57–L61 上升最快，在 L62 和输出处最强。

   Qwen3-32B's knowledge of a specific paper's authors forms late and gradually: the target − control title-specific difference appears around L50, rises fastest over L57–L61, and is strongest at L62 and the output.

2. 干预实验（Stage 11–13）显示，论文信息从 L24 起在标题位置逐渐形成，在 L44–L52 汇集到名字位置，L52 之后不再需要标题（control 组到 L54–56；对 5 个假标题都成立）；只是要到 L56–62 才能在名字位置被 lens 读出。

   Interventions (Stages 11–13) show that the paper information forms gradually at the title position from L24 on and is gathered at the name positions in L44–L52; the title is no longer needed after L52 (L54–56 for control; the same for all 5 false titles); it only becomes lens-readable at the name positions in L56–62.

3. **读得早，说得晚。**在名字位置用 lens 读，"写不全但认得出"的目标组在中间层没有领先，相对对照组的优势只出现在最后两层。但在标题最后一个 token 上，线性 probe 从 L24 起就能读出少量这篇论文特有的作者信息（+0.05 到 +0.08），目标组比对照组高（+0.04 到 +0.08，置信区间在 0 以上）已复核（按作者团队分折、剔除标题复用后复核）。两者并不矛盾：标题从 L24 起在标题位置逐渐形成、L44–52 汇集到名字位置，只是还不是 lens 能在名字位置读出的形式。

   Read early, spoken late. Read with a lens at the name positions, target papers (cannot write the list but recognise it) have no lead in the middle layers; their advantage over control appears only in the last two layers. At the last title token, however, a linear probe reads a small amount of paper-

specific author information from L24 on (+0.05 to +0.08), more for target papers (target − control +0.04 to +0.08, CIs above zero; re-checked with team folds and title reuse removed). The two fit together: the information forms at the title from L24 on and is gathered at the name positions in L44–52, but not yet in a form a lens can read there.

4 这一优势几乎全部是标题特异的，在去掉低引用档后依然成立，不能用名字好猜或引用数差异来解释；两组都只保留 R0（一个作者都没写对）后，输出处的差从 +0.207 变为 +0.199，结论不变（§6.13）。

That advantage is almost entirely title-specific and survives dropping the low-citation bins, so it is not explained by guessable names or citation differences; with R0 papers only (no author written) in both groups it goes from +0.207 to +0.199 at the output, the same conclusion (§6.13).

5 Jacobian lens 能让中间层读出更多与名字相关的信息，但这部分信息不区分论文；三种 Jacobian lens 的结论一致。

Jacobian lenses read more name-related information from middle layers than the logit lens, but that information is not paper-specific; all three Jacobian lenses agree.

6 标题特异信号在名字里的分布取决于格式：首字母几乎不带信号，信号集中在后面的姓上；完整的名本身就带有和姓相当的信号。知道第 1 个 token 后，后续 token 总体只容易一点（+0.04）；但完整的名进前 10 时，姓明显更容易（+0.22），首字母则没有这种帮助。

Where the title-specific signal sits within a name depends on the format: an initial carries almost none and the signal concentrates on the surname after it, while a full given name carries about as much as the surname. Knowing the first token makes later tokens only slightly easier overall (+0.04), but a full given name in the top 10 makes the surname clearly easier (+0.22), while an initial does not.

7 引用越低，模型越不认识论文：标题特异信号随引用数单调上升（目标组从 +0.35 到 +0.64），在两组内部都成立。

The fewer the citations, the less the model knows the paper: the title-specific signal rises monotonically with citations (target group from +0.35 to +0.64), within both groups.

8 没有哪种 lens 能在中间层读出偏向目标组的论文信息；Jacobian lens 在中间层多出的那点标题特异信号很小，对照组反而略多。

No lens reads target-favouring paper information in middle layers; the small extra title-specific signal of the Jacobian lenses there is, if anything, larger for control papers.

§8 局限 *Limitations*

- **测的是打分，不是生成。**Stage 10–12 的所有实验都是把正确名字放进去（教师强制），看模型给它打多少分；可目标组里很多论文，模型实际上一个作者都写不对。所以结论说的是“模型内部对正确作者的倾向”，不是“模型生成作者的过程”。
  Scoring, not generation: every experiment in Stages 10–12 feeds the correct name (teacher forcing) and measures how the model scores it, while for many target papers the model writes no correct author at all. The results describe the model's internal preference for the correct authors, not the process by which it generates authors.
- **只用了一个模型。**全部结论来自 Qwen3-32B，层号是它特有的。换一个模型，层的位置肯定不同，机制是否相同也不知道。

One model: every result comes from Qwen3-32B and the layer numbers are specific to it; in another model the layers will differ, and whether the mechanism is the same is unknown.

- 一致性检查的容差在看到结果后从 0.25 放宽到 0.5。差异的形态符合 bf16 舍入，但这是事后调整，且该检查无法发现两条计算路径共有的错误。
  The parity tolerance was raised from 0.25 to 0.5 after seeing the results. The differences look like bf16 rounding, but the change is post hoc, and the check cannot catch an error shared by both computation paths.
- 分组来自同一模型的标注实验，只对 Qwen3-32B 有效；低引用档里的"认出"接近随机偏好，所以加做了去掉低档的敏感性分析。
  Groups come from a labelling run of the same model and hold for Qwen3-32B only; in low-citation bins recognition is close to a fixed preference, hence the sensitivity analysis without those bins.
- 高引用档几乎没有对照组论文（4097+ 档为 0），组间比较主要来自中低引用档。
  High-citation bins have almost no control papers (none in 4097+), so group contrasts come mostly from low and middle bins.
- 主分析中每位作者单独打分（接在 "Authors:" 后）。Stage 11 E3 已把全部作者连写（"Authors: A1, A2, ..."），检验了作者顺序和前面作者的帮助；但"谁和谁是合作者"（例如把某位作者换成第一作者的真实合作者）还没有在模型内部检验。
  In the main analysis each author is scored alone after "Authors:". Stage 11 E3 writes all authors in one chain ("Authors: A1, A2, ..."), which tests author order and the help from earlier authors; whether the model knows who co-authors with whom (e.g. swapping in a real co-author of the first author) is not yet tested inside the model.
- 目标组 11% 是 R1（写对少数作者）、对照组只有 1.5%，所以两组都写作"写不全（R0/R1）"而不是"写不出"；只用 R0 的敏感性分析见 §6.13，结论不变。
  11% of target papers are R1 (a few authors right) against 1.5% of controls, hence "cannot write the list (R0/R1)" rather than "cannot write"; the R0-only sensitivity analysis (§6.13) gives the same conclusions.
- 多选题分组有一定不稳定性：抽 500 篇换一批干扰项重测，通过与否的一致率为 83.6%（kappa 0.63），也就是约六分之一论文的分组会变。这会让目标组和对照组的差别被稀释，不改变结论方向。
  The multiple-choice grouping is not fully stable: on 500 papers re-asked with a second draw of distractors, the pass label agrees 83.6% of the time (kappa 0.63), so about one paper in six would change group. This dilutes the target – control difference rather than changing its direction.
- 标注包里没有开放回答的生成长度上限和 thinking 模式设置（在标注运行的 run.json 里），复现分组需要向组长取这份文件。如果当时没有关闭 thinking，模型会先"思考"一段再作答，可能影响 R0/R1/R2 的判定。
  The label package lacks the open answer's maximum generation length and thinking-mode setting (they are in the labelling run's run.json); reproducing the groups needs that file from the group lead. If thinking was not switched off, the model may have reasoned before answering, which could affect the R0/R1/R2 labels.
- 名次基于 bf16 输出的 logits，并列时按有利方向计（只数严格更大的 logit）。
  Ranks use bf16 logits; ties are counted favourably (only strictly greater logits count).
- 细层（L50–55、L57–61）只算了 public Jacobian lens 和 logit lens（self100 和 fitA 只拟合了 6–7 个层，要加细层需要重新拟合）；§6.7–6.9 的补充分析只用了主轮的 6 个层。

The fine layers (L50–55, L57–61) were computed for the public Jacobian lens and the logit lens only (self100 and fitA were fitted at 6–7 layers, so fine layers would need new fits); the follow-up analyses in §6.7–6.9 use the 6 main-round layers.

- Stage 11 的替换和阻断确定了标题信息被读取的时间（L24–L50）和路径（经过标题之后的 token），但还没有确定这些层内部具体由哪些注意力头或 MLP 完成
  Stage 11 patching and knockout fix when (L24–L50) and through which positions (the tokens after the title) the title is read, but not which attention heads or MLPs do it inside those layers
- 6.7 中"第 1 个 token 是否进前 10"的分组是观察性的，两组作者在名字格式、长度等方面不同；按名字格式分开后结论才稳定。
  The top-10 split in 6.7 is observational; the two sets of authors differ in name format and length, and the conclusion is stable only after separating name formats.

结果文件 Result files：`/scratch/zhang.zhiqi2/jlens/351_stage10/reports/stage10_report.md` · `reports/stage10_title_summary.md` · `summary/` · `summary_title/` · `reports/parity.json` · `reports/crosscheck_stage6.csv` · `summary_extra/`（§6.7–6.9，`stage10_extra.py`）

第三部分

跨阶段：R0/R1 分层分析与两阶段对照

Stage 1–9 只比 A vs B（都是 R0），Stage 10–11 比 target vs control（R0 + R1 合并）。这一部分把两者放到同一口径下。

Stage 10–11 A 这篇论文? R0/R1 分层分析

为什么要做：Stage 1–9 只比较 A（认得出 · R0）和 B（认不出 · R0），两组都一个作者也没写对；Stage 10–11 的 target/control 把 R0 和 R1（写对了一部分，但 HR2 > 0.5）合在一起。R1 在 target 中占 11%（C = 511 篇），在 control 中只占 1.5%（D = 34 篇），所以 target 的优势可能部分来自“本来就能写出部分作者”的论文。这里用 Stage 10 和 Stage 11 已有的结果重新分层，没有新跑 GPU。

	认得出（target）	认不出（control）	合计
R0：一个真作者都没写对	A = 4,110	B = 2,186	6,296
R1：写对一部分（HR2 > 0.5）	C = 511	D = 34	545
Stage 11 样本（替换、阻断）	A 557 · C 36	B 588 · D 5	1,186

方法。指标与 Stage 10 主分析相同：标题特异信号 = 真标题 − 5 个假标题平均，单位 log10(1/名次)，先对论文内的名字 token 平均。组间差只在同一引用档内比较，用冻结脚本的 stratified_diff（档内两组都 ≥ 30 篇，按 $n_a n_b/(n_a+n_b)$ 加权；R1 相关比较因为样本少放宽到每格 ≥ 10 篇），bootstrap 2,000 次。Stage 11 的替换和阻断曲线、标题位置 probe 直接按分组重新汇总，probe 的预测与 Stage 11 完全相同（同样的 5 折和正则化选择）。

1. 主分析只用 R0：A − B

结论不变。输出处的目标−对照标题特异差从合并口径的 +0.207 变为 **+0.199 [0.187, 0.212]**；L24–L48 仍约为 0（Jacobian lens 在 L48–L52 略负），从 L52 前后开始上升，L57–L61 最快，L62 为 +0.22。曲线形状和合并口径几乎重合。

标题特异 目标−对照（引用档内）	L24	L48	L52	L56	L58	L60	L62	输出
R0 口径（A − B），logit	+0.007	+0.003	+0.018	+0.063	+0.110	+0.170	+0.220 [0.205, 0.236]	**+0.199** [0.187, 0.212]
R0 口径，public lens	−0.001	−0.039	−0.038	+0.009	+0.053	+0.138	+0.221 [0.206, 0.236]	
R1 口径（C − B），logit	+0.010	+0.011	+0.030	+0.112	+0.204	+0.356	+0.390 [0.349, 0.432]	**+0.372** [0.342, 0.405]
R1 口径，public lens	−0.009	−0.162	−0.166	−0.073	+0.035	+0.253	+0.399 [0.361, 0.439]	
合并口径（target − control），logit	+0.007	+0.004	+0.018	+0.065	+0.114	+0.178	+0.229 [0.212, 0.245]	**+0.207** [0.195, 0.220]
合并口径，public lens	−0.002	−0.044	−0.043	+0.007	+0.054	+0.145	+0.230 [0.216, 0.246]	

可比较的论文数：R0 口径 A 3,423 / B 2,151；R1 口径 C 391 / B 885；合并口径 3,734 / 2,182。R1 口径用 R0 对照组作参照，因为 D 只有 34 篇，无法在引用档内比较。

Stage 11 只用 R0 后，替换和阻断曲线也几乎不变：替换“标题之后的 token”恢复比例，A / B 在 L40 为 0.28 / 0.34，L48 为 0.81 / 0.87，L52 起 0.99–1.02；从 L0 阻断对标题的注意力损失 0.84 / 0.81，从 L52 起约为 0。标题位置的线性 probe：R0 口径的目标−对照为 +0.02 到 +0.04（L16 +0.018，L32 +0.034，L56 +0.038，置信区间都在 0 以上），与合并口径相同。

2. 认得出的论文里：R1 vs R0（C vs A）

R1 论文确实更强，但强在最后几层，时间点与 R0 相同。在目标组内部、引用档内比较（C 485 / A 3,204）：

C − A（引用档内）	L48	L52	L56	L58	L60	L62	输出
标题特异，logit	−0.003	+0.012	+0.042 [0.017, 0.067]	+0.070	+0.133	+0.096	**+0.110** [0.086, 0.133]
标题特异，public lens	−0.085	−0.064	−0.046	−0.019	+0.066	+0.103	
只看姓的第一个 token，标题特异	−0.009		+0.147			+0.321	+0.304 [0.232, 0.372]
不给标题（名字先验）	+0.015		+0.046			+0.040	+0.021 [−0.001, 0.044]

要点：C 比 A 多出的部分几乎都是标题特异的（名字先验的差在输出处只有 +0.02，置信区间含 0），集中在姓上；中间层没有领先，Jacobian lens 在 L48–L56 甚至为负。Stage 11 中 C（36 篇）的替换恢复稍晚：L40 恢复 0.16 [0.12, 0.21]，A 为 0.28；L48 为 0.72 / 0.81；到 L52 两者都恢复 0.97 以上。从 L48 起阻断，C 仍损失 0.11，A 为 0.06。也就是说，R1 论文的标题信息被读取得略晚一点，但完成时间相同。C 只有 36 篇，这一点只作描述。

3. control R1（D，34 篇）：只做描述

分组（不做引用档调整）	logit L56	logit L60	logit L62	输出
A 认得出 · R0（4,110）	+0.177	+0.470	+0.563	+0.463 [0.455, 0.470]
B 认不出 · R0（2,186）	+0.101	+0.231	+0.251	+0.198 [0.190, 0.207]
C 认得出 · R1（511）	+0.233	+0.663	+0.737	+0.627 [0.606, 0.649]
D 认不出 · R1（34）	+0.249	+0.395	+0.324	+0.279 [0.224, 0.332]

D 介于 B 和 A 之间：能写对部分作者但认不出整份名单的论文，标题特异信号比 B 略高，远低于 A 和 C。D 在 Stage 11 样本里只有 5 篇，不做分析。

4. R1 论文内部：写对的作者 vs 没写对的作者

标注包里没有这项信息。开放回答的结果（open_results.jsonl）只记录每篇论文写对的人数 m，没有记录是哪几位作者。我们按“姓 + 名的首字母，先按名在前、再按姓在前（如 “Sakaguchi Shimon”“Tounsi A”），一一对应”重建了匹配。重建出的人数与标注包的 m 一致的比例：R0 99.9%、R1 99.3%、R2 98.1%。只使用一致的论文：R1 的 target/control 论文 541 篇，打分的作者 2,945 位（其中 701 位写对）；同时有写对和没写对作者的论文 495 篇。写对的作者有 29% 是第一作者（全部作者中第一作者占 18%），所以另做了去掉第一作者的版本。

比较方式：在同一篇论文内，写对的作者平均减没写对的作者平均，再对论文平均，bootstrap 重抽论文。

写对 − 没写对（论文内配对，495 篇）	L48	L52	L54	L56	L58	L60	L61	输出
标题特异，logit	−0.007	+0.019	+0.046	+0.136	+0.217	+0.314	+0.349	**+0.199** [0.168, 0.232]
标题特异，public lens	−0.003	+0.018	+0.038	+0.120	+0.191	+0.276	+0.276	
去掉第一作者（333 篇），logit	−0.008	+0.022	+0.046	+0.140	+0.222	+0.297	+0.338	+0.204 [0.165, 0.241]
不给标题（名字先验），logit	−0.011	+0.006	+0.038	+0.062	+0.094	+0.137	+0.144	+0.097 [0.060, 0.134]

结果：模型在开放回答里真正写出来的作者，输出处的标题特异信号比同一篇论文里没写出的作者高 +0.20；但这个差在 L52 之前约为 0，从 L54 开始上升，L57–L61 最快，与全组的时间点完全相同。写对的作者名字本身也更好猜（不给标题时输出处 +0.10；public lens 在 L24–L48 也有 +0.05 到 +0.10），但这是名字先验，不随标题变化；减去假标题后的标题特异差在中间层约为 0。所以即使是模型确实能说出来的作者，论文特异的作者信息也只在最后几层出现。

5. 三种口径并列：结论变了吗?

问题	R0 口径（A − B）	R1 口径（C − B）	合并口径（target − control）	结论
中间层（L24–L48）有没有目标优势	没有（logit ≈ 0，Jacobian 略负）	没有（Jacobian 在 L48–56 更负）	没有	不变
优势从哪层开始	L52 前后，L57–61 最快	L52 前后，L56–60 最快	L52 前后，L57–61 最快	不变
输出处大小	+0.199 [0.187, 0.212]	+0.372 [0.342, 0.405]	+0.207 [0.195, 0.220]	R1 更大，合并口径几乎等于 R0
标题在哪几层被读取（替换）	L24–L50，L52 完成	同样 L52 完成，L40–48 略慢（n = 36）	L24–L50，L52 完成	不变
标题位置 probe 的目标优势	+0.02 到 +0.04	+0.02 到 +0.05（区间较宽）	+0.02 到 +0.04	不变

> **结论**
>
> 只用和 Stage 1–9 相同的 A/B 分组（都是 R0），所有结论都成立：目标组的优势真实存在、几乎全部是标题特异的、只在最后几层出现。R1 论文让优势更大，但不改变时间点；在 R1 论文内部，模型写对的作者也是在最后几层才领先。之前“合并 R0 与 R1 可能夸大目标组优势”的担心可以排除：合并口径与 R0 口径只差约 0.01。

代码：~/jlens_work/10_stage10/stage10_extra_r0r1.py（CPU 作业 11429580，复用冻结的 351_stage10.py stratified_diff 和 stage11_analyze.py）。结果：/scratch/zhang.zhiqi2/jlens/351_stage10/summary_r0r1/*.csv、R1_author_hits.csv、

R1_author_scores.parquet；/scratch/zhang.zhiqi2/jlens/361_stage11/summary_r0r1/stage11_curves_by_recall.csv、E4b_probe_by_recall.csv；报告 351_stage10/reports/r0_r1_analysis.md。

两阶段对照（Stage 1–9 与 Stage 10–11）

设计上改了什么

方面	Stage 1–9	Stage 10–11
样本	Pilot50、200 篇新论文	全部 9,108 篇，33,811 位作者，149,999 个名字 token
指标	金标准 vs 1 或 100 个错误名字（logit 差、胜率）	全词表名次 log10(1/名次)
分组	A vs B（都是 R0），逐对匹配	target = A + C = 4,621 vs control = B + D = 2,220（R0 + R1），引用档内比较
标题对照	1 个交叉标题或 20 个打乱标题	5 个匹配假标题 + 删除标题
层	7 层积分或 L56	全部层报告，加细层 L50–61
质量控制	实现检查、bootstrap	parity、与 Stage 6 交叉核对、输入 sha256 冻结

结论上变了什么

发现	Stage 1–9	Stage 10–11	判断
真标题有帮助	Pilot +9.3 pp，新 200 篇 +5.2 pp	L62 标题特异信号约 0.44	确认
认得出 > 认不出	不确定，依赖少数对	输出 +0.21 [0.20, 0.22]，中间层约 0	确认，但只在最后几层
关键层	L56	L56 开始，L57–61 上升最快；标题在 L24–50 被读取	细化
J-Lens vs Vanilla	无优势	中间层读出更多“名字形状”，不读出论文身份	一致
第一个 token vs 后续	差异在后续 token	由名字格式解释：首字母开头时姓是后续 token	解释
引用数	低–高不确定	随引用单调上升，ρ = 0.45	解决
lens 稳定性	一次 split-half；Stage 9 只完成 Fit A	三种 Jacobian lens 结论一致	仍需核实

小样本阶段提醒我们要注意的问题

- **单篇杠杆**：Stage 4 中一篇论文占 L56 均值的 71%。

- **尾部驱动**：Stage 8 A–B 去掉 10/100 对后消失。
- **分叉路径**：L56 被反复查看后定为主终点。
- **候选伪影**：100 个错误名字只有约 46 个不同首 token，约 3% 与金标准平局。
- **标签噪声**：0–2 引用档严格通过率 25.5%。
- **覆盖不全**：第一作者代替整个团队。
- **指标选择**：KL 保真度与作者排名不一致。
- **协议漂移**：主终点在 README 与执行之间改变。

Stage 10 通过设计逐一应对：全量论文、全部作者和 token、报告所有层、全词表名次、引用档内比较、冻结输入并做 parity 检查。无法通过设计解决的是：分组仍来自同一模型的一次标注。

> **可比性：已核对**
>
> Stage 1–9 的 A/B 都是 R0，Stage 10–11 的 target/control 合并了 R0 与 R1。在 Stage 10–11 上只保留 R0 后（上一节），结论不变：输出处 +0.199 vs +0.207，各层形状相同，Stage 11 曲线也不变。

第四部分

Stage 13：中间层到底表示什么

lens 读不出不等于信息不存在：中间层可能在表示任务或论文身份，而不是名字。计划、预测和进展都在这里更新。

Stage 12 C 哪一层 D 名字 正式结果：单个位置、注意力与 MLP、名字先验、作者提示 lens

2026-10-28 20:00 全部 408 个单元完成，由 analyze 作业自动汇总（`371_stage12/reports/stage12_report.md`）。区间是按论文的 bootstrap 95% 置信区间。P1 和 P2 的正式数字与下文“审查”一节引用的 CPU 预览相同。

P1 哪个位置带着论文信息（真标题 → false_0，只替换一个位置，恢复比例）

替换的位置	L44	L48	L50	L52	L56
“:”（p1）	+0.011	+0.074	+0.157	**+0.172**	+0.130
年份第三位数字（p5）	**+0.071**	+0.062	+0.035	+0.027	−0.000
标题的右引号（p9）	+0.027	+0.011	+0.004	+0.002	−0.000
其余单个位置（p2–p4、p6–p8）	都 ⩽ 0.008				
全部名字位置	+0.236	+0.612	+0.726	**+0.847**	+0.878
整个提示（= Stage 11 E1）	+0.429	+0.825	+0.933	+0.996	+0.999

论文信息在 L44–L48 离开标题，替换后能恢复的部分主要在名字位置本身；标题之后的单个 token 最多只带 “:” 的 0.17。这和 Stage 11 E2n（挡住 “:” 和名字位置直接看标题，最多只损失 15%）合起来看，信息是分散的、多条路径的，不是集中在某一个“笔记本”token 上。

P2 注意力还是 MLP（只替换一层的一个组件输出，作用于标题之后的全部 token）

层	注意力	MLP
L8–L44	都 ⩽ 0.023（L24 注意力 +0.023 最大）	
L48	**+0.231** [0.221, 0.244]	+0.068
L52	+0.109	**+0.178** [0.168, 0.190]
L56	+0.058	**+0.224** [0.208, 0.239]

先是 L48 的注意力把标题信息读进来，然后 L52–L56 的 MLP 接着处理。单层替换只能给出下限，因为信息可能分散在好几层。MLP 这一步究竟是在“查记忆”还是只在“变换格式”，这个实验分不开。

N1、N2 名字本身好不好猜

- **N1 多选选项先验**：不给标题时，真作者列表在 4 个选项里“最像真的”的比例是 0.255，和随机的 0.25 一样，margin +0.004 [−0.002, +0.009]。给了真标题后升到 0.625。多选题答对靠的不是名字听起来更像。
- **N2 纯名字先验**（提示里完全没有论文）：同 bin 内 target − control 只有 +0.047 [0.031, 0.062]，没有标题时是 +0.087，有真标题时是 +0.247。先验约占真标题差距的 19%（按无标题提示算是 35%），和 Stage 10 的“名字先验约占 1/3”一致。

F2 用作者提示拟合的 lens

在名字位置上，L24–L56 的 target − control 都 ⩽ 0（L44–L52 为 −0.04 到 −0.06，置信区间不含 0），只有 L62 是 +0.238。在标题位置上，除 L56（+0.030 [0.000, 0.060]）外，置信区间都包含 0 或为负。也就是说，换成在作者提示上拟合的 lens，中间层仍然读不出“这篇论文特有”的作者信号。这支持 B 线“读出工具读不到”的结论，但仍然不能说明信息不存在（见 Stage 13）。

已改写（2026-10-30，用户同意）：原先“论文信息被搬到标题之后的 token 上”这一说法（§1、§6.11、§7）已按 P1、X6、X7 的结果改为“从 L24 起在标题位置逐渐形成，在 L44–L52 汇集到名字位置”，“待复核”标记已去掉。

Stage 13 · X6 C 哪一层

Stage 11 的替换结果换成其他 4 个假标题后仍然成立

2026-10-29 00:50 完成，97 个 GPU 单元，规则见预注册补充 3。自检：把 5 个假标题都换成 Stage 11 的同一份数据时，算出的结果与 Stage 11 E1 完全一致（最大差 2×10^{-16}）。另外，X6 重算的 false_0 第 0 分片与 Stage 11 原始结果逐个排名相同。区间是按作者团队重抽的 bootstrap，5 个假标题共用同一组抽样。报告：`381_stage13/reports/x6_report.md`

组	L48：false_0	L48：5 个假标题范围	L48：平均	L52：平均	预注册判定
target	0.803	0.788–0.803	0.794 [0.777, 0.811]	0.987 [0.981, 0.993]	成立
control	0.866	0.864–0.885	0.876 [0.847, 0.904]	1.012 [1.001, 1.024]	成立
全部	0.825	0.813–0.825	0.821 [0.806, 0.835]	0.995 [0.990, 1.001]	成立

成立的条件是：平均恢复率 L48 在 0.70–0.95 之间，L52 ⩾ 0.95；每个假标题的 L48 与 false_0 相差不超过 0.10，L52 ⩾ 0.90。三组全部满足，各假标题之间的差都不超过 0.02。所以 §6.11 的“L48 恢复约 80–87%，L52 起 100%”不是 false_0 特有的结果。所有层的数字见 `summary_x6/x6_recovery.csv`。

按名字 token 角色拆开（补充 4 要求，2026-10-31，作业 11512706）

角色（全部论文）	L48 的 R	L52	L48 角色 − 合计	预注册判定（target / control / 全部）
合计	0.821 [0.806, 0.835]	0.995	—	成立 / 成立 / 成立
名字第一个 token（首字母或名）	0.791 [0.738, 0.849]	1.045	−0.030 [−0.077, +0.021]	成立 / 成立 / 成立
姓的第一个 token	0.734 [0.711, 0.757]	0.971	−0.087 [−0.104, −0.070]	**差一点不成立**（target L48 为 0.696，界线 0.70）/ 成立 / 成立
姓的后续 token	0.893 [0.880, 0.906]	0.997	+0.072 [+0.057, +0.087]	成立 / 成立 / 成立

标点的真假差距只有 0.006–0.018，低于 0.05，不报告比例。各角色在 5 个假标题之间 L48 的差都不超过 0.076。角色之间的差别只在 L48 恢复了多少：姓的第一个 token 和完整的名恢复得晚一些（完整的名 L48 只有 0.63，作为次要角色报告），姓的后续 token 早一些；“L48 约 80%”是这些角色的平均。到 L52 各角色都 ⩾ 0.96，L56 都是 1.00。381_stage13/reports/x6x7_roles.md

Stage 13 · X7 C 哪一层

阻断实验扣除“模型被带偏”的影响之后

2026-10-29 07:30 完成，24 个 GPU 单元，1,186 篇论文，规则见预注册补充 3。做法是把 Stage 11 的阻断（从第 l 层起禁止看标题）也用在假标题运行上，仍然给真作者打分。T = 真标题运行的损失（与 Stage 11 E2 一致，最大差 1×10^{-16}），F = 假标题运行的损失，S = T − F 是这篇论文特有的损失，都除以“真标题 − 假标题”的差。区间按作者团队重抽。WARN：

假标题运行中“不阻断”的那一列只有 60% 的行与 Stage 11 假标题运行完全相同，平均差 0.010 个 log10 名次、没有方向性，和 Stage 11 记录过的批量计算舍入差异同一量级。报告：381_stage13/reports/x7_report.md

从哪层起阻断	target：T	target：F	target：S	control：S	全部：S
L0	0.839	−0.161	1.000 [0.994, 1.006]	1.012	1.004
L24	0.708	−0.157	0.865	0.889	0.873
L32	0.357	−0.167	0.524	0.626	0.558
L40	0.139	−0.132	0.271	0.335	0.293
L48	0.066	−0.065	0.130	0.168	0.143
L50	0.020	−0.030	0.050	0.089	0.064
L52	0.006	−0.013	0.018 [0.010, 0.027]	0.051 [0.033, 0.068]	0.029 [0.021, 0.038]
L54 及以后	S 都在 ±0.02 以内				

F 是负的：在假标题运行里阻断标题，真作者的得分反而上升，因为挡掉的是一个误导性的标题。所以 Stage 11 从 L0 阻断时的 83% 损失其实低估了：扣除假标题运行之后，这篇论文特有的损失 S(L0) ≈ 1.0，也就是标题带来的论文特有信号被全部去掉。

预注册判定（S(L52) ⩽ 0.05 且 S(L0) ⩾ 0.5）：target 成立（S(L52) = 0.018），全部论文成立（0.029），**control 差一点不成立**（0.051，阈值 0.05；区间 [0.033, 0.068]）。control 组在 L52 还剩约 5% 的论文特有损失，L54 降到 0.018，L56 起为 0。所以“L52 之后不再需要标题”对 target 和全部论文成立；对 control，更准确的说法是“到 L54–56 才完全不需要”。

按名字 token 角色拆开（2026-10-31，作业 11512706）：全部论文的 S(L52)，名字第一个 token 0.029 [−0.017, 0.075]，姓的第一个 token 0.032 [0.021, 0.043]，姓的后续 token 0.031 [0.022, 0.041]，与合计 0.029 都没有差别（差值区间都含 0）。target 和全部论文在三个角色上都成立；control 本来就差一点不成立（0.051），拆开后名字第一个 token 0.078、姓的后续 token 0.052 不成立，姓的第一个 token 0.049 刚好成立。所以 control 的“差一点”是合计层面的小效应，不是某一个角色造成的。381_stage13/reports/x6x7_roles.md

Stage 13 · M3 X1 X4 B 读出工具 C 哪一层

中间层的标题状态：是“这篇论文”，还是“这个问题”？

2026-10-29 完成。规则见 prereg.json 及补充 1、2：探针按作者团队分 5 折；X1、X4 在按团队划分的调参集上选层、在测试集上确认；区间均为按作者团队重抽的 bootstrap。报告：381_stage13/reports/m3_report.md、x1_report.md、x4_report.md

M3 同一篇论文换三种问法（问作者 / 问年份 / 问领域），探针能否通用（9,108 篇）

迁移比 T = 在一种问法上训练、换另一种问法测试的成绩 ÷ 同一问法内训练和测试的成绩。补充 2 规定的主要指标是 L16–L40 的 T，并且要和 L4（只有文字信息的层）相比。

位置	年份 T：L4	年份 L16–L40	领域 T：L4	领域 L16–L40	T − T(L4)，L16–L40	判定（按补充 2）
标题最后一个 token	0.98	0.92–0.95	1.00	0.99	年份 −0.03 到 −0.06，引用数 −0.02 到 −0.05（区间都不含 0）；领域 −0.004 到 −0.007	不高于 L4 文字水平（年份、引用数低于 L4，领域与 L4 分不开）→ **M3 不支持 H2**
最后的 “:”	< 0	< 0	0.29	0.26–0.36	—	T < 0.5 → 判为“任务特定”（H1）

怎么读：三种问法只在标题前的 9 个 token 上不同，标题本身完全一样，所以标题位置的状态从 L4 起就主要由标题文字决定。T 在 L16–L40 一直 ⩾ 0.92，但补充 2 规定只看它相对 L4 的变化：年份的 T − T(L4) 为 −0.03 到 −0.06，引用数为 −0.02 到 −0.05，区间都不含 0；领域为 −0.004 到 −0.007，与 L4 分不开。也就是说，中间层并不比只有文字信息的 L4 更跨问法一致，T 高是因为三种问法里标题文字完全相同。所以 **M3 不支持 H2**：它只说明标题位置的表示不随问法改变，不能说明模型在标题处多出了文字以外的“论文身份”。（2026-10-31 更正：此前的自动判定按 T ⩾ 0.8 的绝对阈值写成“判为 H2”，不符合补充 2；已按补充 2 重写，见 `381_stage13/reports/m3_report.md` 末节，脚本 `13_stage13/stage13_m3_verdict2.py`。）到了 “:” 位置，状态已经按问题重新组织：用别的问法训练的探针预测年份和引用数，比直接猜平均值还差（R^2 为负，表中写作 < 0）。身份指数 I 在两个位置都低于 L4（标题位置 −0.003 到 −0.016，“:” 位置 −0.42 到 −0.61），同样不支持“高于文字水平”。完整数字见 `summary_m3/`。

X1 把 A 从“别的问法”得到的标题状态替换进 B 的作者提示（测试集 582 篇）

层	R 作者问法	R 年份问法	R 领域问法	R 随机论文 C	判定（补充 2）
L4–L16	1.00	1.00	1.00	−0.15 到 −0.13	只作文字替换的对照，不下结论
L24	0.99	0.99	0.99	−0.10	与任务无关
L32	0.97	0.97	0.97	−0.07	与任务无关
L40	0.92	0.92	0.92	−0.01	与任务无关
L48	0.42	0.41	0.42	+0.12	与任务无关（作者 − 年份 = +0.019）

L24–L48 各层，作者问法减年份问法、作者问法减领域问法都在 ±0.02 以内，区间在 [−0.1, 0.1] 之内；作者问法减随机 C 都 ⩾ +0.30，所以判为“与任务无关”。随机 C 的恢复率在 L4–L16 和 L48 的绝对值超过 0.1。2026-10-31 按 C 重算（每对论文先减去 C 的结果，R′ = R − R(C)；同一套团队 bootstrap，作业 11512702）：各问法的恢复率整体移动 −R(C)（测试集 L4–L32 上升约 0.07–0.15，L48 下降 0.12，L48 的 R′ 作者 0.30、年份 0.28、领域 0.29），但“作者 − 年份”“作者 − 领域”两个差值在减去同一个 C 后完全不变，所以按补充 2（区间在 [−0.1, 0.1] 内）L24–L48 的判定都不变。L48 有一点小而确实的任务依赖：作者 − 年份 +0.019 [+0.012, +0.026]、作者 − 领域 +0.008 [+0.001, +0.014]，区间不含 0；相对 C，年份问法保留作者问法效果的 94%，领域 97%。`381_stage13/reports/x1_vsC.md`三种问法下标题位置的状态并不相同：以“换一篇论文”的移动距离为 1，换问法让标题状态移动约 0.15（L24）、0.17（L40）、0.27（L48）；同一篇论文两种问法的余弦

为 0.98、0.98、0.95，两篇不同论文为 0.30–0.47（381_stage13/reports/x1_similarity.md）。所以准确的说法是：**问法让标题状态移动约 15–27%（以换论文为 1），但替换效果不变**。这个相似度与 M3 一样受“三种问法标题文字相同”的影响，只说明问法对标题状态影响小，**不能单独作为“论文身份”的证据**。对照：在 “:” 位置，换问法的移动距离是换论文的 3–5 倍。

X4 把论文自己的标题状态放进“X 的发表年份 / 第一作者 / 领域是”这类提示

答案	标题位置：最早可读出层（调参集选、测试集确认）	测试集 D	“:” 位置
第一作者	L8（已确认）	+0.046 [0.035, 0.059]，L40 最高 +0.068	L48 起 +0.012
年份	L40（已确认）	+0.013 [0.008, 0.018]	读不出
领域	调参集上读不出（区间很宽）	—	读不出

D = 用本论文的状态减去用配对论文的状态得到的答案得分（年份从不出现在提示里）。预注册的顺序（年份、领域不晚于作者）**不成立**：最先能读出的是第一作者，年份要到 L40 才能读出，而且很弱。也就是说，最早可解码的顺序是第一作者（L8）早于年份（L40），**与 H2 预测的方向相反**。在同一引用档内，认得出的论文（target）比 control 更容易读出作者：标题位置 L8–L40 高 +0.04 到 +0.06，区间都不含 0。年份没有这种差别。

X4 第一作者 L8：按 token 角色拆开，并与纯文本基线比较（2026-10-30）

原结果只存了名字各 token 的平均分，所以按 token 重新打分（作业 11500437）。用原来的批大小重算，4,712 个值与原分数完全相同；换一种批大小，L8 平均 D 为 +0.0490 对 +0.0484，只差 0.0006，批大小不影响结论。381_stage13/summary_x1x4/x4_rolesplit.csv

第一作者名字的 token	篇数	Qwen L8 的 D	Qwen L40 的 D	纯文本基线（BERT）
姓的第一个 token	1,178	+0.066 [0.045, 0.088]	+0.124 [0.099, 0.148]	阳性对照未通过，不可比
名的第一个 token（完整的名）	357	+0.018 [−0.003, 0.041]	+0.058 [0.035, 0.083]	+0.088 [0.020, 0.156]
首字母	880	+0.017 [0.006, 0.029]	+0.027 [0.016, 0.036]	—

结论（2026-10-30，用户确认的措辞）：在阳性对照通过的名字首 token 上（357 篇），纯文本基线（BERT）的自身优势（均值/标准差 0.13）不小于 Qwen 在同一 token 上的信号（L8 +0.018，0.09，区间含 0），两者逐篇几乎不相关（r = 0.07）。Qwen L8 的信号主要来自姓的首 token（+0.066 [0.045, 0.088]），而姓氏上文本基线的阳性对照没有通过，因此**不能排除** L8 的作者信号可以由标题文字解释。

Stage 13 · X3 C 哪一层

换一种说法的标题：模型表示的是意思、用词，还是这篇论文?

2026-10-31 完成。规则：prereg.json（X3）及补充 1、2、4、5。para_run 24 个分片（作业 11513313 分片 0、11385978 其余 23 个），分析作业 11521572，文本基线作业 11522507。主分析 1,110 篇（补充 5 的 1,115 篇中有 5 篇不在 pairs 表里），敏感性分析 1,012 篇。区间均为按作者团队重抽的 bootstrap。381_stage13/reports/x3_report.md、x3_textbase_recovery.md、x3_groupsplit.md

做法：用 Qwen3-32B 把标题改写成意思相同、用词不同的版本，比较原标题、改写、同领域里用词最接近的另一篇论文（近邻 D）在“作者是谁”提示中的表示和作者打分。主指标 G′ = cos(原, 改写) − cos(原, D)，只看它超出 L4 文字水平的部分 G′ − G′(L4)。

标题最后一个 token，测试集	L4 的 G′	G′ − G′(L4)，L28–L40	最高	L48	L60–L62
主分析（552 篇）	+0.30	+0.06 到 +0.16	L36 +0.159 [0.146, 0.171]	+0.013（区间含 0）	< 0
敏感性分析（506 篇）	+0.31	相近	L36 约 +0.16	—	< 0
有匹配近邻的子集（37 篇）	+0.12	—	+0.036（按规则的起始层）	—	—

L4 上 G′ 已有 +0.30，这来自用词：改写与原标题的词重合度（修正版 Jaccard）中位数 0.611，近邻 D 只有 0.154。所以近邻 D 在 94% 的论文上找不到“用词不少于改写”的候选：同领域里与原标题词重合超过 0.3 的论文只占 2.4%，而改写有 88% 超过 0.3；只有 66 篇改写本身用词变化很大（中位数 0.143），才有匹配的 D。按规则取“调参集上第一个显著的层”得到 L8（+0.012），敏感性分析是 L24，起始层不稳，不作为结论。

按 target / control 拆开（主分析，测试集）：L28–L40 两组几乎相同（L36：target +0.158，control +0.160，差 −0.002 [−0.027, +0.025]），L24–L48 各层两组之差的区间都含 0。认不认得这篇论文，对这个中间层优势没有影响。

文本模型基线（同样的 G′，减去各模型自己的文字基线层）：BERT 每一层都低于它的第 0 层（−0.06 到 −0.21），没有中间层优势；句子向量模型 all-mpnet 只在最后一层超出（+0.142 [0.129, 0.156]）。最大优势 ÷ 文字基线的 G′：Qwen 0.52 [0.46, 0.59]，mpnet 0.30，BERT 为负；但在用词匹配的 66 篇子集上，mpnet（1.40）与 Qwen（1.90）之差的区间含 0。mpnet 的训练语料可能见过这些标题，但没有作者信息。

行为（教师强制打分，第一作者）：改写 − D 为 +0.239 [0.212, 0.266]。换算成恢复比例（改写 − 假）÷（真 − 假），“真”为原标题、“假”为近邻 D（Stage 10 的 false_0 提示带年份，与 X3 的提示模板不同，所以不用）：全部 0.90 [0.87, 0.94]，target 0.90 [0.85, 0.94]，control 0.91 [0.84, 0.98]，两组之差 −0.01 [−0.09, +0.07]；有匹配近邻的子集 0.73 [0.57, 0.89]。

结论（2026-11-01 用户确认的措辞）：改写标题在 Qwen 中间层（L28–L40，最高 L36 +0.16）比用词相近的近邻 D 更接近原标题，超出 L4 文字水平；行为上改写保留了原标题对 D 约 90% 的第一作者偏好（教师强制打分）。但这不足以说明“论文身份”：只懂语义、不认识作者的句子向量模型（all-

mpnet）在用词匹配的子集上也有相当的优势；行为恢复和中间层优势在 target 与 control 之间都没有差别，与“认出论文”无关。所以 X3 只说明 Qwen 中间层表示了标题的意思而不只是用词，**不能区分“论文身份”与“语义”**。起始层在主分析和敏感性分析之间不一致（L8 对 L24），不作为结论。

与预注册的出入：补充 5 要求“按 token 角色”报告，但 para_run 只存了每个名字的平均分，无法按角色拆分。“:” 位置上各版本的余弦在 L4–L8 都接近 1，差距只有约 0.002，不作解读。

Stage 13 B 读出工具 C 哪一层 计划：中间层到底表示什么

计划写于 2026-10-28；状态随实验更新。

出发点

lens 读不出，只能说明“这种解码方式读不出”，不能说明信息不存在。logit lens 和三种 Jacobian lens 做的是同一件事：把某一层的表示直接翻译成“下一个词”，再看正确名字排第几。可是早期和中间层可能根本不在表示答案，而是在表示别的东西，比如“这是一个找作者的任务”“这篇论文是哪一篇”“接下来要输出人名格式”。这些信息可以真实存在，只是不在“名字”这个方向上，用名次去量自然量不出来。

现有数据支持这种看法：

- Stage 11 替换显示，论文信息在 L24–L50 就从标题被读走，搬到标题后面那几个 token 上（L48 恢复 83%，L52 起 100%）；从 L52 起阻断对标题的注意力已没有影响。
- 同一时期，在名字位置用 lens 几乎读不出作者（标题特异信号 L24–L48 约为 0）。
- 换成在标题最后一个 token 上训练的线性 probe，从 L16–L24 起就能读出少量这篇论文特有的作者信息（+0.04 到 +0.08），而且对照检验证明它是这篇论文特有的。

信息在动，只是还没变成“名字”的形式。这一阶段要回答：中间层表示的是任务、论文身份，还是以另一种形式存在的作者信息？这是 Line B（读出工具）和 Line C（哪一层）之间的新方向。

开跑前的数据来源审计

每个实验都先核对所用数据当时的提示词是什么、被分析的位置之前模型已经看到了什么，确认满足这个实验的条件，不满足的改设计或加对照。

数据	当时的提示词	分析位置之前模型看到了什么	对本实验的影响与处理
Stage 10 读出（M1）	Who are the authors of the paper titled "{标题}" ({年份})? \nAuthors: + 作者名	名字位置：标题、年份、前面的名字 token 都已看到	M1 只描述 lens 在这个提示下读到什么，不用来推断“是否知道年份”

数据	当时的提示词	分析位置之前模型看到了什么	对本实验的影响与处理
Stage 11 残差，标题最后一个 token（M2）	同上	只有前缀和标题。年份在标题之后，因果注意力看不到	年份、引用数、是否认得出在这里都是干净的：读得出就说明模型从标题认出了论文
Stage 11 残差，“:” 位置（M2）	同上	标题和年份都已看到	**年份在这里是泄题**，只作阳性对照并在表中标注。引用数和“是否认得出”可能借年份间接猜到，所以另报“只用年份能预测多少”的基线，以及去掉年份后再预测的版本。（这些控制是在 M2 作业开始后才加上的；作业 11438885 用的是旧脚本，按版本重算的是作业 11439283。）
Stage 11 残差，假标题 false_0	B 的标题 + **A 的年份**（年份保留不变）	标题位置：只有 B 的标题。“:” 位置：B 的标题 + A 的年份	B 和 A 的年份只有 17.5% 相同（平均差 2.2 年），所以在 “:” 位置上标签会冲突。假标题运行用 B 的标签，主要看标题位置
Stage 11 替换运行	带年份的旧提示词	—	不能直接用于 X1（跨任务需要三种问法对齐、且不含年份），X1 全部重新运行
M3、X1、X3、X4（新运行）	三种问法都不含年份；标题前都是 9 个 token	只有问题和标题	自动检查：模板前缀长度 = 9，提示里没有年份，“:” 位置的表示不受追加答案的影响。M3 的作者得分与 Stage 10 不可直接比较（少了年份），只在 M3 内部比较
X3 改写标题	模型生成	—	自动排除含年份、含作者姓、长度异常的改写；人工抽查通过后才运行
标签	领域、年份、引用数来自标注包（Semantic Scholar）	—	领域可以只靠标题用词推出，所以领域是“主题”基线；年份和引用数从标题推出才算“认出论文”

三种假设及其预测

假设	M1：lens 在中间层排第一的词	M2：probe 读非名字的属性	M3：换任务对照	目前结果（2026-11-01）
H1 任务 / 格式：中间层在表示“要输出作者名单”	多为 “author”、标点、名字常见开头，与标题无关	论文属性读不出或很弱	同一标题在不同问题下，中间层表示早早分开	见上文 M3、X1 结果
H2 论文身份：中间层在表示“是哪一篇论文”	与标题有关的词（照抄标题），换假标题就变	领域、年份（从标题推出）、引用数、是否认得出都读得出，且早于名字	不同问题下同一篇论文的表示在中间层相近，后期才按任务分开 **结果：**不高于 L4 文字水平，不支持	**M3 不支持；X3 显示中间层超出用词的语义表示，但不能与论文身份区分；H2 目前依据 M2 和 X1，其中 M2 的 Qwen 胜过 BERT 按补充 2 只作参考。**另外，X4 最早可解码的顺序是第一作者（L8）早于年份（L40），与 H2 预测的方向相反。

假设	M1：lens 在中间层排第一的词	M2：probe 读非名字的属性	M3：换任务对照	目前结果（2026-11-01）
H3 作者信息已在，只是不在词表方向	不一定	作者首 token 用 probe 读得出，lens 读不出	按作者训练的 probe 能跨任务迁移；作者专用 lens（M4）在中间层读得出名字	**文本基线不弱于 Qwen，不能排除文字解释，证据不足**（X4：名字首 token 上 BERT +0.088 ≥ Qwen L8 +0.018；L8 信号主要在姓上，见上文 X4）

三者不互斥。实验的目标是看每一层主要是哪一种，以及“论文身份”出现的层是否早于“名字”出现的层。

实验（2026-10-28 用户同意：全部写入并排队）

编号	做什么	数据与计算	状态
M1 lens 在读什么	Stage 10 每个名字 token、每种读出、每层都存了排第一的词。把它分类：正确的词 / 像人名开头的词（队列中任一作者名字的首 token）/ 标点与格式 / 任务词（author、paper、et、al 等）/ 从本题标题照抄的词 / 其他。另算：把真标题换成假标题后，排第一的词变了的比例（即使读错，读出是否随标题变）。	已有数据，CPU。真标题、假标题 false_0、删去标题三种条件；全部名字 token 与每个名字的首 token 分开统计。	CPU 作业 11438885 已提交
M2 probe 读非名字的东西	在 Stage 11 存下的残差上训练线性 probe（标题最后一个 token：L16–L60；“:” 位置：L16–L63；全部 9,108 篇）。目标：领域（8 类准确率）；发表年份（R^2，在标题最后一个 token 上模型还没读到年份，读得出就说明它从标题认出了论文）；引用数（R^2，“名气”）；是否认得出（target vs control，引用档内 AUROC）。每个目标都做打乱标签的对照；假标题 false_0	已有数据，CPU。5 折交叉验证（按论文分折），ridge，bootstrap 置信区间。	同上，CPU 作业 11438885

编号	做什么	数据与计算	状态
	的运行用标题所属论文的标签，检验 probe 读的是标题对应的论文。		
M3 换任务对照	同一个标题，三种问法，都不含年份：“作者是谁”（Authors:）、“哪一年发表”（Year:）、“属于什么研究领域”（Field:）。存标题最后一个 token 和最后“:” 的残差（L4–L63 共 15 层），并在输出处给真实年份和第一作者首 token 打分。分析：① 同一篇论文跨任务的相似度减不同论文的相似度（论文身份指数），按层画；② 在一种任务上训练的 probe（领域、年份、引用数、作者首 token）拿到另一种任务上测（跨任务迁移）；③ 任务本身能否从中间层读出。早期相同、后期分开 → 早期是“这篇论文”；早期就分开 → 早期是“任务”。	新 GPU 前向：9,108 篇 × 3 种问法 = 27,324 次前向，每次只做前向（约 1–2 GPU 小时），残差约 8 GB。tiny 模型试跑 14/14 通过。	已排队：接在 Stage 12 作业之后自动运行（Stage 12 没有可领单元时转交）
M4 作者专用 lens	Stage 12 正在用作者提示词拟合的 Jacobian lens（不是 WikiText）。如果它在中间层能读出名字而 WikiText lens 不能，说明信息在，只是换了基底。	Stage 12 F1/F2，GPU	拟合 35/40，进行中
X1 跨任务替换（因果）	（加随机对照 C：同标题长度、作者姓不重合的无关论文的状态 → B；调参集/测试集各半。）A 的“作者是谁”运行里，用同领域、标题 token 数相同、作者姓不重合的论文 B 的	Stage 11 样本中 1,178 篇有合格的 B；L4、8、16、24、32、40、48；GPU 约 1 小时	已排队（随 Stage 12 作业转交）

编号	做什么	数据与计算	状态
	标题作“损坏”运行。在第 l 层把所有标题位置的表示换成 A 的表示，来源分别是 A 在（a）作者问题、（b）年份问题、（c）领域问题下的运行，再看能否说出 A 的第一作者。（b）（c）的恢复程度和（a）一样：这一层标题上的表示与任务无关，就是“这篇论文”；只有（a）能恢复：表示已经带上了任务。三种问法在标题前都正好是 9 个 token，标题落在相同位置。		
X6 另外 4 个假标题补做替换（**最先跑**）	Stage 11 E1（把真标题运行中标题之后的 token 换进假标题运行）原来只用了 false_0。用 false_1–false_4 各重做一遍，代码就是 Stage 11 的原代码，只换假标题条件。“从末尾对齐替换”的长度按 Stage 11 冻结时的同一公式重算：对 false_0 重算与原值完全一致，其余 4 个也都合格。另用 false_0 重跑 1 个 shard，必须与 Stage 11 原结果逐个相同（复现检查）。判定（预注册补充 3）：5 个假标题平均，L48 恢复在 0.70–0.95 之间、L52 ⩾ 0.95，且每个假标题在 L48 与 false_0 相差 ⩽ 0.10、L52 ⩾ 0.90，Stage 11 的时间结论才算稳；否则把各假标题之间的差别作为时间点的不确定性报告。	4 × 24 个 shard，约 2 GPU 小时；tiny 模型试跑通过	已排在 Stage 13 GPU 单元最前面

编号	做什么	数据与计算	状态
X7 knockout 的对照（最后跑）	把同样的 knockout（从第 l 层起禁止看标题）加在假标题运行上，同样给真作者打分。假标题运行里本来就没有这篇论文的信息，所以它的损失只反映“被挡”本身带来的破坏。论文特有的损失 = 真标题运行的损失 − 假标题运行的损失，再除以真假差距。判定：L52 起论文特有损失 ⩽ 0.05，且 L0 ⩾ 0.5；并报告 L0 的 83% 损失扣掉“破坏”后还剩多少。	24 个 shard，约 15 GPU 分钟；tiny 模型试跑通过（“什么都不挡”的一列与普通假标题运行逐个相同）	排在最后
X2 只替换子空间（因果）	用 M2/M3 的 probe 找出“论文身份”方向（领域、年份、引用）和“作者首 token”方向，只替换或抹掉这些方向，看作者能否被带过去或被破坏。只换身份方向就够：作者是之后从身份算出来的（H2）；必须换作者方向：作者信息早已以非词表形式存在（H3）。	依赖 M3 的残差（不含年份的问法）；GPU 约 1 小时	等 M3 结果后排队
X3 同义改写 vs 近邻标题（Stage 13 中最关键）	（主要对照已改为词重合匹配的近邻 D，见第二轮审读。）先用 Qwen3-32B 把每个标题改写成意思相同、用词不同的版本（原始文本贪心生成，不用对话模板，避免 thinking）。自动检查：不含年份、不含作者姓、长度在原标题 0.5–2 倍之间；人工抽查通过后才开始正式运行。再比较原标题、改写标题、近邻标题 B（同领域、同长度）三者的各层表示和作者得分。某一层起改写标	Stage 11 样本；生成约 0.5 小时，正式运行约 1 小时	**已完成（2026-10-31），结果见上文 X3。**生成已完成（1,186 条）。2026-10-30 写定预注册补充 5（381_stage13/config/prereg_addendum5.json，sha256 181c72f7…b113ab）：主分析纳入通过自动检查且与原标题不完全相同的 1,115 条；敏感性分析再剔除 NLI 双向未通过和人工标为“改意思”的，剩 1,015 条；词重合度改用修正版 Jaccard（去停用词、任意长度、简单词形还原），近邻 D 按它重选；Qwen 判断器 v2 一致率 0.55 < 0.80，不用。40 条人工标注中“改意思” 6 条，0.15 [0.07, 0.29]（Wilson 95%），“边界” 7 条，0.175 [0.09, 0.32]。正式运行先跑 1 个分片核对，再放行其余。

编号	做什么	数据与计算	状态
	题比 B 更接近原标题，而且仍能说出作者：从这一层起表示的是“这篇论文”，而不只是主题词。		
X4 Patchscope（用模型自己解码）	把 A 在作者问题（不含年份）里标题最后一个 token 或 “:” 的第 l 层表示，注入中性提示 “Paper: X\n…” 中 X 的同一层位置，分别问发表年份、第一作者、研究领域，给真实答案打分。对照：注入 B 的表示，以及不注入。年份从不在 A 的提示里出现，所以能解码出年份只能来自模型认出了论文。比较三种答案各从哪一层开始可解码，就能看到“先认出论文、后想起作者”的顺序。	Stage 11 样本；L8–L56 共 7 层；GPU 约 1 小时	已排队（随 Stage 12 作业转交）
X5 层序量化	同一批论文上画三条曲线：论文身份能被检索（跨任务匹配到是哪一篇）、作者首 token 能被 probe 读出、名字能被 lens 读出，标出各自开始的层。	M3 + X4 + 已有数据；CPU	等 M3、X4

第 5 版审读后的处理（2026-10-28 12:30，预注册补充 2，sha256 377b7963…34205f）

按审读意见逐条处理，结论暂不改动，相关章节先标为“待复核”：

1. **E4b“只用假标题训练、信号反而更强”**：这一条用的是假标题运行，很可能与 M2 false_0 的泄漏相同（同一借出标题同时在训练和测试里）。
2. **标题一题两用**：B 的标题既是 B 的真标题，又借给 A 当假标题。按团队分组堵不住这条路。改为：测试 A 时，只要 probe 在训练中见过 A 提示里的标题，就把 A 从评分里去掉。具体两种情况：用真标题训练时，A 的假标题来源论文在训练集；用假标题训练时，同一借出标题或 A 自己的标题被训练论文用过。去掉前后都报告。随机分折时，约 80% 的测试论文会被去掉，剩 1,863 篇（目标 896、对照 499）。

3. **置信区间**

   ：所有区间改为按作者团队整体重抽，点估计不变，与原区间并列，并列出“区间是否含 0”发生变化的地方（作业 11443696，覆盖 6.2、6.3、6.4、R0/R1 和 Stage 11 的替换与阻断曲线）。

4. **M3**

   ：同一论文在三种问法下标题 token 完全相同，身份指数必然大于 0。改为必须高于 L4 的纯文字水平，主要判据改为跨任务迁移比。

5. **X1**

   ：早期层替换全部标题位置几乎等于替换标题文字，三种问法都会恢复。改为报告 R(作者) − R(年份)、R(作者) − R(领域) 的全层曲线；≤ L16 只作阳性对照，结论只看 L24 之后，不再挑单一层。

6. **M2c**

   ：只能单向使用。BERT 追平 Qwen 可以说明只是风格；Qwen 超过 BERT 只作参考，不能作为“认出论文”的证据。认出论文的证据必须来自 Qwen 内部：同一引用档内，认得出的论文是否比认不出的读得更准，且超出词袋基线已有的差别（目前看没有）。

7. **X3**

   ：要控制改写与原标题、近邻与原标题的词重合度（Jaccard 和共享生僻词比例），只看控制之后的差别。

8. **Stage 12 F1 作者 lens**

   ：拟合用 40 篇论文，按种子 12 从 Stage 11 样本以外的 target/control 论文中随机抽取，提示词是 Stage 10 的问题加上真实作者名单。这 40 篇与评估用的 Stage 11 样本（1,186 篇）没有相同论文，但原来没按团队分开：有 3 篇评估论文与拟合论文共享一个作者全名（qiang xu、j schwartz、j braun，可能只是同名）。评估时已把这 3 篇排除（371_stage12/config/alens_eval_exclude.json），不用重新拟合。

Stage 11“标题信息搬到标题后面的 token 上”这一说法的审查（2026-10-28 13:00）

逐条核对，结论暂不改动：

1. **“标题后面的 token”包含名字位置本身。**

   属实：E1 复制的是标题之后提示里剩下的全部 token（右引号、“ (”、年份数字、“)? \n”、“Authors”、“:”），再加上名字的 token。Stage 12 P1 已经逐个位置替换完（24/24），初步分析见下：

   - 只替换名字位置，在 L48 恢复 0.61，L52 恢复 0.85。
   - 只替换 “:”，在 L52 恢复 0.17。
   - 只替换年份中的一位数字（p5），最多恢复 0.07（L44）。
   - 其余单个位置都 ≤ 0.03。

也就是说，替换后能恢复的信息

主要在名字位置本身

，不在“笔记本”token 上。可是 E2n（禁止 “:” 和名字位置直接看标题）最多只损失 15%。两者合起来看：名字位置的状态里有最终需要的信息，但这些信息可以经由标题之后的 token 间接到达，而且分散在几个 token 上，单独替换哪一个都不够。“笔记本”的比喻需要改成：

最终在名字位置上算出来，路径可以经过标题之后的 token

。§6.11 中“搬到标题之后的 token 上”的说法已标为待复核；改写措辞要等 Stage 12 P1/P2 的正式分析（不是这次的 CPU 预览），合并 PPT 的“Keys and shelves”页第 ② 点和第 ④ 点到时一起改，现在不动。

2. **只用了一个假标题 false_0。**

   属实。Stage 10 对 5 个假标题取平均，Stage 11 只用匹配最好的一个。已排 X6（false_1–false_4 补做替换），优先级最高。

3. **“搬过来”和“在那里算出来”分不开。**

   属实。Stage 12 P2（单层注意力或 MLP 输出替换，24/24 已完成）初步结果：

   - L48 的注意力输出恢复 0.23（MLP 0.07）；
   - L52 和 L56 的 MLP 输出恢复 0.18 和 0.22（注意力 0.11 和 0.06）；
   - L8–L44 的单层组件都 ⩽ 0.03。

   看起来是 L48 左右由注意力把信息读进来，L52–L56 再由 MLP 加工。但单层替换只是下限，信息可能分散在多层。

4. **knockout 会把模型带到没见过的状态。**

   属实，从 L0 挡损失 83% 不能全算成标题信息的贡献。不过替换实验（E1）是在正常分布内做的，它给出的时间点（L48 恢复 83%，L52 起 100%）和 knockout 一致。已排 X7：把同样的 knockout 加在假标题运行上，看它本身造成多大的变化。因为 knockout 只是次要证据，X7 排在最后。

5. **恢复比例在差距小的论文上不稳定。**

   已核对：报告的恢复比例是“先对论文求平均，再算比例”（分子平均 ÷ 分母平均），是稳的那种。1,186 篇里有 10% 的真假差距 $|\text{gap}| < 0.05$，也有 10% 的差距为负，逐篇比例确实忽大忽小（例如 L52 有 13 篇超出 ±5）。L52 上，所用方法的结果是 0.996，逐篇比例的中位数是 0.988，逐篇比例的均值是 1.31（被极端值拉高）。所用方法与中位数一致。

6. **样本是抽样的**

   （593 + 593 篇，每个引用档两组至少 30 篇），高引用档基本没有对照组，结论主要来自中低引用档。属实，已写在 §8 局限里。

7. **年份在提示里，假标题运行保留了 A 的年份。**

   真标题和假标题运行里的年份 token 完全相同，所以“损坏”运行本身已经带着这份年份信息，恢复比例的分母（真 − 假）已经扣除了它。它不会把恢复比例抬高，但会让真假差距本身

偏小。

第二轮审读（2026-10-28 14:40，预注册补充 4，sha256 ac77da9f...2e6d193）

1. **测的是打分，不是生成。**

   同意。已写进 §8 局限；以后所有结论都表述为“模型内部对正确作者的倾向（教师强制打分）”，不说成“生成作者的过程”。

2. **名字的第一个 token 很多只是首字母。**

   已核对：P1、P2 和 Stage 11 的替换实验都对名字的

   全部

   token 打分（P1 共 19,077 个），不只看第一个。按 token 角色拆开（Stage 12 P1 的 CPU 预览，探索性结果）：

   - **名字第一个 token**

     （首字母或名，在 “:” 位置预测）：只替换 “:” 一个位置，首字母在 L48 恢复 0.50、L52 恢复 0.90；名在 L48 恢复 0.37、L52 恢复 0.95。替换名字位置对它几乎没影响。不过首字母的真假差距只有 0.11，信息量确实很少。

   - **姓**

     （第一个和后续 token，真假差距约 0.5，是信号主体）：只替换名字位置，姓第一个 token 在 L48 恢复 0.55、L52 恢复 0.92；替换 “:” 几乎为 0。

   - 标点的真假差距约为 0，比例没有意义。

   所以“名字位置恢复 0.85”主要来自姓：首字母的信息走 “:”，姓的信息在名字位置本身。以后所有替换和 probe 结果都按角色分开报告；真假差距小于 0.05 的角色不报告恢复比例。

3. **论文身份很难和标题字面意思分开，X3 最关键。**

   同意。X3 新增一个更硬的对照：

   词重合匹配近邻 D

   ，即同领域、作者姓不重合、与原标题的词重合度（Jaccard）不低于改写版的另一篇论文。主要比较改为“改写版 vs D”：改写版比 D 更接近原标题，而且这个差距在 L4 的文字水平之上，才算认的是论文、不是字面。原来的近邻 B 降为次要比较。tiny 模型试跑通过。

4. **只用了一个模型。**

   同意，已写进 §8 局限。

预注册（先写预测，再看数据）

2026-10-28 11:00 写定，文件 381_stage13/config/prereg.json（sha256 18409398…dce701，已设为只读）。写定时 M3、X1、X3、X4 还没有任何数据（GPU 单元 0/144），M2c 已提交但没有输出；M1、M2、M2b 已经跑完，它们只有第一版计划里的定性预测，下面的结果按这一点区分。共同规则：

- 报告所有层和位置，不只挑一层。

- X1、X3、X4 按论文分成调参集和测试集（各一半，目标组和对照组分别分）。选层、选位置只在调参集上做，正式结论用测试集上同一选择的数字。
- 差异的 95% 区间不含 0 才算数。
- X2 跑之前另写补充预注册。

实验	判定规则（摘要）
M2c BERT 对照	BERT 最好一层 ⩾ Qwen 最好一层 − 0.05：年份和名气来自标题风格；Qwen 高出 ⩾ 0.10（R^2）或 ⩾ 0.05（AUROC）：超出风格；其余：不能下结论
M3 换任务	身份指数 I(l) = 同一论文跨任务余弦 − 不同论文跨任务余弦。H2（论文身份）：标题位置 I(l) > 0 从 L8–L24 起，跨任务迁移比 ⩾ 0.8（L16–L40）。H1（任务）：L8–L24 的 I(l) 约为 0，或迁移比 < 0.5。L4 作为词汇下限
X1 跨任务替换	恢复率 R = (替换 − 损坏)/(干净 − 损坏)。在调参集上选 R(作者) − R(随机 C) 最大的层；测试集上 R(年份)、R(领域) 都显著高于 R(随机 C)，且与 R(作者) 相差 ⩽ 0.1：这一层的表示与任务无关。随机 C 的恢复预期约为 0，若某层超过 0.1，所有结果都相对它报告并标注
X3 同义改写	差距 G(l) = cos(原, 改写) − cos(原, 近邻 B)。第一个 G 显著大于 L4 的层就是“论文身份”开始的层（调参集上找，测试集上确认）；行为上，改写标题的作者得分应高于 B
X4 Patchscope	可解码度 D = 注入自身表示的得分 − 注入 B 的得分（年份、第一作者、领域）。H2 预测年份和领域最早可解码的层 ⩽ 第一作者；认得出的论文 D 更大。源提示里没有年份，所以 D(年份) > 0 只能来自模型认出了论文
X5 层序	H2 预测：论文身份最早，其次是 probe 读出作者首 token，最后是 lens 读出名字（L57–L61）

切分方式的审计与修正（2026-10-28 11:40，预注册补充 1，sha256 608045ca...9ad60f）

M2、M2b、M2c 原来都用同一组按论文的 5 折（种子 13），同一篇论文的不同层、不同位置都在同一折。但有两处泄漏：

- 假标题运行里，同一个借出标题被用在多篇论文上，有 2,004 个借出标题同时出现在训练和测试里。所以 false_0 的数字（读借出论文年份 R^2 0.50–0.62）作废。
- 没有按作者团队切：有 2,319 对论文共享至少一位作者全名，probe 可能只是记住了“这个团队常在哪年发论文”。

现在改为按组切：共享任一作者全名的论文为一组（同名不同人也并组，偏保守），false_0 按借出论文及其团队分组，整组进同一折。核对结果：没有任何作者全名或借出标题跨折，5 折大小均衡（1,821–1,822）。M2、M2b、M2c 按组重跑（作业 11443403）；X1/X3/X4 的调参集和测试集也改为按团队划分（0 个团队跨两边）。以按组切的结果为准，按论文切的结果并列保留，作为探索性结果。Stage 11 的 E4b probe 在再次引用前也会按组重跑。

标记状态（2026-10-28 17:30，用户同意改写 1、2）

样本数统一说明：剔除标题复用后共 1,863 篇（目标 896、对照 499；其余为 excluded 与 guard）。目标 − 对照比较和 PPT 中的图只用其中的目标与对照，共 1,395 篇。“只用假标题训练”一组剩 1,568 篇（目标 810、对照 399）。

- **已去掉“待复核”、改为“已复核”的（有复核结果支撑，正文已改）：**
  - §1 摘要中关于 probe 的一句：改为 +0.05 到 +0.08，目标组高 +0.04 到 +0.08；
  - §6.11“标题位置能不能读出作者”：改为复核后的数字，并保留原数字作对比；
  - §6.12“标题位置 probe 的对照检验”：删去“只用假标题训练信号反而更强”，改为“得到相近的信号”，并说明原来的“更强”来自泄漏；表中“只用假标题训练”的三行标为“已被复核结果取代”；
  - §7“读得早，说得晚”中关于 probe 的部分：改为复核后的数字；
  - §6.12 和 §7 标题下的整节提示行已删除。
- **仍然保留“待复核”的（依赖 Stage 12 P1/P2 正式分析和 X6）：**
  - “论文信息被搬到标题之后的 token 上”在 §1、§6.11、§7 的 3 处；
  - §6.11 标题下的提示行。

  （2026-10-30 更新：以上 4 处已按 P1、X6、X7 的结果改写，标记已去掉。）
- X7 只涉及 knockout 的解读，目前正文没有加它的标记；X7 结果出来后再决定要不要改。

按论文切 vs 按团队切（作业 11443403），以及按团队重抽的置信区间（作业 11443686），14:30

- **M2 真标题运行：**

  按团队切几乎没有变化，各目标各层变化都在 0.005 以内。例如 L48 年份 R^2 0.555 vs 0.556，“是否认得出”AUROC 0.671 vs 0.670。
- **M2 假标题运行：**

  按团队并按借出论文切后，数字下降了约 0.1，说明原来确实有泄漏。例如 L48 读借出论文的年份 R^2 从 0.62 降到 0.54，引用数从 0.59 降到 0.49。但仍然读得出，与真标题运行相当：表示仍然跟着提示里的标题走。
- **M2b、M2c：**

  变化都在 0.02 以内，结论不变。
- **置信区间按作者团队整体重抽**

  （7,247 个团队，9,108 篇论文；点估计不变）：区间平均只变宽 0–8%（最多 22%）。380 行里只有 4 行“区间是否含 0”发生变化，全都贴近 0：
  - 6.4 logit lens L32：+0.005，原区间 [0.000, 0.011]，团队区间 [−0.000, 0.010]；
  - 6.2 logit lens L56：+0.035，原区间 [0.006, 0.064]，团队区间 [−0.001, 0.069]；
  - C − A，logit lens L55：+0.025，原区间 [−0.000, 0.049]，团队区间 [0.000, 0.050]；
  - 6.3 目标组 public lens L48：−0.007，原区间 [−0.014, 0.000]，团队区间 [−0.015, −0.000]。

  L62/L63 的主结果（+0.21 到 +0.23）以及 Stage 11 替换和阻断曲线的区间都没有实质变化。还没覆盖的是名字先验分解（6.12）、E4b 和 X 系列，等这些数据齐了再补。

E4b 复核结果（作业 11443587，13:00）

按预注册补充 2，正式结论以“按团队分折 + 剔除标题复用”这一版为准。

- **代码没变：**

  按论文分折、不剔除的那一版逐位复现了已发表的 E4b（最大差 0.0000）。对照组的数字最大差 0.008，来自随机置换和 bootstrap 用的随机数顺序不同，点估计本身相同。

- **标题复用的规模：**

  约 80% 的测试论文，它提示里的某个标题出现在 probe 的训练集中；剔除后剩 1,863 篇（按团队分折；其中目标组 896、对照组 499，另有 excluded 433、guard 35）；“只用假标题训练”的剔除条件更严，剩 1,568 篇（目标 810、对照 399）。

- **probe 在标题位置读出的论文特有信号仍然成立。**

  全部论文平均：L24 为 +0.050（原来 +0.045），L40 为 +0.066（原来 +0.062），L56 为 +0.080（原来 +0.081），区间都在 0 以上。

- **两种置换对照仍然约为 0：**

  正确答案换成随机另一篇论文的作者，或同领域另一篇论文的作者，各层都在 −0.005 到 +0.006 之间。

- **目标组 − 对照组仍为正，而且没有变小：**

  L24–L60 为 +0.036 到 +0.078，区间都在 0 以上。原来是 +0.02 到 +0.04，区间因样本变少而变宽。

- **“只用假标题训练、信号反而更强”不成立。**

  剔除标题复用后，它在 L24 为 +0.050、L40 为 +0.057、L56 为 +0.074，与普通 probe 相当或略低，不再更强。原来那个“更强”来自泄漏：同一个借出标题同时在训练和测试里。§ 6.12 的这一句需要改写。

- **2026-10-30 更新：标准化只在训练折内拟合。**

  上面的数字用全部论文（含测试折）算均值和标准差。改为只用训练折后（作业 11500917），全部论文平均 L24 +0.050、L40 +0.061、L56 +0.075；目标组 − 对照组 L24–L60 为 +0.035 到 +0.078，L44 下界变为 +0.000（边界）。最大变化 0.0075，正则化强度不变，没有结论翻转。正文 § 6.11 已改用新值。381_stage13/reports/e4b_trainstd_compare.md

M2c：BERT 对照（按论文分折，作业 11443232；按团队分折的版本还在跑）

BERT 最好一层（L11–L12）读出年份 R^2 0.24，引用数 0.19（去掉年份后 0.18），“是否认得出”AUROC 0.63。Qwen 在标题最后一个 token 上分别是 0.56、0.53、0.52、0.67。按预注册规则：

- **年份和引用数：**

  BERT 远没有追平 Qwen，不支持“只是风格”。规则规定 Qwen 超过 BERT 只作参考，不能当作“认出了论文”的证据。

- **“是否认得出”：**
  BERT 的 0.63 已达到 Qwen 的 0.67 − 0.05。也就是说，单看标题风格，就能在相当程度上猜出模型认不认得这篇论文：认得出的论文，标题本身就与众不同（例如更有名的领域或写法）。这条按规则支持“风格”解释。

已有结果（M1、M2、M2b 只有定性预测，作探索性结果看）

M1：lens 在中间层排第一的是什么词（名字的第一个 token，真标题）。

- **Jacobian lens：**L24–L48 全部是 “.\n”“...\n\n” 这类“一句话或一段结束”的符号。L51–52 起出现名字，但都是 Robert、Zhang、David 这类常见名字，也就是名字先验。正确的那个 token 在 L52 只占 0.1%，L62 占 2%。
- **logit lens：**L24–L56 几乎都是固定的垃圾 token（“工程技术”“您好”、垃圾词），这是 logit lens 在中间层的已知失效。L57 起才出现名字，L62 占 87%。
- **真假标题对比：**即使在 L24–L48，把真标题换成假标题，排第一的词也有 28–64% 会变。读出随标题而变，但变的不是名字。

这和 H1“表示格式”的预测一致，但更可能说明这些 lens 在中间层根本没在读内容，不说明信息不存在。

M2：在标题最后一个 token 上（年份还没出现）读论文属性。

- 年份 R^2 从 0.39（L16）升到 0.56（L52）。
- 引用数 R^2 从 0.28 升到 0.53；去掉年份后仍为 0.27 到 0.52，只用年份时是 0.05。
- “是否认得出”AUROC 从 0.62 升到 0.67，只用年份时是 0.56。
- 领域准确率 0.69–0.72，打乱标签对照是 0.13。
- “:” 位置的年份 R^2 达 0.98，这是泄题，只作阳性对照。
- **按作者团队整群的区间（2026-10-30，作业 11503585）：**176 个点估计与原结果完全一致；区间平均宽 1.15 倍（真标题 1.02，false_0 1.32），没有任何一行从“不含 0 / 高于随机水平”变为相反。只用年份的基线也补了区间，例如“是否认得出”AUROC 0.555 [0.534, 0.573]。381_stage13/reports/m2_teamci.md
- ~~假标题运行读出的是标题所属论文 B 的年份和引用数。~~ 作废：同一借出标题跨了训练和测试，见上方切分审计。

M2b：标题词袋基线。只用标题词（TF-IDF）时，年份 R^2 0.11，引用数 0.07，所以 Qwen 读出的不只是用词。但 L16 本身已经是很强的文本模型，词袋太弱，不足以下结论，所以加了 M2c（BERT）和 M3 的 L4/L8。另外，认得出的论文年份误差比认不出的小 0.7–1.2 年，可是词袋基线也小 0.88 年，所以目前还看不出“认得出”带来的额外信息。

排队情况（11:00）：

- fairshare 0.09（偏低）。我们的作业优先级约 4,900，前面至少有 15 个别人的 A100 作业，优先级 5,300–9,900。

- 11 张 A100 都被占用，剩余时间 1.3–7 小时。
- 已把 20 个排队作业的时长从 90 分钟缩短到 60 分钟，方便 backfill 插队；实验条件不变。
- 多余的作业不需要取消：排上时如果没有可领取的单元，会在加载模型之前就退出。

> **关于“区分真标题和假标题”**
>
> 本研究的假标题是同领域其他真实论文的标题，年份也匹配，而且在标题和 “:” 位置上下文里还没有任何作者名字。所以只看这两个位置的表示，“真标题”和“假标题”在设计上无法区分：两者都是真实论文。M2 改用“从标题推出年份、引用数、是否认得出”来检验模型是否认出了这篇论文。真/假判别要在上下文里已经出现作者名字的位置上做（M5③）。

代码：~/jlens_work/13_stage13/stage13_cpu.py（M1、M2）、381_stage13.py（M3，含 tiny 模型试跑 dry）；Stage 12 → 13 的转交在 371_stage12.py handover13。结果目录：/scratch/zhang.zhiqi2/jlens/381_stage13/。