Where does Qwen3-32B hold a paper's authors?

Stages 1-9

Small samples: find a signal, try to break it

20 → 50 → 200 papers(Stage 4, Pilot50, Stage 8 cohorts)

Stages 10-13 · post-defence additions (2026-11-05) at the end

Full cohort: locate it, then intervene

9,108 papers · 149,999 name tokens(Stage 10 cohort: papers.parquet, name_tokens.parquet)

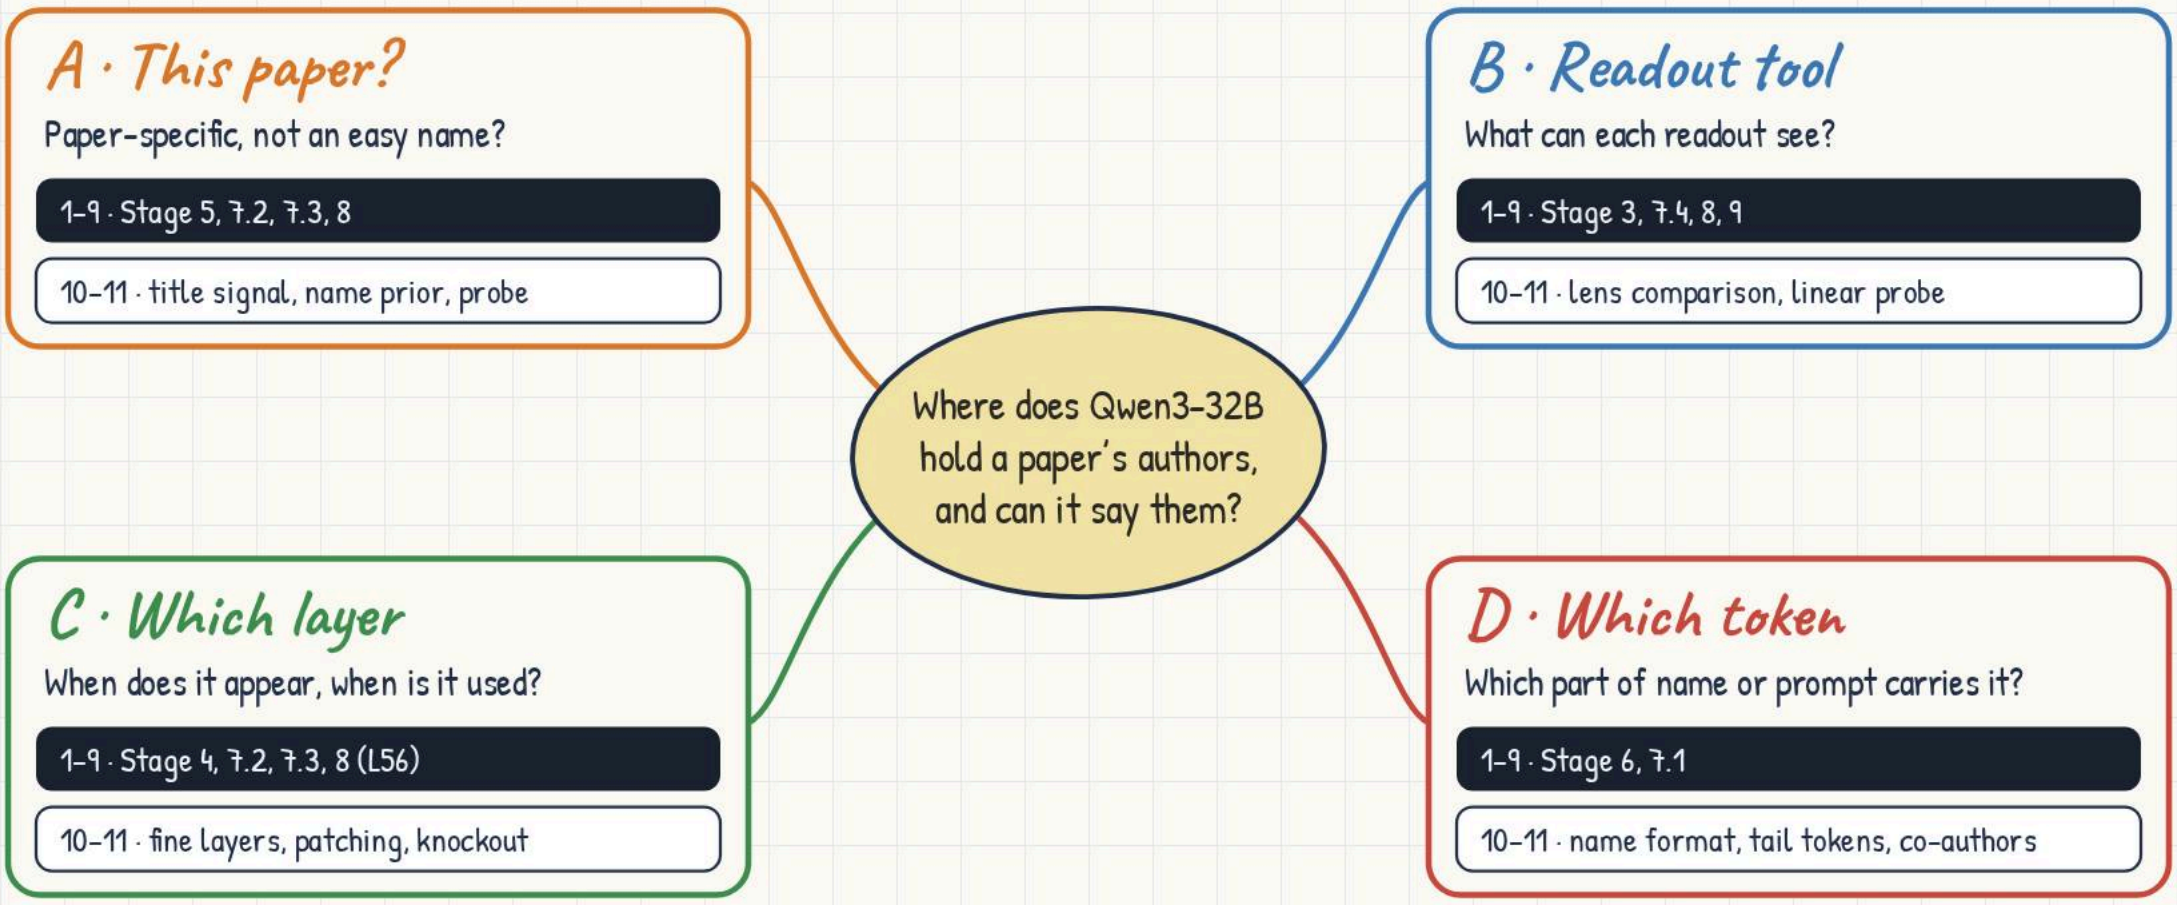
 新写讲稿

今天讲的问题只有一个：Qwen3-32B 把一篇论文的作者记在网络的哪一层。整个工作分两个阶段。左边是 Stage 1–9，用 20、50、200 篇小样本（Stage 4 Benchmark20 20 篇、Pilot50 50 篇（Stage 5–7）、Stage 8 新论文 200 篇；351_all/351_stage4_readout.log、351_stage5_crossed_v2/cohort/pilot50_v1.csv、351_stage8/cohort/stage8_papers.csv）先找到信号，再想办法推翻它；右边是 Stage 10–11，用全部 9,108 篇论文（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv）、149,999 个名字 token（Stage 10 冻结队列，33,811 个作者上下文的名字 token 总数；351_stage10/cohort/name_tokens.parquet；351_stage10/config/manifest.json） 去定位这个信号，并用干预实验检验。深色页是小样本阶段，浅色页是全量阶段。

One question, four lines of argument

Each line narrows the space of explanations; small samples set it up, the full cohort settles it

dark pages = Stages 1–9 · light pages = Stages 10–11 · purple tag = comparison



 新写讲稿

整份报告按四条论证线组织。A 线问信号是不是针对这篇论文，而不只是名字好猜；B 线问每种读出工具能看到什么；C 线问信号在哪一层出现、在哪一层被用到；D 线问名字或提示词的哪一部分带着信号。每条线先看小样本阶段问了什么，再看全量阶段怎么回答。

Stages 1–9 · 20–200 papers

Pilot design

- Pilot50 / Stage 8: 50 and 200 papers(pilot50_v1.csv, stage8_papers.csv)
- Mostly first-listed author, first token
- Score: gold vs 1 or 100 false names (logit margin, win rate)
- A/B both R0, matched in pairs
- Wrong titles: 1 crossed or 20 shuffled
- Layer L56 chosen after repeated looks

Stages 10–11 · 9,108 papers

Full-cohort design

- All 9,108 papers(papers.parquet), every author, every token
- Score: rank over the whole vocabulary, log10(1/rank)
- target = A + C, control = B + D (R0 + R1), compared within citation bins
- 5 matched false titles + no title
- All layers reported, fine layers added
- Parity and Stage 6 cross-check before analysis

What changed in the design, and why

Small samples could not separate "small effect" from "no effect" in a given layer. The full cohort trades candidate-based scores for full-vocabulary ranks and pays for it with GPU time. **Note:** target/control include R1 papers; with R0 only (A vs B, as in the pilot) the output gap is +0.199 vs +0.207(Stage 10, final L63, R0 3,423 vs 2,151; §6.13) and every layer looks the same.

先对比两个阶段的设计。小样本阶段用 50 和 200 篇论文（Pilot50 50 篇（351_stage5_crossed_v2/cohort/pilot50_v1.csv）、Stage 8 新论文 200 篇（351_stage8/cohort/stage8_papers.csv）），主要看第一作者的第一个 token，把正确名字和 1 个或 100 个错误名字（Stage 5 交叉对照每篇 1 个来源论文作者；Stage 7.2 每篇 50 个匹配 + 50 个随机错误作者；351_stage7_2/summary/quality.json；~/jlens_work/07_2_stage7_2/351_stage7_2.py:62-111）比较，A、B 两组都是 R0 并逐对匹配，错误标题用 1 个交叉标题或 20 个打乱标题（Stage 5 每篇 1 个交叉标题；Stage 7.3 / Stage 8 每篇 20 个元数据匹配的错误标题；~/jlens_work/07_3_stage7_3/351_stage7_3.py:83-91；351_stage8/config/stage8B_manifest.json），L56 是反复看过之后才选定的层。全量阶段改为全部 9,108 篇（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv）、所有作者和所有 token，用全词表名次 log10(1/名次) 打分，target = A + C、control = B + D 在引用档内比较，用 5 个匹配假标题（Stage 10 标题条件设计：每篇 5 个匹配假标题（false_0–false_4）加删去标题；351_stage10/config/conditions_manifest.json）加删去标题，所有层都报告，还加了细层。改设计的原因是小样本分不清某一层是“效应小”还是“没有效应”。

Same papers, two ways of grouping

Stages 1–9 compare A vs B; Stages 10–11 compare target vs control. Counts from the 6,841-paper cohort.(Stage 1, 351_audit.json group_counts)

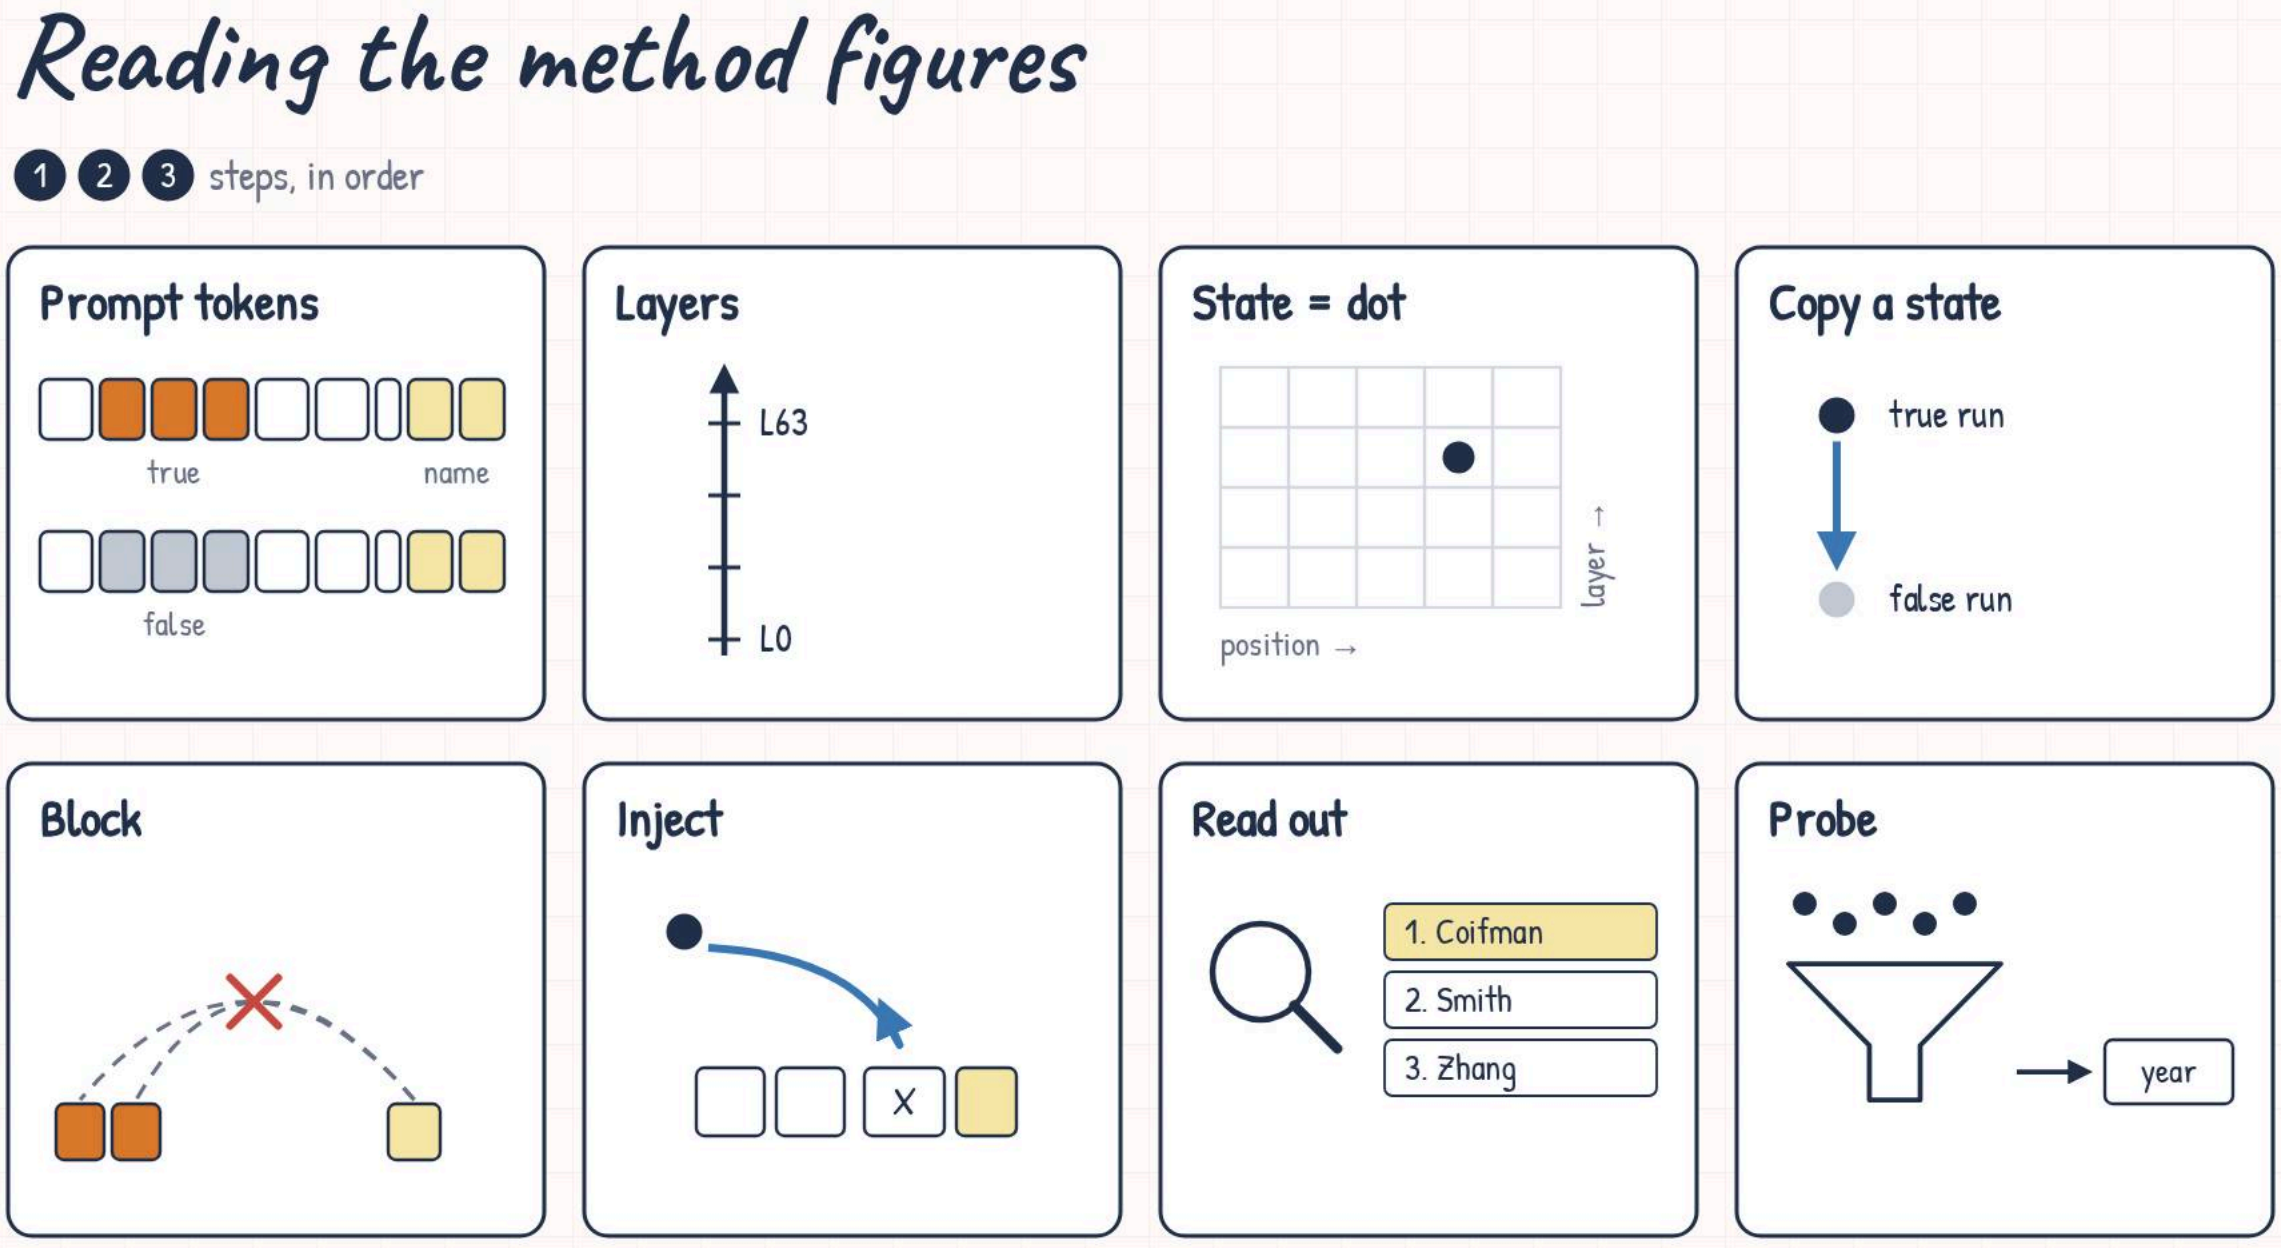
	recognised (target)	not recognised (control)
R0 · no true author written	A = 4,110	B = 2,186
R1 · some authors written (HR2 > 0.5)	C = 511	D = 34
Total	**target = A + C = 4,621**	**control = B + D = 2,220**

Stages 1–9
A vs B: both R0, so the contrast is purely "knows but cannot say"

Stages 10–11
(A + C) vs (B + D): adds 511(351_audit.json) partial-recall papers, almost all on the target side

Check done: with R0 only (A vs B) the output gap is +0.199, versus +0.207 for target vs control(Stage 10, final L63, within-bin; §6.13), and every layer looks the same. The two phases compare like with like.

这一页说明两个阶段的分组其实是同一批论文。R0 是开放回答一个真作者都没写对，R1 是写对了一部分但 HR2 大于 0.5。A = 4,110、B = 2,186、C = 511、D = 34（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表）。Stage 1–9 比的是 A 对 B，两组都是 R0；Stage 10–11 比的是 A + C 对 B + D，多出来的 511 篇 R1（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表）几乎全在 target 一侧。我们已经检查过：只用 R0（A 对 B）时，输出处的差是 +0.199（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv），合并口径是 +0.207（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.196, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），各层形状相同，所以两个阶段可以直接对照。

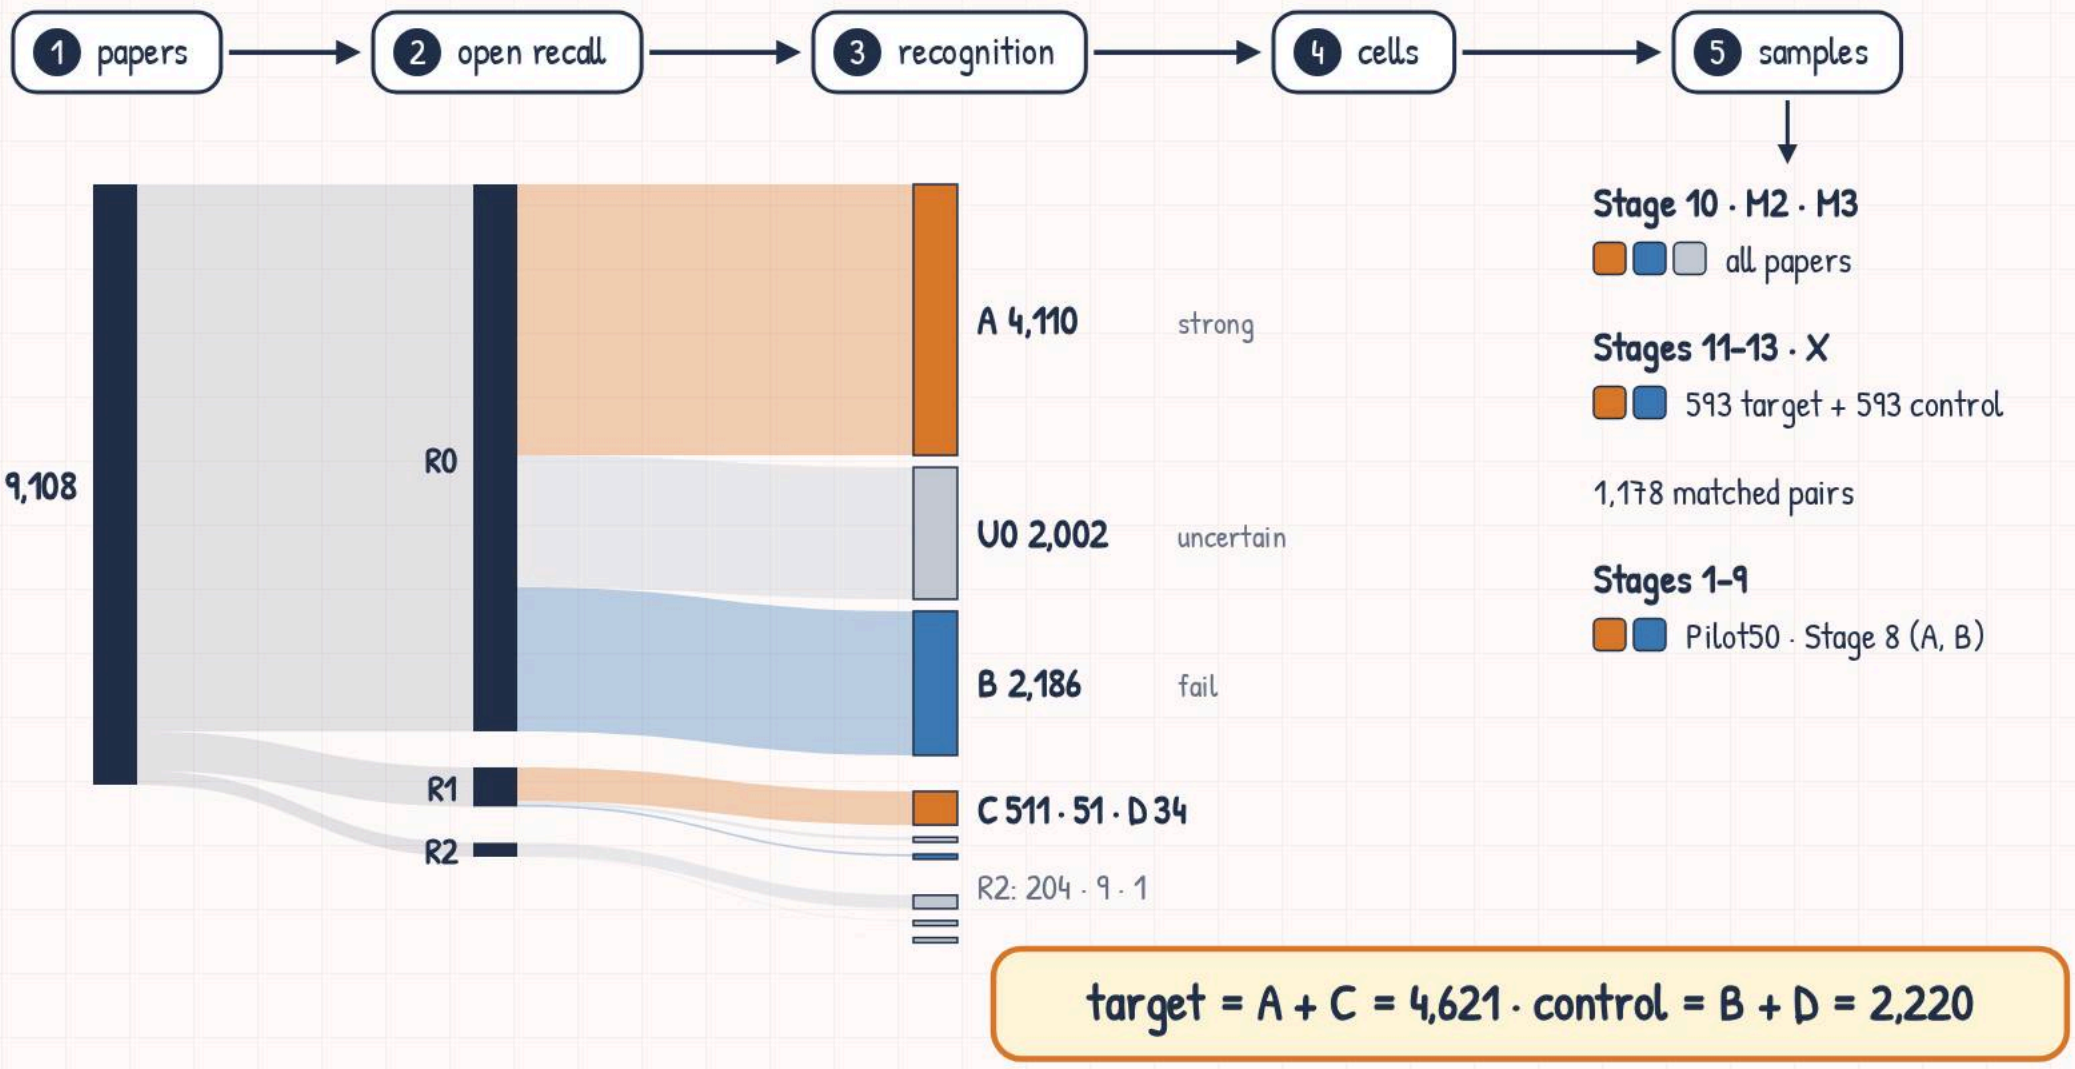


第 5 / 75 页 · Method · Legend for the method figures · 合并 PPT 自身页面 **新写讲稿**

从这一页起，每个方法页都放在它所属实验的结果之前，背景是很浅的粉色网格。图例：提示词画成一排 token 方块，橙色是真标题、灰色是假标题、黄色是名字；层自下而上，L0 在底部、L63 在顶部；一个圆点代表某一层某个位置的隐藏状态。蓝色箭头表示把状态复制或注入到另一次运行，红色叉表示阻断注意力，放大镜表示读出名次，漏斗表示训练探针；带圈数字是步骤顺序。

Groups and samples

example: cell C



9,108 篇论文（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv）先按开放回答分成 R0（一个真作者都没写对）8,298 篇、R1 596 篇、R2（基本写出了作者）214 篇（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表；R0/R1/R2 = 8,298 / 596 / 214），再按四种选项顺序的多选识别分成 strong、uncertain、fail。R0 里 A = 4,110、U0 = 2,002、B = 2,186；R1 里 C = 511、51、D = 34；R2 为 204、9、1（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表；R0 4,110/2,002/2,186，R1 511/51/34，R2 204/9/1（strong/uncertain/fail））。target = A + C = 4,621，control = B + D = 2,220（351_stage10/cohort/papers.parquet 列 group_tight；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 7 行）。Stage 10 和 M2、M3 用全部 9,108 篇（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv），Stage 11–13 的干预和 X 系列用 593 + 593 = 1,186 篇（Stage 11 抽样，10 个可比引用档内配平，目标 593 + 对照 593 = 1,186 篇；361_stage11/config/sample.parquet；361_stage11/config/protocol.json（361_stage11.py:56, 109–115））（X 系列配对后 1,178 对（Stage 13 X 系列配对，1,186 篇中有合格配对论文的 1,178 篇；381_stage13/config/pairs.parquet）），Stage 1–9 的 Pilot50 和 Stage 8 取自 A 和 B；示例论文 Coifman 等（2007）属于 C 格。

Cohort and behavioural labels

From the 15 Oct label package (9,108 papers) to a frozen 6,841-paper analysis cohort(351_audit.json total, four_group_total)

Group	Recognition / open recall	Full(351_audit.json)	Pilot50(pilot50_v1.csv)
A	pass / R0 (no true author written)	4,110	20
B	fail / R0	2,186	20
C	pass / R1 (some authors matched)	511	7
D	fail / R1	34	3

- Pass = 4/4 option orders correct *and* mean true-option probability ≥ 0.5; fail = 0–1/4
- Pilot50: seed 35150, keeps the 20 Stage 4 papers + 30 new
- 20 A/B pairs matched on exact field and citation bin, then |Δyear| + 2·|Δauthors|

Why A vs B?

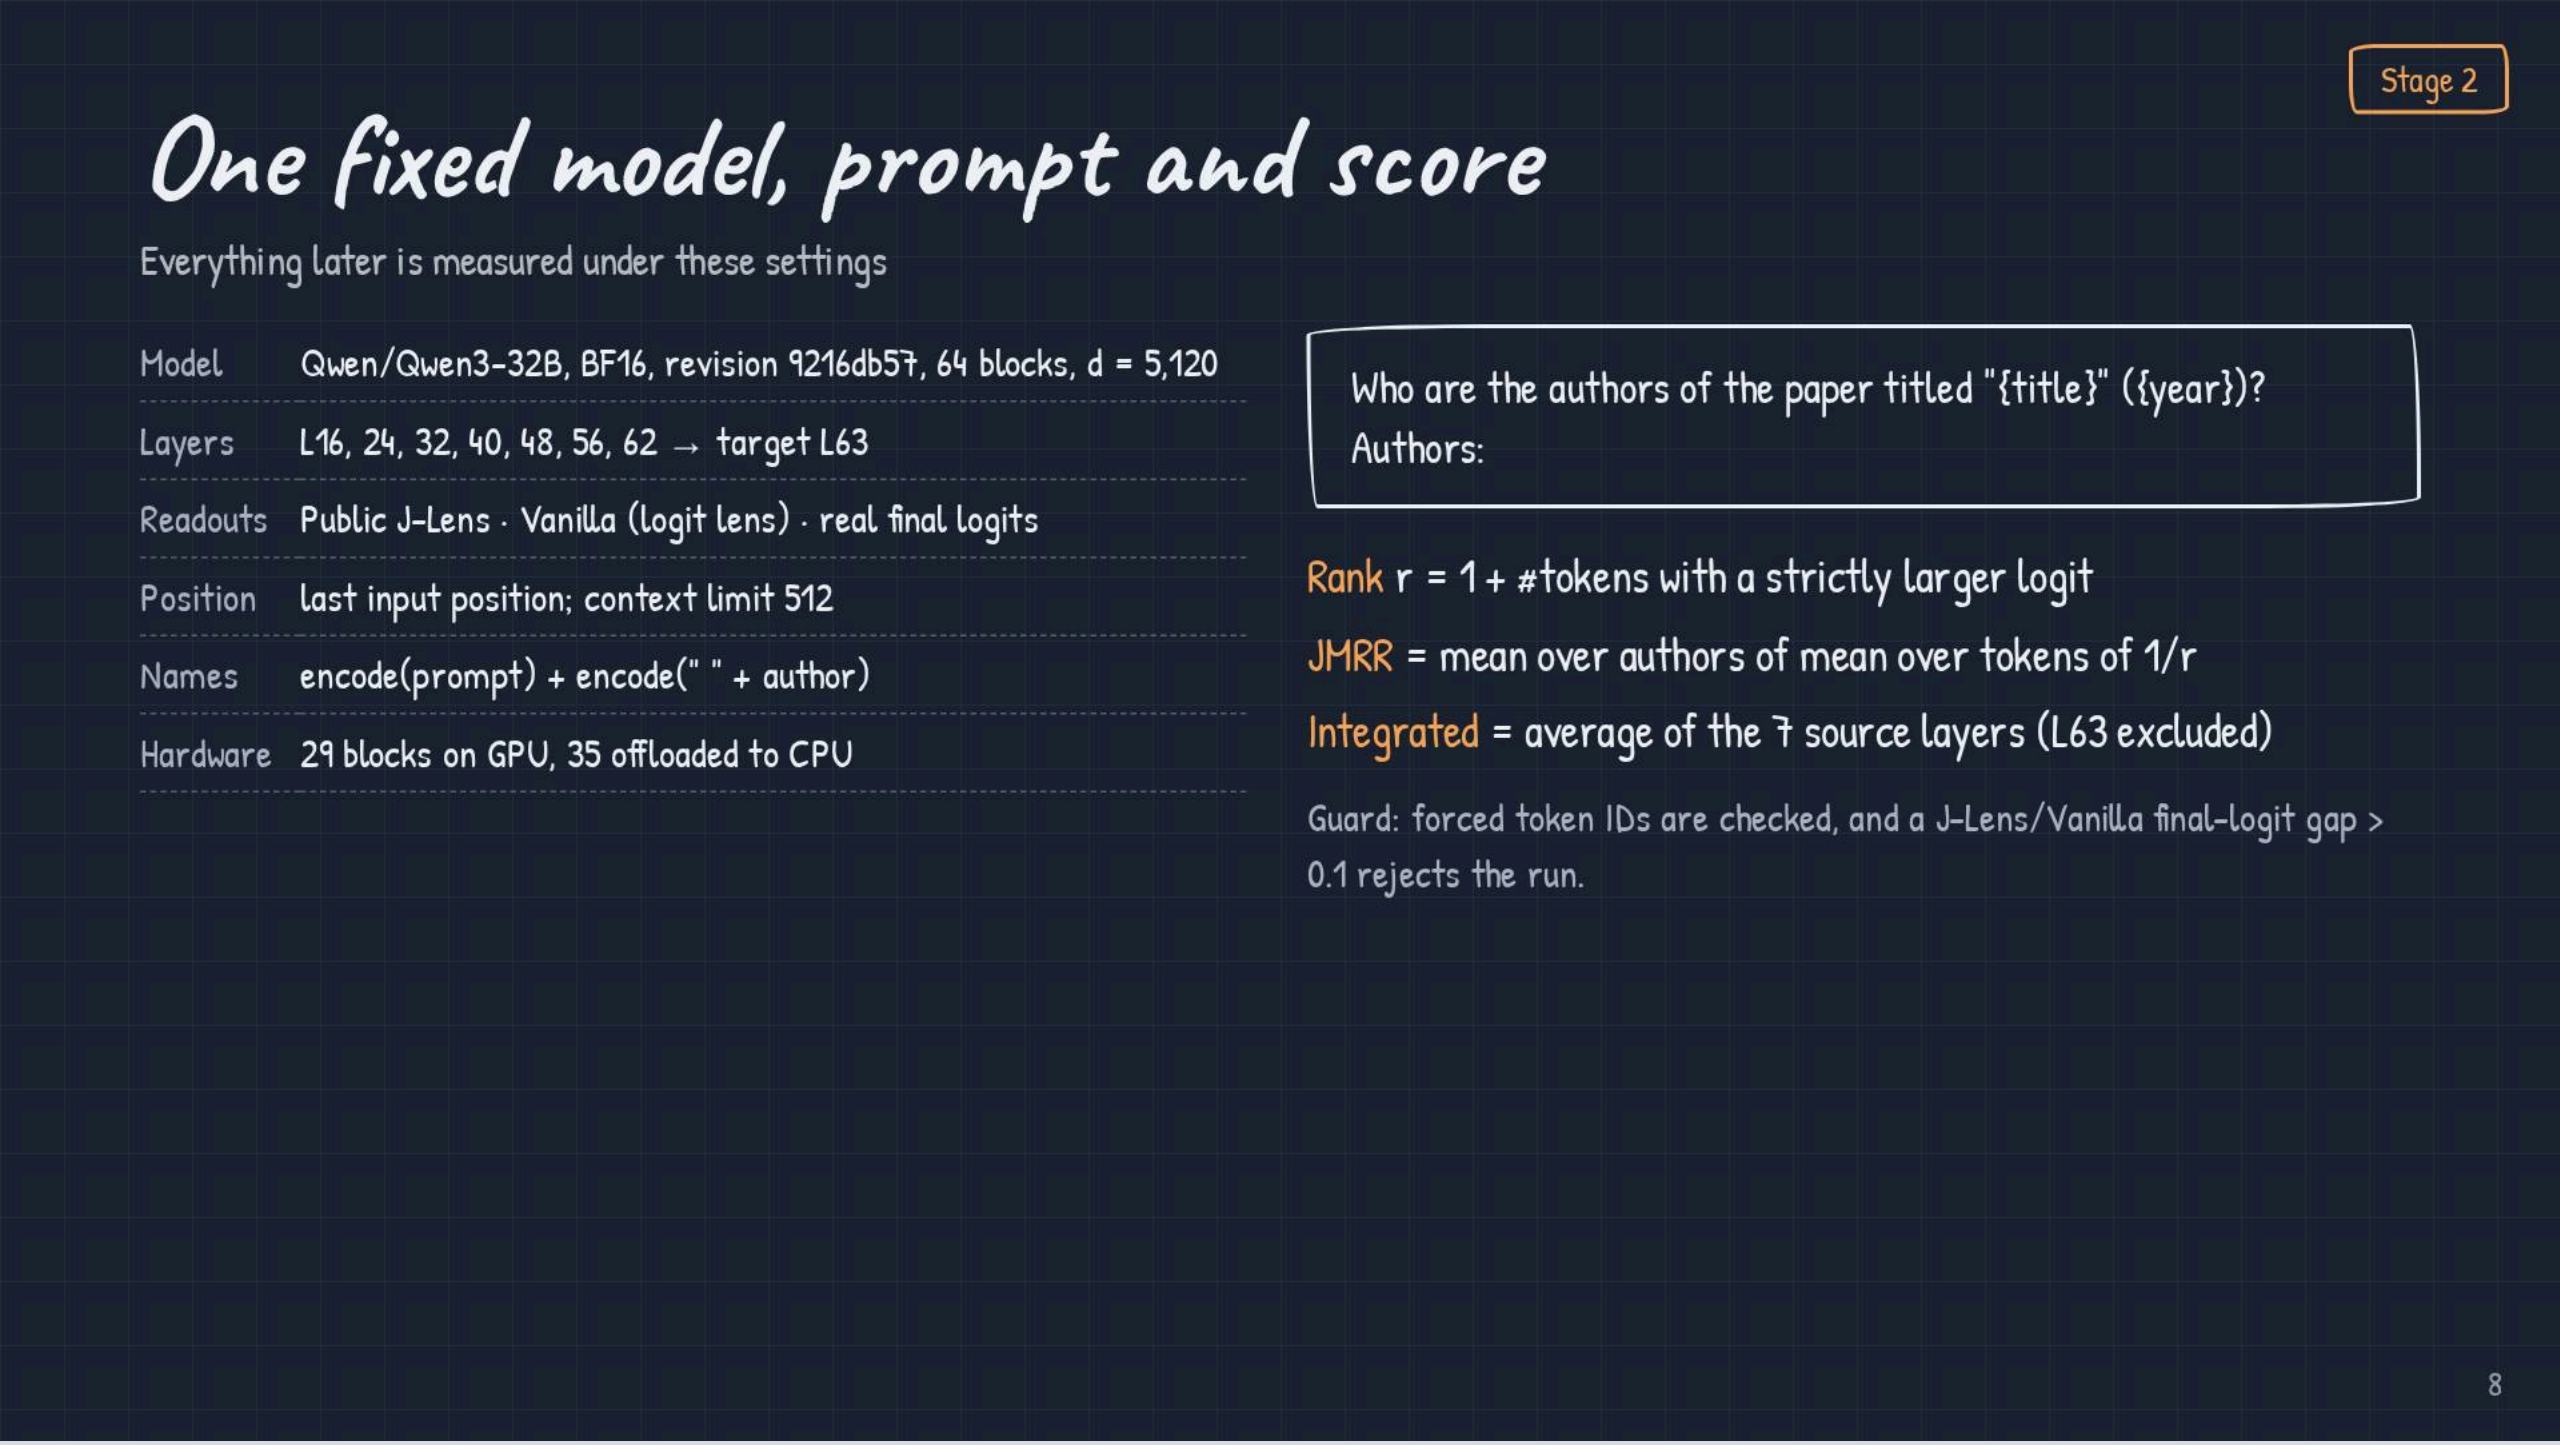
Both groups write **no** correct author. They differ only in whether the model recognises the true list. That isolates "knows but cannot say".

Caveat

In the 0–2-citation bin the strict pass rate is **25.5%**(796 papers; label_README.md l.8), above the planned ≤10% floor: "pass" is not proof of stored knowledge.

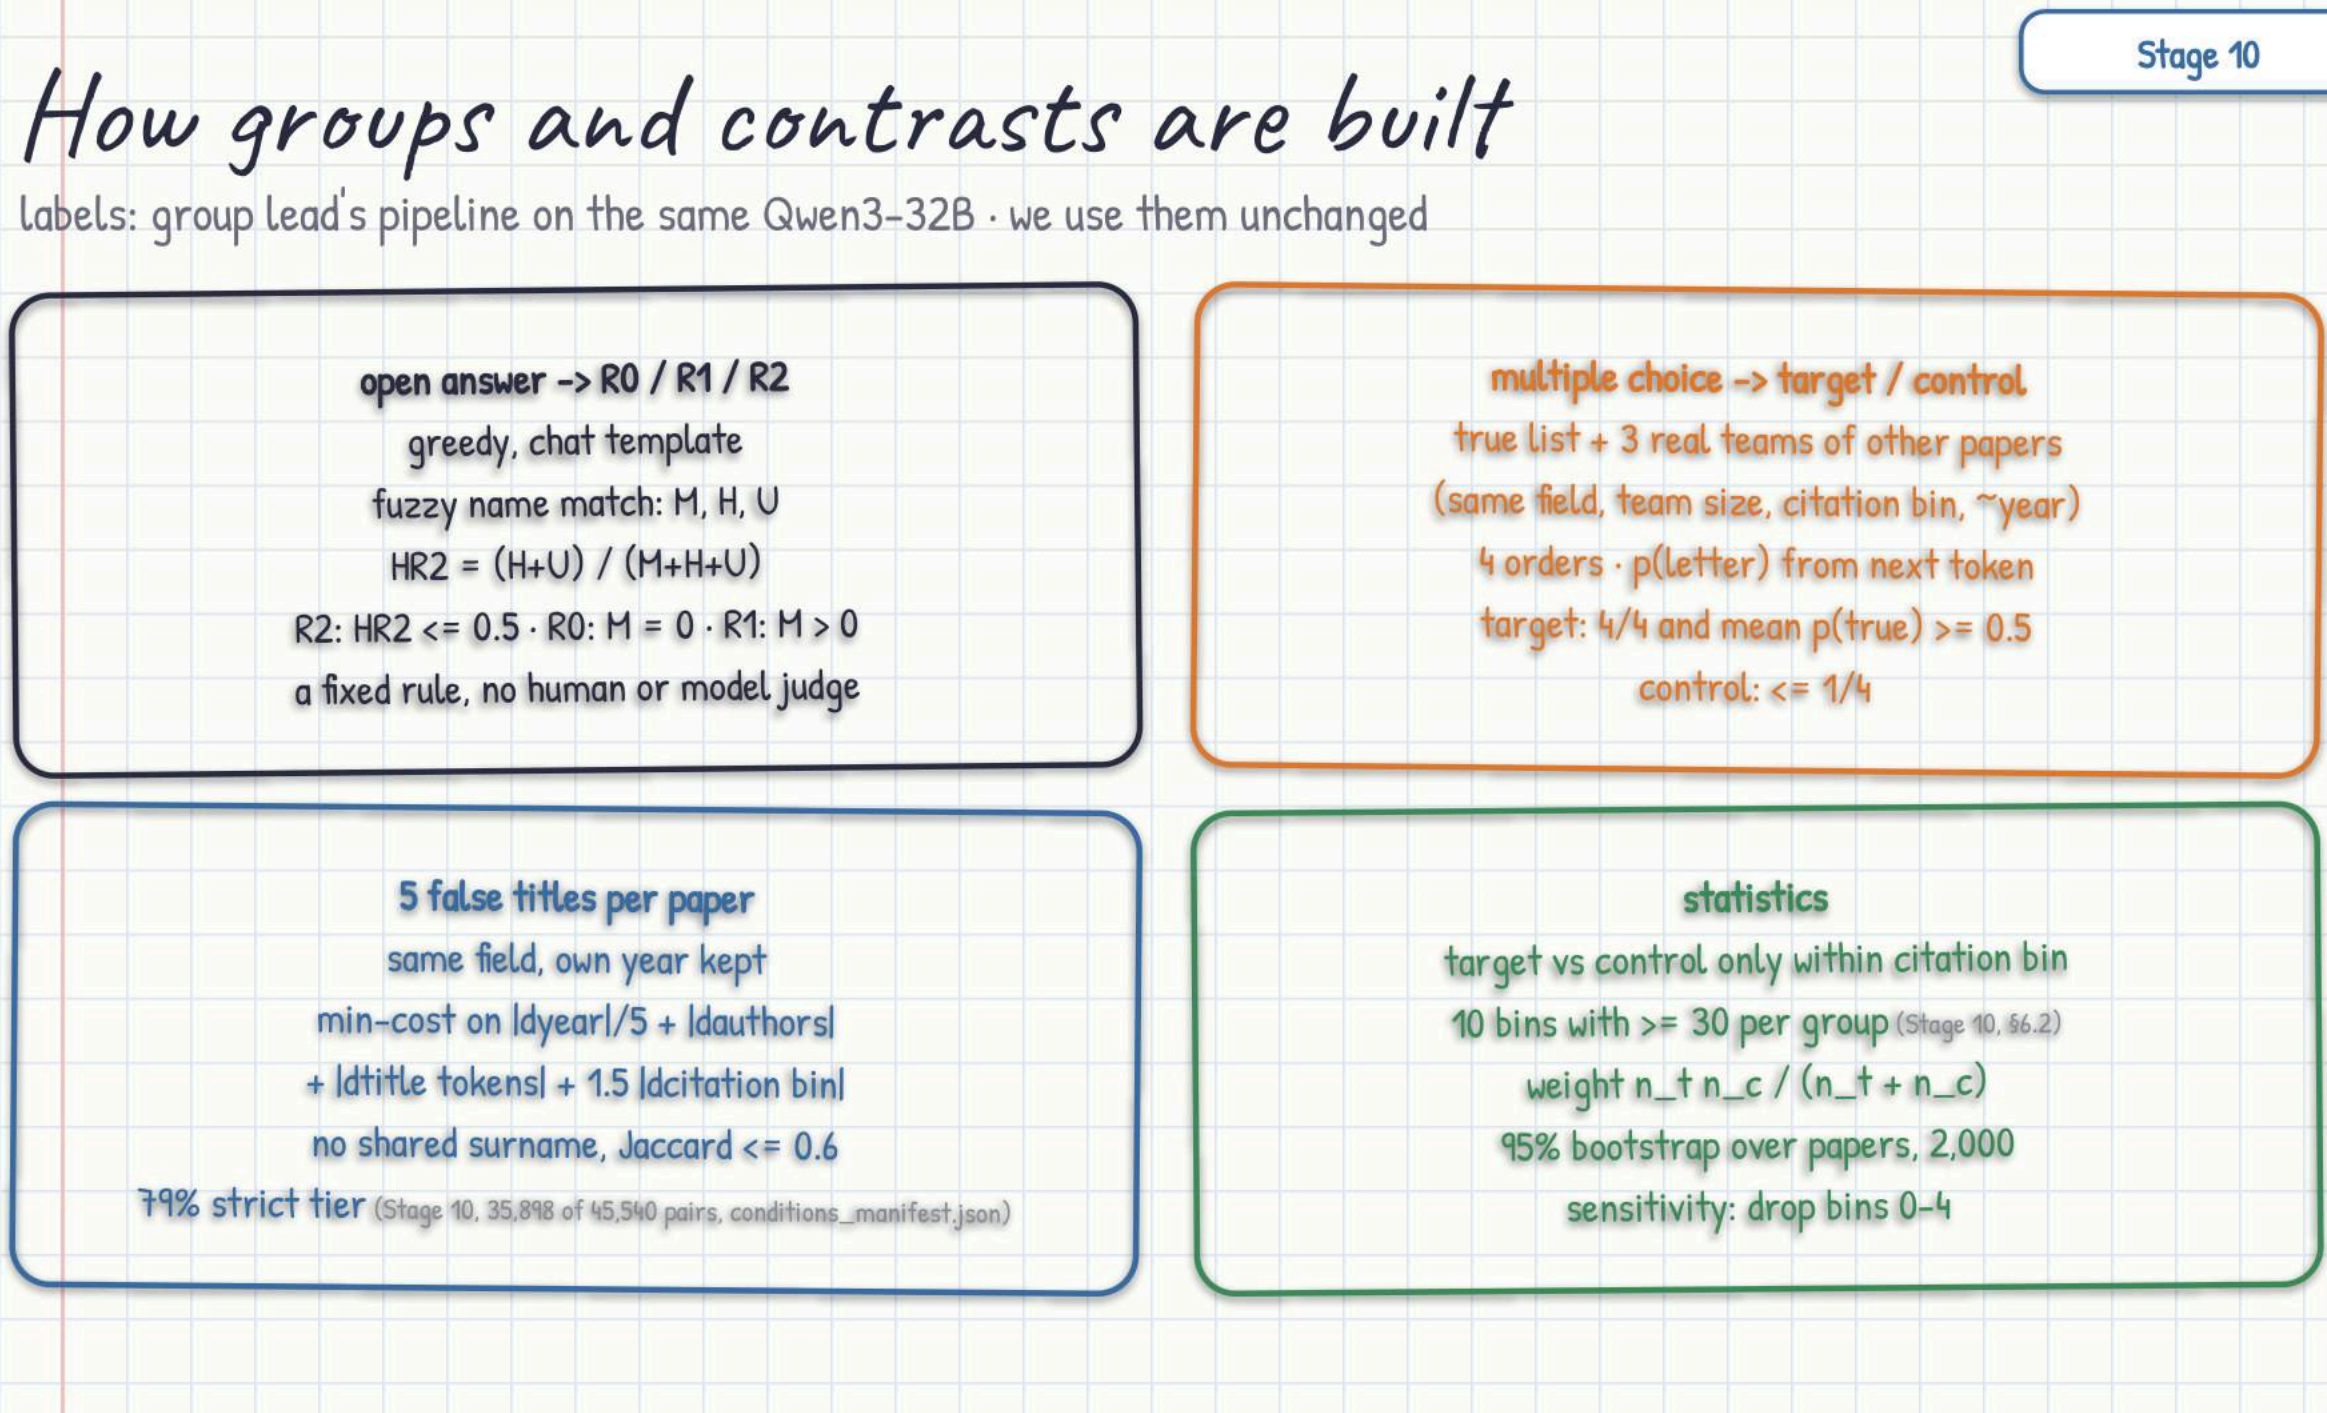
 新写讲稿

Stage 1 建立队列和行为标签。从 10 月 15 日的标注包 9,108 篇论文（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv；351_all/351_audit.json "total"）出发，冻结了 6,841 篇（Stage 1 分析队列 = A + B + C + D 四组；351_all/351_audit.json "four_group_total"；00_cohort/351_prepare_all.py）的分析队列。“认得出”的定义是：4 种选项顺序全对，并且真选项的平均概率至少 0.5（标注规则 group_tight（tightened: min_orders 4, min_p_true 0.5）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/rules.yaml、label_README.md）；“认不出”是 4 次里最多对 1 次（同上 rules.yaml，control = 4 种顺序中至多 1 次答对）。之所以比较 A 和 B，是因为两组都一个作者都没写对，只在能否认出名单上不同，这正好对应“知道但说不出”。需要提醒的是，在 0–2 次引用的档里，严格通过率有 25.5%（标注包自检，0-2 引用档 796 篇，收紧规则（4/4 且真选项平均概率 ⩾ 0.5）多选通过率 25.5%（普通规则 38.6%）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 8 行），高于原计划的 10% 上限（Stage 1 预设的标签质量门槛（0-2 档通过率 ⩽ 10%）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 8 行；报告 Stage 1 节），所以“通过”不等于模型真的记住了。

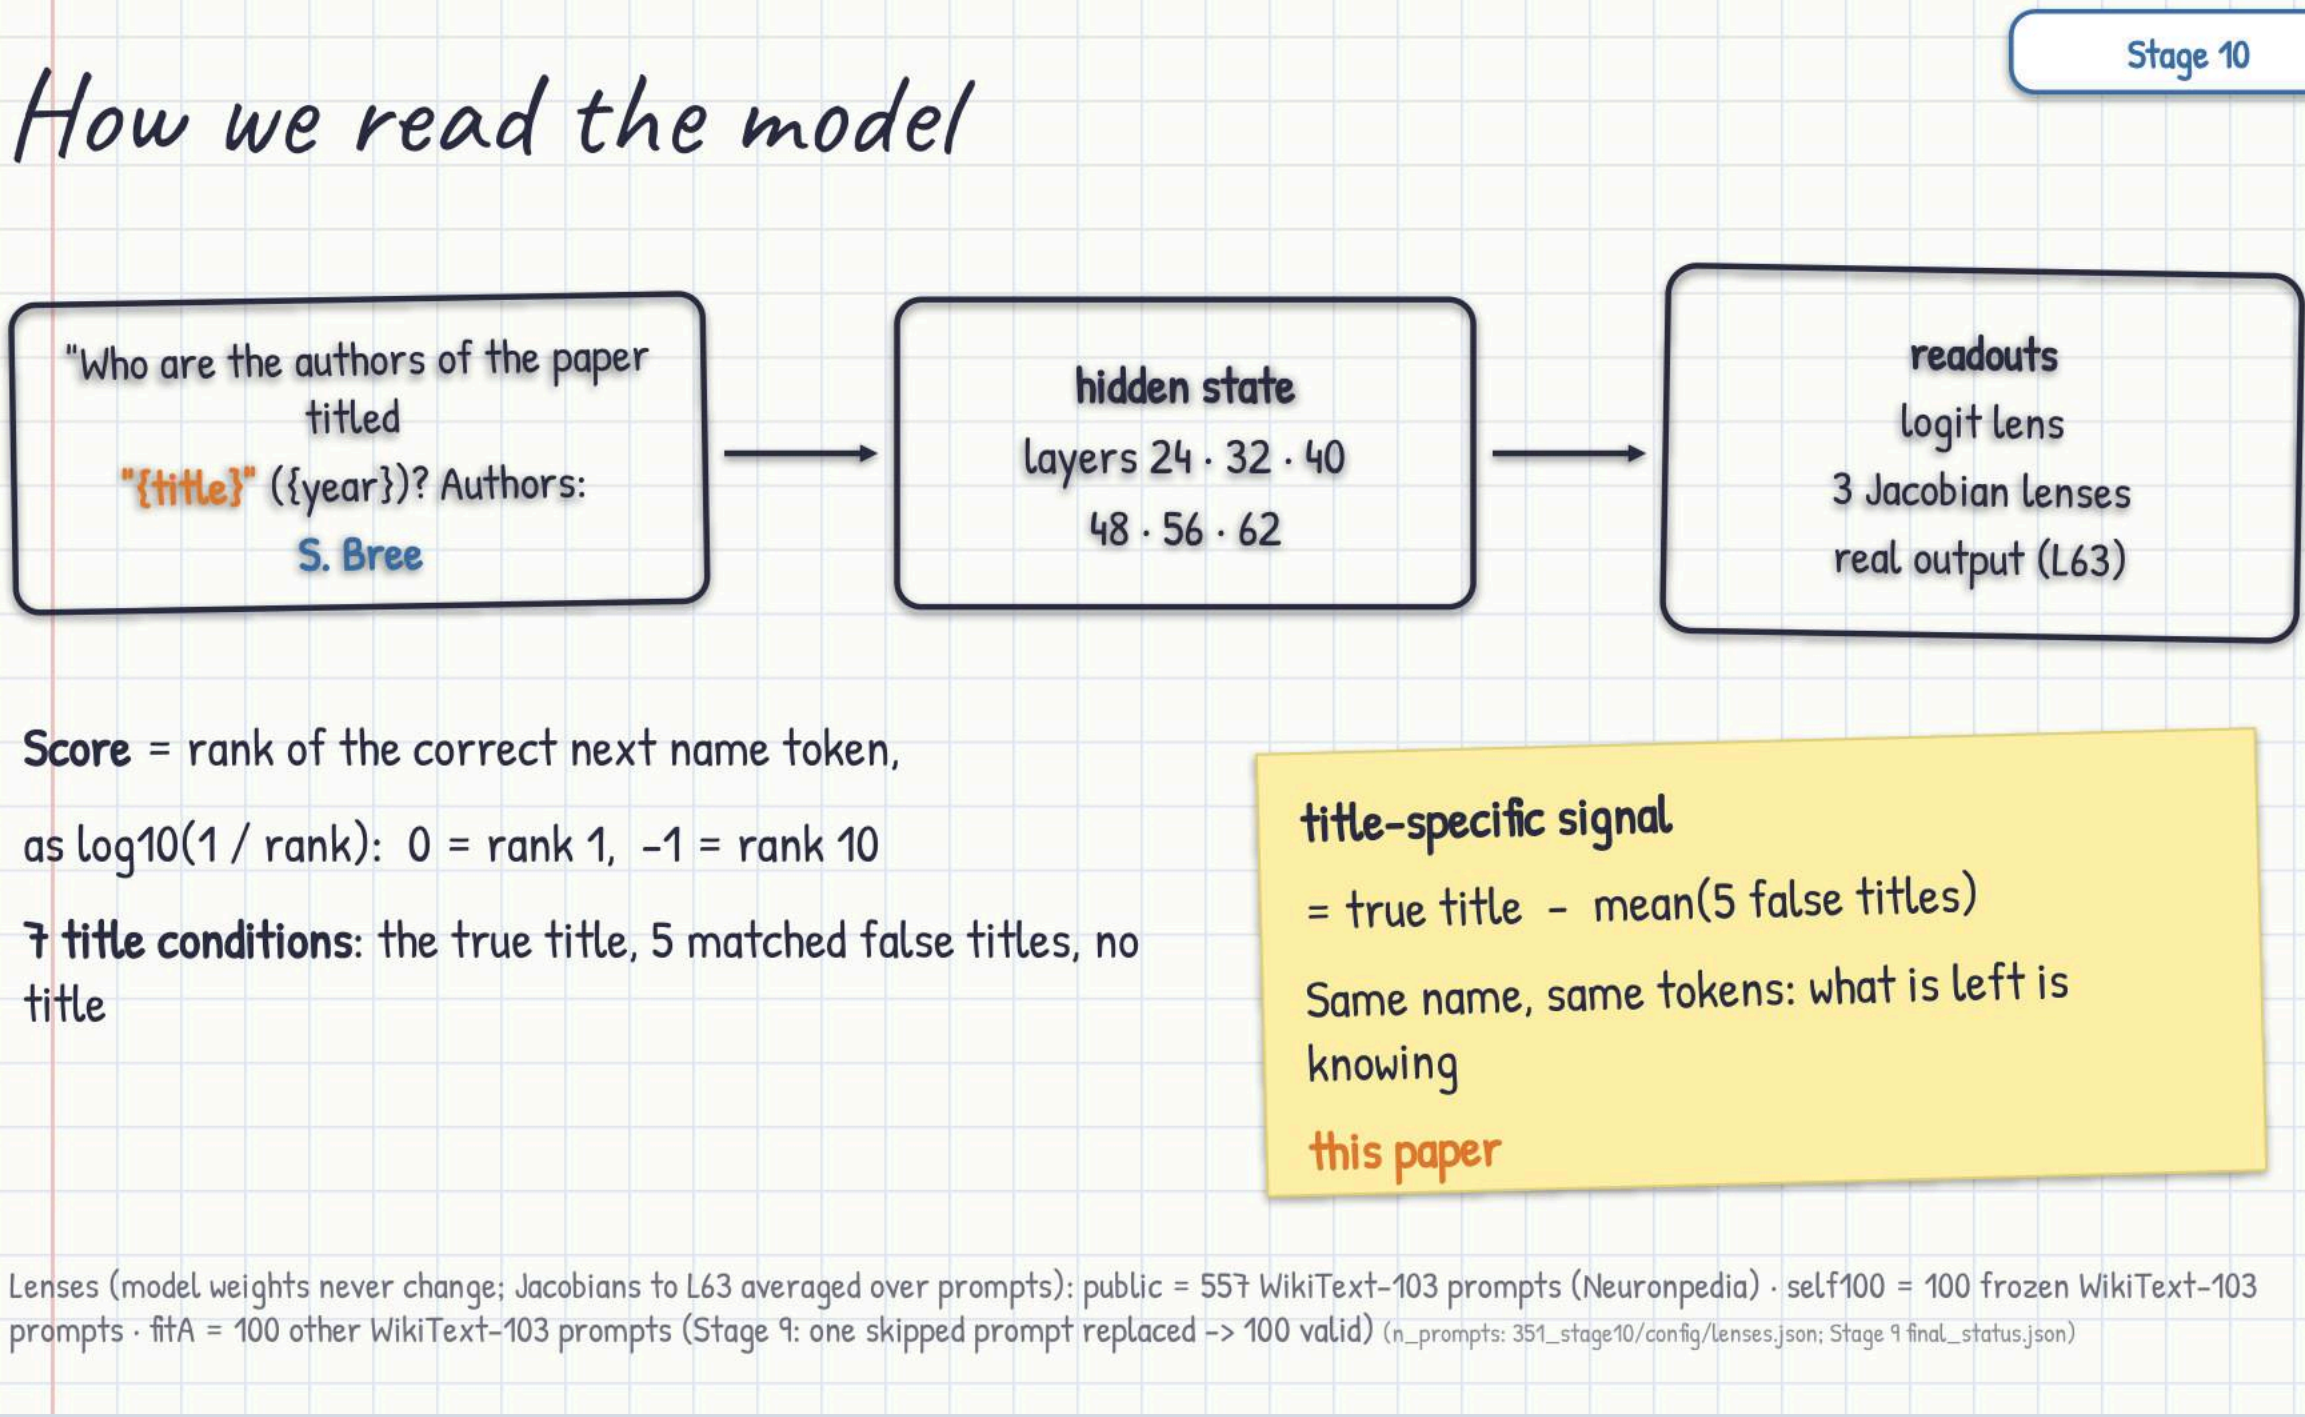


第 8 / 75 页 · Stage 2 · 合并 PPT 自身页面 **新写讲稿**

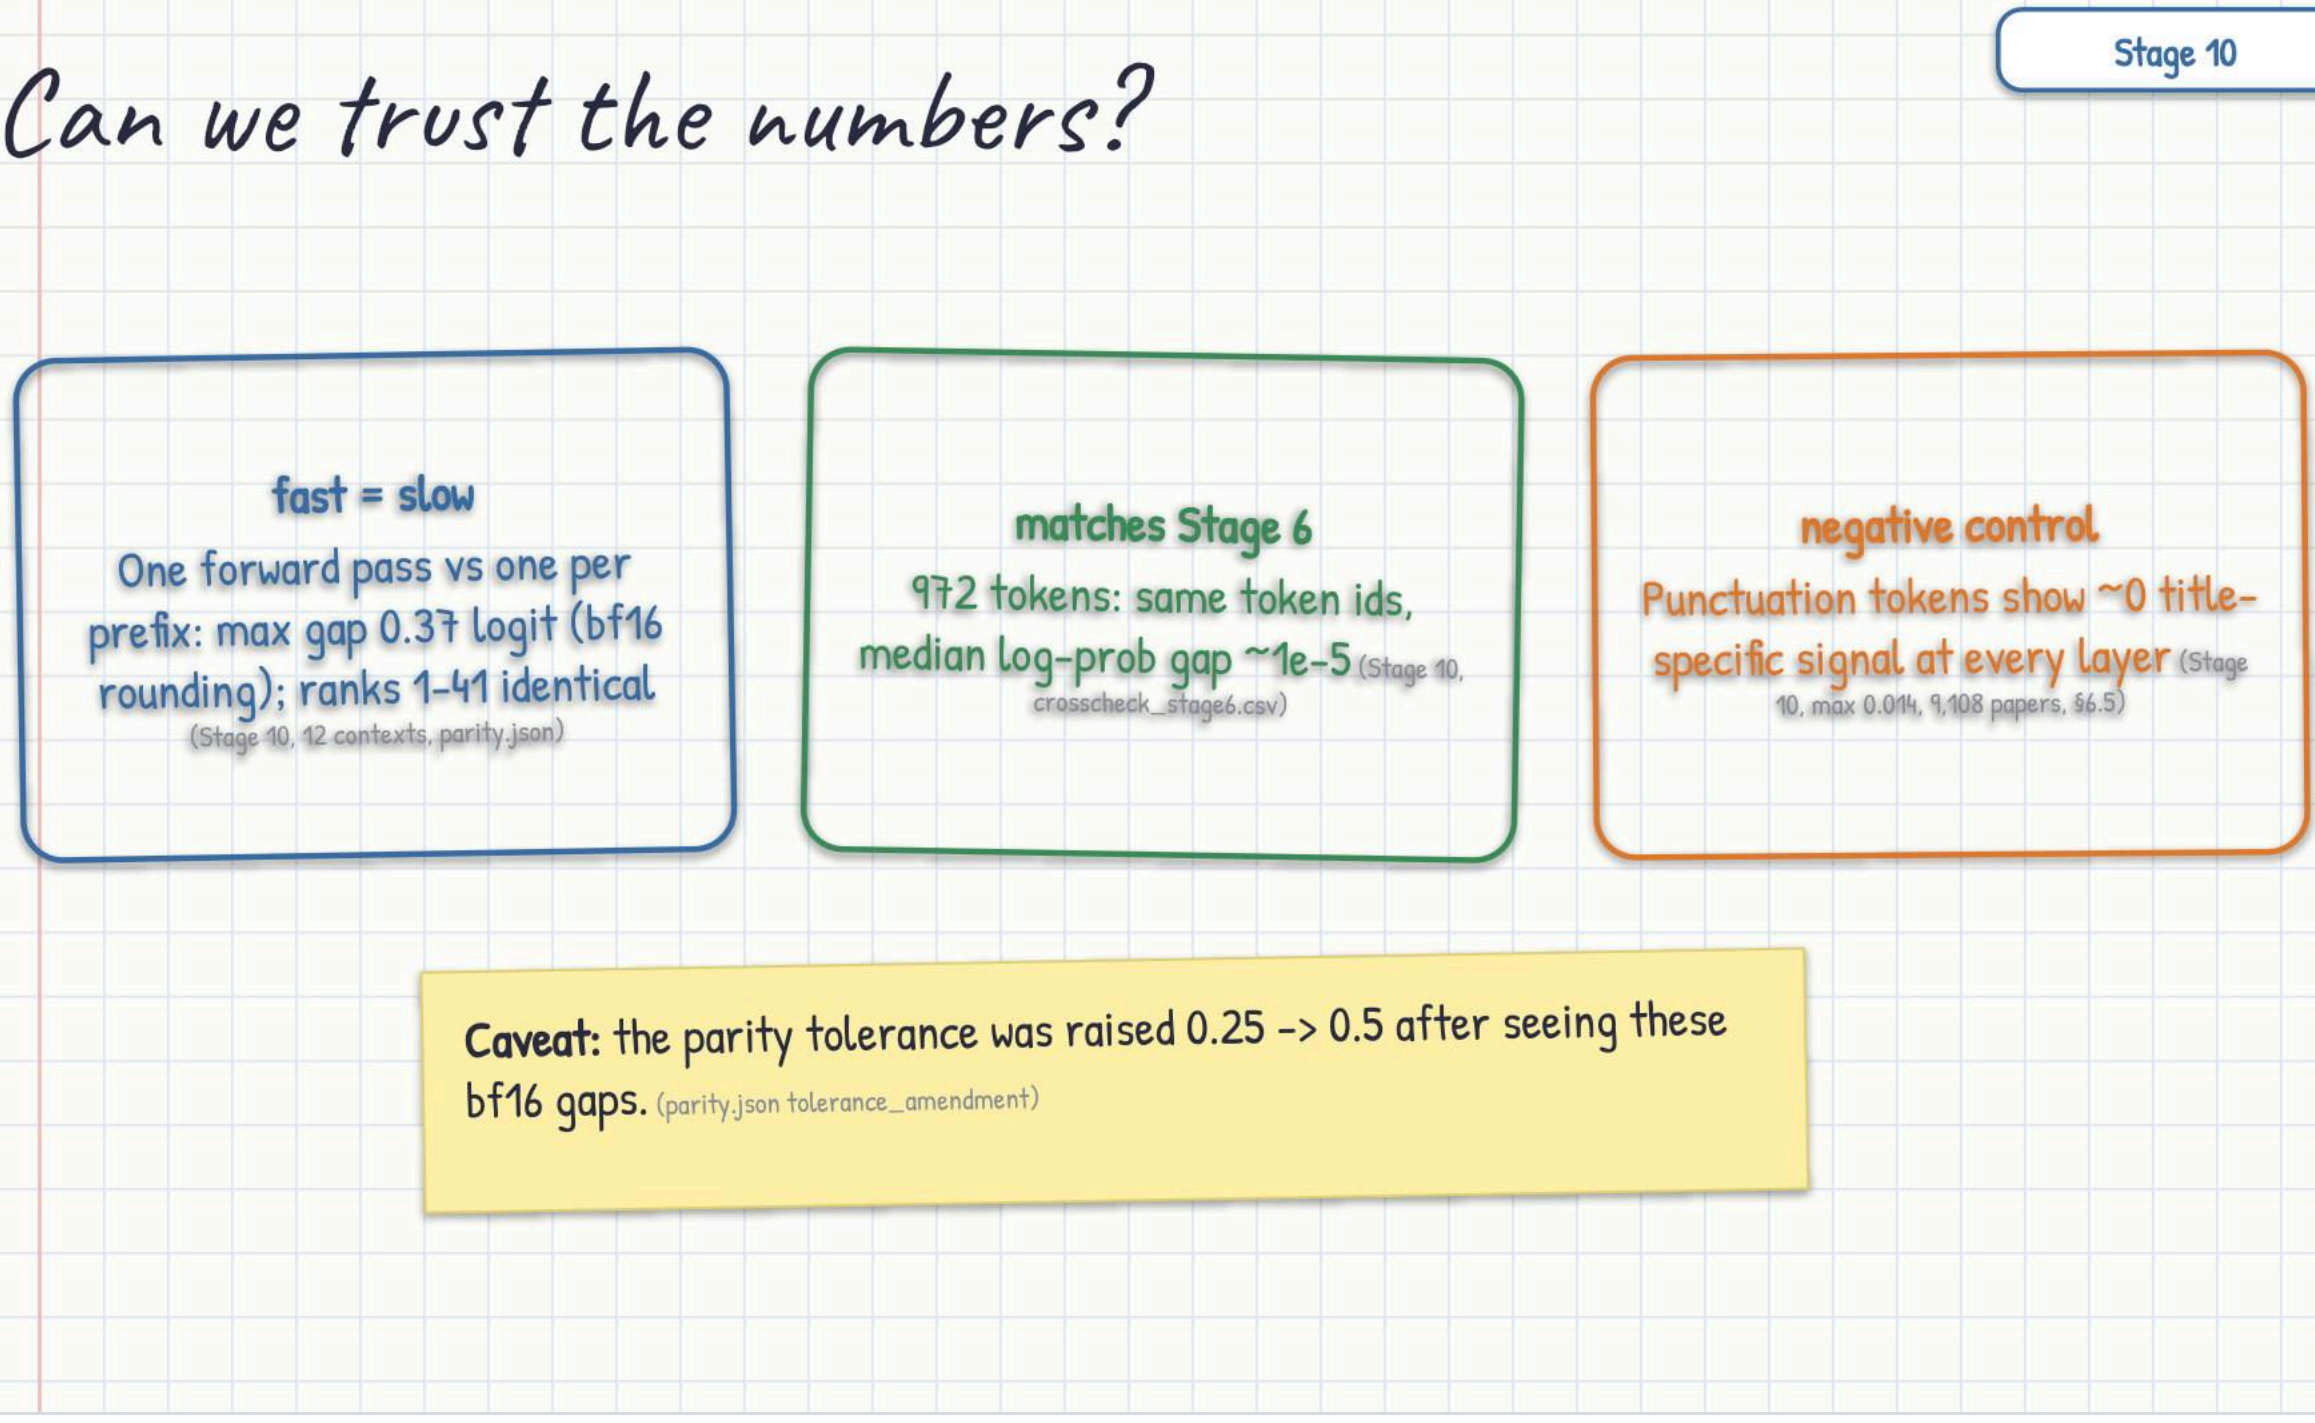
Stage 2 固定了模型、提示词和打分方式，之后所有测量都在这些设置下进行。模型是 Qwen3-32B，BF16，revision 9216db57，64 层，隐藏维度 5,120（Qwen3-32B 配置；351_stage6/config/protocol.json、351_stage6/config/runtime.json；hidden_size 5120 见 HF config.json）。读出层是 L16 到 L62 共 7 层（Stage 2 读出层 L16、24、32、40、48、56、62；351_stage6/config/protocol.json；~/jlens_work/05_stage5/351_stage5.py），读出方式有公开的 J-Lens、logit lens 和模型真实输出。名次 r 定义为 1 加上 logit 严格更大的 token 数。每次运行都会核对强制输入的 token，两条读出路径的最终 logit 差超过 0.1（守卫阈值；~/jlens_work/05_stage5/351_stage5.py:205-206；~/jlens_work/04_stage4/351_stage4_readout.py:86-89）就拒绝这次运行。



这一页是所有数字背后的规则。开放回答用对话模板内的贪心解码；用确定性的模糊姓名匹配数出匹配 M、编造 H、遗漏 U，HR2 = (H+U)/(M+H+U)。HR2 不超过 0.5（标注规则 recall_failure_threshold 0.5；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/rules.yaml、step1_README.md）为 R2，否则一个没匹配上是 R0，匹配上一些是 R1，全程没有人工或模型评判。多选题把真名单和同领域、团队大小相近、同引用档、年份相近的另外 3 篇论文（多选题 4 个选项 = 真团队 + 3 个干扰团队；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/step1_README.md；mc_team.jsonl）的真实团队放在一起，问 4 种顺序（顺序 ABDC、BCAD、CDBA、DACB；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/step1_README.md）；字母概率取自下一个 token 的分布，“A”和“ A”相加，不做重新归一化（平均总和 1.00（标注包 mc_results.jsonl，kind=team，36,432 次：字母概率和均值 0.998，最小 0.142，低于 0.5 的只有 3 次（同一篇论文）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 检查行））。target 是 4 次全对且真字母平均概率至少 0.5（标注规则 group_tight（min_orders 4, min_p_true 0.5）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/rules.yaml），control 是最多对 1 次（同上 rules.yaml，control = 至多 1/4）。



方法。提示词是“Who are the authors of the paper titled ‘…’ (年份)? Authors:”，后面接一位作者的名字。用教师强制：在每个名字 token 之前，看正确 token 排第几。读出方式有 logit lens、三种 Jacobian lens（Neuronpedia 公开的、self100、fitA）和模型真实输出，层从 L24 到 L62。指标是 log10(1/名次)：排第 1 为 0，排第 10 为 −1。每篇论文还要用 5 个匹配的假标题（Stage 10 标题条件设计：每篇 5 个匹配假标题（false_0–false_4）加删去标题；351_stage10/config/conditions_manifest.json）和删去标题各跑一遍；标题特异信号 = 真标题减去假标题的平均，这样名字本身好不好猜的影响就抵消了。



相信数字之前做了三项检查。第一，快速路径和逐个前缀的参考路径一致，差异只在 bf16 舍入范围内。第二，在 972 个重叠 token（Stage 10 与 Stage 6 交叉核对，13 组读出×层各 972 个 token，名次完全相同比例 76.5–95.5%；351_stage10/reports/crosscheck_stage6.csv）上，名次和上一阶段（Stage 6）一致。第三，标点 token 不可能依赖标题，它们的标题特异信号确实约为 0。需要如实说明：一致性检查的容差是在看到结果之后从 0.25 放宽到 0.5（Stage 10 parity，12 个上下文、52 个位置，最大 |logit 差| 0.156–0.367（final@L63 0.367）；351_stage10/reports/parity.json tolerance_amendment；351_stage10/config/analysis_plan.json amendments）的。

Line A

Is it about this paper?



small samples asked

Does the true title beat a crossed or shuffled title? Does A gain more than B?

→

the full cohort answered

Title-specific signal for every token; target beats control only late; name prior split out; probe controls

A 线的问题是：信号是不是针对这篇论文？小样本阶段问的是，真标题能不能胜过交叉标题或打乱的标题，A 组是不是比 B 组得益更多。全量阶段的回答是：对每个 token 计算标题特异信号；目标组只在最后几层才领先对照组；把名字先验单独拆了出来；并做了 probe 的对照检验。

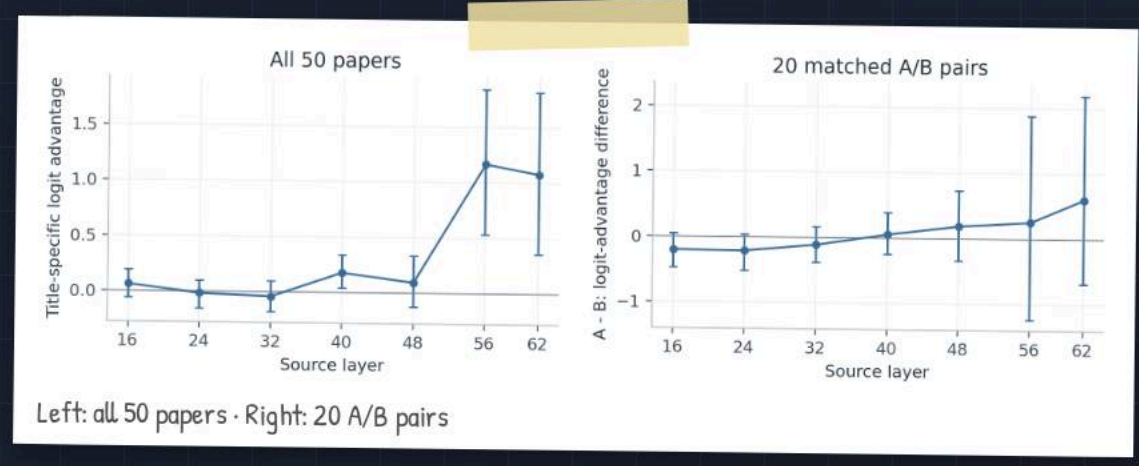
Stage 5 · Line A

Crossed title–author control

Is the gold name high because of the title, or because the name is easy?

Paper P (author G) and source paper Q (author F, same field & bin).
M = logit(G) − logit(F) · T = M(P title) − M(Q title)
A fixed preference for G cancels out.

- All 50 papers: L56 +1.17 [0.53, 1.84], L62 +1.08 [0.36, 1.82](Stage 5, J-Lens, 50 papers, layer_summary.csv)
- Matched A–B, 7-layer integrated: +0.08 [−0.43, +0.65](20 pairs, matched_ab_summary.csv)



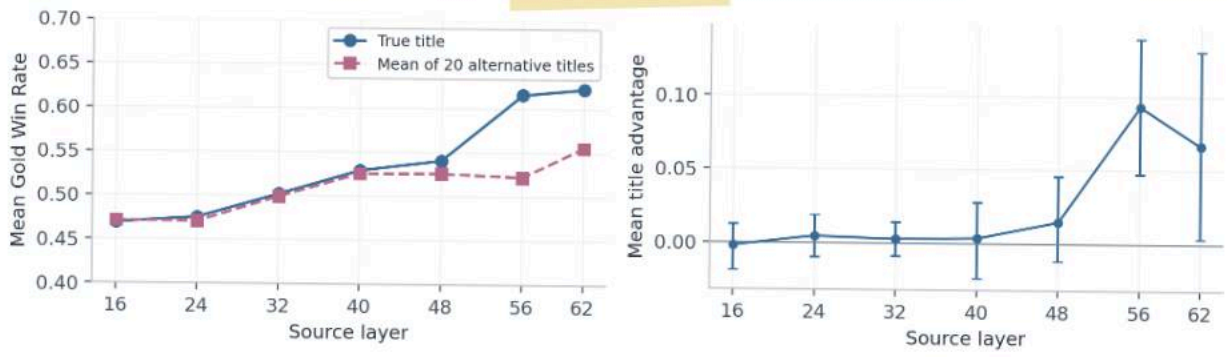
Left: all 50 papers · Right: 20 A/B pairs

The title changes which name wins in late layers. Whether A gains more than B: **not established**.

Stage 5 做的是交叉标题对照：正确名字排得高，是因为标题，还是因为这个名字本身好猜？做法是拿论文 P（作者 G）和同领域、同引用档的来源论文 Q（作者 F）互换标题，看 G 相对 F 的 logit 差在两种标题下的变化，这样对 G 的固定偏好就被抵消了。全部 50 篇论文上（Pilot50；351_stage5_crossed_v2/cohort/pilot50_v1.csv），L56 为 +1.17 [0.53, 1.84]，L62 为 +1.08 [0.36, 1.82]（Stage 5，J-Lens，交叉对比（G 对 F 的 logit 差在两种标题下的变化），50 篇，论文 bootstrap 95% CI：L56 +1.167 [0.533, 1.838]、L62 +1.077 [0.363, 1.816]；报告 Stage 5 节图 5.1 左；351_stage5_crossed_v2/summary/layer_summary.csv 行 group=ALL），说明标题会改变后几层里谁胜出；但 20 对 A/B 匹配的 7 层积分只有 +0.08 [−0.43, +0.65]（Stage 5，J-Lens 7 层积分，匹配 A − B，20 对，+0.081 [−0.426, +0.648]，配对 bootstrap 95% CI；报告 Stage 5 节图 5.1 右；351_stage5_crossed_v2/summary/matched_ab_summary.csv 行 layer=integrated），A 是否比 B 得益更多还不能确定。

Shuffled titles: the true title helps

Same 100 candidates, 20 metadata-matched wrong titles per paper, 1,000 contexts; only the title changes



All 50 papers: true vs mean of 20 alternative titles

- Pooled L56: 0.616 vs 0.523 → +9.3 pp [4.8, 14.0], 35/50 papers positive (J-Lens L56, 50 papers; paper_null_distribution.csv; CI recomputed 10-30)
- Leave-one-out: +8.6 to +10.0 pp (stage7_l56_loo.csv)
- Vanilla L56 +10.6 pp, final output +7.2 pp (paper_null_distribution.csv)
- Matched A–B integrated: +0.018 [−0.021, +0.063] (20 pairs, integrated_ab_bootstrap.csv)

Two different questions: "does the title help?" **yes**; "does it help A more than B?" **not shown**.

 新写讲稿

Stage 7.3 用打乱的标题：候选名字不变，每篇论文配 20 个元数据匹配的错误标题，共 1,000 个上下文（Stage 7.3 设计，50 篇 × 20 个替代标题；~/jlens_work/07_3_stage7_3/351_stage7_3.py:83-91；351_stage7_3/reports/freeze_audit.md），只有标题在变。全部 50 篇合并（Pilot50 50 篇；351_stage7_3/summary/paper_null_distribution.csv），L56 上真标题 0.616 对错误标题平均 0.523（Stage 7.3，J-Lens L56，金标准首 token 胜率，合并池，50 篇均值：真标题 0.6160、20 个错误标题平均 0.5226；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）列 true_win、null_mean），高 +9.3 个百分点 [4.7, 13.9]，50 篇里 35 篇为正（Stage 7.3，J-Lens L56，真标题胜率 − 20 个错误标题平均胜率，合并池，Pilot50 50 篇均值 +0.0934 [0.047, 0.139]（2026-10-30 重算区间，B = 20,000），35/50 篇为正；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv；报告 Stage 7.3 节）；逐篇剔除后在 +8.6 到 +10.0 之间（Stage 7.3，J-Lens L56 标题优势，50 篇逐一留出一篇后的均值范围 +8.64 到 +9.99 pp；351_stage7_3/recompute_2026-10-30/stage7_l56_loo.csv）。Vanilla 在 L56 为 +10.6，最终输出 +7.2（Stage 7.3，Vanilla L56 / 最终输出 L63，真标题胜率 − 20 个错误标题平均，合并池，50 篇均值 +0.1063 / +0.0716；351_stage7_3/summary/paper_null_distribution.csv（mode=vanilla_L56、final_L63））。但匹配的 A−B 积分只有 +0.018 [−0.021, +0.063]（Stage 7.3，J-Lens 7 层积分标题优势的匹配 A − B，合并池，20 对，+0.0177 [−0.0211, +0.0626]，配对 bootstrap 95% CI；351_stage7_3/summary/integrated_ab_bootstrap.csv 行 jlens/combined）。这里要分清两个问题："标题有没有帮助"，答案是有；"对 A 的帮助是否比对 B 大"，没有证明。

Stage 7.3 · robustness

Does the title effect survive the obvious objections?

Source-author overlap

199/1,000 wrong titles come from a paper whose author is in the false pool. Excluding them: +0.026 → +0.028.(quality.json; paper_null_distribution.csv)

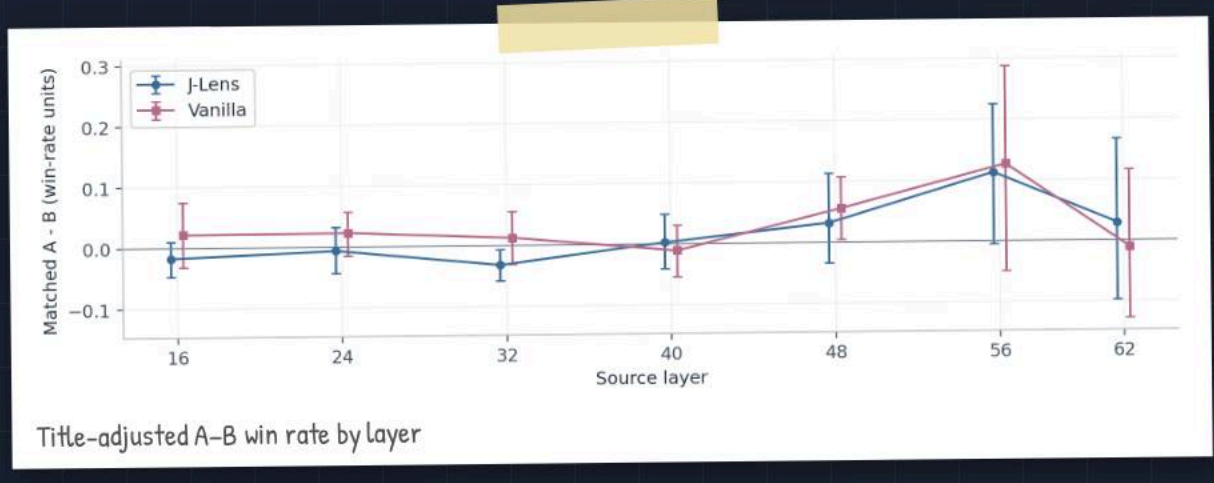
Candidate weighting

Author-, unique-token- and non-collision weights: pooled +0.026 to +0.032; all six A–B CIs include 0.

(stage7_weighting_title_advantage.csv)

Low citations

0–2 citations (n = 6): L56 +0.22, 5/6 positive, but 0/6 beyond its own 20-title tail (≤ 0.05).(floor_L56_low_six.csv)



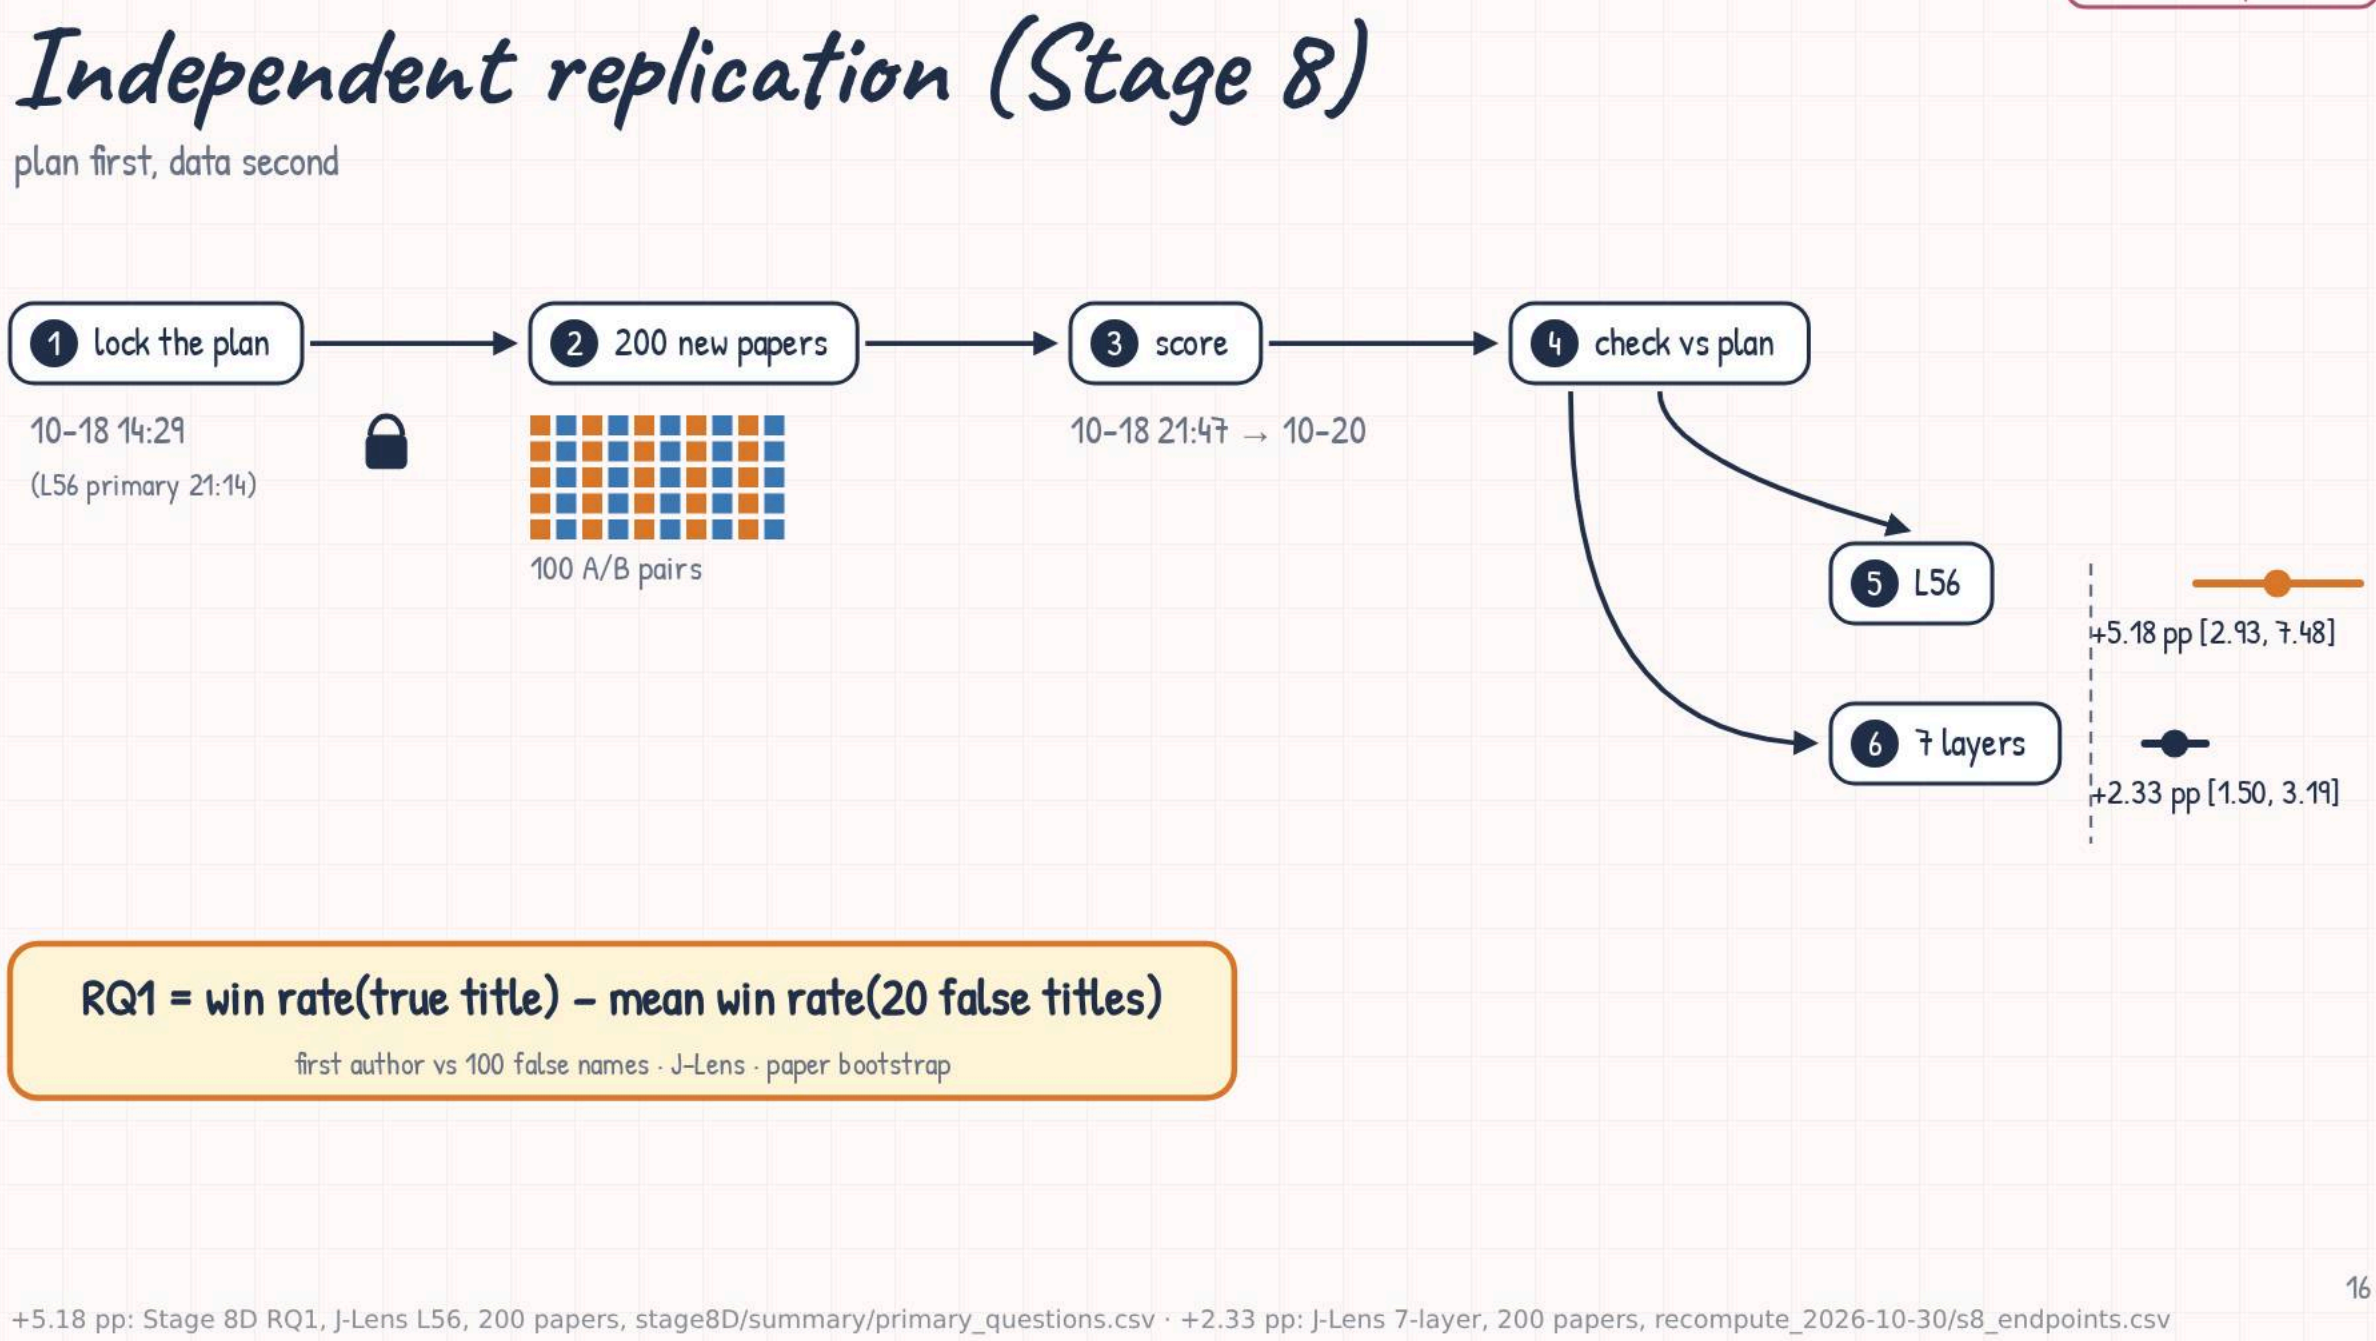
Title-adjusted A–B win rate by layer

Layer heterogeneity

L56 +0.11 but L32 **−0.03** (CI below 0).(20 pairs, matched_ab_bootstrap.csv) Reporting only the positive layers would mislead.

第 15 / 75 页 · Stage 7.3 · robustness · 合并 PPT 自身页面 **新写讲稿**

这一页检查标题效应能否经受几种显而易见的质疑。第一，1,000 个错误标题里有 199 个（Stage 7.3，199/1,000 个替代标题的来源论文作者在错误作者池中；351_stage7_3/summary/quality.json）来自作者在候选池里的论文，剔除后效应从 +0.026 变为 +0.028（Stage 7.3，J-Lens 7 层积分标题优势，合并池，50 篇均值 +0.0262 → 剔除重叠后 +0.0283；351_stage7_3/summary/paper_null_distribution.csv 列 title_advantage / advantage_no_source_false_overlap（方法手册重算））。第二，换成按作者、按唯一 token、按非碰撞加权，合并效应在 +0.026 到 +0.032 之间（Stage 7.3，J-Lens 7 层积分标题优势，作者加权 / 唯一 token / 去平局 +0.026 / +0.032 / +0.027，50 篇；351_stage7_3/recompute_2026-10-30/stage7_weighting_title_advantage.csv），但六个 A–B 区间都含 0（Stage 7.3，3 种加权 × J-Lens/Vanilla 的 7 层积分匹配 A − B，20 对，配对 bootstrap 95% CI；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv 行 16–27）。第三，0–2 次引用的 6 篇论文 L56 为 +0.22，6 篇里 5 篇为正（Stage 7.4 低引用分析，J-Lens L56 标题优势，0-2 档 6 篇，均值 +0.224，5/6 为正，0 篇超出自身 20 个错误标题的 5% 尾部；351_stage7_4/summary/floor_L56_low_six.csv；351_stage7_4/summary/overview.json "floor_low_six_L56"），但没有一篇超出它自己 20 个错误标题的尾部（Stage 7.3 每篇 20 个替代标题；~/jlens_work/07_3_stage7_3/351_stage7_3.py:83-91）。第四，层之间差异很大：L56 为 +0.11，L32 却为 −0.03（区间在 0 以下）（Stage 7.3，J-Lens 单层标题优势的匹配 A − B，合并池，20 对，配对 bootstrap 95% CI：L56 +0.113 [−0.005, +0.225]，L32 −0.032 [−0.058, −0.006]；351_stage7_3/summary/matched_ab_bootstrap.csv 行 jlens_L56 / jlens_L32 combined），只报告正的那些层会误导。

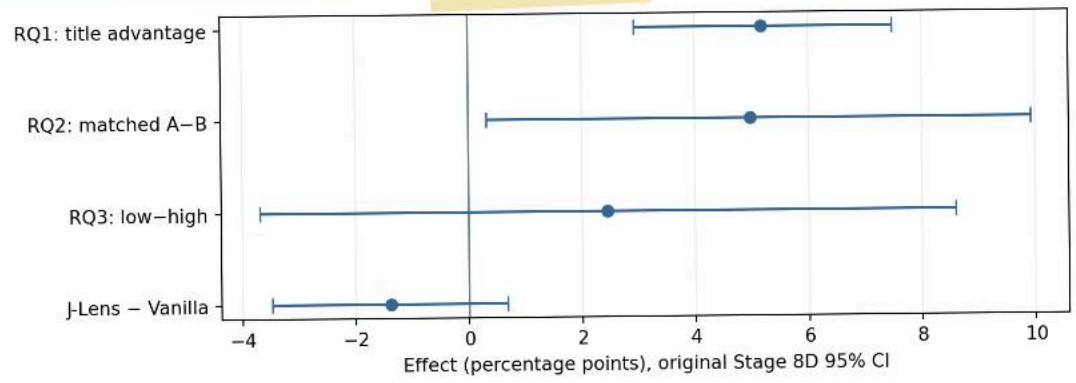


第 16 / 75 页 · Method · Independent replication (Stage 8) · 合并 PPT 自身页面 **新写讲稿**

Stage 8 是独立重复：分析计划在 10 月 18 日 14:29 冻结（analysis_plan.json），当天 21:14 的协议把 L56 定为主层，仍在打分之前。然后取 200 篇新论文（100 对 A/B）（Stage 8A 抽样，100 对匹配 A/B；351_stage8/cohort/stage8_papers.csv；351_stage8/summary/matching_audit.json），10 月 18 日 21:47 开始打分、10 月 20 日结束，再按计划检查。RQ1：L56 处真标题相对 20 个假标题的胜率高 +5.18 个百分点 [2.93, 7.48]（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节）；计划里冻结的主终点（7 层平均）是 +2.33 [1.50, 3.19]（Stage 8 冻结计划主终点，J-Lens 7 层积分，真标题 − 20 个错误标题平均，200 篇，+2.33 pp [1.50, 3.19]，论文 bootstrap 95% CI；351_stage8/recompute_2026-10-30/s8_endpoints.csv）。

Stage 8D · Lines A, B

On 200 new papers the title effect replicates



Stage 8D L56 estimates (PROTOCOL.md), 95% CI (pp)(primary_questions.csv)

(Stage 8D, J-Lens L56; primary_questions.csv)	Estimate	95% CI
RQ1 title, L56(200 papers)	+5.18 pp	[+2.93, +7.48]
RQ2 A–B, L56(100 pairs)	+4.98 pp	[+0.32, +9.91]
RQ2 A–B, 7-layer (frozen primary)(100 pairs; s8_endpoints.csv)	+2.41 pp	[+0.91, +4.00]
RQ3 low–high(25 + 25 pairs)	+2.45 pp	[−3.69, +8.60]
J-Lens–Vanilla(jlens_minus_vanilla.csv)	−1.38 pp	[−3.48, +0.68]

Citation bands: low +6.8 [2.6, 11.6], mid +4.8, high +4.4 [−1.1, 10.0]

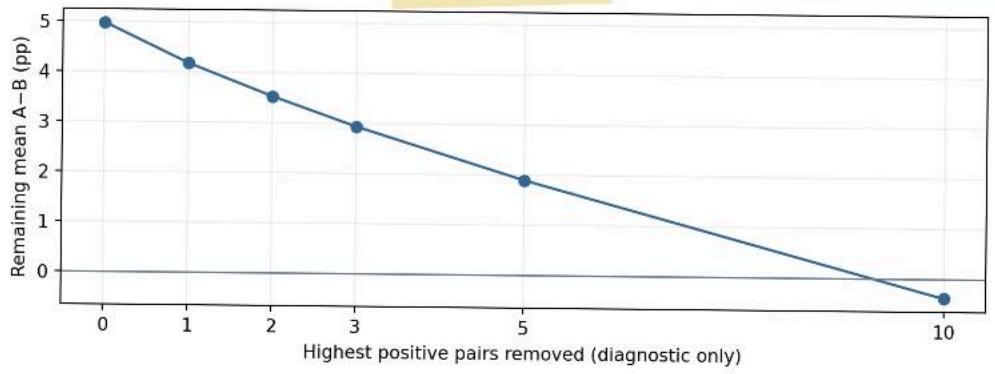
(50/100/50 papers; layer_and_band_summary.csv)

RQ1 is the first **independent** confirmation: correct titles help the gold author on new papers. J-Lens still adds nothing over Vanilla.

 新写讲稿

Stage 8D 在 200 篇全新论文上（Stage 8 新论文；351_stage8/cohort/stage8_papers.csv）冻结设计后复现。RQ1 标题效应 +5.18 个百分点 [+2.93, +7.48]（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节），这是第一次独立确认：正确标题能帮助正确作者。RQ2 的 A−B 为 +4.98 [+0.32, +9.91]（Stage 8D RQ2，J-Lens L56 匹配 A − B，100 对，+4.98 pp [0.32, 9.91]，配对 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ2_matched_A_minus_B）；RQ3 低引用减高引用为 +2.45，区间含 0（Stage 8D RQ3，J-Lens L56，配对平衡的低引用 − 高引用，50 对，+2.45 pp [−3.69, +8.60]；351_stage8/stage8D/summary/primary_questions.csv 行 RQ3_low_minus_high）；J-Lens 减 Vanilla 为 −1.38，区间含 0（Stage 8D，L56 J-Lens − Vanilla 标题优势，200 篇，−1.38 pp [−3.48, +0.68]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/jlens_minus_vanilla.csv）。按引用分档，低档 +6.8，中档 +4.8，高档 +4.4（Stage 8D，J-Lens L56 标题优势按引用带，低 50 / 中 100 / 高 50 篇：+6.83 / +4.75 / +4.38 pp；351_stage8/stage8D/summary/layer_and_band_summary.csv（mode=jlens_L56, scope=citation_band））。J-Lens 仍然没有比 Vanilla 多出什么。

But the A–B gap rests on a few pairs



Remaining A–B after removing the largest positive pairs

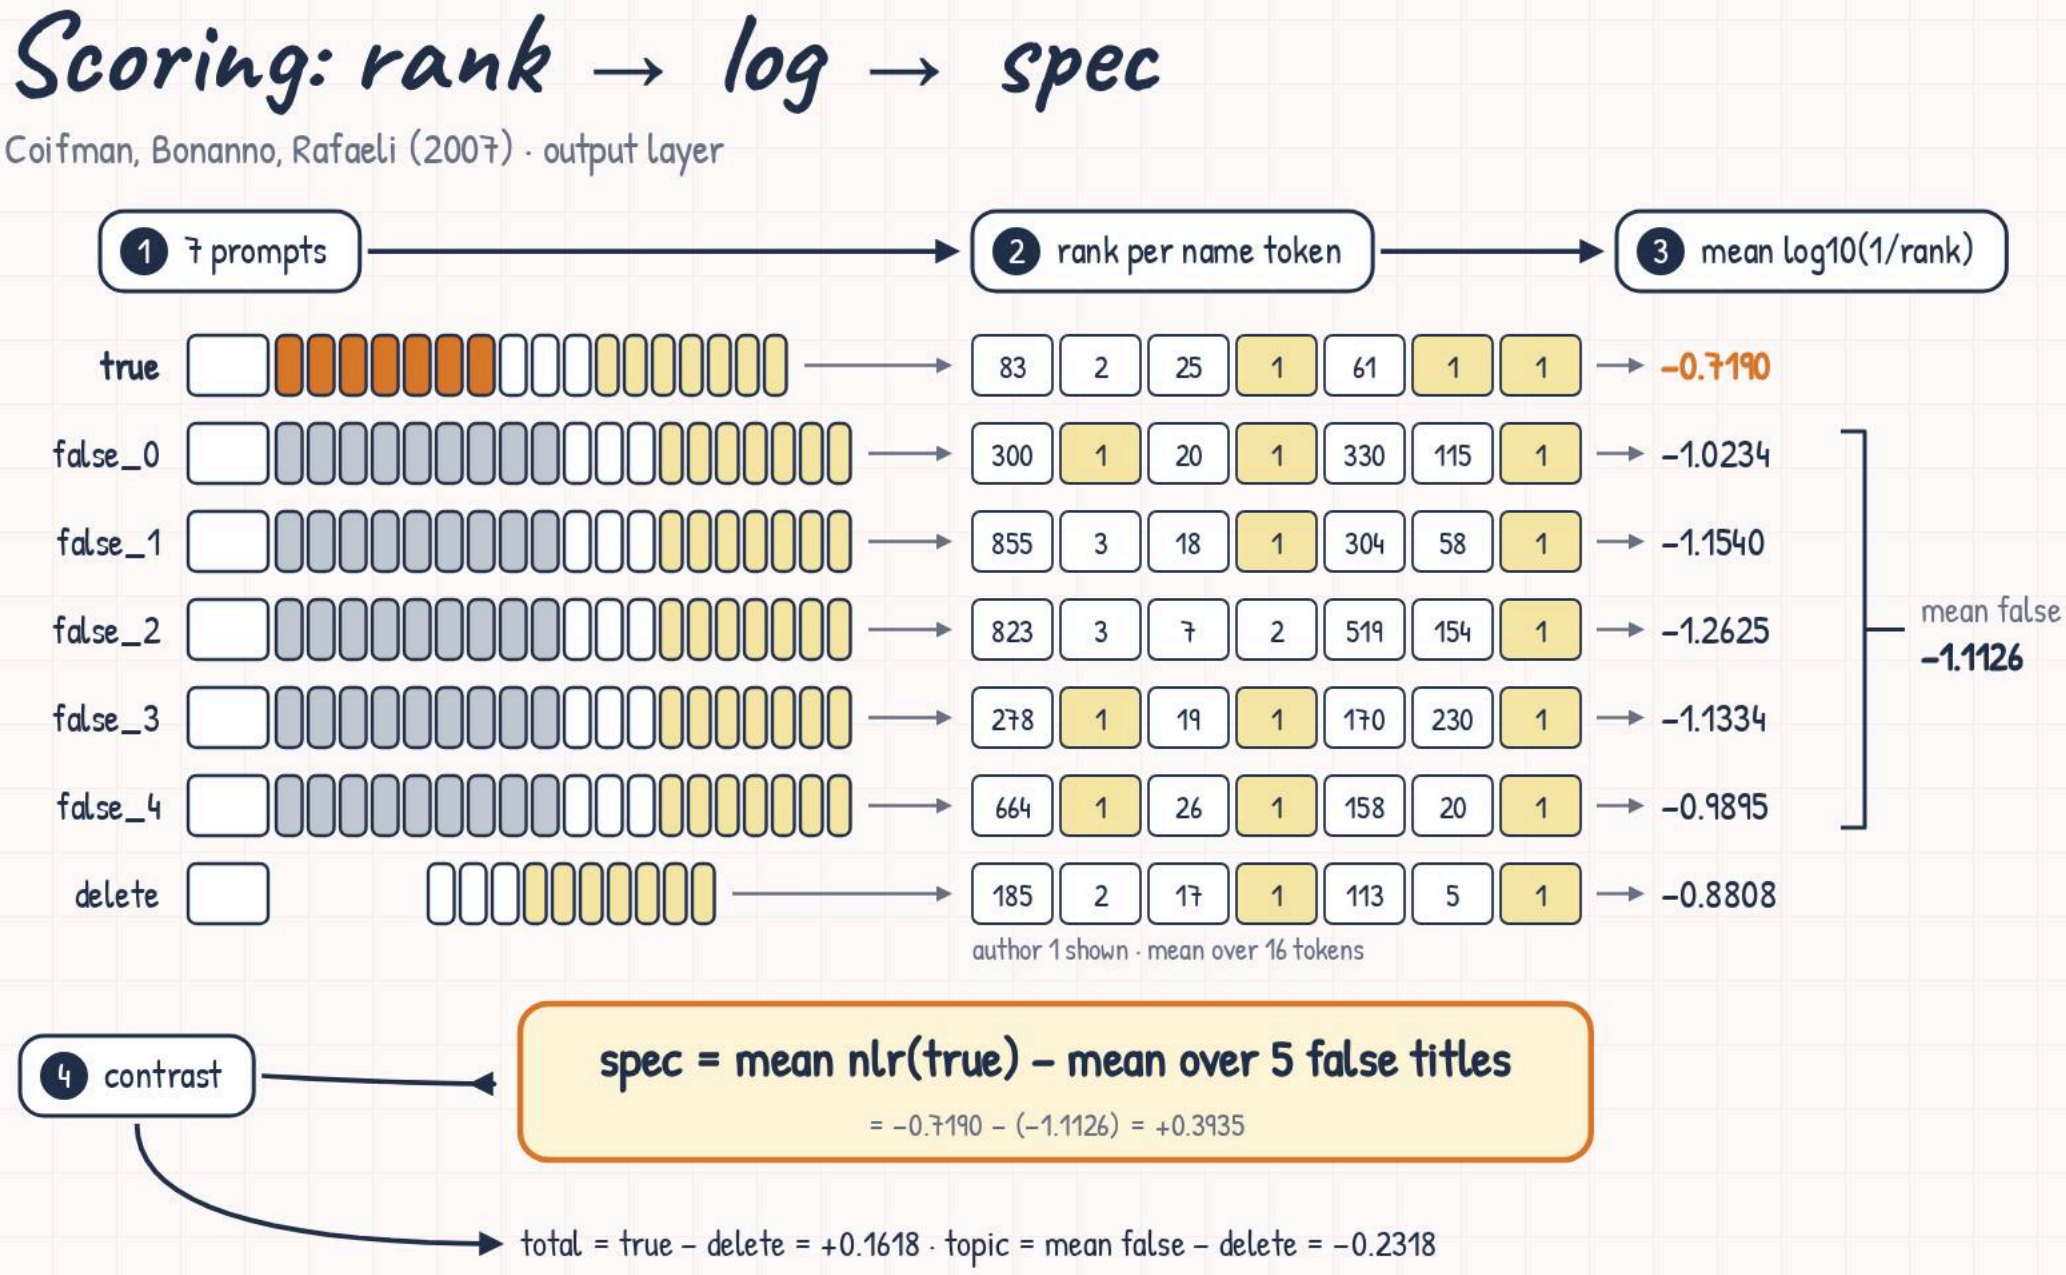
- 100 pairs: 55 positive, 45 negative; median +4.4 pp(J-Lens L56; matched_pair_differences.csv)
- One pair (S8P094) ≈ +84 pp
- Remove top 5 → +1.9 pp; top 10 → −0.4 pp(recomputed from same file)

8E external audit (post-hoc)

- Unique-token weights: RQ1 +4.6, RQ2 +5.4 pp (s8_8E_weighting_by_paper.csv)
- Wrong-title length gap: +0.12 pp per token(200 papers; s8_unsourced_intervals.csv) (association only)
- Original scripts missing; recomputed from raw logits (30 Oct), same estimates(351_stage8/recompute_2026-10-30/): post-hoc only

Small samples can show a positive A–B mean that a handful of papers carry. This is the main reason Stage 10 moved to the full cohort.

但 A–B 的差依赖少数几对论文。100 对里 55 对为正、45 对为负，中位数 +4.4 个百分点（Stage 8D RQ2，J-Lens L56 匹配 A − B，100 对：55 正 / 45 负，中位数 +4.41 pp；351_stage8/stage8D/summary/primary_questions.csv 行 RQ2_matched_A_minus_B；matched_pair_differences.csv（mode=jlens_L56））；其中一对（S8P094）大约 +84（Stage 8D RQ2，最大一对 S8P094 A − B = +84.4 pp；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56））。去掉最大的 5 对后降到 +1.9（Stage 8D RQ2，按 A − B 降序去掉前 5 对后其余 95 对均值 +1.90 pp（事后诊断，方法手册 C 部分重算）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）），去掉 10 对后变成 −0.4（Stage 8D RQ2，J-Lens L56 金标准胜率匹配 A−B，100 对，均值 +4.98 pp，按 A−B 降序去掉前 10 对后其余 90 对均值 −0.39 pp（事后诊断）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）重算；报告 Stage 8D 节）。8E 的外部审计是事后做的，脚本还没归档，不能算完成的实验。小样本可以给出一个由少数论文撑起来的正 A−B 均值，这正是 Stage 10 改用全量数据的主要原因。



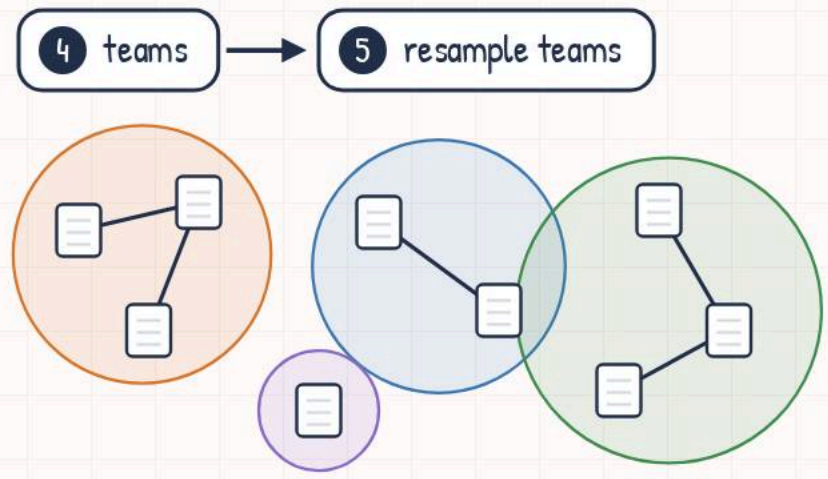
以 Coifman、Bonanno、Rafaeli（2007）为例：同一组名字 token 接在 7 个提示后面（Stage 10 标题条件：真标题、5 个匹配假标题（false_0–false_4）、删去标题；351_stage10/config/conditions_manifest.json）——真标题、5 个匹配的假标题和删去标题。每个名字 token 取它在全词表中的名次，例如第一作者 7 个 token 在真标题下是 83、2、25、1、61、1、1（Stage 10，示例论文 Coifman 等（2007），第一作者 7 个 token，真标题，最终输出 L63 全词表名次；351_stage10/raw/final/L63/shard_011.npz 行 25025–25031；351_stage10/reports/method_figs/coifman_layer_ranks.csv（condition=true, readout=final)），再取 log10(1/名次) 并对 16 个 token 求平均（示例论文 3 位作者共 16 个名字 token；351_stage10/raw/final/L63/shard_011.npz 行 25025–25040）：真标题 −0.7190，5 个假标题平均 −1.1126，删去标题 −0.8808（Stage 10，示例论文，最终输出 L63，16 个名字 token 的平均 log10(1/名次)；方法手册 A_global1 G5.5（351_stage10/reports/methods/parts/A_global1.html）；351_stage10/summary_title/paper_title_contrasts.parquet（readout=final, layer=63））。标题特异信号 spec = −0.7190 − (−1.1126) = +0.3935；total = 真 − 删 = +0.1618，topic = 假 − 删 = −0.2318（同上，示例论文 spec +0.3935、total +0.1618、topic −0.2318；方法手册 A_global1 G5.5；351_stage10/summary_title/paper_title_contrasts.parquet（readout=final, layer=63））。

Statistical conventions

example paper: bin 65–128



$$\Delta = \Sigma\, w_b \cdot (\text{mean}_t - \text{mean}_c),\ w_b \propto n_t \cdot n_c / (n_t + n_c)$$





7,247 teams among 9,108 papers: 381_stage13/reports/cluster_ci.md

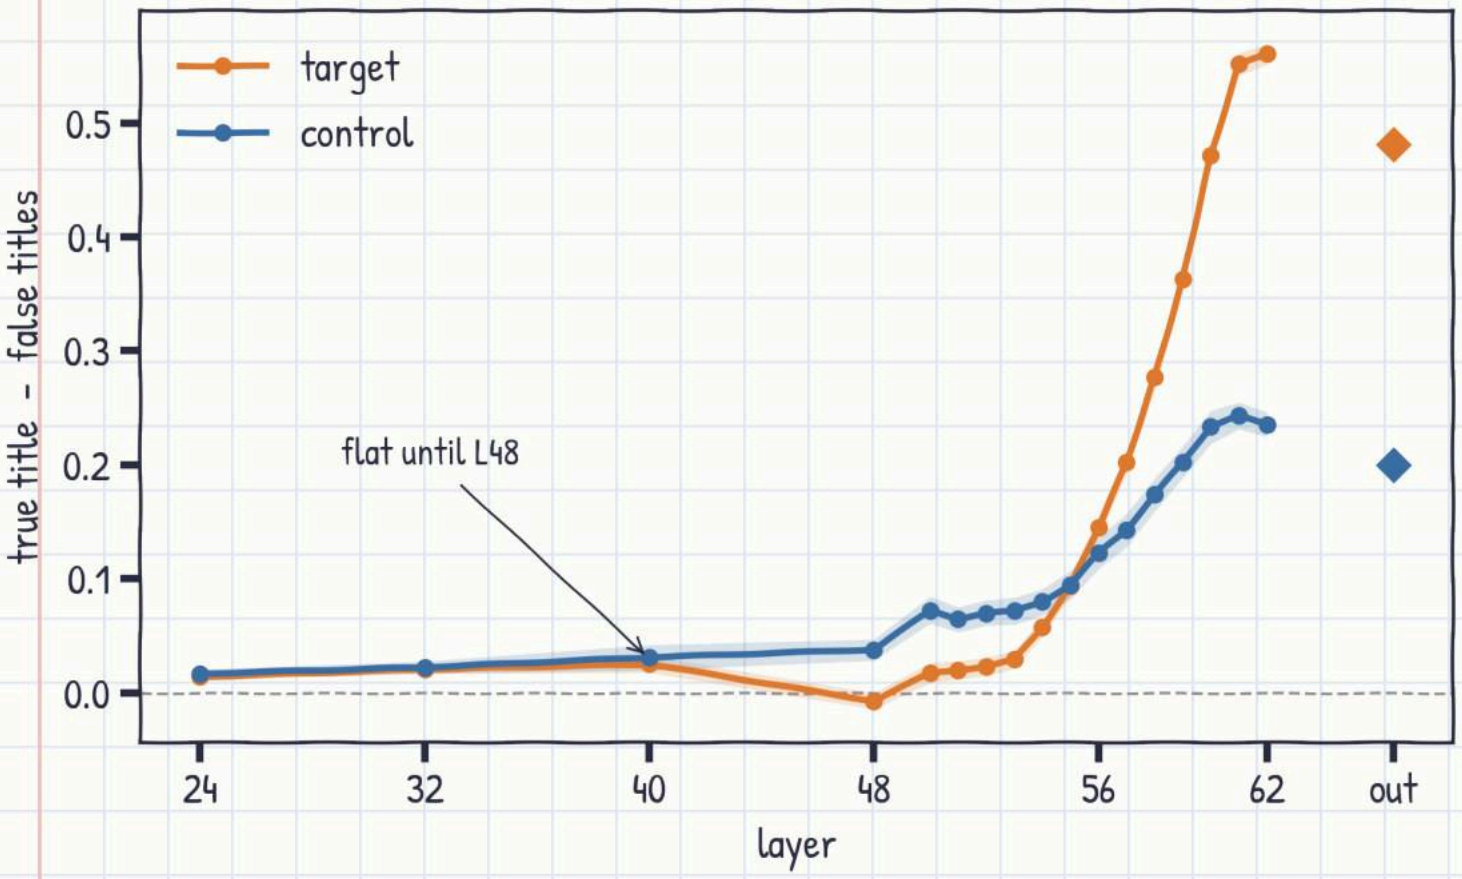
 新写讲稿

组间比较都在引用档内做：13 个引用档（Stage 10 引用档 0-2 … 4097+ 共 13 档；~/jlens_work/10_stage10/351_stage10.py；351_stage10/summary_extra/X2_by_bin.csv）里只用 target 和 control 各至少 30 篇的档（设计常数 MIN_STRATUM = 30；~/jlens_work/10_stage10/351_stage10.py:642；351_stage10/config/analysis_plan.json）（主分析 10 档（满足每组 ≥ 30 篇的 10 个引用档，共有引用档 目标 3,734 + 对照 2,182 篇；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），0-2 到 513-1024），每档内算 target − control，再按 w_b ∝ n_t · n_c/(n_t+n_c) 加权合并。示例论文在 65-128 档，该档 target 441 篇、control 165 篇（Stage 10 队列 group_tight × citation_bin，65-128 档；351_stage10/cohort/papers.parquet）。Stage 13 起置信区间按作者团队重抽样：共享任一作者全名的论文并成一个团队，9,108 篇共 7,247 个团队（Stage 13 团队划分（共享任一作者全名的论文并成一组），9,108 篇 7,247 组；381_stage13/reports/cluster_ci.md 第 3 行；~/jlens_work/13_stage13/stage13_cpu.py group_folds），交叉验证时一个团队只进一个 fold。

Stage 10

Knowing the paper shows up only at the end

title-specific signal · public Jacobian lens (lines) and model output (diamonds)

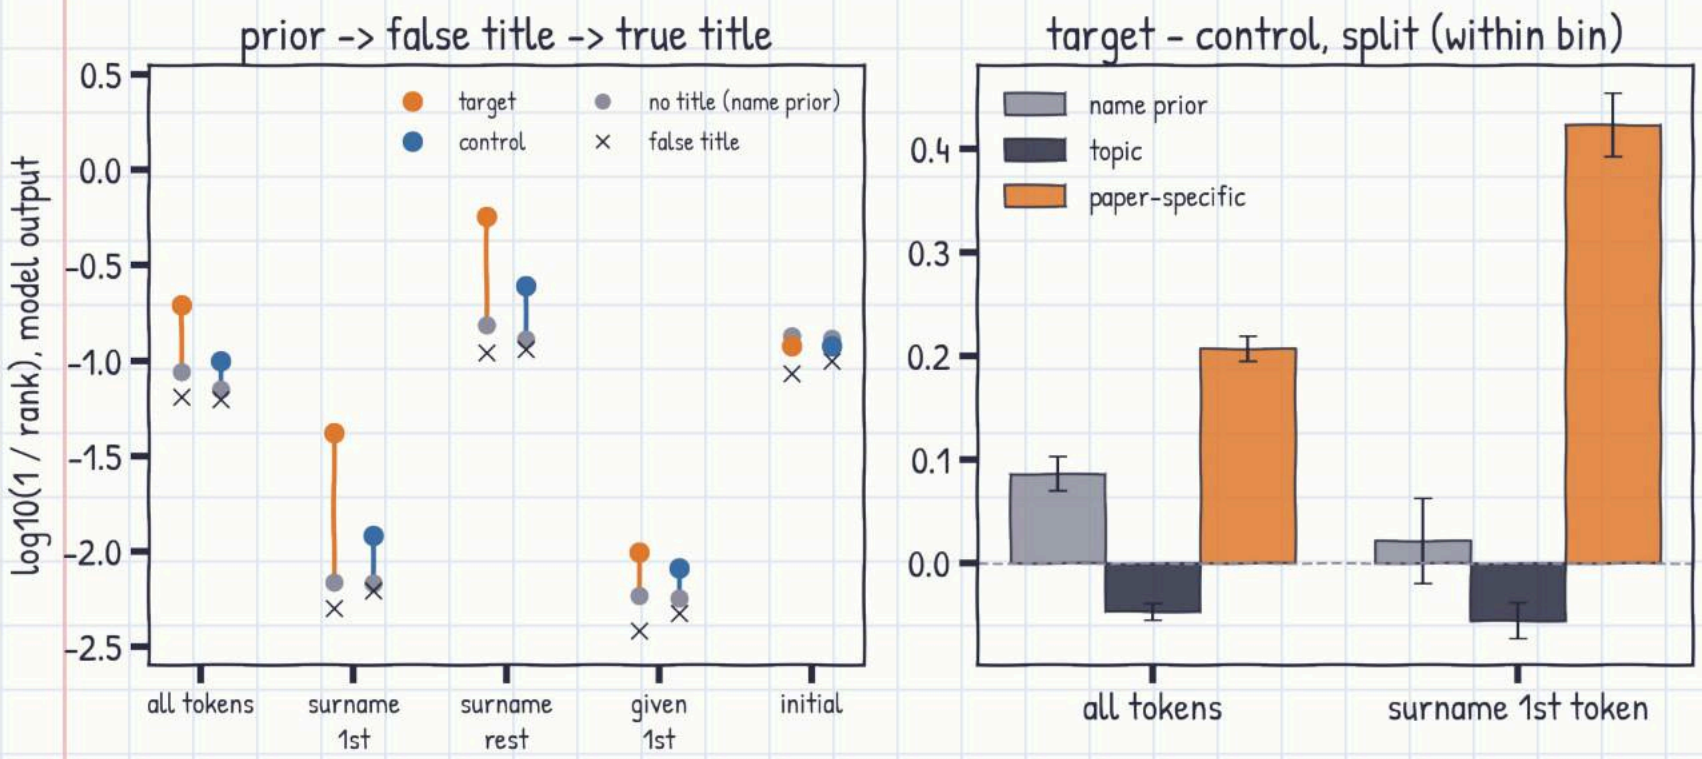


L24–L48: ~0 for both groups (Stage 10, all readouts max 0.04, §6.3)

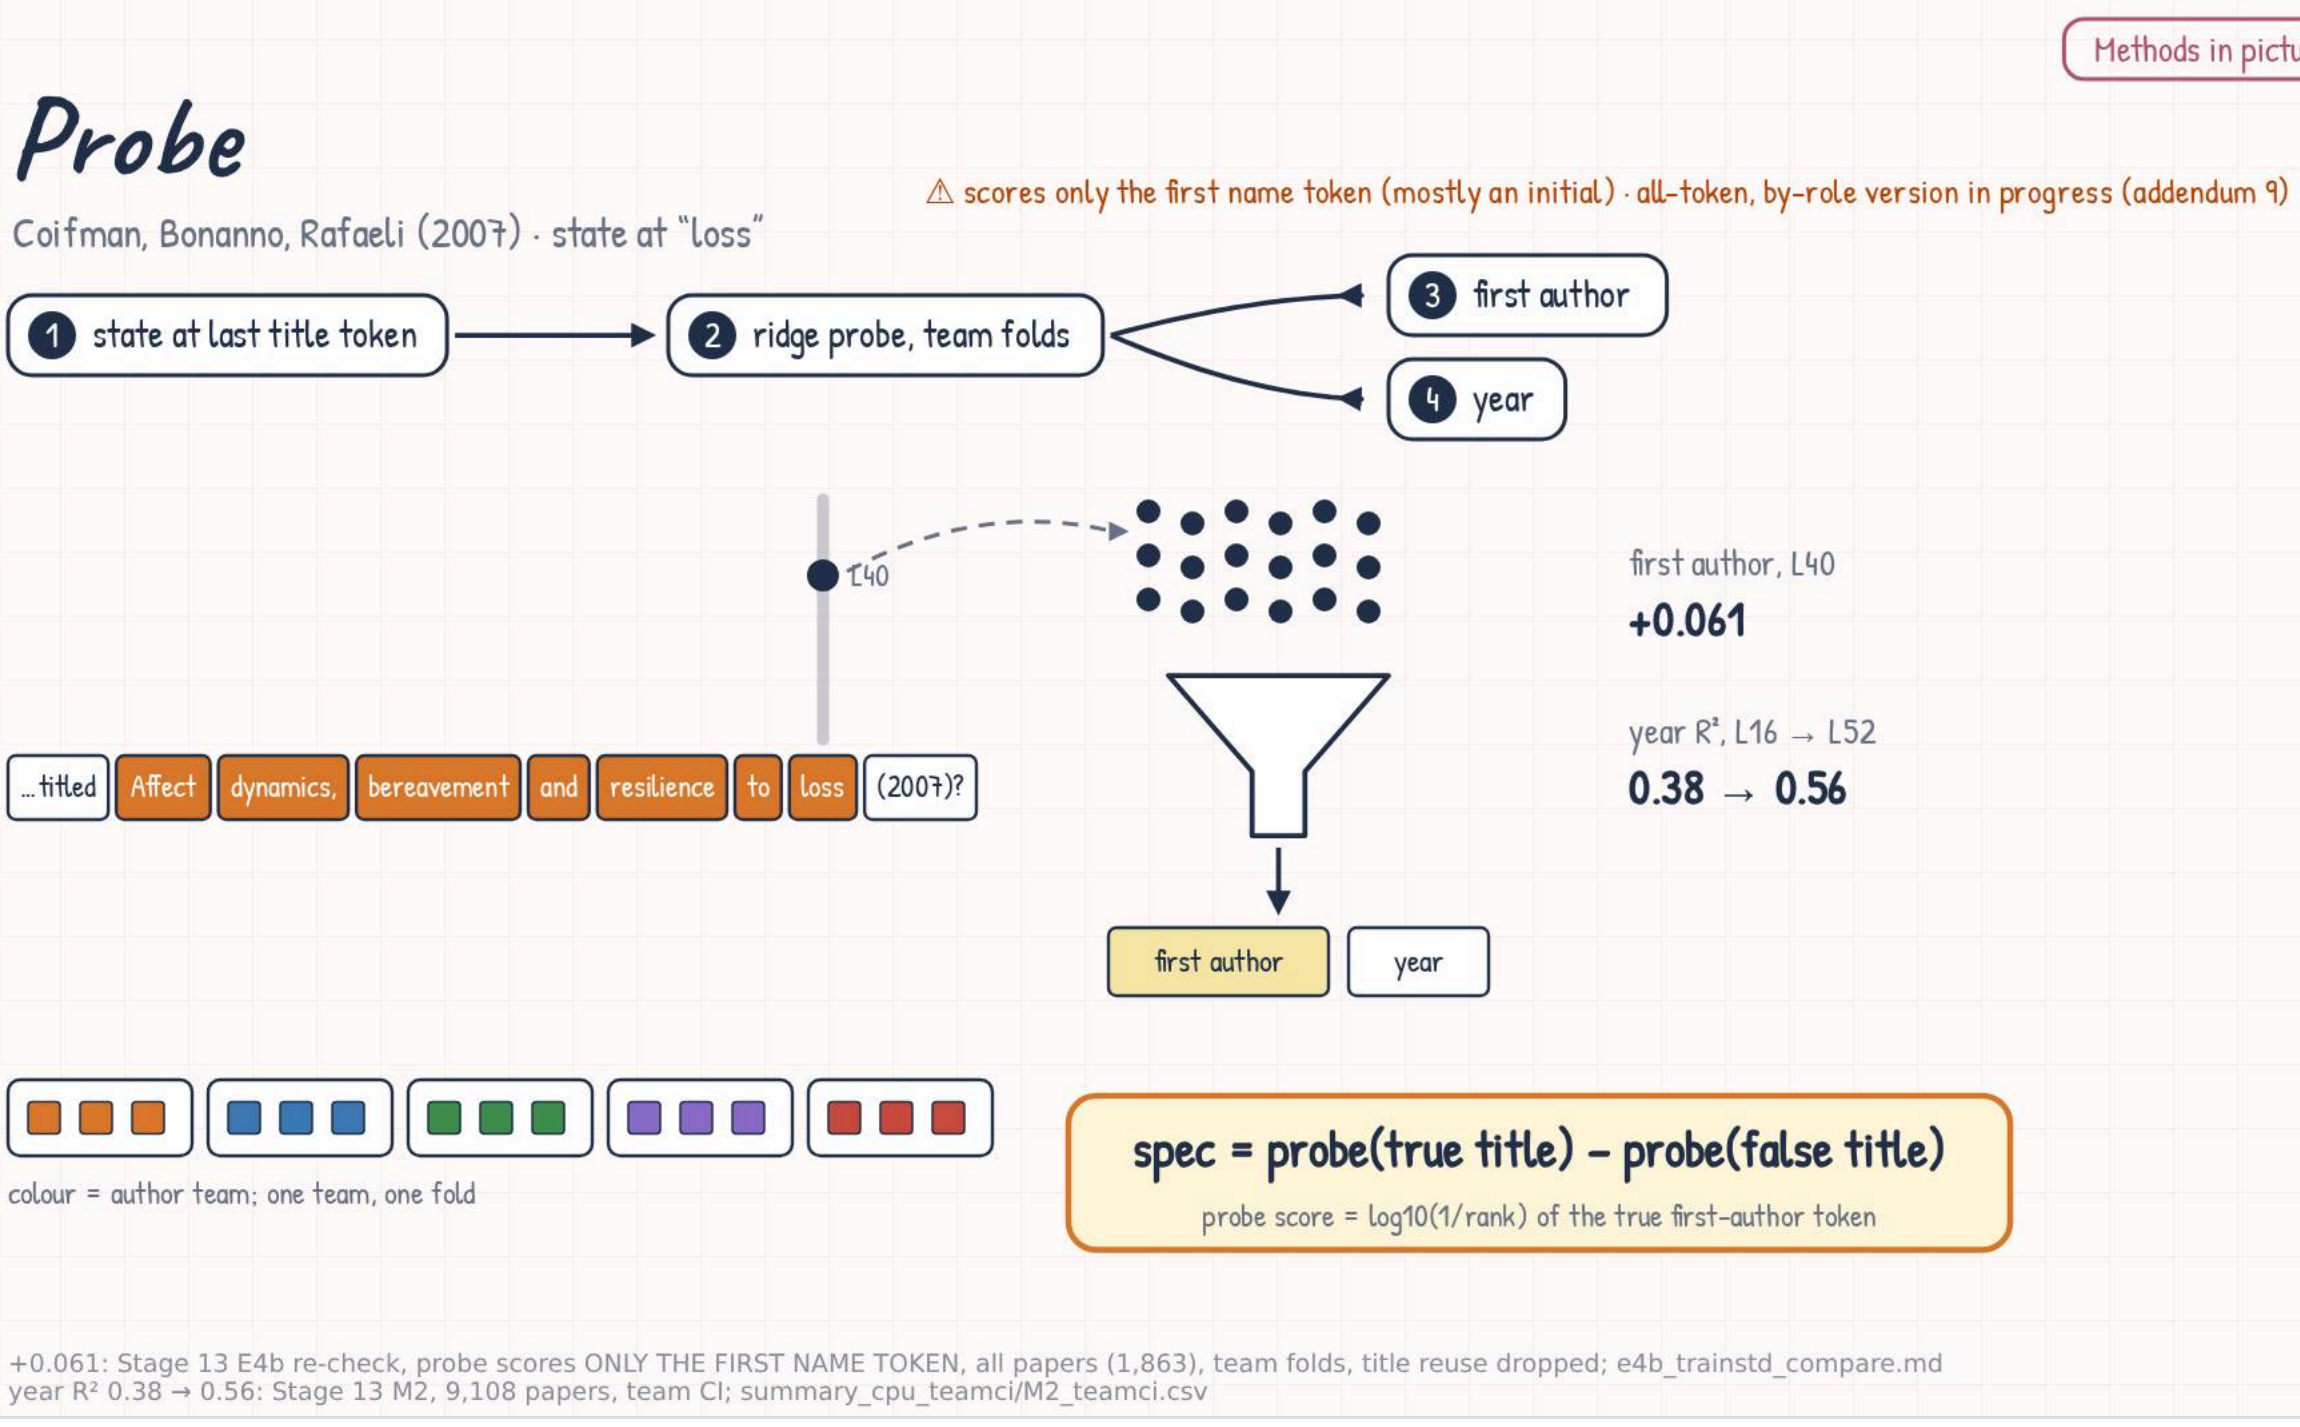
rises at **L56**

L62: **target +0.56** vs **control +0.24**
(Stage 10, public lens L62, 4,621 + 2,220 papers, §6.3 fig.)

现在去掉名字好猜的影响，看真标题减假标题。到 L48 为止，两组都平坦接近 0；从 L56 开始上升，在 L62 和最终输出处最大。目标组最后大约是对照组的两倍（Stage 10，真标题 − 5 个假标题平均，最终输出 L63 各组均值：目标 4,621 篇 0.481，对照 2,220 篇 0.200（比值约 2.4）；报告 §6.3 图；351_stage10/summary_title/A_group_layer.csv）。



名字先验占多少？我们在完全不给标题的情况下给同样的名字打分。没有标题时，正确名字平均已经排在第 12 名左右（Stage 12 名字先验（CPU），不给标题，最终输出 L63，全部 9,108 篇、全部名字 token，平均 log10(1/名次) −1.089 ≈ 第 12.3 名；报告 §6.12；371_stage12/summary_cpu/A_prior_decomposition.csv（all_tokens/all）），因为标点和姓的后半部分在给出前缀后本来就好猜。真标题对姓的第一个 token 帮助最大：目标组从大约第 146 名提到第 24 名（Stage 12 A，姓的第一个 token，目标 4,621 篇，平均 log10(1/名次) 不给标题 −2.164（≈ 第 146 名）→ 真标题 −1.380（≈ 第 24 名）；报告 §6.12 第一张表；371_stage12/summary_cpu/A_prior_decomposition.csv）。在引用档内拆分目标−对照的差：约 0.09 在不给标题时就已存在（Stage 12 A，全部名字 token，最终输出 L63，引用档内 目标−对照（目标 4,621、对照 2,220 篇）：先验 +0.087 [0.070, 0.103]；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）（目标组的名字稍微好猜一些），假标题再抵消 0.05，剩下 0.21 是这篇论文特有的（同上：主题（假标题 − 不给标题）−0.047 [−0.055, −0.038]，论文特有（真 − 假）+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）。只看姓的第一个 token，先验部分约为 0，论文特有部分为 0.42（同上，姓的第一个 token，先验 目标−对照 +0.022 [−0.019, +0.063]，论文特有 +0.423 [0.393, 0.454]；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）。先验和多选题认出程度几乎无关（Spearman 0.09，论文特有部分为 0.33（Stage 12 B，R0/R1 论文 8,894 篇，引用档内中心化后与多选题答对顺序数（0–4）的 Spearman：先验 +0.085 [0.063, 0.106]，论文特有 +0.329 [0.312, 0.346]；371_stage12/reports/stage12_cpu_report.md B；371_stage12/summary_cpu/B_prior_vs_recognition.csv））。



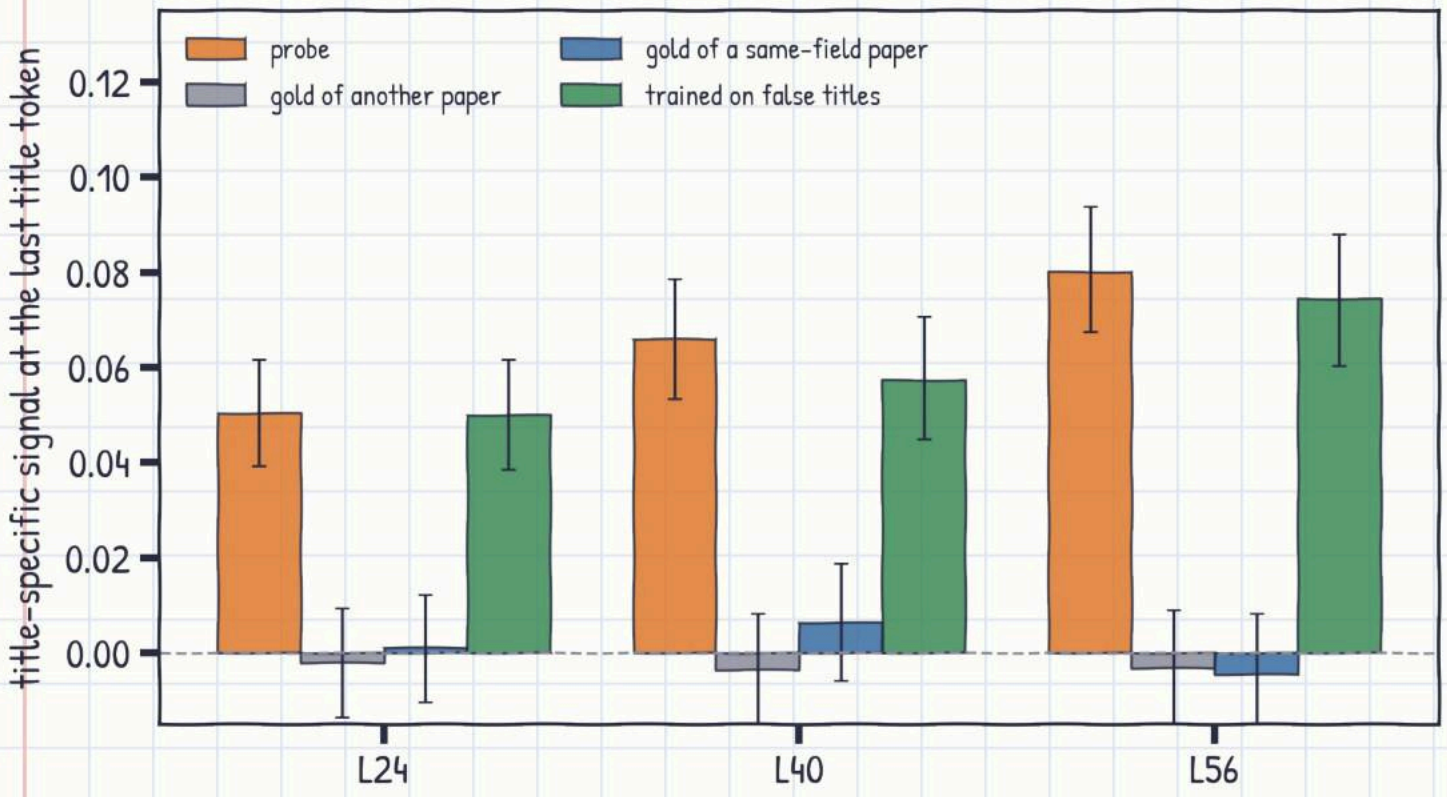
第 23 / 75 页 · Method · Probe · 合并 PPT 自身页面 **新写讲稿**

探针直接从状态读属性：取标题最后一个 token（这里是 “loss”）的残差，例如 L40，用 5 折岭回归（Stage 11 E4b / Stage 13 复核设计：5 折、按作者团队分折，α ∈ {0.1, 1, 10}；~/jlens_work/10_stage10/stage10_extra_r0r1.py probe()；381_stage13/reports/e4b_trainstd_compare.md）（按作者团队分折）预测第一作者的首个 token 或年份。标题特异分数 spec = 真标题的探针分 − 假标题的探针分，L40 为 +0.061 [0.047, 0.076]（Stage 13 E4b 复核，标题最后一个 token 上的 probe，probe 只打分第一作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，全部 1,863 篇，L40 +0.061 [0.047, 0.076]，论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 表 L40 行 new 列）。年份的 R^2 从 L16 的 0.38 升到 L52 的 0.56（Stage 13 M2，真标题，标题最后一个 token，年份岭回归 R^2，9,108 篇：L16 0.383 → L52 0.561，团队整群 95% CI；报告 Stage 13 M2 节；381_stage13/reports/m2_teamci.md 第 46、86 行）（M2）。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母/名/姓分开的版本按补充 9 进行中，尚无结果。

Stage 12

The probe signal is paper-specific

last title token · 5-fold ridge probe · re-checked: author-team folds, title reuse removed



another paper's authors: **0**

same-field paper: **0** (Stage 12 X1 + Stage 13 re-check, §6.12)

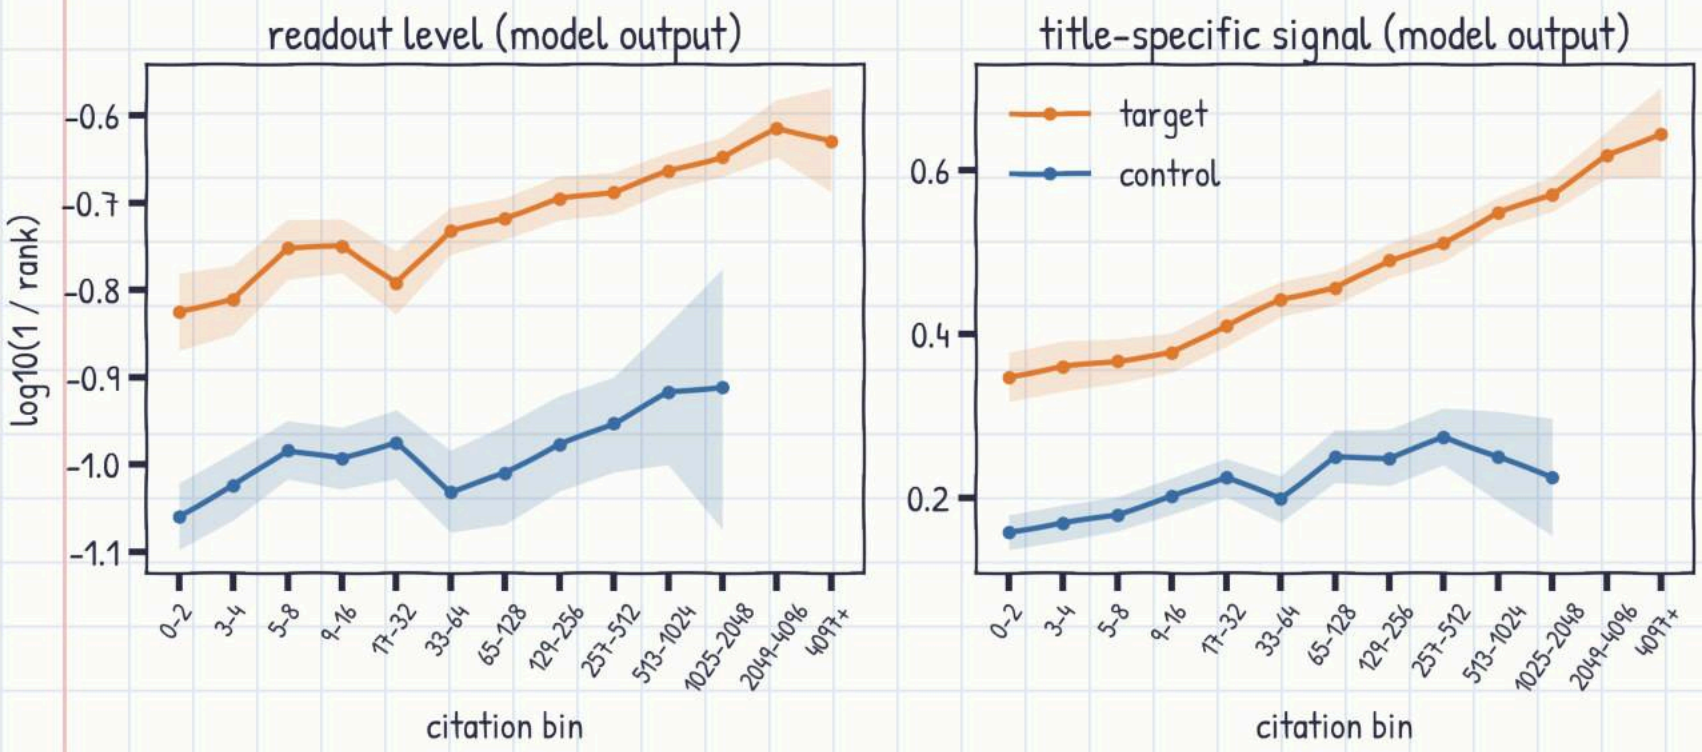
so it is **this paper**, already at L24

lenses cannot read it

Probe scores only the first name token (mostly an initial); all-token, by-role version (addendum 9) in progress.

 按 deck 讲稿备注翻译（已按复核结果更新）

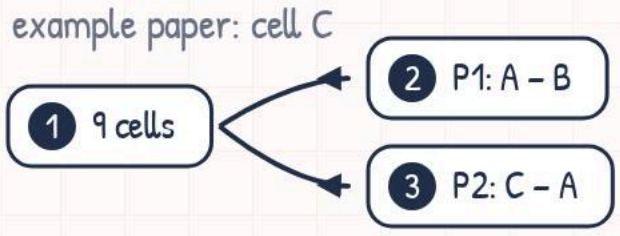
标题位置上的 probe 读到的是真正的论文知识，还是只是主题和名字之间的泛泛关联？如果把它的输出拿去和另一篇论文的作者、或同领域另一篇论文的作者对照打分，信号降为 0。只用假标题数据训练 probe，得到相近的信号；之前“更强”的结果来自泄漏，同一个借出标题同时出现在训练和测试里。这一页的数字已经按作者团队分折、并剔除了 probe 训练时见过同一标题的论文后复核。所以标题最后一个 token 上从 L24 起就有可以线性读出的、属于这篇论文的作者信息，目标组更多，只是 lens 读不出来。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母/名/姓分开的版本按补充 9 进行中，尚无结果。

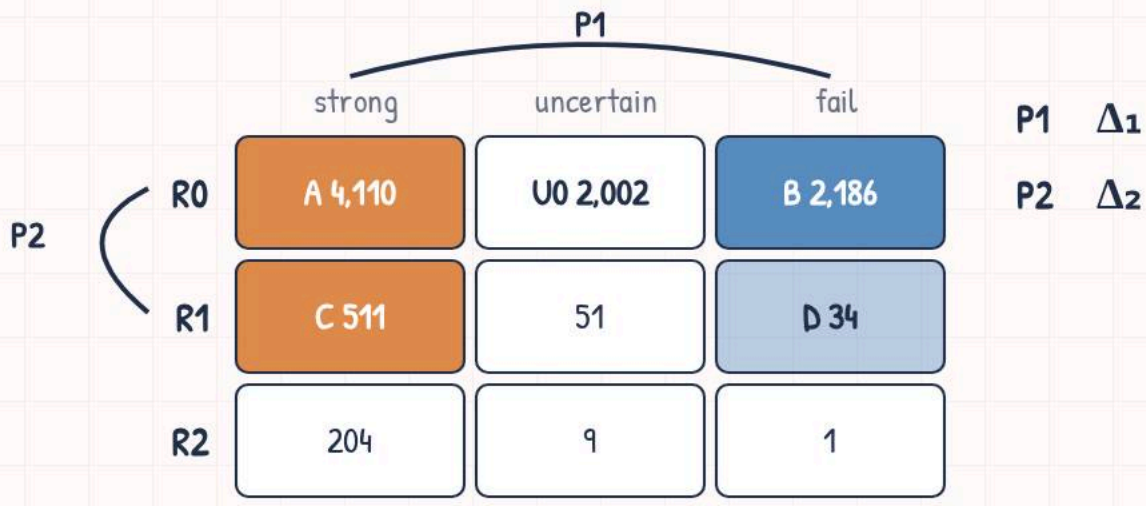


引用数。两组内部，标题特异信号都随引用档稳定上升：目标组从 0–2 档的 +0.35 升到 4097+ 档的 +0.64（Stage 10，真标题 − 5 个假标题平均，最终输出 L63，目标组各引用档均值：0-2 档 +0.347（200 篇）→ 4097+ 档 +0.644 [0.591, 0.701]（84 篇），论文 bootstrap 95% CI；报告 §6.8 图与表；351_stage10/summary_title/A_group_bin_layer.csv（readout=final）；351_stage10/summary_extra/X2_by_bin.csv）。与对数引用数的 Spearman 相关：全部 0.45（Stage 10 补充 X2，标题特异信号（真标题 − 5 个假标题平均，最终输出 L63）对 log10(引用数+1) 的 Spearman ρ，全部 9,108 篇 0.451 [0.433, 0.467]，bootstrap 95% CI；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv），目标组内 0.33，对照组内 0.19（同上 X2，组内 Spearman ρ：目标 4,621 篇 0.328，对照 2,220 篇 0.187；读出水平只有 0.181 / 0.084；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv）。读出水平本身变化小得多：有名论文的名字并不更好猜，只是模型更了解有名的论文。

Group comparisons

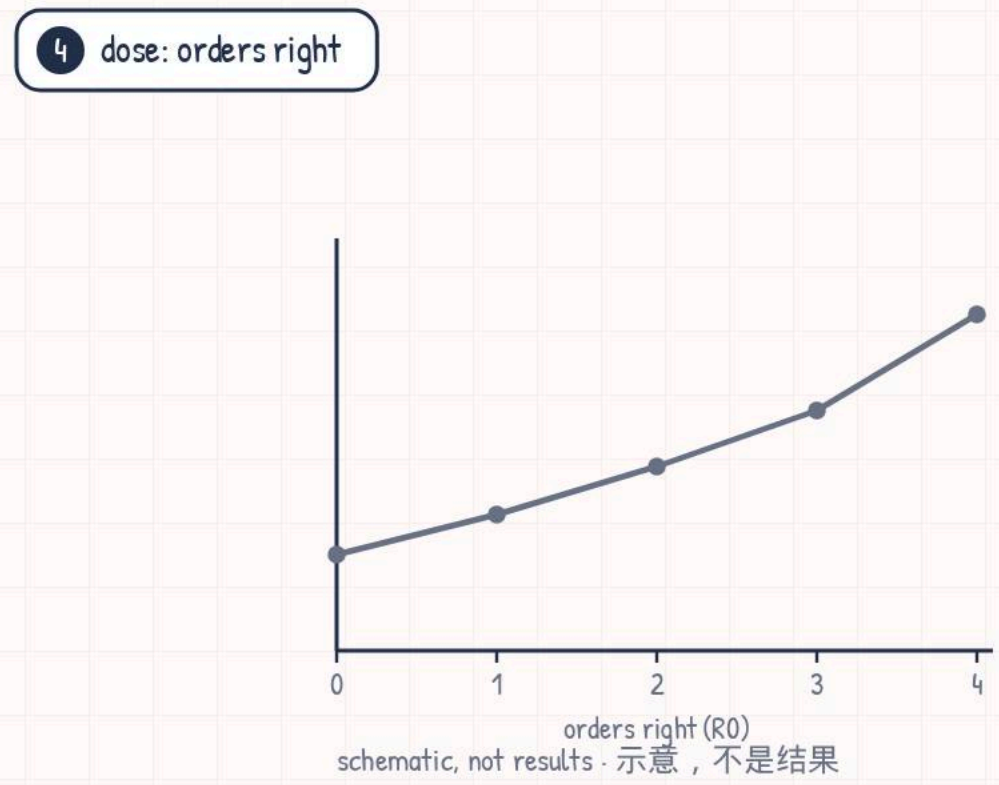
example paper: cell C





P1 Δ_1

P2 Δ_2



contrast = Σ w_b (mean_cell1 – mean_cell2)

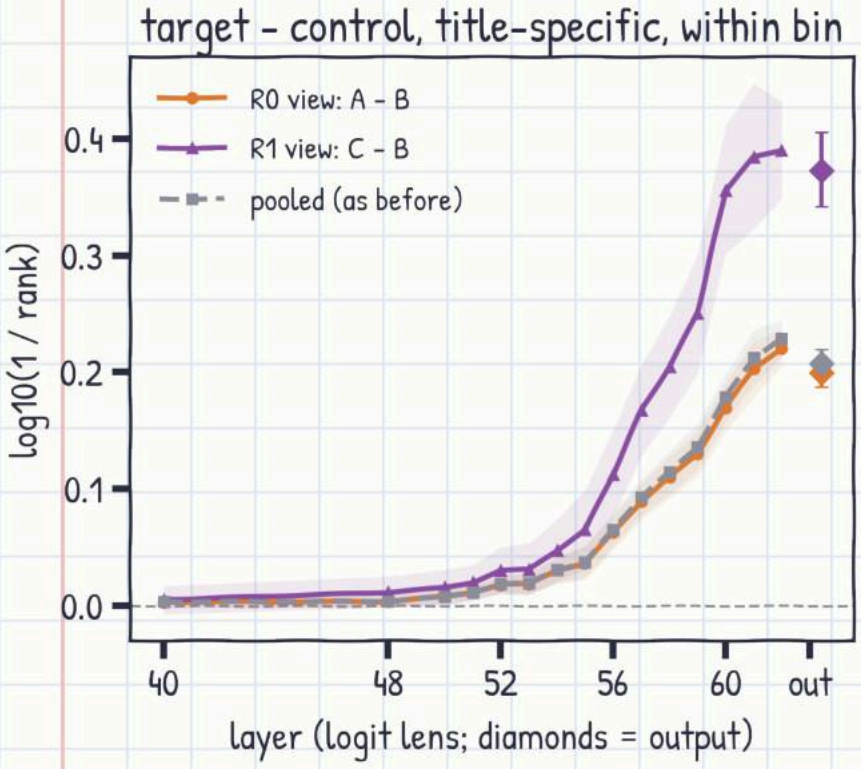
title-specific signal, unwritten authors, output layer; team bootstrap

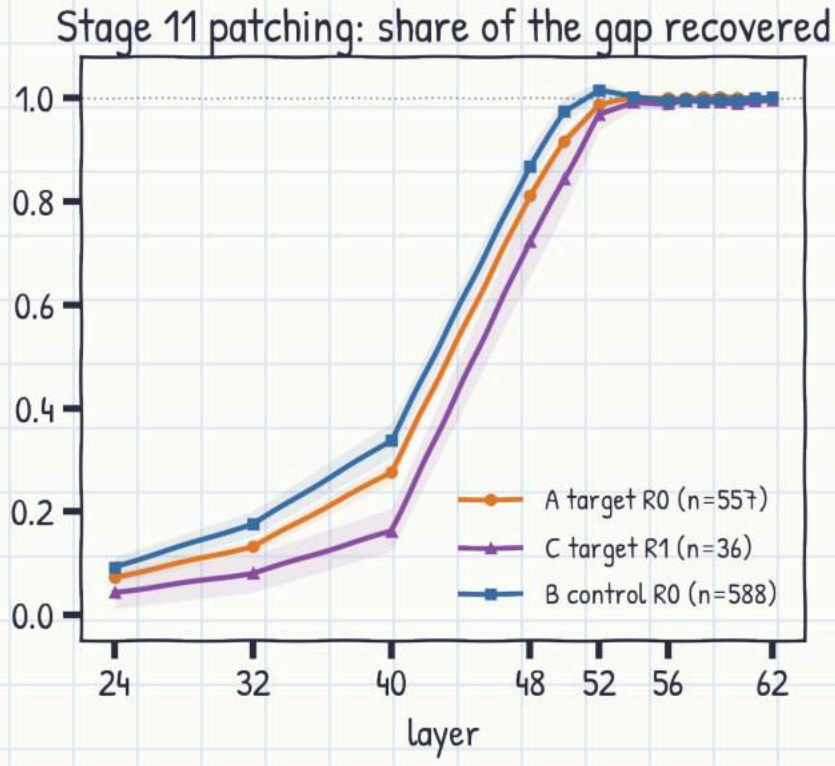
 新写讲稿

组间比较的方法：在 9 个格子里，P1 比较 A 和 B（都是 R0，只差识别），P2 比较 C 和 A，且只看模型没写出的作者，再按作者位置分为合作者和第一作者；另外看 R0 论文的信号随多选答对的顺序数（0 到 4）怎样变化，即剂量曲线。每个对比都在引用档内求差、按 w_b 加权合并，并按作者团队重抽样。这一页只示意方法，Δ_1、Δ_2 和曲线都不是结果；这是答辩后新增的分析，计划预先写定（补充 7、8），结果先交给用户确认。

Is it just the R1 papers? No.

R0 = no true author written · R1 = a few written · A/B/C/D = target/control x R0/R1





R0 only (A – B):

output +0.199 vs +0.207, same shape (Stage 10, A 3,423 / B 2,151, §6.13)

R1 (C – B): +0.37, also late (C 391 / B 885)

C – A within target: +0.11, from L56 (C 485 / A 3,204)

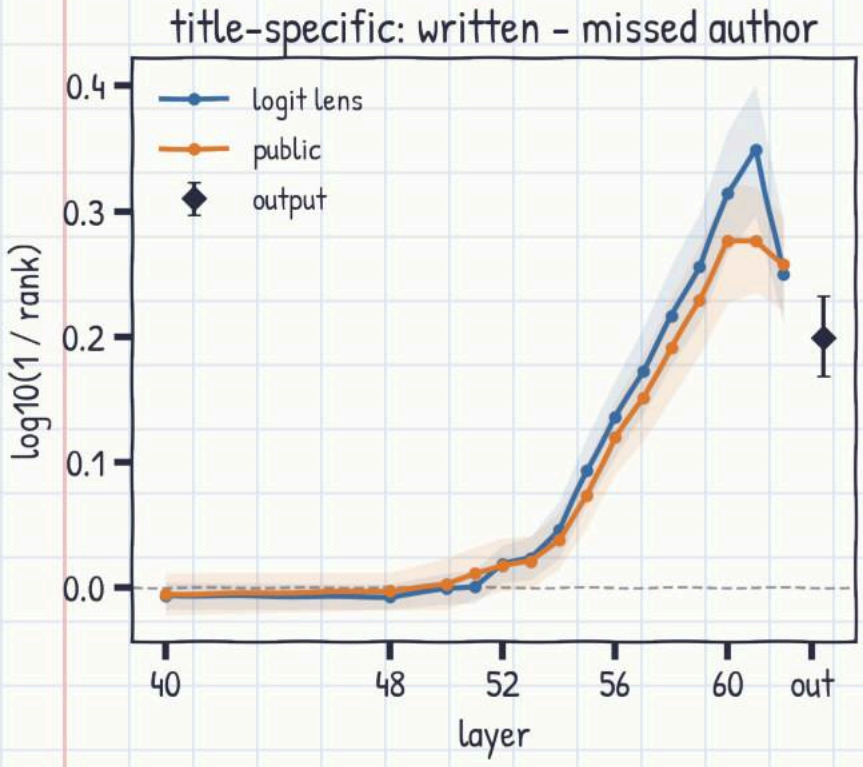
patching: R1 a bit later, done by L52 (Stage 11 E1, 36 R1 targets)

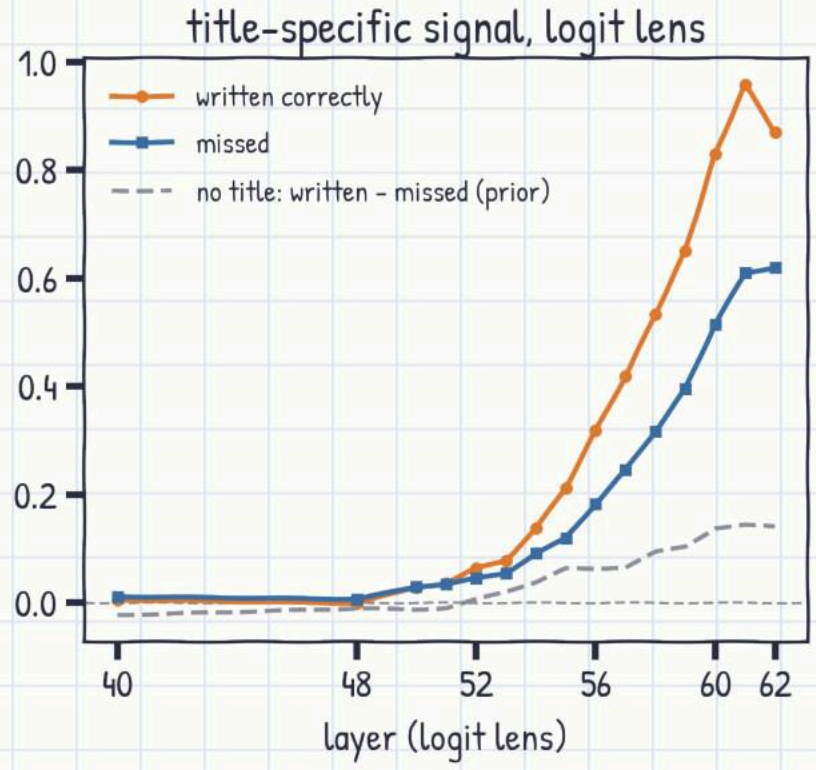
 按 deck 讲稿备注翻译（已按复核结果更新）

目标组的优势是不是只来自 R1 论文？目标组混合了 R0（开放回答一个真作者都没写对）和 R1（写对了一部分）；目标组里 11% 是 R1，对照组里只有 1.5%（目标组 R1 511 / 4,621 篇 = 11%，对照组 R1 34 / 2,220 篇 = 1.5%；351_stage10/reports/r0_sensitivity.md 第一张表；351_stage10/reports/r0_r1_analysis.md §0）。左图是三种口径下引用档内的目标−对照：只用 R0（A 对 B，即 Stage 1–9 的比较）输出处为 +0.199（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv），合并口径为 +0.207（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.196, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），曲线形状相同；R1 目标论文对 R0 对照为 +0.37（Stage 10，R1 目标（C）对 R0 对照（B），真标题 − 5 个假标题平均，最终输出 L63，引用档内，391 + 885 篇，+0.372 [0.342, 0.405]，论文 bootstrap 95% CI；351_stage10/reports/r0_r1_analysis.md §1；351_stage10/summary_r0r1/tc_R1target_vs_R0control.csv），它们更了解自己的论文，但同样要到 L52 之后才领先。对照组 R1 只有 34 篇（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表；D = 34），只做描述，不做检验。右图是按回忆程度分开的 Stage 11 替换曲线：R1 目标论文（36 篇）（Stage 11 样本中的 R1 目标论文 36 篇（对照 R1 5 篇）；351_stage10/reports/r0_r1_analysis.md §5；361_stage11/summary_r0r1/stage11_curves_by_recall.csv）恢复得稍晚，但到 L52 也全部恢复。标题位置的 probe 给出同样的结论：R0 口径为 +0.02 到 +0.04（Stage 11 E4b 原始版（论文分折、未剔除标题复用），标题最后一个 token 上的 probe，probe 只打分第一个名字 token，probe(真标题) − probe(false_0)，A − B 引用档内，A 4,110 / B 2,186 篇：L16 +0.018、L32 +0.034、L56 +0.038，bootstrap 95% CI 均在 0 以上；361_stage11/summary_r0r1/E4b_probe_by_recall.csv）（这是复核前按论文分折的数字）。结论不变。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母/名/姓分开的版本按补充 9 进行中，尚无结果。

Authors it wrote vs authors it missed

inside 495 R1 papers · paired within paper · 95% CI (Stage 10, r0_r1_analysis.md §4)





written − missed, output:
+0.20 (Stage 10, final L63, 495 papers)

~0 up to L52, grows from **L54**

no title (prior): +0.10 (same, no title)

same without first authors

在 R1 论文内部，开放回答写对了一部分作者，漏掉了另一部分。标注包只记录了写对的人数，没有记录是哪几位，所以我们重建了匹配，重建出的人数在 99.3% 的 R1 论文里（重建匹配人数 = 标注包 m 的比例：R0 99.9%、R1 99.3%（596 篇）、R2 98.1%；351_stage10/reports/r0_r1_analysis.md §4；~/jlens_work/10_stage10/stage10_extra_r0r1.py）与标注包一致。在 495 篇同时有写对和漏掉作者的论文里（351_stage10/reports/r0_r1_analysis.md §4；351_stage10/summary_r0r1/R1_author_hits.csv），模型写对的作者在输出处的标题特异信号高 +0.20（Stage 10，R1 论文内 写对 − 没写对的作者（论文内配对），真标题 − 5 个假标题平均，最终输出 L63，495 篇，+0.199 [0.168, 0.232]，论文 bootstrap 95% CI；报告 R0/R1 节 §4 表；351_stage10/summary_r0r1/R1_author_written_minus_missed.csv），去掉第一作者后也一样。但这个差在 L52 之前约为 0（同上，logit lens L48 −0.007、L52 +0.019、L54 +0.046、L57–L61 +0.173 到 +0.349；351_stage10/summary_r0r1/R1_author_written_minus_missed.csv），从 L54 才开始上升：即使是模型真能写出来的作者，论文特有的信号也只在最后几层出现。另外，写对的作者在不给标题时也稍微好猜一些，高 +0.10（同上，不给标题（名字先验），最终输出 L63，写对 − 没写对 +0.097 [0.060, 0.134]，495 篇；351_stage10/summary_r0r1/R1_author_written_minus_missed.csv）。

Stages 1–9 · 20–200 papers

What we saw

- True title helps: pilot L56 +9.3 pp(7.3, 50 papers); 200 new papers +5.2 pp(8D RQ1, 200 papers)
- A–B uncertain in the pilot; +5.0 pp on 200 papers but gone after dropping 10 pairs(8D RQ2, 100 pairs)
- Low – high citation: inconclusive

Stages 10–11 · 9,108 papers

What scale showed

- Title-specific signal clear in every group, ≈0.44 at L62(L62, §6.9)
- target – control ≈0 at L24–L40, slightly negative at L48 (−0.04 to −0.05)(§6.4), +0.21 [0.20, 0.22] at the output(L63, §6.4)
- Name prior is only ~1/3 of the gap; ~0 on surnames(§6.12)
- Signal rises steadily with citations (ρ = 0.45)(§6.8)
- Same groups as the pilot (R0 only, A – B): +0.20 [0.19, 0.21] (R0, §6.13), same late shape
- R1 papers (C) know more (+0.11 over A)(§6.13) but are just as late

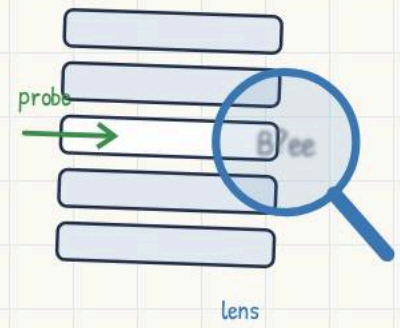
Line A: from "the title helps" to "this paper, late, graded by fame"

The pilot was right that the title matters. It could not see that the target advantage is real but confined to the last layers, so the 7-layer average and the L56 endpoint both diluted it. Restricting the full cohort to the pilot's A/B groups (R0 only) changes nothing: the R1 papers do not drive the result.

A 线的小结。小样本阶段看到：真标题有帮助，Pilot 在 L56 高 +9.3 个百分点（Stage 7.3，J-Lens L56，真标题胜率 − 20 个错误标题平均胜率，合并池，Pilot50 50 篇均值 +0.0934 [0.047, 0.139]（2026-10-30 重算区间，B = 20,000），35/50 篇为正；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv；报告 Stage 7.3 节），200 篇新论文上 +5.2（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节）；A−B 在 Pilot 中不确定，在 200 篇上是 +5.0（Stage 8D RQ2，J-Lens L56 匹配 A − B，100 对，+4.98 pp [0.32, 9.91]，配对 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ2_matched_A_minus_B）但去掉 10 对就消失（Stage 8D RQ2，J-Lens L56 金标准胜率匹配 A−B，100 对，均值 +4.98 pp，按 A−B 降序去掉前 10 对后其余 90 对均值 −0.39 pp（事后诊断）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）重算；报告 Stage 8D 节）；低引用减高引用没有定论。全量阶段看到：每组都有清楚的标题特异信号，L62 约 0.44（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）；目标−对照在 L24–L40 约为 0、L48 略为负（−0.04 到 −0.05，区间不含 0（Stage 10，引用档内目标−对照，三种 Jacobian lens L48 −0.037 到 −0.054；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv)），输出处 +0.21 [0.20, 0.22]（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.196, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）；名字先验只占差距的约三分之一（Stage 12 名字先验拆解（CPU），最终输出 L63，全部名字 token，引用档内 目标−对照（目标 4,621、对照 2,220 篇）：先验 +0.087 [0.070, 0.103] ÷ 真标题差 +0.247 = 0.35；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv），在姓上约为 0（同上，姓的第一个 token，先验 目标−对照 +0.022 [−0.019, +0.063]，论文特有 +0.423 [0.393, 0.454]；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）；信号随引用数稳定上升（ρ = 0.45）（Stage 10 补充 X2，标题特异信号（真标题 − 5 个假标题平均，最终输出 L63）对 log10(引用数+1) 的 Spearman ρ，全部 9,108 篇 0.451 [0.433, 0.467]，bootstrap 95% CI；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv）；只用和 Pilot 相同的 R0 分组（A − B）为 +0.20 [0.19, 0.21]（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv），形状同样是后期才上升；R1 论文（C）比 A 多 +0.11（Stage 10，目标组内 R1 − R0（C − A），真标题 − 5 个假标题平均，最终输出 L63，引用档内（每格 ≥ 10 篇），C 485 + A 3,204 篇，+0.110 [0.086, 0.135]，论文 bootstrap 95% CI；351_stage10/summary_r0/target_R1_minus_R0_within_bin.csv；351_stage10/reports/r0_sensitivity.md），但时间点一样晚。小样本说对了标题重要，但没看出目标组的优势只在最后几层，所以 7 层平均（Stage 5–8 的积分终点 = 7 个源层平均（L63 不计入）；351_stage6/config/protocol.json "paper_integrated"；351_stage8/config/analysis_plan.json）和 L56 终点都把它稀释了。

Line B

What can each readout see?



small samples asked

Is J-Lens better than Vanilla? Is the fitted lens stable?

→

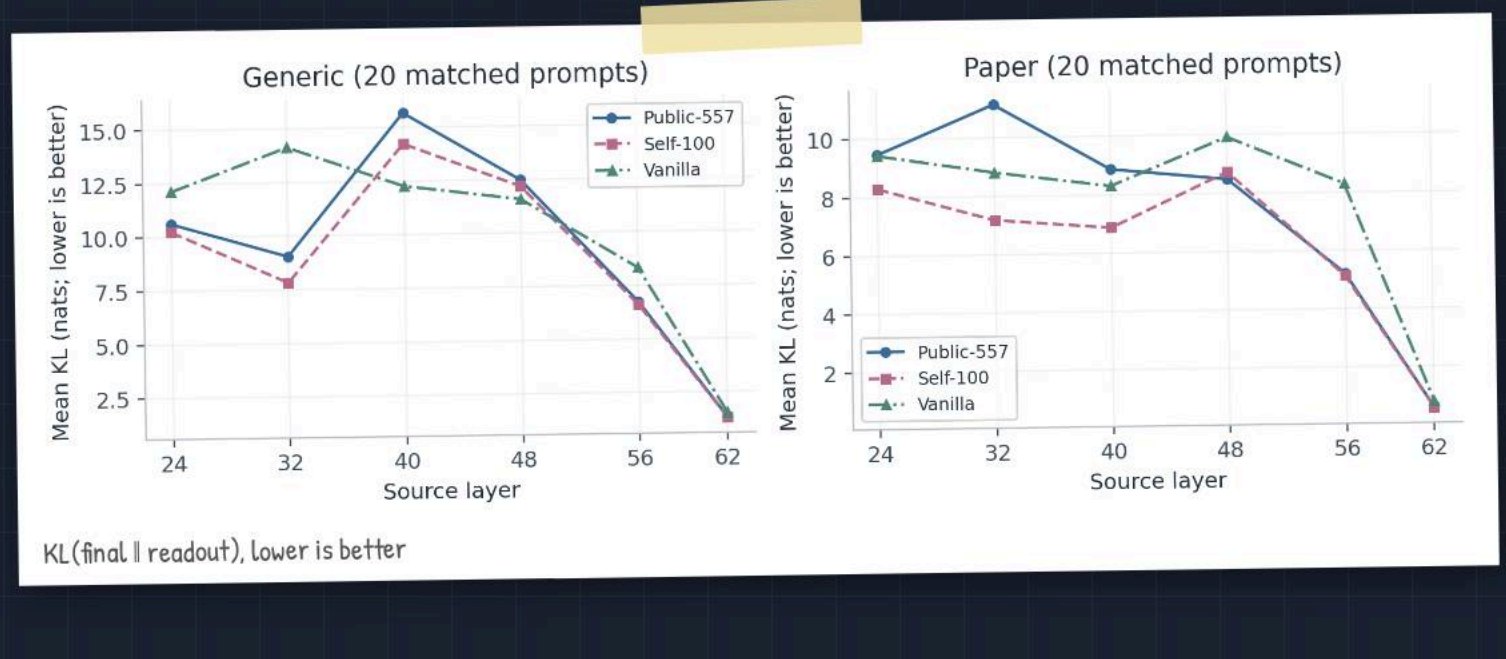
the full cohort answered

Lenses read name shape earlier, not paper identity; a probe at the title token reads paper-specific information

B 线的问题是：每种读出工具能看到什么？小样本阶段问的是 J-Lens 是否比 Vanilla 好，拟合出来的 lens 是否稳定。全量阶段的回答是：lens 在中间层更早读出的是“名字的样子”，而不是论文身份；而在标题 token 上训练的 probe 能读出论文特有的信息。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母/名/姓分开的版本按补充 9 进行中，尚无结果。

Two lenses: Public-557 vs Self-100

Can a middle layer approximate the final next-token distribution? (20 generic + 20 paper prompts)



- Both checkpoints numerically valid (63/63 and 6/6 finite)(matrices.csv; frobenius_norms.csv)
- Self-100 has lower KL on 6/6 generic and 5/6 paper layers (paper L32: 11.1 → 7.2) (20 + 20 prompts; metrics.csv)
- But at paper L62, Self-100 KL beats Vanilla (0.58 vs 0.81) while Top-10 overlap is worse (0.36 vs 0.72)(metrics.csv)
- Author pilot: both lenses 14/20 full-name wins at L48(20 papers, layer_summary.csv)

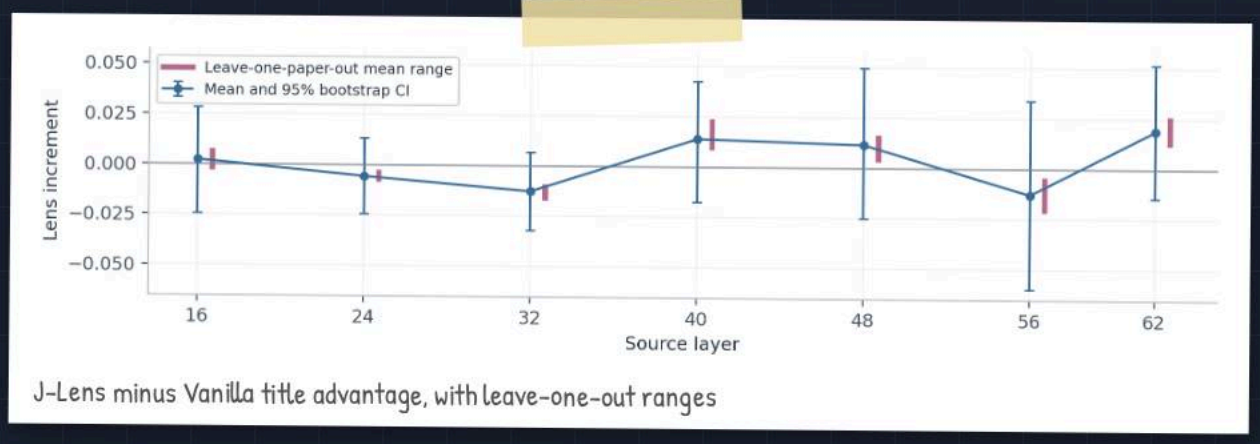
Lesson: a better distribution match does not mean better author ranking. Fidelity cannot stand in for the task.

Stage 3 比较两个 lens：公开的 Public-557 和我们自己拟合的 Self-100，问中间层能否近似最终的下一个 token 分布，用了 20 条通用提示和 20 条论文提示（Stage 3 Exp 2/4 提示集；~/jlens_work/02_self_lens_validation/351_self_jlens_validation.py:13-50）。两个检查点数值上都有效。Self-100 在 6 个通用层中的 6 层、6 个论文层中的 5 层（Stage 3 Exp 2/4，Self-100 − Public KL，各 20 条提示；351_self100_validation/summary/paired_bootstrap_ci.csv、summary/metrics.csv；报告 Stage 3 节图 3.1）KL 更低，例如论文提示 L32 从 11.1 降到 7.2（Stage 3，论文提示 20 条，L32 KL(final ‖ lens)：Public-557 11.135（351_all/351_paper_fidelity.log L32 jlens 行）→ Self-100 7.180（351_self100_validation/summary/metrics.csv paper/self100/32））。但在论文提示 L62，Self-100 的 KL 优于 Vanilla（0.58 对 0.81）（Stage 3，论文提示 20 条，L62 KL：Self-100 0.578、Vanilla 0.808；351_self100_validation/summary/metrics.csv（task=paper, layer=62, kl_final_to_lens_nats）），前 10 名重合度却更差（0.36 对 0.72）（同上，L62 前 10 名重合度：Self-100 0.355、Vanilla 0.720；351_self100_validation/summary/metrics.csv（top10_overlap））。作者小试中两个 lens 在 L48 都是 20 次里 14 次全名胜出（Stage 3 Exp 3，L48 全名胜率 0.70 × 20 篇，两个 lens 相同；351_self100_gold_false/archive/summary/layer_summary.csv 列 full_win_rate）。教训是：分布拟合得更好，不等于作者排名更好，保真度不能代替任务本身。

Stage 7.4 · Line B

Cross-stage audit: does J-Lens add value?

Read-only joins of Stages 5–7.3; 20,000 bootstrap draws



J-Lens minus Vanilla title advantage, with leave-one-out ranges

Stage 5 vs 7.3 at L56	r = 0.45, ρ = 0.47; signs agree 32/50 (50 papers, cross_stage_correlations.csv)
J-Lens − Vanilla	+0.002 [−0.008, +0.012]; median −0.002; 24/50 positive (jlens_increment_bootstrap.csv)
A−B of that increment	−0.014 [−0.033, +0.004] (20 pairs)

Dropping one paper can flip the sign of the J-Lens increment. The pilot shows **no added title-specific value** from J-Lens over Vanilla. Everything so far is exploratory: L56 was inspected repeatedly.

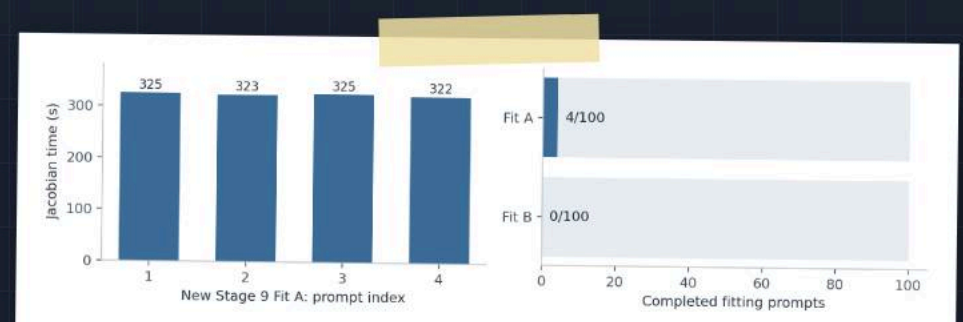
 新写讲稿

Stage 7.4 是跨阶段审计：J-Lens 到底有没有增加价值？只读地合并了 Stage 5 到 7.3 的结果，用 20,000 次 bootstrap（Stage 7.4 设计，种子 741；~/jlens_work/07_4_stage7_4/351_stage7_4.py:10-13）。Stage 5 和 7.3 在 L56 的相关为 r = 0.45，50 篇里 32 篇方向一致（Stage 7.4，J-Lens L56，Stage 5 与 Stage 7.3 的论文级相关，50 篇，Pearson 0.445，同号比例 0.64 = 32/50；351_stage7_4/summary/overview.json "L56_jlens_stage5_stage73"；351_stage7_4/summary/cross_stage_correlations.csv）。J-Lens 减 Vanilla 的标题优势为 +0.002 [−0.008, +0.012]，中位数 −0.002，50 篇里 24 篇为正（Stage 7.4，J-Lens − Vanilla 标题优势，7 层积分，50 篇，均值 +0.0022 [−0.0075, +0.0124]，中位数 −0.0019，24 篇为正，论文 bootstrap 95% CI；351_stage7_4/summary/jlens_increment_bootstrap.csv 行 integrated；overview.json）；这个增量的 A−B 为 −0.014（Stage 7.4，J-Lens 增量的匹配 A − B，20 对，−0.0139 [−0.0332, +0.0036]；351_stage7_4/summary/overview.json "matched_ab_difference_of_lens_increment"），区间含 0。去掉一篇论文就可能让 J-Lens 增量变号（Stage 7.4，逐一留出一篇后 7 层积分增量范围 −0.000046 到 +0.003494；351_stage7_4/summary/overview.json "integrated_jlens_minus_vanilla"）。Pilot 没有显示 J-Lens 比 Vanilla 多出任何标题特异的价值；而且到这里为止都是探索性的，L56 被反复看过。

Stage 9: is the lens stable across fitting data?

New FullFit protocol, different from the historical 50+50 split

	Historical split-half	Stage 9 FullFit
Fit data	Self-100 split 50 + 50	two disjoint 100-prompt sets
Holdout	20 generic + 20 paper	independent 100 WikiText
Layers	6	7 (adds L16)
Status	complete	only Fit A completed; Fit B and holdout not run



Archived progress: Fit A 4/100, Fit B 0/100 at the time of writing(351_stage9 checkpoints)

- WikiText-103 train, 100–1,200 chars, deduplicated by hash, seed 3519001
- ~324 s Jacobian time per prompt, ~62 GiB CPU RAM(full_A.log; benchmark log); per-prompt checkpoints

Only Fit A was finished, and Stage 10 used it as "fitA". Without Fit B and the holdout, fitting stability is **untested**.

Stage 9 想检验 lens 是否依赖拟合数据，用的是新的 FullFit 方案，和历史上的 50 + 50 拆分（Stage 3 Exp 7 历史拆分，偶数 / 奇数索引各 50 条；351_self100_split_half/fits/config_A.json、config_B.json）不同：两套互不重叠的 100 条提示，外加独立的 100 条 WikiText 留出集（Stage 9A.1 设计，FitA100 / FitB100 / Holdout100 各 100 条；351_stage9/config/plan.json、manifest.json "counts"；~/jlens_work/09_stage9/351_stage9.py:50-62），层数增加到 7 层（Stage 9 拟合层 L16–L62 共 7 层；351_stage9/runner_runs/full_A_100_7layers/fitting_config.json；351_stage10/config/lenses.json fitA）（加了 L16）。每条提示的 Jacobian 约需 324 秒、约 62 GiB CPU 内存（Stage 9 正式 Fit A 第 1–4 条每条 325/323/325/322 s（均值 323.75 s，351_stage9_full_A.log）；单条提示 7 层基准 CPU 内存峰值约 62.06 GiB（351_stage9_benchmark_A1_7layers.log)），每条存一次检查点。最后只完成了 Fit A，Stage 10 用的“fitA”就是它；Fit B 和留出比较都没做，所以 lens 的拟合稳定性还没有检验。

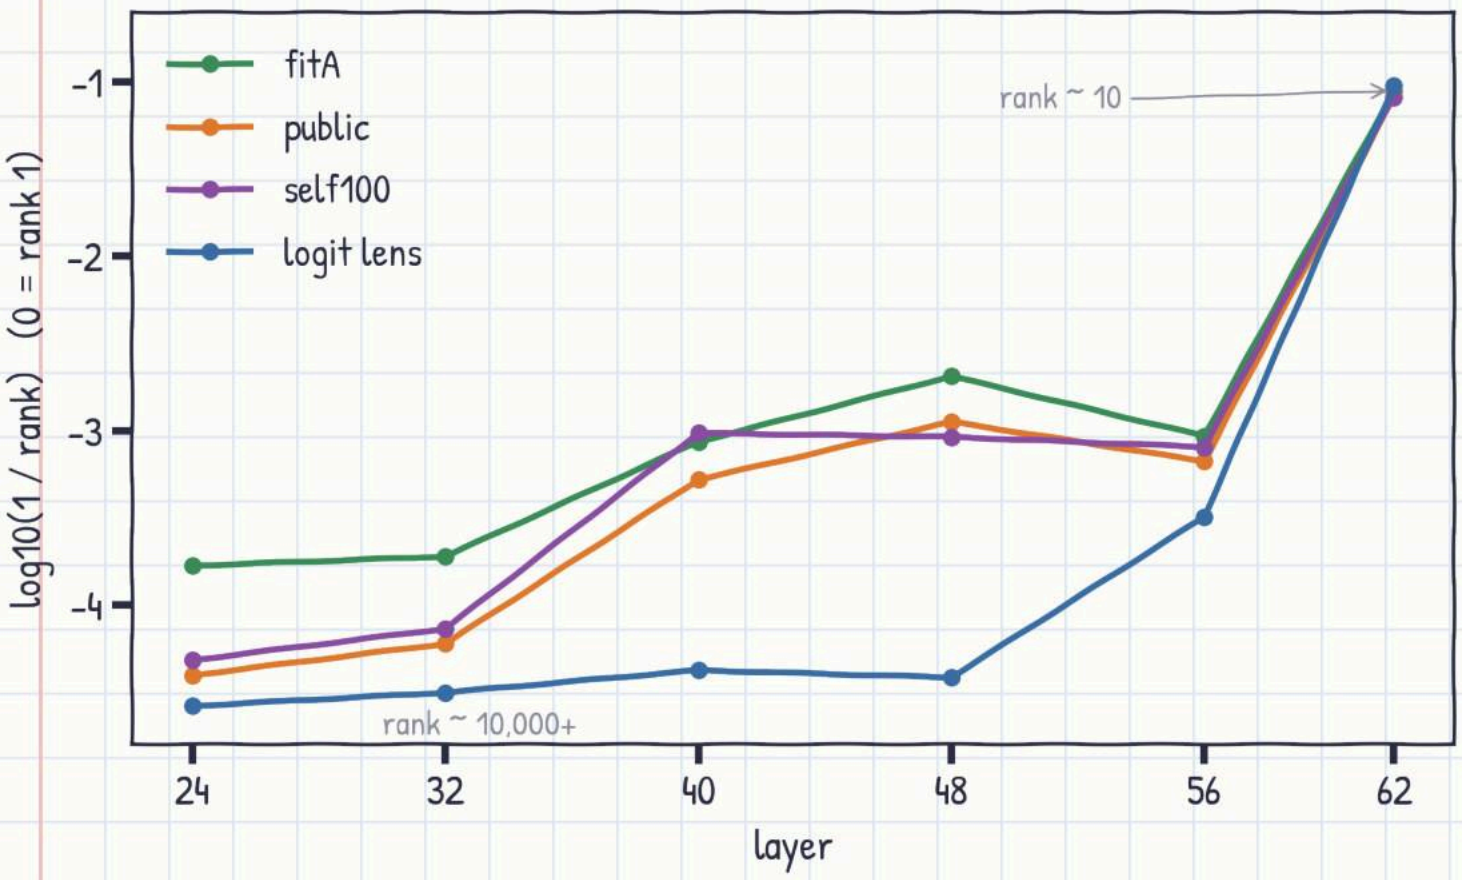


第 34 / 75 页 · Method · Layer-by-layer readout · 合并 PPT 自身页面 **新写讲稿**

逐层读出：在名字位置取每一层的隐藏状态，用 logit lens 映射到全词表，看真名字 token 的名次，再算 nlr = log10(1/名次)。示例论文第一作者姓的首个 token “Co”：L24 名次 37,675，L56 120,750，L61 9,811，L62 120，输出层 61（Stage 10，示例论文 Coifman 等（2007），真标题，第一作者姓的首个 token “Co”（行 25029），logit lens L24–L62 与最终输出 L63 全词表名次；351_stage10/raw/logit/L*/shard_011.npz、raw/final/L63/shard_011.npz；351_stage10/reports/method_figs/coifman_layer_ranks.csv（列 r5_Co））。第一作者 7 个 token 的平均 nlr 到 L58 都在 −4 左右，L62 升到 −1.11、输出层 −0.77（同上，第一作者 7 个 token（行 25025–25031）的平均 log10(1/名次)，logit lens：L24–L58 为 −4.47 到 −3.92，L62 −1.111，最终输出 −0.772；351_stage10/reports/method_figs/coifman_layer_ranks.csv 列 mean_log10_inv_rank）；假标题 false_0 在输出层是 −1.19（同上，false_0 条件，最终输出 L63，−1.194；351_stage10/raw/cond_false_0/final/L63/shard_011.npz；351_stage10/reports/method_figs/coifman_layer_ranks.csv（condition=false_0, readout=final））， 真假之差只在最后几层出现。

Names become readable late

all 9,108 papers · true title (Stage 10 cohort, §6.1)



Logit lens: almost nothing until **L48**

Jacobian lenses read more from **L40**

Everything jumps at **L62** (rank ~10) (Stage 10, logit L62 -0.93, §6.1)

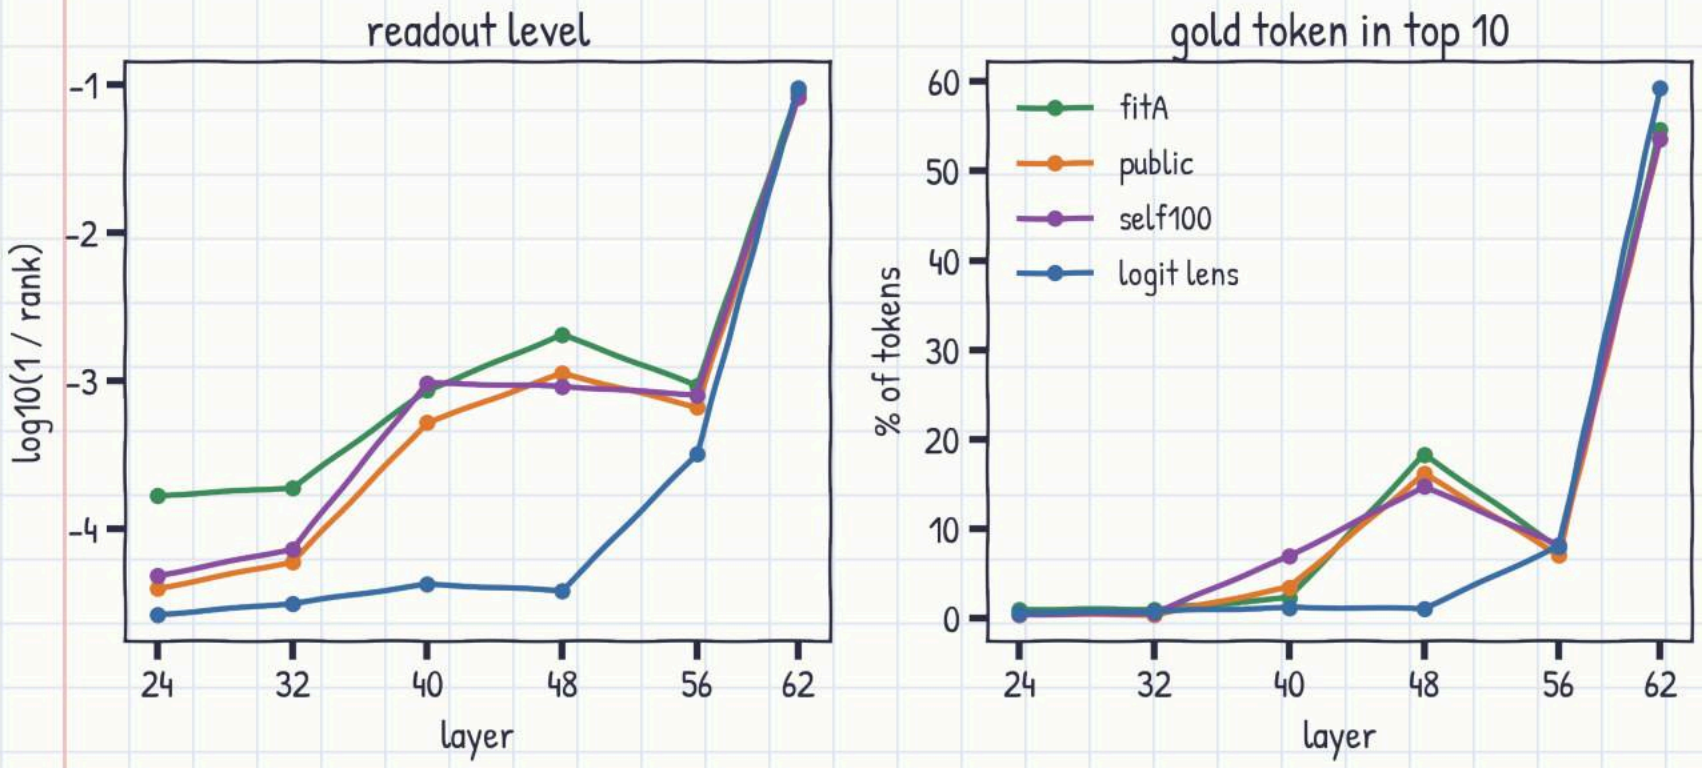
 按 deck 讲稿备注翻译（已按复核结果更新）

所有读出方式都随层数加深而变好。logit lens 在 L48 之前几乎读不出东西（名次在几万名（Stage 10，真标题，logit lens L24–L48，目标 4,621 + 对照 2,220 篇，平均 log10(1/名次) 约 −4.4 到 −4.6；报告 §6.1 表；351_stage10/summary/A_group_layer.csv）），到 L62 才跳上来。Jacobian lens 从 L40 起读出更多，fitA 最多。模型真实输出最好。

Stage 10

Which lens reads best?

all papers · true title



Middle layers:

fitA best; at L48 15–18% top-10 vs 1% for logit

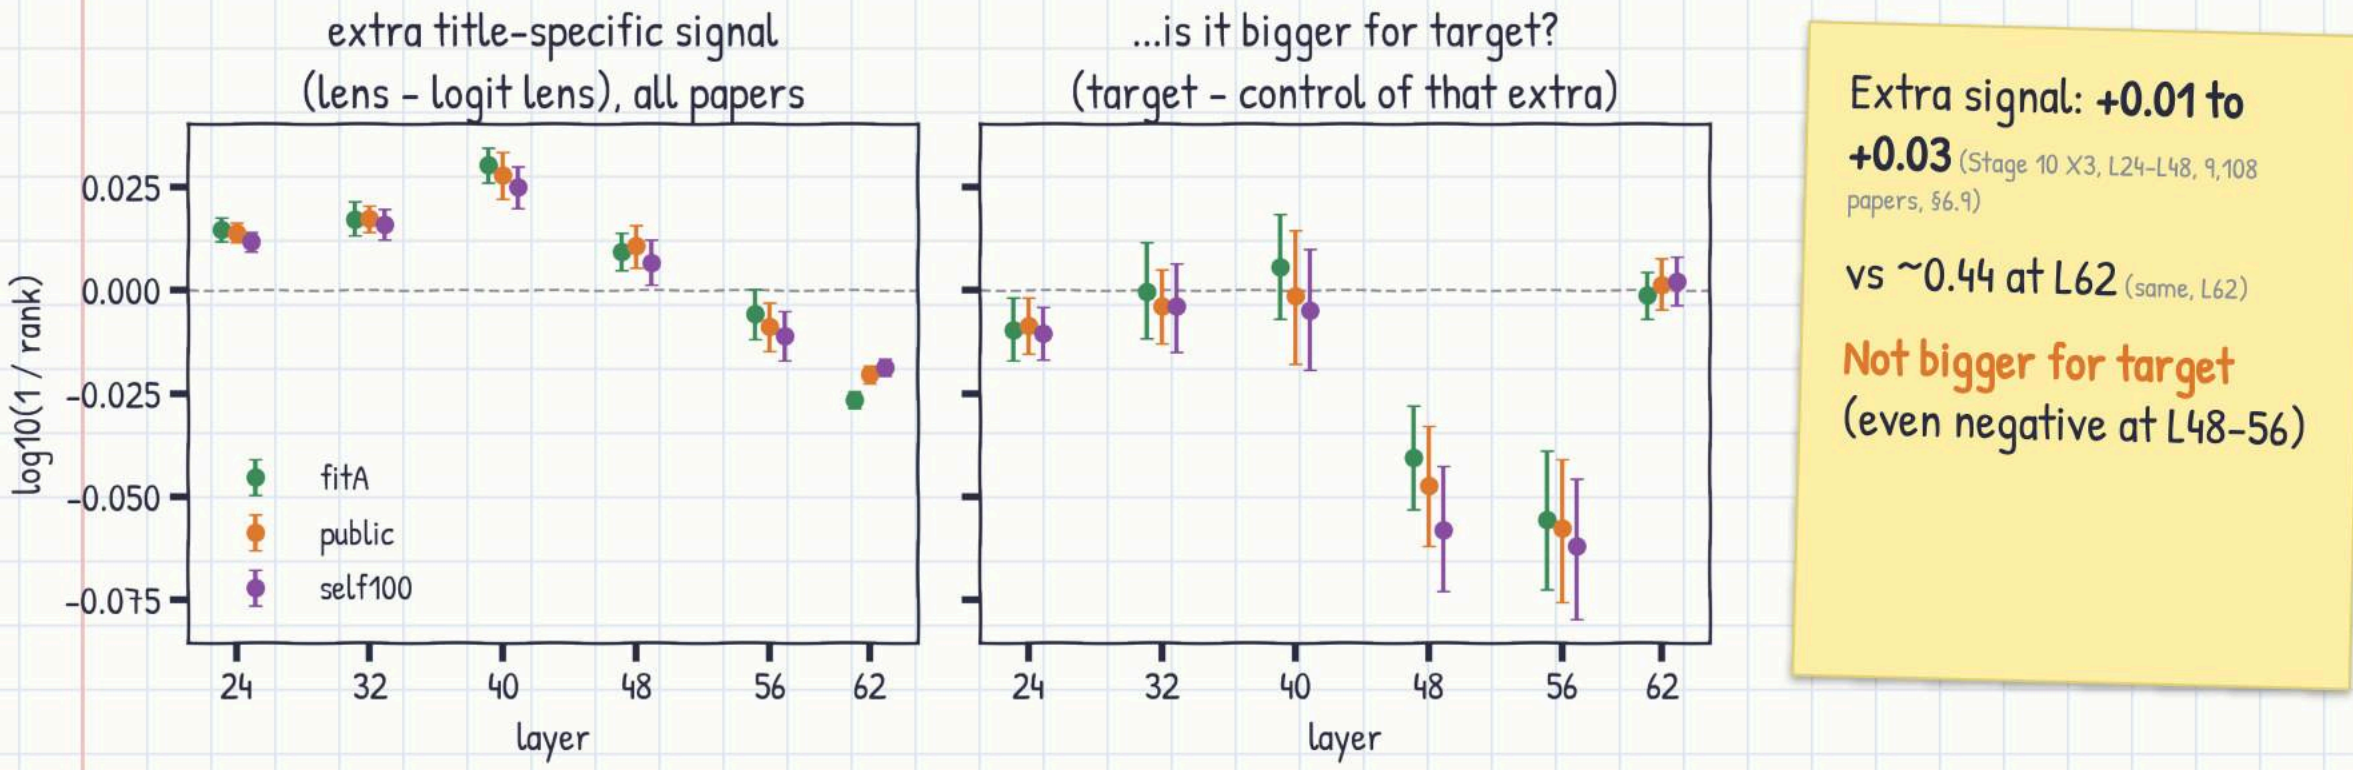
(Stage 10 X3, 9,108 papers, §6.9)

L62: logit lens best (59%)

(same, L62)

 按 deck 讲稿备注翻译（已按复核结果更新）

比较各种 lens。读出质量上，中间多数层 fitA 最好，L40 是 self100；在 L48，Jacobian lens 能把正确 token 放进前 10 名的比例是 15–18%，logit lens 只有 1%（Stage 10 X3，真标题，全部 9,108 篇，同一批 token 配对，L48 前 10 命中率（token 比例）：三种 Jacobian lens 14.7%–18%，logit lens 1.1%；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）。到 L62，最朴素的 logit lens 反而最好。



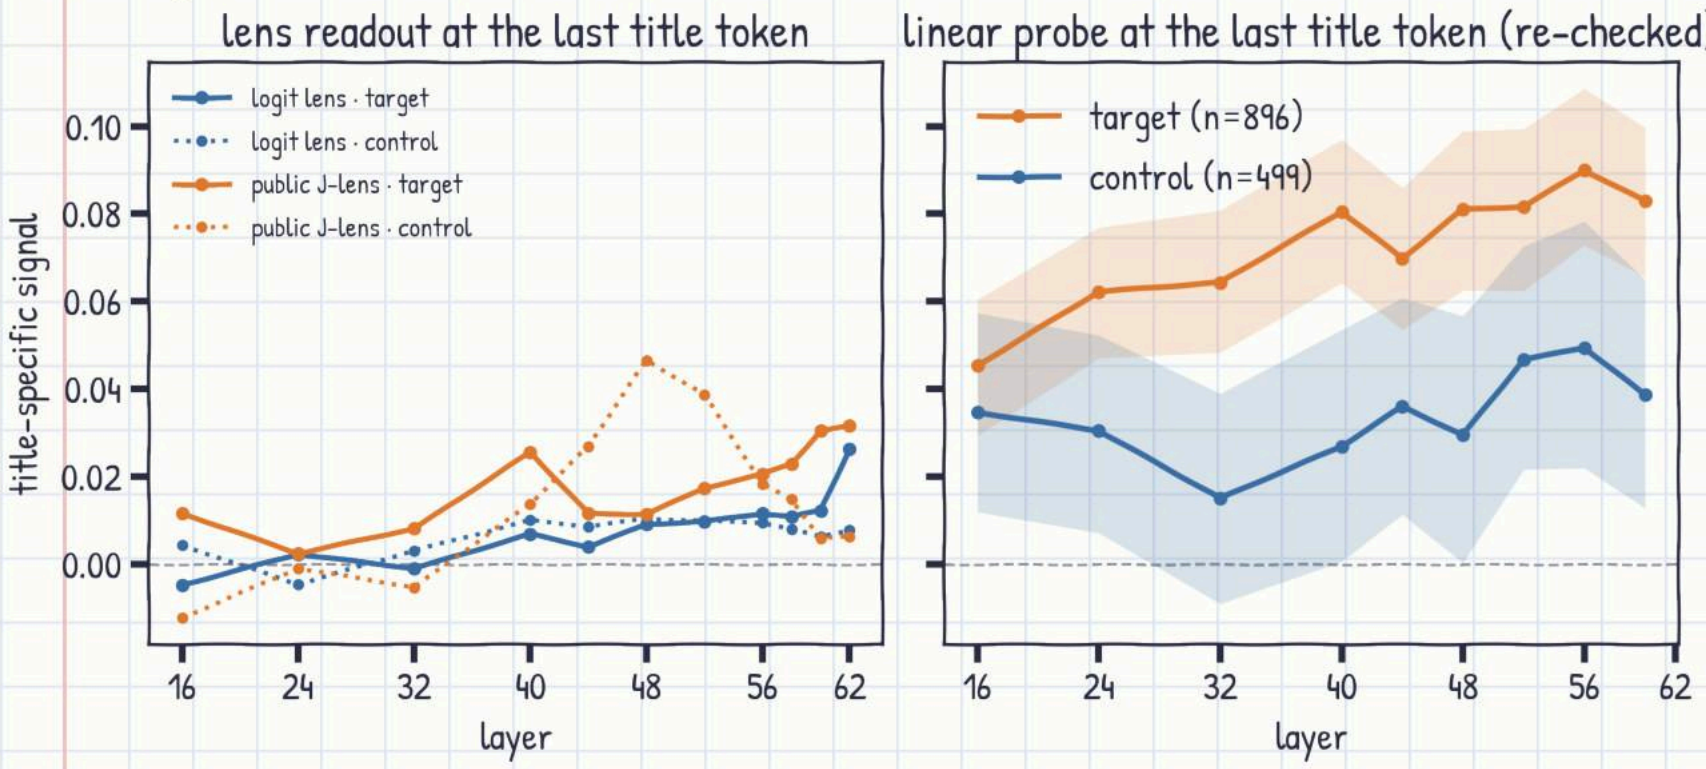
第 37 / 75 页 · deck 第 23 页 按 deck 讲稿备注翻译（已按复核结果更新）

Jacobian lens 能不能看到 logit lens 漏掉的、论文特有的信息？只能看到一点：在 L24–L48 多出 +0.01 到 +0.03 的标题特异信号（Stage 10 补充 X3，三种 Jacobian lens 减 logit lens 的标题特异信号（真标题 − 5 个假标题平均），L24–L48，全部 9,108 篇，+0.007 到 +0.030，论文 bootstrap 95% CI 均在 0 以上；报告 §6.9 表；351_stage10/summary_extra/X3_pairwise.csv），区间在 0 以上，但和 L62 的 0.44 相比（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）非常小。而且这部分对目标组并不更大：多出部分的目标−对照约为 0，在 L48 和 L56 甚至为负（Stage 10 X3，(lens − logit) 标题特异信号的引用档内 目标−对照，三种 Jacobian lens：L24–L40 约 0，L48 与 L56 为 −0.04 到 −0.06，论文 bootstrap 95% CI；报告 §6.9 最后一表；351_stage10/summary_extra/X3_tc_spec_vs_logit.csv）。

Stage 11

Read early: a probe finds it at the title

title-specific signal at the last title token · lenses: all 9,108 papers · probe: re-checked, title reuse removed: 1,863 papers (896 target, 499 control) (Stage 11 E4; Stage 13 E4b)



lenses: **~0.01–0.03** (Stage 11 E4, 4,621 + 2,220, §6.11)

probe: **0.05 -> 0.08** (Stage 13 E4b, 1,863 papers, first name token only)

target > control by **+0.04–0.08** (E4b, 896 vs 499, within bin)

re-checked: team folds, title reuse removed

scores the first name token only (mostly an initial); subtracts false_0 only

read early (title, from L24), **spoken late** (names, L57–61)

Probe scores only the first name token (mostly an initial); all-token, by-role version (addendum 9) in progress.

在标题本身的位置上能读出作者吗？用 lens，几乎读不出：标题最后一个 token 上的标题特异信号只有约 0.01 到 0.03（Stage 11 E4，标题最后一个 token，logit lens 与 public J-lens 读第一个名字 token，真标题 − 5 个假标题平均，全部 9,108 篇，约 0.01–0.03；报告 §6.11 标题位置表；361_stage11/summary/E4_titlepos_lens.csv）。换成跨论文训练的线性 probe 能读出更多：按作者团队分折、并剔除 probe 训练时见过同一标题的论文后复核（剩 1,863 篇，其中目标 896、对照 499（Stage 13 E4b 复核样本，按作者团队分折并剔除 probe 训练时见过同一标题的论文后剩 1,863 篇（目标 896、对照 499、excluded 433、guard 35）；381_stage13/reports/e4b_split_compare.md；381_stage13/summary_cpu_trainstd/E4b_4configs.csv）），L24 约 0.05，到 L56 升到约 0.08（Stage 13 E4b 复核，标题最后一个 token 上的线性 probe，probe 只打分每位作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，全部 1,863 篇：L24 +0.050、L40 +0.061、L56 +0.075（L24–L60 为 +0.047 到 +0.080），论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第一张表），目标组比对照组高 0.03 到 0.08（同上 E4b 复核，probe 只打分第一个名字 token，引用档内目标−对照，目标 896、对照 499 篇，L24–L60 为 +0.035（L44）到 +0.078，论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第二张表）。附录里的对照说明这个 probe 信号是这篇论文特有的，不是主题和名字的关联。它和 lens 的结果不矛盾：标题在标题位置就被读进去了，但名字要到 L57–L61 才在名字位置变得可读。一句话：读得早，说得晚。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母/名/姓分开的版本按补充 9 进行中，尚无结果。

Stages 1–9 · 20–200 papers

What we saw

- Self-100 fits the final distribution better; author ranking not better
- J-Lens − Vanilla ≈0 (7.4: +0.002; Stage 8: −1.4 pp)(50 / 200 papers)
- Stage 9: only Fit A fitted, stability not tested

Overview · Line B

Stages 10–11 · 9,108 papers

What scale showed

- Jacobian lenses: top-10 rate 15–18% at L48 vs 1% for logit lens(9,108 papers; X3_means.csv)
- Extra title-specific signal only +0.01–0.03(L24–L48; X3_means.csv), not target-specific
- At L62 the plain logit lens is best
- Linear probe at the title token: +0.05 → +0.08 (re-checked)(E4b, scores only the first name token; e4b_trainstd_compare.md), paper-specific

Line B: the information is there, but not in a form the lenses read

Both phases agree: no lens reveals hidden paper knowledge in middle layers. Scale adds the positive side: a trained probe can decode it at the title, so the limit is the readout, not the absence of information.

B 线的小结。小样本阶段看到：Self-100 更贴近最终分布，但作者排名没有更好；J-Lens 减 Vanilla 约为 0（7.4 为 +0.002（Stage 7.4，J-Lens − Vanilla 标题优势，7 层积分，50 篇，+0.002 [−0.008, +0.012]；351_stage7_4/summary/jlens_increment_bootstrap.csv 行 integrated），Stage 8 为 −1.4 个百分点（Stage 8D，L56 J-Lens − Vanilla 标题优势，200 篇，−1.38 pp [−3.48, +0.68]；351_stage8/stage8D/summary/jlens_minus_vanilla.csv）；Stage 9 只拟合了 Fit A，稳定性没有检验。全量阶段看到：Jacobian lens 在 L48 的前 10 名比例为 15–18%，logit lens 为 1%（Stage 10 X3，真标题，全部 9,108 篇，L48 前 10 命中率：三种 Jacobian lens 14.7%–18%，logit lens 1.1%；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）；多出的标题特异信号只有 +0.01 到 0.03（Stage 10 补充 X3，三种 Jacobian lens 减 logit lens 的标题特异信号（真标题 − 5 个假标题平均），L24–L48，全部 9,108 篇，+0.007 到 +0.030，论文 bootstrap 95% CI 均在 0 以上；报告 §6.9 表；351_stage10/summary_extra/X3_pairwise.csv），而且不偏向目标组；L62 时朴素的 logit lens 最好；标题 token 上的线性 probe 从 +0.04 升到 +0.08（Stage 11 E4b 原始版（论文分折、未剔除标题复用），标题最后一个 token 上的 probe，probe 只打分第一个名字 token，真标题 − false_0，目标组 L16 +0.043 到 L52–L56 +0.080/+0.082；论文 bootstrap 95% CI；报告 §6.11 标题位置表 probe 行；361_stage11/summary/E4_probe.csv 列 spec_target），而且是论文特有的。（页面上 +0.04 到 +0.08 是复核前的数字（Stage 11 E4b 原始版（论文分折、未剔除标题复用），标题最后一个 token 上的 probe，probe 只打分第一个名字 token，真标题 − false_0，目标组 L16 +0.043 到 L52–L56 +0.080/+0.082；论文 bootstrap 95% CI；报告 §6.11 标题位置表 probe 行；361_stage11/summary/E4_probe.csv 列 spec_target），复核后为 +0.05 到 +0.08（Stage 13 E4b 复核，标题最后一个 token 上的线性 probe，probe 只打分每位作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，全部 1,863 篇：L24 +0.050、L40 +0.061、L56 +0.075（L24–L60 为 +0.047 到 +0.080），论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第一张表），结论不变。）两个阶段一致：没有哪种 lens 能在中间层看出隐藏的论文知识；全量阶段补上了正面的一面：训练过的 probe 能在标题位置解码出来，所以限制在读出工具，而不是信息不存在。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母/名/姓分开的版本按补充 9 进行中，尚无结果。

Line C

When does it appear, and when is it used?



small samples asked

Which layer peaks? (L56 kept standing out)

→

the full cohort answered

Readable late (L57–61) but read from the title early (L24–50)

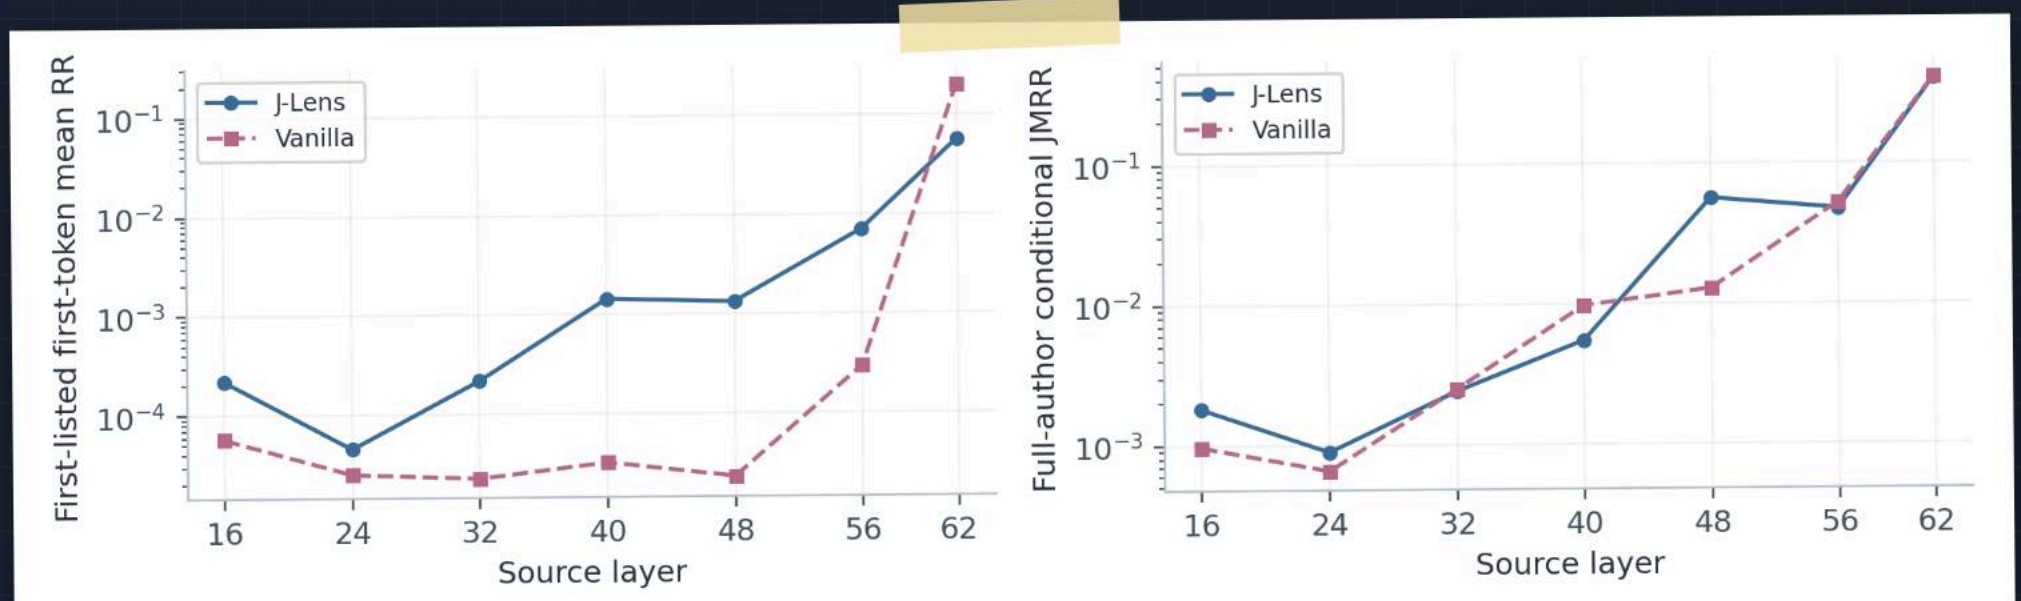
 新写讲稿

C 线的问题是：信号在哪一层出现，又在哪一层被用到？小样本阶段问的是哪一层最高，L56 总是很突出。全量阶段的回答是：名字要到 L57–L61 才变得可读，但标题信息在 L24–L50 就已经被读取了。

Stage 4

First readout: is any author signal there?

20 papers, 93 authors (A8 / B8 / C3 / D1); ~91 s per paper, ~29.5 GiB GPU(351_stage4_readout.log)



Layer profiles: first-listed first-token RR (left) and conditional full-name JMRR (right)

- The pipeline works and J-Lens rises above Vanilla in middle layers
- L56 first-author mean RR 0.0070, median only 0.0009(20 papers; audit_report.md table 1)

One paper = 71% of the L56 mean

Dropping it: 0.0070 → 0.0021.(same file) A layer peak can be a single easy paper, so every later stage adds controls.

41

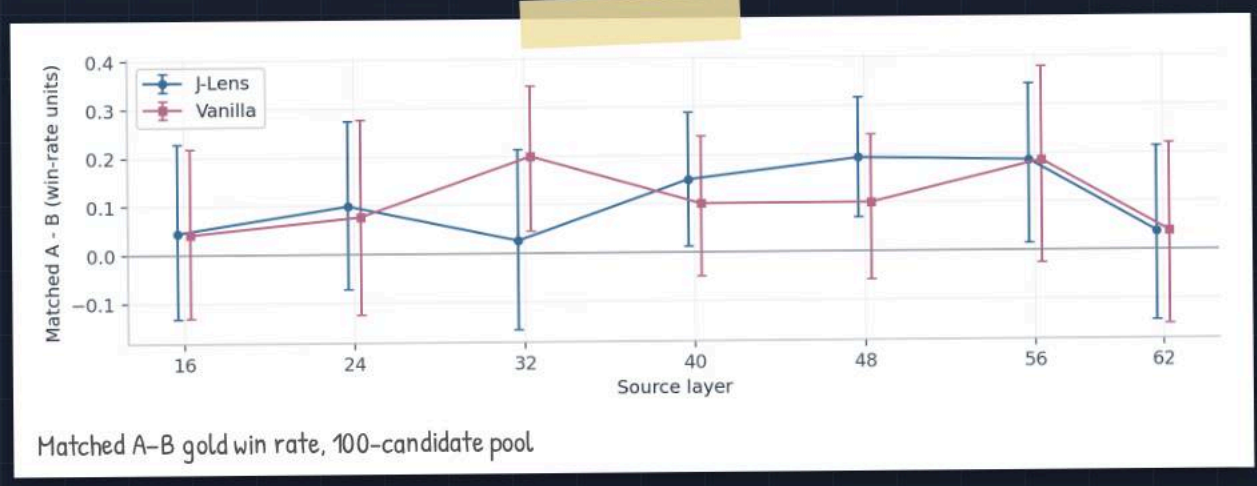
第 41 / 75 页 · Stage 4 · 合并 PPT 自身页面 新写讲稿

Stage 4 是第一次读出：作者信号到底在不在？用了 20 篇论文、93 位作者，A 8 篇、B 8 篇、C 3 篇、D 1 篇，每篇约 91 秒、约 29.5 GiB 显存（Stage 4 Benchmark20；351_all/351_stage4_readout.log "STAGE 4 BENCHMARK ===== 20 papers"、authors_scored 93、"Mean seconds per paper 90.68"、gpu=29.5GiB；报告 Stage 4 节表）。流程能跑通，J-Lens 在中间层高于 Vanilla。但 L56 第一作者的平均倒数名次是 0.0070，中位数只有 0.0009；一篇论文就占了 L56 均值的 71%，去掉它均值降到 0.0021（Stage 4，J-Lens L56，第一作者首 token 倒数名次，20 篇：均值 0.00704，中位数 0.00092，最大单篇占总和 71.03%，去掉后均值 0.00215；351_all/351_stage4_artifacts/audit/audit_report.md 表 1 行 L56）。层的峰值可能只是一篇特别好猜的论文，所以之后每个阶段都加了对照。

Stage 7.2 · Line A

Gold vs 100 real false authors

50 matched (same field, token count, year) + 50 random names per paper; 75,000 scored pairs(candidate_pairwise_scores.csv)

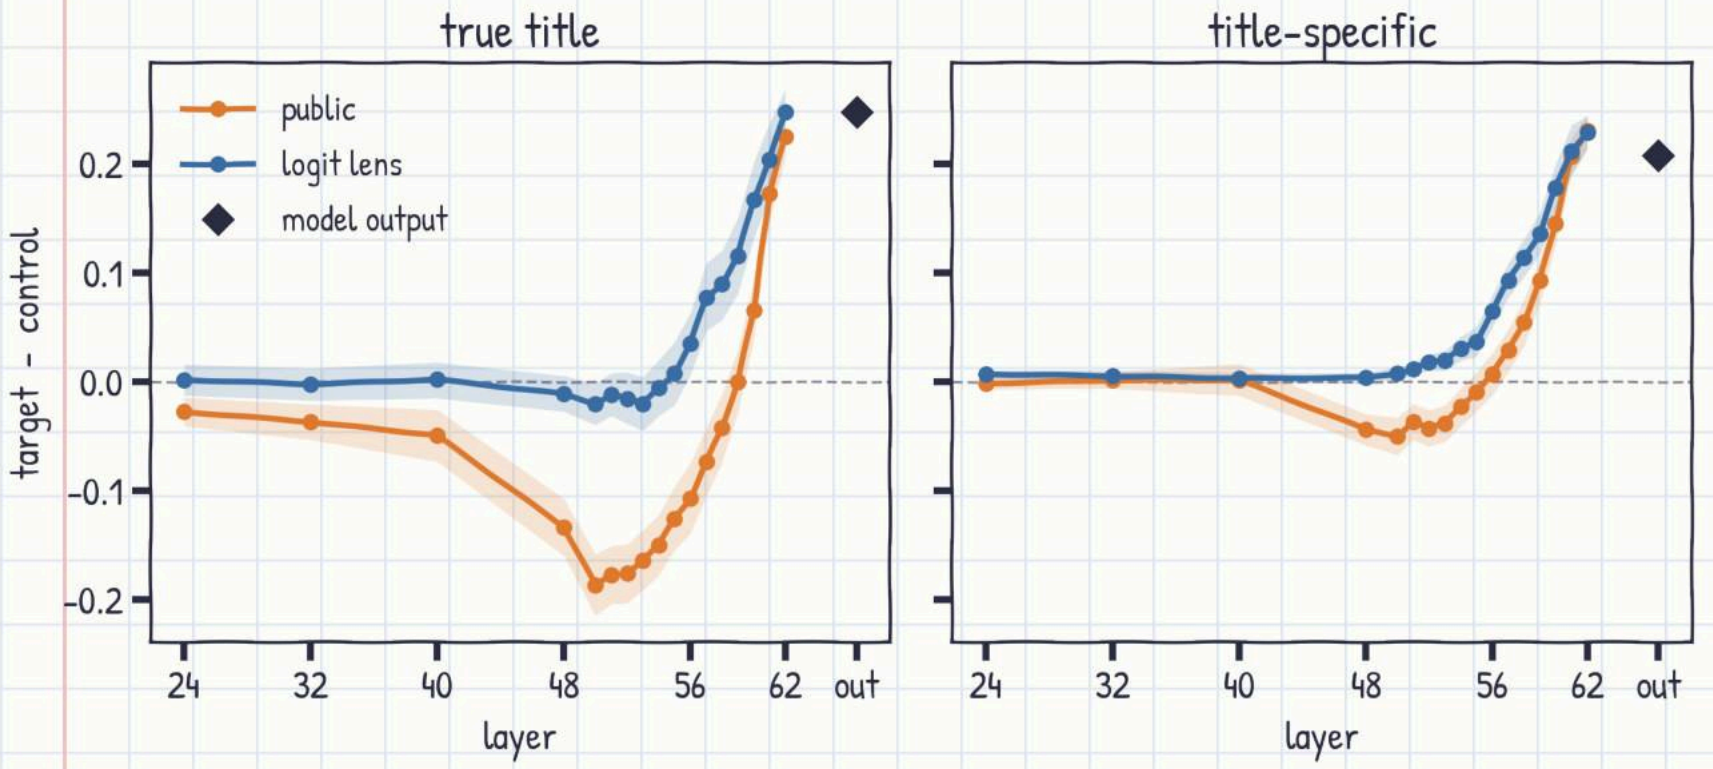


Matched A–B gold win rate, 100-candidate pool

- J-Lens A–B: L40 +0.15, L48 +0.19, L56 +0.19 (CIs above 0); L62 +0.04 (spans 0)(20 pairs, matched_ab_bootstrap.csv)
- 7-layer integrated: +0.105 [−0.012, +0.229](20 pairs; recomputed 10-30)
- 156/5,000 false names share the gold first token (ties) (quality.json)
- 100 names → only ~46 distinct first tokens(mean of 50 papers; candidates csv)

Gold beats real names in middle layers for A more than B. But the same names might win under any title: 7.3 tests that.

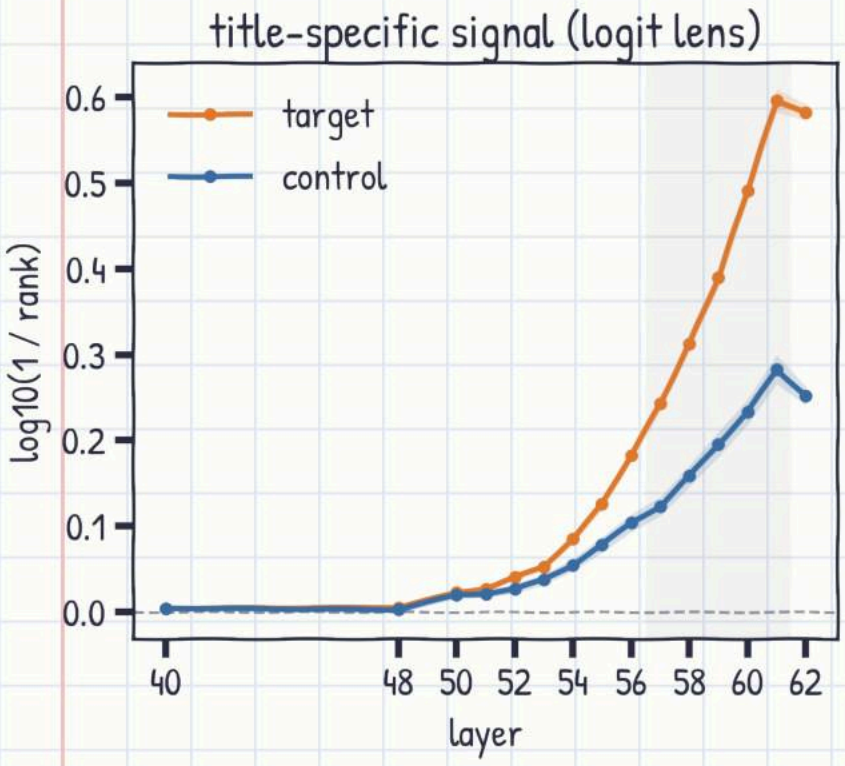
Stage 7.2 把正确名字和 100 个真实的错误作者比较：每篇论文 50 个匹配名字（同领域、同 token 数、同年份）加 50 个随机名字，共 75,000 对（Stage 7.2 设计，Pilot50 50 篇 × 100 个错误作者 × 15 种读出 = 75,000；~/jlens_work/07_2_stage7_2/351_stage7_2.py:62-111；351_stage7_2/summary/quality.json；351_stage7_2/summary/candidate_pairwise_scores.csv）。J-Lens 下的 A–B 胜率：L40 +0.15，L48 +0.19，L56 +0.19，区间都在 0 以上；L62 为 +0.04，区间含 0（Stage 7.2，真标题，首 token 金标准胜率，J-Lens，合并池，Pilot50 20 对 A − B，配对 bootstrap 95% CI：L40 +0.150 [0.013, 0.289]、L48 +0.193 [0.071, 0.318]、L56 +0.187 [0.015, 0.345]、L62 +0.038 [−0.144, +0.215]；报告 Stage 7.2 节图 7.2；351_stage7_2/summary/matched_ab_bootstrap.csv）；7 层积分 +0.105 [−0.012, +0.228]（Stage 7.2，7 层积分，J-Lens，合并池，20 对 A − B，配对 bootstrap 95% CI（2026-10-30 按逐对数据重算）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv 行 "7.2 integrated7 A-B jlens pool=combined"）。需要注意 5,000 个错误名字里有 156 个与正确名字共享第一个 token，100 个名字只有约 46 个不同的第一个 token（Stage 7.2，Pilot50 每篇 100 个错误名字（50 匹配 + 50 随机），共 5,000 个；每篇平均 45.76 个不同首 token（方法手册 C 部分由 351_stage7_2/candidates/pilot50_author_candidates.csv 统计）；156 / 5,000 = 3.1% 与金标准首 token 相同记为平局（351_stage7_2/summary/quality.json））。中间层里 A 比 B 更常胜出，但同样的名字可能在任何标题下都胜出，这要由 7.3 来检验。

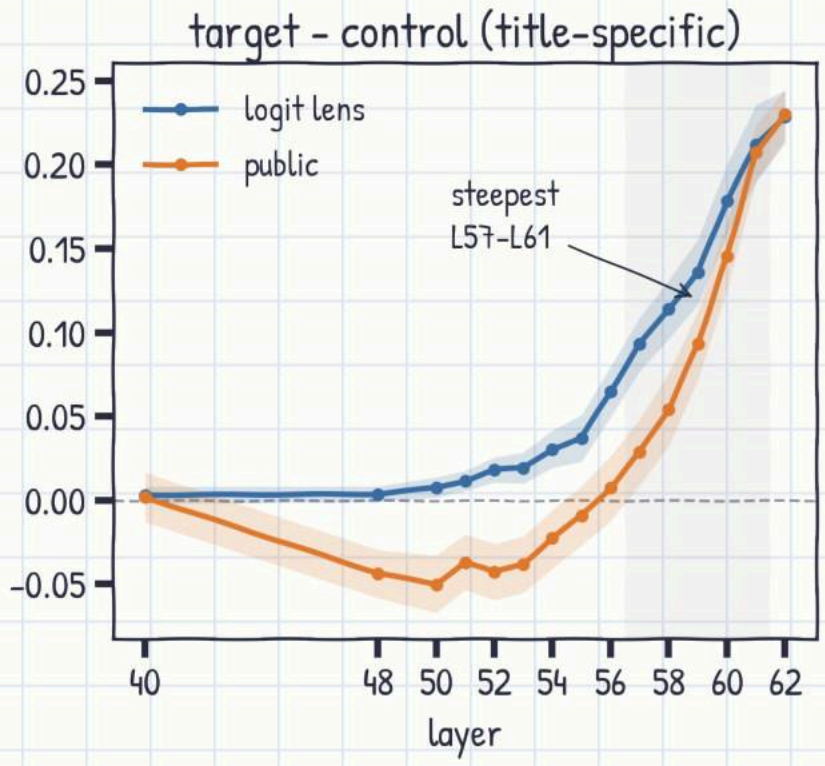


这是关键的一页：在引用档内看目标组减对照组。左边只看真标题，中间层对 Jacobian lens 甚至略为负。右边看标题特异部分：L56 之前约为 0，在 L62 和输出处为 +0.21 到 +0.23（Stage 10，真标题 − 5 个假标题平均，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），L62 四种读出 +0.228 到 +0.231，最终输出 L63 +0.207 [0.196, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）。稳健性：目标组 11% 是 R1（写对少数作者），对照组只有 1.5%（目标组 R1 511 / 4,621 篇 = 11%，对照组 R1 34 / 2,220 篇 = 1.5%；351_stage10/reports/r0_sensitivity.md 第一张表；351_stage10/reports/r0_r1_analysis.md §0）；两组都只保留 R0 时，输出处的差是 +0.199（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv）而不是 +0.207（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.196, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），各层形状相同，Stage 11 的曲线也不变。目标组的优势出现得很晚，而且几乎全部是标题特异的。

It builds up over the last dozen layers

fine layers L40–L62 · title-specific signal · 95% CI





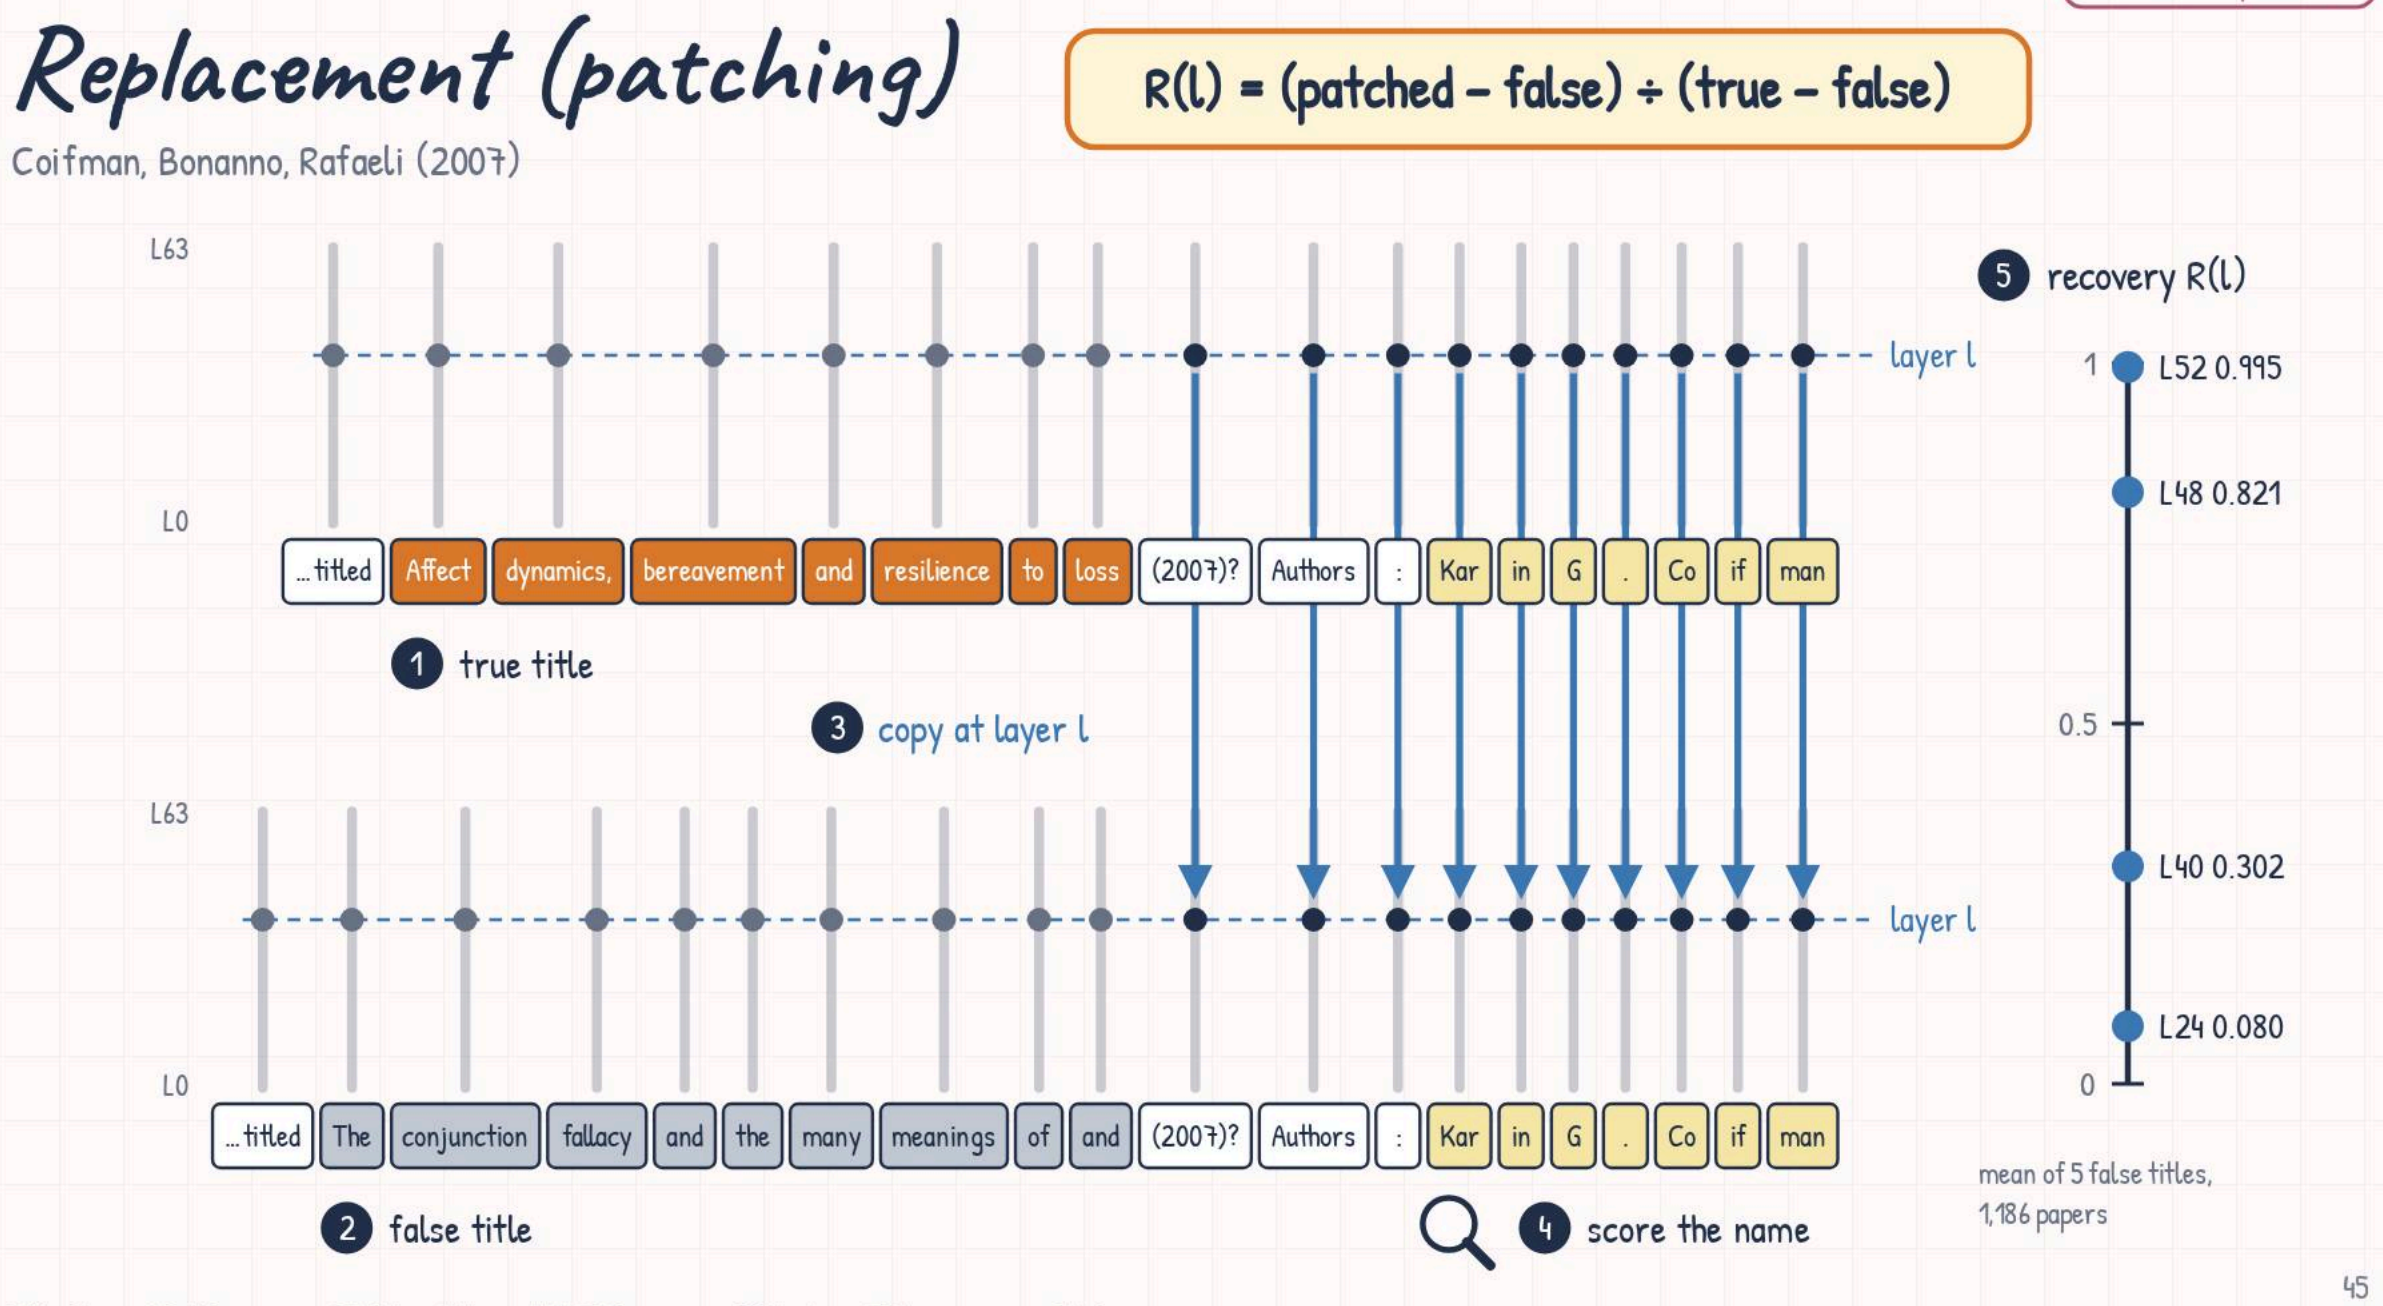
Logit lens: target - control

+0.007 at L50

+0.23 at L62 (Stage 10 logit lens, 3,734 + 2,182 papers, §6.10)

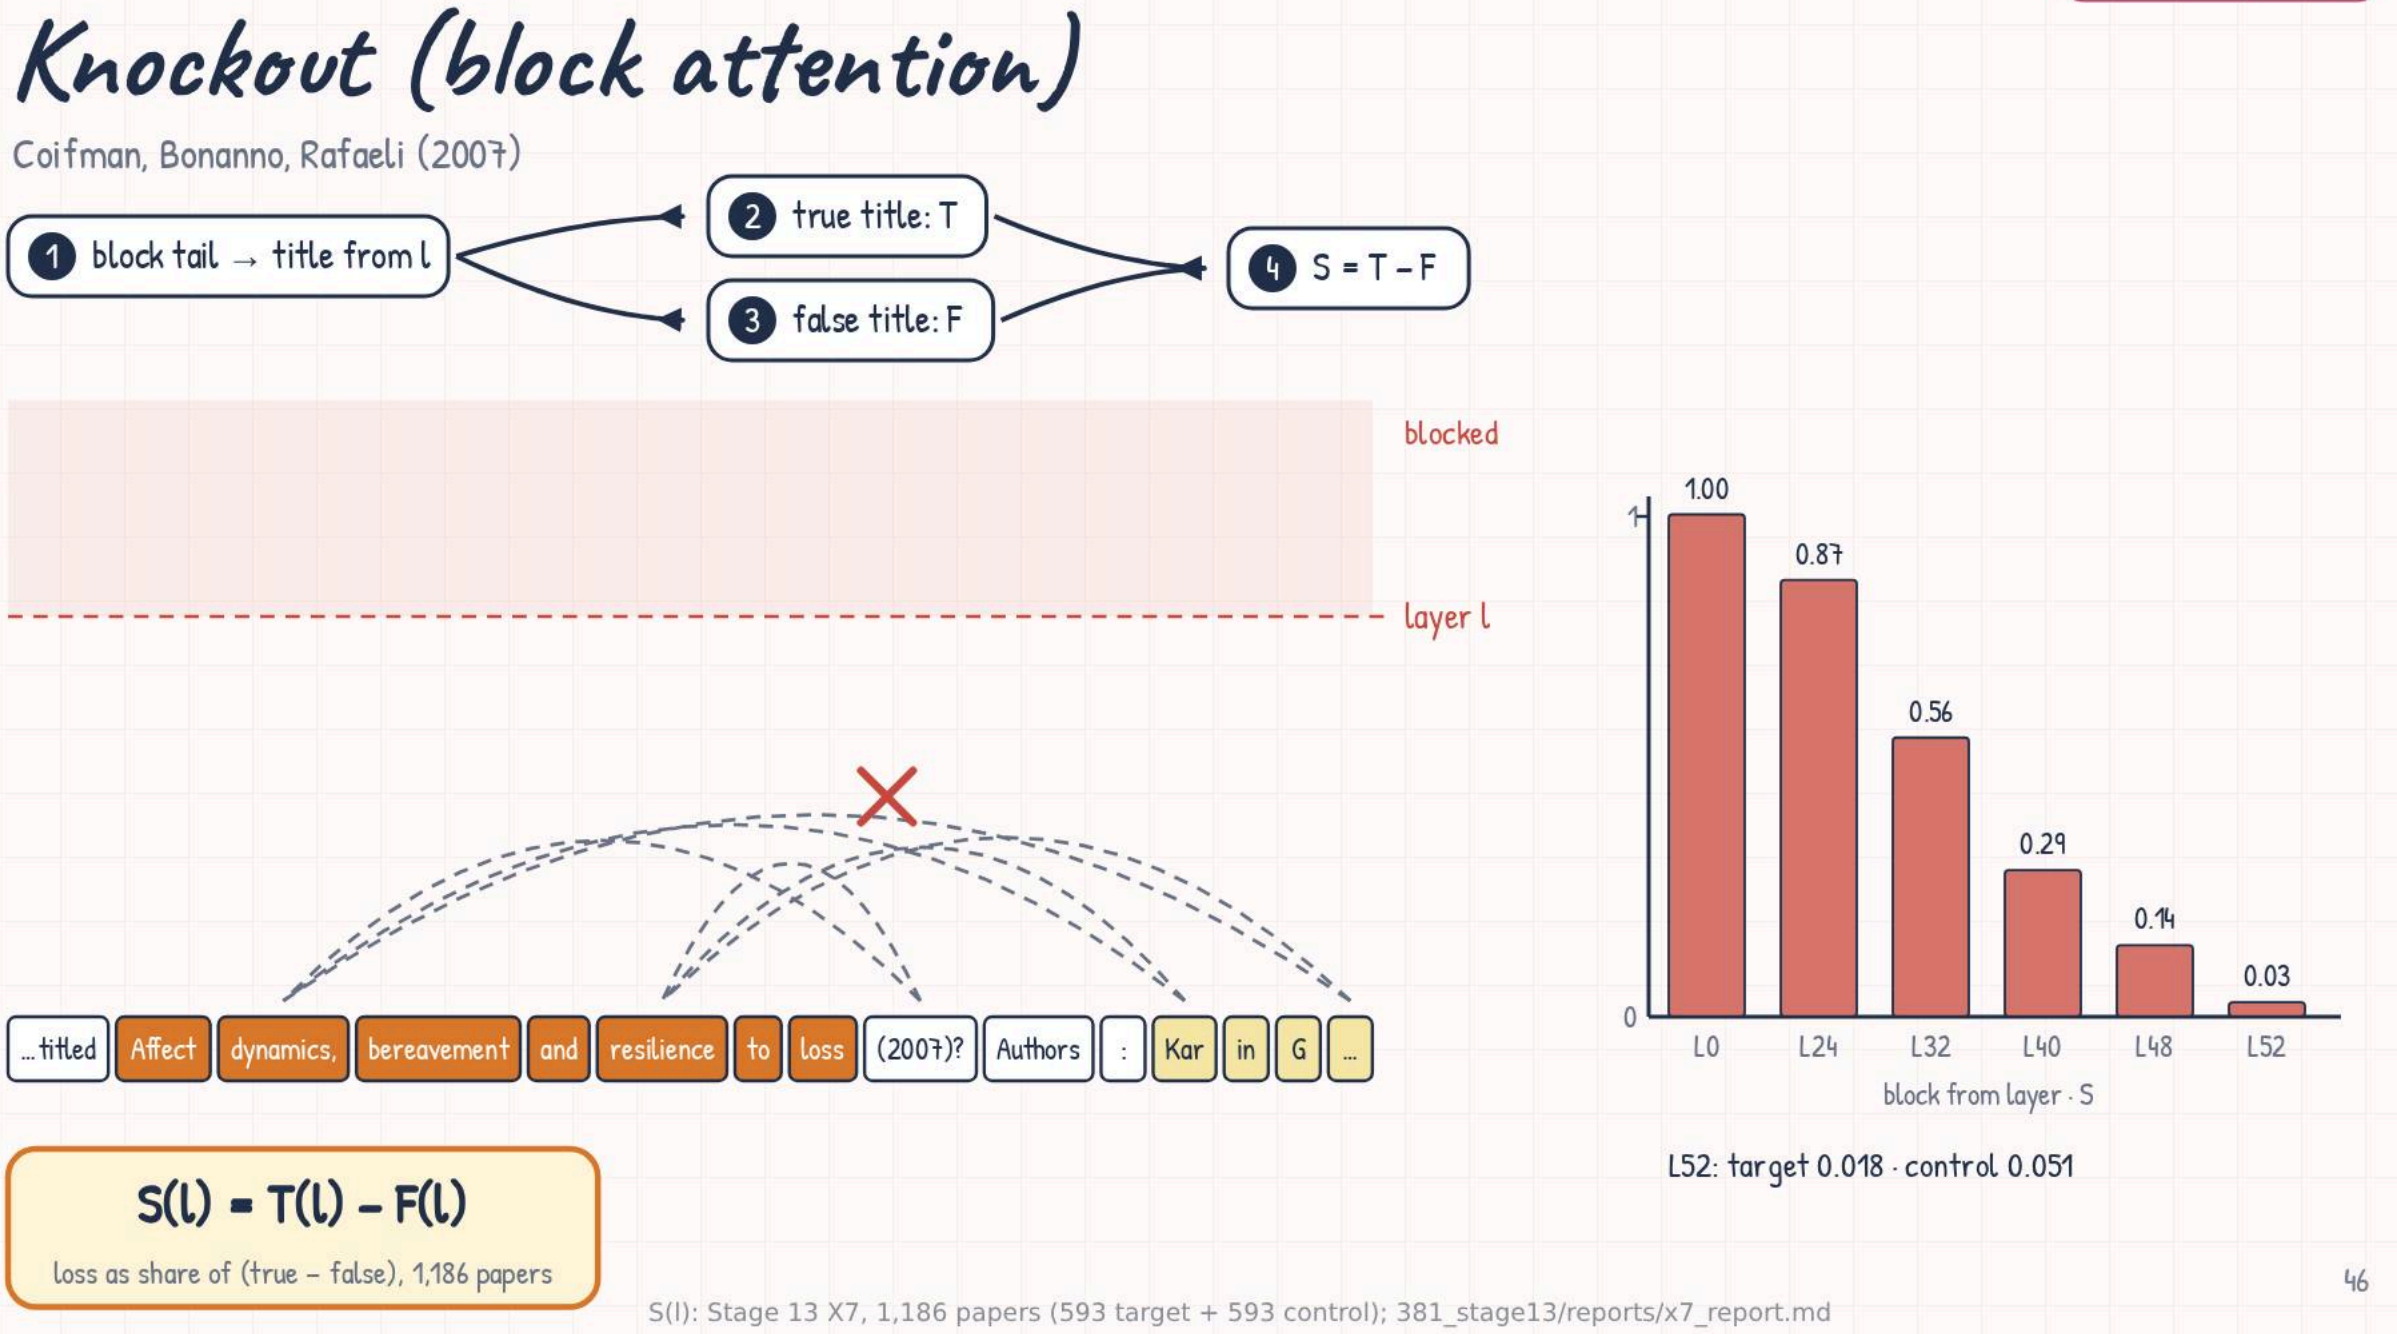
steepest rise **L57–L61**

细层 L50 到 L61 是后来为 logit lens 和公开 lens 补算的。目标组的优势不是在 L62 突然出现的：logit lens 下，标题特异的目标−对照在 L50 为 +0.007，L54 为 +0.03，L56 为 +0.07，L58 为 +0.11，L60 为 +0.18，L62 为 +0.23（Stage 10 主轮 + 细层扩展，真标题 − 5 个假标题平均，logit lens，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇）：L50 +0.007 [0.001, 0.014]、L52 +0.018、L54 +0.030、L56 +0.065、L58 +0.114、L60 +0.178、L62 +0.229，论文 bootstrap 95% CI；报告 §6.10 图与表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）。公开 lens 到 L54 为负，L57 转正（同上，public J-lens：L48–L54 为 −0.02 到 −0.05，L57 起转正 +0.029 [0.009, 0.048]，L61 +0.207；报告 §6.10 图与表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）。上升最快的是 L57 到 L61，两组都在 L61 达到最高（Stage 10，真标题 − 5 个假标题平均，logit lens 各组均值：目标 L50 +0.022 → L61 +0.596，对照 +0.020 → +0.282（L62 为 +0.583 / +0.252）；报告 §6.10；351_stage10/summary_title/A_group_layer.csv）。



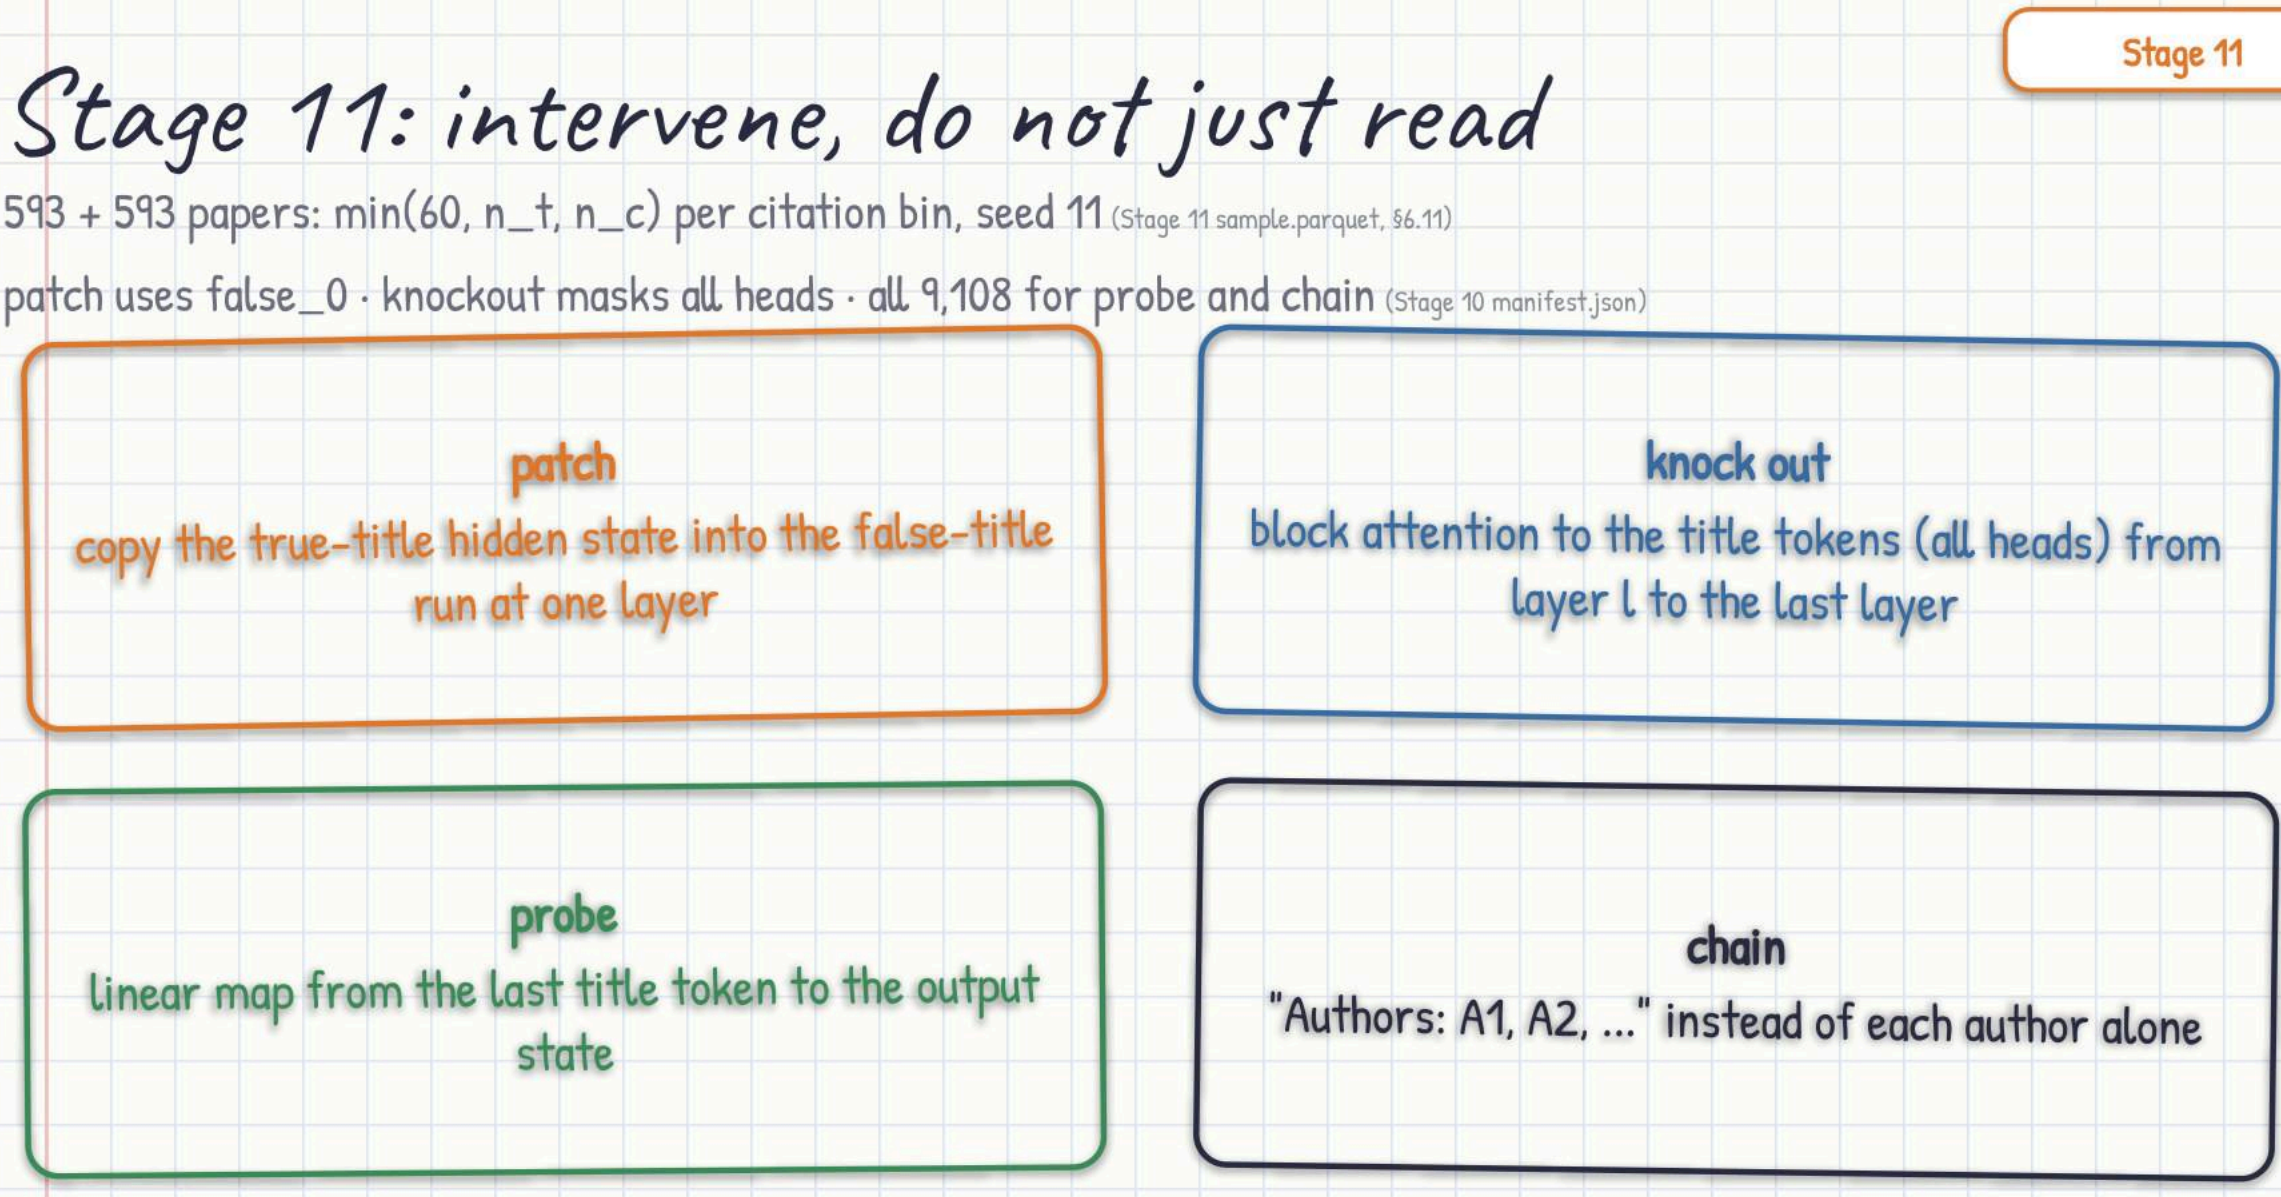
第 45 / 75 页 · Method · Replacement (patching) · 合并 PPT 自身页面 新写讲稿

替换（patching）：同一组名字分别接在真标题和假标题后面跑两次；在第 l 层，把真标题运行中标题之后的 token（“(2007)?”、“Authors”、冒号）和名字位置的状态复制进假标题运行，再给名字打分。恢复比例 R(l) = (patched − false) ÷ (true − false)。1,186 篇、5 个假标题平均：L24 0.080、L40 0.302、L48 0.821、L52 0.995（Stage 13 X6，用 5 个假标题分别做 Stage 11 E1 替换，全部 1,186 篇，5 个假标题平均 R：L24 0.080、L40 0.302、L48 0.821、L52 0.995，团队聚类 95% CI；报告 Stage 13 X6 节；381_stage13/reports/x6_report.md（all 表 average 列））， 即到 L52 标题信息已全部进入标题之后的位置。



第 46 / 75 页 · Method · Knockout (block) · 合并 PPT 自身页面 **新写讲稿**

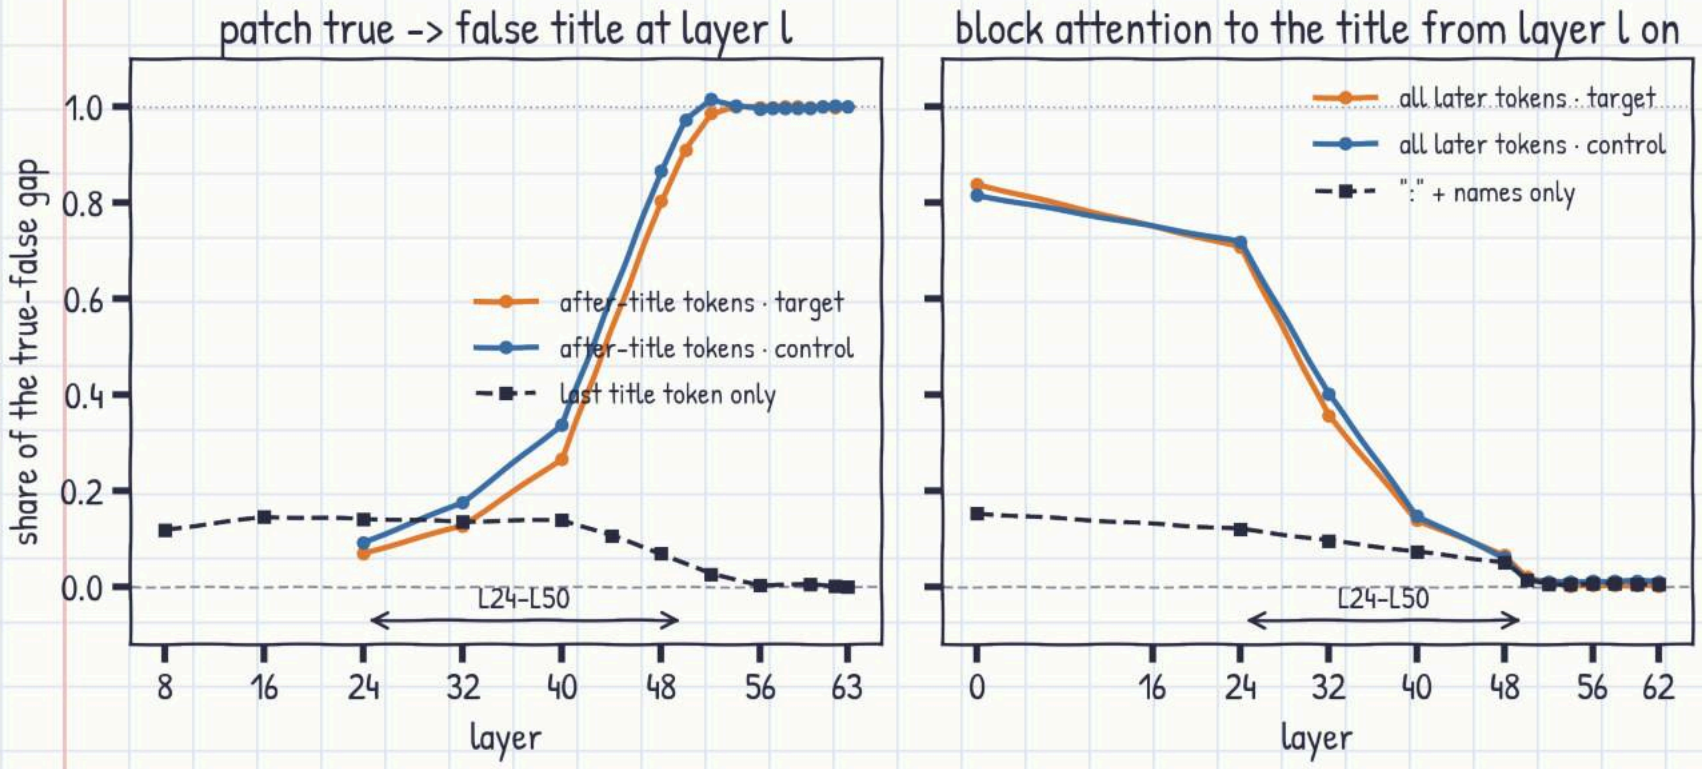
阻断（knockout）：从第 l 层起，让标题之后的每个位置都不能注意标题 token，记下名字分数的损失 T；在假标题运行上做同样的阻断得到 F；S = T − F，用真 − 假差距的比例表示。X7（1,186 篇）：从 L0 阻断 S = 1.00，L24 0.87，L40 0.29，L48 0.14，L52 0.029（target 0.018，control 0.051）（Stage 13 X7，S = T − F（真标题运行的阻断损失减去 false_0 运行的同样阻断），÷ 真 − 假差距，全部 1,186 篇：L0 1.004、L24 0.873、L40 0.293、L48 0.143、L52 0.029（target 0.018、control 0.051），团队聚类 95% CI；报告 Stage 13 X7 表；381_stage13/reports/x7_report.md；381_stage13/summary_x7/x7_knockout.csv），所以 L52 之后标题已基本不再被读取。



Stage 11 把读出问题变成干预实验。用了 593 篇目标论文和 593 篇对照论文（Stage 11 抽样，10 个可比引用档内配平，目标 593 + 对照 593 = 1,186 篇；361_stage11/config/sample.parquet；361_stage11/config/protocol.json），在引用档内匹配。替换：同一篇论文分别用真标题和匹配的假标题运行，在某一层把真标题运行的隐藏状态复制到假标题运行里。阻断：从第 l 层到最后，禁止注意力看标题 token。Probe：训练一个从标题最后一个 token 到输出状态的线性映射。作者链：在前面作者都给出之后，再给每位作者打分。

The title is read in L24-L50, early

model output · share of the true-false gap · CIs about +/-0.02 (Stage 11 E1/E2, 593 + 593 papers, §6.11)



L52+: title no longer needed

the information enters the **name positions at L44–52**, partly via the tokens right after the title

same timing for target and control

两条因果曲线。左边：把真标题运行中标题之后那些 token（右引号、年份、“Authors:”、名字）的隐藏状态复制到假标题运行里，L40 恢复 29%，L48 恢复 82%（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L40 0.291 [0.274, 0.308]，L48 0.825 [0.807, 0.842]；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））， L52 起全部恢复（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L52 0.996 [0.989, 1.003]；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））；只复制标题最后一个 token 只恢复约 12%（Stage 11 E1t，只替换标题最后一个 token，真标题→false_0，最终输出恢复比例，全部 1,186 篇 L8–L40 为 0.12–0.15，L56 0.004；报告 §6.11 恢复比例图虚线；361_stage11/summary/E1t_recovery.csv）。右边：从 L0 起阻断对标题的注意力，去掉 83% 的效应；从 L32 起 37%，从 L48 起 6%，从 L52 起为 0（Stage 11 E2 阻断，标题之后全部位置从第 l 层起不能注意标题，最终输出损失比例（÷ 真标题 − false_0 差距），1,186 篇，L0 0.831 [0.801, 0.862]、L32 0.372、L48 0.064、L52 0.007 [0.001, 0.013]；报告 §6.11 阻断图；361_stage11/summary/E2_knockout.csv（group=all））。只阻断冒号和名字位置最多去掉 15%（Stage 11 E2n，只阻断 “:” 和名字位置对标题的注意力，从 L0 起，最终输出损失比例，1,186 篇，0.153 [0.136, 0.172]；报告 §6.11 阻断图虚线；361_stage11/summary/E2n_knockout.csv），所以页面上说：信息在 L44–52 进入名字位置，部分经由标题之后的 token。（已复核：被复制的 token 里包括名字位置本身。Stage 12 P1 逐位置替换显示，信息主要汇集在名字位置上：只换名字位置在 L52 恢复 0.85，只换冒号最多 0.17（Stage 12 P1 逐位置替换，真标题→false_0，最终输出名字 token 恢复比例，Stage 11 样本 1,186 篇：只换名字位置 L48 0.61、L52 0.847，单个位置最大为 “:” L52 0.172 [0.156, 0.187]；报告 Stage 12 节 P1 表；371_stage12/summary/P1_patch_pos.csv）；X6 用 5 个假标题重做，时间不变，L48 恢复约 0.82，L52 起约 1.0（Stage 13 X6，用 5 个假标题分别做 Stage 11 E1 替换，全部 1,186 篇，5 个假标题平均 R：L24 0.080、L40 0.302、L48 0.821、L52 0.995，团队聚类 95% CI；报告 Stage 13 X6 节；381_stage13/reports/x6_report.md（all 表 average 列））。）目标组和对照组的曲线相同。

Stages 1–9 · 20–200 papers

What we saw

- Stage 4 peak at L56 driven by one paper (71%)(audit_report.md)
- 7.2: A–B win-rate positive at L40–L56
- 7.3, 8: L56 title advantage; L56 became the primary layer

Stages 10–11 · 9,108 papers

What scale showed

- L56 is where it *starts*; steepest rise L57–L61
- Patching: copying tail states recovers 80–87% at L48, 100% from L52(Stage 11 E1, 593 + 593; x6_report.md)
- Knockout: blocking the title from L52 on costs nothing

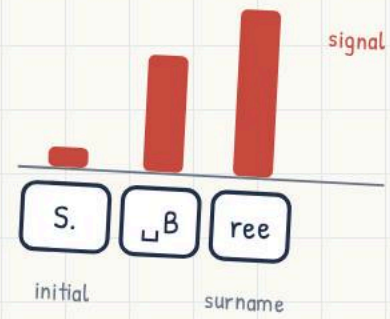
Line C: "read early, spoken late"

L56 was a real landmark, but not the peak. Interventions add what readouts cannot: the title is consumed in L24–50, and the answer only becomes readable at the name a dozen layers later.

C 线的小结。小样本阶段看到：Stage 4 的 L56 峰值由一篇论文撑起（71%）（Stage 4，J-Lens L56，第一作者首 token 倒数名次，20 篇，最大单篇占总和 71.03%；351_all/351_stage4_artifacts/audit/audit_report.md 表 1 行 L56；报告 Stage 4 节）；7.2 中 A–B 胜率在 L40–L56 为正；7.3 和 Stage 8 的标题优势在 L56，于是 L56 成了主要层。全量阶段看到：L56 是开始上升的地方，上升最快的是 L57–L61；替换标题之后的 token 状态在 L48 恢复 80–87%（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例，L48 目标 593 篇 0.803、对照 593 篇 0.866（全部 0.825）；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv），L52 起恢复 100%（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L52 0.996 [0.989, 1.003]（目标 0.986、对照 1.016）；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））；从 L52 起阻断标题几乎没有损失。L56 是真实的路标，但不是峰值；干预实验补上了读出看不到的东西：标题在 L24–50 被读取，答案要到十几层之后才在名字位置变得可读。（已复核：页面中“复制标题之后的 token 状态”包含名字位置本身；Stage 12 P1 和 X6 显示信息主要汇集在名字位置上，L52 起完成。）

Line D

Which token carries it?



small samples asked

First token or the rest of the name?

→

the full cohort answered

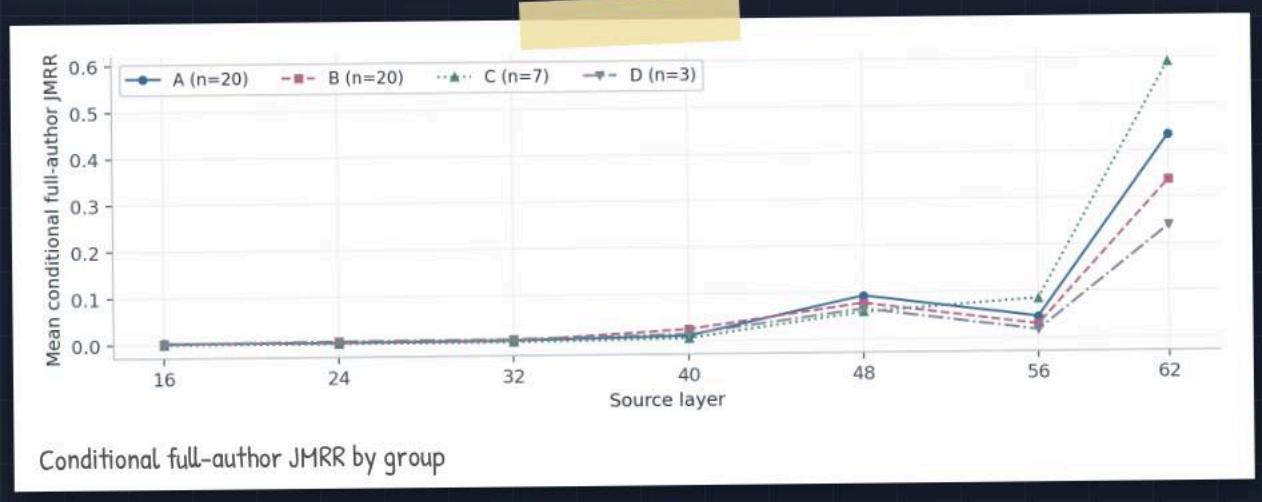
Depends on name format; the information enters the name positions at L44–52, partly via the tokens right after the title; co-authors partly replace the title

D 线的问题是：哪个 token 带着信号？小样本阶段问的是：是名字的第一个 token，还是名字的其余部分？全量阶段的回答是：取决于名字的格式；信息在 L44–52 进入名字位置，部分经由标题之后的 token；前面的合作者会部分代替标题的作用。（这一点已按 Stage 12 P1 和 X6 复核。）

Stage 6 · Line D

From first token to the full name

50 papers, 227 authors, 972 name tokens(token_layer_scores.csv); every listed author scored with teacher forcing



Conditional full-author JMRR by group

Group	Integrated JMRR(integrated_group.csv)
A (20)	0.085 [0.075, 0.096]
B (20)	0.068 [0.057, 0.080]
C (7)	0.106
D (3)	0.050

L62 A–B +0.097 [0.028, 0.163]; Vanilla also +0.091(20 pairs, matched_ab_bootstrap.csv)

Positive, but each token after the first is given the correct prefix. Next: split first token from the rest (7.1).

 新写讲稿

Stage 6 从第一个 token 扩展到完整名字：50 篇论文、227 位作者、972 个名字 token（Stage 6，Pilot50；351_stage6/raw/token_layer_scores.csv（方法手册统计）；351_stage6/summary/summary.json），所有列出的作者都用教师强制打分。条件完整作者 JMRR：A 组 0.085 [0.075, 0.096]，B 组 0.068 [0.057, 0.080]，C 组 0.106，D 组 0.050（Stage 6，J-Lens 条件完整作者 JMRR，7 层积分，各组论文均值（A 20、B 20、C 7、D 3 篇），论文 bootstrap 95% CI；报告 Stage 6 节图 6.1；351_stage6/summary/integrated_group.csv）。L62 上 A−B 为 +0.097 [0.028, 0.163]，Vanilla 也是 +0.091（Stage 6，条件全名 JMRR，L62 匹配 A − B，20 对：J-Lens +0.0966 [0.0282, 0.1630]，Vanilla +0.0907 [0.0161, 0.1676]，配对 bootstrap 95% CI；351_stage6/summary/matched_ab_bootstrap.csv 行 layer=62）。结果为正，但第一个 token 之后的每个 token 都已经给出了正确的前缀，所以下一步要把第一个 token 和其余部分分开（7.1）。

Stage 7.1 · Line D

The A–B gap sits on the rest of the name

CPU-only re-analysis of Stage 6; 10,000 pair-bootstrap draws



Integrated A–B JMRR by token position

Endpoint	A–B (7 layers)(20 pairs; layer_and_integrated_effects.csv)
First token	+0.001 [−0.011, +0.015]
Continuation	+0.021 [+0.002, +0.039]
All tokens	+0.017 [+0.003, +0.030]

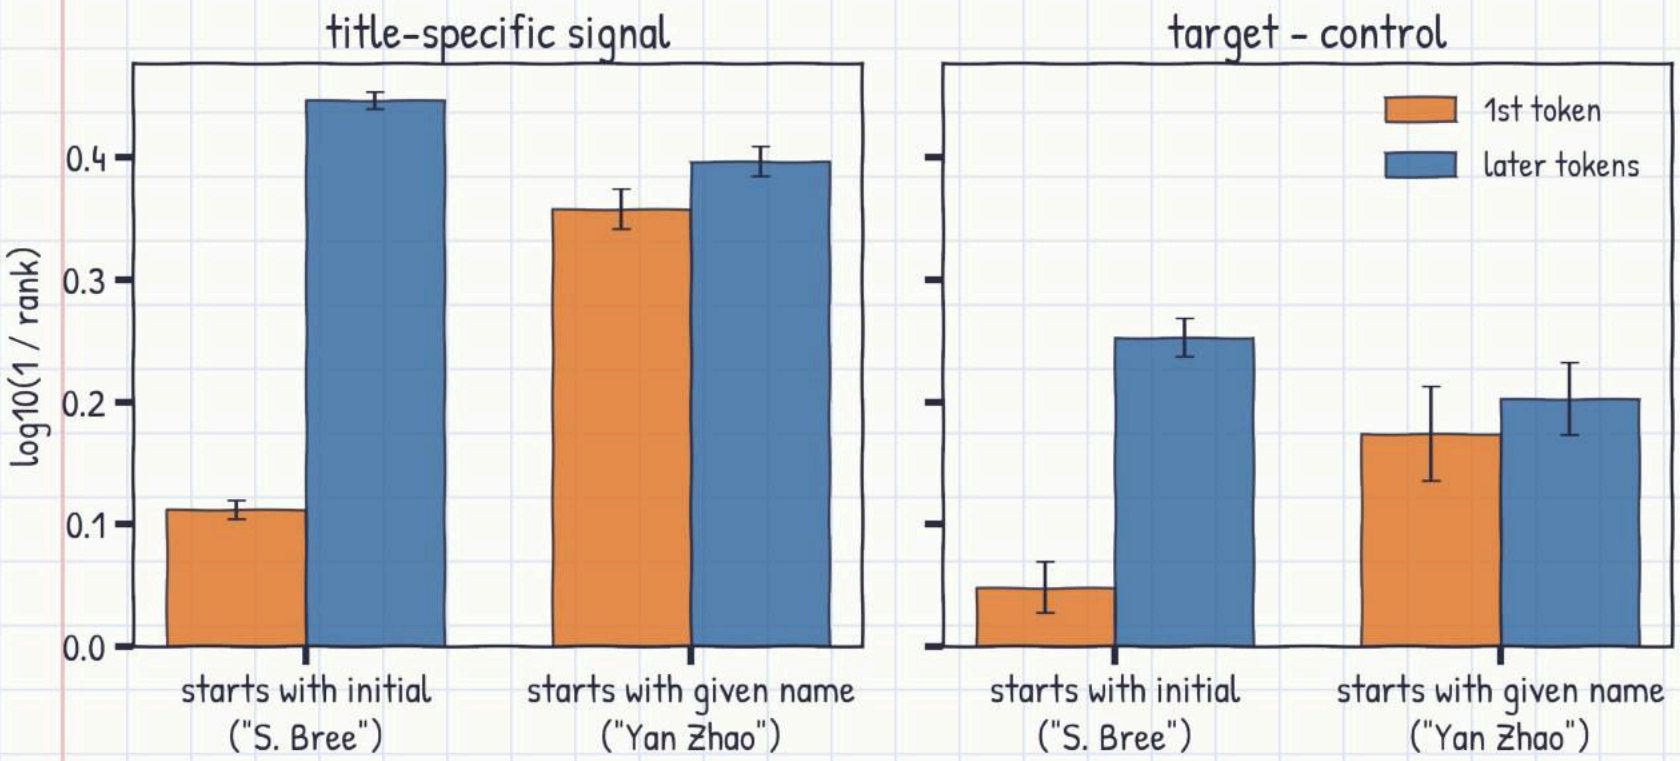
At L62: first +0.014 (12/20 pairs) vs continuation +0.121 (15/20)(layer_position_effects.csv)

Completing a name is easier than starting it. A continuation gap cannot show unaided recall. **Open:** is this about initials vs surnames?

Stage 7.1 只用 CPU 重新分析 Stage 6，做了 10,000 次配对 bootstrap（Stage 7.1 设计，种子 35171；~/jlens_work/07_1_stage7_1/351_stage7.py:14,86-87,181）。7 层积分的 A−B：第一个 token +0.001 [−0.011, +0.015]，后续 token +0.021 [+0.002, +0.039]，全部 token +0.017 [+0.003, +0.030]（Stage 7.1，J-Lens JMRR 7 层积分，匹配 A − B，20 对，配对 bootstrap 95% CI：第一个 token +0.0014 [−0.0114, +0.0149]，后续 token +0.0206 [+0.0022, +0.0385]，全部 token +0.0166 [+0.0026, +0.0299]；报告 Stage 7.1 节表；351_stage7_1/summary/layer_and_integrated_effects.csv）。在 L62，第一个 token +0.014（20 对里 12 对为正），后续 token +0.121（20 对里 15 对为正）（同上，L62：第一个 token +0.0141（12/20 为正），后续 token +0.1215（15/20 为正）；351_stage7_1/summary/layer_and_integrated_effects.csv（layer=62））。补全一个名字比开头更容易，后续 token 上的差距不能说明模型能独立回忆。留下的问题是：这是不是首字母和姓的区别?

First token or the rest of the name?

model output · split by name format



Initial: carries little; signal is on the surname

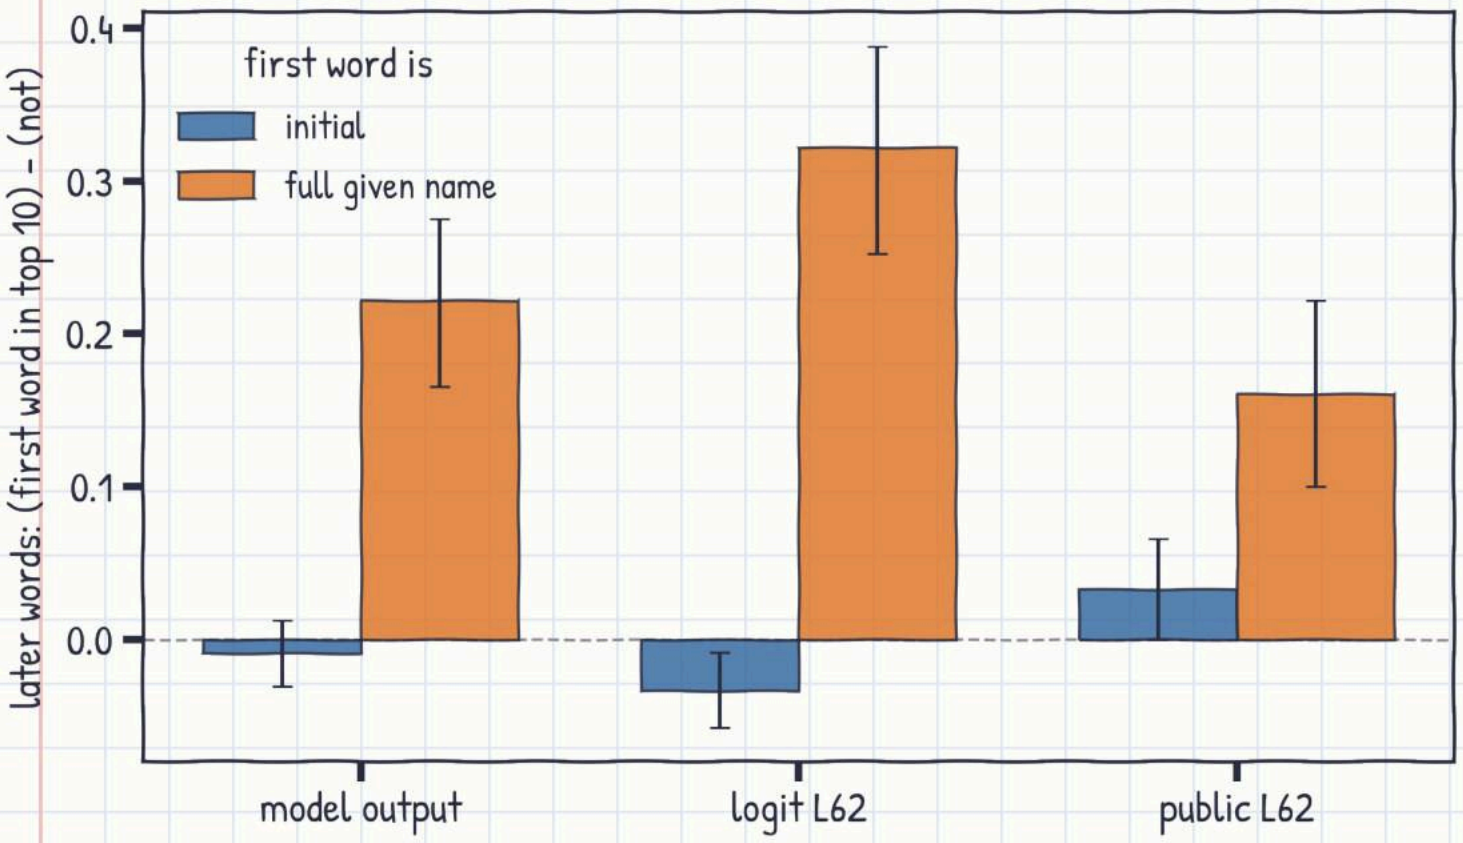
Full given name: carries about as much as the surname

信号是否由第一个 token 决定？取决于名字的格式。以首字母开头的名字，首字母本身带的信号很少，信号在包括姓在内的后续 token 上；以完整名开头的名字，名本身带的信号和其余部分差不多。要注意教师强制：后续 token 在每种条件下都已经看到正确的前缀，所以它们的标题特异信号只能来自标题。

Stage 10

Knowing the given name helps with the surname

true title · later words when the first word is / is not in the top 10



Given name in top 10

surname +0.22 (output) (Stage 10, 8,876 authors, §6.7)

+0.32 (logit L62) (same)

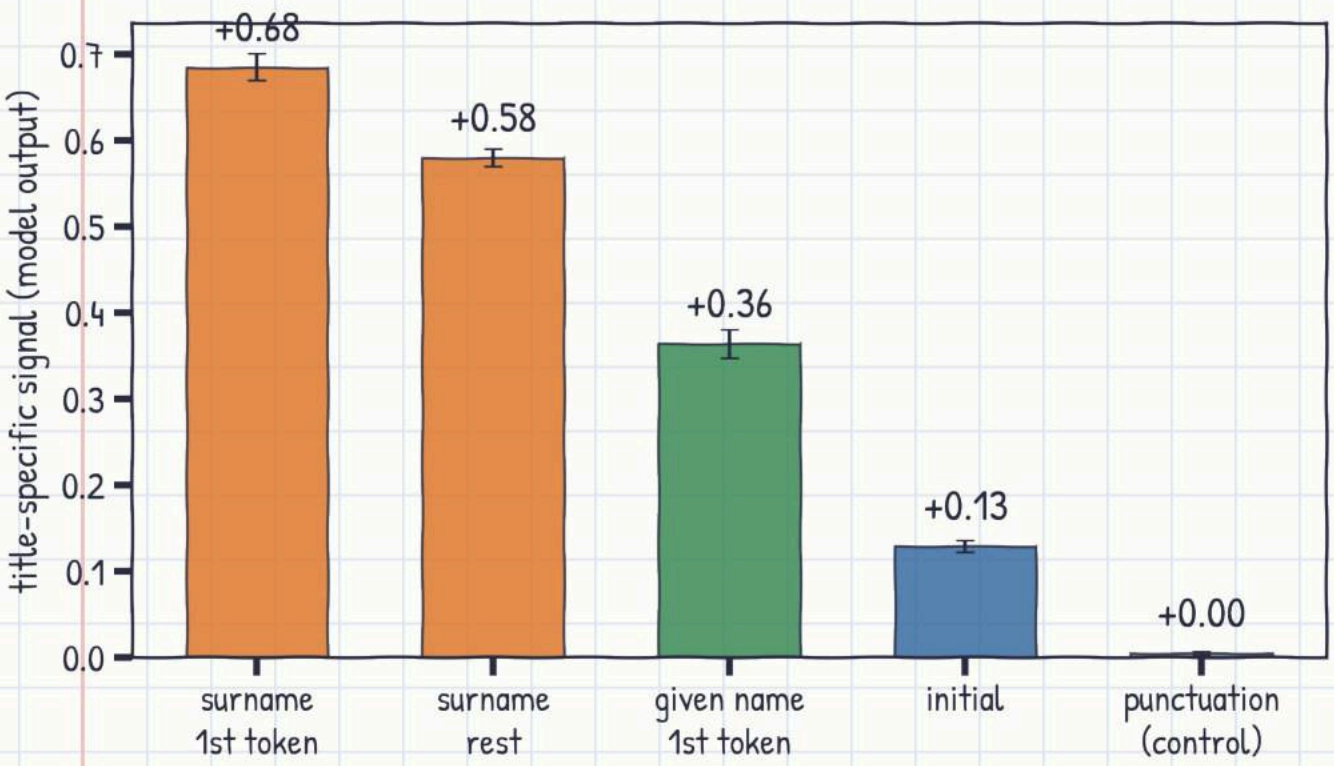
Initial in top 10: no help

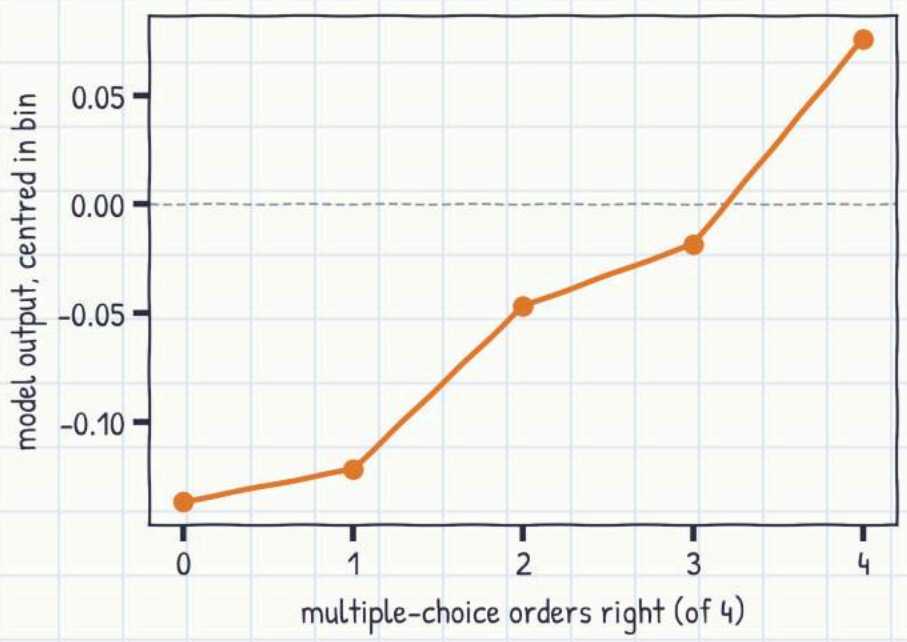
 按 deck 讲稿备注翻译（已按复核结果更新）

知道了第一个词，其余部分会更容易吗？对完整的名，是的：名进入前 10 名时，姓在输出处高 +0.22，logit lens 在 L62 高 +0.32（Stage 10 §6.7，真标题，完整名开头的 8,876 位作者（名进前 10：678 位），姓（后续 token）平均 log10(1/名次)，进前 10 − 未进，论文聚类 bootstrap 95% CI：最终输出 L63 +0.222 [0.165, 0.275]，logit lens L62 +0.322 [0.253, 0.388]；351_stage10/summary_extra/X1_cond_by_first_role.csv）。对首字母则没有这种帮助。如果把两种格式混在一起，甚至会看到负的效果，因为首字母很好猜，而后面的姓很难。

Stage 10

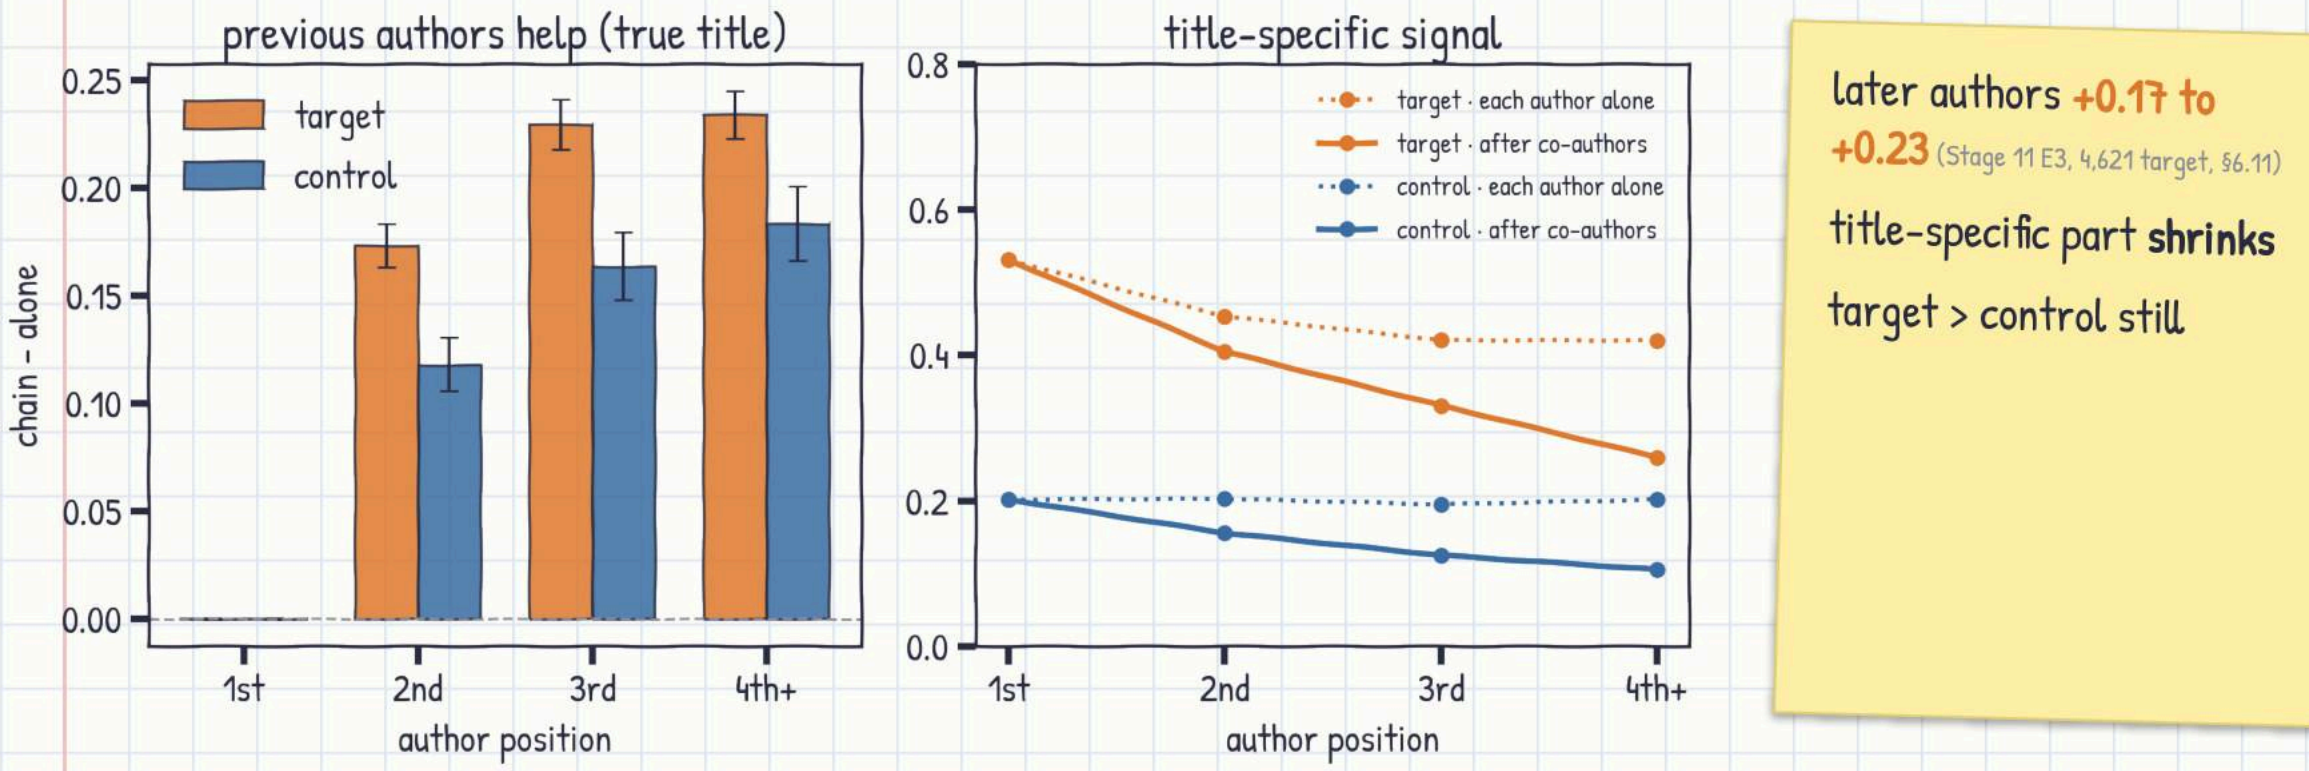
Where the signal sits, and a dose-response





Right: R0/R1 papers, centred within citation bin; Spearman rho = 0.27, p < 0.001. (Stage 10, 8,894 papers, §6.6)

左图是输出处按 token 角色分的标题特异信号：姓的第一个 token 最多，首字母最少，标点约为 0，这是阴性对照。右图是：在所有写不出作者的论文里，多选题答对的顺序越多，模型输出越好（Spearman 0.27）（Stage 10，真标题，最终输出 L63，引用档内中心化的平均 log10(1/名次) 与多选题答对顺序数 0–4，R0/R1 论文 8,894 篇，引用档内 Spearman ρ = 0.268（p < 0.001）；报告 §6.6；351_stage10/summary/C_graded_mc_team_a.csv（metric=mean_nlr））。



作者链。当前面的作者已经在上下文里时，后面的作者更容易：目标组高 +0.17 到 +0.23，对照组高 +0.12 到 +0.18（Stage 11 E3 连写 − 单独打分，真标题，最终输出 L63，作者位置 2 到 4+：目标 +0.173 / +0.229 / +0.234（4,073 / 2,978 / 2,030 篇），对照 +0.118 / +0.164 / +0.183，论文 bootstrap 95% CI；报告 §6.11 连写表 gain 列；361_stage11/summary/E3_chain.csv）。但标题的作用变小了：后面目标作者的标题特异信号从 0.42 降到 0.26（Stage 11 E3，目标组第 4 位起作者，标题特异信号（真标题 − 5 个假标题平均，最终输出）单独打分 +0.421 → 连写 +0.260，2,030 篇（第 2 位为 +0.454 → +0.405）；报告 §6.11 连写表 4+ · target 行；361_stage11/summary/E3_chain.csv），因为合作者已经能确定是哪篇论文。在引用档内，目标组仍然高于对照组 +0.11 到 +0.15（Stage 11 E3 连写，标题特异，引用档内 目标−对照，作者位置 2 / 3 / 4+：+0.151 / +0.124 / +0.114；报告 §6.11 连写表；361_stage11/summary/E3_chain.csv）。

Stages 1–9 · 20–200 papers

What we saw

- A–B lives on continuation tokens (+0.021), not the first token (+0.001)(7.1, 20 pairs)
- Open question: is that teacher forcing, initials or surnames?

Stages 10–11 · 9,108 papers

What scale showed

- 73% of names start with an initial(24,739 / 33,780; §6.7), which carries little
- Full given names carry as much as surnames and help predict them (+0.22)(final L63; §6.7)
- Information travels title → name positions (L44–52), partly via tail tokens
- Earlier co-authors make later ones easier, title matters less

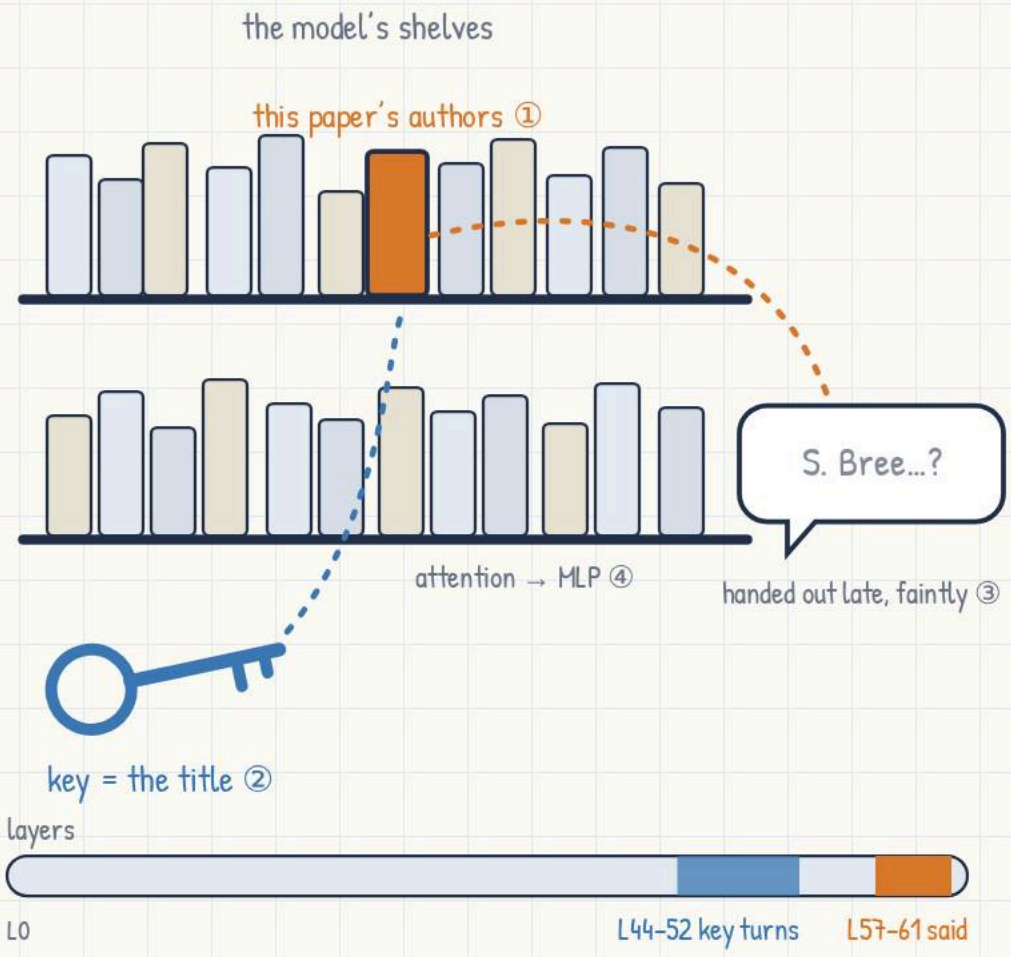
Line D: the puzzle from 7.1 is explained by name format

The pilot's "continuation" result was mostly a format effect: for "S. Bree" the surname is a continuation token. Stage 12 P1 (done) patched single positions: the name positions carry the signal (+0.85 at L52), the colon alone little (+0.17)(P1, 1,186 papers; P1_patch_pos.csv).

D 线的小结。小样本阶段看到：A–B 的差在后续 token 上（+0.021），不在第一个 token 上（+0.001）（Stage 7.1，J-Lens JMRR 7 层积分，匹配 A − B，20 对：后续 token +0.0206 [+0.0022, +0.0385]，第一个 token +0.0014 [−0.0114, +0.0149]；351_stage7_1/summary/layer_and_integrated_effects.csv）；当时留下的问题是，这是教师强制造成的，还是首字母和姓的区别。全量阶段看到：73% 的名字以首字母开头（Stage 10 名字格式，24,739 / 33,780 个作者上下文以首字母开头；报告 §6.7；351_stage10/summary_extra/X1_cond_by_first_role.csv 列 n_contexts（readout=final）），首字母本身信息很少；完整的名带的信号和姓相当，还能帮助预测姓（+0.22）（Stage 10 §6.7，完整名开头 8,876 位作者，名进前 10 − 未进，最终输出 L63 姓 +0.222 [0.165, 0.275]，论文聚类 bootstrap 95% CI；351_stage10/summary_extra/X1_cond_by_first_role.csv）；信息从标题在 L44–L52 汇集到名字位置，部分经由标题之后的 token；前面的合作者让后面的作者更容易，标题的作用变小。7.1 的谜题由名字格式解释：像“S. Bree”这样的名字，姓本来就是后续 token。Stage 12 P1 已完成：只换名字位置在 L52 恢复 0.85，只换冒号最多 0.17（Stage 12 P1 逐位置替换，真标题→false_0，最终输出名字 token 恢复比例，Stage 11 样本 1,186 篇：只换名字位置 L48 0.61、L52 0.847，单个位置最大为 “:” L52 0.172 [0.156, 0.187]；报告 Stage 12 节 P1 表；371_stage12/summary/P1_patch_pos.csv）；X6 用 5 个假标题（Stage 13 X6，用 5 个假标题分别做 Stage 11 E1 替换，全部 1,186 篇，5 个假标题平均 R：L24 0.080、L40 0.302、L48 0.821、L52 0.995，团队聚类 95% CI；报告 Stage 13 X6 节；381_stage13/reports/x6_report.md（all 表 average 列））确认了这个时间。

Keys and shelves

Is the book on the shelf, or is the key failing to get it out?



① Is the book on the shelf? Yes

True title beats false titles (≈0.44 at L62(§6.9)); a probe on the title token reads paper-specific authors from L24 (re-checked)

Lines A, B · Stage 5, 7.3, 8D, 10, 11

② Key = the title, read into the name positions at L44–52

Whole prompt: 0.82 at L48, ≈1.0 from L52; name positions alone 0.61 → 0.85; ':' alone ≤ 0.17(E1, P1; 1,186 papers); knockout after L52 costs almost nothing

Line C · Stage 11, 12 P1

③ Book there but stuck? Not supported

Target − control ≈ 0 at L24–L40, slightly negative at L48 (−0.04 to −0.05), grows only at L57–61 (+0.21 at output(§6.4)): retrieval itself is weak

Lines A, C · Stage 7.2, 10

④ Which shelf? Both, in order

Attention brings the title in at L48 (0.23); MLP takes over at L52–56 (0.18, 0.22)(P2, 1,186 papers). One-layer patching is a lower bound; whether the MLP step is memory lookup is not yet separable

Stage 12 P2

Caveat: a readout not finding it ≠ absent. Stage 13: ':' and name positions hold the task; the title position holds paper attributes and meaning beyond the words, not shown to be paper identity.

 新写讲稿

用“钥匙和书架”来串起四条线。第一，书在不在架上？在：真标题胜过假标题，L62 约 0.44（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 § 6.9 表；351_stage10/summary_extra/X3_means.csv）；标题 token 上的 probe 能读出论文特有的作者（复核后从 L24 起）。第二，钥匙就是标题，在 L44–52 被读进名字位置：整段提示替换在 L48 恢复 0.82（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L48 0.825 [0.807, 0.842]；报告 § 6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））， L52 起约 1.0（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L52 0.996 [0.989, 1.003]；报告 § 6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））；只换名字位置从 0.61 升到 0.85，只换“:”最多 0.17（Stage 12 P1 逐位置替换，真标题→false_0，最终输出名字 token 恢复比例，Stage 11 样本 1,186 篇：只换名字位置 L48 0.61、L52 0.847，单个位置最大为“:” L52 0.172 [0.156, 0.187]；报告 Stage 12 节 P1 表；371_stage12/summary/P1_patch_pos.csv）；L52 之后阻断几乎没有损失（Stage 11 E2 阻断，标题之后全部位置从第 l 层起不能注意标题，最终输出损失比例（÷ 真标题 − false_0 差距），1,186 篇，L52 0.007 [0.001, 0.013]；报告 § 6.11 阻断图；361_stage11/summary/E2_knockout.csv（group=all））（Stage 11 和 Stage 12 P1）。第三，书在架上但取不出来？不支持：目标−对照在 L24–L40 约为 0、L48 略为负（−0.04 到 −0.05，区间不含 0（Stage 10，引用档内目标−对照，三种 Jacobian lens L48 −0.037 到 −0.054；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）），只在 L57–61 上升（输出处 +0.21）（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.196, 0.220]，论文 bootstrap 95% CI；报告 § 6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），提取本身就弱。第四，在哪个书架上？两者都有，有先后：L48 的注意力把标题读进来（恢复 0.23）（Stage 12 P2，标题之后全部位置只替换单层 attention 或 MLP 输出，最终输出恢复比例，1,186 篇：attention L48 0.231（MLP 0.07），MLP L52 0.178、L56 0.224；报告 Stage 12 节 P2 表；371_stage12/summary/P2_patch_comp.csv），L52–56 由 MLP 接手（0.18、0.22）（Stage 12 P2，标题之后全部位置只替换单层 attention 或 MLP 输出，最终输出恢复比例，1,186 篇：attention L48 0.231（MLP 0.07），MLP L52 0.178、L56 0.224；报告 Stage 12 节 P2 表；371_stage12/summary/P2_patch_comp.csv）。单层替换只是下限，MLP 这一步是不是在查记忆还分不开（Stage 12 P2）。最后提醒：读出工具找不到，不等于信息不存在。Stage 13 显示：冒号和名字位置承载的是任务；标题位置承载论文属性和超出用词的语义，但没有证明是论文身份。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母/名/姓分开的版本按补充 9 进行中，尚无结果。

What the small samples taught us to watch for

- **Single-paper leverage**: one paper = 71% of the Stage 4 L56 mean (20 papers)
- **Tail-driven contrasts**: Stage 8 A–B disappears after removing 10 of 100 pairs(8D, matched_pair_differences.csv)
- **Forking paths**: L56 inspected repeatedly, then made primary
- **Candidate artefacts**: 100 false names share ~46 first tokens; 3% tie with gold(7.2 quality.json: 156/5,000)
- **Label noise**: strict "pass" 25.5% in the 0–2 citation bin (label_README.md)
- **Partial coverage**: first-listed author stands in for the team
- **Metric choice**: KL fidelity and author ranking disagree
- **Protocol drift**: primary endpoint changed between README and run

Stage 10 answered each one by design: full cohort, every author and token, all layers reported, full-vocabulary ranks, within-bin comparison, frozen inputs with parity checks. What it cannot fix: groups still come from one labelling run of the same model.

小样本阶段教会我们要提防的几件事：单篇论文的杠杆，一篇论文占 Stage 4 L56 均值的 71%（Stage 4，J-Lens L56，第一作者首 token 倒数名次，20 篇，最大单篇占总和 71.03%；351_all/351_stage4_artifacts/audit/audit_report.md 表 1 行 L56；报告 Stage 4 节）；尾部驱动的对比，Stage 8 的 A–B 去掉 100 对中的 10 对就消失（Stage 8D RQ2，J-Lens L56 金标准胜率匹配 A–B，100 对，均值 +4.98 pp，按 A–B 降序去掉前 10 对后其余 90 对均值 −0.39 pp（事后诊断）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）重算；报告 Stage 8D 节）；分叉路径，L56 被反复查看后才定为主终点；候选伪影，100 个错误名字只有约 46 个不同的第一个 token，3% 与正确名字打平（Stage 7.2，Pilot50 每篇 100 个错误名字（50 匹配 + 50 随机），共 5,000 个；每篇平均 45.76 个不同首 token（方法手册 C 部分由 351_stage7_2/candidates/pilot50_author_candidates.csv 统计）；156 / 5,000 = 3.1% 与金标准首 token 相同记为平局（351_stage7_2/summary/quality.json））；标签噪声，0–2 次引用档的严格通过率为 25.5%（标注包自检，0-2 引用档 796 篇，收紧规则（4/4 且真选项平均概率 ≥ 0.5）多选通过率 25.5%（普通规则 38.6%）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 8 行）；覆盖不全，用第一作者代替整个团队；指标选择，KL 保真度和作者排名不一致；协议漂移，主终点在 README 和实际运行之间改过。Stage 10 在设计上逐条回应：全量论文、所有作者和 token、报告所有层、全词表名次、引用档内比较、冻结输入并做一致性检查。它没法解决的是：分组仍然来自同一模型的一次标注。

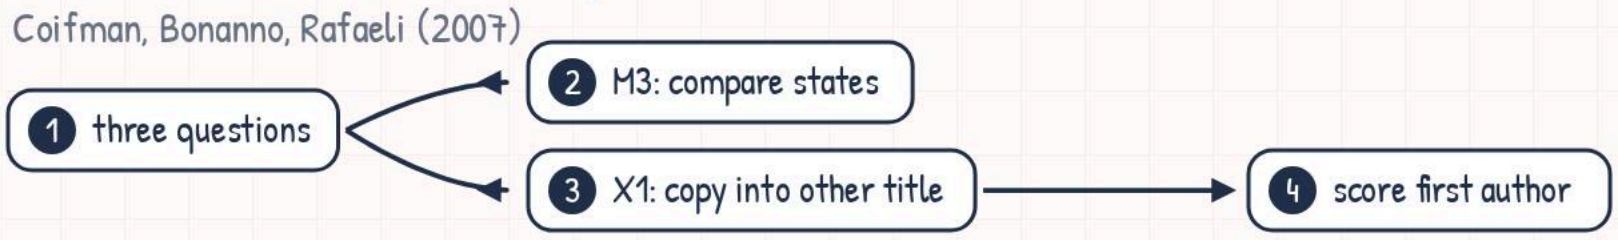
Small vs large, in one table

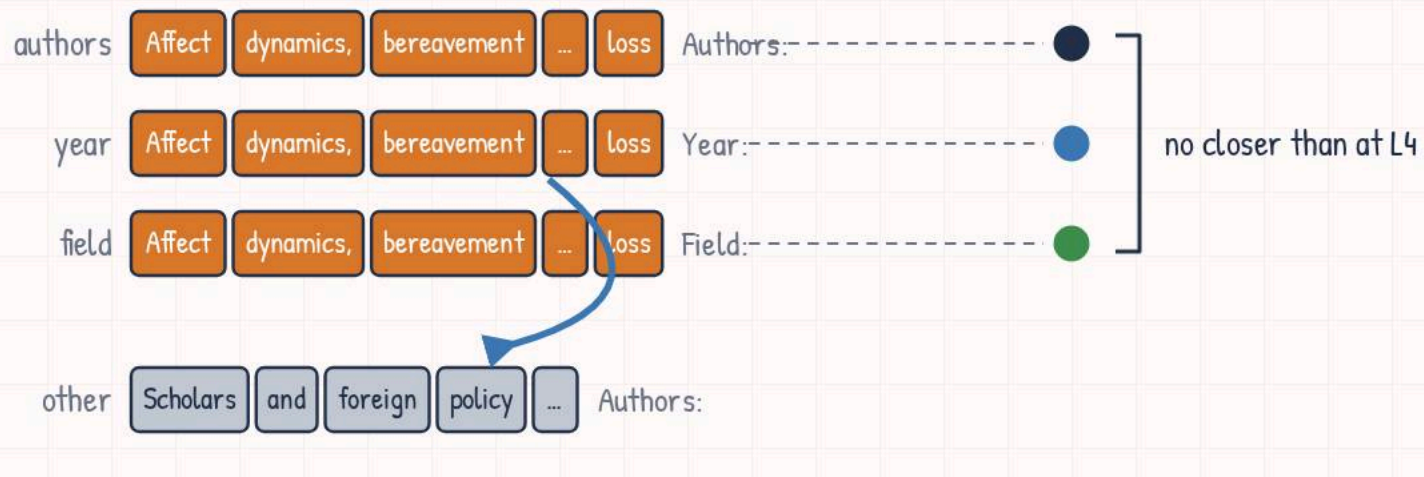
Finding	Stages 1-9 (20-200 papers)	Stages 10-11 (9,108 papers)	Verdict
True title helps	+9.3 pp pilot, +5.2 pp new 200(7.3; 8D RQ1)	≈0.44 title-specific at L62(X3_means.csv)	confirmed
Recognised > not recognised	uncertain, tail-driven	+0.21 at output(§6.4), ≈0 at L24-L40, slightly negative at L48 (−0.04 to −0.05)	confirmed, late only
Same groups (A vs B, R0 only)	A − B as above	+0.20 at output(§6.13), ≈0 at L24-L40, slightly negative at L48; R1 adds strength, not timing	comparable, unchanged
Key layer	L56	starts L56, rises L57-61; read L24-50	refined
J-Lens over Vanilla	no increment	more name shape, no paper identity	consistent
First vs rest of name	gap on continuation	explained by initials vs given names	explained
Citations	low-high inconclusive	monotonic, ρ = 0.45(X2_spearman.csv)	resolved
Lens stability	split-half one split; Stage 9 only Fit A	three Jacobian lenses fitted on different text agree; fit stability rests on Stage 9 Fit A only	only one piece of evidence (Stage 9 Fit A); Fit B not completed

一张表对照小样本和全量。真标题有帮助：Pilot +9.3（Stage 7.3，J-Lens L56，真标题胜率 − 20 个错误标题平均胜率，合并池，Pilot50 50 篇均值 +0.0934 [0.047, 0.139]（2026-10-30 重算区间，B = 20,000），35/50 篇为正；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv；报告 Stage 7.3 节）、新 200 篇 +5.2 个百分点（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节），全量 L62 标题特异约 0.44（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv），确认。认得出大于认不出：小样本不确定、依赖尾部，全量输出处 +0.21（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.196, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）、L24–L40 约为 0、L48 略为负（−0.04 到 −0.05，区间不含 0），确认，但只在最后几层。同一分组（A 对 B，只用 R0）：输出 +0.20（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv）、中间约 0，R1 只增加强度不改变时间，两阶段可比、结论不变。关键层：小样本是 L56，全量是 L56 开始、L57–61 上升、标题在 L24–50 被读取，细化。J-Lens 胜过 Vanilla：小样本没有增量，全量读出更多名字的样子、但没有论文身份，一致。名字第一个 token 和其余部分：小样本差距在后续 token，全量由首字母和完整名的格式差别解释。引用数：小样本低减高没有定论，全量单调上升 ρ = 0.45（Stage 10 补充 X2，标题特异信号（真标题 − 5 个假标题平均，最终输出 L63）对 log10(引用数+1) 的 Spearman ρ，全部 9,108 篇 0.451 [0.433, 0.467]，bootstrap 95% CI；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv），解决。lens 稳定性：小样本只有一次拆分、Stage 9 只有 Fit A，全量三把用不同文本拟合的 Jacobian lens（Stage 10 三种 Jacobian lens：public（557 条 WikiText-103）、self100（100 条）、fitA（Stage 9 Fit A 100 条）；351_stage10/config/lenses.json；报告 §6.9）结论一致；但同一把 lens 的拟合稳定性只有 Fit A 一份证据，Fit B 未完成。

Changing the question

Coifman, Bonanno, Rafaeli (2007)





R from	authors	year	field
L24	**0.99**	**0.98**	**0.99**
L40	**0.92**	**0.92**	**0.92**
L48	**0.42**	**0.41**	**0.42**

$$R(l) = (\text{patched} - \text{other}) \div (\text{own} - \text{other})$$

title states copied at layer l; 582 test papers

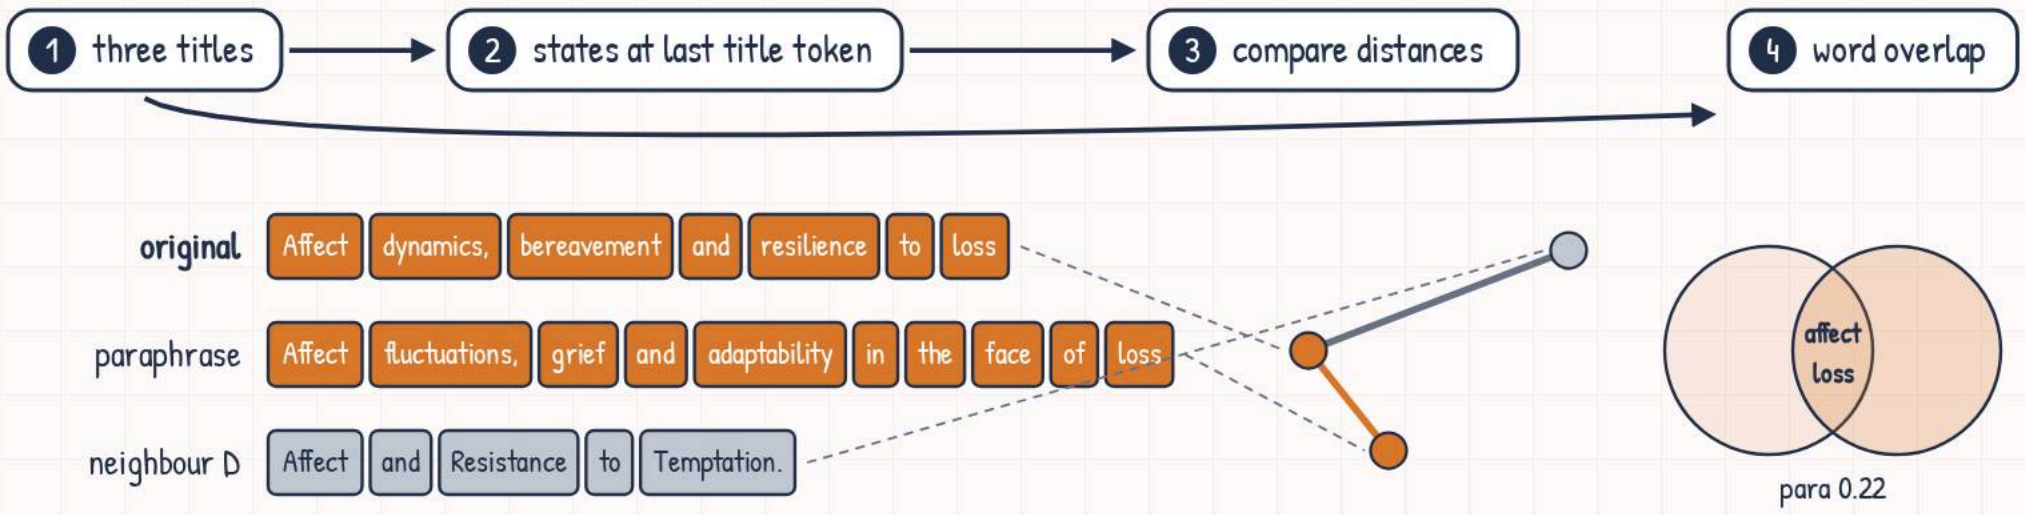
R: Stage 13 X1, test set 582 papers; 381_stage13/reports/x1_report.md

 新写讲稿

换问题：同一标题分别放进作者、年份、领域三个问题里（M3），比较标题最后位置的状态；它们不比 L4 时更接近，也就是没有超出标题文字本身的“论文身份”状态。X1 把本篇在任一问题下的标题状态复制进另一篇论文标题的作者提示，再给本篇第一作者打分：R(l) = (patched − other) ÷ (own − other)，L24 约 0.99，L40 约 0.92，L48 约 0.42（Stage 13 X1，测试集 582 篇，R = (patched − other) ÷ (own − other)，来源问题 作者/年份/领域：L24 0.991/0.985/0.992，L40 0.921/0.917/0.915，L48 0.424/0.405/0.417，团队聚类 95% CI；报告 Stage 13 X1 表；381_stage13/reports/x1_report.md test 表），三种来源几乎一样（测试集 582 篇）（Stage 13 X1 调参集/测试集按作者团队各半：测试 582、调参 596 篇；381_stage13/reports/x1_report.md 第 3 行；381_stage13/config/pairs.parquet）。

Paraphrased title (X3)

same paper in other words vs other paper, same words



G′ = cos(orig, para) − cos(orig, D)

+0.32 at L8 · peak +0.46 at L36 (test set)

first-author score, paraphrase − D: +0.239

medians: 0.61 vs 0.15

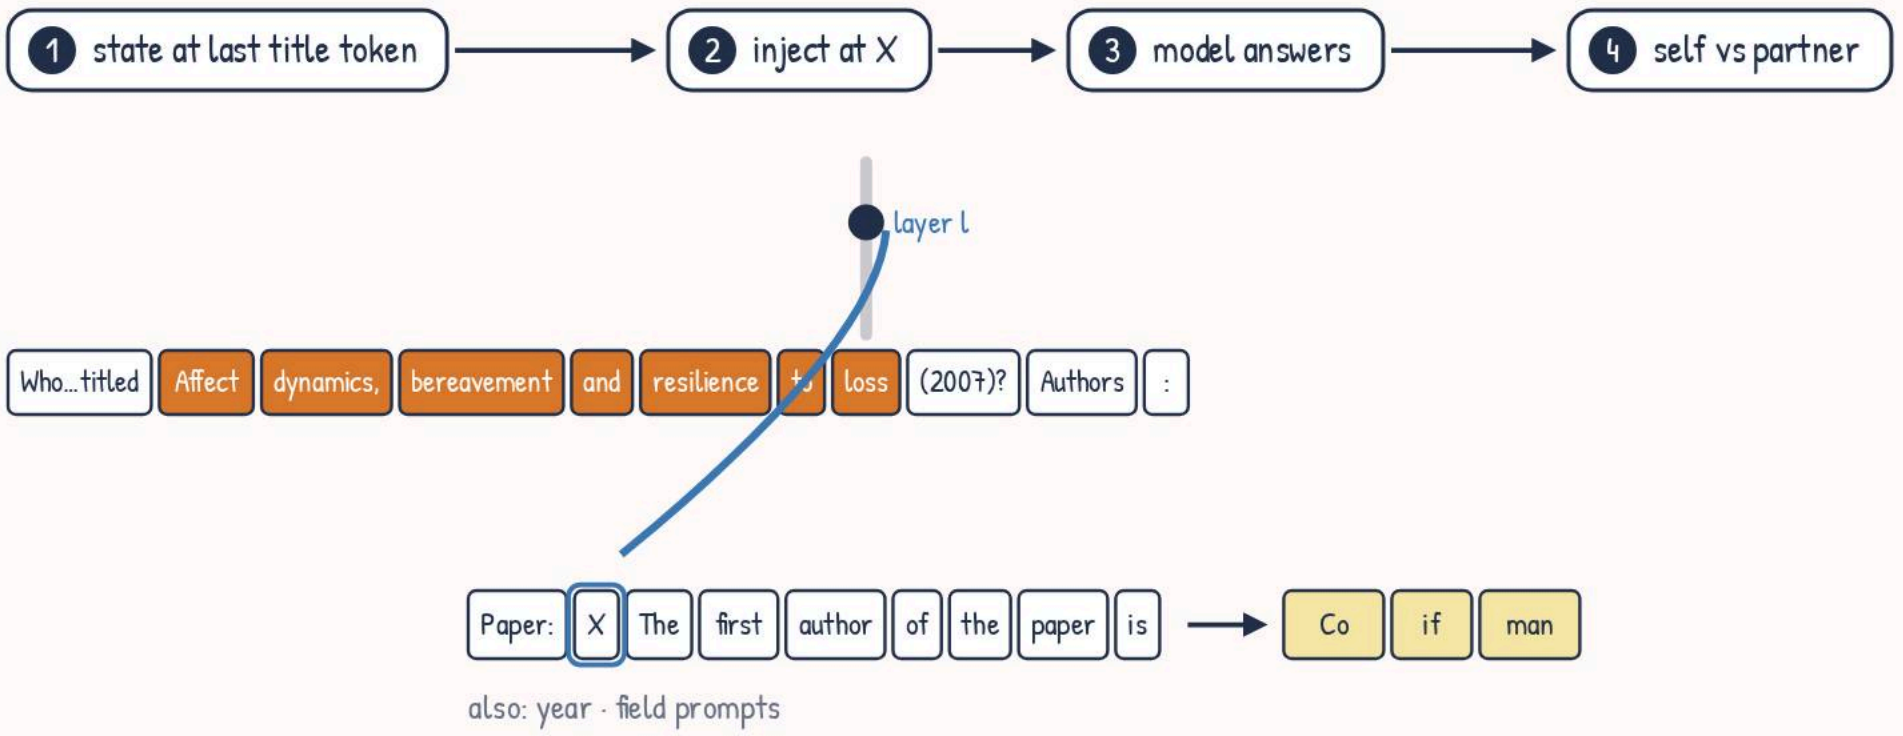
Word overlap 0.22 / 0.14: config/x3_lexical_neighbour_j2.csv (this paper) · medians: x3_report.md (primary set, 1,110) · G′: x3_textbase_recovery.md (test)
+0.239: Stage 13 X3 behaviour, test, 552 papers; x3_textbase_recovery.md

 新写讲稿

改写标题（X3）：示例论文原标题 “Affect dynamics, bereavement and resilience to loss”，改写为 “Affect fluctuations, grief and adaptability in the face of loss”，词汇邻居 D 是另一篇论文 “Affect and Resistance to Temptation.”。比较标题最后位置状态的余弦：G′ = cos(原, 改写) − cos(原, D)，L8 为 +0.32，L36 峰值 +0.46（Stage 13 X3，主分析测试集，标题最后一个 token，G′ = cos(原, 改写) − cos(原, D)：L8 +0.316 [0.293, 0.338]，峰值 L36 +0.463；报告 Stage 13 X3 节；381_stage13/reports/x3_report.md Verdict 节与 G′ 表）。词重叠 jaccard2 的中位数是改写 0.61、D 0.15（Stage 13 X3 主分析 1,110 篇，修正版 Jaccard（jaccard2）中位数：改写 0.611，近邻 D 0.154（敏感性集 1,012 篇为 0.615 / 0.150）；381_stage13/reports/x3_report.md Word overlap 表）（本例 0.22 和 0.14）（示例论文 Coifman 等（2007）：改写 jaccard2 0.222，近邻 D 0.143；381_stage13/config/x3_lexical_neighbour_j2.csv；381_stage13/summary_x3/para_nli.csv）；第一作者分数改写 − D 为 +0.239（Stage 13 X3 行为，第一作者教师强制打分 log10(1/名次)，改写标题 − 近邻 D 标题，主分析测试集 552 篇，+0.239 [0.212, 0.266]，团队聚类 95% CI；381_stage13/reports/x3_report.md Behaviour 表）。

Patchscope (X4)

Coifman, Bonanno, Rafaeli (2007)



D = score(own state) − score(partner state)

score = log10(1/rank) of the true answer tokens

first author from L8: +0.046

year from L40: +0.013

D: Stage 13 X4, test set, team CI; first author L8 +0.046 [0.035, 0.059], year L40 +0.013 [0.008, 0.018]; 381_stage13/reports/x4_report.md

 新写讲稿

Patchscope（X4）：取作者问题里标题最后一个 token 在第 l 层的状态，注入到 “Paper: X / The first author of the paper is” 里 X 的位置（同一层），看模型接下去说出的答案；另有年份和领域两个目标提示。D = 用本篇状态时的分数 − 用配对论文状态时的分数。第一作者从 L8 起可以解码（+0.046）（Stage 13 X4，标题位置，D = 本篇状态 − 配对论文状态的答案分数（log10(1/名次)），最早层在调参集选出、测试集 582 篇确认：第一作者 L8 +0.046 [0.035, 0.059]，团队聚类 95% CI；报告 Stage 13 X4 表；381_stage13/reports/x4_report.md 第 9–11 行），年份从 L40 起（+0.013）（同上，年份 L40 +0.013 [0.008, 0.018]；381_stage13/reports/x4_report.md）。

Stage 12–13: what the middle layers hold

Paper facts are readable at the title early (M2) · H2 (paper identity) partly supported but not established; H3 (hidden author knowledge): insufficient evidence

假设	M1：lens 在中间层排第一的词	M2：probe 读非名字的属性	M3：换任务对照	目前结果（2026-11-01）
H1 任务 / 格式：中间层在表示“要输出作者名单”	多为 “author”、标点、名字常见开头，与标题无关	论文属性读不出或很弱	同一标题在不同问题下，中间层表示早早分开	见上文 M3、X1 结果
H2 论文身份：中间层在表示“是哪一篇论文”	与标题有关的词（照抄标题），换假标题就变	领域、年份（从标题推出）、引用数、是否认得出都读得出，且早于名字	不同问题下同一篇论文的表示在中间层相近，后期才按任务分开 **结果：**不高于 L4 文字水平，不支持	**M3 不支持；X3 显示中间层超出用词的语义表示，但不能与论文身份区分；H2 目前依据 M2 和 X1，其中 M2 的 Qwen 胜过 BERT 按补充 2 只作参考。**另外，X4 最早可解码的顺序是第一作者（L8）早于年份（L40），与 H2 预测的方向相反。
H3 作者信息已在，只是不在词表方向	不一定	作者首 token 用 probe 读得出，lens 读不出	按作者训练的 probe 能跨任务迁移；作者专用 lens（M4）在中间层读得出名字	**文本基线不弱于 Qwen，不能排除文字解释，证据不足**（X4：名字首 token 上 BERT +0.088 ⩾ Qwen L8 +0.018；L8 信号主要在姓上，见上文 X4）

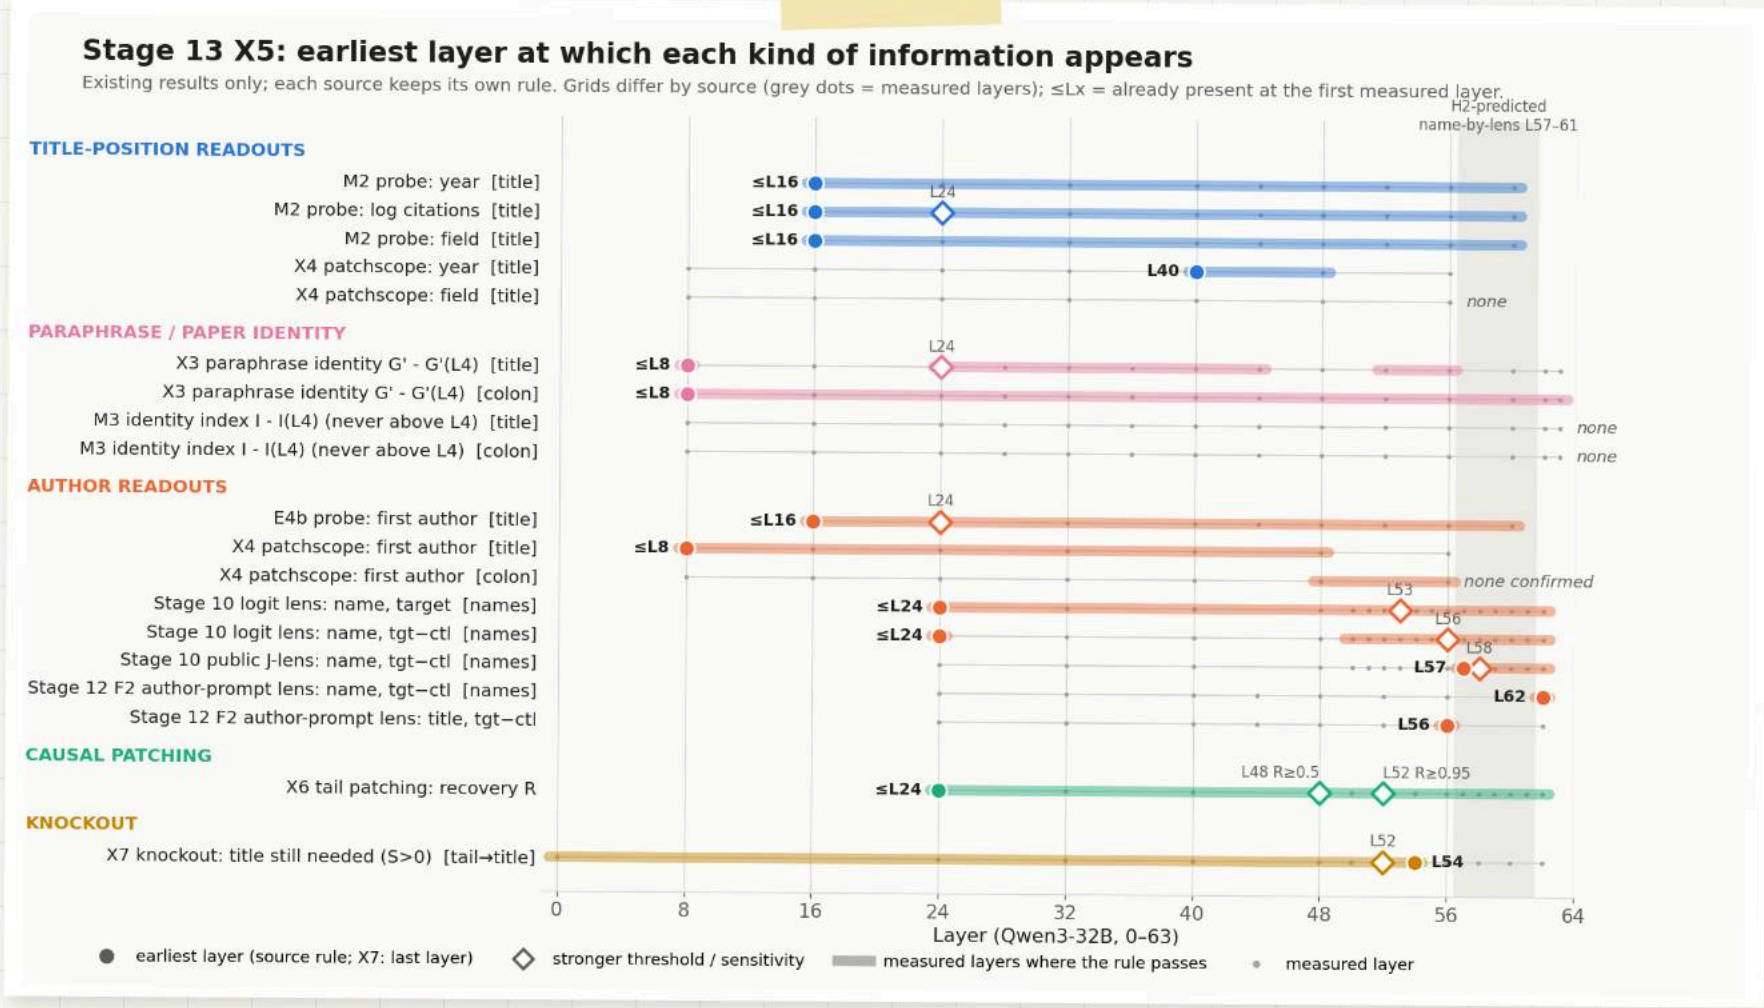
Hypotheses H1–H3 × readouts M1–M3 and current results (report, 2026-11-01)

 新写讲稿

Stage 12 和 13 想回答：中间层到底装着什么。表里有三个假设：H1 中间层只是在准备“输出作者名单”这个任务，H2 中间层表示“这是哪一篇论文”，H3 作者信息已经在、只是不在词表方向上。结果是：probe 在标题位置从 L16 或更早就能读出年份、引用数和领域（M2），但换任务对照 M3 不支持 H2，论文身份指标从不高于 L4 的文字水平；X3 显示 L28–L40 有超出用词的语义表示，但不能区分是语义还是论文身份；X4 在 L8 就能解码第一作者，但这可能来自标题文字本身。所以 H2 部分支持但未确立，H3 证据不足。

Layer order (X5)

Earliest layer at which each kind of information appears · existing results only, each source keeps its own rule



Read early, carried, spoken late

≤L8–L16: title facts and the first-author token

L48–L52: the paper signal reaches the post-title tail (patching R ≥ 0.5 at L48, ≥ 0.95 at L52; knockout costs nothing from L52)

L53–L62: names readable by lens

 新写讲稿

X5 只用已有结果，把每种信息“最早在哪一层出现”排在一张图上，没有新的 GPU 计算。标题里的事实（年份、引用数、领域）和第一作者的首个 token 很早就读得出（L8–L16 或更早）；论文信号在 L48–L52 到达标题之后的位置：替换在 L48 恢复 R ⩾ 0.5，L52 起 ⩾ 0.95（Stage 13 X5 汇总，取 X6 5 个假标题平均恢复比例 L48 0.821、L52 0.995（团队聚类），X5 规则 R ⩾ 0.5 / ⩾ 0.95；381_stage13/summary_x5/x5_layer_order.csv X6 行；381_stage13/summary_x6/x6_recovery.csv；381_stage13/reports/x5_report_v2.md），从 L52 起阻断标题不再有损失（Stage 13 X7，论文特有阻断损失 S(L52)：全部 0.029、target 0.018、control 0.051（control L54 0.018、L56 0.000）；381_stage13/reports/x7_report.md）；名字要到 L53–L62 才能用 lens 读出。注意：M3 不支持 H2，X3 不能区分语义与论文身份，X4 在 L8 的第一作者信号可能来自标题文字，所以这张图只说明先后顺序，不说明机制。

Stage 12: where the paper information travels

All 408 GPU units done · true title → false_0 · share of the true–false gap recovered at the output

- **P1 one position at a time:** the colon carries at most 0.17 (L52)(Stage 12 P1, 1,186 papers, paper bootstrap; P1_patch_pos.csv); all name positions together 0.85 at L52(same; CI [0.830, 0.864]); the whole prompt 1.00 (= Stage 11 E1)(same, 0.996)
- **P2 one component of one layer:** attention at L48 +0.23 [0.22, 0.24](Stage 12 P2, 1,186 papers; P2_patch_comp.csv), MLP at L52–L56 +0.18 to +0.22(same) → attention reads the title in, MLP processes it next
- **N1 name plausibility:** without a title the true list looks "most real" in 0.255 of papers (chance 0.25) (Stage 12 N1, 8,894 R0/R1 papers; N1_prior_mc.csv); with the true title 0.625(same, CI [0.615, 0.635])
- **N2 pure name prior (no paper):** target − control +0.047 [0.031, 0.062] vs +0.247 with the true title(Stage 12 N2, final L63, 4,621 + 2,220, within bin; stage12_report.md) → prior ≈ 19% of the gap
- **F2 lens fitted on author prompts:** target − control ≤ 0 at L24–L56, +0.238 only at L62(Stage 12 F2, name positions, Stage 11 sample, true − 5 false; F2_author_lens.csv)

No single "notebook" token

The paper leaves the title at L44–L48 and is spread over the name positions; a lens fitted on author prompts still reads nothing paper-specific in the middle layers.

 新写讲稿

Stage 12（408 个 GPU 单元全部完成）。P1 一次只替换一个位置：“:” 最多恢复 0.17（Stage 12 P1，真标题→false_0，只替换 “:”，L52，最终输出恢复比例，Stage 11 样本 1,186 篇，论文 bootstrap 95% CI [0.156, 0.187]；报告第四部分 Stage 12 P1 表；371_stage12/summary/P1_patch_pos.csv），全部名字位置一起 0.85（同上，全部名字位置，L52 0.847 [0.830, 0.864]），整个提示 1.00（同上，= Stage 11 E1，L52 0.996）。P2 只替换一层的一个组件：L48 注意力 +0.23（Stage 12 P2，标题之后全部 token，1,186 篇，L48 注意力 0.231 [0.221, 0.244]；371_stage12/summary/P2_patch_comp.csv），L52–L56 的 MLP +0.18 到 +0.22（同上，MLP L52 0.178 [0.168, 0.190]、L56 0.224 [0.208, 0.239]）：先是注意力把标题读进来，然后 MLP 接着处理。N1：不给标题时，真作者列表在 4 个选项里“最像真的”的比例 0.255（Stage 12 N1，删去标题，R0/R1 论文 8,894 篇，CI [0.246, 0.264]；371_stage12/summary/N1_prior_mc.csv），与随机的 0.25 一样；给真标题后 0.625（同上，真标题，CI [0.615, 0.635]）。N2：纯名字提示下 target − control 只有 +0.047（Stage 12 N2，纯名字提示，最终输出 L63，目标 4,621 / 对照 2,220，引用档内差，论文 bootstrap 95% CI [0.031, 0.062]；371_stage12/reports/stage12_report.md），真标题下 +0.247（同上，真标题，[0.229, 0.266]），先验约占 19%（0.047 ÷ 0.247，由上两数算出）。F2：用作者提示拟合的 lens 在名字位置 L24–L56 的 target − control 都 ⩽ 0，只有 L62 为 +0.238（Stage 12 F2，名字位置，真 − 5 个假标题平均，Stage 11 样本，[0.210, 0.267]；371_stage12/summary/F2_author_lens.csv）。

The Stage 11 timing holds for all 5 false titles

X6: replacement with each of the 5 false titles · X7: knockout minus the same knockout on the false-title run (S = T − F)

- **X6 replacement:** mean over 5 false titles 0.821 at L48 and 0.995 at L52(Stage 13 X6, 1,186 papers, team-cluster CI; x6_recovery.csv); each false title within 0.02 of false_0(x6_report.md) → "≈80% at L48, all from L52" is not specific to false_0
- **By name-token role:** surname first token 0.734 at L48, surname continuation 0.893; all roles ≥ 0.96 at L52(X6 roles, all papers; x6x7_roles.md)
- **X7 knockout:** blocking the title on the false-title run RAISES the true author score (F < 0), so the paper-specific loss S(L0) ≈ 1.00(Stage 13 X7, 1,186 papers, all: 1.004; x7_report.md); S(L52) = 0.029 [0.021, 0.038](same, all papers)
- **Pre-registered verdict:** holds for target (S(L52) 0.018) and all papers; control just misses (0.051, threshold 0.05)(X7, target 593 / control 593; x7_report.md) → control needs the title until L54–L56

What changes

Nothing in the timing: the title is used up to about L52 (control L54–56) and the paper information sits in the post-title positions by then.

 新写讲稿

X6：把 Stage 11 的替换换成 5 个假标题各做一遍，平均恢复 L48 为 0.821、L52 为 0.995（Stage 13 X6，真标题→5 个假标题平均，标题后全部位置，最终输出恢复比例（均值比），1,186 篇，团队聚类 95% CI L48 [0.806, 0.835]、L52 [0.990, 1.001]；报告第四部分 X6 表；381_stage13/summary_x6/x6_recovery.csv）；每个假标题与 false_0 相差不超过 0.02（381_stage13/reports/x6_report.md；对照组最大 0.019）。按名字 token 角色：姓的第一个 token L48 为 0.734，姓的后续 token 0.893（X6 角色拆分，全部论文，团队 CI [0.711, 0.757] / [0.880, 0.906]；381_stage13/reports/x6x7_roles.md），L52 各角色都 ⩾ 0.96（同上）。X7：在假标题运行上做同样的阻断，真作者的分数反而上升（F 为负），所以论文特有的损失 S(L0) ≈ 1.00（Stage 13 X7，S = T − F，1,186 篇，全部 1.004；381_stage13/reports/x7_report.md），S(L52) = 0.029（同上，全部论文，团队 CI [0.021, 0.038]）。预注册判定 S(L52) ⩽ 0.05：target 成立（0.018（X7，target 593 篇，[0.010, 0.027]）），control 差一点不成立（0.051（X7，control 593 篇，[0.033, 0.068]）），control 要到 L54–L56 才完全不需要标题。

Same title, different question

M3: probes across three questions (authors / year / field) · X1: patch A's title state from another question into B's author prompt

- **M3 transfer at the title:** T ≥ 0.92 at L16–L40, but never above the L4 text level(Stage 13 M3, 9,108 papers, team folds; m3_report.md) (year T − T(L4) −0.03 to −0.06)(same, CIs exclude 0) → M3 does not support H2
- **M3 at the colon:** T < 0.5 → the state is already organised by the question (H1)(same; summary_m3/m3_transfer.csv)
- **X1 replacement:** R ≈ 0.99 (L24), 0.92 (L40), 0.42 (L48) whichever question the state came from(Stage 13 X1, test 582 pairs, team CI; x1_report.md); authors − year within ±0.02, except a small +0.019 at L48(same, [0.012, 0.026])
- **Retrieval (added 2026-11-05):** no layer retrieves the paper across questions better than L4(X5 retrieval, 9,108 papers; x5_retrieval.md; post-defence)

Reading

The title state hardly depends on the question, and the replacement effect is task-independent; but nothing goes beyond what the title text alone gives at L4.

 新写讲稿

M3：同一篇论文换三种问法，标题最后一个 token 上的迁移比 T 在 L16–L40 都 ⩾ 0.92（Stage 13 M3，9,108 篇，按作者团队分 5 折的 probe，迁移比 = 跨问法成绩 ÷ 同问法成绩；报告第四部分 M3 表；381_stage13/reports/m3_report.md），但按补充 2 只看相对 L4 的变化：年份 T − T(L4) 为 −0.03 到 −0.06（同上，团队聚类 95% CI 都不含 0；summary_m3/m3_transfer.csv），不高于文字水平，所以 M3 不支持 H2。“:” 位置 T < 0.5（同上），状态已按问题重新组织。X1：把 A 在别的问法下的标题状态替换进 B 的作者提示，恢复 R 在 L24 约 0.99、L40 0.92、L48 0.42（Stage 13 X1，测试集 582 对，作者问法来源，团队聚类 95% CI；381_stage13/reports/x1_report.md），三种来源几乎相同；作者 − 年份在 ±0.02 以内，只有 L48 有 +0.019（同上，[0.012, 0.026]）。答辩后补算的跨任务检索（X5 预注册曲线）也没有一层高于 L4（X5 检索，9,108 篇，top-1；381_stage13/reports/x5_retrieval.md；事后补算）。

Patchscope and paraphrases

X4: decode year / first author / field from the paper's own title state · X3: paraphrased title vs a word-matched other paper

- **X4 first author:** decodable from L8, D = +0.046 [0.035, 0.059](Stage 13 X4, test split, team CI; x4_report.md); year only from L40, +0.013 [0.008, 0.018](same); field never → order opposite to the H2 prediction
- **But:** the L8 signal sits on the surname (+0.066), where the text-baseline check failed(X4 role split, 1,178 papers; x4_rolesplit.csv) → may be explained by the title text
- **X3 paraphrase:** closer to the original than a word-matched paper beyond L4, peak L36 +0.16(Stage 13 X3, test 552 papers, G′ − G′(L4), team CI [0.146, 0.171]; x3_report.md); behaviour keeps ≈ 90% of the first-author preference(same, 0.90 [0.87, 0.94])
- **Post-hoc checks:** a sentence-embedding model without author knowledge shows a comparable advantage, and target = control(X3 text baselines and group split; x3_textbase_recovery.md, x3_groupsplit.md) → meaning, not separable from paper identity

H2 / H3 so far

H2 partly supported but not established (rests on M2 and X1); H3: insufficient evidence (text baseline not weaker than Qwen).

 新写讲稿

X4：把论文自己的标题状态注入“X 的第一作者 / 年份 / 领域是”提示。第一作者从 L8 起可解码，D = +0.046（Stage 13 X4，测试集，团队聚类 95% CI [0.035, 0.059]；报告第四部分 X4 表；381_stage13/reports/x4_report.md）；年份要到 L40，+0.013（同上，[0.008, 0.018]）；领域读不出——顺序与 H2 的预测相反。L8 的作者信号主要在姓的第一个 token 上（+0.066（X4 按 token 角色，1,178 篇，[0.045, 0.088]；381_stage13/summary_x1x4/x4_rolesplit.csv）），而姓氏上文本基线的阳性对照没有通过，所以可能来自标题文字。X3：改写标题在 L28–L40 比用词相近的近邻 D 更接近原标题，超出 L4 文字水平，最高 L36 +0.16（Stage 13 X3，主分析测试集 552 篇，G′ − G′(L4)，团队 CI [0.146, 0.171]；381_stage13/reports/x3_report.md）；行为上保留约 90% 的第一作者偏好（同上，教师强制打分，0.90 [0.87, 0.94]）。事后加的检验：不认识作者的句子向量模型在用词匹配子集上也有相当优势，target 与 control 没有差别（381_stage13/reports/x3_textbase_recovery.md、x3_groupsplit.md），所以只能说中间层表示了标题的意思，不能与论文身份区分。

What we learned: read early, spoken late

Read early	Causally the title is read in L24–L50 and gathered at the name positions by L52, then no longer needed. A probe at the title token reads a little of it from L24 (re-checked).
Spoken late	At the name positions, paper-specific author knowledge becomes lens-readable only from ~L50, fastest over L57–L61.
No lens lead	Read with a lens at the names, target is not ahead of control in middle layers; the +0.21 gap is at the end (Stage 10, final L63, §6.4) (probe at the title: target − control +0.04–0.08, re-checked (Stage 13 E4b, first name token only)).
Real knowledge	Name prior is ~1/3 of the gap overall but ~0 on surnames (Stage 12 A, 0.087 / 0.247, §6.12); the rest is paper-specific and grows with citations.
Lenses agree	Jacobian lenses read more in middle layers, but nothing target-specific.
Name format	Initials carry little; full given names carry as much as surnames and help predict them.

总结。一句话：读得早，说得晚。标题在 L24 到 L50 被读进来，证据是替换、阻断和标题 token 上的 probe；但作者名字要到 L57 到 L61 才在名字位置变得可读。lens 的结果（目标组在中间层没有领先）和 probe 的结果（标题 token 上目标组有优势）说的是不同的位置，两者不矛盾。（probe 的数字已按作者团队分折、剔除标题复用后复核：+0.05 到 +0.08（Stage 13 E4b 复核，标题最后一个 token 上的线性 probe，probe 只打分每位作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，全部 1,863 篇：L24 +0.050、L40 +0.061、L56 +0.075（L24–L60 为 +0.047 到 +0.080），论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第一张表），目标组高 +0.03 到 +0.08（同上 E4b 复核，probe 只打分第一个名字 token，引用档内 目标−对照，目标 896、对照 499 篇，L24–L60 为 +0.035（L44）到 +0.078，论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第二张表）。）注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母/名/姓分开的版本按补充 9 进行中，尚无结果。

Limits

Done: Stage 12

- Single-position patching (P1); attention vs MLP (P2, hook check passed)
- Name priors (N1, N2); author-prompt lens (F1, F2): middle layers still not readable

Done: Stage 13

- Probes read year, citations, field at the title from ≤L16 (M2); identity not above the L4 text level (M3)
- Replacement is task-independent (X1); paraphrase meaning beyond wording in L28-L40, not separable from paper identity (X3)
- First author decodable at L8, may be text-explainable (X4); 5 false titles confirm the Stage 11 timing (X6, X7)

Limits

- One model (Qwen3-32B)
- Teacher-forced preference, not generation
- Labels from the team lead's package; labelling code (elm) not available
- H2 (paper identity) partly supported but not established; H3 (hidden author knowledge): insufficient evidence

 按 deck 讲稿备注翻译（已按复核结果更新）

局限。Stage 12 和 13 都已完成。Stage 12 做了逐位置替换（P1）、注意力与 MLP 的替换（P2，显式的 hook 检查已通过）、两个名字先验基线（N1、N2）和在作者提示词上拟合的 lens（F1、F2），中间层仍然读不出名字。Stage 13：probe 从 L16 或更早在标题处读出年份、引用数和领域（M2），但 M3 不超过 L4 的文字水平；替换效应与任务无关（X1）；改写标题在 L28–L40 有超出用词的语义，但与论文身份分不开（X3）；第一作者在 L8 可解码，但可能来自标题文字（X4）；X6/X7 用 5 个假标题（Stage 13 X6 用 false_0–false_4 五个假标题重做 Stage 11 替换（L48 平均 0.821、L52 0.995），X7 在 false_0 运行上重做阻断；381_stage13/reports/x6_report.md、x7_report.md）确认了 Stage 11 的时间。局限：只有一个模型；测的是教师强制下的偏好，不是生成；标签来自组长的数据包，elm 标注代码拿不到；H2 部分支持但未确立，H3 证据不足。

Added after the defence

Added after the defence (2026-11-05)

Group comparisons (plan fixed before the results: addenda 7, 8) · CPU leftovers (post-hoc) · experiments still running

1. Group comparisons A / B / C / D: plan and status (results after the re-runs are approved)
2. CPU leftovers on existing data: X5 retrieval curve, M3 scores, N2 by layer, paper vs team intervals, M5
3. In progress (status only): X2 subspace patching, all-token probe, group re-runs

 新写讲稿

这一部分是答辩（2026-11-02 定稿）之后新增的内容。分组对比的分析计划在看结果前写定（补充 7、8）；CPU 补充分析是事后分析，只作描述；正在进行的实验只说状态，没有结果。

Added after the defence · groups

Group comparisons: plan and status

Plan fixed before any result (addenda 7, 8) · results go to the user and advisor first; not shown until approved

- **Groups:** open answer R0 / R1 / R2 × multiple-choice recognition strong / uncertain / fail; A = R0 × strong 4,110, B = R0 × fail 2,186, C = R1 × strong 511, D = R1 × fail 34 (cohort papers.parquet; addendum 7)
- **No circularity:** every comparison uses only the authors the model did NOT write; written authors are a reference column
- **Primary tests:** P1 recognition A − B; P2 partial recall C − A (first author / co-authors); P3 slope on orders right (0–4) in R0; within citation bin, team bootstrap, Holm over 4; confounder regressions beside each
- **Status:** CPU part computed and sent for review. Still running: intervention re-runs for R2 × strong (204 papers) and R0 × uncertain (600), and the E1 numerator / denominator by group (addendum 8; rerun_R2.parquet, rerun_U0_600.parquet)

Why no numbers here

User decision 2026-11-05: group results appear in the deck and report only after the re-runs and the E1 numerator / denominator are in and approved.

 新写讲稿

分组对比（答辩后新增）：分析计划在看结果前写定（补充 7、8）。分组按开放回答（R0 / R1 / R2）× 多选识别（strong / uncertain / fail）交叉：A = R0 × strong 4,110 篇，B = R0 × fail 2,186，C = R1 × strong 511，D = R1 × fail 34（351_stage10/cohort/papers.parquet，recall_level × mc_team_outcome_tight；补充 7 “groups”）。为避免循环论证，所有比较只用模型没写出的作者。三个主要检验：P1 识别的效应 A − B，P2 写对一部分作者的额外帮助 C − A（第一作者 / 合作者分开），P3 R0 论文的信号对多选题答对顺序数的斜率；引用档内比较、按作者团队重抽、Holm 校正 4 个检验，并各做控制混杂的回归。状态：CPU 部分已算完，结果先交用户和导师审阅；R2 × strong（204 篇）和 R0 × uncertain（600 篇）的干预重跑以及 E1 分子/分母按组拆开还在进行。按用户 2026-11-05 的决定，确认之前不在讲稿和报告里给结果数字。

Added after the defence · CPU

CPU leftovers on existing data (post-hoc)

No new GPU runs · descriptive only · not in the pre-registration except the X5 retrieval curve

- **X5 retrieval curve (pre-registered, computed now):** top-1 retrieval of the same paper across questions is never above L4(M3 cache, 9,108 papers; x5_retrieval.md) (title token 1.000 up to L44, 0.734 at the output)(same, team CI)
- **M3 behaviour scores:** year target − control +0.007 [0.003, 0.012]; first-author first token +0.147 [0.096, 0.191](output, 4,621 / 2,220, within bin, team CI; m3_scores.md)
- **N2 by layer:** pure name prior target − control +0.047 at the output, +0.039 at logit L62; public J-lens L48 −0.133 (true title)(Stage 12 N2 rescored by layer; n2_layers.md) → only L62 reproduces the output pattern
- **Paper vs team intervals:** width ratio 0.97–1.00 (median); "excludes 0" changes in 2 of 1,155 rows(X1, X4, X6, X7, M3; v42_paper_vs_team.md)
- **M5 true vs false title at the name positions:** output 0.919; logit L24 0.516 → L62 0.899(share of pairs, all papers × 5 false titles, team CI; m5_report.md); probe at title / colon AUROC 0.50–0.52(same, Part B)

74

第 74 / 75 页 · Added after the defence · CPU · 合并 PPT 自身页面 新写讲稿

答辩后补算的 CPU 分析，都用已有数据，属于事后分析，只作描述。X5 预注册的跨任务检索曲线：同一篇论文在三种问法下的标题状态能否在全部论文中检索回自己，没有一层高于 L4（X5 检索，M3 残差缓存，9,108 篇，top-1，团队聚类 95% CI；381_stage13/reports/x5_retrieval.md）；标题最后一个 token 上 L44 以前都是 1.000，最终输出 0.734（同上，[0.725, 0.742]）。M3 提示下的行为分数：年份 target − control +0.007（M3 年份分数，最终输出，目标 4,621 / 对照 2,220，引用档内差，团队 CI [0.003, 0.012]；381_stage13/reports/m3_scores.md），第一作者首 token +0.147（同上，[0.096, 0.191]），作者差与分组定义有关。N2 按层：纯名字提示 target − control 在最终输出 +0.047（Stage 12 N2，团队 CI [0.031, 0.062]；371_stage12/reports/n2_layers.md），logit lens L62 +0.039（同上）；public J-lens L48 真标题下 −0.133（同上，[−0.161, −0.107]），只有 L62 重现输出端的模式。论文与团队区间：宽度比中位数 0.97–1.00（381_stage13/reports/v42_paper_vs_team.md 第 1 节），“区间是否含 0”只在 1,155 行中的 2 行改变（同上第 2 节）。M5：名字位置上真标题运行胜过假标题运行的比例，最终输出 0.919（M5 Part A，全部论文 × 5 个假标题，团队 CI [0.915, 0.924]；381_stage13/reports/m5_report.md），logit lens L24 0.516、L62 0.899（同上）；标题和 “:” 位置用 probe 区分真/假标题运行，AUROC 0.50–0.52（同上 Part B），基本分不开。

Added after the defence · running

Still running (status only, no results)

All pre-registered before any data: addenda 6, 8 and 9 (sha256 in the report)

- **X2 subspace patching (addendum 6):** subspaces fitted; GPU shard 0 of 24 done and checked; the rest is queued behind the group re-runs
- **All-token probe (addendum 9):** the title-position probe (E4b) so far scores only the FIRST name token, mostly an initial; the new version scores every name token, split into initial / given name / surname. GPU data step (~1 A100-hour) queued after the re-runs and X2
- **Group re-runs (addendum 8):** E1 / E2 (and P1 / P2 for R2) for R2 × strong and R0 × uncertain; E1 numerator / denominator by group

正在进行，只说状态。X2 子空间替换（补充 6）：子空间已拟合，24 个 GPU 分片中第 0 个已完成并通过检查，其余排在分组重跑之后。全部名字 token 的标题位置 probe（补充 9）：现在的 E4b 只给每位作者名字的第一个 token 打分，73% 的名字以首字母开头（Stage 11 E4b 打分规则，stage11_analyze.py:163–171；方法手册 E4b 节），所以多数时候是首字母；新版本给每个名字 token 打分，按首字母 / 名 / 姓分开，主要问题是姓的第一个 token 在 L40 是否有标题特异信号；需要约 1 个 A100 小时的 GPU 数据步骤，排在分组重跑和 X2 之后。分组重跑（补充 8）：R2 × strong 和 R0 × uncertain 的 E1、E2（R2 另加 P1/P2），以及 E1 分子/分母按组拆开。