Where does Qwen3-32B hold a paper's authors?

Stages 1-9

Small samples: find a signal, try to break it

20 → 50 → 200 papers(Stage 4, Pilot50, Stage 8 cohorts)

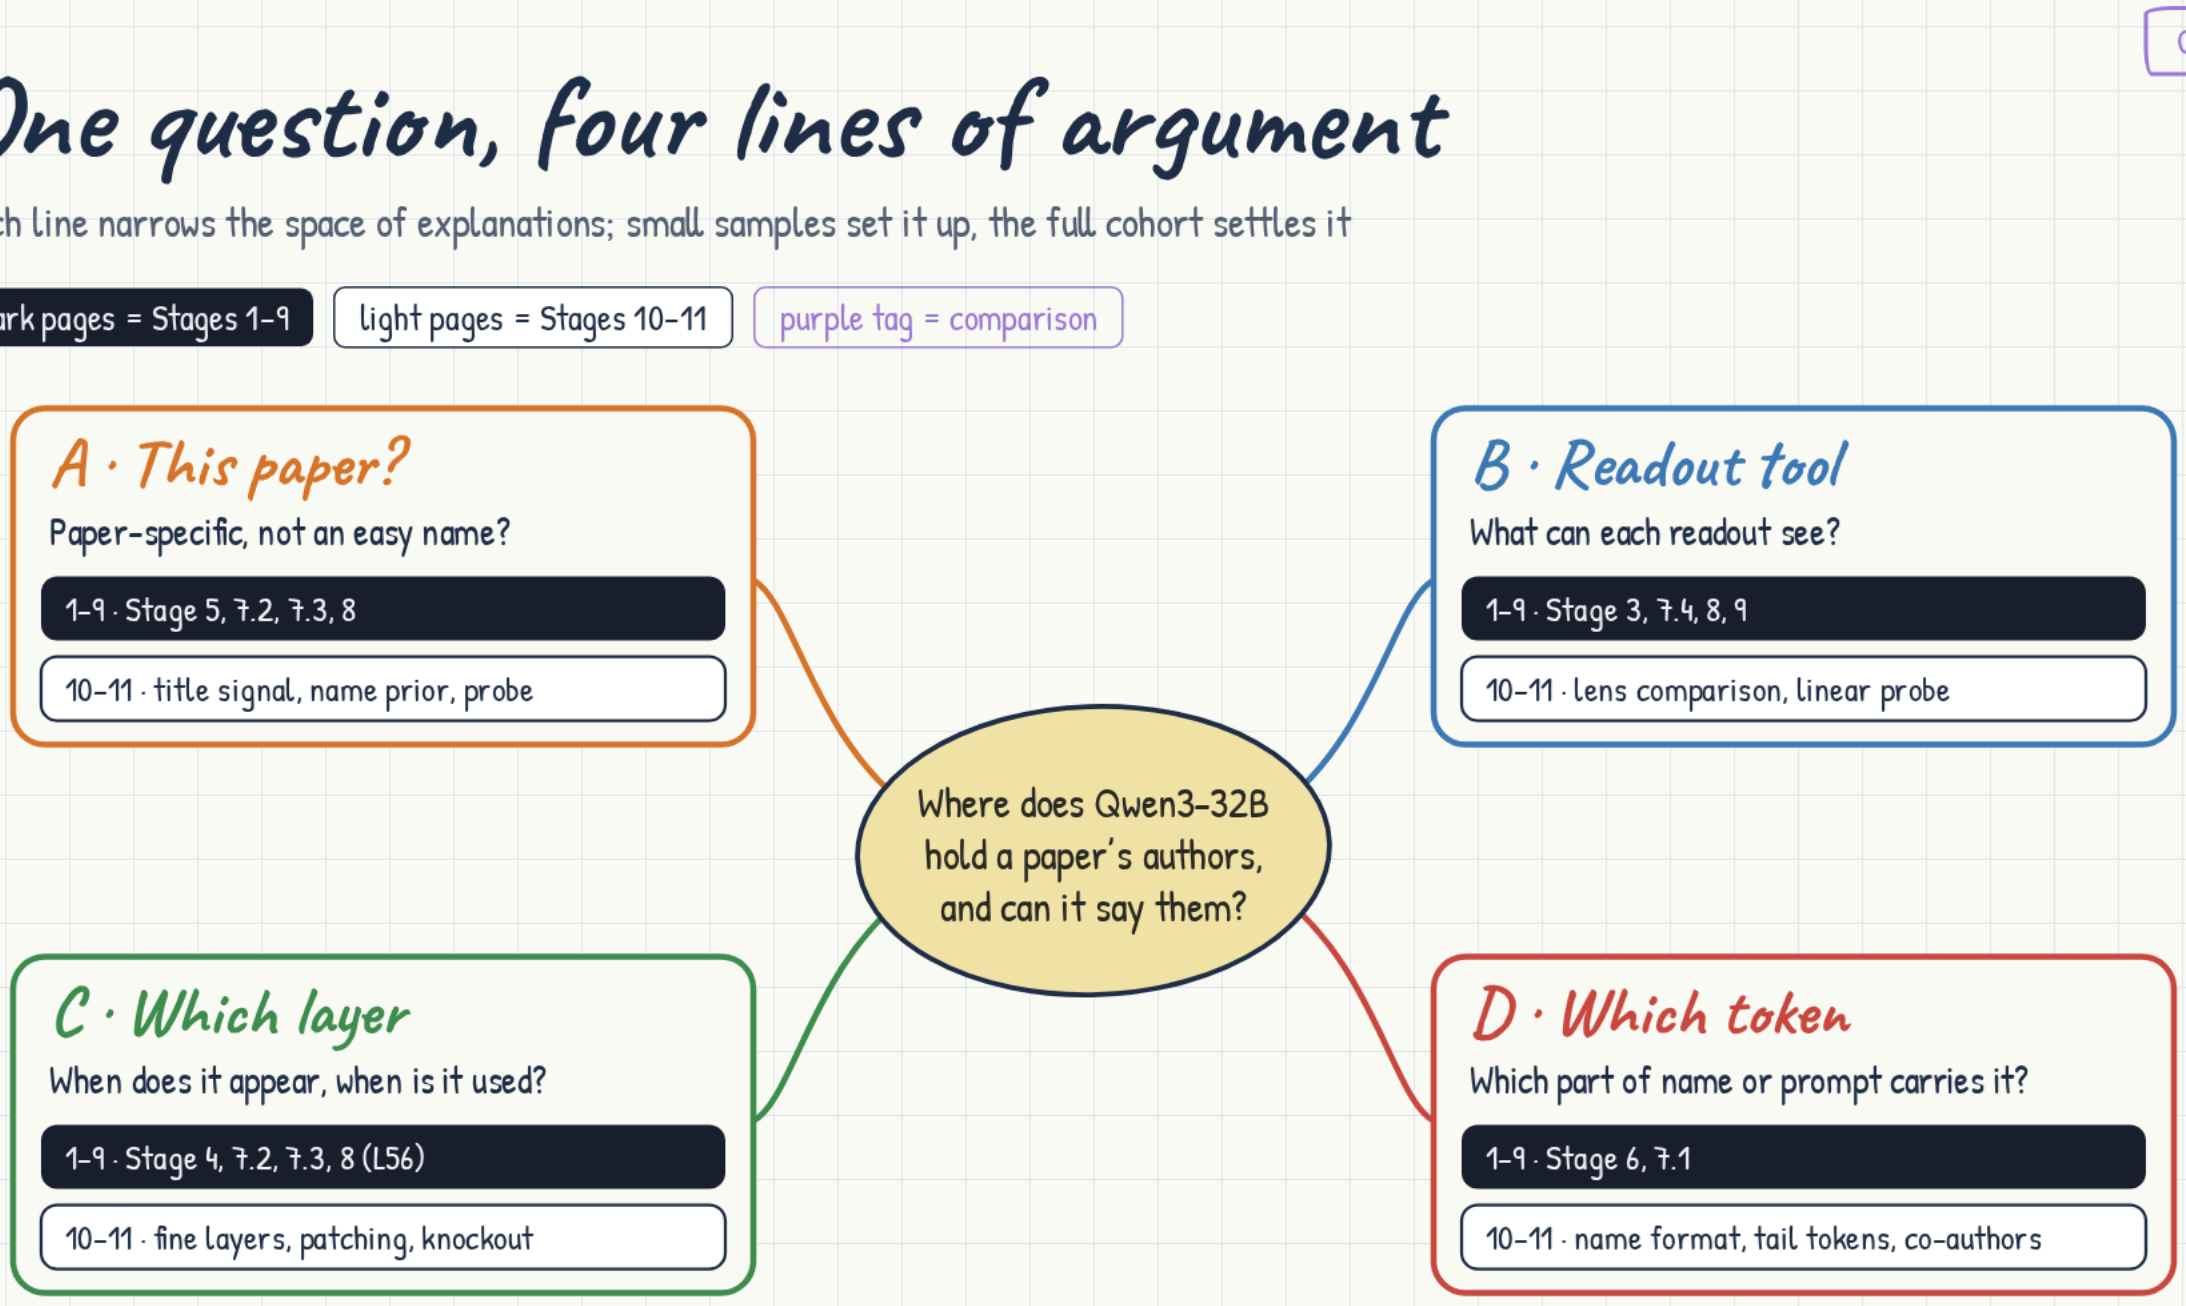
Stages 10-13 · post-defence additions (2026-11-05) at the end

Full cohort: locate it, then intervene

9,108 papers · 149,999 name tokens(Stage 10 cohort: papers.parquet, name_tokens.parquet)

 新写讲稿

今天讲的问题只有一个：Qwen3-32B 把一篇论文的作者记在网络的哪一层。整个工作分两个阶段。左边是 Stage 1–9，用 20、50、200 篇小样本（Stage 4 Benchmark20 20 篇、Pilot50 50 篇（Stage 5–7）、Stage 8 新论文 200 篇；351_all/351_stage4_readout.log、351_stage5_crossed_v2/cohort/pilot50_v1.csv、351_stage8/cohort/stage8_papers.csv）先找到信号，再想办法推翻它；右边是 Stage 10–11，用全部 9,108 篇论文（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv）、149,999 个名字 token（Stage 10 冻结队列，33,811 个作者上下文的名字 token 总数；351_stage10/cohort/name_tokens.parquet；351_stage10/config/manifest.json）去定位这个信号，并用干预实验检验。深色页是小样本阶段，浅色页是全量阶段。



第 2 / 82 页 • Overview • 合并 PPT 自身页面 新写讲稿

整份报告按四条论证线组织。A 线问信号是不是针对这篇论文，而不只是名字好猜；B 线问每种读出工具能看到什么；C 线问信号在哪一层出现、在哪一层被用到；D 线问名字或提示词的哪一部分带着信号。每条线先看小样本阶段问了什么，再看全量阶段怎么回答。

Stages 1–9 · 20–200 papers

Pilot design

- Pilot50 / Stage 8: 50 and 200 papers(pilot50_v1.csv, stage8_papers.csv)
- Mostly first-listed author, first token
- Score: gold vs 1 or 100 false names (logit margin, win rate)
- A/B both R0, matched in pairs
- Wrong titles: 1 crossed or 20 shuffled
- Layer L56 chosen after repeated looks

Overview · design

Stages 10–11 · 9,108 papers

Full-cohort design

- All 9,108 papers(papers.parquet), every author, every token
- Score: rank over the whole vocabulary, log10(1/rank)
- target = A + C, control = B + D (R0 + R1), compared within citation bins
- 5 matched false titles + no title
- All layers reported, fine layers added
- Parity and Stage 6 cross-check before analysis

What changed in the design, and why

Small samples could not separate "small effect" from "no effect" in a given layer. The full cohort trades candidate-based scores for full-vocabulary ranks and pays for it with GPU time. **Note:** target/control include R1 papers; with R0 only (A vs B, as in the pilot) the output gap is +0.199 vs +0.207(Stage 10, final L63, R0 3,423 vs 2,151; §6.13) and every layer looks the same.

先对比两个阶段的设计。小样本阶段用 50 和 200 篇论文（Pilot50 50 篇（351_stage5_crossed_v2/cohort/pilot50_v1.csv）、Stage 8 新论文 200 篇（351_stage8/cohort/stage8_papers.csv）），主要看第一作者的第一个 token，把正确名字和 1 个或 100 个错误名字（Stage 5 交叉对照每篇 1 个来源论文作者；Stage 7.2 每篇 50 个匹配 + 50 个随机错误作者；351_stage7_2/summary/quality.json；~/jlens_work/07_2_stage7_2/351_stage7_2.py:62-111）比较，A、B 两组都是 R0 并逐对匹配，错误标题用 1 个交叉标题或 20 个打乱标题（Stage 5 每篇 1 个交叉标题；Stage 7.3 / Stage 8 每篇 20 个元数据匹配的错误标题；~/jlens_work/07_3_stage7_3/351_stage7_3.py:83-91；351_stage8/config/stage8B_manifest.json），L56 是反复看过之后才选定的层。全量阶段改为全部 9,108 篇（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv）、所有作者和所有 token，用全词表名次 log10(1/名次) 打分，target = A + C、control = B + D 在引用档内比较，用 5 个匹配假标题（Stage 10 标题条件设计：每篇 5 个匹配假标题（false_0–false_4）加删去标题；351_stage10/config/conditions_manifest.json）加删去标题，所有层都报告，还加了细层。改设计的原因是小样本分不清某一层是“效应小”还是“没有效应”。

Overview · groups

Same papers, two ways of grouping

Stages 1–9 compare A vs B; Stages 10–11 compare target vs control. Counts from the 6,841-paper cohort.(Stage 1, 351_audit.json group_counts)

	recognised (target)	not recognised (control)
R0 · no true author written	A = 4,110	B = 2,186
R1 · some authors written (HR2 > 0.5)	C = 511	D = 34
Total	**target = A + C = 4,621**	**control = B + D = 2,220**

Stages 1–9
A vs B: both R0, so the contrast is purely "knows but cannot say"

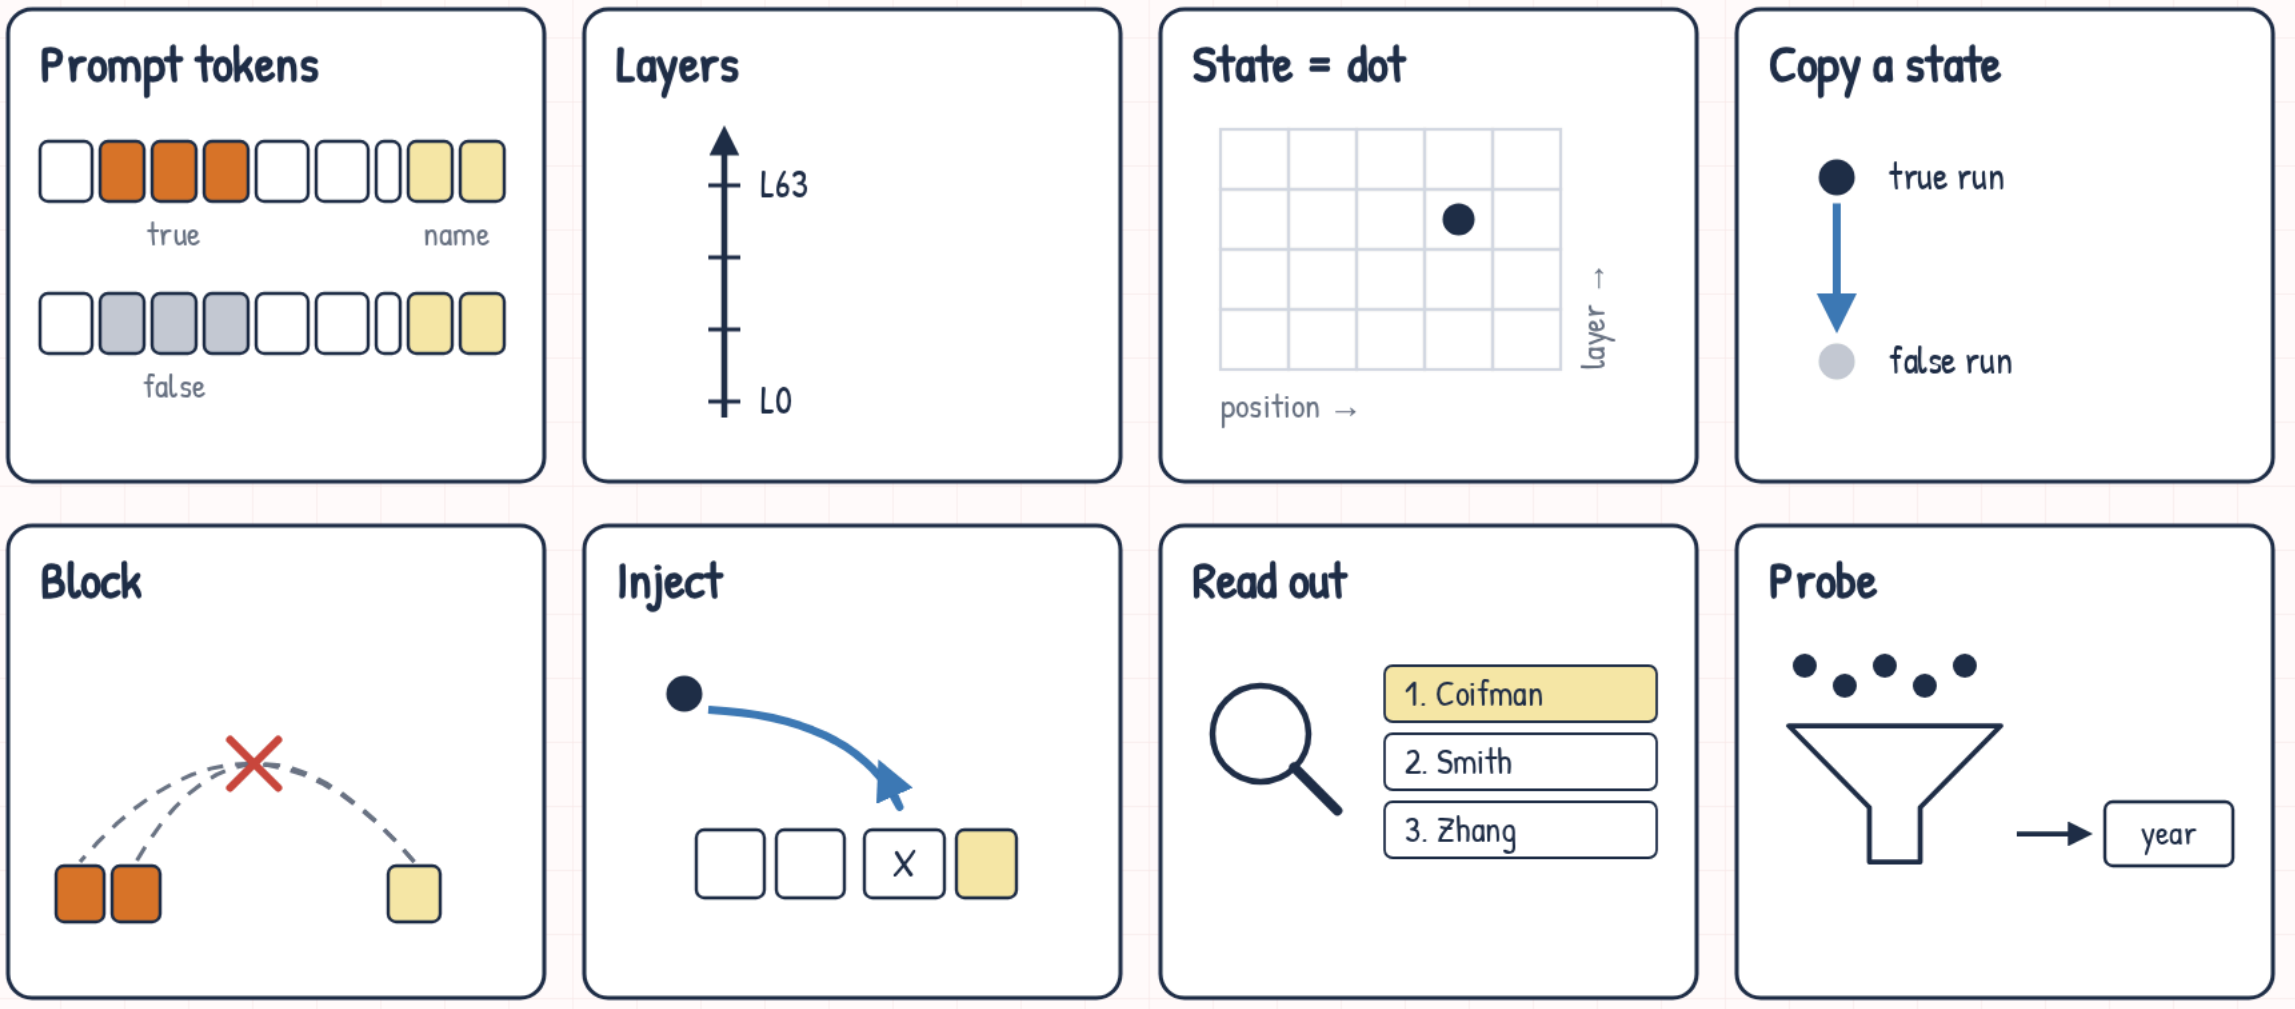
Stages 10–11
(A + C) vs (B + D): adds 511(351_audit.json) partial-recall papers, almost all on the target side

Check done: with R0 only (A vs B) the output gap is +0.199, versus +0.207 for target vs control(Stage 10, final L63, within-bin; §6.13), and every layer looks the same. The two phases compare like with like.

这一页说明两个阶段的分组其实是同一批论文。R0 是开放回答一个真作者都没写对，R1 是写对了一部分但 HR2 大于 0.5。A = 4,110、B = 2,186、C = 511、D = 34（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表）。Stage 1–9 比的是 A 对 B，两组都是 R0；Stage 10–11 比的是 A + C 对 B + D，多出来的 511 篇 R1（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表）几乎全在 target 一侧。我们已经检查过：只用 R0（A 对 B）时，输出处的差是 +0.199（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv），合并口径是 +0.207（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），各层形状相同，所以两个阶段可以直接对照。

Reading the method figures

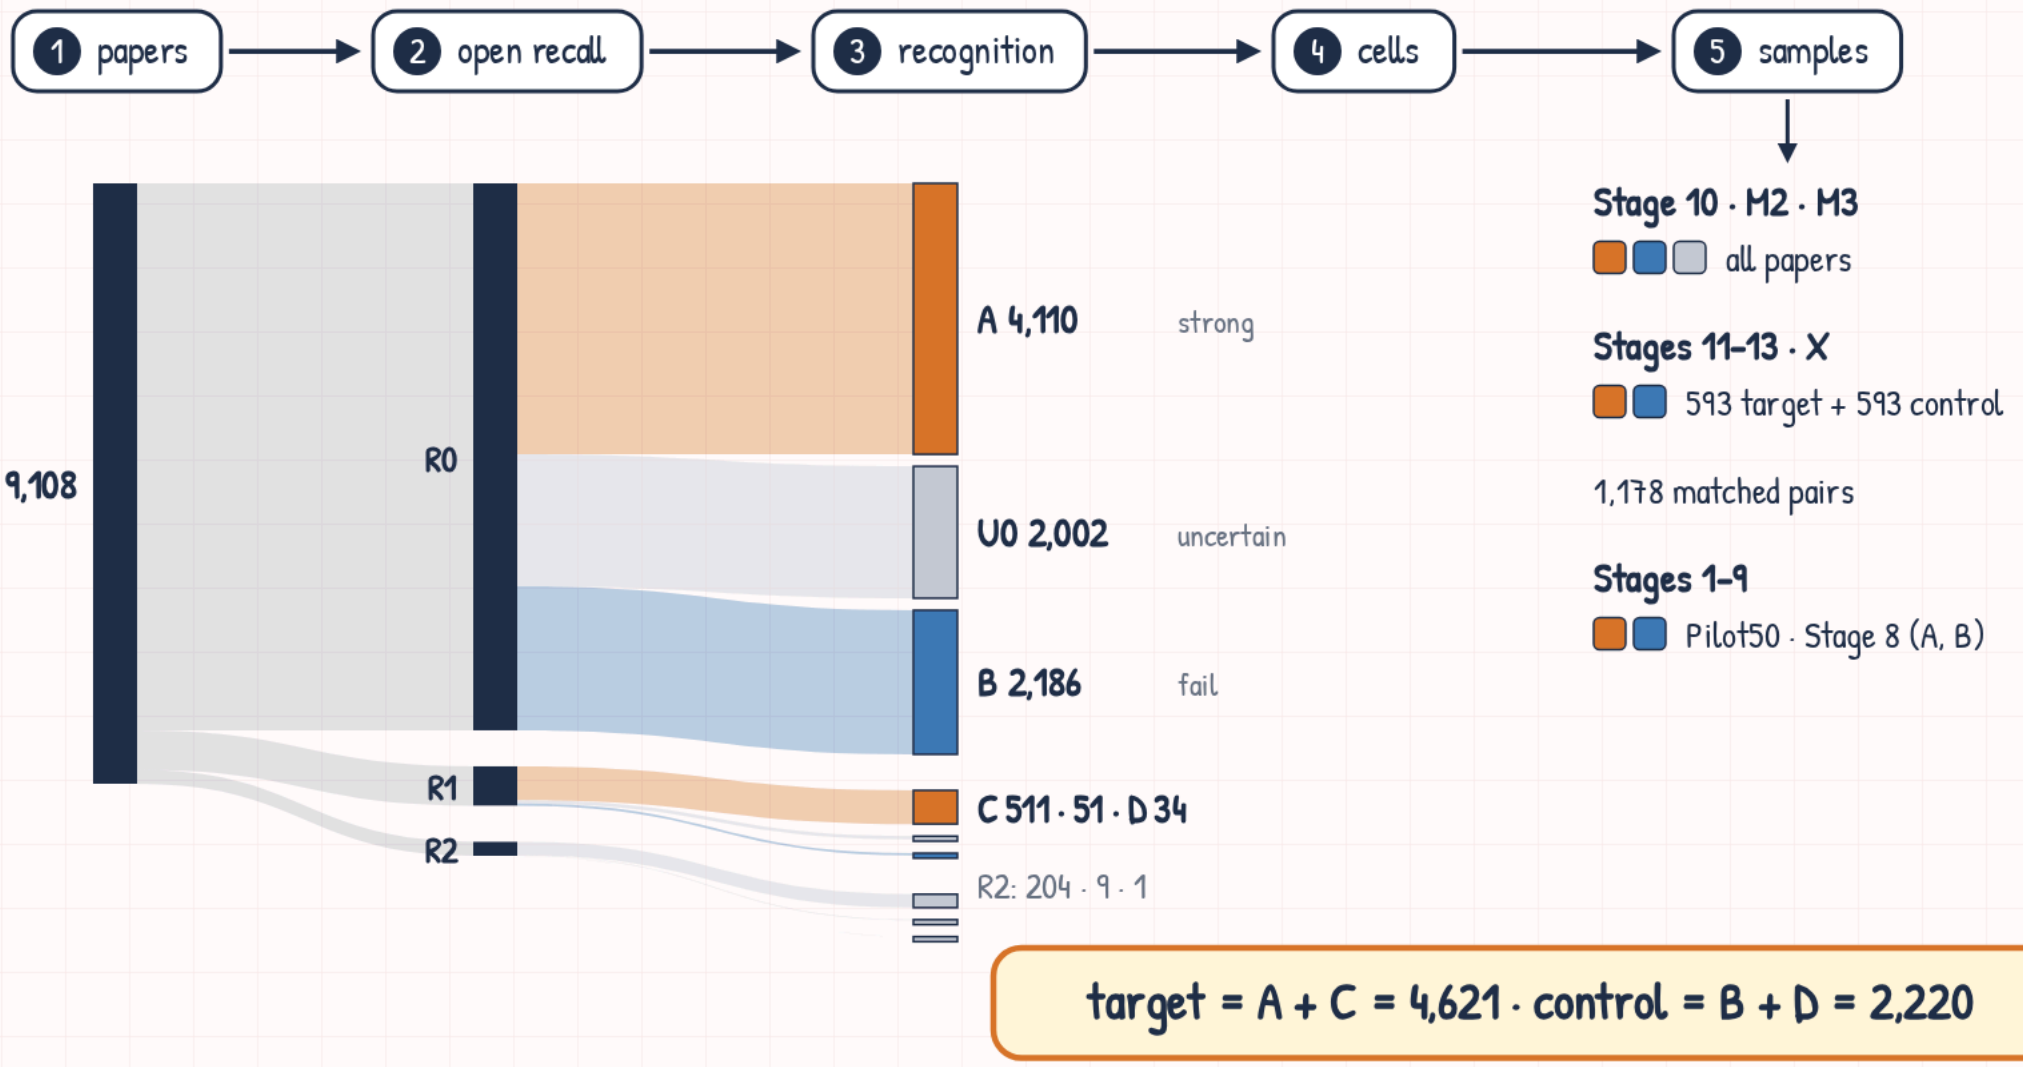
1 2 3 steps, in order



从这一页起，每个方法页都放在它所属实验的结果之前，背景是很浅的粉色网格。图例：提示词画成一排 token 方块，橙色是真标题、灰色是假标题、黄色是名字；层自下而上，L0 在底部、L63 在顶部；一个圆点代表某一层某个位置的隐藏状态。蓝色箭头表示把状态复制或注入到另一次运行，红色叉表示阻断注意力，放大镜表示读出名次，漏斗表示训练探针；带圈数字是步骤顺序。

Groups and samples

example: cell C



9,108 篇论文（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv）先按开放回答分成 R0（一个真作者都没写对）8,298 篇、R1 596 篇、R2（基本写出了作者）214 篇（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表；R0/R1/R2 = 8,298 / 596 / 214），再按四种选项顺序的多选识别分成 strong、uncertain、fail。R0 里 A = 4,110、U0 = 2,002、B = 2,186；R1 里 C = 511、51、D = 34；R2 为 204、9、1（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表；R0 4,110/2,002/2,186，R1 511/51/34，R2 204/9/1（strong/uncertain/fail））。target = A + C = 4,621，control = B + D = 2,220（351_stage10/cohort/papers.parquet 列 group_tight；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 7 行）。Stage 10 和 M2、M3 用全部 9,108 篇（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv），Stage 11–13 的干预和 X 系列用 593 + 593 = 1,186 篇（Stage 11 抽样，10 个可比引用档内配平，目标 593 + 对照 593 = 1,186 篇；361_stage11/config/sample.parquet；361_stage11/config/protocol.json（361_stage11.py:56, 109–115））（X 系列配对后 1,178 对（Stage 13 X 系列配对，1,186 篇中有合格配对论文的 1,178 篇；381_stage13/config/pairs.parquet）），Stage 1–9 的 Pilot50 和 Stage 8 取自 A 和 B；示例论文 Coifman 等（2007）属于 C 格。

Stage 1

Cohort and behavioural labels

From the 15 Oct label package (9,108 papers) to a frozen 6,841-paper analysis cohort(351_audit.json total, four_group_total)

Group	Recognition / open recall	Full(351_audit.json)	Pilot50(pilot50_v1.csv)
A	pass / R0 (no true author written)	4,110	20
B	fail / R0	2,186	20
C	pass / R1 (some authors matched)	511	7
D	fail / R1	34	3

- Pass = 4/4 option orders correct *and* mean true-option probability ≥ 0.5; fail = 0–1/4
- Pilot50: seed 35150, keeps the 20 Stage 4 papers + 30 new
- 20 A/B pairs matched on exact field and citation bin, then |Δyear| + 2·|Δauthors|

Why A vs B?

Both groups write **no** correct author. They differ only in whether the model recognises the true list. That isolates "knows but cannot say".

Caveat

In the 0–2-citation bin the strict pass rate is **25.5%**(796 papers; label_README.md l.8), above the planned ≤10% floor: "pass" is not proof of stored knowledge.

 新写讲稿

Stage 1 建立队列和行为标签。从 10 月 15 日的标注包 9,108 篇论文（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv；351_all/351_audit.json "total"）出发，冻结了 6,841 篇（Stage 1 分析队列 = A + B + C + D 四组；351_all/351_audit.json "four_group_total"；00_cohort/351_prepare_all.py）的分析队列。“认得出”的定义是：4 种选项顺序全对，并且真选项的平均概率至少 0.5（标注规则 group_tight（tightened: min_orders 4, min_p_true 0.5）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/rules.yaml、label_README.md）；“认不出”是 4 次里最多对 1 次（同上 rules.yaml，control = 4 种顺序中至多 1 次答对）。之所以比较 A 和 B，是因为两组都一个作者都没写对，只在能否认出名单上不同，这正好对应“知道但说不出”。需要提醒的是，在 0–2 次引用的档里，严格通过率有 25.5%（标注包自检，0-2 引用档 796 篇，收紧规则（4/4 且真选项平均概率 ⩾ 0.5）多选通过率 25.5%（普通规则 38.6%）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 8 行），高于原计划的 10% 上限（Stage 1 预设的标签质量门槛（0-2 档通过率 ⩽ 10%）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 8 行；报告 Stage 1 节），所以“通过”不等于模型真的记住了。

Stage 2

One fixed model, prompt and score

Everything later is measured under these settings

Model	Qwen/Qwen3-32B, BF16, revision 9216db57, 64 blocks, d = 5,120
Layers	L16, 24, 32, 40, 48, 56, 62 → target L63
Readouts	Public J-Lens · Vanilla (logit lens) · real final logits
Position	last input position; context limit 512
Names	encode(prompt) + encode(" " + author)
Hardware	29 blocks on GPU, 35 offloaded to CPU

> Who are the authors of the paper titled "{title}" ({year})?
> Authors:

Rank r = 1 + #tokens with a strictly larger logit

JMRR = mean over authors of mean over tokens of 1/r

Integrated = average of the 7 source layers (L63 excluded)

Guard: forced token IDs are checked, and a J-Lens/Vanilla final-logit gap > 0.1 rejects the run.

 新写讲稿

Stage 2 固定了模型、提示词和打分方式，之后所有测量都在这些设置下进行。模型是 Qwen3-32B，BF16，revision 9216db57，64 层，隐藏维度 5,120（Qwen3-32B 配置；351_stage6/config/protocol.json、351_stage6/config/runtime.json；hidden_size 5120 见 HF config.json）。读出层是 L16 到 L62 共 7 层（Stage 2 读出层 L16、24、32、40、48、56、62；351_stage6/config/protocol.json；~/jlens_work/05_stage5/351_stage5.py），读出方式有公开的 J-Lens、logit lens 和模型真实输出。名次 r 定义为 1 加上 logit 严格更大的 token 数。每次运行都会核对强制输入的 token，两条读出路径的最终 logit 差超过 0.1（守卫阈值；~/jlens_work/05_stage5/351_stage5.py:205-206；~/jlens_work/04_stage4/351_stage4_readout.py:86-89）就拒绝这次运行。

Stage 10

How groups and contrasts are built

labels: group lead's pipeline on the same Qwen3-32B · we use them unchanged

open answer -> R0 / R1 / R2

greedy, chat template

fuzzy name match: M, H, U

HR2 = (H+U) / (M+H+U)

R2: HR2 <= 0.5 · R0: M = 0 · R1: M > 0

a fixed rule, no human or model judge

multiple choice -> target / control

true list + 3 real teams of other papers

(same field, team size, citation bin, ~year)

4 orders · p(letter) from next token

target: 4/4 and mean p(true) >= 0.5

control: <= 1/4

5 false titles per paper

same field, own year kept

min-cost on |dyear|/5 + |dauthors|

+ |dtitle tokens| + 1.5 |dcitation bin|

no shared surname, Jaccard <= 0.6

79% strict tier (Stage 10, 35,898 of 45,540 pairs, conditions_manifest.json)

statistics

target vs control only within citation bin

10 bins with >= 30 per group (Stage 10, §6.2)

weight n_t n_c / (n_t + n_c)

95% bootstrap over papers, 2,000

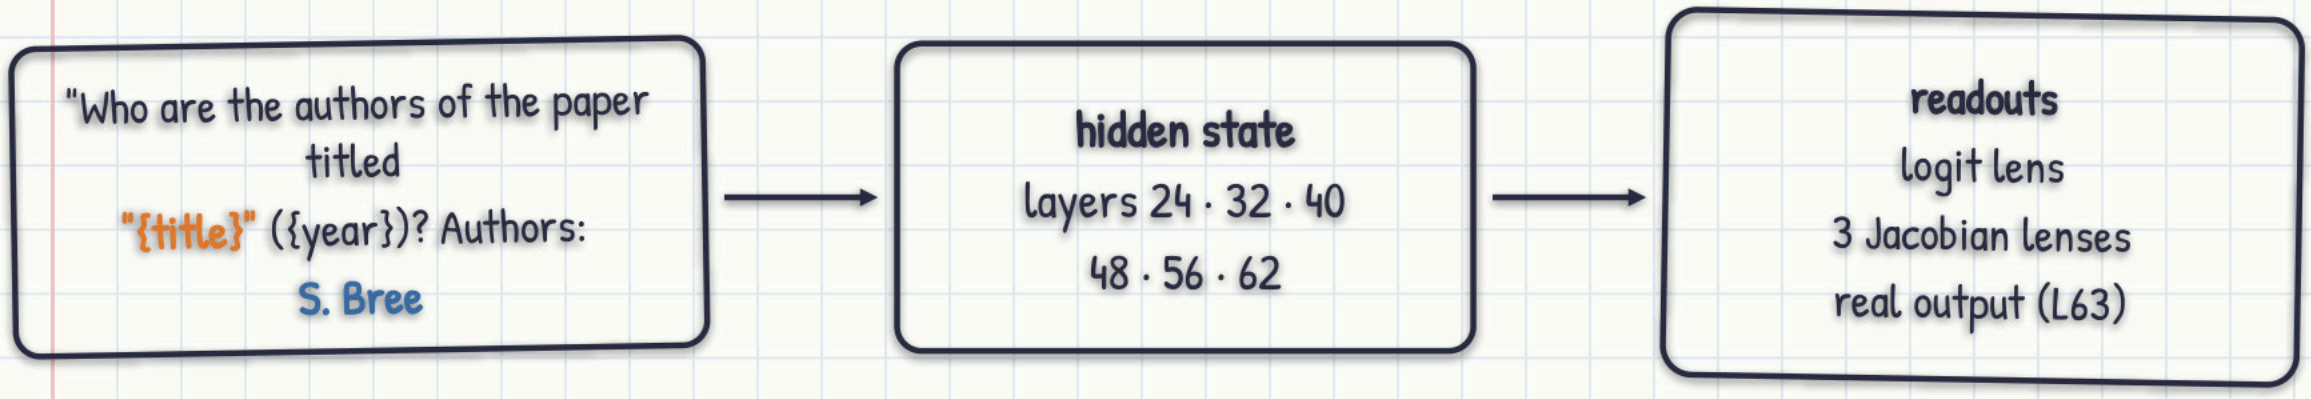
sensitivity: drop bins 0-4

第 9 / 82 页 · deck 第 4 页 按 deck 讲稿备注翻译（已按复核结果更新）

这一页是所有数字背后的规则。开放回答用对话模板内的贪心解码；用确定性的模糊姓名匹配数出匹配 M、编造 H、遗漏 U，HR2 = (H+U)/(M+H+U)。HR2 不超过 0.5（标注规则 recall_failure_threshold 0.5；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/rules.yaml、step1_README.md）为 R2，否则一个没匹配上是 R0，匹配上一些是 R1，全程没有人工或模型评判。多选题把真名单和同领域、团队大小相近、同引用档、年份相近的另外 3 篇论文（多选题 4 个选项 = 真团队 + 3 个干扰团队；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/step1_README.md；mc_team.jsonl）的真实团队放在一起，问 4 种顺序（顺序 ABDC、BCAD、CDBA、DACB；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/step1_README.md）；字母概率取自下一个 token 的分布，“A”和“ A”相加，不做重新归一化（平均总和 1.00（标注包 mc_results.jsonl，kind=team，36,432 次：字母概率和均值 0.998，最小 0.142，低于 0.5 的只有 3 次（同一篇论文）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 检查行））。target 是 4 次全对且真字母平均概率至少 0.5（标注规则 group_tight（min_orders 4, min_p_true 0.5）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/rules.yaml），control 是最多对 1 次（同上 rules.yaml，control = 至多 1/4）。

Stage 10

How we read the model



Score = rank of the correct next name token,

as log10(1 / rank): 0 = rank 1, −1 = rank 10

7 title conditions: the true title, 5 matched false titles, no title

title-specific signal

= true title − mean(5 false titles)

Same name, same tokens: what is left is knowing this paper

Lenses (model weights never change; Jacobians to L63 averaged over prompts): public = 557 WikiText-103 prompts (Neuronpedia) · self100 = 100 frozen WikiText-103 prompts · fitA = 100 other WikiText-103 prompts (Stage 9: one skipped prompt replaced -> 100 valid) (n_prompts: 351_stage10/config/lenses.json; Stage 9 final_status.json)

方法。提示词是“Who are the authors of the paper titled ‘…’ (年份)? Authors:”，后面接一位作者的名字。用教师强制：在每个名字 token 之前，看正确 token 排第几。读出方式有 logit lens、三种 Jacobian lens（Neuronpedia 公开的、self100、fitA）和模型真实输出，层从 L24 到 L62。指标是 log10(1/名次)：排第 1 为 0，排第 10 为 −1。每篇论文还要用 5 个匹配的假标题（Stage 10 标题条件设计：每篇 5 个匹配假标题（false_0–false_4）加删去标题；351_stage10/config/conditions_manifest.json）和删去标题各跑一遍；标题特异信号 = 真标题减去假标题的平均，这样名字本身好不好猜的影响就抵消了。

Can we trust the numbers?

fast = slow

One forward pass vs one per prefix: max gap 0.37 logit (bf16 rounding); ranks 1-41 identical (Stage 10, 12 contexts, parity.json)

matches Stage 6

972 tokens: same token ids, median log-prob gap ~1e-5 (Stage 10, crosscheck_stage6.csv)

negative control

Punctuation tokens show ~0 title-specific signal at every layer (Stage 10, max 0.014, 9,108 papers, §6.5)

Caveat: the parity tolerance was raised 0.25 -> 0.5 after seeing these bf16 gaps. (parity.json tolerance_amendment)

 按 deck 讲稿备注翻译（已按复核结果更新）

相信数字之前做了三项检查。第一，快速路径和逐个前缀的参考路径一致，差异只在 bf16 舍入范围内。第二，在 972 个重叠 token（Stage 10 与 Stage 6 交叉核对，13 组读出×层各 972 个 token，名次完全相同比例 76.5–95.5%；351_stage10/reports/crosscheck_stage6.csv）上，名次和上一阶段（Stage 6）一致。第三，标点 token 不可能依赖标题，它们的标题特异信号确实约为 0。需要如实说明：一致性检查的容差是在看到结果之后从 0.25 放宽到 0.5（Stage 10 parity，12 个上下文、52 个位置，最大 |logit 差| 0.156–0.367（final@L63 0.367）；351_stage10/reports/parity.json tolerance_amendment；351_stage10/config/analysis_plan.json amendments）的。

Line A

Is it about this paper?



small samples asked

Does the true title beat a crossed or shuffled title? Does A gain more than B?

→

the full cohort answered

Title-specific signal for every token; target beats control only late; name prior split out; probe controls

 新写讲稿

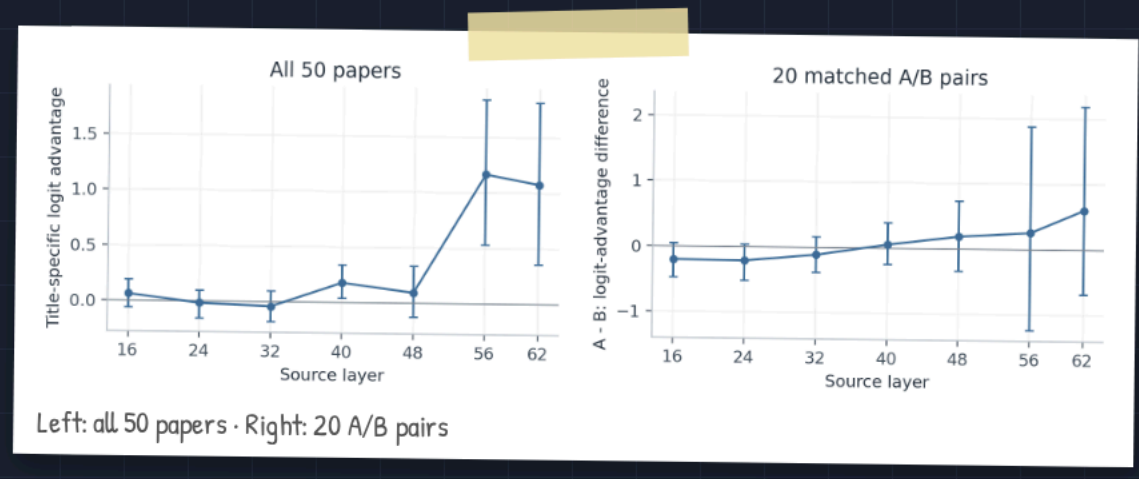
A 线的问题是：信号是不是针对这篇论文？小样本阶段问的是，真标题能不能胜过交叉标题或打乱的标题，A 组是不是比 B 组得益更多。全量阶段的回答是：对每个 token 计算标题特异信号；目标组只在最后几层才领先对照组；把名字先验单独拆了出来；并做了 probe 的对照检验。

Stage 5 · Line A

Crossed title–author control

Is the gold name high because of the title, or because the name is easy?

Paper P (author G) and source paper Q (author F, same field & bin).
M = logit(G) − logit(F) · T = M(P title) − M(Q title)
A fixed preference for G cancels out.



Left: all 50 papers · Right: 20 A/B pairs

- All 50 papers: L56 +1.17 [0.53, 1.84], L62 +1.08 [0.36, 1.82](Stage 5, J-Lens, 50 papers, layer_summary.csv)
- Matched A–B, 7-layer integrated: +0.08 [−0.43, +0.65](20 pairs, matched_ab_summary.csv)

The title changes which name wins in late layers. Whether A gains more than B: **not established**.

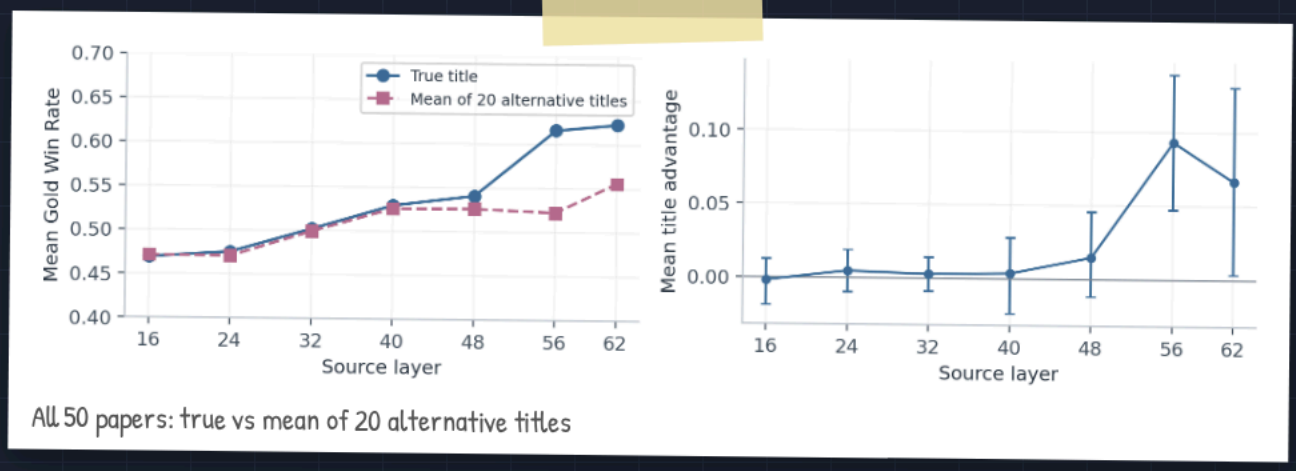
第 13 / 82 页 · Stage 5 · Line A · 合并 PPT 自身页面 **新写讲稿**

Stage 5 做的是交叉标题对照：正确名字排得高，是因为标题，还是因为这个名字本身好猜？做法是拿论文 P（作者 G）和同领域、同引用档的来源论文 Q（作者 F）互换标题，看 G 相对 F 的 logit 差在两种标题下的变化，这样对 G 的固定偏好就被抵消了。全部 50 篇论文上（Pilot50；351_stage5_crossed_v2/cohort/pilot50_v1.csv），L56 为 +1.17 [0.53, 1.84]，L62 为 +1.08 [0.36, 1.82]（Stage 5，J-Lens，交叉对比（G 对 F 的 logit 差在两种标题下的变化），50 篇，论文 bootstrap 95% CI：L56 +1.167 [0.533, 1.838]、L62 +1.077 [0.363, 1.816]；报告 Stage 5 节图 5.1 左；351_stage5_crossed_v2/summary/layer_summary.csv 行 group=ALL），说明标题会改变后几层里谁胜出；但 20 对 A/B 匹配的 7 层积分只有 +0.08 [−0.43, +0.65]（Stage 5，J-Lens 7 层积分，匹配 A − B，20 对，+0.081 [−0.426, +0.648]，配对 bootstrap 95% CI；报告 Stage 5 节图 5.1 右；351_stage5_crossed_v2/summary/matched_ab_summary.csv 行 layer=integrated），A 是否比 B 得益更多还不能确定。

Stage 7.3 · Line A

Shuffled titles: the true title helps

Same 100 candidates, 20 metadata-matched wrong titles per paper, 1,000 contexts; only the title changes



All 50 papers: true vs mean of 20 alternative titles

- Pooled L56: 0.616 vs 0.523 → +9.3 pp [4.8, 14.0], 35/50 papers positive (J-Lens L56, 50 papers; paper_null_distribution.csv; CI recomputed 10-30)
- Leave-one-out: +8.6 to +10.0 pp (stage7_l56_loo.csv)
- Vanilla L56 +10.6 pp, final output +7.2 pp (paper_null_distribution.csv)
- Matched A–B integrated: +0.018 [−0.021, +0.063] (20 pairs, integrated_ab_bootstrap.csv)

Two different questions: "does the title help?" **yes**; "does it help A more than B?" **not shown**.

 新写讲稿

Stage 7.3 用打乱的标题：候选名字不变，每篇论文配 20 个元数据匹配的错误标题，共 1,000 个上下文（Stage 7.3 设计，50 篇 × 20 个替代标题；~/jlens_work/07_3_stage7_3/351_stage7_3.py:83-91；351_stage7_3/reports/freeze_audit.md），只有标题在变。全部 50 篇合并（Pilot50 50 篇；351_stage7_3/summary/paper_null_distribution.csv），L56 上真标题 0.616 对错误标题平均 0.523（Stage 7.3，J-Lens L56，金标准首 token 胜率，合并池，50 篇均值：真标题 0.6160、20 个错误标题平均 0.5226；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）列 true_win、null_mean），高 +9.3 个百分点 [4.7, 13.9]，50 篇里 35 篇为正（Stage 7.3，J-Lens L56，真标题胜率 − 20 个错误标题平均胜率，合并池，Pilot50 50 篇均值 +0.0934 [0.047, 0.139]（2026-10-30 重算区间，B = 20,000），35/50 篇为正；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv；报告 Stage 7.3 节）；逐篇剔除后在 +8.6 到 +10.0 之间（Stage 7.3，J-Lens L56 标题优势，50 篇逐一留出一篇后的均值范围 +8.64 到 +9.99 pp；351_stage7_3/recompute_2026-10-30/stage7_l56_loo.csv）。Vanilla 在 L56 为 +10.6，最终输出 +7.2（Stage 7.3，Vanilla L56 / 最终输出 L63，真标题胜率 − 20 个错误标题平均，合并池，50 篇均值 +0.1063 / +0.0716；351_stage7_3/summary/paper_null_distribution.csv（mode=vanilla_L56、final_L63））。但匹配的 A−B 积分只有 +0.018 [−0.021, +0.063]（Stage 7.3，J-Lens 7 层积分标题优势的匹配 A − B，合并池，20 对，+0.0177 [−0.0211, +0.0626]，配对 bootstrap 95% CI；351_stage7_3/summary/integrated_ab_bootstrap.csv 行 jlens/combined）。这里要分清两个问题："标题有没有帮助"，答案是有；"对 A 的帮助是否比对 B 大"，没有证明。

Stage 7.3 · robustness

Does the title effect survive the obvious objections?

Source-author overlap

199/1,000 wrong titles come from a paper whose author is in the false pool. Excluding them: +0.026 → +0.028.(quality.json; paper_null_distribution.csv)

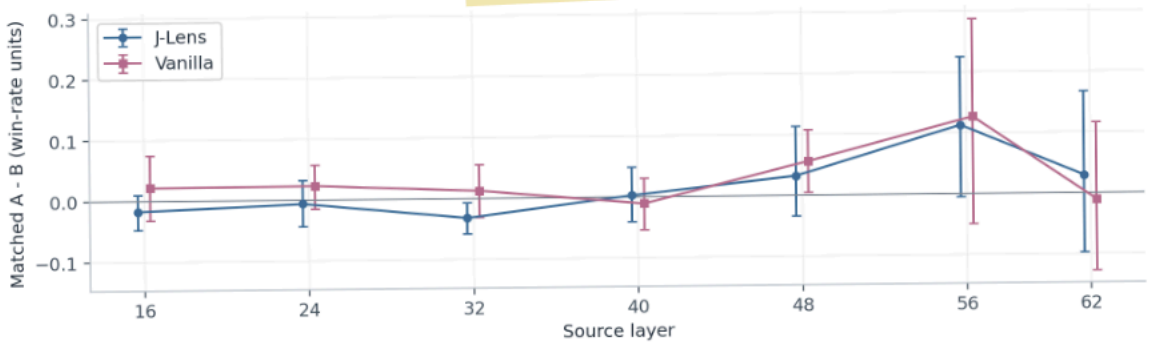
Candidate weighting

Author-, unique-token- and non-collision weights: pooled +0.026 to +0.032; all six A–B CIs include 0.

(stage7_weighting_title_advantage.csv)

Low citations

0–2 citations (n = 6): L56 +0.22, 5/6 positive, but 0/6 beyond its own 20-title tail (≤ 0.05).(floor_L56_low_six.csv)



Title-adjusted A–B win rate by layer

Layer heterogeneity

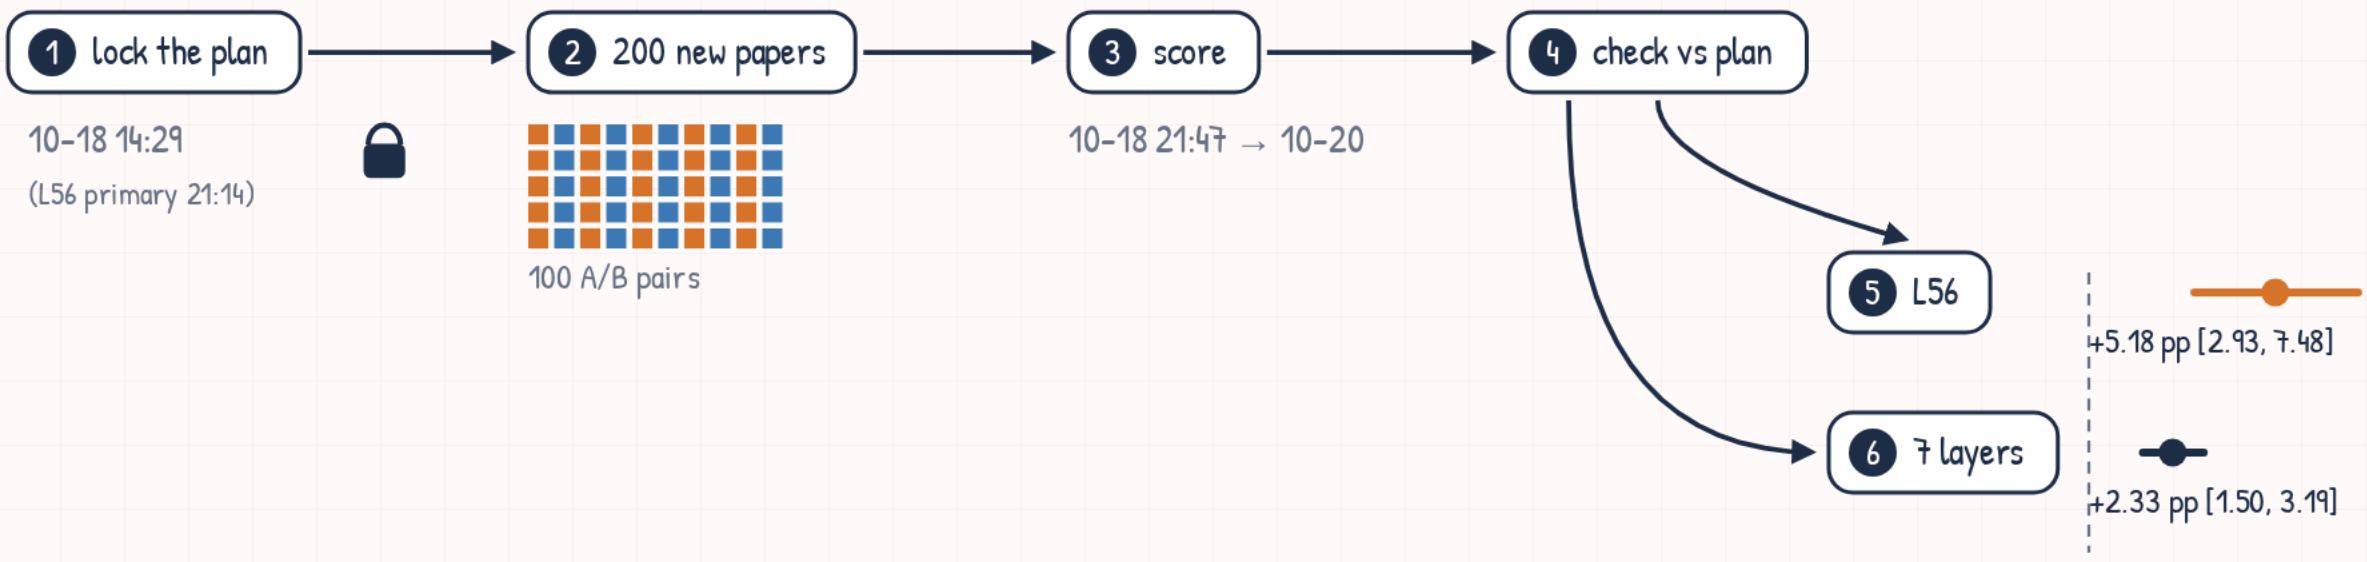
L56 +0.11 but L32 **−0.03** (CI below 0).(20 pairs, matched_ab_bootstrap.csv) Reporting only the positive layers would mislead.

第 15 / 82 页 · Stage 7.3 · robustness · 合并 PPT 自身页面 **新写讲稿**

这一页检查标题效应能否经受几种显而易见的质疑。第一，1,000 个错误标题里有 199 个（Stage 7.3，199/1,000 个替代标题的来源论文作者在错误作者池中；351_stage7_3/summary/quality.json）来自作者在候选池里的论文，剔除后效应从 +0.026 变为 +0.028（Stage 7.3，J-Lens 7 层积分标题优势，合并池，50 篇均值 +0.0262 → 剔除重叠后 +0.0283；351_stage7_3/summary/paper_null_distribution.csv 列 title_advantage / advantage_no_source_false_overlap（方法手册重算））。第二，换成按作者、按唯一 token、按非碰撞加权，合并效应在 +0.026 到 +0.032 之间（Stage 7.3，J-Lens 7 层积分标题优势，作者加权 / 唯一 token / 去平局 +0.026 / +0.032 / +0.027，50 篇；351_stage7_3/recompute_2026-10-30/stage7_weighting_title_advantage.csv），但六个 A–B 区间都含 0（Stage 7.3，3 种加权 × J-Lens/Vanilla 的 7 层积分匹配 A − B，20 对，配对 bootstrap 95% CI；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv 行 16–27）。第三，0–2 次引用的 6 篇论文 L56 为 +0.22，6 篇里 5 篇为正（Stage 7.4 低引用分析，J-Lens L56 标题优势，0-2 档 6 篇，均值 +0.224，5/6 为正，0 篇超出自身 20 个错误标题的 5% 尾部；351_stage7_4/summary/floor_L56_low_six.csv；351_stage7_4/summary/overview.json "floor_low_six_L56"），但没有一篇超出它自己 20 个错误标题的尾部（Stage 7.3 每篇 20 个替代标题；~/jlens_work/07_3_stage7_3/351_stage7_3.py:83-91）。第四，层之间差异很大：L56 为 +0.11，L32 却为 −0.03（区间在 0 以下）（Stage 7.3，J-Lens 单层标题优势的匹配 A − B，合并池，20 对，配对 bootstrap 95% CI：L56 +0.113 [−0.005, +0.225]，L32 −0.032 [−0.058, −0.006]；351_stage7_3/summary/matched_ab_bootstrap.csv 行 jlens_L56 / jlens_L32 combined），只报告正的那些层会误导。

Independent replication (Stage 8)

plan first, data second



RQ1 = win rate(true title) − mean win rate(20 false titles)

first author vs 100 false names · J-Lens · paper bootstrap

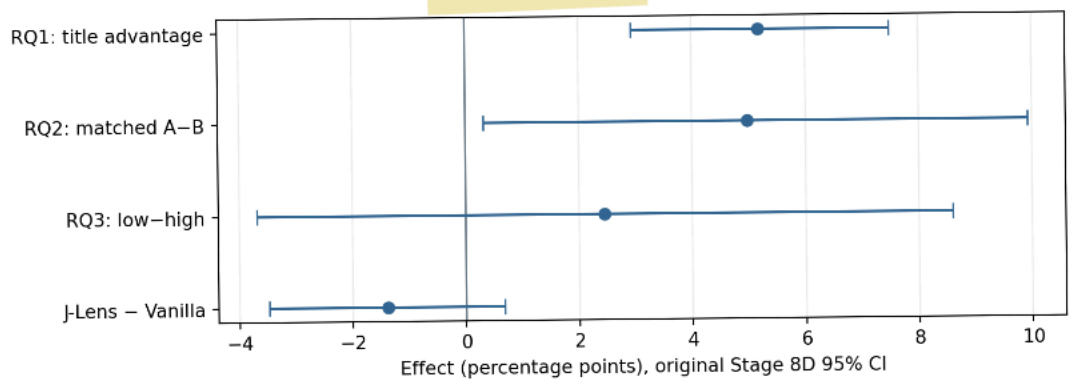
+5.18 pp: Stage 8D RQ1, J-Lens L56, 200 papers, stage8D/summary/primary_questions.csv · +2.33 pp: J-Lens 7-layer, 200 papers, recompute_2026-10-30/s8_endpoints.csv

 新写讲稿

Stage 8 是独立重复：分析计划在 10 月 18 日 14:29 冻结（analysis_plan.json），当天 21:14 的协议把 L56 定为主层，仍在打分之前。然后取 200 篇新论文（100 对 A/B）（Stage 8A 抽样，100 对匹配 A/B；351_stage8/cohort/stage8_papers.csv；351_stage8/summary/matching_audit.json），10 月 18 日 21:47 开始打分、10 月 20 日结束，再按计划检查。RQ1：L56 处真标题相对 20 个假标题的胜率高 +5.18 个百分点 [2.93, 7.48]（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节）；计划里冻结的主终点（7 层平均）是 +2.33 [1.50, 3.19]（Stage 8 冻结计划主终点，J-Lens 7 层积分，真标题 − 20 个错误标题平均，200 篇，+2.33 pp [1.50, 3.19]，论文 bootstrap 95% CI；351_stage8/recompute_2026-10-30/s8_endpoints.csv）。

Stage 8D · Lines A, B

On 200 new papers the title effect replicates



Stage 8D L56 estimates (PROTOCOL.md), 95% CI (pp)(primary_questions.csv)

(Stage 8D, J-Lens L56; primary_questions.csv)	Estimate	95% CI
RQ1 title, L56(200 papers)	+5.18 pp	[+2.93, +7.48]
RQ2 A–B, L56(100 pairs)	+4.98 pp	[+0.32, +9.91]
RQ2 A–B, 7-layer (frozen primary)(100 pairs; s8_endpoints.csv)	+2.41 pp	[+0.91, +4.00]
RQ3 low–high(25 + 25 pairs)	+2.45 pp	[−3.69, +8.60]
J-Lens–Vanilla(jlens_minus_vanilla.csv)	−1.38 pp	[−3.48, +0.68]

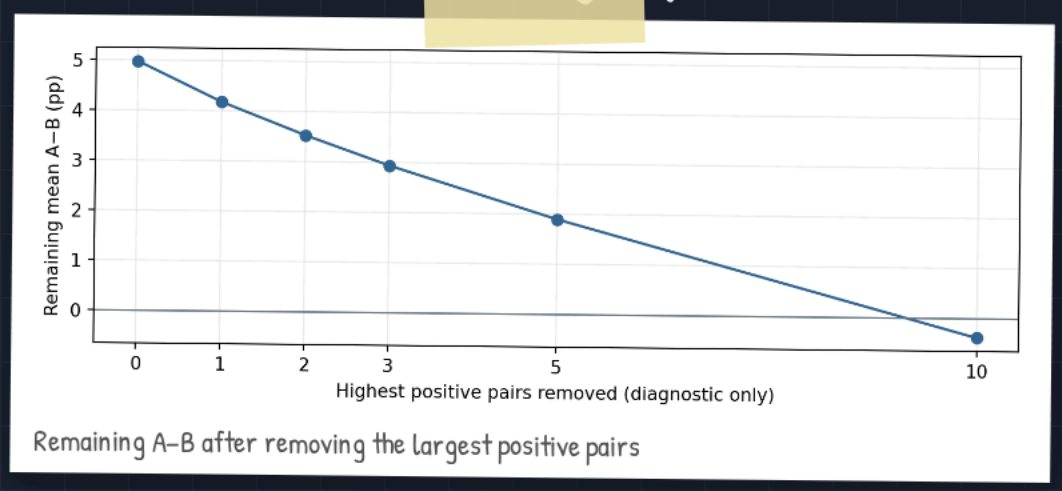
Citation bands: low +6.8 [2.6, 11.6], mid +4.8, high +4.4 [−1.1, 10.0]
(50/100/50 papers; layer_and_band_summary.csv)

RQ1 is the first **independent** confirmation: correct titles help the gold author on new papers. J-Lens still adds nothing over Vanilla.

第 17 / 82 页 · Stage 8D · Lines A, B · 合并 PPT 自身页面 **新写讲稿**

Stage 8D 在 200 篇全新论文上（Stage 8 新论文；351_stage8/cohort/stage8_papers.csv）冻结设计后复现。RQ1 标题效应 +5.18 个百分点 [+2.93, +7.48]（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节），这是第一次独立确认：正确标题能帮助正确作者。RQ2 的 A−B 为 +4.98 [+0.32, +9.91]（Stage 8D RQ2，J-Lens L56 匹配 A − B，100 对，+4.98 pp [0.32, 9.91]，配对 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ2_matched_A_minus_B）；RQ3 低引用减高引用为 +2.45，区间含 0（Stage 8D RQ3，J-Lens L56，配对平衡的低引用 − 高引用，50 对，+2.45 pp [−3.69, +8.60]；351_stage8/stage8D/summary/primary_questions.csv 行 RQ3_low_minus_high）；J-Lens 减 Vanilla 为 −1.38，区间含 0（Stage 8D，L56 J-Lens − Vanilla 标题优势，200 篇，−1.38 pp [−3.48, +0.68]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/jlens_minus_vanilla.csv）。按引用分档，低档 +6.8，中档 +4.8，高档 +4.4（Stage 8D，J-Lens L56 标题优势按引用带，低 50 / 中 100 / 高 50 篇：+6.83 / +4.75 / +4.38 pp；351_stage8/stage8D/summary/layer_and_band_summary.csv（mode=jlens_L56, scope=citation_band））。J-Lens 仍然没有比 Vanilla 多出什么。

But the A–B gap rests on a few pairs



Remaining A–B after removing the largest positive pairs

- 100 pairs: 55 positive, 45 negative; median +4.4 pp (J-Lens L56; matched_pair_differences.csv)
- One pair (S8P094) ≈ +84 pp
- Remove top 5 → +1.9 pp; top 10 → −0.4 pp (recomputed from same file)

8E external audit (post-hoc)

- Unique-token weights: RQ1 +4.6, RQ2 +5.4 pp (s8_8E_weighting_by_paper.csv)
- Wrong-title length gap: +0.12 pp per token (200 papers; s8_unsourced_intervals.csv) (association only)
- Original scripts missing; recomputed from raw logits (30 Oct), same estimates (351_stage8/recompute_2026-10-30/): post-hoc only

Small samples can show a positive A–B mean that a handful of papers carry. This is the main reason Stage 10 moved to the full cohort.

但 A–B 的差依赖少数几对论文。100 对里 55 对为正、45 对为负，中位数 +4.4 个百分点（Stage 8D RQ2，J-Lens L56 匹配 A − B，100 对：55 正 / 45 负，中位数 +4.41 pp；351_stage8/stage8D/summary/primary_questions.csv 行 RQ2_matched_A_minus_B；matched_pair_differences.csv（mode=jlens_L56））；其中一对（S8P094）大约 +84（Stage 8D RQ2，最大一对 S8P094 A − B = +84.4 pp；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56））。去掉最大的 5 对后降到 +1.9（Stage 8D RQ2，按 A − B 降序去掉前 5 对后其余 95 对均值 +1.90 pp（事后诊断，方法手册 C 部分重算）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）），去掉 10 对后变成 −0.4（Stage 8D RQ2，J-Lens L56 金标准胜率匹配 A–B，100 对，均值 +4.98 pp，按 A–B 降序去掉前 10 对后其余 90 对均值 −0.39 pp（事后诊断）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）重算；报告 Stage 8D 节）。8E 的外部审计是事后做的，脚本还没归档，不能算完成的实验。小样本可以给出一个由少数论文撑起来的正 A–B 均值，这正是 Stage 10 改用全量数据的主要原因。

Stage 8 · CPU proxy

Stage 8 frozen endpoint, re-scored on CPU

Addendum 13 C-2 · same 200 papers / 100 pairs · Stage 10 raw scores, all authors, all name tokens · public J-lens rank metric, NOT the W statistic

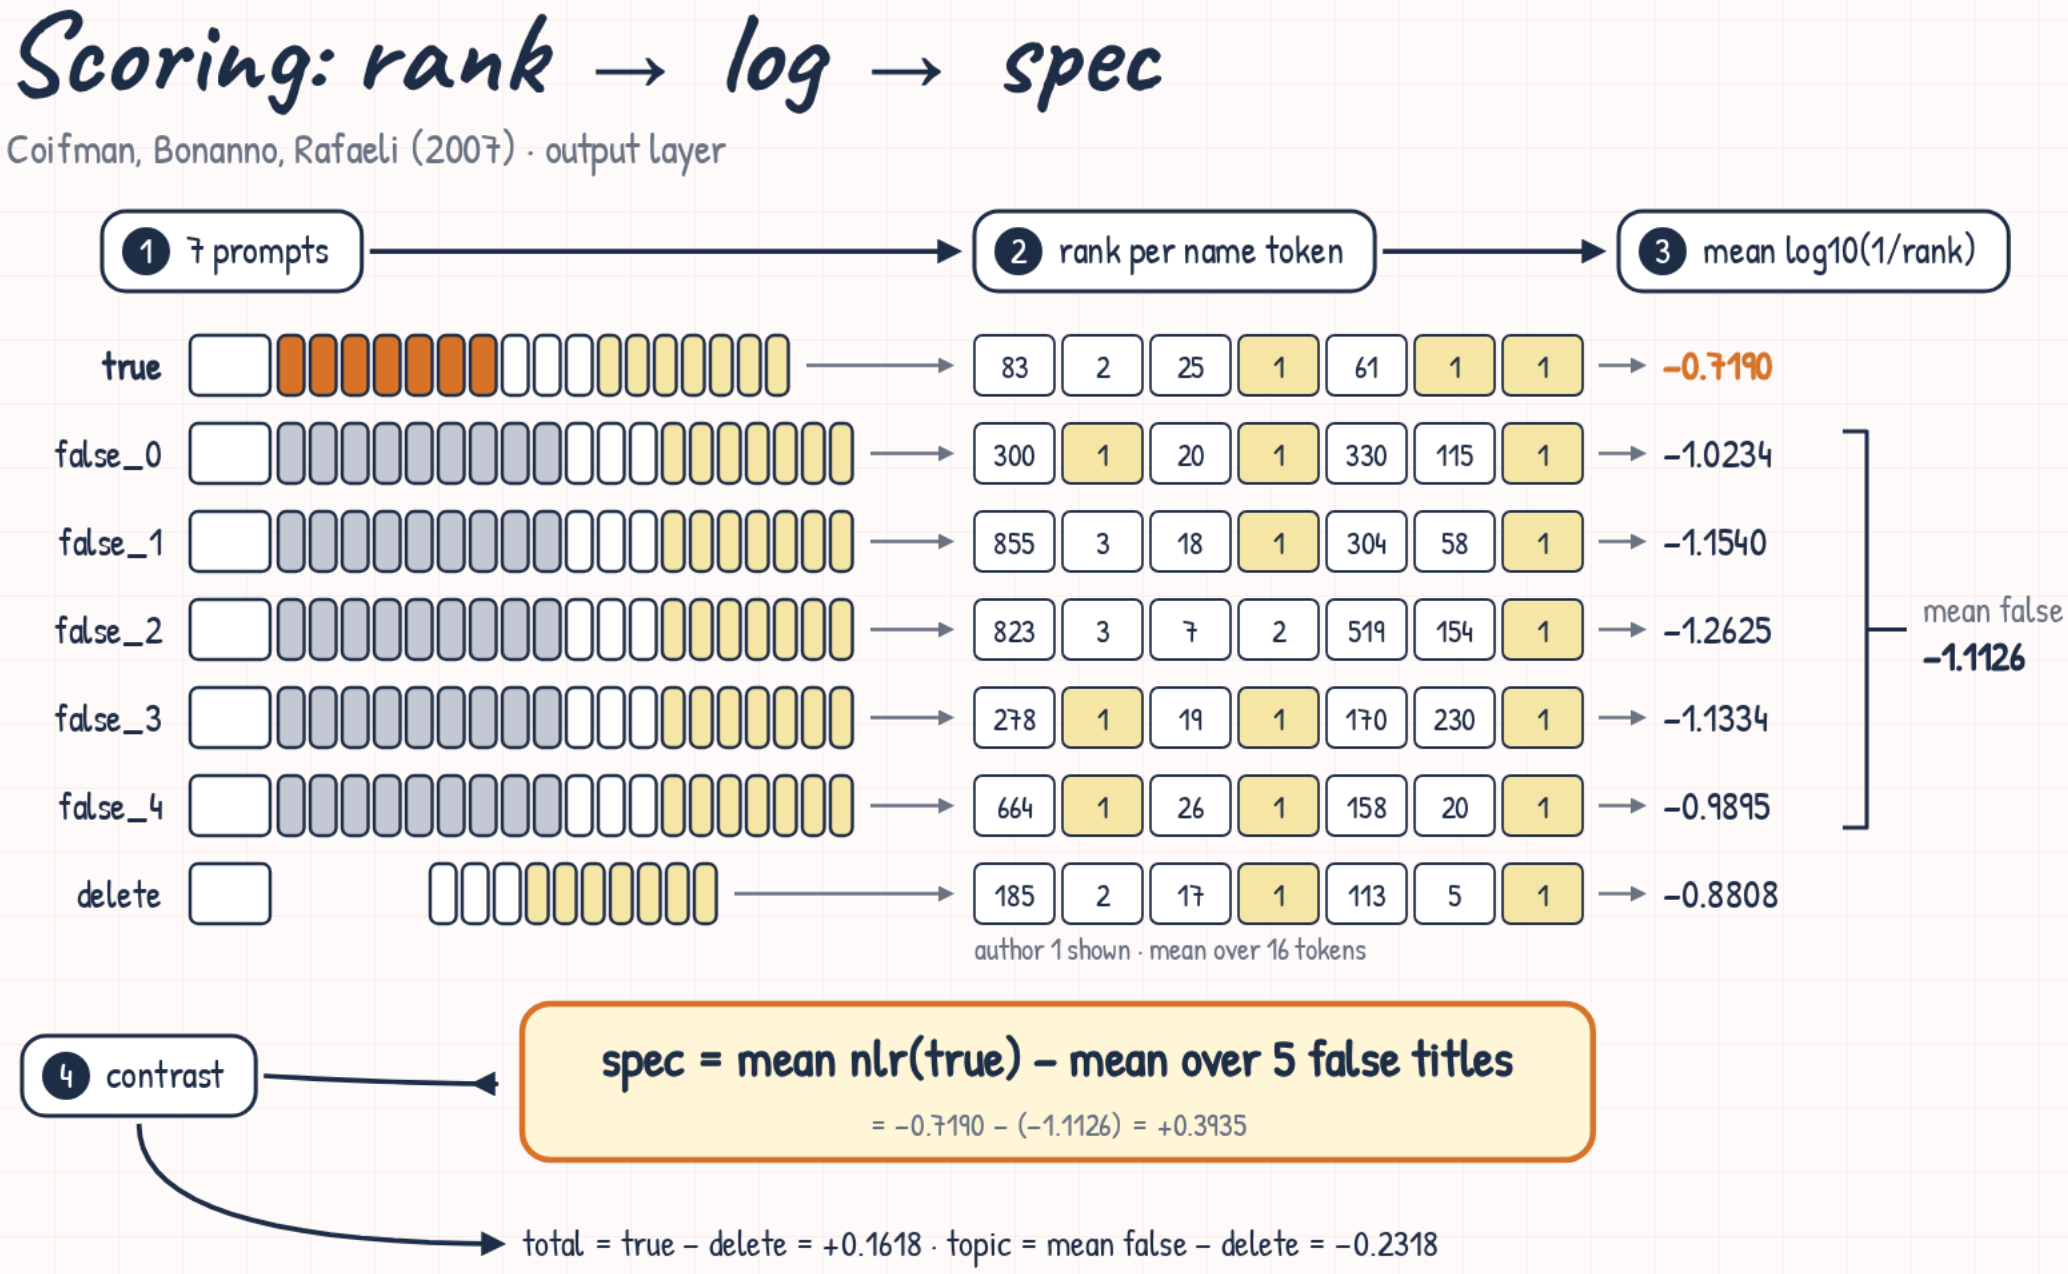
- **Multi-layer endpoint:** RQ1 +0.130 [0.109, 0.153], RQ2 +0.054 [0.008, 0.102] → both hold(public J-lens 6-layer mean; c13_C2.md aa_all)
- **L56 alone:** RQ2 +0.064 [−0.032, +0.163], not significant(same, L56)
- **What it is not:** a CPU proxy with Stage 10's 5 false titles and the rank metric; the GPU re-run of the original W was not done (user decision 2026-11-06)

Reading

The frozen multi-layer conclusion survives an all-author, all-token re-scoring; the single-layer L56 A − B gap does not.

 新写讲稿

Stage 8 的 CPU 代理（补充 13 C-2，事后）：用 Stage 10 已有的原始分数，在 Stage 8 的 200 篇论文上重算冻结的多层终点。全部作者、全部名字 token 的版本中 RQ1 和 RQ2 都成立：public J-lens 6 层平均 RQ1 +0.130 [0.109, 0.153]（补充 13 C-2，200 篇，标题特异信号（真标题 − Stage 10 的 5 个假标题），团队聚类 95% CI；381_stage13/reports/c13_C2.md aa_all int6 行），RQ2 +0.054 [0.008, 0.102]（同上，100 对 A − B，配对 bootstrap）；只看 L56 时 RQ2 +0.064 [−0.032, +0.163]，不显著（同上，L56 行）。这是 CPU 代理：用 public J-lens 的名次指标和 Stage 10 的 5 个假标题，不是 Stage 8 的 W 统计量；按原 W 的 GPU 重算没有做（用户 2026-11-06 决定）。

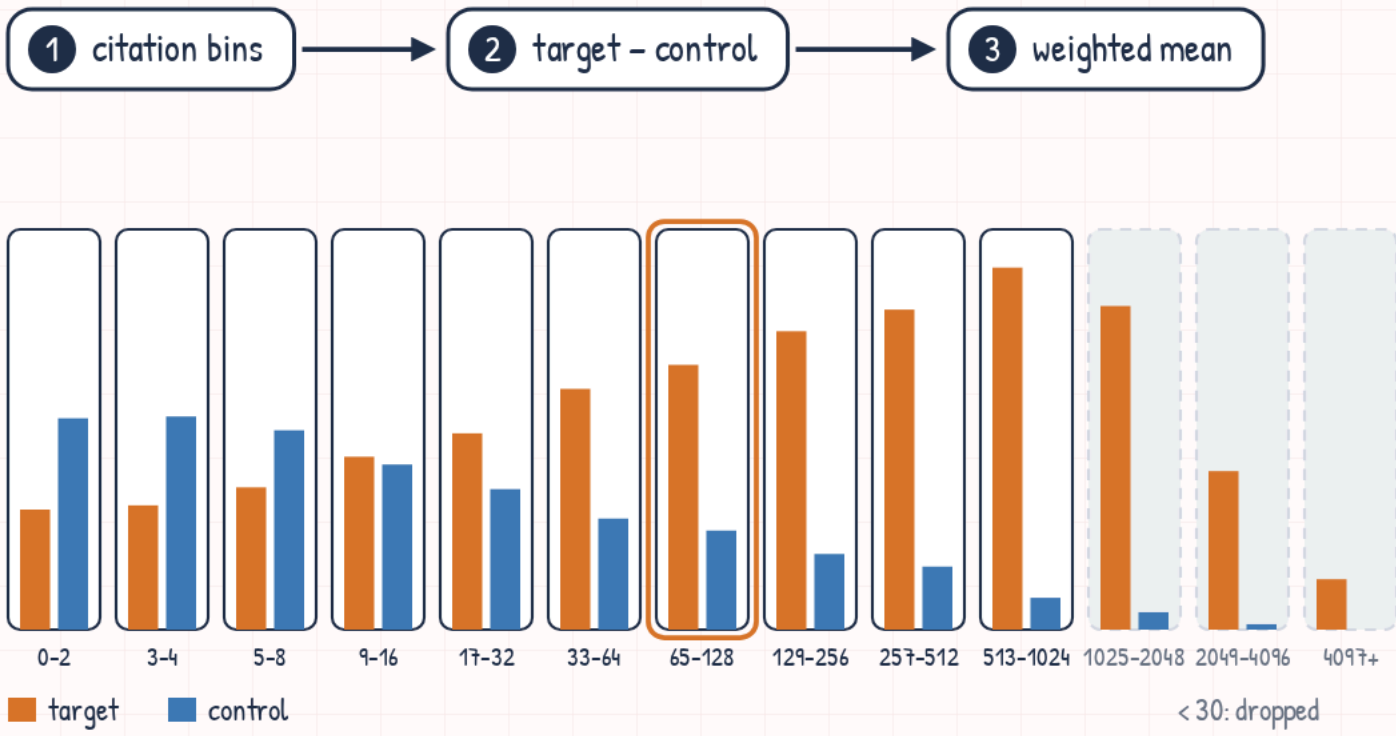


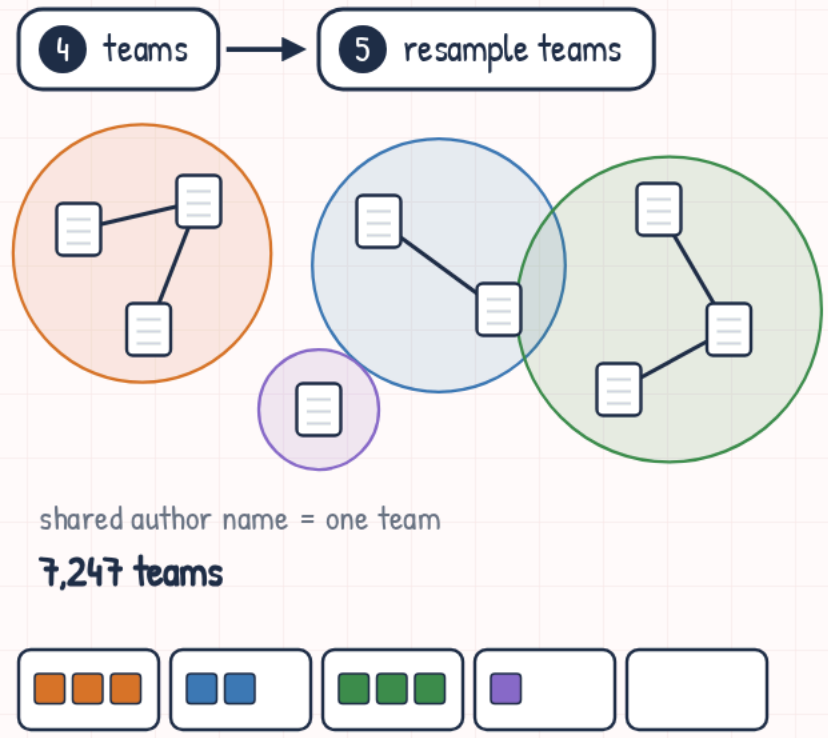
第 20 / 82 页 · Method · Scoring: rank, log, spec · 合并 PPT 自身页面 **新写讲稿**

以 Coifman、Bonanno、Rafaeli（2007）为例：同一组名字 token 接在 7 个提示后面（Stage 10 标题条件：真标题、5 个匹配假标题（false_0–false_4）、删去标题；351_stage10/config/conditions_manifest.json）——真标题、5 个匹配的假标题和删去标题。每个名字 token 取它在全词表中的名次，例如第一作者 7 个 token 在真标题下是 83、2、25、1、61、1、1（Stage 10，示例论文 Coifman 等（2007），第一作者 7 个 token，真标题，最终输出 L63 全词表名次；351_stage10/raw/final/L63/shard_011.npz 行 25025–25031；351_stage10/reports/method_figs/coifman_layer_ranks.csv（condition=true, readout=final）），再取 log10(1/名次) 并对 16 个 token 求平均（示例论文 3 位作者共 16 个名字 token；351_stage10/raw/final/L63/shard_011.npz 行 25025–25040）：真标题 −0.7190，5 个假标题平均 −1.1126，删去标题 −0.8808（Stage 10，示例论文，最终输出 L63，16 个名字 token 的平均 log10(1/名次)；方法手册 A_global1 G5.5（351_stage10/reports/methods/parts/A_global1.html）；351_stage10/summary_title/paper_title_contrasts.parquet（readout=final, layer=63））。标题特异信号 spec = −0.7190 − (−1.1126) = +0.3935；total = 真 − 删 = +0.1618，topic = 假 − 删 = −0.2318（同上，示例论文 spec +0.3935、total +0.1618、topic −0.2318；方法手册 A_global1 G5.5；351_stage10/summary_title/paper_title_contrasts.parquet（readout=final, layer=63））。

Statistical conventions

example paper: bin 65–128





$$\Delta = \Sigma\, w_b \cdot (\text{mean}_t - \text{mean}_c),\ w_b \propto n_t \cdot n_c / (n_t + n_c)$$

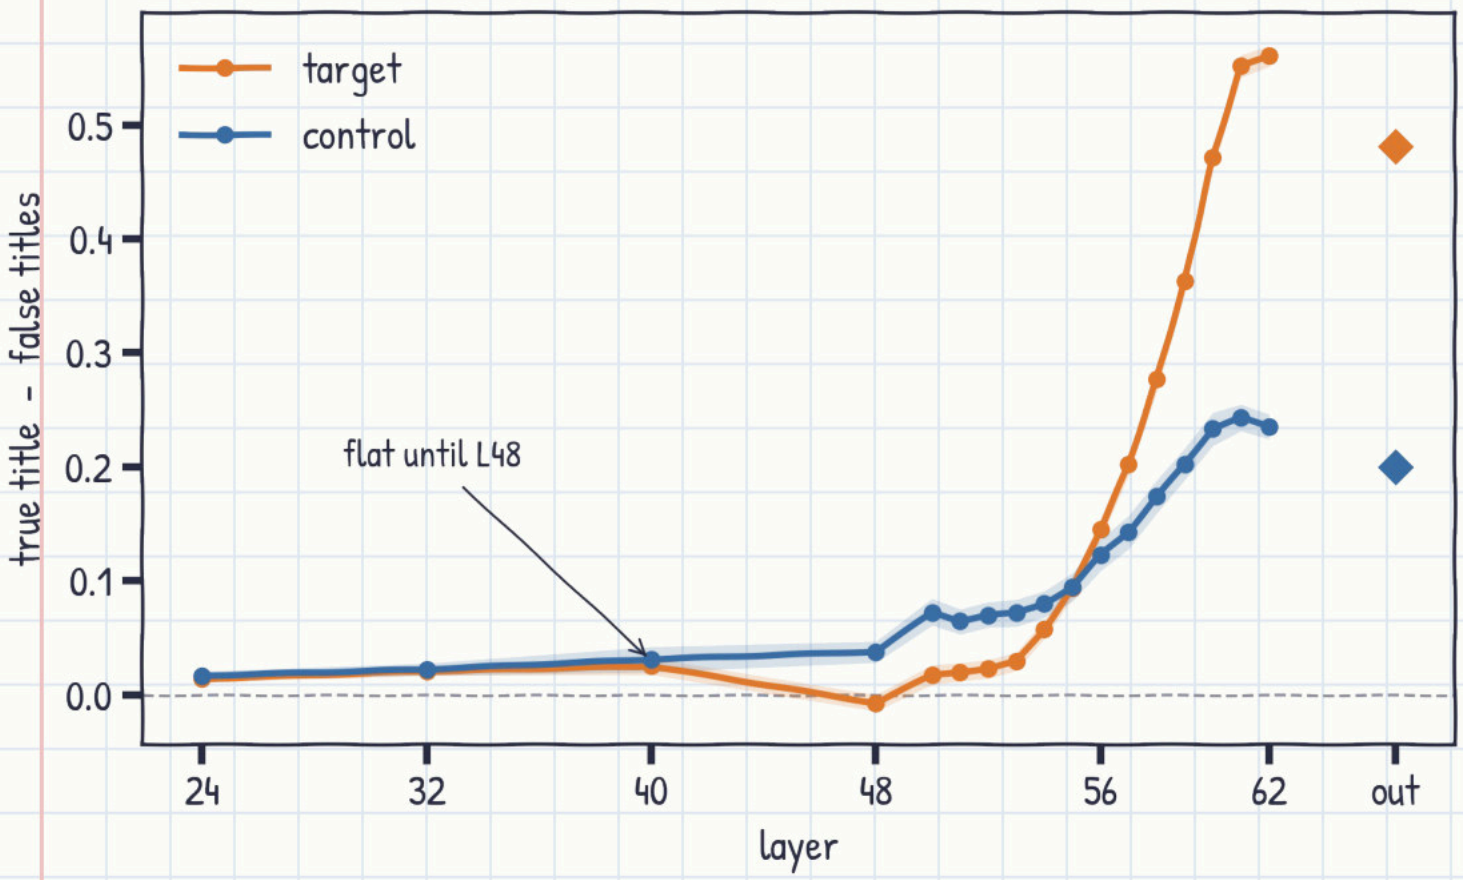
7,247 teams among 9,108 papers: 381_stage13/reports/cluster_ci.md

组间比较都在引用档内做：13 个引用档（Stage 10 引用档 0-2 … 4097+ 共 13 档；~/jlens_work/10_stage10/351_stage10.py；351_stage10/summary_extra/X2_by_bin.csv）里只用 target 和 control 各至少 30 篇的档（设计常数 MIN_STRATUM = 30；~/jlens_work/10_stage10/351_stage10.py:642；351_stage10/config/analysis_plan.json）（主分析 10 档（满足每组 ≥ 30 篇的 10 个引用档，共有引用档 目标 3,734 + 对照 2,182 篇；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），0-2 到 513-1024），每档内算 target − control，再按 $w_b \propto n_t \cdot n_c/(n_t+n_c)$ 加权合并。示例论文在 65-128 档，该档 target 441 篇、control 165 篇（Stage 10 队列 group_tight × citation_bin，65-128 档；351_stage10/cohort/papers.parquet）。Stage 13 起置信区间按作者团队重抽样：共享任一作者全名的论文并成一个团队，9,108 篇共 7,247 个团队（Stage 13 团队划分（共享任一作者全名的论文并成一组），9,108 篇 7,247 组；381_stage13/reports/cluster_ci.md 第 3 行；~/jlens_work/13_stage13/stage13_cpu.py group_folds），交叉验证时一个团队只进一个 fold。

Stage 10

Knowing the paper shows up only at the end

title-specific signal · public Jacobian lens (lines) and model output (diamonds)



L24–L48: ~0 for both groups (Stage 10, all readouts max 0.04, §6.3)

rises at **L56**

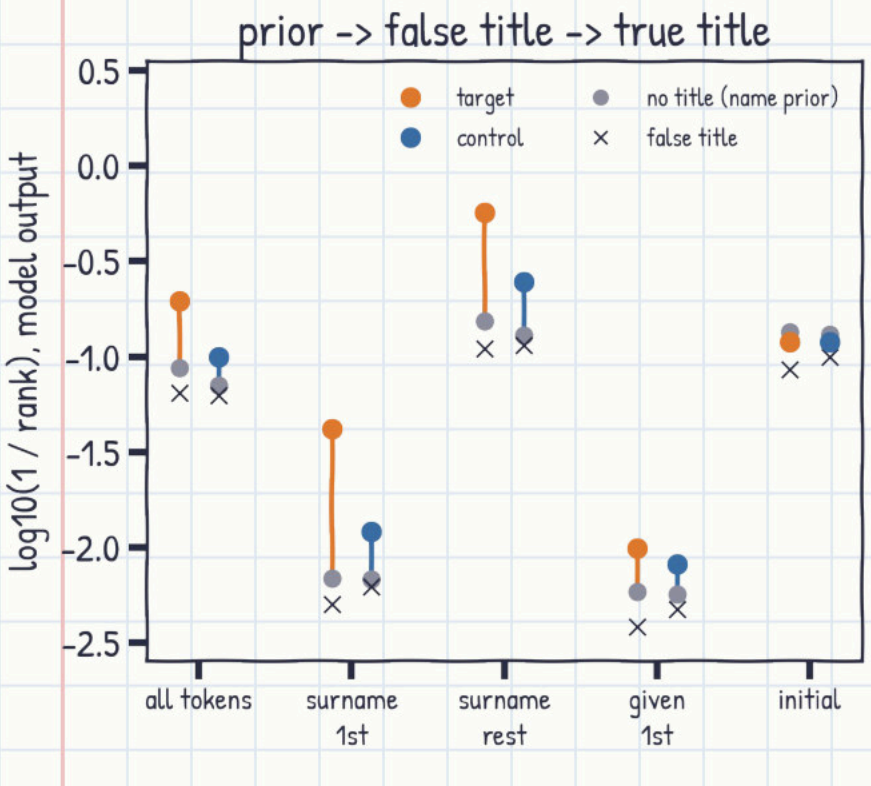
L62: **target +0.56** vs **control +0.24**
(Stage 10, public lens L62, 4,621 + 2,220 papers, §6.3 fig.)

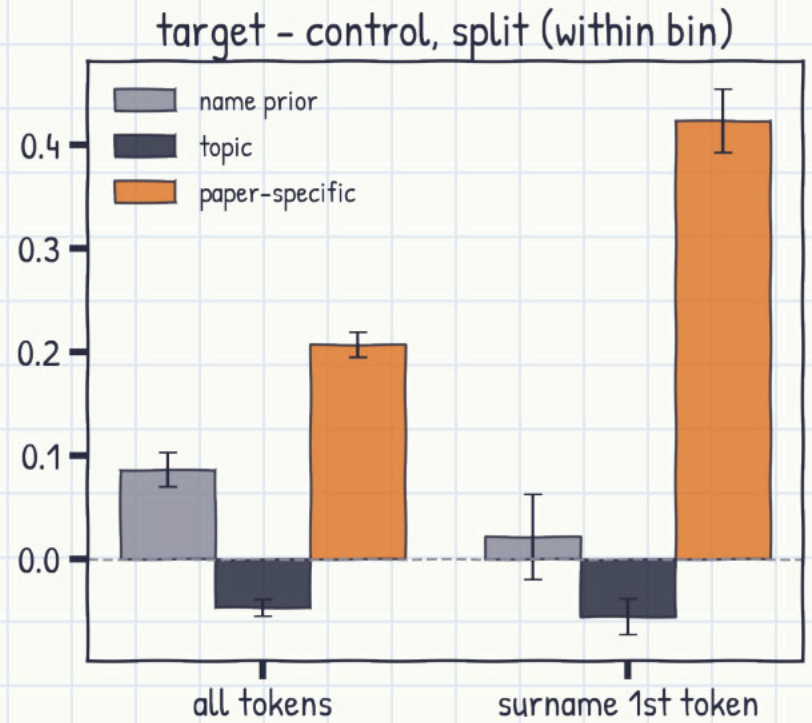
现在去掉名字好猜的影响，看真标题减假标题。到 L48 为止，两组都平坦接近 0；从 L56 开始上升，在 L62 和最终输出处最大。目标组最后大约是对照组的两倍（Stage 10，真标题 − 5 个假标题平均，最终输出 L63 各组均值：目标 4,621 篇 0.481，对照 2,220 篇 0.200（比值约 2.4）；报告 §6.3 图；351_stage10/summary_title/A_group_layer.csv）。

Stage 11

How much is just the name prior?

model output · no title vs false title vs true title · all 9,108 papers





no title: rank ~12 (Stage 12 A, 9,108 papers, §6.12)

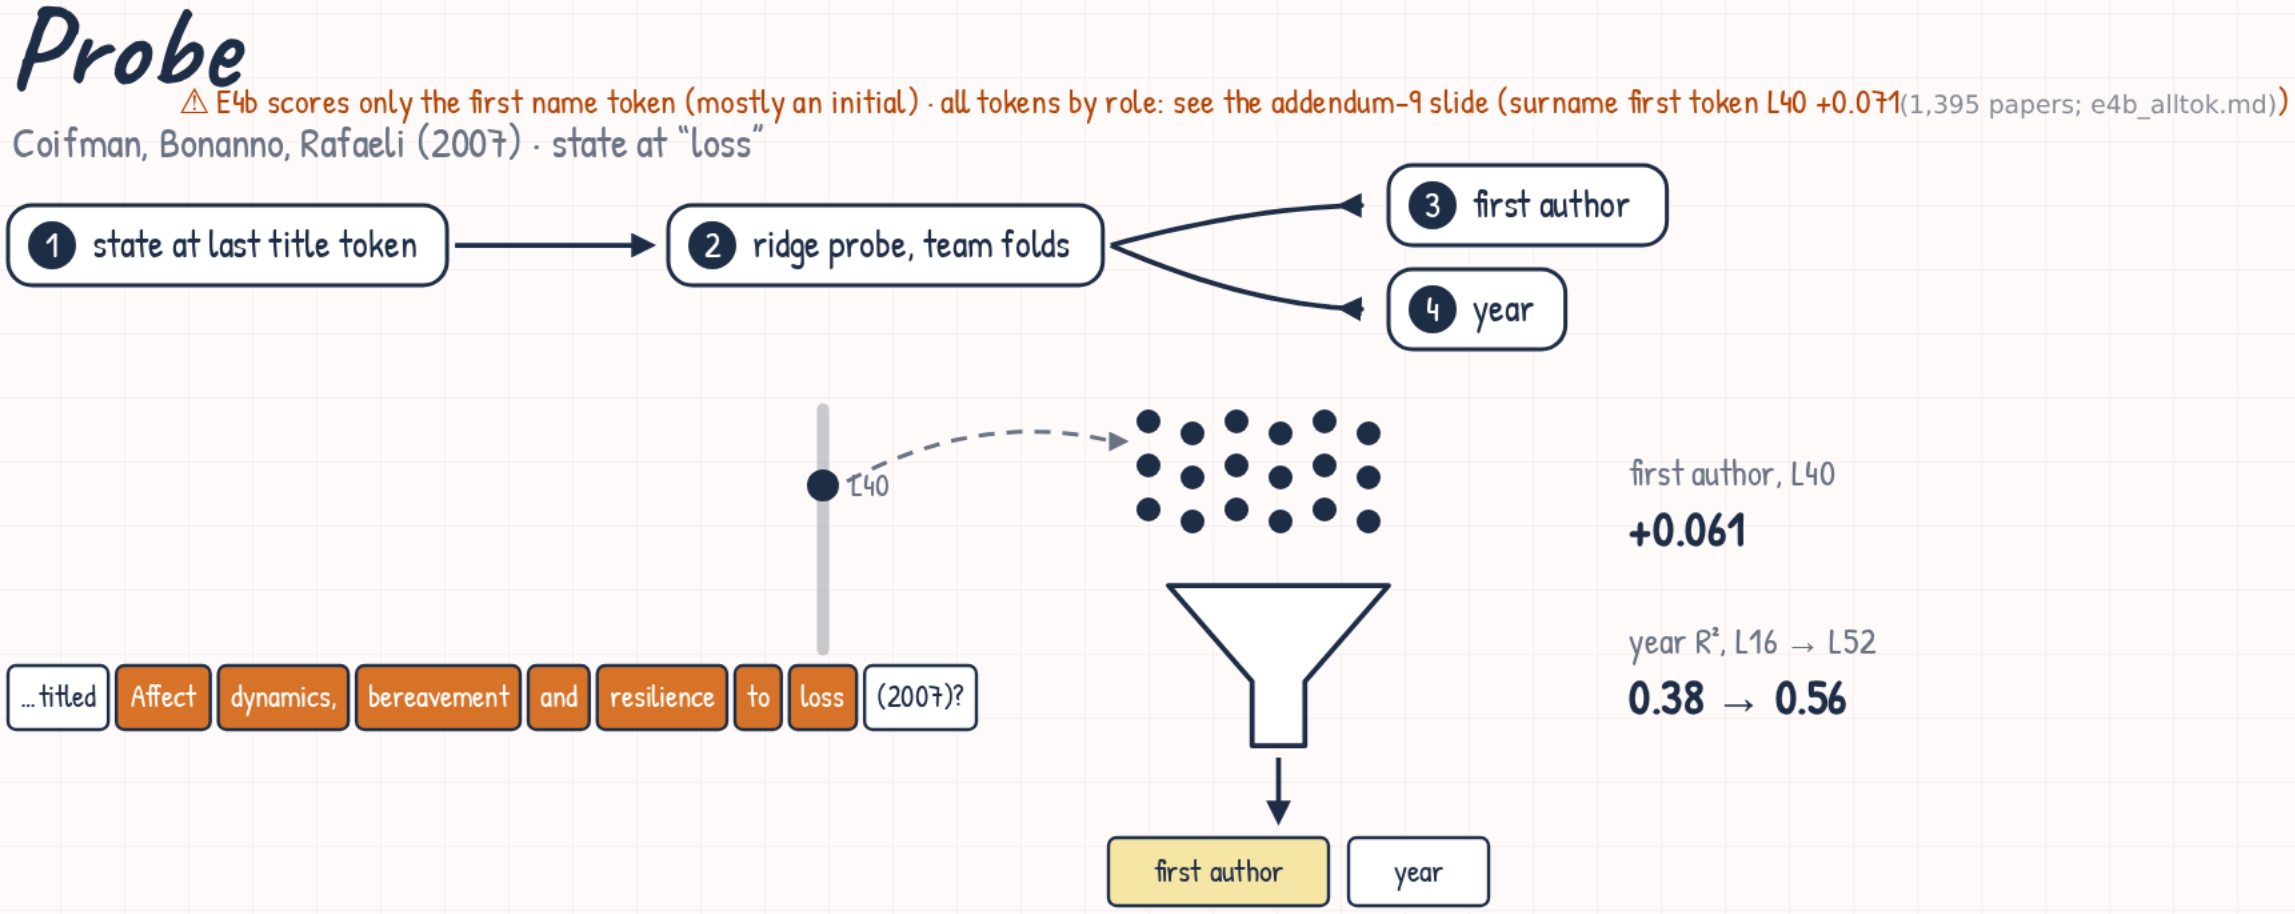
target - control: +0.09 prior, +0.21 paper (Stage 12 A, 4,621 + 2,220, within bin, §6.12)

surname 1st: prior ~0, paper +0.42 (same, 1st surname token)

prior vs recognition rho 0.09 (Stage 12 B, 8,894 R0/R1 papers)

 按 deck 讲稿备注翻译（已按复核结果更新）

名字先验占多少？我们在完全不给标题的情况下给同样的名字打分。没有标题时，正确名字平均已经排在第 12 名左右（Stage 12 名字先验（CPU），不给标题，最终输出 L63，全部 9,108 篇、全部名字 token，平均 log10(1/名次) −1.089 ≈ 第 12.3 名；报告 §6.12；371_stage12/summary_cpu/A_prior_decomposition.csv（all_tokens/all））。因为标点和姓的后半部分在给出前缀后本来就好猜。真标题对姓的第一个 token 帮助最大：目标组从大约第 146 名提到第 24 名（Stage 12 A，姓的第一个 token，目标 4,621 篇，平均 log10(1/名次) 不给标题 −2.164（≈ 第 146 名）→ 真标题 −1.380（≈ 第 24 名）；报告 §6.12 第一张表；371_stage12/summary_cpu/A_prior_decomposition.csv）。在引用档内拆分目标−对照的差：约 0.09 在不给标题时就已存在（Stage 12 A，全部名字 token，最终输出 L63，引用档内 目标−对照（目标 4,621、对照 2,220 篇）：先验 +0.087 [0.070, 0.103]；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）（目标组的名字稍微好猜一些），假标题再抵消 0.05，剩下 0.21 是这篇论文特有的（同上：主题（假标题 − 不给标题）−0.047 [−0.055, −0.038]，论文特有（真 − 假）+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）。只看姓的第一个 token，先验部分约为 0，论文特有部分为 0.42（同上，姓的第一个 token，先验 目标−对照 +0.022 [−0.019, +0.063]，论文特有 +0.423 [0.393, 0.454]；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）。先验和多选题认出程度几乎无关（Spearman 0.09，论文特有部分为 0.33（Stage 12 B，R0/R1 论文 8,894 篇，引用档内中心化后与多选题答对顺序数（0–4）的 Spearman：先验 +0.085 [0.063, 0.106]，论文特有 +0.329 [0.312, 0.346]；371_stage12/reports/stage12_cpu_report.md B；371_stage12/summary_cpu/B_prior_vs_recognition.csv））。



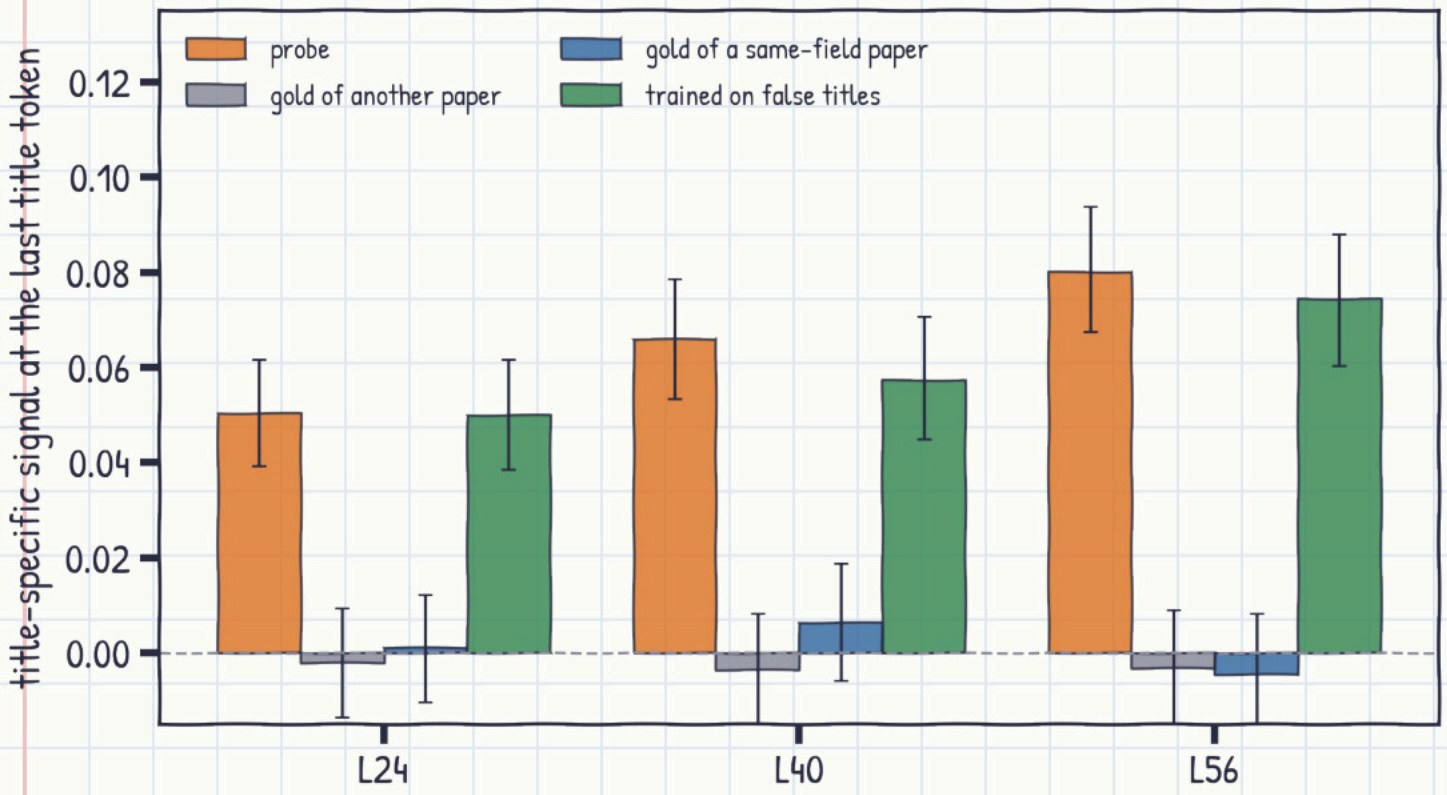
第 24 / 82 页 · Method · Probe · 合并 PPT 自身页面 **新写讲稿**

探针直接从状态读属性：取标题最后一个 token（这里是 “loss”）的残差，例如 L40，用 5 折岭回归（Stage 11 E4b / Stage 13 复核设计：5 折、按作者团队分折，α ∈ {0.1, 1, 10}；~/jlens_work/10_stage10/stage10_extra_r0r1.py probe()；381_stage13/reports/e4b_trainstd_compare.md）（按作者团队分折）预测第一作者的首个 token 或年份。标题特异分数 spec = 真标题的探针分 − 假标题的探针分，L40 为 +0.061 [0.047, 0.076]（Stage 13 E4b 复核，标题最后一个 token 上的 probe，probe 只打分第一作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，全部 1,863 篇，L40 +0.061 [0.047, 0.076]，论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 表 L40 行 new 列）。年份的 R^2 从 L16 的 0.38 升到 L52 的 0.56（Stage 13 M2，真标题，标题最后一个 token，年份岭回归 R^2，9,108 篇：L16 0.383 → L52 0.561，团队整群 95% CI；报告 Stage 13 M2 节；381_stage13/reports/m2_teamci.md 第 46、86 行）（M2）。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Stage 12

The probe signal is paper-specific

last title token · 5-fold ridge probe · re-checked: author-team folds, title reuse removed



another paper's authors: **0**

same-field paper: **0** (Stage 12 X1 + Stage 13 re-check, §6.12)

so it is **this paper**, already at L24

lenses cannot read it

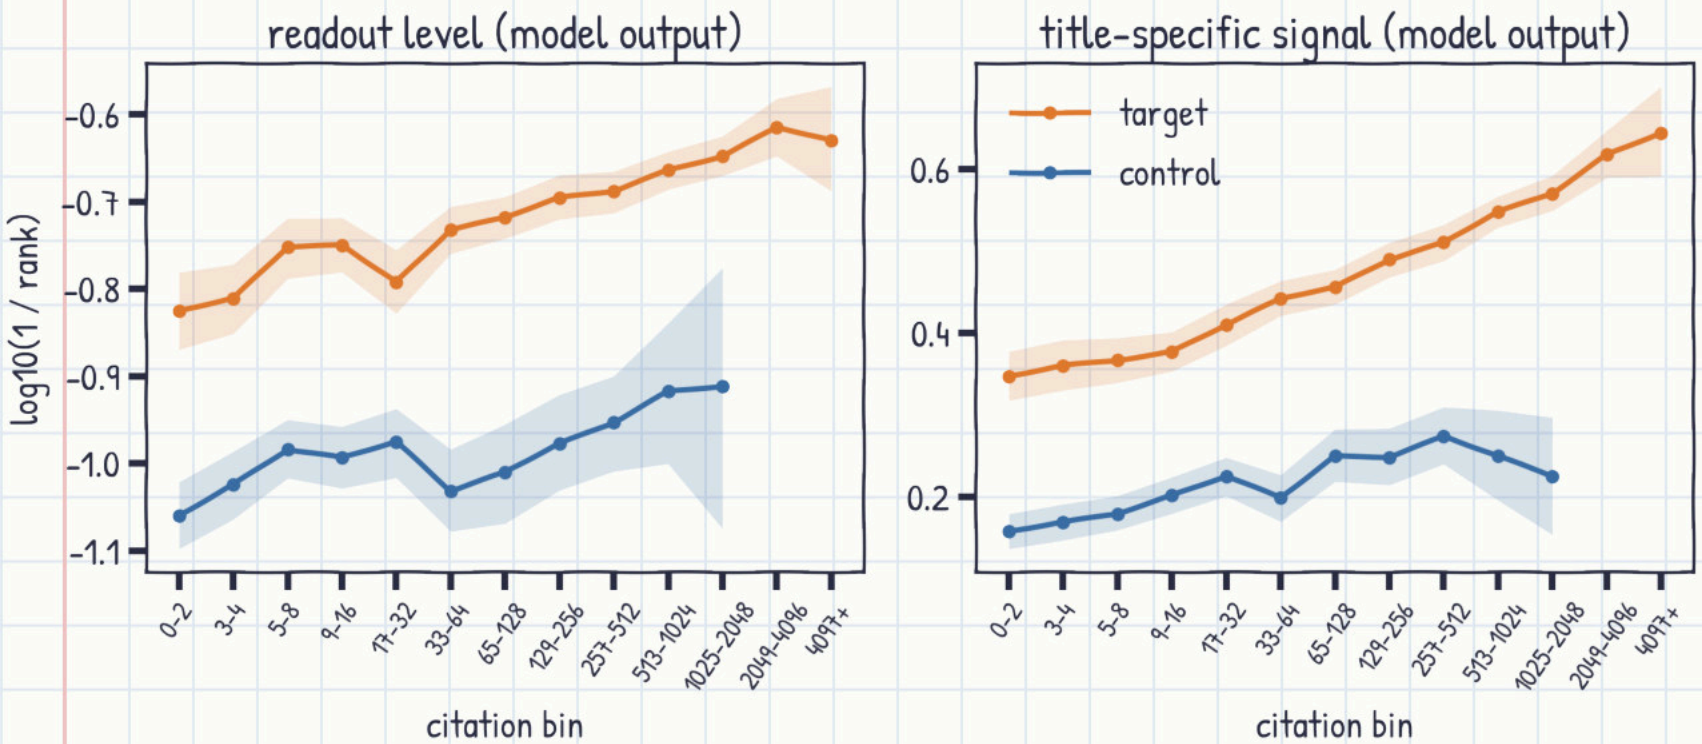
Probe scores only the first name token (mostly an initial); all-token, by-role version (addendum 9, done): surname first token L40 +0.071 [0.058, 0.085] (1,395 papers; e4b_alltok.md).

标题位置上的 probe 读到的是真正的论文知识，还是只是主题和名字之间的泛泛关联？如果把它的输出拿去和另一篇论文的作者、或同领域另一篇论文的作者对照打分，信号降为 0。只用假标题数据训练 probe，得到相近的信号；之前“更强”的结果来自泄漏，同一个借出标题同时出现在训练和测试里。这一页的数字已经按作者团队分折、并剔除了 probe 训练时见过同一标题的论文后复核。所以标题最后一个 token 上从 L24 起就有可以线性读出的、属于这篇论文的作者信息，目标组更多，只是 lens 读不出来。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Stage 10

More citations, more paper knowledge

model output · bins with < 10 papers omitted



Target: +0.35 -> +0.64 (Stage 10, final, 200 / 84 papers, §6.8)

Spearman (title-specific)

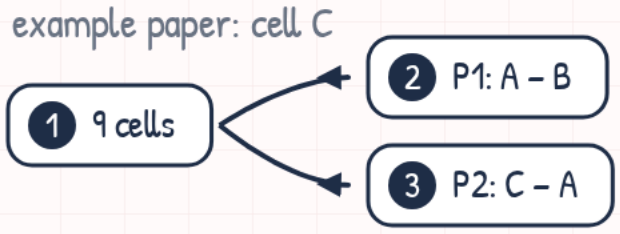
0.45 all · 0.33 target · 0.19 control (Stage 10 X2, 9,108 papers, §6.8)

Target > control in every bin

引用数。两组内部，标题特异信号都随引用档稳定上升：目标组从 0–2 档的 +0.35 升到 4097+ 档的 +0.64（Stage 10，真标题 − 5 个假标题平均，最终输出 L63，目标组各引用档均值：0-2 档 +0.347（200 篇）→ 4097+ 档 +0.644 [0.591, 0.701]（84 篇），论文 bootstrap 95% CI；报告 §6.8 图与表；351_stage10/summary_title/A_group_bin_layer.csv（readout=final）；351_stage10/summary_extra/X2_by_bin.csv）。与对数引用数的 Spearman 相关：全部 0.45（Stage 10 补充 X2，标题特异信号（真标题 − 5 个假标题平均，最终输出 L63）对 log10(引用数+1) 的 Spearman ρ，全部 9,108 篇 0.451 [0.433, 0.467]，bootstrap 95% CI；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv），目标组内 0.33，对照组内 0.19（同上 X2，组内 Spearman ρ：目标 4,621 篇 0.328，对照 2,220 篇 0.187；读出水平只有 0.181 / 0.084；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv）。读出水平本身变化小得多：有名论文的名字并不更好猜，只是模型更了解有名的论文。

Group comparisons

example paper: cell C



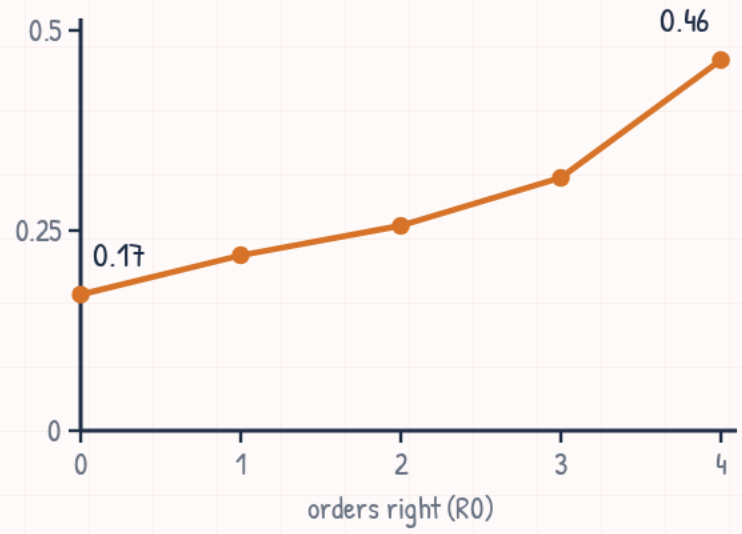


P1 +0.200 [0.188, 0.213]

P2 co-authors +0.061

first author +0.031 (ns)

4 dose: orders right



contrast = Σ w_b (mean_cell1 − mean_cell2)

title-specific signal, unwritten authors, output layer; team bootstrap

P1 +0.200 [0.188, 0.213]: A − B, 3,417 / 2,148 papers; P2 co-authors +0.061, first author +0.031: C − A; dose 0.17 → 0.46: R0 by orders right; 391_groups/primary.csv, stage10_curves.csv

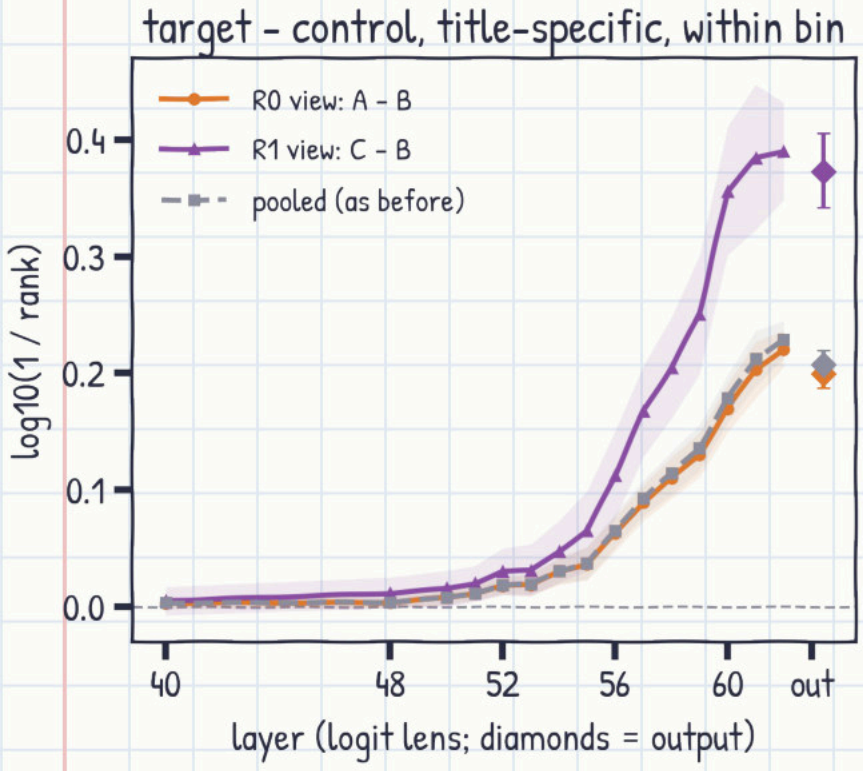
 新写讲稿

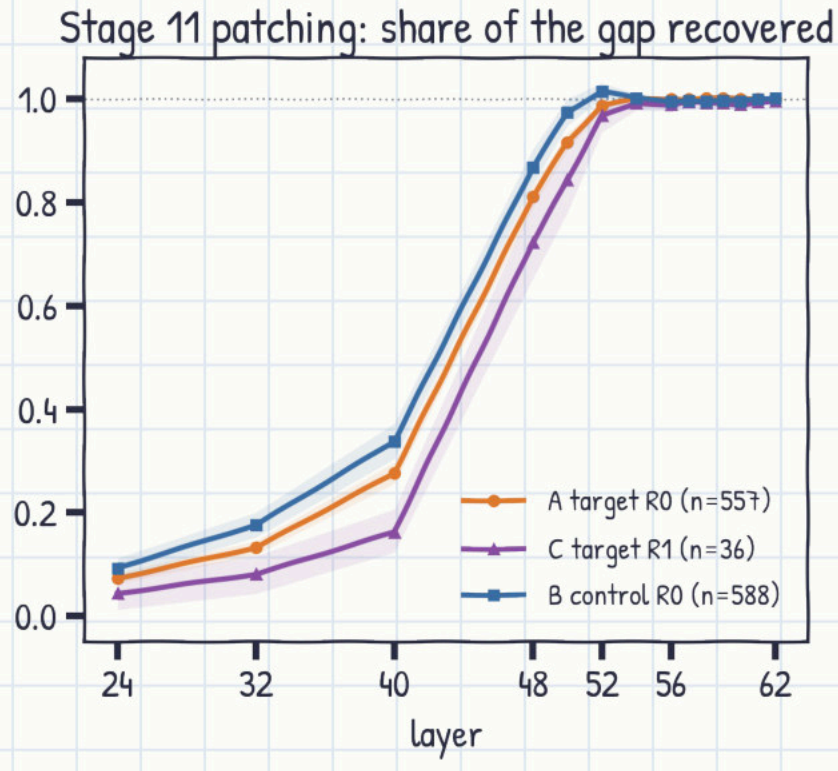
组间比较是答辩后新增的分析，计划预先写定（补充 7、8）。P1 比较 A 和 B（都是 R0，只差识别），输出层标题特异信号 +0.200 [0.188, 0.213]（分组对比 P1 A − B，未写出作者，最终输出 L63，A 3,417 / B 2,148 篇，引用档内差，团队聚类 95% CI；391_groups/primary.csv）；P2 比较 C 和 A，只看模型没写出的作者：合作者 +0.061 [0.034, 0.090]（P2-other C − A，C 390 / A 2,826 篇；primary.csv），第一作者 +0.031 [−0.006, 0.069]（P2-first C − A，C 292 / A 3,199 篇，Holm p 0.112；primary.csv），不显著。剂量曲线：R0 论文按多选答对的顺序数 0 到 4，信号从 0.17 升到 0.46（R0 未写出作者，0 种对 927 篇 0.170、4 种对 4,105 篇 0.463；391_groups/stage10_curves.csv）。所有对比都在引用档内加权，并按团队重抽样。

Stage 10–11

Is it just the R1 papers? No.

R0 = no true author written · R1 = a few written · A/B/C/D = target/control x R0/R1





R0 only (A – B):

output +0.199 vs +0.207, same shape (Stage 10, A 3,423 / B 2,151, §6.13)

R1 (C – B): +0.37, also late (C 391 / B 885)

C – A within target: +0.11, from L56 (C 485 / A 3,204)

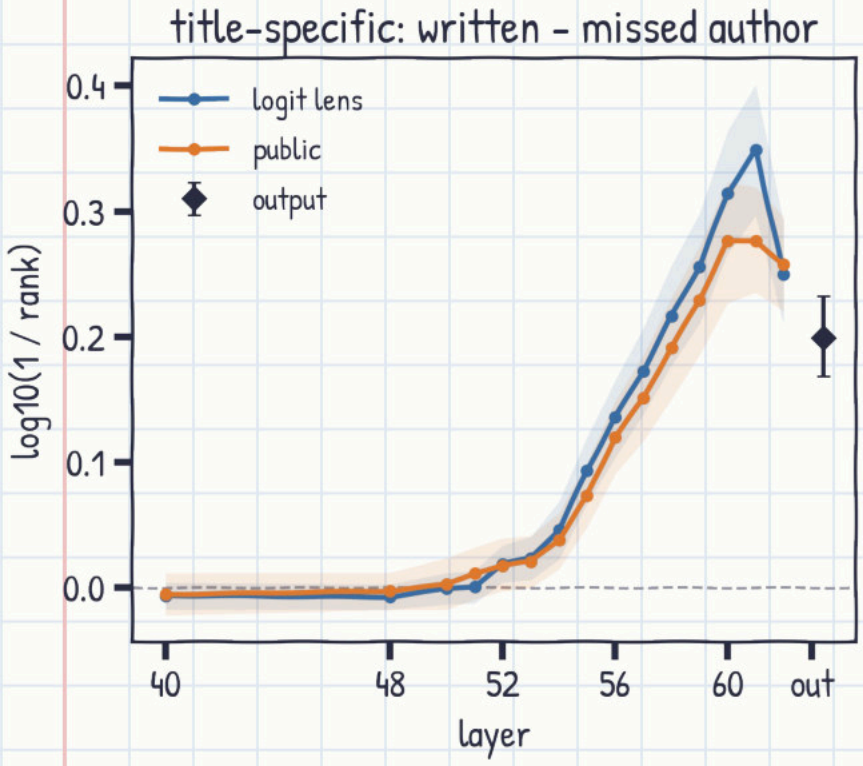
patching: R1 a bit later, done by L52 (Stage 11 E1, 36 R1 targets)

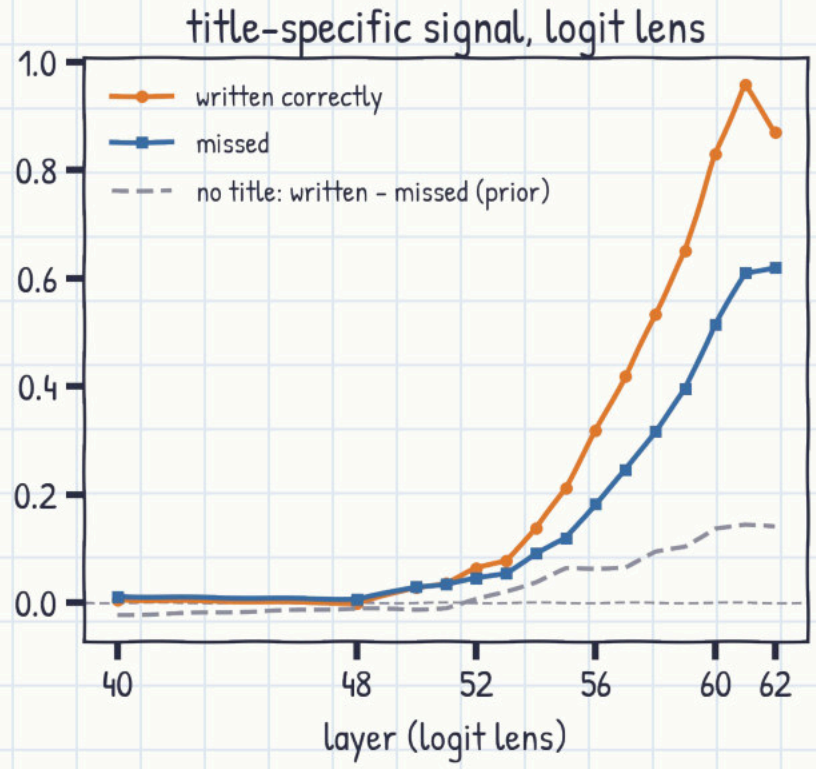
 按 deck 讲稿备注翻译（已按复核结果更新）

目标组的优势是不是只来自 R1 论文？目标组混合了 R0（开放回答一个真作者都没写对）和 R1（写对了一部分）；目标组里 11% 是 R1，对照组里只有 1.5%（目标组 R1 511 / 4,621 篇 = 11%，对照组 R1 34 / 2,220 篇 = 1.5%；351_stage10/reports/r0_sensitivity.md 第一张表；351_stage10/reports/r0_r1_analysis.md §0）。左图是三种口径下引用档内的目标–对照：只用 R0（A 对 B，即 Stage 1–9 的比较）输出处为 +0.199（Stage 10 只用 R0（A 对 B），真标题 – 5 个假标题平均，最终输出 L63，引用档内 目标–对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv），合并口径为 +0.207（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 – 5 个假标题平均，最终输出 L63，引用档内 目标–对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），曲线形状相同；R1 目标论文对 R0 对照为 +0.37（Stage 10，R1 目标（C）对 R0 对照（B），真标题 – 5 个假标题平均，最终输出 L63，引用档内，391 + 885 篇，+0.372 [0.342, 0.405]，论文 bootstrap 95% CI；351_stage10/reports/r0_r1_analysis.md §1；351_stage10/summary_r0r1/tc_R1target_vs_R0control.csv），它们更了解自己的论文，但同样要到 L52 之后才领先。对照组 R1 只有 34 篇（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表；D = 34），只做描述，不做检验。右图是按回忆程度分开的 Stage 11 替换曲线：R1 目标论文（36 篇）（Stage 11 样本中的 R1 目标论文 36 篇（对照 R1 5 篇）；351_stage10/reports/r0_r1_analysis.md §5；361_stage11/summary_r0r1/stage11_curves_by_recall.csv）恢复得稍晚，但到 L52 也全部恢复。标题位置的 probe 给出同样的结论：R0 口径为 +0.02 到 +0.04（Stage 11 E4b 原始版（论文分折、未剔除标题复用），标题最后一个 token 上的 probe，probe 只打分第一个名字 token，probe(真标题) – probe(false_0)，A – B 引用档内，A 4,110 / B 2,186 篇：L16 +0.018、L32 +0.034、L56 +0.038，bootstrap 95% CI 均在 0 以上；361_stage11/summary_r0r1/E4b_probe_by_recall.csv）（这是复核前按论文分折的数字）。结论不变。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Authors it wrote vs authors it missed

inside 495 R1 papers · paired within paper · 95% CI (Stage 10, r0_r1_analysis.md §4)





written − missed, output:
+0.20 (Stage 10, final L63, 495 papers)

~0 up to L52, grows from **L54**

no title (prior): +0.10 (same, no title)

same without first authors

第 29 / 82 页 · deck 第 20 页 按 deck 讲稿备注翻译（已按复核结果更新）

在 R1 论文内部，开放回答写对了一部分作者，漏掉了另一部分。标注包只记录了写对的人数，没有记录是哪几位，所以我们重建了匹配，重建出的人数在 99.3% 的 R1 论文里（重建匹配人数 = 标注包 m 的比例：R0 99.9%、R1 99.3%（596 篇）、R2 98.1%；351_stage10/reports/r0_r1_analysis.md §4；~/jlens_work/10_stage10/stage10_extra_r0r1.py）与标注包一致。在 495 篇同时有写对和漏掉作者的论文里（351_stage10/reports/r0_r1_analysis.md §4；351_stage10/summary_r0r1/R1_author_hits.csv），模型写对的作者在输出处的标题特异信号高 +0.20（Stage 10，R1 论文内 写对 − 没写对的作者（论文内配对），真标题 − 5 个假标题平均，最终输出 L63，495 篇，+0.199 [0.168, 0.232]，论文 bootstrap 95% CI；报告 R0/R1 节 §4 表；351_stage10/summary_r0r1/R1_author_written_minus_missed.csv），去掉第一作者后也一样。但这个差在 L52 之前约为 0（同上，logit lens L48 −0.007、L52 +0.019、L54 +0.046、L57–L61 +0.173 到 +0.349；351_stage10/summary_r0r1/R1_author_written_minus_missed.csv），从 L54 才开始上升：即使是模型真能写出来的作者，论文特有的信号也只在最后几层出现。另外，写对的作者在不给标题时也稍微好猜一些，高 +0.10（同上，不给标题（名字先验），最终输出 L63，写对 − 没写对 +0.097 [0.060, 0.134]，495 篇；351_stage10/summary_r0r1/R1_author_written_minus_missed.csv）。

Stages 1–9 · 20–200 papers

What we saw

- True title helps: pilot L56 +9.3 pp(7.3, 50 papers); 200 new papers +5.2 pp(8D RQ1, 200 papers)
- A–B uncertain in the pilot; +5.0 pp on 200 papers but gone after dropping 10 pairs(8D RQ2, 100 pairs)
- Low – high citation: inconclusive

Stages 10–11 · 9,108 papers

What scale showed

- Title-specific signal clear in every group, ≈0.44 at L62(L62, §6.9)
- target – control ≈0 at L24–L40, slightly negative at L48 (−0.04 to −0.05)(§6.4), +0.21 [0.20, 0.22] at the output(L63, §6.4)
- Name prior is only ~1/3 of the gap; ~0 on surnames(§6.12)
- Signal rises steadily with citations (ρ = 0.451)(§6.8)
- Same groups as the pilot (R0 only, A – B): +0.20 [0.19, 0.21] (R0, §6.13), same late shape
- R1 papers (C) know more (+0.11 over A)(§6.13) but are just as late

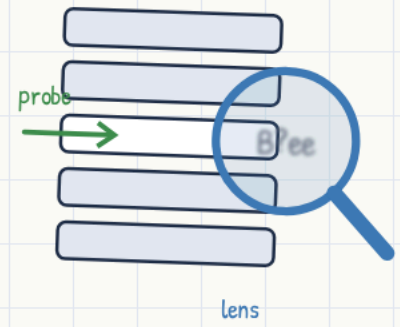
Line A: from "the title helps" to "this paper, late, graded by fame"

The pilot was right that the title matters. It could not see that the target advantage is real but confined to the last layers, so the 7-layer average and the L56 endpoint both diluted it. Restricting the full cohort to the pilot's A/B groups (R0 only) changes nothing: the R1 papers do not drive the result.

A 线的小结。小样本阶段看到：真标题有帮助，Pilot 在 L56 高 +9.3 个百分点（Stage 7.3，J-Lens L56，真标题胜率 − 20 个错误标题平均胜率，合并池，Pilot50 50 篇均值 +0.0934 [0.047, 0.139]（2026-10-30 重算区间，B = 20,000），35/50 篇为正；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv；报告 Stage 7.3 节），200 篇新论文上 +5.2（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节）；A–B 在 Pilot 中不确定，在 200 篇上是 +5.0（Stage 8D RQ2，J-Lens L56 匹配 A − B，100 对，+4.98 pp [0.32, 9.91]，配对 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ2_matched_A_minus_B）但去掉 10 对就消失（Stage 8D RQ2，J-Lens L56 金标准胜率匹配 A–B，100 对，均值 +4.98 pp，按 A–B 降序去掉前 10 对后其余 90 对均值 −0.39 pp（事后诊断）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）重算；报告 Stage 8D 节）；低引用减高引用没有定论。全量阶段看到：每组都有清楚的标题特异信号，L62 约 0.44（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 § 6.9 表；351_stage10/summary_extra/X3_means.csv）；目标–对照在 L24–L40 约为 0、L48 略为负（−0.037 到 −0.054，区间不含 0（Stage 10，引用档内目标–对照，三种 Jacobian lens L48 −0.037 到 −0.054；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）），输出处 +0.207 [0.20, 0.22]（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标–对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 § 6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）；名字先验只占差距的约三分之一（Stage 12 名字先验拆解（CPU），最终输出 L63，全部名字 token，引用档内 目标–对照（目标 4,621、对照 2,220 篇）：先验 +0.087 [0.070, 0.103] ÷ 真标题差 +0.247 = 0.35；报告 § 6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv），在姓上约为 0（同上，姓的第一个 token，先验 目标–对照 +0.022 [−0.019, +0.063]，论文特有 +0.423 [0.393, 0.454]；报告 § 6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）；信号随引用数稳定上升（ρ = 0.451）（Stage 10 补充 X2，标题特异信号（真标题 − 5 个假标题平均，最终输出 L63）对 log10(引用数+1) 的 Spearman ρ，全部 9,108 篇 0.451 [0.433, 0.467]，bootstrap 95% CI；报告 § 6.8 表；351_stage10/summary_extra/X2_spearman.csv）；只用和 Pilot 相同的 R0 分组（A − B）为 +0.20 [0.19, 0.21]（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标–对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 § 6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv），形状同样是后期才上升；R1 论文（C）比 A 多 +0.11（Stage 10，目标组内 R1 − R0（C − A），真标题 − 5 个假标题平均，最终输出 L63，引用档内（每格 ≥ 10 篇），C 485 + A 3,204 篇，+0.110 [0.086, 0.135]，论文 bootstrap 95% CI；351_stage10/summary_r0/target_R1_minus_R0_within_bin.csv；351_stage10/reports/r0_sensitivity.md），但时间点一样晚。小样本说对了标题重要，但没看出目标组的优势只在最后几层，所以 7 层平均（Stage 5–8 的积分终点 = 7 个源层平均（L63 不计入）；351_stage6/config/protocol.json "paper_integrated"；351_stage8/config/analysis_plan.json）和 L56 终点都把它稀释了。

Line B

What can each readout see?



small samples asked

Is J-Lens better than Vanilla? Is the fitted lens stable?

→

the full cohort answered

Lenses read name shape earlier, not paper identity; a probe at the title token reads paper-specific information

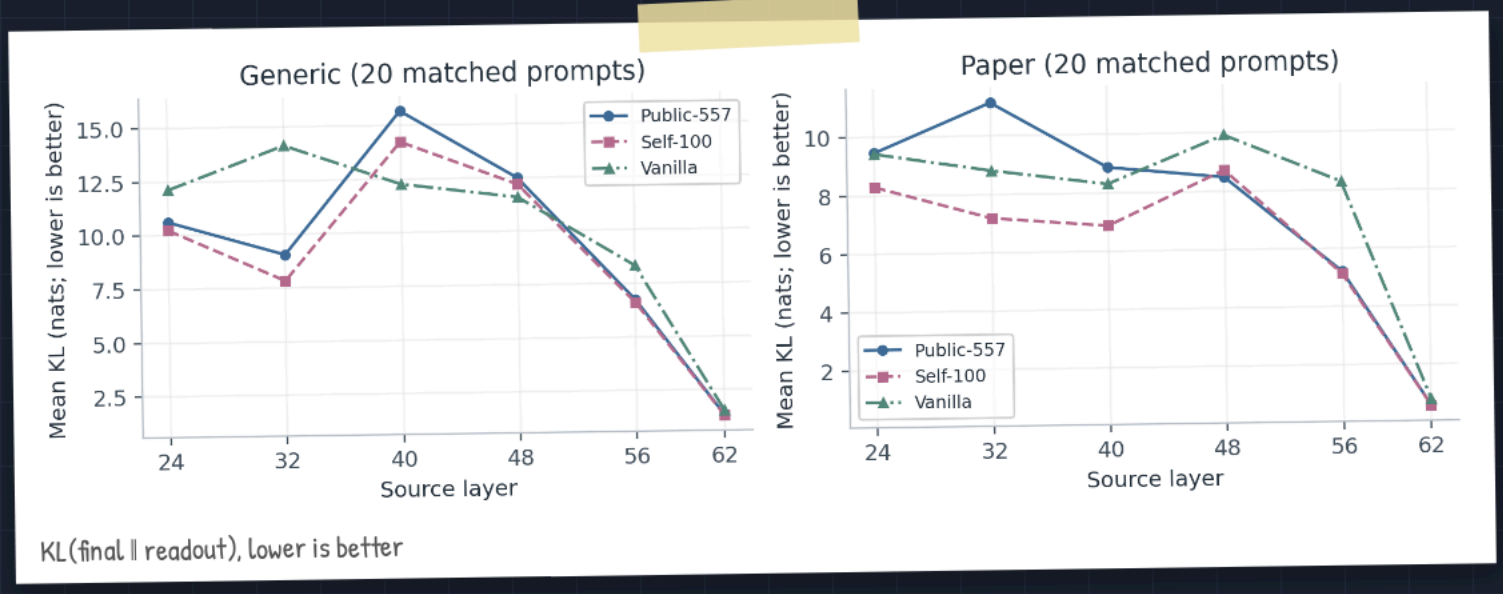
 新写讲稿

B 线的问题是：每种读出工具能看到什么？小样本阶段问的是 J-Lens 是否比 Vanilla 好，拟合出来的 lens 是否稳定。全量阶段的回答是：lens 在中间层更早读出的是“名字的样子”，而不是论文身份；而在标题 token 上训练的 probe 能读出论文特有的信息。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Stage 3 · Exp 1-4

Two lenses: Public-557 vs Self-100

Can a middle layer approximate the final next-token distribution? (20 generic + 20 paper prompts)



- Both checkpoints numerically valid (63/63 and 6/6 finite)(matrices.csv; frobenius_norms.csv)
- Self-100 has lower KL on 6/6 generic and 5/6 paper layers (paper L32: 11.1 → 7.2) (20 + 20 prompts; metrics.csv)
- But at paper L62, Self-100 KL beats Vanilla (0.58 vs 0.81) while Top-10 overlap is worse (0.36 vs 0.72)(metrics.csv)
- Author pilot: both lenses 14/20 full-name wins at L48(20 papers, layer_summary.csv)

Lesson: a better distribution match does not mean better author ranking.
Fidelity cannot stand in for the task.

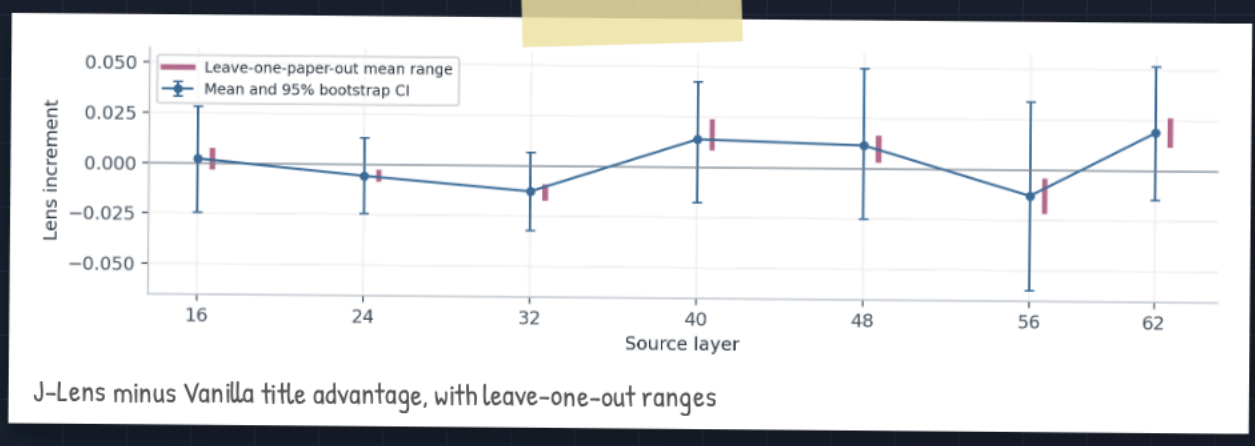
第 32 / 82 页 · Stage 3 · Exp 1–4 · 合并 PPT 自身页面 **新写讲稿**

Stage 3 比较两个 lens：公开的 Public-557 和我们自己拟合的 Self-100，问中间层能否近似最终的下一个 token 分布，用了 20 条通用提示和 20 条论文提示（Stage 3 Exp 2/4 提示集；~/jlens_work/02_self_lens_validation/351_self_jlens_validation.py:13-50）。两个检查点数值上都有效。Self-100 在 6 个通用层中的 6 层、6 个论文层中的 5 层（Stage 3 Exp 2/4，Self-100 − Public KL，各 20 条提示；351_self100_validation/summary/paired_bootstrap_ci.csv、summary/metrics.csv；报告 Stage 3 节图 3.1）KL 更低，例如论文提示 L32 从 11.1 降到 7.2（Stage 3，论文提示 20 条，L32 KL(final ‖ lens)：Public-557 11.135（351_all/351_paper_fidelity.log L32 jlens 行）→ Self-100 7.180（351_self100_validation/summary/metrics.csv paper/self100/32））。但在论文提示 L62，Self-100 的 KL 优于 Vanilla（0.58 对 0.81）（Stage 3，论文提示 20 条，L62 KL：Self-100 0.578、Vanilla 0.808；351_self100_validation/summary/metrics.csv（task=paper, layer=62, kl_final_to_lens_nats）），前 10 名重合度却更差（0.36 对 0.72）（同上，L62 前 10 名重合度：Self-100 0.355、Vanilla 0.720；351_self100_validation/summary/metrics.csv（top10_overlap））。作者小试中两个 lens 在 L48 都是 20 次里 14 次全名胜出（Stage 3 Exp 3，L48 全名胜率 0.70 × 20 篇，两个 lens 相同；351_self100_gold_false/archive/summary/layer_summary.csv 列 full_win_rate）。教训是：分布拟合得更好，不等于作者排名更好，保真度不能代替任务本身。

Stage 7.4 · Line B

Cross-stage audit: does J-Lens add value?

Read-only joins of Stages 5–7.3; 20,000 bootstrap draws



J-Lens minus Vanilla title advantage, with leave-one-out ranges

Stage 5 vs 7.3 at L56	r = 0.45, ρ = 0.47; signs agree 32/50 (50 papers, cross_stage_correlations.csv)
J-Lens − Vanilla	+0.002 [−0.008, +0.012]; median −0.002; 24/50 positive (jlens_increment_bootstrap.csv)
A−B of that increment	−0.014 [−0.033, +0.004] (20 pairs)

Dropping one paper can flip the sign of the J-Lens increment. The pilot shows **no added title-specific value** from J-Lens over Vanilla. Everything so far is exploratory: L56 was inspected repeatedly.

第 33 / 82 页 · Stage 7.4 · Line B · 合并 PPT 自身页面 **新写讲稿**

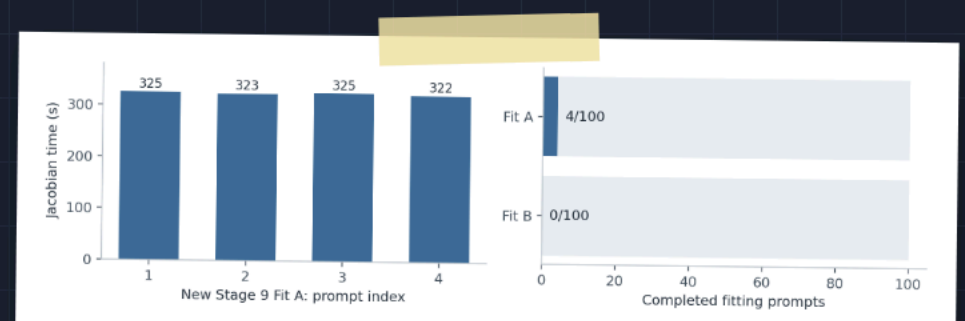
Stage 7.4 是跨阶段审计：J-Lens 到底有没有增加价值？只读地合并了 Stage 5 到 7.3 的结果，用 20,000 次 bootstrap（Stage 7.4 设计，种子 741；~/jlens_work/07_4_stage7_4/351_stage7_4.py:10-13）。Stage 5 和 7.3 在 L56 的相关为 r = 0.45，50 篇里 32 篇方向一致（Stage 7.4，J-Lens L56，Stage 5 与 Stage 7.3 的论文级相关，50 篇，Pearson 0.445，同号比例 0.64 = 32/50；351_stage7_4/summary/overview.json "L56_jlens_stage5_stage73"；351_stage7_4/summary/cross_stage_correlations.csv）。J-Lens 减 Vanilla 的标题优势为 +0.002 [−0.008, +0.012]，中位数 −0.002，50 篇里 24 篇为正（Stage 7.4，J-Lens − Vanilla 标题优势，7 层积分，50 篇，均值 +0.0022 [−0.0075, +0.0124]，中位数 −0.0019，24 篇为正，论文 bootstrap 95% CI；351_stage7_4/summary/jlens_increment_bootstrap.csv 行 integrated；overview.json）；这个增量的 A−B 为 −0.014（Stage 7.4，J-Lens 增量的匹配 A − B，20 对，−0.0139 [−0.0332, +0.0036]；351_stage7_4/summary/overview.json "matched_ab_difference_of_lens_increment"），区间含 0。去掉一篇论文就可能让 J-Lens 增量变号（Stage 7.4，逐一留出一篇后 7 层积分增量范围 −0.000046 到 +0.003494；351_stage7_4/summary/overview.json "integrated_jlens_minus_vanilla"）。Pilot 没有显示 J-Lens 比 Vanilla 多出任何标题特异的价值；而且到这里为止都是探索性的，L56 被反复看过。

Stage 9 · Line B

Stage 9: is the lens stable across fitting data?

New FullFit protocol, different from the historical 50+50 split

	Historical split-half	Stage 9 FullFit
Fit data	Self-100 split 50 + 50	two disjoint 100-prompt sets
Holdout	20 generic + 20 paper	independent 100 WikiText
Layers	6	7 (adds L16)
Status	complete	only Fit A completed; Fit B and holdout not run



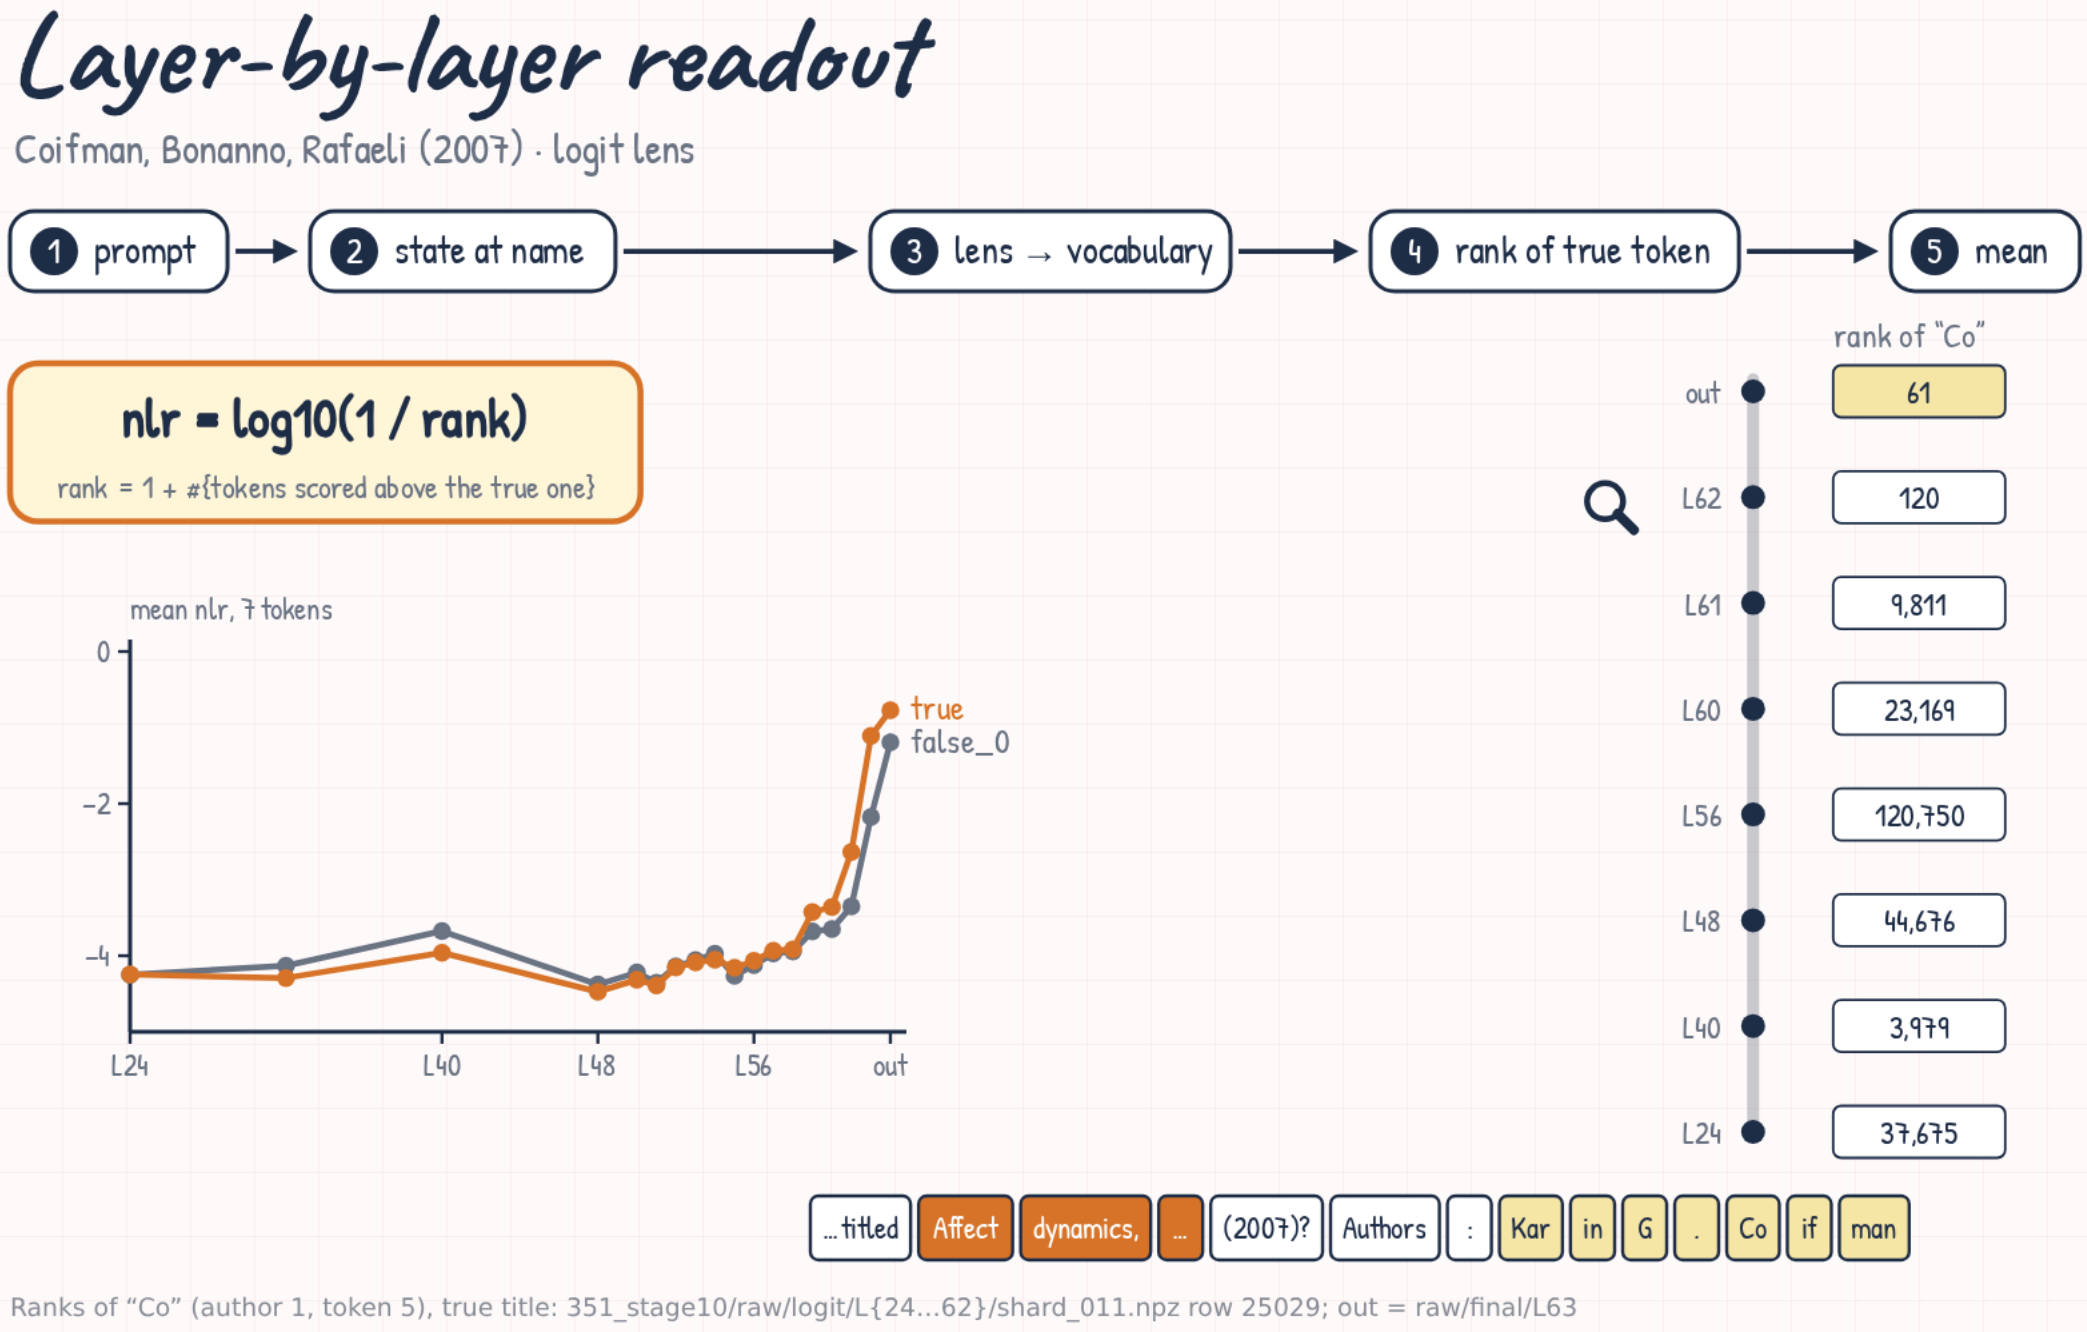
Archived progress: Fit A 4/100, Fit B 0/100 at the time of writing(351_stage9 checkpoints)

- WikiText-103 train, 100–1,200 chars, deduplicated by hash, seed 3519001
- ~324 s Jacobian time per prompt, ~62 GiB CPU RAM(full_A.log; benchmark log); per-prompt checkpoints

Only Fit A was finished, and Stage 10 used it as "fitA". Without Fit B and the holdout, fitting stability is **untested**.

 新写讲稿

Stage 9 想检验 lens 是否依赖拟合数据，用的是新的 FullFit 方案，和历史上的 50 + 50 拆分（Stage 3 Exp 7 历史拆分，偶数 / 奇数索引各 50 条；351_self100_split_half/fits/config_A.json、config_B.json）不同：两套互不重叠的 100 条提示，外加独立的 100 条 WikiText 留出集（Stage 9A.1 设计，FitA100 / FitB100 / Holdout100 各 100 条；351_stage9/config/plan.json、manifest.json "counts"；~/jlens_work/09_stage9/351_stage9.py:50-62），层数增加到 7 层（Stage 9 拟合层 L16–L62 共 7 层；351_stage9/runner_runs/full_A_100_7layers/fitting_config.json；351_stage10/config/lenses.json fitA）（加了 L16）。每条提示的 Jacobian 约需 324 秒、约 62 GiB CPU 内存（Stage 9 正式 Fit A 第 1–4 条每条 325/323/325/322 s（均值 323.75 s，351_stage9_full_A.log）；单条提示 7 层基准 CPU 内存峰值约 62.06 GiB（351_stage9_benchmark_A1_7layers.log）），每条存一次检查点。最后只完成了 Fit A，Stage 10 用的“fitA”就是它；Fit B 和留出比较都没做，所以 lens 的拟合稳定性还没有检验。



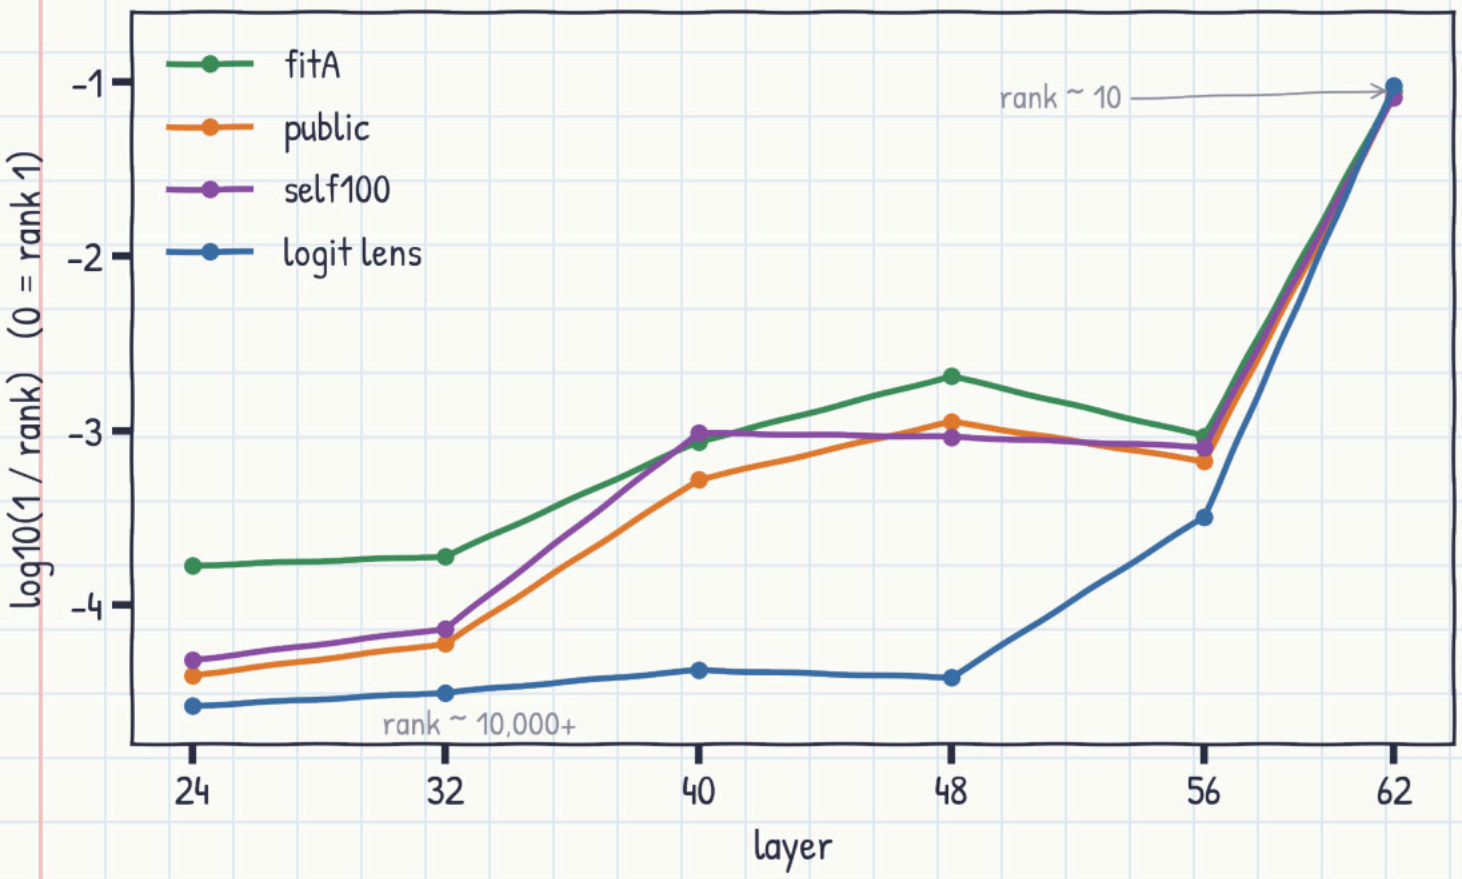
第 35 / 82 页 · Method · Layer-by-layer readout · 合并 PPT 自身页面 **新写讲稿**

逐层读出：在名字位置取每一层的隐藏状态，用 logit lens 映射到全词表，看真名字 token 的名次，再算 nlr = log10(1/名次)。示例论文第一作者姓的首个 token “Co”：L24 名次 37,675，L56 120,750，L61 9,811，L62 120，输出层 61（Stage 10，示例论文 Coifman 等（2007），真标题，第一作者姓的首个 token “Co”（行 25029），logit lens L24–L62 与最终输出 L63 全词表名次；351_stage10/raw/logit/L*/shard_011.npz、raw/final/L63/shard_011.npz；351_stage10/reports/method_figs/coifman_layer_ranks.csv（列 r5_Co））。第一作者 7 个 token 的平均 nlr 到 L58 都在 −4 左右，L62 升到 −1.11、输出层 −0.77（同上，第一作者 7 个 token（行 25025–25031）的平均 log10(1/名次)，logit lens：L24–L58 为 −4.47 到 −3.92，L62 −1.111，最终输出 −0.772；351_stage10/reports/method_figs/coifman_layer_ranks.csv 列 mean_log10_inv_rank）；假标题 false_0 在输出层是 −1.19（同上，false_0 条件，最终输出 L63，−1.194；351_stage10/raw/cond_false_0/final/L63/shard_011.npz；351_stage10/reports/method_figs/coifman_layer_ranks.csv（condition=false_0, readout=final）），真假之差只在最后几层出现。

Stage 10

Names become readable late

all 9,108 papers · true title (Stage 10 cohort, §6.1)



Logit lens: almost nothing until **L48**

Jacobian lenses read more from **L40**

Everything jumps at **L62** (rank ~10) (Stage 10, logit L62 −0.93, §6.1)

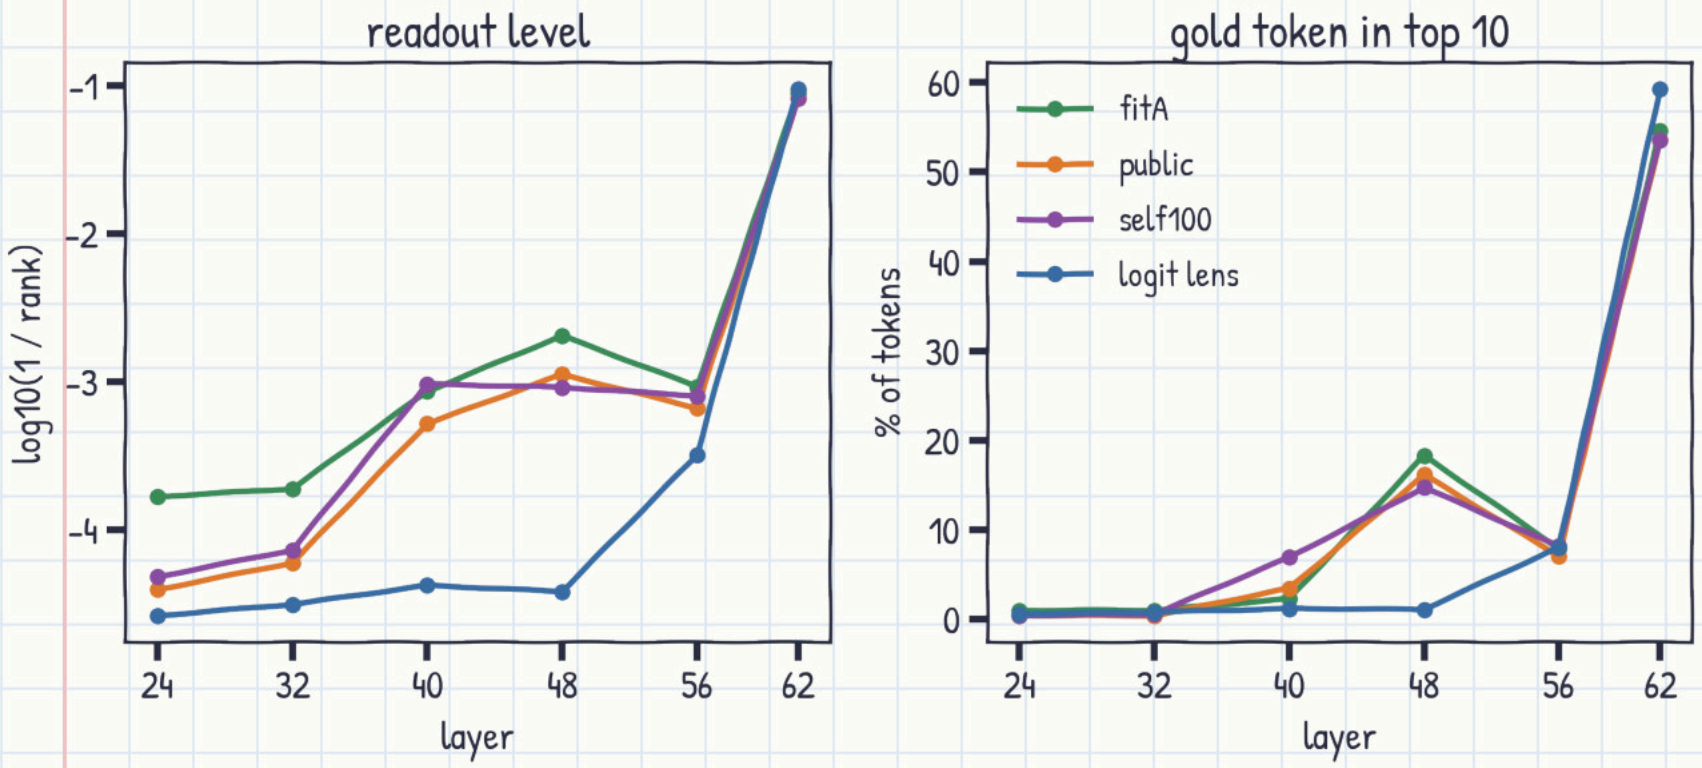
 按 deck 讲稿备注翻译（已按复核结果更新）

所有读出方式都随层数加深而变好。logit lens 在 L48 之前几乎读不出东西（名次在几万名（Stage 10，真标题，logit lens L24–L48，目标 4,621 + 对照 2,220 篇，平均 log10(1/名次) 约 −4.4 到 −4.6；报告 §6.1 表；351_stage10/summary/A_group_layer.csv）），到 L62 才跳上来。Jacobian lens 从 L40 起读出更多，fitA 最多。模型真实输出最好。

Stage 10

Which lens reads best?

all papers · true title



Middle layers:

fitA best; at L48 15–18% top-10 vs 1% for logit

(Stage 10 X3, 9,108 papers, §6.9)

L62: logit lens best (59%)

(same, L62)

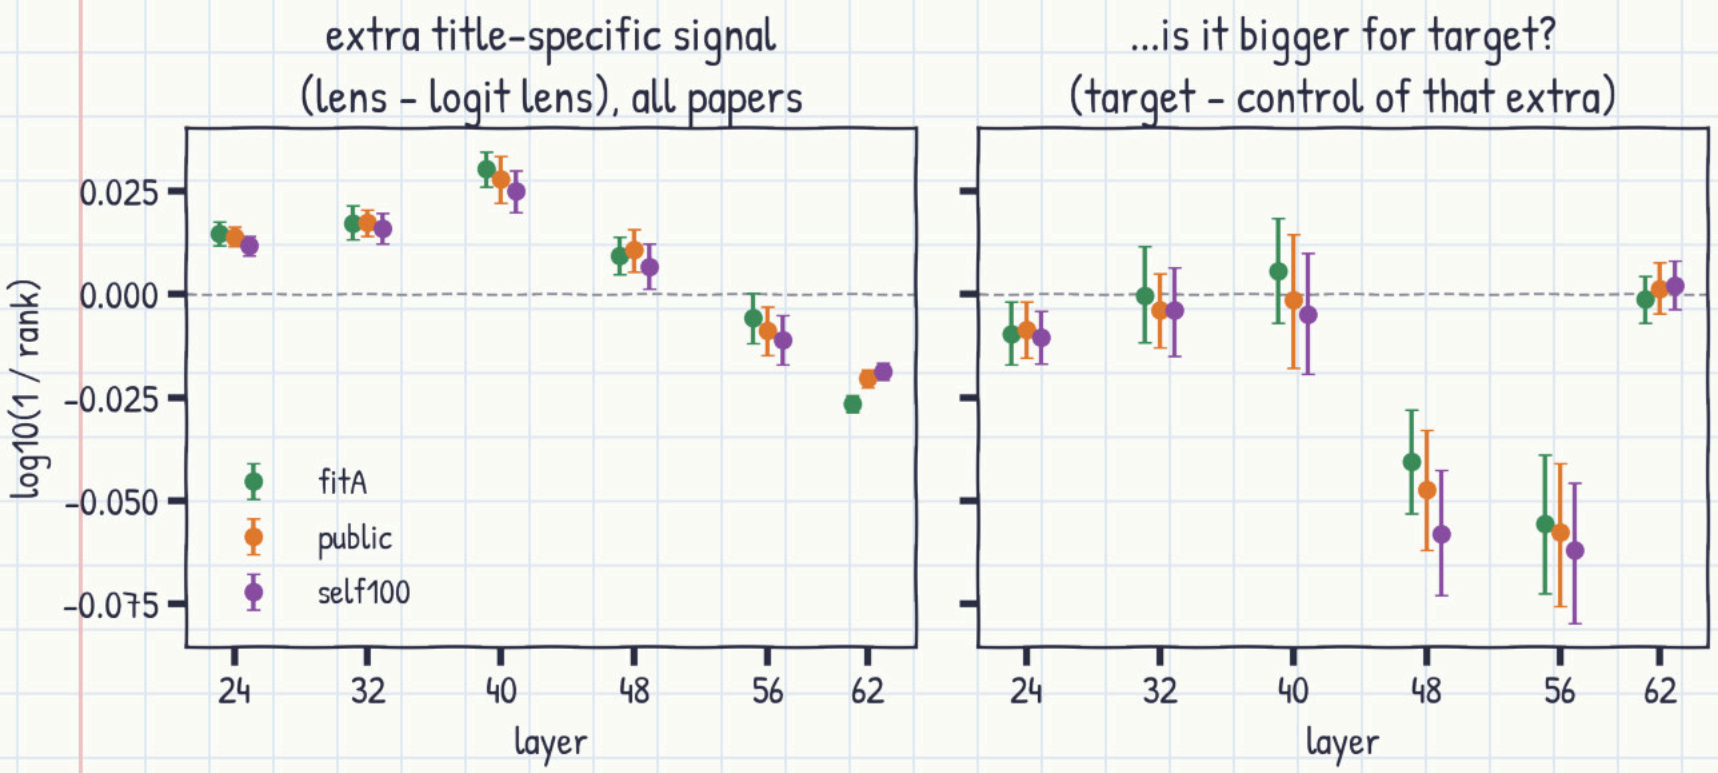
第 37 / 82 页 · deck 第 22 页 按 deck 讲稿备注翻译（已按复核结果更新）

比较各种 lens。读出质量上，中间多数层 fitA 最好，L40 是 self100；在 L48，Jacobian lens 能把正确 token 放进前 10 名的比例是 15–18%，logit lens 只有 1%（Stage 10 X3，真标题，全部 9,108 篇，同一批 token 配对，L48 前 10 命中率（token 比例）：三种 Jacobian lens 14.7%–18%，logit lens 1.1%；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）。到 L62，最朴素的 logit lens 反而最好。

Stage 10

Do lenses reveal hidden paper knowledge?

paired differences, 95% CI



Extra signal: **+0.01 to +0.03** (Stage 10 X3, L24–L48, 9,108 papers, §6.9)

vs ~0.44 at L62 (same, L62)

Not bigger for target
(even negative at L48–56)

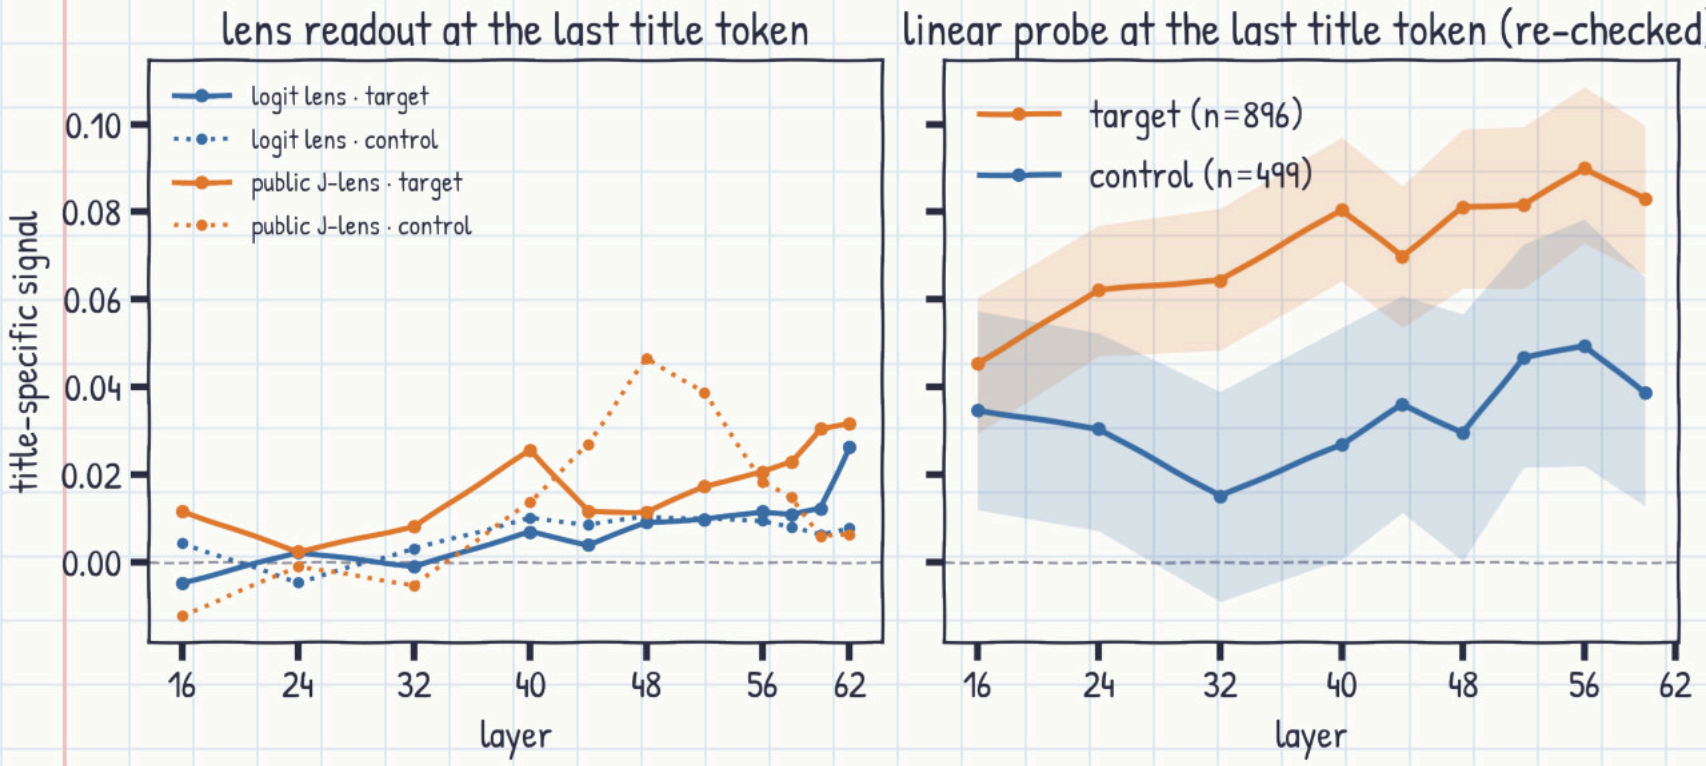
 按 deck 讲稿备注翻译（已按复核结果更新）

Jacobian lens 能不能看到 logit lens 漏掉的、论文特有的信息？只能看到一点：在 L24–L48 多出 +0.01 到 +0.03 的标题特异信号（Stage 10 补充 X3，三种 Jacobian lens 减 logit lens 的标题特异信号（真标题 − 5 个假标题平均），L24–L48，全部 9,108 篇，+0.007 到 +0.030，论文 bootstrap 95% CI 均在 0 以上；报告 §6.9 表；351_stage10/summary_extra/X3_pairwise.csv），区间在 0 以上，但和 L62 的 0.44 相比（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）非常小。而且这部分对目标组并不更大：多出部分的目标−对照约为 0，在 L48 和 L56 甚至为负（Stage 10 X3，(lens − logit) 标题特异信号的引用档内 目标−对照，三种 Jacobian lens：L24–L40 约 0，L48 与 L56 为 −0.04 到 −0.06，论文 bootstrap 95% CI；报告 §6.9 最后一表；351_stage10/summary_extra/X3_tc_spec_vs_logit.csv）。

Stage 11

Read early: a probe finds it at the title

title-specific signal at the last title token · lenses: all 9,108 papers · probe: re-checked, title reuse removed: 1,863 papers (896 target, 499 control) (Stage 11 E4; Stage 13 E4b)



lenses: **~0.01–0.03** (Stage 11 E4, 4,621 + 2,220, §6.11)

probe: **0.05 -> 0.08** (Stage 13 E4b, 1,863 papers, first name token only)

target > control by **+0.03–0.08** (E4b, 896 vs 499, within bin)

re-checked: team folds, title reuse removed

scores the first name token only (mostly an initial); subtracts false_0 only

read early (title, from L24), **spoken late** (names, L57–61)

Probe scores only the first name token (mostly an initial); all-token, by-role version (addendum 9, done): surname first token L40 +0.071 [0.058, 0.085] (1,395 papers; e4b_alltok.md).

在标题本身的位置上能读出作者吗？用 lens，几乎读不出：标题最后一个 token 上的标题特异信号只有约 0.01 到 0.03（Stage 11 E4，标题最后一个 token，logit lens 与 public J-lens 读第一个名字 token，真标题 − 5 个假标题平均，全部 9,108 篇，约 0.01–0.03；报告 §6.11 标题位置表；361_stage11/summary/E4_titlepos_lens.csv）。换成跨论文训练的线性 probe 能读出更多：按作者团队分折、并剔除 probe 训练时见过同一标题的论文后复核（剩 1,863 篇，其中目标 896、对照 499（Stage 13 E4b 复核样本，按作者团队分折并剔除 probe 训练时见过同一标题的论文后剩 1,863 篇（目标 896、对照 499、excluded 433、guard 35）；381_stage13/reports/e4b_split_compare.md；381_stage13/summary_cpu_trainstd/E4b_4configs.csv）），L24 约 0.05，到 L56 升到约 0.08（Stage 13 E4b 复核，标题最后一个 token 上的线性 probe，probe 只打分每位作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，全部 1,863 篇：L24 +0.050、L40 +0.061、L56 +0.075（L24–L60 为 +0.047 到 +0.075），论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第一张表），目标组比对照组高 0.03 到 0.08（同上 E4b 复核，probe 只打分第一个名字 token，引用档内目标–对照，目标 896、对照 499 篇，L24–L60 为 +0.035（L44）到 +0.078，论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第二张表）。附录里的对照说明这个 probe 信号是这篇论文特有的，不是主题和名字的关联。它和 lens 的结果不矛盾：标题在标题位置就被读进去了，但名字要到 L57–L61 才在名字位置变得可读。一句话：读得早，说得晚。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Stages 1–9 · 20–200 papers

What we saw

- Self-100 fits the final distribution better; author ranking not better
- J-Lens − Vanilla ≈0 (7.4: +0.002; Stage 8: −1.4 pp)(50 / 200 papers)
- Stage 9: only Fit A fitted, stability not tested

Stages 10–11 · 9,108 papers

What scale showed

- Jacobian lenses: top-10 rate 15–18% at L48 vs 1% for logit lens(9,108 papers; X3_means.csv)
- Extra title-specific signal only +0.01–0.03(L24–L48; X3_means.csv), not target-specific
- At L62 the plain logit lens is best
- Linear probe at the title token: +0.05 → +0.08 (re-checked) (E4b, scores only the first name token; e4b_trainstd_compare.md), paper-specific

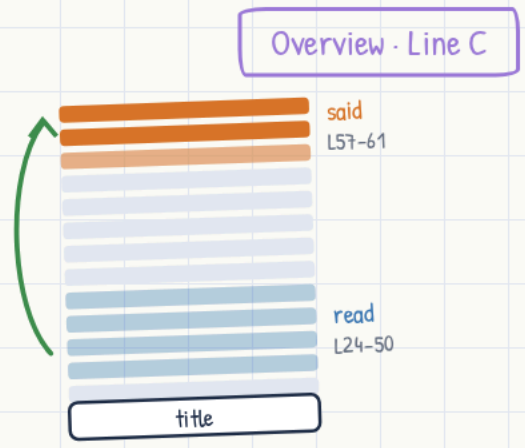
Line B: the information is there, but not in a form the lenses read

Both phases agree: no lens reveals hidden paper knowledge in middle layers. Scale adds the positive side: a trained probe can decode it at the title, so the limit is the readout, not the absence of information.

B 线的小结。小样本阶段看到：Self-100 更贴近最终分布，但作者排名没有更好；J-Lens 减 Vanilla 约为 0（7.4 为 +0.002（Stage 7.4，J-Lens − Vanilla 标题优势，7 层积分，50 篇，+0.002 [−0.008, +0.012]；351_stage7_4/summary/jlens_increment_bootstrap.csv 行 integrated），Stage 8 为 −1.4 个百分点（Stage 8D，L56 J-Lens − Vanilla 标题优势，200 篇，−1.38 pp [−3.48, +0.68]；351_stage8/stage8D/summary/jlens_minus_vanilla.csv））；Stage 9 只拟合了 Fit A，稳定性没有检验。全量阶段看到：Jacobian lens 在 L48 的前 10 名比例为 15–18%，logit lens 为 1%（Stage 10 X3，真标题，全部 9,108 篇，L48 前 10 命中率：三种 Jacobian lens 14.7%–18%，logit lens 1.1%；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）；多出的标题特异信号只有 +0.01 到 0.03（Stage 10 补充 X3，三种 Jacobian lens 减 logit lens 的标题特异信号（真标题 − 5 个假标题平均），L24–L48，全部 9,108 篇，+0.007 到 +0.030，论文 bootstrap 95% CI 均在 0 以上；报告 §6.9 表；351_stage10/summary_extra/X3_pairwise.csv），而且不偏向目标组；L62 时朴素的 logit lens 最好；标题 token 上的线性 probe 从 +0.04 升到 +0.08（Stage 11 E4b 原始版（论文分折、未剔除标题复用），标题最后一个 token 上的 probe，probe 只打分第一个名字 token，真标题 − false_0，目标组 L16 +0.043 到 L52–L56 +0.080/+0.082；论文 bootstrap 95% CI；报告 §6.11 标题位置表 probe 行；361_stage11/summary/E4_probe.csv 列 spec_target），而且是论文特有的。（页面上 +0.04 到 +0.08 是复核前的数字（Stage 11 E4b 原始版（论文分折、未剔除标题复用），标题最后一个 token 上的 probe，probe 只打分第一个名字 token，真标题 − false_0，目标组 L16 +0.043 到 L52–L56 +0.080/+0.082；论文 bootstrap 95% CI；报告 §6.11 标题位置表 probe 行；361_stage11/summary/E4_probe.csv 列 spec_target），复核后为 +0.05 到 +0.08（Stage 13 E4b 复核，标题最后一个 token 上的线性 probe，probe 只打分每位作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，全部 1,863 篇：L24 +0.050、L40 +0.061、L56 +0.075（L24–L60 为 +0.047 到 +0.075），论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第一张表），结论不变。）两个阶段一致：没有哪种 lens 能在中间层看出隐藏的论文知识；全量阶段补上了正面的一面：训练过的 probe 能在标题位置解码出来，所以限制在读出工具，而不是信息不存在。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Line C

When does it appear, and when is it used?



small samples asked

Which layer peaks? (L56 kept standing out)

→

the full cohort answered

Readable late (L57–61) but read from the title early (L24–50)

 新写讲稿

C 线的问题是：信号在哪一层出现，又在哪一层被用到？小样本阶段问的是哪一层最高，L56 总是很突出。全量阶段的回答是：名字要到 L57–L61 才变得可读，但标题信息在 L24–L50 就已经被读取了。