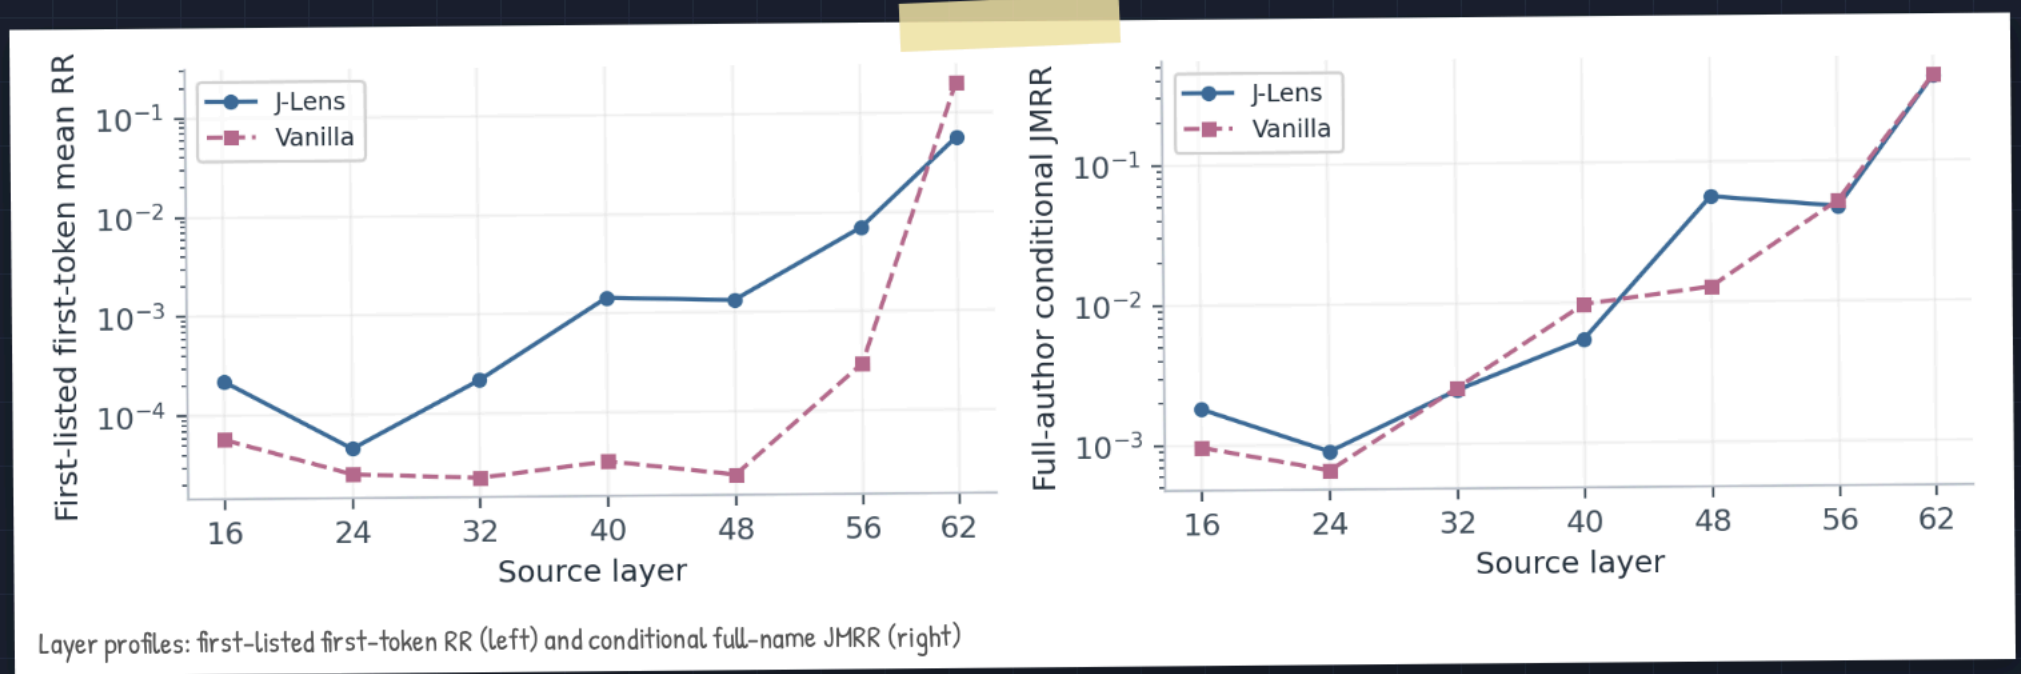
Stage 4

First readout: is any author signal there?

20 papers, 93 authors (A8 / B8 / C3 / D1); ~91 s per paper, ~29.5 GiB GPU(351_stage4_readout.log)



Layer profiles: first-listed first-token RR (left) and conditional full-name JMRR (right)

- The pipeline works and J-Lens rises above Vanilla in middle layers
- L56 first-author mean RR 0.0070, median only 0.0009(20 papers; audit_report.md table 1)

One paper = 71% of the L56 mean

Dropping it: 0.0070 → 0.0021.(same file) A layer peak can be a single easy paper, so every later stage adds controls.

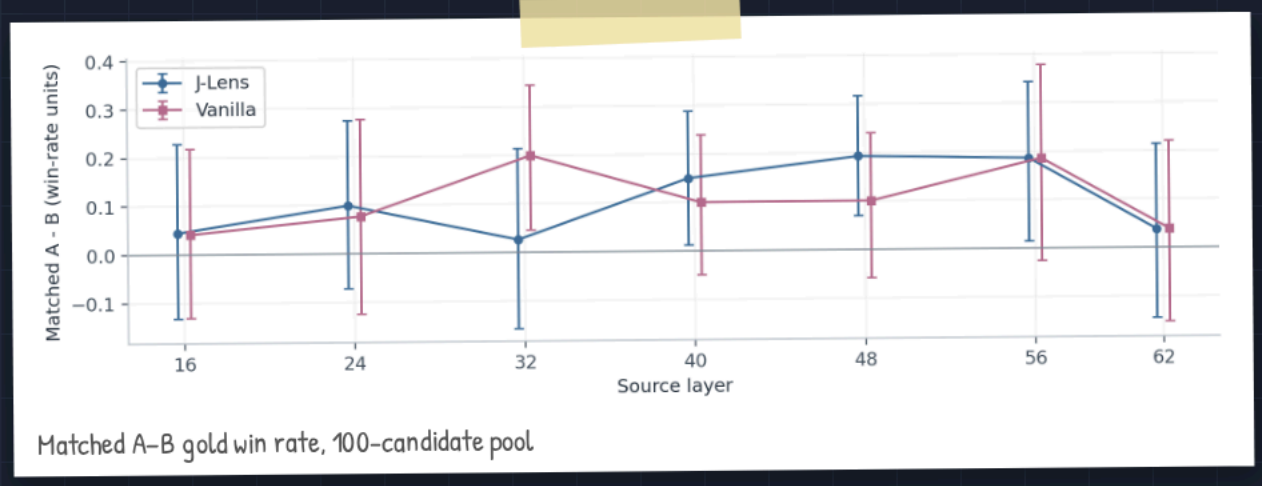
第 42 / 82 页 · Stage 4 · 合并 PPT 自身页面 **新写讲稿**

Stage 4 是第一次读出：作者信号到底在不在？用了 20 篇论文、93 位作者，A 8 篇、B 8 篇、C 3 篇、D 1 篇，每篇约 91 秒、约 29.5 GiB 显存（Stage 4 Benchmark20；351_all/351_stage4_readout.log "STAGE 4 BENCHMARK ===== 20 papers"、authors_scored 93、"Mean seconds per paper 90.68"、gpu=29.5GiB；报告 Stage 4 节表）。流程能跑通，J-Lens 在中间层高于 Vanilla。但 L56 第一作者的平均倒数名次是 0.0070，中位数只有 0.0009；一篇论文就占了 L56 均值的 71%，去掉它均值降到 0.0021（Stage 4，J-Lens L56，第一作者首 token 倒数名次，20 篇：均值 0.00704，中位数 0.00092，最大单篇占总和 71.03%，去掉后均值 0.00215；351_all/351_stage4_artifacts/audit/audit_report.md 表 1 行 L56）。层的峰值可能只是一篇特别好猜的论文，所以之后每个阶段都加了对照。

Stage 7.2 · Line A

Gold vs 100 real false authors

50 matched (same field, token count, year) + 50 random names per paper; 75,000 scored pairs(candidate_pairwise_scores.csv)

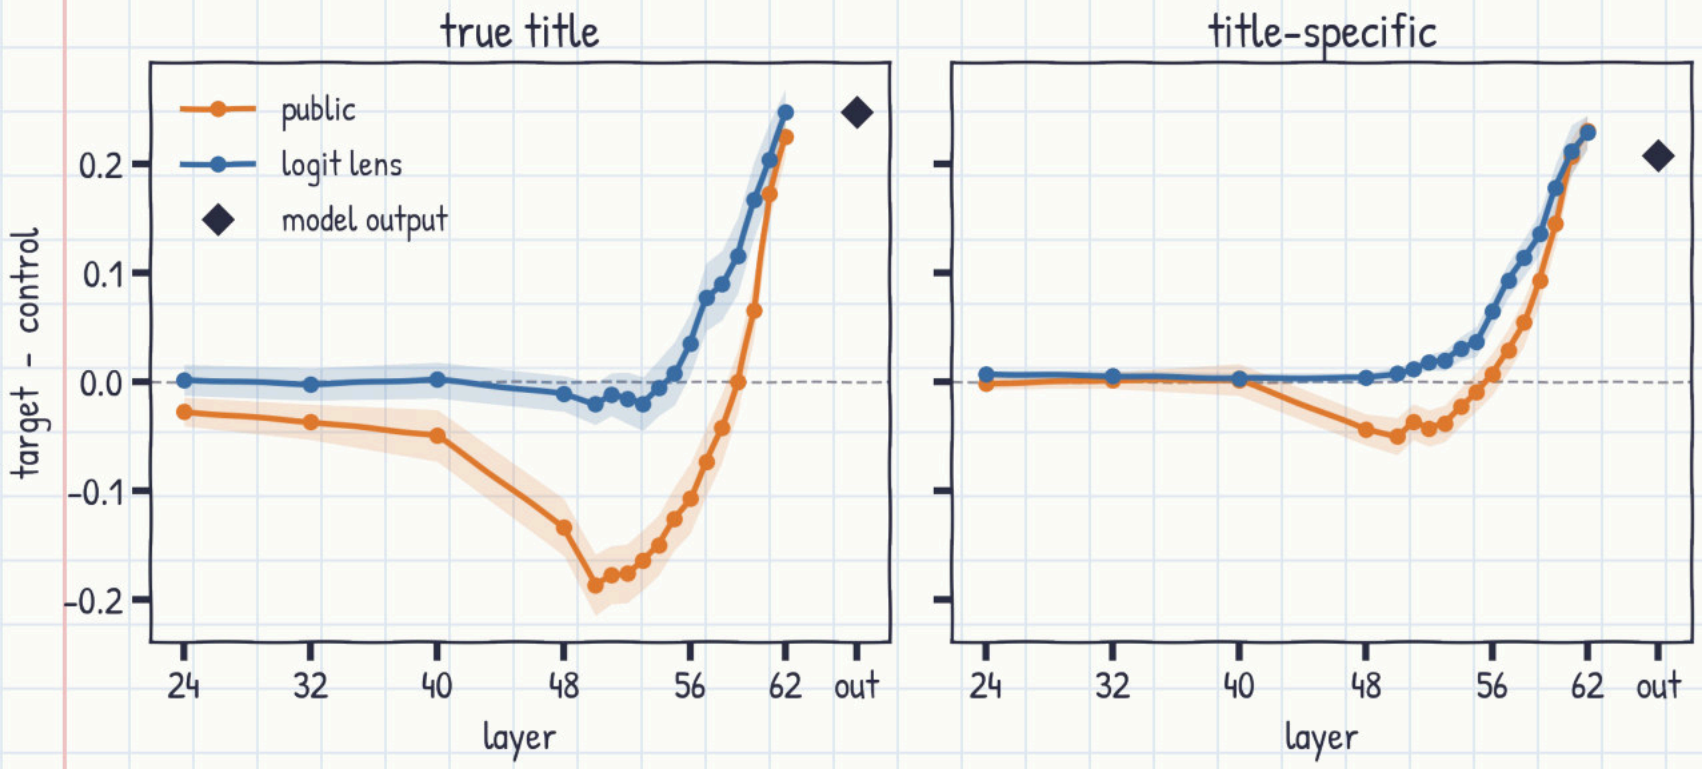


Matched A–B gold win rate, 100-candidate pool

- J-Lens A–B: L40 +0.15, L48 +0.19, L56 +0.19 (CIs above 0); L62 +0.04 (spans 0)(20 pairs, matched_ab_bootstrap.csv)
- 7-layer integrated: +0.105 [−0.012, +0.229](20 pairs; recomputed 10-30)
- 156/5,000 false names share the gold first token (ties) (quality.json)
- 100 names → only ~46 distinct first tokens(mean of 50 papers; candidates csv)

Gold beats real names in middle layers for A more than B. But the same names might win under any title: 7.3 tests that.

Stage 7.2 把正确名字和 100 个真实的错误作者比较：每篇论文 50 个匹配名字（同领域、同 token 数、同年份）加 50 个随机名字，共 75,000 对（Stage 7.2 设计，Pilot50 50 篇 × 100 个错误作者 × 15 种读出 = 75,000；~/jlens_work/07_2_stage7_2/351_stage7_2.py:62-111；351_stage7_2/summary/quality.json；351_stage7_2/summary/candidate_pairwise_scores.csv）。J-Lens 下的 A–B 胜率：L40 +0.15，L48 +0.19，L56 +0.19，区间都在 0 以上；L62 为 +0.04，区间含 0（Stage 7.2，真标题，首 token 金标准胜率，J-Lens，合并池，Pilot50 20 对 A − B，配对 bootstrap 95% CI：L40 +0.150 [0.013, 0.289]、L48 +0.193 [0.071, 0.318]、L56 +0.187 [0.015, 0.345]、L62 +0.038 [−0.144, +0.215]；报告 Stage 7.2 节图 7.2；351_stage7_2/summary/matched_ab_bootstrap.csv）；7 层积分 +0.105 [−0.012, +0.228]（Stage 7.2，7 层积分，J-Lens，合并池，20 对 A − B，配对 bootstrap 95% CI（2026-10-30 按逐对数据重算）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv 行 "7.2 integrated7 A-B jlens pool=combined"）。需要注意 5,000 个错误名字里有 156 个与正确名字共享第一个 token，100 个名字只有约 46 个不同的第一个 token（Stage 7.2，Pilot50 每篇 100 个错误名字（50 匹配 + 50 随机），共 5,000 个；每篇平均 45.76 个不同首 token（方法手册 C 部分由 351_stage7_2/candidates/pilot50_author_candidates.csv 统计）；156 / 5,000 = 3.1% 与金标准首 token 相同记为平局（351_stage7_2/summary/quality.json））。中间层里 A 比 B 更常胜出，但同样的名字可能在任何标题下都胜出，这要由 7.3 来检验。

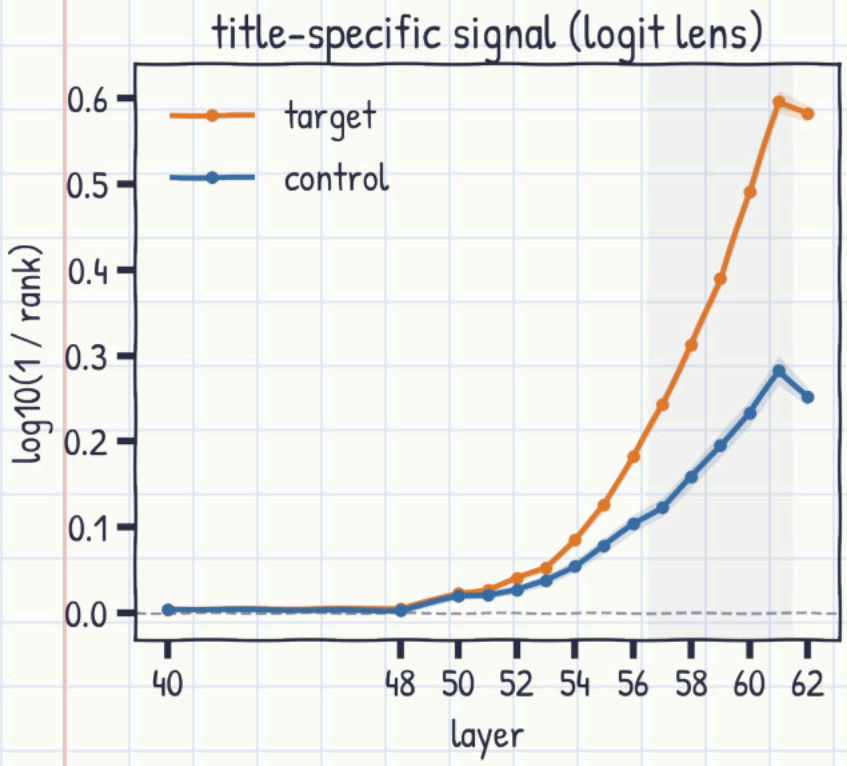


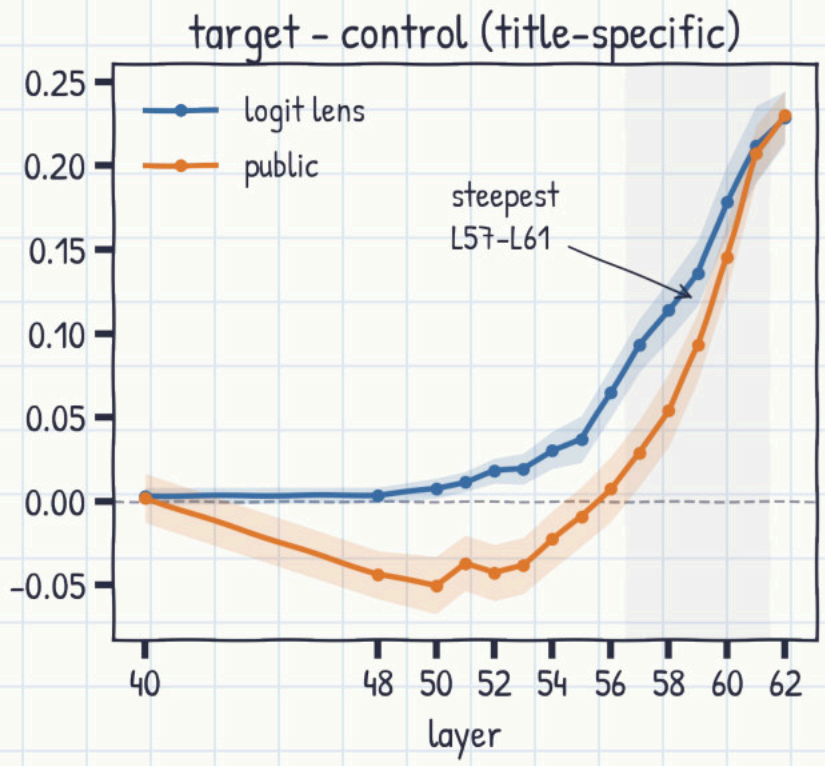
这是关键的一页：在引用档内看目标组减对照组。左边只看真标题，中间层对 Jacobian lens 甚至略为负。右边看标题特异部分：L56 之前约为 0，在 L62 和输出处为 +0.207 到 +0.231（Stage 10，真标题 − 5 个假标题平均，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），L62 四种读出 +0.228 到 +0.231，最终输出 L63 +0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）。稳健性：目标组 11% 是 R1（写对少数作者），对照组只有 1.5%（目标组 R1 511 / 4,621 篇 = 11%，对照组 R1 34 / 2,220 篇 = 1.5%；351_stage10/reports/r0_sensitivity.md 第一张表；351_stage10/reports/r0_r1_analysis.md §0）；两组都只保留 R0 时，输出处的差是 +0.199（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv）而不是 +0.207（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），各层形状相同，Stage 11 的曲线也不变。目标组的优势出现得很晚，而且几乎全部是标题特异的。

Stage 10

It builds up over the last dozen layers

fine layers L40–L62 · title-specific signal · 95% CI





Logit lens: target − control

+0.007 at L50

+0.23 at L62 (Stage 10 logit lens, 3,734 + 2,182 papers, §6.10)

steepest rise **L57–L61**

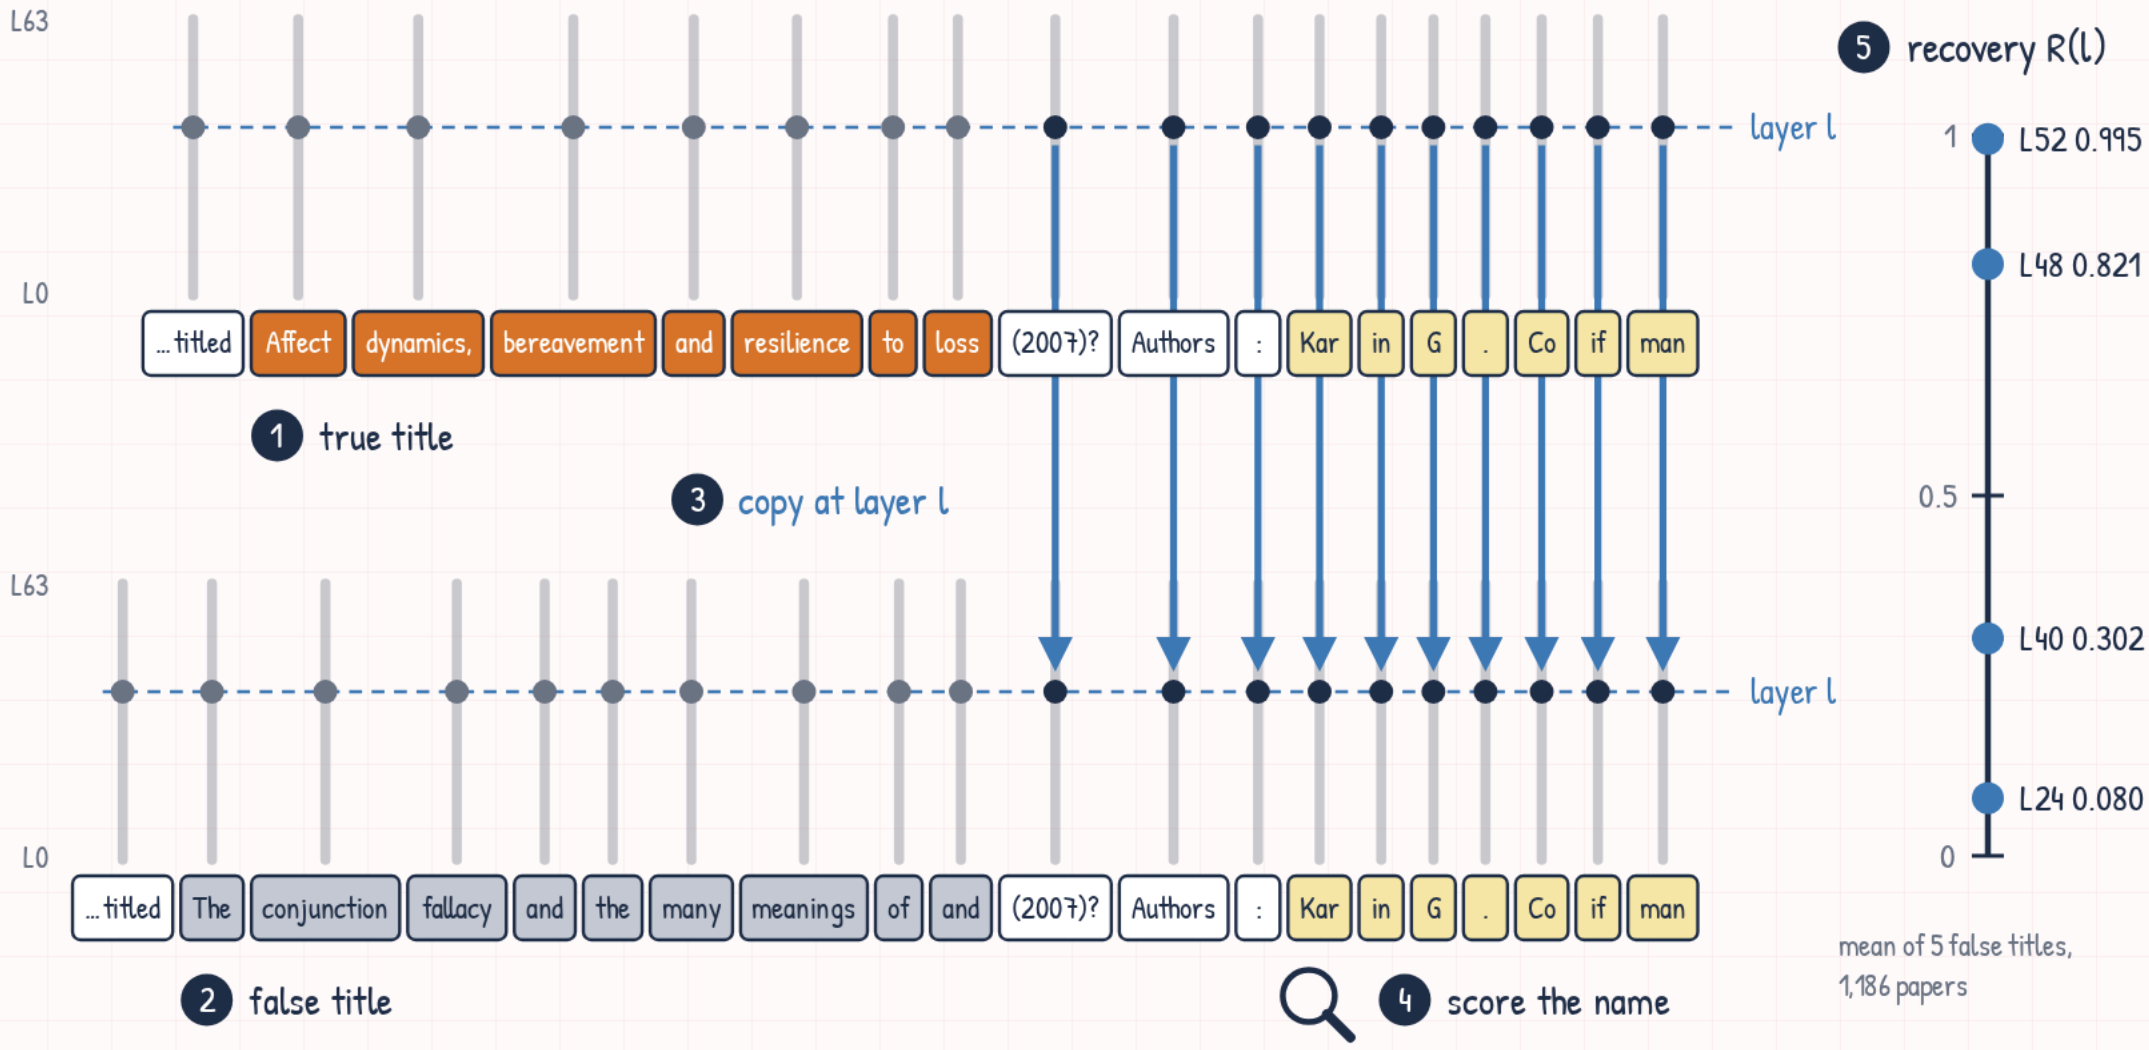
第 45 / 82 页 · deck 第 8 页 按 deck 讲稿备注翻译（已按复核结果更新）

细层 L50 到 L61 是后来为 logit lens 和公开 lens 补算的。目标组的优势不是在 L62 突然出现的：logit lens 下，标题特异的目标−对照在 L50 为 +0.007，L54 为 +0.03，L56 为 +0.07，L58 为 +0.11，L60 为 +0.18，L62 为 +0.23（Stage 10 主轮 + 细层扩展，真标题 − 5 个假标题平均，logit lens，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇）：L50 +0.007 [0.001, 0.014]、L52 +0.018、L54 +0.030、L56 +0.065、L58 +0.114、L60 +0.178、L62 +0.229，论文 bootstrap 95% CI；报告 §6.10 图与表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）。公开 lens 到 L54 为负，L57 转正（同上，public J-lens：L48–L54 为 −0.02 到 −0.05，L57 起转正 +0.029 [0.009, 0.048]，L61 +0.207；报告 §6.10 图与表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）。上升最快的是 L57 到 L61，两组都在 L61 达到最高（Stage 10，真标题 − 5 个假标题平均，logit lens 各组均值：目标 L50 +0.022 → L61 +0.596，对照 +0.020 → +0.282（L62 为 +0.583 / +0.252）；报告 §6.10；351_stage10/summary_title/A_group_layer.csv）。

Replacement (patching)

Coifman, Bonanno, Rafaeli (2007)

R(l) = (patched − false) ÷ (true − false)



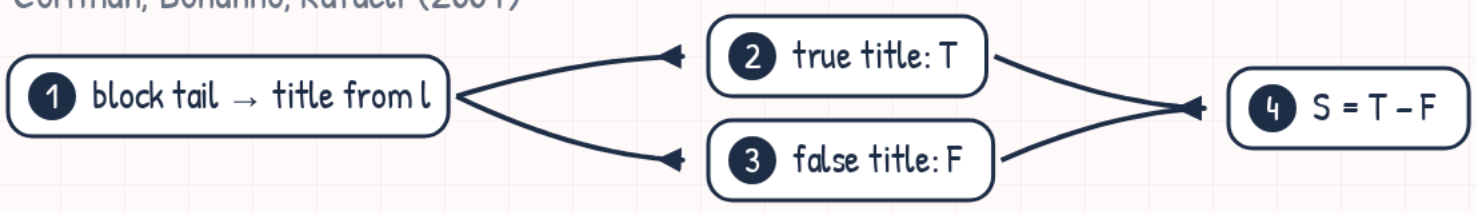
R(l): Stage 13 X6, mean of 5 false titles, all 1,186 papers; 381_stage13/summary_x6/x6_recovery.csv

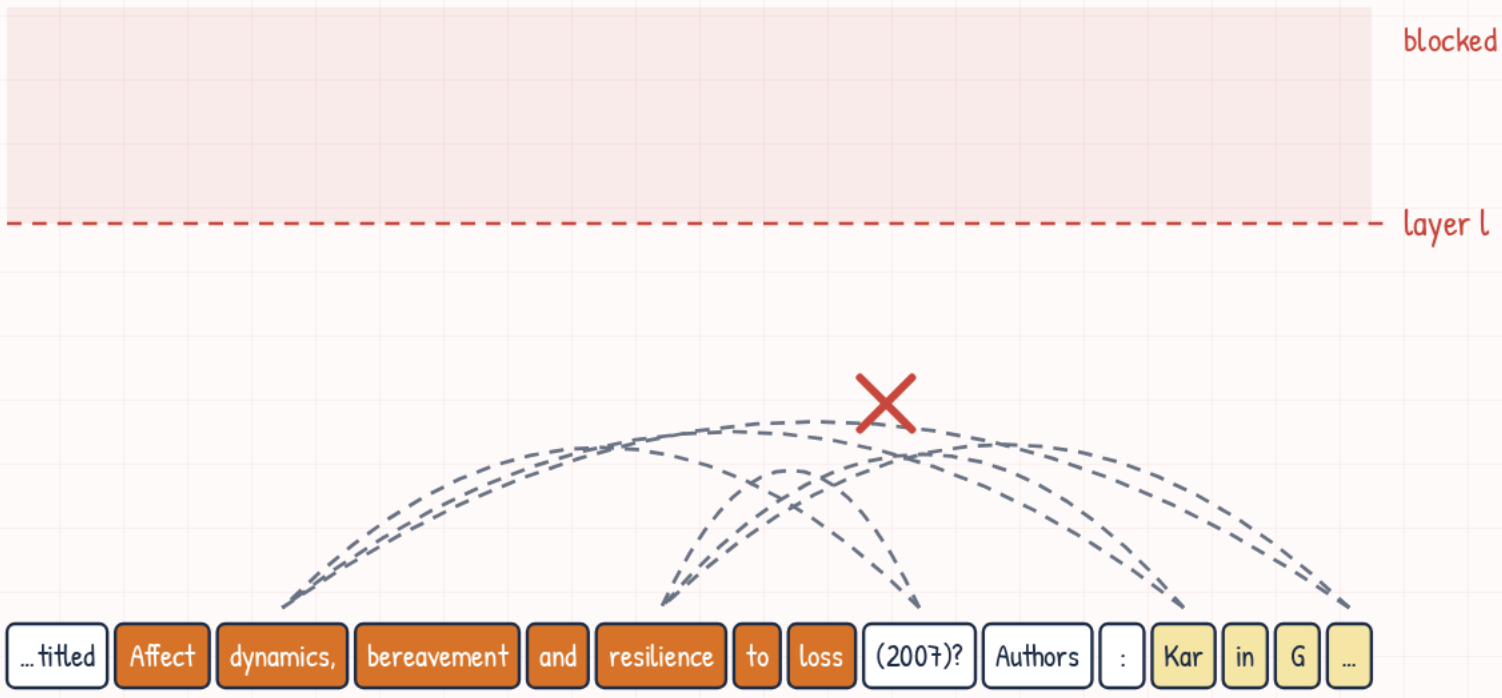
 新写讲稿

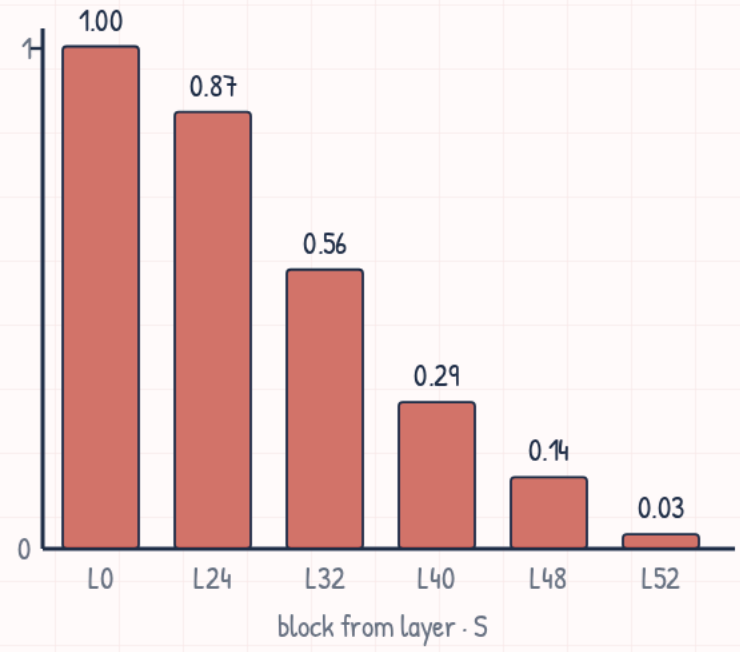
替换（patching）：同一组名字分别接在真标题和假标题后面跑两次；在第 l 层，把真标题运行中标题之后的 token（“(2007)?”、“Authors”、冒号）和名字位置的状态复制进假标题运行，再给名字打分。恢复比例 R(l) = (patched − false) ÷ (true − false)。1,186 篇、5 个假标题平均：L24 0.080、L40 0.302、L48 0.821、L52 0.995（Stage 13 X6，用 5 个假标题分别做 Stage 11 E1 替换，全部 1,186 篇，5 个假标题平均 R：L24 0.080、L40 0.302、L48 0.821、L52 0.995，团队聚类 95% CI；报告 Stage 13 X6 节；381_stage13/reports/x6_report.md（all 表 average 列））， 即到 L52 标题信息已全部进入标题之后的位置。

Knockout (block attention)

Coifman, Bonanno, Rafaeli (2007)







L52: target 0.018 · control 0.051

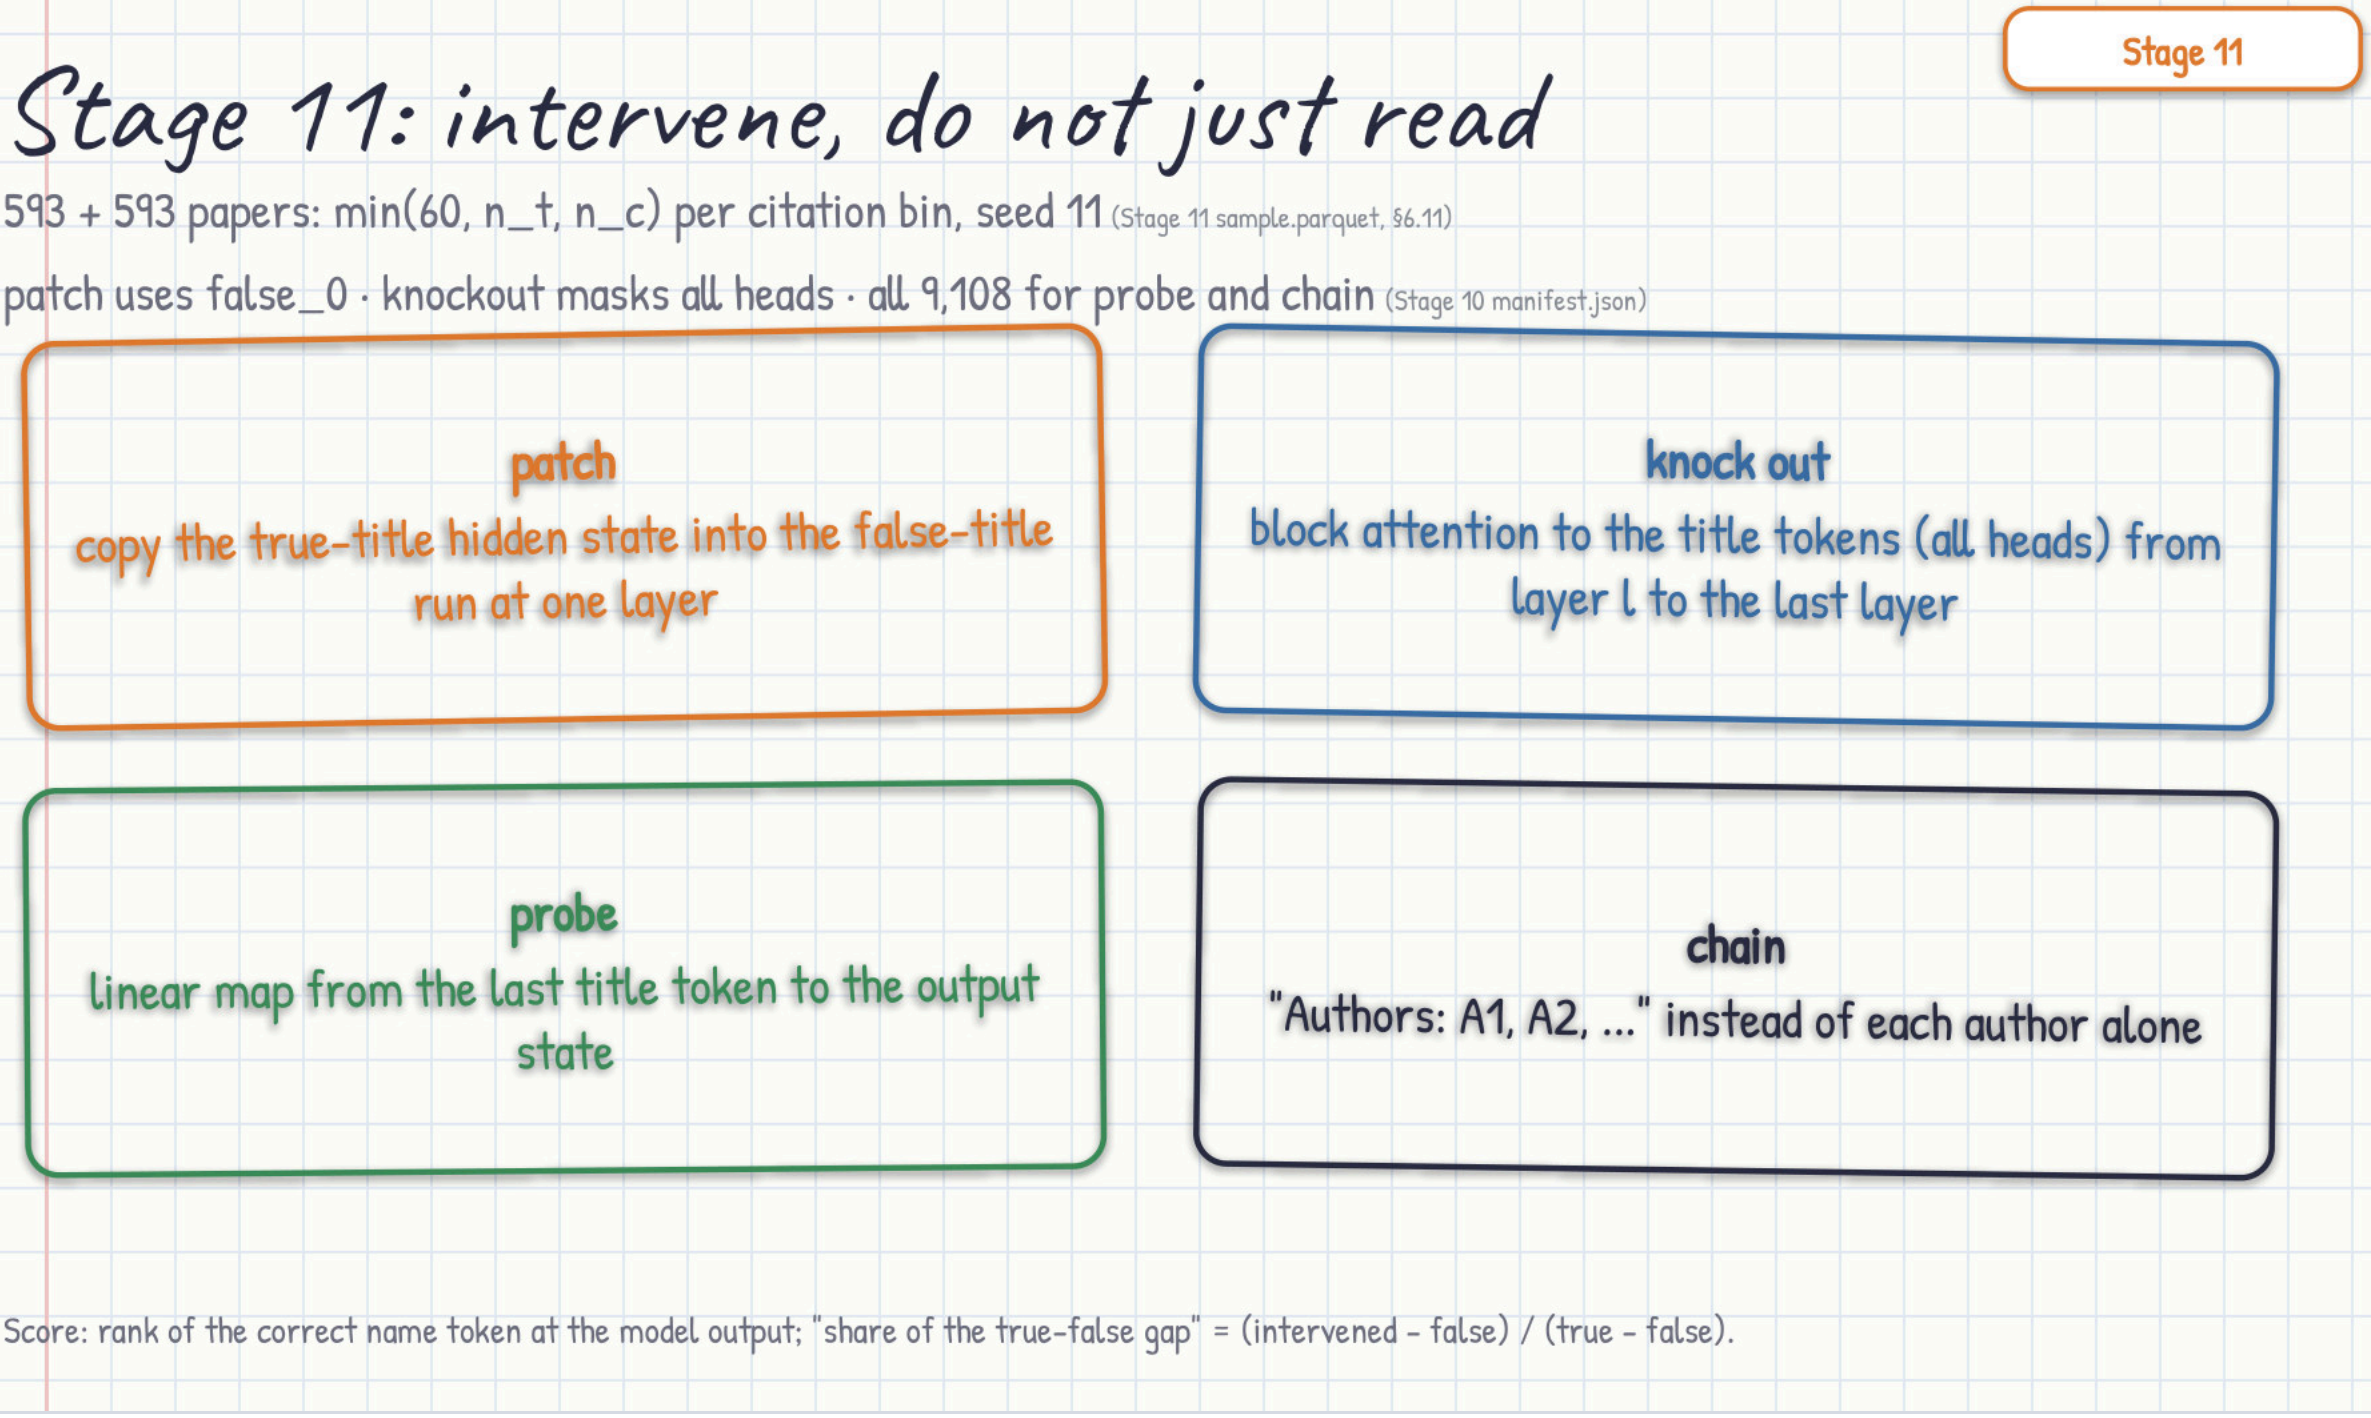
S(l) = T(l) − F(l)

loss as share of (true − false), 1,186 papers

S(l): Stage 13 X7, 1,186 papers (593 target + 593 control); 381_stage13/reports/x7_report.md

 新写讲稿

阻断（knockout）：从第 l 层起，让标题之后的每个位置都不能注意标题 token，记下名字分数的损失 T；在假标题运行上做同样的阻断得到 F；S = T − F，用真 − 假差距的比例表示。X7（1,186 篇）：从 L0 阻断 S = 1.00，L24 0.87，L40 0.29，L48 0.14，L52 0.029（target 0.018，control 0.051）（Stage 13 X7，S = T − F（真标题运行的阻断损失减去 false_0 运行的同样阻断），÷ 真 − 假差距，全部 1,186 篇：L0 1.004、L24 0.873、L40 0.293、L48 0.143、L52 0.029（target 0.018、control 0.051），团队聚类 95% CI；报告 Stage 13 X7 表；381_stage13/reports/x7_report.md；381_stage13/summary_x7/x7_knockout.csv），所以 L52 之后标题已基本不再被读取。

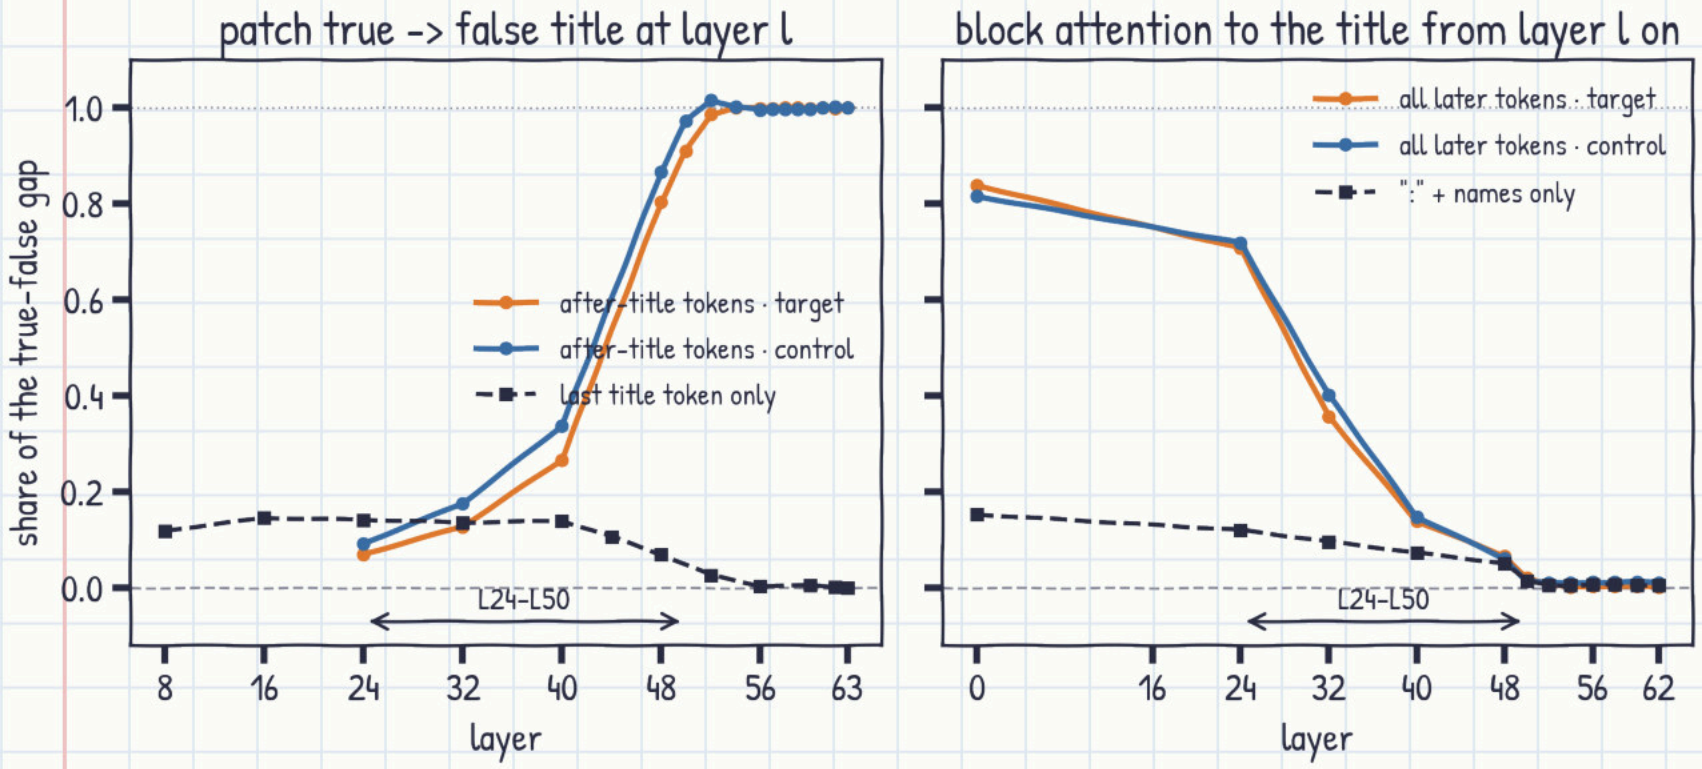


Stage 11 把读出问题变成干预实验。用了 593 篇目标论文和 593 篇对照论文（Stage 11 抽样，10 个可比引用档内配平，目标 593 + 对照 593 = 1,186 篇；361_stage11/config/sample.parquet；361_stage11/config/protocol.json），在引用档内匹配。替换：同一篇论文分别用真标题和匹配的假标题运行，在某一层把真标题运行的隐藏状态复制到假标题运行里。阻断：从第 l 层到最后，禁止注意力看标题 token。Probe：训练一个从标题最后一个 token 到输出状态的线性映射。作者链：在前面作者都给出之后，再给每位作者打分。

Stage 11

The title is read in L24-L50, early

model output · share of the true-false gap · CIs about +/-0.02 (Stage 11 E1/E2, 593 + 593 papers, §6.11)



L52+: title no longer needed

the information enters the **name positions at L44–52**, partly via the tokens right after the title

same timing for target and control

 按 deck 讲稿备注翻译（已按复核结果更新）

两条因果曲线。左边：把真标题运行中标题之后那些 token（右引号、年份、“Authors:”、名字）的隐藏状态复制到假标题运行里，L40 恢复 29%，L48 恢复 0.825（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L40 0.291 [0.274, 0.308]，L48 0.825 [0.807, 0.842]；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all）），L52 起全部恢复（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L52 0.996 [0.989, 1.003]；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））；只复制标题最后一个 token 只恢复约 12%（Stage 11 E1t，只替换标题最后一个 token，真标题→false_0，最终输出恢复比例，全部 1,186 篇 L8–L40 为 0.12–0.15，L56 0.004；报告 §6.11 恢复比例图虚线；361_stage11/summary/E1t_recovery.csv）。右边：从 L0 起阻断对标题的注意力，去掉 83% 的效应；从 L32 起 37%，从 L48 起 6%，从 L52 起为 0（Stage 11 E2 阻断，标题之后全部位置从第 l 层起不能注意标题，最终输出损失比例（÷ 真标题 − false_0 差距），1,186 篇，L0 0.831 [0.801, 0.862]、L32 0.372、L48 0.064、L52 0.007 [0.001, 0.013]；报告 §6.11 阻断图；361_stage11/summary/E2_knockout.csv（group=all））。只阻断冒号和名字位置最多去掉 15%（Stage 11 E2n，只阻断 “:” 和名字位置对标题的注意力，从 L0 起，最终输出损失比例，1,186 篇，0.153 [0.136, 0.172]；报告 §6.11 阻断图虚线；361_stage11/summary/E2n_knockout.csv），所以页面上说：信息在 L44–52 进入名字位置，部分经由标题之后的 token。（已复核：被复制的 token 里包括名字位置本身。Stage 12 P1 逐位置替换显示，信息主要汇集在名字位置上：只换名字位置在 L52 恢复 0.847，只换冒号最多 0.17（Stage 12 P1 逐位置替换，真标题→false_0，最终输出名字 token 恢复比例，Stage 11 样本 1,186 篇：只换名字位置 L48 0.61、L52 0.847，单个位置最大为 “:” L52 0.172 [0.156, 0.187]；报告 Stage 12 节 P1 表；371_stage12/summary/P1_patch_pos.csv）；X6 用 5 个假标题重做，时间不变，L48 恢复约 0.82，L52 起约 1.0（Stage 13 X6，用 5 个假标题分别做 Stage 11 E1 替换，全部 1,186 篇，5 个假标题平均 R：L24 0.080、L40 0.302、L48 0.821、L52 0.995，团队聚类 95% CI；报告 Stage 13 X6 节；381_stage13/reports/x6_report.md（all 表 average 列））。）目标组和对照组的曲线相同。

Stages 1–9 · 20–200 papers

What we saw

- Stage 4 peak at L56 driven by one paper (71%)(audit_report.md)
- 7.2: A–B win-rate positive at L40–L56
- 7.3, 8: L56 title advantage; L56 became the primary layer

Stages 10–11 · 9,108 papers

What scale showed

- L56 is where it *starts*; steepest rise L57–L61
- Patching: copying tail states recovers 80–87% at L48, 100% from L52(Stage 11 E1, 593 + 593; x6_report.md)
- Knockout: blocking the title from L52 on costs nothing

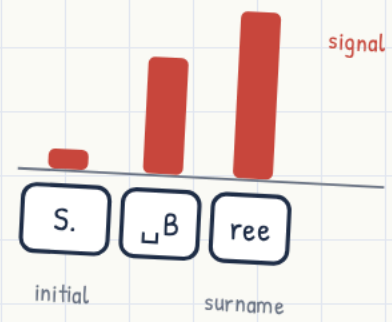
Line C: "read early, spoken late"

L56 was a real landmark, but not the peak. Interventions add what readouts cannot: the title is consumed in L24–50, and the answer only becomes readable at the name a dozen layers later.

C 线的小结。小样本阶段看到：Stage 4 的 L56 峰值由一篇论文撑起（71%）（Stage 4，J-Lens L56，第一作者首 token 倒数名次，20 篇，最大单篇占总和 71.03%；351_all/351_stage4_artifacts/audit/audit_report.md 表 1 行 L56；报告 Stage 4 节）；7.2 中 A–B 胜率在 L40–L56 为正；7.3 和 Stage 8 的标题优势在 L56，于是 L56 成了主要层。全量阶段看到：L56 是开始上升的地方，上升最快的是 L57–L61；替换标题之后的 token 状态在 L48 恢复 80–87%（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例，L48 目标 593 篇 0.803、对照 593 篇 0.866（全部 0.825）；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv），L52 起恢复 0.996（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L52 0.996 [0.989, 1.003]（目标 0.986、对照 1.016）；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））；从 L52 起阻断标题几乎没有损失。L56 是真实的路标，但不是峰值；干预实验补上了读出看不到的东西：标题在 L24–50 被读取，答案要到十几层之后才在名字位置变得可读。（已复核：页面中“复制标题之后的 token 状态”包含名字位置本身；Stage 12 P1 和 X6 显示信息主要汇集在名字位置上，L52 起完成。）

Line D

Which token carries it?



small samples asked

First token or the rest of the name?

→

the full cohort answered

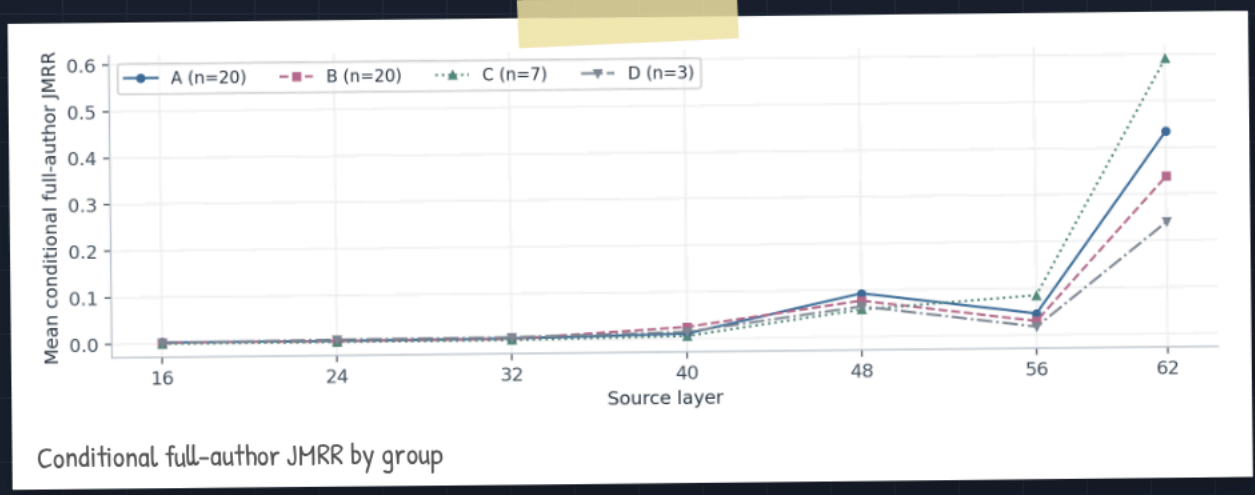
Depends on name format; the information enters the name positions at L44–52, partly via the tokens right after the title; co-authors partly replace the title

D 线的问题是：哪个 token 带着信号？小样本阶段问的是：是名字的第一个 token，还是名字的其余部分？全量阶段的回答是：取决于名字的格式；信息在 L44–52 进入名字位置，部分经由标题之后的 token；前面的合作者会部分代替标题的作用。（这一点已按 Stage 12 P1 和 X6 复核。）

Stage 6 · Line D

From first token to the full name

50 papers, 227 authors, 972 name tokens(token_layer_scores.csv); every listed author scored with teacher forcing



Conditional full-author JMRR by group

Group	Integrated JMRR(integrated_group.csv)
A (20)	0.085 [0.075, 0.096]
B (20)	0.068 [0.057, 0.080]
C (7)	0.106
D (3)	0.050

L62 A–B +0.097 [0.028, 0.163]; Vanilla also +0.091(20 pairs, matched_ab_bootstrap.csv)

Positive, but each token after the first is given the correct prefix. Next: split first token from the rest (7.1).

 新写讲稿

Stage 6 从第一个 token 扩展到完整名字：50 篇论文、227 位作者、972 个名字 token（Stage 6，Pilot50；351_stage6/raw/token_layer_scores.csv（方法手册统计）；351_stage6/summary/summary.json），所有列出的作者都用教师强制打分。条件完整作者 JMRR：A 组 0.085 [0.075, 0.096]，B 组 0.068 [0.057, 0.080]，C 组 0.106，D 组 0.050（Stage 6，J-Lens 条件完整作者 JMRR，7 层积分，各组论文均值（A 20、B 20、C 7、D 3 篇），论文 bootstrap 95% CI；报告 Stage 6 节图 6.1；351_stage6/summary/integrated_group.csv）。L62 上 A−B 为 +0.097 [0.028, 0.163]，Vanilla 也是 +0.091（Stage 6，条件全名 JMRR，L62 匹配 A − B，20 对：J-Lens +0.0966 [0.0282, 0.1630]，Vanilla +0.0907 [0.0161, 0.1676]，配对 bootstrap 95% CI；351_stage6/summary/matched_ab_bootstrap.csv 行 layer=62）。结果为正，但第一个 token 之后的每个 token 都已经给出了正确的前缀，所以下一步要把第一个 token 和其余部分分开（7.1）。

Stage 7.1 · Line D

The A–B gap sits on the rest of the name

CPU-only re-analysis of Stage 6; 10,000 pair-bootstrap draws



Integrated A–B JMRR by token position

Endpoint	A–B (7 layers)(20 pairs; layer_and_integrated_effects.csv)
First token	+0.001 [−0.011, +0.015]
Continuation	+0.021 [+0.002, +0.039]
All tokens	+0.017 [+0.003, +0.030]

At L62: first +0.014 (12/20 pairs) vs continuation +0.121 (15/20)(layer_position_effects.csv)

With a title contrast (addendum 13 C-1): holds at the output (+0.244) and at L62 (+0.278 logit, +0.317 public J-lens); the public J-lens 6-layer mean is not significant (+0.077 [−0.021, +0.180])(20 pairs, rest of the name; c13_C1.md)

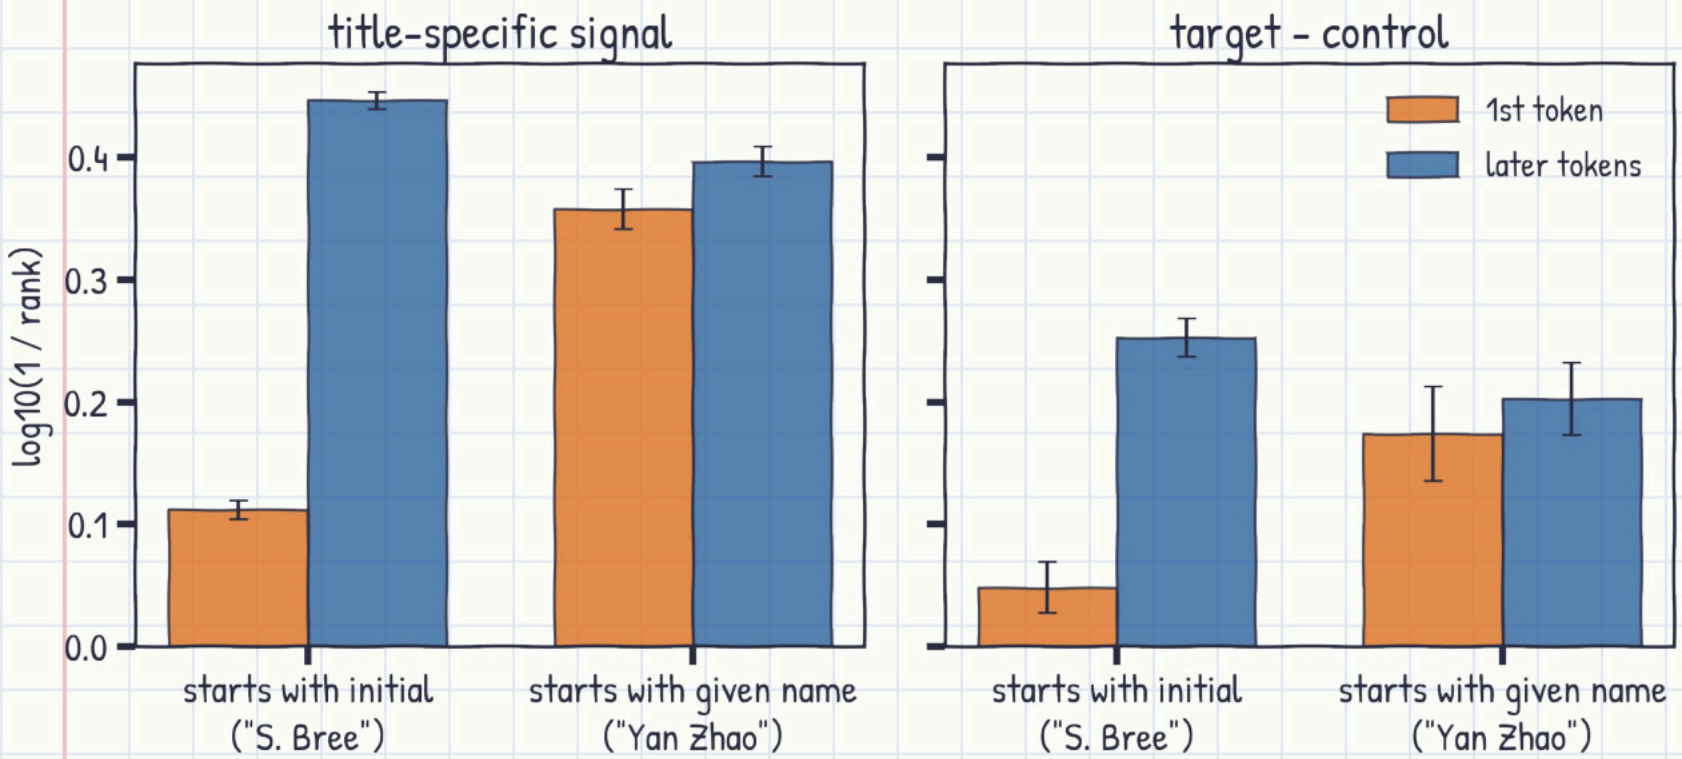
Completing a name is easier than starting it. A continuation gap cannot show unaided recall. **Open:** is this about initials vs surnames?

第 53 / 82 页 · Stage 7.1 · Line D · 合并 PPT 自身页面 **新写讲稿**

Stage 7.1 只用 CPU 重新分析 Stage 6，做了 10,000 次配对 bootstrap（Stage 7.1 设计，种子 35171；~/jlens_work/07_1_stage7_1/351_stage7.py:14,86-87,181）。7 层积分的 A−B：第一个 token +0.001 [−0.011, +0.015]，后续 token +0.021 [+0.002, +0.039]，全部 token +0.017 [+0.003, +0.030]（Stage 7.1，J-Lens JMRR 7 层积分，匹配 A − B，20 对，配对 bootstrap 95% CI：第一个 token +0.0014 [−0.0114, +0.0149]，后续 token +0.0206 [+0.0022, +0.0385]，全部 token +0.0166 [+0.0026, +0.0299]；报告 Stage 7.1 节表；351_stage7_1/summary/layer_and_integrated_effects.csv）。在 L62，第一个 token +0.014（20 对里 12 对为正），后续 token +0.121（20 对里 15 对为正）（同上，L62：第一个 token +0.0141（12/20 为正），后续 token +0.1215（15/20 为正）；351_stage7_1/summary/layer_and_integrated_effects.csv（layer=62））。补全一个名字比开头更容易，后续 token 上的差距不能说明模型能独立回忆。留下的问题是：这是不是首字母和姓的区别？ 2026-11-06 补（补充 13 C-1，事后）：加上标题对照（真标题 − Stage 10 的 5 个假标题）后，A−B 的差别在模型输出和 L62 上成立，public J-lens 多层平均不显著：名字其余 token 上输出 +0.244 [0.087, 0.398]、logit L62 +0.278 [0.088, 0.483]、public J-lens L62 +0.317 [0.145, 0.506]，public J-lens 6 层平均 +0.077 [−0.021, +0.180]（补充 13 C-1，Pilot50 20 对 A−B，配对 bootstrap 95% CI；381_stage13/reports/c13_C1.md aa_cont 行）。

First token or the rest of the name?

model output · split by name format



Initial: carries little; signal is on the surname

Full given name: carries about as much as the surname

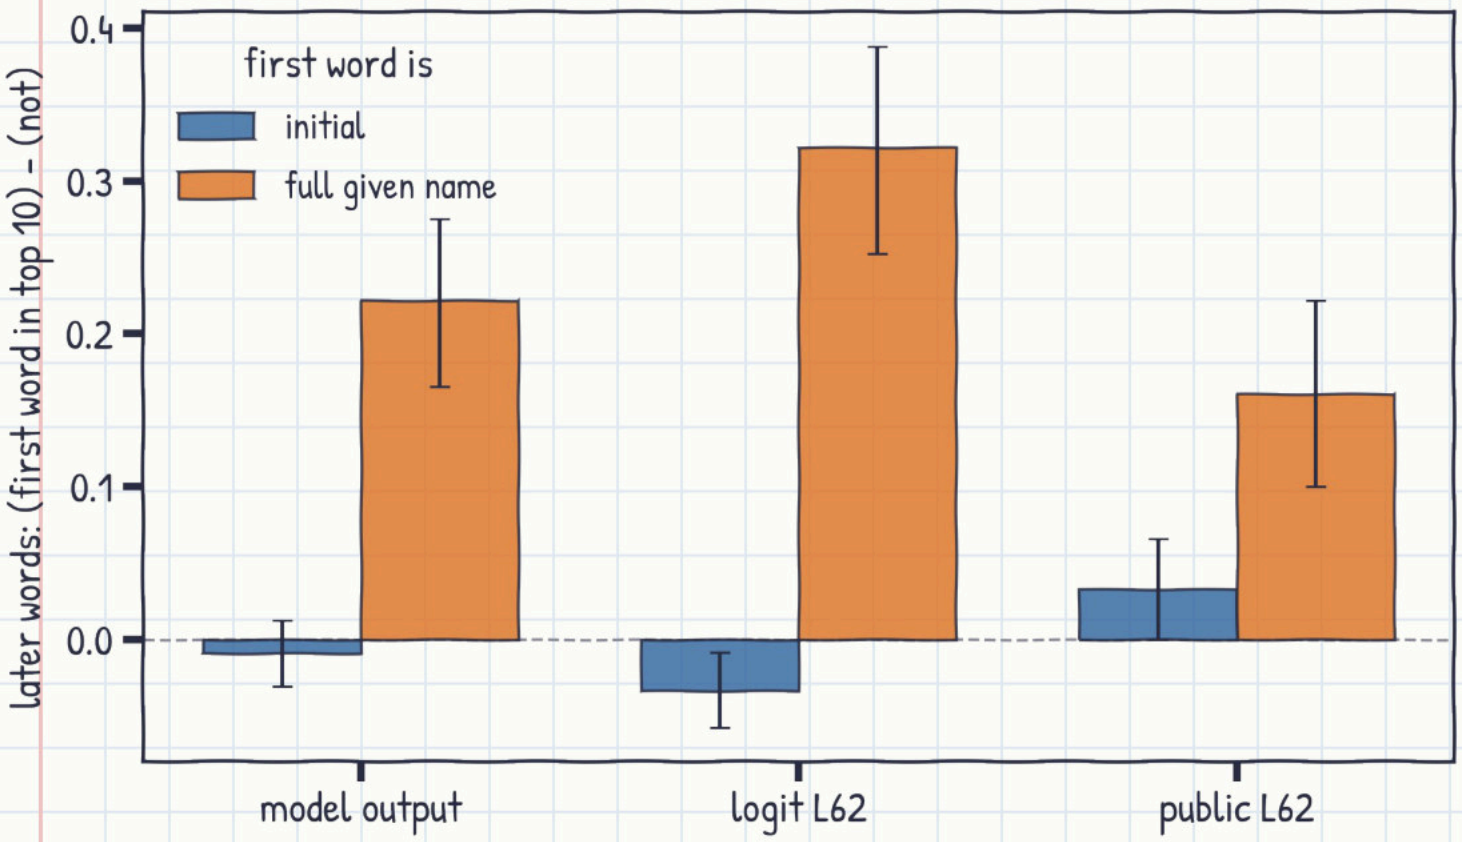
 按 deck 讲稿备注翻译（已按复核结果更新）

信号是否由第一个 token 决定？取决于名字的格式。以首字母开头的名字，首字母本身带的信号很少，信号在包括姓在内的后续 token 上；以完整名开头的名字，名本身带的信号和其余部分差不多。要注意教师强制：后续 token 在每种条件下都已经看到正确的前缀，所以它们的标题特异信号只能来自标题。

Stage 10

Knowing the given name helps with the surname

true title · later words when the first word is / is not in the top 10



Given name in top 10

surname +0.22 (output) (Stage 10, 8,876 authors, §6.7)

+0.32 (logit L62) (same)

Initial in top 10: no help

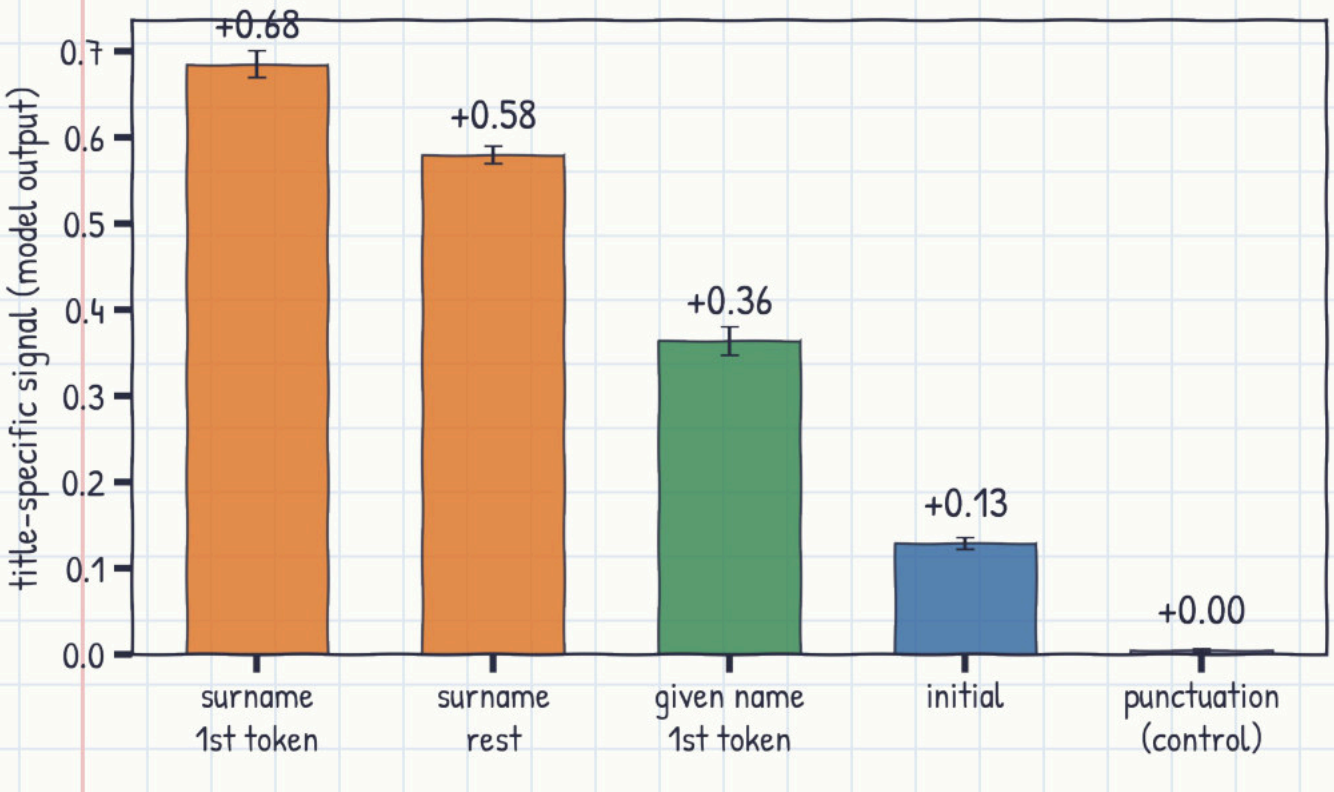
第 55 / 82 页 · deck 第 26 页 按 deck 讲稿备注翻译（已按复核结果更新）

知道了第一个词，其余部分会更容易吗？对完整的名，是的：名进入前 10 名时，姓在输出处高 +0.22，logit lens 在 L62 高 +0.32（Stage 10 §6.7，真标题，完整名开头的 8,876 位作者（名进前 10：678 位），姓（后续 token）平均 log10(1/名次)，进前 10 − 未进，论文聚类 bootstrap 95% CI：最终输出 L63 +0.222 [0.165, 0.275]，logit lens L62 +0.322 [0.253, 0.388]；351_stage10/summary_extra/X1_cond_by_first_role.csv）。对首字母则没有这种帮助。如果把两种格式混在一起，甚至会看到负的效果，因为首字母很好猜，而后面的姓很难。

Stage 10

Where the signal sits, and a dose-response

model output





Right: R0/R1 papers, centred within citation bin; Spearman rho = 0.27, p < 0.001. (Stage 10, 8,894 papers, §6.6)

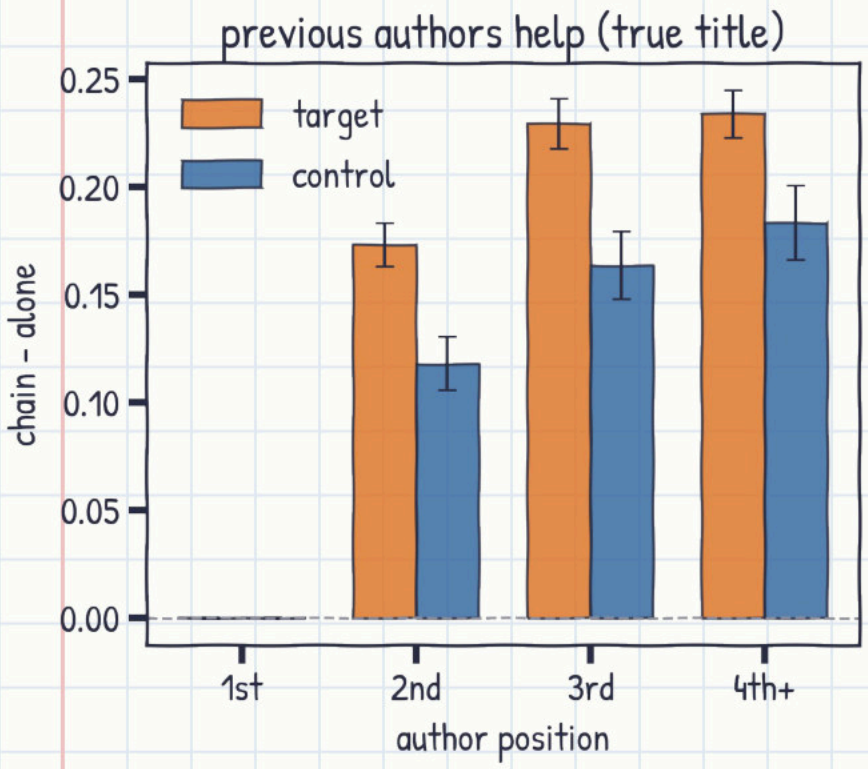
第 56 / 82 页 · deck 第 27 页 按 deck 讲稿备注翻译（已按复核结果更新）

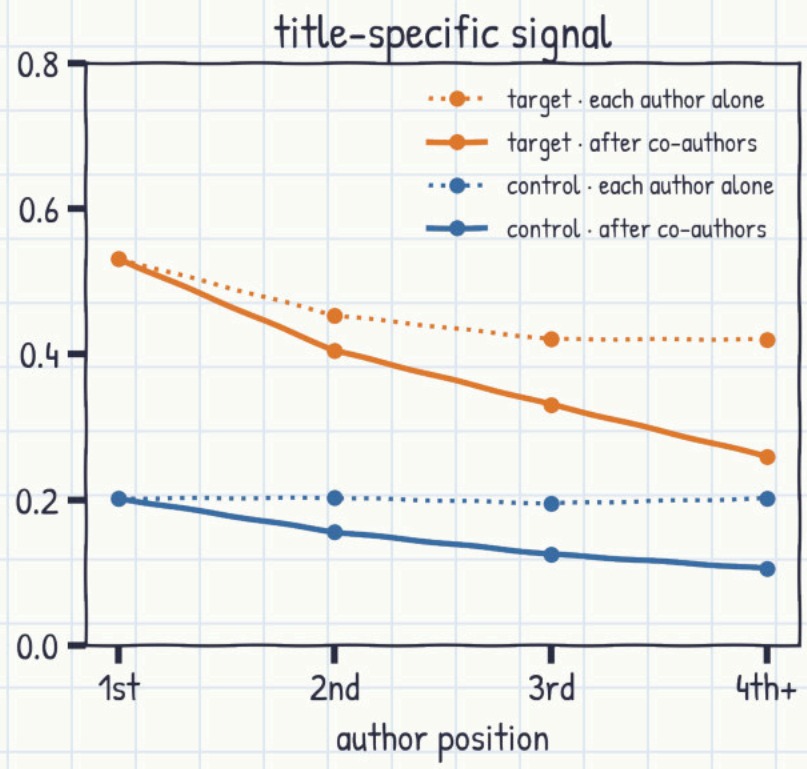
左图是输出处按 token 角色分的标题特异信号：姓的第一个 token 最多，首字母最少，标点约为 0，这是阴性对照。右图是：在所有写不出作者的论文里，多选题答对的顺序越多，模型输出越好（Spearman 0.27）（Stage 10，真标题，最终输出 L63，引用档内中心化的平均 log10(1/名次) 与多选题答对顺序数 0–4，R0/R1 论文 8,894 篇，引用档内 Spearman ρ = 0.268（p < 0.001）；报告 §6.6；351_stage10/summary/C_graded_mc_team_a.csv（metric=mean_nlr））。

Stage 11

Co-authors help, and partly replace the title

model output · all 9,108 papers · 95% CI (Stage 11 E3, §6.11)





later authors **+0.17 to +0.23** (Stage 11 E3, 4,621 target, §6.11)

title-specific part **shrinks**

target > control still

第 57 / 82 页 · deck 第 19 页 按 deck 讲稿备注翻译（已按复核结果更新）

作者链。当前面的作者已经在上下文里时，后面的作者更容易：目标组高 +0.17 到 +0.23，对照组高 +0.12 到 +0.18（Stage 11 E3 连写 – 单独打分，真标题，最终输出 L63，作者位置 2 到 4+：目标 +0.173 / +0.229 / +0.234（4,073 / 2,978 / 2,030 篇），对照 +0.118 / +0.164 / +0.183，论文 bootstrap 95% CI；报告 §6.11 连写表 gain 列；361_stage11/summary/E3_chain.csv）。但标题的作用变小了：后面目标作者的标题特异信号从 0.42 降到 0.26（Stage 11 E3，目标组第 4 位起作者，标题特异信号（真标题 – 5 个假标题平均，最终输出）单独打分 +0.421 → 连写 +0.260，2,030 篇（第 2 位为 +0.454 → +0.405）；报告 §6.11 连写表 4+ · target 行；361_stage11/summary/E3_chain.csv），因为合作者已经能确定是哪篇论文。在引用档内，目标组仍然高于对照组 +0.11 到 +0.15（Stage 11 E3 连写，标题特异，引用档内 目标−对照，作者位置 2 / 3 / 4+：+0.151 / +0.124 / +0.114；报告 §6.11 连写表；361_stage11/summary/E3_chain.csv）。

Stages 1–9 · 20–200 papers

What we saw

- A–B lives on continuation tokens (+0.021), not the first token (+0.001)(7.1, 20 pairs)
- Open question: is that teacher forcing, initials or surnames?

Stages 10–11 · 9,108 papers

What scale showed

- 73% of names start with an initial(24,739 / 33,780; §6.7), which carries little
- Full given names carry as much as surnames and help predict them (+0.22)(final L63; §6.7)
- Information travels title → name positions (L44–52), partly via tail tokens
- Earlier co-authors make later ones easier, title matters less

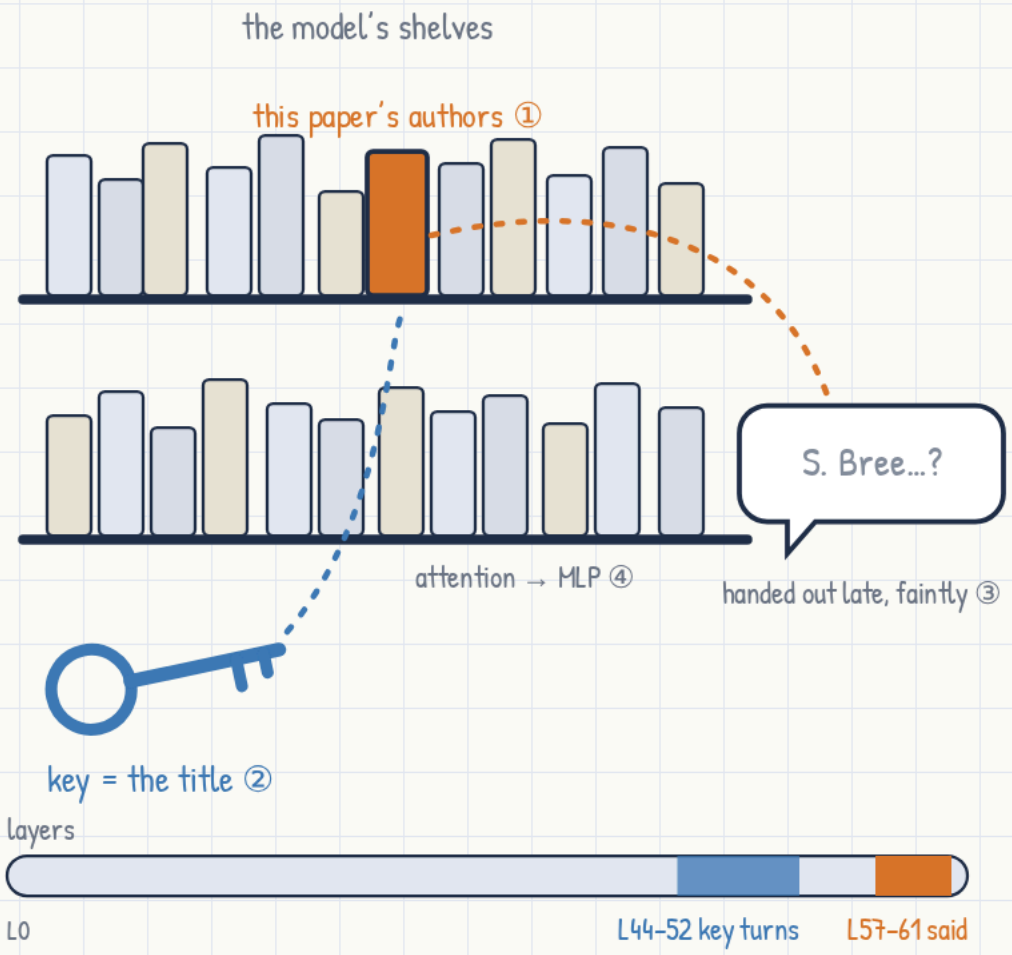
Line D: the puzzle from 7.1 is explained by name format

The pilot's "continuation" result was mostly a format effect: for "S. Bree" the surname is a continuation token. Stage 12 P1 (done) patched single positions: the name positions carry the signal (+0.85 at L52), the colon alone little (+0.17)(P1, 1,186 papers; P1_patch_pos.csv).

D 线的小结。小样本阶段看到：A–B 的差在后续 token 上（+0.021），不在第一个 token 上（+0.001）（Stage 7.1，J-Lens JMRR 7 层积分，匹配 A − B，20 对：后续 token +0.0206 [+0.0022, +0.0385]，第一个 token +0.0014 [−0.0114, +0.0149]；351_stage7_1/summary/layer_and_integrated_effects.csv）；当时留下的问题是，这是教师强制造成的，还是首字母和姓的区别。全量阶段看到：73% 的名字以首字母开头（Stage 10 名字格式，24,739 / 33,780 个作者上下文以首字母开头；报告 §6.7；351_stage10/summary_extra/X1_cond_by_first_role.csv 列 n_contexts（readout=final）），首字母本身信息很少；完整的名带的信号和姓相当，还能帮助预测姓（+0.22）（Stage 10 §6.7，完整名开头 8,876 位作者，名进前 10 − 未进，最终输出 L63 姓 +0.222 [0.165, 0.275]，论文聚类 bootstrap 95% CI；351_stage10/summary_extra/X1_cond_by_first_role.csv）；信息从标题在 L44–L52 汇集到名字位置，部分经由标题之后的 token；前面的合作者让后面的作者更容易，标题的作用变小。7.1 的谜题由名字格式解释：像“S. Bree”这样的名字，姓本来就是后续 token。Stage 12 P1 已完成：只换名字位置在 L52 恢复 0.847，只换冒号最多 0.17（Stage 12 P1 逐位置替换，真标题→false_0，最终输出名字 token 恢复比例，Stage 11 样本 1,186 篇：只换名字位置 L48 0.61、L52 0.847，单个位置最大为 “:” L52 0.172 [0.156, 0.187]；报告 Stage 12 节 P1 表；371_stage12/summary/P1_patch_pos.csv）；X6 用 5 个假标题（Stage 13 X6，用 5 个假标题分别做 Stage 11 E1 替换，全部 1,186 篇，5 个假标题平均 R：L24 0.080、L40 0.302、L48 0.821、L52 0.995，团队聚类 95% CI；报告 Stage 13 X6 节；381_stage13/reports/x6_report.md（all 表 average 列））确认了这个时间。

Keys and shelves

Is the book on the shelf, or is the key failing to get it out?



① Is the book on the shelf? Yes

True title beats false titles (≈0.44 at L62(§6.9)); a probe on the title token reads paper-specific authors from L24 (re-checked)

Lines A, B · Stage 5, 7.3, 8D, 10, 11

② Key = the title, read into the name positions at L44–52

Whole prompt: 0.82 at L48, ≈1.0 from L52; name positions alone 0.61 → 0.85; ':' alone ≤ 0.17(E1, P1; 1,186 papers); knockout after L52 costs almost nothing

Line C · Stage 11, 12 P1

③ Book there but stuck? Not supported

Target − control ≈ 0 at L24–L40, slightly negative at L48 (−0.04 to −0.05), grows only at L57–61 (+0.21 at output(§6.4)): retrieval itself is weak

Lines A, C · Stage 7.2, 10

④ Which shelf? Both, in order

Attention brings the title in at L48 (0.23); MLP takes over at L52–56 (0.18, 0.22)(P2, 1,186 papers). One-layer patching is a lower bound; whether the MLP step is memory lookup is not yet separable

Stage 12 P2

Caveat: a readout not finding it ≠ absent. Stage 13: ':' and name positions hold the task; the title position holds paper attributes and meaning beyond the words, not shown to be paper identity.

用“钥匙和书架”来串起四条线。第一，书在不在架上？在：真标题胜过假标题，L62 约 0.44（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）；标题 token 上的 probe 能读出论文特有的作者（复核后从 L24 起）。第二，钥匙就是标题，在 L44–52 被读进名字位置：整段提示替换在 L48 恢复 0.82（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L48 0.825 [0.807, 0.842]；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））， L52 起约 1.0（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L52 0.996 [0.989, 1.003]；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））；只换名字位置从 0.61 升到 0.85，只换“:”最多 0.17（Stage 12 P1 逐位置替换，真标题→false_0，最终输出名字 token 恢复比例，Stage 11 样本 1,186 篇：只换名字位置 L48 0.61、L52 0.847，单个位置最大为“:” L52 0.172 [0.156, 0.187]；报告 Stage 12 节 P1 表；371_stage12/summary/P1_patch_pos.csv）；L52 之后阻断几乎没有损失（Stage 11 E2 阻断，标题之后全部位置从第 l 层起不能注意标题，最终输出损失比例（÷ 真标题 − false_0 差距），1,186 篇，L52 0.007 [0.001, 0.013]；报告 §6.11 阻断图；361_stage11/summary/E2_knockout.csv（group=all））（Stage 11 和 Stage 12 P1）。第三，书在架上但取不出来？不支持：目标−对照在 L24–L40 约为 0、L48 略为负（−0.037 到 −0.054，区间不含 0（Stage 10，引用档内目标−对照，三种 Jacobian lens L48 −0.037 到 −0.054；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），只在 L57–61 上升（输出处 +0.21）（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），提取本身就弱。第四，在哪个书架上？两者都有，有先后：L48 的注意力把标题读进来（恢复 0.23）（Stage 12 P2，标题之后全部位置只替换单层 attention 或 MLP 输出，最终输出恢复比例，1,186 篇：attention L48 0.231（MLP 0.07），MLP L52 0.178、L56 0.224；报告 Stage 12 节 P2 表；371_stage12/summary/P2_patch_comp.csv），L52–56 由 MLP 接手（0.18、0.22）（Stage 12 P2，标题之后全部位置只替换单层 attention 或 MLP 输出，最终输出恢复比例，1,186 篇：attention L48 0.231（MLP 0.07），MLP L52 0.178、L56 0.224；报告 Stage 12 节 P2 表；371_stage12/summary/P2_patch_comp.csv）。单层替换只是下限，MLP 这一步是不是在查记忆还分不开（Stage 12 P2）。最后提醒：读出工具找不到，不等于信息不存在。Stage 13 显示：冒号和名字位置承载的是任务；标题位置承载论文属性和超出用词的语义，但没有证明是论文身份。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Overview

What the small samples taught us to watch for

- **Single-paper leverage**: one paper = 71% of the Stage 4 L56 mean (20 papers)
- **Tail-driven contrasts**: Stage 8 A–B disappears after removing 10 of 100 pairs(8D, matched_pair_differences.csv)
- **Forking paths**: L56 inspected repeatedly, then made primary
- **Candidate artefacts**: 100 false names share ~46 first tokens; 3% tie with gold(7.2 quality.json: 156/5,000)
- **Label noise**: strict "pass" 25.5% in the 0–2 citation bin (label_README.md)
- **Partial coverage**: first-listed author stands in for the team
- **Metric choice**: KL fidelity and author ranking disagree
- **Protocol drift**: plan locked 10-18 14:29 (7-layer integral primary); the 21:14 PROTOCOL switched to L56, both before 8C scoring; who and why open (U28)

Stage 10 answered each one by design: full cohort, every author and token, all layers reported, full-vocabulary ranks, within-bin comparison, frozen inputs with parity checks. What it cannot fix: groups still come from one labelling run of the same model.

 新写讲稿

小样本阶段教会我们要提防的几件事：单篇论文的杠杆，一篇论文占 Stage 4 L56 均值的 71%（Stage 4，J-Lens L56，第一作者首 token 倒数名次，20 篇，最大单篇占总和 71.03%；351_all/351_stage4_artifacts/audit/audit_report.md 表 1 行 L56；报告 Stage 4 节）；尾部驱动的对比，Stage 8 的 A–B 去掉 100 对中的 10 对就消失（Stage 8D RQ2，J-Lens L56 金标准胜率匹配 A–B，100 对，均值 +4.98 pp，按 A–B 降序去掉前 10 对后其余 90 对均值 −0.39 pp（事后诊断）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）重算；报告 Stage 8D 节）；分叉路径，L56 被反复查看后才定为主终点；候选伪影，100 个错误名字只有约 46 个不同的第一个 token，3% 与正确名字打平（Stage 7.2，Pilot50 每篇 100 个错误名字（50 匹配 + 50 随机），共 5,000 个；每篇平均 45.76 个不同首 token（方法手册 C 部分由 351_stage7_2/candidates/pilot50_author_candidates.csv 统计）；156 / 5,000 = 3.1% 与金标准首 token 相同记为平局（351_stage7_2/summary/quality.json））；标签噪声，0–2 次引用档的严格通过率为 25.5%（标注包自检，0-2 引用档 796 篇，收紧规则（4/4 且真选项平均概率 ≥ 0.5）多选通过率 25.5%（普通规则 38.6%）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 8 行）；覆盖不全，用第一作者代替整个团队；指标选择，KL 保真度和作者排名不一致；协议漂移：分析计划在 10-18 14:29 写定锁定（主终点为 7 层积分），同日 21:14 的 PROTOCOL 改为 L56，两者都早于 8C 打分；改动人和理由待查（U28）。Stage 10 在设计上逐条回应：全量论文、所有作者和 token、报告所有层、全词表名次、引用档内比较、冻结输入并做一致性检查。它没法解决的是：分组仍然来自同一模型的一次标注。

Overview

Small vs large, in one table

Finding	Stages 1–9 (20–200 papers)	Stages 10–11 (9,108 papers)	Verdict
True title helps	+9.3 pp pilot, +5.2 pp new 200(7.3; 8D RQ1)	≈0.44 title-specific at L62(X3_means.csv)	confirmed
Recognised > not recognised	uncertain, tail-driven	+0.21 at output(§6.4), ≈0 at L24–L40, slightly negative at L48 (−0.04 to −0.05)	confirmed, late only
Same groups (A vs B, R0 only)	A – B as above	+0.20 at output(§6.13), ≈0 at L24–L40, slightly negative at L48; R1 adds strength, not timing	comparable, unchanged
Key layer	L56	starts L56, rises L57–61; read L24–50	refined
J-Lens over Vanilla	no increment	more name shape, no paper identity	consistent
First vs rest of name	gap on continuation	explained by initials vs given names	explained
Citations	low–high inconclusive	monotonic, ρ = 0.451(X2_spearman.csv)	resolved
Lens stability	split-half one split; Stage 9 only Fit A	three Jacobian lenses fitted on different text agree; fit stability rests on Stage 9 Fit A only	only one piece of evidence (Stage 9 Fit A); Fit B not completed

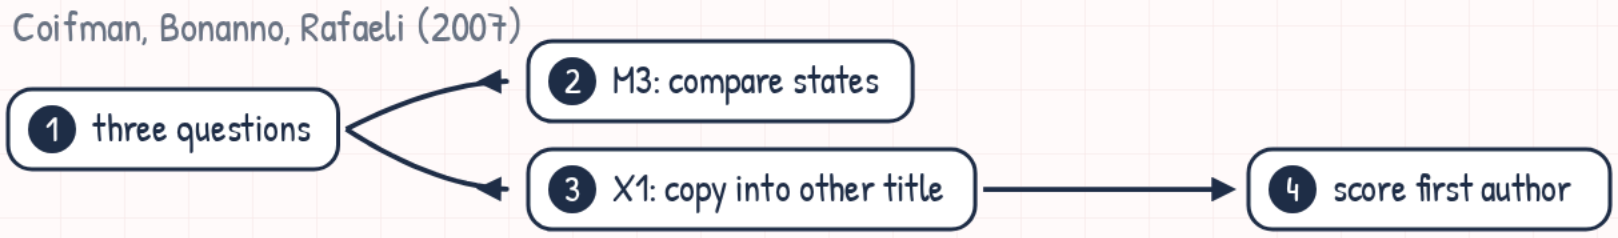
61

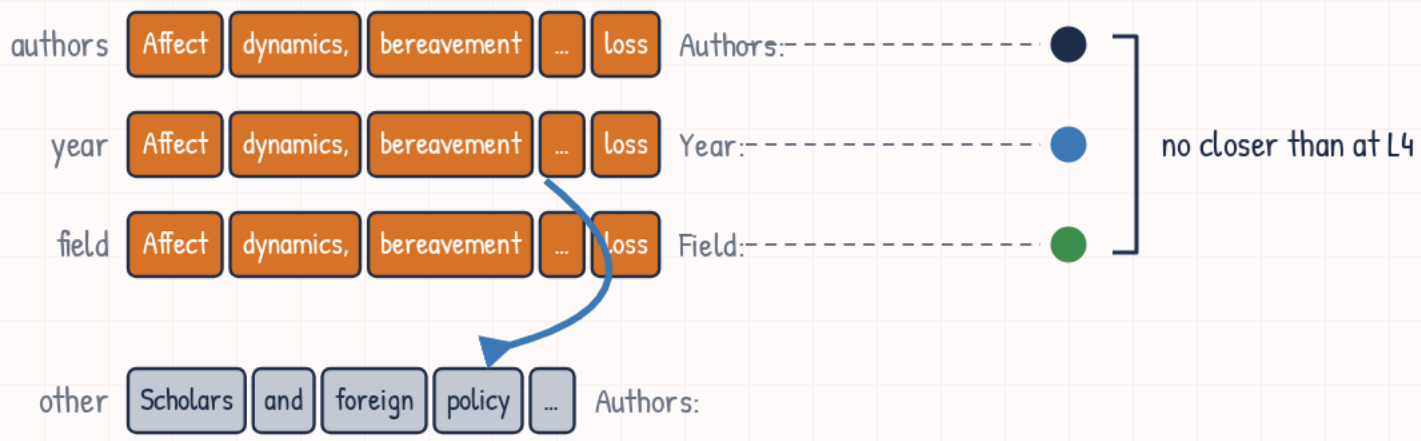
第 61 / 82 页 · Overview · 合并 PPT 自身页面 新写讲稿

一张表对照小样本和全量。真标题有帮助：Pilot +9.3（Stage 7.3，J-Lens L56，真标题胜率 − 20 个错误标题平均胜率，合并池，Pilot50 50 篇均值 +0.0934 [0.047, 0.139]（2026-10-30 重算区间，B = 20,000），35/50 篇为正；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv；报告 Stage 7.3 节）、新 200 篇 +5.18 个百分点（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节），全量 L62 标题特异约 0.44（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv），确认。认得出大于认不出：小样本不确定、依赖尾部，全量输出处 +0.21（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）、L24–L40 约为 0、L48 略为负（−0.037 到 −0.054，区间不含 0），确认，但只在最后几层。同一分组（A 对 B，只用 R0）：输出 +0.20（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv）、中间约 0，R1 只增加强度不改变时间，两阶段可比、结论不变。关键层：小样本是 L56，全量是 L56 开始、L57–61 上升、标题在 L24–50 被读取，细化。J-Lens 胜过 Vanilla：小样本没有增量，全量读出更多名字的样子、但没有论文身份，一致。名字第一个 token 和其余部分：小样本差距在后续 token，全量由首字母和完整名的格式差别解释。引用数：小样本低减高没有定论，全量单调上升 ρ = 0.451（Stage 10 补充 X2，标题特异信号（真标题 − 5 个假标题平均，最终输出 L63）对 log10(引用数+1) 的 Spearman ρ，全部 9,108 篇 0.451 [0.433, 0.467]，bootstrap 95% CI；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv），解决。lens 稳定性：小样本只有一次拆分、Stage 9 只有 Fit A，全量三把用不同文本拟合的 Jacobian lens（Stage 10 三种 Jacobian lens：public（557 条 WikiText-103）、self100（100 条）、fitA（Stage 9 Fit A 100 条）；351_stage10/config/lenses.json；报告 §6.9）结论一致；但同一把 lens 的拟合稳定性只有 Fit A 一份证据，Fit B 未完成。

Changing the question

Coifman, Bonanno, Rafaeli (2007)





R from	authors	year	field
L24	**0.99**	**0.98**	**0.99**
L40	**0.92**	**0.92**	**0.92**
L48	**0.42**	**0.41**	**0.42**

$$R(l) = (\text{patched} - \text{other}) \div (\text{own} - \text{other})$$

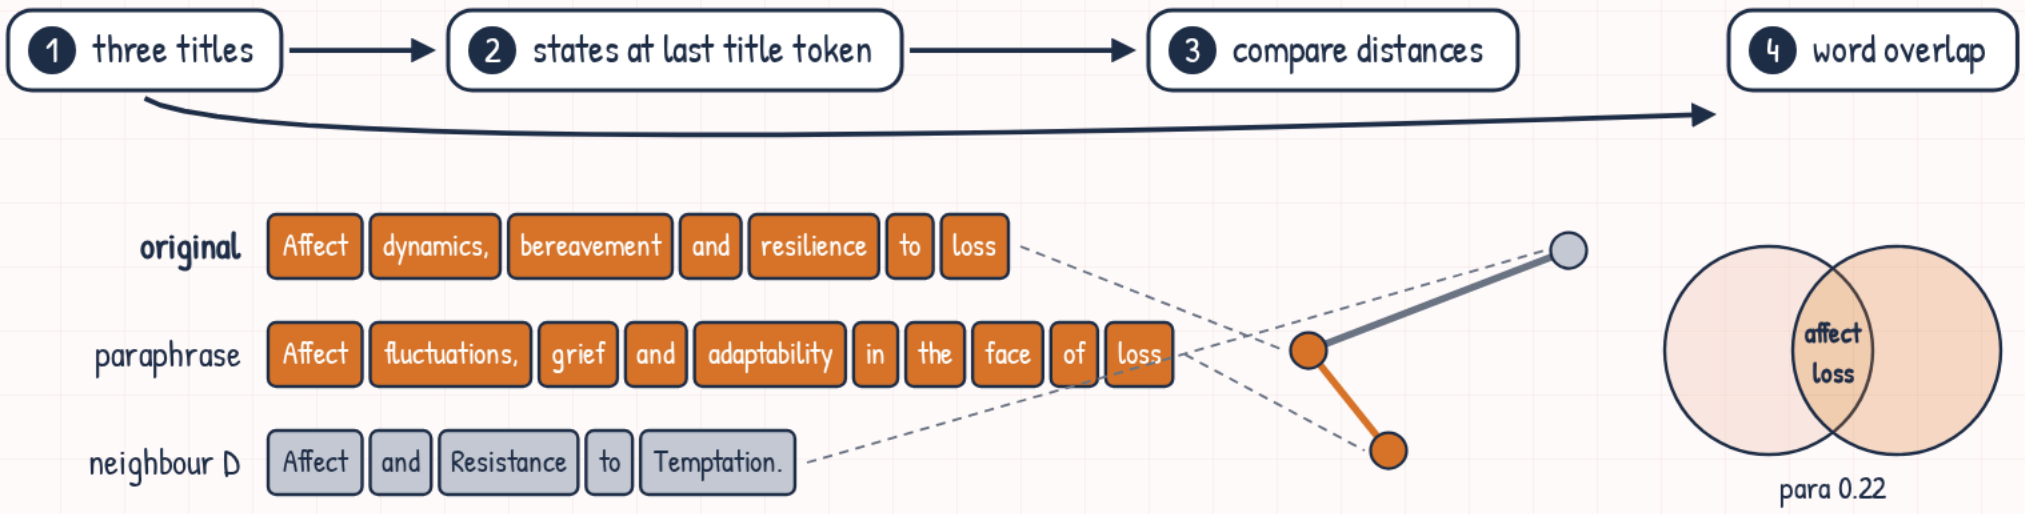
title states copied at layer l; 582 test papers

R: Stage 13 X1, test set 582 papers; 381_stage13/reports/x1_report.md

换问题：同一标题分别放进作者、年份、领域三个问题里（M3），比较标题最后位置的状态；它们不比 L4 时更接近，也就是没有超出标题文字本身的“论文身份”状态。X1 把本篇在任一问题下的标题状态复制进另一篇论文标题的作者提示，再给本篇第一作者打分：R(l) = (patched − other) ÷ (own − other)，L24 约 0.99，L40 约 0.92，L48 约 0.42（Stage 13 X1，测试集 582 篇，R = (patched − other) ÷ (own − other)，来源问题 作者/年份/领域：L24 0.991/0.985/0.992，L40 0.921/0.917/0.915，L48 0.424/0.405/0.417，团队聚类 95% CI；报告 Stage 13 X1 表；381_stage13/reports/x1_report.md test 表），三种来源几乎一样（测试集 582 篇）（Stage 13 X1 调参集/测试集按作者团队各半：测试 582、调参 596 篇；381_stage13/reports/x1_report.md 第 3 行；381_stage13/config/pairs.parquet）。

Paraphrased title (X3)

same paper in other words vs other paper, same words



para 0.22



D 0.14

G′ = cos(orig, para) − cos(orig, D)

+0.32 at L8 · peak +0.46 at L36 (test set)

first-author score, paraphrase − D: +0.239

medians: 0.61 vs 0.15

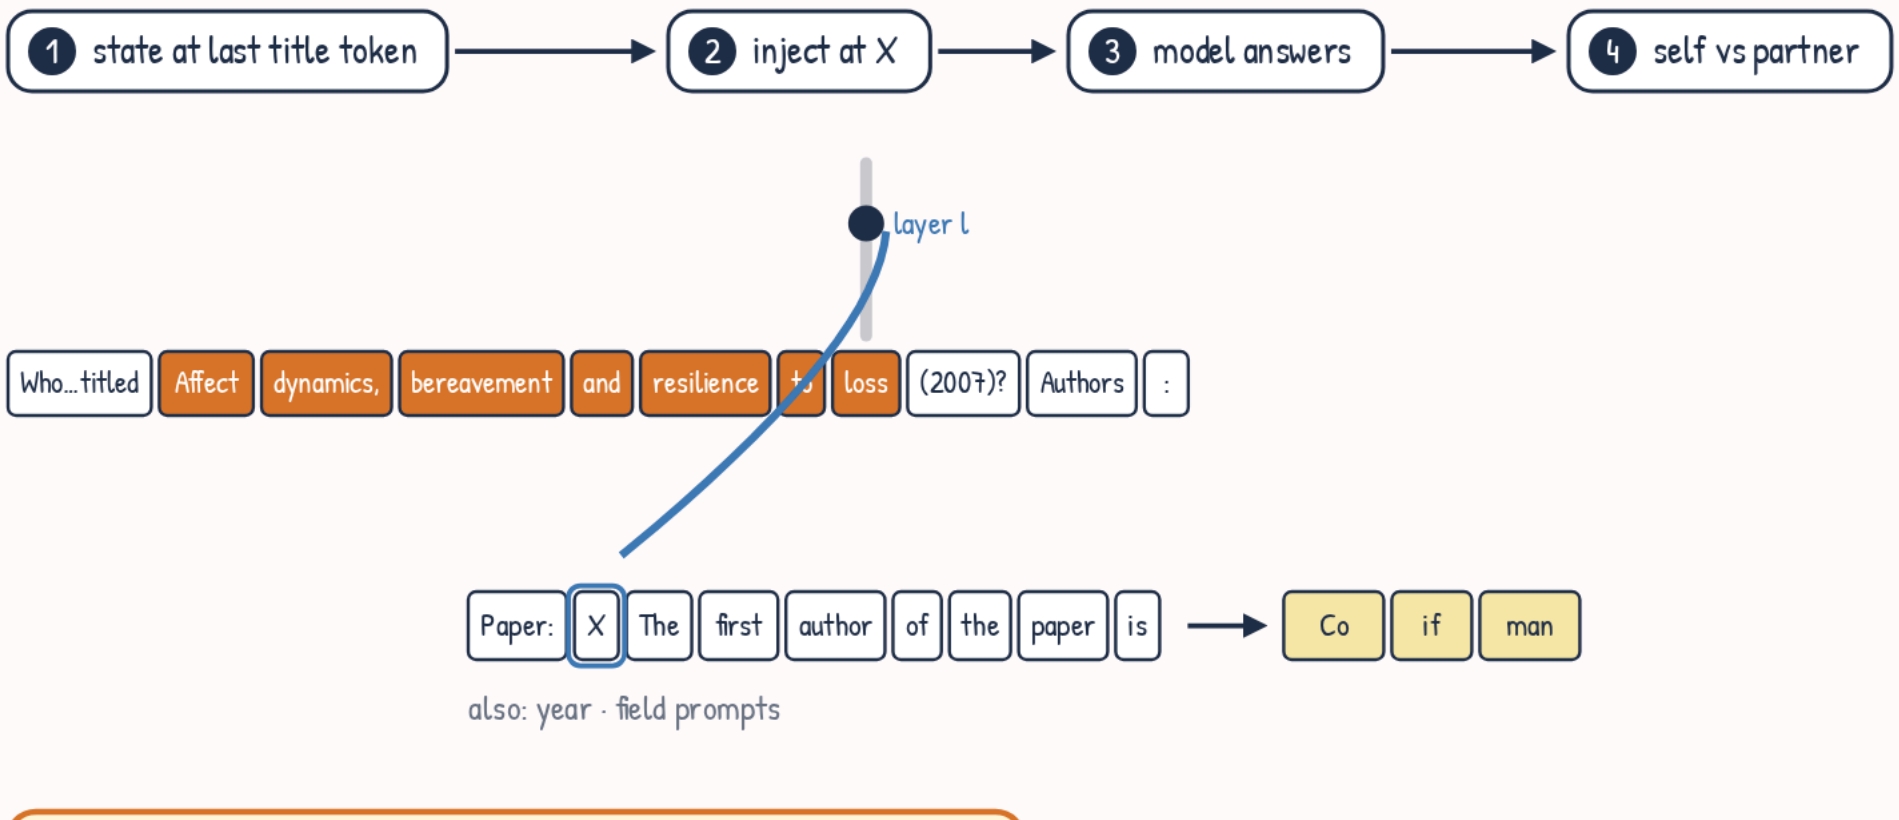
Word overlap 0.22 / 0.14: config/x3_lexical_neighbour_j2.csv (this paper) · medians: x3_report.md (primary set, 1,110) · G′: x3_textbase_recovery.md (test)
+0.239: Stage 13 X3 behaviour, test, 552 papers; x3_textbase_recovery.md

 新写讲稿

改写标题（X3）：示例论文原标题 “Affect dynamics, bereavement and resilience to loss”，改写为 “Affect fluctuations, grief and adaptability in the face of loss”，词汇邻居 D 是另一篇论文 “Affect and Resistance to Temptation.”。比较标题最后位置状态的余弦：G′ = cos(原, 改写) − cos(原, D)，L8 为 +0.32，L36 峰值 +0.46（Stage 13 X3，主分析测试集，标题最后一个 token，G′ = cos(原, 改写) − cos(原, D)：L8 +0.316 [0.293, 0.338]，峰值 L36 +0.463；报告 Stage 13 X3 节；381_stage13/reports/x3_report.md Verdict 节与 G′ 表）。词重叠 jaccard2 的中位数是改写 0.61、D 0.15（Stage 13 X3 主分析 1,110 篇，修正版 Jaccard（jaccard2）中位数：改写 0.611，近邻 D 0.154（敏感性集 1,012 篇为 0.615 / 0.150）；381_stage13/reports/x3_report.md Word overlap 表）（本例 0.22 和 0.14）（示例论文 Coifman 等（2007）：改写 jaccard2 0.222，近邻 D 0.143；381_stage13/config/x3_lexical_neighbour_j2.csv；381_stage13/summary_x3/para_nli.csv）；第一作者分数改写 − D 为 +0.239（Stage 13 X3 行为，第一作者教师强制打分 log10(1/名次)，改写标题 − 近邻 D 标题，主分析测试集 552 篇，+0.239 [0.212, 0.266]，团队聚类 95% CI；381_stage13/reports/x3_report.md Behaviour 表）。

Patchscope (X4)

Coifman, Bonanno, Rafaeli (2007)



D = score(own state) − score(partner state)

score = log10(1/rank) of the true answer tokens

first author from L8: +0.046

year from L40: +0.013

D: Stage 13 X4, test set, team CI; first author L8 +0.046 [0.035, 0.059], year L40 +0.013 [0.008, 0.018]; 381_stage13/reports/x4_report.md

 新写讲稿

Patchscope（X4）：取作者问题里标题最后一个 token 在第 l 层的状态，注入到 “Paper: X / The first author of the paper is” 里 X 的位置（同一层），看模型接下去说出的答案；另有年份和领域两个目标提示。D = 用本篇状态时的分数 − 用配对论文状态时的分数。第一作者从 L8 起可以解码（+0.046）（Stage 13 X4，标题位置，D = 本篇状态 − 配对论文状态的答案分数（log10(1/名次)），最早层在调参集选出、测试集 582 篇确认：第一作者 L8 +0.046 [0.035, 0.059]，团队聚类 95% CI；报告 Stage 13 X4 表；381_stage13/reports/x4_report.md 第 9–11 行），年份从 L40 起（+0.013）（同上，年份 L40 +0.013 [0.008, 0.018]；381_stage13/reports/x4_report.md）。

Stage 12–13: what the middle layers hold

Paper facts are readable at the title early (M2) · H2 (paper identity) partly supported but not established; H3 (hidden author knowledge): insufficient evidence · X2 (2026-11-05): H2 not supported; H3 passes by rule but the author subspace decodes nothing → still insufficient

Hypothesis	M1: top word of the lens in middle layers	M2: probe reads non-name attributes	M3: change-of-task control	Current result (2026-11-05)
H1 task / format: the middle layers represent "output an author list"	mostly "author", punctuation, common name starts; unrelated to the title	paper attributes not readable or very weak	the same title under different questions separates early in the middle layers	see the M3 and X1 results
H2 paper identity: the middle layers represent "which paper this is"	title-related words (copied from the title); change with a false title	field, year (inferred from the title), citations and recognition all readable, and earlier than the names	the same paper under different questions is close in the middle layers and separates by task only late **Result:** not above the L4 text level, not supported	**M3 does not support it; X3 shows a semantic representation beyond wording in the middle layers, but it cannot be separated from paper identity; H2 currently rests on M2 and X1, and M2's Qwen-over-BERT advantage is reference only (addendum 2).** Also, the earliest decodable order in X4 is first author (L8) before year (L40), opposite to the H2 prediction. **X2 does not support it.**
H3 author information already there, just not in vocabulary directions	not necessarily	the authors' first token readable by the probe, not by the lens	an author-trained probe transfers across tasks; an author-specific lens (M4) reads names in the middle layers	**Text baseline not weaker than Qwen, a text explanation cannot be excluded: insufficient evidence** (X4: on the given-name first token BERT +0.088 ≥ Qwen L8 +0.018; the L8 signal sits mainly on the surname, see X4); **X2 passes by rule but the subspace decodes nothing: still insufficient**

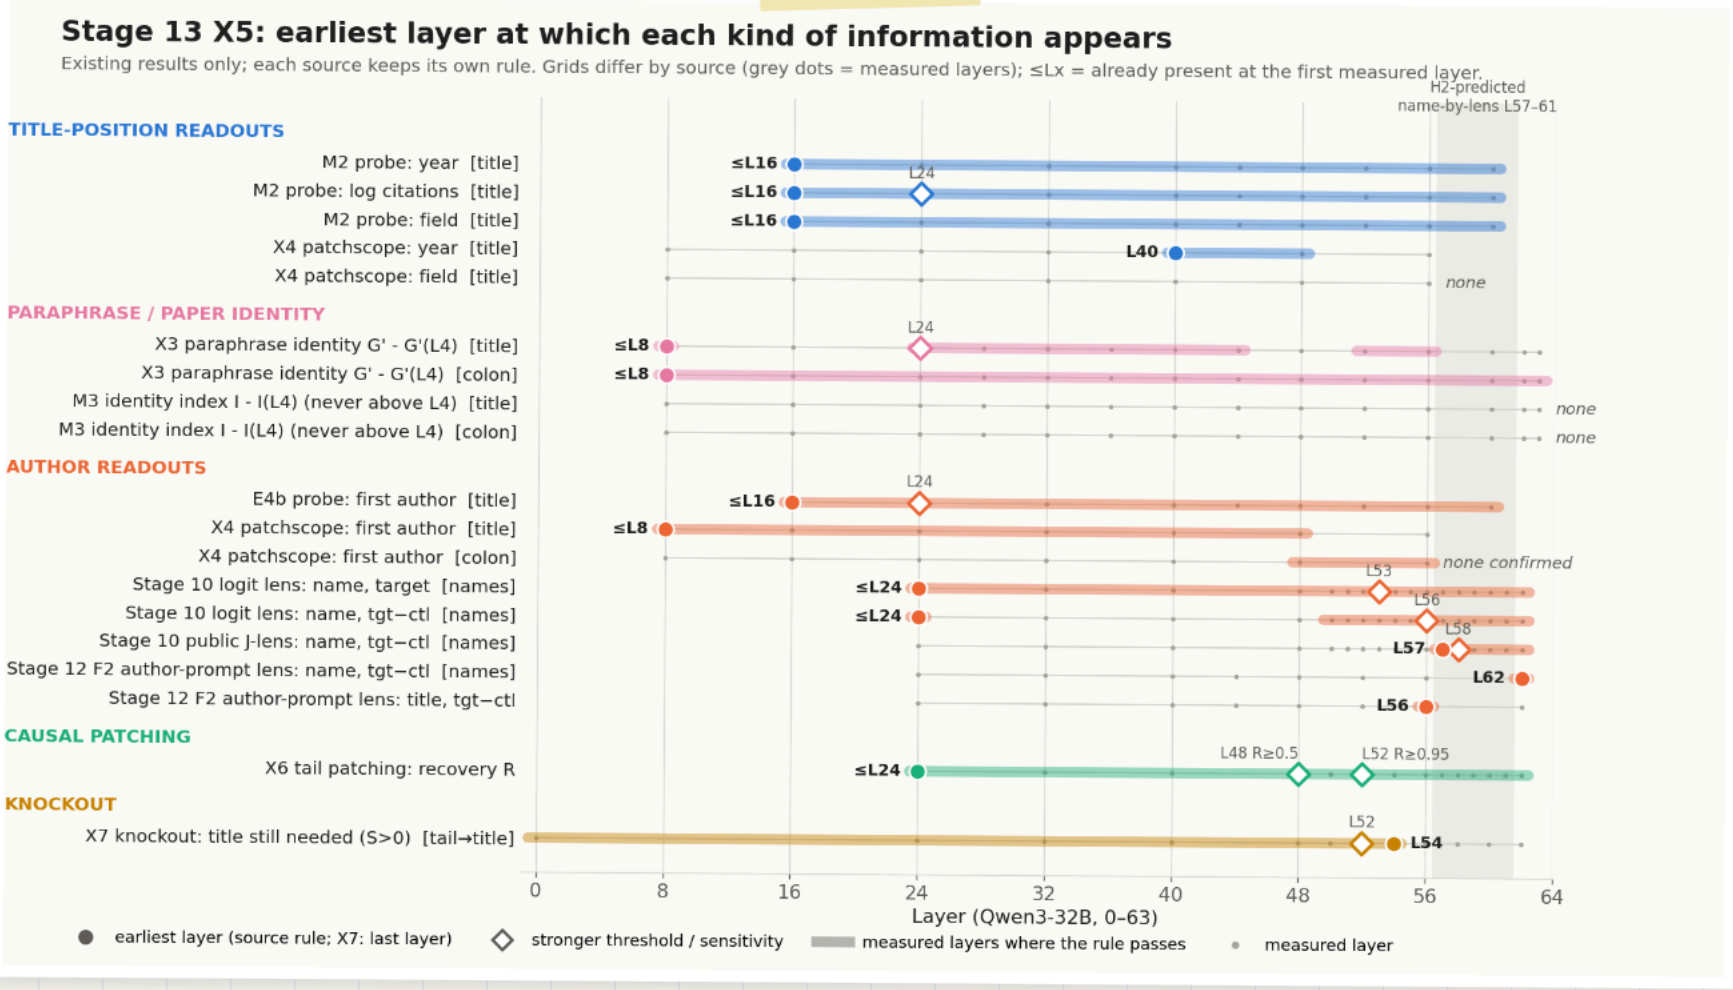
Hypotheses H1–H3 × readouts M1–M3 and current results (report v28, 2026-11-05)

 新写讲稿

Stage 12 和 13 想回答：中间层到底装着什么。表里有三个假设：H1 中间层只是在准备“输出作者名单”这个任务，H2 中间层表示“这是哪一篇论文”，H3 作者信息已经在、只是不在词表方向上。结果是：probe 在标题位置从 L16 或更早就能读出年份、引用数和领域（M2），但换任务对照 M3 不支持 H2，论文身份指标从不高于 L4 的文字水平；X3 显示 L28–L40 有超出用词的语义表示，但不能区分是语义还是论文身份；X4 在 L8 就能解码第一作者，但这可能来自标题文字本身。所以 H2 部分支持但未确立，H3 证据不足。 X2（2026-11-05）：按预注册判据 H2 不支持、H3 通过，但作者子空间几乎解码不出作者，H3 证据仍不足；总体判断不变。

Layer order (X5)

Earliest layer at which each kind of information appears · existing results only, each source keeps its own rule



Read early, carried, spoken late

≤L8–L16: title facts and the first-author token

L48–L52: the paper signal reaches the post-title tail (patching R ≥ 0.5 at L48, ≥ 0.95 at L52; knockout costs nothing from L52)

L53–L62: names readable by lens

X5 只用已有结果，把每种信息“最早在哪一层出现”排在一张图上，没有新的 GPU 计算。标题里的事实（年份、引用数、领域）和第一作者的首个 token 很早就读得出（L8–L16 或更早）；论文信号在 L48–L52 到达标题之后的位置：替换在 L48 恢复 R ⩾ 0.5，L52 起 ⩾ 0.95（Stage 13 X5 汇总，取 X6 5 个假标题平均恢复比例 L48 0.821、L52 0.995（团队聚类），X5 规则 R ⩾ 0.5 / ⩾ 0.95；381_stage13/summary_x5/x5_layer_order.csv X6 行；381_stage13/summary_x6/x6_recovery.csv；381_stage13/reports/x5_report_v2.md），从 L52 起阻断标题不再有损失（Stage 13 X7，论文特有阻断损失 S(L52)：全部 0.029、target 0.018、control 0.051（control L54 0.018、L56 0.000）；381_stage13/reports/x7_report.md）；名字要到 L53–L62 才能用 lens 读出。注意：M3 不支持 H2，X3 不能区分语义与论文身份，X4 在 L8 的第一作者信号可能来自标题文字，所以这张图只说明先后顺序，不说明机制。

Stage 12: where the paper information travels

All 408 GPU units done · true title → false_0 · share of the true–false gap recovered at the output

- **P1 one position at a time:** the colon carries at most 0.17 (L52)(Stage 12 P1, 1,186 papers, paper bootstrap; P1_patch_pos.csv); all name positions together 0.85 at L52(same; CI [0.830, 0.864]); the whole prompt 1.00 (= Stage 11 E1)(same, 0.996)
- **P2 one component of one layer:** attention at L48 +0.23 [0.22, 0.24](Stage 12 P2, 1,186 papers; P2_patch_comp.csv), MLP at L52–L56 +0.18 to +0.22(same) → attention reads the title in, MLP processes it next
- **N1 name plausibility:** without a title the true list looks "most real" in 0.255 of papers (chance 0.25) (Stage 12 N1, 8,894 R0/R1 papers; N1_prior_mc.csv); with the true title 0.625(same, CI [0.615, 0.635])
- **N2 pure name prior (no paper):** target – control +0.047 [0.031, 0.062] vs +0.247 with the true title(Stage 12 N2, final L63, 4,621 + 2,220, within bin; stage12_report.md) → prior ≈ 19% of the gap
- **F2 lens fitted on author prompts:** target – control ≤ 0 at L24–L56, +0.238 only at L62(Stage 12 F2, name positions, Stage 11 sample, true − 5 false; F2_author_lens.csv)

No single "notebook" token

The paper leaves the title at L44–L48 and is spread over the name positions; a lens fitted on author prompts still reads nothing paper-specific in the middle layers.

 新写讲稿

Stage 12（408 个 GPU 单元全部完成）。P1 一次只替换一个位置：“:” 最多恢复 0.17（Stage 12 P1，真标题→false_0，只替换 “:”，L52，最终输出恢复比例，Stage 11 样本 1,186 篇，论文 bootstrap 95% CI [0.156, 0.187]；报告第四部分 Stage 12 P1 表；371_stage12/summary/P1_patch_pos.csv），全部名字位置一起 0.85（同上，全部名字位置，L52 0.847 [0.830, 0.864]），整个提示 1.00（同上，= Stage 11 E1，L52 0.996）。P2 只替换一层的一个组件：L48 注意力 +0.23（Stage 12 P2，标题之后全部 token，1,186 篇，L48 注意力 0.231 [0.221, 0.244]；371_stage12/summary/P2_patch_comp.csv），L52–L56 的 MLP +0.18 到 +0.22（同上，MLP L52 0.178 [0.168, 0.190]、L56 0.224 [0.208, 0.239]）：先是注意力把标题读进来，然后 MLP 接着处理。N1：不给标题时，真作者列表在 4 个选项里“最像真的”的比例 0.255（Stage 12 N1，删去标题，R0/R1 论文 8,894 篇，CI [0.246, 0.264]；371_stage12/summary/N1_prior_mc.csv），与随机的 0.25 一样；给真标题后 0.625（同上，真标题，CI [0.615, 0.635]）。N2：纯名字提示下 target − control 只有 +0.047（Stage 12 N2，纯名字提示，最终输出 L63，目标 4,621 / 对照 2,220，引用档内差，论文 bootstrap 95% CI [0.031, 0.062]；371_stage12/reports/stage12_report.md），真标题下 +0.247（同上，真标题，[0.229, 0.266]），先验约占 19%（0.047 ÷ 0.247，由上两数算出）。F2：用作者提示拟合的 lens 在名字位置 L24–L56 的 target − control 都 ⩽ 0，只有 L62 为 +0.238（Stage 12 F2，名字位置，真 − 5 个假标题平均，Stage 11 样本，[0.210, 0.267]；371_stage12/summary/F2_author_lens.csv）。

The Stage 11 timing holds for all 5 false titles

X6: replacement with each of the 5 false titles · X7: knockout minus the same knockout on the false-title run (S = T − F)

- **X6 replacement:** mean over 5 false titles 0.821 at L48 and 0.995 at L52(Stage 13 X6, 1,186 papers, team-cluster CI; x6_recovery.csv); each false title within 0.02 of false_0(x6_report.md) → "≈80% at L48, all from L52" is not specific to false_0
- **By name-token role:** surname first token 0.734 at L48, surname continuation 0.893; all roles ≥ 0.96 at L52(X6 roles, all papers; x6x7_roles.md)
- **X7 knockout:** blocking the title on the false-title run RAISES the true author score (F < 0), so the paper-specific loss S(L0) ≈ 1.00(Stage 13 X7, 1,186 papers, all: 1.004; x7_report.md); S(L52) = 0.029 [0.021, 0.038](same, all papers)
- **Pre-registered verdict (false_0 only):** holds for target (S(L52) 0.018) and all papers; control just misses (0.051, threshold 0.05)(X7, target 593 / control 593; x7_report.md)
- **Added 2026-11-06, mean of 5 false titles:** target +0.022, control +0.042, all +0.028 — all ≤ 0.05, so the claim holds in every group; control's 0.051 was one false title's fluctuation(addendum 10 item 2; b1_x7f_report.md)

What changes

Nothing in the timing: the title is used up to about L52 and the paper information sits in the post-title positions by then (with five false titles all three groups pass).

 新写讲稿

X6：把 Stage 11 的替换换成 5 个假标题各做一遍，平均恢复 L48 为 0.821、L52 为 0.995（Stage 13 X6，真标题→5 个假标题平均，标题后全部位置，最终输出恢复比例（均值比），1,186 篇，团队聚类 95% CI L48 [0.806, 0.835]、L52 [0.990, 1.001]；报告第四部分 X6 表；381_stage13/summary_x6/x6_recovery.csv）；每个假标题与 false_0 相差不超过 0.02（381_stage13/reports/x6_report.md；对照组最大 0.019）。按名字 token 角色：姓的第一个 token L48 为 0.734，姓的后续 token 0.893（X6 角色拆分，全部论文，团队 CI [0.711, 0.757] / [0.880, 0.906]；381_stage13/reports/x6x7_roles.md），L52 各角色都 ⩾ 0.96（同上）。X7：在假标题运行上做同样的阻断，真作者的分数反而上升（F 为负），所以论文特有的损失 S(L0) ≈ 1.00（Stage 13 X7，S = T − F，1,186 篇，全部 1.004；381_stage13/reports/x7_report.md），S(L52) = 0.029（同上，全部论文，团队 CI [0.021, 0.038]）。预注册判定 S(L52) ⩽ 0.05：target 成立（0.018（X7，target 593 篇，[0.010, 0.027]）），control 差一点不成立（0.051（X7，control 593 篇，[0.033, 0.068]）），control 要到 L54–L56 才完全不需要标题。2026-11-06 补做（补充 10 第 2 项）：X7 补做了另外 4 个假标题，按 5 个平均判定，target、control 和全部论文都满足预注册判据（S(L52) 分别为 +0.022、+0.042、+0.028，均 ⩽ 0.05）（X7 五个假标题平均，target 593 / control 593 / 全部 1,186 篇，团队聚类 95% CI [0.015, 0.029] / [0.028, 0.055] / [0.022, 0.035]；381_stage13/reports/b1_x7f_report.md）；原来对照组只用 false_0 时为 0.051，属于单个假标题的波动（control 逐个假标题 0.051 / 0.035 / 0.048 / 0.033 / 0.041；同一报告）。

Same title, different question

M3: probes across three questions (authors / year / field) · X1: patch A's title state from another question into B's author prompt

- **M3 transfer at the title:** T ≥ 0.92 at L16–L40, but never above the L4 text level(Stage 13 M3, 9,108 papers, team folds; m3_report.md) (year T − T(L4) −0.03 to −0.06)(same, CIs exclude 0) → M3 does not support H2
- **M3 at the colon:** T < 0.5 → the state is already organised by the question (H1)(same; summary_m3/m3_transfer.csv)
- **X1 replacement:** R ≈ 0.99 (L24), 0.92 (L40), 0.42 (L48) whichever question the state came from(Stage 13 X1, test 582 pairs, team CI; x1_report.md); authors − year within ±0.02, except a small +0.019 at L48(same, [0.012, 0.026])
- **Retrieval (added 2026-11-05):** no layer retrieves the paper across questions better than L4(X5 retrieval, 9,108 papers; x5_retrieval.md; post-defence)

Reading

The title state hardly depends on the question, and the replacement effect is task-independent; but nothing goes beyond what the title text alone gives at L4.

 新写讲稿

M3：同一篇论文换三种问法，标题最后一个 token 上的迁移比 T 在 L16–L40 都 ⩾ 0.92（Stage 13 M3，9,108 篇，按作者团队分 5 折的 probe，迁移比 = 跨问法成绩 ÷ 同问法成绩；报告第四部分 M3 表；381_stage13/reports/m3_report.md），但按补充 2 只看相对 L4 的变化：年份 T − T(L4) 为 −0.03 到 −0.06（同上，团队聚类 95% CI 都不含 0；summary_m3/m3_transfer.csv），不高于文字水平，所以 M3 不支持 H2。":" 位置 T < 0.5（同上），状态已按问题重新组织。X1：把 A 在别的问法下的标题状态替换进 B 的作者提示，恢复 R 在 L24 约 0.99、L40 0.92、L48 0.42（Stage 13 X1，测试集 582 对，作者问法来源，团队聚类 95% CI；381_stage13/reports/x1_report.md），三种来源几乎相同；作者 − 年份在 ±0.02 以内，只有 L48 有 +0.019（同上，[0.012, 0.026]）。答辩后补算的跨任务检索（X5 预注册曲线）也没有一层高于 L4（X5 检索，9,108 篇，top-1；381_stage13/reports/x5_retrieval.md；事后补算）。 2026-11-06（批次 1 第 1 项）：X1–X4 改为给全部作者打分（全部名字 token）并按作者排位分层，结论都不变：X1 仍与任务无关，L48 有一点小而确实的任务依赖（作者 − 年份 +0.024 [0.019, 0.030]（补充 10 第 1 项，测试集，团队聚类 95% CI；381_stage13/reports/b1_xall_report.md））。

Patchscope and paraphrases

X4: decode year / first author / field from the paper's own title state · X3: paraphrased title vs a word-matched other paper

- **X4 first author:** decodable from L8, D = +0.046 [0.035, 0.059](Stage 13 X4, test split, team CI; x4_report.md); year only from L40, +0.013 [0.008, 0.018](same); field never → order opposite to the H2 prediction
- **But:** the L8 signal sits on the surname (+0.066), where the text-baseline check failed(X4 role split, 1,178 papers; x4_rolesplit.csv) → may be explained by the title text
- **X3 paraphrase:** closer to the original than a word-matched paper beyond L4, peak L36 +0.16(Stage 13 X3, test 552 papers, G′ − G′(L4), team CI [0.146, 0.171]; x3_report.md); behaviour keeps ≈ 90% of the first-author preference(same, 0.90 [0.87, 0.94])
- **Post-hoc checks:** a sentence-embedding model without author knowledge shows a comparable advantage, and target = control(X3 text baselines and group split; x3_textbase_recovery.md, x3_groupsplit.md) → meaning, not separable from paper identity

H2 / H3 so far

H2 partly supported but not established (rests on M2 and X1); H3: insufficient evidence (text baseline not weaker than Qwen).

 新写讲稿

X4：把论文自己的标题状态注入“X 的第一作者 / 年份 / 领域是”提示。第一作者从 L8 起可解码，D = +0.046（Stage 13 X4，测试集，团队聚类 95% CI [0.035, 0.059]；报告第四部分 X4 表；381_stage13/reports/x4_report.md）；年份要到 L40，+0.013（同上，[0.008, 0.018]）；领域读不出——顺序与 H2 的预测相反。L8 的作者信号主要在姓的第一个 token 上（+0.066（X4 按 token 角色，1,178 篇，[0.045, 0.088]；381_stage13/summary_x1x4/x4_rolesplit.csv）），而姓氏上文本基线的阳性对照没有通过，所以可能来自标题文字。X3：改写标题在 L28–L40 比用词相近的近邻 D 更接近原标题，超出 L4 文字水平，最高 L36 +0.16（Stage 13 X3，主分析测试集 552 篇，G′ − G′(L4)，团队 CI [0.146, 0.171]；381_stage13/reports/x3_report.md）；行为上保留约 90% 的第一作者偏好（同上，教师强制打分，0.90 [0.87, 0.94]）。事后加的检验：不认识作者的句子向量模型在用词匹配子集上也有相当优势，target 与 control 没有差别（381_stage13/reports/x3_textbase_recovery.md、x3_groupsplit.md），所以只能说中间层表示了标题的意思，不能与论文身份区分。 2026-11-06（批次 1 第 1 项，全部作者）：X3 改写标题保留约 90% 的作者偏好，target 与 control 一样；X4 从 L8 起可解码出作者，各作者排位相同，认得出的论文在 L8–L40 更高；但只靠标题文字的基线不弱于 Qwen，仍不能排除标题文字的解释（381_stage13/reports/b1_xall_report.md）。

X2: swap only a subspace

Patch only the paper-attribute (S_id, 9-dim) or the author (S_auth, 10-dim) component of A's title states into B · test 582 pairs · team-cluster 95% CI

- **Carry:** S_id at L40 moves +0.005 of the gap (random +0.003, full replacement +0.920); S_auth at L48 moves +0.018 (random +0.003, full +0.428)(Stage 13 X2, test 582 pairs; x2_report.md Verdict)
- **Pre-registered verdict:** H2 not supported (R_id 0.005 < 0.5 × R_full 0.460); H3 passes (R_auth − R_id +0.014 [+0.008, +0.020])(same, L40 / L48)
- **But:** the author subspace hardly decodes authors (held-out $R^2 \leq 0.003$; first-author token hit rate 0.078–0.079, below the constant baseline 0.080) and moves only about 4% of the full replacement(subspace fits on 5,041 training papers, 5 team folds; x2_report.md)
- **Remove arm:** setting either component to the mean costs no more than a random subspace (+0.001)(test, L_S − L_rand; same)

Reading

H3 passes by the pre-registered rule and H2 is not supported, but the author subspace cannot decode authors, so this is no strong evidence for H3. The information carried from the title to the names lies almost entirely outside both subspaces.

 新写讲稿

X2 只替换子空间（预注册补充 6，2026-11-05 完成）。在 B 的作者提示里只把标题位置状态在某个子空间上的分量换成 A 的：论文属性子空间 S_id（年份、引用数、领域，9 维）在 L40 只搬动 +0.005（Stage 13 X2，测试集 582 对，R_S（均值比）；随机子空间 +0.003，完整替换 +0.920；381_stage13/reports/x2_report.md Verdict 表），作者子空间 S_auth 在 L48 搬动 +0.018（同上，L48；随机 +0.003，完整替换 +0.428）。按预注册判据，H3 通过、H2 不支持（H2：R_id 0.005 < 0.5 × R_full 0.460；H3：R_auth − R_id +0.014 [+0.008, +0.020]，团队聚类 95% CI；同上）。但作者子空间本身几乎解码不出作者（留出 $R^2 \leqslant 0.003$（S_auth 作者映射，5,041 篇训练论文，5 折团队留出 R^2 0.0009–0.0033；x2_report.md Subspace fits 表），第一作者名字 token 猜中率 0.078–0.079（同表 author top-1，L16–L48 各层），低于常数基线 0.080（同表 majority)），它搬动的量只有完整替换的约 4%（0.018 ÷ 0.428），因此不能作为 H3 的有力证据。从标题传到作者名字的信息，几乎全部分散在这两个子空间之外。与预注册的出入：X2 的 H3 判定按规则通过，但因子空间本身无解码能力而降级，与 X3 的处理方式相同；S_id 只有 9 维。 2026-11-06（批次 1 第 1 项）：用全部作者重新拟合作者子空间后，搬动量从 0.016 升到 0.032（完整替换的约 7%），但子空间本身仍几乎解码不出作者（留出 $R^2 \leqslant 0.009$），H3 仍证据不足（381_stage13/reports/b1_xall_report.md “X2: verdict” 与 “New S_auth” 节）。

The probe on every name token

Title-position probe extended to all name tokens and split by role · L40 · true − false_0 · 1,395–1,754 target + control papers · team-cluster 95% CI

- **Surname first token:** +0.071 [0.058, 0.085], above the initial +0.044 [0.030, 0.057]; difference +0.028 [0.011, 0.045] → both pre-registered checks pass(addendum 9; e4b_alltok.md §5)
- **Given name first token strongest:** L40 +0.124, L56 +0.163(1,706 papers; same)
- **So E4b underestimated it:** E4b scored only each author's first token, mostly an initial
- **Permutation controls:** ≈ 0 on surname and given-name tokens; ≈ +0.02 on initials → about half of the initial's signal is not paper-specific(e4b_alltok.md §7)
- **Target − control:** mainly initials and given names (positive from L24–L32); surname first token, five false titles with per-donor exclusion: positive from L24 (L40 +0.030, L56 +0.058)(within bin; b1_e4b5_report.md, per-donor); with false_0 only (fewer papers) not significant before L56

Five false titles (batch 1)

Per-donor exclusion, 4,654 papers: surname L40 +0.076, surname − initial +0.033. Without the title-reuse exclusion (C-3, C-3b) the signals are unchanged but include leakage: sensitivity only. (b1_e4b5_report.md; c13_C3b.md)

 新写讲稿

补充 9（答辩后新增，分析计划在看结果前写定）：把标题位置 probe 扩展到每位作者的全部名字 token，并按角色分开。在 L40，姓的第一个 token 的标题特异信号为 +0.071 [0.058, 0.085]（补充 9，标题最后一个 token，真标题 − false_0，目标 + 对照 1,395 篇，剔除标题复用，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md 第 5 节），高于首字母的 +0.044 [0.030, 0.057]（同上，1,590 篇），差为 +0.028 [0.011, 0.045]（同上，两项均值之差），两项预注册判据都通过。名的第一个 token 最强（L40 +0.124（1,706 篇，[0.108, 0.142]），L56 +0.163（[0.145, 0.181]））。原 E4b 只给每位作者的第一个 token 打分，而这个 token 多半是首字母，所以它低估了标题位置携带的名字信息。两种置换对照在姓、名的其余 token 上约为 0；在首字母上约为 +0.02（随机论文 / 同领域论文的作者作金标准；e4b_alltok.md 第 7 节），说明首字母的信号约一半不针对具体论文。认得出的论文在标题位置携带更多名字信息，这一差别主要来自首字母和名（L24–L32 起为正，+0.02 到 +0.09（引用档内目标 − 对照；e4b_alltok.md 第 3 节））；按逐个假标题排除、5 个假标题平均，姓的第一个 token 的 target − control 从 L24 起为正（L40 +0.030（引用档内 target − control，[0.013, 0.048]，团队聚类 95% CI；381_stage13/reports/b1_e4b5_report.md “Per-donor exclusion” 节），L56 +0.058（同上，[0.039, 0.078]））；只用 false_0、样本较小时，L56 前不显著（false_0 版本，1,395 篇；同一报告 V0 表）。probe 的定义：输入是第 l 层标题最后一个 token 的残差；目标是模型自己在 L63、在预测该角色名字 token 的位置上的状态，按论文平均；ridge，按作者团队分折；在 9,137 个名字 token 的词表里解码；标题特异 = 真标题 − false_0。批次 1 第 4 项（2026-11-06）：E4b 5 个假标题（偏离 D1 逐个假标题排除，保留 4,654 篇，平均 1.5 个假标题）：L40 姓首 token +0.076 [0.068, 0.083]，姓 − 首字母 +0.033 [0.023, 0.042]，原 E4b 第一个 token +0.066；置换对照首字母仍 +0.018，其余 ≈ 0；硬检查 E4b L40 +0.0609 PASS（381_stage13/reports/b1_e4b5_report.md 第 2 节与 “Per-donor exclusion” 节，目标 + 对照，团队聚类 95% CI）。不剔除标题复用的敏感性分析（补充 13 C-3、C-3b）含泄漏，只作敏感性分析，不作结论：C-3b 硬检查 PASS，L40 姓的第一个 token +0.077 [0.071, 0.084]、首字母 +0.034 [0.029, 0.039]、姓 − 首字母 +0.043 [0.035, 0.051]（6,841 篇；381_stage13/reports/c13_C3b.md），target − control 的区间几乎处处在 0 以上，与 C-3 一样。

What we learned: read early, spoken late

Read early	Causally the title is read in L24–L50 and gathered at the name positions by L52, then no longer needed. A probe at the title token reads a little of it from L24 (re-checked).
Spoken late	At the name positions, paper-specific author knowledge becomes lens-readable only from ~L50, fastest over L57–L61.
No lens lead	Read with a lens at the names, target is not ahead of control in middle layers; the +0.21 gap is at the end (Stage 10, final L63, §6.4) (probe at the title: target − control +0.03–0.08, re-checked (Stage 13 E4b, first name token only)).
Real knowledge	Name prior is ~1/3 of the gap overall but ~0 on surnames (Stage 12 A, 0.087 / 0.247, §6.12); the rest is paper-specific and grows with citations.
Lenses agree	Jacobian lenses read more in middle layers, but nothing target-specific.
Name format	Initials carry little; full given names carry as much as surnames and help predict them.

第 73 / 82 页 · deck 第 14 页 按 deck 讲稿备注翻译（已按复核结果更新）

总结。一句话：读得早，说得晚。标题在 L24 到 L50 被读进来，证据是替换、阻断和标题 token 上的 probe；但作者名字要到 L57 到 L61 才在名字位置变得可读。lens 的结果（目标组在中间层没有领先）和 probe 的结果（标题 token 上目标组有优势）说的是不同的位置，两者不矛盾。（probe 的数字已按作者团队分折、剔除标题复用后复核：+0.05 到 +0.08（Stage 13 E4b 复核，标题最后一个 token 上的线性 probe，probe 只打分每位作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，全部 1,863 篇：L24 +0.050、L40 +0.061、L56 +0.075（L24–L60 为 +0.047 到 +0.075），论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第一张表），目标组高 +0.03 到 +0.08（同上 E4b 复核，probe 只打分第一个名字 token，引用档内 目标−对照，目标 896、对照 499 篇，L24–L60 为 +0.035（L44）到 +0.078，论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第二张表）。）注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Limits

Done: Stage 12

- Single-position patching (P1); attention vs MLP (P2, hook check passed)
- Name priors (N1, N2); author-prompt lens (F1, F2): middle layers still not readable

Done: Stage 13

- Probes read year, citations, field at the title from ≤L16 (M2); identity not above the L4 text level (M3)
- Replacement is task-independent (X1); paraphrase meaning beyond wording in L28–L40, not separable from paper identity (X3)
- First author decodable at L8, may be text-explainable (X4); 5 false titles confirm the Stage 11 timing (X6, X7)

Limits

- One model (Qwen3-32B)
- Teacher-forced preference, not generation
- Labels from the team lead's package; labelling code (elm) not available
- H2 (paper identity) partly supported but not established; H3 (hidden author knowledge): insufficient evidence

局限。Stage 12 和 13 都已完成。Stage 12 做了逐位置替换（P1）、注意力与 MLP 的替换（P2，显式的 hook 检查已通过）、两个名字先验基线（N1、N2）和在作者提示词上拟合的 lens（F1、F2），中间层仍然读不出名字。Stage 13：probe 从 L16 或更早在标题处读出年份、引用数和领域（M2），但 M3 不超过 L4 的文字水平；替换效应与任务无关（X1）；改写标题在 L28–L40 有超出用词的语义，但与论文身份分不开（X3）；第一作者在 L8 可解码，但可能来自标题文字（X4）；X6/X7 用 5 个假标题（Stage 13 X6 用 false_0–false_4 五个假标题重做 Stage 11 替换（L48 平均 0.821、L52 0.995），X7 在 false_0 运行上重做阻断；381_stage13/reports/x6_report.md、x7_report.md）确认了 Stage 11 的时间。局限：只有一个模型；测的是教师强制下的偏好，不是生成；标签来自组长的数据包，elm 标注代码拿不到；H2 部分支持但未确立，H3 证据不足。

Added after the defence

Added after the defence (2026-11-05)

Group comparisons (plan fixed before the results: addenda 7, 8) · CPU leftovers (post-hoc) · experiments still running

1. Group comparisons A / B / C / D: three findings, intervention re-runs (E1 and P1 / P2 numerator / denominator), recognition
2. CPU leftovers on existing data: X5 retrieval curve, M3 scores, N2 by layer, paper vs team intervals, M5
3. Redo programme (addenda 10–14): done, batch 1 (only P1 / P2 with five false titles still running), batches 2 and 3; limits that cannot be redone

75

第 75 / 82 页 · Added after the defence · 合并 PPT 自身页面 **新写讲稿**

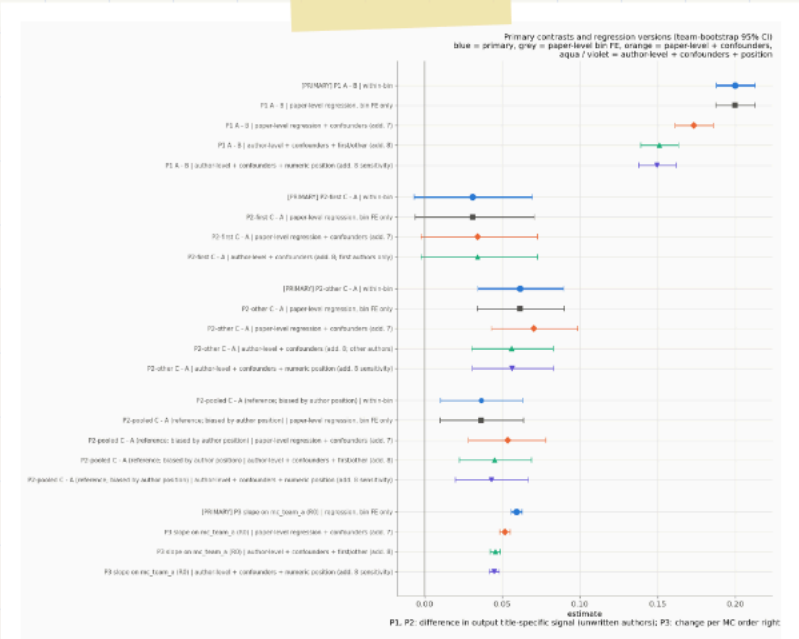
这一部分是答辩（2026-11-02 定稿）之后新增的内容。分组对比是答辩后新增的分析，分析计划在看结果前写定（补充 7、8）；CPU 补充分析是事后分析，只作描述；重做计划（补充 10–13）的规则都在看结果前写定。X2 和补充 9 的结果放在 Stage 13 部分。

Added after the defence · groups

Group comparisons: three findings

Plan fixed before the results (addenda 7, 8) · unwritten authors only · output (L63) title-specific signal · within citation bin · team-bootstrap 95% CI · Holm over 4 tests

- **1 Recognition:** with no author written (R0), recognised papers (A) beat unrecognised ones (B) by **+0.200 [0.188, 0.213]**(P1 A − B, 3,417 / 2,148 papers, Holm p ≤ 0.002; primary.csv); with confounders +0.173 [0.161, 0.186](paper level, 5,565), author level + position +0.151 [0.139, 0.163](19,893 authors)
- **2 Graded:** each extra multiple-choice order right adds **+0.059 [0.056, 0.063]**(P3, 8,288 R0 papers, bin FE; Holm p ≤ 0.002) (confounders +0.046 [0.042, 0.049](author level)); ≈ 0.17 with none right, ≈ 0.46 with all four(R0, 927 / 4,105 papers; stage10_curves.csv)
- **3 Partial recall helps little (≈ ⅓ of recognition), output only:** C − A co-authors **+0.061 [0.034, 0.090]**(P2-other, 390 / 2,826 papers, Holm p ≤ 0.002), first author +0.031 [−0.006, 0.069], n.s.(P2-first, 292 / 3,199); ≈ 0 at L48–L62 with the logit lens, −0.07 to −0.11 at L48–L59 with the public J-lens(stage10_contrasts.csv, unwritten_other). The earlier ≈ +0.11 used all authors (circular)(r0_r1_analysis.md §2)
- **Reference only:** R2 written authors +0.844(200 papers; summary_table.md); only 28 R2 papers have unwritten authors(same)



Primary contrasts (blue) and regression versions; team-bootstrap 95% CI (391_groups/figures/fig3)

第 76 / 82 页 · Added after the defence · groups · 合并 PPT 自身页面 新写讲稿

分组对比，答辩后新增的分析，分析计划在看结果前写定（补充 7、8）。只比较模型没写出的作者，指标是输出层（L63）的标题特异信号（真标题 − 5 个假标题平均）。发现 1，识别的效应：两组都一个作者没写对（R0）时，在模型没写出的作者上，认得出的论文（A）比认不出的论文（B）在输出层的标题特异信号高 +0.200 [0.188, 0.213]（分组对比 P1 A − B，A 3,417 / B 2,148 篇、10 个引用档，引用档内差，团队聚类 95% CI；Holm 校正后 p ⩽ 0.002，受 2,000 次重抽的分辨率限制；391_groups/primary.csv）。控制领域、年份、作者人数和首字母开头名字的比例后：论文层面 +0.173 [0.161, 0.186]（5,565 篇；primary.csv）；作者层面再加作者排位 +0.151 [0.139, 0.163]（19,893 位作者；primary.csv）。发现 2，识别程度与信号成梯度关系：在 R0 论文里，多选题 4 种选项顺序中每多答对一次，输出层信号高 +0.059 [0.056, 0.063]（P3，R0 论文 8,288 篇，引用档固定效应；primary.csv）；控制混杂后 +0.046 [0.042, 0.049]（作者层面，30,060 位作者）。全错时约 0.170，全对时约 0.463（0 种对 927 篇 0.170、4 种对 4,105 篇 0.463；391_groups/stage10_curves.csv）；识别不确定的论文落在两组之间。发现 3，写对一部分作者，对没写出的作者的额外帮助较小（约为识别效应的三分之一），而且只出现在最终输出：合作者 +0.061 [0.034, 0.090]（P2-other C − A，C 390 / A 2,826 篇，Holm p ⩽ 0.002；primary.csv），第一作者 +0.031 [−0.006, 0.069]，不显著（P2-first，C 292 / A 3,199 篇；primary.csv）。logit lens 下 L48–L62 约为 0（P2-other 按层，logit lens −0.019 到 +0.035，区间都含 0）；公开 J-lens 下 L48–L59 为 −0.07 到 −0.11（public J-lens，区间都在 0 以下；391_groups/stage10_contrasts.csv）。以前用全部作者算出的约 +0.11（351_stage10/reports/r0_r1_analysis.md §2），主要是因为模型已经写出的作者分数本来就高（循环论证）。参照：R2 写出的作者在输出层为 +0.844（200 篇；391_groups/summary_table.md），只作上限参照；R2 里有未写出作者的论文只有 28 篇，不做对比。

Added after the defence · re-runs

Re-runs: numerator and denominator

Addendum 8 · E1 recovery R = mean(patched − false) ÷ mean(true − false) · unwritten authors · team-cluster 95% CI

group (unwritten authors)	papers	denominator: true − false	E1 numerator L48	E1 R(L48)	E1 R(L52)
A R0 × recognised	557	+0.407 [0.386, 0.430]	+0.330	+0.811 [0.790, 0.832]	+0.988 [0.980, 0.996]
B R0 × not recognised	586	+0.214 [0.196, 0.234]	+0.186	+0.869 [0.835, 0.906]	+1.016 [1.002, 1.031]
U0 R0 × uncertain	599	+0.293 [0.271, 0.316]	+0.248	+0.844 [0.814, 0.877]	+1.000 [0.988, 1.012]
C R1 × recognised (descriptive)	32	+0.464 [0.388, 0.538]	+0.335	+0.721 [0.650, 0.806]	+0.996 [0.968, 1.026]
R2 written authors (reference)	200	+0.845 [0.798, 0.897]	+0.566	+0.670 [0.630, 0.707]	+0.948 [0.927, 0.965]

B's higher ratio is a small-denominator effect: numerator B − A −0.010, −0.040, −0.144, −0.184 at L24 / L40 / L48 / L52, all CIs below 0(e1_e2_num_den_B_minus_A.csv) — B carries no more absolute paper-specific signal than A at any layer.

U0 timing as A and B (descriptive); R2 upper reference only; C 32 / D 5 / R2-unwritten 28 papers → descriptive(rerun_report.md Counts)

77

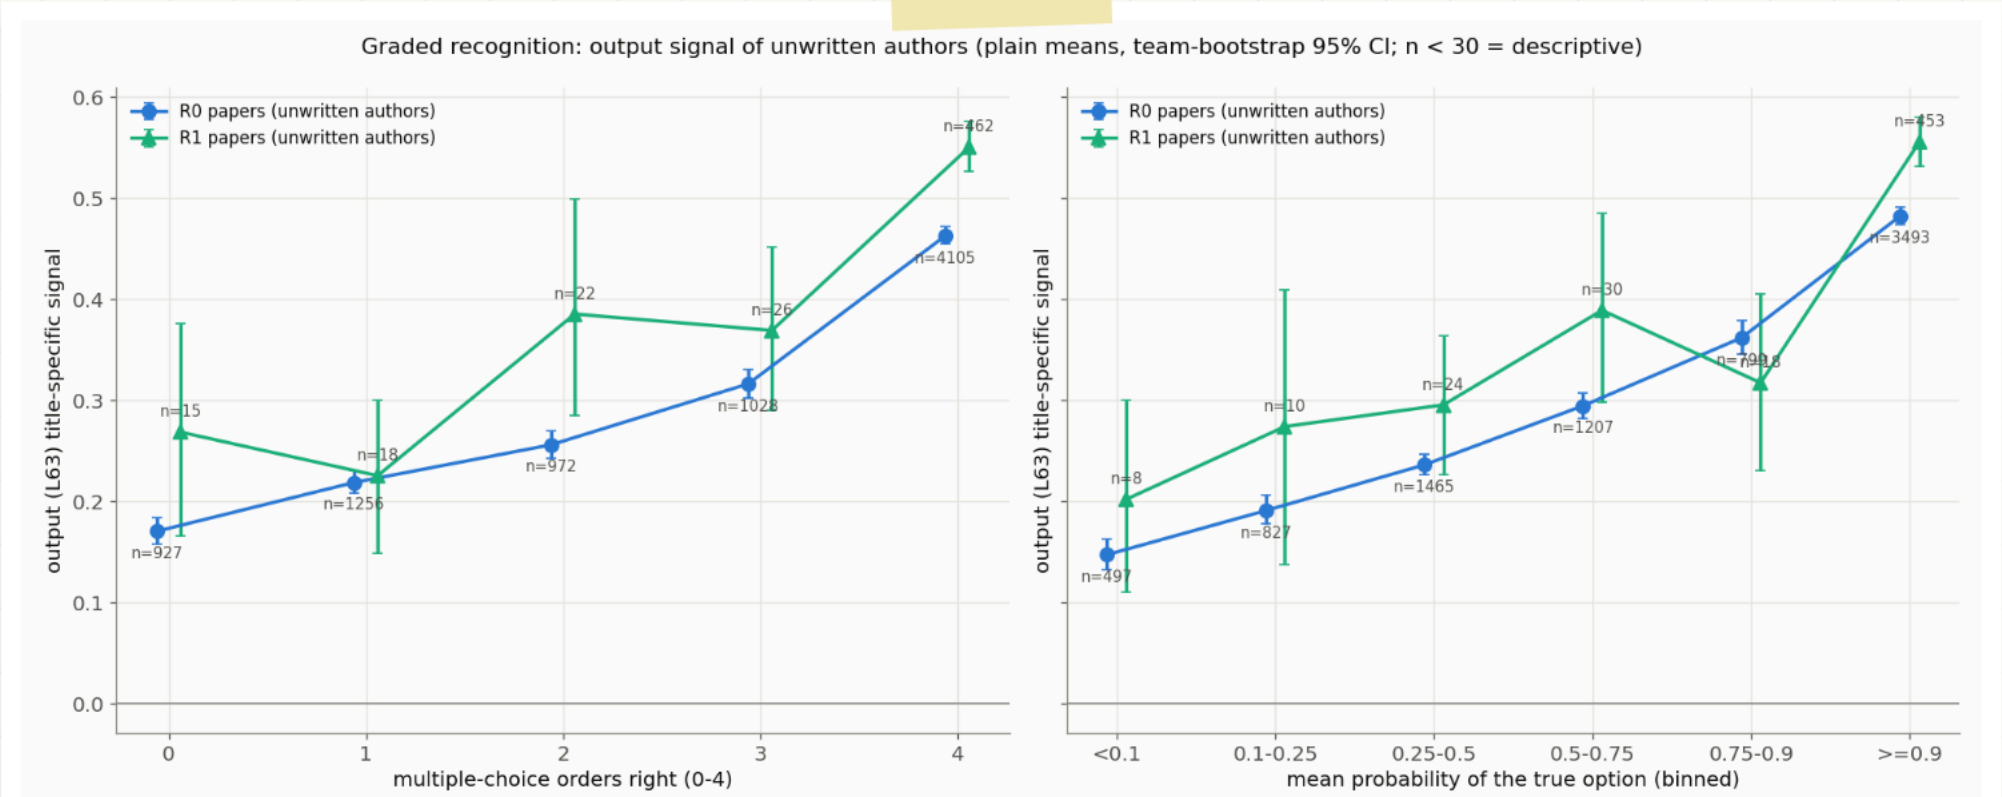
第 77 / 82 页 · Added after the defence · re-runs · 合并 PPT 自身页面 新写讲稿

补充 8 的干预重跑（R2 × strong 204 篇、R0 × uncertain 600 篇）与 Stage 11 原样本一起，只按模型没写出的作者汇总。E1 恢复比例 R = mean(替换 − 假标题) ÷ mean(真标题 − 假标题)。分母（真标题 − 假标题）：A 0.407、B 0.214、U0 0.293、C 0.464（E1，未写出作者，最终输出；A 557、B 586、U0 599、C 32 篇；391_groups/reports/e1_num_den.md）。分子 B − A 在 L24、L40、L48、L52 为 −0.010、−0.040、−0.144、−0.184，区间都在 0 以下（配对团队 bootstrap；391_groups/summary_rerun/e1_e2_num_den_B_minus_A.csv）：B 的恢复比例较高（L48 0.869 对 A 0.811（e1_num_den.md））只是因为分母约为 A 的一半（B/A 0.53），B 在任何一层携带的论文特有绝对信号都不比 A 多。U0 的时间点与 A、B 相同（R(L48) 0.844、R(L52) 1.000（U0 599 篇；rerun_report.md），描述）。R2 只作上限参照（写出的作者真假差距 0.845（R2 写出的作者 200 篇））；C 32 篇、D 5 篇、R2 未写出作者 28 篇（rerun_report.md Counts 表）只作描述。

Added after the defence · groups

Recognition changes the size, not the timing

Unwritten authors, output (L63) signal, plain means with team-bootstrap 95% CI; n < 30 descriptive



Left: multiple-choice orders right (0–4); right: mean probability of the true option. Blue R0, green R1 (391_groups/figures/fig2)

Re-runs: over 0–4 orders right the denominator rises 0.185 → 0.407, while E1 R(L48) stays flat, 0.90 → 0.81 (R0 papers A + U0 + B, 241 / 557 papers at 0 / 4; rerun_report.md "Continuous recognition")

第 78 / 82 页 · Added after the defence · groups · 合并 PPT 自身页面 **新写讲稿**

左图：R0 论文（蓝）未写出作者的输出层信号随多选题答对的选项顺序数从约 0.17 升到约 0.46（R0 未写出作者，最终输出 L63，简单平均，团队聚类 95% CI；0 种对 927 篇 0.170，4 种对 4,105 篇 0.463；391_groups/stage10_curves.csv；报告图 P5.2）。干预重跑：从 0 种到 4 种答对，真假标题差距（分母）从 0.185 升到 0.407（R0 论文 A + U0 + B，E1 分母；0 种对 241 篇、4 种对 557 篇；391_groups/reports/rerun_report.md Continuous recognition 表），而 E1 R(L48) 基本持平，从 0.90 到 0.81（同表 L48 列，0.904 [0.848, 0.965] → 0.811 [0.790, 0.832]）：识别程度改变信号的大小，不改变时间。P1 / P2 的分子 / 分母见下一页。

Added after the defence · re-runs

P1 / P2: the same small-denominator effect

Stage 12 single positions (P1) and attention / MLP (P2) split by group · unwritten authors · paired team bootstrap 95% CI

patched part	layer	numerator B − A	ratio B − A	numerator B/A
P1 all name positions	L48	−0.105 [−0.123, −0.087]	+0.052 [+0.011, +0.098]	0.57
P1 all name positions	L56	−0.183 [−0.209, −0.157]	−0.050 [−0.087, −0.012]	0.50
P2 attention	L48	−0.029 [−0.038, −0.021]	+0.057 [+0.030, +0.086]	0.66
P2 MLP	L56	−0.041 [−0.053, −0.029]	+0.008 [−0.030, +0.044]	0.54
P1 ':' only	L48	−0.000 [−0.007, +0.005]	+0.050 [+0.026, +0.071]	0.99
P1 ':' only	L52	−0.013 [−0.024, −0.002]	+0.073 [+0.038, +0.106]	0.79

B's higher P1 / P2 ratios also come from the small denominator: B's numerator is below A's at the name positions, in attention and in the MLP; at the ':' token the numerators are similar in L44–L48 (B/A 0.78–0.99), and B's ratio is higher only because its denominator is about half of A's(A 557 / B 586 papers; denominator B − A −0.192, B/A 0.53; p1_p2_num_den_B_minus_A.csv; e1_num_den.md P1/P2)

B 组的 P1/P2 比例偏高同样来自分母小：名字位置、注意力和 MLP 上 B 的分子都低于 A（Stage 12 P1 / P2 按组重算，未写出作者，最终输出，A 557 / B 586 篇；分子 B − A：名字位置 L48 −0.105 [−0.123, −0.087]、L56 −0.183 [−0.209, −0.157]，注意力 L48 −0.029 [−0.038, −0.021]，MLP L56 −0.041 [−0.053, −0.029]，配对团队 bootstrap 95% CI；391_groups/summary_rerun/p1_p2_num_den_B_minus_A.csv；reports/e1_num_den.md P1 / P2 节）；':' token 在 L44–L48 两组分子相近（B/A 0.78–0.99（只替换 ":"，分子 B/A：L44 0.78、L48 0.99；同一文件）），B 的比例高只因分母约为 A 的一半（分母 B − A −0.192 [−0.222, −0.162]，B/A 0.53；同一文件）。

Added after the defence · CPU

CPU leftovers on existing data (post-hoc)

No new GPU runs · descriptive only · not in the pre-registration except the X5 retrieval curve

- **X5 retrieval curve (pre-registered, computed now):** top-1 retrieval of the same paper across questions is never above L4(M3 cache, 9,108 papers; x5_retrieval.md) (title token 1.000 up to L44, 0.734 at the output)(same, team CI)
- **M3 behaviour scores:** year target − control +0.007 [0.003, 0.012]; first-author first token +0.147 [0.096, 0.191](output, 4,621 / 2,220, within bin, team CI; m3_scores.md)
- **N2 by layer:** pure name prior target − control +0.047 at the output, +0.039 at logit L62; public J-lens L48 −0.133 (true title)(Stage 12 N2 rescored by layer; n2_layers.md) → only L62 reproduces the output pattern
- **Paper vs team intervals:** width ratio 0.97–1.00 (median); "excludes 0" changes in 2 of 1,155 rows(X1, X4, X6, X7, M3; v42_paper_vs_team.md)
- **M5 true vs false title at the name positions:** output 0.919; logit L24 0.516 → L62 0.899(share of pairs, all papers × 5 false titles, team CI; m5_report.md); probe at title / colon AUROC 0.50–0.52(same, Part B)

 新写讲稿

答辩后补算的 CPU 分析，都用已有数据，属于事后分析，只作描述。X5 预注册的跨任务检索曲线：同一篇论文在三种问法下的标题状态能否在全部论文中检索回自己，没有一层高于 L4（X5 检索，M3 残差缓存，9,108 篇，top-1，团队聚类 95% CI；381_stage13/reports/x5_retrieval.md）；标题最后一个 token 上 L44 以前都是 1.000，最终输出 0.734（同上，[0.725, 0.742]）。M3 提示下的行为分数：年份 target − control +0.007（M3 年份分数，最终输出，目标 4,621 / 对照 2,220，引用档内差，团队 CI [0.003, 0.012]；381_stage13/reports/m3_scores.md），第一作者首 token +0.147（同上，[0.096, 0.191]），作者差与分组定义有关。N2 按层：纯名字提示 target − control 在最终输出 +0.047（Stage 12 N2，团队 CI [0.031, 0.062]；371_stage12/reports/n2_layers.md），logit lens L62 +0.039（同上）；public J-lens L48 真标题下 −0.133（同上，[−0.161, −0.107]），只有 L62 重现输出端的模式。论文与团队区间：宽度比中位数 0.97–1.00（381_stage13/reports/v42_paper_vs_team.md 第 1 节），“区间是否含 0”只在 1,155 行中的 2 行改变（同上第 2 节）。M5：名字位置上真标题运行胜过假标题运行的比例，最终输出 0.919（M5 Part A，全部论文 × 5 个假标题，团队 CI [0.915, 0.924]；381_stage13/reports/m5_report.md），logit lens L24 0.516、L62 0.899（同上）；标题和 “:” 位置用 probe 区分真/假标题运行，AUROC 0.50–0.52（同上 Part B），基本分不开。

Added after the defence · redo programme

Redo programme (addenda 10–14)

All rules fixed before the results · reproducing the published numbers is a hard check for every item · status 2026-11-06 evening

- **Done:** X7 with five false titles; all-token probe (addendum 9); CPU items C-1 to C-5; C-3b (no-exclusion sensitivity, includes leakage, not a conclusion)
- **Batch 1, done:** X1–X4 for all authors → conclusions unchanged (X1 task-independent, small L48 author – year +0.024; X3 keeps ≈ 90%; X4 from L8; X2 moves 0.032, subspace $R^2 \leq 0.009$, H3 still insufficient)(b1_xall_report.md) · E4b minus five false titles: surname L40 +0.076 [0.068, 0.083], surname – initial +0.033(b1_e4b5_report.md)
- **Batch 1, running:** P1 / P2 with five false titles — 116 / 194 units done, 78 left in three parallel chains; result after approval
- **Batch 2 (addenda 11, 12):** code, tiny tests and hard-check unit tests done; starts automatically after batch 1; deviations recorded (D12-1 to D12-3; 2-7 source = year-free X4 prompt)(prereg_addendum12_deviations.json)
- **Batch 3 (addendum 14):** 3-1 Stage 10 L41–L47, L49 · 3-2 L0–L23 · 3-3 Stage 7.1B fast path: code in progress; 3-4 / 3-5 (Stage 8 GPU W) not run(prereg_addendum14.json)
- **Not done:** Stage 8 GPU re-run of the original W (user decision 2026-11-06; CPU proxy C-2 instead)(c13_C2.md)

重做计划（补充 10–14，规则都在看结果前写定并锁定；复现已发表数字是每一项的硬检查）。已完成：X7 五个假标题、补充 9 全部名字 token 的 probe、CPU 项 C-1 到 C-5（381_stage13/reports/b1_x7f_report.md、e4b_alltok.md、c13_C1.md–c13_C5.md）；C-3b（不剔除标题复用，只作敏感性分析，含泄漏，不作结论）（c13_C3b.md）。批次 1 已完成：X1–X4 改为给全部作者打分（全部名字 token），并按作者排位分层。结论都不变：X1 仍与任务无关，L48 有一点小而确实的任务依赖（作者 – 年份 +0.024 [0.019, 0.030]）；X3 改写标题保留约 90% 的作者偏好，target 与 control 一样；X4 从 L8 起可解码出作者，各作者排位相同，认得出的论文在 L8–L40 更高；但只靠标题文字的基线不弱于 Qwen，仍不能排除标题文字的解释。X2 用全部作者重新拟合作者子空间后，搬动量从 0.016 升到 0.032（完整替换的约 7%），但子空间本身仍几乎解码不出作者（留出 $R^2 \leqslant 0.009$），H3 仍证据不足（补充 10 第 1 项，硬检查 PASS；381_stage13/reports/b1_xall_report.md）。E4b 5 个假标题（偏离 D1 逐个假标题排除，保留 4,654 篇，平均 1.5 个假标题）：L40 姓首 token +0.076 [0.068, 0.083]，姓 – 首字母 +0.033 [0.023, 0.042]，原 E4b 第一个 token +0.066；置换对照首字母仍 +0.018，其余 ≈ 0；硬检查 E4b L40 +0.0609 PASS（381_stage13/reports/b1_e4b5_report.md）。批次 1 还在运行：P1/P2 用 5 个假标题，194 个单元已完成 116 个，其余 78 个分三条并行作业链计算，结果经用户确认后补入。批次 2（补充 11、12）：代码、tiny 测试和硬检查的单元测试都已完成，批次 1 结束后由编排作业自动开始；与预注册的出入记在补充 12 出入记录 D12-1 到 D12-3（2-1、2-2 用较省但包含原始提示逐位复现重拟合的硬检查；2-11 重建标签、论文内 AUROC、两个基线、对照组只作描述）（381_stage13/config/prereg_addendum12_deviations.json），2-7 的来源改用不含年份的 X4 提示。批次 3（补充 14）：3-1、3-2、3-3 代码在写；3-4、3-5 不做（Stage 8 按原 W 的 GPU 重算，用户 2026-11-06 决定）（381_stage13/config/prereg_addendum14.json）。

Added after the defence · limits

Limits that cannot be redone

Written 2026-11-06

- **One model:** the groups (recognised or not, authors written or not) come from Qwen3-32B's own labels; another model would need new labels
- **Teacher forcing:** every score is the rank the model gives the correct name once it is in the prompt — a preference, not generation
- **Label pipeline:** the label package author's elm code and run.json are not on the cluster, so generation length, thinking mode and the multiple-choice setup cannot be re-checked
- **High-citation bins:** the 4097+ bin has no B / D papers(84 target, 0 control; m3_scores.md §2), so within-bin comparisons cannot use it

 新写讲稿

不能补做的局限（2026-11-06 写定）：只有一个模型（分组标签来自 Qwen3-32B 自己的标注，换模型要重新标注）；教师强制（测的是偏好，不是生成）；标注流程（标注包作者的 elm 代码和 run.json 不在集群上，开放回答的生成参数和多选题设置无法复核）；高引用档缺对照（4097+ 档没有 B / D 论文（Stage 10 队列 4097+ 档：目标 84、对照 0 篇；381_stage13/reports/m3_scores.md 第 2 节），引用档内比较用不到这一档）。