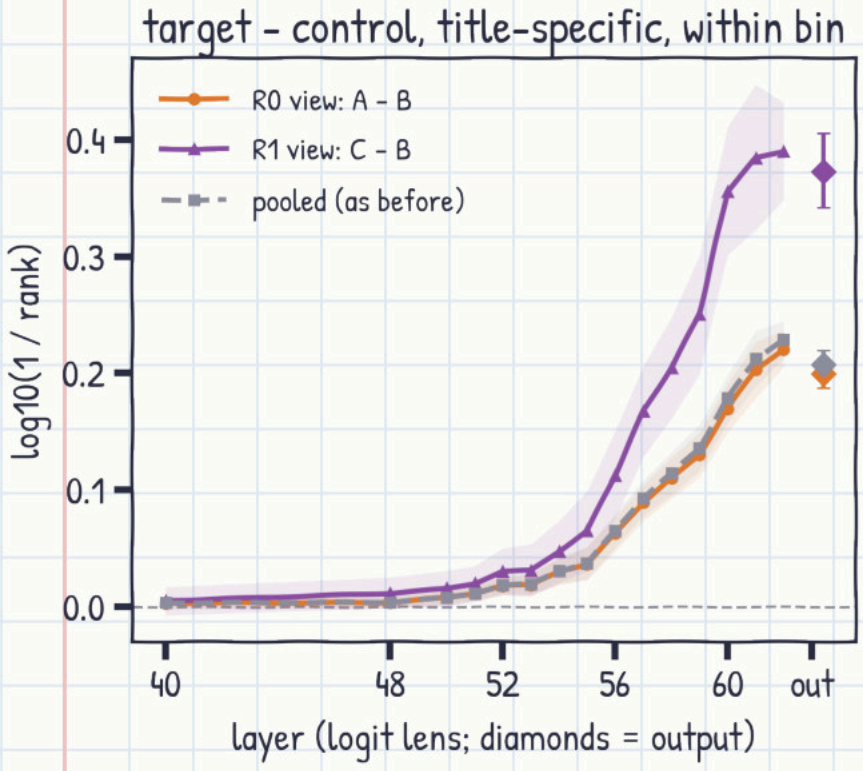
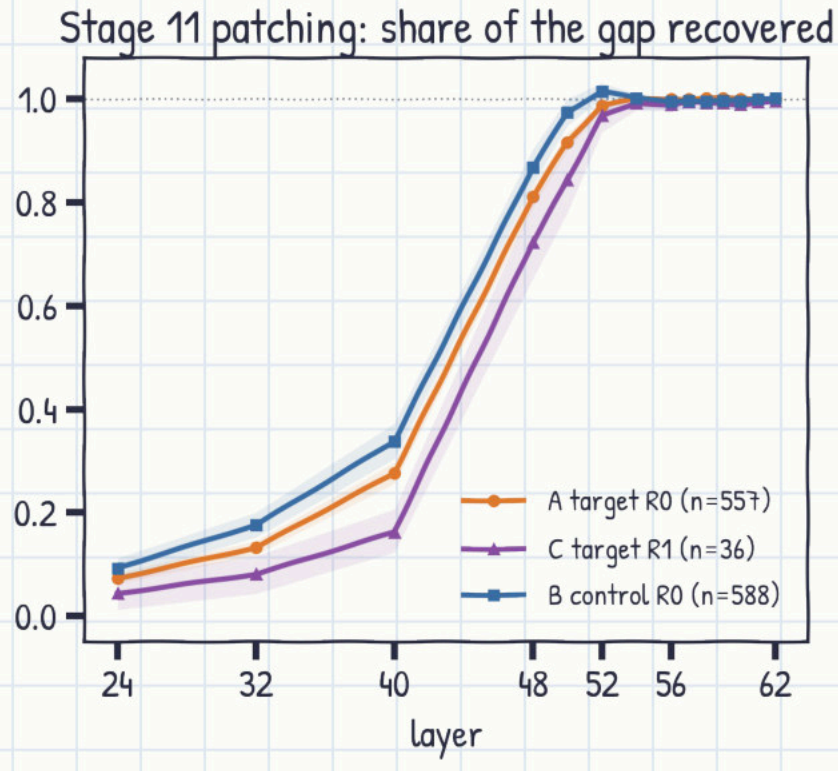
Stage 10–11

# Is it just the R1 papers? No.

R0 = no true author written · R1 = a few written · A/B/C/D = target/control x R0/R1




**R0 only (A – B):**

output +0.199 vs +0.207, same shape (Stage 10, A 3,423 / B 2,151, §6.13)

**R1 (C – B):** +0.37, also late (C 391 / B 885)

C – A within target: +0.11, from L56 (C 485 / A 3,204)

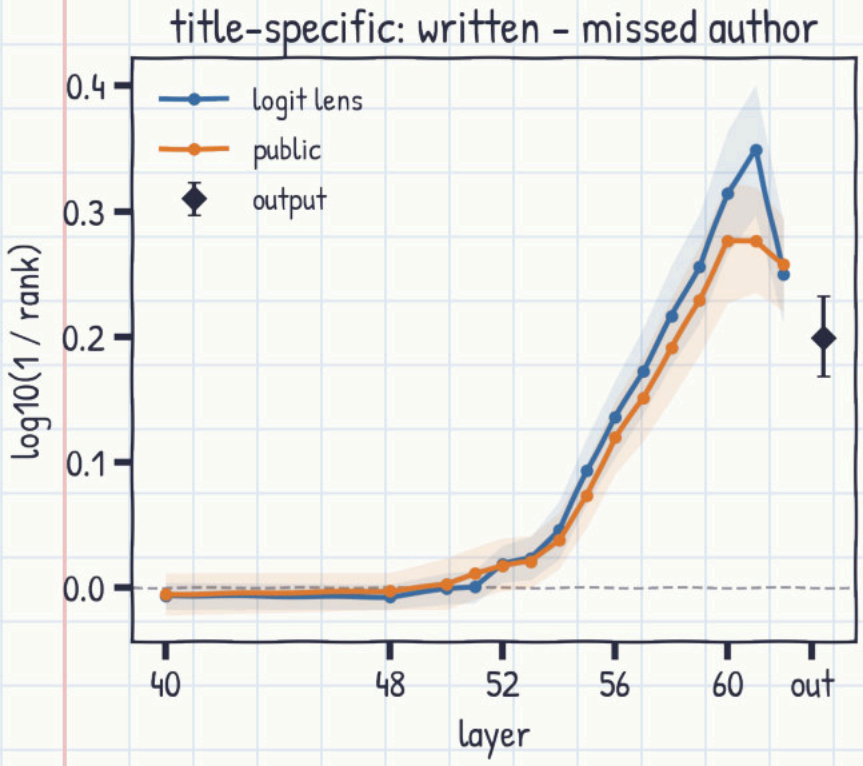
**patching:** R1 a bit later, done by L52 (Stage 11 E1, 36 R1 targets)

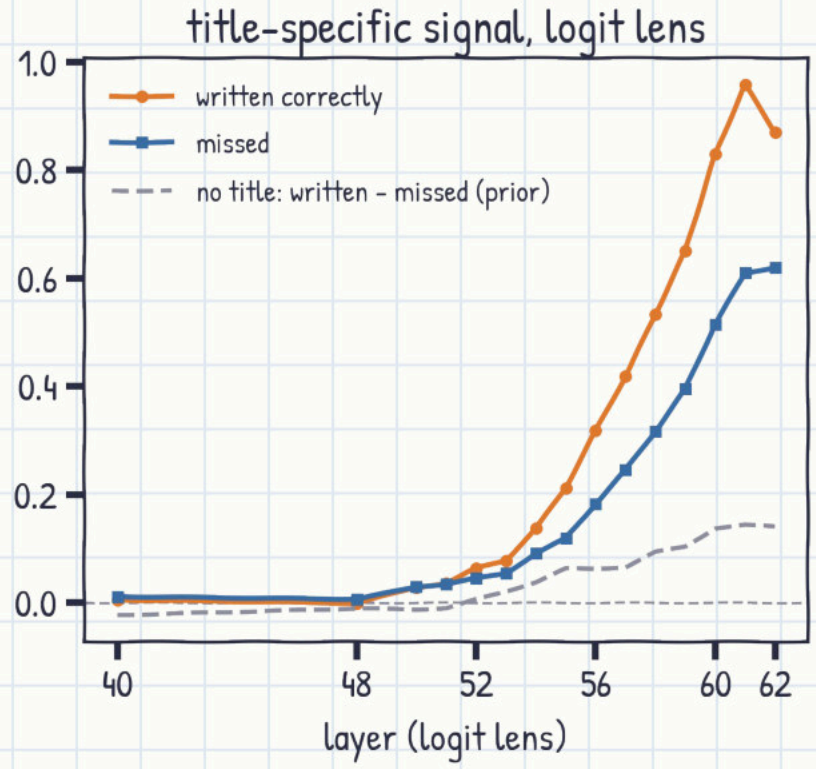
 按 deck 讲稿备注翻译（已按复核结果更新）

目标组的优势是不是只来自 R1 论文？目标组混合了 R0（开放回答一个真作者都没写对）和 R1（写对了一部分）；目标组里 11% 是 R1，对照组里只有 1.5%（目标组 R1 511 / 4,621 篇 = 11%，对照组 R1 34 / 2,220 篇 = 1.5%；351_stage10/reports/r0_sensitivity.md 第一张表；351_stage10/reports/r0_r1_analysis.md §0）。左图是三种口径下引用档内的目标–对照：只用 R0（A 对 B，即 Stage 1–9 的比较）输出处为 +0.199（Stage 10 只用 R0（A 对 B），真标题 – 5 个假标题平均，最终输出 L63，引用档内 目标–对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv），合并口径为 +0.207（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 – 5 个假标题平均，最终输出 L63，引用档内 目标–对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），曲线形状相同；R1 目标论文对 R0 对照为 +0.37（Stage 10，R1 目标（C）对 R0 对照（B），真标题 – 5 个假标题平均，最终输出 L63，引用档内，391 + 885 篇，+0.372 [0.342, 0.405]，论文 bootstrap 95% CI；351_stage10/reports/r0_r1_analysis.md §1；351_stage10/summary_r0r1/tc_R1target_vs_R0control.csv），它们更了解自己的论文，但同样要到 L52 之后才领先。对照组 R1 只有 34 篇（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表；D = 34），只做描述，不做检验。右图是按回忆程度分开的 Stage 11 替换曲线：R1 目标论文（36 篇）（Stage 11 样本中的 R1 目标论文 36 篇（对照 R1 5 篇）；351_stage10/reports/r0_r1_analysis.md §5；361_stage11/summary_r0r1/stage11_curves_by_recall.csv）恢复得稍晚，但到 L52 也全部恢复。标题位置的 probe 给出同样的结论：R0 口径为 +0.02 到 +0.04（Stage 11 E4b 原始版（论文分折、未剔除标题复用），标题最后一个 token 上的 probe，probe 只打分第一个名字 token，probe(真标题) – probe(false_0)，A – B 引用档内，A 4,110 / B 2,186 篇：L16 +0.018、L32 +0.034、L56 +0.038，bootstrap 95% CI 均在 0 以上；361_stage11/summary_r0r1/E4b_probe_by_recall.csv）（这是复核前按论文分折的数字）。结论不变。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

# Authors it wrote vs authors it missed

inside 495 R1 papers · paired within paper · 95% CI (Stage 10, r0_r1_analysis.md §4)




written − missed, output:
**+0.20** (Stage 10, final L63, 495 papers)

~0 up to L52, grows from **L54**

no title (prior): +0.10 (same, no title)

same without first authors

 按 deck 讲稿备注翻译（已按复核结果更新）

在 R1 论文内部，开放回答写对了一部分作者，漏掉了另一部分。标注包只记录了写对的人数，没有记录是哪几位，所以我们重建了匹配，重建出的人数在 99.3% 的 R1 论文里（重建匹配人数 = 标注包 m 的比例：R0 99.9%、R1 99.3%（596 篇）、R2 98.1%；351_stage10/reports/r0_r1_analysis.md §4；~/jlens_work/10_stage10/stage10_extra_r0r1.py）与标注包一致。在 495 篇同时有写对和漏掉作者的论文里（351_stage10/reports/r0_r1_analysis.md §4；351_stage10/summary_r0r1/R1_author_hits.csv），模型写对的作者在输出处的标题特异信号高 +0.20（Stage 10，R1 论文内 写对 − 没写对的作者（论文内配对），真标题 − 5 个假标题平均，最终输出 L63，495 篇，+0.199 [0.168, 0.232]，论文 bootstrap 95% CI；报告 R0/R1 节 §4 表；351_stage10/summary_r0r1/R1_author_written_minus_missed.csv），去掉第一作者后也一样。但这个差在 L52 之前约为 0（同上，logit lens L48 −0.007、L52 +0.019、L54 +0.046、L57–L61 +0.173 到 +0.349；351_stage10/summary_r0r1/R1_author_written_minus_missed.csv），从 L54 才开始上升：即使是模型真能写出来的作者，论文特有的信号也只在最后几层出现。另外，写对的作者在不给标题时也稍微好猜一些，高 +0.10（同上，不给标题（名字先验），最终输出 L63，写对 − 没写对 +0.097 [0.060, 0.134]，495 篇；351_stage10/summary_r0r1/R1_author_written_minus_missed.csv）。

Stages 1–9 · 20–200 papers

## What we saw

- True title helps: pilot L56 +9.3 pp(7.3, 50 papers); 200 new papers +5.2 pp(8D RQ1, 200 papers)
- A–B uncertain in the pilot; +5.0 pp on 200 papers but gone after dropping 10 pairs(8D RQ2, 100 pairs)
- Low – high citation: inconclusive

Stages 10–11 · 9,108 papers

## What scale showed

- Title-specific signal clear in every group, ≈0.44 at L62(L62, §6.9)
- target – control ≈0 at L24–L40, slightly negative at L48 (−0.04 to −0.05)(§6.4), +0.21 [0.20, 0.22] at the output(L63, §6.4)
- Name prior is only ~1/3 of the gap; ~0 on surnames(§6.12)
- Signal rises steadily with citations (ρ = 0.451)(§6.8)
- Same groups as the pilot (R0 only, A – B): +0.20 [0.19, 0.21] (R0, §6.13), same late shape
- R1 papers (C) know more (+0.11 over A)(§6.13) but are just as late

**Line A: from "the title helps" to "this paper, late, graded by fame"**

The pilot was right that the title matters. It could not see that the target advantage is real but confined to the last layers, so the 7-layer average and the L56 endpoint both diluted it. Restricting the full cohort to the pilot's A/B groups (R0 only) changes nothing: the R1 papers do not drive the result.

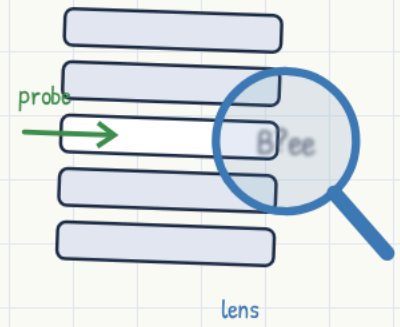




A 线的小结。小样本阶段看到：真标题有帮助，Pilot 在 L56 高 +9.3 个百分点（Stage 7.3，J-Lens L56，真标题胜率 − 20 个错误标题平均胜率，合并池，Pilot50 50 篇均值 +0.0934 [0.047, 0.139]（2026-10-30 重算区间，B = 20,000），35/50 篇为正；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv；报告 Stage 7.3 节），200 篇新论文上 +5.2（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节）；A–B 在 Pilot 中不确定，在 200 篇上是 +5.0（Stage 8D RQ2，J-Lens L56 匹配 A − B，100 对，+4.98 pp [0.32, 9.91]，配对 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ2_matched_A_minus_B）但去掉 10 对就消失（Stage 8D RQ2，J-Lens L56 金标准胜率匹配 A−B，100 对，均值 +4.98 pp，按 A−B 降序去掉前 10 对后其余 90 对均值 −0.39 pp（事后诊断）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）重算；报告 Stage 8D 节）；低引用减高引用没有定论。全量阶段看到：每组都有清楚的标题特异信号，L62 约 0.44（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）；目标−对照在 L24–L40 约为 0、L48 略为负（−0.037 到 −0.054，区间不含 0（Stage 10，引用档内目标−对照，三种 Jacobian lens L48 −0.037 到 −0.054；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）），输出处 +0.207 [0.20, 0.22]（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）；名字先验只占差距的约三分之一（Stage 12 名字先验拆解（CPU），最终输出 L63，全部名字 token，引用档内 目标−对照（目标 4,621、对照 2,220 篇）：先验 +0.087 [0.070, 0.103] ÷ 真标题差 +0.247 = 0.35；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv），在姓上约为 0（同上，姓的第一个 token，先验 目标−对照 +0.022 [−0.019, +0.063]，论文特有 +0.423 [0.393, 0.454]；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）；信号随引用数稳定上升（ρ = 0.451）（Stage 10 补充 X2，标题特异信号（真标题 − 5 个假标题平均，最终输出 L63）对 log10(引用数+1) 的 Spearman ρ，全部 9,108 篇 0.451 [0.433, 0.467]，bootstrap 95% CI；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv）；只用和 Pilot 相同的 R0 分组（A − B）为 +0.20 [0.19, 0.21]（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv），形状同样是后期才上升；R1 论文（C）比 A 多 +0.11（Stage 10，目标组内 R1 − R0（C − A），真标题 − 5 个假标题平均，最终输出 L63，引用档内（每格 ≥ 10 篇），C 485 + A 3,204 篇，+0.110 [0.086, 0.135]，论文 bootstrap 95% CI；351_stage10/summary_r0/target_R1_minus_R0_within_bin.csv；351_stage10/reports/r0_sensitivity.md），但时间点一样晚。小样本说对了标题重要，但没看出目标组的优势只在最后几层，所以 7 层平均（Stage 5–8 的积分终点 = 7 个源层平均（L63 不计入）；351_stage6/config/protocol.json "paper_integrated"；351_stage8/config/analysis_plan.json）和 L56 终点都把它稀释了。

Line B

# What can each readout see?




small samples asked

Is J-Lens better than Vanilla? Is the fitted lens stable?

→

the full cohort answered

Lenses read name shape earlier, not paper identity; a probe at the title token reads paper-specific information



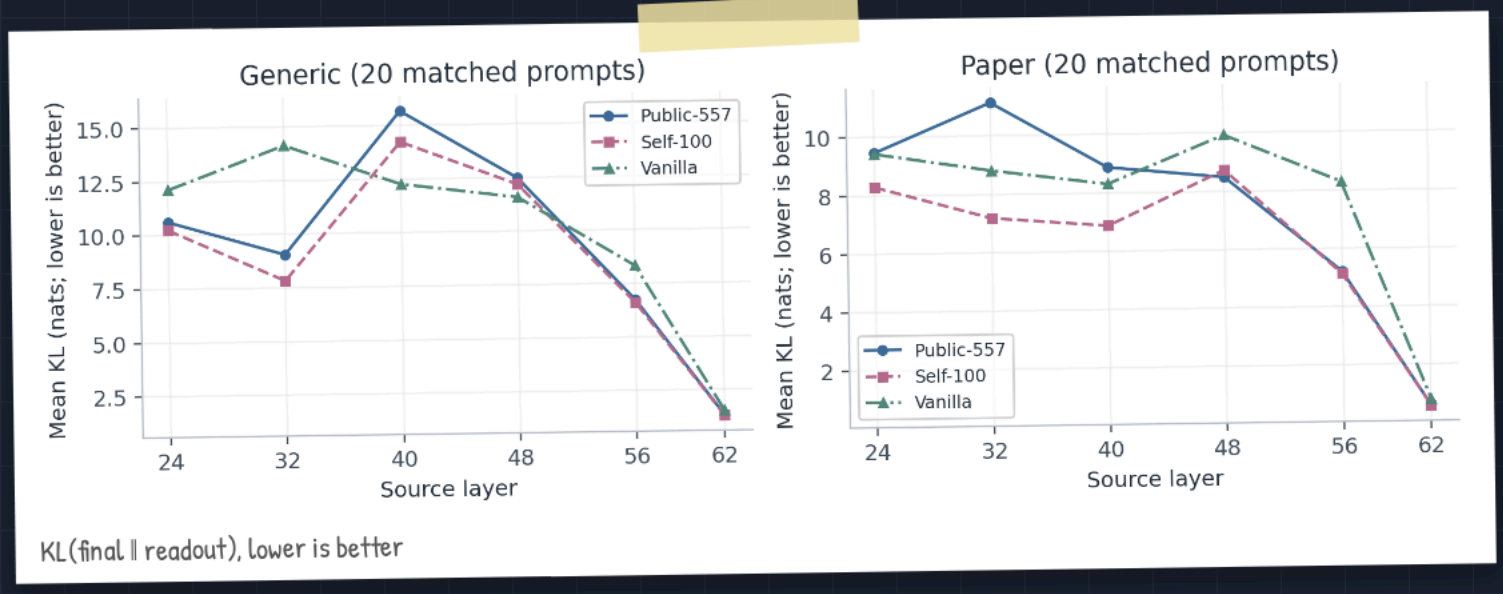


B 线的问题是：每种读出工具能看到什么？小样本阶段问的是 J-Lens 是否比 Vanilla 好，拟合出来的 lens 是否稳定。全量阶段的回答是：lens 在中间层更早读出的是“名字的样子”，而不是论文身份；而在标题 token 上训练的 probe 能读出论文特有的信息。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Stage 3 · Exp 1-4

# Two lenses: Public-557 vs Self-100

Can a middle layer approximate the final next-token distribution? (20 generic + 20 paper prompts)




- Both checkpoints numerically valid (63/63 and 6/6 finite)(matrices.csv; frobenius_norms.csv)
- Self-100 has lower KL on 6/6 generic and 5/6 paper layers (paper L32: 11.1 → 7.2) (20 + 20 prompts; metrics.csv)
- But at paper L62, Self-100 KL beats Vanilla (0.58 vs 0.81) while Top-10 overlap is worse (0.36 vs 0.72)(metrics.csv)
- Author pilot: both lenses 14/20 full-name wins at L48(20 papers, layer_summary.csv)

Lesson: a better distribution match does not mean better author ranking.
Fidelity cannot stand in for the task.



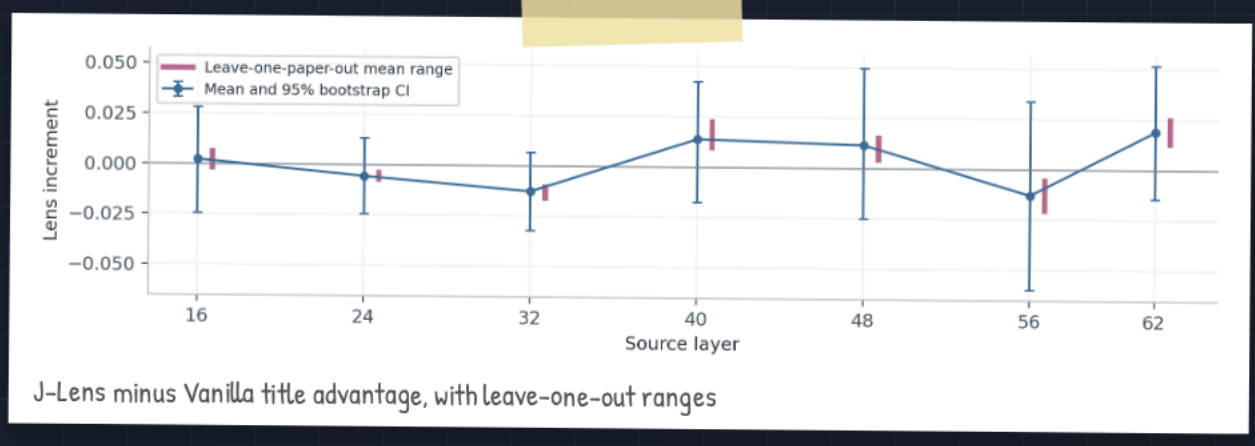
第 32 / 82 页 · Stage 3 · Exp 1–4 · 合并 PPT 自身页面 **新写讲稿**

Stage 3 比较两个 lens：公开的 Public-557 和我们自己拟合的 Self-100，问中间层能否近似最终的下一个 token 分布，用了 20 条通用提示和 20 条论文提示（Stage 3 Exp 2/4 提示集；~/jlens_work/02_self_lens_validation/351_self_jlens_validation.py:13-50）。两个检查点数值上都有效。Self-100 在 6 个通用层中的 6 层、6 个论文层中的 5 层（Stage 3 Exp 2/4，Self-100 − Public KL，各 20 条提示；351_self100_validation/summary/paired_bootstrap_ci.csv、summary/metrics.csv；报告 Stage 3 节图 3.1）KL 更低，例如论文提示 L32 从 11.1 降到 7.2（Stage 3，论文提示 20 条，L32 KL(final ‖ lens)：Public-557 11.135（351_all/351_paper_fidelity.log L32 jlens 行）→ Self-100 7.180（351_self100_validation/summary/metrics.csv paper/self100/32））。但在论文提示 L62，Self-100 的 KL 优于 Vanilla（0.58 对 0.81）（Stage 3，论文提示 20 条，L62 KL：Self-100 0.578、Vanilla 0.808；351_self100_validation/summary/metrics.csv（task=paper, layer=62, kl_final_to_lens_nats）），前 10 名重合度却更差（0.36 对 0.72）（同上，L62 前 10 名重合度：Self-100 0.355、Vanilla 0.720；351_self100_validation/summary/metrics.csv（top10_overlap））。作者小试中两个 lens 在 L48 都是 20 次里 14 次全名胜出（Stage 3 Exp 3，L48 全名胜率 0.70 × 20 篇，两个 lens 相同；351_self100_gold_false/archive/summary/layer_summary.csv 列 full_win_rate）。教训是：分布拟合得更好，不等于作者排名更好，保真度不能代替任务本身。

Stage 7.4 · Line B

# Cross-stage audit: does J-Lens add value?

Read-only joins of Stages 5–7.3; 20,000 bootstrap draws




J-Lens minus Vanilla title advantage, with leave-one-out ranges

| | |
|---|---|
| Stage 5 vs 7.3 at L56 | r = 0.45, ρ = 0.47; signs agree 32/50 (50 papers, cross_stage_correlations.csv) |
| J-Lens − Vanilla | +0.002 [−0.008, +0.012]; median −0.002; 24/50 positive (jlens_increment_bootstrap.csv) |
| A−B of that increment | −0.014 [−0.033, +0.004] (20 pairs) |

Dropping one paper can flip the sign of the J-Lens increment. The pilot shows **no added title-specific value** from J-Lens over Vanilla. Everything so far is exploratory: L56 was inspected repeatedly.



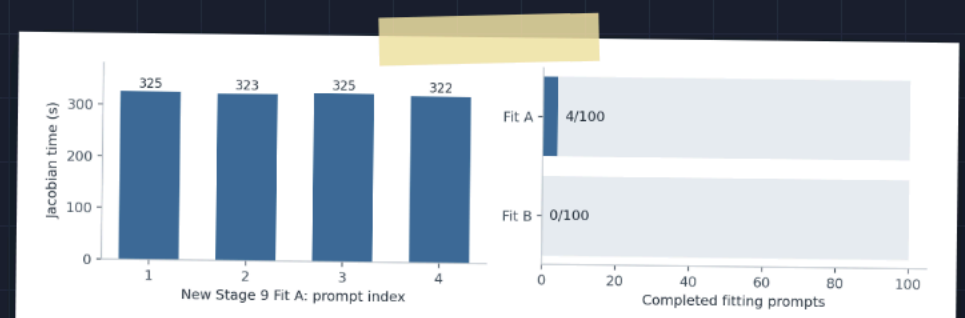
 新写讲稿

Stage 7.4 是跨阶段审计：J-Lens 到底有没有增加价值？只读地合并了 Stage 5 到 7.3 的结果，用 20,000 次 bootstrap（Stage 7.4 设计，种子 741；~/jlens_work/07_4_stage7_4/351_stage7_4.py:10-13）。Stage 5 和 7.3 在 L56 的相关为 r = 0.45，50 篇里 32 篇方向一致（Stage 7.4，J-Lens L56，Stage 5 与 Stage 7.3 的论文级相关，50 篇，Pearson 0.445，同号比例 0.64 = 32/50；351_stage7_4/summary/overview.json "L56_jlens_stage5_stage73"；351_stage7_4/summary/cross_stage_correlations.csv）。J-Lens 减 Vanilla 的标题优势为 +0.002 [−0.008, +0.012]，中位数 −0.002，50 篇里 24 篇为正（Stage 7.4，J-Lens − Vanilla 标题优势，7 层积分，50 篇，均值 +0.0022 [−0.0075, +0.0124]，中位数 −0.0019，24 篇为正，论文 bootstrap 95% CI；351_stage7_4/summary/jlens_increment_bootstrap.csv 行 integrated；overview.json）；这个增量的 A−B 为 −0.014（Stage 7.4，J-Lens 增量的匹配 A − B，20 对，−0.0139 [−0.0332, +0.0036]；351_stage7_4/summary/overview.json "matched_ab_difference_of_lens_increment"），区间含 0。去掉一篇论文就可能让 J-Lens 增量变号（Stage 7.4，逐一留出一篇后 7 层积分增量范围 −0.000046 到 +0.003494；351_stage7_4/summary/overview.json "integrated_jlens_minus_vanilla"）。Pilot 没有显示 J-Lens 比 Vanilla 多出任何标题特异的价值；而且到这里为止都是探索性的，L56 被反复看过。

# Stage 9: is the lens stable across fitting data?

New FullFit protocol, different from the historical 50+50 split

| | Historical split-half | Stage 9 FullFit |
|---|---|---|
| Fit data | Self-100 split 50 + 50 | two disjoint 100-prompt sets |
| Holdout | 20 generic + 20 paper | independent 100 WikiText |
| Layers | 6 | 7 (adds L16) |
| Status | complete | only Fit A completed; Fit B and holdout not run |




Archived progress: Fit A 4/100, Fit B 0/100 at the time of writing(351_stage9 checkpoints)

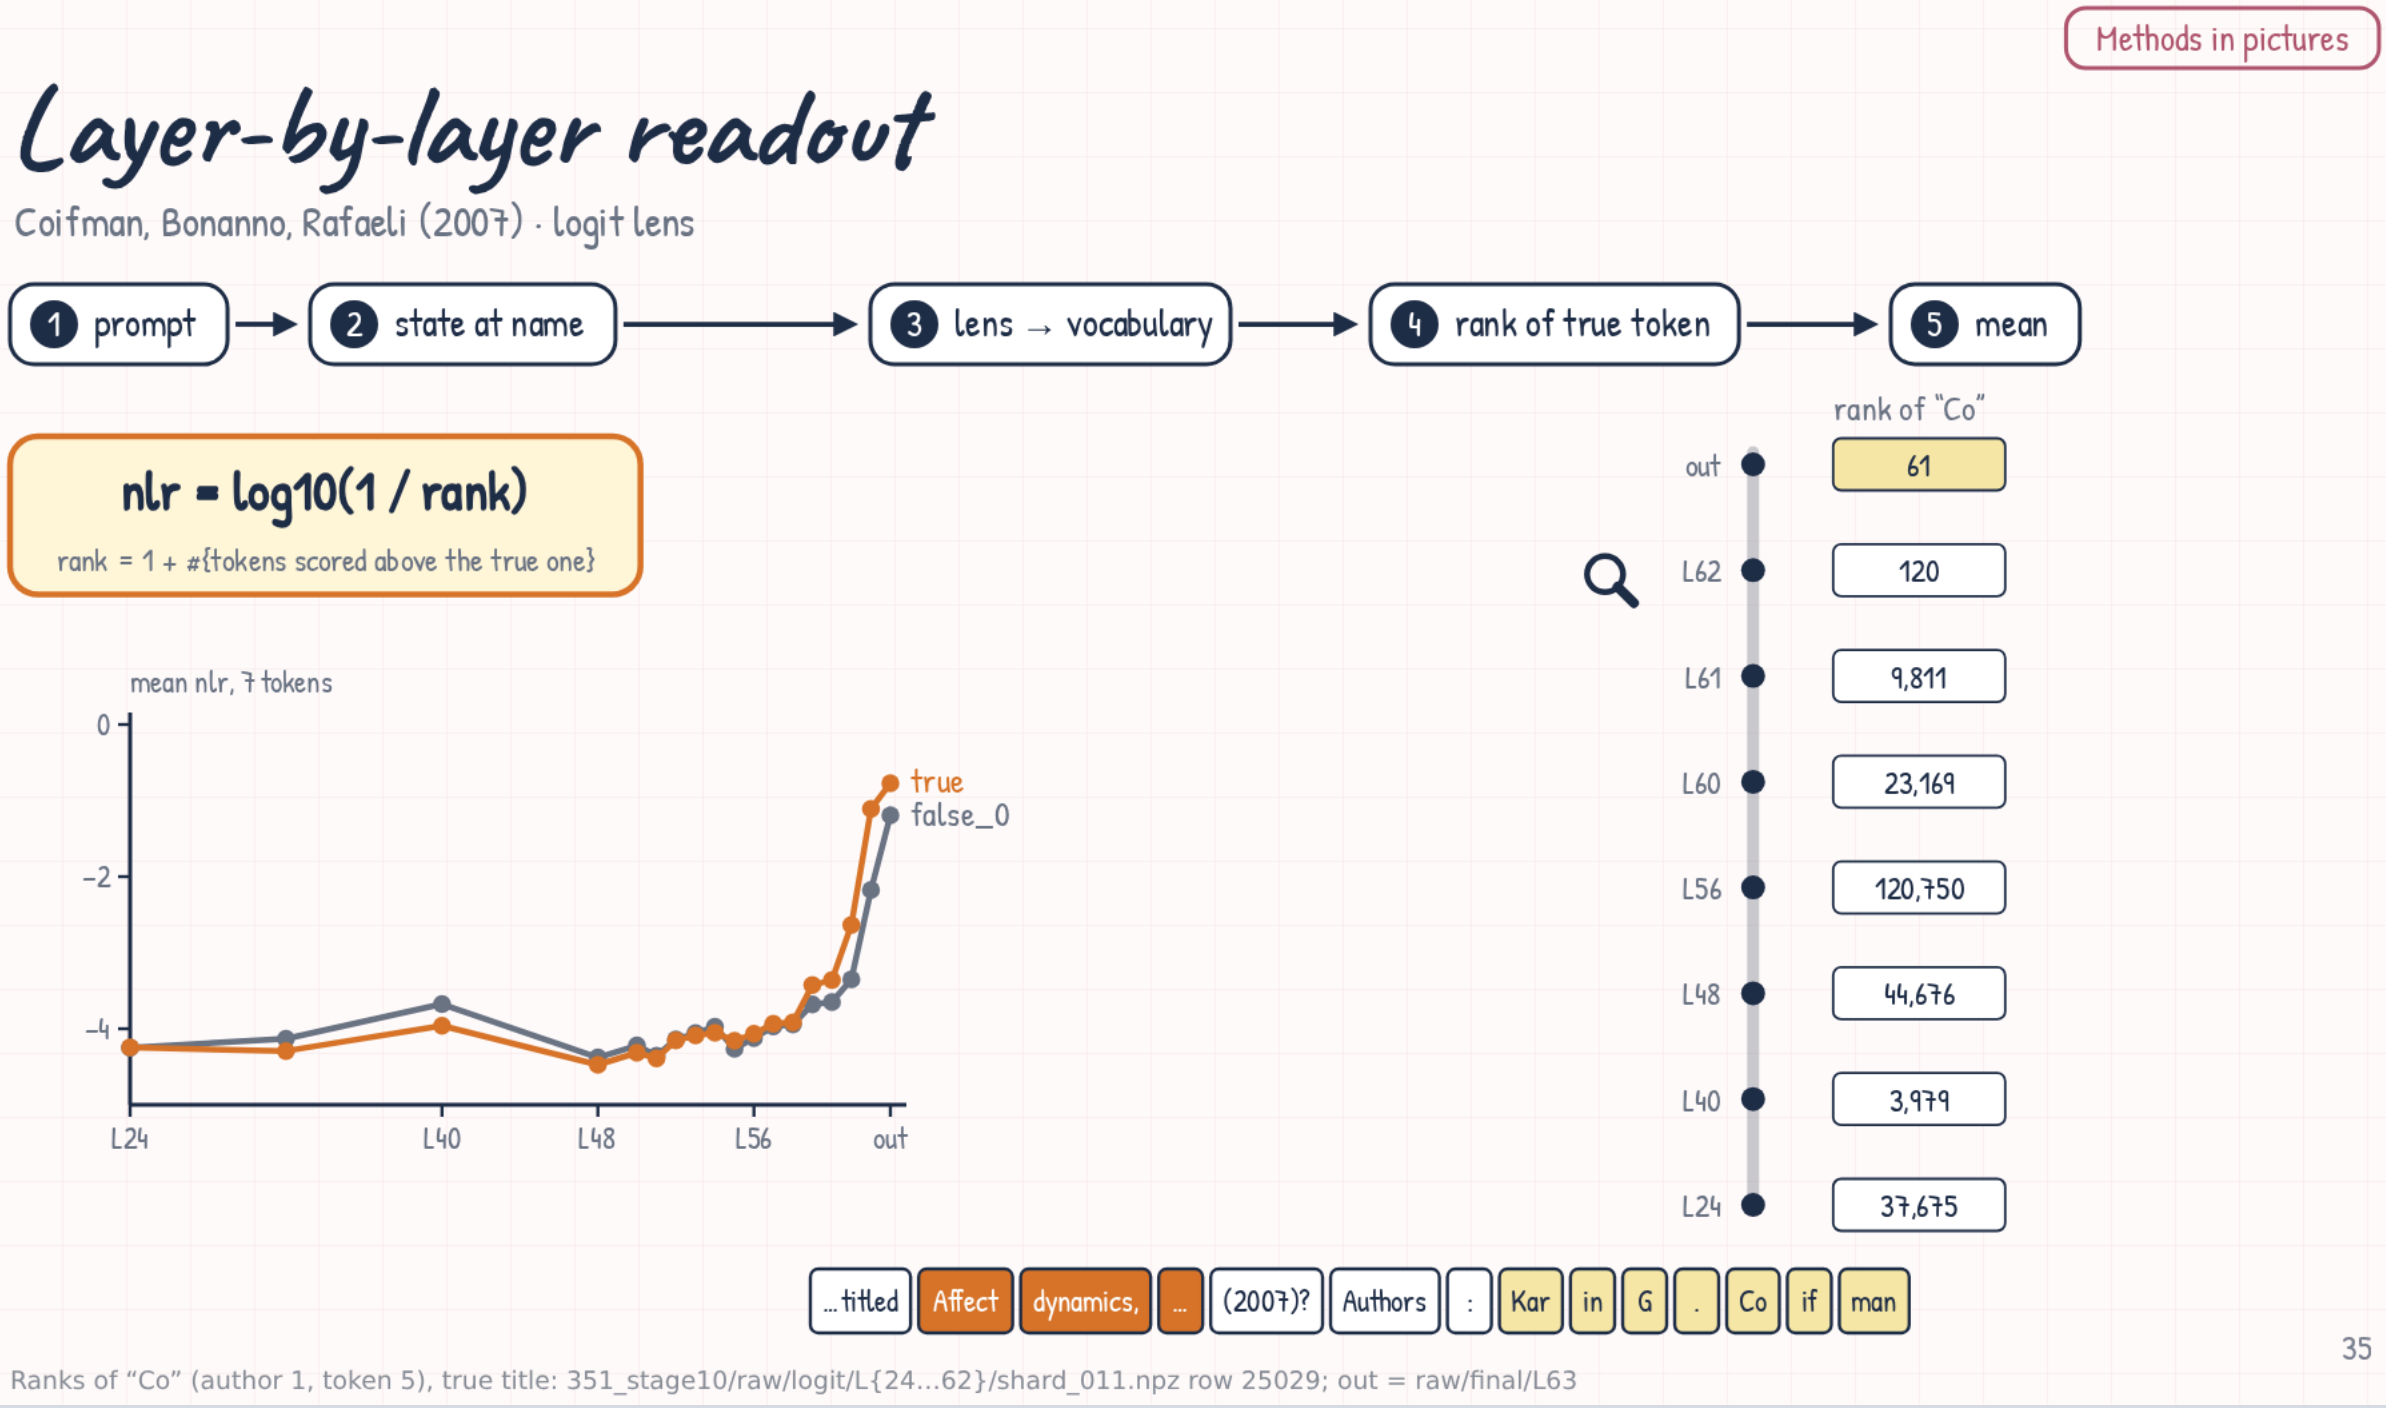
- WikiText-103 train, 100–1,200 chars, deduplicated by hash, seed 3519001
- ~324 s Jacobian time per prompt, ~62 GiB CPU RAM(full_A.log; benchmark log); per-prompt checkpoints

Only Fit A was finished, and Stage 10 used it as "fitA". Without Fit B and the holdout, fitting stability is **untested**.





Stage 9 想检验 lens 是否依赖拟合数据，用的是新的 FullFit 方案，和历史上的 50 + 50 拆分（Stage 3 Exp 7 历史拆分，偶数 / 奇数索引各 50 条；351_self100_split_half/fits/config_A.json、config_B.json）不同：两套互不重叠的 100 条提示，外加独立的 100 条 WikiText 留出集（Stage 9A.1 设计，FitA100 / FitB100 / Holdout100 各 100 条；351_stage9/config/plan.json、manifest.json "counts"；~/jlens_work/09_stage9/351_stage9.py:50-62），层数增加到 7 层（Stage 9 拟合层 L16–L62 共 7 层；351_stage9/runner_runs/full_A_100_7layers/fitting_config.json；351_stage10/config/lenses.json fitA）（加了 L16）。每条提示的 Jacobian 约需 324 秒、约 62 GiB CPU 内存（Stage 9 正式 Fit A 第 1–4 条每条 325/323/325/322 s（均值 323.75 s，351_stage9_full_A.log）；单条提示 7 层基准 CPU 内存峰值约 62.06 GiB（351_stage9_benchmark_A1_7layers.log)），每条存一次检查点。最后只完成了 Fit A，Stage 10 用的“fitA”就是它；Fit B 和留出比较都没做，所以 lens 的拟合稳定性还没有检验。



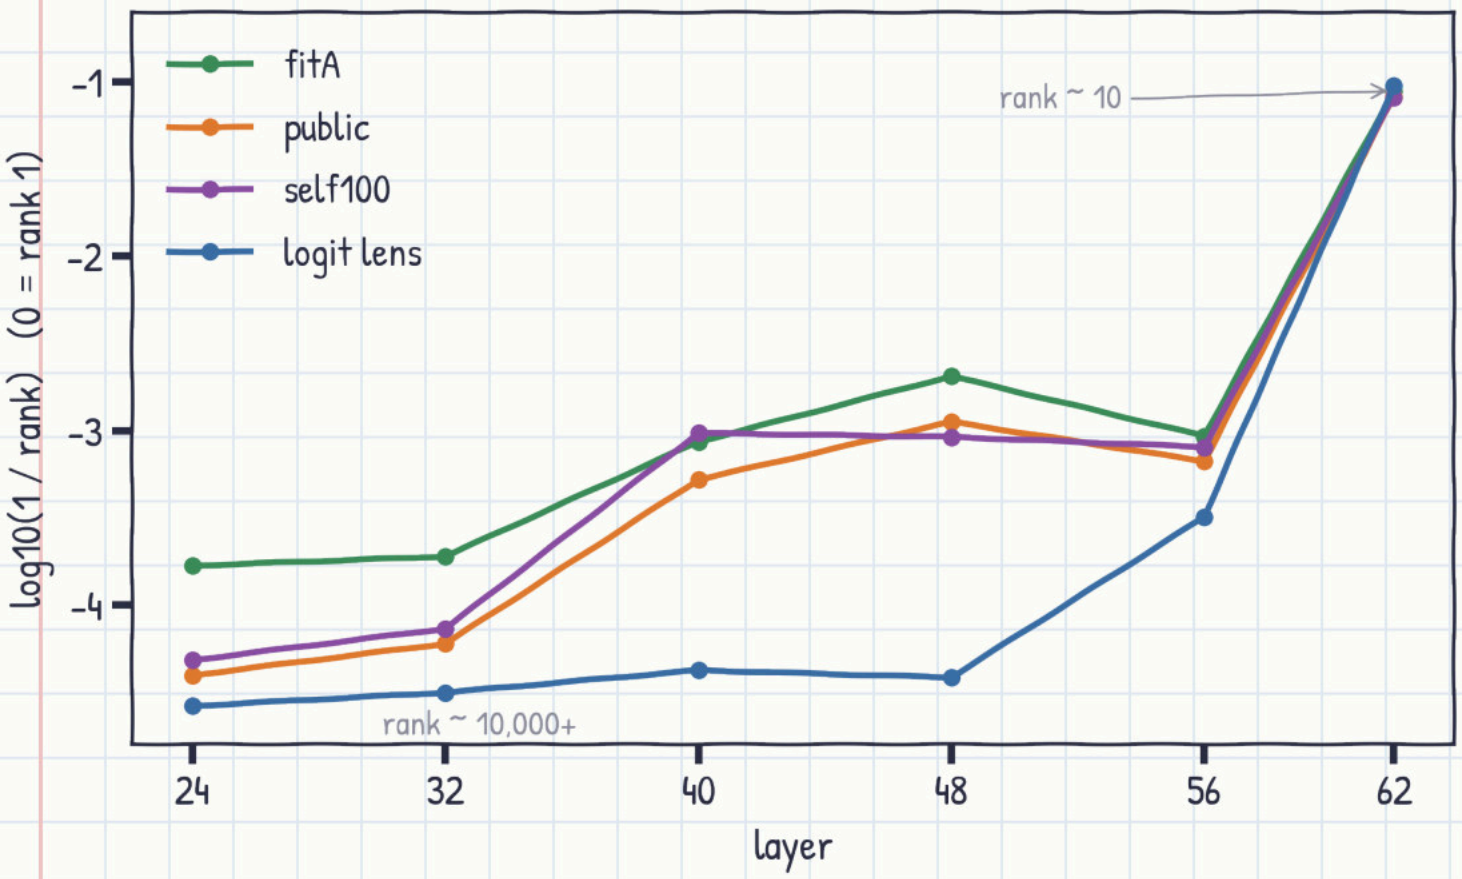

第 35 / 82 页 · Method · Layer-by-layer readout · 合并 PPT 自身页面 **新写讲稿**

逐层读出：在名字位置取每一层的隐藏状态，用 logit lens 映射到全词表，看真名字 token 的名次，再算 nlr = log10(1/名次)。示例论文第一作者姓的首个 token “Co”：L24 名次 37,675，L56 120,750，L61 9,811，L62 120，输出层 61（Stage 10，示例论文 Coifman 等（2007），真标题，第一作者姓的首个 token “Co”（行 25029），logit lens L24–L62 与最终输出 L63 全词表名次；351_stage10/raw/logit/L*/shard_011.npz、raw/final/L63/shard_011.npz；351_stage10/reports/method_figs/coifman_layer_ranks.csv（列 r5_Co））。第一作者 7 个 token 的平均 nlr 到 L58 都在 −4 左右，L62 升到 −1.11、输出层 −0.77（同上，第一作者 7 个 token（行 25025–25031）的平均 log10(1/名次)，logit lens：L24–L58 为 −4.47 到 −3.92，L62 −1.111，最终输出 −0.772；351_stage10/reports/method_figs/coifman_layer_ranks.csv 列 mean_log10_inv_rank）；假标题 false_0 在输出层是 −1.19（同上，false_0 条件，最终输出 L63，−1.194；351_stage10/raw/cond_false_0/final/L63/shard_011.npz；351_stage10/reports/method_figs/coifman_layer_ranks.csv（condition=false_0, readout=final）），真假之差只在最后几层出现。

Stage 10

# Names become readable late

all 9,108 papers · true title (Stage 10 cohort, §6.1)




Logit lens: almost nothing until **L48**

Jacobian lenses read more from **L40**

Everything jumps at **L62** (rank ~10) (Stage 10, logit L62 −0.93, §6.1)

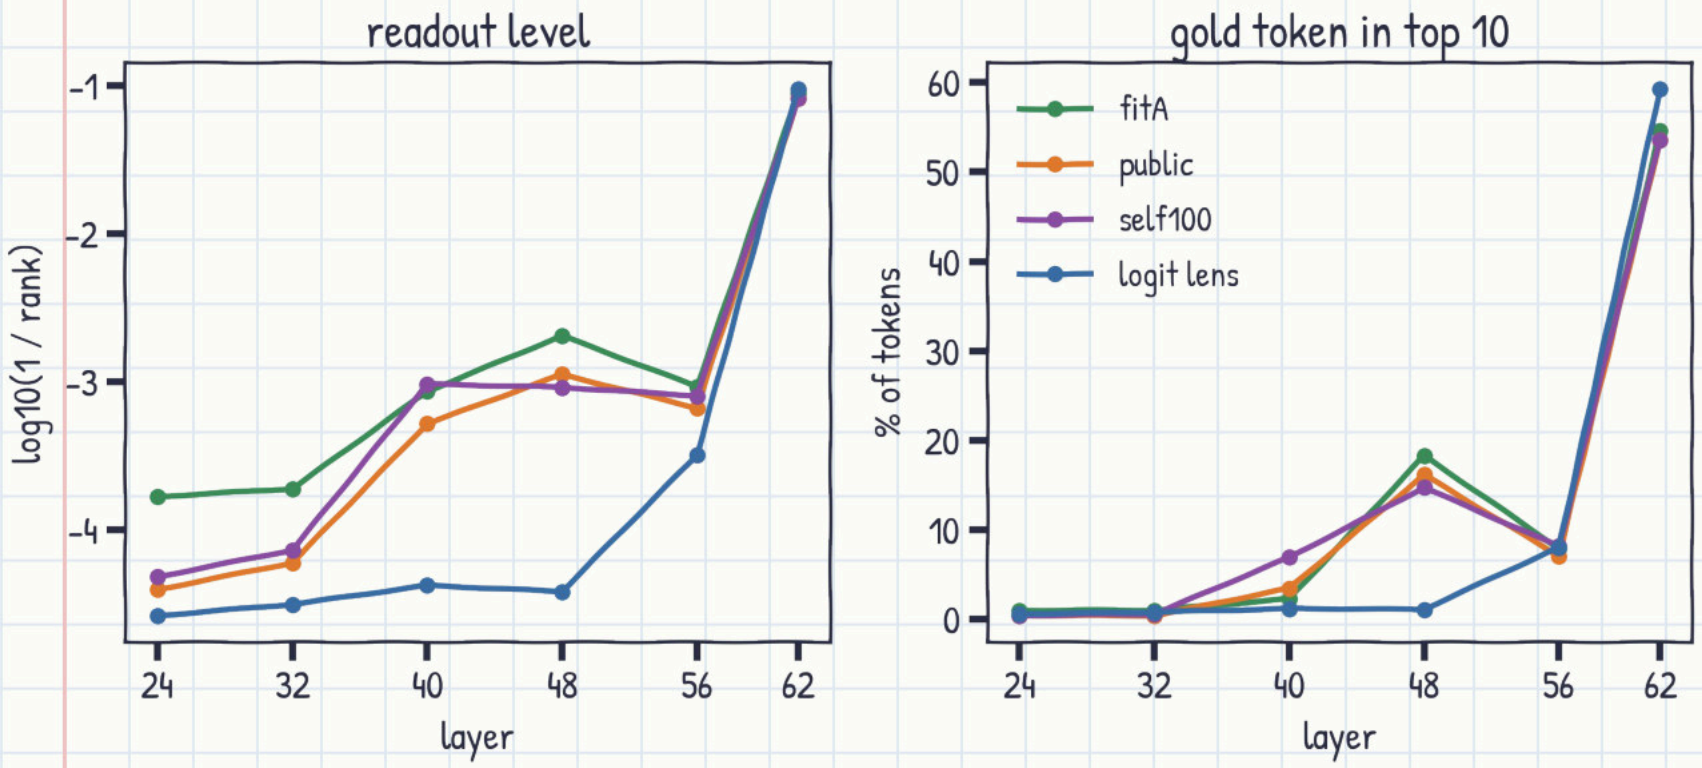
 按 deck 讲稿备注翻译（已按复核结果更新）

所有读出方式都随层数加深而变好。logit lens 在 L48 之前几乎读不出东西（名次在几万名（Stage 10，真标题，logit lens L24–L48，目标 4,621 + 对照 2,220 篇，平均 log10(1/名次) 约 −4.4 到 −4.6；报告 §6.1 表；351_stage10/summary/A_group_layer.csv）），到 L62 才跳上来。Jacobian lens 从 L40 起读出更多，fitA 最多。模型真实输出最好。

Stage 10

# Which lens reads best?

all papers · true title




**Middle layers:**

fitA best; at L48 15–18% top-10 vs 1% for logit

(Stage 10 X3, 9,108 papers, §6.9)

**L62:** logit lens best (59%)

(same, L62)

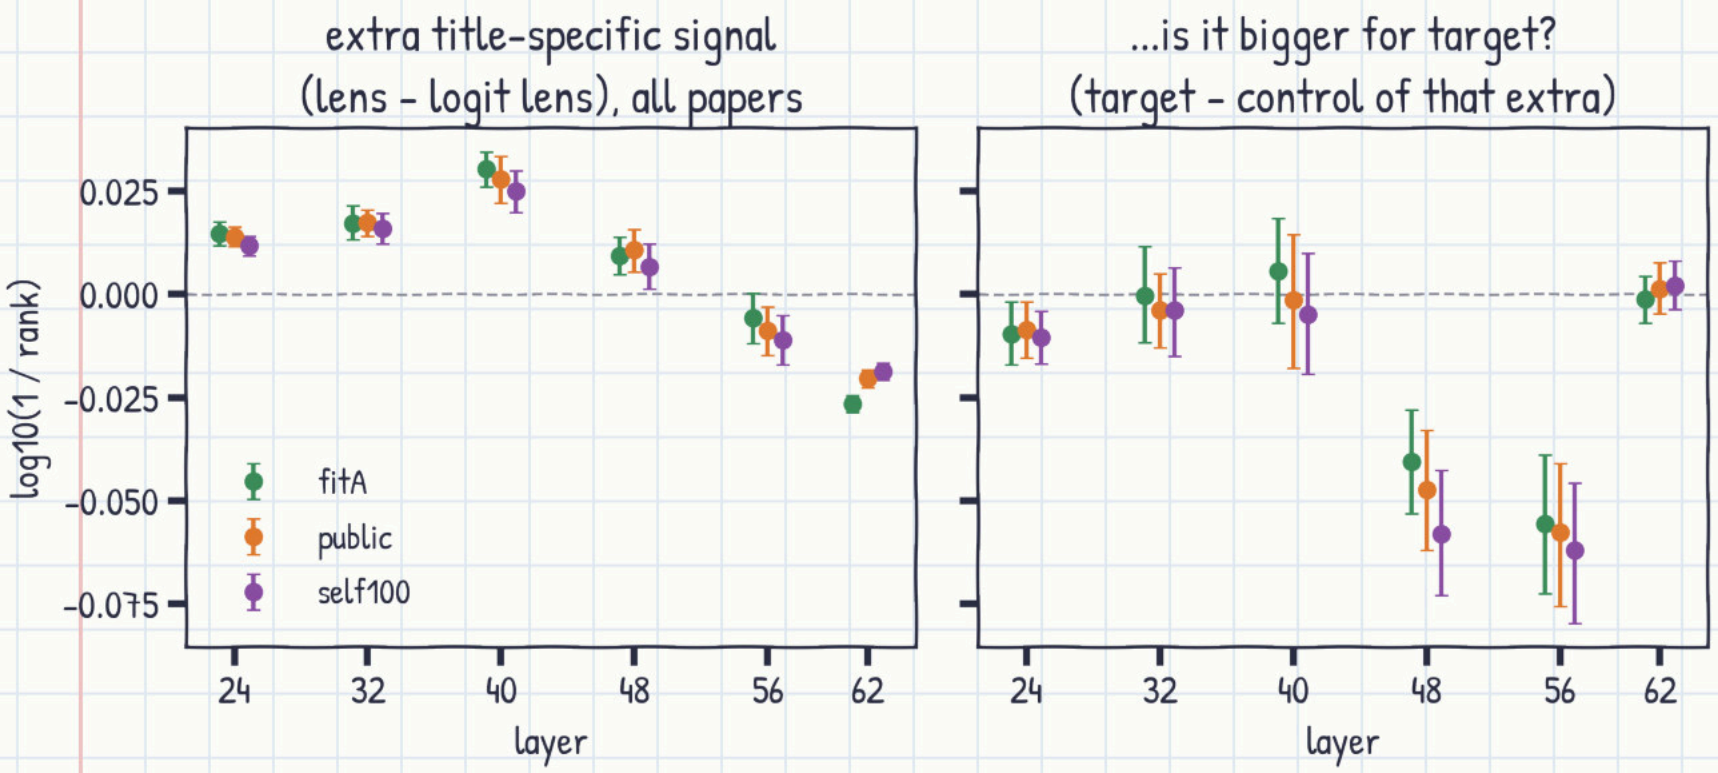
第 37 / 82 页 · deck 第 22 页 按 deck 讲稿备注翻译（已按复核结果更新）

比较各种 lens。读出质量上，中间多数层 fitA 最好，L40 是 self100；在 L48，Jacobian lens 能把正确 token 放进前 10 名的比例是 15–18%，logit lens 只有 1%（Stage 10 X3，真标题，全部 9,108 篇，同一批 token 配对，L48 前 10 命中率（token 比例）：三种 Jacobian lens 14.7%–18%，logit lens 1.1%；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）。到 L62，最朴素的 logit lens 反而最好。

Stage 10

# Do lenses reveal hidden paper knowledge?

paired differences, 95% CI




Extra signal: **+0.01 to +0.03** (Stage 10 X3, L24–L48, 9,108 papers, §6.9)

vs ~0.44 at L62 (same, L62)

Not bigger for target
(even negative at L48–56)

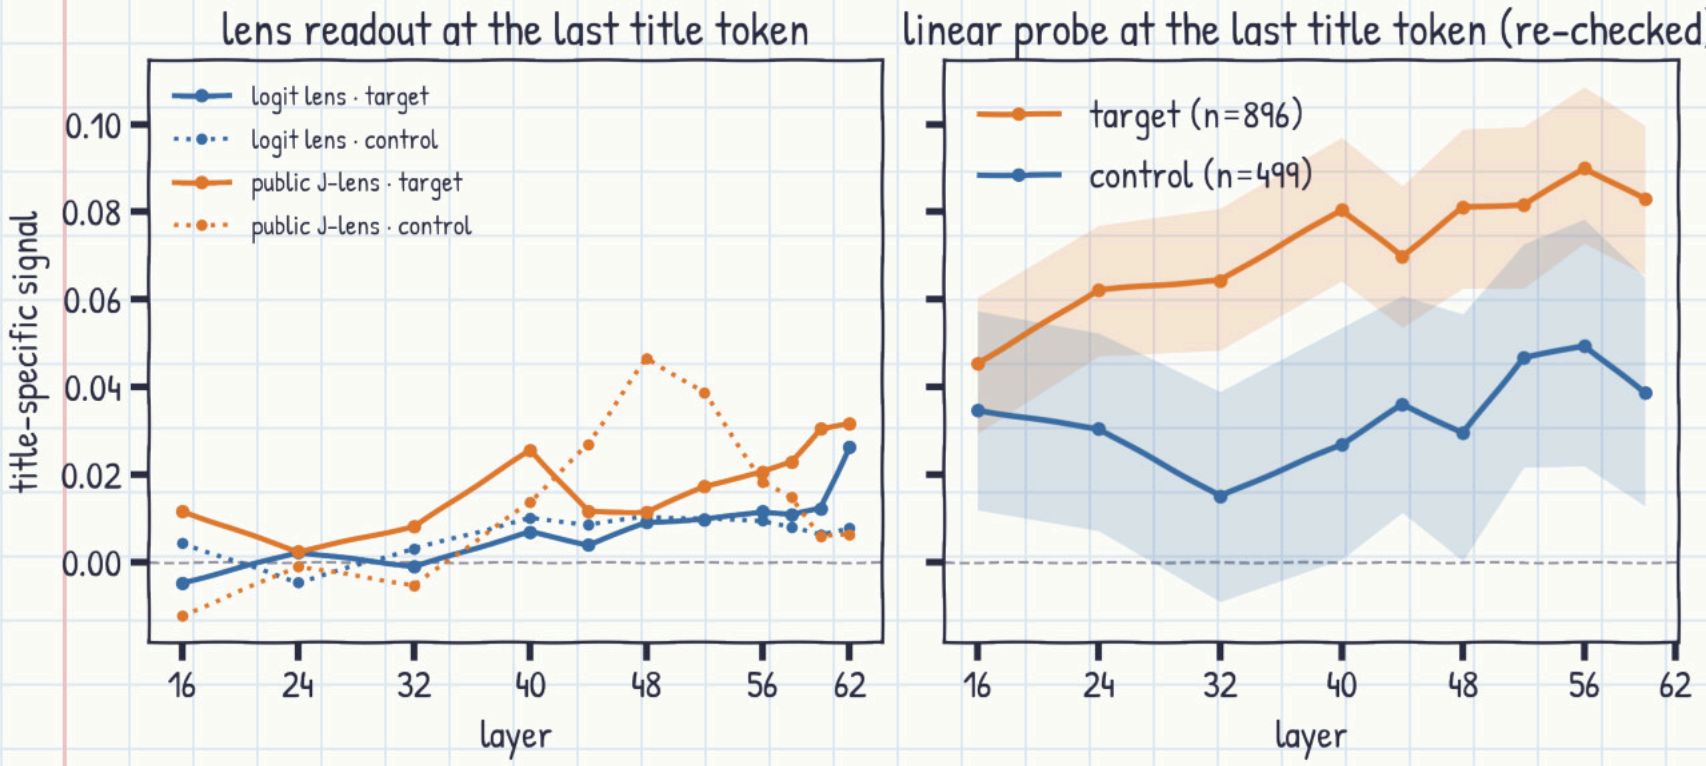
 按 deck 讲稿备注翻译（已按复核结果更新）

Jacobian lens 能不能看到 logit lens 漏掉的、论文特有的信息？只能看到一点：在 L24–L48 多出 +0.01 到 +0.03 的标题特异信号（Stage 10 补充 X3，三种 Jacobian lens 减 logit lens 的标题特异信号（真标题 − 5 个假标题平均），L24–L48，全部 9,108 篇，+0.007 到 +0.030，论文 bootstrap 95% CI 均在 0 以上；报告 §6.9 表；351_stage10/summary_extra/X3_pairwise.csv），区间在 0 以上，但和 L62 的 0.44 相比（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）非常小。而且这部分对目标组并不更大：多出部分的目标−对照约为 0，在 L48 和 L56 甚至为负（Stage 10 X3，(lens − logit) 标题特异信号的引用档内 目标−对照，三种 Jacobian lens：L24–L40 约 0，L48 与 L56 为 −0.04 到 −0.06，论文 bootstrap 95% CI；报告 §6.9 最后一表；351_stage10/summary_extra/X3_tc_spec_vs_logit.csv）。

Stage 11

# Read early: a probe finds it at the title

title-specific signal at the last title token · lenses: all 9,108 papers · probe: re-checked, title reuse removed: 1,863 papers (896 target, 499 control) (Stage 11 E4; Stage 13 E4b)




lenses: **~0.01–0.03** (Stage 11 E4, 4,621 + 2,220, §6.11)

probe: **0.05 -> 0.08** (Stage 13 E4b, 1,863 papers, first name token only)

target > control by **+0.03–0.08** (E4b, 896 vs 499, within bin)

re-checked: team folds, title reuse removed

scores the first name token only (mostly an initial); subtracts false_0 only

**read early** (title, from L24), **spoken late** (names, L57–61)

Probe scores only the first name token (mostly an initial); all-token, by-role version (addendum 9, done): surname first token L40 +0.071 [0.058, 0.085] (1,395 papers; e4b_alltok.md).



在标题本身的位置上能读出作者吗？用 lens，几乎读不出：标题最后一个 token 上的标题特异信号只有约 0.01 到 0.03（Stage 11 E4，标题最后一个 token，logit lens 与 public J-lens 读第一个名字 token，真标题 − 5 个假标题平均，全部 9,108 篇，约 0.01–0.03；报告 §6.11 标题位置表；361_stage11/summary/E4_titlepos_lens.csv）。换成跨论文训练的线性 probe 能读出更多：按作者团队分折、并剔除 probe 训练时见过同一标题的论文后复核（剩 1,863 篇，其中目标 896、对照 499（Stage 13 E4b 复核样本，按作者团队分折并剔除 probe 训练时见过同一标题的论文后剩 1,863 篇（目标 896、对照 499、excluded 433、guard 35）；381_stage13/reports/e4b_split_compare.md；381_stage13/summary_cpu_trainstd/E4b_4configs.csv）），L24 约 0.05，到 L56 升到约 0.08（Stage 13 E4b 复核，标题最后一个 token 上的线性 probe，probe 只打分每位作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，全部 1,863 篇：L24 +0.050、L40 +0.061、L56 +0.075（L24–L60 为 +0.047 到 +0.075），论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第一张表），目标组比对照组高 0.03 到 0.08（同上 E4b 复核，probe 只打分第一个名字 token，引用档内目标–对照，目标 896、对照 499 篇，L24–L60 为 +0.035（L44）到 +0.078，论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第二张表）。附录里的对照说明这个 probe 信号是这篇论文特有的，不是主题和名字的关联。它和 lens 的结果不矛盾：标题在标题位置就被读进去了，但名字要到 L57–L61 才在名字位置变得可读。一句话：读得早，说得晚。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Stages 1–9 · 20–200 papers

## What we saw

- Self-100 fits the final distribution better; author ranking not better
- J-Lens − Vanilla ≈0 (7.4: +0.002; Stage 8: −1.4 pp)(50 / 200 papers)
- Stage 9: only Fit A fitted, stability not tested

Stages 10–11 · 9,108 papers

## What scale showed

- Jacobian lenses: top-10 rate 15–18% at L48 vs 1% for logit lens(9,108 papers; X3_means.csv)
- Extra title-specific signal only +0.01–0.03(L24–L48; X3_means.csv), not target-specific
- At L62 the plain logit lens is best
- Linear probe at the title token: +0.05 → +0.08 (re-checked) (E4b, scores only the first name token; e4b_trainstd_compare.md), paper-specific

**Line B: the information is there, but not in a form the lenses read**

Both phases agree: no lens reveals hidden paper knowledge in middle layers. Scale adds the positive side: a trained probe can decode it at the title, so the limit is the readout, not the absence of information.

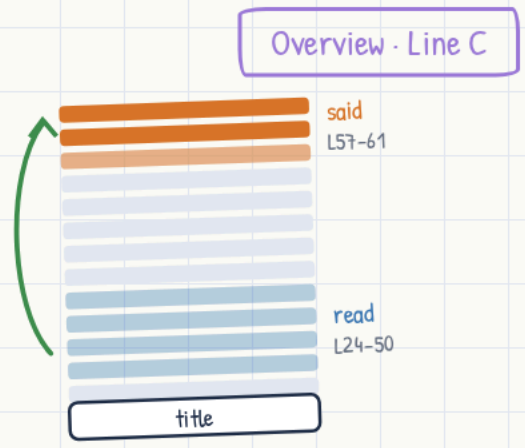




B 线的小结。小样本阶段看到：Self-100 更贴近最终分布，但作者排名没有更好；J-Lens 减 Vanilla 约为 0（7.4 为 +0.002（Stage 7.4，J-Lens − Vanilla 标题优势，7 层积分，50 篇，+0.002 [−0.008, +0.012]；351_stage7_4/summary/jlens_increment_bootstrap.csv 行 integrated），Stage 8 为 −1.4 个百分点（Stage 8D，L56 J-Lens − Vanilla 标题优势，200 篇，−1.38 pp [−3.48, +0.68]；351_stage8/stage8D/summary/jlens_minus_vanilla.csv））；Stage 9 只拟合了 Fit A，稳定性没有检验。全量阶段看到：Jacobian lens 在 L48 的前 10 名比例为 15–18%，logit lens 为 1%（Stage 10 X3，真标题，全部 9,108 篇，L48 前 10 命中率：三种 Jacobian lens 14.7%–18%，logit lens 1.1%；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）；多出的标题特异信号只有 +0.01 到 0.03（Stage 10 补充 X3，三种 Jacobian lens 减 logit lens 的标题特异信号（真标题 − 5 个假标题平均），L24–L48，全部 9,108 篇，+0.007 到 +0.030，论文 bootstrap 95% CI 均在 0 以上；报告 §6.9 表；351_stage10/summary_extra/X3_pairwise.csv），而且不偏向目标组；L62 时朴素的 logit lens 最好；标题 token 上的线性 probe 从 +0.04 升到 +0.08（Stage 11 E4b 原始版（论文分折、未剔除标题复用），标题最后一个 token 上的 probe，probe 只打分第一个名字 token，真标题 − false_0，目标组 L16 +0.043 到 L52–L56 +0.080/+0.082；论文 bootstrap 95% CI；报告 §6.11 标题位置表 probe 行；361_stage11/summary/E4_probe.csv 列 spec_target），而且是论文特有的。（页面上 +0.04 到 +0.08 是复核前的数字（Stage 11 E4b 原始版（论文分折、未剔除标题复用），标题最后一个 token 上的 probe，probe 只打分第一个名字 token，真标题 − false_0，目标组 L16 +0.043 到 L52–L56 +0.080/+0.082；论文 bootstrap 95% CI；报告 §6.11 标题位置表 probe 行；361_stage11/summary/E4_probe.csv 列 spec_target），复核后为 +0.05 到 +0.08（Stage 13 E4b 复核，标题最后一个 token 上的线性 probe，probe 只打分每位作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，全部 1,863 篇：L24 +0.050、L40 +0.061、L56 +0.075（L24–L60 为 +0.047 到 +0.075），论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第一张表），结论不变。）两个阶段一致：没有哪种 lens 能在中间层看出隐藏的论文知识；全量阶段补上了正面的一面：训练过的 probe 能在标题位置解码出来，所以限制在读出工具，而不是信息不存在。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Line C

# When does it appear, and when is it used?




small samples asked

Which layer peaks? (L56 kept standing out)

→

the full cohort answered

Readable late (L57–61) but read from the title early (L24–50)



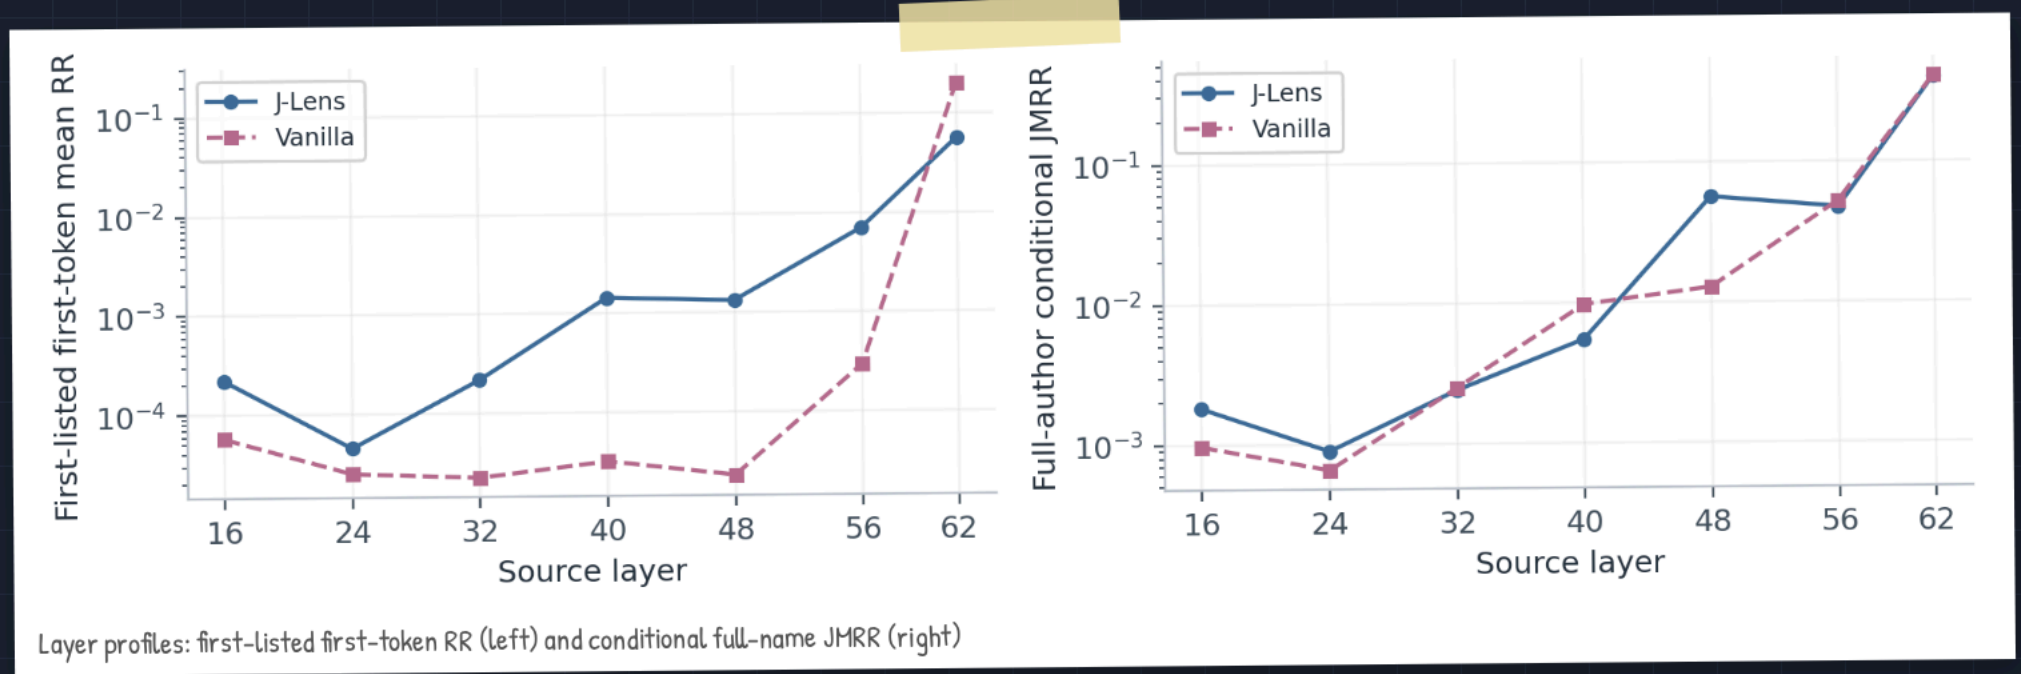
 新写讲稿

C 线的问题是：信号在哪一层出现，又在哪一层被用到？小样本阶段问的是哪一层最高，L56 总是很突出。全量阶段的回答是：名字要到 L57–L61 才变得可读，但标题信息在 L24–L50 就已经被读取了。

Stage 4

# First readout: is any author signal there?

20 papers, 93 authors (A8 / B8 / C3 / D1); ~91 s per paper, ~29.5 GiB GPU(351_stage4_readout.log)




Layer profiles: first-listed first-token RR (left) and conditional full-name JMRR (right)

- The pipeline works and J-Lens rises above Vanilla in middle layers
- L56 first-author mean RR 0.0070, median only 0.0009(20 papers; audit_report.md table 1)

**One paper = 71% of the L56 mean**

Dropping it: 0.0070 → 0.0021.(same file) A layer peak can be a single easy paper, so every later stage adds controls.



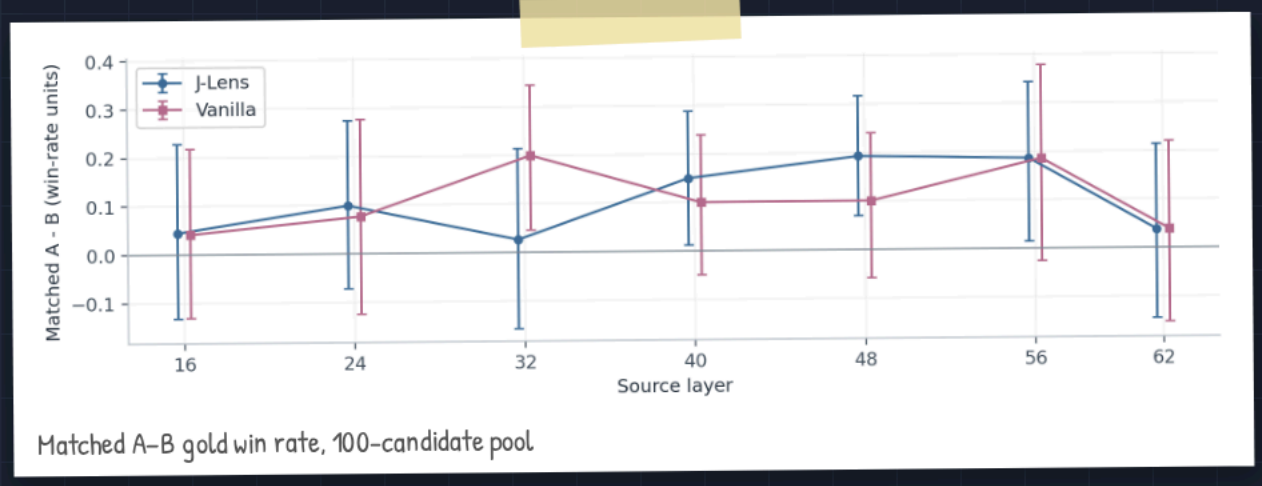
第 42 / 82 页 · Stage 4 · 合并 PPT 自身页面 新写讲稿

Stage 4 是第一次读出：作者信号到底在不在？用了 20 篇论文、93 位作者，A 8 篇、B 8 篇、C 3 篇、D 1 篇，每篇约 91 秒、约 29.5 GiB 显存（Stage 4 Benchmark20；351_all/351_stage4_readout.log "STAGE 4 BENCHMARK ===== 20 papers"、authors_scored 93、"Mean seconds per paper 90.68"、gpu=29.5GiB；报告 Stage 4 节表）。流程能跑通，J-Lens 在中间层高于 Vanilla。但 L56 第一作者的平均倒数名次是 0.0070，中位数只有 0.0009；一篇论文就占了 L56 均值的 71%，去掉它均值降到 0.0021（Stage 4，J-Lens L56，第一作者首 token 倒数名次，20 篇：均值 0.00704，中位数 0.00092，最大单篇占总和 71.03%，去掉后均值 0.00215；351_all/351_stage4_artifacts/audit/audit_report.md 表 1 行 L56）。层的峰值可能只是一篇特别好猜的论文，所以之后每个阶段都加了对照。

Stage 7.2 · Line A

# Gold vs 100 real false authors

50 matched (same field, token count, year) + 50 random names per paper; 75,000 scored pairs(candidate_pairwise_scores.csv)




Matched A–B gold win rate, 100-candidate pool

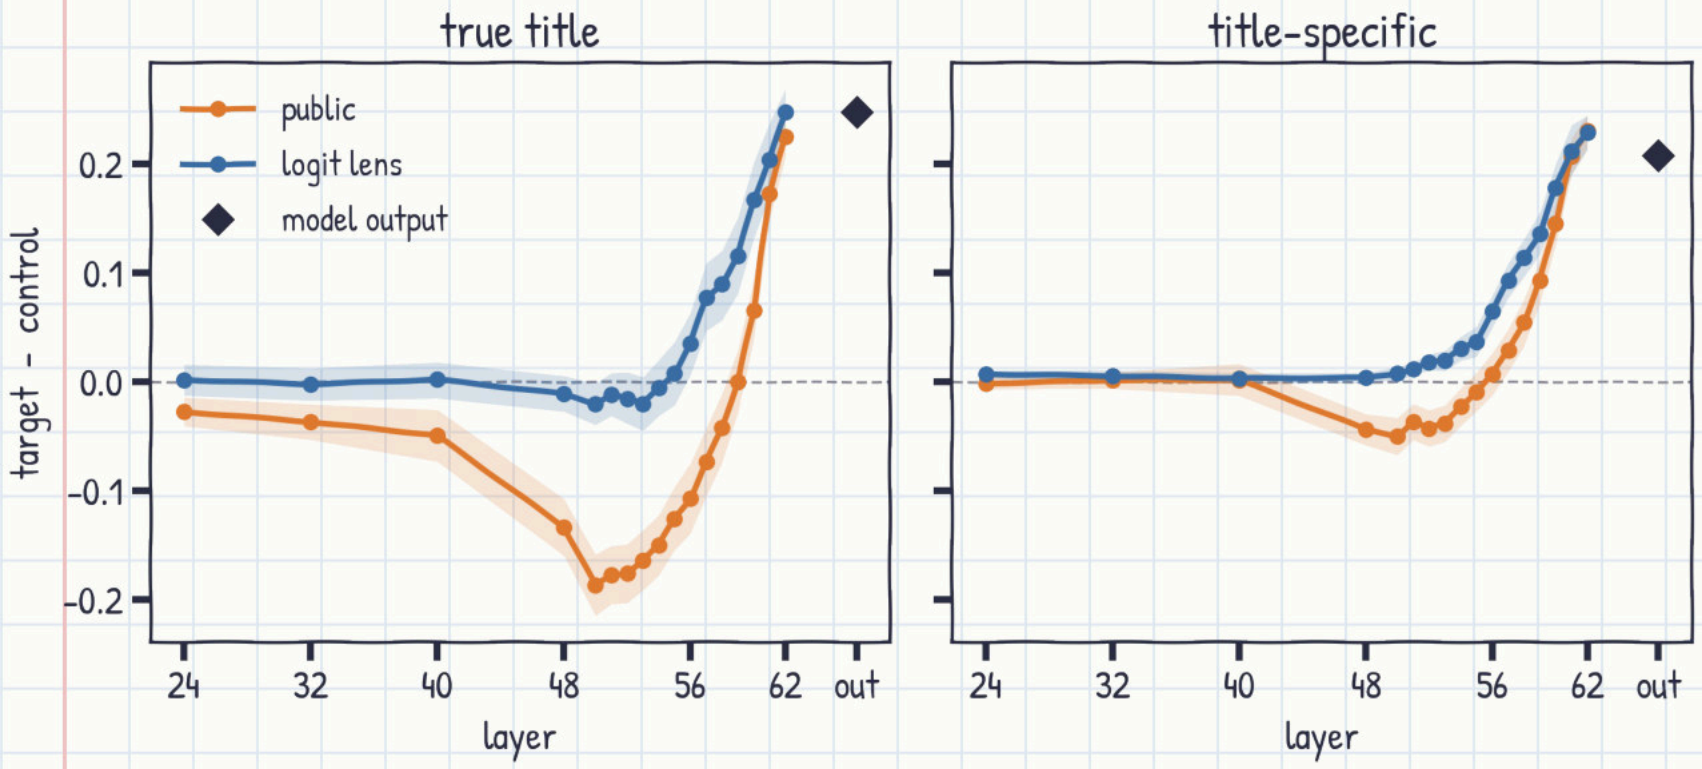
- J-Lens A–B: L40 +0.15, L48 +0.19, L56 +0.19 (CIs above 0); L62 +0.04 (spans 0)(20 pairs, matched_ab_bootstrap.csv)
- 7-layer integrated: +0.105 [−0.012, +0.229](20 pairs; recomputed 10-30)
- 156/5,000 false names share the gold first token (ties) (quality.json)
- 100 names → only ~46 distinct first tokens(mean of 50 papers; candidates csv)

Gold beats real names in middle layers for A more than B. But the same names might win under any title: 7.3 tests that.



 新写讲稿

Stage 7.2 把正确名字和 100 个真实的错误作者比较：每篇论文 50 个匹配名字（同领域、同 token 数、同年份）加 50 个随机名字，共 75,000 对（Stage 7.2 设计，Pilot50 50 篇 × 100 个错误作者 × 15 种读出 = 75,000；~/jlens_work/07_2_stage7_2/351_stage7_2.py:62-111；351_stage7_2/summary/quality.json；351_stage7_2/summary/candidate_pairwise_scores.csv）。J-Lens 下的 A–B 胜率：L40 +0.15，L48 +0.19，L56 +0.19，区间都在 0 以上；L62 为 +0.04，区间含 0（Stage 7.2，真标题，首 token 金标准胜率，J-Lens，合并池，Pilot50 20 对 A − B，配对 bootstrap 95% CI：L40 +0.150 [0.013, 0.289]、L48 +0.193 [0.071, 0.318]、L56 +0.187 [0.015, 0.345]、L62 +0.038 [−0.144, +0.215]；报告 Stage 7.2 节图 7.2；351_stage7_2/summary/matched_ab_bootstrap.csv）；7 层积分 +0.105 [−0.012, +0.228]（Stage 7.2，7 层积分，J-Lens，合并池，20 对 A − B，配对 bootstrap 95% CI（2026-10-30 按逐对数据重算）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv 行 "7.2 integrated7 A-B jlens pool=combined"）。需要注意 5,000 个错误名字里有 156 个与正确名字共享第一个 token，100 个名字只有约 46 个不同的第一个 token（Stage 7.2，Pilot50 每篇 100 个错误名字（50 匹配 + 50 随机），共 5,000 个；每篇平均 45.76 个不同首 token（方法手册 C 部分由 351_stage7_2/candidates/pilot50_author_candidates.csv 统计）；156 / 5,000 = 3.1% 与金标准首 token 相同记为平局（351_stage7_2/summary/quality.json））。中间层里 A 比 B 更常胜出，但同样的名字可能在任何标题下都胜出，这要由 7.3 来检验。



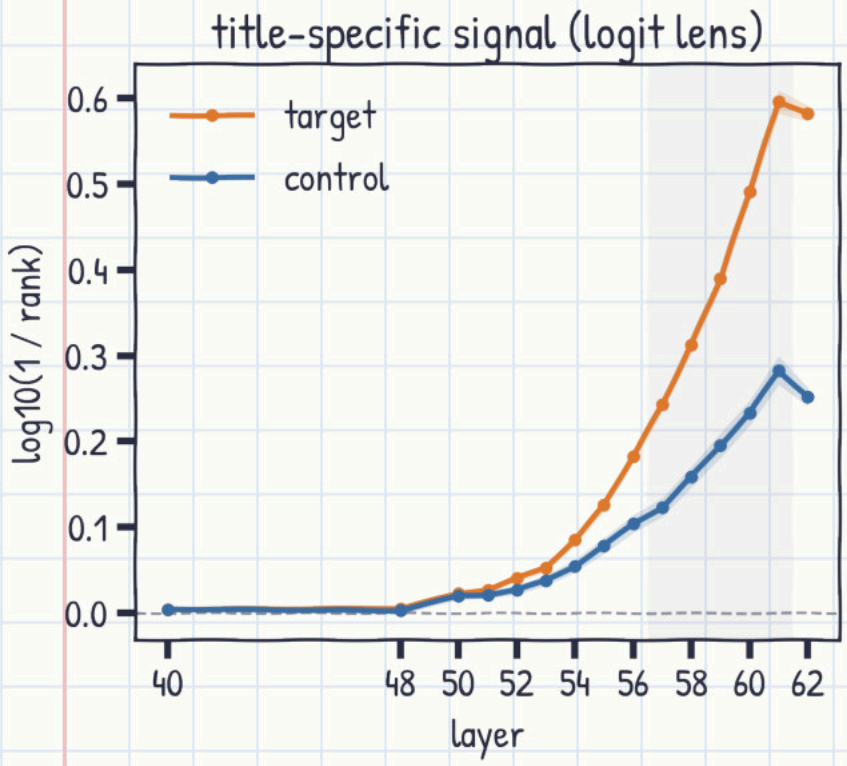


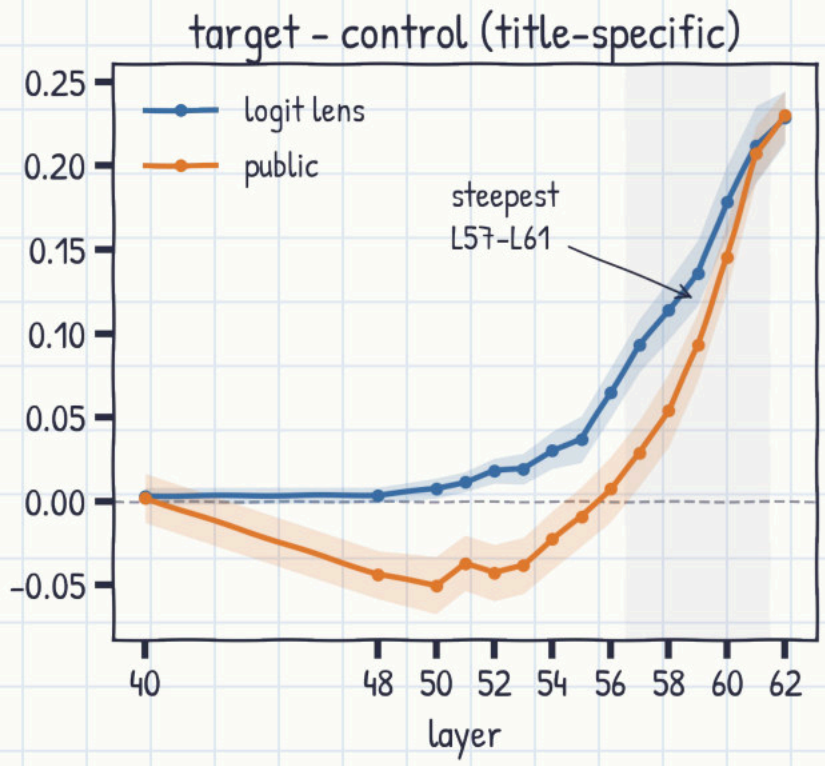

这是关键的一页：在引用档内看目标组减对照组。左边只看真标题，中间层对 Jacobian lens 甚至略为负。右边看标题特异部分：L56 之前约为 0，在 L62 和输出处为 +0.207 到 +0.231（Stage 10，真标题 − 5 个假标题平均，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），L62 四种读出 +0.228 到 +0.231，最终输出 L63 +0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）。稳健性：目标组 11% 是 R1（写对少数作者），对照组只有 1.5%（目标组 R1 511 / 4,621 篇 = 11%，对照组 R1 34 / 2,220 篇 = 1.5%；351_stage10/reports/r0_sensitivity.md 第一张表；351_stage10/reports/r0_r1_analysis.md §0）；两组都只保留 R0 时，输出处的差是 +0.199（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv）而不是 +0.207（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），各层形状相同，Stage 11 的曲线也不变。目标组的优势出现得很晚，而且几乎全部是标题特异的。

Stage 10

# It builds up over the last dozen layers

fine layers L40–L62 · title-specific signal · 95% CI




Logit lens: target − control

**+0.007 at L50**

**+0.23 at L62** (Stage 10 logit lens, 3,734 + 2,182 papers, §6.10)

steepest rise **L57–L61**

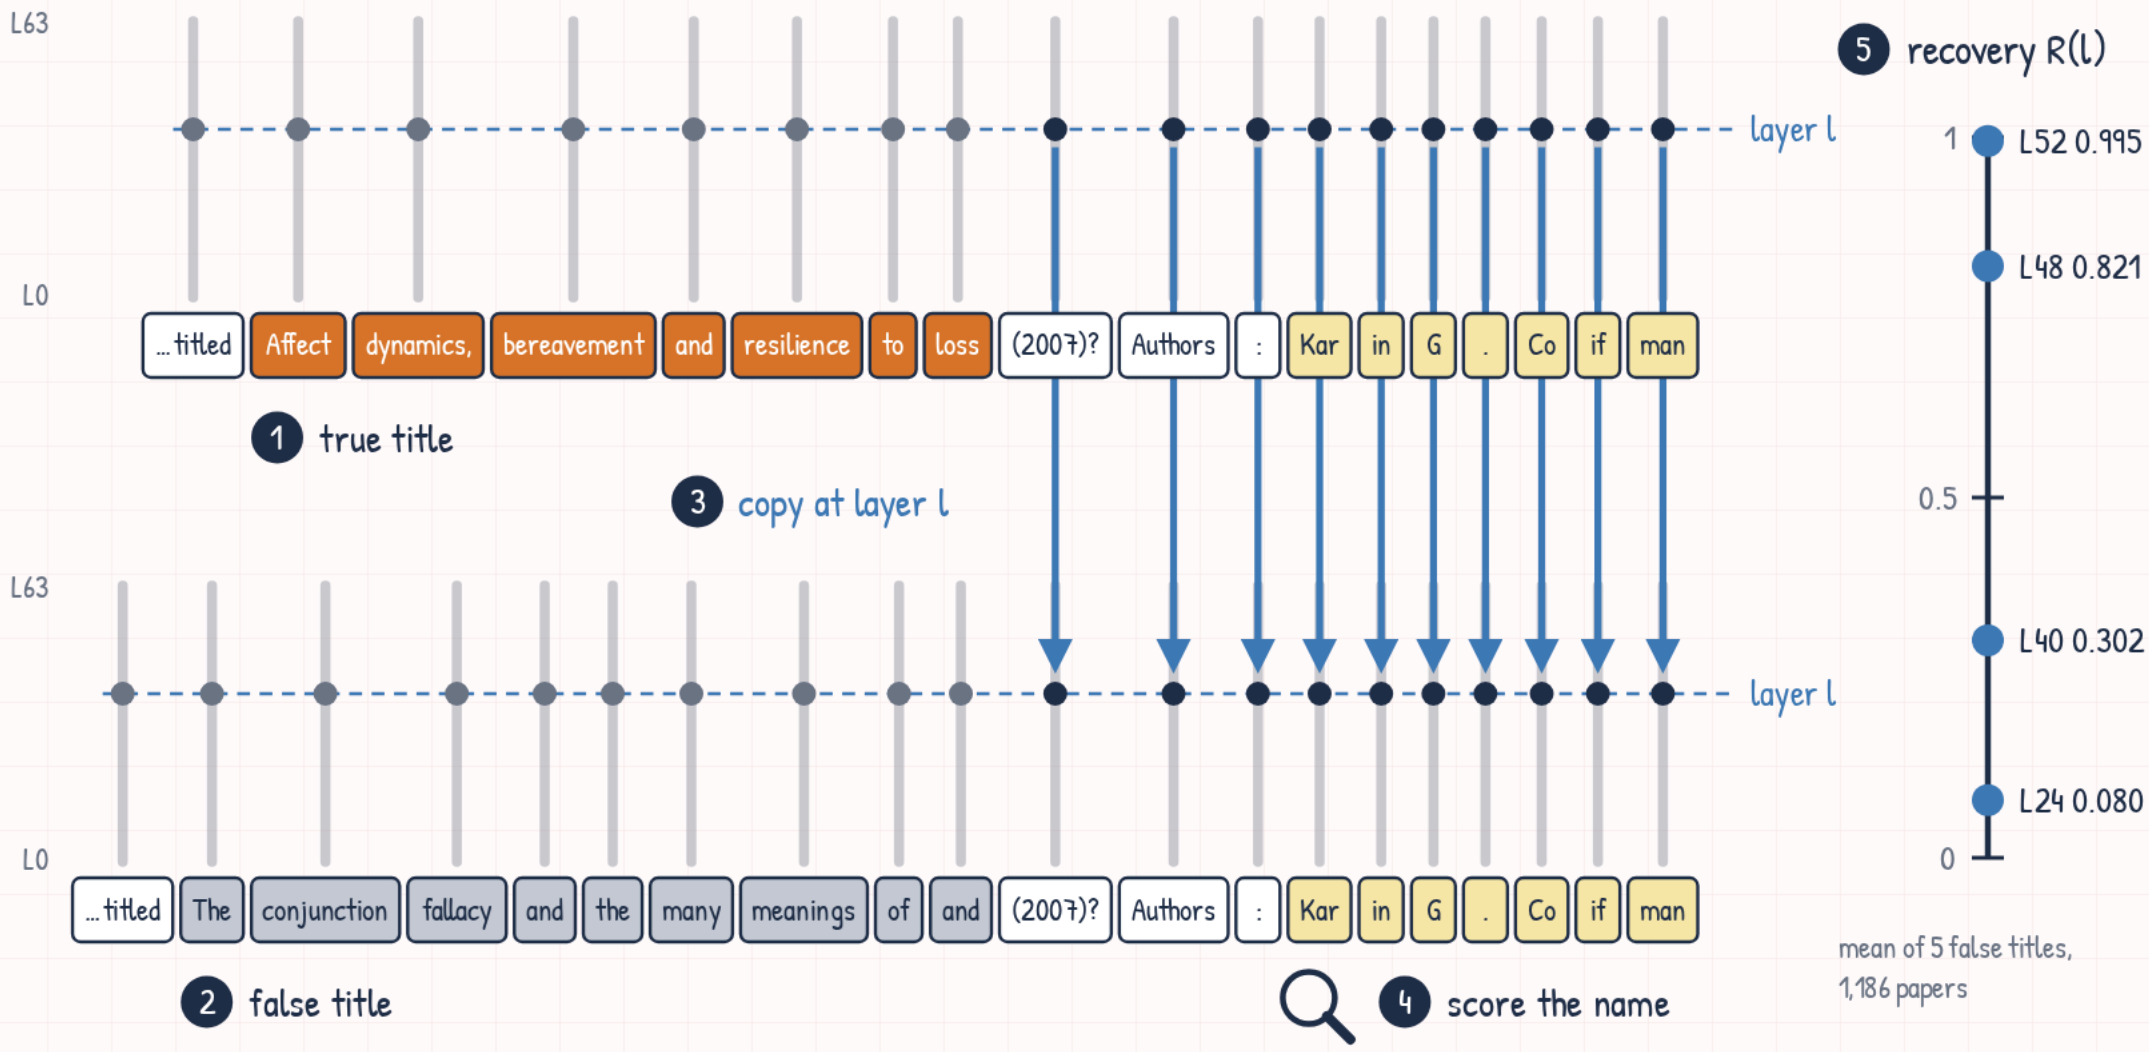
 按 deck 讲稿备注翻译（已按复核结果更新）

细层 L50 到 L61 是后来为 logit lens 和公开 lens 补算的。目标组的优势不是在 L62 突然出现的：logit lens 下，标题特异的目标−对照在 L50 为 +0.007，L54 为 +0.03，L56 为 +0.07，L58 为 +0.11，L60 为 +0.18，L62 为 +0.23（Stage 10 主轮 + 细层扩展，真标题 − 5 个假标题平均，logit lens，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇）：L50 +0.007 [0.001, 0.014]、L52 +0.018、L54 +0.030、L56 +0.065、L58 +0.114、L60 +0.178、L62 +0.229，论文 bootstrap 95% CI；报告 §6.10 图与表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）。公开 lens 到 L54 为负，L57 转正（同上，public J-lens：L48–L54 为 −0.02 到 −0.05，L57 起转正 +0.029 [0.009, 0.048]，L61 +0.207；报告 §6.10 图与表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）。上升最快的是 L57 到 L61，两组都在 L61 达到最高（Stage 10，真标题 − 5 个假标题平均，logit lens 各组均值：目标 L50 +0.022 → L61 +0.596，对照 +0.020 → +0.282（L62 为 +0.583 / +0.252）；报告 §6.10；351_stage10/summary_title/A_group_layer.csv）。

# Replacement (patching)

Coifman, Bonanno, Rafaeli (2007)

$$R(l) = (\text{patched} - \text{false}) \div (\text{true} - \text{false})$$




R(l): Stage 13 X6, mean of 5 false titles, all 1,186 papers; 381_stage13/summary_x6/x6_recovery.csv

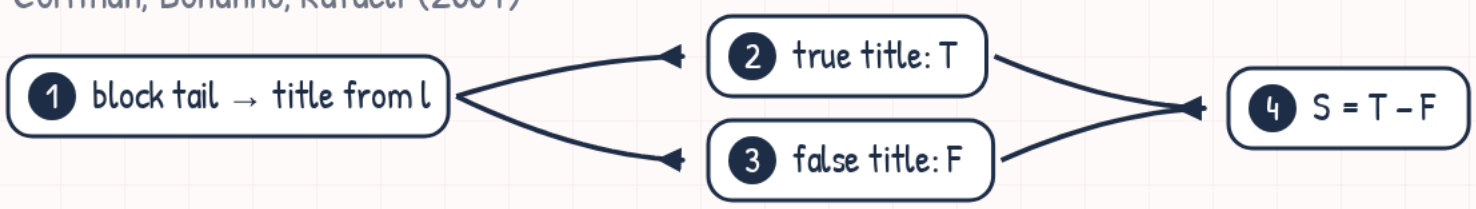


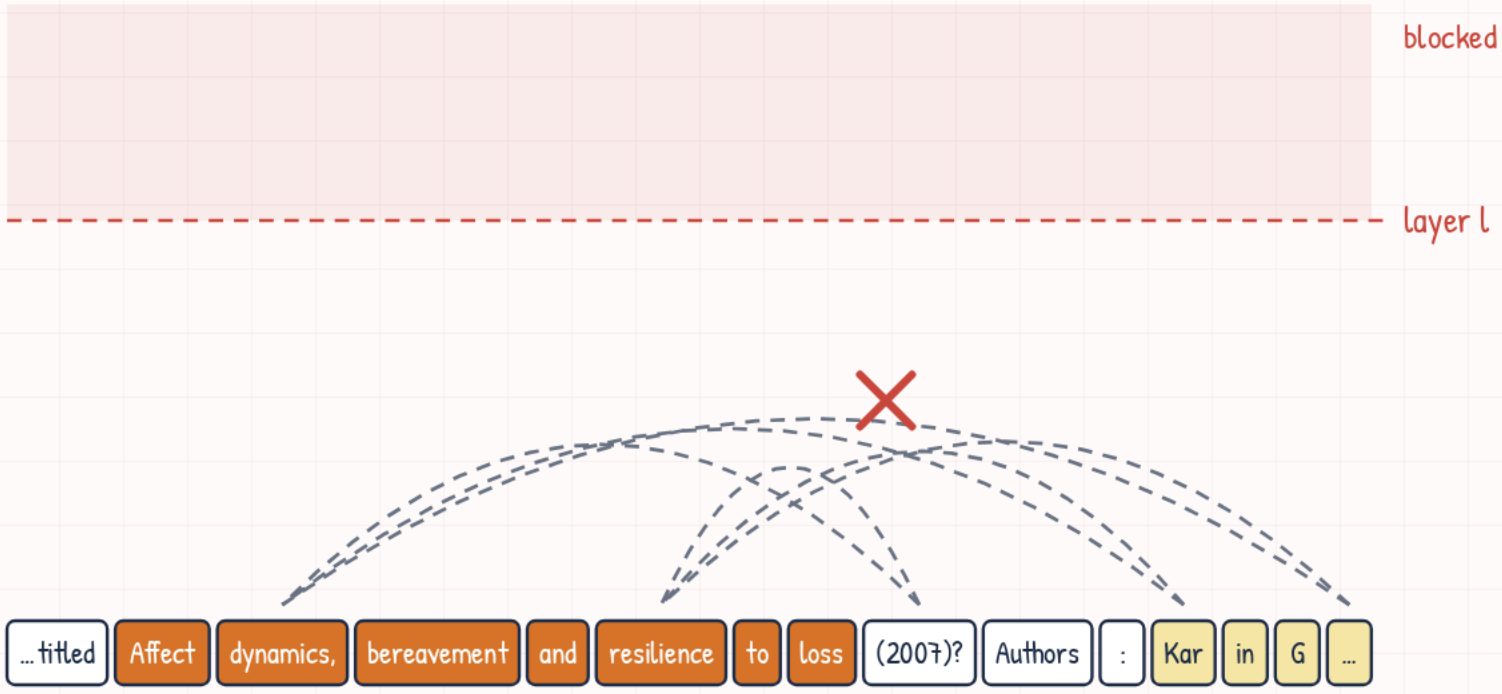
 新写讲稿

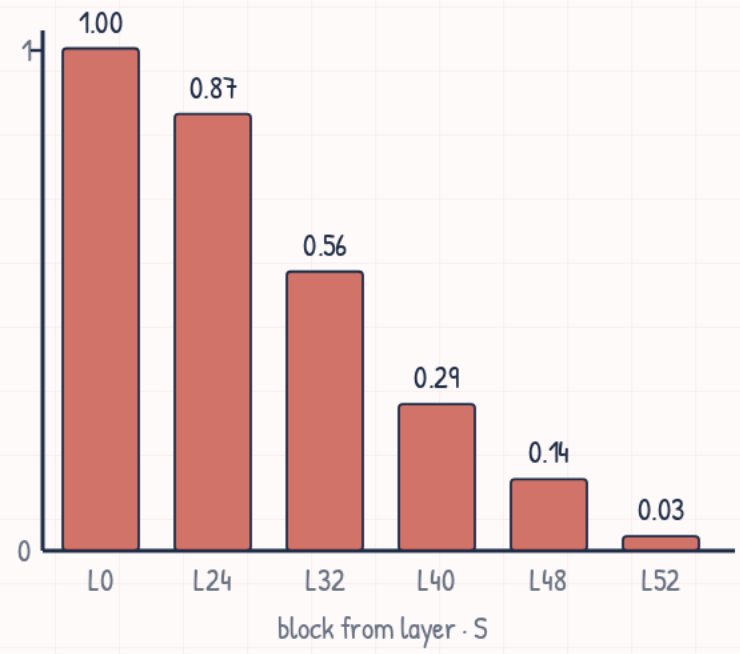
替换（patching）：同一组名字分别接在真标题和假标题后面跑两次；在第 l 层，把真标题运行中标题之后的 token（“(2007)?”、“Authors”、冒号）和名字位置的状态复制进假标题运行，再给名字打分。恢复比例 R(l) = (patched − false) ÷ (true − false)。1,186 篇、5 个假标题平均：L24 0.080、L40 0.302、L48 0.821、L52 0.995（Stage 13 X6，用 5 个假标题分别做 Stage 11 E1 替换，全部 1,186 篇，5 个假标题平均 R：L24 0.080、L40 0.302、L48 0.821、L52 0.995，团队聚类 95% CI；报告 Stage 13 X6 节；381_stage13/reports/x6_report.md（all 表 average 列））， 即到 L52 标题信息已全部进入标题之后的位置。

# Knockout (block attention)

Coifman, Bonanno, Rafaeli (2007)




**S(l) = T(l) − F(l)**

loss as share of (true − false), 1,186 papers

L52: target 0.018 · control 0.051

S(l): Stage 13 X7, 1,186 papers (593 target + 593 control); 381_stage13/reports/x7_report.md



 新写讲稿

阻断（knockout）：从第 l 层起，让标题之后的每个位置都不能注意标题 token，记下名字分数的损失 T；在假标题运行上做同样的阻断得到 F；S = T − F，用真 − 假差距的比例表示。X7（1,186 篇）：从 L0 阻断 S = 1.00，L24 0.87，L40 0.29，L48 0.14，L52 0.029（target 0.018，control 0.051）（Stage 13 X7，S = T − F（真标题运行的阻断损失减去 false_0 运行的同样阻断），÷ 真 − 假差距，全部 1,186 篇：L0 1.004、L24 0.873、L40 0.293、L48 0.143、L52 0.029（target 0.018、control 0.051），团队聚类 95% CI；报告 Stage 13 X7 表；381_stage13/reports/x7_report.md；381_stage13/summary_x7/x7_knockout.csv），所以 L52 之后标题已基本不再被读取。

# Stage 11: intervene, do not just read

593 + 593 papers: min(60, n_t, n_c) per citation bin, seed 11 (Stage 11 sample.parquet, §6.11)

patch uses false_0 · knockout masks all heads · all 9,108 for probe and chain (Stage 10 manifest.json)

**patch**

copy the true-title hidden state into the false-title run at one layer

**knock out**

block attention to the title tokens (all heads) from layer l to the last layer

**probe**

linear map from the last title token to the output state

**chain**

"Authors: A1, A2, ..." instead of each author alone

Score: rank of the correct name token at the model output; "share of the true-false gap" = (intervened - false) / (true - false).

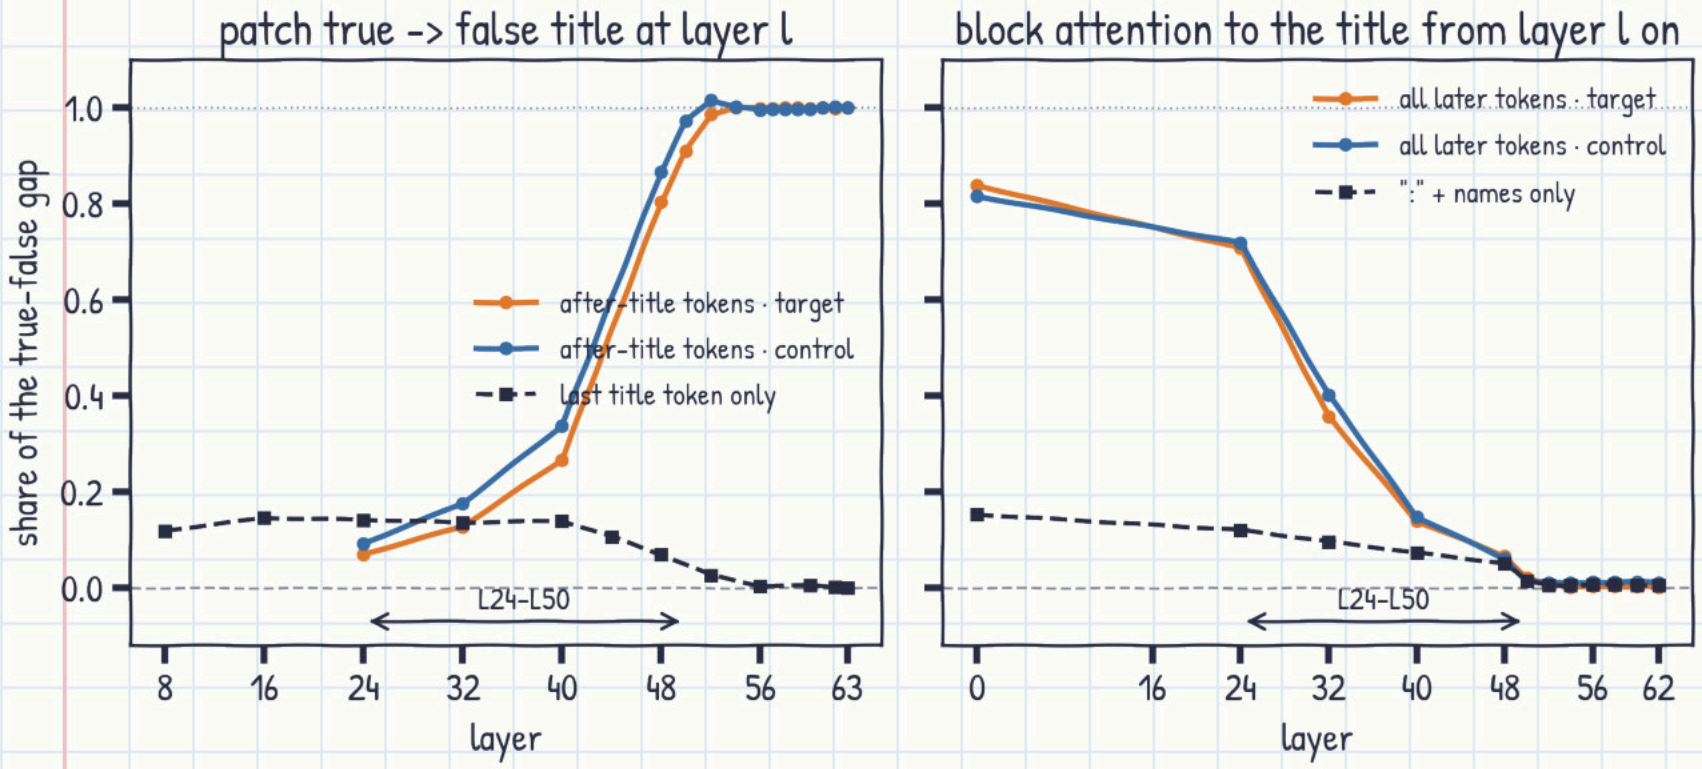


Stage 11 把读出问题变成干预实验。用了 593 篇目标论文和 593 篇对照论文（Stage 11 抽样，10 个可比引用档内配平，目标 593 + 对照 593 = 1,186 篇；361_stage11/config/sample.parquet；361_stage11/config/protocol.json），在引用档内匹配。替换：同一篇论文分别用真标题和匹配的假标题运行，在某一层把真标题运行的隐藏状态复制到假标题运行里。阻断：从第 l 层到最后，禁止注意力看标题 token。Probe：训练一个从标题最后一个 token 到输出状态的线性映射。作者链：在前面作者都给出之后，再给每位作者打分。

Stage 11

# The title is read in L24-L50, early

model output · share of the true-false gap · CIs about +/-0.02 (Stage 11 E1/E2, 593 + 593 papers, §6.11)




L52+: title no longer needed

the information enters the **name positions at L44–52**, partly via the tokens right after the title

same timing for target and control

 按 deck 讲稿备注翻译（已按复核结果更新）

两条因果曲线。左边：把真标题运行中标题之后那些 token（右引号、年份、“Authors:”、名字）的隐藏状态复制到假标题运行里，L40 恢复 29%，L48 恢复 0.825（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L40 0.291 [0.274, 0.308]，L48 0.825 [0.807, 0.842]；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all）），L52 起全部恢复（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L52 0.996 [0.989, 1.003]；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））；只复制标题最后一个 token 只恢复约 12%（Stage 11 E1t，只替换标题最后一个 token，真标题→false_0，最终输出恢复比例，全部 1,186 篇 L8–L40 为 0.12–0.15，L56 0.004；报告 §6.11 恢复比例图虚线；361_stage11/summary/E1t_recovery.csv）。右边：从 L0 起阻断对标题的注意力，去掉 83% 的效应；从 L32 起 37%，从 L48 起 6%，从 L52 起为 0（Stage 11 E2 阻断，标题之后全部位置从第 l 层起不能注意标题，最终输出损失比例（÷ 真标题 − false_0 差距），1,186 篇，L0 0.831 [0.801, 0.862]、L32 0.372、L48 0.064、L52 0.007 [0.001, 0.013]；报告 §6.11 阻断图；361_stage11/summary/E2_knockout.csv（group=all））。只阻断冒号和名字位置最多去掉 15%（Stage 11 E2n，只阻断 “:” 和名字位置对标题的注意力，从 L0 起，最终输出损失比例，1,186 篇，0.153 [0.136, 0.172]；报告 §6.11 阻断图虚线；361_stage11/summary/E2n_knockout.csv），所以页面上说：信息在 L44–52 进入名字位置，部分经由标题之后的 token。（已复核：被复制的 token 里包括名字位置本身。Stage 12 P1 逐位置替换显示，信息主要汇集在名字位置上：只换名字位置在 L52 恢复 0.847，只换冒号最多 0.17（Stage 12 P1 逐位置替换，真标题→false_0，最终输出名字 token 恢复比例，Stage 11 样本 1,186 篇：只换名字位置 L48 0.61、L52 0.847，单个位置最大为 “:” L52 0.172 [0.156, 0.187]；报告 Stage 12 节 P1 表；371_stage12/summary/P1_patch_pos.csv）；X6 用 5 个假标题重做，时间不变，L48 恢复约 0.82，L52 起约 1.0（Stage 13 X6，用 5 个假标题分别做 Stage 11 E1 替换，全部 1,186 篇，5 个假标题平均 R：L24 0.080、L40 0.302、L48 0.821、L52 0.995，团队聚类 95% CI；报告 Stage 13 X6 节；381_stage13/reports/x6_report.md（all 表 average 列））。）目标组和对照组的曲线相同。

Stages 1–9 · 20–200 papers

## What we saw

- Stage 4 peak at L56 driven by one paper (71%)(audit_report.md)
- 7.2: A–B win-rate positive at L40–L56
- 7.3, 8: L56 title advantage; L56 became the primary layer

Stages 10–11 · 9,108 papers

## What scale showed

- L56 is where it *starts*; steepest rise L57–L61
- Patching: copying tail states recovers 80–87% at L48, 99.6% from L52(Stage 11 E1, 593 + 593; x6_report.md)
- Knockout: blocking the title from L52 on costs nothing

**Line C: "read early, spoken late"**

L56 was a real landmark, but not the peak. Interventions add what readouts cannot: the title is consumed in L24–50, and the answer only becomes readable at the name a dozen layers later.

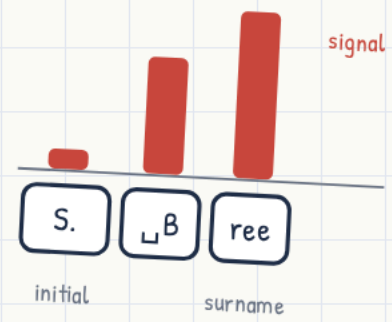




C 线的小结。小样本阶段看到：Stage 4 的 L56 峰值由一篇论文撑起（71%）（Stage 4，J-Lens L56，第一作者首 token 倒数名次，20 篇，最大单篇占总和 71.03%；351_all/351_stage4_artifacts/audit/audit_report.md 表 1 行 L56；报告 Stage 4 节）；7.2 中 A–B 胜率在 L40–L56 为正；7.3 和 Stage 8 的标题优势在 L56，于是 L56 成了主要层。全量阶段看到：L56 是开始上升的地方，上升最快的是 L57–L61；替换标题之后的 token 状态在 L48 恢复 80–87%（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例，L48 目标 593 篇 0.803、对照 593 篇 0.866（全部 0.825）；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv），L52 起恢复 0.996（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L52 0.996 [0.989, 1.003]（目标 0.986、对照 1.016）；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））；从 L52 起阻断标题几乎没有损失。L56 是真实的路标，但不是峰值；干预实验补上了读出看不到的东西：标题在 L24–50 被读取，答案要到十几层之后才在名字位置变得可读。（已复核：页面中“复制标题之后的 token 状态”包含名字位置本身；Stage 12 P1 和 X6 显示信息主要汇集在名字位置上，L52 起完成。）

Line D

# Which token carries it?




small samples asked

First token or the rest of the name?

→

the full cohort answered

Depends on name format; the information enters the name positions at L44–52, partly via the tokens right after the title; co-authors partly replace the title



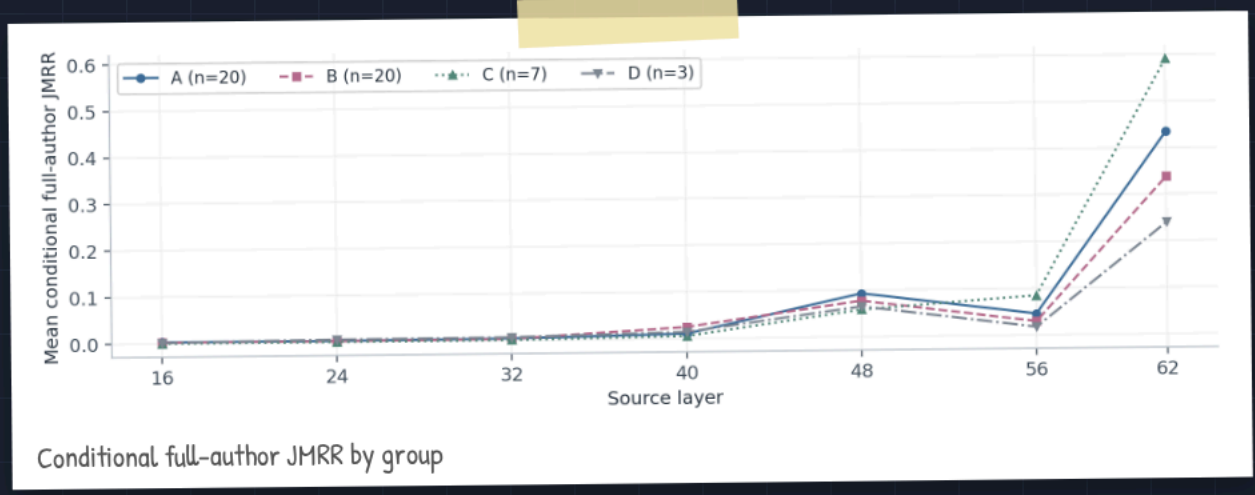


D 线的问题是：哪个 token 带着信号？小样本阶段问的是：是名字的第一个 token，还是名字的其余部分？全量阶段的回答是：取决于名字的格式；信息在 L44–52 进入名字位置，部分经由标题之后的 token；前面的合作者会部分代替标题的作用。（这一点已按 Stage 12 P1 和 X6 复核。）

Stage 6 · Line D

# From first token to the full name

50 papers, 227 authors, 972 name tokens(token_layer_scores.csv); every listed author scored with teacher forcing




Conditional full-author JMRR by group

| Group | Integrated JMRR(integrated_group.csv) |
|---|---|
| A (20) | 0.085 [0.075, 0.096] |
| B (20) | 0.068 [0.057, 0.080] |
| C (7) | 0.106 |
| D (3) | 0.050 |

L62 A–B +0.097 [0.028, 0.163]; Vanilla also +0.091(20 pairs, matched_ab_bootstrap.csv)

Positive, but each token after the first is given the correct prefix. Next: split first token from the rest (7.1).



 新写讲稿

Stage 6 从第一个 token 扩展到完整名字：50 篇论文、227 位作者、972 个名字 token（Stage 6，Pilot50；351_stage6/raw/token_layer_scores.csv（方法手册统计）；351_stage6/summary/summary.json），所有列出的作者都用教师强制打分。条件完整作者 JMRR：A 组 0.085 [0.075, 0.096]，B 组 0.068 [0.057, 0.080]，C 组 0.106，D 组 0.050（Stage 6，J-Lens 条件完整作者 JMRR，7 层积分，各组论文均值（A 20、B 20、C 7、D 3 篇），论文 bootstrap 95% CI；报告 Stage 6 节图 6.1；351_stage6/summary/integrated_group.csv）。L62 上 A−B 为 +0.097 [0.028, 0.163]，Vanilla 也是 +0.091（Stage 6，条件全名 JMRR，L62 匹配 A − B，20 对：J-Lens +0.0966 [0.0282, 0.1630]，Vanilla +0.0907 [0.0161, 0.1676]，配对 bootstrap 95% CI；351_stage6/summary/matched_ab_bootstrap.csv 行 layer=62）。结果为正，但第一个 token 之后的每个 token 都已经给出了正确的前缀，所以下一步要把第一个 token 和其余部分分开（7.1）。

Stage 7.1 · Line D

# The A–B gap sits on the rest of the name

CPU-only re-analysis of Stage 6; 10,000 pair-bootstrap draws



Integrated A–B JMRR by token position

| Endpoint | A–B (7 layers)(20 pairs; layer_and_integrated_effects.csv) |
|---|---|
| First token | +0.001 [−0.011, +0.015] |
| Continuation | +0.021 [+0.002, +0.039] |
| All tokens | +0.017 [+0.003, +0.030] |

At L62: first +0.014 (12/20 pairs) vs continuation +0.121 (15/20)(layer_position_effects.csv)

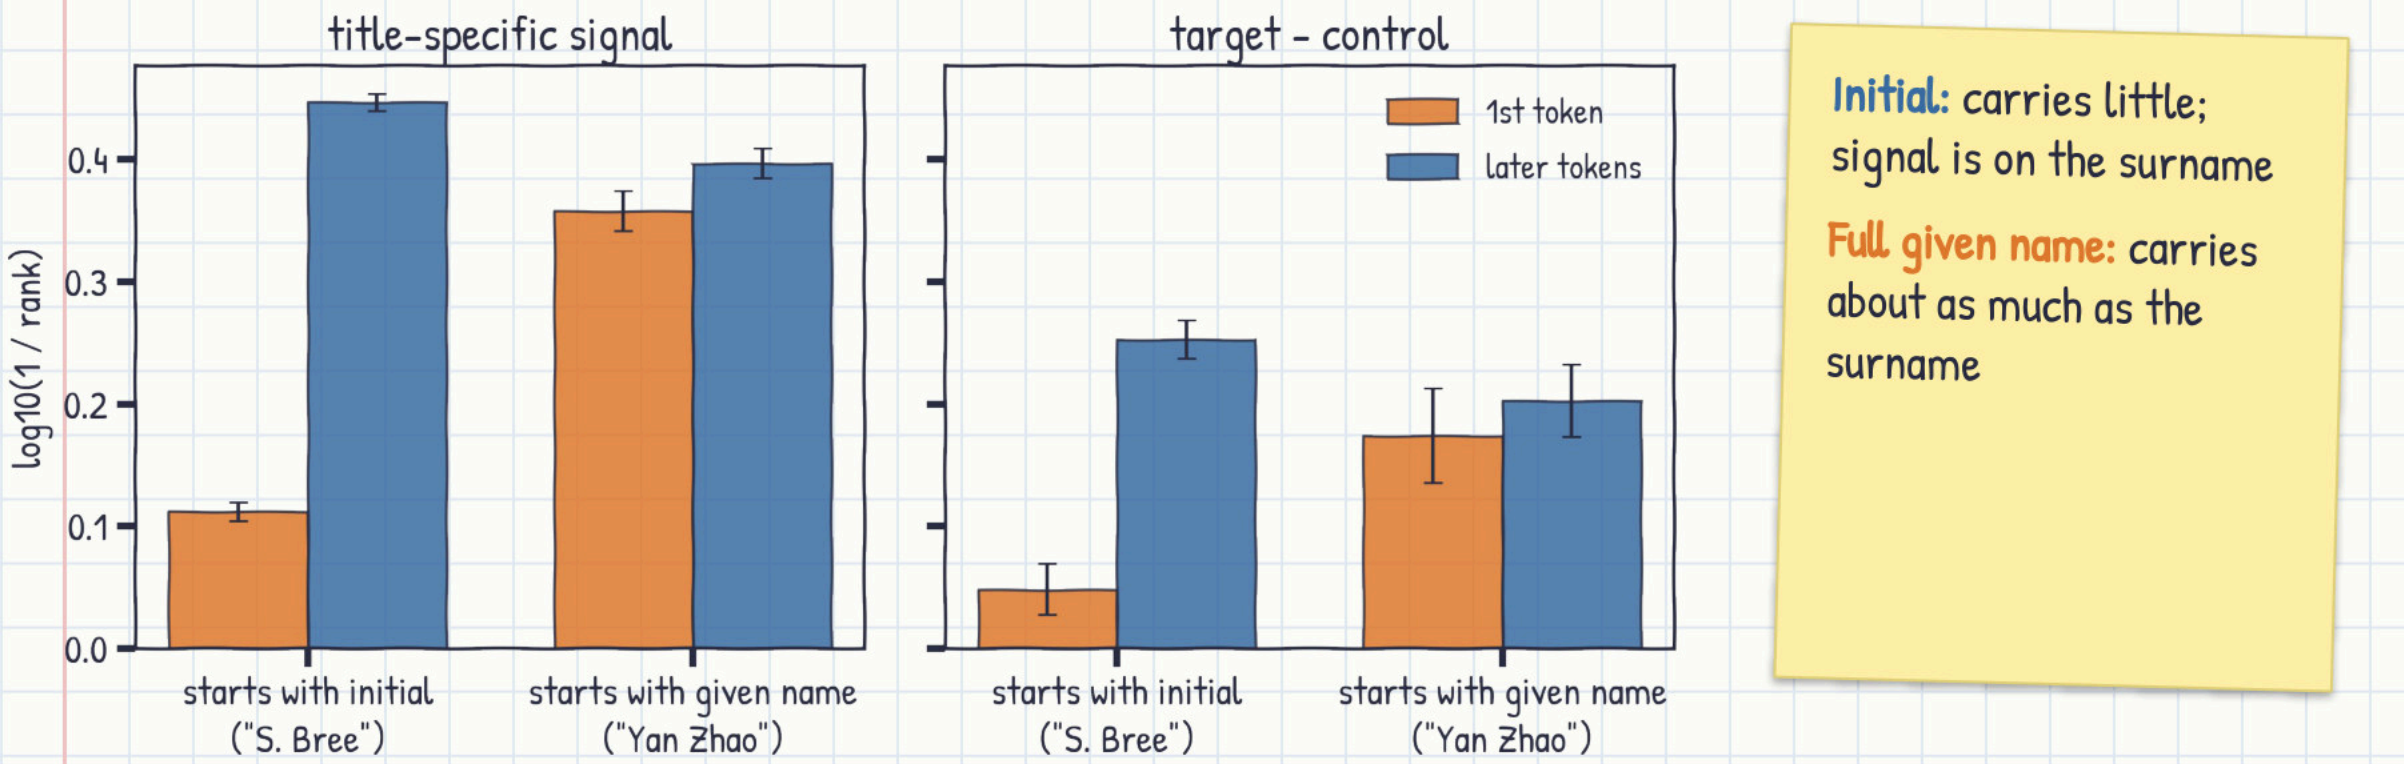
With a title contrast (addendum 13 C-1): holds at the output (+0.244) and at L62 (+0.278 logit, +0.317 public J-lens); the public J-lens 6-layer mean is not significant (+0.077 [−0.021, +0.180])(20 pairs, rest of the name; c13_C1.md)

Completing a name is easier than starting it. A continuation gap cannot show unaided recall. **Open:** is this about initials vs surnames?



第 53 / 82 页 · Stage 7.1 · Line D · 合并 PPT 自身页面 **新写讲稿**

Stage 7.1 只用 CPU 重新分析 Stage 6，做了 10,000 次配对 bootstrap（Stage 7.1 设计，种子 35171；~/jlens_work/07_1_stage7_1/351_stage7.py:14,86-87,181）。7 层积分的 A−B：第一个 token +0.001 [−0.011, +0.015]，后续 token +0.021 [+0.002, +0.039]，全部 token +0.017 [+0.003, +0.030]（Stage 7.1，J-Lens JMRR 7 层积分，匹配 A − B，20 对，配对 bootstrap 95% CI：第一个 token +0.0014 [−0.0114, +0.0149]，后续 token +0.0206 [+0.0022, +0.0385]，全部 token +0.0166 [+0.0026, +0.0299]；报告 Stage 7.1 节表；351_stage7_1/summary/layer_and_integrated_effects.csv）。在 L62，第一个 token +0.014（20 对里 12 对为正），后续 token +0.121（20 对里 15 对为正）（同上，L62：第一个 token +0.0141（12/20 为正），后续 token +0.1215（15/20 为正）；351_stage7_1/summary/layer_and_integrated_effects.csv（layer=62））。补全一个名字比开头更容易，后续 token 上的差距不能说明模型能独立回忆。留下的问题是：这是不是首字母和姓的区别？ 2026-11-06 补（补充 13 C-1，事后）：加上标题对照（真标题 − Stage 10 的 5 个假标题）后，A−B 的差别在模型输出和 L62 上成立，public J-lens 多层平均不显著：名字其余 token 上输出 +0.244 [0.087, 0.398]、logit L62 +0.278 [0.088, 0.483]、public J-lens L62 +0.317 [0.145, 0.506]，public J-lens 6 层平均 +0.077 [−0.021, +0.180]（补充 13 C-1，Pilot50 20 对 A−B，配对 bootstrap 95% CI；381_stage13/reports/c13_C1.md aa_cont 行）。



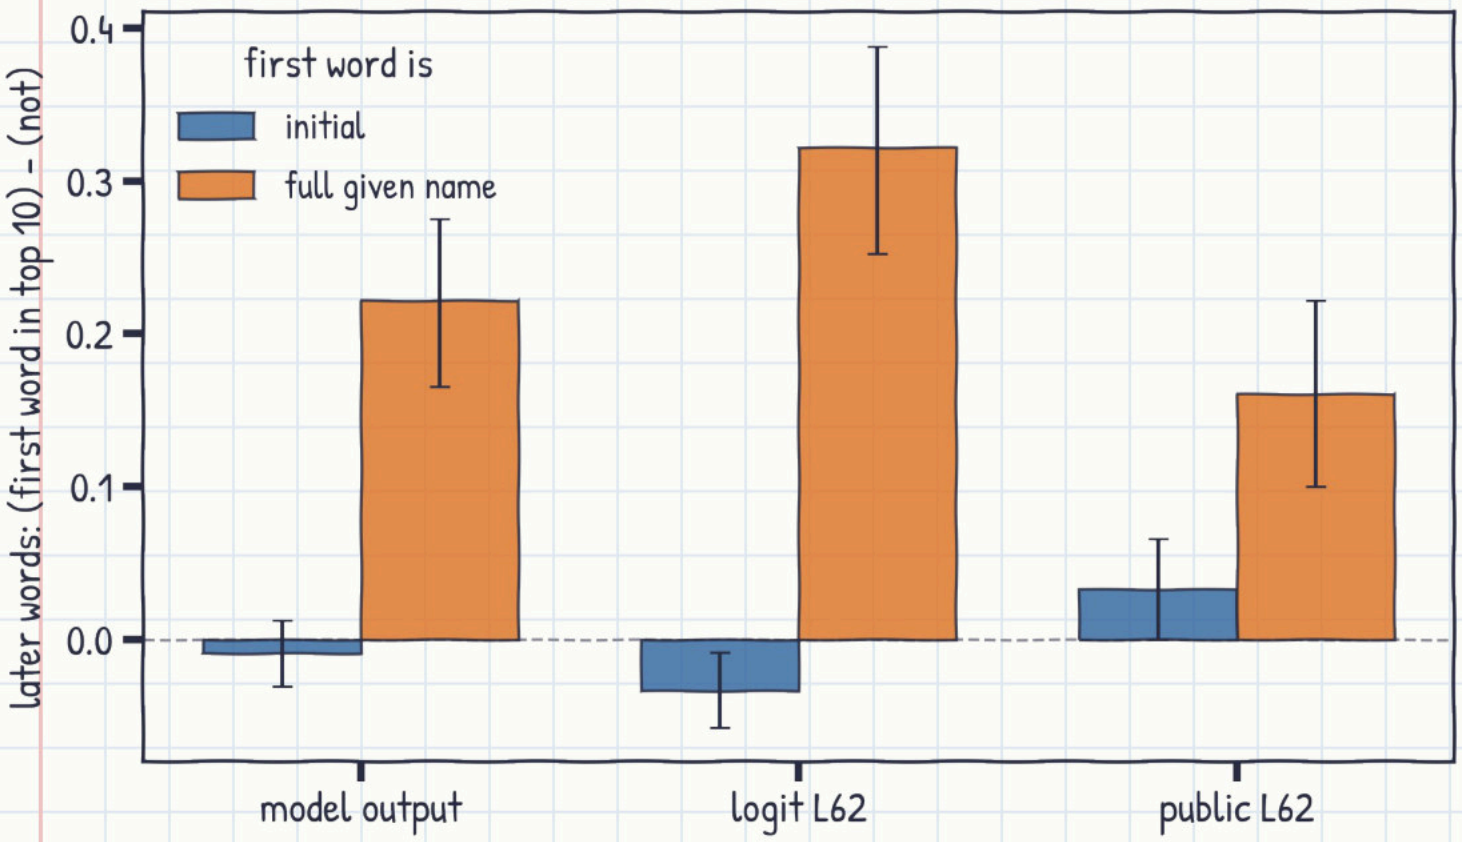



信号是否由第一个 token 决定？取决于名字的格式。以首字母开头的名字，首字母本身带的信号很少，信号在包括姓在内的后续 token 上；以完整名开头的名字，名本身带的信号和其余部分差不多。要注意教师强制：后续 token 在每种条件下都已经看到正确的前缀，所以它们的标题特异信号只能来自标题。

Stage 10

# Knowing the given name helps with the surname

true title · later words when the first word is / is not in the top 10




**Given name in top 10**

surname +0.22 (output) (Stage 10, 8,876 authors, §6.7)

+0.32 (logit L62) (same)

**Initial in top 10**: no help



知道了第一个词，其余部分会更容易吗？对完整的名，是的：名进入前 10 名时，姓在输出处高 +0.22，logit lens 在 L62 高 +0.32（Stage 10 §6.7，真标题，完整名开头的 8,876 位作者（名进前 10：678 位），姓（后续 token）平均 log10(1/名次)，进前 10 − 未进，论文聚类 bootstrap 95% CI：最终输出 L63 +0.222 [0.165, 0.275]，logit lens L62 +0.322 [0.253, 0.388]；351_stage10/summary_extra/X1_cond_by_first_role.csv）。对首字母则没有这种帮助。如果把两种格式混在一起，甚至会看到负的效果，因为首字母很好猜，而后面的姓很难。