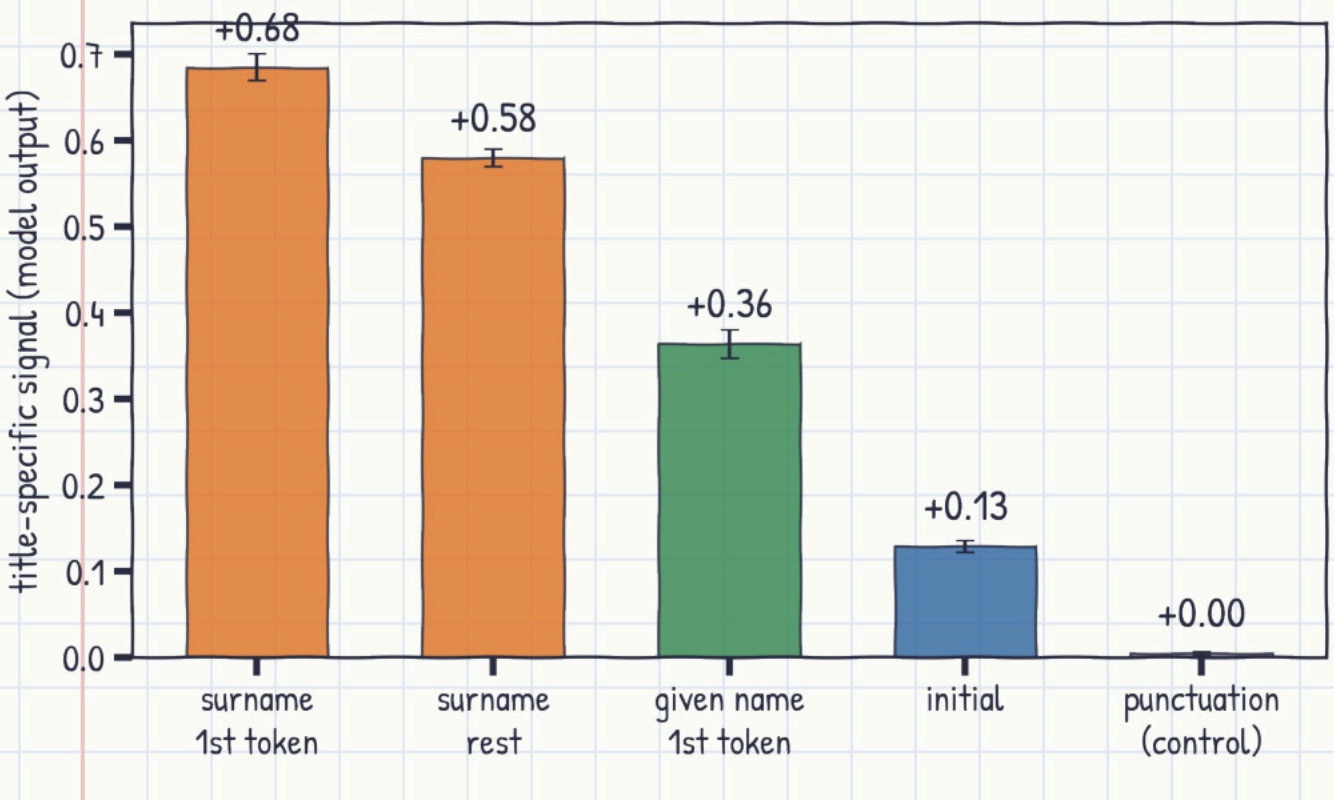
# Where the signal sits, and a dose-response







Right: R0/R1 papers, centred within citation bin; Spearman rho = 0.27, p < 0.001. (Stage 10, 8,894 papers, §6.6)

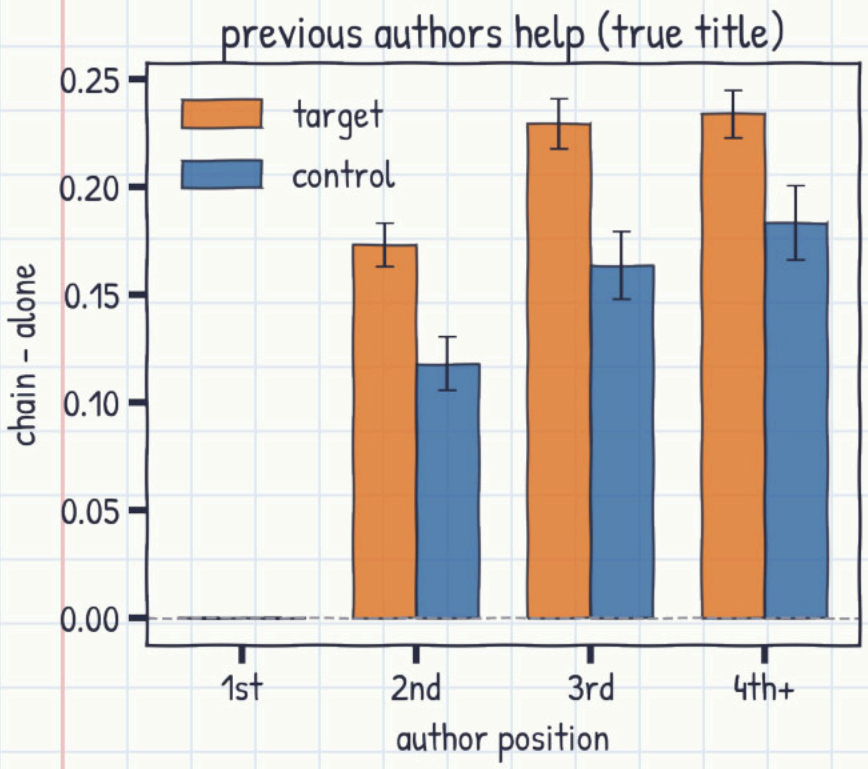
 按 deck 讲稿备注翻译（已按复核结果更新）

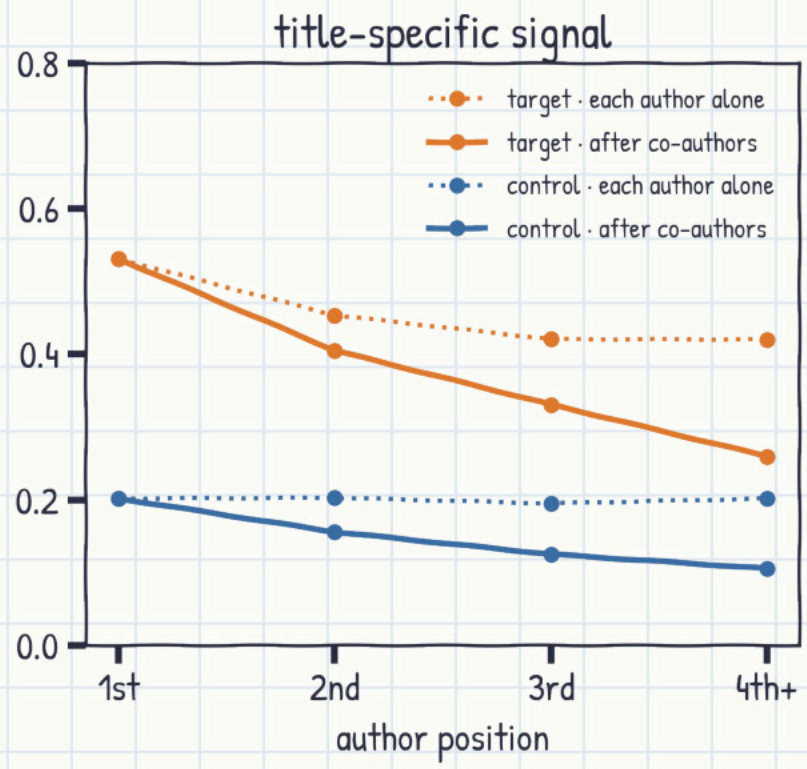
左图是输出处按 token 角色分的标题特异信号：姓的第一个 token 最多，首字母最少，标点约为 0，这是阴性对照。右图是：在所有写不出作者的论文里，多选题答对的顺序越多，模型输出越好（Spearman 0.27）（Stage 10，真标题，最终输出 L63，引用档内中心化的平均 log10(1/名次) 与多选题答对顺序数 0–4，R0/R1 论文 8,894 篇，引用档内 Spearman ρ = 0.268（p < 0.001）；报告 §6.6；351_stage10/summary/C_graded_mc_team_a.csv（metric=mean_nlr））。

Stage 11

# Co-authors help, and partly replace the title

model output · all 9,108 papers · 95% CI (Stage 11 E3, §6.11)




later authors **+0.17 to +0.23** (Stage 11 E3, 4,621 target, §6.11)

title-specific part **shrinks**

target > control still

第 57 / 82 页 · deck 第 19 页 按 deck 讲稿备注翻译（已按复核结果更新）

作者链。当前面的作者已经在上下文里时，后面的作者更容易：目标组高 +0.17 到 +0.23，对照组高 +0.12 到 +0.18（Stage 11 E3 连写 – 单独打分，真标题，最终输出 L63，作者位置 2 到 4+：目标 +0.173 / +0.229 / +0.234（4,073 / 2,978 / 2,030 篇），对照 +0.118 / +0.164 / +0.183，论文 bootstrap 95% CI；报告 §6.11 连写表 gain 列；361_stage11/summary/E3_chain.csv）。但标题的作用变小了：后面目标作者的标题特异信号从 0.42 降到 0.26（Stage 11 E3，目标组第 4 位起作者，标题特异信号（真标题 – 5 个假标题平均，最终输出）单独打分 +0.421 → 连写 +0.260，2,030 篇（第 2 位为 +0.454 → +0.405）；报告 §6.11 连写表 4+ · target 行；361_stage11/summary/E3_chain.csv），因为合作者已经能确定是哪篇论文。在引用档内，目标组仍然高于对照组 +0.11 到 +0.15（Stage 11 E3 连写，标题特异，引用档内 目标−对照，作者位置 2 / 3 / 4+：+0.151 / +0.124 / +0.114；报告 §6.11 连写表；361_stage11/summary/E3_chain.csv）。

Stages 1–9 · 20–200 papers

## What we saw

- A–B lives on continuation tokens (+0.021), not the first token (+0.001)(7.1, 20 pairs)
- Open question: is that teacher forcing, initials or surnames?

Stages 10–11 · 9,108 papers

## What scale showed

- 73% of names start with an initial(24,739 / 33,780; §6.7), which carries little
- Full given names carry as much as surnames and help predict them (+0.22)(final L63; §6.7)
- Information travels title → name positions (L44–52), partly via tail tokens
- Earlier co-authors make later ones easier, title matters less

**Line D: the puzzle from 7.1 is explained by name format**

The pilot's "continuation" result was mostly a format effect: for "S. Bree" the surname is a continuation token. Stage 12 P1 (done) patched single positions: the name positions carry the signal (+0.85 at L52), the colon alone little (+0.17)(P1, 1,186 papers; P1_patch_pos.csv).

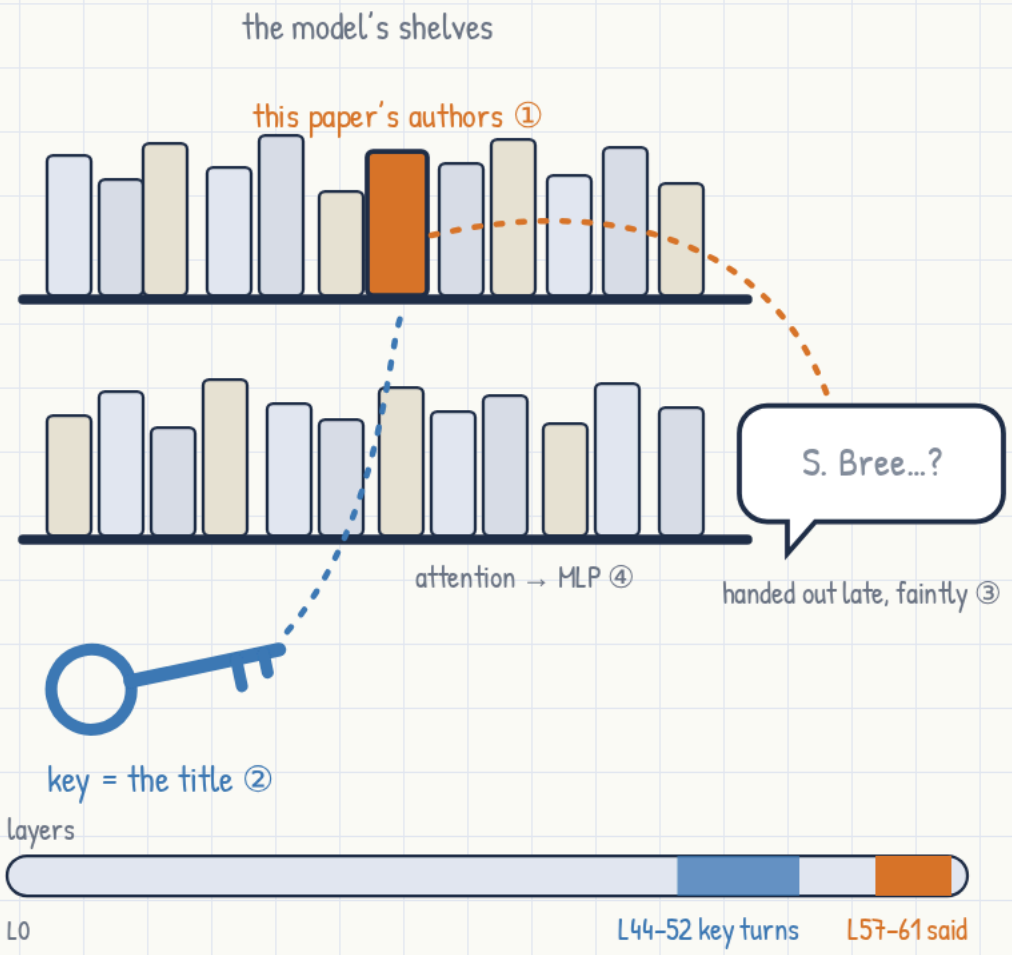




D 线的小结。小样本阶段看到：A–B 的差在后续 token 上（+0.021），不在第一个 token 上（+0.001）（Stage 7.1，J-Lens JMRR 7 层积分，匹配 A − B，20 对：后续 token +0.0206 [+0.0022, +0.0385]，第一个 token +0.0014 [−0.0114, +0.0149]；351_stage7_1/summary/layer_and_integrated_effects.csv）；当时留下的问题是，这是教师强制造成的，还是首字母和姓的区别。全量阶段看到：73% 的名字以首字母开头（Stage 10 名字格式，24,739 / 33,780 个作者上下文以首字母开头；报告 §6.7；351_stage10/summary_extra/X1_cond_by_first_role.csv 列 n_contexts（readout=final）），首字母本身信息很少；完整的名带的信号和姓相当，还能帮助预测姓（+0.22）（Stage 10 §6.7，完整名开头 8,876 位作者，名进前 10 − 未进，最终输出 L63 姓 +0.222 [0.165, 0.275]，论文聚类 bootstrap 95% CI；351_stage10/summary_extra/X1_cond_by_first_role.csv）；信息从标题在 L44–L52 汇集到名字位置，部分经由标题之后的 token；前面的合作者让后面的作者更容易，标题的作用变小。7.1 的谜题由名字格式解释：像“S. Bree”这样的名字，姓本来就是后续 token。Stage 12 P1 已完成：只换名字位置在 L52 恢复 0.847，只换冒号最多 0.17（Stage 12 P1 逐位置替换，真标题→false_0，最终输出名字 token 恢复比例，Stage 11 样本 1,186 篇：只换名字位置 L48 0.61、L52 0.847，单个位置最大为 “:” L52 0.172 [0.156, 0.187]；报告 Stage 12 节 P1 表；371_stage12/summary/P1_patch_pos.csv）；X6 用 5 个假标题（Stage 13 X6，用 5 个假标题分别做 Stage 11 E1 替换，全部 1,186 篇，5 个假标题平均 R：L24 0.080、L40 0.302、L48 0.821、L52 0.995，团队聚类 95% CI；报告 Stage 13 X6 节；381_stage13/reports/x6_report.md（all 表 average 列））确认了这个时间。

# Keys and shelves

Is the book on the shelf, or is the key failing to get it out?




### ① Is the book on the shelf? Yes

True title beats false titles (≈0.44 at L62(§6.9)); a probe on the title token reads paper-specific authors from L24 (re-checked)

Lines A, B · Stage 5, 7.3, 8D, 10, 11

### ② Key = the title, read into the name positions at L44–52

Whole prompt: 0.82 at L48, ≈1.0 from L52; name positions alone 0.61 → 0.85; ':' alone ≤ 0.17(E1, P1; 1,186 papers); knockout after L52 costs almost nothing

Line C · Stage 11, 12 P1

### ③ Book there but stuck? Not supported

Target − control ≈ 0 at L24–L40, slightly negative at L48 (−0.04 to −0.05), grows only at L57–61 (+0.21 at output(§6.4)): retrieval itself is weak

Lines A, C · Stage 7.2, 10

### ④ Which shelf? Both, in order

Attention brings the title in at L48 (0.23); MLP takes over at L52–56 (0.18, 0.22)(P2, 1,186 papers). One-layer patching is a lower bound; whether the MLP step is memory lookup is not yet separable

Stage 12 P2

Caveat: a readout not finding it ≠ absent. Stage 13: ':' and name positions hold the task; the title position holds paper attributes and meaning beyond the words, not shown to be paper identity.





用“钥匙和书架”来串起四条线。第一，书在不在架上？在：真标题胜过假标题，L62 约 0.44（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）；标题 token 上的 probe 能读出论文特有的作者（复核后从 L24 起）。第二，钥匙就是标题，在 L44–52 被读进名字位置：整段提示替换在 L48 恢复 0.82（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L48 0.825 [0.807, 0.842]；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））， L52 起约 1.0（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L52 0.996 [0.989, 1.003]；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））；只换名字位置从 0.61 升到 0.85，只换“:”最多 0.17（Stage 12 P1 逐位置替换，真标题→false_0，最终输出名字 token 恢复比例，Stage 11 样本 1,186 篇：只换名字位置 L48 0.61、L52 0.847，单个位置最大为“:” L52 0.172 [0.156, 0.187]；报告 Stage 12 节 P1 表；371_stage12/summary/P1_patch_pos.csv）；L52 之后阻断几乎没有损失（Stage 11 E2 阻断，标题之后全部位置从第 l 层起不能注意标题，最终输出损失比例（÷ 真标题 − false_0 差距），1,186 篇，L52 0.007 [0.001, 0.013]；报告 §6.11 阻断图；361_stage11/summary/E2_knockout.csv（group=all））（Stage 11 和 Stage 12 P1）。第三，书在架上但取不出来？不支持：目标−对照在 L24–L40 约为 0、L48 略为负（−0.037 到 −0.054，区间不含 0（Stage 10，引用档内目标−对照，三种 Jacobian lens L48 −0.037 到 −0.054；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），只在 L57–61 上升（输出处 +0.21）（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），提取本身就弱。第四，在哪个书架上？两者都有，有先后：L48 的注意力把标题读进来（恢复 0.23）（Stage 12 P2，标题之后全部位置只替换单层 attention 或 MLP 输出，最终输出恢复比例，1,186 篇：attention L48 0.231（MLP 0.07），MLP L52 0.178、L56 0.224；报告 Stage 12 节 P2 表；371_stage12/summary/P2_patch_comp.csv），L52–56 由 MLP 接手（0.18、0.22）（Stage 12 P2，标题之后全部位置只替换单层 attention 或 MLP 输出，最终输出恢复比例，1,186 篇：attention L48 0.231（MLP 0.07），MLP L52 0.178、L56 0.224；报告 Stage 12 节 P2 表；371_stage12/summary/P2_patch_comp.csv）。单层替换只是下限，MLP 这一步是不是在查记忆还分不开（Stage 12 P2）。最后提醒：读出工具找不到，不等于信息不存在。Stage 13 显示：冒号和名字位置承载的是任务；标题位置承载论文属性和超出用词的语义，但没有证明是论文身份。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Overview

# What the small samples taught us to watch for

- **Single-paper leverage**: one paper = 71% of the Stage 4 L56 mean (20 papers)
- **Tail-driven contrasts**: Stage 8 A–B disappears after removing 10 of 100 pairs(8D, matched_pair_differences.csv)
- **Forking paths**: L56 inspected repeatedly, then made primary
- **Candidate artefacts**: 100 false names share ~46 first tokens; 3% tie with gold(7.2 quality.json: 156/5,000)
- **Label noise**: strict "pass" 25.5% in the 0–2 citation bin (label_README.md)
- **Partial coverage**: first-listed author stands in for the team
- **Metric choice**: KL fidelity and author ranking disagree
- **Protocol drift**: plan locked 10-18 14:29 (7-layer integral primary); the 21:14 PROTOCOL switched to L56, both before 8C scoring; who and why open (U28)

Stage 10 answered each one by design: full cohort, every author and token, all layers reported, full-vocabulary ranks, within-bin comparison, frozen inputs with parity checks. What it cannot fix: groups still come from one labelling run of the same model.



 新写讲稿

小样本阶段教会我们要提防的几件事：单篇论文的杠杆，一篇论文占 Stage 4 L56 均值的 71%（Stage 4，J-Lens L56，第一作者首 token 倒数名次，20 篇，最大单篇占总和 71.03%；351_all/351_stage4_artifacts/audit/audit_report.md 表 1 行 L56；报告 Stage 4 节）；尾部驱动的对比，Stage 8 的 A–B 去掉 100 对中的 10 对就消失（Stage 8D RQ2，J-Lens L56 金标准胜率匹配 A–B，100 对，均值 +4.98 pp，按 A–B 降序去掉前 10 对后其余 90 对均值 −0.39 pp（事后诊断）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）重算；报告 Stage 8D 节）；分叉路径，L56 被反复查看后才定为主终点；候选伪影，100 个错误名字只有约 46 个不同的第一个 token，3% 与正确名字打平（Stage 7.2，Pilot50 每篇 100 个错误名字（50 匹配 + 50 随机），共 5,000 个；每篇平均 45.76 个不同首 token（方法手册 C 部分由 351_stage7_2/candidates/pilot50_author_candidates.csv 统计）；156 / 5,000 = 3.1% 与金标准首 token 相同记为平局（351_stage7_2/summary/quality.json））；标签噪声，0–2 次引用档的严格通过率为 25.5%（标注包自检，0-2 引用档 796 篇，收紧规则（4/4 且真选项平均概率 ≥ 0.5）多选通过率 25.5%（普通规则 38.6%）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 8 行）；覆盖不全，用第一作者代替整个团队；指标选择，KL 保真度和作者排名不一致；协议漂移：分析计划在 10-18 14:29 写定锁定（主终点为 7 层积分），同日 21:14 的 PROTOCOL 改为 L56，两者都早于 8C 打分；改动人和理由待查（U28）。Stage 10 在设计上逐条回应：全量论文、所有作者和 token、报告所有层、全词表名次、引用档内比较、冻结输入并做一致性检查。它没法解决的是：分组仍然来自同一模型的一次标注。

# Small vs large, in one table

| Finding | Stages 1–9 (20–200 papers) | Stages 10–11 (9,108 papers) | Verdict |
|---|---|---|---|
| True title helps | +9.3 pp pilot, +5.2 pp new 200(7.3; 8D RQ1) | ≈0.44 title-specific at L62(X3_means.csv) | confirmed |
| Recognised > not recognised | uncertain, tail-driven | +0.21 at output(§6.4), ≈0 at L24–L40, slightly negative at L48 (−0.04 to −0.05) | confirmed, late only |
| Same groups (A vs B, R0 only) | A – B as above | +0.20 at output(§6.13), ≈0 at L24–L40, slightly negative at L48; R1 adds strength, not timing | comparable, unchanged |
| Key layer | L56 | starts L56, rises L57–61; read L24–50 | refined |
| J-Lens over Vanilla | no increment | more name shape, no paper identity | consistent |
| First vs rest of name | gap on continuation | explained by initials vs given names | explained |
| Citations | low–high inconclusive | monotonic, ρ = 0.451(X2_spearman.csv) | resolved |
| Lens stability | split-half one split; Stage 9 only Fit A | three Jacobian lenses fitted on different text agree; fit stability rests on Stage 9 Fit A only | only one piece of evidence (Stage 9 Fit A); Fit B not completed |

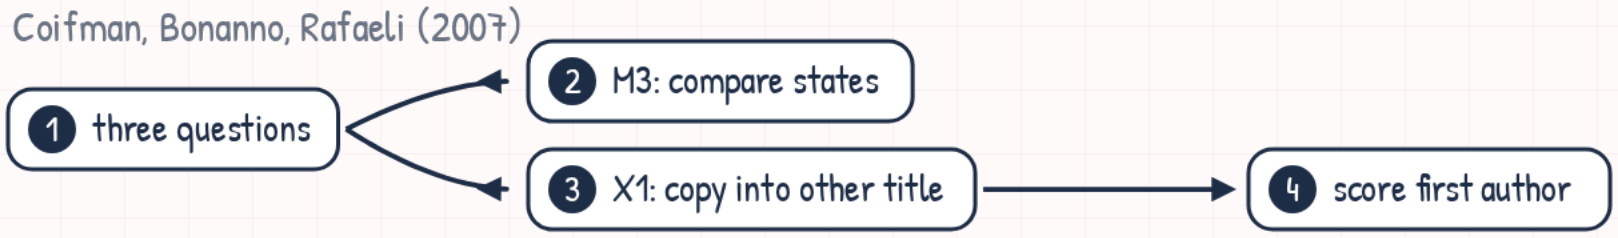


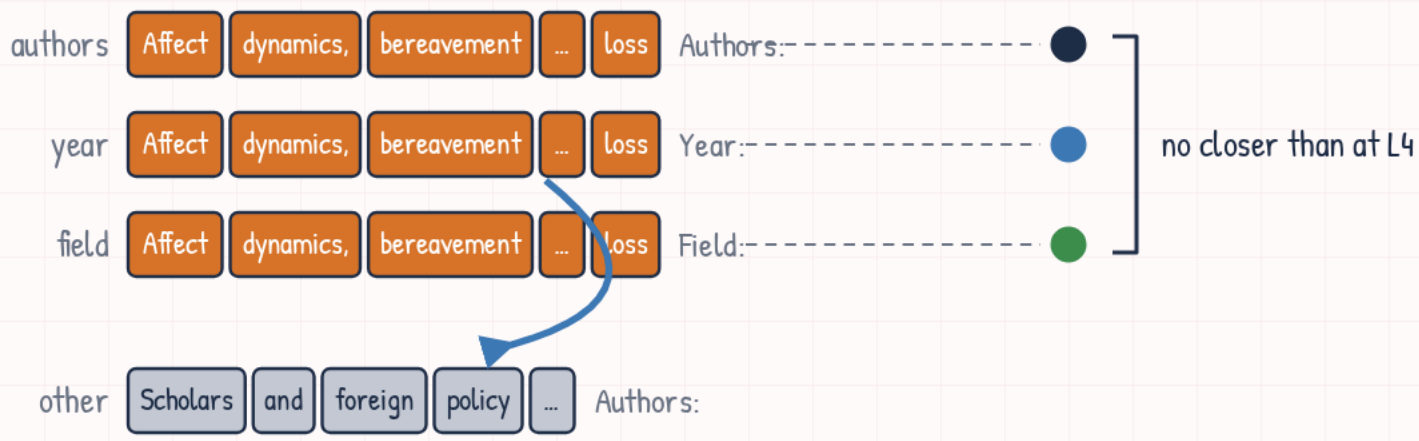
 新写讲稿

一张表对照小样本和全量。真标题有帮助：Pilot +9.3（Stage 7.3，J-Lens L56，真标题胜率 − 20 个错误标题平均胜率，合并池，Pilot50 50 篇均值 +0.0934 [0.047, 0.139]（2026-10-30 重算区间，B = 20,000），35/50 篇为正；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv；报告 Stage 7.3 节）、新 200 篇 +5.18 个百分点（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节），全量 L62 标题特异约 0.44（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv），确认。认得出大于认不出：小样本不确定、依赖尾部，全量输出处 +0.21（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）、L24–L40 约为 0、L48 略为负（−0.037 到 −0.054，区间不含 0），确认，但只在最后几层。同一分组（A 对 B，只用 R0）：输出 +0.20（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv）、中间约 0，R1 只增加强度不改变时间，两阶段可比、结论不变。关键层：小样本是 L56，全量是 L56 开始、L57–61 上升、标题在 L24–50 被读取，细化。J-Lens 胜过 Vanilla：小样本没有增量，全量读出更多名字的样子、但没有论文身份，一致。名字第一个 token 和其余部分：小样本差距在后续 token，全量由首字母和完整名的格式差别解释。引用数：小样本低减高没有定论，全量单调上升 ρ = 0.451（Stage 10 补充 X2，标题特异信号（真标题 − 5 个假标题平均，最终输出 L63）对 log10(引用数+1) 的 Spearman ρ，全部 9,108 篇 0.451 [0.433, 0.467]，bootstrap 95% CI；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv），解决。lens 稳定性：小样本只有一次拆分、Stage 9 只有 Fit A，全量三把用不同文本拟合的 Jacobian lens（Stage 10 三种 Jacobian lens：public（557 条 WikiText-103）、self100（100 条）、fitA（Stage 9 Fit A 100 条）；351_stage10/config/lenses.json；报告 §6.9）结论一致；但同一把 lens 的拟合稳定性只有 Fit A 一份证据，Fit B 未完成。

# Changing the question

Coifman, Bonanno, Rafaeli (2007)




| R from | authors | year | field |
|---|---|---|---|
| L24 | 0.99 | 0.98 | 0.99 |
| L40 | 0.92 | 0.92 | 0.92 |
| L48 | 0.42 | 0.41 | 0.42 |

$$R(l) = (\text{patched} - \text{other}) \div (\text{own} - \text{other})$$

title states copied at layer l; 582 test papers

R: Stage 13 X1, test set 582 papers; 381_stage13/reports/x1_report.md

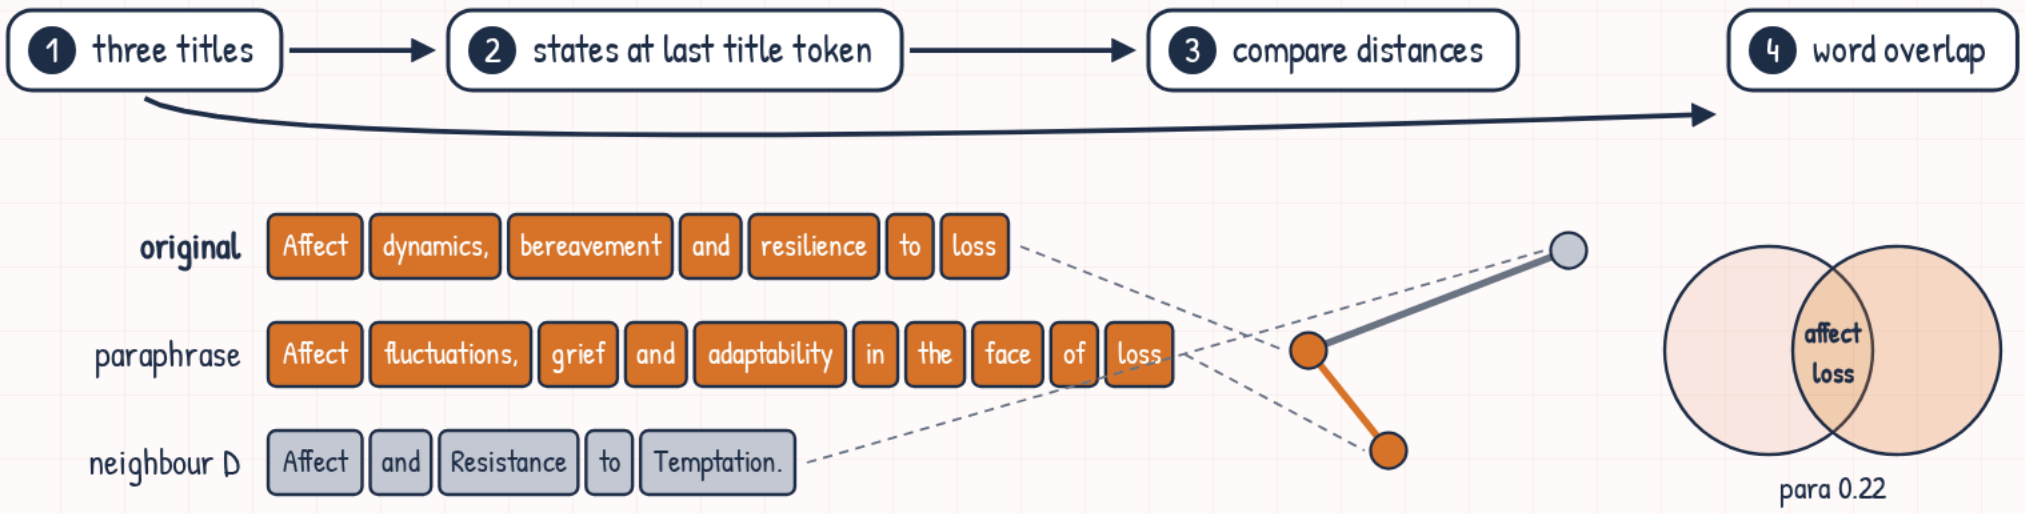


 新写讲稿

换问题：同一标题分别放进作者、年份、领域三个问题里（M3），比较标题最后位置的状态；它们不比 L4 时更接近，也就是没有超出标题文字本身的“论文身份”状态。X1 把本篇在任一问题下的标题状态复制进另一篇论文标题的作者提示，再给本篇第一作者打分：R(l) = (patched − other) ÷ (own − other)，L24 约 0.99，L40 约 0.92，L48 约 0.42（Stage 13 X1，测试集 582 篇，R = (patched − other) ÷ (own − other)，来源问题 作者/年份/领域：L24 0.991/0.985/0.992，L40 0.921/0.917/0.915，L48 0.424/0.405/0.417，团队聚类 95% CI；报告 Stage 13 X1 表；381_stage13/reports/x1_report.md test 表），三种来源几乎一样（测试集 582 篇）（Stage 13 X1 调参集/测试集按作者团队各半：测试 582、调参 596 篇；381_stage13/reports/x1_report.md 第 3 行；381_stage13/config/pairs.parquet）。

# Paraphrased title (X3)

same paper in other words vs other paper, same words







para 0.22




D 0.14

**G′ = cos(orig, para) − cos(orig, D)**

+0.32 at L8 · peak +0.46 at L36 (test set)

first-author score, paraphrase − D: +0.239

medians: 0.61 vs 0.15

Word overlap 0.22 / 0.14: config/x3_lexical_neighbour_j2.csv (this paper) · medians: x3_report.md (primary set, 1,110) · G′: x3_textbase_recovery.md (test)
+0.239: Stage 13 X3 behaviour, test, 552 papers; x3_textbase_recovery.md

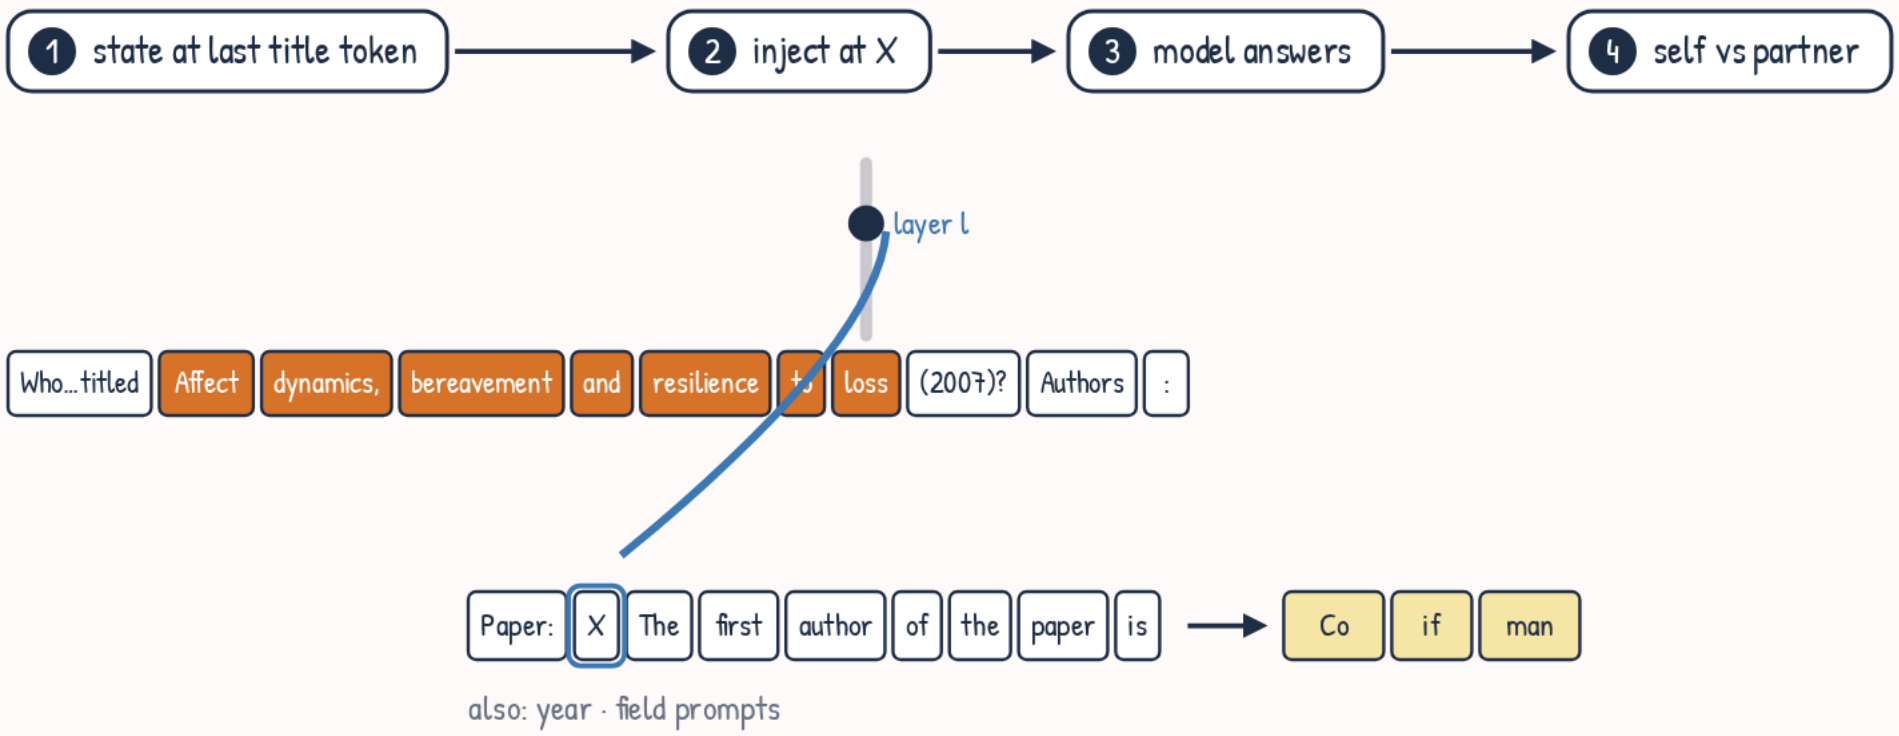


 新写讲稿

改写标题（X3）：示例论文原标题 “Affect dynamics, bereavement and resilience to loss”，改写为 “Affect fluctuations, grief and adaptability in the face of loss”，词汇邻居 D 是另一篇论文 “Affect and Resistance to Temptation.”。比较标题最后位置状态的余弦：G′ = cos(原, 改写) − cos(原, D)，L8 为 +0.32，L36 峰值 +0.46（Stage 13 X3，主分析测试集，标题最后一个 token，G′ = cos(原, 改写) − cos(原, D)：L8 +0.316 [0.293, 0.338]，峰值 L36 +0.463；报告 Stage 13 X3 节；381_stage13/reports/x3_report.md Verdict 节与 G′ 表）。词重叠 jaccard2 的中位数是改写 0.61、D 0.15（Stage 13 X3 主分析 1,110 篇，修正版 Jaccard（jaccard2）中位数：改写 0.611，近邻 D 0.154（敏感性集 1,012 篇为 0.615 / 0.150）；381_stage13/reports/x3_report.md Word overlap 表）（本例 0.22 和 0.14）（示例论文 Coifman 等（2007）：改写 jaccard2 0.222，近邻 D 0.143；381_stage13/config/x3_lexical_neighbour_j2.csv；381_stage13/summary_x3/para_nli.csv）；第一作者分数改写 − D 为 +0.239（Stage 13 X3 行为，第一作者教师强制打分 log10(1/名次)，改写标题 − 近邻 D 标题，主分析测试集 552 篇，+0.239 [0.212, 0.266]，团队聚类 95% CI；381_stage13/reports/x3_report.md Behaviour 表）。

# Patchscope (X4)

Coifman, Bonanno, Rafaeli (2007)




**D = score(own state) − score(partner state)**

score = log10(1/rank) of the true answer tokens

first author from L8: +0.046

year from L40: +0.013

D: Stage 13 X4, test set, team CI; first author L8 +0.046 [0.035, 0.059], year L40 +0.013 [0.008, 0.018]; 381_stage13/reports/x4_report.md



 新写讲稿

Patchscope（X4）：取作者问题里标题最后一个 token 在第 l 层的状态，注入到 “Paper: X / The first author of the paper is” 里 X 的位置（同一层），看模型接下去说出的答案；另有年份和领域两个目标提示。D = 用本篇状态时的分数 − 用配对论文状态时的分数。第一作者从 L8 起可以解码（+0.046）（Stage 13 X4，标题位置，D = 本篇状态 − 配对论文状态的答案分数（log10(1/名次)），最早层在调参集选出、测试集 582 篇确认：第一作者 L8 +0.046 [0.035, 0.059]，团队聚类 95% CI；报告 Stage 13 X4 表；381_stage13/reports/x4_report.md 第 9–11 行），年份从 L40 起（+0.013）（同上，年份 L40 +0.013 [0.008, 0.018]；381_stage13/reports/x4_report.md）。

# Stage 12–13: what the middle layers hold

Paper facts are readable at the title early (M2) · H2 (paper identity) partly supported but not established; H3 (hidden author knowledge): insufficient evidence · X2 (2026-11-05): H2 not supported; H3 passes by rule but the author subspace can hardly decode authors (held-out $R^2 \leq 0.009$) → still insufficient

| Hypothesis | M1: top word of the lens in middle layers | M2: probe reads non-name attributes | M3: change-of-task control | Current result (report v29, 2026-11-07) |
|---|---|---|---|---|
| **H1 task / format:** the middle layers represent "output an author list" | mostly "author", punctuation, common name starts; unrelated to the title | paper attributes not readable or very weak | the same title under different questions separates early in the middle layers | holds at ":" and name positions; at L4–L40, ":" moves 3–5× more when the question changes than when the paper changes (2.2× at L48, 1.3–1.5× at L56–L63) |
| **H2 paper identity:** the middle layers represent "which paper this is" | title-related words (copied from the title); change with a false title | field, year (inferred from the title), citations and recognition all readable, and earlier than the names | the same paper under different questions is close in the middle layers and separates by task only late<br>**Result:** not above the L4 text level, not supported | **M3 does not support it; X3 shows a semantic representation beyond wording in the middle layers, but it cannot be separated from paper identity; H2 currently rests on M2 and X1, and M2's Qwen-over-BERT advantage is reference only (addendum 2).** Also, the earliest decodable order in X4 is first author (L8) before year (L40), opposite to the H2 prediction. **X2 does not support it.** |
| **H3 author information already there, just not in vocabulary directions** | not necessarily | the authors' first token readable by the probe, not by the lens | an author-trained probe transfers across tasks; an author-specific lens (M4) reads names in the middle layers | **Text baseline not weaker than Qwen, a text explanation cannot be excluded: insufficient evidence** (X4: on the given-name first token BERT +0.088 ≥ Qwen L8 +0.018; the L8 signal sits mainly on the surname, see X4); **X2 passes by rule, but the author subspace can hardly decode authors (held-out $R^2 \leq 0.009$; refit on all authors it moves 0.032, about 7% of full patching): still insufficient** |

Hypotheses H1–H3 × readouts M1–M3 and current results (report v29, 2026-11-07)

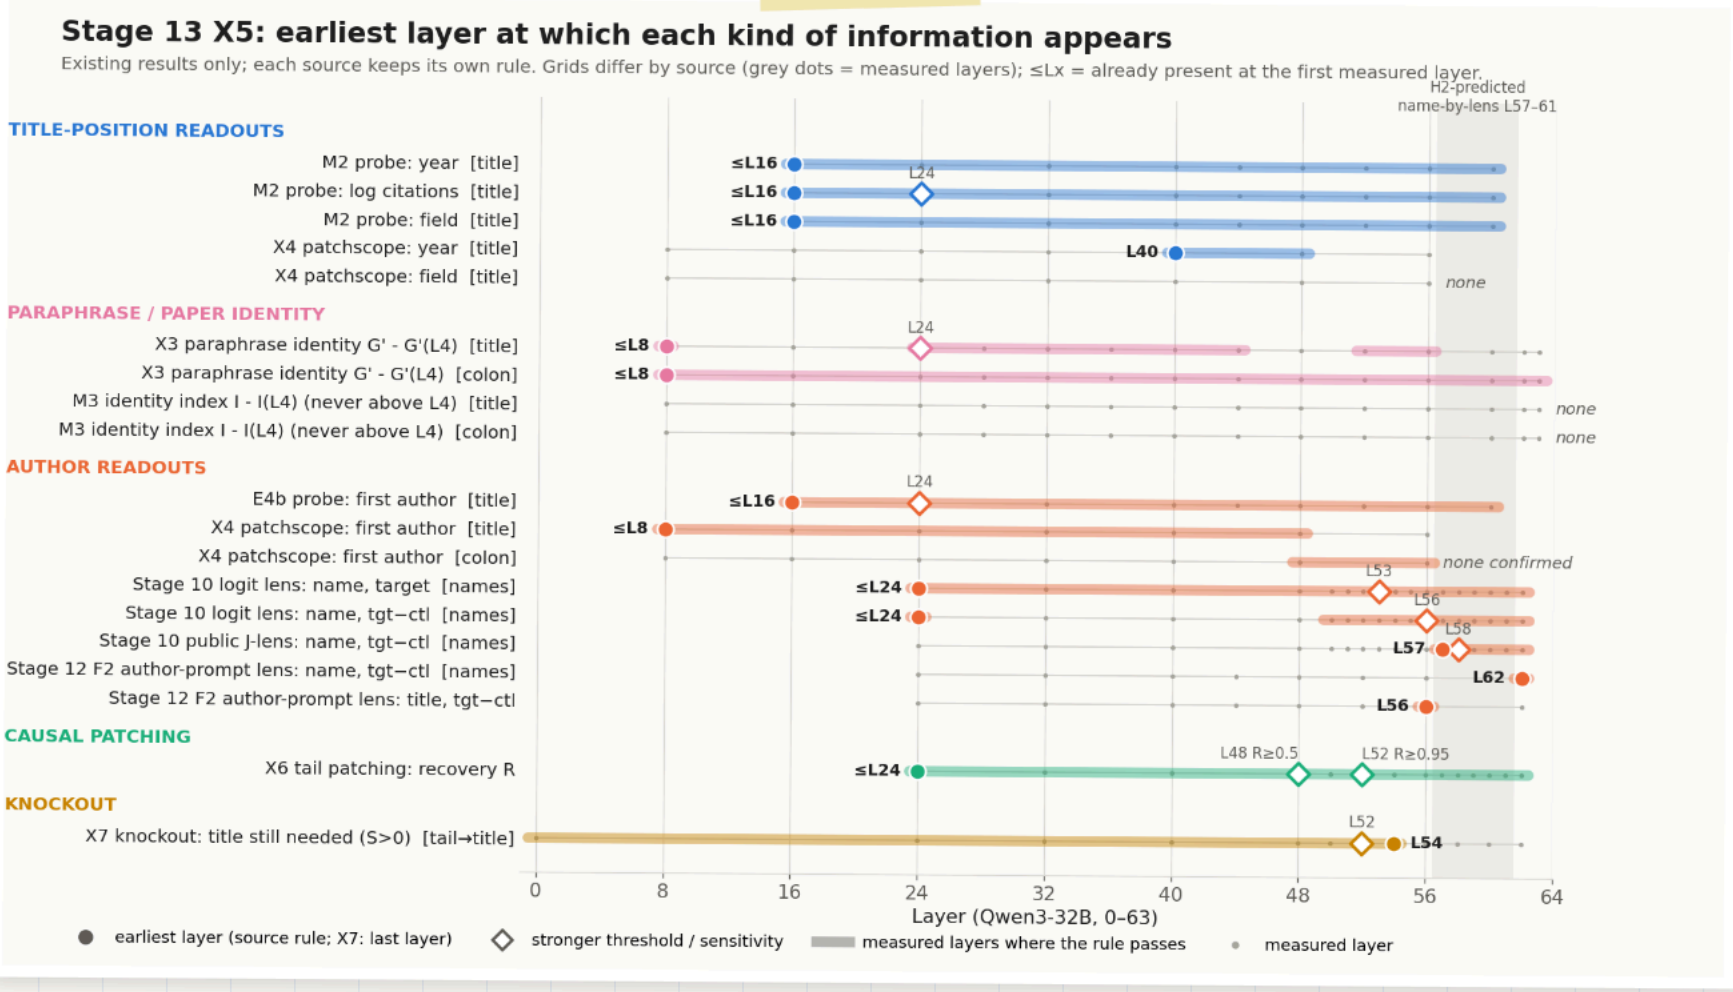


 新写讲稿

Stage 12 和 13 想回答：中间层到底装着什么。表里有三个假设：H1 中间层只是在准备“输出作者名单”这个任务，H2 中间层表示“这是哪一篇论文”，H3 作者信息已经在、只是不在词表方向上。结果是：probe 在标题位置从 L16 或更早就能读出年份、引用数和领域（M2），但换任务对照 M3 不支持 H2，论文身份指标从不高于 L4 的文字水平；X3 显示 L28–L40 有超出用词的语义表示，但不能区分是语义还是论文身份；X4 在 L8 就能解码第一作者，但这可能来自标题文字本身。所以 H2 部分支持但未确立，H3 证据不足。 X2（2026-11-05）：按预注册判据 H2 不支持、H3 通过，但作者子空间几乎解码不出作者，H3 证据仍不足；总体判断不变。

# Layer order (X5)

Earliest layer at which each kind of information appears · existing results only, each source keeps its own rule




**Read early, carried, spoken late**

**≤L8–L16**: title facts and the first-author token

**L48–L52**: the paper signal reaches the post-title tail (patching R ≥ 0.5 at L48, ≥ 0.95 at L52; knockout costs nothing from L52)

**L53–L62**: names readable by lens





X5 只用已有结果，把每种信息“最早在哪一层出现”排在一张图上，没有新的 GPU 计算。标题里的事实（年份、引用数、领域）和第一作者的首个 token 很早就读得出（L8–L16 或更早）；论文信号在 L48–L52 到达标题之后的位置：替换在 L48 恢复 R ≥ 0.5，L52 起 ≥ 0.95（Stage 13 X5 汇总，取 X6 5 个假标题平均恢复比例 L48 0.821、L52 0.995（团队聚类），X5 规则 R ≥ 0.5 / ≥ 0.95；381_stage13/summary_x5/x5_layer_order.csv X6 行；381_stage13/summary_x6/x6_recovery.csv；381_stage13/reports/x5_report_v2.md），从 L52 起阻断标题不再有损失（Stage 13 X7，论文特有阻断损失 S(L52)：全部 0.029、target 0.018、control 0.051（control L54 0.018、L56 0.000）；381_stage13/reports/x7_report.md）；名字要到 L53–L62 才能用 lens 读出。注意：M3 不支持 H2，X3 不能区分语义与论文身份，X4 在 L8 的第一作者信号可能来自标题文字，所以这张图只说明先后顺序，不说明机制。

# Stage 12: where the paper information travels

All 408 GPU units done · true title → false_0 · share of the true–false gap recovered at the output

- **P1 one position at a time:** the colon carries at most 0.17 (L52)(Stage 12 P1, 1,186 papers, paper bootstrap; P1_patch_pos.csv); all name positions together 0.85 at L52(same; CI [0.830, 0.864]); the whole prompt 1.00 (= Stage 11 E1)(same, 0.996)
- **P2 one component of one layer:** attention at L48 +0.23 [0.22, 0.24](Stage 12 P2, 1,186 papers; P2_patch_comp.csv), MLP at L52–L56 +0.18 to +0.22(same) → attention reads the title in, MLP processes it next
- **N1 name plausibility:** without a title the true list looks "most real" in 0.255 of papers (chance 0.25) (Stage 12 N1, 8,894 R0/R1 papers; N1_prior_mc.csv); with the true title 0.625(same, CI [0.615, 0.635])
- **N2 pure name prior (no paper):** target – control +0.047 [0.031, 0.062] vs +0.247 with the true title(Stage 12 N2, final L63, 4,621 + 2,220, within bin; stage12_report.md) → prior ≈ 19% of the gap
- **F2 lens fitted on author prompts:** target – control ≤ 0 at L24–L56, +0.238 only at L62(Stage 12 F2, name positions, Stage 11 sample, true − 5 false; F2_author_lens.csv)

### No single "notebook" token

The paper leaves the title at L44–L48 and is spread over the name positions; a lens fitted on author prompts still reads nothing paper-specific in the middle layers.



 新写讲稿

Stage 12（408 个 GPU 单元全部完成）。P1 一次只替换一个位置：“:” 最多恢复 0.17（Stage 12 P1，真标题→false_0，只替换 “:”，L52，最终输出恢复比例，Stage 11 样本 1,186 篇，论文 bootstrap 95% CI [0.156, 0.187]；报告第四部分 Stage 12 P1 表；371_stage12/summary/P1_patch_pos.csv），全部名字位置一起 0.85（同上，全部名字位置，L52 0.847 [0.830, 0.864]），整个提示 1.00（同上，= Stage 11 E1，L52 0.996）。P2 只替换一层的一个组件：L48 注意力 +0.23（Stage 12 P2，标题之后全部 token，1,186 篇，L48 注意力 0.231 [0.221, 0.244]；371_stage12/summary/P2_patch_comp.csv），L52–L56 的 MLP +0.18 到 +0.22（同上，MLP L52 0.178 [0.168, 0.190]、L56 0.224 [0.208, 0.239]）：先是注意力把标题读进来，然后 MLP 接着处理。N1：不给标题时，真作者列表在 4 个选项里“最像真的”的比例 0.255（Stage 12 N1，删去标题，R0/R1 论文 8,894 篇，CI [0.246, 0.264]；371_stage12/summary/N1_prior_mc.csv），与随机的 0.25 一样；给真标题后 0.625（同上，真标题，CI [0.615, 0.635]）。N2：纯名字提示下 target − control 只有 +0.047（Stage 12 N2，纯名字提示，最终输出 L63，目标 4,621 / 对照 2,220，引用档内差，论文 bootstrap 95% CI [0.031, 0.062]；371_stage12/reports/stage12_report.md），真标题下 +0.247（同上，真标题，[0.229, 0.266]），先验约占 19%（0.047 ÷ 0.247，由上两数算出）。F2：用作者提示拟合的 lens 在名字位置 L24–L56 的 target − control 都 ⩽ 0，只有 L62 为 +0.238（Stage 12 F2，名字位置，真 − 5 个假标题平均，Stage 11 样本，[0.210, 0.267]；371_stage12/summary/F2_author_lens.csv）。

# The Stage 11 timing holds for all 5 false titles

X6: replacement with each of the 5 false titles · X7: knockout minus the same knockout on the false-title run (S = T − F)

- **X6 replacement:** mean over 5 false titles 0.821 at L48 and 0.995 at L52(Stage 13 X6, 1,186 papers, team-cluster CI; x6_recovery.csv); each false title within 0.02 of false_0(x6_report.md) → "≈80% at L48, all from L52" is not specific to false_0
- **By name-token role:** surname first token 0.734 at L48, surname continuation 0.893; all roles ≥ 0.96 at L52(X6 roles, all papers; x6x7_roles.md)
- **X7 knockout:** blocking the title on the false-title run RAISES the true author score (F < 0), so the paper-specific loss S(L0) ≈ 1.00(Stage 13 X7, 1,186 papers, all: 1.004; x7_report.md); S(L52) = 0.029 [0.021, 0.038](same, all papers)
- **Pre-registered verdict (false_0 only):** holds for target (S(L52) 0.018) and all papers; control just misses (0.051, threshold 0.05)(X7, target 593 / control 593; x7_report.md)
- **Added 2026-11-06, mean of 5 false titles:** target +0.022, control +0.042, all +0.028 — all ≤ 0.05, so the claim holds in every group; control's 0.051 was one false title's fluctuation(addendum 10 item 2; b1_x7f_report.md)

### What changes

Nothing in the timing: the title is used up to about L52 and the paper information sits in the post-title positions by then (with five false titles all three groups pass).



 新写讲稿

X6：把 Stage 11 的替换换成 5 个假标题各做一遍，平均恢复 L48 为 0.821、L52 为 0.995（Stage 13 X6，真标题→5 个假标题平均，标题后全部位置，最终输出恢复比例（均值比），1,186 篇，团队聚类 95% CI L48 [0.806, 0.835]、L52 [0.990, 1.001]；报告第四部分 X6 表；381_stage13/summary_x6/x6_recovery.csv）；每个假标题与 false_0 相差不超过 0.02（381_stage13/reports/x6_report.md；对照组最大 0.019）。按名字 token 角色：姓的第一个 token L48 为 0.734，姓的后续 token 0.893（X6 角色拆分，全部论文，团队 CI [0.711, 0.757] / [0.880, 0.906]；381_stage13/reports/x6x7_roles.md），L52 各角色都 ⩾ 0.96（同上）。X7：在假标题运行上做同样的阻断，真作者的分数反而上升（F 为负），所以论文特有的损失 S(L0) ≈ 1.00（Stage 13 X7，S = T − F，1,186 篇，全部 1.004；381_stage13/reports/x7_report.md），S(L52) = 0.029（同上，全部论文，团队 CI [0.021, 0.038]）。预注册判定 S(L52) ⩽ 0.05：target 成立（0.018（X7，target 593 篇，[0.010, 0.027]）），control 差一点不成立（0.051（X7，control 593 篇，[0.033, 0.068]）），control 要到 L54–L56 才完全不需要标题。2026-11-06 补做（补充 10 第 2 项）：X7 补做了另外 4 个假标题，按 5 个平均判定，target、control 和全部论文都满足预注册判据（S(L52) 分别为 +0.022、+0.042、+0.028，均 ⩽ 0.05）（X7 五个假标题平均，target 593 / control 593 / 全部 1,186 篇，团队聚类 95% CI [0.015, 0.029] / [0.028, 0.055] / [0.022, 0.035]；381_stage13/reports/b1_x7f_report.md）；原来对照组只用 false_0 时为 0.051，属于单个假标题的波动（control 逐个假标题 0.051 / 0.035 / 0.048 / 0.033 / 0.041；同一报告）。

# Same title, different question

M3: probes across three questions (authors / year / field) · X1: patch A's title state from another question into B's author prompt

- **M3 transfer at the title:** T ≥ 0.92 at L16–L40, but never above the L4 text level(Stage 13 M3, 9,108 papers, team folds; m3_report.md) (year T − T(L4) −0.03 to −0.06)(same, CIs exclude 0) → M3 does not support H2
- **M3 at the colon:** T < 0.5 → the state is already organised by the question (H1)(same; summary_m3/m3_transfer.csv)
- **X1 replacement:** R ≈ 0.99 (L24), 0.92 (L40), 0.42 (L48) whichever question the state came from(Stage 13 X1, test 582 pairs, team CI; x1_report.md); authors − year within ±0.02, except a small +0.019 at L48(same, [0.012, 0.026])
- **Retrieval (added 2026-11-05):** no layer retrieves the paper across questions better than L4(X5 retrieval, 9,108 papers; x5_retrieval.md; post-defence)

**Reading**

The title state hardly depends on the question, and the replacement effect is task-independent; but nothing goes beyond what the title text alone gives at L4.



 新写讲稿

M3：同一篇论文换三种问法，标题最后一个 token 上的迁移比 T 在 L16–L40 都 ⩾ 0.92（Stage 13 M3，9,108 篇，按作者团队分 5 折的 probe，迁移比 = 跨问法成绩 ÷ 同问法成绩；报告第四部分 M3 表；381_stage13/reports/m3_report.md），但按补充 2 只看相对 L4 的变化：年份 T − T(L4) 为 −0.03 到 −0.06（同上，团队聚类 95% CI 都不含 0；summary_m3/m3_transfer.csv），不高于文字水平，所以 M3 不支持 H2。":" 位置 T < 0.5（同上），状态已按问题重新组织。X1：把 A 在别的问法下的标题状态替换进 B 的作者提示，恢复 R 在 L24 约 0.99、L40 0.92、L48 0.42（Stage 13 X1，测试集 582 对，作者问法来源，团队聚类 95% CI；381_stage13/reports/x1_report.md），三种来源几乎相同；作者 − 年份在 ±0.02 以内，只有 L48 有 +0.019（同上，[0.012, 0.026]）。答辩后补算的跨任务检索（X5 预注册曲线）也没有一层高于 L4（X5 检索，9,108 篇，top-1；381_stage13/reports/x5_retrieval.md；事后补算）。 2026-11-06（批次 1 第 1 项）：X1–X4 改为给全部作者打分（全部名字 token）并按作者排位分层，结论都不变：X1 仍与任务无关，L48 有一点小而确实的任务依赖（作者 − 年份 +0.024 [0.019, 0.030]（补充 10 第 1 项，测试集，团队聚类 95% CI；381_stage13/reports/b1_xall_report.md））。

# Patchscope and paraphrases

X4: decode year / first author / field from the paper's own title state · X3: paraphrased title vs a word-matched other paper

- **X4 first author:** decodable from L8, D = +0.046 [0.035, 0.059](Stage 13 X4, test split, team CI; x4_report.md); year only from L40, +0.013 [0.008, 0.018](same); field never → order opposite to the H2 prediction
- **But:** the L8 signal sits on the surname (+0.066), where the text-baseline check failed(X4 role split, 1,178 papers; x4_rolesplit.csv) → may be explained by the title text
- **X3 paraphrase:** closer to the original than a word-matched paper beyond L4, peak L36 +0.16(Stage 13 X3, test 552 papers, G′ − G′(L4), team CI [0.146, 0.171]; x3_report.md); behaviour keeps ≈ 90% of the first-author preference(same, 0.90 [0.87, 0.94])
- **Post-hoc checks:** a sentence-embedding model without author knowledge shows a comparable advantage, and target = control(X3 text baselines and group split; x3_textbase_recovery.md, x3_groupsplit.md) → meaning, not separable from paper identity

### H2 / H3 so far

H2 partly supported but not established (rests on M2 and X1); H3: insufficient evidence (text baseline not weaker than Qwen).



 新写讲稿

X4：把论文自己的标题状态注入“X 的第一作者 / 年份 / 领域是”提示。第一作者从 L8 起可解码，D = +0.046（Stage 13 X4，测试集，团队聚类 95% CI [0.035, 0.059]；报告第四部分 X4 表；381_stage13/reports/x4_report.md）；年份要到 L40，+0.013（同上，[0.008, 0.018]）；领域读不出——顺序与 H2 的预测相反。L8 的作者信号主要在姓的第一个 token 上（+0.066（X4 按 token 角色，1,178 篇，[0.045, 0.088]；381_stage13/summary_x1x4/x4_rolesplit.csv）），而姓氏上文本基线的阳性对照没有通过，所以可能来自标题文字。X3：改写标题在 L28–L40 比用词相近的近邻 D 更接近原标题，超出 L4 文字水平，最高 L36 +0.16（Stage 13 X3，主分析测试集 552 篇，G′ − G′(L4)，团队 CI [0.146, 0.171]；381_stage13/reports/x3_report.md）；行为上保留约 90% 的第一作者偏好（同上，教师强制打分，0.90 [0.87, 0.94]）。事后加的检验：不认识作者的句子向量模型在用词匹配子集上也有相当优势，target 与 control 没有差别（381_stage13/reports/x3_textbase_recovery.md、x3_groupsplit.md），所以只能说中间层表示了标题的意思，不能与论文身份区分。 2026-11-06（批次 1 第 1 项，全部作者）：X3 改写标题保留约 90% 的作者偏好，target 与 control 一样；X4 从 L8 起可解码出作者，各作者排位相同，认得出的论文在 L8–L40 更高；但只靠标题文字的基线不弱于 Qwen，仍不能排除标题文字的解释（381_stage13/reports/b1_xall_report.md）。

# X2: swap only a subspace

Patch only the paper-attribute (S_id, 9-dim) or the author (S_auth, 10-dim) component of A's title states into B · test 582 pairs · team-cluster 95% CI

- **Carry:** S_id at L40 moves +0.005 of the gap (random +0.003, full replacement +0.920); S_auth at L48 moves +0.018 (random +0.003, full +0.428)(Stage 13 X2, test 582 pairs; x2_report.md Verdict)
- **Pre-registered verdict:** H2 not supported (R_id 0.005 < 0.5 × R_full 0.460); H3 passes (R_auth − R_id +0.014 [+0.008, +0.020])(same, L40 / L48)
- **But:** the author subspace hardly decodes authors (held-out $R^2 \leq 0.003$; first-author token hit rate 0.078–0.079, below the constant baseline 0.080) and moves only about 4% of the full replacement(subspace fits on 5,041 training papers, 5 team folds; x2_report.md)
- **Remove arm:** setting either component to the mean costs no more than a random subspace (+0.001)(test, L_S − L_rand; same)

**Reading**

H3 passes by the pre-registered rule and H2 is not supported, but the author subspace cannot decode authors, so this is no strong evidence for H3. The information carried from the title to the names lies almost entirely outside both subspaces.



 新写讲稿

X2 只替换子空间（预注册补充 6，2026-11-05 完成）。在 B 的作者提示里只把标题位置状态在某个子空间上的分量换成 A 的：论文属性子空间 S_id（年份、引用数、领域，9 维）在 L40 只搬动 +0.005（Stage 13 X2，测试集 582 对，R_S（均值比）；随机子空间 +0.003，完整替换 +0.920；381_stage13/reports/x2_report.md Verdict 表），作者子空间 S_auth 在 L48 搬动 +0.018（同上，L48；随机 +0.003，完整替换 +0.428）。按预注册判据，H3 通过、H2 不支持（H2：R_id 0.005 < 0.5 × R_full 0.460；H3：R_auth − R_id +0.014 [+0.008, +0.020]，团队聚类 95% CI；同上）。但作者子空间本身几乎解码不出作者（留出 $R^2 \leqslant 0.003$（S_auth 作者映射，5,041 篇训练论文，5 折团队留出 $R^2$ 0.0009–0.0033；x2_report.md Subspace fits 表），第一作者名字 token 猜中率 0.078–0.079（同表 author top-1，L16–L48 各层），低于常数基线 0.080（同表 majority)），它搬动的量只有完整替换的约 4%（0.018 ÷ 0.428），因此不能作为 H3 的有力证据。从标题传到作者名字的信息，几乎全部分散在这两个子空间之外。与预注册的出入：X2 的 H3 判定按规则通过，但因子空间本身无解码能力而降级，与 X3 的处理方式相同；S_id 只有 9 维。 2026-11-06（批次 1 第 1 项）：用全部作者重新拟合作者子空间后，搬动量从 0.016 升到 0.032（完整替换的约 7%），但子空间本身仍几乎解码不出作者（留出 $R^2 \leqslant 0.009$），H3 仍证据不足（381_stage13/reports/b1_xall_report.md “X2: verdict” 与 “New S_auth” 节）。

# The probe on every name token

Title-position probe extended to all name tokens and split by role · L40 · true − false_0 · 1,395–1,754 target + control papers · team-cluster 95% CI

- **Surname first token:** +0.071 [0.058, 0.085], above the initial +0.044 [0.030, 0.057]; difference +0.028 [0.011, 0.045] → both pre-registered checks pass(addendum 9; e4b_alltok.md §5)
- **Given name first token strongest:** L40 +0.124, L56 +0.163(1,706 papers; same)
- **So E4b underestimated it:** E4b scored only each author's first token, mostly an initial
- **Permutation controls:** ≈ 0 on surname and given-name tokens; ≈ +0.02 on initials → about half of the initial's signal is not paper-specific(e4b_alltok.md §7)
- **Target − control (five false titles, per-donor exclusion):** given-name first token positive from L16, surname from L24 (L40 +0.030 [0.013, 0.048]); initial not significant (L40 +0.014 [−0.002, +0.030]); with false_0 only the surname is not significant before L56 — earlier statement superseded(within bin; b1_e4b5_report.md, per-donor)

### Five false titles (batch 1)

Per-donor exclusion, 4,654 papers: surname L40 +0.076, surname − initial +0.033. Without the title-reuse exclusion (C-3, C-3b) the signals are unchanged but include leakage: sensitivity only. (b1_e4b5_report.md; c13_C3b.md)



 新写讲稿

补充 9（答辩后新增，分析计划在看结果前写定）：把标题位置 probe 扩展到每位作者的全部名字 token，并按角色分开。在 L40，姓的第一个 token 的标题特异信号为 +0.071 [0.058, 0.085]（补充 9，标题最后一个 token，真标题 − false_0，目标 + 对照 1,395 篇，剔除标题复用，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md 第 5 节），高于首字母的 +0.044 [0.030, 0.057]（同上，1,590 篇），差为 +0.028 [0.011, 0.045]（同上，两项均值之差），两项预注册判据都通过。名的第一个 token 最强（L40 +0.124（1,706 篇，[0.108, 0.142]），L56 +0.163（[0.145, 0.181]））。原 E4b 只给每位作者的第一个 token 打分，而这个 token 多半是首字母，所以它低估了标题位置携带的名字信息。两种置换对照在姓、名的其余 token 上约为 0；在首字母上约为 +0.02（随机论文 / 同领域论文的作者作金标准；e4b_alltok.md 第 7 节），说明首字母的信号约一半不针对具体论文。认得出的论文在标题位置携带更多名字信息，按逐个假标题排除、5 个假标题平均，名的第一个 token 从 L16 起、姓从 L24 起 target−control 为正（姓 L40 +0.030 [0.013, 0.048]）；首字母不显著（L40 +0.014 [−0.002, +0.030]）。只用 false_0、样本较小时姓在 L56 前不显著，此前的说法已被取代（381_stage13/summary_b1_e4b5/perdonor_by_run_layer.csv，version=Vpd，列 tc / tc_lo / tc_hi（引用档内 target−control，团队聚类 bootstrap 2,000 次 95% CI）：given_first L16 +0.029 [+0.005, +0.052] 起各层都 > 0；surname_first L24 +0.019 [+0.001, +0.038] 起各层都 > 0；initial L40 +0.014 [−0.002, +0.030]；false_0 版本（V0，1,395 篇）姓 L16–L52 CI 含 0；b1_e4b5_report.md “Per-donor exclusion” 节 target − control 表）。probe 的定义：输入是第 l 层标题最后一个 token 的残差；目标是模型自己在 L63、在预测该角色名字 token 的位置上的状态，按论文平均；ridge，按作者团队分折；在 9,137 个名字 token 的词表里解码；标题特异 = 真标题 − false_0。批次 1 第 4 项（2026-11-06）：E4b 5 个假标题（偏离 D1 逐个假标题排除，保留 4,654 篇，平均 1.5 个假标题）：L40 姓首 token +0.076 [0.068, 0.083]，姓 − 首字母 +0.033 [0.023, 0.042]，原 E4b 第一个 token +0.066；置换对照首字母仍 +0.018，其余 ≈ 0；硬检查 E4b L40 +0.0609 PASS（381_stage13/reports/b1_e4b5_report.md 第 2 节与 “Per-donor exclusion” 节，目标 + 对照，团队聚类 95% CI）。不剔除标题复用的敏感性分析（补充 13 C-3、C-3b）含泄漏，只作敏感性分析，不作结论：C-3b 硬检查 PASS，L40 姓的第一个 token +0.077 [0.071, 0.084]、首字母 +0.034 [0.029, 0.039]、姓 − 首字母 +0.043 [0.035, 0.051]（6,841 篇；381_stage13/reports/c13_C3b.md），target − control 的区间几乎处处在 0 以上，与 C-3 一样。

# What we learned: read early, spoken late

| | |
|---|---|
| Read early | Causally the title is read in L24–L50 and gathered at the name positions by L52, then no longer needed. A probe at the title token reads a little of it from L24 (re-checked). |
| Spoken late | At the name positions, paper-specific author knowledge becomes lens-readable only from ~L50, fastest over L57–L61. |
| No lens lead | Read with a lens at the names, target is not ahead of control in middle layers; the +0.21 gap is at the end (Stage 10, final L63, §6.4) (probe at the title: target − control +0.03–0.08, re-checked (Stage 13 E4b, first name token only)). |
| Real knowledge | Name prior is ~1/3 of the gap overall but ~0 on surnames (Stage 12 A, 0.087 / 0.247, §6.12); the rest is paper-specific and grows with citations. |
| Lenses agree | Jacobian lenses read more in middle layers, but nothing target-specific. |
| Name format | Initials carry little; full given names carry as much as surnames and help predict them. |

第 73 / 82 页 · deck 第 14 页 按 deck 讲稿备注翻译（已按复核结果更新）

总结。一句话：读得早，说得晚。标题在 L24 到 L50 被读进来，证据是替换、阻断和标题 token 上的 probe；但作者名字要到 L57 到 L61 才在名字位置变得可读。lens 的结果（目标组在中间层没有领先）和 probe 的结果（标题 token 上目标组有优势）说的是不同的位置，两者不矛盾。（probe 的数字已按作者团队分折、剔除标题复用后复核：+0.05 到 +0.08（Stage 13 E4b 复核，标题最后一个 token 上的线性 probe，probe 只打分每位作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，全部 1,863 篇：L24 +0.050、L40 +0.061、L56 +0.075（L24–L60 为 +0.047 到 +0.075），论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第一张表），目标组高 +0.03 到 +0.08（同上 E4b 复核，probe 只打分第一个名字 token，引用档内 目标−对照，目标 896、对照 499 篇，L24–L60 为 +0.035（L44）到 +0.078，论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第二张表）。）注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

# Limits

**Done: Stage 12**

- Single-position patching (P1); attention vs MLP (P2, hook check passed)
- Name priors (N1, N2); author-prompt lens (F1, F2): middle layers still not readable

**Done: Stage 13**

- Probes read year, citations, field at the title from ≤L16 (M2); identity not above the L4 text level (M3)
- Replacement is task-independent (X1); paraphrase meaning beyond wording in L28–L40, not separable from paper identity (X3)
- First author decodable at L8, may be text-explainable (X4); 5 false titles confirm the Stage 11 timing (X6, X7)

**Limits**

- One model (Qwen3-32B)
- Teacher-forced preference, not generation
- Labels from the team lead's package; labelling code (elm) not available
- H2 (paper identity) partly supported but not established; H3 (hidden author knowledge): insufficient evidence



局限。Stage 12 和 13 都已完成。Stage 12 做了逐位置替换（P1）、注意力与 MLP 的替换（P2，显式的 hook 检查已通过）、两个名字先验基线（N1、N2）和在作者提示词上拟合的 lens（F1、F2），中间层仍然读不出名字。Stage 13：probe 从 L16 或更早在标题处读出年份、引用数和领域（M2），但 M3 不超过 L4 的文字水平；替换效应与任务无关（X1）；改写标题在 L28–L40 有超出用词的语义，但与论文身份分不开（X3）；第一作者在 L8 可解码，但可能来自标题文字（X4）；X6/X7 用 5 个假标题（Stage 13 X6 用 false_0–false_4 五个假标题重做 Stage 11 替换（L48 平均 0.821、L52 0.995），X7 在 false_0 运行上重做阻断；381_stage13/reports/x6_report.md、x7_report.md）确认了 Stage 11 的时间。局限：只有一个模型；测的是教师强制下的偏好，不是生成；标签来自组长的数据包，elm 标注代码拿不到；H2 部分支持但未确立，H3 证据不足。

Added after the defence

# Added after the defence (2026-11-05)

Group comparisons (plan fixed before the results: addenda 7, 8) · CPU leftovers (post-hoc) · experiments still running

1. Group comparisons A / B / C / D: three findings, intervention re-runs (E1 and P1 / P2 numerator / denominator), recognition
2. CPU leftovers on existing data: X5 retrieval curve, M3 scores, N2 by layer, paper vs team intervals, M5
3. Redo programme (addenda 10–14): done, batch 1 (only P1 / P2 with five false titles still running), batches 2 and 3; limits that cannot be redone

75

第 75 / 82 页 · Added after the defence · 合并 PPT 自身页面 **新写讲稿**

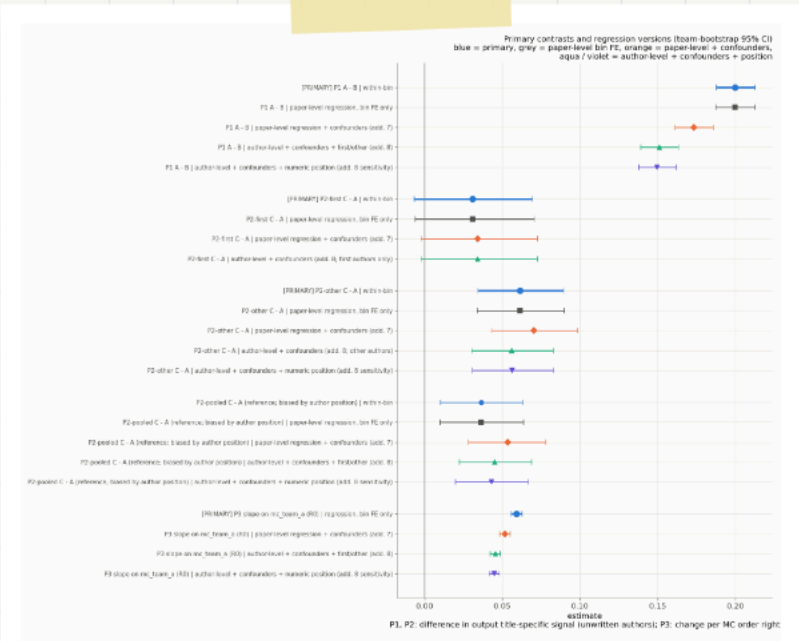
这一部分是答辩（2026-11-02 定稿）之后新增的内容。分组对比是答辩后新增的分析，分析计划在看结果前写定（补充 7、8）；CPU 补充分析是事后分析，只作描述；重做计划（补充 10–13）的规则都在看结果前写定。X2 和补充 9 的结果放在 Stage 13 部分。

Added after the defence · groups

# Group comparisons: three findings

Plan fixed before the results (addenda 7, 8) · unwritten authors only · output (L63) title-specific signal · within citation bin · team-bootstrap 95% CI · Holm over 4 tests

- **1 Recognition:** with no author written (R0), recognised papers (A) beat unrecognised ones (B) by **+0.200 [0.188, 0.213]**(P1 A − B, 3,417 / 2,148 papers, Holm p ≤ 0.002; primary.csv); with confounders +0.173 [0.161, 0.186](paper level, 5,565), author level + position +0.151 [0.139, 0.163](19,893 authors)
- **2 Graded:** each extra multiple-choice order right adds **+0.059 [0.056, 0.063]**(P3, 8,288 R0 papers, bin FE; Holm p ≤ 0.002) (confounders +0.046 [0.042, 0.049](author level)); ≈ 0.17 with none right, ≈ 0.46 with all four(R0, 927 / 4,105 papers; stage10_curves.csv)
- **3 Partial recall helps little (≈ ⅓ of recognition), output only:** C − A co-authors **+0.061 [0.034, 0.090]**(P2-other, 390 / 2,826 papers, Holm p ≤ 0.002), first author +0.031 [−0.006, 0.069], n.s.(P2-first, 292 / 3,199); ≈ 0 at L48–L62 with the logit lens, −0.07 to −0.11 at L48–L59 with the public J-lens(stage10_contrasts.csv, unwritten_other). The earlier ≈ +0.11 used all authors (circular)(r0_r1_analysis.md §2)
- **Reference only:** R2 written authors +0.844(200 papers; summary_table.md); only 28 R2 papers have unwritten authors(same)




Primary contrasts (blue) and regression versions; team-bootstrap 95% CI (391_groups/figures/fig3)



第 76 / 82 页 · Added after the defence · groups · 合并 PPT 自身页面 新写讲稿

分组对比，答辩后新增的分析，分析计划在看结果前写定（补充 7、8）。只比较模型没写出的作者，指标是输出层（L63）的标题特异信号（真标题 − 5 个假标题平均）。发现 1，识别的效应：两组都一个作者没写对（R0）时，在模型没写出的作者上，认得出的论文（A）比认不出的论文（B）在输出层的标题特异信号高 +0.200 [0.188, 0.213]（分组对比 P1 A − B，A 3,417 / B 2,148 篇、10 个引用档，引用档内差，团队聚类 95% CI；Holm 校正后 p ⩽ 0.002，受 2,000 次重抽的分辨率限制；391_groups/primary.csv）。控制领域、年份、作者人数和首字母开头名字的比例后：论文层面 +0.173 [0.161, 0.186]（5,565 篇；primary.csv）；作者层面再加作者排位 +0.151 [0.139, 0.163]（19,893 位作者；primary.csv）。发现 2，识别程度与信号成梯度关系：在 R0 论文里，多选题 4 种选项顺序中每多答对一次，输出层信号高 +0.059 [0.056, 0.063]（P3，R0 论文 8,288 篇，引用档固定效应；primary.csv）；控制混杂后 +0.046 [0.042, 0.049]（作者层面，30,060 位作者）。全错时约 0.170，全对时约 0.463（0 种对 927 篇 0.170、4 种对 4,105 篇 0.463；391_groups/stage10_curves.csv）；识别不确定的论文落在两组之间。发现 3，写对一部分作者，对没写出的作者的额外帮助较小（约为识别效应的三分之一），而且只出现在最终输出：合作者 +0.061 [0.034, 0.090]（P2-other C − A，C 390 / A 2,826 篇，Holm p ⩽ 0.002；primary.csv），第一作者 +0.031 [−0.006, 0.069]，不显著（P2-first，C 292 / A 3,199 篇；primary.csv）。logit lens 下 L48–L62 约为 0（P2-other 按层，logit lens −0.019 到 +0.035，区间都含 0）；公开 J-lens 下 L48–L59 为 −0.07 到 −0.11（public J-lens，区间都在 0 以下；391_groups/stage10_contrasts.csv）。以前用全部作者算出的约 +0.11（351_stage10/reports/r0_r1_analysis.md §2），主要是因为模型已经写出的作者分数本来就高（循环论证）。参照：R2 写出的作者在输出层为 +0.844（200 篇；391_groups/summary_table.md），只作上限参照；R2 里有未写出作者的论文只有 28 篇，不做对比。

Added after the defence · re-runs

# Re-runs: numerator and denominator

Addendum 8 · E1 recovery R = mean(patched − false) ÷ mean(true − false) · unwritten authors · team-cluster 95% CI

| group (unwritten authors) | papers | denominator: true − false | E1 numerator L48 | E1 R(L48) | E1 R(L52) |
|---|---|---|---|---|---|
| A R0 × recognised | 557 | +0.407 [0.386, 0.430] | +0.330 | +0.811 [0.790, 0.832] | +0.988 [0.980, 0.996] |
| B R0 × not recognised | 586 | +0.214 [0.196, 0.234] | +0.186 | +0.869 [0.835, 0.906] | +1.016 [1.002, 1.031] |
| U0 R0 × uncertain | 599 | +0.293 [0.271, 0.316] | +0.248 | +0.844 [0.814, 0.877] | +1.000 [0.988, 1.012] |
| C R1 × recognised (descriptive) | 32 | +0.464 [0.388, 0.538] | +0.335 | +0.721 [0.650, 0.806] | +0.996 [0.968, 1.026] |
| R2 written authors (reference) | 200 | +0.845 [0.798, 0.897] | +0.566 | +0.670 [0.630, 0.707] | +0.948 [0.927, 0.965] |

**B's higher ratio is a small-denominator effect:** numerator B − A −0.010, −0.040, −0.144, −0.184 at L24 / L40 / L48 / L52, all CIs below 0(e1_e2_num_den_B_minus_A.csv) — B carries no more absolute paper-specific signal than A at any layer.

**U0 timing as A and B (descriptive); R2 upper reference only;** C 32 / D 5 / R2-unwritten 28 papers → descriptive(rerun_report.md Counts)

77

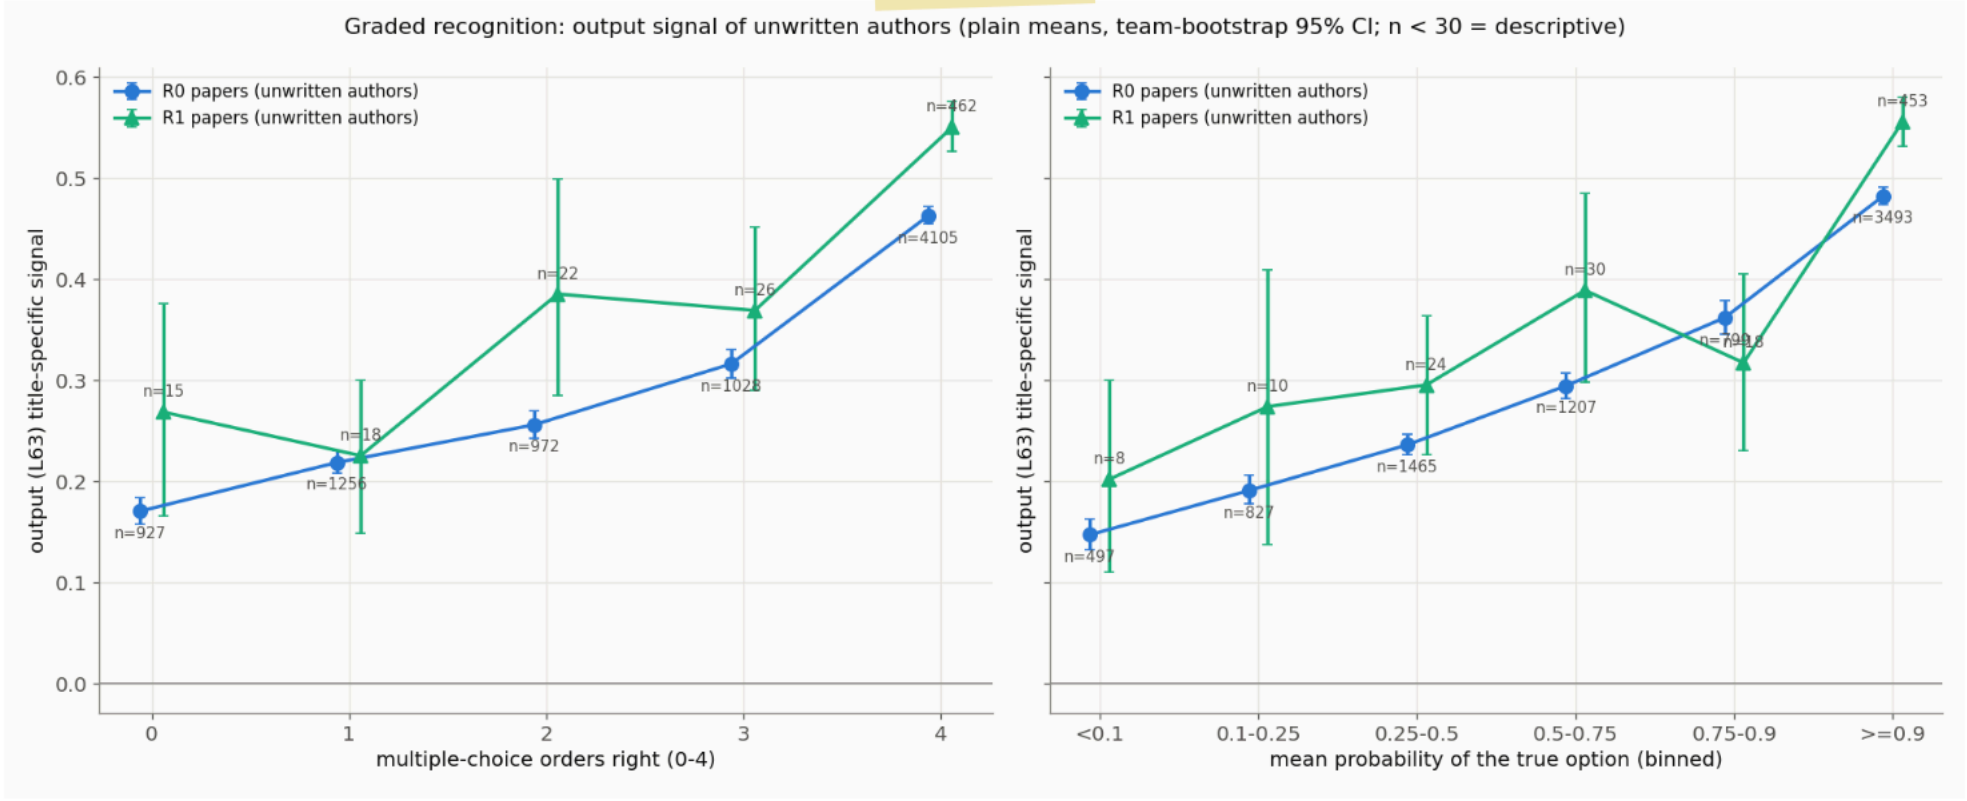
第 77 / 82 页 · Added after the defence · re-runs · 合并 PPT 自身页面 新写讲稿

补充 8 的干预重跑（R2 × strong 204 篇、R0 × uncertain 600 篇）与 Stage 11 原样本一起，只按模型没写出的作者汇总。E1 恢复比例 R = mean(替换 − 假标题) ÷ mean(真标题 − 假标题)。分母（真标题 − 假标题）：A 0.407、B 0.214、U0 0.293、C 0.464（E1，未写出作者，最终输出；A 557、B 586、U0 599、C 32 篇；391_groups/reports/e1_num_den.md）。分子 B − A 在 L24、L40、L48、L52 为 −0.010、−0.040、−0.144、−0.184，区间都在 0 以下（配对团队 bootstrap；391_groups/summary_rerun/e1_e2_num_den_B_minus_A.csv）：B 的恢复比例较高（L48 0.869 对 A 0.811（e1_num_den.md））只是因为分母约为 A 的一半（B/A 0.53），B 在任何一层携带的论文特有绝对信号都不比 A 多。U0 的时间点与 A、B 相同（R(L48) 0.844、R(L52) 1.000（U0 599 篇；rerun_report.md），描述）。R2 只作上限参照（写出的作者真假差距 0.845（R2 写出的作者 200 篇））；C 32 篇、D 5 篇、R2 未写出作者 28 篇（rerun_report.md Counts 表）只作描述。

Added after the defence · groups

# Recognition changes the size, not the timing

Unwritten authors, output (L63) signal, plain means with team-bootstrap 95% CI; n < 30 descriptive




Left: multiple-choice orders right (0–4); right: mean probability of the true option. Blue R0, green R1 (391_groups/figures/fig2)

**Re-runs:** over 0–4 orders right the denominator rises 0.185 → 0.407, while E1 R(L48) stays flat, 0.90 → 0.81 (R0 papers A + U0 + B, 241 / 557 papers at 0 / 4; rerun_report.md "Continuous recognition")



第 78 / 82 页 · Added after the defence · groups · 合并 PPT 自身页面 **新写讲稿**

左图：R0 论文（蓝）未写出作者的输出层信号随多选题答对的选项顺序数从约 0.17 升到约 0.46（R0 未写出作者，最终输出 L63，简单平均，团队聚类 95% CI；0 种对 927 篇 0.170，4 种对 4,105 篇 0.463；391_groups/stage10_curves.csv；报告图 P5.2）。干预重跑：从 0 种到 4 种答对，真假标题差距（分母）从 0.185 升到 0.407（R0 论文 A + U0 + B，E1 分母；0 种对 241 篇、4 种对 557 篇；391_groups/reports/rerun_report.md Continuous recognition 表），而 E1 R(L48) 基本持平，从 0.90 到 0.81（同表 L48 列，0.904 [0.848, 0.965] → 0.811 [0.790, 0.832]）：识别程度改变信号的大小，不改变时间。P1 / P2 的分子 / 分母见下一页。

Added after the defence · re-runs

# P1 / P2: the same small-denominator effect

Stage 12 single positions (P1) and attention / MLP (P2) split by group · unwritten authors · paired team bootstrap 95% CI

| patched part | layer | numerator B − A | ratio B − A | numerator B/A |
|---|---|---|---|---|
| P1 all name positions | L48 | −0.105 [−0.123, −0.087] | +0.052 [+0.011, +0.098] | 0.57 |
| P1 all name positions | L56 | −0.183 [−0.209, −0.157] | −0.050 [−0.087, −0.012] | 0.50 |
| P2 attention | L48 | −0.029 [−0.038, −0.021] | +0.057 [+0.030, +0.086] | 0.66 |
| P2 MLP | L56 | −0.041 [−0.053, −0.029] | +0.008 [−0.030, +0.044] | 0.54 |
| P1 ':' only | L48 | −0.000 [−0.007, +0.005] | +0.050 [+0.026, +0.071] | 0.99 |
| P1 ':' only | L52 | −0.013 [−0.024, −0.002] | +0.073 [+0.038, +0.106] | 0.79 |

B's higher P1 / P2 ratios also come from the small denominator: B's numerator is below A's at the name positions, in attention and in the MLP; at the ':' token the numerators are similar in L44–L48 (B/A 0.78–0.99), and B's ratio is higher only because its denominator is about half of A's(A 557 / B 586 papers; denominator B − A −0.192, B/A 0.53; p1_p2_num_den_B_minus_A.csv; e1_num_den.md P1/P2)





B 组的 P1/P2 比例偏高同样来自分母小：名字位置、注意力和 MLP 上 B 的分子都低于 A（Stage 12 P1 / P2 按组重算，未写出作者，最终输出，A 557 / B 586 篇；分子 B − A：名字位置 L48 −0.105 [−0.123, −0.087]、L56 −0.183 [−0.209, −0.157]，注意力 L48 −0.029 [−0.038, −0.021]，MLP L56 −0.041 [−0.053, −0.029]，配对团队 bootstrap 95% CI；391_groups/summary_rerun/p1_p2_num_den_B_minus_A.csv；reports/e1_num_den.md P1 / P2 节）；':' token 在 L44–L48 两组分子相近（B/A 0.78–0.99（只替换 ":"，分子 B/A：L44 0.78、L48 0.99；同一文件）），B 的比例高只因分母约为 A 的一半（分母 B − A −0.192 [−0.222, −0.162]，B/A 0.53；同一文件）。

Added after the defence · CPU

# CPU leftovers on existing data (post-hoc)

No new GPU runs · descriptive only · not in the pre-registration except the X5 retrieval curve

- **X5 retrieval curve (pre-registered, computed now):** top-1 retrieval of the same paper across questions is never above L4(M3 cache, 9,108 papers; x5_retrieval.md) (title token 1.000 up to L44, 0.734 at the output)(same, team CI)
- **M3 behaviour scores:** year target − control +0.007 [0.003, 0.012]; first-author first token +0.147 [0.096, 0.191](output, 4,621 / 2,220, within bin, team CI; m3_scores.md)
- **N2 by layer:** pure name prior target − control +0.047 at the output, +0.039 at logit L62; public J-lens L48 −0.133 (true title)(Stage 12 N2 rescored by layer; n2_layers.md) → only L62 reproduces the output pattern
- **Paper vs team intervals:** width ratio 0.97–1.00 (median); "excludes 0" changes in 2 of 1,155 rows(X1, X4, X6, X7, M3; v42_paper_vs_team.md)
- **M5 true vs false title at the name positions:** output 0.919; logit L24 0.516 → L62 0.899(share of pairs, all papers × 5 false titles, team CI; m5_report.md); probe at title / colon AUROC 0.50–0.52(same, Part B)



 新写讲稿

答辩后补算的 CPU 分析，都用已有数据，属于事后分析，只作描述。X5 预注册的跨任务检索曲线：同一篇论文在三种问法下的标题状态能否在全部论文中检索回自己，没有一层高于 L4（X5 检索，M3 残差缓存，9,108 篇，top-1，团队聚类 95% CI；381_stage13/reports/x5_retrieval.md）；标题最后一个 token 上 L44 以前都是 1.000，最终输出 0.734（同上，[0.725, 0.742]）。M3 提示下的行为分数：年份 target − control +0.007（M3 年份分数，最终输出，目标 4,621 / 对照 2,220，引用档内差，团队 CI [0.003, 0.012]；381_stage13/reports/m3_scores.md），第一作者首 token +0.147（同上，[0.096, 0.191]），作者差与分组定义有关。N2 按层：纯名字提示 target − control 在最终输出 +0.047（Stage 12 N2，团队 CI [0.031, 0.062]；371_stage12/reports/n2_layers.md），logit lens L62 +0.039（同上）；public J-lens L48 真标题下 −0.133（同上，[−0.161, −0.107]），只有 L62 重现输出端的模式。论文与团队区间：宽度比中位数 0.97–1.00（381_stage13/reports/v42_paper_vs_team.md 第 1 节），“区间是否含 0”只在 1,155 行中的 2 行改变（同上第 2 节）。M5：名字位置上真标题运行胜过假标题运行的比例，最终输出 0.919（M5 Part A，全部论文 × 5 个假标题，团队 CI [0.915, 0.924]；381_stage13/reports/m5_report.md），logit lens L24 0.516、L62 0.899（同上）；标题和 “:” 位置用 probe 区分真/假标题运行，AUROC 0.50–0.52（同上 Part B），基本分不开。

Added after the defence · redo programme

# Redo programme (addenda 10–14)

All rules fixed before the results · reproducing the published numbers is a hard check for every item · status 2026-11-06 evening

- **Done:** X7 with five false titles; all-token probe (addendum 9); CPU items C-1 to C-5; C-3b (no-exclusion sensitivity, includes leakage, not a conclusion)
- **Batch 1, done:** X1–X4 for all authors → conclusions unchanged (X1 task-independent, small L48 author – year +0.024; X3 keeps ≈ 90%; X4 from L8; X2 moves 0.032, subspace $R^2 \leq 0.009$, H3 still insufficient)(b1_xall_report.md) · E4b minus five false titles: surname L40 +0.076 [0.068, 0.083], surname – initial +0.033(b1_e4b5_report.md)
- **Batch 1, running:** P1 / P2 with five false titles — 116 / 194 units done, 78 left in three parallel chains; result after approval
- **Batch 2 (addenda 11, 12):** code, tiny tests and hard-check unit tests done; starts automatically after batch 1; deviations recorded (D12-1 to D12-3; 2-7 source = year-free X4 prompt)(prereg_addendum12_deviations.json)
- **Batch 3 (addendum 14):** 3-1 Stage 10 L41–L47, L49 · 3-2 L0–L23 · 3-3 Stage 7.1B fast path: code in progress; 3-4 / 3-5 (Stage 8 GPU W) not run(prereg_addendum14.json)
- **Not done:** Stage 8 GPU re-run of the original W (user decision 2026-11-06; CPU proxy C-2 instead)(c13_C2.md)





重做计划（补充 10–14，规则都在看结果前写定并锁定；复现已发表数字是每一项的硬检查）。已完成：X7 五个假标题、补充 9 全部名字 token 的 probe、CPU 项 C-1 到 C-5（381_stage13/reports/b1_x7f_report.md、e4b_alltok.md、c13_C1.md–c13_C5.md）；C-3b（不剔除标题复用，只作敏感性分析，含泄漏，不作结论）（c13_C3b.md）。批次 1 已完成：X1–X4 改为给全部作者打分（全部名字 token），并按作者排位分层。结论都不变：X1 仍与任务无关，L48 有一点小而确实的任务依赖（作者 – 年份 +0.024 [0.019, 0.030]）；X3 改写标题保留约 90% 的作者偏好，target 与 control 一样；X4 从 L8 起可解码出作者，各作者排位相同，认得出的论文在 L8–L40 更高；但只靠标题文字的基线不弱于 Qwen，仍不能排除标题文字的解释。X2 用全部作者重新拟合作者子空间后，搬动量从 0.016 升到 0.032（完整替换的约 7%），但子空间本身仍几乎解码不出作者（留出 $R^2 \leqslant 0.009$），H3 仍证据不足（补充 10 第 1 项，硬检查 PASS；381_stage13/reports/b1_xall_report.md）。E4b 5 个假标题（偏离 D1 逐个假标题排除，保留 4,654 篇，平均 1.5 个假标题）：L40 姓首 token +0.076 [0.068, 0.083]，姓 – 首字母 +0.033 [0.023, 0.042]，原 E4b 第一个 token +0.066；置换对照首字母仍 +0.018，其余 ≈ 0；硬检查 E4b L40 +0.0609 PASS（381_stage13/reports/b1_e4b5_report.md）。批次 1 还在运行：P1/P2 用 5 个假标题，194 个单元已完成 116 个，其余 78 个分三条并行作业链计算，结果经用户确认后补入。批次 2（补充 11、12）：代码、tiny 测试和硬检查的单元测试都已完成，批次 1 结束后由编排作业自动开始；与预注册的出入记在补充 12 出入记录 D12-1 到 D12-3（2-1、2-2 用较省但包含原始提示逐位复现重拟合的硬检查；2-11 重建标签、论文内 AUROC、两个基线、对照组只作描述）（381_stage13/config/prereg_addendum12_deviations.json），2-7 的来源改用不含年份的 X4 提示。批次 3（补充 14）：3-1、3-2、3-3 代码在写；3-4、3-5 不做（Stage 8 按原 W 的 GPU 重算，用户 2026-11-06 决定）（381_stage13/config/prereg_addendum14.json）。

Added after the defence · limits

# Limits that cannot be redone

Written 2026-11-06

- **One model:** the groups (recognised or not, authors written or not) come from Qwen3-32B's own labels; another model would need new labels
- **Teacher forcing:** every score is the rank the model gives the correct name once it is in the prompt — a preference, not generation
- **Label pipeline:** the label package author's elm code and run.json are not on the cluster, so generation length, thinking mode and the multiple-choice setup cannot be re-checked
- **High-citation bins:** the 4097+ bin has no B / D papers(84 target, 0 control; m3_scores.md §2), so within-bin comparisons cannot use it



 新写讲稿

不能补做的局限（2026-11-06 写定）：只有一个模型（分组标签来自 Qwen3-32B 自己的标注，换模型要重新标注）；教师强制（测的是偏好，不是生成）；标注流程（标注包作者的 elm 代码和 run.json 不在集群上，开放回答的生成参数和多选题设置无法复核）；高引用档缺对照（4097+ 档没有 B / D 论文（Stage 10 队列 4097+ 档：目标 84、对照 0 篇；381_stage13/reports/m3_scores.md 第 2 节），引用档内比较用不到这一档）。