Where does Qwen3-32B hold a paper's authors?

Stages 1-9

Small samples: find a signal, try to break it

20 → 50 → 200 papers(Stage 4, Pilot50, Stage 8 cohorts)

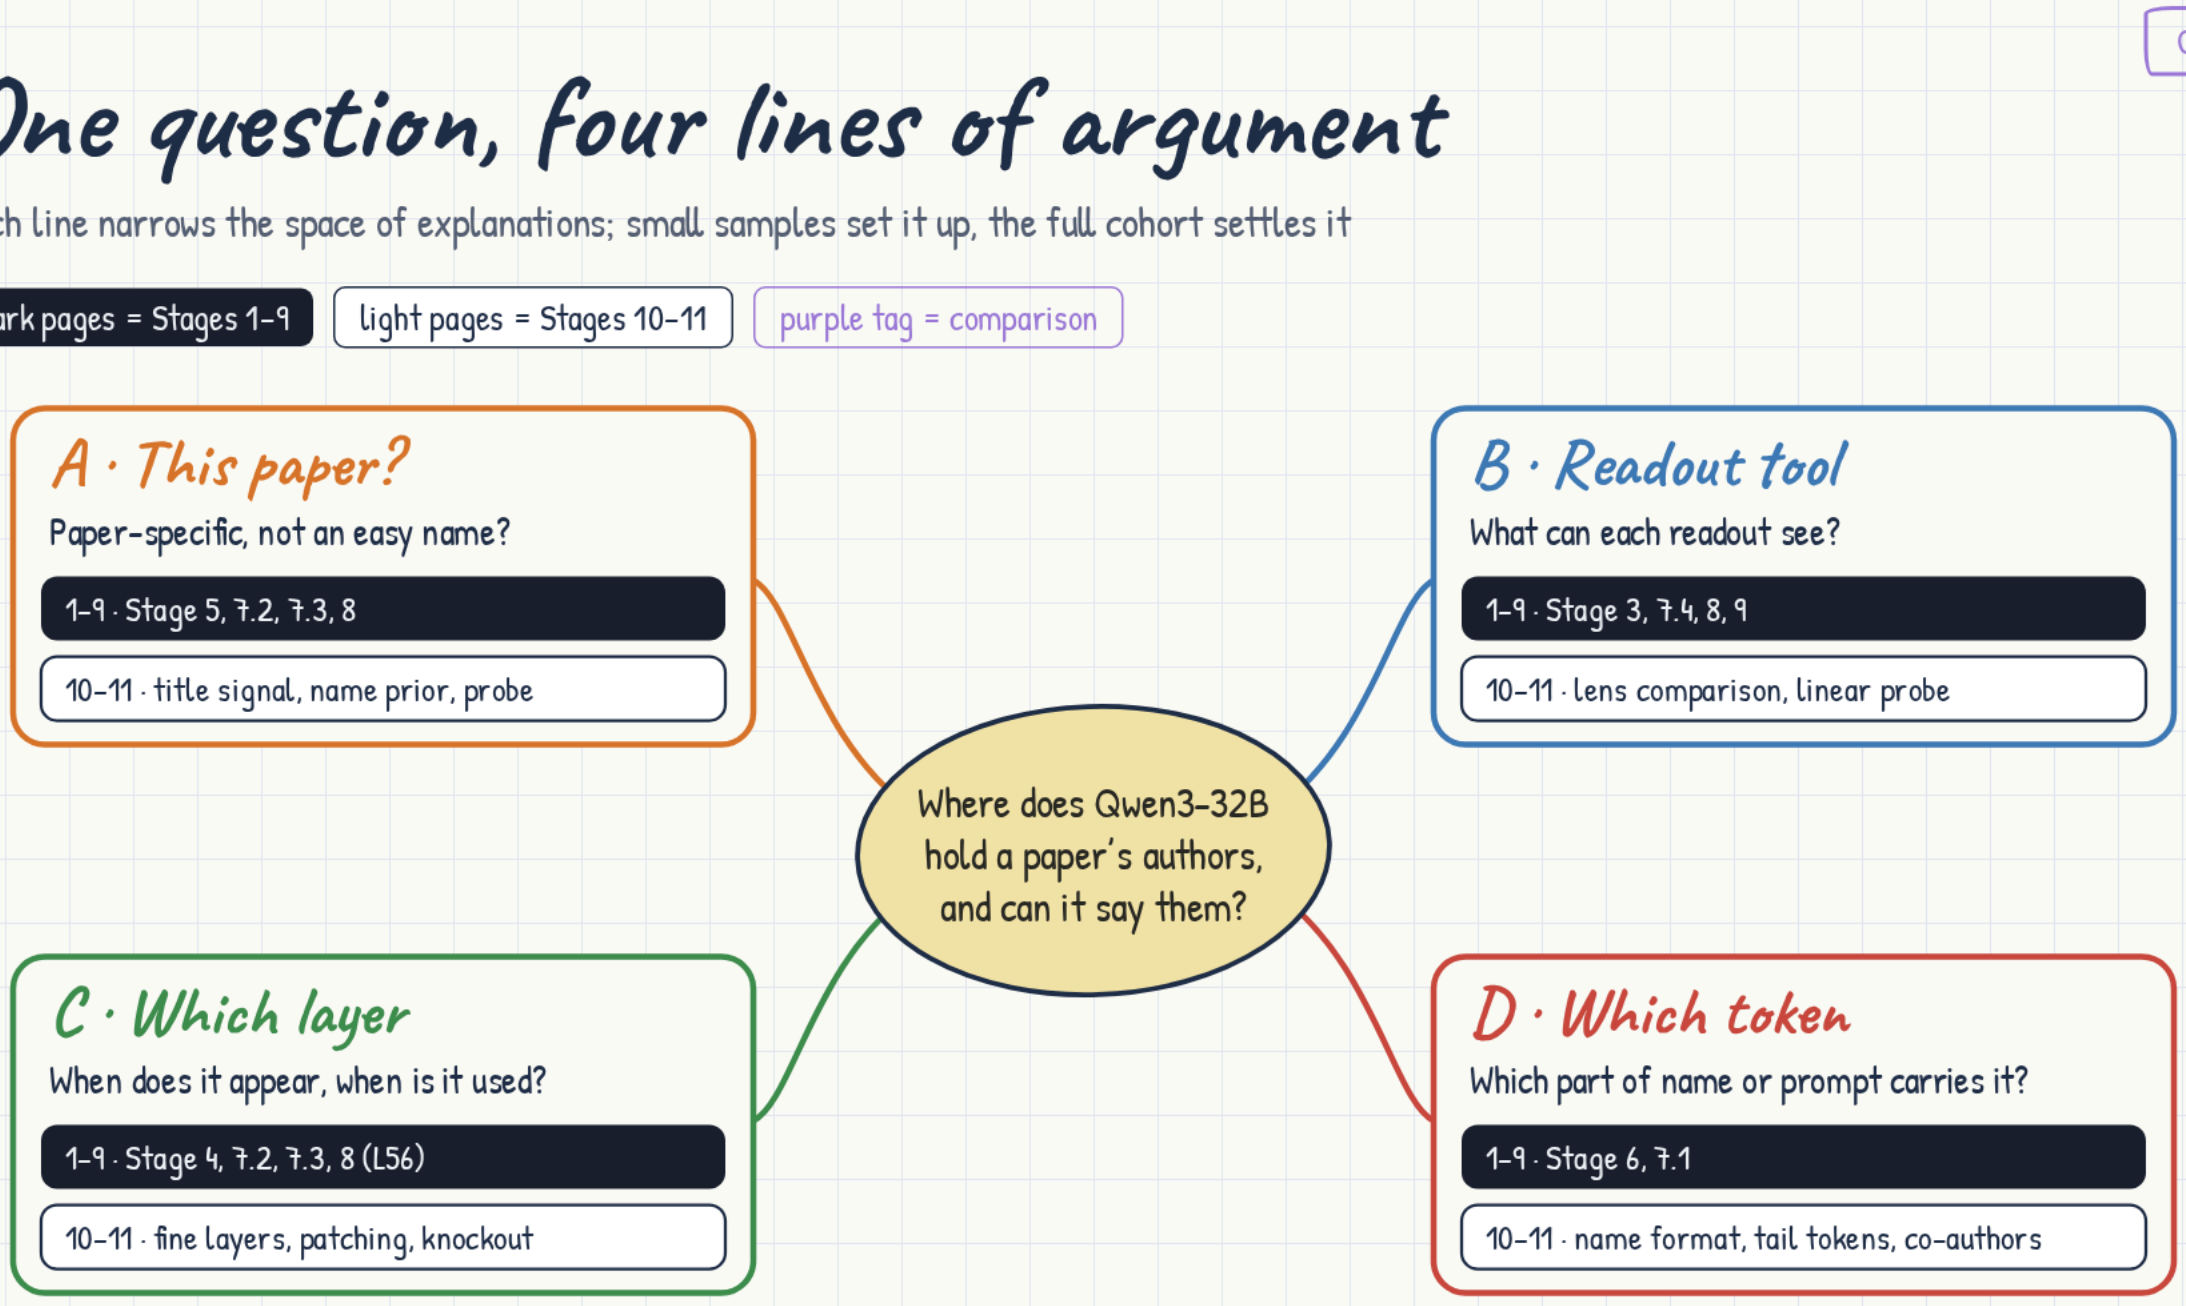
Stages 10-13 · post-defence additions (2026-11-05) at the end

Full cohort: locate it, then intervene

9,108 papers · 149,999 name tokens(Stage 10 cohort: papers.parquet, name_tokens.parquet)

 新写讲稿

今天讲的问题只有一个：Qwen3-32B 把一篇论文的作者记在网络的哪一层。整个工作分两个阶段。左边是 Stage 1–9，用 20、50、200 篇小样本（Stage 4 Benchmark20 20 篇、Pilot50 50 篇（Stage 5–7）、Stage 8 新论文 200 篇；351_all/351_stage4_readout.log、351_stage5_crossed_v2/cohort/pilot50_v1.csv、351_stage8/cohort/stage8_papers.csv）先找到信号，再想办法推翻它；右边是 Stage 10–11，用全部 9,108 篇论文（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv）、149,999 个名字 token（Stage 10 冻结队列，33,811 个作者上下文的名字 token 总数；351_stage10/cohort/name_tokens.parquet；351_stage10/config/manifest.json）去定位这个信号，并用干预实验检验。深色页是小样本阶段，浅色页是全量阶段。



第 2 / 82 页 • Overview • 合并 PPT 自身页面 新写讲稿

整份报告按四条论证线组织。A 线问信号是不是针对这篇论文，而不只是名字好猜；B 线问每种读出工具能看到什么；C 线问信号在哪一层出现、在哪一层被用到；D 线问名字或提示词的哪一部分带着信号。每条线先看小样本阶段问了什么，再看全量阶段怎么回答。

Stages 1–9 · 20–200 papers

Pilot design

- Pilot50 / Stage 8: 50 and 200 papers(pilot50_v1.csv, stage8_papers.csv)
- Mostly first-listed author, first token
- Score: gold vs 1 or 100 false names (logit margin, win rate)
- A/B both R0, matched in pairs
- Wrong titles: 1 crossed or 20 shuffled
- Layer L56 chosen after repeated looks

Overview · design

Stages 10–11 · 9,108 papers

Full-cohort design

- All 9,108 papers(papers.parquet), every author, every token
- Score: rank over the whole vocabulary, log10(1/rank)
- target = A + C, control = B + D (R0 + R1), compared within citation bins
- 5 matched false titles + no title
- All layers reported, fine layers added
- Parity and Stage 6 cross-check before analysis

What changed in the design, and why

Small samples could not separate "small effect" from "no effect" in a given layer. The full cohort trades candidate-based scores for full-vocabulary ranks and pays for it with GPU time. **Note:** target/control include R1 papers; with R0 only (A vs B, as in the pilot) the output gap is +0.199 vs +0.207(Stage 10, final L63, R0 3,423 vs 2,151; §6.13) and every layer looks the same.

先对比两个阶段的设计。小样本阶段用 50 和 200 篇论文（Pilot50 50 篇（351_stage5_crossed_v2/cohort/pilot50_v1.csv）、Stage 8 新论文 200 篇（351_stage8/cohort/stage8_papers.csv）），主要看第一作者的第一个 token，把正确名字和 1 个或 100 个错误名字（Stage 5 交叉对照每篇 1 个来源论文作者；Stage 7.2 每篇 50 个匹配 + 50 个随机错误作者；351_stage7_2/summary/quality.json；~/jlens_work/07_2_stage7_2/351_stage7_2.py:62-111）比较，A、B 两组都是 R0 并逐对匹配，错误标题用 1 个交叉标题或 20 个打乱标题（Stage 5 每篇 1 个交叉标题；Stage 7.3 / Stage 8 每篇 20 个元数据匹配的错误标题；~/jlens_work/07_3_stage7_3/351_stage7_3.py:83-91；351_stage8/config/stage8B_manifest.json），L56 是反复看过之后才选定的层。全量阶段改为全部 9,108 篇（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv）、所有作者和所有 token，用全词表名次 log10(1/名次) 打分，target = A + C、control = B + D 在引用档内比较，用 5 个匹配假标题（Stage 10 标题条件设计：每篇 5 个匹配假标题（false_0–false_4）加删去标题；351_stage10/config/conditions_manifest.json）加删去标题，所有层都报告，还加了细层。改设计的原因是小样本分不清某一层是“效应小”还是“没有效应”。

Overview · groups

Same papers, two ways of grouping

Stages 1–9 compare A vs B; Stages 10–11 compare target vs control. Counts from the 6,841-paper cohort.(Stage 1, 351_audit.json group_counts)

	recognised (target)	not recognised (control)
R0 · no true author written	A = 4,110	B = 2,186
R1 · some authors written (HR2 > 0.5)	C = 511	D = 34
Total	**target = A + C = 4,621**	**control = B + D = 2,220**

Stages 1–9
A vs B: both R0, so the contrast is purely "knows but cannot say"

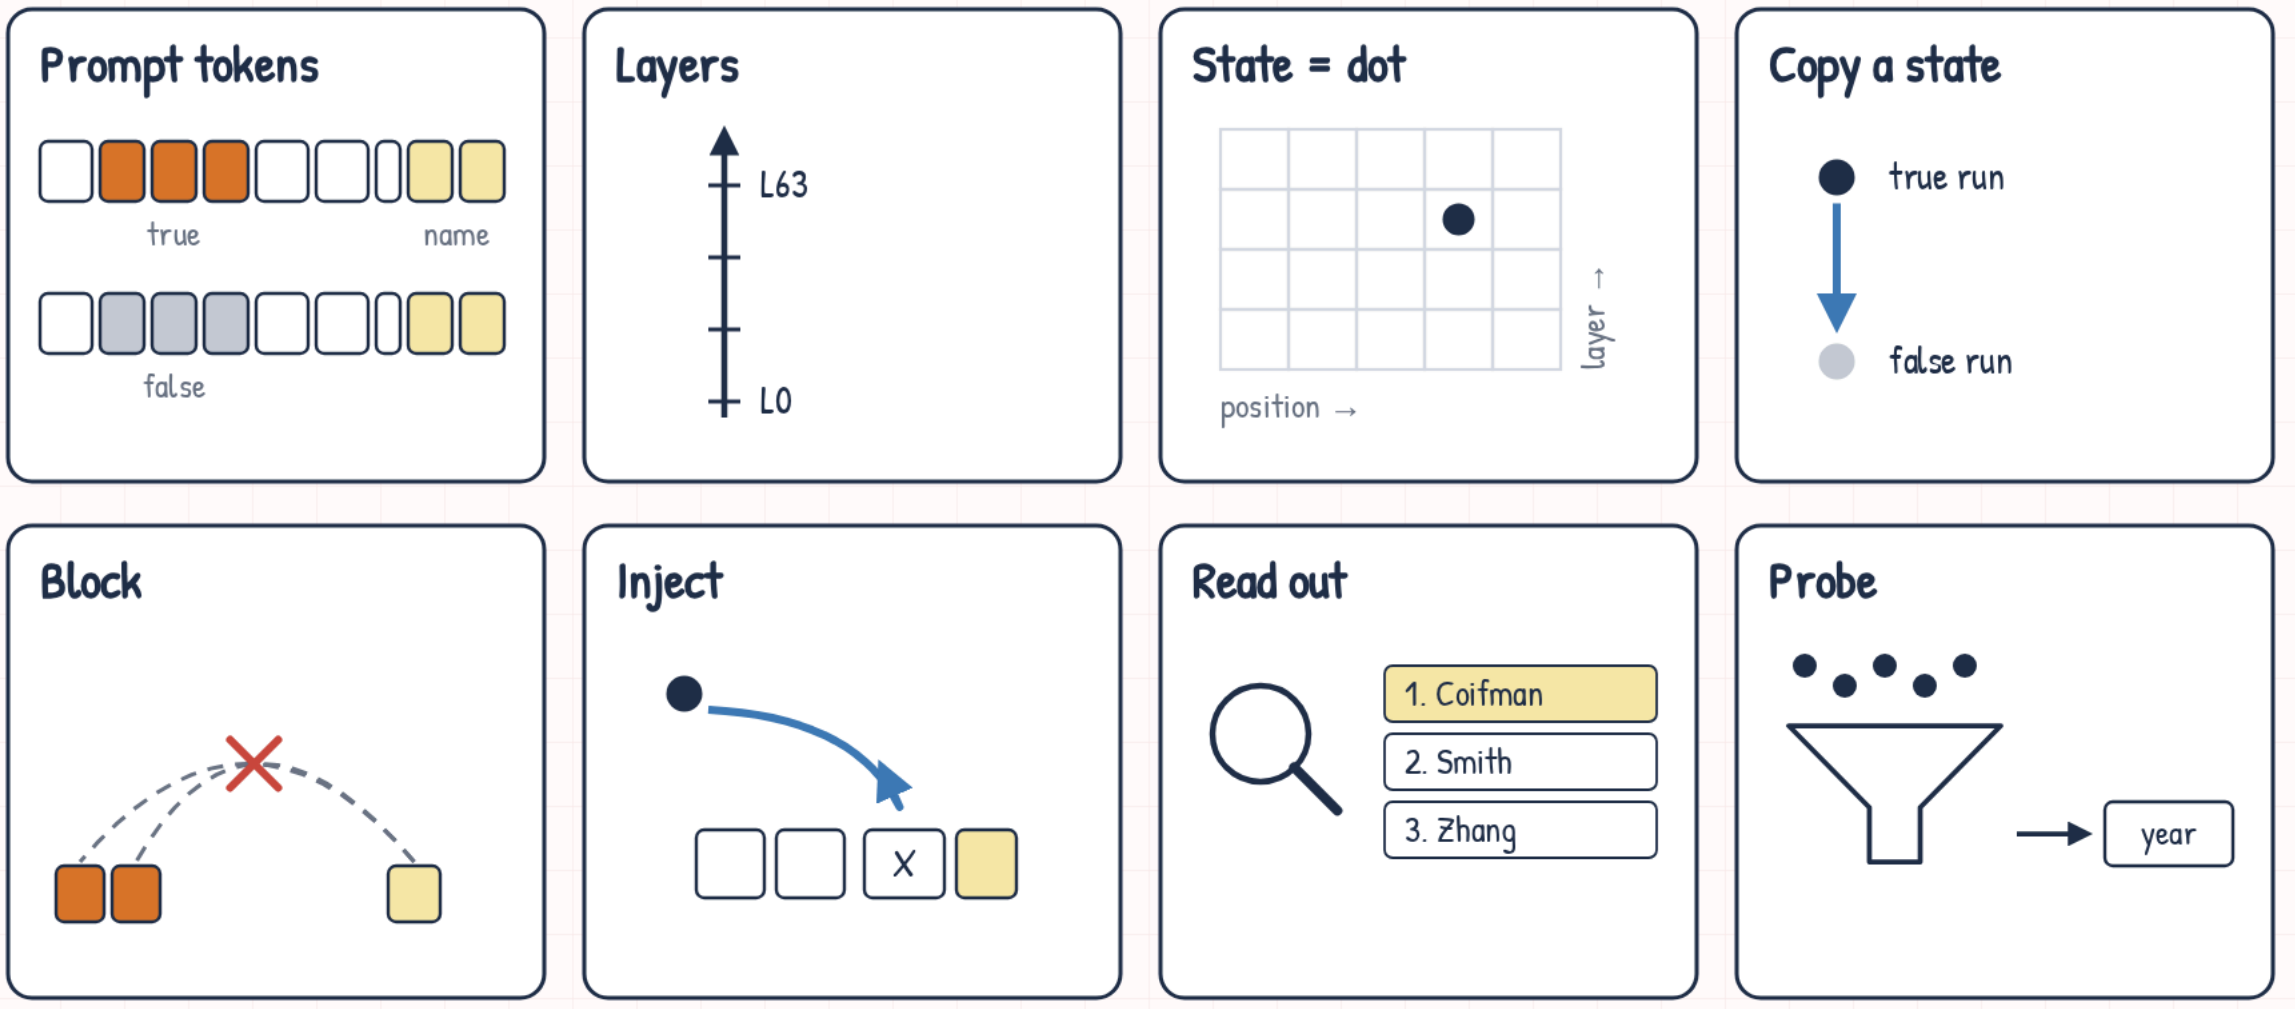
Stages 10–11
(A + C) vs (B + D): adds 511(351_audit.json) partial-recall papers, almost all on the target side

Check done: with R0 only (A vs B) the output gap is +0.199, versus +0.207 for target vs control(Stage 10, final L63, within-bin; §6.13), and every layer looks the same. The two phases compare like with like.

这一页说明两个阶段的分组其实是同一批论文。R0 是开放回答一个真作者都没写对，R1 是写对了一部分但 HR2 大于 0.5。A = 4,110、B = 2,186、C = 511、D = 34（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表）。Stage 1–9 比的是 A 对 B，两组都是 R0；Stage 10–11 比的是 A + C 对 B + D，多出来的 511 篇 R1（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表）几乎全在 target 一侧。我们已经检查过：只用 R0（A 对 B）时，输出处的差是 +0.199（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv），合并口径是 +0.207（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），各层形状相同，所以两个阶段可以直接对照。

Reading the method figures

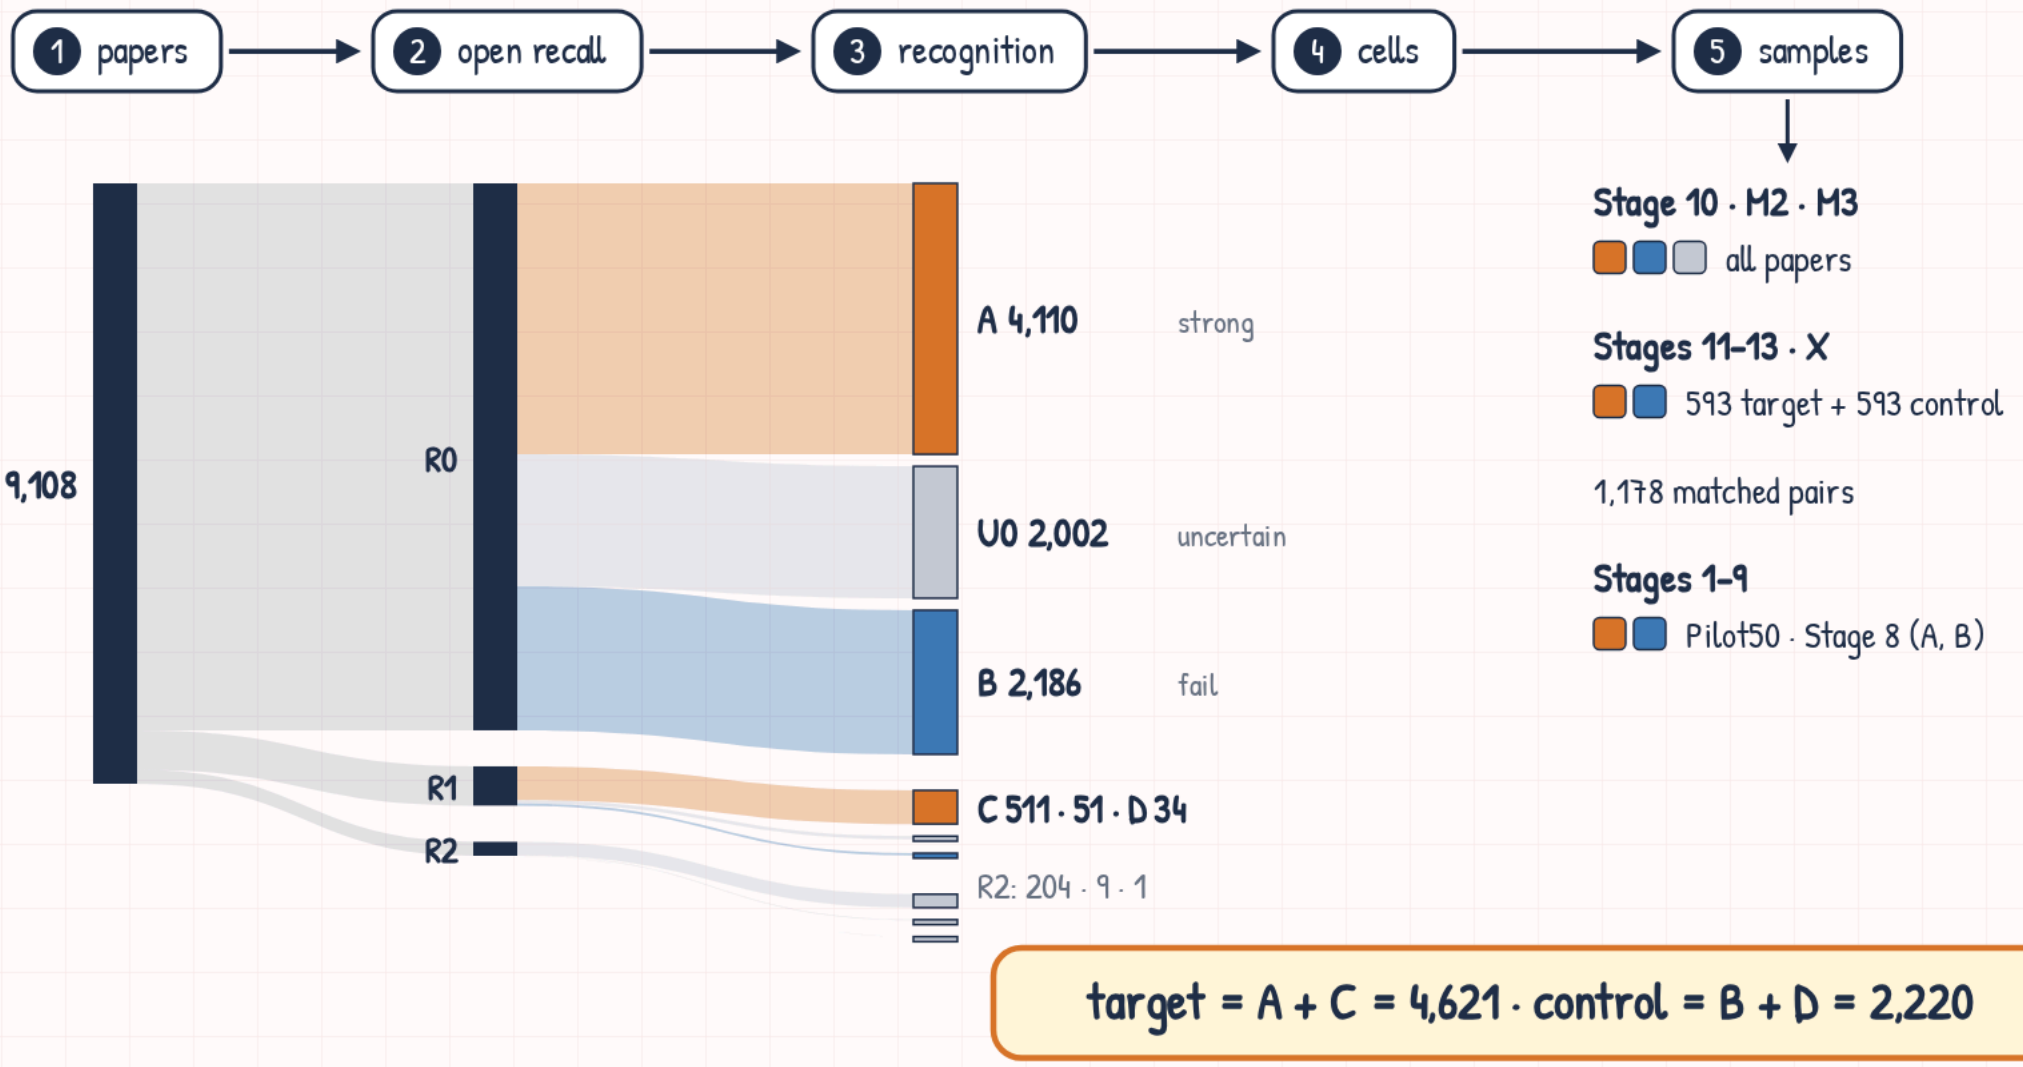
1 2 3 steps, in order



从这一页起，每个方法页都放在它所属实验的结果之前，背景是很浅的粉色网格。图例：提示词画成一排 token 方块，橙色是真标题、灰色是假标题、黄色是名字；层自下而上，L0 在底部、L63 在顶部；一个圆点代表某一层某个位置的隐藏状态。蓝色箭头表示把状态复制或注入到另一次运行，红色叉表示阻断注意力，放大镜表示读出名次，漏斗表示训练探针；带圈数字是步骤顺序。

Groups and samples

example: cell C



9,108 篇论文（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv）先按开放回答分成 R0（一个真作者都没写对）8,298 篇、R1 596 篇、R2（基本写出了作者）214 篇（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表；R0/R1/R2 = 8,298 / 596 / 214），再按四种选项顺序的多选识别分成 strong、uncertain、fail。R0 里 A = 4,110、U0 = 2,002、B = 2,186；R1 里 C = 511、51、D = 34；R2 为 204、9、1（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表；R0 4,110/2,002/2,186，R1 511/51/34，R2 204/9/1（strong/uncertain/fail））。target = A + C = 4,621，control = B + D = 2,220（351_stage10/cohort/papers.parquet 列 group_tight；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 7 行）。Stage 10 和 M2、M3 用全部 9,108 篇（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv），Stage 11–13 的干预和 X 系列用 593 + 593 = 1,186 篇（Stage 11 抽样，10 个可比引用档内配平，目标 593 + 对照 593 = 1,186 篇；361_stage11/config/sample.parquet；361_stage11/config/protocol.json（361_stage11.py:56, 109–115））（X 系列配对后 1,178 对（Stage 13 X 系列配对，1,186 篇中有合格配对论文的 1,178 篇；381_stage13/config/pairs.parquet）），Stage 1–9 的 Pilot50 和 Stage 8 取自 A 和 B；示例论文 Coifman 等（2007）属于 C 格。

Stage 1

Cohort and behavioural labels

From the 15 Oct label package (9,108 papers) to a frozen 6,841-paper analysis cohort(351_audit.json total, four_group_total)

Group	Recognition / open recall	Full(351_audit.json)	Pilot50(pilot50_v1.csv)
A	pass / R0 (no true author written)	4,110	20
B	fail / R0	2,186	20
C	pass / R1 (some authors matched)	511	7
D	fail / R1	34	3

- Pass = 4/4 option orders correct *and* mean true-option probability ≥ 0.5; fail = 0–1/4
- Pilot50: seed 35150, keeps the 20 Stage 4 papers + 30 new
- 20 A/B pairs matched on exact field and citation bin, then |Δyear| + 2·|Δauthors|

Why A vs B?

Both groups write **no** correct author. They differ only in whether the model recognises the true list. That isolates "knows but cannot say".

Caveat

In the 0–2-citation bin the strict pass rate is **25.5%**(796 papers; label_README.md l.8), above the planned ≤10% floor: "pass" is not proof of stored knowledge.

 新写讲稿

Stage 1 建立队列和行为标签。从 10 月 15 日的标注包 9,108 篇论文（标注包全部论文 = Stage 10 全量队列；351_stage10/cohort/papers.parquet；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/paper_labels_with_papers.csv；351_all/351_audit.json "total"）出发，冻结了 6,841 篇（Stage 1 分析队列 = A + B + C + D 四组；351_all/351_audit.json "four_group_total"；00_cohort/351_prepare_all.py）的分析队列。“认得出”的定义是：4 种选项顺序全对，并且真选项的平均概率至少 0.5（标注规则 group_tight（tightened: min_orders 4, min_p_true 0.5）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/rules.yaml、label_README.md）；“认不出”是 4 次里最多对 1 次（同上 rules.yaml，control = 4 种顺序中至多 1 次答对）。之所以比较 A 和 B，是因为两组都一个作者都没写对，只在能否认出名单上不同，这正好对应“知道但说不出”。需要提醒的是，在 0–2 次引用的档里，严格通过率有 25.5%（标注包自检，0-2 引用档 796 篇，收紧规则（4/4 且真选项平均概率 ⩾ 0.5）多选通过率 25.5%（普通规则 38.6%）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 8 行），高于原计划的 10% 上限（Stage 1 预设的标签质量门槛（0-2 档通过率 ⩽ 10%）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 8 行；报告 Stage 1 节），所以“通过”不等于模型真的记住了。

Stage 2

One fixed model, prompt and score

Everything later is measured under these settings

Model	Qwen/Qwen3-32B, BF16, revision 9216db57, 64 blocks, d = 5,120
Layers	L16, 24, 32, 40, 48, 56, 62 → target L63
Readouts	Public J-Lens · Vanilla (logit lens) · real final logits
Position	last input position; context limit 512
Names	encode(prompt) + encode(" " + author)
Hardware	29 blocks on GPU, 35 offloaded to CPU

> Who are the authors of the paper titled "{title}" ({year})?
> Authors:

Rank r = 1 + #tokens with a strictly larger logit

JMRR = mean over authors of mean over tokens of 1/r

Integrated = average of the 7 source layers (L63 excluded)

Guard: forced token IDs are checked, and a J-Lens/Vanilla final-logit gap > 0.1 rejects the run.

 新写讲稿

Stage 2 固定了模型、提示词和打分方式，之后所有测量都在这些设置下进行。模型是 Qwen3-32B，BF16，revision 9216db57，64 层，隐藏维度 5,120（Qwen3-32B 配置；351_stage6/config/protocol.json、351_stage6/config/runtime.json；hidden_size 5120 见 HF config.json）。读出层是 L16 到 L62 共 7 层（Stage 2 读出层 L16、24、32、40、48、56、62；351_stage6/config/protocol.json；~/jlens_work/05_stage5/351_stage5.py），读出方式有公开的 J-Lens、logit lens 和模型真实输出。名次 r 定义为 1 加上 logit 严格更大的 token 数。每次运行都会核对强制输入的 token，两条读出路径的最终 logit 差超过 0.1（守卫阈值；~/jlens_work/05_stage5/351_stage5.py:205-206；~/jlens_work/04_stage4/351_stage4_readout.py:86-89）就拒绝这次运行。

Stage 10

How groups and contrasts are built

labels: group lead's pipeline on the same Qwen3-32B · we use them unchanged

open answer -> R0 / R1 / R2

greedy, chat template

fuzzy name match: M, H, U

HR2 = (H+U) / (M+H+U)

R2: HR2 <= 0.5 · R0: M = 0 · R1: M > 0

a fixed rule, no human or model judge

multiple choice -> target / control

true list + 3 real teams of other papers

(same field, team size, citation bin, ~year)

4 orders · p(letter) from next token

target: 4/4 and mean p(true) >= 0.5

control: <= 1/4

5 false titles per paper

same field, own year kept

min-cost on |dyear|/5 + |dauthors|

+ |dtitle tokens| + 1.5 |dcitation bin|

no shared surname, Jaccard <= 0.6

79% strict tier (Stage 10, 35,898 of 45,540 pairs, conditions_manifest.json)

statistics

target vs control only within citation bin

10 bins with >= 30 per group (Stage 10, §6.2)

weight n_t n_c / (n_t + n_c)

95% bootstrap over papers, 2,000

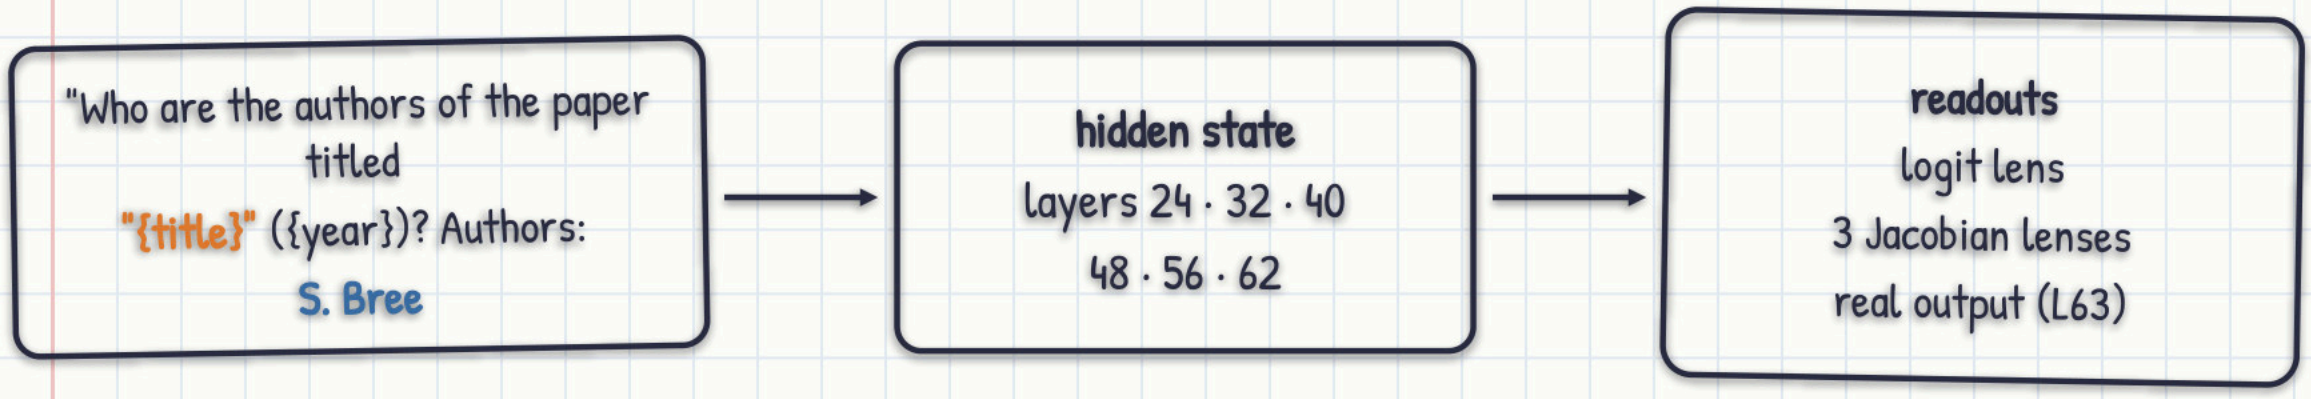
sensitivity: drop bins 0-4

第 9 / 82 页 · deck 第 4 页 按 deck 讲稿备注翻译（已按复核结果更新）

这一页是所有数字背后的规则。开放回答用对话模板内的贪心解码；用确定性的模糊姓名匹配数出匹配 M、编造 H、遗漏 U，HR2 = (H+U)/(M+H+U)。HR2 不超过 0.5（标注规则 recall_failure_threshold 0.5；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/rules.yaml、step1_README.md）为 R2，否则一个没匹配上是 R0，匹配上一些是 R1，全程没有人工或模型评判。多选题把真名单和同领域、团队大小相近、同引用档、年份相近的另外 3 篇论文（多选题 4 个选项 = 真团队 + 3 个干扰团队；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/step1_README.md；mc_team.jsonl）的真实团队放在一起，问 4 种顺序（顺序 ABDC、BCAD、CDBA、DACB；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/step1_README.md）；字母概率取自下一个 token 的分布，“A”和“ A”相加，不做重新归一化（平均总和 1.00（标注包 mc_results.jsonl，kind=team，36,432 次：字母概率和均值 0.998，最小 0.142，低于 0.5 的只有 3 次（同一篇论文）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 检查行））。target 是 4 次全对且真字母平均概率至少 0.5（标注规则 group_tight（min_orders 4, min_p_true 0.5）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/rules.yaml），control 是最多对 1 次（同上 rules.yaml，control = 至多 1/4）。

Stage 10

How we read the model



Score = rank of the correct next name token,

as log10(1 / rank): 0 = rank 1, −1 = rank 10

7 title conditions: the true title, 5 matched false titles, no title

title-specific signal

= true title − mean(5 false titles)

Same name, same tokens: what is left is knowing this paper

Lenses (model weights never change; Jacobians to L63 averaged over prompts): public = 557 WikiText-103 prompts (Neuronpedia) · self100 = 100 frozen WikiText-103 prompts · fitA = 100 other WikiText-103 prompts (Stage 9: one skipped prompt replaced -> 100 valid) (n_prompts: 351_stage10/config/lenses.json; Stage 9 final_status.json)

方法。提示词是“Who are the authors of the paper titled ‘…’ (年份)? Authors:”，后面接一位作者的名字。用教师强制：在每个名字 token 之前，看正确 token 排第几。读出方式有 logit lens、三种 Jacobian lens（Neuronpedia 公开的、self100、fitA）和模型真实输出，层从 L24 到 L62。指标是 log10(1/名次)：排第 1 为 0，排第 10 为 −1。每篇论文还要用 5 个匹配的假标题（Stage 10 标题条件设计：每篇 5 个匹配假标题（false_0–false_4）加删去标题；351_stage10/config/conditions_manifest.json）和删去标题各跑一遍；标题特异信号 = 真标题减去假标题的平均，这样名字本身好不好猜的影响就抵消了。

Can we trust the numbers?

fast = slow

One forward pass vs one per prefix: max gap 0.37 logit (bf16 rounding); ranks 1-41 identical (Stage 10, 12 contexts, parity.json)

matches Stage 6

972 tokens: same token ids, median log-prob gap ~1e-5 (Stage 10, crosscheck_stage6.csv)

negative control

Punctuation tokens show ~0 title-specific signal at every layer (Stage 10, max 0.014, 9,108 papers, §6.5)

Caveat: the parity tolerance was raised 0.25 -> 0.5 after seeing these bf16 gaps. (parity.json tolerance_amendment)

 按 deck 讲稿备注翻译（已按复核结果更新）

相信数字之前做了三项检查。第一，快速路径和逐个前缀的参考路径一致，差异只在 bf16 舍入范围内。第二，在 972 个重叠 token（Stage 10 与 Stage 6 交叉核对，13 组读出×层各 972 个 token，名次完全相同比例 76.5–95.5%；351_stage10/reports/crosscheck_stage6.csv）上，名次和上一阶段（Stage 6）一致。第三，标点 token 不可能依赖标题，它们的标题特异信号确实约为 0。需要如实说明：一致性检查的容差是在看到结果之后从 0.25 放宽到 0.5（Stage 10 parity，12 个上下文、52 个位置，最大 |logit 差| 0.156–0.367（final@L63 0.367）；351_stage10/reports/parity.json tolerance_amendment；351_stage10/config/analysis_plan.json amendments）的。

Line A

Is it about this paper?



small samples asked

Does the true title beat a crossed or shuffled title? Does A gain more than B?

→

the full cohort answered

Title-specific signal for every token; target beats control only late; name prior split out; probe controls

 新写讲稿

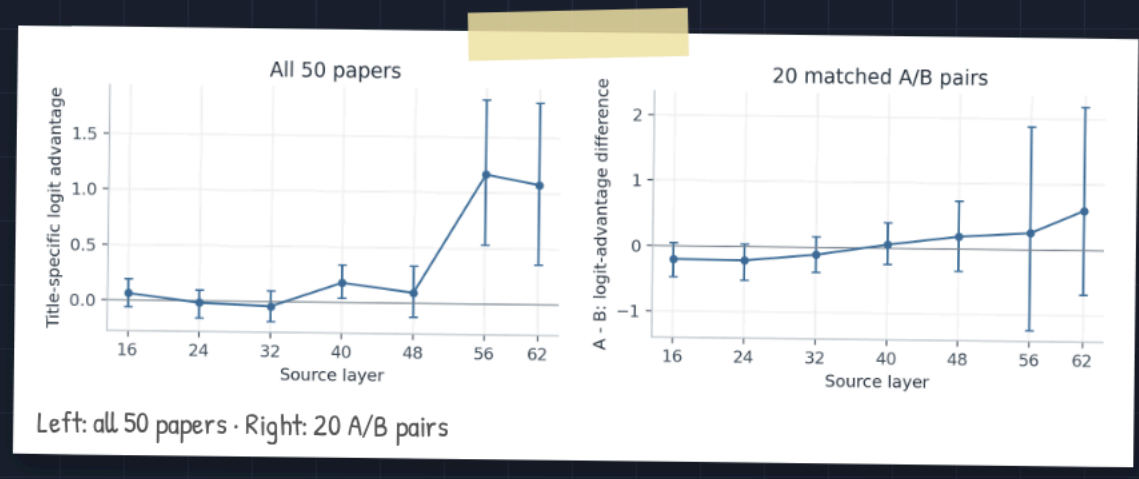
A 线的问题是：信号是不是针对这篇论文？小样本阶段问的是，真标题能不能胜过交叉标题或打乱的标题，A 组是不是比 B 组得益更多。全量阶段的回答是：对每个 token 计算标题特异信号；目标组只在最后几层才领先对照组；把名字先验单独拆了出来；并做了 probe 的对照检验。

Stage 5 · Line A

Crossed title–author control

Is the gold name high because of the title, or because the name is easy?

Paper P (author G) and source paper Q (author F, same field & bin).
M = logit(G) − logit(F) · T = M(P title) − M(Q title)
A fixed preference for G cancels out.



Left: all 50 papers · Right: 20 A/B pairs

- All 50 papers: L56 +1.17 [0.53, 1.84], L62 +1.08 [0.36, 1.82](Stage 5, J-Lens, 50 papers, layer_summary.csv)
- Matched A–B, 7-layer integrated: +0.08 [−0.43, +0.65](20 pairs, matched_ab_summary.csv)

The title changes which name wins in late layers. Whether A gains more than B: **not established**.

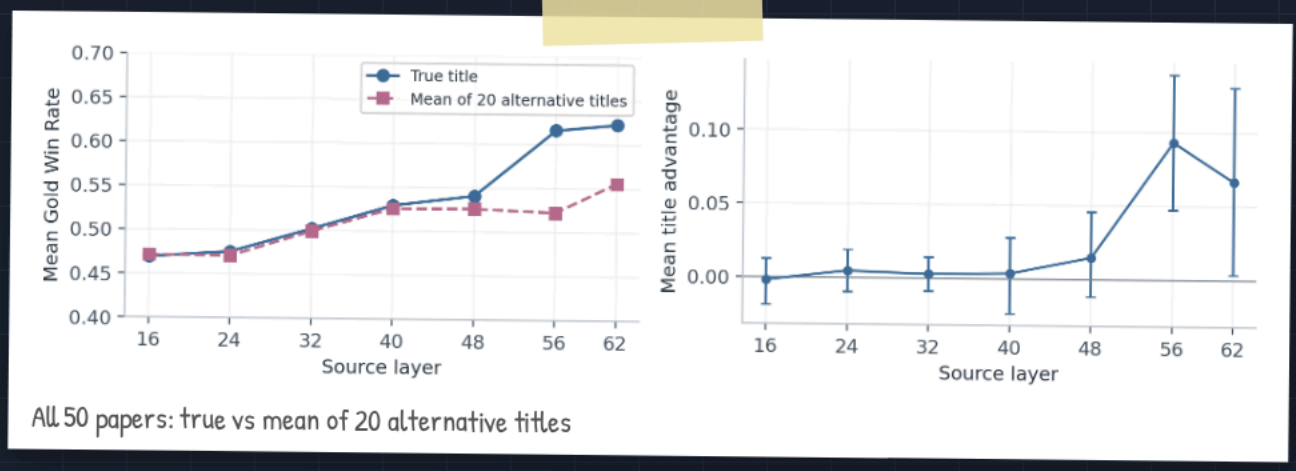
第 13 / 82 页 · Stage 5 · Line A · 合并 PPT 自身页面 **新写讲稿**

Stage 5 做的是交叉标题对照：正确名字排得高，是因为标题，还是因为这个名字本身好猜？做法是拿论文 P（作者 G）和同领域、同引用档的来源论文 Q（作者 F）互换标题，看 G 相对 F 的 logit 差在两种标题下的变化，这样对 G 的固定偏好就被抵消了。全部 50 篇论文上（Pilot50；351_stage5_crossed_v2/cohort/pilot50_v1.csv），L56 为 +1.17 [0.53, 1.84]，L62 为 +1.08 [0.36, 1.82]（Stage 5，J-Lens，交叉对比（G 对 F 的 logit 差在两种标题下的变化），50 篇，论文 bootstrap 95% CI：L56 +1.167 [0.533, 1.838]、L62 +1.077 [0.363, 1.816]；报告 Stage 5 节图 5.1 左；351_stage5_crossed_v2/summary/layer_summary.csv 行 group=ALL），说明标题会改变后几层里谁胜出；但 20 对 A/B 匹配的 7 层积分只有 +0.08 [−0.43, +0.65]（Stage 5，J-Lens 7 层积分，匹配 A − B，20 对，+0.081 [−0.426, +0.648]，配对 bootstrap 95% CI；报告 Stage 5 节图 5.1 右；351_stage5_crossed_v2/summary/matched_ab_summary.csv 行 layer=integrated），A 是否比 B 得益更多还不能确定。

Stage 7.3 · Line A

Shuffled titles: the true title helps

Same 100 candidates, 20 metadata-matched wrong titles per paper, 1,000 contexts; only the title changes



All 50 papers: true vs mean of 20 alternative titles

- Pooled L56: 0.616 vs 0.523 → +9.3 pp [4.8, 14.0], 35/50 papers positive (J-Lens L56, 50 papers; paper_null_distribution.csv; CI recomputed 10-30)
- Leave-one-out: +8.6 to +10.0 pp (stage7_l56_loo.csv)
- Vanilla L56 +10.6 pp, final output +7.2 pp (paper_null_distribution.csv)
- Matched A–B integrated: +0.018 [−0.021, +0.063] (20 pairs, integrated_ab_bootstrap.csv)

Two different questions: "does the title help?" **yes**; "does it help A more than B?" **not shown**.

第 14 / 82 页 · Stage 7.3 · Line A · 合并 PPT 自身页面 **新写讲稿**

Stage 7.3 用打乱的标题：候选名字不变，每篇论文配 20 个元数据匹配的错误标题，共 1,000 个上下文（Stage 7.3 设计，50 篇 × 20 个替代标题；~/jlens_work/07_3_stage7_3/351_stage7_3.py:83-91；351_stage7_3/reports/freeze_audit.md），只有标题在变。全部 50 篇合并（Pilot50 50 篇；351_stage7_3/summary/paper_null_distribution.csv），L56 上真标题 0.616 对错误标题平均 0.523（Stage 7.3，J-Lens L56，金标准首 token 胜率，合并池，50 篇均值：真标题 0.6160、20 个错误标题平均 0.5226；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）列 true_win、null_mean），高 +9.3 个百分点 [4.8, 14.0]，50 篇里 35 篇为正（Stage 7.3，J-Lens L56，真标题胜率 − 20 个错误标题平均胜率，合并池，Pilot50 50 篇均值 +0.0934 [0.048, 0.140]（2026-10-30 重算区间，B = 20,000），35/50 篇为正；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv；报告 Stage 7.3 节）；逐篇剔除后在 +8.6 到 +10.0 之间（Stage 7.3，J-Lens L56 标题优势，50 篇逐一留出一篇后的均值范围 +8.64 到 +9.99 pp；351_stage7_3/recompute_2026-10-30/stage7_l56_loo.csv）。Vanilla 在 L56 为 +10.6，最终输出 +7.2（Stage 7.3，Vanilla L56 / 最终输出 L63，真标题胜率 − 20 个错误标题平均，合并池，50 篇均值 +0.1063 / +0.0716；351_stage7_3/summary/paper_null_distribution.csv（mode=vanilla_L56、final_L63））。但匹配的 A−B 积分只有 +0.018 [−0.021, +0.063]（Stage 7.3，J-Lens 7 层积分标题优势的匹配 A − B，合并池，20 对，+0.0177 [−0.0211, +0.0626]，配对 bootstrap 95% CI；351_stage7_3/summary/integrated_ab_bootstrap.csv 行 jlens/combined）。这里要分清两个问题："标题有没有帮助"，答案是有；"对 A 的帮助是否比对 B 大"，没有证明。

Stage 7.3 · robustness

Does the title effect survive the obvious objections?

Source-author overlap

199/1,000 wrong titles come from a paper whose author is in the false pool. Excluding them: +0.026 → +0.028.(quality.json; paper_null_distribution.csv)

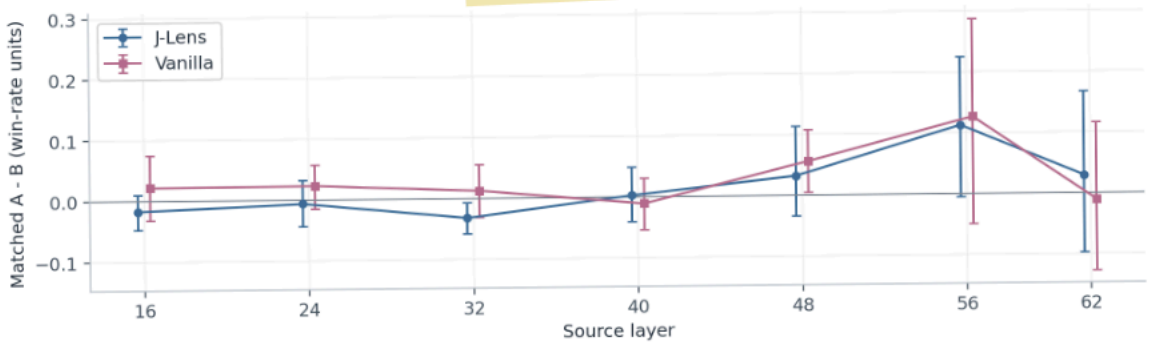
Candidate weighting

Author-, unique-token- and non-collision weights: pooled +0.026 to +0.032; all six A–B CIs include 0.

(stage7_weighting_title_advantage.csv)

Low citations

0–2 citations (n = 6): L56 +0.22, 5/6 positive, but 0/6 beyond its own 20-title tail (≤ 0.05).(floor_L56_low_six.csv)



Title-adjusted A–B win rate by layer

Layer heterogeneity

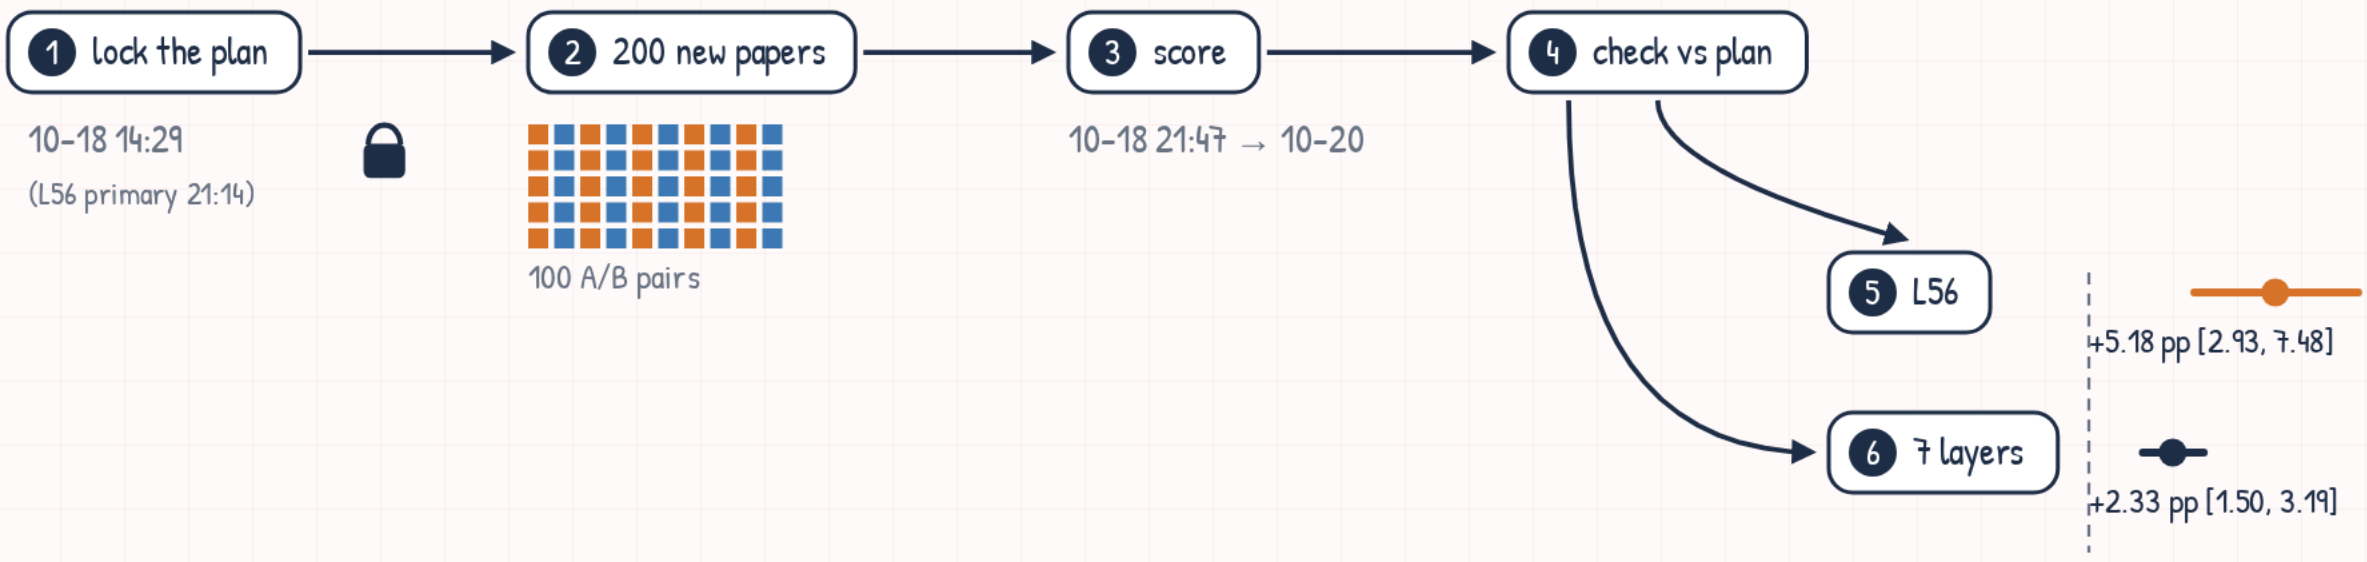
L56 +0.11 but L32 **−0.03** (CI below 0).(20 pairs, matched_ab_bootstrap.csv) Reporting only the positive layers would mislead.

第 15 / 82 页 · Stage 7.3 · robustness · 合并 PPT 自身页面 **新写讲稿**

这一页检查标题效应能否经受几种显而易见的质疑。第一，1,000 个错误标题里有 199 个（Stage 7.3，199/1,000 个替代标题的来源论文作者在错误作者池中；351_stage7_3/summary/quality.json）来自作者在候选池里的论文，剔除后效应从 +0.026 变为 +0.028（Stage 7.3，J-Lens 7 层积分标题优势，合并池，50 篇均值 +0.0262 → 剔除重叠后 +0.0283；351_stage7_3/summary/paper_null_distribution.csv 列 title_advantage / advantage_no_source_false_overlap（方法手册重算））。第二，换成按作者、按唯一 token、按非碰撞加权，合并效应在 +0.026 到 +0.032 之间（Stage 7.3，J-Lens 7 层积分标题优势，作者加权 / 唯一 token / 去平局 +0.026 / +0.032 / +0.027，50 篇；351_stage7_3/recompute_2026-10-30/stage7_weighting_title_advantage.csv），但六个 A–B 区间都含 0（Stage 7.3，3 种加权 × J-Lens/Vanilla 的 7 层积分匹配 A − B，20 对，配对 bootstrap 95% CI；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv 行 16–27）。第三，0–2 次引用的 6 篇论文 L56 为 +0.22，6 篇里 5 篇为正（Stage 7.4 低引用分析，J-Lens L56 标题优势，0-2 档 6 篇，均值 +0.224，5/6 为正，0 篇超出自身 20 个错误标题的 5% 尾部；351_stage7_4/summary/floor_L56_low_six.csv；351_stage7_4/summary/overview.json "floor_low_six_L56"），但没有一篇超出它自己 20 个错误标题的尾部（Stage 7.3 每篇 20 个替代标题；~/jlens_work/07_3_stage7_3/351_stage7_3.py:83-91）。第四，层之间差异很大：L56 为 +0.11，L32 却为 −0.03（区间在 0 以下）（Stage 7.3，J-Lens 单层标题优势的匹配 A − B，合并池，20 对，配对 bootstrap 95% CI：L56 +0.113 [−0.005, +0.225]，L32 −0.032 [−0.058, −0.006]；351_stage7_3/summary/matched_ab_bootstrap.csv 行 jlens_L56 / jlens_L32 combined），只报告正的那些层会误导。

Independent replication (Stage 8)

plan first, data second



RQ1 = win rate(true title) − mean win rate(20 false titles)

first author vs 100 false names · J-Lens · paper bootstrap

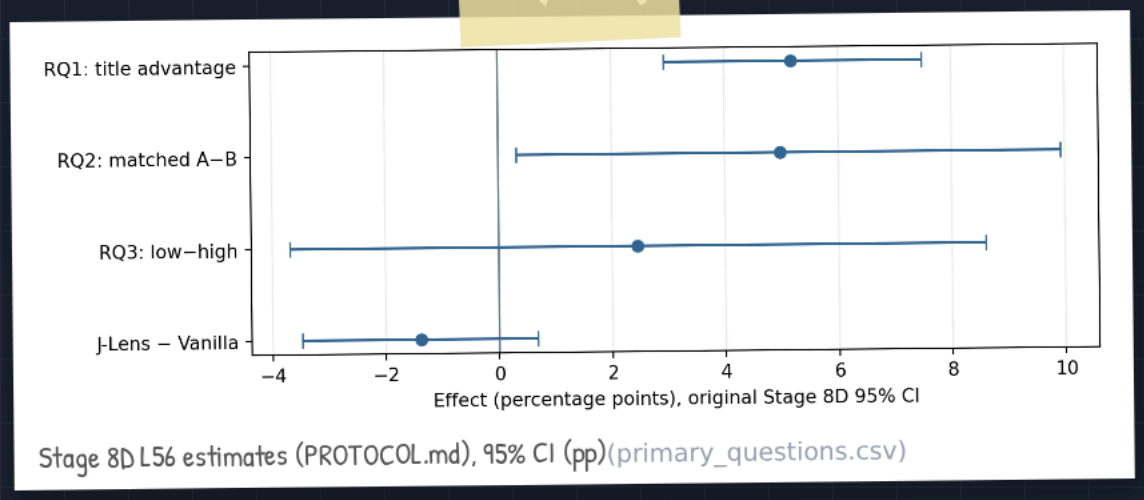
+5.18 pp: Stage 8D RQ1, J-Lens L56, 200 papers, stage8D/summary/primary_questions.csv · +2.33 pp: J-Lens 7-layer, 200 papers, recompute_2026-10-30/s8_endpoints.csv

 新写讲稿

Stage 8 是独立重复：分析计划在 10 月 18 日 14:29 冻结（analysis_plan.json），当天 21:14 的协议把 L56 定为主层，仍在打分之前。然后取 200 篇新论文（100 对 A/B）（Stage 8A 抽样，100 对匹配 A/B；351_stage8/cohort/stage8_papers.csv；351_stage8/summary/matching_audit.json），10 月 18 日 21:47 开始打分、10 月 20 日结束，再按计划检查。RQ1：L56 处真标题相对 20 个假标题的胜率高 +5.18 个百分点 [2.93, 7.48]（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节）；计划里冻结的主终点（7 层平均）是 +2.33 [1.50, 3.19]（Stage 8 冻结计划主终点，J-Lens 7 层积分，真标题 − 20 个错误标题平均，200 篇，+2.33 pp [1.50, 3.19]，论文 bootstrap 95% CI；351_stage8/recompute_2026-10-30/s8_endpoints.csv）。

Stage 8D · Lines A, B

On 200 new papers the title effect replicates



Stage 8D L56 estimates (PROTOCOL.md), 95% CI (pp)(primary_questions.csv)

(Stage 8D, J-Lens L56; primary_questions.csv)	Estimate	95% CI
RQ1 title, L56(200 papers)	+5.18 pp	[+2.93, +7.48]
RQ2 A–B, L56(100 pairs)	+4.98 pp	[+0.32, +9.91]
RQ2 A–B, 7-layer (frozen primary)(100 pairs; s8_endpoints.csv)	+2.41 pp	[+0.91, +4.00]
RQ3 low–high(25 + 25 pairs)	+2.45 pp	[−3.69, +8.60]
J-Lens–Vanilla(jlens_minus_vanilla.csv)	−1.38 pp	[−3.48, +0.68]

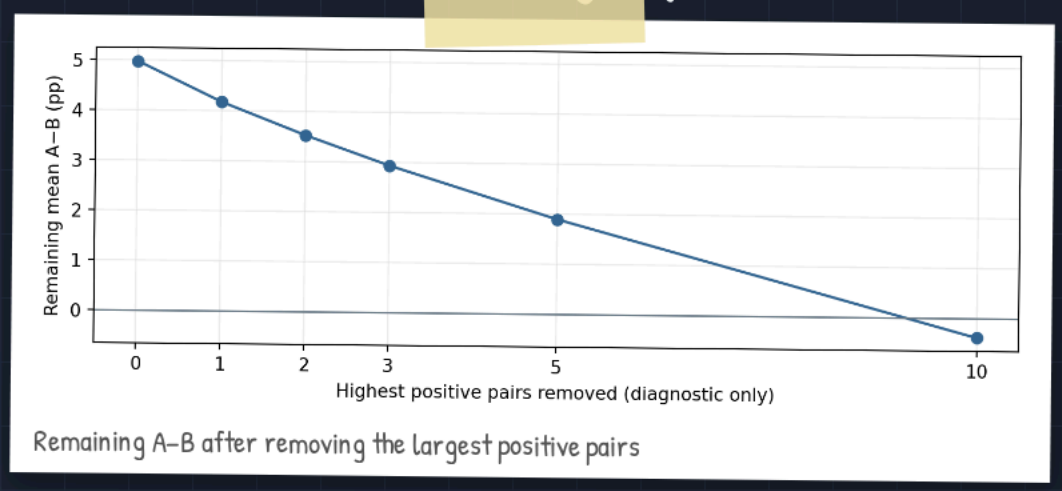
Citation bands: low +6.8 [2.5, 11.6], mid +4.8, high +4.4 [−1.1, 10.0]
(50/100/50 papers; layer_and_band_summary.csv)

RQ1 is the first **independent** confirmation: correct titles help the gold author on new papers. J-Lens still adds nothing over Vanilla.

第 17 / 82 页 · Stage 8D · Lines A, B · 合并 PPT 自身页面 **新写讲稿**

Stage 8D 在 200 篇全新论文上（Stage 8 新论文；351_stage8/cohort/stage8_papers.csv）冻结设计后复现。RQ1 标题效应 +5.18 个百分点 [+2.93, +7.48]（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节），这是第一次独立确认：正确标题能帮助正确作者。RQ2 的 A−B 为 +4.98 [+0.32, +9.91]（Stage 8D RQ2，J-Lens L56 匹配 A − B，100 对，+4.98 pp [0.32, 9.91]，配对 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ2_matched_A_minus_B）；RQ3 低引用减高引用为 +2.45，区间含 0（Stage 8D RQ3，J-Lens L56，配对平衡的低引用 − 高引用，50 对，+2.45 pp [−3.69, +8.60]；351_stage8/stage8D/summary/primary_questions.csv 行 RQ3_low_minus_high）；J-Lens 减 Vanilla 为 −1.38，区间含 0（Stage 8D，L56 J-Lens − Vanilla 标题优势，200 篇，−1.38 pp [−3.48, +0.68]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/jlens_minus_vanilla.csv）。按引用分档，低档 +6.8，中档 +4.8，高档 +4.4（Stage 8D，J-Lens L56 标题优势按引用带，低 50 / 中 100 / 高 50 篇：+6.83 / +4.75 / +4.38 pp；351_stage8/stage8D/summary/layer_and_band_summary.csv（mode=jlens_L56, scope=citation_band））。J-Lens 仍然没有比 Vanilla 多出什么。

But the A–B gap rests on a few pairs



Remaining A–B after removing the largest positive pairs

- 100 pairs: 55 positive, 45 negative; median +4.4 pp (J-Lens L56; matched_pair_differences.csv)
- One pair (S8P094) ≈ +84 pp
- Remove top 5 → +1.9 pp; top 10 → −0.4 pp (recomputed from same file)

8E external audit (post-hoc)

- Unique-token weights: RQ1 +4.6, RQ2 +5.4 pp (s8_8E_weighting_by_paper.csv)
- Wrong-title length gap: +0.12 pp per token (200 papers; s8_unsourced_intervals.csv) (association only)
- Original scripts missing; recomputed from raw logits (30 Oct), same estimates (351_stage8/recompute_2026-10-30/): post-hoc only

Small samples can show a positive A–B mean that a handful of papers carry. This is the main reason Stage 10 moved to the full cohort.

但 A–B 的差依赖少数几对论文。100 对里 55 对为正、45 对为负，中位数 +4.4 个百分点（Stage 8D RQ2，J-Lens L56 匹配 A − B，100 对：55 正 / 45 负，中位数 +4.41 pp；351_stage8/stage8D/summary/primary_questions.csv 行 RQ2_matched_A_minus_B；matched_pair_differences.csv（mode=jlens_L56））；其中一对（S8P094）大约 +84（Stage 8D RQ2，最大一对 S8P094 A − B = +84.4 pp；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56））。去掉最大的 5 对后降到 +1.9（Stage 8D RQ2，按 A − B 降序去掉前 5 对后其余 95 对均值 +1.90 pp（事后诊断，方法手册 C 部分重算）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）），去掉 10 对后变成 −0.4（Stage 8D RQ2，J-Lens L56 金标准胜率匹配 A–B，100 对，均值 +4.98 pp，按 A–B 降序去掉前 10 对后其余 90 对均值 −0.39 pp（事后诊断）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）重算；报告 Stage 8D 节）。8E 的外部审计是事后做的，脚本还没归档，不能算完成的实验。小样本可以给出一个由少数论文撑起来的正 A–B 均值，这正是 Stage 10 改用全量数据的主要原因。

Stage 8 re-scored on CPU: three premises

Addendum 13 C-2 · same 200 papers / 100 pairs · Stage 10 raw scores, all authors, all name tokens · public J-lens rank metric, NOT the W statistic

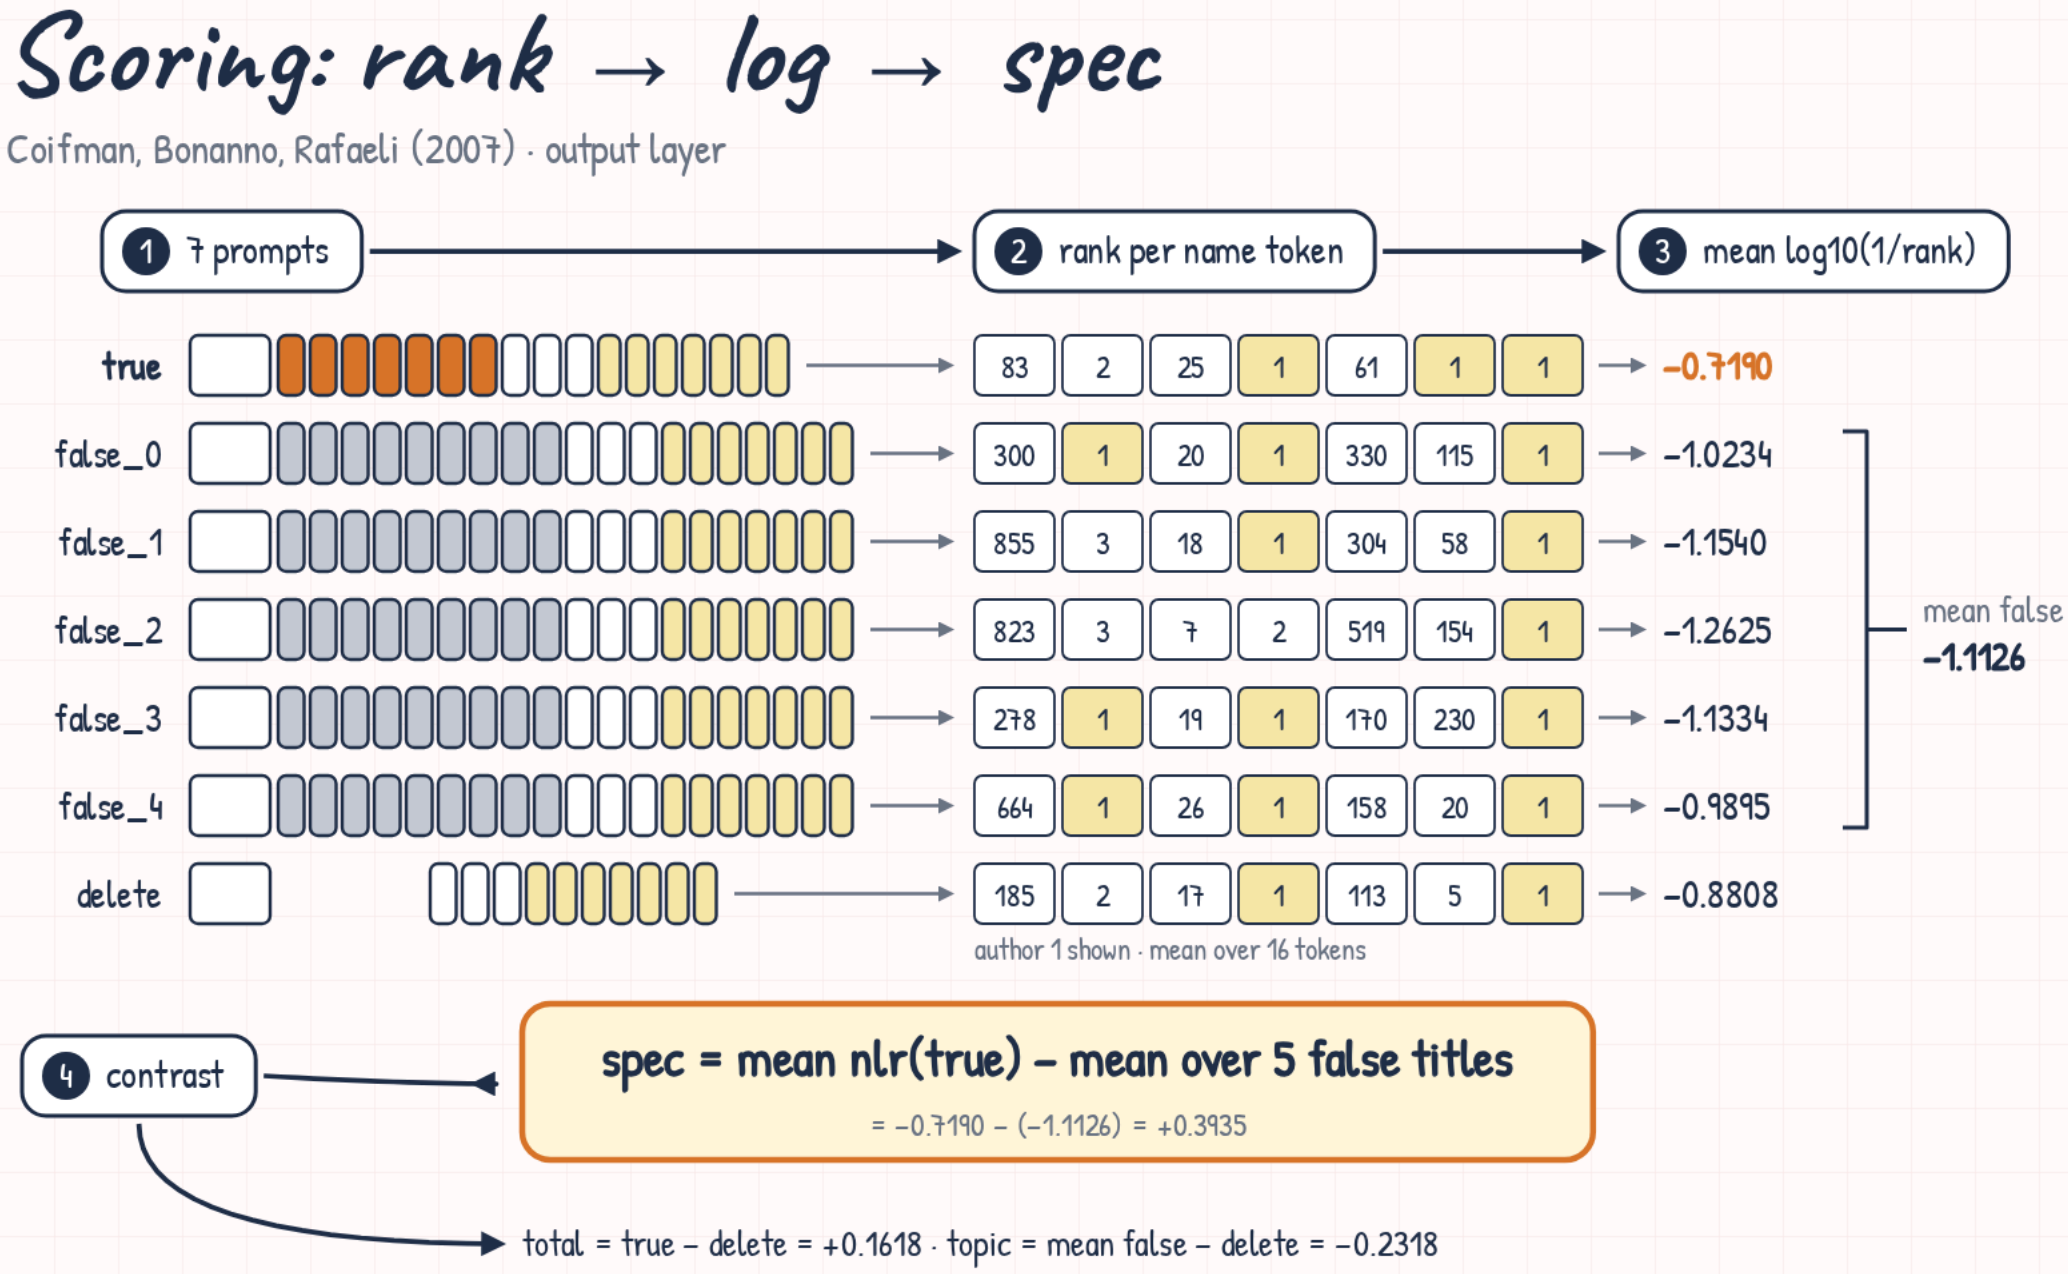
- **6-layer mean (int6, no L16):** RQ1 +0.130 [0.108, 0.153], RQ2 +0.054 [0.008, 0.102] → both positive, but not the locked 7-layer endpoint(public J-lens 6-layer mean; c13_C2.md aa_all)
- **L56 alone:** RQ2 +0.064 [−0.032, +0.163], CI includes 0 → addendum-13 rule triggered the W re-run; not done = deviation D13-1(same, L56)
- **What it is not:** a CPU proxy with Stage 10's 5 false titles and the rank metric, not W; locked 7-layer endpoint (approx., no L16): RQ2 +0.046 [+0.007, +0.088] / +0.049 [+0.005, +0.094], same direction(c2_followup_proxy.csv)

Three premises

W scores only the first author's first token (64.5% are initials); D13-1 (rule triggered at L56 only); U28 (L56 made primary at 21:14, by whom and why unknown).

 新写讲稿

Stage 8 的 CPU 代理（补充 13 C-2，事后）：用 Stage 10 已有的原始分数，在 Stage 8 的 200 篇论文上重算。全部作者、全部名字 token 的版本中，public J-lens 6 层平均（int6，少了 L16，与锁定的 7 层积分终点不是同一终点）RQ1 和 RQ2 都为正：RQ1 +0.130 [0.108, 0.153]（补充 13 C-2，200 篇，标题特异信号（真标题 − Stage 10 的 5 个假标题），团队聚类 95% CI；381_stage13/reports/c13_C2.md aa_all int6 行），RQ2 +0.054 [0.008, 0.102]（同上，100 对 A − B，配对 bootstrap）；只看 L56 时 RQ2 +0.064 [−0.032, +0.163]，不显著（同上，L56 行）。这是 CPU 代理：用 public J-lens 的名次指标和 Stage 10 的 5 个假标题，不是 Stage 8 的 W 统计量；按原 W 的 GPU 重算没有做（用户 2026-11-06 决定）。Stage 8 的结论（真标题让模型更偏好真实第一作者 RQ1；A 组强于 B 组 RQ2）较稳，但有三个前提：① W 只给第一作者名字的第一个 token 打分，在 Stage 8 的 200 篇里有 129 篇（64.5%）这个 token 只是首字母（audit_20261105/part_A_stage4_9.md 第 10 行）；② 偏离 D13-1：按补充 13 C-2 的规则，全部作者 CPU 代理只在 L56 的 RQ2 上与已发表结论不一致（+0.064 [−0.032, +0.163]，区间含 0），触发了按原 W 在 GPU 上重算，用户 2026-11-06 决定不做；在锁定计划的 7 层积分终点上（近似，Stage 10 没有 L16）代理 RQ2 为 +0.046 [+0.007, +0.088]（L16 = 0）或 +0.049 [+0.005, +0.094]（L16 = L24），同向、区间不含 0（381_stage13/reports/c13_C2.md；381_stage13/c13_C2_followup/c2_followup_proxy.csv）；③ U28：L56 在锁定计划里是探索性次终点，10-18 21:14 的 PROTOCOL.md 把它改为主终点，改动者和依据仍未查清。

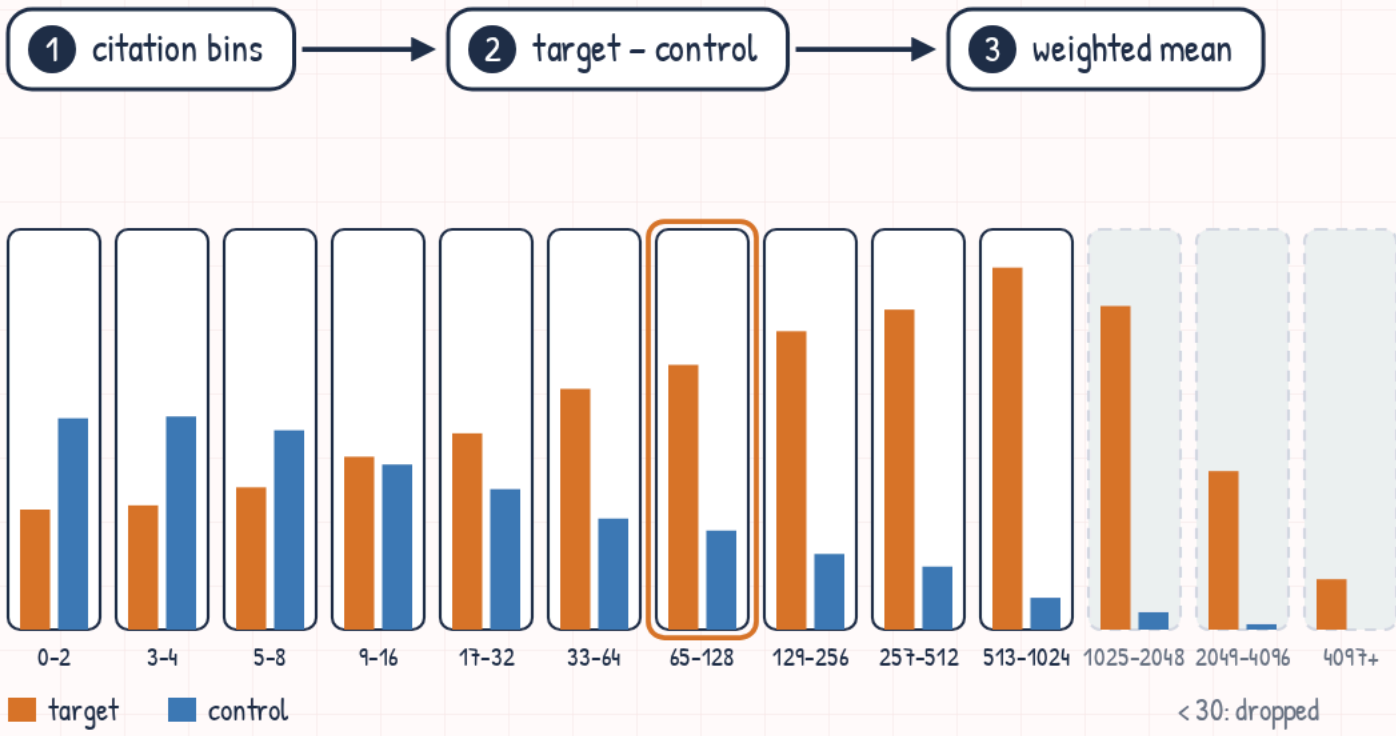


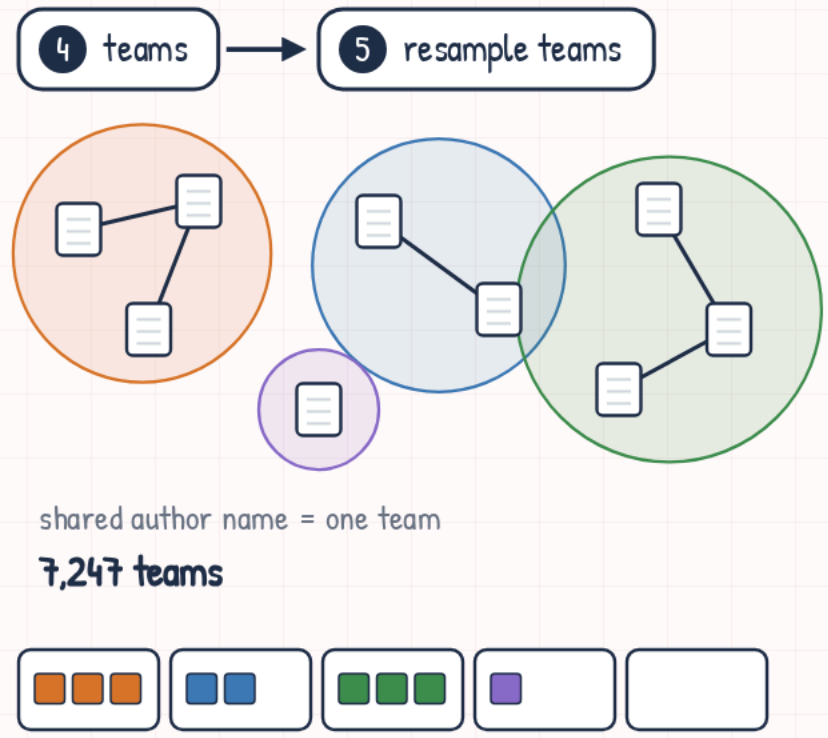
第 20 / 82 页 · Method · Scoring: rank, log, spec · 合并 PPT 自身页面 **新写讲稿**

以 Coifman、Bonanno、Rafaeli（2007）为例：同一组名字 token 接在 7 个提示后面（Stage 10 标题条件：真标题、5 个匹配假标题（false_0–false_4）、删去标题；351_stage10/config/conditions_manifest.json）——真标题、5 个匹配的假标题和删去标题。每个名字 token 取它在全词表中的名次，例如第一作者 7 个 token 在真标题下是 83、2、25、1、61、1、1（Stage 10，示例论文 Coifman 等（2007），第一作者 7 个 token，真标题，最终输出 L63 全词表名次；351_stage10/raw/final/L63/shard_011.npz 行 25025–25031；351_stage10/reports/method_figs/coifman_layer_ranks.csv（condition=true, readout=final）），再取 log10(1/名次) 并对 16 个 token 求平均（示例论文 3 位作者共 16 个名字 token；351_stage10/raw/final/L63/shard_011.npz 行 25025–25040）：真标题 −0.7190，5 个假标题平均 −1.1126，删去标题 −0.8808（Stage 10，示例论文，最终输出 L63，16 个名字 token 的平均 log10(1/名次)；方法手册 A_global1 G5.5（351_stage10/reports/methods/parts/A_global1.html）；351_stage10/summary_title/paper_title_contrasts.parquet（readout=final, layer=63））。标题特异信号 spec = −0.7190 − (−1.1126) = +0.3935；total = 真 − 删 = +0.1618，topic = 假 − 删 = −0.2318（同上，示例论文 spec +0.3935、total +0.1618、topic −0.2318；方法手册 A_global1 G5.5；351_stage10/summary_title/paper_title_contrasts.parquet（readout=final, layer=63））。

Statistical conventions

example paper: bin 65–128





$$\Delta = \Sigma\, w_b \cdot (\text{mean}_t - \text{mean}_c),\ w_b \propto n_t \cdot n_c / (n_t + n_c)$$

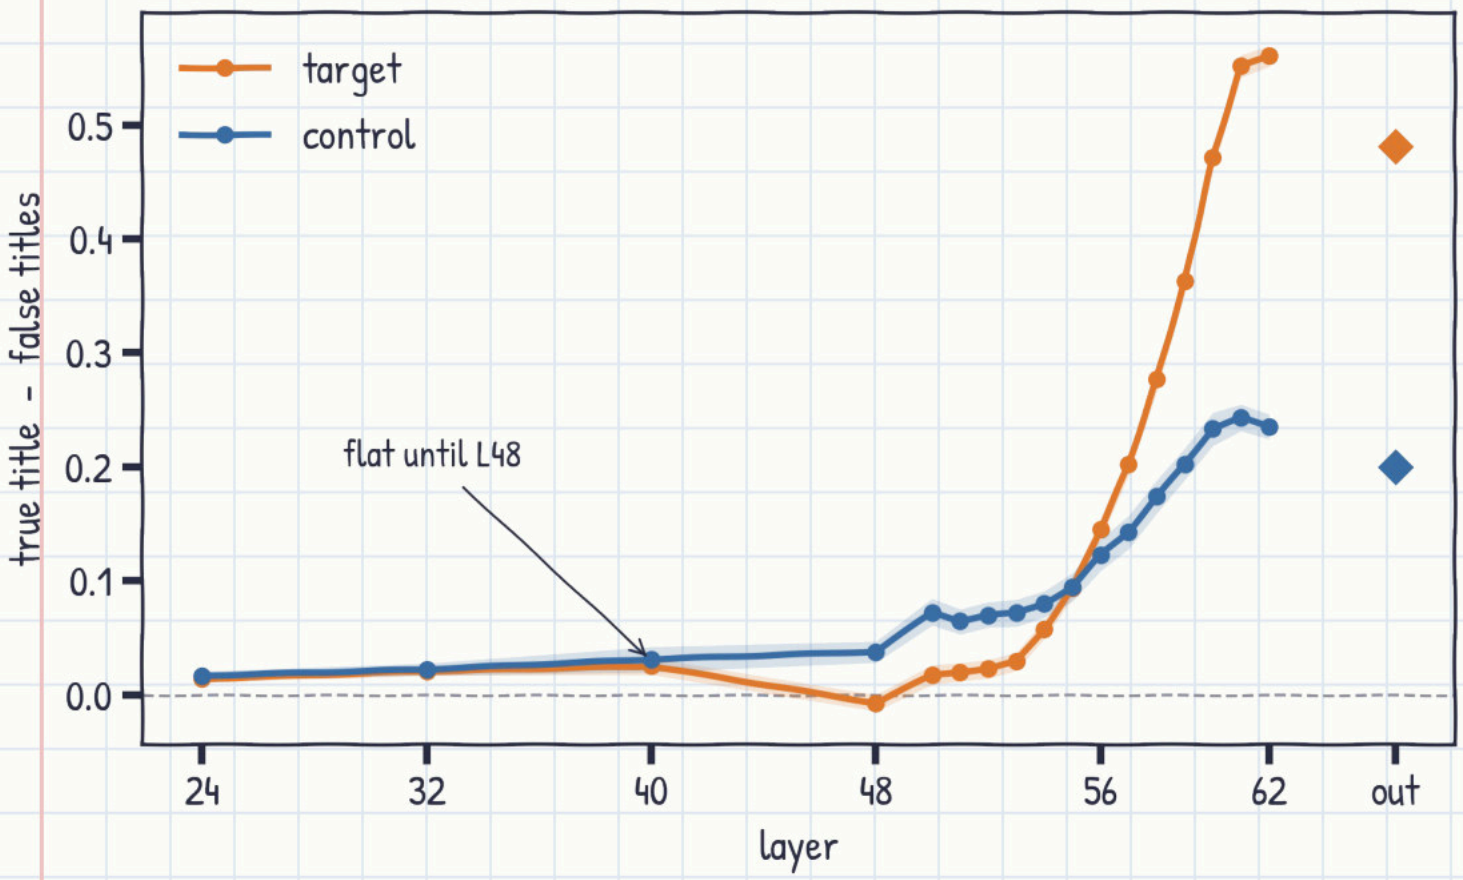
7,247 teams among 9,108 papers: 381_stage13/reports/cluster_ci.md

组间比较都在引用档内做：13 个引用档（Stage 10 引用档 0-2 … 4097+ 共 13 档；~/jlens_work/10_stage10/351_stage10.py；351_stage10/summary_extra/X2_by_bin.csv）里只用 target 和 control 各至少 30 篇的档（设计常数 MIN_STRATUM = 30；~/jlens_work/10_stage10/351_stage10.py:642；351_stage10/config/analysis_plan.json）（主分析 10 档（满足每组 ≥ 30 篇的 10 个引用档，共有引用档 目标 3,734 + 对照 2,182 篇；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），0-2 到 513-1024），每档内算 target − control，再按 $w_b \propto n_t \cdot n_c/(n_t+n_c)$ 加权合并。示例论文在 65-128 档，该档 target 441 篇、control 165 篇（Stage 10 队列 group_tight × citation_bin，65-128 档；351_stage10/cohort/papers.parquet）。Stage 13 起置信区间按作者团队重抽样：共享任一作者全名的论文并成一个团队，9,108 篇共 7,247 个团队（Stage 13 团队划分（共享任一作者全名的论文并成一组），9,108 篇 7,247 组；381_stage13/reports/cluster_ci.md 第 3 行；~/jlens_work/13_stage13/stage13_cpu.py group_folds），交叉验证时一个团队只进一个 fold。

Stage 10

Knowing the paper shows up only at the end

title-specific signal · public Jacobian lens (lines) and model output (diamonds)



L24–L48: ~0 for both groups (Stage 10, all readouts max 0.04, §6.3)

rises at **L56**

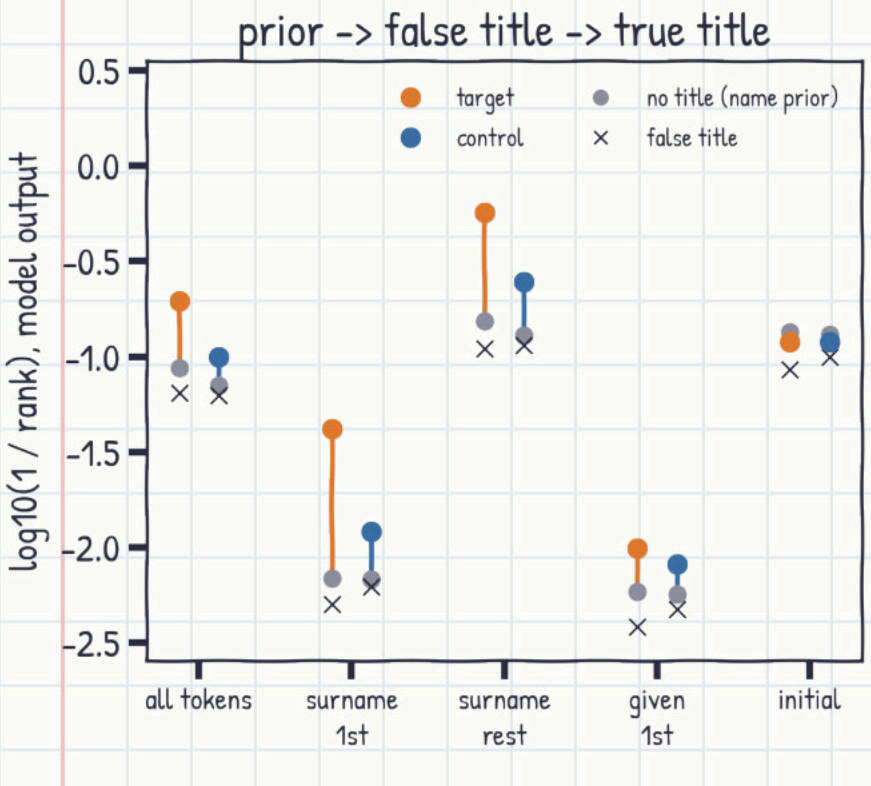
L62: **target +0.56** vs **control +0.24**
(Stage 10, public lens L62, 4,621 + 2,220 papers, §6.3 fig.)

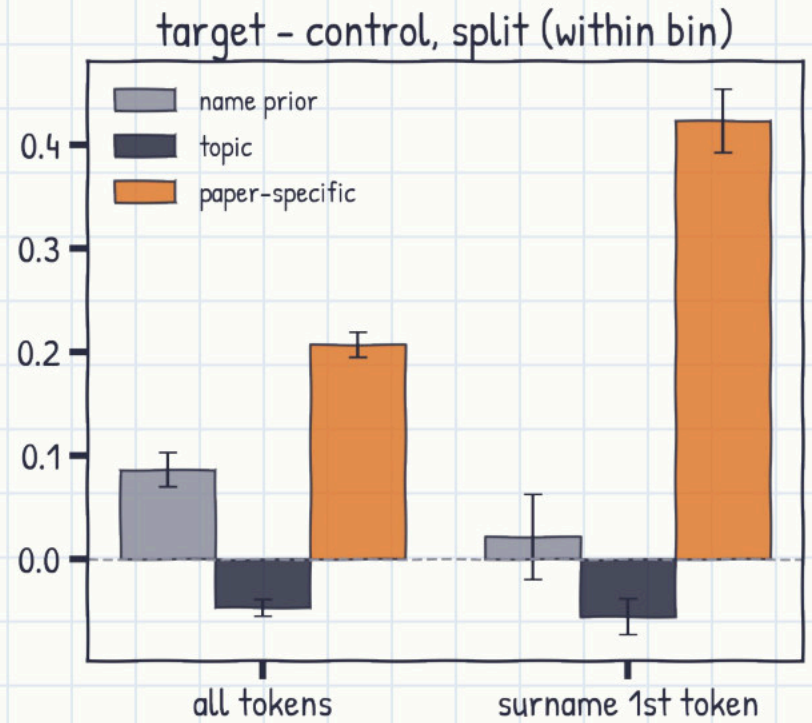
现在去掉名字好猜的影响，看真标题减假标题。到 L48 为止，两组都平坦接近 0；从 L56 开始上升，在 L62 和最终输出处最大。目标组最后大约是对照组的两倍（Stage 10，真标题 − 5 个假标题平均，最终输出 L63 各组均值：目标 4,621 篇 0.481，对照 2,220 篇 0.200（比值约 2.4）；报告 §6.3 图；351_stage10/summary_title/A_group_layer.csv）。

Stage 11

How much is just the name prior?

model output · no title vs false title vs true title · all 9,108 papers





no title: rank ~12 (Stage 12 A, 9,108 papers, §6.12)

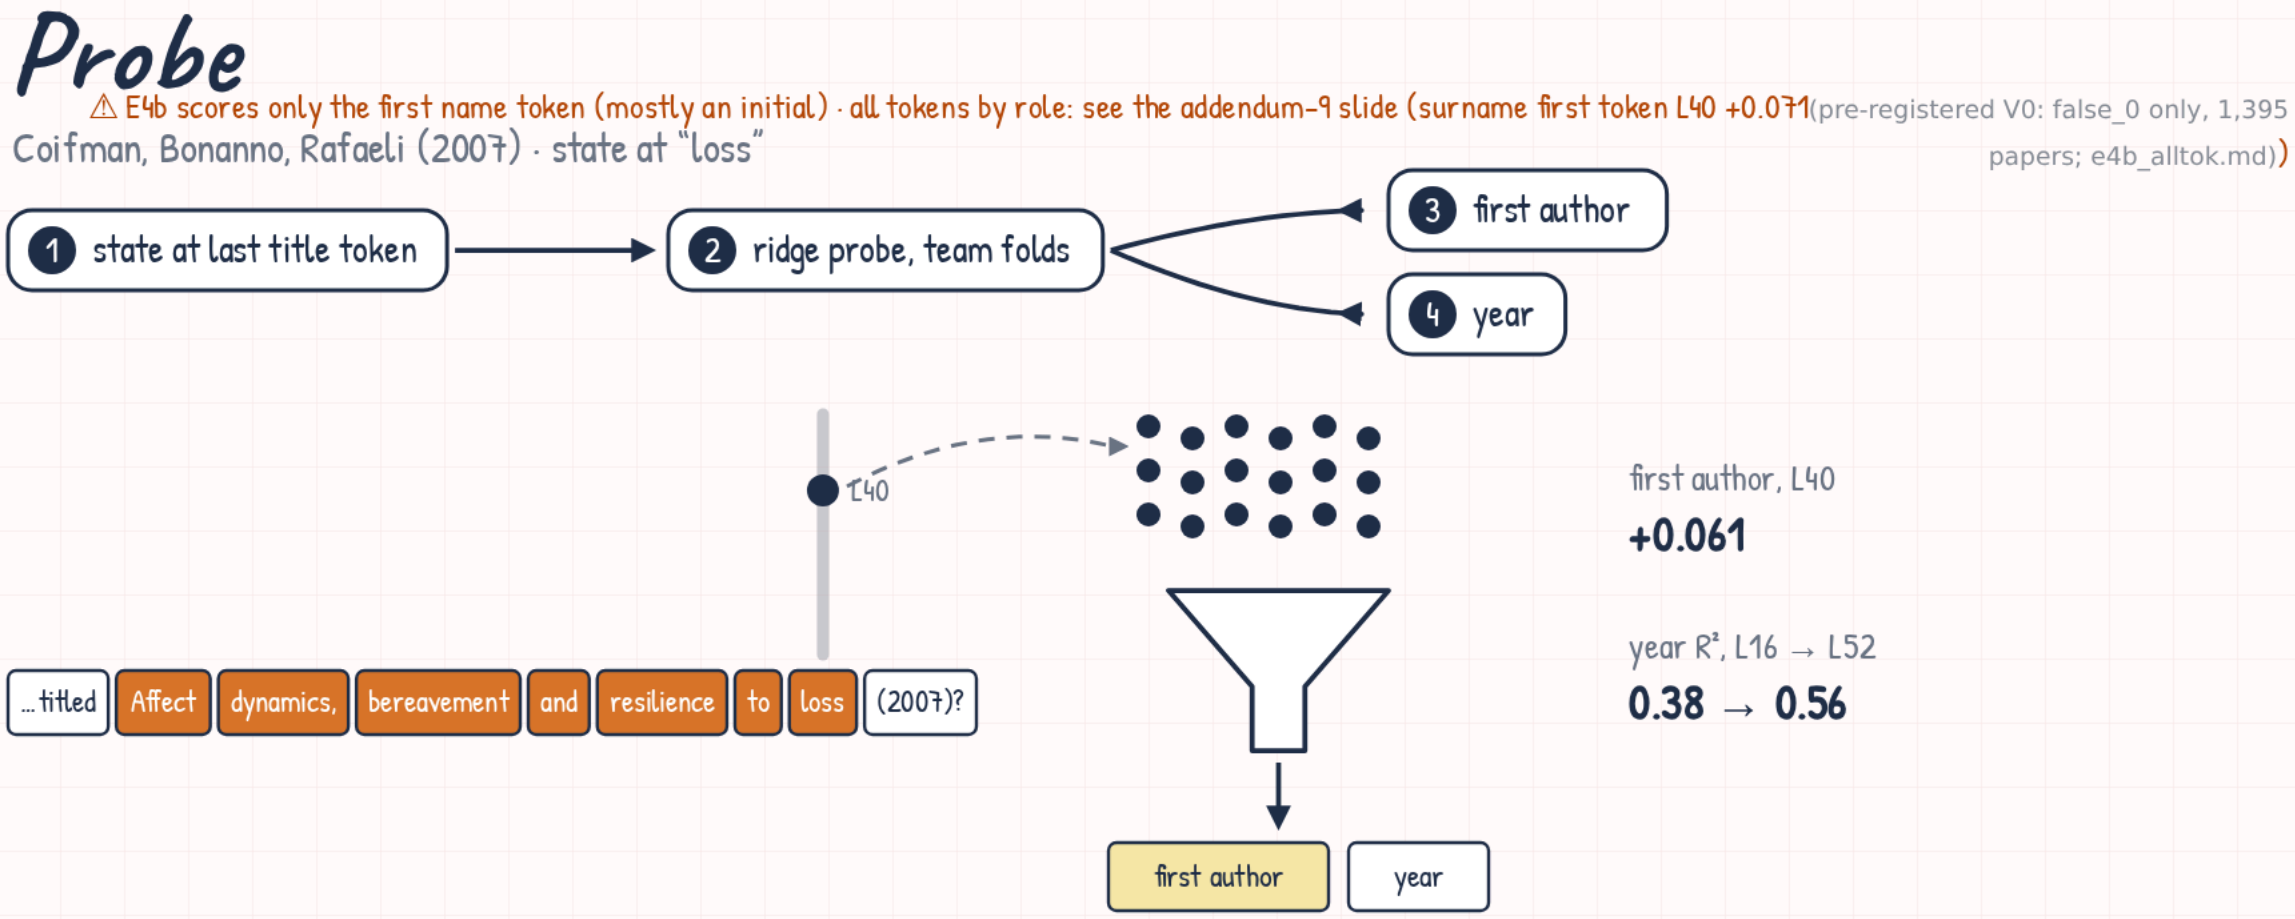
target - control: +0.09 prior, +0.21 paper (Stage 12 A, 4,621 + 2,220, within bin, §6.12)

surname 1st: prior ~0, paper +0.42 (same, 1st surname token)

prior vs recognition rho 0.09 (Stage 12 B, 8,894 R0/R1 papers)

 按 deck 讲稿备注翻译（已按复核结果更新）

名字先验占多少？我们在完全不给标题的情况下给同样的名字打分。没有标题时，正确名字平均已经排在第 12 名左右（Stage 12 名字先验（CPU），不给标题，最终输出 L63，全部 9,108 篇、全部名字 token，平均 log10(1/名次) −1.089 ≈ 第 12.3 名；报告 §6.12；371_stage12/summary_cpu/A_prior_decomposition.csv（all_tokens/all））。因为标点和姓的后半部分在给出前缀后本来就好猜。真标题对姓的第一个 token 帮助最大：目标组从大约第 146 名提到第 24 名（Stage 12 A，姓的第一个 token，目标 4,621 篇，平均 log10(1/名次) 不给标题 −2.164（≈ 第 146 名）→ 真标题 −1.380（≈ 第 24 名）；报告 §6.12 第一张表；371_stage12/summary_cpu/A_prior_decomposition.csv）。在引用档内拆分目标−对照的差：约 0.09 在不给标题时就已存在（Stage 12 A，全部名字 token，最终输出 L63，引用档内 目标−对照（目标 4,621、对照 2,220 篇）：先验 +0.087 [0.070, 0.103]；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）（目标组的名字稍微好猜一些），假标题再抵消 0.05，剩下 0.21 是这篇论文特有的（同上：主题（假标题 − 不给标题）−0.047 [−0.055, −0.038]，论文特有（真 − 假）+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）。只看姓的第一个 token，先验部分约为 0，论文特有部分为 0.42（同上，姓的第一个 token，先验 目标−对照 +0.022 [−0.019, +0.063]，论文特有 +0.423 [0.393, 0.454]；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）。先验和多选题认出程度几乎无关（Spearman 0.09，论文特有部分为 0.33（Stage 12 B，R0/R1 论文 8,894 篇，引用档内中心化后与多选题答对顺序数（0–4）的 Spearman：先验 +0.085 [0.063, 0.106]，论文特有 +0.329 [0.312, 0.346]；371_stage12/reports/stage12_cpu_report.md B；371_stage12/summary_cpu/B_prior_vs_recognition.csv））。



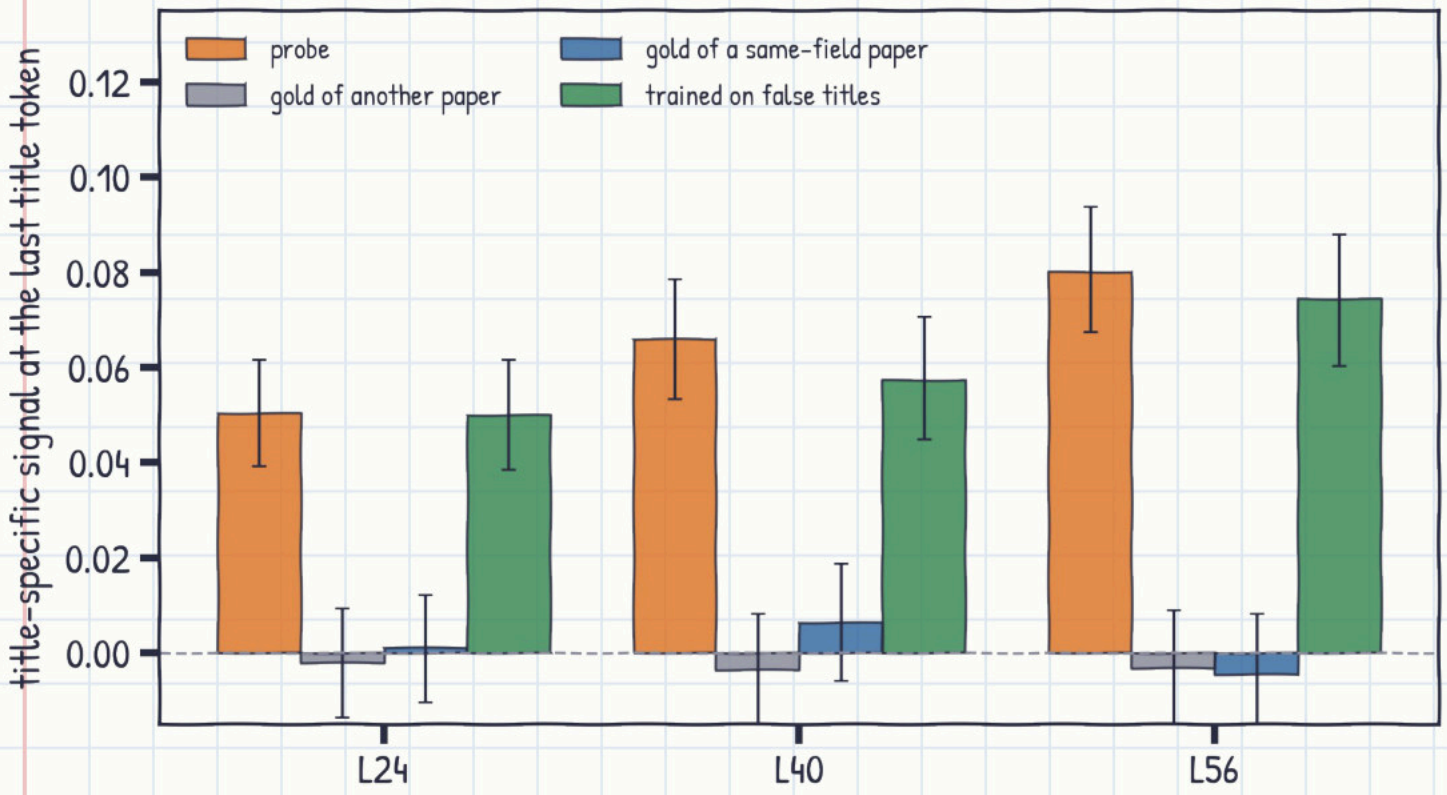
第 24 / 82 页 · Method · Probe · 合并 PPT 自身页面 **新写讲稿**

探针直接从状态读属性：取标题最后一个 token（这里是 “loss”）的残差，例如 L40，用 5 折岭回归（Stage 11 E4b / Stage 13 复核设计：5 折、按作者团队分折，α ∈ {0.1, 1, 10}；~/jlens_work/10_stage10/stage10_extra_r0r1.py probe()；381_stage13/reports/e4b_trainstd_compare.md）（按作者团队分折）预测第一作者的首个 token 或年份。标题特异分数 spec = 真标题的探针分 − 假标题的探针分，L40 为 +0.061 [0.047, 0.076]（Stage 13 E4b 复核，标题最后一个 token 上的 probe，probe 只打分第一作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，target + control 1,395 篇（剔除后全部论文 1,863 篇，E4b 只用其中 1,395 篇），L40 +0.061 [0.047, 0.076]，论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 表 L40 行 new 列）。年份的 R^2 从 L16 的 0.38 升到 L52 的 0.56（Stage 13 M2，真标题，标题最后一个 token，年份岭回归 R^2，9,108 篇：L16 0.383 → L52 0.561，团队整群 95% CI；报告 Stage 13 M2 节；381_stage13/reports/m2_teamci.md 第 46、86 行）（M2）。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Stage 12

The probe signal is paper-specific

last title token · 5-fold ridge probe · re-checked: author-team folds, title reuse removed



another paper's authors: **0**

same-field paper: **0** (Stage 12 X1 + Stage 13 re-check, §6.12)

so it is **this paper**, already at L24

lenses cannot read it

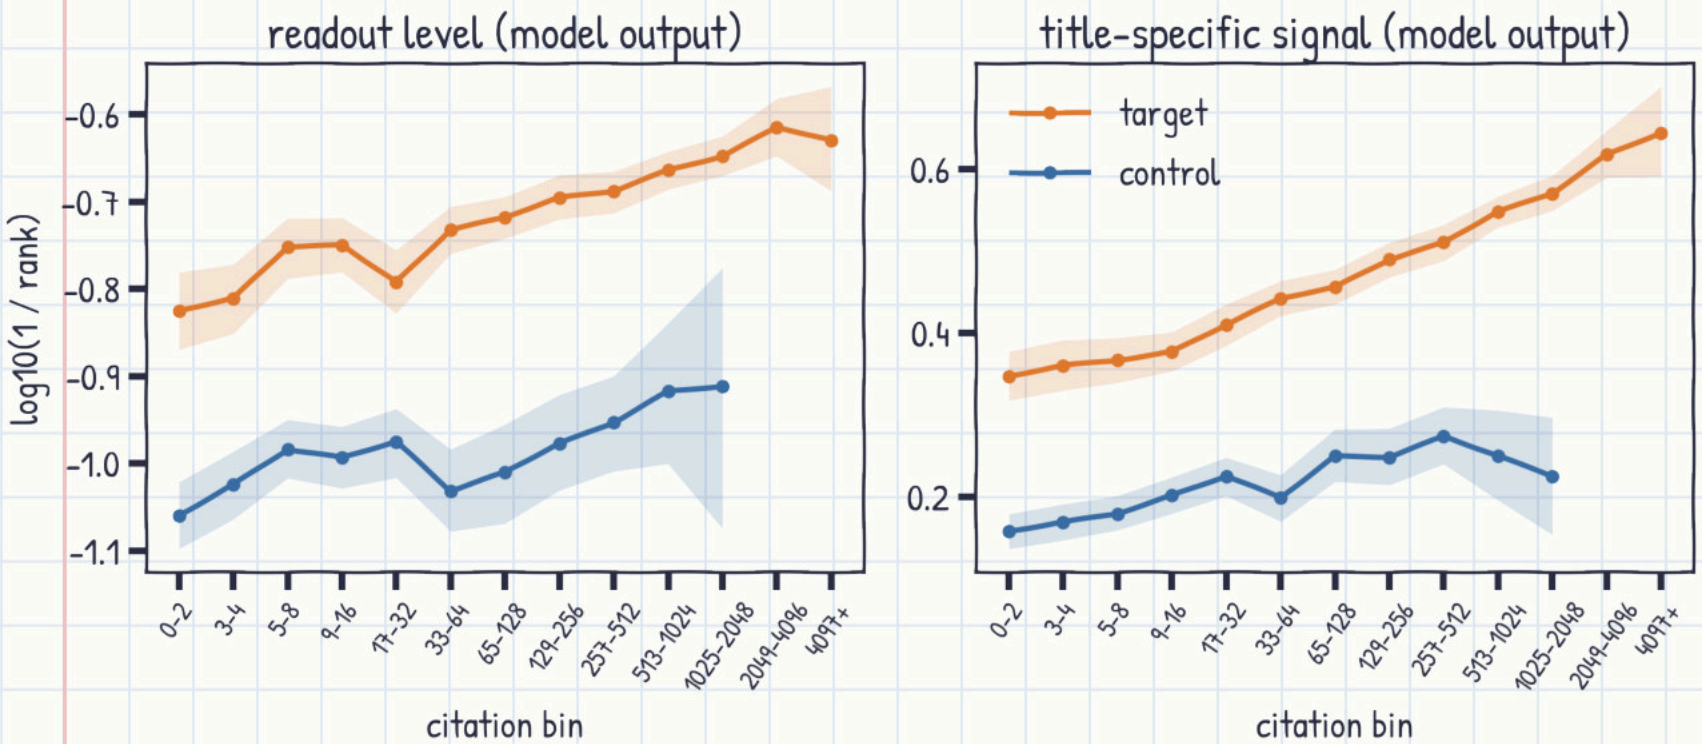
Probe scores only the first name token (mostly an initial); all-token, by-role version (addendum 9, done): surname first token L40 +0.071 [0.058, 0.085] (1,395 papers; e4b_alltok.md).

标题位置上的 probe 读到的是真正的论文知识，还是只是主题和名字之间的泛泛关联？如果把它的输出拿去和另一篇论文的作者、或同领域另一篇论文的作者对照打分，信号降为 0。只用假标题数据训练 probe，得到相近的信号；之前“更强”的结果来自泄漏，同一个借出标题同时出现在训练和测试里。这一页的数字已经按作者团队分折、并剔除了 probe 训练时见过同一标题的论文后复核。所以标题最后一个 token 上从 L24 起就有可以线性读出的、属于这篇论文的作者信息，目标组更多，只是 lens 读不出来。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Stage 10

More citations, more paper knowledge

model output · bins with < 10 papers omitted



Target: +0.35 -> +0.64 (Stage 10, final, 200 / 84 papers, §6.8)

Spearman (title-specific)

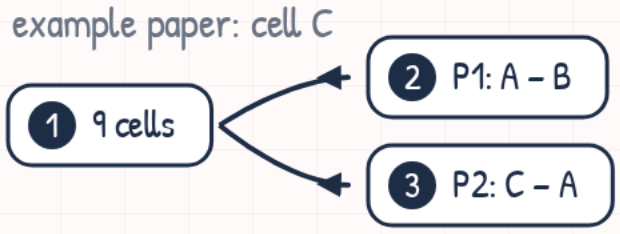
0.45 all · 0.33 target · 0.19 control (Stage 10 X2, 9,108 papers, §6.8)

Target > control in every bin

引用数。两组内部，标题特异信号都随引用档稳定上升：目标组从 0–2 档的 +0.35 升到 4097+ 档的 +0.64（Stage 10，真标题 − 5 个假标题平均，最终输出 L63，目标组各引用档均值：0-2 档 +0.347（200 篇）→ 4097+ 档 +0.644 [0.591, 0.701]（84 篇），论文 bootstrap 95% CI；报告 §6.8 图与表；351_stage10/summary_title/A_group_bin_layer.csv（readout=final）；351_stage10/summary_extra/X2_by_bin.csv）。与对数引用数的 Spearman 相关：全部 0.45（Stage 10 补充 X2，标题特异信号（真标题 − 5 个假标题平均，最终输出 L63）对 log10(引用数+1) 的 Spearman ρ，全部 9,108 篇 0.451 [0.433, 0.467]，bootstrap 95% CI；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv），目标组内 0.33，对照组内 0.19（同上 X2，组内 Spearman ρ：目标 4,621 篇 0.328，对照 2,220 篇 0.187；读出水平只有 0.181 / 0.084；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv）。读出水平本身变化小得多：有名论文的名字并不更好猜，只是模型更了解有名的论文。

Group comparisons

example paper: cell C



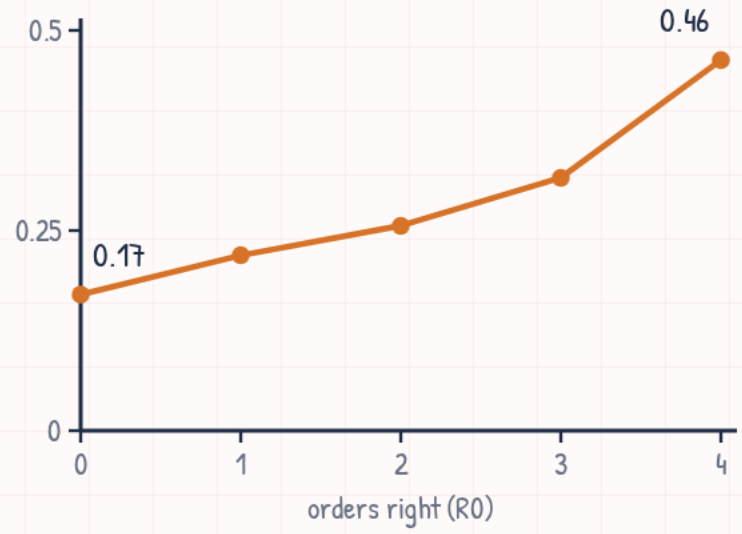


P1 +0.200 [0.188, 0.213]

P2 co-authors +0.061

first author +0.031 (ns)

4 dose: orders right



contrast = Σ w_b (mean_cell1 − mean_cell2)

title-specific signal, unwritten authors, output layer; team bootstrap

P1 +0.200 [0.188, 0.213]: A − B, 3,417 / 2,148 papers; P2 co-authors +0.061, first author +0.031: C − A; dose 0.17 → 0.46: R0 by orders right; 391_groups/primary.csv, stage10_curves.csv

 新写讲稿

组间比较是答辩后新增的分析，计划预先写定（补充 7、8）。P1 比较 A 和 B（都是 R0，只差识别），输出层标题特异信号 +0.200 [0.188, 0.213]（分组对比 P1 A − B，未写出作者，最终输出 L63，A 3,417 / B 2,148 篇，引用档内差，团队聚类 95% CI；391_groups/primary.csv）；P2 比较 C 和 A，只看模型没写出的作者：合作者 +0.061 [0.034, 0.090]（P2-other C − A，C 390 / A 2,826 篇；primary.csv），第一作者 +0.031 [−0.006, 0.069]（P2-first C − A，C 292 / A 3,199 篇，Holm p 0.112；primary.csv），不显著。剂量曲线：R0 论文按多选答对的顺序数 0 到 4，信号从 0.17 升到 0.46（R0 未写出作者，0 种对 927 篇 0.170、4 种对 4,105 篇 0.463；391_groups/stage10_curves.csv）。所有对比都在引用档内加权，并按团队重抽样。