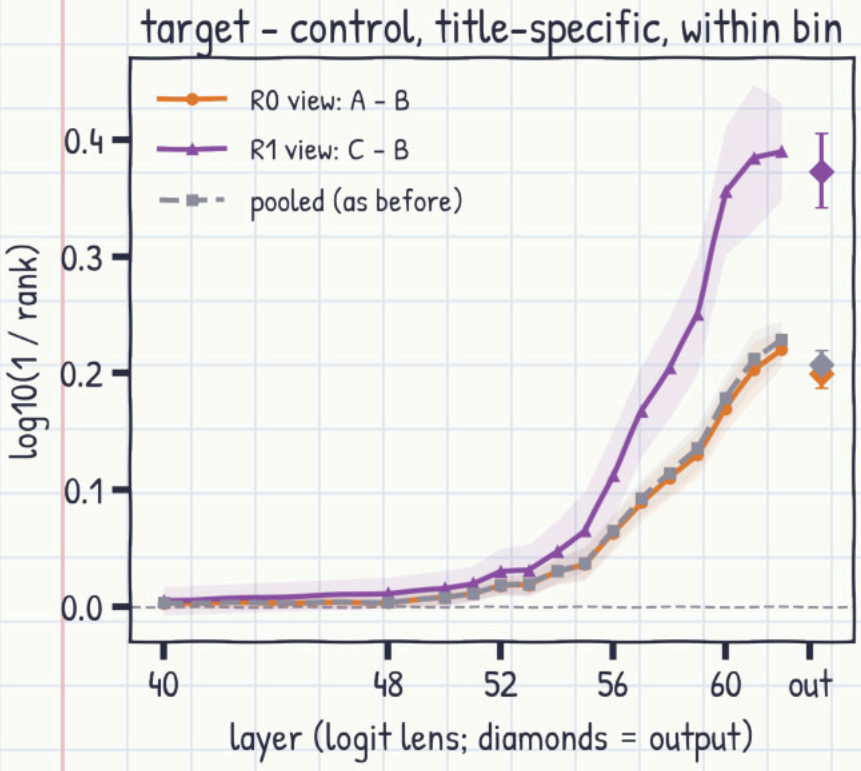
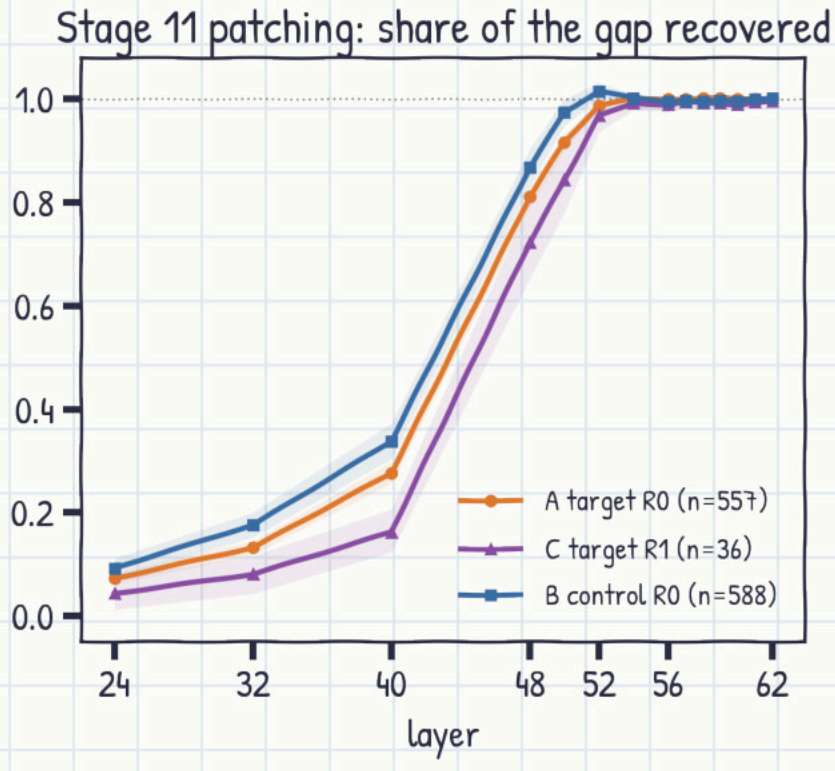
Stage 10–11

Is it just the R1 papers? No.

R0 = no true author written · R1 = a few written · A/B/C/D = target/control x R0/R1





R0 only (A – B):

output +0.199 vs +0.207, same shape (Stage 10, A 3,423 / B 2,151, §6.13)

R1 (C – B): +0.37, also late (C 391 / B 885)

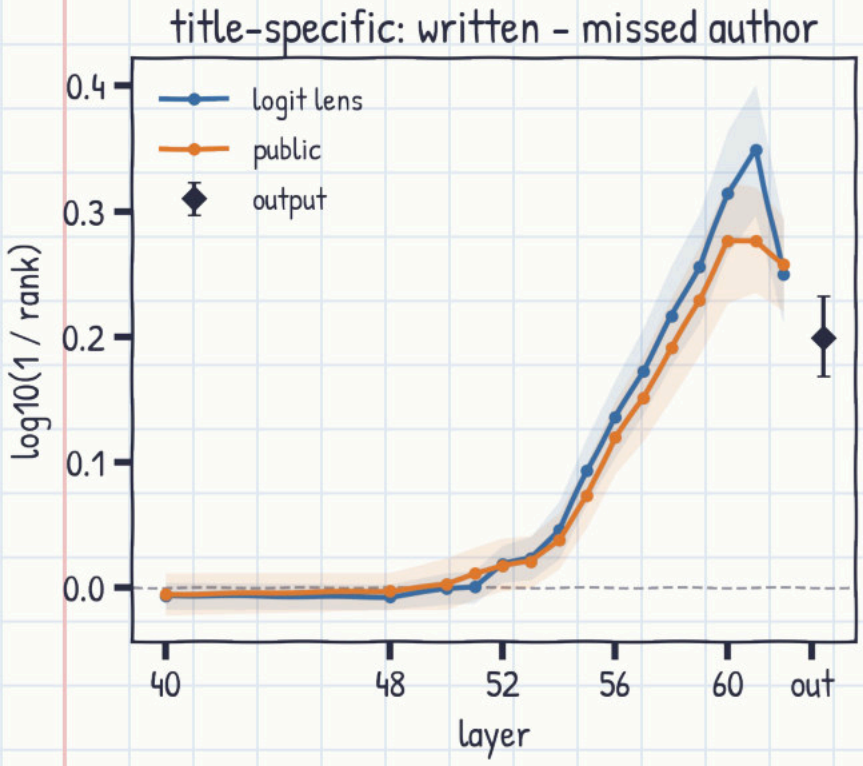
C – A within target: +0.11, from L56 (C 485 / A 3,204)

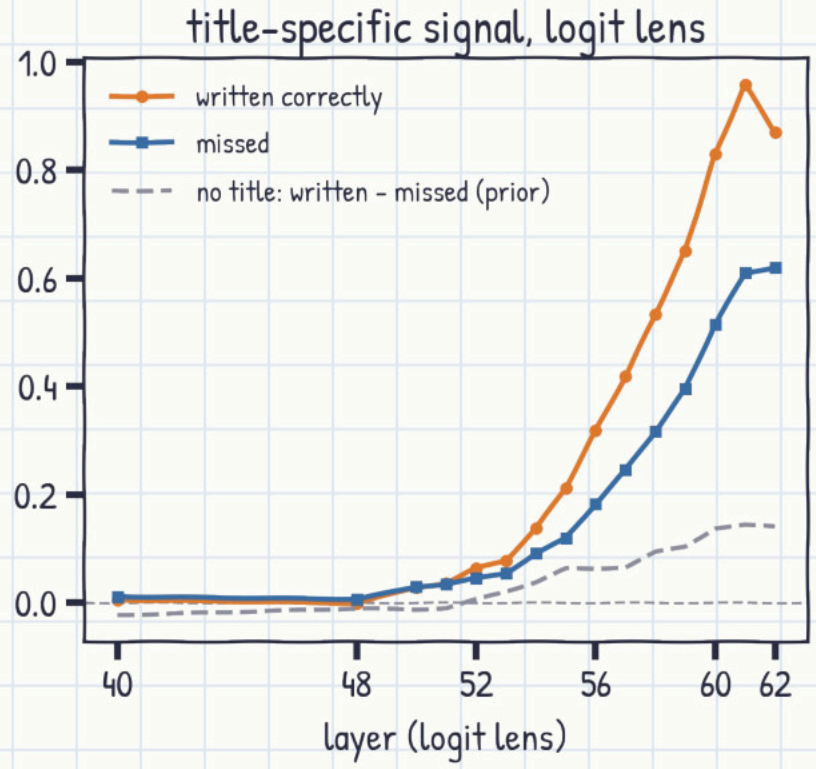
patching: R1 a bit later, done by L52 (Stage 11 E1, 36 R1 targets)

目标组的优势是不是只来自 R1 论文？目标组混合了 R0（开放回答一个真作者都没写对）和 R1（写对了一部分）；目标组里 11% 是 R1，对照组里只有 1.5%（目标组 R1 511 / 4,621 篇 = 11%，对照组 R1 34 / 2,220 篇 = 1.5%；351_stage10/reports/r0_sensitivity.md 第一张表；351_stage10/reports/r0_r1_analysis.md §0）。左图是三种口径下引用档内的目标–对照：只用 R0（A 对 B，即 Stage 1–9 的比较）输出处为 +0.199（Stage 10 只用 R0（A 对 B），真标题 – 5 个假标题平均，最终输出 L63，引用档内 目标–对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv），合并口径为 +0.207（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 – 5 个假标题平均，最终输出 L63，引用档内 目标–对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），曲线形状相同；R1 目标论文对 R0 对照为 +0.37（Stage 10，R1 目标（C）对 R0 对照（B），真标题 – 5 个假标题平均，最终输出 L63，引用档内，391 + 885 篇，+0.372 [0.342, 0.405]，论文 bootstrap 95% CI；351_stage10/reports/r0_r1_analysis.md §1；351_stage10/summary_r0r1/tc_R1target_vs_R0control.csv），它们更了解自己的论文，但同样要到 L52 之后才领先。对照组 R1 只有 34 篇（标注包分组，9,108 篇按开放回答 recall_level × 多选 mc_team_outcome_tight 计数；351_stage10/cohort/papers.parquet recall_level × mc_team_outcome_tight（method_figs/cohort_cells.csv）；报告 Stage 1 分组表；D = 34），只做描述，不做检验。右图是按回忆程度分开的 Stage 11 替换曲线：R1 目标论文（36 篇）（Stage 11 样本中的 R1 目标论文 36 篇（对照 R1 5 篇）；351_stage10/reports/r0_r1_analysis.md §5；361_stage11/summary_r0r1/stage11_curves_by_recall.csv）恢复得稍晚，但到 L52 也全部恢复。标题位置的 probe 给出同样的结论：R0 口径为 +0.02 到 +0.04（Stage 11 E4b 原始版（论文分折、未剔除标题复用），标题最后一个 token 上的 probe，probe 只打分第一个名字 token，probe(真标题) – probe(false_0)，A – B 引用档内，A 4,110 / B 2,186 篇：L16 +0.018、L32 +0.034、L56 +0.038，bootstrap 95% CI 均在 0 以上；361_stage11/summary_r0r1/E4b_probe_by_recall.csv）（这是复核前按论文分折的数字）。结论不变。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。 2026-11-08 补（补充 11 B）：C 补全到 462 篇后，同一引用档内与 A 时间点相同（E1 L48 −0.037 [−0.080, +0.009]），真假标题差距更大（C − A +0.075 [+0.024, +0.130]）；D 33 篇只作描述（391_groups/reports/b2_cd_report.md）。

Authors it wrote vs authors it missed

inside 495 R1 papers · paired within paper · 95% CI (Stage 10, r0_r1_analysis.md §4)





written − missed, output:
+0.20 (Stage 10, final L63, 495 papers)

~0 up to L52, grows from **L54**

no title (prior): +0.10 (same, no title)

same without first authors

在 R1 论文内部，开放回答写对了一部分作者，漏掉了另一部分。标注包只记录了写对的人数，没有记录是哪几位，所以我们重建了匹配，重建出的人数在 99.3% 的 R1 论文里（重建匹配人数 = 标注包 m 的比例：R0 99.9%、R1 99.3%（596 篇）、R2 98.1%；351_stage10/reports/r0_r1_analysis.md §4；~/jlens_work/10_stage10/stage10_extra_r0r1.py）与标注包一致。在 495 篇同时有写对和漏掉作者的论文里（351_stage10/reports/r0_r1_analysis.md §4；351_stage10/summary_r0r1/R1_author_hits.csv），模型写对的作者在输出处的标题特异信号高 +0.20（Stage 10，R1 论文内 写对 − 没写对的作者（论文内配对），真标题 − 5 个假标题平均，最终输出 L63，495 篇，+0.199 [0.168, 0.232]，论文 bootstrap 95% CI；报告 R0/R1 节 §4 表；351_stage10/summary_r0r1/R1_author_written_minus_missed.csv），去掉第一作者后也一样。但这个差在 L52 之前约为 0（同上，logit lens L48 −0.007、L52 +0.019、L54 +0.046、L57–L61 +0.173 到 +0.349；351_stage10/summary_r0r1/R1_author_written_minus_missed.csv），从 L54 才开始上升：即使是模型真能写出来的作者，论文特有的信号也只在最后几层出现。另外，写对的作者在不给标题时也稍微好猜一些，高 +0.10（同上，不给标题（名字先验），最终输出 L63，写对 − 没写对 +0.097 [0.060, 0.134]，495 篇；351_stage10/summary_r0r1/R1_author_written_minus_missed.csv）。

Stages 1–9 · 20–200 papers

What we saw

- True title helps: pilot L56 +9.3 pp(7.3, 50 papers); 200 new papers +5.2 pp(8D RQ1, 200 papers)
- A–B uncertain in the pilot; +5.0 pp on 200 papers but gone after dropping 10 pairs(8D RQ2, 100 pairs)
- Low – high citation: inconclusive

Stages 10–11 · 9,108 papers

What scale showed

- Title-specific signal clear in every group, ≈0.44 at L62(L62, §6.9)
- target – control ≈0 at L24–L40, slightly negative at L48 (−0.04 to −0.05)(§6.4), +0.21 [0.20, 0.22] at the output(L63, §6.4)
- Name prior (delete-title condition) is only ~0.35 of the gap; ~0 on surnames(§6.12)
- Signal rises steadily with citations (ρ = 0.451)(§6.8)
- Same groups as the pilot (R0 only, A – B): +0.20 [0.19, 0.21] (R0, §6.13), same late shape
- R1 papers (C) know more (+0.11 over A)(§6.13) but are just as late

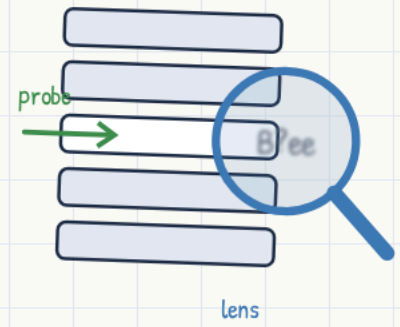
Line A: from "the title helps" to "this paper, late, graded by fame"

The pilot was right that the title matters. It could not see that the target advantage is real but confined to the last layers, so the 7-layer average and the L56 endpoint both diluted it. Restricting the full cohort to the pilot's A/B groups (R0 only) changes nothing: the R1 papers do not drive the result.

A 线的小结。小样本阶段看到：真标题有帮助，Pilot 在 L56 高 +9.3 个百分点（Stage 7.3，J-Lens L56，真标题胜率 − 20 个错误标题平均胜率，合并池，Pilot50 50 篇均值 +0.0934 [0.048, 0.140]（2026-10-30 重算区间，B = 20,000），35/50 篇为正；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv；报告 Stage 7.3 节），200 篇新论文上 +5.2（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节）；A–B 在 Pilot 中不确定，在 200 篇上是 +5.0（Stage 8D RQ2，J-Lens L56 匹配 A − B，100 对，+4.98 pp [0.32, 9.91]，配对 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ2_matched_A_minus_B）但去掉 10 对就消失（Stage 8D RQ2，J-Lens L56 金标准胜率匹配 A−B，100 对，均值 +4.98 pp，按 A−B 降序去掉前 10 对后其余 90 对均值 −0.39 pp（事后诊断）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）重算；报告 Stage 8D 节）；低引用减高引用没有定论。全量阶段看到：每组都有清楚的标题特异信号，L62 约 0.44（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）；目标−对照在 L24–L40 约为 0、L48 略为负（−0.037 到 −0.054，区间不含 0（Stage 10，引用档内目标−对照，三种 Jacobian lens L48 −0.037 到 −0.054；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）），输出处 +0.207 [0.195, 0.220]（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）；名字先验只占差距的约三分之一（Stage 12 名字先验拆解（CPU），最终输出 L63，全部名字 token，引用档内 目标−对照（目标 4,621、对照 2,220 篇）：先验 +0.087 [0.070, 0.103] ÷ 真标题差 +0.247 = 0.35；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv），在姓上约为 0（同上，姓的第一个 token，先验 目标−对照 +0.022 [−0.019, +0.063]，论文特有 +0.423 [0.393, 0.454]；报告 §6.12 第二张表；371_stage12/summary_cpu/A_prior_decomposition.csv）；信号随引用数稳定上升（ρ = 0.451）（Stage 10 补充 X2，标题特异信号（真标题 − 5 个假标题平均，最终输出 L63）对 log10(引用数+1) 的 Spearman ρ，全部 9,108 篇 0.451 [0.433, 0.467]，bootstrap 95% CI；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv）；只用和 Pilot 相同的 R0 分组（A − B）为 +0.20 [0.19, 0.21]（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv），形状同样是后期才上升；R1 论文（C）比 A 多 +0.11（Stage 10，目标组内 R1 − R0（C − A），真标题 − 5 个假标题平均，最终输出 L63，引用档内（每格 ≥ 10 篇），C 485 + A 3,204 篇，+0.110 [0.086, 0.135]，论文 bootstrap 95% CI；351_stage10/summary_r0/target_R1_minus_R0_within_bin.csv；351_stage10/reports/r0_sensitivity.md），但时间点一样晚。小样本说对了标题重要，但没看出目标组的优势只在最后几层，所以 7 层平均（Stage 5–8 的积分终点 = 7 个源层平均（L63 不计入）；351_stage6/config/protocol.json "paper_integrated"；351_stage8/config/analysis_plan.json）和 L56 终点都把它稀释了。

Line B

What can each readout see?



small samples asked

Is J-Lens better than Vanilla? Is the fitted lens stable?

→

the full cohort answered

Lenses read name shape earlier, not paper identity; a probe at the title token reads paper-specific information

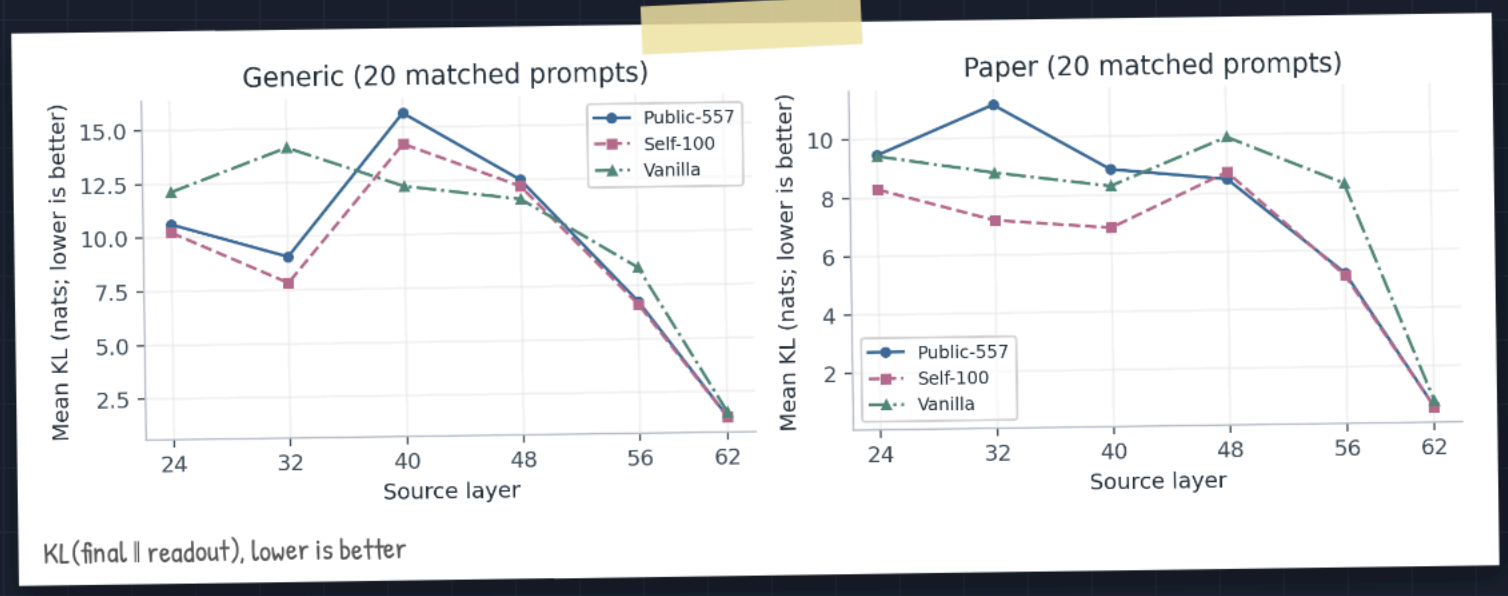
 新写讲稿

B 线的问题是：每种读出工具能看到什么？小样本阶段问的是 J-Lens 是否比 Vanilla 好，拟合出来的 lens 是否稳定。全量阶段的回答是：lens 在中间层更早读出的是“名字的样子”，而不是论文身份；而在标题 token 上训练的 probe 能读出论文特有的信息。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Stage 3 · Exp 1-4

Two lenses: Public-557 vs Self-100

Can a middle layer approximate the final next-token distribution? (20 generic + 20 paper prompts)



- Both checkpoints numerically valid (63/63 and 6/6 finite)(matrices.csv; frobenius_norms.csv)
- Self-100 has lower KL on 6/6 generic and 5/6 paper layers (paper L32: 11.1 → 7.2) (20 + 20 prompts; metrics.csv)
- But at paper L62, Self-100 KL beats Vanilla (0.58 vs 0.81) while Top-10 overlap is worse (0.36 vs 0.72)(metrics.csv)
- Author pilot: both lenses 14/20 full-name wins at L48(20 papers, layer_summary.csv)

Lesson: a better distribution match does not mean better author ranking.
Fidelity cannot stand in for the task.

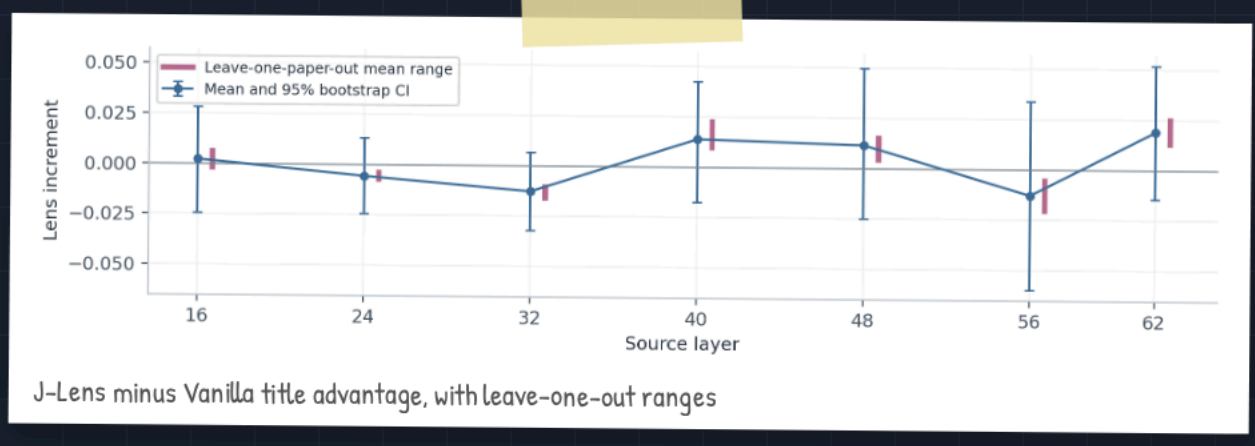
第 32 / 82 页 · Stage 3 · Exp 1–4 · 合并 PPT 自身页面 新写讲稿

Stage 3 比较两个 lens：公开的 Public-557 和我们自己拟合的 Self-100，问中间层能否近似最终的下一个 token 分布，用了 20 条通用提示和 20 条论文提示（Stage 3 Exp 2/4 提示集；~/jlens_work/02_self_lens_validation/351_self_jlens_validation.py:13-50）。两个检查点数值上都有效。Self-100 在 6 个通用层中的 6 层、6 个论文层中的 5 层（Stage 3 Exp 2/4，Self-100 − Public KL，各 20 条提示；351_self100_validation/summary/paired_bootstrap_ci.csv、summary/metrics.csv；报告 Stage 3 节图 3.1）KL 更低，例如论文提示 L32 从 11.1 降到 7.2（Stage 3，论文提示 20 条，L32 KL(final ‖ lens)：Public-557 11.135（351_all/351_paper_fidelity.log L32 jlens 行）→ Self-100 7.180（351_self100_validation/summary/metrics.csv paper/self100/32））。但在论文提示 L62，Self-100 的 KL 优于 Vanilla（0.58 对 0.81）（Stage 3，论文提示 20 条，L62 KL：Self-100 0.578、Vanilla 0.808；351_self100_validation/summary/metrics.csv（task=paper, layer=62, kl_final_to_lens_nats）），前 10 名重合度却更差（0.36 对 0.72）（同上，L62 前 10 名重合度：Self-100 0.355、Vanilla 0.720；351_self100_validation/summary/metrics.csv（top10_overlap））。作者小试中两个 lens 在 L48 都是 20 次里 14 次全名胜出（Stage 3 Exp 3，L48 全名胜率 0.70 × 20 篇，两个 lens 相同；351_self100_gold_false/archive/summary/layer_summary.csv 列 full_win_rate）。教训是：分布拟合得更好，不等于作者排名更好，保真度不能代替任务本身。

Stage 7.4 · Line B

Cross-stage audit: does J-Lens add value?

Read-only joins of Stages 5–7.3; 20,000 bootstrap draws



J-Lens minus Vanilla title advantage, with leave-one-out ranges

Stage 5 vs 7.3 at L56	r = 0.45, ρ = 0.47; signs agree 32/50 (50 papers, cross_stage_correlations.csv)
J-Lens − Vanilla	+0.002 [−0.008, +0.012]; median −0.002; 24/50 positive (jlens_increment_bootstrap.csv)
A−B of that increment	−0.014 [−0.033, +0.004] (20 pairs)

Dropping one paper can flip the sign of the J-Lens increment. The pilot shows **no added title-specific value** from J-Lens over Vanilla. Everything so far is exploratory: L56 was inspected repeatedly.

 新写讲稿

Stage 7.4 是跨阶段审计：J-Lens 到底有没有增加价值？只读地合并了 Stage 5 到 7.3 的结果，用 20,000 次 bootstrap（Stage 7.4 设计，种子 741；~/jlens_work/07_4_stage7_4/351_stage7_4.py:10-13）。Stage 5 和 7.3 在 L56 的相关为 r = 0.45，50 篇里 32 篇方向一致（Stage 7.4，J-Lens L56，Stage 5 与 Stage 7.3 的论文级相关，50 篇，Pearson 0.445，同号比例 0.64 = 32/50；351_stage7_4/summary/overview.json "L56_jlens_stage5_stage73"；351_stage7_4/summary/cross_stage_correlations.csv）。J-Lens 减 Vanilla 的标题优势为 +0.002 [−0.008, +0.012]，中位数 −0.002，50 篇里 24 篇为正（Stage 7.4，J-Lens − Vanilla 标题优势，7 层积分，50 篇，均值 +0.0022 [−0.0075, +0.0124]，中位数 −0.0019，24 篇为正，论文 bootstrap 95% CI；351_stage7_4/summary/jlens_increment_bootstrap.csv 行 integrated；overview.json）；这个增量的 A−B 为 −0.014（Stage 7.4，J-Lens 增量的匹配 A − B，20 对，−0.0139 [−0.0332, +0.0036]；351_stage7_4/summary/overview.json "matched_ab_difference_of_lens_increment"），区间含 0。去掉一篇论文就可能让 J-Lens 增量变号（Stage 7.4，逐一留出一篇后 7 层积分增量范围 −0.000046 到 +0.003494；351_stage7_4/summary/overview.json "integrated_jlens_minus_vanilla"）。Pilot 没有显示 J-Lens 比 Vanilla 多出任何标题特异的价值；而且到这里为止都是探索性的，L56 被反复看过。

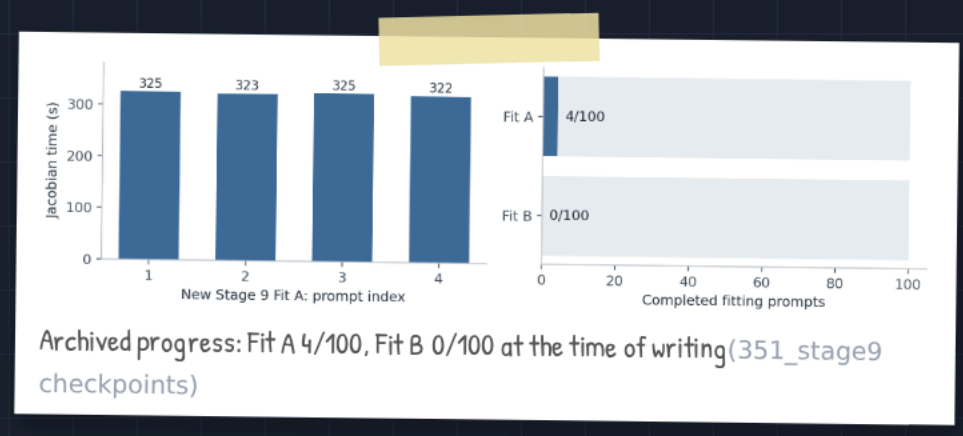
Stage 9 · Line B

Stage 9: is the lens stable across fitting data?

New FullFit protocol, different from the historical 50+50 split

	Historical split-half	Stage 9 FullFit
Fit data	Self-100 split 50 + 50	two disjoint 100-prompt sets
Holdout	20 generic + 20 paper	independent 100 WikiText
Layers	6	7 (adds L16)
Status	complete	only Fit A completed; Fit B and holdout not run

- WikiText-103 train, 100–1,200 chars, deduplicated by hash, seed 3519001
- ~324 s Jacobian time per prompt, ~62 GiB CPU RAM(full_A.log; benchmark log); per-prompt checkpoints

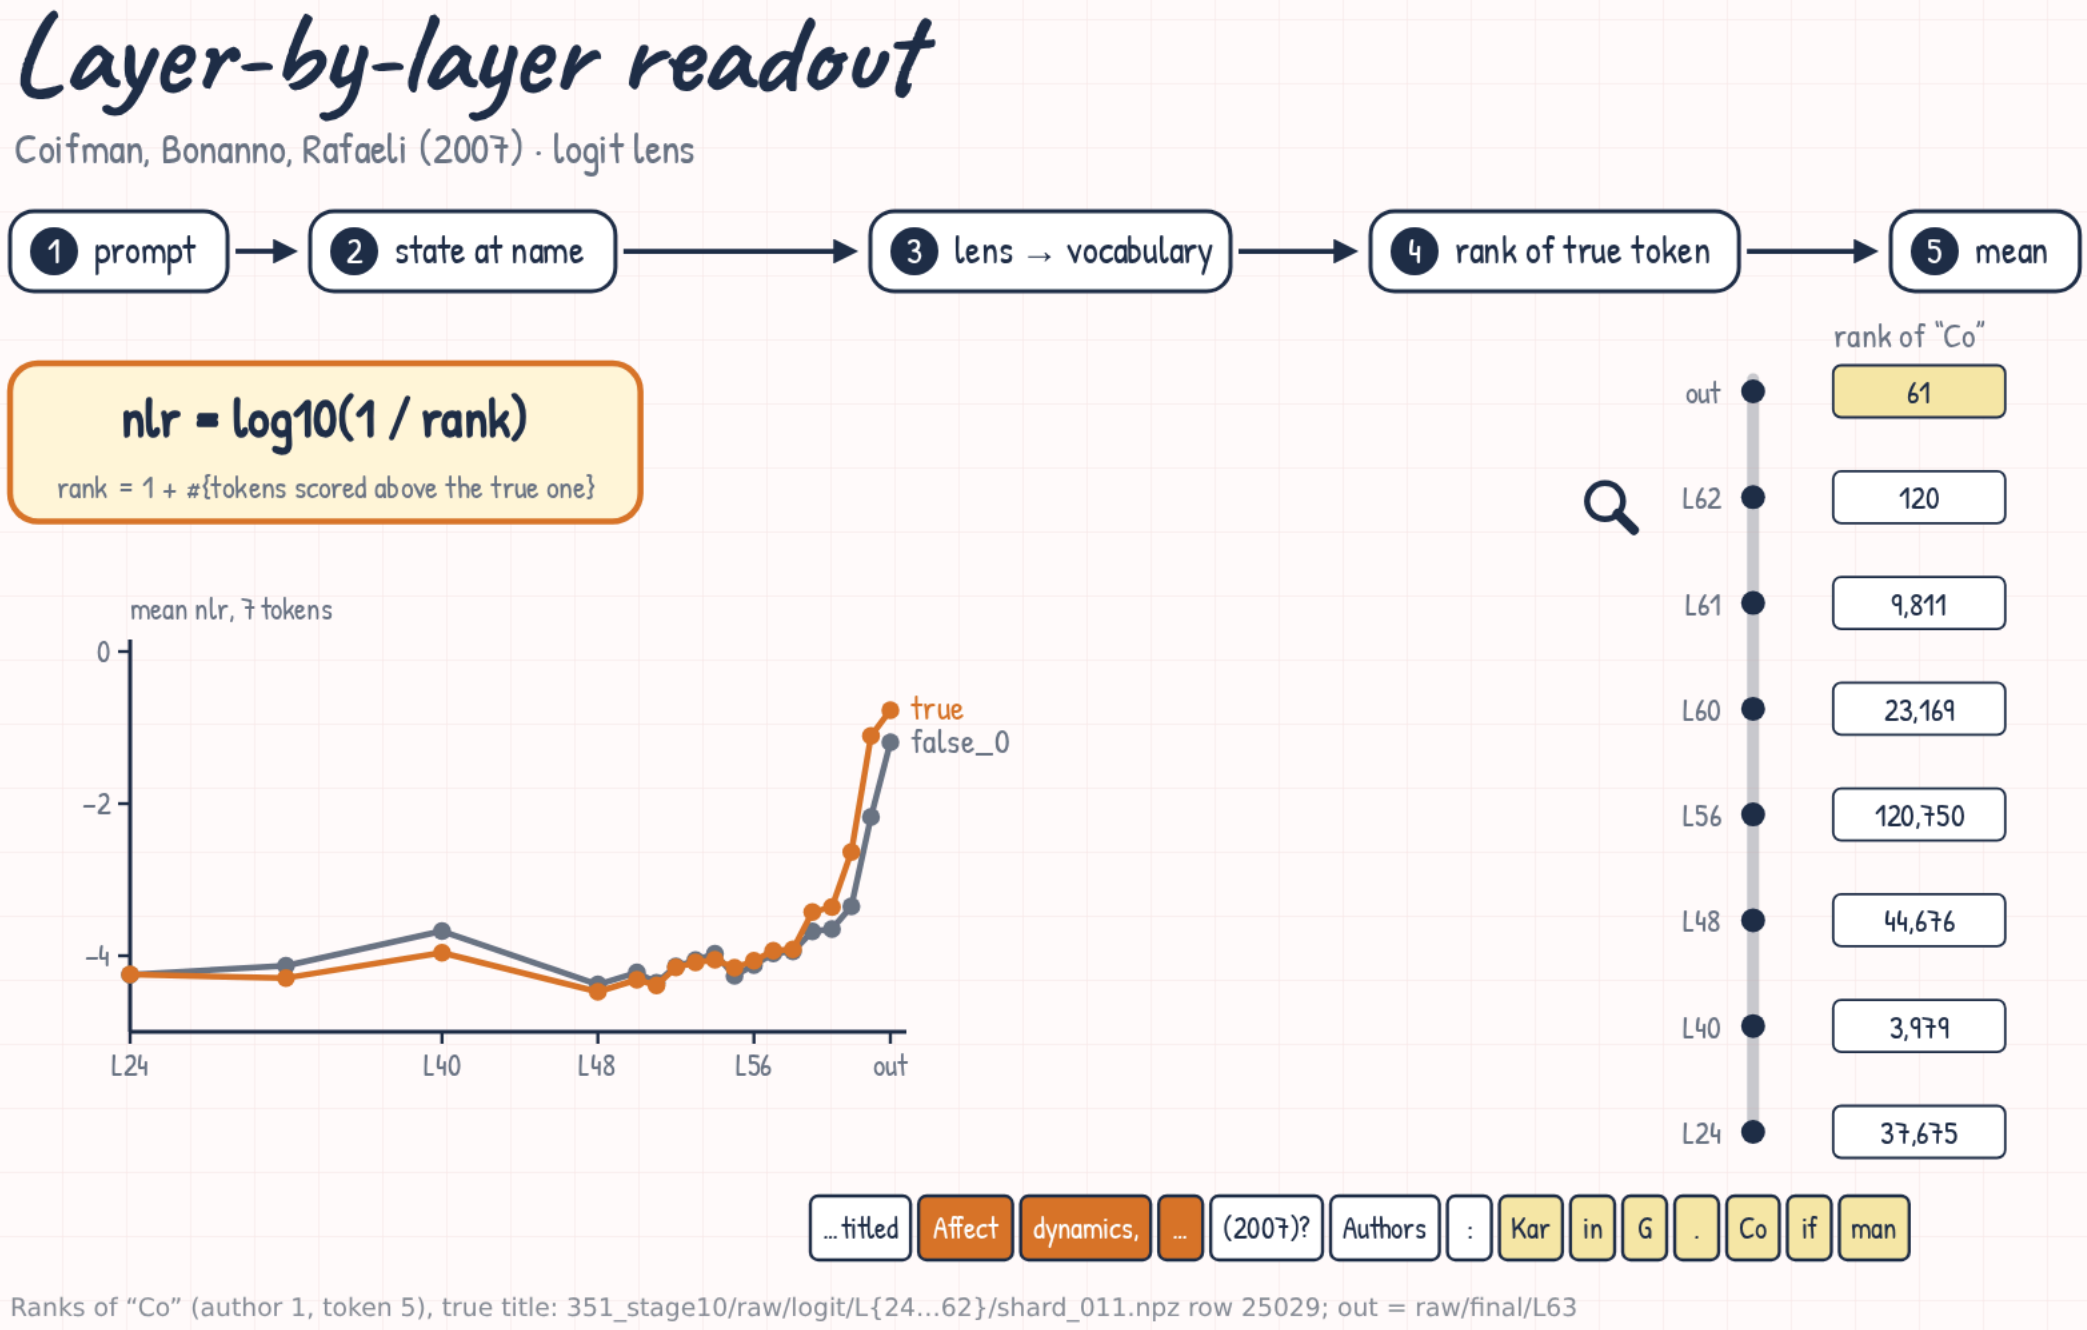


Archived progress: Fit A 4/100, Fit B 0/100 at the time of writing(351_stage9 checkpoints)

Only Fit A was finished, and Stage 10 used it as "fitA". Without Fit B and the holdout, fitting stability is **untested**.

第 34 / 82 页 · Stage 9 · Line B · 合并 PPT 自身页面 **新写讲稿**

Stage 9 想检验 lens 是否依赖拟合数据，用的是新的 FullFit 方案，和历史上的 50 + 50 拆分（Stage 3 Exp 7 历史拆分，偶数 / 奇数索引各 50 条；351_self100_split_half/fits/config_A.json、config_B.json）不同：两套互不重叠的 100 条提示，外加独立的 100 条 WikiText 留出集（Stage 9A.1 设计，FitA100 / FitB100 / Holdout100 各 100 条；351_stage9/config/plan.json、manifest.json "counts"；~/jlens_work/09_stage9/351_stage9.py:50-62），层数增加到 7 层（Stage 9 拟合层 L16–L62 共 7 层；351_stage9/runner_runs/full_A_100_7layers/fitting_config.json；351_stage10/config/lenses.json fitA）（加了 L16）。每条提示的 Jacobian 约需 324 秒、约 62 GiB CPU 内存（Stage 9 正式 Fit A 第 1–4 条每条 325/323/325/322 s（均值 323.75 s，351_stage9_full_A.log）；单条提示 7 层基准 CPU 内存峰值约 62.06 GiB（351_stage9_benchmark_A1_7layers.log)），每条存一次检查点。最后只完成了 Fit A，Stage 10 用的“fitA”就是它；Fit B 和留出比较都没做，所以 lens 的拟合稳定性还没有检验。



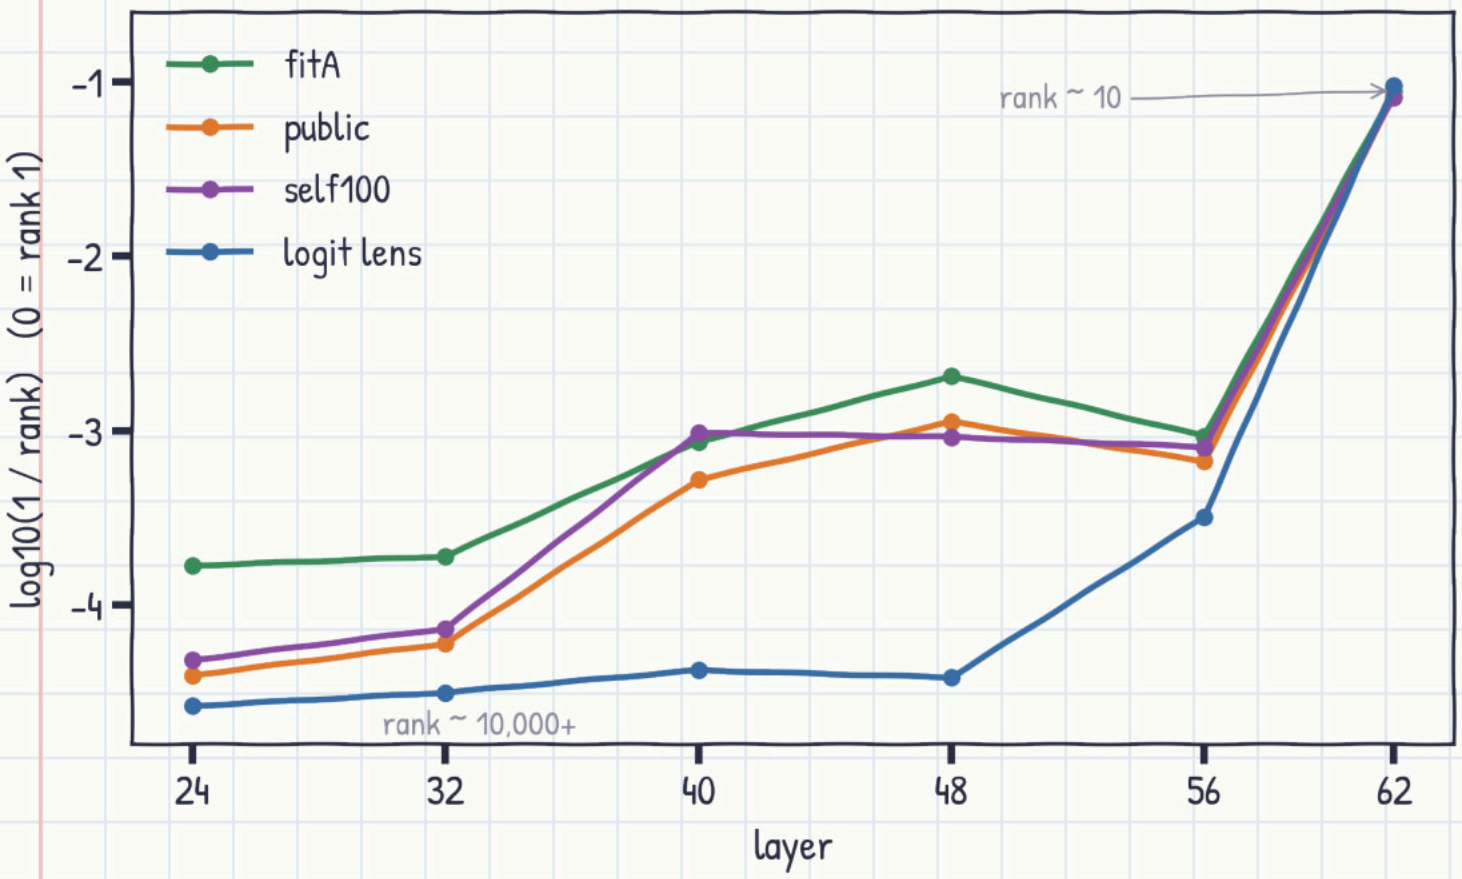
第 35 / 82 页 · Method · Layer-by-layer readout · 合并 PPT 自身页面 **新写讲稿**

逐层读出：在名字位置取每一层的隐藏状态，用 logit lens 映射到全词表，看真名字 token 的名次，再算 nlr = log10(1/名次)。示例论文第一作者姓的首个 token “Co”：L24 名次 37,675，L56 120,750，L61 9,811，L62 120，输出层 61（Stage 10，示例论文 Coifman 等（2007），真标题，第一作者姓的首个 token “Co”（行 25029），logit lens L24–L62 与最终输出 L63 全词表名次；351_stage10/raw/logit/L*/shard_011.npz、raw/final/L63/shard_011.npz；351_stage10/reports/method_figs/coifman_layer_ranks.csv（列 r5_Co））。第一作者 7 个 token 的平均 nlr 到 L58 都在 −4 左右，L62 升到 −1.11、输出层 −0.77（同上，第一作者 7 个 token（行 25025–25031）的平均 log10(1/名次)，logit lens：L24–L58 为 −4.47 到 −3.92，L62 −1.111，最终输出 −0.772；351_stage10/reports/method_figs/coifman_layer_ranks.csv 列 mean_log10_inv_rank）；假标题 false_0 在输出层是 −1.19（同上，false_0 条件，最终输出 L63，−1.194；351_stage10/raw/cond_false_0/final/L63/shard_011.npz；351_stage10/reports/method_figs/coifman_layer_ranks.csv（condition=false_0, readout=final）），真假之差只在最后几层出现。

Stage 10

Names become readable late

all 9,108 papers · true title (Stage 10 cohort, §6.1)



Logit lens: almost nothing until **L48**

Jacobian lenses read more from **L40**

Everything jumps at **L62** (rank ~10) (Stage 10, logit L62 −0.93, §6.1)

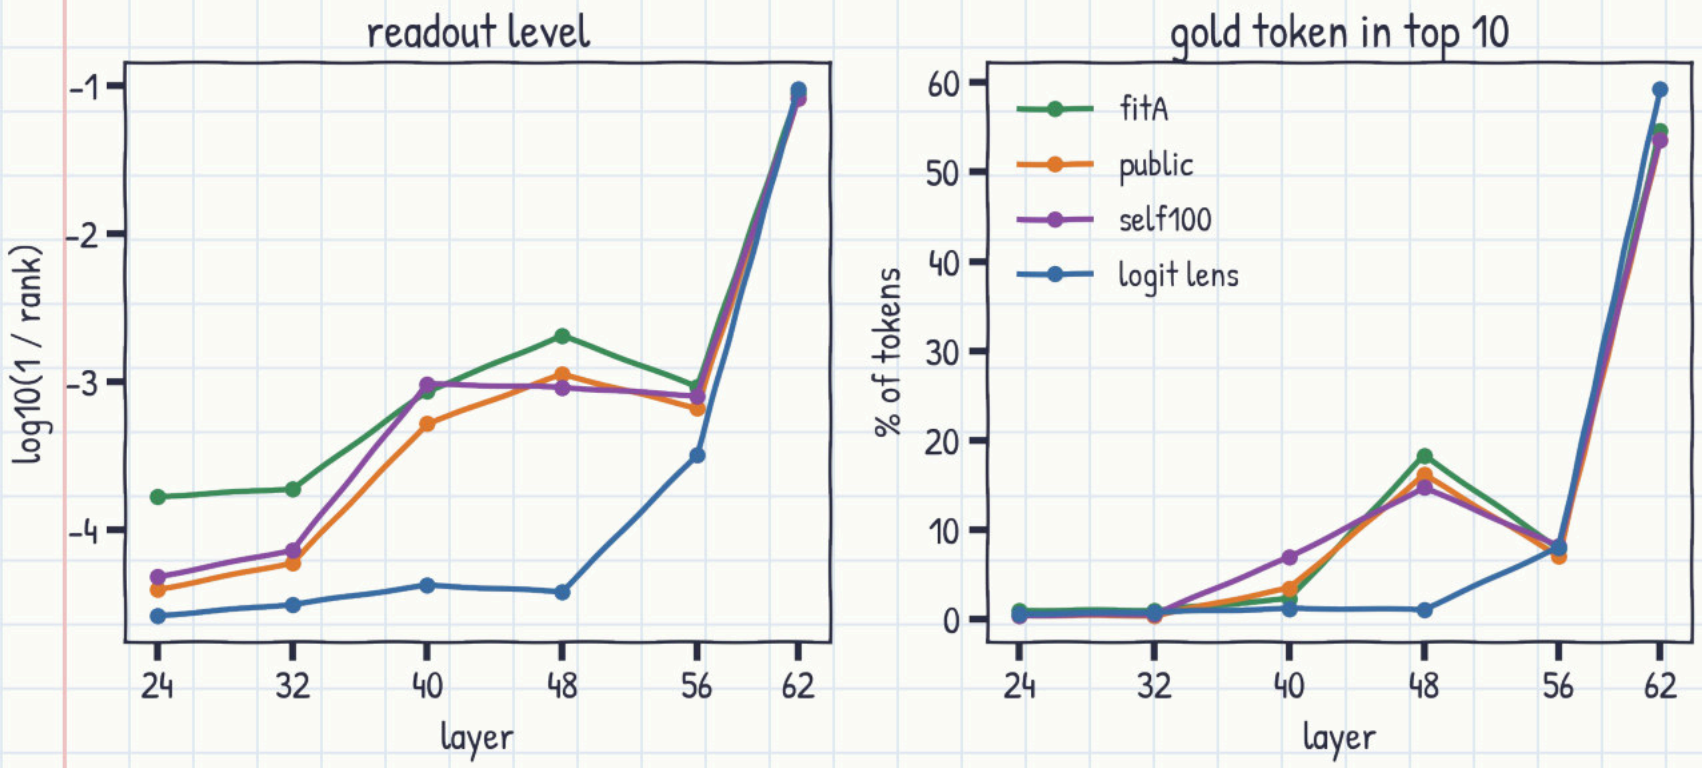
 按 deck 讲稿备注翻译（已按复核结果更新）

所有读出方式都随层数加深而变好。logit lens 在 L48 之前几乎读不出东西（名次在几万名（Stage 10，真标题，logit lens L24–L48，目标 4,621 + 对照 2,220 篇，平均 log10(1/名次) 约 −4.4 到 −4.6；报告 §6.1 表；351_stage10/summary/A_group_layer.csv）），到 L62 才跳上来。Jacobian lens 从 L40 起读出更多，fitA 最多。模型真实输出最好。

Stage 10

Which lens reads best?

all papers · true title



Middle layers:

fitA best; at L48 15–18% top-10 vs 1% for logit

(Stage 10 X3, 9,108 papers, §6.9)

L62: logit lens best (59%)

(same, L62)

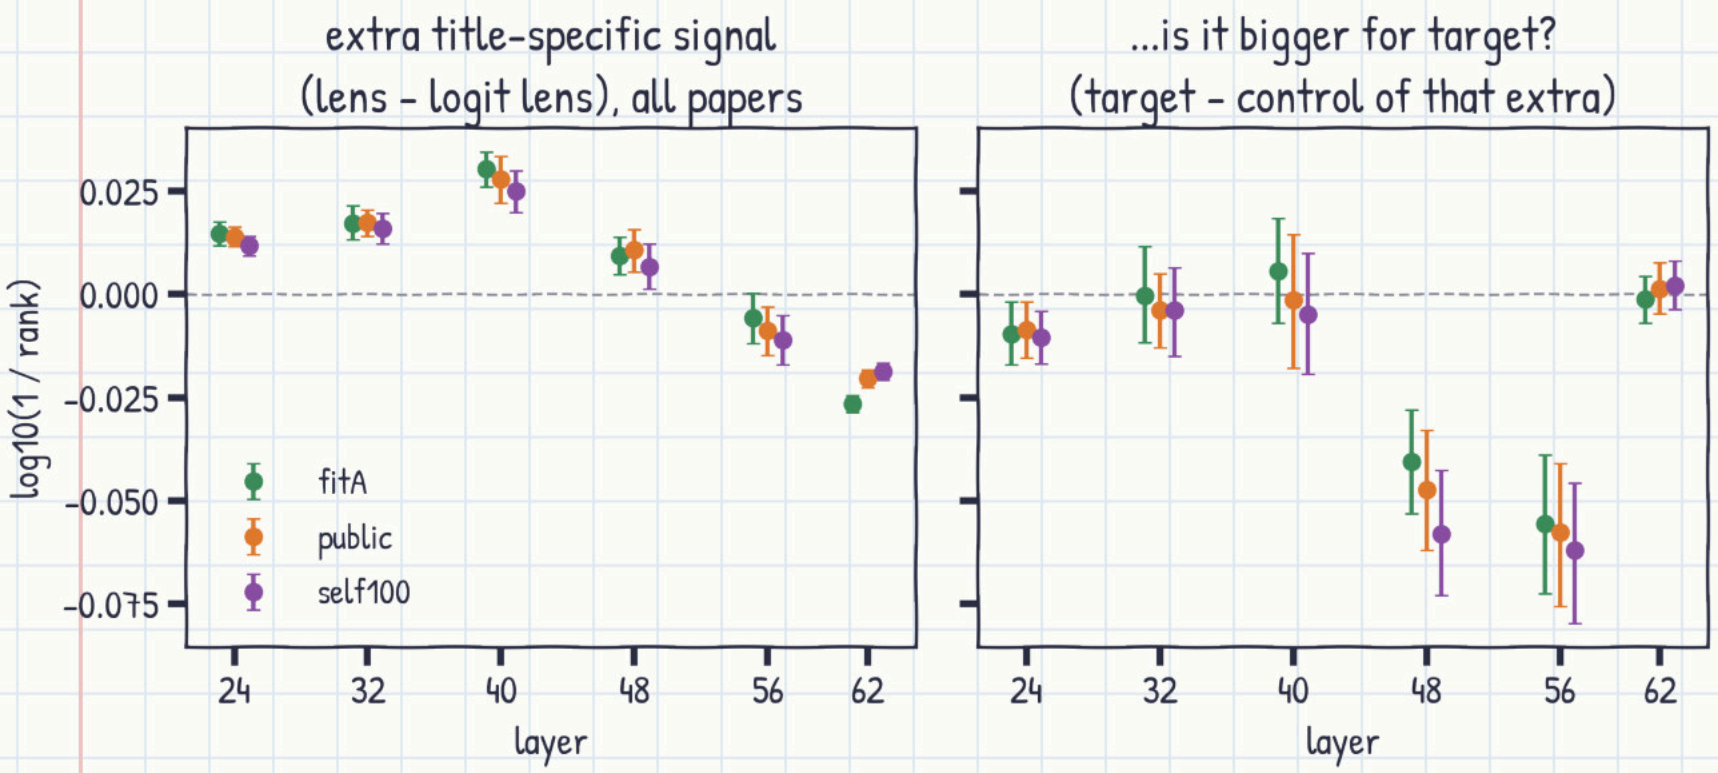
第 37 / 82 页 · deck 第 22 页 按 deck 讲稿备注翻译（已按复核结果更新）

比较各种 lens。读出质量上，中间多数层 fitA 最好，L40 是 self100；在 L48，Jacobian lens 能把正确 token 放进前 10 名的比例是 15–18%，logit lens 只有 1%（Stage 10 X3，真标题，全部 9,108 篇，同一批 token 配对，L48 前 10 命中率（token 比例）：三种 Jacobian lens 14.7%–18%，logit lens 1.1%；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）。到 L62，最朴素的 logit lens 反而最好。

Stage 10

Do lenses reveal hidden paper knowledge?

paired differences, 95% CI



Extra signal: **+0.01 to +0.03** (Stage 10 X3, L24–L48, 9,108 papers, §6.9)

vs ~0.44 at L62 (same, L62)

Not bigger for target (even negative at L48–56)

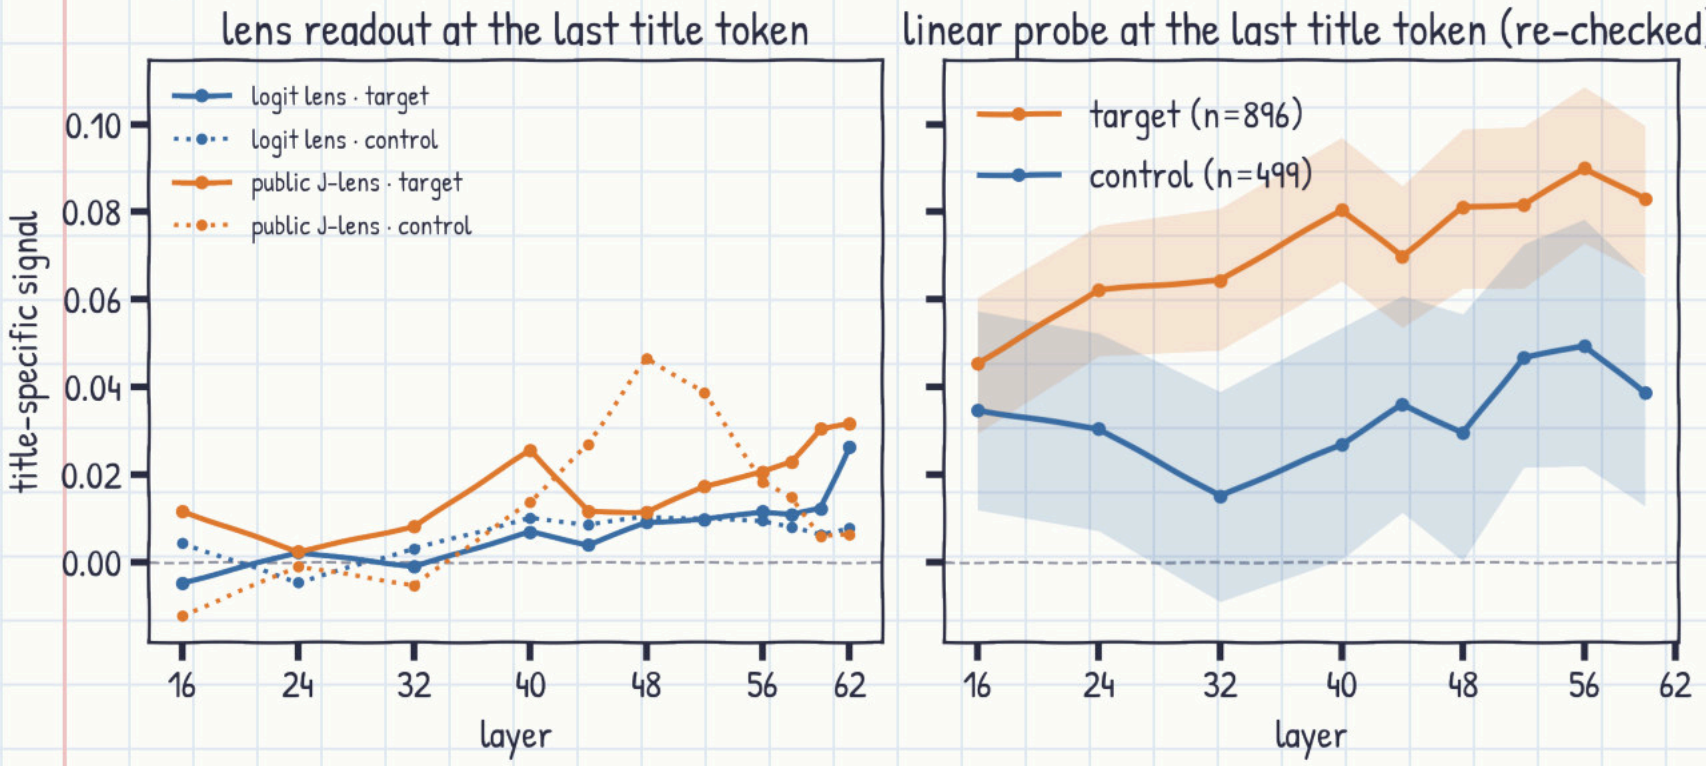
 按 deck 讲稿备注翻译（已按复核结果更新）

Jacobian lens 能不能看到 logit lens 漏掉的、论文特有的信息？只能看到一点：在 L24–L48 多出 +0.01 到 +0.03 的标题特异信号（Stage 10 补充 X3，三种 Jacobian lens 减 logit lens 的标题特异信号（真标题 − 5 个假标题平均），L24–L48，全部 9,108 篇，+0.007 到 +0.030，论文 bootstrap 95% CI 均在 0 以上；报告 §6.9 表；351_stage10/summary_extra/X3_pairwise.csv），区间在 0 以上，但和 L62 的 0.44 相比（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）非常小。而且这部分对目标组并不更大：多出部分的目标−对照约为 0，在 L48 和 L56 甚至为负（Stage 10 X3，(lens − logit) 标题特异信号的引用档内 目标−对照，三种 Jacobian lens：L24–L40 约 0，L48 与 L56 为 −0.04 到 −0.06，论文 bootstrap 95% CI；报告 §6.9 最后一表；351_stage10/summary_extra/X3_tc_spec_vs_logit.csv）。

Stage 11

Read early: a probe finds it at the title

title-specific signal at the last title token · lenses: all 9,108 papers · probe: re-checked, title reuse removed: 1,863 papers (896 target, 499 control) (Stage 11 E4; Stage 13 E4b)



lenses: **~0.01–0.03** (Stage 11 E4, 4,621 + 2,220, §6.11)

probe: **0.05 -> 0.08** (Stage 13 E4b, 1,863 papers, first name token only)

target > control by **+0.03–0.08** (E4b, 896 vs 499, within bin)

re-checked: team folds, title reuse removed

scores the first name token only (mostly an initial); subtracts false_0 only

read early (title, from L24), **spoken late** (names, L57–61)

Probe scores only the first name token (mostly an initial); all-token, by-role version (addendum 9, done): surname first token L40 +0.071 [0.058, 0.085] (1,395 papers; e4b_alltok.md).

 按 deck 讲稿备注翻译（已按复核结果更新）

在标题本身的位置上能读出作者吗？用 lens，几乎读不出：标题最后一个 token 上的标题特异信号只有约 0.01 到 0.03（Stage 11 E4，标题最后一个 token，logit lens 与 public J-lens 读第一个名字 token，真标题 − 5 个假标题平均，全部 9,108 篇，约 0.01–0.03；报告 §6.11 标题位置表；361_stage11/summary/E4_titlepos_lens.csv）。换成跨论文训练的线性 probe 能读出更多：按作者团队分折、并剔除 probe 训练时见过同一标题的论文后复核（剩 1,863 篇，其中目标 896、对照 499（Stage 13 E4b 复核样本，按作者团队分折并剔除 probe 训练时见过同一标题的论文后剩 1,863 篇（目标 896、对照 499、excluded 433、guard 35）；381_stage13/reports/e4b_split_compare.md；381_stage13/summary_cpu_trainstd/E4b_4configs.csv）），L24 约 0.05，到 L56 升到约 0.08（Stage 13 E4b 复核，标题最后一个 token 上的线性 probe，probe 只打分每位作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，target + control 1,395 篇（剔除后全部论文 1,863 篇，E4b 只用其中 1,395 篇）：L24 +0.050、L40 +0.061、L56 +0.075（L24–L60 为 +0.047 到 +0.075），论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第一张表），目标组比对照组高 0.03 到 0.08（同上 E4b 复核，probe 只打分第一个名字 token，引用档内 目标−对照，目标 896、对照 499 篇，L24–L60 为 +0.035（L44）到 +0.078，论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第二张表）。附录里的对照说明这个 probe 信号是这篇论文特有的，不是主题和名字的关联。它和 lens 的结果不矛盾：标题在标题位置就被读进去了，但名字要到 L57–L61 才在名字位置变得可读。一句话：读得早，说得晚。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Stages 1-9 · 20-200 papers

What we saw

- Self-100 fits the final distribution better; author ranking not better
- J-Lens − Vanilla ≈0 (7.4: +0.002; Stage 8: −1.4 pp)(50 / 200 papers)
- Stage 9: only Fit A fitted, stability not tested

Overview · Line B

Stages 10-11 · 9,108 papers

What scale showed

- Jacobian lenses: top-10 rate 15–18% at L48 vs 1% for logit lens(9,108 papers; X3_means.csv)
- Extra title-specific signal only +0.01–0.03(L24–L48; X3_means.csv), not target-specific
- At L62 the plain logit lens is best
- Linear probe at the title token: +0.05 → +0.08 (re-checked) (E4b, scores only the first name token; e4b_trainstd_compare.md), paper-specific

Line B: the information is there, but not in a form the lenses read

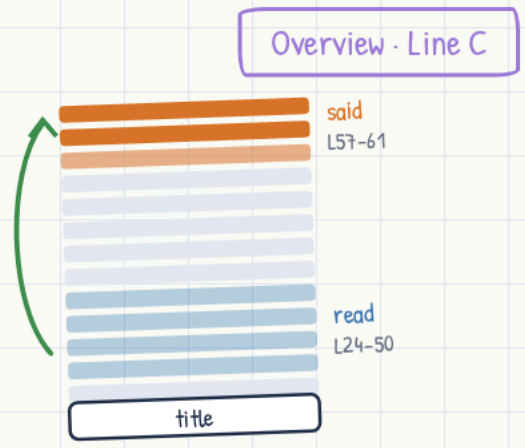
Both phases agree: no lens reveals hidden paper knowledge in middle layers. Scale adds the positive side: a trained probe can decode it at the title, so the limit is the readout, not the absence of information.

 新写讲稿

B 线的小结。小样本阶段看到：Self-100 更贴近最终分布，但作者排名没有更好；J-Lens 减 Vanilla 约为 0（7.4 为 +0.002（Stage 7.4，J-Lens − Vanilla 标题优势，7 层积分，50 篇，+0.002 [−0.008, +0.012]；351_stage7_4/summary/jlens_increment_bootstrap.csv 行 integrated），Stage 8 为 −1.4 个百分点（Stage 8D，L56 J-Lens − Vanilla 标题优势，200 篇，−1.38 pp [−3.48, +0.68]；351_stage8/stage8D/summary/jlens_minus_vanilla.csv））；Stage 9 只拟合了 Fit A，稳定性没有检验。全量阶段看到：Jacobian lens 在 L48 的前 10 名比例为 15–18%，logit lens 为 1%（Stage 10 X3，真标题，全部 9,108 篇，L48 前 10 命中率：三种 Jacobian lens 14.7%–18%，logit lens 1.1%；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv）；多出的标题特异信号只有 +0.01 到 0.03（Stage 10 补充 X3，三种 Jacobian lens 减 logit lens 的标题特异信号（真标题 − 5 个假标题平均），L24–L48，全部 9,108 篇，+0.007 到 +0.030，论文 bootstrap 95% CI 均在 0 以上；报告 §6.9 表；351_stage10/summary_extra/X3_pairwise.csv），而且不偏向目标组；L62 时朴素的 logit lens 最好；标题 token 上的线性 probe 从 +0.04 升到 +0.08（Stage 11 E4b 原始版（论文分折、未剔除标题复用），标题最后一个 token 上的 probe，probe 只打分第一个名字 token，真标题 − false_0，目标组 L16 +0.043 到 L52–L56 +0.080/+0.082；论文 bootstrap 95% CI；报告 §6.11 标题位置表 probe 行；361_stage11/summary/E4_probe.csv 列 spec_target），而且是论文特有的。（页面上 +0.04 到 +0.08 是复核前的数字（Stage 11 E4b 原始版（论文分折、未剔除标题复用），标题最后一个 token 上的 probe，probe 只打分第一个名字 token，真标题 − false_0，目标组 L16 +0.043 到 L52–L56 +0.080/+0.082；论文 bootstrap 95% CI；报告 §6.11 标题位置表 probe 行；361_stage11/summary/E4_probe.csv 列 spec_target），复核后为 +0.05 到 +0.08（Stage 13 E4b 复核，标题最后一个 token 上的线性 probe，probe 只打分每位作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，target + control 1,395 篇（剔除后全部论文 1,863 篇，E4b 只用其中 1,395 篇）：L24 +0.050、L40 +0.061、L56 +0.075（L24–L60 为 +0.047 到 +0.075），论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第一张表），结论不变。）两个阶段一致：没有哪种 lens 能在中间层看出隐藏的论文知识；全量阶段补上了正面的一面：训练过的 probe 能在标题位置解码出来，所以限制在读出工具，而不是信息不存在。注意：这个 probe 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9）已完成，见 Stage 13 部分的补充 9 页：L40 姓的第一个 token +0.071 [0.058, 0.085]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Line C

When does it appear, and when is it used?



small samples asked

Which layer peaks? (L56 kept standing out)

→

the full cohort answered

Readable late (L57–61) but read from the title early (L24–50)

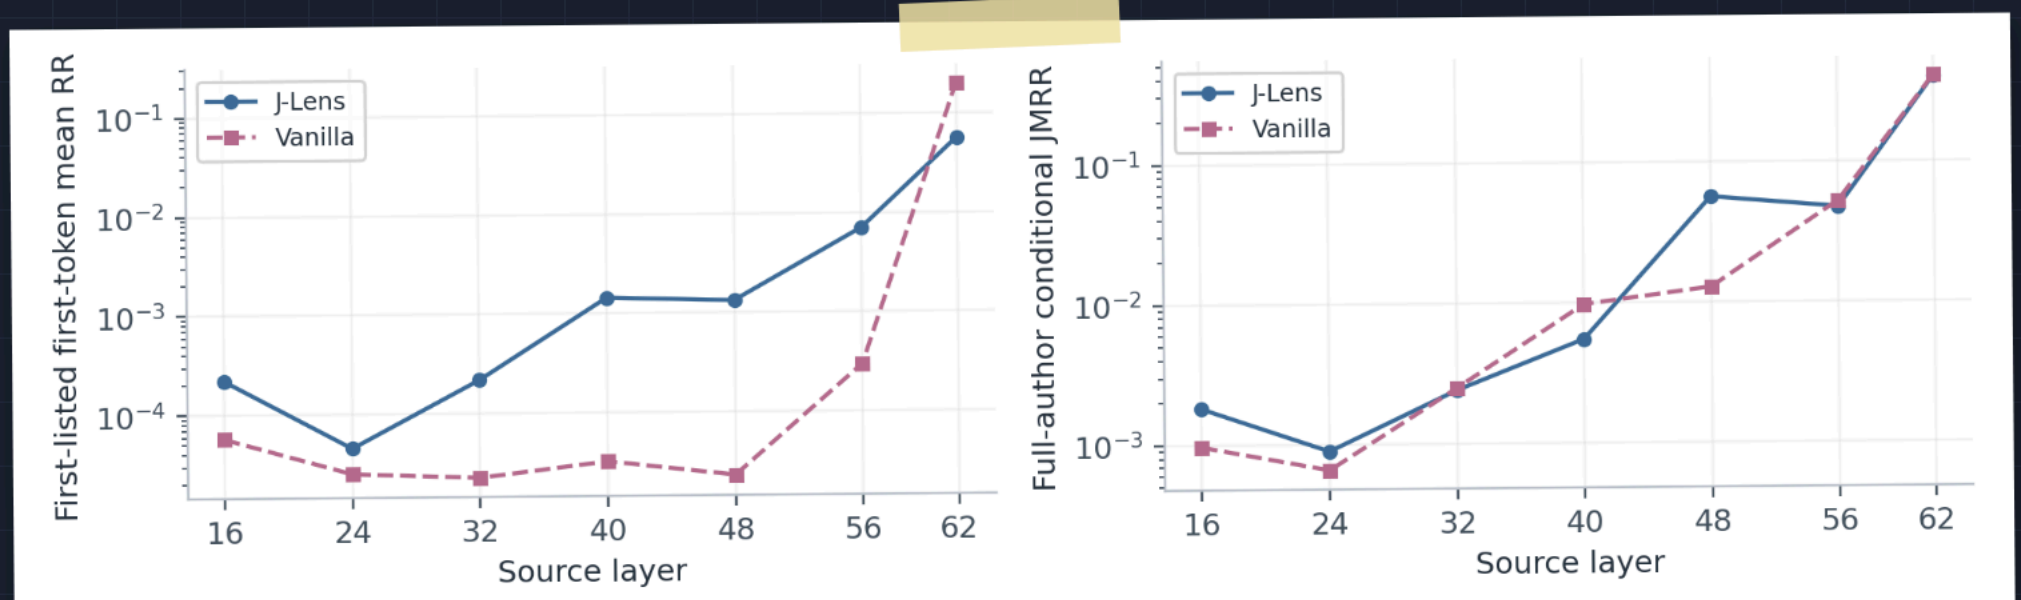
 新写讲稿

C 线的问题是：信号在哪一层出现，又在哪一层被用到？小样本阶段问的是哪一层最高，L56 总是很突出。全量阶段的回答是：名字要到 L57–L61 才变得可读，但标题信息在 L24–L50 就已经被读取了。

Stage 4

First readout: is any author signal there?

20 papers, 93 authors (A8 / B8 / C3 / D1); ~91 s per paper, ~29.5 GiB GPU(351_stage4_readout.log)



Layer profiles: first-listed first-token RR (left) and conditional full-name JMRR (right)

- The pipeline works and J-Lens rises above Vanilla in middle layers
- L56 first-author mean RR 0.0070, median only 0.0009(20 papers; audit_report.md table 1)

One paper = 71% of the L56 mean

Dropping it: 0.0070 → 0.0021.(same file) A layer peak can be a single easy paper, so every later stage adds controls.

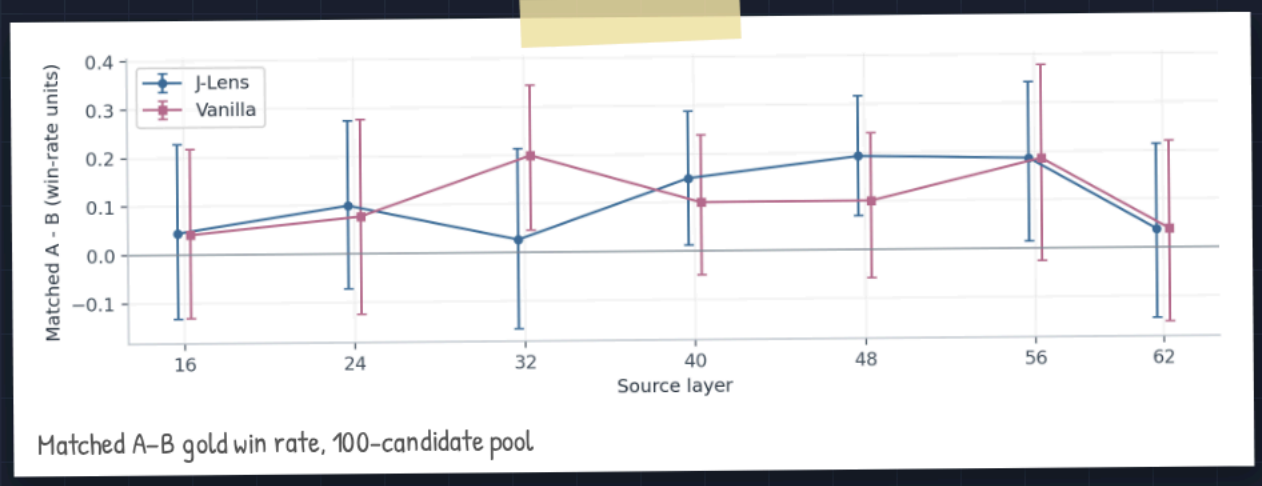
第 42 / 82 页 · Stage 4 · 合并 PPT 自身页面 **新写讲稿**

Stage 4 是第一次读出：作者信号到底在不在？用了 20 篇论文、93 位作者，A 8 篇、B 8 篇、C 3 篇、D 1 篇，每篇约 91 秒、约 29.5 GiB 显存（Stage 4 Benchmark20；351_all/351_stage4_readout.log "STAGE 4 BENCHMARK ===== 20 papers"、authors_scored 93、"Mean seconds per paper 90.68"、gpu=29.5GiB；报告 Stage 4 节表）。流程能跑通，J-Lens 在中间层高于 Vanilla。但 L56 第一作者的平均倒数名次是 0.0070，中位数只有 0.0009；一篇论文就占了 L56 均值的 71%，去掉它均值降到 0.0021（Stage 4，J-Lens L56，第一作者首 token 倒数名次，20 篇：均值 0.00704，中位数 0.00092，最大单篇占总和 71.03%，去掉后均值 0.00215；351_all/351_stage4_artifacts/audit/audit_report.md 表 1 行 L56）。层的峰值可能只是一篇特别好猜的论文，所以之后每个阶段都加了对照。

Stage 7.2 · Line A

Gold vs 100 real false authors

50 matched (same field, token count, year) + 50 random names per paper; 75,000 scored pairs(candidate_pairwise_scores.csv)



Matched A–B gold win rate, 100-candidate pool

- J-Lens A–B: L40 +0.15, L48 +0.19, L56 +0.19 (CIs above 0); L62 +0.04 (spans 0)(20 pairs, matched_ab_bootstrap.csv)
- 7-layer integrated: +0.105 [−0.012, +0.229](20 pairs; recomputed 10-30)
- 156/5,000 false names share the gold first token (ties) (quality.json)
- 100 names → only ~46 distinct first tokens(mean of 50 papers; candidates csv)

Gold beats real names in middle layers for A more than B. But the same names might win under any title: 7.3 tests that.

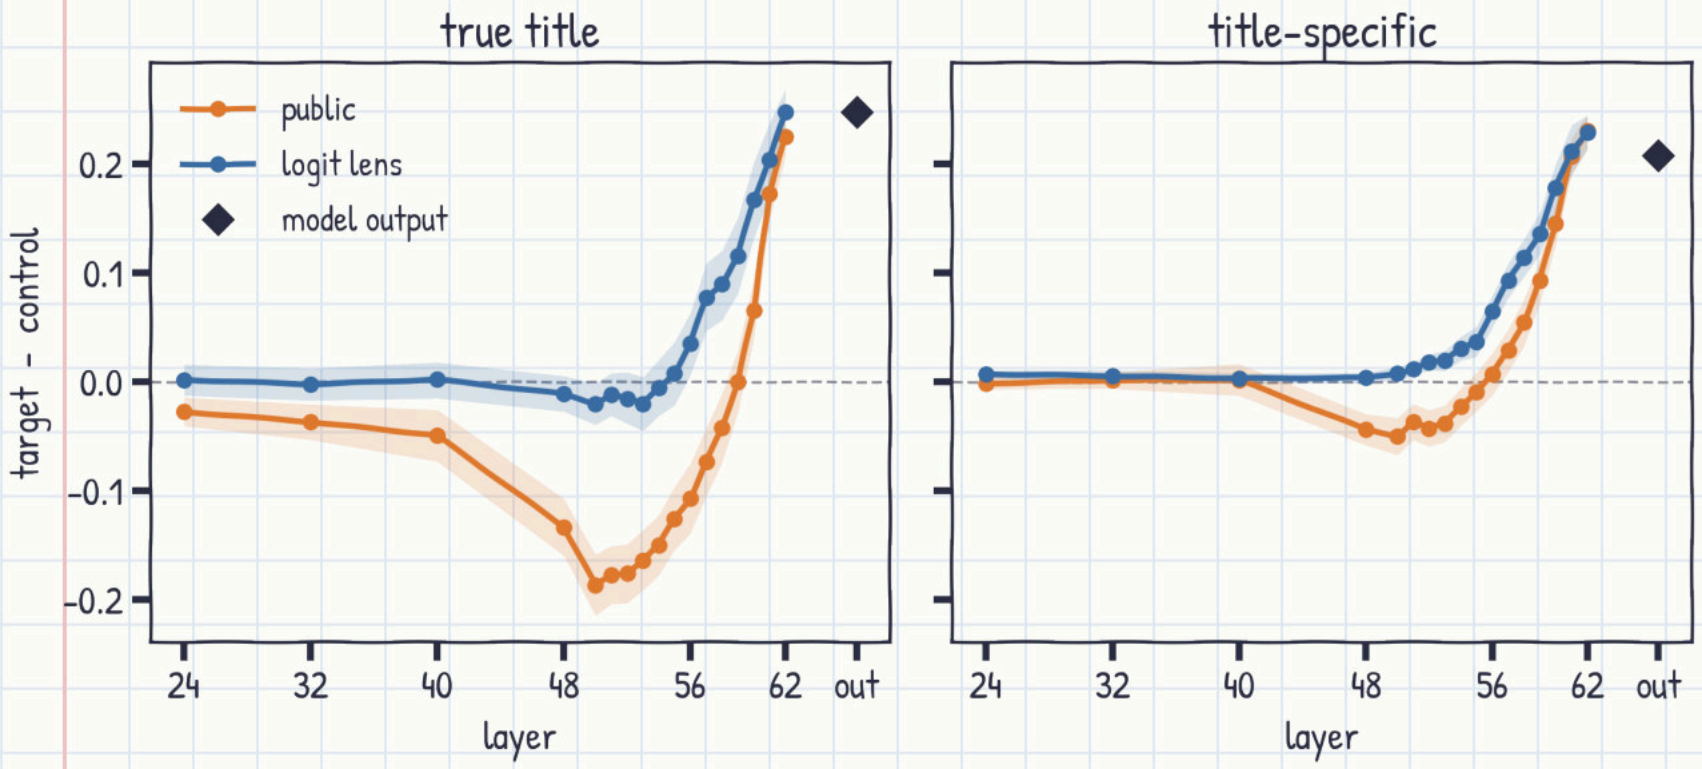
 新写讲稿

Stage 7.2 把正确名字和 100 个真实的错误作者比较：每篇论文 50 个匹配名字（同领域、同 token 数、同年份）加 50 个随机名字，共 75,000 对（Stage 7.2 设计，Pilot50 50 篇 × 100 个错误作者 × 15 种读出 = 75,000；~/jlens_work/07_2_stage7_2/351_stage7_2.py:62-111；351_stage7_2/summary/quality.json；351_stage7_2/summary/candidate_pairwise_scores.csv）。J-Lens 下的 A–B 胜率：L40 +0.15，L48 +0.19，L56 +0.19，区间都在 0 以上；L62 为 +0.04，区间含 0（Stage 7.2，真标题，首 token 金标准胜率，J-Lens，合并池，Pilot50 20 对 A − B，配对 bootstrap 95% CI：L40 +0.150 [0.013, 0.289]、L48 +0.193 [0.071, 0.318]、L56 +0.187 [0.015, 0.345]、L62 +0.038 [−0.144, +0.215]；报告 Stage 7.2 节图 7.2；351_stage7_2/summary/matched_ab_bootstrap.csv）；7 层积分 +0.105 [−0.012, +0.228]（Stage 7.2，7 层积分，J-Lens，合并池，20 对 A − B，配对 bootstrap 95% CI（2026-10-30 按逐对数据重算）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv 行 "7.2 integrated7 A-B jlens pool=combined"）。需要注意 5,000 个错误名字里有 156 个与正确名字共享第一个 token，100 个名字只有约 46 个不同的第一个 token（Stage 7.2，Pilot50 每篇 100 个错误名字（50 匹配 + 50 随机），共 5,000 个；每篇平均 45.76 个不同首 token（方法手册 C 部分由 351_stage7_2/candidates/pilot50_author_candidates.csv 统计）；156 / 5,000 = 3.1% 与金标准首 token 相同记为平局（351_stage7_2/summary/quality.json））。中间层里 A 比 B 更常胜出，但同样的名字可能在任何标题下都胜出，这要由 7.3 来检验。

Stage 10

Target pulls ahead only in the last layers

target − control, within citation bin, 95% CI



Middle layers: **no head start**

L62 / output:

+0.21 to +0.23 (Stage 10, L62 + final L63, 3,734 + 2,182 papers, §6.4)

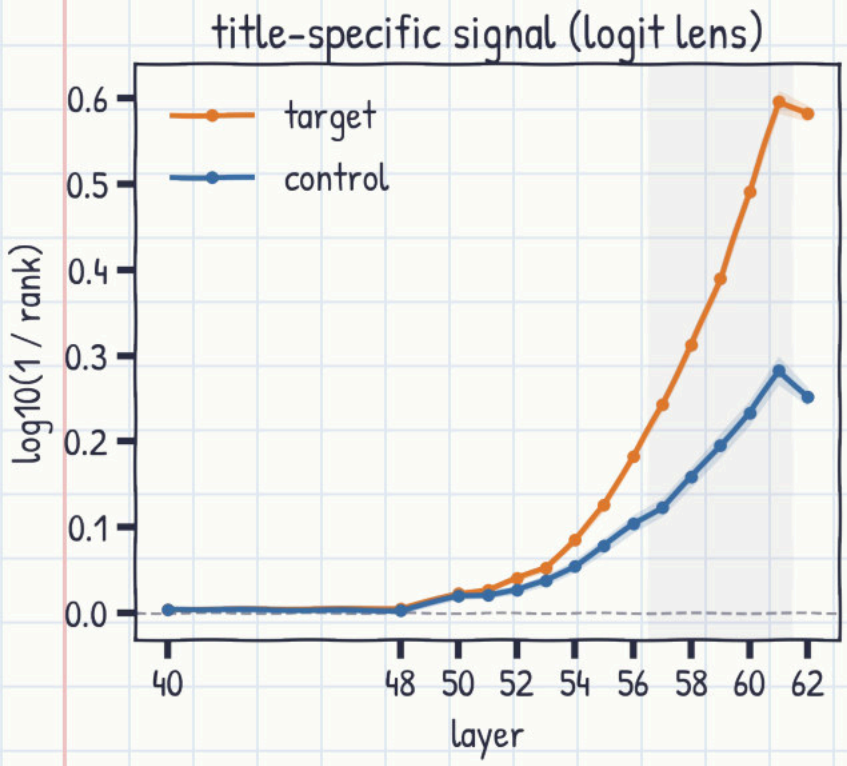
almost all title-specific

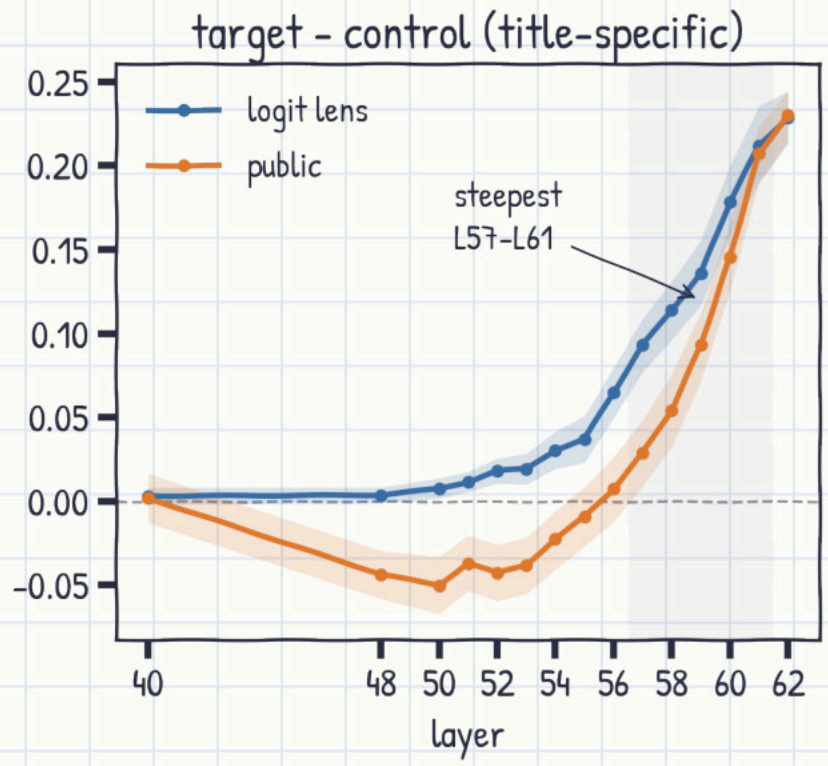
R0 only (no author written): output +0.199 vs +0.207 (Stage 10, 3,423 + 2,151 R0 papers, §6.13)

这是关键的一页：在引用档内看目标组减对照组。左边只看真标题，中间层对 Jacobian lens 甚至略为负。右边看标题特异部分：L56 之前约为 0，在 L62 和输出处为 +0.207 到 +0.231（Stage 10，真标题 − 5 个假标题平均，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），L62 四种读出 +0.228 到 +0.231，最终输出 L63 +0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）。稳健性：目标组 11% 是 R1（写对少数作者），对照组只有 1.5%（目标组 R1 511 / 4,621 篇 = 11%，对照组 R1 34 / 2,220 篇 = 1.5%；351_stage10/reports/r0_sensitivity.md 第一张表；351_stage10/reports/r0_r1_analysis.md §0）；两组都只保留 R0 时，输出处的差是 +0.199（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv）而不是 +0.207（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv），各层形状相同，Stage 11 的曲线也不变。目标组的优势出现得很晚，而且几乎全部是标题特异的。

It builds up over the last dozen layers

fine layers L40–L62 · title-specific signal · 95% CI





Logit lens: target − control

+0.007 at L50

+0.23 at L62 (Stage 10 logit lens, 3,734 + 2,182 papers, §6.10)

steepest rise **L57–L61**

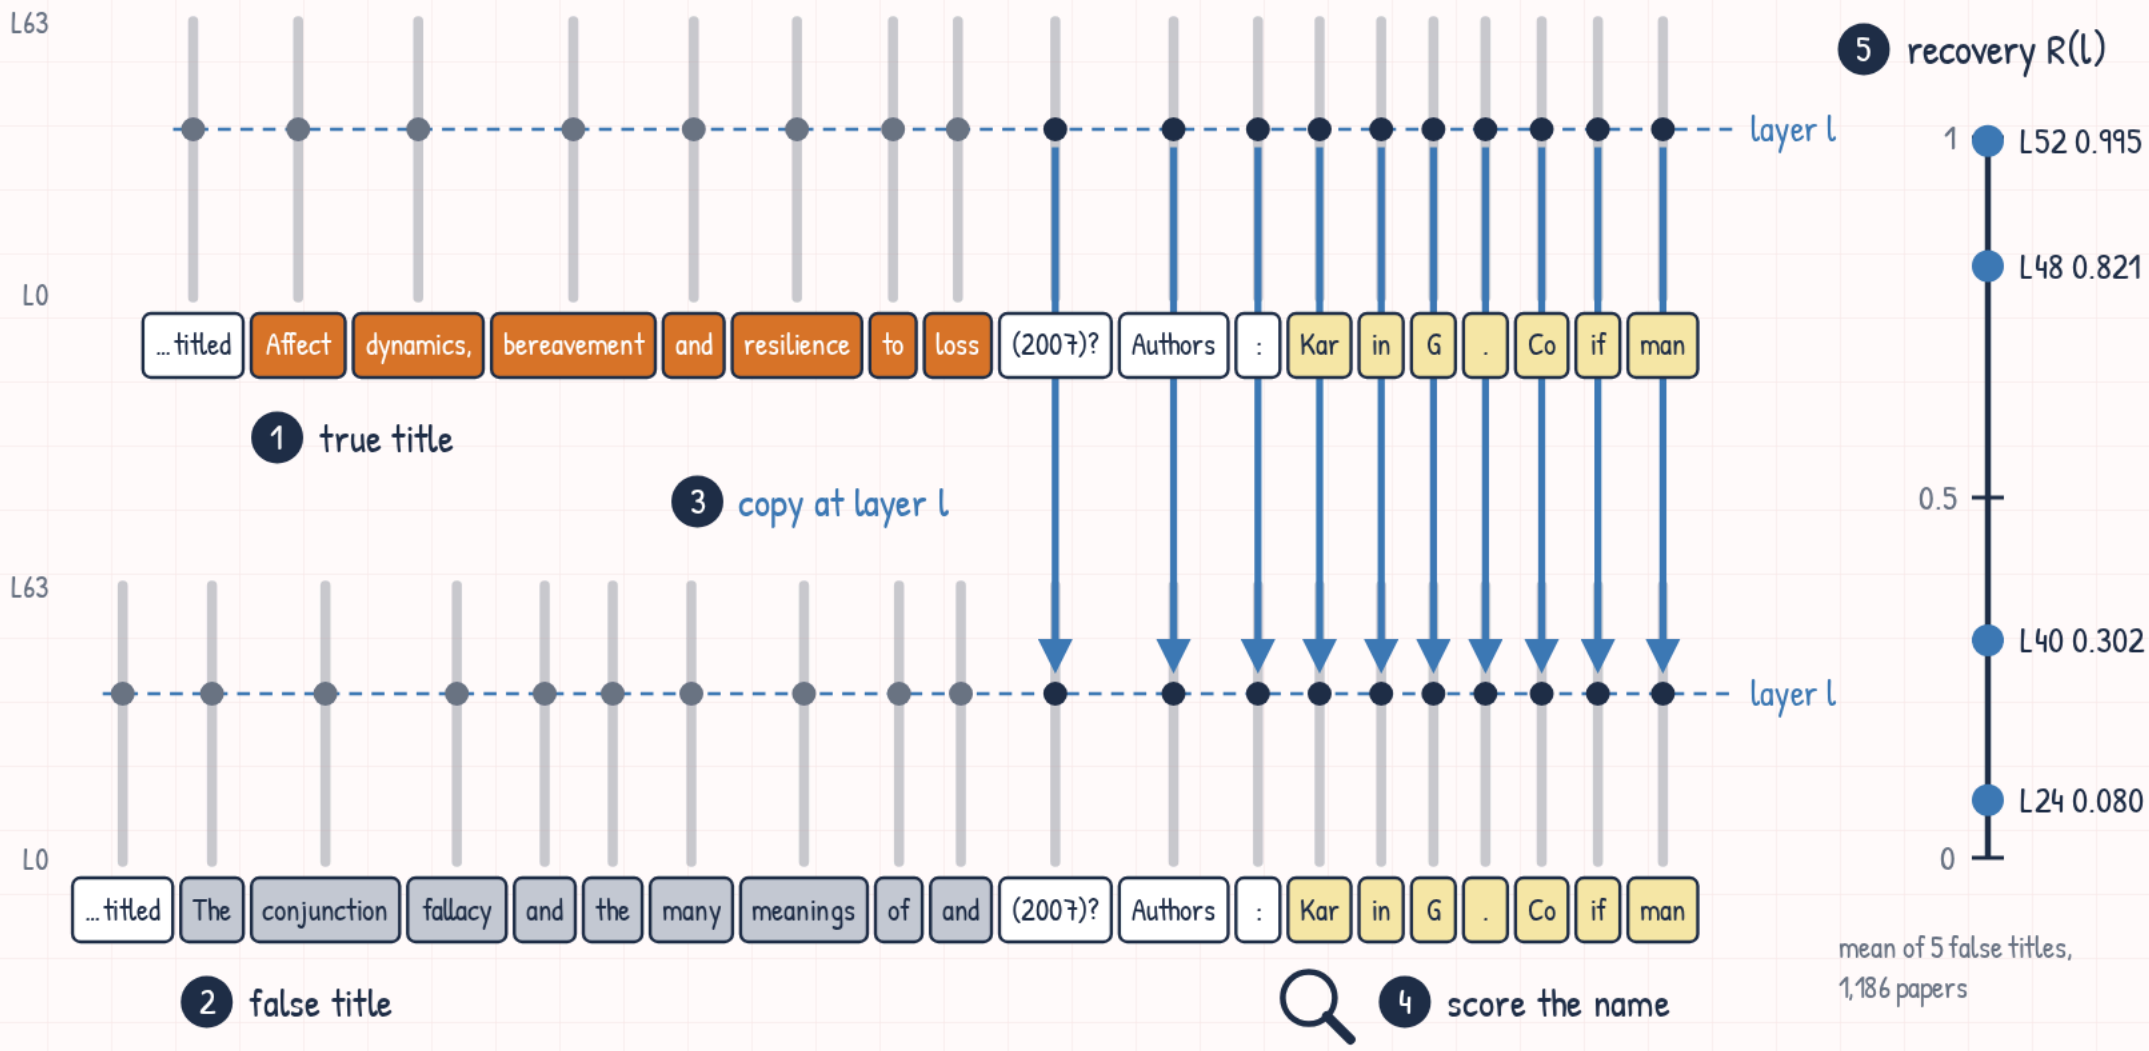
 按 deck 讲稿备注翻译（已按复核结果更新）

细层 L50 到 L61 是后来为 logit lens 和公开 lens 补算的。目标组的优势不是在 L62 突然出现的：logit lens 下，标题特异的目标−对照在 L50 为 +0.007，L54 为 +0.03，L56 为 +0.07，L58 为 +0.11，L60 为 +0.18，L62 为 +0.23（Stage 10 主轮 + 细层扩展，真标题 − 5 个假标题平均，logit lens，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇）：L50 +0.007 [0.001, 0.014]、L52 +0.018、L54 +0.030、L56 +0.065、L58 +0.114、L60 +0.178、L62 +0.229，论文 bootstrap 95% CI；报告 §6.10 图与表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）。公开 lens 到 L54 为负，L57 转正（同上，public J-lens：L48–L54 为 −0.02 到 −0.05，L57 起转正 +0.029 [0.009, 0.048]，L61 +0.207；报告 §6.10 图与表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）。上升最快的是 L57 到 L61，两组都在 L61 达到最高（Stage 10，真标题 − 5 个假标题平均，logit lens 各组均值：目标 L50 +0.022 → L61 +0.596，对照 +0.020 → +0.282（L62 为 +0.583 / +0.252）；报告 §6.10；351_stage10/summary_title/A_group_layer.csv）。

Replacement (patching)

Coifman, Bonanno, Rafaeli (2007)

$$R(l) = (\text{patched} - \text{false}) \div (\text{true} - \text{false})$$



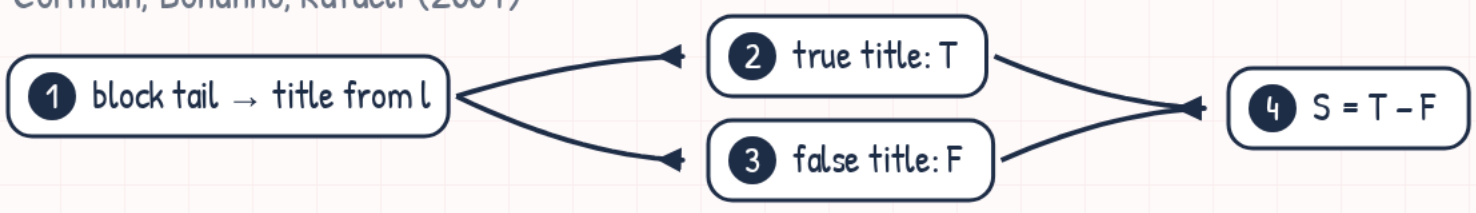
R(l): Stage 13 X6, mean of 5 false titles, all 1,186 papers; 381_stage13/summary_x6/x6_recovery.csv

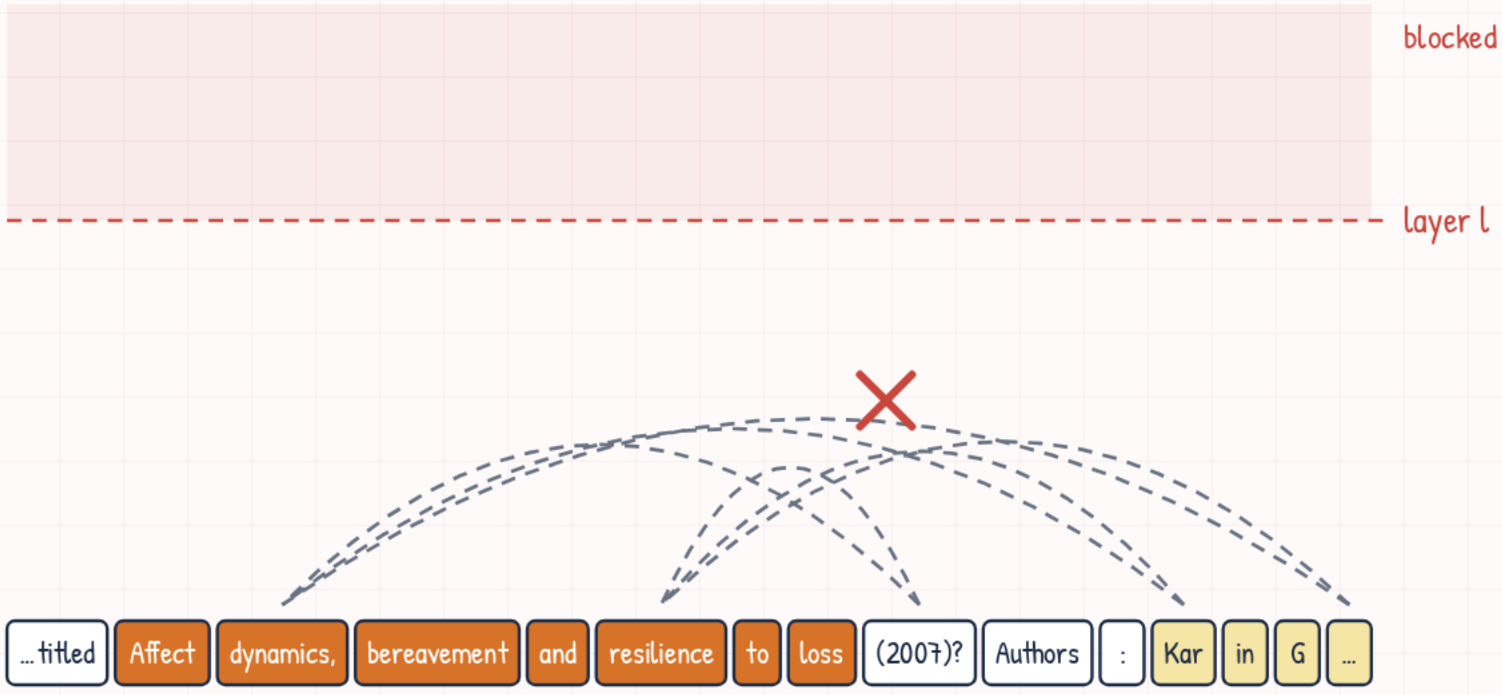
 新写讲稿

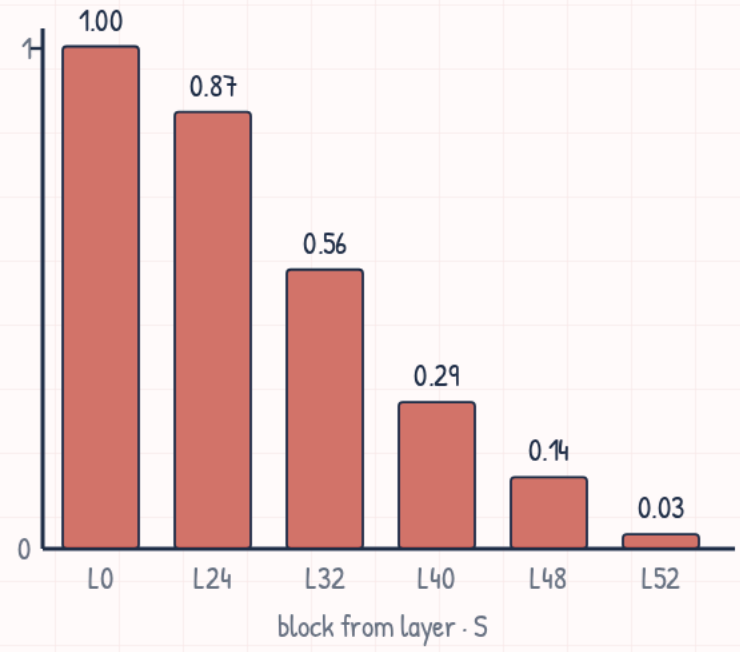
替换（patching）：同一组名字分别接在真标题和假标题后面跑两次；在第 l 层，把真标题运行中标题之后的 token（“(2007)?”、“Authors”、冒号）和名字位置的状态复制进假标题运行，再给名字打分。恢复比例 R(l) = (patched − false) ÷ (true − false)。1,186 篇、5 个假标题平均：L24 0.080、L40 0.302、L48 0.821、L52 0.995（Stage 13 X6，用 5 个假标题分别做 Stage 11 E1 替换，全部 1,186 篇，5 个假标题平均 R：L24 0.080、L40 0.302、L48 0.821、L52 0.995，团队聚类 95% CI；报告 Stage 13 X6 节；381_stage13/reports/x6_report.md（all 表 average 列））， 即到 L52 标题信息已全部进入标题之后的位置。

Knockout (block attention)

Coifman, Bonanno, Rafaeli (2007)







L52: target 0.018 · control 0.051

S(l) = T(l) − F(l)

loss as share of (true − false), 1,186 papers

S(l): Stage 13 X7, 1,186 papers (593 target + 593 control); 381_stage13/reports/x7_report.md

 新写讲稿

阻断（knockout）：从第 l 层起，让标题之后的每个位置都不能注意标题 token，记下名字分数的损失 T；在假标题运行上做同样的阻断得到 F；S = T − F，用真 − 假差距的比例表示。X7（1,186 篇）：从 L0 阻断 S = 1.00，L24 0.87，L40 0.29，L48 0.14，L52 0.029（target 0.018，control 0.051）（Stage 13 X7，S = T − F（真标题运行的阻断损失减去 false_0 运行的同样阻断），÷ 真 − 假差距，全部 1,186 篇：L0 1.004、L24 0.873、L40 0.293、L48 0.143、L52 0.029（target 0.018、control 0.051），团队聚类 95% CI；报告 Stage 13 X7 表；381_stage13/reports/x7_report.md；381_stage13/summary_x7/x7_knockout.csv），所以 L52 之后标题已基本不再被读取。

Stage 11: intervene, do not just read

593 + 593 papers: min(60, n_t, n_c) per citation bin, seed 11 (Stage 11 sample.parquet, §6.11)

patch uses false_0 · knockout masks all heads · all 9,108 for probe and chain (Stage 10 manifest.json)

patch

copy the true-title hidden state into the false-title run at one layer

knock out

block attention to the title tokens (all heads) from layer l to the last layer

probe

linear map from the last title token to the output state

chain

"Authors: A1, A2, ..." instead of each author alone

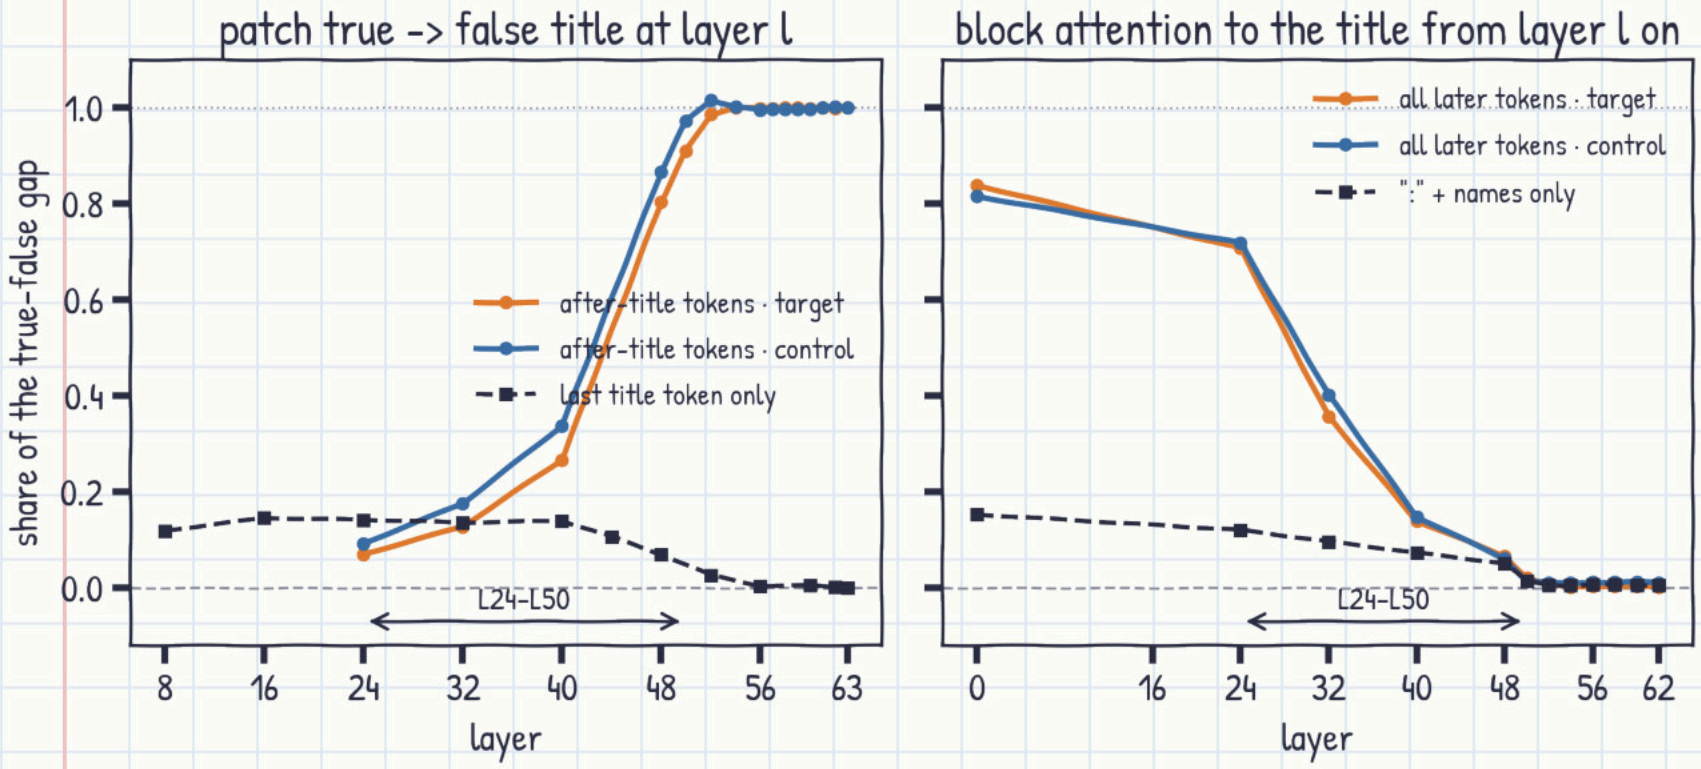
Score: rank of the correct name token at the model output; "share of the true-false gap" = (intervened - false) / (true - false).

Stage 11 把读出问题变成干预实验。用了 593 篇目标论文和 593 篇对照论文（Stage 11 抽样，10 个可比引用档内配平，目标 593 + 对照 593 = 1,186 篇；361_stage11/config/sample.parquet；361_stage11/config/protocol.json），在引用档内匹配。替换：同一篇论文分别用真标题和匹配的假标题运行，在某一层把真标题运行的隐藏状态复制到假标题运行里。阻断：从第 l 层到最后，禁止注意力看标题 token。Probe：训练一个从标题最后一个 token 到输出状态的线性映射。作者链：在前面作者都给出之后，再给每位作者打分。

Stage 11

The title is read in L24-L50, early

model output · share of the true-false gap · CIs about +/-0.02 (Stage 11 E1/E2, 593 + 593 papers, §6.11)



L52+: title no longer needed

the information enters the **name positions at L44–52**, partly via the tokens right after the title

same timing for target and control

两条因果曲线。左边：把真标题运行中标题之后那些 token（右引号、年份、“Authors:”、名字）的隐藏状态复制到假标题运行里，L40 恢复 29%，L48 恢复 0.825（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L40 0.291 [0.274, 0.308]，L48 0.825 [0.807, 0.842]；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all）），L52 起全部恢复（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L52 0.996 [0.989, 1.003]；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））；只复制标题最后一个 token 只恢复约 12%（Stage 11 E1t，只替换标题最后一个 token，真标题→false_0，最终输出恢复比例，全部 1,186 篇 L8–L40 为 0.12–0.15，L56 0.004；报告 §6.11 恢复比例图虚线；361_stage11/summary/E1t_recovery.csv）。右边：从 L0 起阻断对标题的注意力，去掉 83% 的效应；从 L32 起 37%，从 L48 起 6%，从 L52 起为 0（Stage 11 E2 阻断，标题之后全部位置从第 l 层起不能注意标题，最终输出损失比例（÷ 真标题 − false_0 差距），1,186 篇，L0 0.831 [0.801, 0.862]、L32 0.372、L48 0.064、L52 0.007 [0.001, 0.013]；报告 §6.11 阻断图；361_stage11/summary/E2_knockout.csv（group=all））。只阻断冒号和名字位置最多去掉 15%（Stage 11 E2n，只阻断 “:” 和名字位置对标题的注意力，从 L0 起，最终输出损失比例，1,186 篇，0.153 [0.136, 0.172]；报告 §6.11 阻断图虚线；361_stage11/summary/E2n_knockout.csv），所以页面上说：信息在 L44–52 进入名字位置，部分经由标题之后的 token。（已复核：被复制的 token 里包括名字位置本身。Stage 12 P1 逐位置替换显示，信息主要汇集在名字位置上：只换名字位置在 L52 恢复 0.847，只换冒号最多 0.17（Stage 12 P1 逐位置替换，真标题→false_0，最终输出名字 token 恢复比例，Stage 11 样本 1,186 篇：只换名字位置 L48 0.61、L52 0.847，单个位置最大为 “:” L52 0.172 [0.156, 0.187]；报告 Stage 12 节 P1 表；371_stage12/summary/P1_patch_pos.csv）；X6 用 5 个假标题重做，时间不变，L48 恢复约 0.82，L52 起约 1.0（Stage 13 X6，用 5 个假标题分别做 Stage 11 E1 替换，全部 1,186 篇，5 个假标题平均 R：L24 0.080、L40 0.302、L48 0.821、L52 0.995，团队聚类 95% CI；报告 Stage 13 X6 节；381_stage13/reports/x6_report.md（all 表 average 列））。）目标组和对照组的曲线相同。

Stages 1–9 · 20–200 papers

What we saw

- Stage 4 peak at L56 driven by one paper (71%)(audit_report.md)
- 7.2: A–B win-rate positive at L40–L56
- 7.3, 8: L56 title advantage; L56 became the primary layer

Stages 10–11 · 9,108 papers

What scale showed

- L56 is where it *starts*; steepest rise L57–L61
- Patching: copying tail states recovers 80–87% at L48, 99.6% from L52(Stage 11 E1, 593 + 593; x6_report.md)
- Knockout: blocking the title from L52 on costs nothing

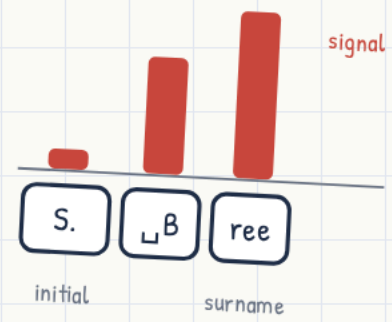
Line C: "read early, spoken late"

L56 was a real landmark, but not the peak. Interventions add what readouts cannot: the title is consumed in L24–50, and the answer only becomes readable at the name a dozen layers later.

C 线的小结。小样本阶段看到：Stage 4 的 L56 峰值由一篇论文撑起（71%）（Stage 4，J-Lens L56，第一作者首 token 倒数名次，20 篇，最大单篇占总和 71.03%；351_all/351_stage4_artifacts/audit/audit_report.md 表 1 行 L56；报告 Stage 4 节）；7.2 中 A–B 胜率在 L40–L56 为正；7.3 和 Stage 8 的标题优势在 L56，于是 L56 成了主要层。全量阶段看到：L56 是开始上升的地方，上升最快的是 L57–L61；替换标题之后的 token 状态在 L48 恢复 80–87%（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例，L48 目标 593 篇 0.803、对照 593 篇 0.866（全部 0.825）；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv），L52 起恢复 0.996（Stage 11 E1 替换，真标题→false_0，标题之后全部位置，最终输出名字 token 恢复比例（均值比），目标 593 + 对照 593 篇，L52 0.996 [0.989, 1.003]（目标 0.986、对照 1.016）；报告 §6.11 恢复比例图；361_stage11/summary/E1_recovery.csv（group=all））；从 L52 起阻断标题几乎没有损失。L56 是真实的路标，但不是峰值；干预实验补上了读出看不到的东西：标题在 L24–50 被读取，答案要到十几层之后才在名字位置变得可读。（已复核：页面中“复制标题之后的 token 状态”包含名字位置本身；Stage 12 P1 和 X6 显示信息主要汇集在名字位置上，L52 起完成。）

Line D

Which token carries it?



small samples asked

First token or the rest of the name?

→

the full cohort answered

Depends on name format; the information enters the name positions at L44–52, partly via the tokens right after the title; co-authors partly replace the title

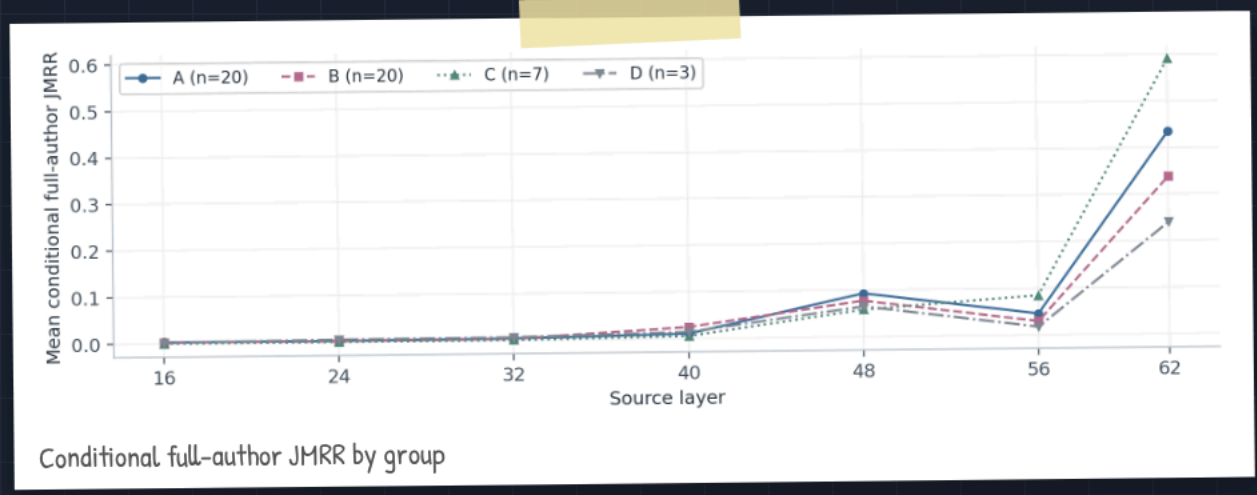
 新写讲稿

D 线的问题是：哪个 token 带着信号？小样本阶段问的是：是名字的第一个 token，还是名字的其余部分？全量阶段的回答是：取决于名字的格式；信息在 L44–52 进入名字位置，部分经由标题之后的 token；前面的合作者会部分代替标题的作用。（这一点已按 Stage 12 P1 和 X6 复核。）

Stage 6 · Line D

From first token to the full name

50 papers, 227 authors, 972 name tokens(token_layer_scores.csv); every listed author scored with teacher forcing



Conditional full-author JMRR by group

Group	Integrated JMRR(integrated_group.csv)
A (20)	0.085 [0.075, 0.096]
B (20)	0.068 [0.057, 0.080]
C (7)	0.106
D (3)	0.050

L62 A–B +0.097 [0.028, 0.163]; Vanilla also +0.091(20 pairs, matched_ab_bootstrap.csv)

Positive, but each token after the first is given the correct prefix. Next: split first token from the rest (7.1).

第 52 / 82 页 · Stage 6 · Line D · 合并 PPT 自身页面 新写讲稿

Stage 6 从第一个 token 扩展到完整名字：50 篇论文、227 位作者、972 个名字 token（Stage 6，Pilot50；351_stage6/raw/token_layer_scores.csv（方法手册统计）；351_stage6/summary/summary.json），所有列出的作者都用教师强制打分。条件完整作者 JMRR：A 组 0.085 [0.075, 0.096]，B 组 0.068 [0.057, 0.080]，C 组 0.106，D 组 0.050（Stage 6，J-Lens 条件完整作者 JMRR，7 层积分，各组论文均值（A 20、B 20、C 7、D 3 篇），论文 bootstrap 95% CI；报告 Stage 6 节图 6.1；351_stage6/summary/integrated_group.csv）。L62 上 A–B 为 +0.097 [0.028, 0.163]，Vanilla 也是 +0.091（Stage 6，条件全名 JMRR，L62 匹配 A − B，20 对：J-Lens +0.0966 [0.0282, 0.1630]，Vanilla +0.0907 [0.0161, 0.1676]，配对 bootstrap 95% CI；351_stage6/summary/matched_ab_bootstrap.csv 行 layer=62）。结果为正，但第一个 token 之后的每个 token 都已经给出了正确的前缀，所以下一步要把第一个 token 和其余部分分开（7.1）。

Stage 7.1 · Line D

The A–B gap sits on the rest of the name

CPU-only re-analysis of Stage 6; 10,000 pair-bootstrap draws



Integrated A–B JMRR by token position

Endpoint	A–B (7 layers)(20 pairs; layer_and_integrated_effects.csv)
First token	+0.001 [−0.011, +0.015]
Continuation	+0.021 [+0.002, +0.039]
All tokens	+0.017 [+0.003, +0.030]

At L62: first +0.014 (12/20 pairs) vs continuation +0.121 (15/20)(layer_position_effects.csv)

With a title contrast (addendum 13 C-1): holds at the output (+0.244) and at L62 (+0.278 logit, +0.317 public J-lens); the public J-lens 6-layer mean is not significant (+0.077 [−0.021, +0.180])(20 pairs, rest of the name; c13_C1.md)

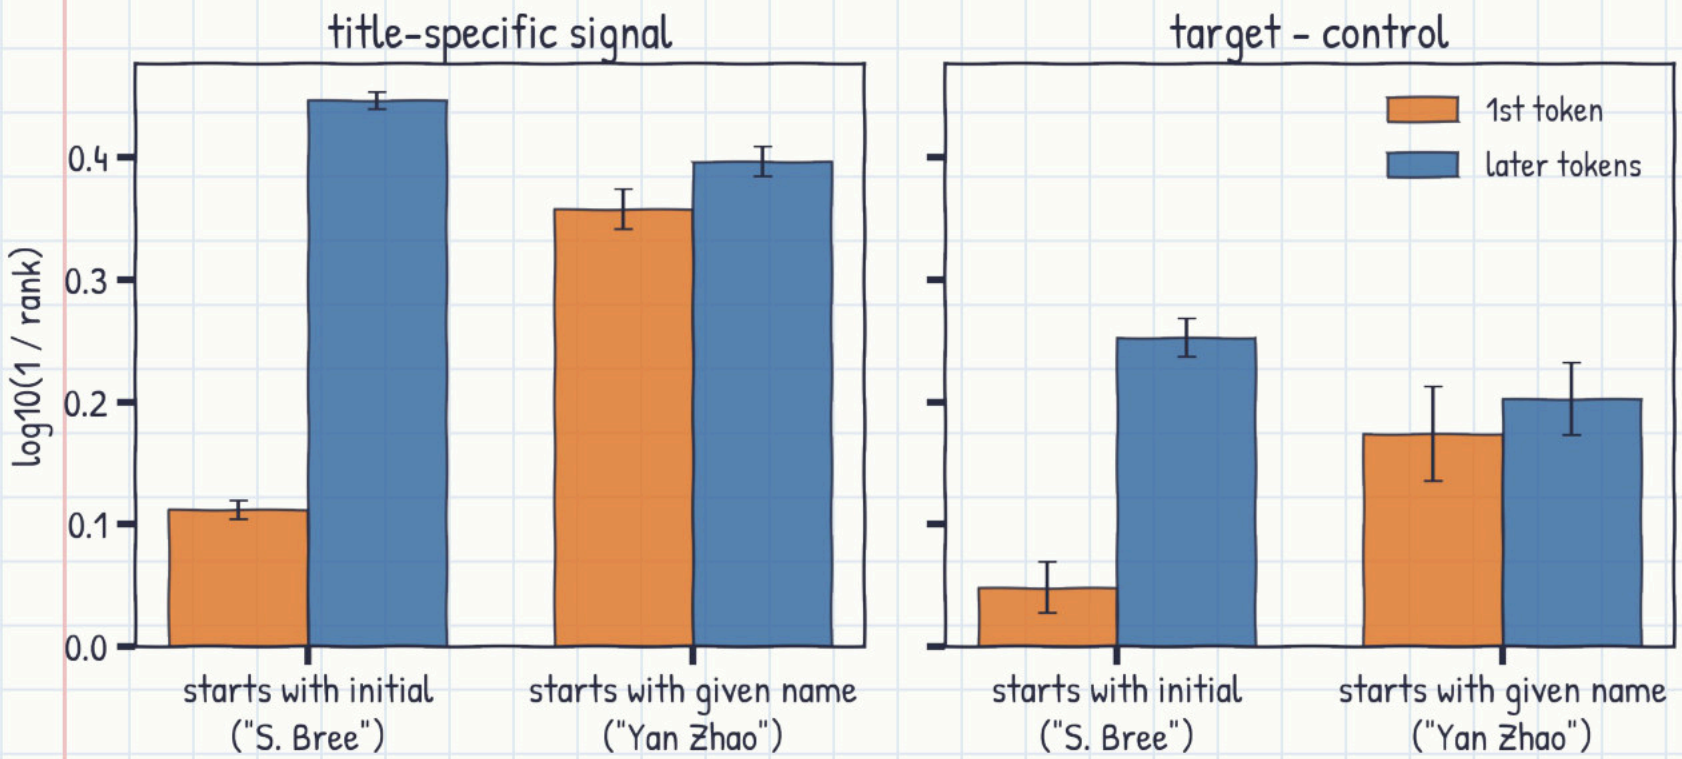
Completing a name is easier than starting it. A continuation gap cannot show unaided recall. **Open:** is this about initials vs surnames?

第 53 / 82 页 · Stage 7.1 · Line D · 合并 PPT 自身页面 **新写讲稿**

Stage 7.1 只用 CPU 重新分析 Stage 6，做了 10,000 次配对 bootstrap（Stage 7.1 设计，种子 35171；~/jlens_work/07_1_stage7_1/351_stage7.py:14,86-87,181）。7 层积分的 A−B：第一个 token +0.001 [−0.011, +0.015]，后续 token +0.021 [+0.002, +0.039]，全部 token +0.017 [+0.003, +0.030]（Stage 7.1，J-Lens JMRR 7 层积分，匹配 A − B，20 对，配对 bootstrap 95% CI：第一个 token +0.0014 [−0.0114, +0.0149]，后续 token +0.0206 [+0.0022, +0.0385]，全部 token +0.0166 [+0.0026, +0.0299]；报告 Stage 7.1 节表；351_stage7_1/summary/layer_and_integrated_effects.csv）。在 L62，第一个 token +0.014（20 对里 12 对为正），后续 token +0.121（20 对里 15 对为正）（同上，L62：第一个 token +0.0141（12/20 为正），后续 token +0.1215（15/20 为正）；351_stage7_1/summary/layer_and_integrated_effects.csv（layer=62））。补全一个名字比开头更容易，后续 token 上的差距不能说明模型能独立回忆。留下的问题是：这是不是首字母和姓的区别？ 2026-11-06 补（补充 13 C-1，事后）：加上标题对照（真标题 − Stage 10 的 5 个假标题）后，A−B 的差别在模型输出和 L62 上成立，public J-lens 多层平均不显著：名字其余 token 上输出 +0.244 [0.087, 0.398]、logit L62 +0.278 [0.088, 0.483]、public J-lens L62 +0.317 [0.145, 0.506]，public J-lens 6 层平均 +0.077 [−0.021, +0.180]（补充 13 C-1，Pilot50 20 对 A−B，配对 bootstrap 95% CI；381_stage13/reports/c13_C1.md aa_cont 行）。

First token or the rest of the name?

model output · split by name format



Initial: carries little; signal is on the surname

Full given name: carries about as much as the surname

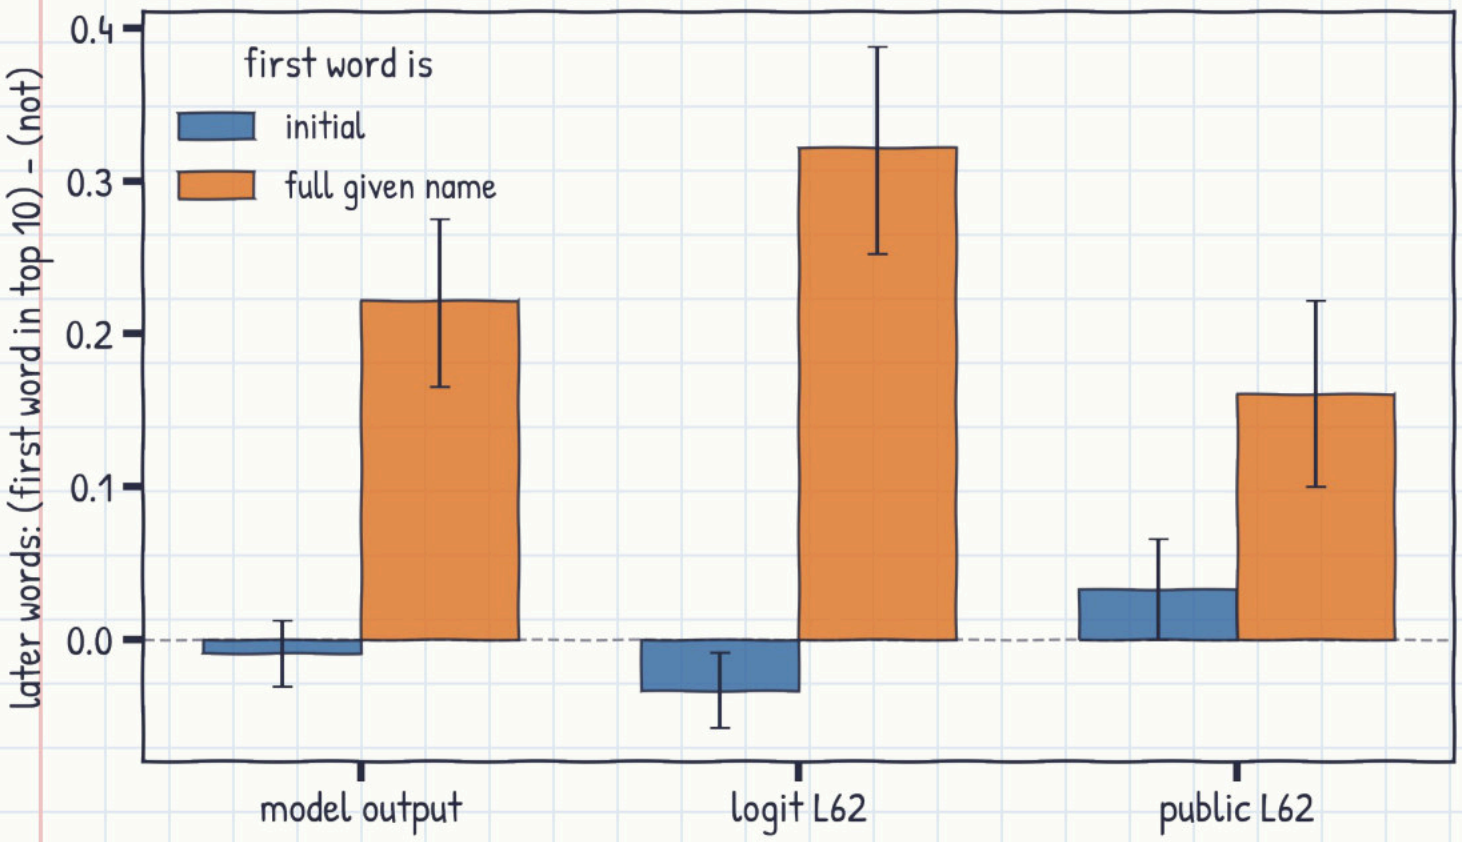
 按 deck 讲稿备注翻译（已按复核结果更新）

信号是否由第一个 token 决定？取决于名字的格式。以首字母开头的名字，首字母本身带的信号很少，信号在包括姓在内的后续 token 上；以完整名开头的名字，名本身带的信号和其余部分差不多。要注意教师强制：后续 token 在每种条件下都已经看到正确的前缀，所以它们的标题特异信号只能来自标题。

Stage 10

Knowing the given name helps with the surname

true title · later words when the first word is / is not in the top 10



Given name in top 10

surname +0.22 (output) (Stage 10, 8,876 authors, §6.7)

+0.32 (logit L62) (same)

Initial in top 10: no help

 按 deck 讲稿备注翻译（已按复核结果更新）

知道了第一个词，其余部分会更容易吗？对完整的名，是的：名进入前 10 名时，姓在输出处高 +0.22，logit lens 在 L62 高 +0.32（Stage 10 §6.7，真标题，完整名开头的 8,876 位作者（名进前 10：678 位），姓（后续 token）平均 log10(1/名次)，进前 10 − 未进，论文聚类 bootstrap 95% CI：最终输出 L63 +0.222 [0.165, 0.275]，logit lens L62 +0.322 [0.253, 0.388]；351_stage10/summary_extra/X1_cond_by_first_role.csv）。对首字母则没有这种帮助。如果把两种格式混在一起，甚至会看到负的效果，因为首字母很好猜，而后面的姓很难。