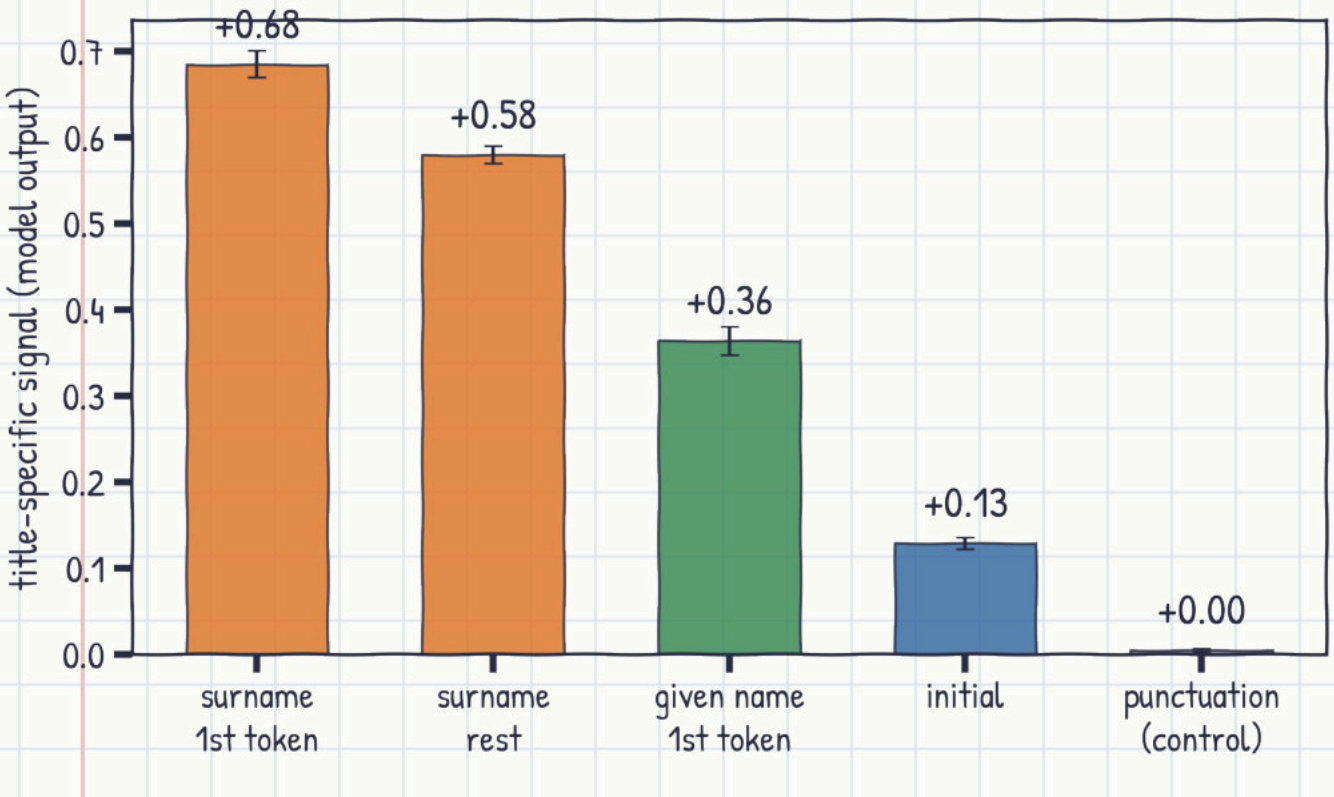
Stage 10

Where the signal sits, and a dose-response

model output





Right: R0/R1 papers, centred within citation bin; Spearman rho = 0.27, p < 0.001. (Stage 10, 8,894 papers, §6.6)

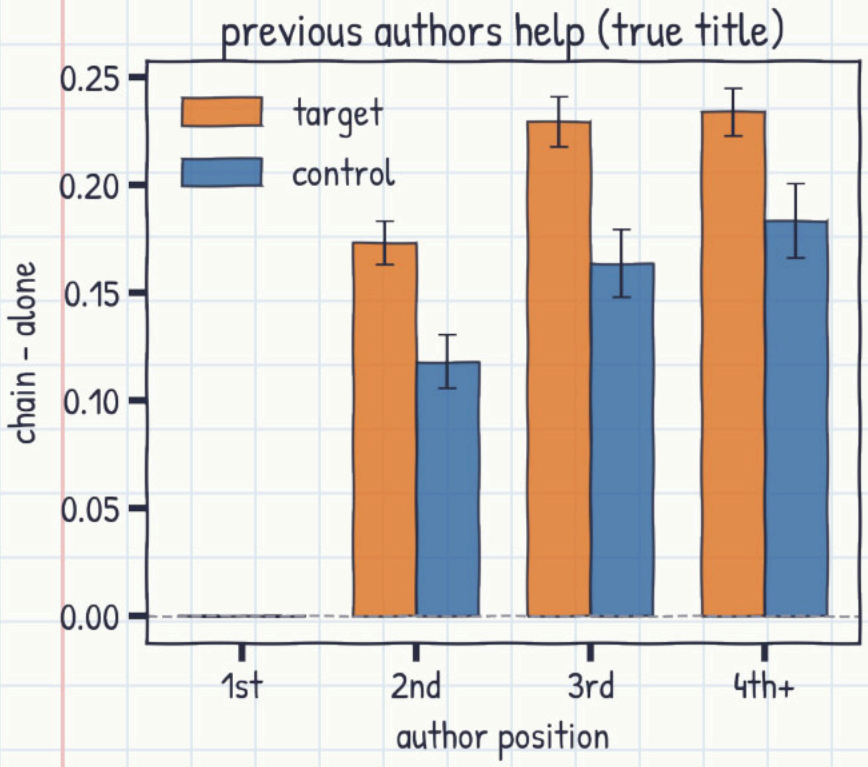
 按 deck 讲稿备注翻译（已按复核结果更新）

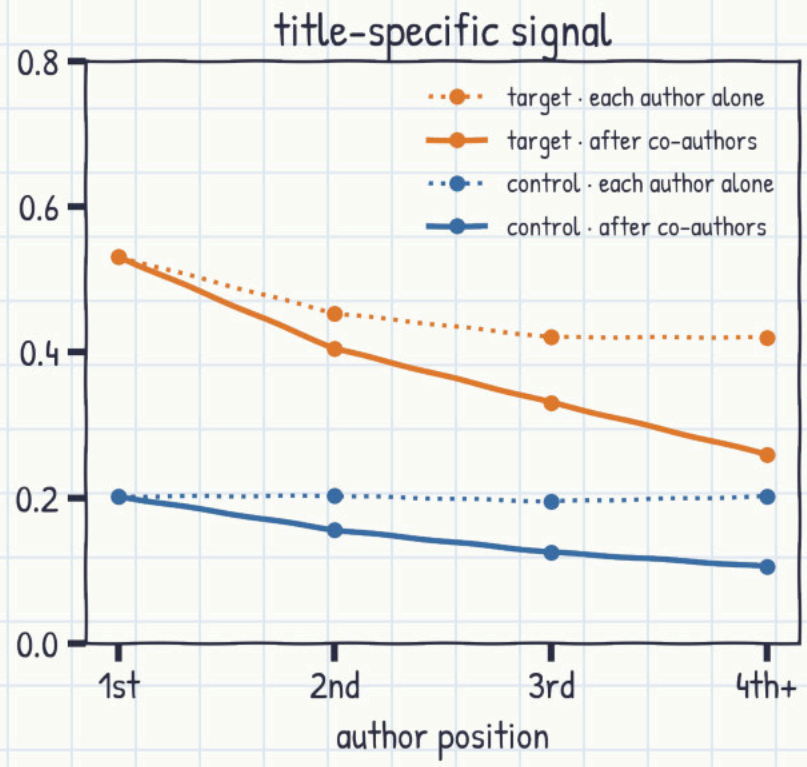
左图是输出处按 token 角色分的标题特异信号：姓的第一个 token 最多，首字母最少，标点约为 0，这是阴性对照。右图是：在所有写不出作者的论文里，多选题答对的顺序越多，模型输出越好（Spearman 0.27）（Stage 10，真标题，最终输出 L63，引用档内中心化的平均 log10(1/名次) 与多选题答对顺序数 0–4，R0/R1 论文 8,894 篇，引用档内 Spearman ρ = 0.268（p < 0.001）；报告 §6.6；351_stage10/summary/C_graded_mc_team_a.csv（metric=mean_nlr））。

Stage 11

Co-authors help, and partly replace the title

model output · all 9,108 papers · 95% CI (Stage 11 E3, §6.11)





later authors **+0.17 to +0.23** (Stage 11 E3, 4,621 target, §6.11)

title-specific part **shrinks**

target > control still

第 57 / 84 页 · deck 第 19 页 按 deck 讲稿备注翻译（已按复核结果更新）

作者链。当前面的作者已经在上下文里时，后面的作者更容易：目标组高 +0.17 到 +0.23，对照组高 +0.12 到 +0.18（Stage 11 E3 连写 – 单独打分，真标题，最终输出 L63，作者位置 2 到 4+：目标 +0.173 / +0.229 / +0.234（4,073 / 2,978 / 2,030 篇），对照 +0.118 / +0.164 / +0.183，论文 bootstrap 95% CI；报告 §6.11 连写表 gain 列；361_stage11/summary/E3_chain.csv）。但标题的作用变小了：后面目标作者的标题特异信号从 0.42 降到 0.26（Stage 11 E3，目标组第 4 位起作者，标题特异信号（真标题 – 5 个假标题平均，最终输出）单独打分 +0.421 → 连写 +0.260，2,030 篇（第 2 位为 +0.454 → +0.405）；报告 §6.11 连写表 4+ · target 行；361_stage11/summary/E3_chain.csv），因为合作者已经能确定是哪篇论文。在引用档内，目标组仍然高于对照组 +0.11 到 +0.15（Stage 11 E3 连写，标题特异，引用档内 目标−对照，作者位置 2 / 3 / 4+：+0.151 / +0.124 / +0.114；报告 §6.11 连写表；361_stage11/summary/E3_chain.csv）。

Stages 1–9 · 20–200 papers

What we saw

- A–B lives on continuation tokens (+0.021), not the first token (+0.001)(7.1, 20 pairs)
- Open question: is that teacher forcing, initials or surnames?

Stages 10–11 · 9,108 papers

What scale showed

- 73% of names start with an initial(24,739 / 33,780; §6.7), which carries little
- Full given names carry as much as surnames and help predict them (+0.22)(final L63; §6.7)
- Information travels title → name positions (L44–52), partly via tail tokens
- Earlier co-authors make later ones easier, title matters less

Line D: the puzzle from 7.1 is explained by name format

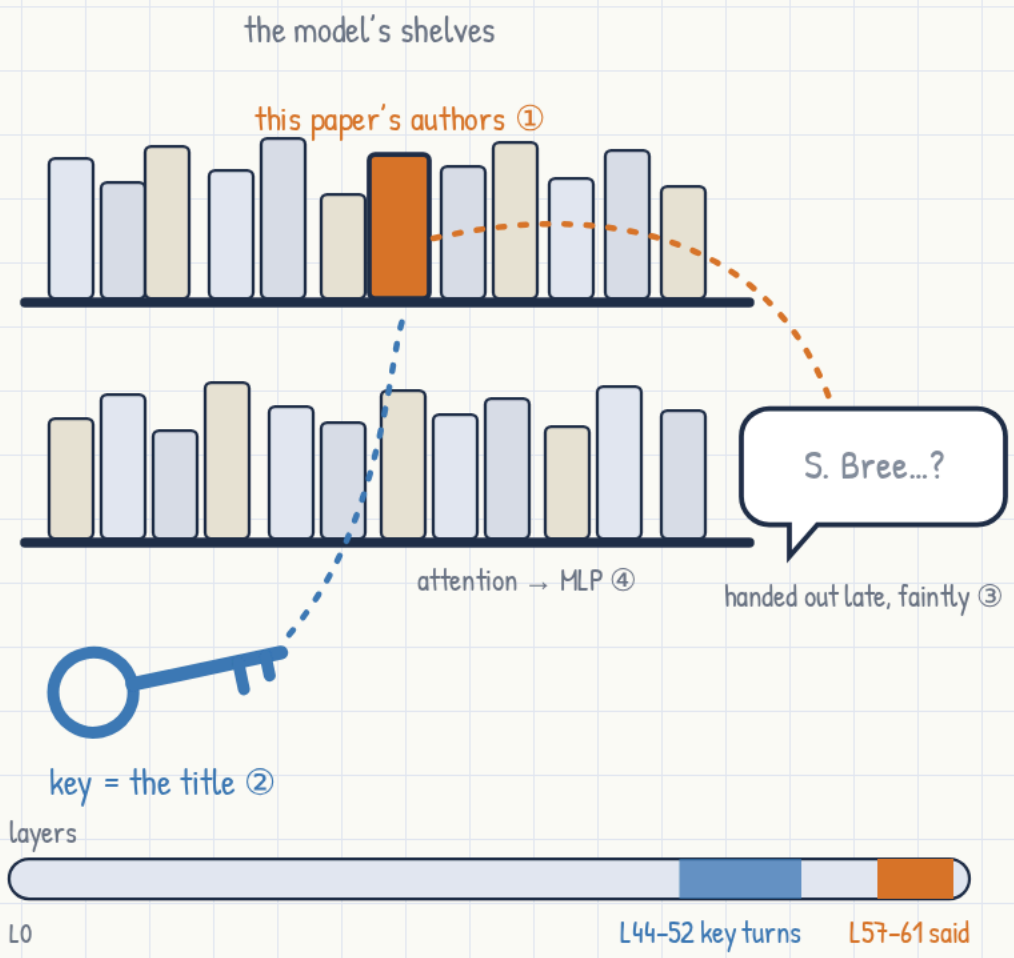
The pilot's "continuation" result was mostly a format effect: for "S. Bree" the surname is a continuation token. Stage 12 P1 (done) patched single positions: the name positions carry the signal (+0.85 at L52), the colon alone little (+0.17)(P1, 1,186 papers; P1_patch_pos.csv).

第 58 / 84 页 · Overview · Line D · 合并 PPT 自身页面 新写讲稿

D 线的小结。小样本阶段看到：A–B 的差在后续 token 上（+0.021），不在第一个 token 上（+0.001）（Stage 7.1，J-Lens JMRR 7 层积分，匹配 A − B，20 对：后续 token +0.0206 [+0.0022, +0.0385]，第一个 token +0.0014 [−0.0114, +0.0149]；351_stage7_1/summary/layer_and_integrated_effects.csv）；当时留下的问题是，这是教师强制造成的，还是首字母和姓的区别。全量阶段看到：73% 的名字以首字母开头（Stage 10 名字格式，24,739 / 33,780 个作者上下文以首字母开头；报告 §6.7；351_stage10/summary_extra/X1_cond_by_first_role.csv 列 n_contexts（readout=final）），首字母本身信息很少；完整的名带的信号和姓相当，还能帮助预测姓（+0.22）（Stage 10 §6.7，完整名开头 8,876 位作者，名进前 10 − 未进，最终输出 L63 姓 +0.222 [0.165, 0.275]，论文聚类 bootstrap 95% CI；351_stage10/summary_extra/X1_cond_by_first_role.csv）；信息从标题在 L44–L52 汇集到名字位置，部分经由标题之后的 token；前面的合作者让后面的作者更容易，标题的作用变小。7.1 的谜题由名字格式解释：像“S. Bree”这样的名字，姓本来就是后续 token。Stage 12 P1 已完成：只换名字位置在 L52 恢复 0.847，只换冒号最多 0.17（Stage 12 P1 逐位置替换，真标题→false_0，最终输出名字 token 恢复比例，Stage 11 样本 1,186 篇：只换名字位置 L48 0.61、L52 0.847，单个位置最大为 “:” L52 0.172 [0.156, 0.187]；报告 Stage 12 节 P1 表；371_stage12/summary/P1_patch_pos.csv）；X6 用 5 个假标题（Stage 13 X6，用 5 个假标题分别做 Stage 11 E1 替换，全部 1,186 篇，5 个假标题平均 R：L24 0.080、L40 0.302、L48 0.821、L52 0.995，团队聚类 95% CI；报告 Stage 13 X6 节；381_stage13/reports/x6_report.md（all 表 average 列））确认了这个时间。

Keys and shelves

Is the book on the shelf, or is the key failing to get it out?



怎么算：spec = true − mean(false_0..4)；recovery(l) = mean_p[P̄_p(l) − F̄_p] / mean_p[T̄_p − F̄_p]；T − C 档内合并 · 9,108 篇（lens）/ 1,186 篇（E1、P1、P2，P1/P2 为 5 个假标题平均）· 出处：X3_means.csv、E1_recovery.csv、p12f_mean5.csv

1 Is the book on the shelf? Yes

True title beats false titles (≈0.44 at L62(§6.9)); a probe on the title token reads paper-specific authors from L24 (re-checked)

Lines A, B · Stage 5, 7.3, 8D, 10, 11

2 Key = the title, read into the name positions at L44–52

Whole prompt: 0.82 at L48, ≈1.0 from L52; name positions alone 0.613 → 0.841 (false_0 0.61 → 0.85); ':' ≤ 0.181 (0.17)(E1, P1 5-title mean; 1,186 papers); knockout after L52 costs almost nothing

Line C · Stage 11, 12 P1

3 Book there but stuck? Not supported

Target − control ≈ 0 at L24–L40, slightly negative at L48 (−0.04 to −0.05), grows only at L57–61 (+0.21 at output(§6.4)): retrieval itself is weak

Lines A, C · Stage 7.2, 10

4 Which shelf? Both, in order

Attention brings the title in at L48 (0.237; false_0 0.231); MLP takes over at L52–56 (0.181, 0.226; false_0 0.178, 0.224)(P2 5-title mean, p12f_mean5.csv). One-layer patching is a lower bound; whether the MLP step is memory lookup is not yet separable

Stage 12 P2

Caveat: a readout not finding it ≠ absent. Stage 13: ':' and name positions hold the task; the title position holds paper attributes and meaning beyond the words, not shown to be paper identity.

【讲稿】这一页用“书架和钥匙”总结前面四条线。第一，书在架上吗？在：真标题比假标题强，L62 约 0.44；标题位置的 probe 从 L24 起就能读出这篇论文的作者信息。第二，钥匙就是标题：整段替换在 L48 恢复 0.82、L52 起约 1.0；只换名字位置从 0.613 升到 0.841（5 个假标题平均；只用 false_0 时 0.61 → 0.85），只换“:”最多 0.181（false_0 版 0.17）；L52 之后再阻断标题几乎没有损失。第三，书在架上但拿不出来？不支持：中间层 target − control 约为 0，只在 L57–61 上升，到输出 +0.21。第四，哪层架子？两步：L48 注意力把标题读进来（0.237，false_0 版 0.231），L52–56 由 MLP 接手（0.181、0.226）。最后提醒：读不出来不等于没有。 【怎么算】spec = true − mean(false_0..4)；recovery(l) = mean_p[P̄_p(l) − F̄_p] / mean_p[T̄_p − F̄_p]；target−control = Σ_b w_b [mean_{target,b} − mean_{control,b}]，w_b = n_t n_c/(n_t+n_c) 归一化 【数据】Stage 10 全部 9,108 篇（lens，名字位置，L62 四种读出 0.436–0.463）；Stage 11/12 样本 1,186 篇（E1、P1、P2，标题之后的位置）；补充 9 标题位置 probe 1,395–1,706 篇 【对照】5 个假标题（Stage 10；P1 / P2 五标题平均，括号内为只用 false_0）；E1 与标题位置 probe 只减 false_0；control 组（同一引用档） 【区间】Stage 10–12 表：论文 bootstrap 2,000 次（在"档 × 组"内对论文有放回重抽，2.5/97.5 分位）；P1 / P2 五标题平均与补充 9：团队整群 bootstrap 2,000 次（按作者团队重抽，2.5/97.5 百分位） 【出处】351_stage10/summary_extra/X3_means.csv；361_stage11/summary/E1_recovery.csv；391_groups/summary_b1_p12f/p12f_mean5.csv；summary_title/B_spec_target_vs_control_within_bin.csv；381_stage13/reports/e4b_alltok.md

Overview

What the small samples taught us to watch for

- **Single-paper leverage**: one paper = 71% of the Stage 4 L56 mean (20 papers)
- **Tail-driven contrasts**: Stage 8 A–B disappears after removing 10 of 100 pairs(8D, matched_pair_differences.csv)
- **Forking paths**: L56 inspected repeatedly, then made primary
- **Candidate artefacts**: 100 false names share ~46 first tokens; 3% tie with gold(7.2 quality.json: 156/5,000)
- **Label noise**: strict "pass" 25.5% in the 0–2 citation bin (label_README.md)
- **Partial coverage**: first-listed author stands in for the team
- **Metric choice**: KL fidelity and author ranking disagree
- **Protocol drift**: plan locked 10-18 14:29 (7-layer integral primary); the 21:14 PROTOCOL switched to L56, both before 8C scoring; who and why open (U28)

Stage 10 answered each one by design: full cohort, every author and token, all layers reported, full-vocabulary ranks, within-bin comparison, frozen inputs with parity checks. What it cannot fix: groups still come from one labelling run of the same model.

 新写讲稿

小样本阶段教会我们要提防的几件事：单篇论文的杠杆，一篇论文占 Stage 4 L56 均值的 71%（Stage 4，J-Lens L56，第一作者首 token 倒数名次，20 篇，最大单篇占总和 71.03%；351_all/351_stage4_artifacts/audit/audit_report.md 表 1 行 L56；报告 Stage 4 节）；尾部驱动的对比，Stage 8 的 A–B 去掉 100 对中的 10 对就消失（Stage 8D RQ2，J-Lens L56 金标准胜率匹配 A–B，100 对，均值 +4.98 pp，按 A–B 降序去掉前 10 对后其余 90 对均值 −0.39 pp（事后诊断）；351_stage8/stage8D/summary/matched_pair_differences.csv（mode=jlens_L56）重算；报告 Stage 8D 节）；分叉路径，L56 被反复查看后才定为主终点；候选伪影，100 个错误名字只有约 46 个不同的第一个 token，3% 与正确名字打平（Stage 7.2，Pilot50 每篇 100 个错误名字（50 匹配 + 50 随机），共 5,000 个；每篇平均 45.76 个不同首 token（方法手册 C 部分由 351_stage7_2/candidates/pilot50_author_candidates.csv 统计）；156 / 5,000 = 3.1% 与金标准首 token 相同记为平局（351_stage7_2/summary/quality.json））；标签噪声，0–2 次引用档的严格通过率为 25.5%（标注包自检，0-2 引用档 796 篇，收紧规则（4/4 且真选项平均概率 ≥ 0.5）多选通过率 25.5%（普通规则 38.6%）；labels_20261015/zhiqi_qwen3-32b_labels_2026-10-15/label_README.md 第 8 行）；覆盖不全，用第一作者代替整个团队；指标选择，KL 保真度和作者排名不一致；协议漂移：分析计划在 10-18 14:29 写定锁定（主终点为 7 层积分），同日 21:14 的 PROTOCOL 改为 L56，两者都早于 8C 打分；改动人和理由待查（U28）。Stage 10 在设计上逐条回应：全量论文、所有作者和 token、报告所有层、全词表名次、引用档内比较、冻结输入并做一致性检查。它没法解决的是：分组仍然来自同一模型的一次标注。

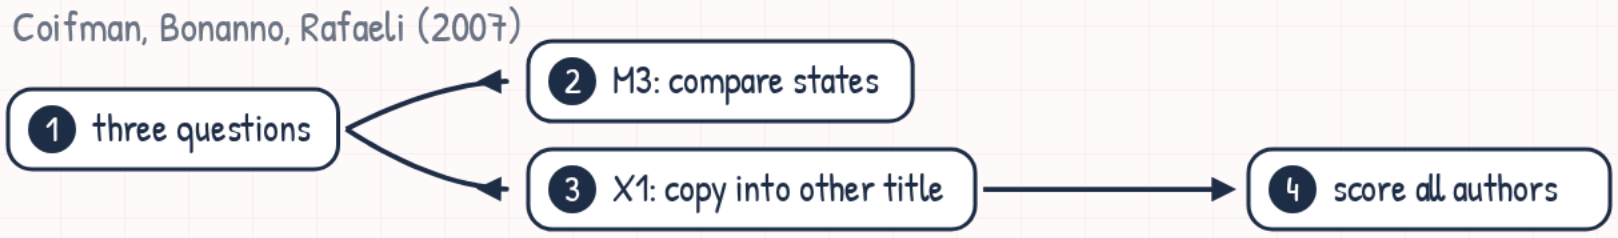
Small vs large, in one table

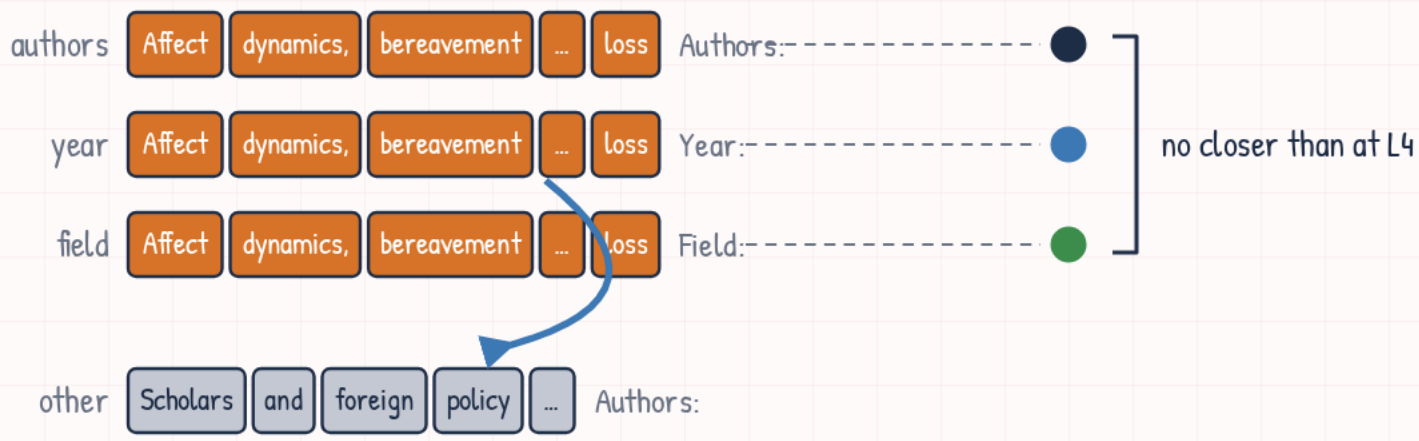
Finding	Stages 1-9 (20-200 papers)	Stages 10-11 (9,108 papers)	Verdict
True title helps	+9.3 pp pilot, +5.2 pp new 200(7.3; 8D RQ1)	≈0.44 title-specific at L62(X3_means.csv)	confirmed
Recognised > not recognised	uncertain, tail-driven	+0.21 at output(§6.4), ≈0 at L24-L40, slightly negative at L48 (−0.04 to −0.05)	confirmed, late only
Same groups (A vs B, R0 only)	A − B as above	+0.20 at output(§6.13), ≈0 at L24-L40, slightly negative at L48; R1 adds strength, not timing	comparable, unchanged
Key layer	L56	starts L56, rises L57-61; read L24-50	refined
J-Lens over Vanilla	no increment	more name shape, no paper identity	consistent
First vs rest of name	gap on continuation	explained by initials vs given names	explained
Citations	low-high inconclusive	monotonic, ρ = 0.451(X2_spearman.csv)	resolved
Lens stability	split-half one split; Stage 9 only Fit A	three Jacobian lenses fitted on different text agree; fit stability rests on Stage 9 Fit A only	only one piece of evidence (Stage 9 Fit A); Fit B not completed

一张表对照小样本和全量。真标题有帮助：Pilot +9.3（Stage 7.3，J-Lens L56，真标题胜率 − 20 个错误标题平均胜率，合并池，Pilot50 50 篇均值 +0.0934 [0.048, 0.140]（2026-10-30 重算区间，B = 20,000），35/50 篇为正；351_stage7_3/summary/paper_null_distribution.csv（pool=combined, mode=jlens_L56）；351_stage7_3/recompute_2026-10-30/stage7_interval_recompute.csv；报告 Stage 7.3 节）、新 200 篇 +5.18 个百分点（Stage 8D RQ1，J-Lens L56，真标题 − 20 个匹配错误标题，200 篇新论文，+5.18 pp [2.93, 7.48]，论文 bootstrap 95% CI；351_stage8/stage8D/summary/primary_questions.csv 行 RQ1_L56_replication；报告 Stage 8D 节），全量 L62 标题特异约 0.44（Stage 10，真标题 − 5 个假标题平均，L62，全部 9,108 篇均值，三种 Jacobian lens 0.436–0.444（public 0.442）；报告 §6.9 表；351_stage10/summary_extra/X3_means.csv），确认。认得出大于认不出：小样本不确定、依赖尾部，全量输出处 +0.21（Stage 10 合并口径（target = A + C 对 control = B + D），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照（共有引用档 目标 3,734 + 对照 2,182 篇），+0.207 [0.195, 0.220]，论文 bootstrap 95% CI；报告 §6.4 表；351_stage10/summary_title/B_spec_target_vs_control_within_bin.csv）、L24–L40 约为 0、L48 略为负（−0.037 到 −0.054，区间不含 0），确认，但只在最后几层。同一分组（A 对 B，只用 R0）：输出 +0.20（Stage 10 只用 R0（A 对 B），真标题 − 5 个假标题平均，最终输出 L63，引用档内 目标−对照，A 3,423 + B 2,151 篇，+0.199 [0.188, 0.212]，论文 bootstrap 95% CI；报告 §6.13 表；351_stage10/reports/r0_sensitivity.md；351_stage10/summary_r0/B_spec_target_vs_control_within_bin_R0.csv）、中间约 0，R1 主要增加强度，时间几乎相同（上升最陡处相同，起点晚 1–2 层），两阶段可比、结论不变。关键层：小样本是 L56，全量是 L56 开始、L57–61 上升、标题在 L24–50 被读取，细化。J-Lens 胜过 Vanilla：小样本没有增量，全量读出更多名字的样子、但没有论文身份，一致。名字第一个 token 和其余部分：小样本差距在后续 token，全量由首字母和完整名的格式差别解释。引用数：小样本低减高没有定论，全量单调上升 ρ = 0.451（Stage 10 补充 X2，标题特异信号（真标题 − 5 个假标题平均，最终输出 L63）对 log10(引用数+1) 的 Spearman ρ，全部 9,108 篇 0.451 [0.433, 0.467]，bootstrap 95% CI；报告 §6.8 表；351_stage10/summary_extra/X2_spearman.csv），解决。lens 稳定性：小样本只有一次拆分、Stage 9 只有 Fit A，全量三把用不同文本拟合的 Jacobian lens（Stage 10 三种 Jacobian lens：public（557 条 WikiText-103）、self100（100 条）、fitA（Stage 9 Fit A 100 条）；351_stage10/config/lenses.json；报告 §6.9）结论一致；但同一把 lens 的拟合稳定性只有 Fit A 一份证据，Fit B 未完成。

Changing the question

Coifman, Bonanno, Rafaeli (2007)





R from	authors	year	field
L24	**0.996**	**0.990**	**0.992**
L40	**0.933**	**0.928**	**0.929**
L48	**0.455**	**0.431**	**0.444**

$$R(l) = (\text{patched} - \text{other}) \div (\text{own} - \text{other})$$

title states copied at layer l; 582 test papers

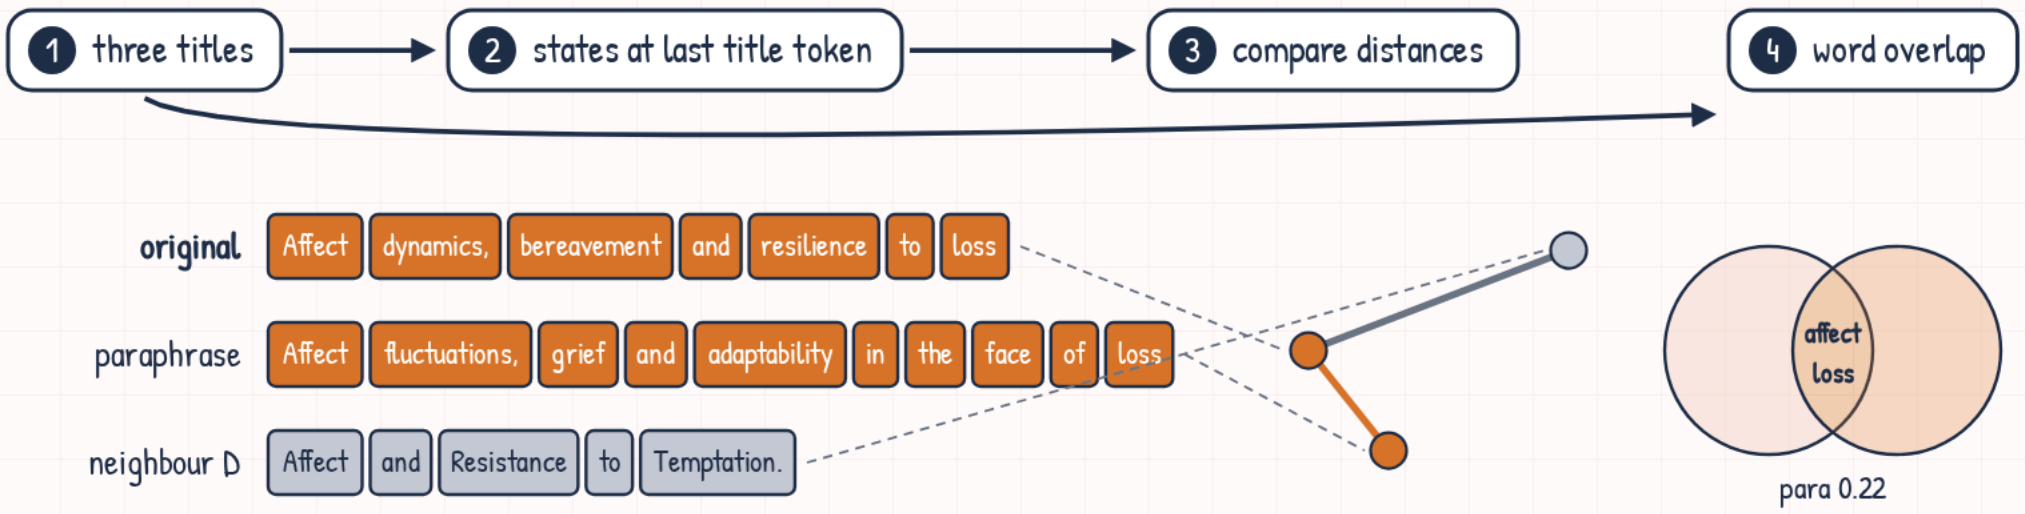
R: Stage 13 X1, all authors (batch 1 item 1), test 582 papers; b1_xall_report.md (old first-author: 0.99 / 0.92 / 0.42)

 新写讲稿

换问题：同一标题分别放进作者、年份、领域三个问题里（M3），比较标题最后位置的状态；它们不比 L4 时更接近，也就是没有超出标题文字本身的“论文身份”状态。X1 把本篇在任一问题下的标题状态复制进另一篇论文标题的作者提示，再给本篇全部作者打分（旧版只看第一作者）：R(l) = (patched − other) ÷ (own − other)，全部作者 L24 约 0.996，L40 约 0.933，L48 约 0.455（补充 10 第 1 项；381_stage13/reports/b1_xall_report.md “X1: R (test, confirmatory) by stratum” 表）（旧版只看第一作者：L24 约 0.99，L40 约 0.92，L48 约 0.42）（Stage 13 X1，测试集 582 篇，R = (patched − other) ÷ (own − other)，来源问题 作者/年份/领域：L24 0.991/0.985/0.992，L40 0.921/0.917/0.915，L48 0.424/0.405/0.417，团队聚类 95% CI；报告 Stage 13 X1 表；381_stage13/reports/x1_report.md test 表），三种来源几乎一样（测试集 582 篇）（Stage 13 X1 调参集/测试集按作者团队各半：测试 582、调参 596 篇；381_stage13/reports/x1_report.md 第 3 行；381_stage13/config/pairs.parquet）。

Paraphrased title (X3)

same paper in other words vs other paper, same words



para 0.22



D 0.14

G′ = cos(orig, para) − cos(orig, D)

+0.32 at L8 · peak +0.46 at L36 (test set)

all-author score, paraphrase − D: +0.229

medians: 0.61 vs 0.15

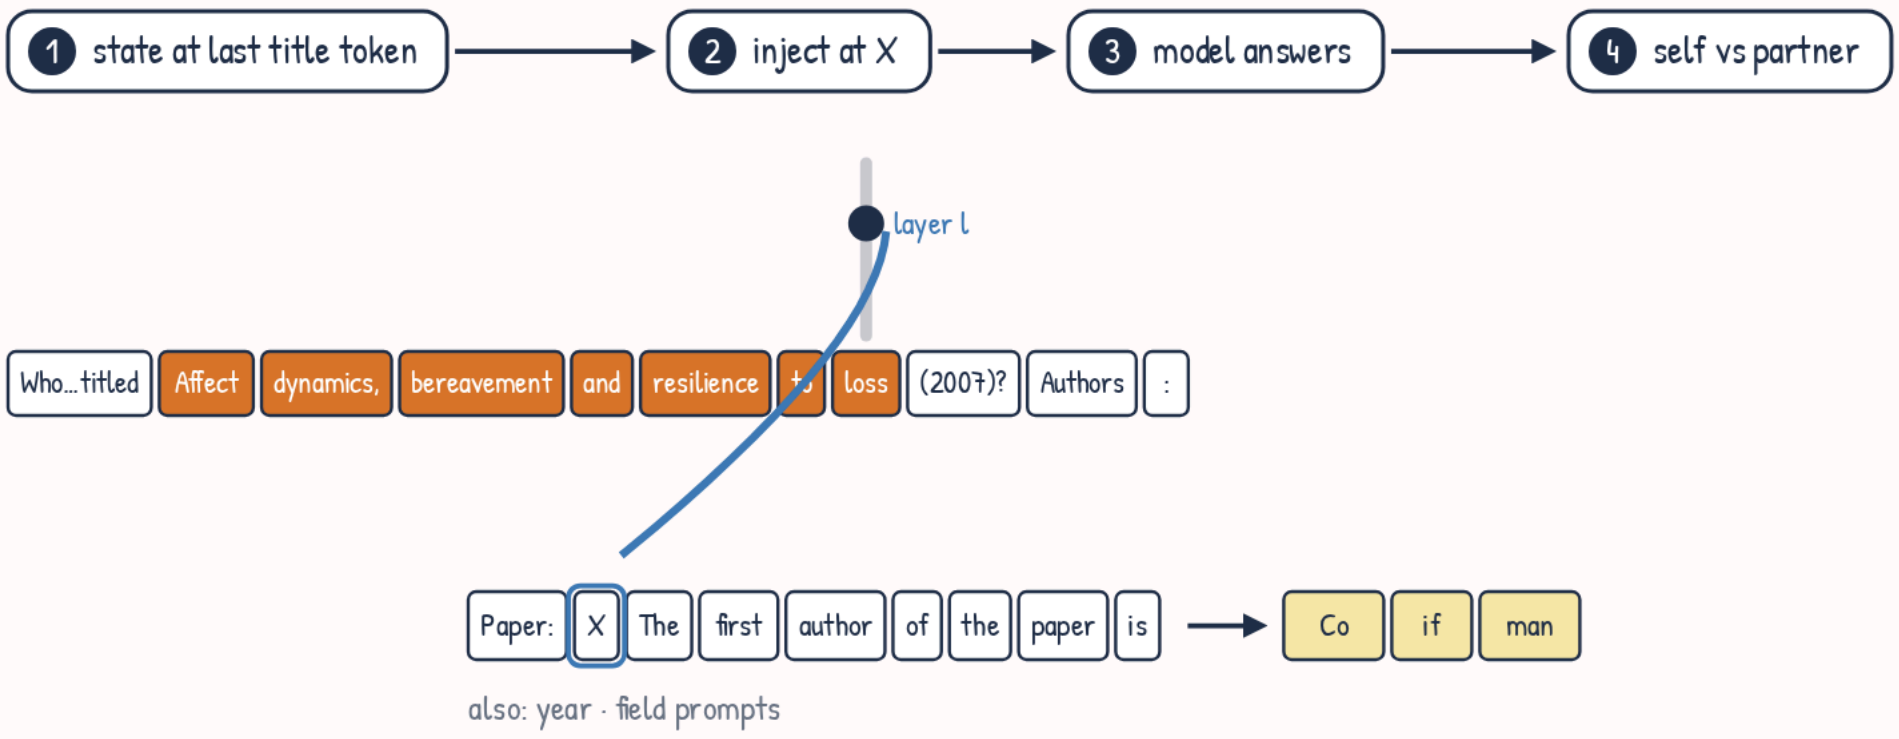
Word overlap 0.22 / 0.14: config/x3_lexical_neighbour_j2.csv (this paper) · medians: x3_report.md (primary set, 1,110) · G′: x3_textbase_recovery.md (test)
+0.229: Stage 13 X3 behaviour, all authors (batch 1 item 1), test, 552 papers; b1_xall_report.md (old first-author: +0.239)

 新写讲稿

改写标题（X3）：示例论文原标题 “Affect dynamics, bereavement and resilience to loss”，改写为 “Affect fluctuations, grief and adaptability in the face of loss”，词汇邻居 D 是另一篇论文 “Affect and Resistance to Temptation.”。比较标题最后位置状态的余弦：G′ = cos(原, 改写) − cos(原, D)，L8 为 +0.32，L36 峰值 +0.46（Stage 13 X3，主分析测试集，标题最后一个 token，G′ = cos(原, 改写) − cos(原, D)：L8 +0.316 [0.293, 0.338]，峰值 L36 +0.463；报告 Stage 13 X3 节；381_stage13/reports/x3_report.md Verdict 节与 G′ 表）。词重叠 jaccard2 的中位数是改写 0.61、D 0.15（Stage 13 X3 主分析 1,110 篇，修正版 Jaccard（jaccard2）中位数：改写 0.611，近邻 D 0.154（敏感性集 1,012 篇为 0.615 / 0.150）；381_stage13/reports/x3_report.md Word overlap 表）（本例 0.22 和 0.14）（示例论文 Coifman 等（2007）：改写 jaccard2 0.222，近邻 D 0.143；381_stage13/config/x3_lexical_neighbour_j2.csv；381_stage13/summary_x3/para_nli.csv）；全部作者分数改写 − D 为 +0.229 [0.208, 0.250]（补充 10 第 1 项；381_stage13/reports/b1_xall_report.md “X3 behaviour” 表）（旧版只看第一作者：+0.239（Stage 13 X3 行为，第一作者教师强制打分 log10(1/名次)，改写标题 − 近邻 D 标题，主分析测试集 552 篇，+0.239 [0.212, 0.266]，团队聚类 95% CI；381_stage13/reports/x3_report.md Behaviour 表））。

Patchscope (X4)

Coifman, Bonanno, Rafaeli (2007)



D = score(own state) − score(partner state)

score = log10(1/rank) of the true answer tokens

first author from L8: +0.046

year from L40: +0.013

D: Stage 13 X4 (prompt asks for the first author by design), test set, team CI; first author L8 +0.046 [0.035, 0.059], year L40 +0.013 [0.008, 0.018]; x4_report.md

 新写讲稿

Patchscope（X4）：取作者问题里标题最后一个 token 在第 l 层的状态，注入到 “Paper: X / The first author of the paper is” 里 X 的位置（同一层），看模型接下去说出的答案；另有年份和领域两个目标提示。D = 用本篇状态时的分数 − 用配对论文状态时的分数。第一作者从 L8 起可以解码（+0.046；提示按设计问第一作者；全作者版本同样从 L8 起可解码，测试集 +0.048 [0.039, 0.058]）（Stage 13 X4，标题位置，D = 本篇状态 − 配对论文状态的答案分数（log10(1/名次)），最早层在调参集选出、测试集 582 篇确认：第一作者 L8 +0.046 [0.035, 0.059]，团队聚类 95% CI；报告 Stage 13 X4 表；381_stage13/reports/x4_report.md 第 9–11 行），年份从 L40 起（+0.013）（同上，年份 L40 +0.013 [0.008, 0.018]；381_stage13/reports/x4_report.md）。

Stage 12–13: what the middle layers hold

Paper facts are readable at the title early (M2) · H2 (paper identity) partly supported but not established; H3 (hidden author knowledge): partly supported (name-position probe, addendum 11: criterion met for the surname at L40/L48, but lens intervals also exclude 0 and the scales differ, so sizes cannot be compared) · X2 alone: H2 not supported; author subspace can hardly decode authors ($R^2 \leq 0.009$)

怎么算：H3 名字位置 probe spec = probe(true) − probe(false)（Vpd 4,654 篇，团队整群）；H1 question share · 出处：b2_np_report_v2.md、x1_similarity.md

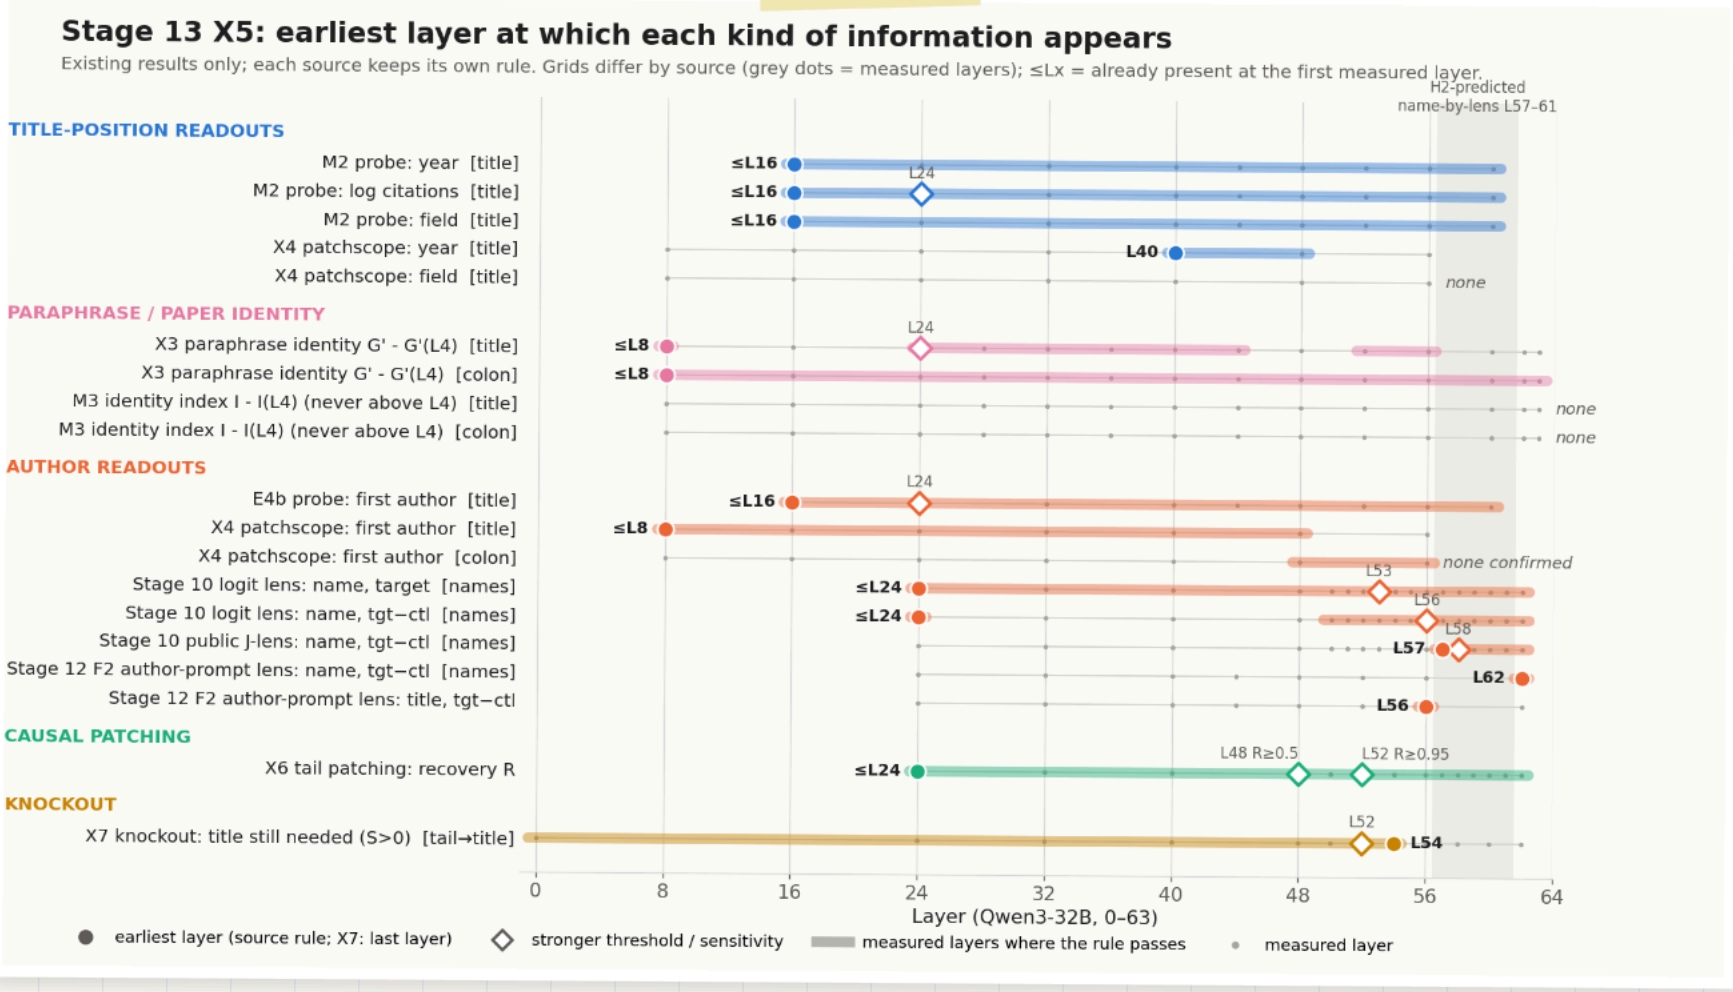
Hypothesis	M1: top word of the lens in middle layers	M2: probe reads non-name attributes	M3: change-of-task control	Current result (report v41, 2026-11-12)
H1 task / format: the middle layers represent "output an author list"	mostly "author", punctuation, common name starts; unrelated to the title	paper attributes not readable or very weak	the same title under different questions separates early in the middle layers	holds at ":" and name positions; at L4–L40, ":" moves 3–5× more when the question changes than when the paper changes (2.2× at L48, 1.3–1.5× at L56–L63)
H2 paper identity: the middle layers represent "which paper this is"	title-related words (copied from the title); change with a false title	field, year (inferred from the title), citations and recognition all readable, and earlier than the names	the same paper under different questions is close in the middle layers and separates by task only late **Result:** not above the L4 text level, not supported	**M3 does not support it; X3 shows a semantic representation beyond wording in the middle layers, but it cannot be separated from paper identity; H2 currently rests on M2 and X1, and M2's Qwen-over-BERT advantage is reference only (addendum 2).** Also, the earliest decodable order in X4 is first author (L8) before year (L40), opposite to the H2 prediction; the X4 recognised − control difference in first-author D (not significant on test) is no longer counted as H2 evidence (text-only BERT baseline +0.088 not weaker than Qwen L8 +0.018). **X2 does not support it.**
H3 author information already there, just not in vocabulary directions	not necessarily	the authors' first token readable by the probe, not by the lens	an author-trained probe transfers across tasks; an author-specific lens (M4) reads names in the middle layers	**Partly supported (2026-11-09, name-position probe, addendum 11):** By the addendum-11 pre-registered criterion, the surname first token meets H3 at L40/L48 (name-position probe, per-donor exclusion; probe L40 +0.069 [0.064, 0.074], L48 +0.103 [0.097, 0.110]; target − control L40 +0.031 [0.019, 0.044], L48 +0.053 [0.038, 0.067]); post-hoc check: the lens intervals also exclude 0 (logit L40 +0.010 [0.005, 0.014]; J-lens L40 +0.048 [0.042, 0.054]) and the two scales differ and cannot be compared in size, so H3 is

 新写讲稿

【讲稿】这张表把三个假设和三种读法对齐。H1 任务 / 格式：在 ":" 和名字位置成立，换问法时状态的移动是换论文的 3–5 倍（L48 2.2 倍）。H2 论文身份：部分支持但未确立——M3 不支持，X3 有超出用词的语义但与论文身份分不开，X2 不支持。H3 隐藏的作者知识：2026-11-09 起改为部分支持——名字位置 probe 按补充 11 判据，姓首 token L40 +0.069、L48 +0.103，target − control L40 +0.031；但 lens 的区间也不含 0，而且尺度不同，所以只能说部分支持。 【怎么算】H1：question share = mean(同篇换问法相对距离) / mean(换论文相对距离)（方法手册原文）；H3：名字位置 probe：ridge 从第 l 层"预测名字 token 的位置"的残差拟合到同一位置模型自己的 L63 状态，在 9,137 个名字 token 内求名次 → nlr；spec = probe(true) − probe(false)（方法手册 定义：名字位置 probe spec） 【数据】H1：M3 缓存 9,108 篇，":" 位置；H3：名字位置 probe 逐个排除版 Vpd 4,654 篇，姓首 token；X2：测试集 582 对 【对照】换论文（H1）；lens 与置换对照（H3） 【区间】团队整群 bootstrap 2,000 次（按作者团队重抽，2.5/97.5 百分位） 【出处】381_stage13/reports/x1_similarity.md；381_stage13/reports/b2_np_report_v2.md；381_stage13/reports/b1_xall_report.md

Layer order (X5)

Earliest layer at which each kind of information appears · existing results only, each source keeps its own rule



Read early, carried, spoken late

≤L8–L16: title facts and the first-author token

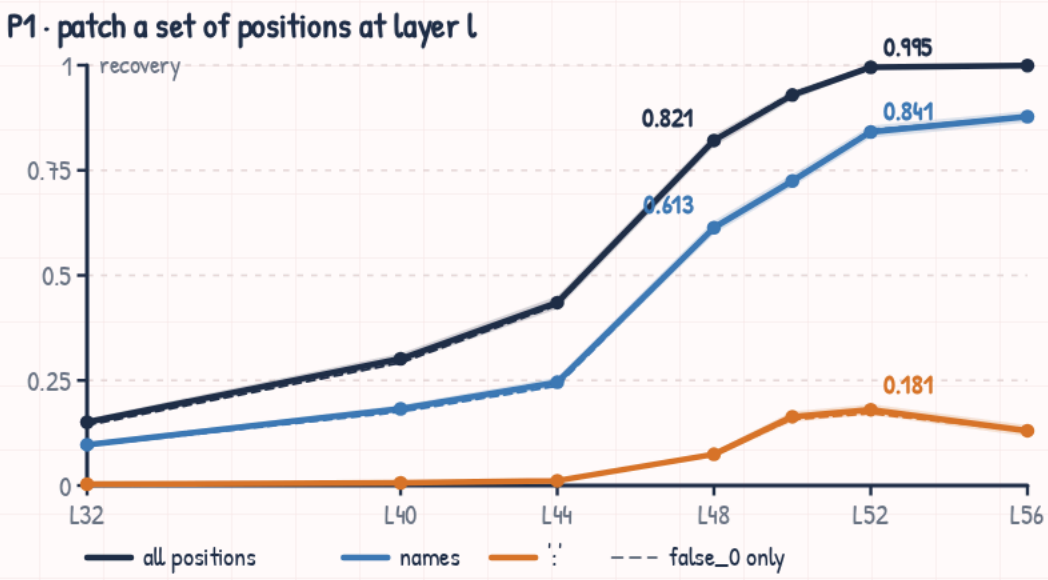
L48–L52: the paper signal reaches the post-title tail (patching R ≥ 0.5 at L48, ≥ 0.95 at L52; knockout costs nothing from L52)

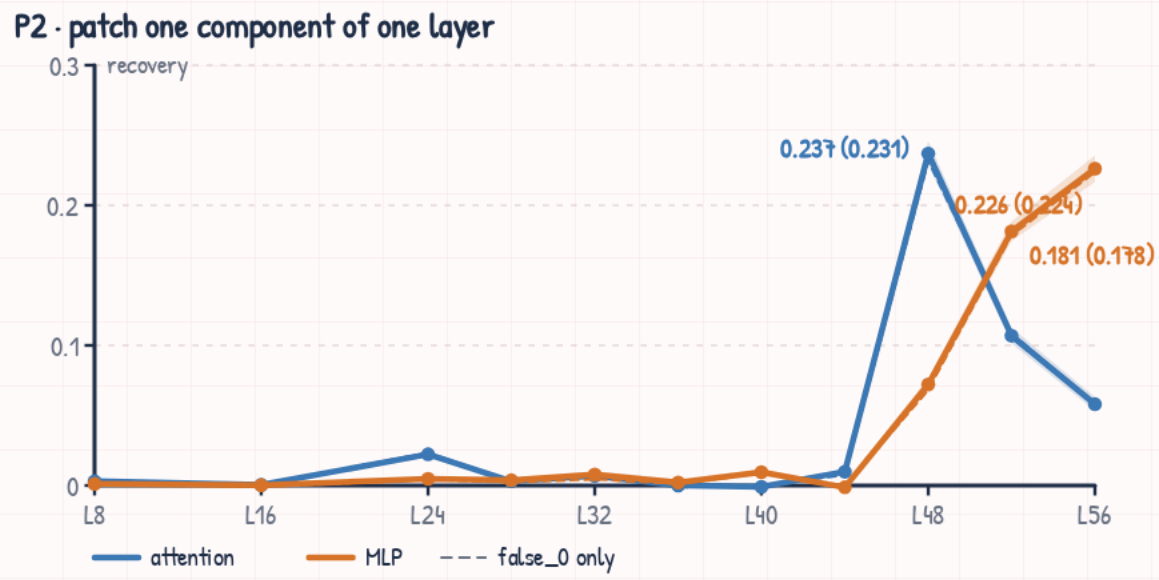
L53–L62: names readable by lens

X5 只用已有结果，把每种信息“最早在哪一层出现”排在一张图上，没有新的 GPU 计算。标题里的事实（年份、引用数、领域）和第一作者的首个 token 很早就读得出（L8–L16 或更早）；论文信号在 L48–L52 到达标题之后的位置：替换在 L48 恢复 R ⩾ 0.5，L52 起 ⩾ 0.95（Stage 13 X5 汇总，取 X6 5 个假标题平均恢复比例 L48 0.821、L52 0.995（团队聚类），X5 规则 R ⩾ 0.5 / ⩾ 0.95；381_stage13/summary_x5/x5_layer_order.csv X6 行；381_stage13/summary_x6/x6_recovery.csv；381_stage13/reports/x5_report_v2.md），从 L52 起阻断标题不再有损失（Stage 13 X7，论文特有阻断损失 S(L52)：全部 0.029、target 0.018、control 0.051（control L54 0.018、L56 0.000）；381_stage13/reports/x7_report.md）；名字要到 L53–L62 才能用 lens 读出。注意：M3 不支持 H2，X3 不能区分语义与论文身份，X4 在 L8 的第一作者信号可能来自标题文字，所以这张图只说明先后顺序，不说明机制。

Stage 12: where the paper information travels

P1 / P2 with five false titles (addendum 10, item 3) · share of the true − false gap recovered at the output · 1,186 papers





怎么算：recovery(l) = mean_p[P̄_p(l) − F̄_p] / mean_p[T̄_p − F̄_p]（P1 位置子集 / P2 单层单组件；5 个假标题平均，细虚线 = 只用 false_0）· Stage 11 样本 1,186 篇 · 团队整群 95% CI · 391_groups/summary_b1_p12f/p12f_mean5.csv（b1_p12f_report.md）

Plotted (mean of 5 false titles [team 95% CI] (false_0)) — all positions after the title: L32 0.151 [0.143, 0.159] (false_0 0.143); L40 0.302 [0.290, 0.314] (false_0 0.292); L44 0.435 [0.420, 0.451] (false_0 0.429); L48 0.821 [0.807, 0.835] (false_0 0.825); L50 0.929 [0.918, 0.940] (false_0 0.933); L52 0.995 [0.990, 1.001] (false_0 0.996); L56 0.999 [0.997, 1.001] (false_0 0.999) | name positions only: L32 0.097 [0.092, 0.103] (false_0 0.094); L40 0.183 [0.174, 0.191] (false_0 0.175); L44 0.246 [0.235, 0.257] (false_0 0.236); L48 0.613 [0.599, 0.630] (false_0 0.612); L50 0.725 [0.710, 0.740] (false_0 0.726); L52 0.841 [0.827, 0.856] (false_0 0.847); L56 0.877 [0.864, 0.891] (false_0 0.878) | ':' only: L32 0.003 [0.002, 0.005] (false_0 0.005); L40 0.006 [0.005, 0.008] (false_0 0.008); L44 0.011 [0.009, 0.013] (false_0 0.011); L48 0.074 [0.068, 0.081] (false_0 0.074); L50 0.164 [0.152, 0.176] (false_0 0.157); L52 0.181 [0.168, 0.193] (false_0 0.172); L56 0.131 [0.117, 0.144] (false_0 0.130) | attention: L8 0.003 [0.002, 0.004] (false_0 0.003); L16 0.000 [−0.000, 0.001] (false_0 0.001); L24 0.022 [0.020, 0.024] (false_0 0.023); L28 0.003 [0.002, 0.004] (false_0 0.003); L32 0.007 [0.006, 0.008] (false_0 0.007); L36 −0.000 [−0.001, 0.001] (false_0 0.001); L40 −0.001 [−0.002, 0.000] (false_0 −0.000); L44 0.010 [0.008, 0.012] (false_0 0.007); L48 0.237 [0.229, 0.246] (false_0 0.231); L52 0.107 [0.101, 0.113] (false_0 0.109); L56 0.058 [0.053, 0.063] (false_0 0.058) | MLP: L8 0.001 [0.000, 0.002] (false_0 0.002); L16 0.000 [−0.001, 0.001] (false_0 −0.001); L24 0.005 [0.003, 0.006] (false_0 0.004); L28 0.004 [0.002, 0.005] (false_0 0.002); L32 0.008 [0.006, 0.010] (false_0 0.004); L36 0.002 [−0.000, 0.004] (false_0 0.001); L40 0.010 [0.008, 0.012] (false_0 0.009); L44 −0.001 [−0.004, 0.001] (false_0 −0.001); L48 0.072 [0.068, 0.077] (false_0 0.068); L52 0.181 [0.174, 0.188] (false_0 0.178); L56 0.226 [0.217, 0.236] (false_0 0.224)

N1 name plausibility: without a title the true list looks "most real" in 0.255 of papers (chance 0.25); with the true title 0.625 [0.615, 0.635]

N2 pure name prior: target − control +0.047 [0.031, 0.062] vs +0.247 with the true title → ≈ 19% of the gap (delete-title prior of §6.12: 0.35)

F2 lens fitted on author prompts: target − control ≤ 0 at L24–L56, +0.238 only at L62

N1 name plausibility: Stage 12 N1, 8,894 R0/R1 papers, paper bootstrap; N1_prior_mc.csv · N2 pure name prior: Stage 12 N2, final L63, 4,621 + 2,220, within bin, paper bootstrap; stage12_report.md · F2 lens fitted on author prompts: Stage 12 F2, name positions, Stage 11 sample, true − 5 false; F2_author_lens.csv

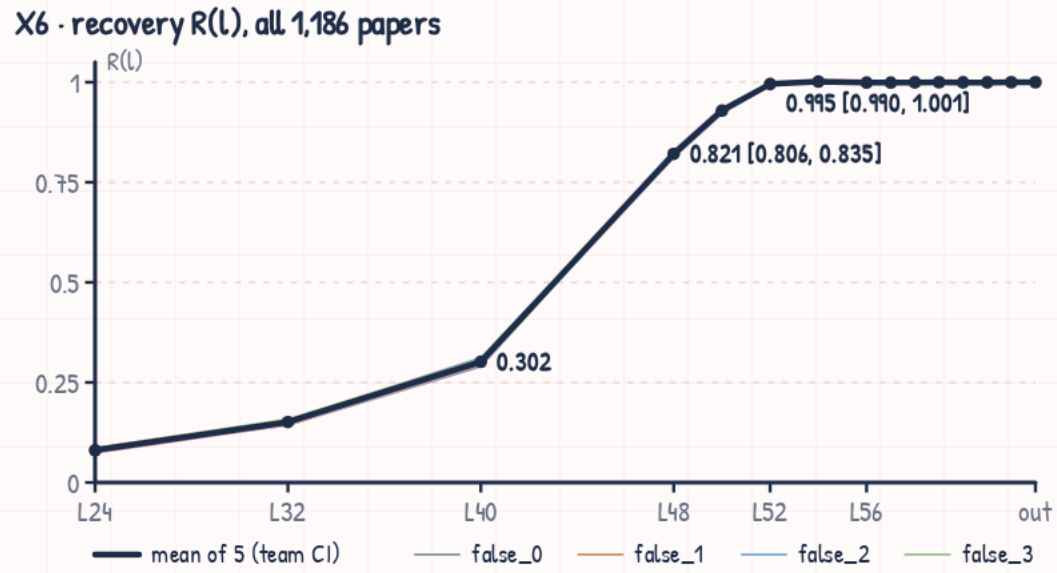
P1 / P2: 391_groups/summary_b1_p12f/p12f_mean5.csv (columns ratio, ratio_lo, ratio_hi, ratio_false0; who = all_authors, group = all); 391_groups/reports/b1_p12f_report.md

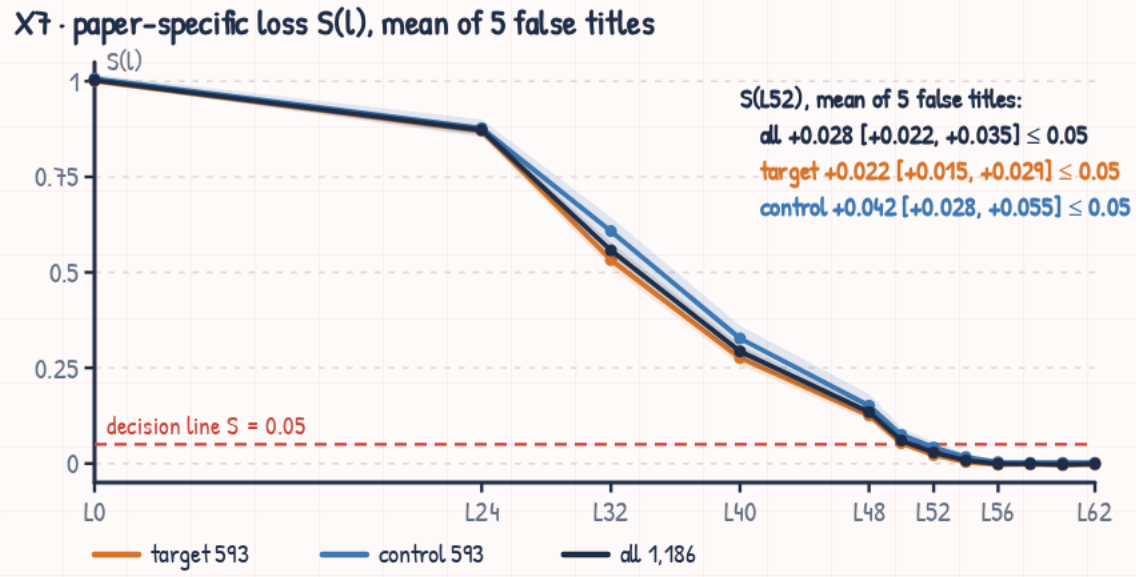
 新写讲稿

【讲稿】Stage 12：论文信息走到哪里。左图 P1 一次替换一组位置，主线是 5 个假标题平均，细虚线是只用 false_0：整段标题之后 L48 0.821、L52 0.995；只换名字位置 L52 0.841（false_0 版 0.847）；只换“:”最多 0.181（0.172）。右图 P2 只换一层的一个组件：L48 注意力 0.237（0.231），L52–L56 MLP 0.181、0.226（0.178、0.224）——先是注意力把标题读进来，再由 MLP 处理。下面三条：N1 不给标题时真名单“最像真的”比例 0.255，与随机 0.25 一样；N2 纯名字先验约占差距的 19%；F2 用作者提示拟合的 lens 在中间层仍读不出论文特有的信息。 【怎么算】recovery(l) = mean_p[P̄_p(l) − F̄_p] / mean_p[T̄_p − F̄_p]（P1、P2 同一估计量：分子换成"替换后 − 未替换"，分母"真 − 未替换"，见方法手册 D-P1 / D-P2） 【数据】Stage 11 样本 1,186 篇（target 593 + control 593），全部作者全部名字 token，最终输出 L63；P1 层 L32–L56，P2 层 L8–L56 【对照】5 个假标题 false_0..false_4 各做一次替换，取平均（主线）；细虚线 = 只用 false_0（原 Stage 12 发表版） 【区间】团队整群 bootstrap 2,000 次（按作者团队重抽，2.5/97.5 百分位） 【出处】391_groups/summary_b1_p12f/p12f_mean5.csv；391_groups/reports/b1_p12f_report.md

The Stage 11 timing holds for all 5 false titles

X6: replacement with each of the 5 false titles · X7: knockout minus the same knockout on the false-title run (S = T − F)





怎么算：X6：R(l) = mean_papers(nlr_patched@l − nlr_false) / mean_papers(nlr_true − nlr_false)；平均 R = 5 个标题 R 的简单平均（bootstrap 同样逐次平均）· X7：T(l) = mean(kT64 − kT_l) / mean(true − false)；F(l) = mean(kF64 − kF_l) / mean(true − false)；S(l) = T(l) − F(l)（论文特有损失）· 1,186 篇（593 + 593），标题后全部位置，最终输出 · 团队整群 95% CI · summary_x6/x6_recovery.csv；summary_b1_x7f/x7f_knockout.csv

Plotted — mean of 5: L24 0.080 [0.075, 0.086]; L32 0.151 [0.143, 0.159]; L40 0.302 [0.290, 0.315]; L48 0.821 [0.806, 0.835]; L50 0.929 [0.917, 0.941]; L52 0.995 [0.990, 1.001]; L54 1.001 [0.998, 1.004]; L56 0.999 [0.997, 1.001]; L57 0.999 [0.997, 1.001]; L58 0.999 [0.997, 1.001]; L59 1.000 [0.998, 1.002]; L60 0.999 [0.998, 1.001]; L61 1.000 [0.998, 1.001]; L62 1.000 [0.999, 1.001]; L63 1.000 [1.000, 1.000] | false_0: L24 0.077 L32 0.144 L40 0.291 L48 0.825 L50 0.932 L52 0.996 L54 1.001 L56 0.998 L57 0.999 L58 1.000 L59 1.000 L60 0.999 L61 1.000 L62 1.001 L63 1.000 | false_1: L24 0.086 L32 0.156 L40 0.307 L48 0.822 L50 0.926 L52 0.997 L54 1.002 L56 1.000 L57 1.000 L58 1.000 L59 1.000 L60 1.000 L61 1.000 L62 0.999 L63 1.000 | false_2: L24 0.080 L32 0.153 L40 0.310 L48 0.813 L50 0.927 L52 0.996 L54 1.001 L56 1.000 L57 0.998 L58 0.999 L59 1.000 L60 1.000 L61 0.999 L62 1.001 L63 1.000 | false_3: L24 0.085 L32 0.158 L40 0.307 L48 0.823 L50 0.931 L52 0.994 L54 0.999 L56 0.998 L57 0.998 L58 0.998 L59 0.998 L60 0.999 L61 0.998 L62 1.000 L63 1.000 | false_4: L24 0.074 L32 0.145 L40 0.294 L48 0.823 L50 0.929 L52 0.994 L54 1.004 L56 0.999 L57 1.000 L58 1.000 L59 1.001 L60 1.000 L61 1.000 L62 1.000 L63 1.000 | S target: L0 +1.001 [+0.996, +1.005]; L24 +0.870 [+0.856, +0.884]; L32 +0.533 [+0.511, +0.555]; L40 +0.276 [+0.257, +0.294]; L48 +0.126 [+0.112, +0.140]; L50 +0.053 [+0.044, +0.062]; L52 +0.022 [+0.015, +0.029]; L54 +0.003 [−0.001, +0.008]; L56 −0.004 [−0.007, −0.001]; L58 −0.003 [−0.006, +0.000]; L60 −0.005 [−0.008, −0.002]; L62 −0.003 [−0.006, −0.001] | S control: L0 +1.007 [+0.996, +1.018]; L24 +0.877 [+0.854, +0.900]; L32 +0.608 [+0.571, +0.644]; L40 +0.327 [+0.295, +0.361]; L48 +0.151 [+0.122, +0.181]; L50 +0.075 [+0.055, +0.094]; L52 +0.042 [+0.028, +0.055]; L54 +0.016 [+0.008, +0.025]; L56 +0.003 [−0.002, +0.009]; L58 +0.002 [−0.003, +0.008]; L60 +0.002 [−0.003, +0.007]; L62 +0.002 [−0.002, +0.007] | S all: L0 +1.003 [+0.998, +1.008]; L24 +0.872 [+0.861, +0.884]; L32 +0.558 [+0.539, +0.577]; L40 +0.293 [+0.276, +0.310]; L48 +0.134 [+0.120, +0.148]; L50 +0.060 [+0.051, +0.069]; L52 +0.028 [+0.022, +0.035]; L54 +0.008 [+0.004, +0.012]; L56 −0.001 [−0.004, +0.001]; L58 −0.001 [−0.004, +0.002]; L60 −0.003 [−0.005, −0.000]; L62 −0.001 [−0.004, +0.001]

By name-token role: surname first token 0.734 at L48, surname continuation 0.893; all roles ≥ 0.96 at L52

Pre-registered verdict (false_0 only): target S(L52) 0.018 holds, control 0.051 just misses 0.05; 5-title mean: all groups pass

By name-token role: X6 roles, all papers; x6x7_roles.md · Pre-registered verdict (false_0 only): X7 x7_report.md; addendum 10 item 2, b1_x7f_report.md

X6: 381_stage13/summary_x6/x6_recovery.csv (group = all; false_0..4, average) · X7: 381_stage13/summary_b1_x7f/x7f_knockout.csv (title = mean5; S, S_lo, S_hi); x6_report.md, b1_x7f_report.md

 新写讲稿

【讲稿】X6 把 Stage 11 的替换换成 5 个假标题各做一遍：平均恢复 L48 0.821 [0.806, 0.835]、L52 0.995，每个假标题与 false_0 相差不超过 0.02，所以“L48 约 80%、L52 起全部”不是 false_0 特有的。右图 X7：阻断减去同样阻断在假标题运行上的损失，S = T − F；从 L0 起约 1.0，到 L52 只剩 +0.028（全部论文），target +0.022、control +0.042，都低于预注册判据 0.05（红虚线）。原来只用 false_0 时 control 0.051 差一点不过，是单个假标题的波动。 【怎么算】X6：R(l) = mean_papers(nlr_patched@l − nlr_false) / mean_papers(nlr_true − nlr_false)；平均 R = 5 个标题 R 的简单平均（bootstrap 同样逐次平均）；X7：T(l) = mean(kT64 − kT_l) / mean(true − false)；F(l) = mean(kF64 − kF_l) / mean(true − false)；S(l) = T(l) − F(l)（论文特有损失） 【数据】Stage 11 样本 1,186 篇（target 593 + control 593），标题后全部位置，全部作者全部名字 token，最终输出；X6 层 L24–L63，X7 起始层 L0–L62 【对照】X6：5 个假标题各替换一次（细线），粗线为平均；X7：同样的阻断在假标题运行上做一遍（F），S = T − F；判据 S(L52) ⩽ 0.05（红虚线） 【区间】团队整群 bootstrap 2,000 次（按作者团队重抽，2.5/97.5 百分位） 【出处】381_stage13/summary_x6/x6_recovery.csv；381_stage13/summary_b1_x7f/x7f_knockout.csv；x6_report.md；b1_x7f_report.md

Same title, different question

M3: probes across three questions (authors / year / field) · X1: patch A's title state from another question into B's author prompt

- **M3 transfer at the title:** T ≥ 0.92 at L16–L40, but never above the L4 text level(Stage 13 M3, 9,108 papers, team folds; m3_report.md) (year T − T(L4) −0.03 to −0.06)(same, CIs exclude 0) → M3 does not support H2
- **M3 at the colon:** T < 0.5 → the state is already organised by the question (H1)(same; summary_m3/m3_transfer.csv)
- **X1 replacement:** R ≈ 0.996 (L24), 0.933 (L40), 0.455 (L48) for all authors, whichever question the state came from (old first-author version: 0.99 / 0.92 / 0.42)(Stage 13 X1, test 582 pairs, team CI; x1_report.md); authors − year within ±0.02, except a small +0.019 at L48(same, [0.012, 0.026])
- **Retrieval (added 2026-11-05):** no layer retrieves the paper across questions better than L4(X5 retrieval, 9,108 papers; x5_retrieval.md; post-defence)

Reading

The title state hardly depends on the question, and the replacement effect is task-independent; but nothing goes beyond what the title text alone gives at L4.

 新写讲稿

M3：同一篇论文换三种问法，标题最后一个 token 上的迁移比 T 在 L16–L40 都 ⩾ 0.92（Stage 13 M3，9,108 篇，按作者团队分 5 折的 probe，迁移比 = 跨问法成绩 ÷ 同问法成绩；报告第四部分 M3 表；381_stage13/reports/m3_report.md），但按补充 2 只看相对 L4 的变化：年份 T − T(L4) 为 −0.03 到 −0.06（同上，团队聚类 95% CI 都不含 0；summary_m3/m3_transfer.csv），不高于文字水平，所以 M3 不支持 H2。 ":" 位置 T < 0.5（同上），状态已按问题重新组织。X1：把 A 在别的问法下的标题状态替换进 B 的作者提示，恢复 R 在 L24 约 0.996、L40 0.933、L48 0.455（全部作者，b1_xall_report.md；旧版只看第一作者：0.99 / 0.92 / 0.42）（Stage 13 X1，测试集 582 对，作者问法来源，团队聚类 95% CI；381_stage13/reports/x1_report.md），三种来源几乎相同；作者 − 年份在 ±0.02 以内，只有 L48 有 +0.019（同上，[0.012, 0.026]）。答辩后补算的跨任务检索（X5 预注册曲线）也没有一层高于 L4（X5 检索，9,108 篇，top-1；381_stage13/reports/x5_retrieval.md；事后补算）。 2026-11-06（批次 1 第 1 项）：X1–X4 改为给全部作者打分（全部名字 token）并按作者排位分层，结论都不变：X1 仍与任务无关，L48 有一点小而确实的任务依赖（作者 − 年份 +0.024 [0.019, 0.030]（补充 10 第 1 项，测试集，团队聚类 95% CI；381_stage13/reports/b1_xall_report.md））。

Patchscope and paraphrases

X4: decode year / first author / field from the paper's own title state · X3: paraphrased title vs a word-matched other paper

- **X4 first author:** decodable from L8, D = +0.046 [0.035, 0.059](Stage 13 X4, test split, team CI; x4_report.md) (all authors also from L8: +0.048 [0.039, 0.058]); year only from L40, +0.013 [0.008, 0.018](same); field never → order opposite to the H2 prediction
- **But:** the L8 signal sits on the surname (+0.066), where the text-baseline check failed(X4 role split, 1,178 papers; x4_rolesplit.csv) → may be explained by the title text
- **X3 paraphrase:** closer to the original than a word-matched paper beyond L4, peak L36 +0.16(Stage 13 X3, test 552 papers, G′ − G′(L4), team CI [0.146, 0.171]; x3_report.md); behaviour keeps ≈ 90% of the author preference(all authors, all tokens 0.897 [0.868, 0.926]; old first-author version 0.90 [0.86, 0.94])
- **Post-hoc checks:** a sentence-embedding model without author knowledge shows a comparable advantage, and target = control(X3 text baselines and group split; x3_textbase_recovery.md, x3_groupsplit.md) → meaning, not separable from paper identity

H2 / H3 so far

H2 partly supported but not established (rests on M2 and X1; X4 recognition gap no longer counted); H3: partly supported by the name-position probe (addendum 11); X4 alone cannot exclude the title text.

 新写讲稿

X4：把论文自己的标题状态注入“X 的第一作者 / 年份 / 领域是”提示。第一作者从 L8 起可解码，D = +0.046（Stage 13 X4，测试集，团队聚类 95% CI [0.035, 0.059]；报告第四部分 X4 表；381_stage13/reports/x4_report.md）（全作者版本同样从 L8 起可解码：测试集 +0.048 [0.039, 0.058]）；年份要到 L40，+0.013（同上，[0.008, 0.018]）；领域读不出——顺序与 H2 的预测相反。L8 的作者信号主要在姓的第一个 token 上（+0.066（X4 按 token 角色，1,178 篇，[0.045, 0.088]；381_stage13/summary_x1x4/x4_rolesplit.csv），而姓氏上文本基线的阳性对照没有通过，所以可能来自标题文字。X3：改写标题在 L28–L40 比用词相近的近邻 D 更接近原标题，超出 L4 文字水平，最高 L36 +0.16（Stage 13 X3，主分析测试集 552 篇，G′ − G′(L4)，团队 CI [0.146, 0.171]；381_stage13/reports/x3_report.md）；行为上保留约 90% 的作者偏好（全部作者全部 token 0.897 [0.868, 0.926]，补充 10 第 1 项；旧版只看第一作者：0.90 [0.86, 0.94]）。事后加的检验：不认识作者的句子向量模型在用词匹配子集上也有相当优势，target 与 control 没有差别（381_stage13/reports/x3_textbase_recovery.md、x3_groupsplit.md），所以只能说中间层表示了标题的意思，不能与论文身份区分。 2026-11-06（批次 1 第 1 项，全部作者）：X3 改写标题保留约 90% 的作者偏好，target 与 control 一样；X4 从 L8 起可解码出作者，各作者排位相同，认得出的论文方向上更高，但按预注册在测试集上不显著（L8 +0.023 [−0.001, +0.048]，v42_paper_vs_team.md §3）；但只靠标题文字的基线不弱于 Qwen，仍不能排除标题文字的解释，这一差别不再作为 H2 的证据（只看标题文字的 BERT 基线 +0.088 不弱于 Qwen L8 +0.018）（381_stage13/reports/b1_xall_report.md）。

X2: swap only a subspace

Patch only the paper-attribute (S_id, 9-dim) or the author (S_auth, 10-dim) component of A's title states into B · test 582 pairs · team-cluster 95% CI

- **Carry:** S_id at L40 moves +0.005 of the gap (random +0.003, full replacement +0.920); S_auth at L48 moves +0.018 (random +0.003, full +0.428)(Stage 13 X2, test 582 pairs; x2_report.md Verdict)
- **Pre-registered verdict:** H2 not supported (R_id 0.005 < 0.5 × R_full 0.460); H3 passes (R_auth − R_id +0.014 [+0.008, +0.020])(same, L40 / L48)
- **But:** the author subspace hardly decodes authors (held-out $R^2 \leq 0.003$; first-author token hit rate 0.078–0.079, below the constant baseline 0.080) and moves only about 4% of the full replacement(subspace fits on 5,041 training papers, 5 team folds; x2_report.md)
- **Remove arm:** setting either component to the mean costs no more than a random subspace (+0.001)(test, L_S − L_rand; same)

Reading

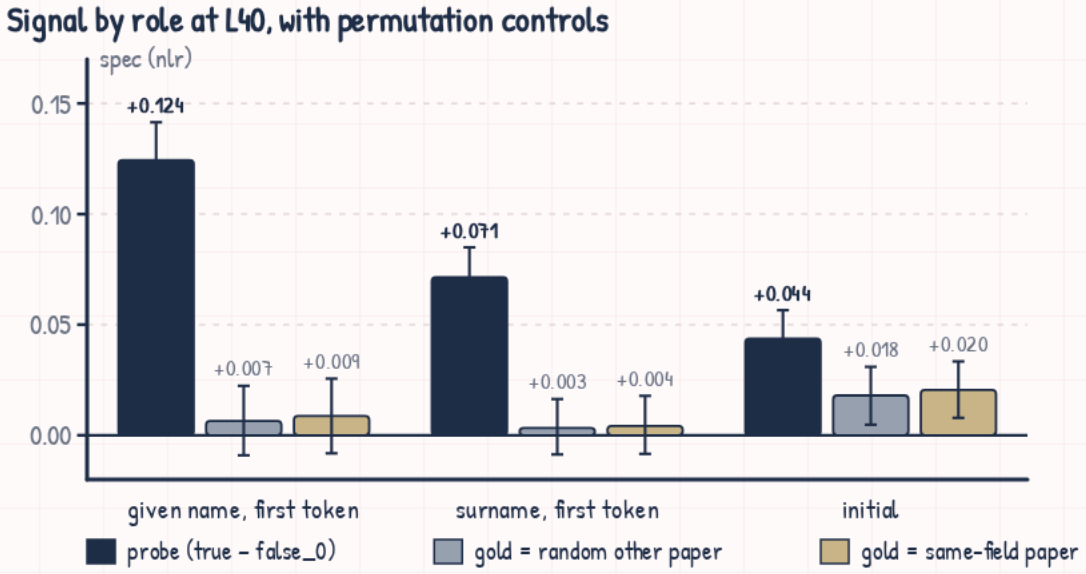
H3 passes by the pre-registered rule and H2 is not supported, but the author subspace cannot decode authors, so this is no strong evidence for H3. The information carried from the title to the names lies almost entirely outside both subspaces.

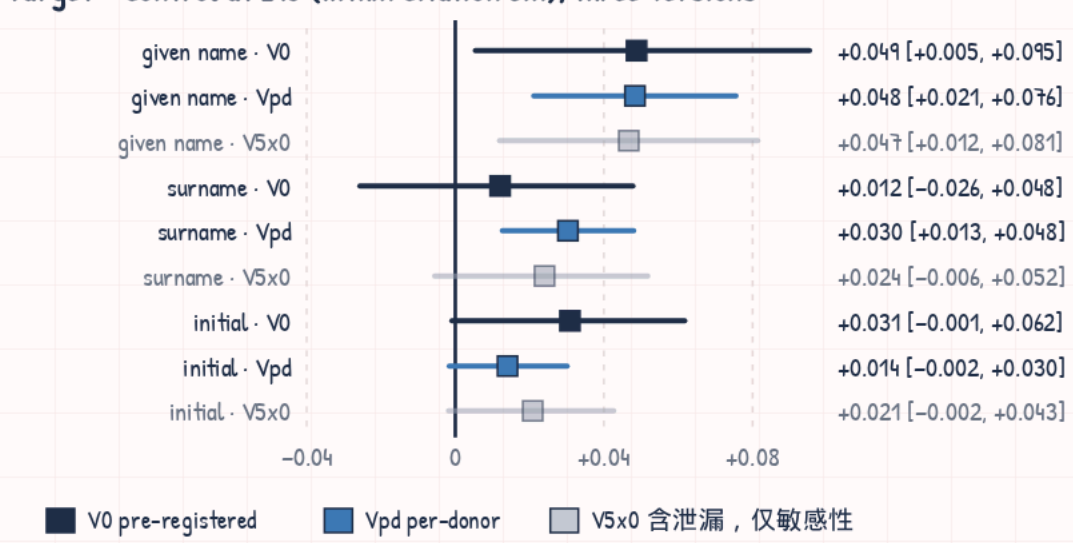
 新写讲稿

X2 只替换子空间（预注册补充 6，2026-11-05 完成）。在 B 的作者提示里只把标题位置状态在某个子空间上的分量换成 A 的：论文属性子空间 S_id（年份、引用数、领域，9 维）在 L40 只搬动 +0.005（Stage 13 X2，测试集 582 对，R_S（均值比）；随机子空间 +0.003，完整替换 +0.920；381_stage13/reports/x2_report.md Verdict 表），作者子空间 S_auth 在 L48 搬动 +0.018（同上，L48；随机 +0.003，完整替换 +0.428）。按预注册判据，H3 通过、H2 不支持（H2：R_id 0.005 < 0.5 × R_full 0.460；H3：R_auth − R_id +0.014 [+0.008, +0.020]，团队聚类 95% CI；同上）。但作者子空间本身几乎解码不出作者（留出 $R^2 \leqslant 0.003$（S_auth 作者映射，5,041 篇训练论文，5 折团队留出 R^2 0.0009–0.0033；x2_report.md Subspace fits 表），第一作者名字 token 猜中率 0.078–0.079（同表 author top-1，L16–L48 各层），低于常数基线 0.080（同表 majority)），它搬动的量只有完整替换的约 4%（0.018 ÷ 0.428），因此不能作为 H3 的有力证据。从标题传到作者名字的信息，几乎全部分散在这两个子空间之外。与预注册的出入：X2 的 H3 判定按规则通过，但因子空间本身无解码能力而降级，与 X3 的处理方式相同；S_id 只有 9 维。 2026-11-06（批次 1 第 1 项）：用全部作者重新拟合作者子空间后，搬动量从 0.016 升到 0.032（完整替换的约 7%），但子空间本身仍几乎解码不出作者（留出 $R^2 \leqslant 0.009$），单看 X2，H3 证据仍不足（H3 总体判断已按名字位置 probe 改为部分支持）（381_stage13/reports/b1_xall_report.md “X2: verdict” 与 “New S_auth” 节）。

The probe on every name token

Title-position probe, all authors, all name tokens, split by role · L40 · team-cluster 95% CI





怎么算：spec(p) = score(p, X_true) − score(p, X_false_0)，每个名字 token 按角色取名次 → nlr；T − C：target−control = Σ_b w_b [mean_{target,b} − mean_{control,b}]，w_b = n_t n_c/(n_t+n_c) 归一化 · L40，名 1,706 / 姓 1,395 / 首字母 1,590 篇（V0）；Vpd 3,046 / 4,654 / 4,812 篇 · 团队整群 95% CI · alltok_controls.csv；perdonor_by_run_layer.csv

Plotted — given name, first token · probe (true − false_0): +0.124 [+0.108, +0.142] (n 1,706) | given name, first token · gold = random other paper: +0.007 [−0.009, +0.022] (n 1,706) | given name, first token · gold = same-field paper: +0.009 [−0.008, +0.026] (n 1,706) | surname, first token · probe (true − false_0): +0.071 [+0.058, +0.085] (n 1,395) | surname, first token · gold = random other paper: +0.003 [−0.009, +0.016] (n 1,395) | surname, first token · gold = same-field paper: +0.004 [−0.008, +0.018] (n 1,395) | initial · probe (true − false_0): +0.044 [+0.030, +0.057] (n 1,590) | initial · gold = random other paper: +0.018 [+0.005, +0.031] (n 1,590) | initial · gold = same-field paper: +0.020 [+0.008, +0.033] (n 1,590) | T − C given name, first token V0: +0.049 [+0.005, +0.095] (n 1,706) | T − C given name, first token Vpd: +0.048 [+0.021, +0.076] (n 3,046) | T − C given name, first token V5x0: +0.047 [+0.012, +0.081] (n 1,706) | T − C surname, first token V0: +0.012 [−0.026, +0.048] (n 1,395) | T − C surname, first token Vpd: +0.030 [+0.013, +0.048] (n 4,654) | T − C surname, first token V5x0: +0.024 [−0.006, +0.052] (n 1,395) | T − C initial V0: +0.031 [−0.001, +0.062] (n 1,590) | T − C initial Vpd: +0.014 [−0.002, +0.030] (n 4,812) | T − C initial V5x0: +0.021 [−0.002, +0.043] (n 1,590)

Surname first token above the initial: +0.071 vs +0.044, difference +0.028 [+0.011, +0.045] → both pre-registered checks pass; E4b (first token only, mostly initials) underestimated it

Permutation controls: ≈ 0 on surname and given-name tokens; ≈ +0.02 on initials → about half of the initial's signal is not paper-specific

Target − control: given name positive in all three versions; surname not significant pre-registered, positive only post hoc (per-donor) → surname evidence weak

Surname first token above the initial: e4b_alltok.md §5 · Permutation controls: e4b_alltok.md §7 · Target − control: b1_e4b5_report.md

Bars: 381_stage13/summary_alltok/alltok_controls.csv (layer 40) · forest: 381_stage13/summary_b1_e4b5/perdonor_by_run_layer.csv (tc, tc_lo, tc_hi; V0 / Vpd / V5x0) · e4b_alltok.md, b1_e4b5_report.md

 新写讲稿

【讲稿】补充 9 把标题位置的 probe 扩展到全部作者的全部名字 token，并按角色分开。左图 L40：名的第一个 token +0.124，姓的第一个 token +0.071，首字母 +0.044；姓比首字母高 +0.028，两项预注册判据都通过。灰色和土黄色是置换对照（gold 换成别的论文的作者）：在姓和名上约为 0，在首字母上约 +0.02，说明首字母的信号约一半不针对具体论文。右图是 target − control 的三个版本：预注册版里名为正、姓不显著（+0.012）；事后逐个排除版里姓为正（+0.030）；浅色的 5 个假标题平均版含泄漏，只作敏感性。结论：名的信号稳定，姓的证据弱。 【怎么算】score(p, x) = mean_{a ∈ authors(p)} −log10(1 + #{v ∈ V: ℓ_v(x) > ℓ_{g_a}(x)})，ℓ(x) = RMSNorm(probe(x)) · W_Vᵀ；spec(p) = score(p, X_true) − score(p, X_false_0)（推广到全部作者全部名字 token，按角色取 gold）；target − control：target−control = Σ_b w_b [mean_{target,b} − mean_{control,b}]，w_b = n_t n_c/(n_t+n_c) 归一化 【数据】标题最后一个 token 的残差，L40；target + control 论文，剔除标题复用后：名 1,706、姓 1,395、首字母 1,590 篇（V0）；逐个排除版 Vpd 名 3,046、姓 4,654、首字母 4,812 篇 【对照】置换对照：gold 换成随机另一篇 / 同领域另一篇论文的作者；三个版本 V0（预注册，只减 false_0）/ Vpd（事后偏离 D1）/ V5x0（5 个假标题平均，含泄漏，仅敏感性） 【区间】团队整群 bootstrap 2,000 次（按作者团队重抽，2.5/97.5 百分位） 【出处】381_stage13/summary_alltok/alltok_controls.csv；381_stage13/summary_b1_e4b5/perdonor_by_run_layer.csv；e4b_alltok.md；b1_e4b5_report.md

Name-position probe: H3 partly supported

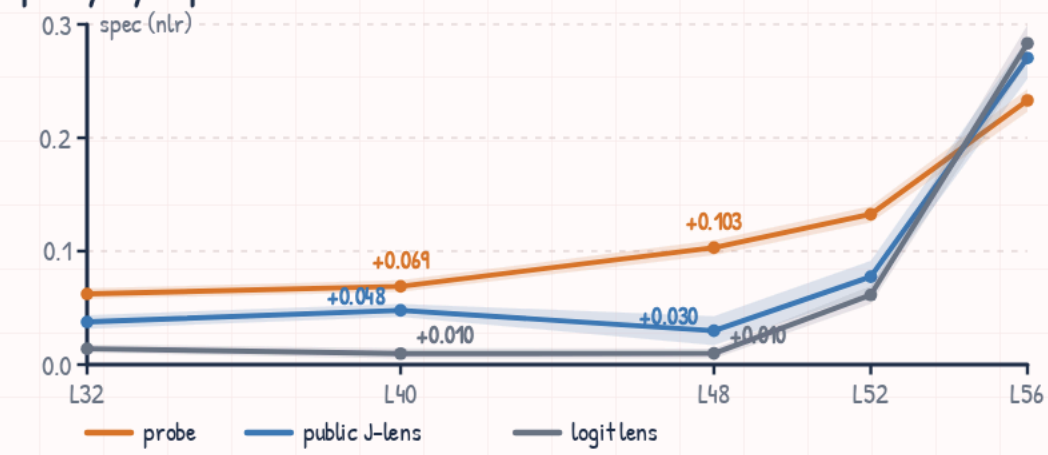
Addendum 11 A · per-donor version Vpd (D11-1) · surname first token · all papers 4,654 · team-cluster 95% CI

1 title in prompt → 2 residual at name-predicting position, layer l → 3 ridge probe → 4 → model's own L63 state → 5 decode among 9,137 names → nlr

spec = probe(true) − probe(false)
false = mean of the usable false titles (Vpd)

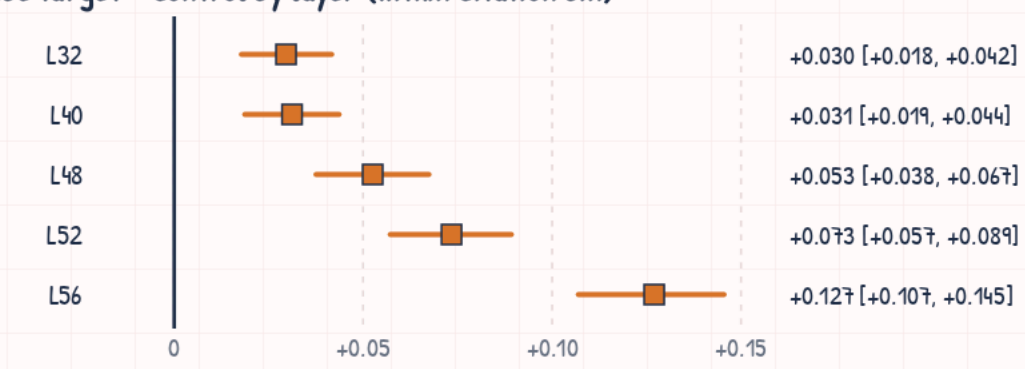
按补充 11 预注册判据通过（姓首 token L40/L48）；事后检验：lens 区间同样不含 0、尺度不同无法比较大小，因此降为部分支持

spec by layer: probe vs lenses



different rank scales (9,137 names vs full vocabulary): compare sign and CI, not size

Probe target − control by layer (within citation bin)



Initials (L40): permutation-control row +0.020 [+0.015, +0.026] ≈ half of the signal +0.045 [+0.039, +0.051]
首字母的对照行约为信号的一半：约一半信号不是论文特有的

怎么算：名字位置 probe：ridge 从第 l 层"预测名字 token 的位置"的残差拟合到同一位置模型自己的 L63 状态，在 9,137 个名字 token 内求名次 → nlr；spec = probe(true) − probe(false)（方法手册 定义：名字位置 probe spec） · T − C：档内合并差 · Vpd 4,654 篇（姓首 token），层 L32–L56 · 团队整群 95% CI · summary_b2_np/np_lens_compare_v2.csv；np_role_layer_v2.csv

Plotted — probe (9,137 name tokens): L32 +0.062 [+0.058, +0.067]; L40 +0.069 [+0.064, +0.074]; L48 +0.103 [+0.097, +0.110]; L52 +0.133 [+0.125, +0.140]; L56 +0.233 [+0.223, +0.243] | public J-lens (full vocabulary): L32 +0.038 [+0.032, +0.044]; L40 +0.048 [+0.042, +0.054]; L48 +0.030 [+0.017, +0.043]; L52 +0.078 [+0.063, +0.092]; L56 +0.270 [+0.252, +0.288] | logit lens (full vocabulary): L32 +0.014 [+0.011, +0.018]; L40 +0.010 [+0.005, +0.014]; L48 +0.010 [+0.005, +0.014]; L52 +0.061 [+0.054, +0.069]; L56 +0.283 [+0.267, +0.299] | probe T − C L32: +0.030 [+0.018, +0.042] | probe T − C L40: +0.031 [+0.019, +0.044] | probe T − C L48: +0.053 [+0.038, +0.067] | probe T − C L52: +0.073 [+0.057, +0.089] | probe T − C L56: +0.127 [+0.107, +0.145] | Initials (L40): permutation-control row +0.020 [+0.015, +0.026] ≈ half of the signal +0.045 [+0.039, +0.051]

381_stage13/summary_b2_np/np_lens_compare_v2.csv (Vpd, surname_first; probe_spec, lens_spec) · np_role_layer_v2.csv (tc_diff; initial any_est) · 381_stage13/reports/b2_np_report_v2.md

 新写讲稿

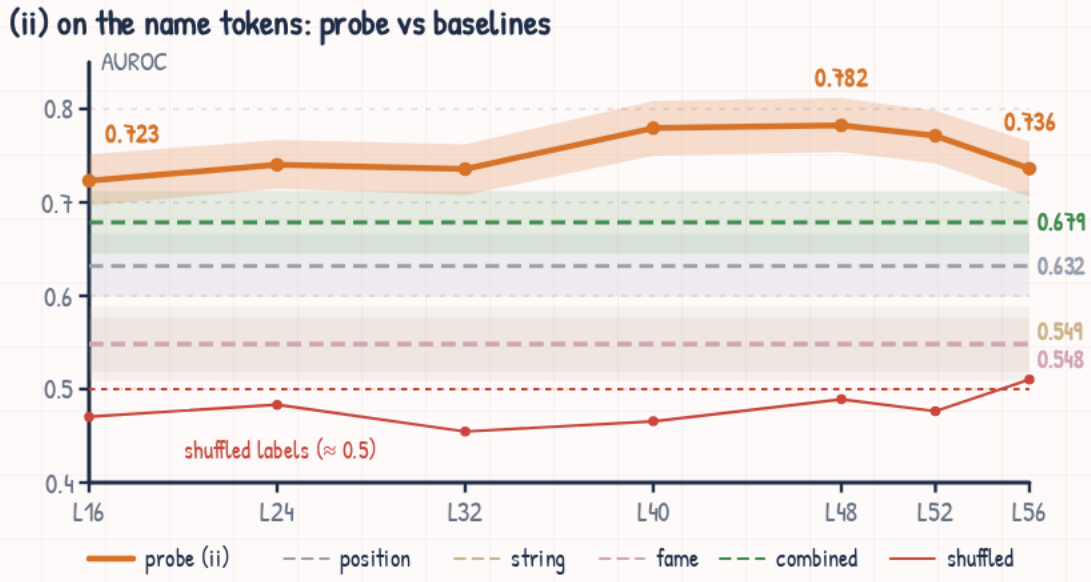
【讲稿】这一页是新的名字位置 probe，直接检验 H3。在预测名字 token 的位置取第 l 层残差，用 ridge 拟合到模型自己在 L63 的状态，再在 9,137 个名字 token 里求真作者的名次；spec = 真标题 − 假标题。姓的第一个 token：probe L40 +0.069、L48 +0.103；右图 target − control L40 +0.031、L48 +0.053，区间都在 0 以上。按补充 11 预注册判据通过（姓首 token L40/L48）；事后检验：lens 区间同样不含 0（logit L40 +0.010，J-lens +0.048），尺度不同无法比较大小，因此降为部分支持。另外，首字母的对照行 +0.020 约为信号 +0.045 的一半。 【怎么算】名字位置 probe：ridge 从第 l 层"预测名字 token 的位置"的残差拟合到同一位置模型自己的 L63 状态，在 9,137 个名字 token 内求名次 → nlr；spec = probe(true) − probe(false)（方法手册 定义：名字位置 probe spec）；target − control：target−control = Σ_b w_b [mean_{target,b} − mean_{control,b}]，w_b = n_t n_c/(n_t+n_c) 归一化 【数据】target + control 6,841 篇中逐个假标题排除后保留 4,654 篇（姓首 token；每篇平均约 1.5 个可用假标题），名字位置（预测每个名字 token 的位置），L32、L40、L48、L52、L56；teacher forcing 【对照】主版本 Vpd（D11-1）；V0（只减 false_0）与 V5x0（含泄漏，仅敏感性）见报告；lens 对照：logit lens、public J-lens 在同一组论文、token、假标题上读；置换对照：gold 换成随机另一篇论文的作者 【区间】团队整群 bootstrap 2,000 次（按作者团队重抽，2.5/97.5 百分位） 【出处】 381_stage13/summary_b2_np/np_lens_compare_v2.csv；np_role_layer_v2.csv；381_stage13/reports/b2_np_report_v2.md（第 5 节判据表）

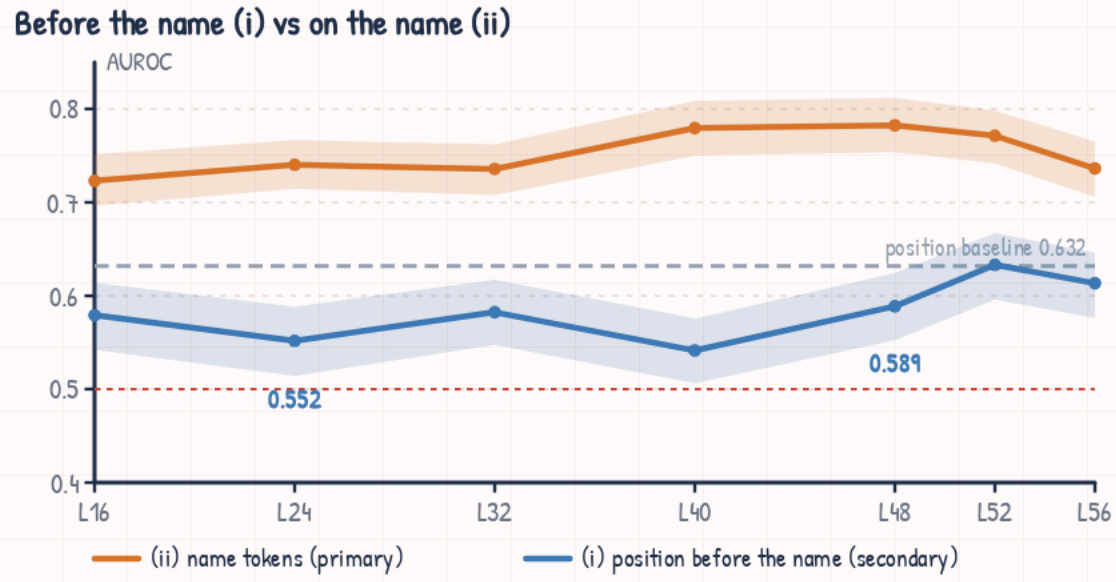
Names the model writes itself: true vs fabricated

C24 · addendum 15, item 2-11b · 518 target papers, 671 true names (M) vs fabricated (H) · team-cluster 95% CI

初步：输出置信度基线暂停

1 model writes the author list itself → 2 residuals saved during generation → 3 label each written name true / fabricated → 4 within-paper AUROC





怎么算：论文内 AUROC：每篇 target 论文（≥ 1 个真作者 M 且 ≥ 1 个编造名字 H）内的全部 M-H 名字对，probe 分数 M > H 记 1、并列记 0.5，取平均（方法手册 定义：2-11b 论文内 AUROC） · 518 篇 target 论文、3,388 个 M-H 对，L16–L56 · 团队整群 95% CI · b2_gennames_b/summary/probe_within.csv；robust_posthoc.csv

Plotted — position: 0.632 [0.599, 0.666] | name / string features: 0.549 [0.509, 0.588] | fame (post hoc): 0.548 [0.519, 0.576] | combined (post hoc): 0.679 [0.645, 0.712] | shuffled: L16 0.470 [0.434, 0.506]; L24 0.483 [0.449, 0.516]; L32 0.455 [0.420, 0.490]; L40 0.466 [0.434, 0.496]; L48 0.489 [0.456, 0.525]; L52 0.477 [0.443, 0.513]; L56 0.510 [0.478, 0.543] | probe (ii) name tokens: L16 0.723 [0.696, 0.751]; L24 0.740 [0.715, 0.767]; L32 0.736 [0.708, 0.762]; L40 0.780 [0.750, 0.808]; L48 0.782 [0.754, 0.812]; L52 0.771 [0.742, 0.798]; L56 0.736 [0.706, 0.765] | probe (i) pre-name position: L16 0.579 [0.542, 0.614]; L24 0.552 [0.514, 0.588]; L32 0.582 [0.548, 0.617]; L40 0.541 [0.506, 0.576]; L48 0.589 [0.552, 0.624]; L52 0.633 [0.596, 0.667]; L56 0.613 [0.576, 0.646]

补充 15 预注册判据：(ii) 在 L16–L56 七层都同时高于排位基线和名字特征基线（例如 L48 0.782 [0.754, 0.812]）；(i) 名字写出之前读不出（不高于排位基线）。
前提：chat 模板下现场生成（不是 teacher forcing）；标签来自规则匹配；control 只作描述；与 H3 的关系未预注册；输出置信度基线（生成时 log-prob / 熵）暂停，待定。

381_stage13/b2_gennames_b/summary/probe_within.csv (auroc_within, lo, hi; position / string baselines) · robust_posthoc.csv (fame, combined, shuffled CI) · b2_gennames_b_report.md, b2_gennames_b_robust_posthoc.md

 新写讲稿

【讲稿】这一页是 C24：让模型自己写作者名单，生成时保存残差，把每个写出的名字标为真作者或编造，再在每篇论文内算 AUROC。名字写出之后，名字 token 上的 probe 在 L16 到 L56 七层都同时高于排位基线（0.632）和名字特征基线（0.549），例如 L48 0.782 [0.754, 0.812]；加上名气、三者合并基线（0.679）后仍更高；打乱标签约 0.5。写名字之前的位置读不出，不高于排位基线。这是初步结果：输出置信度基线没做完——第 0 片重放核对 argmax 一致率 0.979，低于预先定的 0.99，按规则停下，等决定；而且是在 chat 模板下现场生成，标签来自规则匹配，和 H3 的关系没有预注册。 【怎么算】论文内 AUROC：每篇 target 论文（≥ 1 个真作者 M 且 ≥ 1 个编造名字 H）内的全部 M–H 名字对，probe 分数 M > H 记 1、并列记 0.5，取平均（方法手册 定义：2-11b 论文内 AUROC）；判据：CI(probe − 排位) > 0 且 CI(probe − 名字特征) > 0 【数据】target 论文中至少有 1 个真作者和 1 个编造名字的 518 篇，671 个真名，3,388 个论文内名字对；L16–L56 七层；(ii) 名字 token 平均（主）、(i) 写名字之前的位置（次）；chat 模板下现场生成 【对照】基线：名字在列表中的位置；名字长度与队列内频率；名气（事后）；三者合并（事后）；打乱标签（训练折内置换）≈ 0.5 【区间】团队整群 bootstrap 2,000 次（按作者团队重抽，2.5/97.5 百分位） 【出处】381_stage13/b2_gennames_b/summary/probe_within.csv；robust_posthoc.csv；381_stage13/reports/b2_gennames_b_report.md；b2_gennames_b_robust_posthoc.md

What we learned: read early, spoken late

Read early	Causally the title is read in L24–L50 and gathered at the name positions by L52, then no longer needed. A probe at the title token reads a little of it from L24 (re-checked).
Spoken late	At the name positions, paper-specific author knowledge becomes lens-readable only from ~L50, fastest over L57–L61.
No lens lead	Read with a lens at the names, target is not ahead of control in middle layers; the +0.21 gap is at the end (Stage 10, final L63, §6.4) (probe at the title: target − control +0.03–0.08, re-checked (Stage 13 E4b, first name token only)).
Real knowledge	Name prior is ~1/3 of the gap overall but ~0 on surnames (Stage 12 A, 0.087 / 0.247, §6.12); the rest is paper-specific and grows with citations.
Lenses agree	Jacobian lenses read more in middle layers, but nothing target-specific.
Name format	Initials carry little; full given names carry as much as surnames and help predict them.

第 75 / 84 页 · deck 第 14 页 按 deck 讲稿备注翻译（已按复核结果更新）

总结。一句话：读得早，说得晚。标题在 L24 到 L50 被读进来，证据是替换、阻断和标题 token 上的 probe；但作者名字要到 L57 到 L61 才在名字位置变得可读。lens 的结果（目标组在中间层没有领先）和 probe 的结果（标题 token 上的 target − control（同一引用档内，全部作者全部名字 token 按角色，措辞 B 第 3 版）：预注册版中名的第一个 token 在 L24–L48 为正，姓在 L24–L48 不显著（L40 +0.012 [−0.026, +0.048]）；事后的逐个排除版中姓从 L24 起为正（L40 +0.030 [0.013, 0.048]）。名的信号在三版中一致；姓的证据弱，只来自事后版本。首字母在个别层为正、模式不一致（未做多层校正），不作结论。旧版只打首 token 时目标组有优势）说的是不同的位置，两者不矛盾。（probe 的数字已按作者团队分折、剔除标题复用后复核：全部作者全部名字 token 按角色（补充 9，预注册版 V0）：L40 名首 token +0.124、姓首 token +0.071、首字母 +0.044（e4b_alltok.md）（旧版只打首 token：+0.05 到 +0.08）（Stage 13 E4b 复核，标题最后一个 token 上的线性 probe，probe 只打分每位作者名字的第一个 token，真标题 − false_0，按作者团队分折 + 剔除标题复用 + 训练折内标准化，target + control 1,395 篇（剔除后全部论文 1,863 篇，E4b 只用其中 1,395 篇）：L24 +0.050、L40 +0.061、L56 +0.075（L24–L60 为 +0.047 到 +0.075），论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第一张表），目标组高 +0.03 到 +0.08（同上 E4b 复核，probe 只打分第一个名字 token，引用档内 目标−对照，目标 896、对照 499 篇，L24–L60 为 +0.035（L44）到 +0.078，论文 bootstrap 95% CI；报告 §6.11；381_stage13/reports/e4b_trainstd_compare.md Confirmatory 第二张表）。）注意：旧版 E4b 只给每位作者名字的第一个 token 打分（73% 的名字以首字母开头，多数时候是首字母）；上面的主数字是给全部名字 token 打分、按首字母 / 名 / 姓分开的版本（补充 9，见 Stage 13 部分的补充 9 页）：L40 姓的第一个 token +0.071 [0.058, 0.085]、名的第一个 token +0.124 [0.108, 0.142]、首字母 +0.044 [0.030, 0.057]（补充 9，目标 + 对照 1,395 篇，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md）。

Limits

Done: Stage 12

- Single-position patching (P1); attention vs MLP (P2, hook check passed)
- Name priors (N1, N2); author-prompt lens (F1, F2): middle layers still not readable

Done: Stage 13

- Probes read year, citations, field at the title from ≤L16 (M2); identity not above the L4 text level (M3)
- Replacement is task-independent (X1); paraphrase meaning beyond wording in L28–L40, not separable from paper identity (X3)
- First author decodable at L8, may be text-explainable (X4); 5 false titles confirm the Stage 11 timing (X6, X7)

Limits

- One model (Qwen3-32B)
- Teacher-forced preference, not generation
- Labels from the team lead's package; labelling code (elm) not available
- H2 (paper identity) partly supported but not established; H3 (hidden author knowledge): insufficient evidence

局限。Stage 12 和 13 都已完成。Stage 12 做了逐位置替换（P1）、注意力与 MLP 的替换（P2，显式的 hook 检查已通过）、两个名字先验基线（N1、N2）和在作者提示词上拟合的 lens（F1、F2），中间层仍然读不出名字。Stage 13：probe 从 L16 或更早在标题处读出年份、引用数和领域（M2），但 M3 不超过 L4 的文字水平；替换效应与任务无关（X1）；改写标题在 L28–L40 有超出用词的语义，但与论文身份分不开（X3）；第一作者在 L8 可解码，但可能来自标题文字（X4）；X6/X7 用 5 个假标题（Stage 13 X6 用 false_0–false_4 五个假标题重做 Stage 11 替换（L48 平均 0.821、L52 0.995），X7 在 false_0 运行上重做阻断；381_stage13/reports/x6_report.md、x7_report.md）确认了 Stage 11 的时间。局限：只有一个模型；测的是教师强制下的偏好，不是生成；标签来自组长的数据包，elm 标注代码拿不到；H2 部分支持但未确立，H3 部分支持（名字位置 probe，补充 11）。

Added after the defence

Added after the defence (2026-11-05)

Group comparisons (plan fixed before the results: addenda 7, 8) · CPU leftovers (post-hoc) · experiments still running

1. Group comparisons A / B / C / D: three findings, intervention re-runs (E1 and P1 / P2 numerator / denominator), recognition
2. CPU leftovers on existing data: X5 retrieval curve, M3 scores, N2 by layer, paper vs team intervals, M5
3. Redo programme (addenda 10–14): done, batch 1 (complete), batches 2 and 3 (in progress); limits that cannot be redone

 新写讲稿

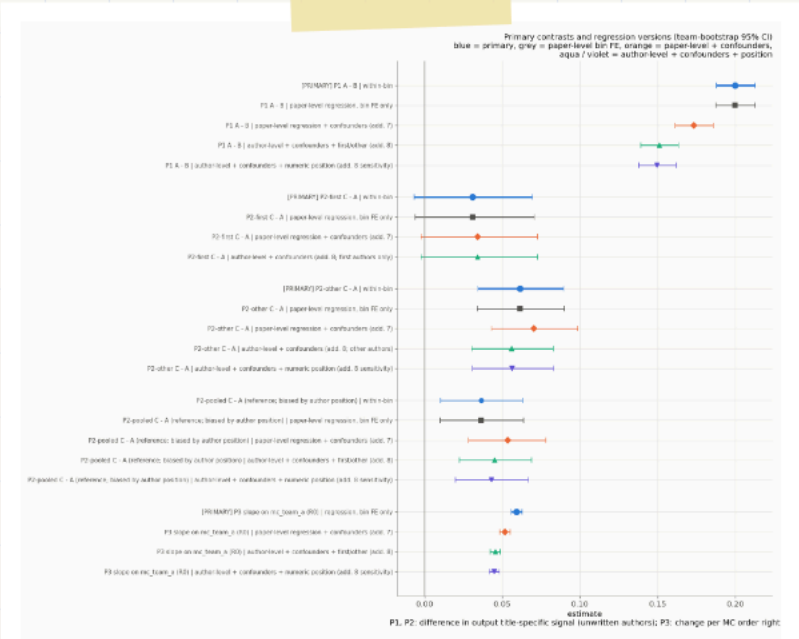
这一部分是答辩（2026-11-02 定稿）之后新增的内容。分组对比是答辩后新增的分析，分析计划在看结果前写定（补充 7、8）；CPU 补充分析是事后分析，只作描述；重做计划（补充 10–13）的规则都在看结果前写定。X2 和补充 9 的结果放在 Stage 13 部分。 2026-11-12：C24 模型自己写出的名字：真作者与编造的名字可在名字 token 上线性区分（较稳但有前提；补充 15，批次 2 第 2-11b 项）：Qwen3-32B 自己写作者名单时，名字写出之后，名字 token 上的中间层残差能线性区分真作者与编造的名字（补充 15 预注册主分析，名字 token 平均；L16–L56 七层都同时胜过排位基线和名字特征基线，例如 L48 AUROC 0.782 [0.754, 0.812]，probe − 排位 +0.151 [0.111, 0.190]，probe − 名字特征 +0.234 [0.186, 0.284]；打乱标签 0.455–0.510）；名字写出之前的位置读不出（次分析，AUROC 不高于排位基线）。前提：在 chat 模板下现场生成的文本上测得，不是其他实验用的原始提示；标签来自规则匹配（matcher v3b）；control 组只作描述（51 个真名）；“probe 信号可能部分来自输出置信度”这一替代解释尚未排除；事后的名气基线（事后，探索性）：只用名气 0.548 [0.519, 0.576]，probe − （排位 + 名字特征 + 名气）在每层仍 > 0（L16 +0.045 [0.008, 0.081] … L48 +0.104 [0.067, 0.139]），名气只覆盖数据集内出现过的情况。补充 15 没有写它与 H3 的关系，不作为 H3 的证据；与 H3 的关系未预注册，只作讨论。（b2_gennames_b_report.md） Patchscope（批次 2 第 2-7、2-9 项，补充 12；只作描述）：用名字位置作源时，第一作者在 L8–L16 约为 0，L40 +0.006 [0.004, 0.008]，L48 +0.014 [0.011, 0.017]（标题位置作源 L40 +0.068 [0.056, 0.080]）；“:” 位置作源到 L40 约为 0，L48 +0.012 [0.009, 0.015]；x4tok 标题位置作源、姓的第一个 token 在 L40 最高 +0.124 [0.099, 0.148]（以上为预注册要求报告、无判定规则；认得出的 target − control 与 name_all 源的 x4tok 部分为探索性）。不据此讨论 H3。（b2_ps_report.md）

Added after the defence · groups

Group comparisons: three findings

Plan fixed before the results (addenda 7, 8) · unwritten authors only · output (L63) title-specific signal · within citation bin · team-bootstrap 95% CI · Holm over 4 tests

- **1 Recognition:** with no author written (R0), recognised papers (A) beat unrecognised ones (B) by **+0.200 [0.188, 0.213]**(P1 A − B, 3,417 / 2,148 papers, Holm p ≤ 0.002; primary.csv); with confounders +0.173 [0.161, 0.186](paper level, 5,565), author level + position +0.151 [0.139, 0.163](19,893 authors)
- **2 Graded:** each extra multiple-choice order right adds **+0.059 [0.056, 0.063]**(P3, 8,288 R0 papers, bin FE; Holm p ≤ 0.002) (confounders +0.046 [0.042, 0.049](author level)); ≈ 0.17 with none right, ≈ 0.46 with all four(R0, 927 / 4,105 papers; stage10_curves.csv)
- **3 Partial recall helps little (≈ ⅓ of recognition), output only:** C − A co-authors **+0.061 [0.034, 0.090]**(P2-other, 390 / 2,826 papers, Holm p ≤ 0.002), first author +0.031 [−0.006, 0.069], n.s.(P2-first, 292 / 3,199); ≈ 0 at L48–L62 with the logit lens, −0.07 to −0.11 at L48–L59 with the public J-lens(stage10_contrasts.csv, unwritten_other). The earlier ≈ +0.11 used all authors (circular)(r0_r1_analysis.md §2)
- **Reference only:** R2 written authors +0.844(200 papers; summary_table.md); only 28 R2 papers have unwritten authors(same)



Primary contrasts (blue) and regression versions; team-bootstrap 95% CI (391_groups/figures/fig3)

第 78 / 84 页 · Added after the defence · groups · 合并 PPT 自身页面 **新写讲稿**

分组对比，答辩后新增的分析，分析计划在看结果前写定（补充 7、8）。只比较模型没写出的作者，指标是输出层（L63）的标题特异信号（真标题 − 5 个假标题平均）。发现 1，识别的效应：两组都一个作者没写对（R0）时，在模型没写出的作者上，认得出的论文（A）比认不出的论文（B）在输出层的标题特异信号高 +0.200 [0.188, 0.213]（分组对比 P1 A − B，A 3,417 / B 2,148 篇、10 个引用档，引用档内差，团队聚类 95% CI；Holm 校正后 p ⩽ 0.002，受 2,000 次重抽的分辨率限制；391_groups/primary.csv）。控制领域、年份、作者人数和首字母开头名字的比例后：论文层面 +0.173 [0.161, 0.186]（5,565 篇；primary.csv）；作者层面再加作者排位 +0.151 [0.139, 0.163]（19,893 位作者；primary.csv）。发现 2，识别程度与信号成梯度关系：在 R0 论文里，多选题 4 种选项顺序中每多答对一次，输出层信号高 +0.059 [0.056, 0.063]（P3，R0 论文 8,288 篇，引用档固定效应；primary.csv）；控制混杂后 +0.046 [0.042, 0.049]（作者层面，30,060 位作者）。全错时约 0.170，全对时约 0.463（0 种对 927 篇 0.170、4 种对 4,105 篇 0.463；391_groups/stage10_curves.csv）；识别不确定的论文落在两组之间。发现 3，写对一部分作者，对没写出的作者的额外帮助较小（约为识别效应的三分之一），而且只出现在最终输出：合作者 +0.061 [0.034, 0.090]（P2-other C − A，C 390 / A 2,826 篇，Holm p ⩽ 0.002；primary.csv），第一作者 +0.031 [−0.006, 0.069]，不显著（P2-first，C 292 / A 3,199 篇；primary.csv）。logit lens 下 L48–L62 约为 0（P2-other 按层，logit lens −0.019 到 +0.035，区间都含 0）；公开 J-lens 下 L48–L59 为 −0.07 到 −0.11（public J-lens，区间都在 0 以下；391_groups/stage10_contrasts.csv）。以前用全部作者算出的约 +0.11（351_stage10/reports/r0_r1_analysis.md §2），主要是因为模型已经写出的作者分数本来就高（循环论证）。参照：R2 写出的作者在输出层为 +0.844（200 篇；391_groups/summary_table.md），只作上限参照；R2 里有未写出作者的论文只有 28 篇，不做对比。

Added after the defence · re-runs

Re-runs: numerator and denominator

Addendum 8 · E1 recovery R = mean(patched − false) ÷ mean(true − false) · unwritten authors · team-cluster 95% CI

group (unwritten authors)	papers	denominator: true − false	E1 numerator L48	E1 R(L48)	E1 R(L52)
A R0 × recognised	557	+0.407 [0.386, 0.430]	+0.330	+0.811 [0.790, 0.832]	+0.988 [0.980, 0.996]
B R0 × not recognised	586	+0.214 [0.196, 0.234]	+0.186	+0.869 [0.835, 0.906]	+1.016 [1.002, 1.031]
U0 R0 × uncertain	599	+0.293 [0.271, 0.316]	+0.248	+0.844 [0.814, 0.877]	+1.000 [0.988, 1.012]
C R1 × recognised (addendum 11 B)	462	+0.559 [0.529, 0.590]	+0.408	+0.731 [0.705, 0.757]	+0.985 [0.977, 0.994]
R2 written authors (reference)	200	+0.845 [0.798, 0.897]	+0.566	+0.670 [0.630, 0.707]	+0.948 [0.927, 0.965]

B's higher ratio is a small-denominator effect: numerator B − A −0.010, −0.040, −0.144, −0.184 at L24 / L40 / L48 / L52, all CIs below 0(e1_e2_num_den_B_minus_A.csv) — B carries no more absolute paper-specific signal than A at any layer.

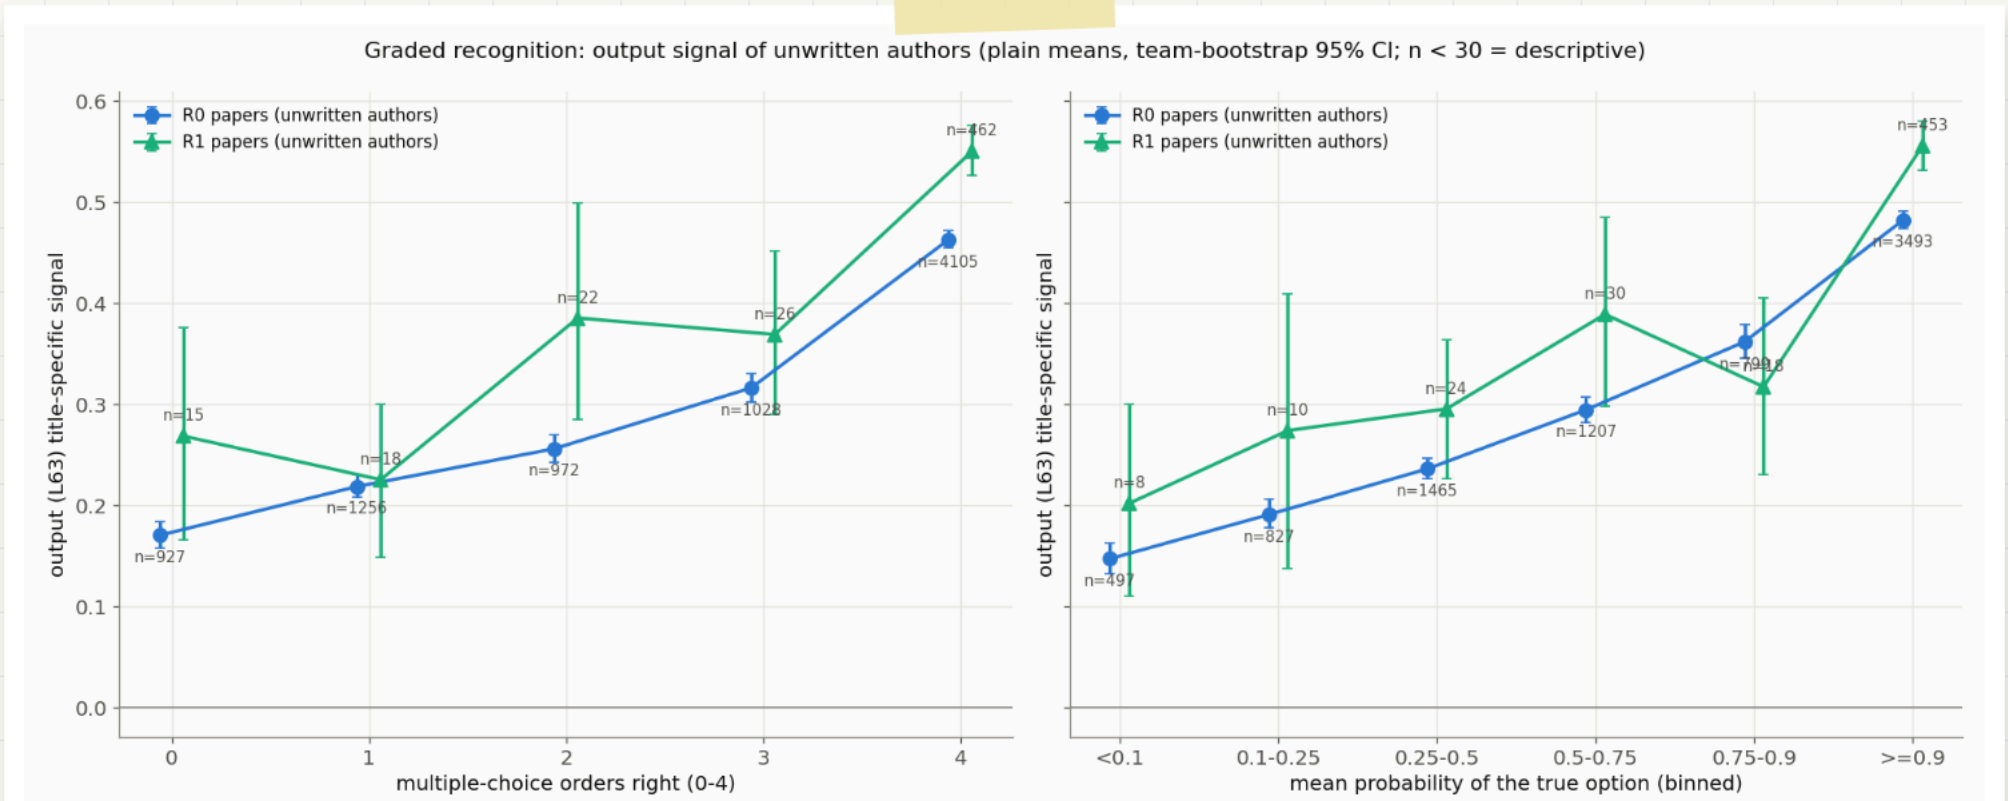
U0 reaches R ≈ 1 by L52 like A and B (descriptive); R2 upper reference only; C completed to 462 papers: within bin (258 of 462 C papers, 6 bins) reaching R ≈ 1 by L52 like A, larger gap (C − A +0.075 [+0.024, +0.130]); D 33 / R2-unwritten 28 papers → descriptive(rerun_report.md Counts; b2_cd_report.md)

补充 8 的干预重跑（R2 × strong 204 篇、R0 × uncertain 600 篇）与 Stage 11 原样本一起，只按模型没写出的作者汇总。E1 恢复比例 R = mean(替换 − 假标题) ÷ mean(真标题 − 假标题)。分母（真标题 − 假标题）：A 0.407、B 0.214、U0 0.293、C 0.559（E1，未写出作者，最终输出；A 557、B 586、U0 599 篇；391_groups/reports/e1_num_den.md；C 为补充 11 B 补全后的 462 篇，[0.529, 0.590]，391_groups/reports/b2_cd_report.md；原 32 篇时为 0.464）。分子 B − A 在 L24、L40、L48、L52 为 −0.010、−0.040、−0.144、−0.184，区间都在 0 以下（配对团队 bootstrap；391_groups/summary_rerun/e1_e2_num_den_B_minus_A.csv）：B 的恢复比例较高（L48 0.869 对 A 0.811（e1_num_den.md））只是因为分母约为 A 的一半（B/A 0.53），B 在任何一层携带的论文特有绝对信号都不比 A 多。U0 的时间点与 A、B 相同（R(L48) 0.844、R(L52) 1.000（U0 599 篇；rerun_report.md），描述）。R2 只作上限参照（写出的作者真假差距 0.845（R2 写出的作者 200 篇））；D 33 篇、R2 未写出作者 28 篇（rerun_report.md Counts 表；b2_cd_report.md）只作描述。C / D 组补全 E1 / E2（批次 2 第 2-6 项，补充 11 B，已完成）：C 组未写出作者 462 篇，同一引用档内与 A 相比（6 个引用档，C 258 篇、A 323 篇）：E1 恢复比例 L48 −0.037 [−0.080, +0.009]，L52 +0.007 [−0.009, +0.024]；L56 −0.007 [−0.014, −0.001]，个别层差异极小，不作解释（小于批量舍入噪声：同一输入按 batch 1 和 15 元素 batch 计算，组级 E1 恢复比例的差最大 0.0148（L40），L52 约 0.002，只给分布、没有 CI；补充 12 第 2-4 项，381_stage13/reports/b2_e1noise.md）；E2 阻断损失 L32–L52 区间都含 0。C 的真假标题差距更大：分母 C 0.559 [0.529, 0.590]、A 0.407 [0.386, 0.430]，同档内 C − A +0.075 [+0.024, +0.130]。也就是说，C 的信号更大，但时间点与 A 相同。D（33 篇）按补充 11 只作描述，D − B、C − D 也只作描述（补充 11 B；未写出作者；团队整群 bootstrap 2,000 次 95% CI；391_groups/reports/b2_cd_report.md Numerator / denominator 表与 Contrasts 表；硬检查：重跑 Stage 11 第 0 号分片，差 0.0（容差 0.005），PASS）。前提：同一引用档内只用到 C 462 篇中的 258 篇；分子、分母都只用 false_0；比例差主要反映分母不同（分母效应）。

Added after the defence · groups

Recognition changes the size; timing nearly the same

Unwritten authors, output (L63) signal, plain means with team-bootstrap 95% CI; n < 30 descriptive



Left: multiple-choice orders right (0-4); right: mean probability of the true option. Blue R0, green R1 (391_groups/figures/fig2)

Re-runs: over 0–4 orders right the denominator rises 0.185 → 0.407, while E1 R(L48) falls slightly, 0.90 → 0.81 (R0 papers A + U0 + B, 241 / 557 papers at 0 / 4; rerun_report.md “Continuous recognition”)

怎么算： 未写出作者的 spec（L63，真 − 5 个假标题平均）按识别程度分组的普通均值 · R0 927–4,105 / R1 15–462 篇 · 团队整群 · 出处：stage10_curves.csv、rerun_report.md

80

第 80 / 84 页 · Added after the defence · groups · 合并 PPT 自身页面 **新写讲稿**

【讲稿】识别程度改变信号的大小；时间几乎相同——各组到 L52 都达到 R ≈ 1（R(L52)：A 0.988 [0.980, 0.996]、U0 1.000 [0.988, 1.012]、B 1.016 [1.002, 1.031]、C 0.985 [0.977, 0.994]，“L52 之前完成”不受影响），而在 L48 识别程度高的论文恢复得略少（R(L48) 每多答对一次 −0.019 [−0.032, −0.007]，事后分析；答对次数与组 B → U0 → A 重合，所以这是组间比较，不是组内剂量反应；391_groups/summary_rerun_plot_20261112/trend.csv）。按多选题答对次数（0 到 4）分组，未写出作者在输出层的标题特异信号从 0.17 升到 0.46（R0），R1 到 0.55；右图按真选项概率分箱，趋势一样。重跑的 E1 显示：从答对 0 次到 4 次，分母从 0.185 升到 0.407，L48 的恢复比例略降（0.90 → 0.81，每多答对一次 −0.019 [−0.032, −0.007]，事后；答对次数与组 B → U0 → A 重合，是组间比较）。认得越清楚，信号越大，但标题被读入的层是一样的。 【怎么算】未写出作者的 spec（Stage 10 最终输出 L63，真标题 − 5 个假标题平均，对名字 token 平均），按多选答对次数 / 真选项概率分组取普通均值；E1 分母 = mean_p[T_p − F_p] 【数据】R0 每组 927–4,105 篇，R1 每组 15–462 篇（n < 30 只作描述）；重跑：答对 0 次 241 篇、4 次 557 篇 【对照】5 个假标题（信号）；false_0（E1 分母） 【区间】团队整群 bootstrap 2,000 次（按作者团队重抽，2.5/97.5 百分位） 【出处】391_groups/stage10_curves.csv；391_groups/reports/rerun_report.md “Continuous recognition”

Added after the defence · re-runs

P1 / P2: the same small-denominator effect

Stage 12 single positions (P1) and attention / MLP (P2) split by group · unwritten authors · paired team bootstrap 95% CI

patched part	layer	numerator B − A	ratio B − A	numerator B/A
P1 all name positions	L48	−0.105 [−0.123, −0.087]	+0.052 [+0.011, +0.098]	0.57
P1 all name positions	L56	−0.183 [−0.209, −0.157]	−0.050 [−0.087, −0.012]	0.50
P2 attention	L48	−0.029 [−0.038, −0.021]	+0.057 [+0.030, +0.086]	0.66
P2 MLP	L56	−0.041 [−0.053, −0.029]	+0.008 [−0.030, +0.044]	0.54
P1 ':' only	L48	−0.000 [−0.007, +0.005]	+0.050 [+0.026, +0.071]	0.99
P1 ':' only	L52	−0.013 [−0.024, −0.002]	+0.073 [+0.038, +0.106]	0.79

B's higher P1 / P2 ratios also come from the small denominator: B's numerator is below A's at the name positions, in attention and in the MLP; at the ':' token the numerators are similar in L44–L48 (B/A 0.72–0.87 with five false titles; false_0 0.78–0.99), and B's ratio is higher only because its denominator is about half of A's(A 557 / B 586 papers; denominator B − A −0.192, B/A 0.53; p1_p2_num_den_B_minus_A.csv; e1_num_den.md P1/P2)

B 组的 P1/P2 比例偏高同样来自分母小：名字位置、注意力和 MLP 上 B 的分子都低于 A（Stage 12 P1 / P2 按组重算，未写出作者，最终输出，A 557 / B 586 篇；分子 B − A：名字位置 L48 −0.105 [−0.123, −0.087]、L56 −0.183 [−0.209, −0.157]，注意力 L48 −0.029 [−0.038, −0.021]，MLP L56 −0.041 [−0.053, −0.029]，配对团队 bootstrap 95% CI；391_groups/summary_rerun/p1_p2_num_den_B_minus_A.csv；reports/e1_num_den.md P1 / P2 节）；':' token 在 L44–L48 两组分子相近（B/A：5 个假标题版 0.72–0.87，false_0 版 0.78–0.99（只替换 “:”，分子 B/A：5 个假标题版 L44 0.72、L48 0.87，391_groups/reports/b1_p12f_report.md；false_0 版 L44 0.78、L48 0.99，同一文件）），B 的比例高只因分母约为 A 的一半（分母 B − A −0.192 [−0.222, −0.162]，B/A 0.53；同一文件）。

Added after the defence · CPU

CPU leftovers on existing data (post-hoc)

No new GPU runs · descriptive only · not in the pre-registration except the X5 retrieval curve

- **X5 retrieval curve (pre-registered, computed now):** top-1 retrieval of the same paper across questions is never above L4(M3 cache, 9,108 papers; x5_retrieval.md) (title token 1.000 up to L44, 0.734 at the output)(same, team CI)
- **M3 behaviour scores:** year target − control +0.007 [0.003, 0.012]; all authors, all name tokens +0.234 [0.215, 0.252] (2-10; old first-author first-token version +0.147 [0.096, 0.191])(output, 4,621 / 2,220, within bin, team CI; m3_scores.md)
- **N2 by layer:** pure name prior target − control +0.047 at the output, +0.039 at logit L62; public J-lens L48 −0.133 (true title)(Stage 12 N2 rescored by layer; n2_layers.md) → only L62 reproduces the output pattern
- **Paper vs team intervals:** width ratio 0.97–1.00 (median); "excludes 0" changes in 2 of 1,155 rows(X1, X4, X6, X7, M3; v42_paper_vs_team.md)
- **M5 true vs false title at the name positions:** output 0.919; logit L24 0.516 → L62 0.899(share of pairs, all papers × 5 false titles, team CI; m5_report.md); probe at title / colon AUROC 0.50–0.52(same, Part B)

答辩后补算的 CPU 分析，都用已有数据，属于事后分析，只作描述。X5 预注册的跨任务检索曲线：同一篇论文在三种问法下的标题状态能否在全部论文中检索回自己，没有一层高于 L4（X5 检索，M3 残差缓存，9,108 篇，top-1，团队聚类 95% CI；381_stage13/reports/x5_retrieval.md）；标题最后一个 token 上 L44 以前都是 1.000，最终输出 0.734（同上，[0.725, 0.742]）。M3 提示下的行为分数：年份 target − control +0.007（M3 年份分数，最终输出，目标 4,621 / 对照 2,220，引用档内差，团队 CI [0.003, 0.012]；381_stage13/reports/m3_scores.md），全部作者全部名字 token +0.234（补充 12 第 2-10 项，[0.215, 0.252]；b2_m3tok.md）（旧版只看第一作者首 token：+0.147（[0.096, 0.191]）），作者差与分组定义有关。N2 按层：纯名字提示 target − control 在最终输出 +0.047（Stage 12 N2，团队 CI [0.031, 0.062]；371_stage12/reports/n2_layers.md），logit lens L62 +0.039（同上）；public J-lens L48 真标题下 −0.133（同上，[−0.161, −0.107]），只有 L62 重现输出端的模式。论文与团队区间：宽度比中位数 0.97–1.00（381_stage13/reports/v42_paper_vs_team.md 第 1 节），“区间是否含 0”只在 1,155 行中的 2 行改变（同上第 2 节）。M5：名字位置上真标题运行胜过假标题运行的比例，最终输出 0.919（M5 Part A，全部论文 × 5 个假标题，团队 CI [0.915, 0.924]；381_stage13/reports/m5_report.md），logit lens L24 0.516、L62 0.899（同上）；标题和“:” 位置用 probe 区分真/假标题运行，AUROC 0.50–0.52（同上 Part B），基本分不开。

Added after the defence · redo programme

Redo programme (addenda 10–14)

All rules fixed before the results · reproducing the published numbers is a hard check for every item · status 2026-11-08

- **Done:** X7 with five false titles; all-token probe (addendum 9); CPU items C-1 to C-5; C-3b (no-exclusion sensitivity, includes leakage, not a conclusion)
- **Batch 1, done:** X1–X4 for all authors → conclusions unchanged (X1 task-independent, small L48 author – year +0.024; X3 keeps ≈ 90%; X4 from L8; X2 moves 0.032, subspace $R^2 \leq 0.009$, X2 alone leaves H3 insufficient)(b1_xall_report.md) · E4b, per-donor exclusion (4,654 papers, ~1.5 false titles each): surname L40 +0.076 [0.068, 0.083], surname – initial +0.033(b1_e4b5_report.md)
- **Batch 1, done:** P1 / P2 with five false titles (five-title mean primary, false_0 beside): every mean5 – false_0 CI includes 0 → conclusions unchanged; colon numerator B/A 0.72–0.87; p9: 694–711 papers per false title, different sets, unweighted(b1_p12f_report.md)
- **Batch 2 (addenda 11, 12):** running; C / D completion done (C 462 papers; within bin 258 of 462 vs A: R ≈ 1 by L52); 2-11 stopped by its hard check → 2-11b (addendum 15): done: pre-registered verdict passes at all 7 layers (C24); 2-2, 2-3, 2-4, 2-5 (name-position probe: H3 partly supported), 2-8, 2-10 done; Patchscope (2-7, 2-9) done (descriptive only); 2-1: deviation D12-5 (gate reference computed in the wrong precision, f64 vs the fp32 log; not a relaxed criterion); gate fixed to fp32 vs fp32 and resumed, gate v4 queued; deviations recorded (D12-1 to D12-3; 2-7 source = year-free X4 prompt)(prereg_addendum12_deviations.json)
- **Batch 3 (addendum 14):** 3-1 Stage 10 L41–L47, L49: done · 3-2 L0–L23: running (194/504) · 3-3 Stage 7.1B fast path: stopped (deviation D14-1; equivalence with the old per-prefix results not confirmed); 3-4 / 3-5 (Stage 8 GPU W) not run(prereg_addendum14.json)
- **Not done:** Stage 8 GPU re-run of the original W (user decision 2026-11-06; CPU proxy C-2 instead)(c13_C2.md)

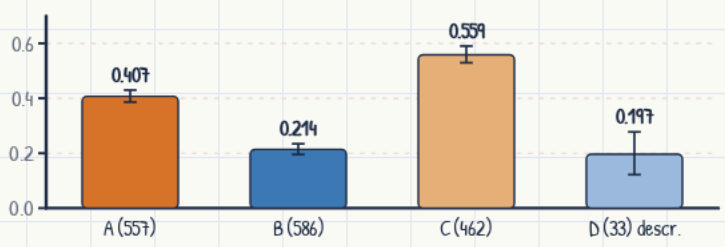
重做计划（补充 10–14，规则都在看结果前写定并锁定；复现已发表数字是每一项的硬检查）。已完成：X7 五个假标题、补充 9 全部名字 token 的 probe、CPU 项 C-1 到 C-5（b1_x7f_report.md、e4b_alltok.md、c13_C1–C5.md）；C-3b（不剔除标题复用，只作敏感性分析，含泄漏，不作结论）（c13_C3b.md）。批次 1 已完成：X1–X4 改为给全部作者打分（全部名字 token），并按作者排位分层。结论都不变：X1 仍与任务无关，L48 有一点小而确实的任务依赖（作者 – 年份 +0.024 [0.019, 0.030]）；X3 改写标题保留约 90% 的作者偏好，target 与 control 一样；X4 从 L8 起可解码出作者，各作者排位相同，认得出的论文方向上更高，但按预注册在测试集上不显著（L8 +0.023 [−0.001, +0.048]，v42_paper_vs_team.md §3）；但只靠标题文字的基线不弱于 Qwen，仍不能排除标题文字的解释，不再作为 H2 的证据。X2 用全部作者重新拟合作者子空间后，搬动量从 0.016 升到 0.032（完整替换的约 7%），但子空间本身仍几乎解码不出作者（留出 $R^2 \leqslant 0.009$），单看 X2，H3 证据仍不足（b1_xall_report.md）。E4b 逐个假标题排除版（偏离 D1，4,654 篇，每篇约 1.5 个可用假标题）：L40 姓首 token +0.076 [0.068, 0.083]，姓 – 首字母 +0.033 [0.023, 0.042]；硬检查 E4b L40 +0.0609 PASS（b1_e4b5_report.md）。P1 / P2 用 5 个假标题（已完成）：5 个假标题平均为主结果，与 false_0 之差的区间都含 0，结论不变；p9 各假标题 694–711 篇，集合不同，未加权；“:” 分子 B/A 0.72–0.87（false_0 0.78–0.99）。C / D 组补全（已完成）：C 462 篇，同一引用档内与 A 时间点相同；D 33 篇只作描述（b1_p12f_report.md；b2_cd_report.md）。批次 2（补充 11、12）：批次 1 结束后已由编排作业开始运行；2-11 模型自生成名字的首名复现率 0.880 < 0.90，按预注册停止，改为 2-11b（补充 15，已锁定），已完成：预注册判定在 7 层都成立（见 C24）；2-3、2-4、2-8、2-10 已完成；名字位置 probe、2-2 已完成；Patchscope 已完成（描述）；2-1：出入记录 D12-5（gate 精度修正），gate v4 排队中；出入记录见补充 12（D12-1 到 D12-5；2-7 的来源改用不含年份的 X4 提示）。批次 3（补充 14）：3-1 已完成，3-2 运行中（194 / 504）；3-3（7.1B 快路径补完）已停止（偏离 D14-1）：3-3 停止：只有 7 篇论文同时有旧逐前缀结果和快路径结果，不足以确认两者在 ±0.02 内等效（输出层 target−control 差值之差 +0.0059，按论文 Welch 95% CI [−0.0207, +0.0324]；论文级 bootstrap [−0.0005, +0.0181]，因每组仅 3–4 篇偏窄，不作判据）。差异来源为 bf16 舍入随前向长度变化；长度跨档比例 target 28%、control 15%。Stage 10 全程使用快路径，组间口径一致，一致性检查按 0.25 容差（351_stage10.py 第 919 行）通过率 99.81%。（更正（2026-11-12）：99.81% 出自 3-3 检查；Stage 10 主轮见局限 L02。）决定过程：原判据（≥ 99% 名次完全一致）未通过（79.8%）→ 用户指出事后判据的设计缺陷 → 在看到论文级结果之前写定并锁定修正判据 → 按修正判据（Welch 区间）仍未通过 → 停止。（381_stage13/config/prereg_addendum14_deviations.json）；3-4、3-5 不做（Stage 8 按原 W 的 GPU 重算，用户 2026-11-06 决定）（prereg_addendum14.json）。

Added after the defence · limits

Limits that cannot be redone

Written 2026-11-06; last three items added 2026-11-08 (v30)

- **One model:** the groups (recognised or not, authors written or not) come from Qwen3-32B's own labels; another model would need new labels
- **Teacher forcing:** every score is the rank the model gives the correct name once it is in the prompt — a preference, not generation (C24 使用模型自生成文本，非 teacher forcing)
- **Label pipeline:** the label package author's elm code and run.json are not on the cluster, so generation length, thinking mode and the multiple-choice setup cannot be re-checked
- **High-citation bins:** the 4097+ bin has no B / D papers(84 target, 0 control; m3_scores.md §2), so within-bin comparisons cannot use it
- **Layers and samples:** Stage 10 samples L24–L40 every 8th layer (no L25–L31, L33–L39; no plan to fill; L41–L47, L49 filled by 3-1); interventions use 1,186 of 9,108 papers; denominator effects (C 0.559 vs A 0.407)
- **Post hoc and single title:** parity tolerance 0.25 → 0.5 was used, a post-hoc change (main round: 10 of 25 pairs above 0.25, max 0.367; size matches bf16 rounding, up to ~0.46); M5 part B and the E4b X1-controls pipeline use false_0 only, no plan
- **Layer gap, stopped item:** X4 year onset somewhere in L33–L40; Jacobian vs logit jump between L32 and L40; X4 first-author peak could be L33–L47 · 2-11 stopped (first-name reproduction 0.880 < 0.90)



Denominator effect (L03): E1 true − false gap by group, unwritten authors

怎么算：分母 = mean_p[T̄_p − F̄_p]（recovery(l) = mean_p[P̄_p(l) − F̄_p] / mean_p[T̄_p − F̄_p] 的分母，false_0）· 未写出的作者，Stage 11 样本 + 补充 11 B 补全（C 462、D 33 篇只作描述）· 团队整群 95% CI · 出处：391_groups/b2_cd/summary/cd_group_values.csv（b2_cd_report.md）

Plotted — A: 0.407 [0.386, 0.430] (n 557) | B: 0.214 [0.196, 0.234] (n 586) | C: 0.559 [0.529, 0.590] (n 462) | D: 0.197 [0.122, 0.277] (n 33)

 新写讲稿

【讲稿】最后是不能重做的局限。只有一个模型，分组也来自它自己的标签；teacher forcing 测的是偏好不是生成——例外是 C24，它用的是模型自生成的文本，不是 teacher forcing；标签代码拿不到；4097 以上的引用档没有 B、D 论文；层不完整，干预只用了 1,186 篇；parity 容差事后从 0.25 放宽到 0.5；2-11 首名复现率 0.880 低于 0.90 而停止。下面的图是各组 E1 的分母（真 − 假差距）：C 0.559、A 0.407，B 只有约一半，所以比较恢复比例时要先看分母。 【怎么算】分母 = mean_p[T̄_p − F̄_p]，即 recovery(l) = mean_p[P̄_p(l) − F̄_p] / mean_p[T̄_p − F̄_p] 的分母；parity：max |Δlogit|（容差 0.25 → 0.5）；首名复现率 = 复现出的第一作者名字比例 【数据】E1 未写出作者：A 557、B 586、C 462、D 33 篇（D 只作描述）；parity 12 个上下文、25 对；2-11 首名复现率 0.880 【对照】分母只用 false_0；C 与 A 比较在同一引用档内（258 篇可比） 【区间】团队整群 bootstrap 2,000 次（按作者团队重抽，2.5/97.5 百分位）（分母柱）；parity 与复现率无区间 【出处】391_groups/b2_cd/summary/cd_group_values.csv；351_stage10/reports/parity.json；381_stage13/orch_b2/state.json；m3_scores.md §2