逐个实验讲解稿（方法详解版）：设计、数据处理、公式、结果、说明什么

配合 PPT v21 和报告第 30 版使用（2026-11-08 更新：P1 / P2 五个假标题、C / D 组补全、Stage 8 的三个前提和新增局限已加入；2026-11-06 更新：补充 9、X7 五个假标题等重做结果已加入）。第〇部分是所有实验共用的打分和统计方法，先讲一次，后面每个实验只讲自己特有的设计和公式。数字和定义均取自方法手册（2026-11-03 定稿）。

第〇部分：共用方法

0.1 模型与提示

- 模型：Qwen3-32B，bf16，64 层，每层每个位置的内部状态（残差流）是 5,120 维。
- 作者问法（裸文本，不套聊天模板）：
  > Who are the authors of the paper titled "{标题}" ({年份})? Authors: {一位作者}
- **单独打分（Stage 10 起的默认）**：每位作者单独接在 “Authors:” 后面，各自一个上下文，和其他作者无关，即 encode(提示) + encode(" " + 作者名)。**连写打分**（“Authors: A1, A2, …”）只用在 Stage 11 的作者连写实验和 Stage 12 N1。
- 关键位置：**标题最后一个 token**（这时模型还没看到年份，不会泄题）、**“:”**（它的输出就是第一个名字 token）、**名字位置**（回答里每个名字 token 所在的位置）。
- 打分方式是 **teacher forcing**：把正确作者名直接放进回答里，看模型给它打多少分，而不是让模型自己生成。

0.2 一个 token 的分数

在某个读出工具 r、某一层 l、某个位置上，模型给出对全词表 V = 151,936 个 token 的打分 z。对正确 token g：

> **rank = 1 + #{v : z_v > z_g}**（只数严格更高的；并列不往后排） **nlr = log10(1 / rank) = −log10(rank)**

排第 1 得 0，第 10 得 −1，第 100 得 −2，最低约 −5.18。不去掉特殊 token，比较对象是全部 151,936 行。

0.3 一篇论文的分数

> **mean_nlr(论文) = 这篇论文所有被打分作者的所有名字 token 的 nlr 平均**

这是主指标，按 token 加权；按作者先平均再平均的版本作为次要指标一并报告。组间、层间比较时，先得到每篇的值，再对论文求平均。

0.4 七个提示条件与标题特异信号

同一篇论文、同一组名字 token，只换提示里的标题，共 7 个条件：真标题、5 个假标题（false_0…false_4）、删掉标题。

> **spec（标题特异信号）= true − (1/5) Σ false_k** total = true − delete topic = false 平均 − delete

因为名字 token 完全相同，名字本身好不好猜在差值里抵消，spec 只剩“认得这篇论文”带来的部分。

算例（手册 G5.5，一篇真实论文，模型输出层，3 位作者 16 个 token）：

条件	mean_nlr
真标题	−0.7190
false_0 … false_4	−1.0234、−1.1540、−1.2625、−1.1334、−0.9895（平均 −1.1126）
删标题	−0.8808

> spec = −0.7190 − (−1.1126) = **+0.394**，名次约好 2.5 倍 total = −0.7190 − (−0.8808) = +0.162 topic = −1.1126 − (−0.8808) = −0.232

这篇论文换上别的同领域标题，作者分数反而比不给标题还低（topic 为负），只有真标题才明显抬高。

0.5 假标题怎么选

对每篇论文，从**同领域**的其他论文里挑 5 个借标题，年份保留本篇自己的。先排除：本篇自己、和本篇有任何共同姓氏的论文、标题词重合（≥4 字母的词，Jaccard）> 0.6 的论文。然后按代价最小指派：

> **代价 = |Δ年份|/5 + |Δ作者数| / max(1, 0.25·n) + |Δ标题 token 数| / max(1, 0.2·长度) + 1.5·|Δ引用档|**

按 strict → medium → loose → nearest 四档依次放宽，每档用匈牙利算法（linear_sum_assignment）做最小代价指派；strict、medium、loose 三档每个供体最多借出 5 次，nearest 档最多 7 次。false_0 是档最好、代价最低的那个。78.8% 的配对来自 strict 档。

0.6 target 与 control 的比较

只在两组都至少 30 篇的引用档里比（主分析 10 档：0–2 到 513–1024）：

> **target − control = Σ_b w_b · (target 平均_b − control 平均_b)**，**w_b = n_t·n_c / (n_t + n_c)**，再归一化

两组越平衡的档权重越大。例：一档 target 100、control 30，权重 23；一档各 50，权重 25。

置信区间：Stage 10 在“档 × 组”内对论文有放回重抽 2,000 次取 2.5/97.5 分位；复核后改为**按作者团队整群重抽**，点估计不变。

作者团队：两篇论文共享任一作者全名就并成一组（并查集，A–B 共享、B–C 共享，则 A、B、C 同组），全队列 7,247 个团队。所有 probe 的 5 折都按团队分，同一团队全在训练或全在测试。

0.7 干预实验的两个比例

恢复率（替换实验）：

> **R(l) = 平均[s(替换后) − s(假)] ÷ 平均[s(真) − s(假)]**

损失（阻断实验）：

> **Loss(l) = 平均[s(真) − s(阻断后)] ÷ 平均[s(真) − s(假)]**

两者都是**先对所有论文平均分子和分母，再相除**，避免真假差接近 0 的论文把比值拉爆。例：真 1.0、假 0.2、替换后 0.6，R = 0.4/0.8 = 50%。

0.8 读出工具

- **logit lens**：直接把第 l 层的状态送进最后一步：logits = lm_head(final_norm(h_l))。
- **Jacobian lens**：先估计“第 l 层的变化会怎样影响 L63”：用一批普通文本，对 L63 的每个维度做一次反向传播，得到 Jacobian 矩阵 J_l，在有效位置（跳过前 16 个位置和最后一个）和所有文本上平

均。使用时 logits = lm_head(final_norm(J_l · h_l))。三把 lens：public（Neuronpedia，557 条 WikiText-103）、self100（100 条）、fitA（另 100 条）。

- **模型输出**：L63 的真实输出。

0.9 名字 token 怎么切

注意有两种“切名字”，不要混：

（1）我们打分用的切分（方法手册 G5.2）：标注包的 authors 列按 “;” 切开、去首尾空白；每位作者前面加一个空格，用 Qwen 分词器切成 token。再给每个 token 标角色：按空白分词，最后一个词是**姓**；van、de、von 等是**前缀**；单个字母（可带点，如 “G.”）是**首字母**；其余是**名**；整个 token 都是标点（如 “.”）的记为 punct。每个词的第一个 token 记为“_first”，后续记为“_cont”。规模：33,811 位作者、149,999 个名字 token；没有作者因过长被排除。

（2）组长的 panel.py：把模型开放回答里写出的那一串文字切成一个个名字，用来算 M/H/U。这一项的规则还需要组长确认。

0.10 一致性检查（PPT 第 9 页）

- 快路径（一次前向给整个名字打分）和慢路径（每个前缀单独前向）：最大 logit 差 0.16–0.37，约 1–1.5 个 bf16 单位；名次 1–41 完全一致。
- 和 Stage 6 核对 972 个 token：token id 相同，log-prob 差中位数约 10^{-5}。
- 标点阴性对照：标点 token 的标题特异信号每层都约为 0。
- 容差在看到 bf16 差距后从 0.25 放宽到 0.5，原记录保留。

第一部分：它知道吗？

实验 1：分组（Stage 1）

设计：用组长的标签流程，在同一个 Qwen3-32B 上对 9,108 篇论文做开放回答和多选题。

数据处理与公式：

- 开放回答：chat 模板、关闭 thinking、贪心解码、最多 96 token。用 NameMatcher（姓 + 名首字母）把写出的名字和真名单匹配，得到 M（写对）、H（编造）、U（漏掉）。
  > **HR2 = (H + U) / (M + H + U)** R0：M = 0；R1：M > 0 且 HR2 > 0.5；R2：HR2 ≤ 0.5（guard，不分析）例：4 位作者，模型写了 3 个名字、1 个对 → M = 1, H = 2, U = 3，HR2 = 5/6 ≈ 0.83 → R1
- 多选题：真名单 + 3 个同领域、同团队规模、同引用档、年份相近的真实团队，4 种顺序各问一次，读下一个 token 上 A/B/C/D 的概率。
  > target：4 次全对且真选项平均概率 ≥ 0.5；control：最多对 1 次；其余 excluded

结果：target 4,621，control 2,220；其中“一个都写不对但多选全对”的 A 组 4,110 篇。不给标题时真名单被选为最像真的只有 25.5%（Stage 12 N1），等于瞎猜。

说明什么：“写不出但认得出”的论文大量存在；多选答对靠的是标题，不是名字听起来像。

实验 2：全队列逐层读出（Stage 10）

设计：9,108 篇 × 全部作者 × 7 个条件 × 4 种读出 × 6 层（L24、32、40、48、56、62）+ 模型输出，共 149,999 个名字 token。

数据处理：每篇按 0.3 算 mean_nlr，按 0.4 算 spec，再按 0.6 算档内 target − control。

样本范围：9,108 篇都跑了读出。“全部论文”的总体曲线用全部论文；**组间比较只用 target（A + C）和 control（B + D）**，R2、识别不确定和 excluded 没有进入比较（由答辩后的分组对比补上）。

结果（读出工具都要说清楚）：

- public Jacobian lens：L24–L48 两组 spec 都约为 0；L62 target **+0.56**、control **+0.24**（这是两组各自的平均，未按引用档配对）。
- 模型输出层：两组平均约 0.48 和 0.20；**档内配对的 target − control = +0.21 [0.20, 0.22]**（按论文重抽的区间；改用团队整群后的区间待确认）。
- 只用 R0（A vs B）：**+0.20 [0.19, 0.21]**（PPT 第 22 页；精确点估计 +0.199）。

说明什么：认得出的论文带有论文特有的作者信息，按 L62 的 +0.56 换算（10^0.56），真作者名次好约 3.6 倍；一个作者都写不对的论文也一样。但读出工具在中间层看不到。

实验 3：信号拆分（Stage 10）

公式：由 0.4 的定义，每篇论文都有恒等式

> **真标题分数 = 删标题分数（名字先验）+ topic（同领域标题带来的）+ spec（论文特有）**

对三项分别做档内 target − control，三个差加起来正好等于真标题分数上的组差。

结果：target 和 control 在真标题分数上差 +0.247 = 先验 +0.087 + 主题 −0.047 + 论文特有 +0.207。

说明什么：主体是论文特有的，不是“这个领域常见这些姓”。

实验 4：独立复现（Stage 8）

设计：200 篇新论文，冻结分析计划后再看数据。

指标：

> **W** = 正确作者第一个 token 的打分赢过 100 个错误作者第一个 token 的比例（金标准胜率）**TA**（标题优势）= W(真标题) − 20 个错误标题下 W 的平均 **7 层积分** = L16、24、32、40、48、56、62 七层的平均

统计：W 中首 token 与错误作者并列时记 0.5。A − B 比较；冻结计划要求逐层 Holm 校正（按 p 值从小到大，第 k 个的门槛是 0.05/(m − k + 1)）和逐对剔除（LOPO：每次去掉一对论文重算），但原代码没有实现，两者都是 2026-10-30 事后补算（作业 11500770），p 值公式与检验族划分是我们的选择。

结果：冻结计划的主终点（7 层积分）A − B **+2.41 pp**，LOPO 100 次都不跨 0；Holm 校正后逐层只有 L62 显著。PROTOCOL.md 定的 L56 终点（同一 100 对）为 +4.98 pp [+0.32, +9.91]，LOPO 无变号但 14/100 次区间跨 0；积分终点约为 L56 的一半。

说明什么：主效应在新样本上复现，且不靠个别论文；逐层显著只在最后一层站得住，和“说得晚”一致。（主动说明：分析计划在 10-18 14:29 写定锁定（主终点为 7 层积分），同日 21:14 的 PROTOCOL 改为 L56，两者都早于 8C 打分；改动人和理由待查（U28）；两种都报告。）

> 2026-11-08（报告第 30 版）：Stage 8 的结论（真标题让模型更偏好真实第一作者 RQ1；A 组强于 B 组 RQ2）较稳，但有三个前提：① W 只给第一作者名字的第一个 token 打分，在 Stage 8 的 200 篇里有 129 篇（64.5%）这个 token 只是首字母（audit_20261105/part_A_stage4_9.md 第 10 行）；② 偏离 D13-1：按补充 13 C-2 的规则，全部作者 CPU 代理只在 L56 的 RQ2 上与已发表结论不一致（+0.064 [−0.032, +0.163]，区间含 0），触发了按原 W 在 GPU 上重算，用户 2026-11-06 决定不

> 做；在锁定计划的 7 层积分终点上（近似，Stage 10 没有 L16）代理 RQ2 为 +0.046 [+0.007, +0.088]（L16 = 0）或 +0.049 [+0.005, +0.094]（L16 = L24），同向、区间不含 0（381_stage13/reports/c13_C2.md；381_stage13/c13_C2_followup/c2_followup_proxy.csv）；③ U28：L56 在锁定计划里是探索性次终点，10-18 21:14 的 PROTOCOL.md 把它改为主终点，改动者和依据仍未查清。

第二部分：什么时候知道？

实验 5：细层读出（Stage 10）

设计：在主轮 L40、48、56、62 之外，补算 L50–L55、L57–L61，只用 logit lens 和 public lens；L41–L47 和 L49 没有算。

结果：target − control 在 L50 为 +0.007，L62 为 +0.23；上升最陡在 L57–61。

说明什么：从读出工具看，“认得出”的优势只在最后十来层形成：“说得晚”。

实验 6：读出工具比较（Stage 10）

指标：除 nlr 外，看“正确 token 进前 10 的比例”；以及 lens 比 logit lens 多出的 spec。

结果：L48 Jacobian lens 前 10 命中 15–18%，logit lens 1%；L62 logit lens 最好（59%）。Jacobian lens 多出的 spec 只有 +0.01 到 +0.03，target 不比 control 多（L48–56 甚至为负）。

说明什么：更好的 lens 在中间层也看不到论文特有的作者信息，但“读不出 ≠ 不存在”，所以要动手干预。

实验 7：替换（Stage 11 E1）

设计：

- 样本：每个引用档内 target、control 各取 min(60, n_t, n_c) 篇，种子 11，共 593 + 593 篇。
- 两次前向：真标题（clean）和 false_0 假标题（corrupt）。
- 在第 l 层，把 clean 那遍**对齐尾段**（右引号、年份、“Authors”、“:”和所有名字位置）的 block 输出复制到 corrupt 那遍对应位置，其余照常往后算。
- 在模型输出上打分。

公式：0.7 的恢复率 R(l)。

结果：L24 约 0.07–0.09，L40 约 0.27–0.34，**L48 约 0.82，L52 起约 1.0**；target 与 control 时间几乎相同（都在 L52–L54 达到 R ≈ 1；L48 target − control −0.063 [−0.104, −0.024]，团队 95% CI，事后，control 略早）。只换标题最后一个 token（E1t）在 L40 前约 0.12–0.15，L56 后为 0。

说明什么：到 L52，论文信息已经全部到了标题之后的位置，比读出工具看到它早 5–10 层：“读得早”。

实验 8：阻断（Stage 11 E2）

设计：从第 l 层到 L63，在注意力打分上加掩码：标题之后的所有位置对标题 token 的那些格子设为 bf16 能表示的最小值，softmax 后约等于 0，所有头都挡。

公式：0.7 的 Loss(l)。

结果：从 L0 起挡损失约 0.83，L32 起约 0.37，**L52 起约 0**。只挡冒号和名字位置（E2n）最多损失 0.15，说明信息还能经由标题后其他 token 绕过去。

说明什么：L52 以后模型不再需要看标题，和替换从相反方向得到同一时间点。

实验 9：加固（X6、X7）

X6 设计：用 false_1…false_4 重做 E1。每个假标题长度不同，所以按同一公式为每个假标题重新计算对齐尾段，保证不把真标题 token 换进去；先用 false_0 重跑一个分片，必须和原结果逐个相同（516 行 × 15 层全部一致）。

X7 设计与公式：对 corrupt 那遍也做同样阻断，算它的损失 F；真标题那遍的损失 T。

> **论文特有损失 S = T − F**（都以真假差为 1）

结果：X6：5 个假标题平均 L48 0.82、L52 0.995，每个和 false_0 最多差 0.02（预注册允许 0.10）。X7：L0 起挡 S ≈ 1.0；L52 起挡 target 0.018、control 0.051；L56 起都是 0。

> 2026-11-06：X7 补做了另外 4 个假标题，按 5 个平均判定，target、control 和全部论文都满足预注册判据（S(L52) 分别为 +0.022、+0.042、+0.028，均 ≤ 0.05）（补充 10 第 2 项；381_stage13/reports/b1_x7f_report.md）；原来对照组只用 false_0 时为 0.051，属于单个假标题的波动。

说明什么：时间点不依赖某个假标题；阻断结论不是“搞乱模型”造成的，挡住后真假标题的分数完全一样。

实验 10：哪个位置（Stage 12 P1）

设计：替换时只换一个位置。从提示末尾往前编号：p1 = “:”，p2 = “Authors”，p3 = “)?\n”，p4–p7 = 年份 4 位数字，p8 = “ (”，p9 = 右引号；另一个条件是“全部名字位置”。

额外处理：按 token 角色分开算恢复率：initial（单字母）、given（名）、surname（姓）；真假差 < 0.05 的角色（如标点）不报告比例。

结果：只换名字位置 L48 0.61、L52 0.85；只换 “:” 最多 0.172；其他单个位置 ≤ 0.03。姓的首 token 靠名字位置恢复（L52 0.92），首字母靠 “:” 恢复（L52 0.92，按 raw 重算的 0.917），但首字母真假差只有 0.11，姓约 0.5。

说明什么：信息主要直接进入名字位置，主要体现在姓上。

实验 11：哪个部件（Stage 12 P2）

设计：只替换第 l 层的注意力输出（o_proj 之后）或 MLP 输出（down_proj 之后），在加回残差流之前替换；替换范围是整段对齐尾部加全部名字位置（与 P1 的 all 相同），不只是名字位置。

结果：L48 注意力 0.23（MLP 0.07）；L52、L56 MLP 0.18、0.22（注意力 0.11、0.06）；L44 之前任何单个部件 ≤ 0.03。

说明什么：L48 注意力把标题信息搬进名字位置，L52–56 MLP 加工。单层替换是下限；MLP 是否“查记忆”分不出。

实验 12：标题位置的 probe（Stage 11 E4b）

设计：作者是一串名字，没法直接回归，所以学“模型自己在 ‘:’ 处 L63 的状态”，那个状态直接决定第一个名字 token。

数据处理与公式：

1. 输入 X：真标题运行中标题最后一个 token 在第 l 层的状态（L16、24、…、60）；标准化（减均值、除标准差）。原版的均值、标准差用全部 9,108 篇（含测试折）计算；2026-10-30 改为只在训

练折内计算后重算，E4b（target + control 1,395 篇）为 L40 0.061、L56 0.075；两种标准化差别最大 0.0007，0.066 / 0.080 是 X1 对照流程全部 1,863 篇的数字，差别来自论文集合，不是标准化，没有结论翻转。

2. 目标 Y：同一次运行 ":" 处 L63 的状态。
3. ridge 回归闭式解：
   > $\mathbf{W = (G + \alpha \cdot tr(G)/d \cdot I)^{-1} A^T(Y - \bar{Y})}$，$G = A^TA$，$\alpha \in \{0.1, 1, 10\}$，各层都选中 1
4. 测试折上预测 $\hat{Y}$，经模型自己的 final norm，只和 **4,314 个名字 token**（队列里所有名字首 token 和姓首 token）的 lm_head 行相乘。
5. 每位作者**第一个名字 token** 在 4,314 个里的 −log10(名次)，对作者平均。
6. 同一个 W 输入 false_0 那遍的状态再打一次分；**spec = 真 − false_0**。
7. 按团队 5 折；剔除"提示里的标题在训练中出现过"的论文，剩 1,863 篇（target 896、control 499）；E4b 信号只用其中 target + control 的 1,395 篇。

对照：把打分用的正确作者换成随机另一篇、或同领域另一篇论文的作者。

结果：全部作者、全部名字 token、按角色（补充 9，预注册版 V0，只减 false_0）L24 / L40 / L56：名的第一个 token +0.098 / +0.124 / +0.163，姓的第一个 token +0.058 / +0.071 / +0.098，首字母 +0.021 / +0.044 / +0.054。旧版只打首 token：L24 +0.050，L40 +0.061，L56 +0.075（E4b，target + control 1,395 篇；X1 对照流程全部 1,863 篇为 +0.050 / +0.066 / +0.080）；target 比 control 高 +0.03 到 +0.08（以上为旧版）。target − control（同一引用档内，全部作者全部名字 token 按角色，措辞 B 第 3 版）：预注册版中名的第一个 token 在 L24–L48 为正，姓在 L24–L48 不显著（L40 +0.012 [−0.026, +0.048]）；事后的逐个排除版中姓从 L24 起为正（L40 +0.030 [0.013, 0.048]）。名的信号在三版中一致；姓的证据弱，只来自事后版本。首字母在个别层为正、模式不一致（未做多层校正），不作结论。旧版的两个置换对照 −0.005 到 +0.006。两种标准化差别最大 0.0007（L24/L40/L56 ≤ 0.0004）。

说明什么：标题位置很早就有一点线性可读、属于这篇论文的作者信息，lens 读不到。信号小（名次好约 1.2 倍），而且只打分了第一个 token（73% 是首字母）、只减了 false_0，是辅助证据。

> 补充 9（答辩后新增，分析计划在看结果前写定）把这个 probe 扩展到每位作者的全部名字 token 并按角色分开：L40 姓的第一个 token +0.071 [0.058, 0.085]（预注册版 V0：只减 false_0，目标 + 对照 1,395 篇，剔除标题复用，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md），高于首字母 +0.044 [0.030, 0.057]（1,590 篇）；名的第一个 token 最强（L40 +0.124、L56 +0.163（1,706 篇））。原 E4b 只打分第一个 token（多半是首字母），所以低估了标题位置携带的名字信息。

实验 13：层序汇总（X5）

设计：不做新计算，把各实验按自己的判定规则得到的"最早出现层"放在同一条层轴上。

结果：标题位置论文属性 ≤ L8–L16；替换 L48 恢复一半、L52 > 95%；阻断 L52 后无损失；名字位置 lens 读出作者 L53–L62。

说明什么："读得早，说得晚"的完整时间线。

第三部分：中间层存的是什么？

三个假设：**H1** 任务/格式（"我要输出作者名单"）；**H2** 论文身份（"这是哪篇论文"）；**H3** 作者已经在了，只是不在词表方向上。所有判定规则在看数据前写进预注册（原文件 + 补充 1–5）。

实验 14：中间层排第一的词（M1）

设计：名字首 token 位置，看 Jacobian lens 和 logit lens 排第一的 token 是什么；再换假标题，看第一名变不变。

结果：L24–L48 Jacobian lens 第一名 100% 是 ".\n" 这类句末符号；L51–52 起出现 Robert、Zhang 等常见名；正确名字 L52 占 0.1%、L62 占 2%（logit lens 在 L62 的第一名有 87% 是像名字的 token，不一定是正确名字）；换假标题后 28–64% 的第一名会变。

说明什么：名字位置的中间层在 lens 看来是"格式"，支持 H1。

实验 15：读论文属性（M2、M2b、M2c）

设计：标题最后一个 token、9 层，按团队 5 折 ridge。

目标与指标：

- 领域：8 类 one-hot，预测取最大一类 → **准确率**
- 年份 → $R^2 = 1 - \Sigma(y - \hat{y})^2 / \Sigma(y - \bar{y})^2$
- 引用数：log10(1 + 引用数) → R^2；"去掉年份的引用数"先用年份解释掉一部分再预测
- 认得出：target = 1、control = 0，ridge 输出当分数 → **每个引用档内的 AUROC**，再按权重合并
- $\alpha \in \{0.01, 0.1, 1, 10, 100, 1000\}$

对照：打乱标签；只用提示年份预测（年份基线）；":" 位置读年份作阳性对照；M2b 用 TF-IDF（1–2 词组）、M2c 用 bert-base-uncased 每层平均池化，同样 ridge。

结果：年份 R^2 0.38 → 0.56，引用数 0.29 → 0.53，领域约 0.71（打乱 0.13），认得出 AUROC 0.62 → 0.67；":" 位置年份 R^2 0.97–0.98；BERT 0.24、0.19、0.63；TF-IDF 年份 0.10。

说明什么：标题位置早早就有论文属性，年份和引用数明显超过 BERT，部分支持 H2。但认得出这一项 BERT 也有 0.63，不作证据；按预注册，Qwen 胜过 BERT 只作参考。

实验 16：换问法（M3）

设计：同一标题三种问法（问作者、年份、领域），标题前的问法部分都对齐成 9 个 token，存 15 层在标题位置和 ":" 的状态。

两个指标：

> **迁移比 T** = 在问法 a 上训练、到问法 b 上测的成绩 ÷ 在 b 上自己训练的成绩 **身份指数 I** = 同一篇论文两种问法下的余弦 − 和其他论文的平均余弦（向量先减均值、归一化）

判据（补充 2）：L4 几乎只编码文字，所以只看 **T(l) − T(L4)** 和 **I(l) − I(L4)**，区间不含 0 且大于 0 才算。

结果：标题位置年份 T − T(L4) 在 L16–L40 为 −0.03 到 −0.06，引用数也为负，领域和 L4 分不开；I − I(L4) 所有层 < 0。

说明什么：中间层不比 L4 更跨问法一致，"换问法不变"可能只是标题文字相同。M3 不支持 H2。

实验 17：跨问法替换（X1）

设计：把"问年份"（或问领域、随机另一篇论文 C）时第 l 层整个标题区间的状态，替换进"问作者"的那遍，在模型输出上给第一作者打分。1,178 对论文，按团队分调参 596 / 测试 582。

公式：

> **R(来源, l) = 平均[s(来源替换) − s(corrupt)] ÷ 平均[s(clean) − s(corrupt)]** 判据：l ≥ 24 时，R(作者) − R(年份)、R(作者) − R(领域) 的区间都在 [−0.1, 0.1] 内，且 R(作者) − R(C) 下限 > 0 → 与任务无关

相似度检查：问法份额 = 同篇换问法的相对距离 ÷ 换论文的相对距离（0 = 问法不改变状态，1 = 和换论文一样远）。

结果：L24–L48 都判“与任务无关”；L48 作者 − 年份 +0.019 [0.012, 0.026]，很小但确实存在。标题位置问法份额 15–27%；“:” 位置 3–5 倍（L4–L40；L48 约 2.2 倍，L56–L63 为 1.3–1.5 倍）（x1_similarity.md colon 表）。

说明什么：“:” 存任务（H1）；标题位置跨问法通用，但同样受“标题文字相同”影响。

实验 18：改写标题（X3）

设计：每篇论文 A 有四个版本放进作者问法：原标题、Qwen 生成的改写、搭档 B、近邻 D。D 是同领域、无共同姓氏、词重合不低于改写版且最接近的另一篇论文；没有这样的论文时，取词重合最高的一篇（大多数论文走的是这条后备规则）。

数据处理：

- 词重合 Jaccard2 = |W(t) ∩ W(p)| / |W(t) ∪ W(p)|，W 为去停用词、去后缀的词集。
- 改写的质量：排除和原标题相同的 27 条；NLI 双向蕴含检查；人工核对 40 条；主分析 1,110 条，敏感性分析（剔除人工判为改意思和 NLI 未通过的）1,012 条。

公式：

> **G′(l) = cos(原, 改写) − cos(原, D)**，在标题最后一个 token 判据（补充 4）：G′(l) > 0 且 **G′(l) − G′(L4) > 0**，调参集找到、测试集确认 行为：第一作者得分（改写） − 第一作者得分（D）> 0 词重合控制：回归里加 Jaccard 和共享稀有词比例

事后加的两项：

- 文本模型基线：BERT、all-mpnet 算同样的 G′，减各自第 0 层。
- target / control 拆开；行为恢复比例 = (改写 − D) ÷ (原 − D)。

结果：G′ 在 L4 就有 +0.30（来自用词），G′ − G′(L4) 在 L28–L40 为 +0.06 到 +0.16（L36 最大），行为 +0.24；按预注册判为“存在论文身份信号”。但在用词真正匹配的 66 篇中的 test 部分（37 篇）上，all-mpnet 的优势和 Qwen 相当（1.40 对 1.90，差的区间含 0）；target 和 control 完全一样（L36 +0.158 对 +0.160，行为恢复 0.90 对 0.91）。近邻 D 难配：改写词重合中位数 0.61，D 只有 0.15。

说明什么：Qwen 中间层表示了标题的“意思”，不只是用词；但分不清是认出论文还是懂得意思。解读降为“语义表示”，预注册结果和事后检验都报告。

实验 19：Patchscope（X4）

设计：把论文 A 在作者问法下第 l 层（8、16、…、56）标题最后一个 token 或 “:” 的状态，注入一个只有占位符 X 的目标提示（比如问年份、问第一作者、问领域），看模型说出的答案；对照用搭档 B 的状态。

公式：

> **D = s(用 A 自己的状态) − s(用搭档 B 的状态)**，对 A 的正确答案打分 最早可解码层：调参集上 D 的区间第一次 > 0 的层，测试集确认

文本基线：只从标题文字训练分类器，预测第一作者名首 token 和姓首 token；阳性对照检查基线有没有能力测出东西。

结果：第一作者 L8 起可解码（+0.046）（全作者版本同样从 L8 起可解码：测试集 +0.048 [0.039, 0.058]），年份 L40 起（+0.013）。文本基线在名字首 token 上不弱于 Qwen（BERT +0.088 对 Qwen +0.018）；姓那一项的阳性对照没通过。

说明什么：作者信息出现很早，但不能排除来自标题文字，单看 X4，H3 证据不足（H3 总体判断见名字位置 probe：部分支持）；“先作者后年份”和 H2 预测相反。

第三部分小结

H1 在 “:” 和名字位置成立；H2 部分支持但未确立：M2、X1 有利，M3 不高于文字水平，X3 分不清语义和身份，X4 顺序相反；H3 部分支持（名字位置 probe，补充 11）。

收尾

可信度：预注册（原文件 + 5 份补充，sha256 只读）；按作者团队分折和整群 bootstrap；每个结论配阳性、阴性、打乱标签对照和文本基线；每次改代码先复现旧数字。自己查出并修正了假标题复用泄漏、预注册判据用错、文本基线代码错误、Stage 8 主终点改动，旧结果保留并标明。

局限：一个模型；teacher forcing 下的偏好不是生成；lens 拟合稳定性只有 Fit A；高引用档几乎没有 control。

> 2026-11-12：**C24 模型自己写出的名字：真作者与编造的名字可在名字 token 上线性区分（较稳但有前提；补充 15，批次 2 第 2-11b 项）：**Qwen3-32B 自己写作者名单时，名字写出之后，名字 token 上的中间层残差能线性区分真作者与编造的名字（补充 15 预注册主分析，名字 token 平均；L16–L56 七层都同时胜过排位基线和名字特征基线，例如 L48 AUROC 0.782 [0.754, 0.812]，probe − 排位 +0.151 [0.111, 0.190]，probe − 名字特征 +0.234 [0.186, 0.284]；打乱标签 0.455–0.510）；名字写出之前的位置读不出（次分析，AUROC 不高于排位基线）。前提：在 chat 模板下现场生成的文本上测得，不是其他实验用的原始提示；标签来自规则匹配（matcher v3b）；control 组只作描述（51 个真名）；“probe 信号可能部分来自输出置信度”这一替代解释尚未排除（生成时 token 对数概率 / 熵基线未做）；事后的名气基线（事后，探索性）：只用名气 0.548 [0.519, 0.576]，probe −（排位 + 名字特征 + 名气）在每层仍 > 0（L16 +0.045 [0.008, 0.081] … L48 +0.104 [0.067, 0.139]），名气只覆盖数据集内出现过的情况。补充 15 没有写它与 H3 的关系，不作为 H3 的证据；与 H3 的关系未预注册，只作讨论。（381_stage13/reports/b2_gennames_b_report.md；b2_gennames_b_robust_posthoc.md；团队整群 bootstrap 2,000 次）**Patchscope（批次 2 第 2-7、2-9 项，补充 12；只作描述）：**用名字位置作源时，第一作者在 L8–L16 约为 0，L40 +0.006 [0.004, 0.008]，L48 +0.014 [0.011, 0.017]（标题位置作源 L40 +0.068 [0.056, 0.080]）；“:” 位置作源到 L40 约为 0，L48 +0.012 [0.009, 0.015]；x4tok 标题位置作源、姓的第一个 token 在 L40 最高 +0.124 [0.099, 0.148]（以上为预注册要求报告、无判定规则；认得出的 target − control 与 name_all 源的 x4tok 部分为探索性）。不据此讨论 H3。（381_stage13/reports/b2_ps_report.md）

> 2026-11-09：**名字位置 probe（批次 2 第 2-5 项，补充 11 A，已完成；H3 改为部分支持）：**按补充 11 预注册判据，姓首 token 在 L40/L48 满足 H3（名字位置 probe，逐个假标题排除版；probe L40 +0.069 [0.064, 0.074]、L48 +0.103 [0.097, 0.110]；target − control L40 +0.031 [0.019, 0.044]、L48 +0.053 [0.038, 0.067]）；事后检验：lens 的区间同样不含 0（logit L40 +0.010 [0.005,

0.014]；J-lens L40 +0.048 [0.042, 0.054]），且两者尺度不同、无法比较大小，因此降为'部分支持'。名和姓的后续 token 在 L40 与 J-lens 比较时不满足判据（b2_np_report_v2.md 第 373、377 行）。首字母的对照行（+0.020 [0.015, 0.026]）约为信号（+0.045 [0.039, 0.051]）的一半，约一半信号不是论文特有的。前提：主结果为逐个假标题排除版（Vpd，D11-1，每篇平均约 1.5 个可用假标题）；对照行用同一组假标题（D11-1 第 2 版，一致性检查 PASS）；姓的置换对照约为 0（L40 −0.005 [−0.009, +0.000]）。以下只作描述：同一引用档内 target − control（预注册要求报告、无判定规则）；按行为分组，A − B 姓 L40 +0.030 [0.017, 0.042]（预注册要求报告、无判定规则；D 组和 n < 30 的组只作描述）；lens 的 target − control（探索性）；逐层峰值和逐层上升（探索性）。V0（1,395 篇，姓 L40 +0.066 [0.056, 0.077]，target − control L40 +0.030 [0.005, 0.057]）和 V5x0（L40 +0.065 [0.057, 0.073]；含泄漏，仅敏感性）只作敏感性。

（381_stage13/reports/b2_np_report_v2.md；summary_b2_np/np_role_layer_v2.csv、np_lens_compare_v2.csv；团队整群 bootstrap 2,000 次）

2026-11-08（报告第 30 版）：**P1 / P2 用 5 个假标题（批次 1 第 3 项，已完成，硬检查 PASS）：**按补充 10 第 27 行，5 个假标题平均为主结果，原 false_0 版并列。两版所有“5 个假标题平均 − false_0”的区间都含 0（差的绝对值 0.001–0.006，在批量舍入噪声的量级内：组级最大 0.0148），已发表结论不变：论文信息在 L44–L52 汇集到名字位置，注意力在 L48 读入，MLP 在 L52–L56 接手。5 个假标题平均（括号内为 false_0）：P1 全部位置 L48 +0.821 [0.807, 0.835]（0.825）、L52 +0.995 [0.990, 1.001]（0.996）；P1 只换名字位置 L52 +0.841 [0.827, 0.856]（0.847）；P2 注意力 L48 +0.237 [0.229, 0.246]（0.231）；P2 MLP L52 +0.181 [0.174, 0.188]（0.178）、L56 +0.226 [0.217, 0.236]（0.224）（补充 10 第 3 项，Stage 11 样本 1,186 篇，团队整群 bootstrap 2,000 次 95% CI；391_groups/reports/b1_p12f_report.md P1 / P2 表；summary_b1_p12f/p12f_mean5.csv）。p9 位置（标题的右引号；只有共享尾长为 9 的论文，平均每篇约 3 个可用假标题）：各假标题 694–711 篇，集合不同，未加权（summary_b1_p12f/p12f_per_title.csv，item = p9：false_0 708、false_1 694、false_2 711、false_3 707、false_4 710 篇）。“:” 位置的分子 B/A：5 个假标题版 0.72–0.87，false_0 版 0.78–0.99；B 的比例高只因分母约为 A 的一半（P1 只替换 “:”，未写出作者，A 557 / B 586 篇：5 个假标题版 L44 0.72、L48 0.87，分母 B/A 0.51（b1_p12f_report.md “B - A” 表）；false_0 版 L44 0.78、L48 0.99（391_groups/summary_rerun/p1_p2_num_den_B_minus_A.csv））。硬检查：false_0 臂复现已发表值（最大差 2.2e-16），PASS。**C / D 组补全 E1 / E2（批次 2 第 2-6 项，补充 11 B，已完成）：**C 组未写出作者 462 篇，同一引用档内与 A 相比（6 个引用档，C 258 篇、A 323 篇）：E1 恢复比例 L48 −0.037 [−0.080, +0.009]，L52 +0.007 [−0.009, +0.024]；L56 −0.007 [−0.014, −0.001]，个别层差异极小，不作解释（小于批量舍入噪声：同一输入按 batch 1 和 15 元素 batch 计算，组级 E1 恢复比例的差最大 0.0148（L40），L52 约 0.002，只给分布、没有 CI；补充 12 第 2-4 项，381_stage13/reports/b2_e1noise.md）；E2 阻断损失 L32–L52 区间都含 0。C 的真假标题差距更大：分母 C 0.559 [0.529, 0.590]、A 0.407 [0.386, 0.430]，同档内 C − A +0.075 [+0.024, +0.130]。也就是说，C 的信号更大，但时间点与 A 相同。D（33 篇）按补充 11 只作描述，D − B、C − D 也只作描述（补充 11 B；未写出作者；团队整群 bootstrap 2,000 次 95% CI；391_groups/reports/b2_cd_report.md Numerator / denominator 表与 Contrasts 表；硬检查：重跑 Stage 11 第 0 号分片，差 0.0（容差 0.005），PASS）。前提：同一引用档内只用到 C 462 篇中的 258 篇；分子、分母都只用 false_0；比例差主要反映分母不同（分母效应）。X4 中认得出的论文第一作者 D 更高（测试集不显著）这一差别不再作为 H2 的证据（只看标题文字的 BERT 基线 +0.088 不弱于 Qwen L8 +0.018）。**2026-11-08（报告第 30 版）补充的局限：**层不完整：Stage 10 在 L24–L40 每 8 层取一层（没有 L25–L31、L33–L39），没有补层计划（补充 14 的 3-1 已补 L41–L47、L49，2026-11-12 完成；3-2 补 L0–L23，运行中，194 / 504）。主要结论的起始层都不在缺口里；落在缺口里的只有三条描述：X4 年份最早可读出层 L40（前一个测量层是 L32，真实起点在 L33–L40 之间）、Stage 10 真标题下 Jacobian lens 从 L40 起明显好于 logit lens（跳变在 L33–L40 的哪一层不知道；3-1 补测后，标题特异信号上 J-lens 在 L41–L46 为

> +0.007 到 +0.014、logit 约为 0，到 L47 两者几乎相同（J-lens +0.001 [−0.005, +0.006]，logit −0.003））、X4 第一作者峰值 L40（真实峰值可能在 L33–L47）。“L24–L48 约为 0”在 L25–L31、L33–L39 没有测过；3-1 补测的 L41–L49 上，logit 的 target − control 都在 ±0.005 以内、从 L50 起为正（起始层不变）；public J-lens 的 target − control 在 L41–L55 为负、L56 约为 0（+0.007 [−0.014, +0.029]）（L41 −0.017 [−0.032, −0.002]，L47 −0.035，L49 −0.043）、从 L57 起为正，“中间层没有领先”仍成立（3-1 用团队整群区间，Stage 10 已发表的是论文 bootstrap 区间，点估计相同；381_stage13/reports/b3_3_1_report.md）（~/jlens_work/conclusions_v30_checks.md A1）；一致性容差事后放宽，而且用到了：Stage 10 一致性检查的容差在看到结果后从 0.25 放宽到 0.5（用户 2026-10-25 批准）。主轮 25 个（读出 × 层）组合的最大差 0.367，只有按 0.5 才通过；全部名次 < 42 完全一致，名次不一致使 log10(1/名次) 最多变 0.070。原定 0.25 时，Stage 10 主轮一致性检查（12 个上下文、52 个 token 位置）的 25 个 lens × 层组合中有 10 个超出 0.25，最大差 0.367（351_stage10/reports/parity_before_tol05_amendment.json）；3-3 在 7 篇论文的 23,280 行上按 0.25 计 99.81% 在容差内。这一量级与 3-3 查明的 bf16 舍入随前向长度变化（最大约 0.46）一致，但容差是在看到数据后放宽到 0.5 的，属于事后修改。批量大小本身造成的组级 E1 恢复比例差最大 0.0148（L40），单 token 的 log10(1/名次) 差 p99 最高 0.22（补充 12 第 2-4 项，381_stage13/reports/b2_e1noise.md）。保留在事后改动清单里（351_stage10/reports/parity.json tolerance_amendment；parity_before_tol05_amendment.json；conclusions_v30_checks.md A2）；干预只用了 1,186 篇：E1、E1t、E2、E2n、P1、P2、F2、X6、X7 只用 9,108 篇中的 1,186 篇（target 593 + control 593，每档每组最多 60 篇，10 档），作为局限，不重做（361_stage11/summary/E1_recovery.csv n_papers）；分母效应：恢复比例 = 分子 ÷ 真假标题差距，组间比较受分母影响：C 0.559 对 A 0.407（C / D 组补全）；“:” 位置分子 B/A 5 个假标题版 0.72–0.87、false_0 版 0.78–0.99；B 组比例偏高只因分母约为 A 的一半。C / D 组补全与 P1 / P2 五个假标题的结论都以此为前提；只用 false_0、没有补做计划：M5 B 部分（真标题对 false_0 的标题 / “:” 位置 probe）和 E4b 的 X1 对照流程只用 false_0，没有计划；M2 已不在此列：M2 的假标题运行已补 5 个假标题；标题复用和供体在训练折的排除对每个假标题都为 0 行（exclusion_audit.csv）；另有约 7,240–7,370 行/假标题的供体论文以 target 行出现在训练折中（显示另一篇论文的标题和标签，只有年份在 ':' 之后进入提示），未作为泄漏处理（381_stage13/reports/m2_f5_report.md；381_stage13/summary_m2_f5/M2_f5_mean.csv、exclusion_audit.csv（作业 11747064））；数字核对只覆盖已登记的部分：已登记 680 个结论数字、4,307 处全部一致（第 29 版 h 的核对）；第 30 版新放回或新增的数字已登记进严格核对（claims_defs_v9，结果见核对表）；另约 1,024 个结论性数字未登记（2026-11-07 计数）（351_stage10/reports/numcheck/claims/out_20261108_140102/）。

请教：换模型复现；用虚构论文作对照，区分“认出论文”和“懂得意思”。