逐个实验讲解稿：怎么做、结果、说明什么

按汇报顺序排，每个实验三段：**怎么做 / 结果 / 说明什么**。括号里是对应的页码，指《Keys_and_shelves_evidence_pages.pdf》（16 页证据页，取自 PPT v19）。数字都是定稿版（报告 v26）；2026-11-06 起与报告 v29 一致，重做计划的新结果用绿色框标出。

讲数字时可以随手换算：分数差 d 就是“名次好了 10^d 倍”。+0.05 ≈ 1.1 倍，+0.21 ≈ 1.6 倍，+0.44 ≈ 2.75 倍，+0.56 ≈ 3.6 倍。

开场：问题和答案

“模型经常编论文作者。我们想知道它是真不知道，还是知道但说不出。答案是：对认得出的论文，它知道一些；这份信息在中间层就到位了，但到最后几层才说出来。我们叫‘读得早，说得晚’。下面我分三部分讲：它知不知道、什么时候知道、中间层存的是什么。”

第一部分：它知道吗？

实验 1：分组（Stage 1，第 3、4 页）

怎么做：用组长的标签流程，在同一个 Qwen3-32B 上对 9,108 篇论文做两件事。第一，让模型自由列作者，按写对多少分成 R0（一个都没写对）、R1（写对少数）、R2（基本写对，不分析）。第二，做多选题：真名单加 3 个同领域、同规模、同引用档的真实团队，换 4 种顺序问。4 次全对、且真选项概率 ≥ 0.5 的叫 target（认得出），最多对 1 次的叫 control（认不出）。

结果：target 4,621 篇，control 2,220 篇。其中 R0 里认得出的有 4,110 篇，也就是“一个作者都写不对，但多选题每次都认得出”。另外做了一个检查：不给标题时，真名单被选为“最像真的”只有 25.5%，和四选一瞎猜一样。

说明什么：有大量论文属于“写不出但认得出”，这正是我们要研究的对象。多选题答对靠的是标题，不是名字听起来像。

实验 2：怎么读模型、怎么打分（第 2 页）

怎么做：提示是“Who are the authors of the paper titled ‘标题’ (年份)? Authors:”，后面接真作者名。在每一层取出内部状态，用读出工具变成“对下一个词的预测”，看正确名字 token 在整个词表里排第几，打分 log10(1/名次)。同一份名单再配 5 个假标题各跑一遍，假标题借自同领域、年份和规模相近的别的论文。真标题分数减假标题平均分，叫“标题特异信号”。

说明什么：名字一样、token 一样，减掉之后剩下的只能来自“认得这篇论文”，这是我们所有实验的基本量。

实验 3：全队列逐层读出（Stage 10，第 6 页）

怎么做：9,108 篇论文、全部作者名，在 6 个层用 4 种读出工具算标题特异信号，target 和 control 只在同一引用档内比较。

结果：用 public Jacobian lens，L24 到 L48 两组都约为 0；L62 上 target 平均 +0.56，control 平均 +0.24。模型输出层上，按引用档配对的 target − control 为 **+0.21 [0.20, 0.22]**。只用 R0 论文重算是 +0.20 [0.19, 0.21]，几乎不变。（组间比较只用 target 和 control，R2 和识别不确定的论文没有进入。）

说明什么：认得出的论文，模型确实带有论文特有的作者信息；按 L62 的 +0.56 换算，真作者的名次比假标题时好约 3.6 倍；即使一个作者都写不对，这份信息也在。但读出工具在中间层看不到它。

实验 4：信号拆分（Stage 10）

怎么做：把真标题的分数拆成三块：不给标题时也有的分（名字先验）、换成同领域假标题带来的分（领域主题）、只有真标题才有的分（论文特有）。

结果：+0.247 = 先验 +0.087 + 主题 −0.047 + 论文特有 +0.207。

说明什么：主要部分是论文特有的，不是“这个领域常见这些姓”。

实验 5：独立复现（Stage 8）

怎么做：在 200 篇新论文上，按事先冻结的分析计划重做，主终点是 7 层平均的 A − B 差。

结果：冻结计划的主终点（7 层积分）A − B 为 +2.41 个百分点 [+0.91, +4.00]，逐次剔除每一对论文重算 100 次都不跨 0。PROTOCOL.md 改定的 L56 终点，同一批 100 对，是 +4.98 个百分点 [+0.32, +9.91]，100 次里有 14 次区间跨 0。逐层检验做 Holm 多重比较校正后，只有 L62 仍显著。Holm 校正和逐对剔除是冻结计划里要求、但原代码没做，10 月 30 日补算的。

说明什么：主效应在新样本上能复现，而且不靠某几篇论文撑着；但逐层的显著性只在最后一层站得住，和“说得晚”一致。要主动说明：分析计划在 10-18 14:29 写定锁定（主终点为 7 层积分），同日 21:14 的 PROTOCOL 改为 L56，两者都早于 8C 打分；改动人和理由待查（U28）；我们把原定主终点和 L56 都报告了。

第二部分：什么时候知道？

实验 6：细层读出（Stage 10，第 11、12 页）

怎么做：在主轮 L40、48、56、62 之外，补算 L50–L55 和 L57–L61（只用 logit lens 和 public lens），算 target − control。L41–L47 和 L49 没有算。

结果：L50 只有 +0.007，L62 达到 +0.23，**上升最快在 L57–61。**

说明什么：从读出工具看，“认得出”的优势只在最后十来层形成，这是“说得晚”。

实验 7：读出工具比较（Stage 10，第 13–15 页）

怎么做：比较 logit lens 和 3 把 Jacobian lens（用不同文本拟合）。

结果：logit lens 在 L48 前正确名字排在一万名以后；Jacobian lens 在 L48 能把 15–18% 的正确 token 排进前 10，logit lens 只有 1%。但 Jacobian lens 多读出的论文特有信号只有 +0.01 到 +0.03，而且不偏向 target。

说明什么：换更好的读出工具，中间层也看不到论文特有的作者信息。但“读出工具看不到”不等于“没有”，所以下一步要动手干预。

实验 8：替换（Stage 11，第 9、10 页）

怎么做：真标题跑一遍、假标题跑一遍。在第 l 层把真标题那遍“标题之后所有 token”的内部状态复制到假标题那遍，其余照常往后算，看真作者分数恢复了多少：恢复率 = (替换后 − 假) ÷ (真 − 假)，先对所有论文平均再相除。样本是 593 + 593 篇。

结果：L24 恢复不到 0.1，L40 约 0.3，**L48 约 0.82，L52 起约 1.0**；target 和 control 时间点一样。

说明什么：到 L52，论文信息已经全部在标题之后的位置上了，比读出工具看到它（L57–61）早 5 到 10 层。这是“读得早”的因果证据。

实验 9：阻断（Stage 11，第 10 页）

怎么做：从第 l 层到最后一层，禁止标题之后的所有位置去注意标题 token，看分数掉多少。

结果：从 L0 起挡损失约 0.83，从 L32 起约 0.37，**从 L52 起几乎为 0**。

说明什么：L52 以后模型不再需要看标题，和替换实验从相反方向得到同一个时间点。

实验 10：两项加固（X6、X7）

怎么做：X6：替换原来只用了一个假标题，现在用另外 4 个重做。X7：阻断可能“把模型搞乱”，所以在假标题那遍也做同样阻断，用真标题的损失减去假标题的损失。

结果：X6：5 个假标题平均，L48 恢复 0.82、L52 恢复 0.995，每个假标题和原来最多差 0.02。X7：从 L0 起挡，论文特有信号全部消失（1.0）；从 L52 起挡，target 只剩约 2%，control 约 5%，L56 起都是 0。

说明什么：时间点不是某个假标题碰巧造成的，阻断的结论也不是“搞乱模型”造成的。

实验 11：信息落在哪个位置（Stage 12 P1，第 1 页）

怎么做：替换时一次只换一个位置：冒号、年份数字、“Authors”、名字位置等。

结果：只换名字位置，L48 恢复 0.61、L52 恢复 0.85；只换冒号最多 0.17；其他单个位置都不超过 0.03。按 token 拆：姓的信息在名字位置本身，真假差约 0.5，是主体；首字母的信息经过冒号，但真假差只有 0.11。

说明什么：信息主要直接进入名字位置，主要体现在姓上。

实验 12：哪个部件在起作用（Stage 12 P2，第 1 页）

怎么做：只替换某一层的注意力输出，或只替换 MLP 的输出，替换范围是整段对齐尾部（右引号、年份、“Authors”、冒号）加全部名字位置，不只是名字位置。

结果：L48 注意力恢复 0.23，同层 MLP 只有 0.07；L52、L56 的 MLP 分别恢复 0.18、0.22。L44 之前任何单个部件都不超过 0.03。

说明什么：先由 L48 的注意力把标题信息搬进名字位置，再由 L52–56 的 MLP 加工。要说明两点：只换一层是下限；MLP 那一步是不是“查记忆”，这个实验分不出来。

实验 13：标题位置的 probe（Stage 11 E4b，第 7、8 页）

怎么做：取标题最后一个 token 的状态，用 5 折 ridge 回归学一个线性映射，预测模型自己在冒号处最后一层的状态，因为那个状态直接决定说出的第一个名字。再把预测结果变成对名字 token 的打分。按作者团队分折，剔除“标题在训练中出现过”的论文，剩 1,863 篇。原版标准化用了全部论文（含测试折），复核时改为只在训练折内标准化重算，L40 从 0.066 变为 0.061、L56 从 0.080 变为 0.075，结论不变。

结果：从 L24 起 +0.05 到 +0.08，target 比 control 高 +0.03 到 +0.08。换成别的论文或同领域论文的作者打分，约为 0。

说明什么：标题位置很早就有一点线性可读、属于这篇论文的作者信息，读出工具读不到。信号很小，名次只好 1.2 倍，而且只打分了第一个名字 token（多是首字母），所以它是辅助证据，主要证据还是替换实验。

> 补充 9（答辩后新增，分析计划在看结果前写定）把这个 probe 扩展到每位作者的全部名字 token 并按角色分开：L40 姓的第一个 token +0.071 [0.058, 0.085]（目标 + 对照 1,395 篇，剔除标题复用，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md），高于首字母 +0.044 [0.030, 0.057]（1,590 篇）；名的第一个 token 最强（L40 +0.124、L56 +0.163（1,706 篇））。原 E4b 只打分第一个 token（多半是首字母），所以低估了标题位置携带的名字信息。

实验 14：层序汇总（X5）

怎么做：把前面各实验的"最早出现层"放到同一条层轴上。

结果：标题位置的论文属性 ≤ L8–L16 就读得出；替换在 L48 恢复一半、L52 超过 95%；名字位置用读出工具读出作者要到 L53–L62。

说明什么：一张图把"读得早，说得晚"的时间线完整串起来。

第三部分：中间层存的是什么？

"既然信息在中间层就有，读出工具却看不到，那中间层里存的是什么形式？我们提了三个假设：H1 是任务和格式，'我要输出作者名单'；H2 是论文身份，'这是哪篇论文'；H3 是作者其实已经在了，只是不在词表方向上。"

实验 15：中间层排第一的是什么（M1）

怎么做：不看正确名字排第几，而看名字位置上读出工具排第一的是什么词。

结果：L24–L48，100% 是句号、换行这类句末符号；L51–52 起出现 Robert、Zhang 这样的常见名字；正确名字在 L52 只占 0.1%。

说明什么：读出工具在名字位置看到的是"格式"，支持 H1。

实验 16：读论文的其他属性（M2、M2c）

怎么做：在标题最后一个 token 上训练 probe，读年份、引用数、领域、认不认得出。这个位置还没看到年份，不会泄题。对照：打乱标签；冒号位置读年份作阳性对照（那里已经看到年份）；用只读标题文字的 BERT 作基线。

结果：年份 R^2 从 L16 的 0.38 升到 L52 的 0.56，引用数 0.29 → 0.53，领域准确率约 0.71（打乱标签只有 0.13），认得出 AUROC 0.62 → 0.67。BERT 分别是 0.24、0.19、0.63。冒号位置读年份 R^2 0.98。

说明什么：标题位置很早就有论文属性，年份和引用数明显超过只看文字的 BERT，支持 H2。但"认不认得出"BERT 也能做到 0.63，所以这一项不作证据；而且按预注册，Qwen 胜过 BERT 只作参考。

实验 17：换问法（M3、X1）

怎么做：同一个标题，换成问作者、问年份、问领域三种问法，看标题位置的状态变不变。X1 更进一步：把"问年份"时的标题状态替换进"问作者"那遍，看作者分数能否恢复。

结果：M3：同一篇论文换问法，状态几乎不变，但这在 L4（几乎只有文字）就已经如此；按预注册要比 L4 高才算数，结果不高于 L4。X1：替换后作者分数恢复得和用"问作者"的状态一样好，差别在预注册的 ±0.1 以内；冒号位置相反，换问法时变化是换论文的 3–5 倍。

说明什么：冒号位置存的是任务，支持 H1。标题位置跨问法通用，但 M3 显示这可能只是因为三种问法的标题文字相同，所以 M3 不支持 H2。

实验 18：改写标题（X3，最关键的区分实验）

怎么做：同一篇论文的标题换个说法，和一篇用词相近的别的论文 D 比：如果模型认的是“论文”，改写版应该更像原标题。扣掉 L4 的文字水平，再控制用词重合度。

结果：L28–L40 改写版比 D 更接近原标题，L36 最大 +0.16；行为上，改写标题保留了原标题约 90% 的作者优势。按预注册判据，这算“存在论文身份信号”。但我们看到结果后又加了两项检验：只懂语义、不认识作者的句子向量模型在用词匹配的论文上也能做到差不多；而且 target 和 control 完全一样，行为 0.90 对 0.91，表示层 0.158 对 0.160。

说明什么：Qwen 中间层表示了标题的“意思”而不只是用词，但分不清是认出了论文还是懂了意思。我们把解读降为“语义表示”，预注册的结果和事后检验都如实报告。

实验 19：Patchscope（X4）

怎么做：把论文的标题状态注入一个只有占位符的新提示，比如“这篇论文发表于”，看模型能不能说出年份或第一作者。另外用只读标题文字的模型作基线。

结果：第一作者 L8 就能解码出一点（+0.046），年份要到 L40（+0.013）。但只靠标题文字的基线在名字首 token 上不弱于 Qwen。

说明什么：作者信息出现得很早，但不能排除来自标题文字，所以 H3 证据不足。而且“先作者后年份”的顺序和 H2 预测的方向相反。

第三部分小结

“三个假设的结论是：H1 在冒号和名字位置成立；H2 部分支持但未确立，标题位置有论文属性和语义，但我们专门设计的区分实验 M3、X3、X4 都没能证明是‘认出论文’；H3 证据不足。”

收尾

怎么保证可信：“Stage 13 所有判定规则都在看数据之前写定；所有 probe 按作者团队分折防泄漏；每个结论都配阳性、阴性对照和文本基线；置信区间按作者团队重抽。过程中我们自己查出过假标题复用的泄漏、一个预注册判据用错、一个文本基线的代码错误，都修正了，结论该降级的降级，旧结果保留。”

局限：“只用了一个模型；测的是把正确名字放进去打分的偏好，不是真实生成；读出工具的稳定性只有一份拟合证据。”

请教：“下一步我们考虑换一个模型复现，或者用模型不可能见过的虚构论文做对照，来区分‘认出论文’和‘懂得意思’。想听您的意见。”