# 逐个实验讲解稿：怎么做、结果、说明什么

按汇报顺序排，每个实验三段：**怎么做 / 结果 / 说明什么**。括号里是对应的页码，指《Keys_and_shelves_evidence_pages.pdf》（16 页证据页，取自 PPT v19）。数字都是定稿版（报告 v26）；2026-11-06 起与报告 v29 一致，2026-11-08 起与报告第 30 版一致，重做计划的新结果用绿色框标出。

讲数字时可以随手换算：分数差 d 就是“名次好了 10^d 倍”。+0.05 ≈ 1.1 倍，+0.21 ≈ 1.6 倍，+0.44 ≈ 2.75 倍，+0.56 ≈ 3.6 倍。

---

## 开场：问题和答案

“模型经常编论文作者。我们想知道它是真不知道，还是知道但说不出。答案是：对认得出的论文，它知道一些；这份信息在中间层就到位了，但到最后几层才说出来。我们叫‘读得早，说得晚’。下面我分三部分讲：它知不知道、什么时候知道、中间层存的是什么。”

---

## 第一部分：它知道吗？

**实验 1：分组（Stage 1，第 3、4 页）**

**怎么做**：用组长的标签流程，在同一个 Qwen3-32B 上对 9,108 篇论文做两件事。第一，让模型自由列作者，按写对多少分成 R0（一个都没写对）、R1（写对少数）、R2（基本写对，不分析）。第二，做多选题：真名单加 3 个同领域、同规模、同引用档的真实团队，换 4 种顺序问。4 次全对、且真选项概率 ≥ 0.5 的叫 target（认得出），最多对 1 次的叫 control（认不出）。

**结果**：target 4,621 篇，control 2,220 篇。其中 R0 里认得出的有 4,110 篇，也就是“一个作者都写不对，但多选题每次都认得出”。另外做了一个检查：不给标题时，真名单被选为“最像真的”只有 25.5%，和四选一瞎猜一样。

**说明什么**：有大量论文属于“写不出但认得出”，这正是我们要研究的对象。多选题答对靠的是标题，不是名字听起来像。

**实验 2：怎么读模型、怎么打分（第 2 页）**

**怎么做**：提示是“Who are the authors of the paper titled ‘标题’ (年份)? Authors:”，后面接真作者名。在每一层取出内部状态，用读出工具变成“对下一个词的预测”，看正确名字 token 在整个词表里排第几，打分 log10(1/名次)。同一份名单再配 5 个假标题各跑一遍，假标题借自同领域、年份和规模相近的别的论文。真标题分数减假标题平均分，叫“标题特异信号”。

**说明什么**：名字一样、token 一样，减掉之后剩下的只能来自“认得这篇论文”，这是我们所有实验的基本量。

**实验 3：全队列逐层读出（Stage 10，第 6 页）**

**怎么做**：9,108 篇论文、全部作者名，在 6 个层用 4 种读出工具算标题特异信号，target 和 control 只在同一引用档内比较。

**结果**：用 public Jacobian lens，L24 到 L48 两组都约为 0；L62 上 target 平均 +0.56，control 平均 +0.24。模型输出层上，按引用档配对的 target − control 为 **+0.21 [0.20, 0.22]**。只用 R0 论文重算是 +0.20 [0.19, 0.21]，几乎不变。（组间比较只用 target 和 control，R2 和识别不确定的论文没有进入。）

**说明什么**：认得出的论文，模型确实带有论文特有的作者信息；按 L62 的 +0.56 换算，真作者的名次比假标题时好约 3.6 倍；即使一个作者都写不对，这份信息也在。但读出工具在中间层看不到它。

**实验 4：信号拆分（Stage 10）**

**怎么做**：把真标题的分数拆成三块：不给标题时也有的分（名字先验）、换成同领域假标题带来的分（领域主题）、只有真标题才有的分（论文特有）。

**结果**：+0.247 = 先验 +0.087 + 主题 −0.047 + 论文特有 +0.207。

**说明什么**：主要部分是论文特有的，不是“这个领域常见这些姓”。

**实验 5：独立复现（Stage 8）**

**怎么做**：在 200 篇新论文上，按事先冻结的分析计划重做，主终点是 7 层平均的 A − B 差。

**结果**：冻结计划的主终点（7 层积分）A − B 为 +2.41 个百分点 [+0.91, +4.00]，逐次剔除每一对论文重算 100 次都不跨 0。PROTOCOL.md 改定的 L56 终点，同一批 100 对，是 +4.98 个百分点 [+0.32, +9.91]，100 次里有 14 次区间跨 0。逐层检验做 Holm 多重比较校正后，只有 L62 仍显著。Holm 校正和逐对剔除是冻结计划里要求、但原代码没做，10 月 30 日补算的。

**说明什么**：主效应在新样本上能复现，而且不靠某几篇论文撑着；但逐层的显著性只在最后一层站得住，和“说得晚”一致。要主动说明：分析计划在 10-18 14:29 写定锁定（主终点为 7 层积分），同日 21:14 的 PROTOCOL 改为 L56，两者都早于 8C 打分；改动人和理由待查（U28）；我们把原定主终点和 L56 都报告了。

> 2026-11-08（报告第 30 版）：Stage 8 的结论（真标题让模型更偏好真实第一作者 RQ1；A 组强于 B 组 RQ2）较稳，但有三个前提：① W 只给第一作者名字的第一个 token 打分，在 Stage 8 的 200 篇里有 129 篇（64.5%）这个 token 只是首字母（audit_20261105/part_A_stage4_9.md 第 10 行）；② 偏离 D13-1：按补充 13 C-2 的规则，全部作者 CPU 代理只在 L56 的 RQ2 上与已发表结论不一致（+0.064 [−0.032, +0.163]，区间含 0），触发了按原 W 在 GPU 上重算，用户 2026-11-06 决定不做；在锁定计划的 7 层积分终点上（近似，Stage 10 没有 L16）代理 RQ2 为 +0.046 [+0.007, +0.088]（L16 = 0）或 +0.049 [+0.005, +0.094]（L16 = L24），同向、区间不含 0（381_stage13/reports/c13_C2.md；381_stage13/c13_C2_followup/c2_followup_proxy.csv）；③ U28：L56 在锁定计划里是探索性次终点，10-18 21:14 的 PROTOCOL.md 把它改为主终点，改动者和依据仍未查清。

---

## 第二部分：什么时候知道？

**实验 6：细层读出（Stage 10，第 11、12 页）**

**怎么做**：在主轮 L40、48、56、62 之外，补算 L50–L55 和 L57–L61（只用 logit lens 和 public lens），算 target − control。L41–L47 和 L49 没有算。

**结果**：L50 只有 +0.007，L62 达到 +0.23，**上升最快在 L57–61。**

**说明什么**：从读出工具看，“认得出”的优势只在最后十来层形成，这是“说得晚”。

**实验 7：读出工具比较（Stage 10，第 13–15 页）**

**怎么做**：比较 logit lens 和 3 把 Jacobian lens（用不同文本拟合）。

**结果**：logit lens 在 L48 前正确名字排在一万名以后；Jacobian lens 在 L48 能把 15–18% 的正确 token 排进前 10，logit lens 只有 1%。但 Jacobian lens 多读出的论文特有信号只有 +0.01 到 +0.03，而且不偏向 target。

**说明什么**：换更好的读出工具，中间层也看不到论文特有的作者信息。但“读出工具看不到”不等于“没有”，所以下一步要动手干预。

**实验 8：替换（Stage 11，第 9、10 页）**

**怎么做**：真标题跑一遍、假标题跑一遍。在第 l 层把真标题那遍“标题之后所有 token”的内部状态复制到假标题那遍，其余照常往后算，看真作者分数恢复了多少：恢复率 = (替换后 − 假) ÷ (真 − 假)，先对所有论文平均再相除。样本是 593 + 593 篇。

**结果**：L24 恢复不到 0.1，L40 约 0.3，**L48 约 0.82，L52 起约 1.0**；target 和 control 时间点一样。

**说明什么**：到 L52，论文信息已经全部在标题之后的位置上了，比读出工具看到它（L57–61）早 5 到 10 层。这是“读得早”的因果证据。

**实验 9：阻断（Stage 11，第 10 页）**

**怎么做**：从第 l 层到最后一层，禁止标题之后的所有位置去注意标题 token，看分数掉多少。

**结果**：从 L0 起挡损失约 0.83，从 L32 起约 0.37，**从 L52 起几乎为 0**。

**说明什么**：L52 以后模型不再需要看标题，和替换实验从相反方向得到同一个时间点。

**实验 10：两项加固（X6、X7）**

**怎么做**：X6：替换原来只用了一个假标题，现在用另外 4 个重做。X7：阻断可能“把模型搞乱”，所以在假标题那遍也做同样阻断，用真标题的损失减去假标题的损失。

**结果**：X6：5 个假标题平均，L48 恢复 0.82、L52 恢复 0.995，每个假标题和原来最多差 0.02。X7：从 L0 起挡，论文特有信号全部消失（1.0）；从 L52 起挡，target 只剩约 2%，control 约 5%，L56 起都是 0。

**说明什么**：时间点不是某个假标题碰巧造成的，阻断的结论也不是“搞乱模型”造成的。

**实验 11：信息落在哪个位置（Stage 12 P1，第 1 页）**

**怎么做**：替换时一次只换一个位置：冒号、年份数字、“Authors”、名字位置等。

**结果**：只换名字位置，L48 恢复 0.61、L52 恢复 0.85；只换冒号最多 0.17；其他单个位置都不超过 0.03。按 token 拆：姓的信息在名字位置本身，真假差约 0.5，是主体；首字母的信息经过冒号，但真假差只有 0.11。

**说明什么**：信息主要直接进入名字位置，主要体现在姓上。

**实验 12：哪个部件在起作用（Stage 12 P2，第 1 页）**

**怎么做**：只替换某一层的注意力输出，或只替换 MLP 的输出，替换范围是整段对齐尾部（右引号、年份、“Authors”、冒号）加全部名字位置，不只是名字位置。

**结果**：L48 注意力恢复 0.23，同层 MLP 只有 0.07；L52、L56 的 MLP 分别恢复 0.18、0.22。L44 之前任何单个部件都不超过 0.03。

**说明什么**：先由 L48 的注意力把标题信息搬进名字位置，再由 L52–56 的 MLP 加工。要说明两点：只换一层是下限；MLP 那一步是不是“查记忆”，这个实验分不出来。

**实验 13：标题位置的 probe（Stage 11 E4b，第 7、8 页）**

**怎么做**：取标题最后一个 token 的状态，用 5 折 ridge 回归学一个线性映射，预测模型自己在冒号处最后一层的状态，因为那个状态直接决定说出的第一个名字。再把预测结果变成对名字 token 的打分。按作者团队分折，剔除“标题在训练中出现过”的论文，剩 1,863 篇，E4b 信号只用其中 target + control 的 1,395 篇。全部作者、全部名字 token、按角色（补充 9，预注册版 V0，只减 false_0）L24 / L40 / L56：名的第一个 token +0.098 / +0.124 / +0.163，姓的第一个 token +0.058 / +0.071 / +0.098，首字母 +0.021 / +0.044 / +0.054（旧版只打首 token：L24 +0.050、L40 +0.061、L56 +0.075）。原版标准化用了全部论文（含测试折），复核时改为只在训练折内标准化；两种标准化差别最大 0.0007，结论不变。

**结果**：全部作者全部名字 token 按角色从 L16 起各角色都为正（L40 名首 token +0.124、姓首 token +0.071、首字母 +0.044）；target − control（同一引用档内，全部作者全部名字 token 按角色，措辞 B 第 3 版）：预注册版中名的第一个 token 在 L24–L48 为正，姓在 L24–L48 不显著（L40 +0.012 [−0.026, +0.048]）；事后的逐个排除版中姓从 L24 起为正（L40 +0.030 [0.013, 0.048]）。名的信号在三版中一致；姓的证据弱，只来自事后版本。首字母在个别层为正、模式不一致（未做多层校正），不作结论。（旧版只打首 token：从 L24 起 +0.05 到 +0.08，target 比 control 高 +0.03 到 +0.08。）换成别的论文或同领域论文的作者打分，约为 0。

**说明什么**：标题位置很早就有一点线性可读、属于这篇论文的作者信息，读出工具读不到。信号很小，名次只好 1.2 倍，而且只打分了第一个名字 token（多是首字母），所以它是辅助证据，主要证据还是替换实验。

> 补充 9（答辩后新增，分析计划在看结果前写定）把这个 probe 扩展到每位作者的全部名字 token 并按角色分开：L40 姓的第一个 token +0.071 [0.058, 0.085]（预注册版 V0：只减 false_0，目标 + 对照 1,395 篇，剔除标题复用，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md），高于首字母 +0.044 [0.030, 0.057]（1,590 篇）；名的第一个 token 最强（L40 +0.124、L56 +0.163（1,706 篇））。原 E4b 只打分第一个 token（多半是首字母），所以低估了标题位置携带的名字信息。

**实验 14：层序汇总（X5）**

**怎么做**：把前面各实验的“最早出现层”放到同一条层轴上。

**结果**：标题位置的论文属性 ≤ L8–L16 就读得出；替换在 L48 恢复一半、L52 超过 95%；名字位置用读出工具读出作者要到 L53–L62。

**说明什么**：一张图把“读得早，说得晚”的时间线完整串起来。

---

## 第三部分：中间层存的是什么？

“既然信息在中间层就有，读出工具却看不到，那中间层里存的是什么形式？我们提了三个假设：H1 是任务和格式，‘我要输出作者名单’；H2 是论文身份，‘这是哪篇论文’；H3 是作者其实已经在了，只是不在词表方向上。”

**实验 15：中间层排第一的是什么（M1）**

**怎么做**：不看正确名字排第几，而看名字位置上读出工具排第一的是什么词。

**结果**：L24–L48，100% 是句号、换行这类句末符号；L51–52 起出现 Robert、Zhang 这样的常见名字；正确名字在 L52 只占 0.1%。

**说明什么**：读出工具在名字位置看到的是“格式”，支持 H1。

**实验 16：读论文的其他属性（M2、M2c）**

**怎么做**：在标题最后一个 token 上训练 probe，读年份、引用数、领域、认不认得出。这个位置还没看到年份，不会泄题。对照：打乱标签；冒号位置读年份作阳性对照（那里已经看到年份）；用只读标题文字的 BERT 作基线。

**结果**：年份 $R^2$ 从 L16 的 0.38 升到 L52 的 0.56，引用数 0.29 → 0.53，领域准确率约 0.71（打乱标签只有 0.13），认得出 AUROC 0.62 → 0.67。BERT 分别是 0.24、0.19、0.63。冒号位置读年份 $R^2$ 0.98。

**说明什么**：标题位置很早就有论文属性，年份和引用数明显超过只看文字的 BERT，支持 H2。但“认不认得出”BERT 也能做到 0.63，所以这一项不作证据；而且按预注册，Qwen 胜过 BERT 只作参考。

**实验 17：换问法（M3、X1）**

**怎么做**：同一个标题，换成问作者、问年份、问领域三种问法，看标题位置的状态变不变。X1 更进一步：把“问年份”时的标题状态替换进“问作者”那遍，看作者分数能否恢复。

**结果**：M3：同一篇论文换问法，状态几乎不变，但这在 L4（几乎只有文字）就已经如此；按预注册要比 L4 高才算数，结果不高于 L4。X1：替换后作者分数恢复得和用“问作者”的状态一样好，差别在预注册的 ±0.1 以内；冒号位置相反，换问法时变化是换论文的 3–5 倍（L4–L40；L48 约 2.2 倍，L56–L63 为 1.3–1.5 倍）（x1_similarity.md colon 表）。

**说明什么**：冒号位置存的是任务，支持 H1。标题位置跨问法通用，但 M3 显示这可能只是因为三种问法的标题文字相同，所以 M3 不支持 H2。

**实验 18：改写标题（X3，最关键的区分实验）**

**怎么做**：同一篇论文的标题换个说法，和一篇用词相近的别的论文 D 比：如果模型认的是“论文”，改写版应该更像原标题。扣掉 L4 的文字水平，再控制用词重合度。

**结果**：L28–L40 改写版比 D 更接近原标题，L36 最大 +0.16；行为上，改写标题保留了原标题约 90% 的作者优势。按预注册判据，这算“存在论文身份信号”。但我们看到结果后又加了两项检验：只懂语义、不认识作者的句子向量模型在用词匹配的论文上也能做到差不多；而且 target 和 control 完全一样，行为 0.90 对 0.91，表示层 0.158 对 0.160。

**说明什么**：Qwen 中间层表示了标题的“意思”而不只是用词，但分不清是认出了论文还是懂了意思。我们把解读降为“语义表示”，预注册的结果和事后检验都如实报告。

**实验 19：Patchscope（X4）**

**怎么做**：把论文的标题状态注入一个只有占位符的新提示，比如“这篇论文发表于”，看模型能不能说出年份或第一作者。另外用只读标题文字的模型作基线。

**结果**：第一作者 L8 就能解码出一点（+0.046）（全作者版本同样从 L8 起可解码：测试集 +0.048 [0.039, 0.058]），年份要到 L40（+0.013）。但只靠标题文字的基线在名字首 token 上不弱于 Qwen。

**说明什么**：作者信息出现得很早，但不能排除来自标题文字，所以单看 X4，H3 证据不足（H3 总体判断见名字位置 probe：部分支持）。而且“先作者后年份”的顺序和 H2 预测的方向相反。

**第三部分小结**

“三个假设的结论是：H1 在冒号和名字位置成立；H2 部分支持但未确立，标题位置有论文属性和语义，但我们专门设计的区分实验 M3、X3、X4 都没能证明是‘认出论文’；H3 部分支持（名字位置 probe，补充 11）。”

---

## 收尾

**怎么保证可信**：“Stage 13 所有判定规则都在看数据之前写定；所有 probe 按作者团队分折防泄漏；每个结论都配阳性、阴性对照和文本基线；置信区间按作者团队重抽。过程中我们自己查出过假标题复用的泄漏、一个预注册判据用错、一个文本基线的代码错误，都修正了，结论该降级的降级，旧结果保留。”

**局限**：“只用了一个模型；测的是把正确名字放进去打分的偏好，不是真实生成；读出工具的稳定性只有一份拟合证据。”

> 2026-11-12：**C24 模型自己写出的名字：真作者与编造的名字可在名字 token 上线性区分（较稳但有前提；补充 15，批次 2 第 2-11b 项）：**Qwen3-32B 自己写作者名单时，名字写出之后，名字 token 上的中间层残差能线性区分真作者与编造的名字（补充 15 预注册主分析，名字 token 平均；L16–L56 七层都同时胜过排位基线和名字特征基线，例如 L48 AUROC 0.782 [0.754, 0.812]，probe − 排位 +0.151 [0.111, 0.190]，probe − 名字特征 +0.234 [0.186, 0.284]；打乱标签 0.455–0.510）；名字写出之前的位置读不出（次分析，AUROC 不高于排位基线）。前提：在 chat 模板下现场生成的文本上测得，不是其他实验用的原始提示；标签来自规则匹配（matcher v3b）；control 组只作描述（51 个真名）；“probe 信号可能部分来自输出置信度”这一替代解释尚未排除（生成时 token 对数概率 / 熵基线未做）；事后的名气基线（事后，探索性）：只用名气 0.548 [0.519, 0.576]，probe −（排位 + 名字特征 + 名气）在每层仍 > 0（L16 +0.045 [0.008, 0.081] … L48 +0.104 [0.067, 0.139]），名气只覆盖数据集内出现过的情况。补充 15 没有写它与 H3 的关系，不作为 H3 的证据；与 H3 的关系未预注册，只作讨论。（381_stage13/reports/b2_gennames_b_report.md；b2_gennames_b_robust_posthoc.md；团队整群 bootstrap 2,000 次）**Patchscope（批次 2 第 2-7、2-9 项，补充 12；只作描述）：**用名字位置作源时，第一作者在 L8–L16 约为 0，L40 +0.006 [0.004, 0.008]，L48 +0.014 [0.011, 0.017]（标题位置作源 L40 +0.068 [0.056, 0.080]）；“:” 位置作源到 L40 约为 0，L48 +0.012 [0.009, 0.015]；x4tok 标题位置作源、姓的第一个 token 在 L40 最高 +0.124 [0.099, 0.148]（以上为预注册要求报告、无判定规则；认得出的 target − control 与 name_all 源的 x4tok 部分为探索性）。不据此讨论 H3。（381_stage13/reports/b2_ps_report.md）

> 2026-11-09：**名字位置 probe（批次 2 第 2-5 项，补充 11 A，已完成；H3 改为部分支持）：**按补充 11 预注册判据，姓首 token 在 L40/L48 满足 H3（名字位置 probe，逐个假标题排除版；probe L40 +0.069 [0.064, 0.074]、L48 +0.103 [0.097, 0.110]；target − control L40 +0.031 [0.019, 0.044]、L48 +0.053 [0.038, 0.067]）；事后检验：lens 的区间同样不含 0（logit L40 +0.010 [0.005, 0.014]；J-lens L40 +0.048 [0.042, 0.054]），且两者尺度不同、无法比较大小，因此降为'部分支持'。名和姓的后续 token 在 L40 与 J-lens 比较时不满足判据（b2_np_report_v2.md 第 373、377 行）。首字母的对照行（+0.020 [0.015, 0.026]）约为信号（+0.045 [0.039, 0.051]）的一半，约一半信号不是论文特有的。前提：主结果为逐个假标题排除版（Vpd，D11-1，每篇平均约 1.5 个可用假标题）；对照行用同一组假标题（D11-1 第 2 版，一致性检查 PASS）；姓的置换对照约为 0（L40 −0.005 [−0.009, +0.000]）。以下只作描述：同一引用档内 target − control（预注册要求报告、无判定规则）；按行为分组，A − B 姓 L40 +0.030 [0.017, 0.042]（预注册要求报告、无判定规则；D 组和 n < 30 的组只作描述）；lens 的 target − control（探索性）；逐层峰值和逐层上升（探索性）。V0（1,395 篇，姓 L40 +0.066 [0.056, 0.077]，target − control L40 +0.030 [0.005, 0.057]）和 V5x0（L40 +0.065 [0.057, 0.073]；含泄漏，仅敏感性）只作敏感性。
>
> （381_stage13/reports/b2_np_report_v2.md；summary_b2_np/np_role_layer_v2.csv、np_lens_compare_v2.csv；团队整群 bootstrap 2,000 次）

2026-11-08（报告第 30 版）：**P1 / P2 用 5 个假标题（批次 1 第 3 项，已完成，硬检查 PASS）：**按补充 10 第 27 行，5 个假标题平均为主结果，原 false_0 版并列。两版所有“5 个假标题平均 − false_0”的区间都含 0（差的绝对值 0.001–0.006，在批量舍入噪声的量级内：组级最大 0.0148），已发表结论不变：论文信息在 L44–L52 汇集到名字位置，注意力在 L48 读入，MLP 在 L52–L56 接手。5 个假标题平均（括号内为 false_0）：P1 全部位置 L48 +0.821 [0.807, 0.835]（0.825）、L52 +0.995 [0.990, 1.001]（0.996）；P1 只换名字位置 L52 +0.841 [0.827, 0.856]（0.847）；P2 注意力 L48 +0.237 [0.229, 0.246]（0.231）；P2 MLP L52 +0.181 [0.174, 0.188]（0.178）、L56 +0.226 [0.217, 0.236]（0.224）（补充 10 第 3 项，Stage 11 样本 1,186 篇，团队整群 bootstrap 2,000 次 95% CI；391_groups/reports/b1_p12f_report.md P1 / P2 表；summary_b1_p12f/p12f_mean5.csv）。p9 位置（标题的右引号；只有共享尾长为 9 的论文，平均每篇约 3 个可用假标题）：各假标题 694–711 篇，集合不同，未加权（summary_b1_p12f/p12f_per_title.csv，item = p9：false_0 708、false_1 694、false_2 711、false_3 707、false_4 710 篇）。“:” 位置的分子 B/A：5 个假标题版 0.72–0.87，false_0 版 0.78–0.99；B 的比例高只因分母约为 A 的一半（P1 只替换 “:”，未写出作者，A 557 / B 586 篇：5 个假标题版 L44 0.72、L48 0.87，分母 B/A 0.51（b1_p12f_report.md “B - A” 表）；false_0 版 L44 0.78、L48 0.99（391_groups/summary_rerun/p1_p2_num_den_B_minus_A.csv））。硬检查：false_0 臂复现已发表值（最大差 2.2e-16），PASS。**C / D 组补全 E1 / E2（批次 2 第 2-6 项，补充 11 B，已完成）：**C 组未写出作者 462 篇，同一引用档内与 A 相比（6 个引用档，C 258 篇、A 323 篇）：E1 恢复比例 L48 −0.037 [−0.080, +0.009]，L52 +0.007 [−0.009, +0.024]；L56 −0.007 [−0.014, −0.001]，个别层差异极小，不作解释（小于批量舍入噪声：同一输入按 batch 1 和 15 元素 batch 计算，组级 E1 恢复比例的差最大 0.0148（L40），L52 约 0.002，只给分布、没有 CI；补充 12 第 2-4 项，381_stage13/reports/b2_e1noise.md）；E2 阻断损失 L32–L52 区间都含 0。C 的真假标题差距更大：分母 C 0.559 [0.529, 0.590]、A 0.407 [0.386, 0.430]，同档内 C − A +0.075 [+0.024, +0.130]。也就是说，C 的信号更大，但时间点与 A 相同。D（33 篇）按补充 11 只作描述，D − B、C − D 也只作描述（补充 11 B；未写出作者；团队整群 bootstrap 2,000 次 95% CI；391_groups/reports/b2_cd_report.md Numerator / denominator 表与 Contrasts 表；硬检查：重跑 Stage 11 第 0 号分片，差 0.0（容差 0.005），PASS）。前提：同一引用档内只用到 C 462 篇中的 258 篇；分子、分母都只用 false_0；比例差主要反映分母不同（分母效应）。X4 中认得出的论文第一作者 D 更高（测试集不显著）这一差别不再作为 H2 的证据（只看标题文字的 BERT 基线 +0.088 不弱于 Qwen L8 +0.018）。**2026-11-08（报告第 30 版）补充的局限：**层不完整：Stage 10 在 L24–L40 每 8 层取一层（没有 L25–L31、L33–L39），没有补层计划（补充 14 的 3-1 已补 L41–L47、L49，2026-11-12 完成；3-2 补 L0–L23，运行中，194 / 504）。主要结论的起始层都不在缺口里；落在缺口里的只有三条描述：X4 年份最早可读出层 L40（前一个测量层是 L32，真实起点在 L33–L40 之间）、Stage 10 真标题下 Jacobian lens 从 L40 起明显好于 logit lens（跳变在 L33–L40 的哪一层不知道；3-1 补测后，标题特异信号上 J-lens 在 L41–L46 为 +0.007 到 +0.014、logit 约为 0，到 L47 两者几乎相同（J-lens +0.001 [−0.005, +0.006]，logit −0.003））、X4 第一作者峰值 L40（真实峰值可能在 L33–L47）。“L24–L48 约为 0”在 L25–L31、L33–L39 没有测过；3-1 补测的 L41–L49 上，logit 的 target − control 都在 ±0.005 以内、从 L50 起为正（起始层不变）；public J-lens 的 target − control 在 L41–L55 为负、L56 约为 0（+0.007 [−0.014, +0.029]）（L41 −0.017 [−0.032, −0.002]，L47 −0.035，L49 −0.043）、从 L57 起为正，“中间层没有领先”仍成立（3-1 用团队整群区间，Stage 10 已发表的是论文 bootstrap 区间，点估计相同；381_stage13/reports/b3_3_1_report.md）（~/jlens_work/conclusions_v30_checks.md A1）；一致性容差事后放宽，而且用到了：Stage 10 一致性检查的容差在看到结果后从 0.25 放宽到 0.5（用户 2026-10-25 批准）。主轮 25 个（读出 × 层）组合的最大差 0.367，只有按 0.5 才通过；全部名次 < 42 完全一致，名次不一致使 log10(1/名次) 最多变 0.070。原定 0.25 时，Stage 10 主轮一致性检查（12 个上下文、52 个 token 位置）的 25 个 lens × 层组合中有 10 个超出 0.25，最大差 0.367（351_stage10/reports/parity_before_tol05_amendment.json）；3-3 在 7 篇论文的 23,280 行上按 0.25 计 99.81% 在容差内。这一量级与 3-3 查明的 bf16 舍入随前向长度变化（最大约 0.46）一

> 致，但容差是在看到数据后放宽到 0.5 的，属于事后修改。批量大小本身造成的组级 E1 恢复比例差最大 0.0148（L40），单 token 的 log10(1/名次) 差 p99 最高 0.22（补充 12 第 2-4 项，381_stage13/reports/b2_e1noise.md）。保留在事后改动清单里（351_stage10/reports/parity.json tolerance_amendment；parity_before_tol05_amendment.json；conclusions_v30_checks.md A2）；干预只用了 1,186 篇：E1、E1t、E2、E2n、P1、P2、F2、X6、X7 只用 9,108 篇中的 1,186 篇（target 593 + control 593，每档每组最多 60 篇，10 档），作为局限，不重做（361_stage11/summary/E1_recovery.csv n_papers）；分母效应：恢复比例 = 分子 ÷ 真假标题差距，组间比较受分母影响：C 0.559 对 A 0.407（C / D 组补全）；":" 位置分子 B/A 5 个假标题版 0.72–0.87、false_0 版 0.78–0.99；B 组比例偏高只因分母约为 A 的一半。C / D 组补全与 P1 / P2 五个假标题的结论都以此为前提；只用 false_0、没有补做计划：M5 B 部分（真标题对 false_0 的标题 / ":" 位置 probe）和 E4b 的 X1 对照流程只用 false_0，没有计划；M2 已不在此列：M2 的假标题运行已补 5 个假标题；标题复用和供体在训练折的排除对每个假标题都为 0 行（exclusion_audit.csv）；另有约 7,240–7,370 行/假标题的供体论文以 target 行出现在训练折中（显示另一篇论文的标题和标签，只有年份在 ':' 之后进入提示），未作为泄漏处理（381_stage13/reports/m2_f5_report.md；381_stage13/summary_m2_f5/M2_f5_mean.csv、exclusion_audit.csv（作业 11747064））；数字核对只覆盖已登记的部分：已登记 680 个结论数字、4,307 处全部一致（第 29 版 h 的核对）；第 30 版新放回或新增的数字已登记进严格核对（claims_defs_v9，结果见核对表）；另约 1,024 个结论性数字未登记（2026-11-07 计数）（351_stage10/reports/numcheck/claims/out_20261108_140102/）。

**请教**："下一步我们考虑换一个模型复现，或者用模型不可能见过的虚构论文做对照，来区分'认出论文'和'懂得意思'。想听您的意见。"