项目进度汇报：Qwen3-32B 在哪一层“记住”论文作者

汇报人：Zhiqi Zhang ｜ 截至 2026-11-03 ｜ 代码与结果 tag：`defense-2026-11`

一、一句话总结

对于模型**写不出作者、但多选题认得出**的论文，Qwen3-32B 内部确实带有这篇论文特有的作者信息：标题信息在 **L44–52** 被读进名字位置，到 **L52** 已全部到位，但要到 **L57–61** 才变成读出工具能看到的名字。我们称之为“**读得早，说得晚**”。中间层里存的是什么，我们检验了三个假设：任务/格式在冒号和名字位置成立；“论文身份”只得到部分支持，所有专门用来区分“认出论文”和“读懂标题意思”的实验都没能证明前者；“作者已经在那里”证据不足。

二、研究问题

模型经常编造论文作者。我们想知道：**它是真的不知道，还是知道但说不出来？**如果是后者，信息存在哪一层、哪个位置，又是在哪一步才变成说出口的名字。

核心思路是**对比**：同一份作者名单，配真标题和配假标题（借用同领域另一篇论文的标题）各跑一遍，两者之差只能来自“认得这篇论文”。再把论文分成“认得出”和“认不出”两组比较。

三、数据与分组

论文：9,108 篇，来自 Dreaming Up Authors 代码包（dua 1.0.0）的分层样本：从 OAG v2 抽取、经 5 道过滤剩 1,921,209 篇，再按 8 个领域 × 13 个引用档、每格最多 100 篇取样。标题、年份、作者、引用数来自 Semantic Scholar 2025 年 9 月快照。我们的 9,108 篇和包里逐篇一致。

标签：组长用 elm 流程在同一个 Qwen3-32B 上生成，我们原样使用。

1. **开放回答**：关闭 thinking、贪心解码、最多 96 token，用 NameMatcher（姓 + 名首字母）匹配，按写对比例分 R0（一个都没写对）、R1（写对少数）、R2（基本写对，作为 guard 不分析）。
2. **多选题**：真名单加 3 个同领域、同规模、同引用档的真实团队，换 4 种顺序问。4 次全对且真选项概率 ≥ 0.5 为 **target**，最多对 1 次为 **control**。

	target（认得出）	**control（认不出）**
R0	A = 4,110	B = 2,186
R1	C = 511	D = 34
合计	**4,621**	**2,220**

多选题是否只是“名字听起来更像”：不给标题时，真名单被选为最像真的比例是 25.5%，等于四选一瞎猜（Stage 12 N1），所以多选答对依赖标题。

假标题：每篇论文 5 个，同领域、保留本论文年份，按年份、作者人数、标题长度、引用档的加权差最小匹配，要求无共同姓氏、标题词重合 ≤ 0.6。

四、实验体系

1. 按研究问题划分 Stage

Stage	问题	方法
1–2	分组和提示词是否可靠	标签核对、提示词验证
3	读出工具能不能用	搭建和校验 Jacobian lens
4–7	小样本上有没有信号、能否排除替代解释	20–200 篇，交叉标题、完整作者名、多种对照
8	独立样本能否复现	200 篇新论文，冻结分析计划
9	读出工具是否稳定	重新拟合 lens（只完成 Fit A）
10	全队列逐层“看”	9,108 篇 × 4 种读出工具
11	动手干预，信息什么时候到位	替换（patching）、阻断（knockout）、probe
12	定位到具体位置和部件	逐位置替换、注意力 vs MLP、名字先验
13	中间层到底表示什么	三个假设，M1–M4、X1–X7 共 11 项实验

2. 四条论证线

- **A 线：是这篇论文吗？**真标题 vs 假标题，论文特有信号是否存在。
- **B 线：读出工具可不可靠？**多种 lens 交叉比较、probe、文本基线。
- **C 线：发生在哪一层？**读出曲线、替换、阻断、层序汇总。
- **D 线：落在哪个 token？**首字母、名、姓分开看。

3. 主要工具

工具	回答什么	做法
logit lens / Jacobian lens	某一层“想说”什么词	把中间层状态（经线性近似搬到最后一层）直接变成词表打分
probe	信息是否线性可读	5 折 ridge 回归，从内部状态预测答案，在没见过的论文上测
替换（patching）	信息何时、在哪里被用到	把真标题那遍某层某位置的状态塞进假标题那遍，看恢复多少
阻断（knockout）	之后还需不需要标题	从第 l 层起禁止标题之后的位置注意标题
Patchscope	状态里能解码出什么	把状态注入只有占位符的新提示，看模型说出什么
文本基线	是否只是标题用词	BERT、TF-IDF、句子向量模型读同样的标题

打分：正确名字 token 在全词表的名次，取 log10(1/名次)。两个分数差 d 等于名次好了 10^d 倍，比如 +0.21 是 1.6 倍，+0.44 是 2.75 倍。

五、主要发现

发现 1：认得出的论文，模型确实带有论文特有的作者信息（A 线）

- 最后一层 L62，真标题比假标题对真作者的分数高约 0.44，相当于名次好 2.75 倍。
- 分组看：target +0.56，control +0.24；**target − control 在输出层为 +0.21 [0.20, 0.22]**，几乎全部是论文特有的部分。
- 只用 R0（一个作者都没写对的论文）重算，差值 +0.199，和全部 +0.207 几乎一样：**写不出作者的论文里，模型照样"知道一些"。**
- **独立复现（Stage 8）**：在 200 篇新论文上，按冻结计划的主终点（7 层积分），A − B 为 +2.41 pp，逐对剔除 100 次都不跨 0。逐层检验做 Holm 校正后，只有 L62 仍显著。
- **拆分**：真标题带来的 +0.247 = 名字先验 +0.087 + 领域主题 −0.047 + 论文特有 +0.207。
- **引用数越高信号越强**：Spearman ρ = 0.45。

发现 2：说得晚——名字到最后几层才读得出（C 线）

- 中间层 L24–L48，两组的论文特有信号都约为 0。
- 逐层细看：target − control 在 L50 只有 +0.007，L62 达 +0.23，**上升最陡在 L57–61。**
- 所有读出工具一致：logit lens 在 L48 之前正确名字排在一万名以后，L62 跳到约第 10 名。Jacobian lens 在中间层多读出的部分只有 +0.01 到 +0.03，而且不偏向 target。

发现 3：读得早——信息在 L44–52 就已到位（C 线，因果证据）

- **替换**：把真标题那遍标题之后的状态塞进假标题那遍，L48 恢复约 0.82，L52 起约 1.0。
- **阻断**：从 L52 起挡住对标题的注意力，几乎没有损失。
- **两项加固**：
  - X6 用另外 4 个假标题重做替换，L48 平均 0.82、L52 平均 0.995，每个假标题和原来最多差 0.02。
  - X7 在假标题那遍也做阻断并扣除，"论文特有损失"从 L0 起挡是 1.0（全部消失），从 L52 起挡 target 约 2%、control 约 5%，到 L56 两组都为 0。所以阻断结论不是"把模型搞乱"造成的。
- **层序汇总（X5）**：标题位置的论文属性在最早测到的层（≤ L8–L16）就读得出；替换在 L48 恢复一半、L52 超过 95%；名字位置用 lens 读出作者要到 L53–L62。

发现 4：信息落在名字位置本身，先注意力后 MLP（D 线、Stage 12）

- **逐位置替换（P1）**：只换名字位置，L48 恢复 0.61，L52 恢复 0.85；只换冒号最多 0.17；其他单个位置都不超过 0.03。信息主要直接进入名字位置，不是先存在标题后面的 token 上。
- **按 token 拆**：首字母的信息经过冒号，但首字母本身真假差只有 0.11；**姓**的信息在名字位置本身，真假差约 0.5，是信号主体。
- **按部件替换（P2）**：L48 注意力恢复 0.23（同层 MLP 0.07）；L52、L56 的 MLP 恢复 0.18、0.22。顺序是注意力先把标题信息读进来，MLP 再加工。单层替换只是下限；MLP 那步是否是"查记忆"，这个实验分不出。

发现 5：标题位置有一点线性可读的作者信息（B 线）

- probe 从标题最后一个 token 读作者，在按作者团队分折、剔除标题复用后（1,863 篇），从 L24 起 +0.05 到 +0.08，target 比 control 高 +0.03 到 +0.08。原版标准化用了全部论文，改为只在训练折内

标准化重算后，L40 为 0.061、L56 为 0.075，结论不变。

- 换成别的论文、同领域论文的作者打分，约为 0，说明信号属于这篇论文。
- 局限：只给每位作者的第一个名字 token 打分（73% 是首字母），只减了一个假标题。补充 9（答辩后新增，分析计划在看结果前写定）把这个 probe 扩展到每位作者的全部名字 token 并按角色分开：L40 姓的第一个 token +0.071 [0.058, 0.085]（目标 + 对照 1,395 篇，剔除标题复用，团队聚类 95% CI；381_stage13/reports/e4b_alltok.md），高于首字母 +0.044 [0.030, 0.057]（1,590 篇）；名的第一个 token 最强（L40 +0.124、L56 +0.163（1,706 篇））。原 E4b 只打分第一个 token（多半是首字母），所以低估了标题位置携带的名字信息。减 5 个假标题平均的版本还在运行。

发现 6：中间层表示什么——三个假设的检验结果（Stage 13）

假设	判断	依据
H1 任务 / 格式	成立（冒号和名字位置）	lens 在中间层名字位置 100% 把句末标点排第一；换问法时冒号位置的变化是换论文的 3–5 倍
H2 论文身份	部分支持，未确立	支持：标题位置能读出年份（R^2 0.38→0.56）、引用数（0.29→0.53）、领域（准确率约 0.71，打乱标签 0.13），BERT 只读标题分别是 0.24、0.19；跨问法替换（X1）恢复作者分数差别在 ±0.1 内。不支持：M3 按预注册不高于 L4 的文字水平；X4 先解码出第一作者（L8）再解码年份（L40），和 H2 预测的顺序相反；X3 见下
H3 作者已在、只是不在词表方向	证据不足	专门用作者提示拟合的 lens 也读不出；probe 从 L8 起有作者信号，但只靠标题文字的基线不弱于 Qwen，不能排除文字解释

X3 是最关键的区分实验：同一篇论文改写标题，和一篇用词同样相近的别的论文比。

- 结果：改写版在 L28–L40 比近邻更接近原标题（L36 最大 +0.16），行为上保留原标题约 90% 的作者优势。按预注册判据，这算“存在论文身份信号”。
- 但我们事后加了两项检验：只懂语义、不认识任何作者的句子向量模型在用词匹配的子集上也有相当优势；而且 target 和 control 完全一样（行为 0.90 对 0.91，表示层 L36 为 +0.158 对 +0.160）。
- 所以我们把解读降为“中间层表示了标题的**意思**而不只是用词”，分不清是认出论文还是懂得意思。预注册判据的结果和事后检验都如实报告。

六、如何保证实验的系统性与可信度

1. **预注册**：Stage 13 的每个判定规则都在看到数据之前写定，原始文件加 5 份补充，均有 sha256 并只读保存；文件修改时间和 git 时间证明写定早于数据。
2. **严格的对照设计**：每个主要结论都配阳性对照（如冒号位置读年份 R^2 0.98，证明方法测得出）、阴性对照（标点 token、换成别人的作者）和打乱标签对照。
3. **防泄漏**：所有 probe 按作者团队分折（共享任一作者全名即同组，7,247 个团队）；剔除“同一个标题既当真标题又借给别人当假标题”的论文；标准化改为只在训练折内做（重算结论不变）；分折存档，所有脚本读同一份。

4. **统计**：target 和 control 只在同一引用档内比较并加权；置信区间改为按作者团队整群 bootstrap；Stage 8 补做 Holm 校正和逐对剔除。
5. **多工具交叉验证**：4 把读出工具、probe、替换、阻断、Patchscope、3 种文本基线，从不同方向回答同一问题。
6. **复现检查**：每次改代码重跑，都先用原设置复现旧数字（例如 X6 重算 false_0，516 行 × 15 层逐个相同）。
7. **结论随证据调整**：凡是新检验不支持的，就降级并写明，不删旧结果（见第七部分）。
8. **完整记录**：方法手册 290 页，每个数字追到脚本行号、结果文件、作业号和 commit；查不到的标“未知/需确认”。代码和结果打 tag `defense-2026-11`。

七、自查中发现并修正的问题

问题	影响	处理
假标题被重复借用，同一标题出现在训练和测试	M2 的假标题结果虚高	作废
probe 没按作者团队分折	结果可能偏高	全部改为按团队分折重跑，结论不变
一个标题既当真标题又当假标题	probe 结论可能虚高	剔除后重跑（剩 1,863 篇），信号仍在；“只用假标题训练信号更强”一说撤回
置信区间按论文独立重抽	区间偏窄	改为团队整群 bootstrap，点估计不变
Stage 11 替换范围包含名字位置	“信息存在标题后 token 上”的解释不对	Stage 12 拆开后改为“进入名字位置”
替换只用一个假标题、阻断可能搞乱模型	时间点可能偶然	X6、X7 补做，结论成立
Stage 8 主终点在冻结后被改成 L56	可能“挑了有利终点”	补报原定主终点（仍显著）、Holm、逐对剔除
M3 自动判定没按预注册规则	H2 被过度支持	按补充 2 重判为不支持
X4 文本基线代码错误、阳性对照失败	H3 被过度支持	修正后结论反转为“不能排除文字解释”
几个区间和数字找不到计算文件	无法复现	从原始数据重算替换，数值都在原范围内

八、局限

1. 只用了一个模型（Qwen3-32B），层数和机制是否适用于其他模型未知。
2. 全部结论基于“把正确名字放进去打分”的教师强制偏好，不是模型自由生成时的行为。

3. 读出工具的拟合稳定性只有 Stage 9 Fit A 一份证据；Fit B 与 holdout 已列入重做计划（补充 12，批次 2），尚未运行。
4. bf16 一致性容差在看到差距后从 0.25 放宽到 0.5（原记录保留）。
5. 高引用档几乎没有 control 论文，结论主要来自中低引用论文。
6. 单层替换只给出下限；MLP 是否在“查记忆”无法区分。
7. 标签流程的部分细节（干扰团队抽法、elm 版本等）还需组长确认。

九、目前状态与下一步

实验状态：Stage 1–8、10–12 全部完成；Stage 9 只完成 Fit A（Fit B 与 holdout 已列入重做计划）；Stage 13 完成 M1–M4、X1–X7（X2 于 2026-11-05 完成），M5 的 CPU 部分已完成。重做计划（补充 10–13，规则都在看结果前写定）进行中：已完成 X7 五个假标题、补充 9 全部名字 token 的 probe、CPU 项 C-1 到 C-5；X1–X4 全部作者、P1/P2 五个假标题、E4b 减 5 个假标题还在运行（批次 1）；Stage 9 Fit B 与 holdout 等在批次 2（补充 11、12）。

待确认：

- 向组长确认 6 项标签流程细节（elm 代码和运行记录、多选题 thinking 设置、名字切分规则、干扰团队抽法、et al. 截断规则、运行配置）。
- Stage 8 主终点改动的来由，正在查当时的会话记录。

可能的下一步（希望听取老师意见）：

1. 换一个模型复现主要结果，检验“读得早、说得晚”是否普遍。
2. 在模型自由生成时检验，看内部信号能否预测它最终写对还是写错。
3. 设计新的实验区分“认出论文”和“懂得标题意思”，比如用模型不可能见过的虚构论文作对照。
4. 补完 Fit B，加固读出工具的稳定性证据。

十、材料索引

材料	链接
实验报告（主报告；当前 v29，2026-11-06）	https://claude.ai/artifact/QB335qoaBWvSdFyfvc2bSe
方法手册（全部实验的材料、工具、步骤、出处）	https://claude.ai/artifact/W7r7xVte3eaNcbo8D8cybo
汇报 PPT（当前 v20，82 页）	https://claude.ai/artifact/XcgK4YF2dYQxudWfhk8MsD
下载页（所有 PDF 和 pptx）	https://claude.ai/artifact/5Tdt1mQa8xnPiqQEKvjzta